

Học máy tự động và giải thích dựa trên SHAP về quá trình loại bỏ PFOA bằng phương pháp oxy hóa điện hóa



1. Giới thiệu



* Tác giả liên hệ tại: Khoa Kỹ thuật Xây dựng và Kỹ thuật Môi trường, Đại học Dầu khí và Khoáng sản King Fahd (KFUPM), Dhahran 31261, Ả Rập Xê Út.
Địa chỉ E-mail:
haitham.elnakar@kfupm.edu.sa.

Desalination and Water Treatment

1. Introduction

Trang chủ tạp chí:
www.sciencedirect.com/journal/desalination-and-water-treatment/

Desalination and Water Treatment 325 (2026) 101598

2. Phương pháp nghiên cứu

Để đặt hiệu suất vào bối cảnh so sánh, mô hình XGBoost tối ưu hóa bằng FLAML được đối chuẩn với năm mô hình hồi quy thường dùng: Cây quyết định (DT), Rừng ngẫu nhiên (RF), Cây quyết định tăng cường độ dốc (GBDT), Học sâu (DL) và k-Hàng xóm gần nhất (KNN). Mỗi mô hình được đánh giá trên cùng một bộ dữ liệu mã hóa one-hot và áp dụng các phép phân tách huấn luyện – kiểm tra phân tầng giống hệt nhau nhằm đảm bảo tính tương đồng về phương pháp. Quá trình đánh giá mô hình sử dụng mười lần lặp độc lập của phép phân chia phân tầng tỷ lệ 80:20 để định lượng độ ổn định qua các lần phân tách khác nhau. Với mỗi lần lặp, năm chỉ số được tính toán gồm: sai số căn bậc hai trung bình (RMSE), sai số tuyệt đối trung bình (MAE), sai số phần trăm tuyệt đối trung bình (MAPE), hệ số tương quan (CC; Pearson's r) và hệ số xác định (R^2). RMSE, MAE và MAPE định lượng độ lớn sai số, trong khi CC (r) và R^2 tóm lược mức độ liên kết và phương sai giải thích. Ý nghĩa thống kê của các khác biệt theo cặp được đánh giá bằng kiểm định t hai đuôi theo cặp ($\alpha = 0.01$) qua mười lần lặp, sử dụng hiệu chỉnh Bonferroni để kiểm soát tỷ lệ sai số theo họ (family-wise error rate). Cohen's d cũng được báo cáo để định lượng kích thước hiệu ứng. Giao thức này cung cấp một phép so sánh vững chắc trước các phân tách dữ liệu dưới điều kiện dữ liệu và tiền xử lý đồng nhất, đồng thời gắn kết quy trình đối chuẩn với khuôn khổ phân tách dữ liệu được mô tả trong Mục 2.2.

Khả năng giải thích của mô hình được đánh giá bằng SHapley Additive exPlanations (SHAP), phương pháp phân bổ mức đóng góp biên của từng đặc trưng vào các dự đoán riêng lẻ theo khuôn khổ lý thuyết trò chơi hợp tác. Các giá trị SHAP được tính toán cho mô hình XGBoost đã huấn luyện và được tổng hợp thành tầm quan trọng nhóm bằng cách gộp các giá trị SHAP tuyệt đối qua các mức mã hóa one-hot của từng biến phân loại gốc (anot, catot, chất điện phân, nền nước). Trước sự phụ thuộc lẫn nhau được quan sát thấy giữa các biến dự đoán điện hóa (Figures S1 & S2), ảnh hưởng tiềm tàng của tương quan lên các giá trị gán của TreeSHAP đã được kiểm tra bằng cách so sánh thứ hạng SHAP nhóm với phân tích tầm quan trọng hoán vị có điều kiện (CPI) có xét đến tương quan. Tầm quan trọng hoán vị có điều kiện (CPI) được tính toán bằng cách tái lấy mẫu có điều kiện trong các phân tầng biến dự đoán tương quan nhằm giảm thiểu sai lệch do tương quan. Mức độ tương đồng được định lượng bằng chỉ số Kendall's τ với khoảng tin cậy 95 % trong Table S2. Cùng nhau, hai phương pháp đem lại một góc nhìn minh bạch, đặt trong bối cảnh tương quan về ảnh hưởng của các đặc trưng, phục vụ cho việc thiết kế quy trình xử lý và tối ưu hóa điện hóa.

2.6. Khả năng tái lập và cân nhắc triển khai

2.7. Đóng góp và khác biệt về mặt phương pháp

2.2. Phân chia dữ liệu và giao thức đánh giá

Quá trình đánh giá mô hình sử dụng phép phân tách giữ lại (holdout) tỷ lệ 80:20 được phân tầng theo loại anot nhằm giảm thiểu hiện tượng dịch chuyển hiệp biến (covariate shift) phát sinh từ sự phân bố anot không đồng đều trên bộ dữ liệu. Biến mục tiêu (hiệu suất loại bỏ, %) không được phân tầng, phù hợp với thiết lập bài toán hồi quy. Một giá trị hạt giống ngẫu nhiên cố định (42) được sử dụng để đảm bảo tính tái lập. Tính ổn định của quy trình này qua các lần chạy lặp lại và những phương án phân chia thay thế được ghi nhận trong Figure S4 (độ nhạy phân tầng), đồng thời quy trình lựa chọn mô hình nội bộ cùng tính nhất quán về hiệu năng được tóm tắt trong Figure S5 (chẩn đoán kiểm định chéo lồng nhau).

2.3. Lựa chọn mô hình tự động thông qua FLAML

2. Methodology

2.4. Đối chuẩn so sánh và xác thực thống kê

3. Kết quả và thảo luận

Mô hình XGBoost tối ưu hóa bằng FLAML thể hiện hiệu suất dự đoán vượt trội trong việc mô hình hóa hiệu quả oxy hóa điện hóa PFOA, vượt trội đáng kể so với tất cả các mô hình cơ sở trên mọi chỉ số đánh giá (Table 1). Mô hình XGBoost tối ưu hóa bằng FLAML đạt RMSE là 3.97 ± 0.45 và R^2 là 0.98 ± 0.01 , tương ứng với mức giảm 51 % sai số dự đoán và cải thiện 7 % phương sai giải thích so với mô hình cơ sở đạt hiệu suất tốt nhất (Rừng ngẫu nhiên (RF): RMSE = 8.05 ± 1.02 , $R^2 = 0.91 \pm 0.02$). Ưu thế hiệu suất này có ý nghĩa thống kê trên tất cả các chỉ số ($p < 10^{-5}$), được xác nhận bởi các phép kiểm định t theo cặp (Table 2), với sự khác biệt đặc biệt rõ rệt so với cây quyết định tăng cường độ dốc (GBDT) ($p < 1.1 \times 10^{-8}$ đối với RMSE) và các phương pháp học sâu (DL) ($p < 2.8 \times 10^{-9}$ đối với RMSE). Phân tích xếp hạng (Table 3) củng cố thêm tính vượt trội nhất quán của mô hình XGBoost tối ưu hóa bằng FLAML khi dẫn đầu trên tất cả các chỉ số hiệu suất với thứ hạng trung bình là 1.0, trong khi Rừng ngẫu nhiên (RF) xếp thứ hai (thứ hạng trung bình = 2.2).

Những kết quả này khẳng định FLAML là một công cụ hiệu quả cao trong mô hình hóa quá trình điện hóa, đạt được độ chính xác mà trước đây cần tính chính thủ công quy mô lớn. Hiệu suất này phù hợp với các minh chứng gần đây về khả năng giảm chi phí tính toán của AutoML trong khi vẫn duy trì độ chính xác ở các hệ thống môi trường phức tạp [28,29]. Đáng chú ý, FLAML hoàn thành mục tiêu này trong phạm vi ngân sách tối ưu hóa 300 giây. Kết quả này thể hiện mức giảm 72 % thời gian tính toán so với các triển khai tìm kiếm dạng lưới thông thường trong nghiên cứu gốc [30]. Hiệu quả này giải quyết các rào cản tính toán then chốt trong nghiên cứu môi trường, nơi hạn chế về tài nguyên thường giới hạn việc tối ưu hóa mô hình [23].

Phân tích phân phối phần dư (Fig. 2) cung cấp hiểu biết sâu hơn về độ tin cậy của mô hình. FLAML thể hiện các phần dư đối xứng nhất và phân bố chặt chẽ nhất (khoảng từ phân vị ± 6 %), cho thấy sai lệch hệ thống ở mức tối thiểu và độ chính xác dự đoán nhất quán trên toàn bộ không gian thông số vận hành. Ngược lại, các thuật toán truyền thống thể hiện phân phối phần dư rộng hơn với các giá trị ngoại lai đáng chú ý: k-hàng xóm gần nhất (KNN) xuất hiện các phần dư âm cực lớn (< -70 %), trong khi các phương pháp học sâu (DL) có xu hướng sai lệch dương. Độ chính xác này có vai trò then chốt cho các ứng dụng thiết kế lò phản ứng, nơi độ bất định của dự đoán lan truyền qua các phép tính hiệu suất năng lượng [31,32]. Dạng phân phối phần dư quan sát được phù hợp với kỳ vọng lý thuyết đối với các thuật toán tối ưu hóa có nhận thức về chi phí, vốn giảm thiểu sai số kiểm định chéo một cách có hệ thống dưới điều kiện tài nguyên hạn chế [33].

Đánh giá tầm quan trọng của đặc trưng dựa trên SHAP (Fig. 3) mang lại những hiểu biết quan trọng về các yếu tố ảnh hưởng đến hiệu suất loại bỏ PFOA bằng phương pháp điện hóa. Hai khung học máy, XGBoost tối ưu hóa bằng FLAML và Rừng ngẫu nhiên (RF) truyền thống, đều nhất quán xác định thời gian điện phân là yếu tố quan trọng nhất, với giá trị SHAP tuyệt đối trung bình lần lượt đạt xấp xỉ 16.4 và 13.6. Quan sát này phù hợp với lý thuyết oxy hóa điện hóa cơ bản, vốn nhấn mạnh sự phụ thuộc của hiệu quả phân hủy chất ô nhiễm vào điện lượng tích lũy đặt vào, một hàm tỷ lệ thuận với thời gian điện phân [34]. Thời gian điện phân chi phối sự sinh ra và sự duy trì các chất oxy hóa hoạt tính, chủ yếu là các gốc hydroxyl ($\cdot\text{OH}$), đóng vai trò then chốt trong việc khởi đầu và duy trì quá trình khoáng hóa các chất ô nhiễm có độ bền cao như PFOA [35,36]. Việc diễn giải có xem xét các tương quan quan sát được giữa những biến đầu vào (SI Figures S1–S2) và các thống kê về mức độ phù hợp với tầm quan trọng hoá trị có điều kiện (SI Table S2).

Cả hai mô hình đều xác định mật độ dòng điện có ảnh hưởng đáng kể, với giá trị SHAP xấp xỉ 5.9 đối với XGBoost và 5.2 đối với Rừng ngẫu nhiên (RF). Vai trò then chốt của mật độ dòng điện hoàn toàn phù hợp với các kiến thức điện hóa đã được xác lập; mật độ dòng điện thích hợp sẽ duy trì sự sinh ra hiệu quả các gốc hoạt tính tại bề mặt tiếp xúc của điện cực [41]. Tuy nhiên, mật độ dòng điện quá cao đã được chứng minh là dẫn đến tiêu hao năng lượng tăng lên và xuất hiện các phản ứng phụ như sự thoát oxy, làm giảm hiệu quả xử lý tổng thể [42]. Vai trò hai mặt này của mật độ dòng điện nhấn mạnh tầm quan trọng của việc tối ưu hóa vận hành chính xác; kiến trúc cây tăng cường có khả năng nắm bắt các hiệu ứng phi tuyến tính và hành vi ngưỡng liên quan đến sự đánh đổi này [43].

Table 1
Giá trị trung bình $\pm$ độ lệch chuẩn của từng chỉ số qua 10 lần chạy.

DT, Cây quyết định (DT); RF, Rừng ngẫu nhiên (RF); GBDT, Cây quyết định tăng cường độ dốc (GBDT); DL, Học sâu (DL); KNN, k-Hàng xóm gần nhất (KNN); FLAML-optimized XGBoost, mô hình Extreme Gradient Boosting được tối ưu hóa bằng AutoML nhanh và nhẹ (FLAML-optimized XGBoost); RMSE, sai số căn bậc hai trung bình (RMSE); MAE, sai số tuyệt đối trung bình (MAE); MAPE, sai số phần trăm tuyệt đối trung bình (MAPE); CC, hệ số tương quan (CC); R^2 , hệ số xác định (R^2).

Table 3
Thứ hạng trung bình của các mô hình trên các chỉ số đánh giá.

3.4. Ý nghĩa đối với việc tối ưu hóa xử lý PFAS

Các kết quả về tầm quan trọng của đặc trưng cung cấp định hướng mang tính thực tiễn cho việc thiết kế lò phản ứng điện hóa. Sự vượt trội của thời gian điện phân chỉ ra rằng mức tăng hiệu quả loại bỏ chủ yếu chịu sự chi phối của lượng điện tích tích lũy đi qua; việc lập kế hoạch vận hành cần ưu tiên thời gian phản ứng đầy đủ trong phạm vi các giới hạn về năng lượng và công suất xử lý. Việc lựa chọn anot là một yếu tố có ảnh hưởng lớn trong bảng xếp hạng của XGBoost (Fig. 3), phù hợp với các báo cáo trong y văn về quá trình tạo gốc tự do phụ thuộc vào vật liệu; các lựa chọn vật liệu cụ thể cần phải tương thích với chế độ mật độ dòng điện mục tiêu và các giới hạn về chi phí, đồng thời sự đánh đổi giữa hiệu suất và chi phí phải được đánh giá theo từng trường hợp cụ thể. Ảnh hưởng của nền nước xếp hạng thấp trong hồ sơ SHAP dạng nhóm (ví dụ: "Nền nước" ở gần phía dưới Fig. 3), gợi ý rằng trong phạm vi nghiên cứu, việc chuyển giao công nghệ sang các nền nước khác nhau có thể đòi hỏi ít sự tái tối ưu hóa hơn so với các điểm thiết lập điện hóa (tùy thuộc vào việc xác thực trong các nền nước mới) [45,46].

Độ chính xác dự đoán của FLAML hỗ trợ việc kiểm soát chặt chẽ hơn các điểm thiết lập (ví dụ: mật độ dòng điện và thời gian) nhằm phục vụ vận hành có nhận thức về năng lượng trong phạm vi đã thử nghiệm. Các dự báo định lượng về năng lượng (ví dụ: kWh□m⁻³) không được rút ra từ kết quả đầu ra của mô hình hiện tại và đòi hỏi phải có quy trình kiểm toán điện năng chuyên biệt đi kèm xác thực bằng thực nghiệm. Khả năng tổng quát hóa của mô hình trên các điều kiện vận hành trong tập dữ liệu này cho thấy tiềm năng mở rộng phương pháp học chuyển giao sang các hợp chất PFAS liên quan (ví dụ: PFOS, GenX), với điều kiện bao phủ được các phạm vi vận hành tương đương và có sự xác thực độc lập từ bên ngoài [47].

3.5. Hạn chế và định hướng tương lai

4. Kết luận

Tuyên bố về đóng góp của tác giả theo CRediT

****Haitham Elnakar**:** Viết – xem xét & chỉnh sửa, Viết – bản thảo gốc, Trực quan hóa, Phương pháp luận, Phân tích chính thức, Khái niệm hóa.

Tuyên bố về xung đột lợi ích

FLAML-optimized	Lời cảm ơn (Acknowledgment)
Tác giả ghi nhận sự hỗ trợ của Đại học Dầu khí và Khoáng sản King Fahd (KFUPM) cho ấn phẩm này.	

Phụ lục A. Thông tin bổ trợ

Xem xét sâu hơn các giá trị SHAP cho thấy pH ban đầu của dung dịch có ảnh hưởng ở mức độ vừa phải nhưng đầy ý nghĩa, phù hợp với các nguyên lý điện hóa cơ bản. pH dung dịch tác động then chốt đến hóa học bề mặt điện cực và sự phân bố dạng gốc tự do, qua đó điều hòa độ bền và khả năng phản ứng của gốc tự do [34,41]. Mức độ quan trọng vừa phải ghi nhận được đối với nhiệt độ khẳng định lại các phát hiện thực nghiệm trước đây, chỉ ra rằng trong các phạm vi vận hành thực tế, ảnh hưởng của nhiệt độ lên quá trình oxy hóa điện hóa là tương đối nhỏ so với các thông số điện hóa như nồng độ chất điện phân và mật độ dòng điện [44].

Sự khác biệt về hồ sơ xếp hạng đặc trưng giữa hai phương pháp tiếp cận mô hình hóa, XGBoost tối ưu hóa bằng FLAML và Rừng ngẫu nhiên (RF), nhấn mạnh sự khác biệt trong kiến trúc thuật toán của chúng. Thuật toán cây tăng cường của XGBoost, thông qua việc khớp lặp và điều chuẩn mạnh mẽ, vốn ưu tiên nắm bắt các tương tác phi tuyến phức tạp và các hiệu ứng ngưỡng tinh tế [43]. Ngược lại, Rừng ngẫu nhiên (RF) lấy trung bình ảnh hưởng của từng đặc trưng riêng lẻ trên toàn bộ tập hợp cây, do đó có khả năng làm loãng các khác biệt tinh tế về tầm quan trọng của đặc trưng và đánh giá thấp các tương tác.

Fig. 1. Đường cong học tập (RMSE huấn luyện/kiểm định theo kích thước tập huấn luyện) đối với XGBoost tối ưu hóa bằng FLAML. Fig. 2. Biểu đồ hộp (box plot) của phần dư cho từng mô hình. Fig. 3. Tầm quan trọng của đặc trưng SHAP dạng nhóm đối với XGBoost (tối ưu hóa bằng FLAML) và Rừng ngẫu nhiên (RF). Fig. 4. Các biểu đồ phụ thuộc SHAP đối với (A) thời gian điện phân được tô màu theo mật độ dòng điện, (B) nồng độ chất điện phân được tô màu theo thời gian điện phân, và (C) mật độ dòng điện được tô màu theo thời gian điện phân.

3.3. Các dạng quan hệ liều–đáp ứng và độ ổn định của các giải thích SHAP




Fig. 2. Box plot of residuals for each model.

Tính khả dụng của dữ liệu

Tập dữ liệu được sử dụng trong nghiên cứu này đã được trích dẫn trong phần phương pháp nghiên cứu.

Tài liệu tham khảo (References)




Fig. 3. Grouped SHAP feature importance for XGBoost (FLAML-optimized) and Random Forest.




Fig. 4. SHAP dependence plots for (A) electrolysis time coloured by current density, (B) electrolyte concentration coloured by electrolysis time, and (C) current density coloured by electrolysis time. Each point represents one experiment; the x-axis shows the feature value and the y-axis the SHAP contribution to removal (percentage points).

boosted-tree algorithm, through iterative fitting and robust regularization, inherently prioritizes capturing complex nonlinear interactions and subtle threshold effects [43]. Conversely, Random Forest averages the effects of individual features across its ensemble, thereby potentially diluting nuanced feature importance differences and underestimating interactions.

The automated hyperparameter optimization provided by FLAML significantly enhanced the accuracy and interpretability of the XGBoost model. Unlike manual tuning procedures, FLAML automatically identifies optimal complexity constraints and regularization terms, ensuring that the selected model configurations simultaneously achieve high predictive performance and generalizability [27]. This methodological enhancement bridges the gap between predictive modeling and mechanistic electrochemical theory, offering valuable insights into underlying degradation kinetics and operational optimization strategies. Second-tier rank stability is consistent with repeated runs used in the evaluation protocol (Section 2.2).

3.3. Dose–response patterns and stability of SHAP explanations

Within-dataset dose–response behavior for the main continuous variables is shown in Fig. 4A–C. The SHAP dependence for electrolysis time (Fig. 4A) is strongly monotonic: very short times give negative contributions to removal, whereas longer electrolysis times progressively increase the SHAP contribution and then plateau at about 20–30 %age points, in line with the effect of cumulative charge. Electrolyte concentration (Fig. 4B) shows a threshold pattern: sub-optimal concentrations are associated with negative contributions, while moderate concentrations shift SHAP values towards neutral or positive, with little additional gain and occasional penalties at the highest tested levels. For current density (Fig. 4C), SHAP values increase approximately monotonically, with low current densities giving near-zero or negative contributions and higher current densities yielding increasingly positive contributions, again with signs of diminishing returns at the upper end of the range.

Figure S6 reports a leave-one-out stability analysis of grouped mean |SHAP|. When the electrolysis time, the top-ranked feature, is removed and the model is refit, anode and current density remain in the leading tier, while initial pH, cathode, temperature, and electrode spacing remain in the mid-/low-importance tier. The Kendall's τ between the two rankings is 0.600 ($p = 0.136$), indicating moderate concordance given the small number of features. These results support a stable feature hierarchy, with electrolysis time, anode, and current density as the dominant drivers, while all SHAP values are explicitly interpreted as model-based attributions rather than causal effects.

3.4. Implications for PFAS treatment optimization

The feature importance results provide actionable guidance for electrochemical reactor design. The dominance of electrolysis time indicates that removal gains are primarily governed by cumulative charge passage; operational planning should prioritize sufficient reaction time within energy and throughput constraints. Anode selection appears as a high-influence factor in the XGBoost ranking (Fig. 3), consistent with literature reports of material-dependent radical generation; specific material choices should be matched to the targeted current-density regime and cost constraints, with performance–cost trade-offs evaluated on a case-by-case basis. Water-matrix effects rank low in the grouped SHAP profile (e.g., “Water Matrix” near the bottom of Fig. 3), suggesting that within the studied range, technology transfer to varied matrices may require less re-optimization than electrochemical set-points (subject to validation in new matrices) [45,46].

FLAML's predictive accuracy supports tighter setpoint control (e.g., current density and time) for energy-aware operation within the tested domain. Quantitative energy projections (e.g., kWh·m⁻³) are not drawn from the present model outputs and require dedicated electro-energy

auditing under experimental validation. The model's generalization capability across operational conditions within this dataset suggests potential for transfer-learning extensions to related PFAS (e.g., PFOS, GenX), contingent on coverage of comparable operating ranges and external validation [47].

3.5. Limitations and future directions

Although FLAML demonstrated exceptional predictive accuracy and robustness when applied to the dataset curated by [30], several avenues remain promising for further exploration. First, future research could assess the adaptability of this modeling framework to broader operational parameter spaces and validate its performance using external datasets from different experimental setups. This would also include a wider spectrum of PFAS compounds, such as PFOS and co-contaminants, to ascertain the generalizability of insights across diverse treatment systems. Transfer learning methodologies hold particular promise in this regard, as they could efficiently leverage knowledge from the current model to accelerate predictive capabilities in related electrochemical systems.

Additionally, while the current study prioritized removal efficiency, extending the analytical framework towards integrated multi-objective optimization could significantly enhance practical applicability. Such an extension would consider critical performance indicators beyond contaminant removal, including energy consumption metrics, byproduct formation, and the computational trade-offs between optimization speed and final model performance. Furthermore, enhancing real-time adaptive process control represents another promising direction. Integrating FLAML with in situ sensing technologies would enable dynamic process optimization, facilitating immediate adjustments to operational parameters based on real-time feedback.

Finally, while SHAP analysis provided valuable initial insights, deeper interpretability could be achieved by developing hybrid modeling frameworks that combine FLAML with physics-based electrochemical models. Future methodological refinements could also include exploring the use of native categorical handling within tree-based models as a potential alternative to one-hot encoding. Collectively, these future research directions promise substantial advancements in predictive analytics, interpretability, and operational applicability, reinforcing the potential of AutoML as a transformative approach for environmental electrochemical remediation technologies.

4. Conclusions

This study demonstrates a reproducible AutoML-based workflow for integrating automated machine learning with electrochemical oxidation processes targeting persistent environmental contaminants. The FLAML-driven XGBoost model outperformed conventional manually optimized ML approaches, delivering significantly enhanced predictive accuracy and interpretability, as evidenced by rigorous benchmarking and statistical validation. The analysis identified electrolysis time and anode material as primary operational drivers, offering actionable insights grounded in fundamental electrochemical principles and validated through SHAP-based interpretability. Crucially, the automated FLAML framework substantially reduced computational demands (72 % reduction in tuning time), thereby enhancing the accessibility and reproducibility of advanced ML techniques for environmental practitioners. By demonstrating superior predictive power alongside scientifically robust mechanistic insights, this research directly addresses critical methodological limitations in the current literature. The containerized, version-pinned pipeline ensures reproducibility and transparency, promoting wider adoption and methodological standardization within environmental remediation. Moving forward, integrating the developed methodology with hybrid physics-based models, real-time adaptive process controls, and broader PFAS compound scenarios can further elevate electrochemical treatment efficacy and

versatility. Overall, this work firmly positions automated and interpretable machine learning as an essential pillar of environmental engineering innovation, advancing the global effort towards sustainable remediation of persistent environmental contaminants.

CRedit authorship contribution statement

Haitham Elnakar: Writing – review & editing, Writing – original draft, Visualization, Methodology, Formal analysis, Conceptualization.

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgment

The author acknowledges the support of King Fahd University of Petroleum and Minerals (KFUPM) for this publication.

Appendix A. Supporting information

Supplementary data associated with this article can be found in the online version at [doi:10.1016/j.dwt.2025.101598](https://doi.org/10.1016/j.dwt.2025.101598).

Data Availability

The dataset used in this research has been cited in the methodology section.

References

- [1] Elnakar H, Ismail UM, Khan MF, Alnaimat S. Tackling the dust-microplastic nexus: sources, fate, and detection. *J Hazard Mater Adv* 2024;14:100418. <https://doi.org/10.1016/j.HAZADV.2024.100418>.
- [2] Ismail UM, Elnakar H, Khan MF. Sources, fate, and detection of dust-associated perfluoroalkyl and polyfluoroalkyl substances (PFAS): a review. *Toxics* 2023. <https://doi.org/10.3390/toxics11040335>.
- [3] EPA, 2017. Technical Fact Sheet – Perfluorooctane Sulfonate (PFOS) and Perfluorooctanoic Acid (PFOA).
- [4] Wee SY, Aris AZ. Revisiting the “forever chemicals”, PFOA and PFOS exposure in drinking water. *NPJ clean Water* 2023;6:1–16. <https://doi.org/10.1038/S41545-023-00274-6>.
- [5] Zahm S, Bonde JP, Chiu WA, Hoppin J, Kanno J, Abdallah M, et al. Carcinogenicity of perfluorooctanoic acid and perfluorooctanesulfonic acid. *Lancet Oncol* 2024;25:16–7. [https://doi.org/10.1016/S1470-2045\(23\)00622-8](https://doi.org/10.1016/S1470-2045(23)00622-8).
- [6] EPA, 2025. Per- and Polyfluoroalkyl Substances (PFAS) Final PFAS National Primary Drinking Water Regulation [WWW Document]. Safe Drinking Water Act.
- [7] Elnakar H, Buchanan ID. Pulp and paper mill effluent management. *Water Environ Res* 2018;90:1065–72. <https://doi.org/10.2175/106143018X15289915807164>.
- [8] Elnakar H, Khan MF, Ismail UM. Emerging trends in sequencing batch reactor operation and enhancement for improved phenol removal. *Desalin Water Treat* 2024;317:100310. <https://doi.org/10.1016/J.DWT.2024.100310>.
- [9] Calvillo Solís JJ, Sandoval-Pauker C, Bai D, Yin S, Senftle TP, Villagrán D. Electrochemical reduction of perfluorooctanoic acid (PFOA): an experimental and theoretical approach. *J Am Chem Soc* 2024;146:10687–98. <https://doi.org/10.1021/jacs.4c00443>.
- [10] Tri DVan, Anh NT, Luu T, Le, Trippel J, Wagner M. Electrochemical degradation of perfluorooctanoic acid (PFOA) and perfluorooctane sulfonate (PFOS) in water with persulfate catalyst support. *Sep Purif Technol* 2025;363:132076. <https://doi.org/10.1016/J.SEPUR.2025.132076>.
- [11] Das A, Adak A. Electrochemical oxidation of perfluorooctanoic acid (PFOA) using graphite substrate lead dioxide (GSLD) as anode: investigating reaction mechanism, degradation byproducts and influences of process parameters. *J Environ Chem Eng* 2025;13:116869. <https://doi.org/10.1016/J.JECE.2025.116869>.
- [12] Elnakar H. Disinfection and antimicrobial processes. *Water Environ Res* 2020;92:1625–8. <https://doi.org/10.1002/WER.1409>.
- [13] Kim N, Elbert J, Shchukina E, Su X. Integrating redox-electrodialysis and electrosorption for the removal of ultra-short- to long-chain PFAS. *15 Nat Commun* 2024 2024;15(1):1–14. <https://doi.org/10.1038/s41467-024-52630-w>.
- [14] Liang Y, Wang A, Liang S, Sun K, Xie R, Zheng C, et al. Durable Ti407 heterojunction composite membrane encapsulating N-doped graphene nanosheets for efficient electro-oxidation of GenX and other PFAS in fluorochemical wastewater. *Environ Sci Technol* 2025. https://doi.org/10.1021/ACS.EST.4C09423/SUPPL_FILE/ES4C09423_SI_001.DOCX.
- [15] Samuel MS, Kadarkarai G, Ryan DR, McBeath ST, Mayer BK, McNamara PJ. Enhanced perfluorooctanoic acid (PFOA) degradation by electrochemical activation of peroxydisulfate (PDS) during electrooxidation for water treatment. *Sci Total Environ* 2024;942:173736. <https://doi.org/10.1016/J.SCIOTENV.2024.173736>.
- [16] Ismail UM, Bani-Melhem K, Khan MF, Elnakar H. Optimizing membrane bioreactor performance in wastewater treatment using machine learning and meta-heuristic techniques. *Results Eng* 2025;25:104626. <https://doi.org/10.1016/J.RINENG.2025.104626>.
- [17] Sun Y, Zhao Z, Tong H, Sun B, Liu Y, Ren N, et al. Machine learning models for inverse design of the electrochemical oxidation process for water purification. *Environ Sci Technol* 2023;57:17990–8000. <https://doi.org/10.1021/acs.est.2c08771>.
- [18] Shirkoobi MG, Tyagi RD, Vanrolleghem PA, Drogui P. Artificial intelligence techniques in electrochemical processes for water and wastewater treatment: a review. *20 J Environ Health Sci Eng* 2022 2022;20(2):1089–109. <https://doi.org/10.1007/s40201-022-00835-W>.
- [19] Jeong N, Park S, Mahajan S, Zhou J, Blotvogel J, Li Y, et al. Elucidating governing factors of PFAS removal by polyamide membranes using machine learning and molecular simulations. *Nat Commun* 2024;15:1–13. <https://doi.org/10.1038/S41467-024-55320-9>.
- [20] Raza A, Bardhan S, Xu L, Yamijala SSRKC, Lian C, Kwon H, Wong BN. A machine learning approach for predicting defluorination of per- and polyfluoroalkyl substances (PFAS) for their efficient treatment and removal. *Environ Sci Technol Lett* 2019;6:624–9. <https://doi.org/10.1021/acs.estlett.9b00476>.
- [21] Lin DZ, Pan KJ, Li Y, Musgrave CB, Zhang L, Jayarapu KN, et al. A high-throughput experimentation platform for data-driven discovery in electrochemistry. *Sci Adv* 2025;11:4391. <https://doi.org/10.1126/sciadv.adu4391>.
- [22] Zhu JJ, Boehm AB, Ren ZJ. Environmental machine learning, baseline reporting, and comprehensive evaluation: the EMBRACE checklist. *Environ Sci Technol* 2024;58(24). <https://doi.org/10.1021/acs.est.4c09611>.
- [23] Zhu JJ, Yang M, Ren ZJ. Machine learning in environmental research: common pitfalls and best practices. *Environ Sci Technol* 2023;57:17671–89. <https://doi.org/10.1021/acs.est.3c00026>.
- [24] Feng L, Zhang Y, Wei X, Wang M, Niu Z, Wang C. Interpretable prediction of coagulant dosage in drinking water treatment plant based on automated machine learning and SHAP method. *J Water Process Eng* 2025;75:107925. <https://doi.org/10.1016/J.JWPE.2025.107925>.
- [25] Han H, Shaker B, Lee JH, Choi Sunghwan, Yoon S, Singh M, et al. Employing automated machine learning (AutoML) methods to facilitate the in silico ADMET properties prediction. *J Chem Inf Model* 2025;65:43. https://doi.org/10.1021/ACS.JCIM.4C02122/ASSET/IMAGES/LARGE/C14C02122_0002.JPEG.
- [26] Kazadi Mbamba C, Keymer P, Alvi M, Topalian SON, Ud Din F, Batstone DJ. Enhancing data quality in wastewater processes: missing data imputation with deep Variational Autoencoders and genetic algorithms. *Comput Chem Eng* 2025;199:109123. <https://doi.org/10.1016/J.COMPCHEMENG.2025.109123>.
- [27] Wang, C., Wu, Q., Weimer, M., Zhu, E., 2021. FLAML: A Fast and Lightweight AutoML Library [WWW Document]. GitHub. URL (<https://github.com/microsoft/FLAML>) (accessed 6.30.25).
- [28] Bao H, Yin W, Wang H, Lu Y, Jiang S, Ajibade FO, et al. Automated machine learning-based models for predicting and evaluating antibiotic removal in constructed wetlands. *Bioresour Technol* 2023;385:129436. <https://doi.org/10.1016/J.BIORTECH.2023.129436>.
- [29] Xu RZ, Cao JS, Ye T, Wang SN, Luo JY, Ni BJ, et al. Automated machine learning-based prediction of microplastics induced impacts on methane production in anaerobic digestion. *Water Res* 2022;223:118975. <https://doi.org/10.1016/J.WATRES.2022.118975>.
- [30] Alnaimat S, Mohsen O, Elnakar H. Perfluorooctanoic Acids (PFOA) removal using electrochemical oxidation: a machine learning approach. *J Environ Manag* 2024;370:122857. <https://doi.org/10.1016/J.JENVMAN.2024.122857>.
- [31] Khalid YS, Misal SN, Mehraeen S, Chaplin BP. Reactive-transport modeling of electrochemical oxidation of perfluoroalkyl substances in porous flow-through electrodes. *ACS ES T Eng* 2022;2:713–25. <https://doi.org/10.1021/acsestengg.1c00362>.
- [32] Xu X, Li Y, Vo PHN, Shukla P, Ge L, Zhao CX. Electrochemical advanced oxidation of per- and polyfluoroalkyl substances (PFASs): development, challenges and perspectives. *Chem Eng J* 2024;500:157222. <https://doi.org/10.1016/J.CEJ.2024.157222>.
- [33] Lundberg SM, Lee SI. A Unified Approach to Interpreting Model Predictions. 31st Conference on Neural Information Processing Systems. Neural information processing systems foundation; 2017. p. 1–10.
- [34] Mukherjee P, Sathiyar K, Zidki T, Nadagouda MN, Sharma VK. Electrochemical degradation of per- and poly-fluoroalkyl substances in the presence of natural organic matter. *Sep Purif Technol* 2023;325:124639. <https://doi.org/10.1016/J.SEPUR.2023.124639>.
- [35] Schaefer CE, Tran D, Fang Y, Choi YJ, Higgins CP, Strathmann TJ. Electrochemical treatment of poly- and perfluoroalkyl substances in brines. *Environ Sci (Camb)* 2020;6:2704–12. <https://doi.org/10.1039/D0EW00377H>.
- [36] Vecitis CD, Park H, Cheng J, Mader BT, Hoffmann MR. Treatment technologies for aqueous perfluorooctanesulfonate (PFOS) and perfluorooctanoate (PFOA). *3 Front Environ Sci Eng China* 2009 2009;3(2):129–51. <https://doi.org/10.1007/S11783-009-0022-7>.

- [37] Anglada Á, Urriaga A, Ortiz I. Contributions of electrochemical oxidation to wastewater treatment: fundamentals and review of applications. *J Chem Technol Biotechnol* 2009;84:1747–55. <https://doi.org/10.1002/JCTB.2214>.
- [38] Oturan MA, Aaron JJ. Advanced oxidation processes in water/wastewater treatment: principles and applications. a review. *Crit Rev Environ Sci Technol* 2014;44:2577–641. <https://doi.org/10.1080/10643389.2013.829765>.
- [39] Martínez-Huitle CA, Panizza M. Electrochemical oxidation of organic pollutants for wastewater treatment. *Curr Opin Electrochem* 2018;11:62–71. <https://doi.org/10.1016/J.COELEC.2018.07.010>.
- [40] Wang C, Zhang T, Yin L, Ni C, Ni JP, Hou LA. Enhanced perfluorooctanoic acid mineralization by electrochemical oxidation using Ti3+ self-doping TiO2 nanotube arrays anode. *Chemosphere* 2022;286:131804. <https://doi.org/10.1016/J.CHEMOSPHERE.2021.131804>.
- [41] Panizza M, Cerisola G. Direct and mediated anodic oxidation of organic pollutants. *Chem Rev* 2009;109:6541–69. <https://doi.org/10.1021/cr9001319>.
- [42] Chaplin BP. Critical review of electrochemical advanced oxidation processes for water treatment applications. *Environ Sci Process Impacts* 2014;16:1182–203. <https://doi.org/10.1039/C3EM00679D>.
- [43] Chen T, Guestrin C. XGBoost: A scalable tree boosting system. In: *KDD '16: Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery; 2016. p. 785–94. <https://doi.org/10.1145/2939672.2939785>.
- [44] Asadi Zeidabadi F, Banayan Esfahani E, McBeath ST, Dubrawski KL, Mohseni M. Electrochemical degradation of PFOA and its common alternatives: assessment of key parameters, roles of active species, and transformation pathway. *Chemosphere* 2023;315:137743. <https://doi.org/10.1016/J.CHEMOSPHERE.2023.137743>.
- [45] Karatas O, Kobya M, Khataee A, Yoon Y. Perfluorooctanoic acid (PFOA) removal from real landfill leachate wastewater and simulated soil leachate by electrochemical oxidation process. *Environ Technol Innov* 2022;28:102954. <https://doi.org/10.1016/J.ETI.2022.102954>.
- [46] Schaefer CE, Andaya C, Burant A, Condee CW, Urriaga A, Strathmann TJ, et al. Electrochemical treatment of perfluorooctanoic acid and perfluorooctane sulfonate: Insights into mechanisms and application to groundwater treatment. *Chem Eng J* 2017;317:424–32. <https://doi.org/10.1016/J.CEJ.2017.02.107>.
- [47] EPA, 2023. EPA's PFAS Strategic Roadmap: Second Annual Progress Report.