



Học chuyển giao giải thích được giữa các nhà máy nhằm dự đoán bám bẩn trong bể phản ứng sinh học màng

* Tác giả liên hệ.
** Tác giả liên hệ. Trường Công nghệ vì sự Phát triển Bền vững, Đại học Sư phạm Bắc Kinh, Trung Quốc.
Địa chỉ email: xuboyan@bnu.edu.cn (B. Xu), huanghy@bnu.edu.cn (H.Y. Ng).
1 Đồng tác giả thứ nhất.

Danh mục nội dung có tại ScienceDirect

Trang chủ tạp chí:
www.elsevier.com/locate/memsci

Journal of Membrane Science 758 (2026) 126065

1. Introduction

1. Giới thiệu

Trực tuyến từ ngày 19 tháng 8 năm 2026
0376-7388/© 2026 Elsevier B.V. Mọi quyền được bảo lưu, bao gồm
các quyền khai thác văn bản và dữ liệu, đào tạo AI và các công nghệ
tương tự.

Đô thị hóa và các yêu cầu tái sử dụng nước thải ngày càng tăng tiếp tục thúc đẩy xử lý nước thải hướng tới các quy trình tăng cường. Các quy trình này cần cung cấp nước đầu ra ổn định, chất lượng cao trong diện tích cơ sở hạ tầng hạn chế [1]. Do đó, bể phản ứng sinh học màng (MBR) tích hợp xử lý sinh học với tách màng được ứng dụng rộng rãi cho nước thải sinh hoạt và nước thải công nghiệp. Hệ thống này mang lại chất lượng nước đầu ra vượt trội và cấu hình nhỏ gọn. Tuy nhiên, bám bẩn màng vẫn là trở ngại chính ngăn cản việc khai thác hoàn toàn các ưu điểm này [2].

2. Vật liệu và phương pháp

2.1. Thu thập dữ liệu

Đối với mỗi nhà máy, tập dữ liệu bao gồm 11 biến: Thời gian lưu thủy lực (HRT), Thời gian lưu bùn (SRT), thông lượng màng (FLUX), nhu cầu oxy hóa học tổng số (TCOD), nhu cầu oxy hóa học hòa tan (SCOD), Chất rắn lơ lửng hỗn hợp bùn lỏng (MLSS), Chất rắn lơ lửng bay hơi hỗn hợp bùn lỏng (MLVSS), Protein trong EPS (EPSp), Polysaccharide trong EPS (EPSc), Protein trong SMP (SMPP) và Polysaccharide trong SMP (SMPc). Giá trị TMP được thu thập từ việc theo dõi trực tuyến thường quy và được căn chỉnh theo từng ngày lấy mẫu phục vụ phân tích tiếp theo.


Một nhà máy MBR (bể phản ứng sinh học màng) quy mô pilot xử lý nước thải sinh hoạt tại Singapore được lựa chọn làm nhà máy đích (target plant). Hệ thống tiếp nhận nước đầu vào giàu Fe với liều lượng Fe khoảng 10–30 mg/L. Hệ thống có công suất xử lý 24 m³/d. Cấu hình quy trình gồm tiền xử lý, bể phản ứng sinh học cấp nước phân đoạn nằm ngăn với các vùng kỵ khí/hiếu khí và một bể màng (Fig. 1(a)). Biên dạng áp suất xuyên màng (TMP) của nhà máy đích trong thời gian theo dõi được thể hiện trong Fig. 2(a). Mô-đun màng được trình bày trong Fig. 2(b), còn quy trình và các thông số vận hành chi tiết được tóm tắt trong Text S1. Tập dữ liệu của nhà máy đích bao gồm giai đoạn từ tháng 9 năm 2021 đến tháng 6 năm 2022. Tần suất đo Chất polyme ngoại bào (EPS) và Sản phẩm vi sinh hòa tan (SMP) là hai lần mỗi tuần. Do đó, việc phát triển mô hình chỉ dựa trên các ngày có đầy đủ phép đo trùng khớp cho mọi biến đầu vào và TMP. Quá trình này mang lại 71 bản ghi hợp lệ trùng khớp theo thời gian. Bối cảnh nhà máy đích hạn chế dữ liệu này phản ánh các hạn chế giám sát thực tế trong vận hành MBR quy mô pilot. Đồng thời, bối cảnh này cung cấp một kịch bản thực tế để đánh giá khung học chuyển giao (transfer learning) liên nhà máy (cross-plant) được đề xuất.

2.2. Phương pháp phân tích lý hóa


Ba nhà máy MBR đặt ngập quy mô pilot xử lý nước thải sinh hoạt tại Singapore được chọn làm các nhà máy nguồn (source plants), mang lại 332 bản ghi tổng cộng, bao gồm 100 bản ghi từ Nhà máy 1, 132 bản ghi từ Nhà máy 2 và 100 bản ghi từ Nhà máy 3 (Fig. 1(b)). Ảnh chụp các nhà máy nguồn được cung cấp trong Fig. S1. Biên dạng TMP của các nhà máy này trong suốt thời gian theo dõi được thể hiện trong Fig. S2. Các nhà máy này có cấu hình quy trình tương đương. Cấu hình gồm xử lý sinh học thiếu khí/hiếu khí tiếp nối bởi tách màng đặt ngập, đi kèm tuần hoàn và xả bùn thông thường. Các đặc tính chi tiết của hệ thống màng và thiết lập vận hành được tóm tắt trong Table S1. Dù nhà máy đích có thành phần nước đầu vào khác biệt do bổ sung Fe ở thượng nguồn, cấu hình xử lý tổng thể vẫn tương đương với các nhà máy nguồn. Các cơ chế bám bẩn màng MBR nhìn chung tương tự nhau. Đặc điểm này ủng hộ việc áp dụng học chuyển giao (transfer learning) giữa các nhà máy nguồn và nhà máy đích.

2.3. Tiền xử lý dữ liệu và lựa chọn đặc trưng

Fig. 1. Khung dự đoán áp suất xuyên màng (TMP) dựa trên học chuyển giao (transfer learning) trong các hệ MBR: (a) quy trình xử lý của nhà máy đích và các thách thức dự đoán liên quan: dữ liệu hạn chế, dữ liệu khuyết thiếu và các phép đo nhiễu, (b) các đặc tính chính của ba nhà máy nguồn: kích thước tập dữ liệu lớn hơn, chất lượng dữ liệu cao hơn và cấu hình quy trình tương tự, (c) quy trình tiền huấn luyện của các mô hình Mạng bộ nhớ ngắn-dài (LSTM) và Tăng cường gradient cực đại (XGBoost) bằng dữ liệu từ ba nhà máy nguồn, (d) quy trình tinh chỉnh (fine-tuning) các mô hình cơ sở (base models) bằng tập dữ liệu nhà máy đích để thu được các mô hình học chuyển giao, (e) khả năng giải thích mô hình và phân tích thống kê bằng phân tích Loại bỏ từng đặc trưng (LOFO) và SHAP (SHapley Additive exPlanations).



Nghiên cứu thực hiện phân tích thành phần chính (PCA) đồng thời trên các biến đầu vào cùng dTMP. Phân tích này giúp đánh giá sai khác phân phối và độ chồng lấp nguồn - đích liên quan đến học chuyển giao (transfer learning). Các khối đầu vào và đầu ra được chuẩn hóa riêng biệt, đồng thời được gán trọng số tổng thể bằng nhau (Text S4).



2.6. Xây dựng các mô hình học chuyển giao (transfer learning)

2.4. Xây dựng các mô hình cơ sở (base models) dựa trên các nhà máy nguồn (source plants)

Trước khi thiết lập các mô hình học chuyển giao (transfer learning), một mô hình chuẩn đối sánh (baseline model) được phát triển chỉ từ tập dữ liệu của nhà máy đích (target plant). Hiệu suất của mô hình này được so sánh với các mô hình học chuyển giao. Để bảo đảm tính so sánh, tập dữ liệu nhà máy đích (target plant) được phân chia theo trình tự thời gian. 50% dữ liệu đầu tiên được dùng để huấn luyện mô hình, và 50% dữ liệu còn lại được giữ lại để kiểm tra. Với cách phân chia này, lượng dữ liệu nhà máy đích (target plant) khả dụng cho việc huấn luyện mô hình rất hạn chế. Với tập huấn luyện nhỏ như vậy, mô hình chuẩn đối sánh Mạng bộ nhớ ngắn-dài (LSTM) huấn luyện riêng cho nhà máy đích dễ bị khớp không ổn định và quá khớp (overfitting). Hạn chế này làm cho kết quả so sánh giảm độ tin cậy [39]. Do đó, một mô hình XGBoost độc lập được chọn làm mô hình chuẩn đối sánh. Mô hình này được huấn luyện trên phần dữ liệu huấn luyện của nhà máy đích (target plant) với cùng tập đặc trưng như các mô hình học chuyển giao. Bộ chuẩn hóa cho biến mục tiêu cũng được khớp độc lập bằng chính phần dữ liệu huấn luyện này. Các thiết lập chi tiết được liệt kê trong Table S4.

2.5. Xây dựng mô hình chuẩn đối sánh (baseline model) cho nhà máy đích (target plant)

Tất cả các thử nghiệm được triển khai trong Python 3.10.18 cùng các thư viện bên thứ ba liên quan. Các mô hình học sâu (DL) được xây dựng và huấn luyện trong PyTorch 2.7.0. Môi trường tính toán gồm một bộ xử lý Intel Core i7-14700KF (28 lõi logic), 32 GB RAM và một GPU NVIDIA GeForce RTX 5060 Ti.

2.7. Đánh giá hiệu suất mô hình

Hiệu suất mô hình được đánh giá bằng R2, RMSE và MAE (chi tiết trong Text S10). Khả năng giải thích của mô hình được khảo sát bằng phân tích Loại bỏ từng đặc trưng (LOFO) và SHAP (SHapley Additive exPlanations) (Fig. 1(e)). Chi tiết được trình bày tương ứng trong Text S11 và Text S12.

2.8. Khả năng thích ứng của mô hình trong các điều kiện liên kịch bản

3. Kết quả và thảo luận

3.1. Phân bố nguồn–đích và phân tích thành phần chính (PCA)

Fig. 3. Phân bố dữ liệu nguồn–đích, hiện tượng cộng tuyến đặc trưng và hiệu suất dự đoán của các mô hình cơ sở (base models): (a) Phân tích thành phần chính (PCA) đồng thời của các tập dữ liệu nhà máy nguồn (source plant) và nhà máy đích (target plant), (b) bản đồ nhiệt tương quan Pearson giữa đặc trưng với đặc trưng ($X-X$), cùng các biểu đồ phân tán dự đoán cho (c) XGBoost-base và (d) LSTM-base.

3.2.1. Lựa chọn đặc trưng dựa trên tương quan

Sau đó, phân tích tương quan Pearson giữa đặc trưng với đặc trưng ($X-X$) được thực hiện để kiểm soát thêm hiện tượng cộng tuyến giữa các đặc trưng (Fig. 3(b)). Thời gian lưu thủy lực (HRT) tương quan âm mạnh với thông lượng màng (FLUX) ($r_{xj,xk} = -0.86$), có thể phản ánh sự liên kết vận hành giữa chúng. Cụ thể, HRT tỷ lệ nghịch với lưu lượng xử lý, còn FLUX biểu thị lưu lượng dòng thấm trên một đơn vị diện tích màng [8]. Chất rắn lơ lửng hỗn hợp bùn lỏng (MLSS) và chất rắn lơ lửng bay hơi hỗn hợp bùn lỏng (MLVSS) thể hiện tương quan dương rất mạnh ($r_{xj,xk} = 0.96$). Điều này phù hợp với việc MLVSS là thành phần sinh khối bay hơi của MLSS [40]. Trong hai cặp đặc trưng cộng tuyến này, FLUX và MLVSS có giá trị $|r_{x,y}|$ với áp suất xuyên màng (TMP) cao hơn nên được giữ lại. Theo đó, các biến FLUX, thời gian lưu bùn (SRT), MLVSS, Polysaccharide trong EPS (EPSc), Protein trong EPS (EPSp) và Protein trong SMP (SMPp) được giữ lại. Tập đầu vào rút gọn này phục vụ cho việc phát triển mô hình cơ sở (base model) tiếp theo.

3.2.2. Đánh giá hiệu suất của các mô hình cơ sở (base model)


3.2.3. Giải thích SHAP (SHapley Additive exPlanations) cho các mô hình cơ sở (base models) và đặc tính hóa lý

LSTM-base đạt hiệu suất dự đoán miền nguồn tốt và cho thấy nhiều triển vọng trong học chuyển giao (transfer learning) (thảo luận trong Mục 3.3). Vì vậy, các đặc tính hóa lý của sinh khối tại các nhà máy nguồn (source plant) được kiểm tra thêm. Phân tích này nhằm xác định xem mẫu quy gán đã học có phù hợp với cơ chế bám bẩn màng thực tế hay không. Chất polyme ngoại bào (EPS) và Sản phẩm vi sinh hòa tan (SMP) được chú trọng, vì chúng là các đặc trưng quan trọng trong phân tích SHAP. Cụ thể, EPS liên kết chặt chẽ hơn với các bông bùn và hiện tượng bám bẩn liên quan đến màng [45]. Trong khi đó, SMP chủ yếu đại diện cho các chất hữu cơ hòa tan [46].

3.3. Hiệu suất và giải thích học chuyển giao (transfer learning)

3.3.1. Ảnh hưởng của tỷ lệ tinh chỉnh (FT) đến hiệu suất học chuyển giao (transfer learning)

Nghiên cứu kiểm tra ảnh hưởng của tỷ lệ tinh chỉnh (FT) đến hiệu suất học chuyển giao (transfer learning). Phân tích này nhằm xác định lượng dữ liệu nhà máy đích (target plant) cần thiết để thích ứng hiệu quả. Mức FT = 0 đại diện cho chuyển giao trực tiếp không thích ứng tại nhà máy đích (target plant). Ở điều kiện này, các mô hình LSTM và XGBoost tiền huấn luyện đều cho giá trị R² thấp, lần lượt là 0,41 và 0,39. Kết quả này phản ánh khả năng dự đoán hạn chế trong thiết lập chuyển giao zero-shot. Kết quả Phân tích thành phần chính (PCA) trước đó đã chỉ ra sự dịch chuyển phân bố đo lường được giữa nguồn và đích. Cùng với kết quả này, phát hiện trên cho thấy chỉ chuyển giao trực tiếp là chưa đủ. Mô hình không thể dự đoán áp suất xuyên màng (TMP) đáng tin cậy tại nhà máy đích (target plant) [53].



Để so sánh hiệu suất dự đoán trên nhà máy đích (target plant), mô hình chuẩn đối sánh (baseline model) cùng với LSTM-FT và XGBoost-FT đã được đánh giá (Fig. 5(d)). Mô hình chuẩn đối sánh này được huấn luyện riêng dựa trên các tập dữ liệu của nhà máy đích.

3.3.3. Giải thích đóng góp của đặc trưng bằng LOFO và SHAP trong quá trình chuyển giao

Phân tích SHAP tiếp tục được sử dụng để khảo sát sự biến đổi của mẫu quy gán đặc trưng khi tăng FT. Trong chuyển giao zero-shot (zero-shot transfer) (FT = 0), EPSc là đặc trưng xếp hạng cao nhất. Biến này đóng góp tỷ trọng lớn nhất vào tổng mức quy gán (Fig. 6(b); Fig. S8(a)). Mức đóng góp này vượt xa Chất rắn lơ lửng bay hơi hỗn hợp bùn lỏng (MLVSS) và EPSp. Điều này cho thấy trong chuyển giao zero-shot, mô hình được chuyển giao duy trì mẫu quy gán tập trung mạnh vào EPSc. Đặc điểm này phản ánh sự tái hiệu chỉnh hạn chế trước khi tinh chỉnh (fine-tuning). Khi FT tăng từ 10% đến 30%, mẫu quy gán trở nên phân tán hơn. Mức quy gán cho EPSp tăng lên, cùng với các đóng góp tương đương hơn từ EPSc, SRT và MLVSS (Fig. S9–S10). Tại FT = 40%, EPSc và EPSp xếp hàng đầu và cùng chiếm hơn nửa tổng mức quy gán (Fig. 6(c); Fig. S8(b)). Kết quả này thể hiện một cấu trúc quy gán cân bằng hơn tập trung vào EPS sau khi tinh chỉnh. Thứ hạng đặc trưng và cấu trúc quy gán tại FT = 50% phần lớn tương tự như tại FT = 40% (Fig. S11). Điều này phù hợp với mức cải thiện hiệu suất bổ sung rất hạn chế khi FT vượt quá 40%. Cùng với kết quả LOFO, các phát hiện này chỉ ra rằng hiệu suất LSTM-FT chủ yếu nhờ các biến liên quan đến EPS. Trong đó, EPSp giữ vị trí dẫn đầu và EPSp trở nên nổi bật hơn sau khi tinh chỉnh.

3.3.4. Vì sao học chuyển giao (transfer learning) giúp dự đoán bám bản màng chính xác ở nhà máy đích (target plant)?

Kết quả làm sạch tại chỗ (CIP) hai bước củng cố thêm mối liên hệ giữa phản ứng EPS gắn với Fe và thành phần lớp bám bản giữ lại ở nhà máy đích. Trong giai đoạn làm sạch bằng axit xitric (CA), tổng Fe tăng mạnh từ 0.62 lên 43.02 mg/L (Fig. 7(e)). Kết quả này cho thấy lượng lớn thành phần chứa Fe đã được giải phóng khỏi lớp bám bản. Trong giai đoạn làm sạch bằng NaClO kế tiếp, Tổng cacbon hữu cơ (TOC) tăng từ 5.19 lên 43.22 mg/L (Fig. 7(f)). Đồng thời, tổng Fe cũng tăng từ 1.85 lên 11.16 mg/L. Điều này phản ánh sự giải phóng của chất hữu cơ có thể oxy hóa cùng các hợp phần mang Fe. Tại nhà máy đích, Nhu cầu oxy hóa học hòa tan (SCOD) thấp hơn Nhu cầu oxy hóa học tổng số (TCOD) (93 so với 271 mg/L). Các kết quả này chứng minh rằng lớp bám bản chủ đạo không chỉ do riêng chất hữu cơ hòa tan tạo thành. Thay vào đó, lớp bám bản gắn kết chặt chẽ hơn với cấu trúc nền hữu cơ liên kết với bùn chứa các hợp phần liên quan đến Fe.

Fig. 7. Bảng chứng hóa lý củng cố cho mẫu quy gán lấy EPS làm trung tâm do LSTM-FT học được tại nhà máy đích. Các đặc tính của hỗn hợp bùn lỏng gồm (a) Thời gian hút mao dẫn (CST) cùng CST riêng và (d) độ nhớt cùng độ nhớt riêng. Phổ Ma trận kích thích - phát xạ (EEM) của (b) EPS và (c) SMP. Nồng độ sắt tổng số trong các dung dịch làm sạch thu thập trong quy trình làm sạch tại chỗ (CIP) hai bước thể hiện ở (e). Nồng độ Tổng cacbon hữu cơ (TOC) trong dung dịch làm sạch thu thập trong quá trình rửa bằng natri hypoclorit thể hiện ở (f). Trước CIP, cùm màng được xả cặn và tráng rửa bằng nước lọc qua màng. Quy trình CIP hai bước bao gồm làm sạch bằng axit xitric (15 g/L, pH = 2.5), tiếp theo là natri hypoclorit (1 g/L, pH = 10). Các mẫu được thu thập ngay trước và sau mỗi bước làm sạch. Ký hiệu B-CA và A-CA tương ứng biểu thị các mẫu lấy trước và sau khi làm sạch bằng axit xitric. Ký hiệu B-NaClO và A-NaClO biểu thị các mẫu lấy trước và sau khi làm sạch bằng natri hypoclorit.

Phân tích trước đó chủ yếu tập trung vào kích bản MBR xử lý nước thải sinh hoạt. Do đó, nghiên cứu tiến hành đánh giá bổ sung trên một hệ MBR quy mô thí điểm xử lý nước thải công nghiệp hóa dầu và được phẩm hỗn hợp. Trường hợp này cung cấp thử nghiệm sơ bộ cho quy trình học chuyển giao (transfer learning) đã thiết lập dưới một nền nước thải khác biệt hơn. So với nhà máy đích (target plant) xử lý nước thải sinh hoạt, MBR công nghiệp thể hiện một kích bản chuyển giao khó khăn hơn. Hệ thống này có thành phần nước đầu vào phức tạp hơn, tải trọng hữu cơ cao hơn và động học sinh khối do các xáo trộn vận hành chi phối. Đường biến thiên áp suất xuyên màng (TMP) của MBR công nghiệp thể hiện một xu hướng dài hạn rõ rệt (Fig. 8(a)). Đường này cũng ghi nhận nhiều biến động đột ngột từ các sự kiện vận hành thực tế. Điều này phản ánh hành vi bám bản màng phức tạp trong các điều kiện kỹ thuật thực tế.

Thông tin bám bản vẫn được chia sẻ giữa các kích bản. Protein trong EPS (EPSp) (256.8 ± 126.7 mg/L) có cùng bậc độ lớn với các nhà máy nguồn (source plant) ($184\text{--}229$ mg/L). Đồng thời, Polysaccharide trong SMP (SMPc) (6.9 ± 5.0 mg/L) cũng nằm trong phạm vi của nhà máy nguồn ($5.2\text{--}11.5$ mg/L). Sự tương đồng này cho thấy một phần thông tin bám bản học từ các nhà máy nguồn vẫn có thể chuyển giao sang MBR công nghiệp. Khả năng chuyển giao này duy trì tốt ngay cả dưới một nền nước thải khác biệt đáng kể.






Fig. 8. Đánh giá bổ sung khung học chuyển giao (transfer learning) đề xuất trong MBR xử lý nước thải công nghiệp: (a) đường biến thiên áp suất xuyên màng (TMP) cùng các sự kiện vận hành chính, (b) thống kê tóm tắt các biến vận hành và hóa lý trong MBR công nghiệp, (c) mô hình LSTM tiên huấn luyện trước và sau khi tinh chỉnh, được đánh giá tại FT = 0 và FT = 40% bằng R^2 , MAE và RMSE, và (d) giá trị SHAP tuyệt đối trung bình của LSTM-FT tại FT = 40%.



Tuyên bố đóng góp của tác giả theo CRediT

4. Ý nghĩa và triển vọng

- Việc xác thực trên MBR công nghiệp chứng minh thêm rằng khung làm việc vẫn hiệu quả dưới một bối cảnh bám bản khác biệt rõ rệt. Khác với nhà máy đích xử lý nước thải sinh hoạt, SMPp trở thành đặc trưng quan trọng thứ hai trong MBR công nghiệp. Điều này phản ánh tín hiệu SMP chứa protein nổi bật hơn, gắn liền với các xáo trộn vận hành và sự phân rã sinh khối. Vai trò vượt trội liên tục của EPSc trong MBR công nghiệp củng cố thêm tính ổn định xuyên kịch bản của nền tảng bám bản có thể chuyển giao này. Đồng thời, sự gia tăng quy kết của SMPp cho thấy tính chính xác có thể tái điều chỉnh trọng số thích ứng. Nhờ đó, mô hình phù hợp với các yếu tố gây bám bản đặc thù của từng nhà máy.

- Nhìn chung, nghiên cứu này chứng minh rằng thông tin liên quan đến bám bản dùng chung có thể được chuyển giao giữa các nhà máy MBR. Thông tin này được tái hiệu chuẩn có chọn lọc với dữ liệu hạn chế từ nhà máy đích. Đồng thời, các bằng chứng lý hóa độc lập giúp quá trình thích ứng này có thể giải thích được về mặt khoa học. Do đó, khung nghiên cứu cung cấp một nền tảng thực tiễn để dự đoán TMP đáng tin cậy. Khung này hỗ trợ ra quyết định kiểm soát bám bản thích ứng với từng nhà máy trong các hệ thống MBR hạn chế dữ liệu.

5. Kết luận

Dữ liệu sẽ được cung cấp khi có yêu cầu hợp lý.

Tuyên bố về xung đột lợi ích


Phụ lục A. Dữ liệu bổ sung

Các tác giả tuyên bố không có xung đột lợi ích tài chính hoặc quan hệ cá nhân nào có thể ảnh hưởng đến công trình trong bài báo này.

Lời cảm ơn

Dữ liệu bổ sung cho bài viết này có thể được tìm thấy trực tuyến tại <https://doi.org/10.1016/j.memsci.2026.126065>.

Các tác giả trân trọng cảm ơn sự hỗ trợ tài chính từ Quỹ Học giả Thái Sơn của tỉnh Sơn Đông theo Mã số Tài trợ tsqn202312222. Nghiên cứu này cũng được hỗ trợ bởi Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc (42406133). Ngoài ra, Quỹ Nghiên cứu Cơ bản và Nghiên cứu Cơ bản Ứng dụng tỉnh Quảng Đông (2023A1515110786) cũng tài trợ cho nghiên cứu. Các tác giả cũng cảm ơn các thành viên nhóm nghiên cứu của Giáo sư How Yong Ng tại Singapore (như Wei Hao Loh, David Imanuel Tanaka, v.v.). Nhóm đã hỗ trợ quý báu trong việc thu thập dữ liệu vận hành từ các nhà máy bể phản ứng sinh học màng (MBR) quy mô thử nghiệm. Dữ liệu được sử dụng riêng cho việc mô hình hóa và mô phỏng dựa trên AI trong nghiên cứu này. Mọi thông tin nhạy cảm, bảo mật hoặc mang tính nhận dạng đều được ẩn danh hoặc che giấu trước khi phân tích.



Tính sẵn có của dữ liệu

Tài liệu tham khảo

3.3.5. Cross-scenario adaptability to an MBR treating industrial wastewater

Because the preceding analysis focused mainly on the domestic MBR scenario, additional validation was conducted using a pilot-scale MBR treating mixed petrochemical and pharmaceutical industrial wastewater. This case provided a preliminary test of the established transfer learning workflow under a more distinct wastewater background. Compared with the domestic target plant, the industrial MBR presented a more challenging transfer scenario, with a more complex influent composition, higher organic loading, and disturbance-driven biomass dynamics. The TMP profile of the industrial MBR showed a clear long-term trend together with multiple abrupt perturbations associated with real operational events (Fig. 8(a)), reflecting complex membrane-fouling behavior under practical engineering conditions.

The industrial MBR differed substantially from the source plants in wastewater and sludge properties, with consistently higher TCOD, SCOD, MLSS, and MLVSS (Fig. 8(b)). Importantly, despite these background differences, EPSc (43.6 ± 20.2 mg/L) remained close to the source plant range (32.3 – 43.5 mg/L), suggesting that EPSc-related

fouling information was still shared across scenarios. EPSp (256.8 ± 126.7 mg/L) was also of the same order of magnitude as in the source plants (184 – 229 mg/L), and SMPc (6.9 ± 5.0 mg/L) fell within the source plant range (5.2 – 11.5 mg/L). These overlaps suggest that part of the fouling-related information learned from the source plants could still be transferred to the industrial MBR, even under a substantially different wastewater background.

Under zero-shot transfer (FT = 0), the base model achieved only moderate performance in the industrial MBR ($R^2 = 0.46$; Fig. 8(c)), suggesting that the fouling-related information learned from the source plants was partially applicable but insufficient to fully capture the TMP dynamics in the industrial MBR. Fine-tuning with industrial MBR data improved prediction performance. This validation used the same chronological fine-tuning/testing logic, pretrained model, preprocessing procedure, and model settings as the main target plant analysis. At FT = 40%, R^2 increased to 0.89, while MAE and RMSE decreased by 68.6% and 54.7%, respectively, relative to FT = 0. This improvement indicates that the established workflow could be adapted to the industrial wastewater background without additional model optimization.

SHAP analysis further showed that EPSc retained the highest attribution after fine-tuning, whereas SMPp increased to the second-highest attribution level (Fig. 8(d)). This pattern differed from that observed in the domestic target MBR plant, where fine-tuning mainly increased the attribution of EPSp. Thus, the two target cases shared stable EPSc-related fouling information, but differed in the feature requiring target-specific recalibration: EPSp in the Fe-enriched domestic MBR and SMPp in the industrial MBR. The increased attribution of SMPp suggests that fine-tuning recalibrated the model toward a more prominent soluble proteinaceous signal under the industrial wastewater background.

The increased attribution of SMPp after fine-tuning was mechanistically plausible in the industrial MBR. SMPp was higher in the industrial MBR (27.6 ± 17.4 mg/L) than in the source plants (10.8 – 13.8 mg/L), indicating a stronger background of dissolved proteinaceous organics. Previous characterization of this industrial MBR showed pronounced SMP protein peaks during operational disturbances, together with decreases in MLSS and MLVSS, consistent with biomass loss, cell decay, and proteinaceous SMP release into the mixed liquor [56]. Moreover,




Fig. 8. Additional validation of the proposed transfer learning framework in an industrial wastewater MBR: (a) TMP profile with major operational events, (b) summary statistics of the operational and physicochemical variables in the industrial MBR, (c) the pretrained LSTM model before and after fine-tuning, evaluated at FT = 0 and FT = 40% using R^2 , MAE, and RMSE, and (d) mean absolute SHAP values of LSTM-FT at FT = 40%.

SMP in this MBR was dominated by proteins rather than carbohydrates. These observations suggest that the enhanced SMPp attribution in the transfer model was associated with disturbance-driven soluble protein release. Such proteinaceous SMP could contribute to fouling development, thereby explaining the increased attribution of SMPp after fine-tuning.

Overall, this additional validation suggests that the proposed transfer learning workflow remained applicable to the industrial MBR, not because fouling mechanisms were identical across scenarios, but because the model retained transferable EPSc-related fouling information while fine-tuning recalibrated the attribution structure toward the dominant target-specific signal. In the domestic target MBR plant, this recalibration was reflected by the increased attribution of EPSp under Fe-enriched conditions, whereas in the industrial MBR, it was reflected by the increased attribution of SMPp associated with disturbance-driven soluble protein release. These results further support the ability of the transfer learning framework to preserve transferable fouling-related information while adapting to plant-specific fouling signals across distinct wastewater backgrounds.

4. Implications and outlook

The significance of this study lies not only in improving fouling prediction for a single pilot-scale MBR, but also in providing a basis for more mechanism-informed prediction in data-limited plants. By transferring knowledge learned from data-richer source plants, the LSTM model achieved reliable prediction in a data-limited target plant, suggesting that data-limited plants may not need to build fouling prediction systems entirely from scratch.

More importantly, the present results suggest that indicator selection for fouling prediction should begin with identifying the dominant fouling processes, followed by extraction of representative fouling fingerprints for prediction. Within this framework, indicators such as EPSc and EPSp appear to contain transferable fouling information across MBR plants. However, these variables are expensive, labor-intensive, and difficult to monitor routinely, which limits their direct practical use. A more feasible direction may therefore be to translate key fouling characteristics into monitorable surrogate fingerprints; in this regard, online spectral signals such as UV-vis and fluorescence fingerprints may provide a practical basis for plant-adaptive prediction and proactive fouling control [57].

Nevertheless, several limitations remain and point to directions for future work. The present models were developed from a limited number of pilot-scale MBRs with relatively similar operational backgrounds. At full scale, membrane fouling is further shaped by scale-dependent hydrodynamics and aeration and by greater operational variability than in pilot systems [58], so the pretrained relationships may not directly capture full-scale fouling dynamics. For systems with substantially different influent or operating conditions, the sludge and EPS/SMP composition and the dominant foulants can change, weakening the transferable EPS-centered signal and possibly requiring additional plant-specific indicators for reliable adaptation. The framework should therefore be further validated on larger datasets and extended to full-scale, geographically diverse plants to establish its robustness and generalizability. In addition, the prediction accuracy did not approach unity, indicating that the current indicator set is still incomplete. Besides organic foulants, the target plant also showed evidence of inorganic contributions, particularly iron-associated fouling revealed by the CIP results, which may not yet be fully captured by the present model inputs. Identifying more comprehensive indicators that better capture the combined effects of organic and inorganic foulants may in turn help support earlier fouling warning, better timing of operational adjustment and membrane cleaning, reduced energy and chemical consumption, and improved process stability (Fig. S13).

5. Conclusions

- Reliable base models for MBR fouling prediction were developed by pretraining on the three data-richer source plants. SHAP analysis showed that LSTM-base learned physically meaningful fouling-related patterns mainly through EPSc, EPSp, and SMPp, rather than relying on a single dominant operational signal. This was supported by the shared source plant characteristics, including EPS aromatic protein-like fluorescence, flocculated sludge particle-size distributions, and preferential retention of SMP by the membrane. These results indicate that LSTM-base provided a mechanistically interpretable and reliable pretrained basis for subsequent cross-plant transfer.
- Fine-tuning improved TMP prediction for the target plant treating domestic wastewater, with LSTM-FT achieving $R^2 = 0.89$ at 40% FT. SHAP and LOFO analyses showed that EPSc remained dominant, while EPSp gained importance after fine-tuning. Under the Fe-enriched condition of the target MBR plant, the increased importance of EPSp was associated with a shift toward protein-enriched EPS characteristics. Together, these findings explain why fine-tuning improved prediction accuracy: it retained the transferable EPSc-centered fouling basis while recalibrating the model toward Fe-associated, protein-enriched EPS characteristics that were more closely associated with fouling in the target plant.
- Validation in the industrial MBR further demonstrated that the framework remained effective under a markedly different fouling background. Unlike the target plant treating domestic wastewater, SMPp became the second most important feature in the industrial MBR, reflecting a more prominent proteinaceous SMP signal linked to operational disturbances and biomass decay. The continued dominance of EPSc in the industrial MBR further supported the cross-scenario stability of this transferable fouling basis, while the increased attribution of SMPp showed that fine-tuning could adaptively reweight plant-specific fouling drivers.
- Overall, this study demonstrates that shared fouling-related information can be transferred across MBR plants and selectively recalibrated with limited target-plant data, while independent physicochemical evidence makes this adaptation scientifically interpretable. The framework therefore provides a practical foundation for reliable TMP prediction and plant-adaptive fouling decision support in data-limited MBRs.

CRediT authorship contribution statement

Xiaohang Han: Conceptualization, Data curation, Formal analysis, Investigation, Methodology, Software, Validation, Visualization, Writing – original draft. **Liu Yang:** Conceptualization, Data curation, Formal analysis, Investigation, Methodology, Software, Validation, Visualization, Writing – original draft. **Huan Qin:** Data curation, Investigation. **Shujuan Huang:** Data curation, Investigation. **Han Zhang:** Data curation, Investigation. **Boyan Xu:** Conceptualization, Funding acquisition, Project administration, Supervision, Writing – review & editing. **How Yong Ng:** Conceptualization, Funding acquisition, Supervision, Writing – review & editing.

Declaration of competing interests

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgement

The authors gratefully acknowledge financial support from the Taishan Scholar Foundation of Shandong Province under Grant No. tsqn202312222. The research was also supported by National Natural

Science Foundation of China (42406133), and the Basic and Applied Basic Research Foundation of Guangdong Province (2023A1515110786). The authors also thank the members of Professor How Yong Ng's research group in Singapore (e.g., Wei Hao Loh, David Imanuel Tanaka, and etc.) for their valuable assistance in collecting operational data from the pilot-scale membrane bioreactor plants. The data were used exclusively for AI-based modeling and simulation in this study, and all sensitive, confidential, or identifying information was anonymized or masked prior to analysis.

Appendix A. Supplementary data

Supplementary data to this article can be found online at <https://doi.org/10.1016/j.memsci.2026.126065>.

Data availability

Data will be made available on request.

References

- [1] P.L. McCarty, J. Bae, J. Kim, Domestic wastewater treatment as a net energy producer—can this be achieved? *Environ. Sci. Technol.* 45 (17) (2011) 7100–7106, <https://doi.org/10.1021/es2014264>.
- [2] C. Niu, X. Li, R. Dai, Z. Wang, Artificial intelligence-incorporated membrane fouling prediction for membrane-based processes in the past 20 years: a critical review, *Water Res.* 216 (2022), <https://doi.org/10.1016/j.watres.2022.118299>.
- [3] F. Meng, S. Zhang, Y. Oh, Z. Zhou, H.S. Shin, S.R. Chae, Fouling in membrane bioreactors: an updated review, *Water Res.* 114 (2017) 151–180, <https://doi.org/10.1016/j.watres.2017.02.006>.
- [4] K. Xiao, S. Liang, X. Wang, C. Chen, X. Huang, Current state and challenges of full-scale membrane bioreactor applications: a critical review, *Bioresour. Technol.* 271 (2019) 473–481, <https://doi.org/10.1016/j.biortech.2018.09.061>.
- [5] K.B. Newhart, R.W. Holloway, A.S. Hering, T.Y. Cath, Data-driven performance analyses of wastewater treatment plants: a review, *Water Res.* 157 (2019) 498–513, <https://doi.org/10.1016/j.watres.2019.03.030>.
- [6] M. Faisal, K.M. Muttaqi, D. Sutanto, A.Q. Al-Shetwi, P.J. Ker, M.A. Hannan, Control technologies of wastewater treatment plants: the state-of-the-art, current challenges, and future directions, *Renew. Sustain. Energy Rev.* 181 (2023), <https://doi.org/10.1016/j.rser.2023.113324>.
- [7] Y. Zhu, Y. Wang, E. Zhu, Z. Ma, H. Wang, C. Chen, J. Guan, T.D. Waite, Predicting membrane fouling of submerged membrane bioreactor wastewater treatment plants using machine learning, *Environ. Sci. Technol.* 59 (20) (2025) 10010–10021, <https://doi.org/10.1021/acs.est.4c12835>.
- [8] D.J. Kovacs, Z. Li, B.W. Baetz, Y. Hong, S. Donnaz, X. Zhao, P. Zhou, H. Ding, Q. Dong, Membrane fouling prediction and uncertainty analysis using machine learning: a wastewater treatment plant case study, *J. Membr. Sci.* 660 (2022), <https://doi.org/10.1016/j.memsci.2022.120817>.
- [9] K. Nam, S. Heo, G. Rhee, M. Kim, C. Yoo, Dual-objective optimization for energy-saving and fouling mitigation in MBR plants using AI-based influent prediction and an integrated biological-physical model, *J. Membr. Sci.* 626 (2021), <https://doi.org/10.1016/j.memsci.2021.119208>.
- [10] M. Alvi, D. Batstone, C.K. Mbamba, P. Keymer, T. French, A. Ward, J. Dwyer, R. Cardell-Oliver, Deep learning in wastewater treatment: a critical review, *Water Res.* 245 (2023) 120518, <https://doi.org/10.1016/j.watres.2023.120518>.
- [11] R. Huang, C. Ma, J. Ma, X. Huangfu, Q. He, Machine learning in natural and engineered water systems, *Water Res.* 205 (2021) 117666, <https://doi.org/10.1016/j.watres.2021.117666>.
- [12] H. Pang, Y. Ben, Y. Cao, S. Qu, C. Hu, Time series-based machine learning for forecasting multivariate water quality in full-scale drinking water treatment with various reagent dosages, *Water Res.* 268 (2025), <https://doi.org/10.1016/j.watres.2024.122777>.
- [13] J.J. Zhu, A.B. Boehm, Z.J. Ren, Environmental machine learning, baseline reporting, and comprehensive evaluation: the EMBRACE checklist, *Environ. Sci. Technol.* 58 (45) (2024) 19909–19912, <https://doi.org/10.1021/acs.est.4c09611>.
- [14] Y. Lai, K. Xiao, Y. He, X. Liu, J. Tan, W. Xue, A. Zhang, X. Huang, Machine learning for membrane bioreactor research: principles, methods, applications, and a tutorial, *Front. Environ. Sci. Eng.* 19 (3) (2025), <https://doi.org/10.1007/s11783-025-1954-2>.
- [15] Y. Lai, K. Xiao, Y. Tian, M. Xing, H. Ding, J. Tan, J. Zhang, Z. Peng, Y. Fan, X. Lu, S. Liang, W. Xue, X. Huang, Intelligent fouling monitoring in membrane-based wastewater treatment, *Nat. Sustain.* (2026), <https://doi.org/10.1038/s41893-026-01766-2>.
- [16] H. Zhang, H. Jiang, J. Yin, T. Wang, W. Zeng, D. Lin, B. Xu, L. Bai, H. Liang, H. Y. Ng, Biofilm response in potential difference-enhanced membrane-aerated biofilm systems for accelerated antibiotic removal and ARG mitigation, *Water Res.* 285 (2025) 124154, <https://doi.org/10.1016/j.watres.2025.124154>.
- [17] G. Mannina, B.J. Ni, J. Makinia, J. Harmand, M. Alliet, C. Brepols, M.V. Ruano, A. Robles, M. Heran, H. Gulhan, I. Rodriguez-Roda, J. Comas, Biological processes modelling for MBR systems: a review of the state-of-the-art focusing on SMP and EPS, *Water Res.* 242 (2023) 120275, <https://doi.org/10.1016/j.watres.2023.120275>.
- [18] S. Gharibian, H. Hazrati, Towards practical integration of MBR with electrochemical AOP: improved biodegradability of real pharmaceutical wastewater and fouling mitigation, *Water Res.* 218 (2022) 118478, <https://doi.org/10.1016/j.watres.2022.118478>.
- [19] F. Karamouz, H. Hazrati, A.B. Khoshfetrat, Mitigation of fouling in membrane bioreactor using the integration of electrical field and nano chitosan adsorbent, *Environ. Technol. Innov.* 36 (2024), <https://doi.org/10.1016/j.eti.2024.103774>.
- [20] H. Hazrati, N. Jahanbakhshi, M. Rostamizadeh, Fouling reduction in the membrane bioreactor using synthesized zeolite nano-adsorbents, *J. Membr. Sci.* 555 (2018) 455–462, <https://doi.org/10.1016/j.memsci.2018.03.076>.
- [21] A.H. Ba-Alawi, J. Loy-Benitez, S. Kim, C. Yoo, Missing data imputation and sensor self-validation towards a sustainable operation of wastewater treatment plants via deep variational residual autoencoders, *Chemosphere* 288 (Pt 3) (2022) 132647, <https://doi.org/10.1016/j.chemosphere.2021.132647>.
- [22] H. Cheng, J. Wu, Y. Liu, D. Huang, A novel fault identification and root-causality analysis of incipient faults with applications to wastewater treatment processes, *Chemometr. Intell. Lab. Syst.* 188 (2019) 24–36, <https://doi.org/10.1016/j.chemolab.2019.03.004>.
- [23] H. Zhang, L. Shi, J. Cai, X. Wang, Z. Yan, DMGTNet: a graph-temporal deep learning model for membrane fouling prediction in dual-membrane wastewater treatment systems, *J. Membr. Sci.* 736 (2025), <https://doi.org/10.1016/j.memsci.2025.124648>.
- [24] J.-H. Wang, H.-C. Wang, Z.-W. Guo, X. Gao, F. Dong, M.S. Mahmoud, Y.-P. Chen, Y. Shen, Breaking data silos: a new modeling method based on knowledge transfer-enhanced between wastewater treatment plants, *Process Saf. Environ. Prot.* 206 (2026), <https://doi.org/10.1016/j.psep.2025.108309>.
- [25] A. Elahi, D. Shumway, M. Kowalczyk, A. Shrestha, D. Caragea, C. Caragea, S. Dorevitch, Machine learning, generalization, and transfer learning for predicting the exceedance of fecal indicator bacteria thresholds at beaches, *Environ. Sci. Technol.* 59 (42) (2025) 22386–22396, <https://doi.org/10.1021/acs.est.5c02835>.
- [26] G. Ignacz, L. Bader, A.K. Beke, Y. Ghunaim, T. Shastri, H. Vovusha, M.R. Carbone, B. Ghanem, G. Szekely, Machine learning for the advancement of membrane science and technology: a critical review, *J. Membr. Sci.* 713 (2025), <https://doi.org/10.1016/j.memsci.2024.123256>.
- [27] Y. Takefuji, Limitations of SHAP-based interpretations in environmental and membrane filtration applications, *Water Res.* 288 (Pt B) (2026) 124766, <https://doi.org/10.1016/j.watres.2025.124766>.
- [28] A.D. Eaton, M.A.H. Franson, A.P.H. Association, A.W.W. Association, W. E. Federation, Standard Methods for the Examination of Water and Wastewater, American Public Health Association, 2005.
- [29] Z. Huang, S.L. Ong, H.Y. Ng, Submerged anaerobic membrane bioreactor for low-strength wastewater treatment: effect of HRT and SRT on treatment performance and membrane fouling, *Water Res.* 45 (2) (2011) 705–713, <https://doi.org/10.1016/j.watres.2010.08.035>.
- [30] B. Xu, T.C. Albert Ng, S. Huang, X. Shi, H.Y. Ng, Feasibility of isolated novel facultative quorum quenching consortiums for fouling control in an AnMBR, *Water Res.* 169 (2020), <https://doi.org/10.1016/j.watres.2019.115251>.
- [31] B. Xu, Q.A.C. Cho, T.C.A. Ng, S. Huang, H.Y. Ng, Enriched autoinducer-2 (AI-2)-based quorum quenching consortium in a ceramic anaerobic membrane bioreactor (AnMBR) for biofouling retardation, *Water Res.* 214 (2022), <https://doi.org/10.1016/j.watres.2022.118203>.
- [32] X. Yue, Y.K.K. Koh, H.Y. Ng, Effects of dissolved organic matters (DOMs) on membrane fouling in anaerobic ceramic membrane bioreactors (AnCMBRs) treating domestic wastewater, *Water Res.* 86 (2015) 96–107, <https://doi.org/10.1016/j.watres.2015.07.038>.
- [33] M. Ribeiro, K. Grolinger, H.F. ElYamany, W.A. Higashino, M.A.M. Capretz, Transfer learning with seasonal and trend adjustment for cross-building energy forecasting, *Energy Build.* 165 (2018) 352–363, <https://doi.org/10.1016/j.enbuild.2018.01.034>.
- [34] C. Niu, B. Li, Z. Wang, Using artificial intelligence-based algorithms to identify critical fouling factors and predict fouling behavior in anaerobic membrane bioreactors, *J. Membr. Sci.* 687 (2023), <https://doi.org/10.1016/j.memsci.2023.122076>.
- [35] J.J. Zhu, M. Yang, Z.J. Ren, Machine learning in environmental research: common pitfalls and best practices, *Environ. Sci. Technol.* 57 (46) (2023) 17671–17689, <https://doi.org/10.1021/acs.est.3c00026>.
- [36] X. Chen, Y. Zhang, A. Ye, J. Li, K. Hsu, S. Sorooshian, Fine-tuning long short-term memory models for seamless transition in hydrological modelling: from pre-training to post-application, *Environ. Model. Software* 186 (2025), <https://doi.org/10.1016/j.envsoft.2025.106350>.
- [37] J. Zhao, F. Chu, L. Xie, Y. Che, Y. Wu, A.F. Burke, A survey of transformer networks for time series forecasting, *Comput. Sci. Rev.* 60 (2026), <https://doi.org/10.1016/j.cosrev.2025.100883>.
- [38] P. Lara-Benitez, M. Carranza-Garcia, J.C. Riquelme, An experimental review on deep learning architectures for time series forecasting, *Int. J. Neural Syst.* 31 (3) (2021) 2130001, <https://doi.org/10.1142/S0129065721300011>.
- [39] Y. Ma, Y. Qiao, M. Chen, D. Rui, X. Zhang, W. Liu, L. Ye, How small is big enough? Big data-driven machine learning predictions for a full-scale wastewater treatment plant, *Water Res.* 274 (2025), <https://doi.org/10.1016/j.watres.2024.123041>.
- [40] Z. Jiang, Z. Xia, S. Liu, Q. Wei, H. Fan, L. Qi, G. Liu, H. Wang, The effect of fine grits and fine debris concentrations on the MLVSS/MLSS ratio of an activated sludge system, *J. Environ. Sci. (China)* 147 (2025) 607–616, <https://doi.org/10.1016/j.jes.2023.10.032>.

- [41] E. Poorasgari, T. Vistisen Bugge, M. Lykkegaard Christensen, M. Koustrup Jørgensen, Compressibility of fouling layers in membrane bioreactors, *J. Membr. Sci.* 475 (2015) 65–70, <https://doi.org/10.1016/j.memsci.2014.09.056>.
- [42] J. Pyo, Y. Pachepsky, S. Kim, A. Abbas, M. Kim, Y.S. Kwon, M. Ligaray, K.H. Cho, Long short-term memory models of water quality in inland water environments, *Water Res.* X 21 (2023) 100207, <https://doi.org/10.1016/j.wroa.2023.100207>.
- [43] S. Wang, H. Peng, S. Liang, Prediction of estuarine water quality using interpretable machine learning approach, *J. Hydrol.* 605 (2022), <https://doi.org/10.1016/j.jhydrol.2021.127320>.
- [44] A.J. Atkinson, M.D. Armstrong, J.T. Eskew, O. Coronell, 2-Aminoimidazole reduces fouling and improves membrane performance, *J. Membr. Sci.* 629 (2021), <https://doi.org/10.1016/j.memsci.2021.119262>.
- [45] R. Chen, Y. Nie, Y. Hu, R. Miao, T. Utashiro, Q. Li, M. Xu, Y.-Y. Li, Fouling behaviour of soluble microbial products and extracellular polymeric substances in a submerged anaerobic membrane bioreactor treating low-strength wastewater at room temperature, *J. Membr. Sci.* 531 (2017) 1–9, <https://doi.org/10.1016/j.memsci.2017.02.046>.
- [46] H. Lin, M. Zhang, F. Wang, F. Meng, B.-Q. Liao, H. Hong, J. Chen, W. Gao, A critical review of extracellular polymeric substances (EPSs) in membrane bioreactors: characteristics, roles in membrane fouling and control strategies, *J. Membr. Sci.* 460 (2014) 110–125, <https://doi.org/10.1016/j.memsci.2014.02.034>.
- [47] L.-g. Shen, Q. Lei, J.-R. Chen, H.-C. Hong, Y.-M. He, H.-J. Lin, Membrane fouling in a submerged membrane bioreactor: impacts of floc size, *Chem. Eng. J.* 269 (2015) 328–334, <https://doi.org/10.1016/j.cej.2015.02.002>.
- [48] S. Wang, X. Lu, L. Zhang, J. Guo, H. Zhang, Characterization of the initial fouling layer on the membrane surface in a membrane bioreactor: effects of permeation drag, *Membranes* 9 (9) (2019), <https://doi.org/10.3390/membranes9090121>.
- [49] D.W. Gao, Z.D. Wen, B. Li, H. Liang, Membrane fouling related to microbial community and extracellular polymeric substances at different temperatures, *Bioresour. Technol.* 143 (2013) 172–177, <https://doi.org/10.1016/j.biortech.2013.05.127>.
- [50] Y. Tian, Z. Li, Y. Ding, Y. Lu, Identification of the change in fouling potential of soluble microbial products (SMP) in membrane bioreactor coupled with worm reactor, *Water Res.* 47 (6) (2013) 2015–2024, <https://doi.org/10.1016/j.watres.2013.01.026>.
- [51] Y. Ding, Z. Guo, Z. Liang, X. Hou, Z. Li, D. Mu, C. Ge, C. Zhang, C. Jin, Long-term investigation into the membrane fouling behavior in anaerobic membrane bioreactors for municipal wastewater treatment operated at two different temperatures, *Membranes* 10 (9) (2020), <https://doi.org/10.3390/membranes10090231>.
- [52] T. Kakuda, R. Naito, A. Suzuki, A. Hafuka, K. Kimura, Quantitative and qualitative variations of biopolymers in a pilot-scale membrane bioreactor treating municipal wastewater throughout 3 years of operation, *J. Environ. Manag.* 328 (2023) 116863, <https://doi.org/10.1016/j.jenvman.2022.116863>.
- [53] H. Cao, X. Xie, Z. Xiao, W. Liu, Transferability of machine learning models for geogenic contaminated groundwaters, *Environ. Sci. Technol.* 58 (20) (2024) 8783–8791, <https://doi.org/10.1021/acs.est.4c01327>.
- [54] Y. Gao, Y. Mao, L. Kong, L. Sun, S. Fu, W. Zhan, W. Zuo, Elucidating the role of ferric chloride on carbon capture from low-strength municipal wastewater in high-rate activated sludge process: parameter optimization and crucial mechanism, *J. Clean. Prod.* 452 (2024), <https://doi.org/10.1016/j.jclepro.2024.142248>.
- [55] T. Peng, Y. Wang, J. Wang, F. Fang, P. Yan, Z. Liu, Effect of different forms and components of EPS on sludge aggregation during granulation process of aerobic granular sludge, *Chemosphere* 303 (Pt 2) (2022) 135116, <https://doi.org/10.1016/j.chemosphere.2022.135116>.
- [56] Q. Su, Y. Zhong, J.C.J. Rui, M. Ding, T.C.A. Ng, B. Xu, H.Y. Ng, Stability and durability of polymeric membranes in membrane bioreactors for industrial wastewater treatment, *J. Environ. Chem. Eng.* 13 (6) (2025), <https://doi.org/10.1016/j.jece.2025.120356>.
- [57] Y. Lai, Y. Xu, X. Liu, K. Xiao, F. Qu, S. Liang, W. Xue, X. Huang, Feedforward fouling control guided by online UV and fluorescence spectral early warning for low-energy operation of membrane bioreactor, *Water Res.* 297 (2026), <https://doi.org/10.1016/j.watres.2026.125715>.
- [58] F. Delrue, A.E. Stricker, M. Mietton-Peuchot, Y. Racault, Relationships between mixed liquor properties, operating conditions and fouling on two full-scale MBR plants, *Desalination* 272 (1–3) (2011) 9–19, <https://doi.org/10.1016/j.desal.2010.12.056>.