



Dự đoán có thể diễn giải về liều lượng chất keo tụ trong nhà máy xử lý nước cấp dựa trên học máy tự động và phương pháp SHAP

1. Giới thiệu

2. Vật liệu và phương pháp

1. Introduction

2.1. Thu thập và tiền xử lý dữ liệu

Khi thu thập dữ liệu, lỗi đo đạc và sự cố hệ thống chambers tạo ra các giá trị khuyết và nhiễu trong tập dữ liệu thô. Do đó, tiền xử lý là bước thiết yếu để nâng cao độ tin cậy dữ liệu, hiệu suất mô hình và chất lượng ra quyết định [38]. Trong nghiên cứu này, mô hình ước tính K láng giềng gần nhất (KNN, $k = 4$) được dùng để xử lý dữ liệu khuyết. Mô hình này cân bằng giữa độ ổn định nội suy và tính đại diện toàn cục. Phương pháp giúp bảo toàn dữ liệu tốt hơn cho các thông số quan trọng bị khuyết không ngẫu nhiên (ví dụ: nhiệt độ nước, nitơ amoniac). Hiệu quả nội suy trong khoảng $k = 1-10$ được khảo sát bằng tìm kiếm lưới. Sai số toàn phương trung bình (MSE) được sử dụng làm tiêu chí đánh giá. Kết quả cho thấy MSE trên tập kiểm tra đạt giá trị nhỏ nhất tại $k = 4$. Ngoài ra, nhiễu và sai số ngẫu nhiên được giảm thiểu bằng bộ lọc trung bình trượt với kích thước cửa sổ $n = 5$. Kích thước này được xác định dựa trên phân tích hàm tự tương quan (ACF). Giá trị này ghi nhận hiệu quả các biến động ngắn hạn của thông số chất lượng nước. Đồng thời, nó tránh hiện tượng làm mịn quá mức gây suy giảm đỉnh [39].

Để khảo sát tương quan giữa các đặc trưng khác nhau, chúng tôi sử dụng phương pháp hệ số tương quan thứ hạng Spearman (r_s). Các đặc trưng gồm WTR, chỉ số chất lượng nước thô, chỉ số chất lượng nước sau xử lý và liều lượng chất keo tụ. Phương pháp này được biết đến với độ nhạy thấp đối với các mối quan hệ phi tuyến và giá trị ngoại lai. Chúng tôi loại bỏ các đặc trưng có tương quan thấp để giảm bớt đặc trưng dư thừa. Bước này giúp giảm số chiều đầu vào của mô hình, qua đó nâng cao cả hiệu quả vận hành lẫn khả năng tổng quát hóa. Sơ đồ quy trình minh họa phương pháp xây dựng mô hình được trình bày trong Fig. 1.

2.3. Phương pháp diễn giải SHAP

2.4. Đánh giá mô hình

3. Kết quả và thảo luận

3.1. Phân tích dữ liệu chất lượng nước và lựa chọn đặc trưng

Fig. 2 minh họa phân phối biểu đồ tần số và các chỉ số thống kê của từng đặc trưng. Các chỉ số này gồm giá trị nhỏ nhất (MIN), lớn nhất (MAX), trung bình, độ lệch chuẩn (SD) và hệ số biến thiên (CV). CV là thước đo định lượng độ biến động trong các tập dữ liệu [47]. Giá trị CV càng cao cho thấy độ biến động dữ liệu càng lớn. Đáng chú ý, nước thô (RW) có sự khác biệt lớn ở T (SD = 9.37, CV = 62 %), NH3-N (SD = 0.07, CV = 59 %) và NTU (SD = 2.58, CV = 57 %). Nước sau xử lý (TW) cũng ghi nhận biến động ở chỉ số T (SD = 8.77, CV = 54 %). Hầu hết các đặc trưng khác tương đối ổn định. Dao động pH rất nhỏ trong toàn bộ quy trình xử lý nước. Giá trị CV chỉ đạt 3 % đối với pH nước thô (RW) và 2 % đối với pH nước sau xử lý (TW).


Table 1
Các mô-đun Python và chức năng tương ứng được sử dụng.

Ma trận tương quan thứ hạng Spearman trong Fig. 3 minh họa mối quan hệ giữa các thông số đầu vào và biến kết quả. Liều lượng chất keo tụ PACl tương quan mạnh với T-RW ($r_s = -0.71$), NH3-N-RW ($r_s = 0.87$) và pH-RW ($r_s = -0.9$). Tương quan mạnh này cũng được ghi nhận ở T-RW ($r_s = -0.67$) và WTR ($r_s = -0.68$). Tương quan trung bình xuất hiện ở NTU-RW ($r_s = 0.45$), EC-RW ($r_s = 0.56$), pH-RW ($r_s = -0.33$) và CODMn-RW ($r_s = 0.56$). Mức tương quan trung bình cũng được tìm thấy ở EC-TW ($r_s = 0.43$) và NTU-TW ($r_s = -0.23$). CODMn-TW ($r_s = 0.011$) thể hiện tương quan yếu với liều lượng PACl. Đáng chú ý, EC-RW và EC-TW có tương quan tuyến tính rất cao ($r_s = 0.98$). CODMn-RW và EC-RW cũng tương quan tuyến tính cao với T-TW (lần lượt có $r_s = 0.91$ và -0.95). Do đó, để tránh dư thừa, mô hình chỉ giữ lại một đặc trưng từ mỗi cặp có tương quan cao, bên cạnh EC-RW và CODMn-RW. Tập đặc trưng cuối cùng để huấn luyện mô hình gồm T-RW, pH-RW, NH3-N-RW, NTU-RW, EC-RW, CODMn-RW, pH-TW, NTU-TW và WTR. Biến mục tiêu của mô hình là liều lượng PACl. Mô hình này nắm bắt các tương tác phức tạp giữa chất lượng nước thô (RW), liều lượng châm và chất lượng nước sau xử lý (TW).

Fig. 2. Phân phối biểu đồ tần số của các đặc trưng và biến mục tiêu (RW: nước thô, TW: nước sau xử lý, MIN: giá trị nhỏ nhất, MAX: giá trị lớn nhất, SD: độ lệch chuẩn, CV: hệ số biến thiên. Mỗi đồ thị con thể hiện phân phối của các điểm mẫu trong một biến cụ thể. Trục tung biểu thị tần suất xuất hiện của từng đặc trưng trong tập dữ liệu. Trục hoành biểu diễn các khoảng mẫu. Đường màu tím biểu thị đường cong phân phối tần số được làm khớp, chỉ ra phạm vi sử dụng biến trong tập dữ liệu). (Để hiểu rõ các chú dẫn về màu sắc trong hình vẽ này, người đọc vui lòng tham khảo phiên bản trực tuyến của bài báo).


Fig. 4 trình bày kết quả huấn luyện và kiểm tra của mô hình RF được phát triển bằng AutoML để dự đoán liều lượng chất keo tụ. Như thể hiện trong Fig. 4a và b, mô hình thể hiện hiệu suất ổn định và độ chính xác cao trên cả tập huấn luyện và kiểm tra. Hàm lượng chất rắn lơ lửng, hạt keo và các chất ô nhiễm khác trong nước thô ở mức thấp giúp nước có chất lượng cao. Ảnh hưởng tối thiểu của pH-RW và NTU-RW lên quá trình keo tụ khiến sai số trên tập kiểm tra chủ yếu dưới 20 mg/L. Biểu đồ mật độ phân tán trong Fig. 4c và d cho thấy liều lượng PACl thực tế và dự đoán chủ yếu nằm dọc đường chéo. Điều này cho thấy độ chệch tiềm ẩn của mô hình ở mức tối thiểu.

Table 2
Kết quả tối ưu hóa siêu tham số của các mô hình.



Ngoài ra, liều lượng chất keo tụ cần thiết giảm khi pH-RW tăng trong khoảng từ 8.0 đến 8.4. Trong môi trường kiềm yếu, PACI và hạt ô nhiễm mang điện tích trái dấu [55]. Đặc tính này giúp PACI thể hiện hiệu quả keo tụ vượt trội [56]. Nhiệt độ nhìn chung có tác động âm lên việc châm chất keo tụ. Quá trình thủy phân PACI là phản ứng thu nhiệt. Độ nhớt tăng ở nhiệt độ thấp cản trở chuyển động nhiệt của hạt lơ lửng, gây bất lợi cho sự kết tụ keo ổn định [57]. Do đó, cần tăng liều lượng PACI để đạt hiệu quả keo tụ tối ưu [58].

Các tác giả tuyên bố không có xung đột lợi ích tài chính hay quan hệ cá nhân nào ảnh hưởng đến công trình này.



Trong nghiên cứu này, chúng tôi phát triển mô hình dự đoán việc châm chất keo tụ tại nhà máy xử lý nước bằng AutoML. Chúng tôi diễn giải kết quả nhằm giải quyết vấn đề minh bạch của các mô hình dự đoán này. Các kết luận cụ thể như sau:

Fig. 8 thể hiện biểu đồ thác nước và biểu đồ quyết định cho hai mẫu cục bộ cụ thể bằng phương pháp SHAP. Fig. 8a và b thể hiện mẫu có liều lượng chất keo tụ cao hơn giá trị trung bình (14.5 mg/L). Mẫu này được thu thập vào tháng 2 với nguồn nước thô lấy từ sông Loạn Hà và T-RW đạt 3.8 °C. Fig. 8a cho thấy liều lượng chất keo tụ dự đoán của mẫu này (34.9 mg/L) cao hơn mức kỳ vọng trung bình (14.5 mg/L). Nguyên nhân chính do CODMn-RW, tiếp theo là EC-RW, NTU-RW và NH3-N-RW, trong khi đóng góp của pH-RW và WTR là không đáng kể. Fig. 8b thể hiện đóng góp của từng đặc trưng khi vượt mức dự đoán trung bình (14.5 mg/L). Các đóng góp này tạo ra giá trị đầu ra cuối cùng là 34.9 mg/L cho mẫu. Đầu tiên, khi CODMn-RW đạt 5.46 mg/L và vượt ngưỡng 4 mg/L, giá trị SHAP tăng lên đáng kể. Ngoài ra, với EC-RW ở mức 600.6 μ S/cm, NH3-N-RW ở mức 0.36 mg/L và NTU-RW đạt 7.19 NTU, các giá trị SHAP đều duy trì trên 0. Dựa trên đánh giá chuyên môn về tác động tổng thể của chất lượng nước thô, liều lượng PACl sau đó được tăng lên từ mức trung bình.


Tuyên bố đóng góp của tác giả (CRediT)

Tuyên bố về xung đột lợi ích

4. Kết luận

Hyperparameter setting


(2) Diễn giải mô hình dựa trên giá trị SHAP làm rõ ảnh hưởng của từng chỉ số chất lượng nước đến kết quả dự đoán. Cụ thể, khi NTU-RW thấp và tương đối ổn định, độ dẫn điện nước thô tác động mạnh nhất đến việc châm chất keo tụ. Theo sau là các yếu tố NH3-N-RW, CODMn-RW, T-RW và WTR.



Tính khả dụng của dữ liệu

Lời cảm ơn

Nghiên cứu này nhận tài trợ từ Chương trình Nghiên cứu và Phát triển Trọng điểm Quốc gia (2022YFC3203803). Nghiên cứu cũng được hỗ trợ bởi Sở Khoa học và Công nghệ tỉnh Phúc Kiến (2022J01522). Chúng tôi chân thành cảm ơn Công ty Công nghiệp Nước TEDA Thiên Tân đã cung cấp dữ liệu thử.



Dữ liệu sẽ được cung cấp khi có yêu cầu.

Fig. 6 presents the SHAP feature importance and summary plots for the model evaluated on the testing set. Feature importance ranking from highest to lowest is as follows: EC-RW, pH-TW, $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$, T-RW, NTU-RW, WTR, NTU-TW, and pH-RW, as shown in Fig. 6(a). Notably, the model in this study was constructed using monitoring data from the water treatment plant, adhering to the principle of continuously adjusting dosage based on raw water quality to ensure stable and compliant treated water quality. Therefore, the relationship between dosage and treated water quality exhibits a direct causal link, despite dosage exceeding a certain threshold may have minimal impact on treated water quality. On the other hand, the relationship between dosage and raw water quality reflects practical expertise, with water plant operators relying on their experience and raw water quality to set chemical dosages that meet treated water standards. Because of the wide variation in raw water quality and the stability of treated water quality, raw water indicators are generally more important than treated water indicators in the model.

Fig. 6 (b) displays the contribution of input features to the prediction results, with features arranged in descending order along the vertical axis. Consistent SHAP values aligned with characteristic values for EC-RW, $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$, and NTU-RW suggest a positive influence on coagulant dosing, while the opposite trend for pH-RW, T-RW, and WTR suggests a negative influence on dosing. For example, higher EC-RW corresponds to higher SHAP values, indicating an increase in dosing. Higher EC implies lower water purity, potentially containing higher concentrations of dissolved salts, organics, metal ions, and other contaminants. The cations in PACl can neutralize the surface charges of negatively charged suspended particles or colloidal substances in water, reducing the electrostatic repulsion between particles and promoting aggregation [50]. In contrast, higher WTR values correspond to lower SHAP values, indicating a decrease in dosage.

Fig. 7 illustrates the SHAP values for individual variables, which demonstrates the marginal effects of each feature on model predictions.

For the raw water indicator, conductivity reflects the total concentration of dissolved ions in the water and shows a nearly linear enhancement relationship with dosage when it is between 300 and 550 $\mu\text{S}/\text{cm}$, while below 300 $\mu\text{S}/\text{cm}$ or above 550 $\mu\text{S}/\text{cm}$ this relationship shows a trend of diminishing returns. High conductivity compresses the bilayer and promotes coagulation, but low pH inhibits $\text{Al}(\text{OH})_3$ formation when incremental compensation is required. Ammonia is nitrogen in the form of free ammonia (NH_3) and ammonium ions (NH_4^+) regulated by pH and temperature. $\text{NH}_3\text{-N-RW}$ in the range of 0–0.2 mg/L also exerts a positive influence on coagulant dosage, with the relationship becoming less significant beyond this range. High temperature accelerates the hydrolysis, but low $\text{NH}_3\text{-N}$ can reduce the interference, at this time the PACl dosage can be dosed according to professional judgment.

COD_{Mn} reflects the total amount of organic matter and reducing inorganic matter in the water body, there is no obvious correlation with the dosage, if it is less than 4 mg/L, and more than 4 mg/L threshold, it will compete for the active site with the PACl, and the SHAP value at this time shows a sharp upward trend. Furthermore, NTU-RW generally has a positive promoting effect on dosing, as an appropriate increase in coagulant to promote particle aggregation and settlement, which is in line with the findings of Vunain et al. [51]. However, when NTU-RW is less than 2 NTU, the SHAP value shows an upward trend, as sparse and dispersed colloidal particles in low-turbidity water limit the ability of colloids formed after PACl hydrolysis to capture solid impurity particles. Therefore, the dosage of PACl must be increased to compensate for diffusion limitations and to ensure electroneutralization [52–54]. In high COD_{Mn} and high turbidity water, organic matter can encapsulate colloidal particles and additional amounts of PACl are needed to enhance charge neutralization and break down the organic matter barrier.

In addition, the required coagulant dosage decreases as the pH-RW increases within the range of 8.0 to 8.4, which is attributed to the opposite charges of PACl and contaminant particles in a weakly alkaline environment [55], allowing PACl to exhibit superior coagulation properties [56]. It is likely that temperature typically has a negative effect on dosing. The hydrolysis of PACl is an endothermic reaction, but the increased viscosity at low temperatures impedes the thermal motion of suspended particles in water, which is detrimental to the stability of colloidal aggregation [57]. Therefore, the dosage of PACl should be increased to achieve optimal coagulation efficacy [58].

For treated water indicators, a distinct negative linear correlation is observed between pH-TW and the quantity of coagulant administered, primarily clustering within a narrow pH range of 7.6 to 7.8. This negative linear relationship is primarily due to the fact that the




Fig. 6. SHAP feature importance (a) and summary plot (b) for the test set. The vertical axis of plot (a) represents the features in descending order of their average absolute SHAP value on the model output, with larger values indicating a higher contribution of the feature to the prediction, and the horizontal axis indicates the size of the SHAP value, reflecting the average degree of influence of the feature on the model output. Fig (b) each point represents the SHAP value of a sample, the position of the horizontal axis shows the size of the value, the colour shades reflect the original value of the feature is high or low (red is high value, blue is low value), the vertical axis represents the order by the importance of the feature, in line with Fig (a), the superimposed trend represents the relationship between the feature's value high or low and the direction of the SHAP value that can be observed from the distribution of points. (For interpretation of the references to colour in this figure legend, the reader is referred to the web version of this article.)




Fig. 7. Nonlinear relationships between individual water quality parameters and coagulant dosage for EC-RW (a), pH-TW (b), $\text{NH}_3\text{-N-RW}$ (c), $\text{COD}_{\text{Mn-RW}}$ (d), T-RW (e), NTU-RW (f), WTR (g), NTU-TW (h), and pH-RW (i). For each data point with a positive SHAP value, the dosage of coagulant increases with the SHAP value, exerting a positive impact. Conversely, for points with negative SHAP values, the opposite effect is observed. The units for these variables are consistent with those in Fig. 2.

hydrolysis reaction of PACl releases H^+ , resulting in a decrease in effluent pH [59]. However, over-dosing chemicals to meet the effluent pH standard will cause the colloids to re-stabilize, resulting in a decrease in flocculation efficiency. In addition, the increase in dissolved aluminum residue can affect the safety of the effluent [54]. In addition, no apparent linear relationship is observed between PACl dosage and NTU-TW after coagulation, contrary to the results reported by Chiavola [60]. NTU-TW is affected by both raw water quality and coagulant dosage. Specifically, elevated NTU-RW values require a manual increase in coagulant dosage to meet NTU-TW standards. Therefore, the NTU-TW values from an operating plant remain relatively low and stable with minimal variation, which has little impact on dosage prediction. In addition, the effectiveness of PACl in the coagulation process depends primarily on charge neutralization and adsorption bridging. An appropriate dosage of PACl hydrolyzes to produce positively charged ions that neutralize negatively charged colloids, thereby enhancing turbidity removal. However, excessive PACl triggers “colloidal protection,” where excess positively charged ions adsorb onto colloidal surfaces and

hydrophobic colloids become hydrophilic, reducing floc settling and ultimately decreasing turbidity removal efficiency [56,61,62].

Although AutoML (TPOT) and SHAP perform well in optimizing machine learning models and improving interpretability, they still have several limitations. AutoML may face the risk of overfitting during model selection and hyperparameter optimization, and in this study, despite the training set $R^2 = 1.00$, the high consistency of the repeated cross-validation and the independent test set ($R^2 = 0.96$) suggests that the model was not overfitted. The SHAP method reveals complex action laws that cannot be captured by traditional linear methods, identifies the threshold response behavior of key parameters, and breaks through the limitations of linear statistics.

Fig. 8 shows waterfall plots and decision plots for two specific local samples using the SHAP method. Fig. 8a and b show a sample with a coagulant dosage higher than the average value (14.5 mg/L). This sample was collected in February, with the raw water coming from the Luanhe River, and T-RW recorded at 3.8 °C. Fig. 8a shows that the predicted coagulant dosage for this sample (34.9 mg/L) is higher than




Fig. 8. Decision plots and waterfall plots for two local samples, featuring three key characteristics: 1) the output value, representing the prediction for an individual sample; 2) the base value, corresponding to the average expected value in the testing set; and 3) colour coding, where red variables push the prediction upwards and blue variables push it downwards) are presented. The Fig includes decision plot (a) and waterfall plot (b) for a sample with dosing amount above the average, and decision plot (c) and waterfall plot (d) for a sample with dosing amount below the average. (For interpretation of the references to colour in this figure legend, the reader is referred to the web version of this article.)

the average expected value in the test set (14.5 mg/L), mainly due to $\text{COD}_{\text{Mn}}\text{-RW}$, followed by EC-RW , NTU-RW , and $\text{NH}_3\text{-N-RW}$, while the contribution of pH-RW and WTR are negligible. Fig. 8b shows the contribution of each feature in exceeding the average prediction (14.5 mg/L), ultimately resulting in a final output of 34.9 mg/L for this sample. First, $\text{COD}_{\text{Mn}}\text{-RW}$ reaches 5.46 mg/L, exceeding the threshold of 4 mg/L, the SHAP value increases significantly. In addition, with EC-RW at 600.6 $\mu\text{S/cm}$, $\text{NH}_3\text{-N-RW}$ at 0.36 mg/L and NTU-RW at 7.19 NTU, their SHAP values all remain above 0. Based on professional judgment of the overall impact of raw water quality, the dosage of PACl was subsequently increased from the average level.

Fig. 8c and d show a sample taken in May with the Yangtze River as the source water, showing a coagulant dosage below the average. Fig. 8c shows that the predicted coagulant dosage for this sample (8.57 mg/L) is significantly lower than the average expected value in the test set (14.5 mg/L). Among the factors, pH-TW (with a value of 7.906) has the most significant negative effect on the dosage prediction, indicating that a coagulant dosage at this level will significantly lower the pH of the treated water. This is followed by T-RW , EC-RW , and $\text{COD}_{\text{Mn}}\text{-RW}$, while the contribution of $\text{NH}_3\text{-N-RW}$ and WTR is negligible. Fig. 8d further illustrates how each feature contributes to shifting the dosage towards a value below the average prediction (14.5 mg/L), ultimately resulting in a final output of 8.57 mg/L for this sample. For the raw water characterized by T at 22.34 °C, EC at 290.2 $\mu\text{S/cm}$, $\text{COD}_{\text{Mn}}\text{-RW}$ at 2.6 mg/L, and pH at 8.15, the corresponding SHAP values for these parameters are uniformly negative. Based on practical experience, it was decided to reduce the dosage of PACl to a level below the average.

In summary, the model developed in this study optimizes coagulant

dosing, not only enabling precise chemical addition in the coagulation process of water treatment plants—thereby significantly minimizing coagulant overuse—but also employing interpretable methods to reveal key factors and their impact relationships influencing coagulant consumption. This empowers plant operators to make more scientific and rational decisions, avoiding overdosing while ensuring effluent quality. However, in practical water treatment applications, further efforts are required to mitigate the environmental impacts of coagulant use. This can be achieved by integrating the model with processes such as pre-chlorination and activated carbon adsorption to reduce coagulant demand. Additionally, developing green and sustainable water treatment technologies, such as bio-based flocculants (e.g., chitosan, microbial flocculants), photocatalytic technologies [63,64], could reduce reliance on non-renewable resources and minimize environmental risks posed by chemical residues and byproducts (e.g., aluminum hydroxide sludge).

4. Conclusions

In this study, we developed a predictive model for coagulant dosing in a water treatment plant using AutoML and interpreted the model results to address the transparency issue associated with such predictive models. The conclusions are as follows:

- (1) The RF model developed using AutoML demonstrated superior performance with a test R^2 value of 0.96, RMSE of 0.89, and MAE of 0.47. This model offers a faster development cycle and higher prediction accuracy compared to manually selected models, and

serves as a valuable tool for predicting coagulant dosing in water treatment plants.

- (2) Model interpretation based on SHAP values revealed the influence of each water quality indicator on the prediction results. Specifically, when NTU-RW is low and relatively stable, raw water conductivity emerges as the most significant factor influencing coagulant dosing, followed by $\text{NH}_3\text{-N}$ -RW, COD_{Mn} -RW, T-RW, and WTR.
- (3) The optimized model predicts daily PACl savings of 222 kg (11 %) for water from the Yangtze River and 225 kg (8 %) for water from the Luanhe River. This highlights the key role of the coagulant dosing model in improving water treatment efficiency and optimizing resource utilization.

CRediT authorship contribution statement

Liyan Feng: Writing – review & editing, Writing – original draft, Visualization, Validation, Supervision, Software, Resources, Project administration, Methodology, Investigation, Formal analysis, Data curation, Conceptualization. **Ying Zhang:** Resources, Project administration, Methodology, Investigation, Funding acquisition, Data curation. **Xiaoting Wei:** Writing – original draft, Visualization, Supervision, Software. **Mengyuan Wang:** Visualization, Validation, Software, Resources, Project administration. **Zhiguang Niu:** Resources, Project administration, Methodology, Investigation, Data curation. **Chenchen Wang:** Writing – review & editing, Visualization, Supervision, Software, Project administration.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgements

This study was supported by the National Key Research and Development Programme (2022YFC3203803) and the Department of Science and Technology of Fujian Province (2022J01522), and we also thank Tianjin TEDA Water Industry Co. for providing the raw data.

Data availability

Data will be made available on request.

References

- [1] G. Mannina, T.F. Rebouças, A. Cosenza, K. Chandran, A plant-wide wastewater treatment plant model for carbon and energy footprint: model application and scenario analysis, *J. Clean. Prod.* 217 (2019) 244–256.
- [2] Z. Wu, H. Duan, K. Li, L. Ye, A comprehensive carbon footprint analysis of different wastewater treatment plant configurations, *Environ. Res.* 214 (2022) 113818.
- [3] N. Liu, D. Wang, J. Xu, L. Liu, J. Xue, T. Han, J. Wang, J. Lei, H. Shao, X. Zhang, Novel 3D MIL-53(Fe)/graphene aerogel composites for boosted photocatalytic ibuprofen degradation under visible light: process and mechanism, *Surf. Interface Anal.* 46 (2024) 104192, <https://doi.org/10.1016/j.surfin.2024.104192>.
- [4] Y. Wang, G. Jiao, Y. Yang, J. Wang, J. Zhang, H. Jiang, N. Liu, X. Zhang, 3D structure of $\text{LaFe}_{1-8}\text{Co}_{0.3}\text{O}_3$ @carbon cloth composite catalyst for promoting peroxymonosulfate activation: identification of catalytic mechanism towards multiple antibiotics, *Desalination* 602 (2025) 118643, <https://doi.org/10.1016/j.desal.2025.118643>.
- [5] J. Xu, G. Jiao, G. Sheng, N. Lin, B. Yang, J. Wang, H. Jiang, Y. Wang, X. Zhang, Microwave-assisted PMS activation $\text{Ti}_3\text{C}_2/\text{LaFe}_{0.5}\text{Cu}_{0.5}\text{O}_3\text{-P}$ catalysts for efficient degradation of CIP: enhancement of catalytic performance by phosphoric acid etching, *Sep. Purif. Technol.* 354 (2025) 129357.
- [6] Y. Yang, J. Ye, Y. Zhai, B. Yang, M. Yin, Y. Xu, J. Wang, X. Zhang, ZIF-67-derived monolithic bimetallic sulfides as efficient persulfate activators for the degradation of ofloxacin, *Surfaces and Interfaces* 51 (2024) 104713.
- [7] S. Li, G. Zhu, X. Li, P. Wan, F. Yuan, S. Xu, A.S. Hursthouse, Ecosystem-inspired model and artificial intelligence predicts pollutant consumption capacity by coagulation in drinking water treatment, *Environ. Chem. Lett.* 21 (5) (2023) 2499–2508.
- [8] G. Zhu, J. Lin, H. Fang, F. Yuan, X. Li, C. Yuan, A.S. Hursthouse, A flocculation tensor to monitor water quality using a deep learning model, *Environ. Chem. Lett.* 20 (6) (2022) 3405–3414.
- [9] O. Bello, Y. Hamam, K. Djouani, Coagulation process control in water treatment plants using multiple model predictive control, *Alex. Eng. J.* 53 (4) (2014) 939–948.
- [10] S. Peng, Y. Guo, J. Wang, Y. Wang, W. Zhang, X. Zhou, L. Jiang, B. Lai, The coagulation-precipitation turbidity prediction model for precision drug delivery system based on deep learning and machine vision, *J. Environ. Chem. Eng.* 12 (2024) 112211.
- [11] H. Boumezbaur, F. Laouacheria, S. Heddami, L. Djemili, Modelling coagulant dosage in drinking water treatment plant using advance machine learning model: hybrid extreme learning machine optimized by bat algorithm, *Environ. Sci. Pollut. Res.* 30 (28) (2023) 72463–72483.
- [12] X. Fang, J. Zang, Z. Zhai, L. Zhang, Z. Shu, Y. Liang, Exploring potential dual-stage attention based recurrent neural network machine learning application for dosage prediction in intelligent municipal management, *Environ. Sci. Water Res. Technol.* 9 (3) (2023) 890–899, <https://doi.org/10.1039/D2EW00560C>.
- [13] L. Li, S. Rong, R. Wang, S. Yu, Recent advances in artificial intelligence and machine learning for nonlinear relationship analysis and process control in drinking water treatment: a review, *Chem. Eng. J.* 405 (2021) 126673.
- [14] A. Jakovljevic, L. Charlin, B. Barbeau, Applying recurrent neural networks and blocked cross-validation to model conventional drinking water treatment processes, *Water* 16 (7) (2024) 1042.
- [15] M. Achite, S. Samadianfard, N. Elshaboury, M. Sharafi, Modeling and optimization of coagulant dosage in water treatment plants using hybridized random forest model with genetic algorithm optimization, *Environ. Dev. Sustain.* 25 (10) (2023) 11189–11207.
- [16] S. Peng, Y. Guo, J. Wang, Y. Wang, W. Zhang, X. Zhou, L. Jiang, B. Lai, The coagulation-precipitation turbidity prediction model for precision drug delivery system based on deep learning and machine vision, *J. Environ. Chem. Eng.* 12 (2024) 112211, <https://doi.org/10.1016/j.jece.2024.112211>.
- [17] X. Fu, Q. Zheng, G. Jiang, K. Roy, L. Huang, C. Liu, K. Li, H. Chen, X. Song, J. Chen, Z. Wang, Water quality prediction of copper-molybdenum mining-beneficiation wastewater based on the PSO-SVR model, *Front. Environ. Sci. Eng.* 17 (8) (2023) 98, <https://doi.org/10.1007/s11783-023-1698-9>.
- [18] M. Achite, S. Samadianfard, N. Elshaboury, M. Sharafi, Modeling and optimization of coagulant dosage in water treatment plants using hybridized random forest model with genetic algorithm optimization, *Environ. Dev. Sustain.* 25 (10) (2022) 11189–11207, <https://doi.org/10.1007/s10668-022-02523-z>.
- [19] M. Baratchi, C. Wang, S. Limmer, J.N. van Rijn, H. Hoos, T. Bäck, M. Olhofer, Automated machine learning: past, present and future, *Artif. Intell. Rev.* 57 (5) (2024) 122.
- [20] H. Eldeeb, M. Maher, R. Elshawi, S. Sakr, AutoMLBench: a comprehensive experimental evaluation of automated machine learning frameworks, *Expert Syst. Appl.* 243 (2024) 122877.
- [21] A. Brown, M. Gupta, M. Abdelsalam, Automated machine learning for deep learning based malware detection, *Comput. Secur.* 137 (2024) 103582.
- [22] X. Chen, C.Y. Liu, R. Proietti, Z. Li, S.J.B. Yoo, Automating optical network fault management with machine learning, *IEEE Commun. Mag.* 60 (12) (2022) 88–94.
- [23] J. Tetteroo, M. Baratchi, H.H. Hoos, Automated machine learning for COVID-19 forecasting, *IEEE Access* 10 (2022) 94718–94737.
- [24] N.P. Wu, W. Wang, D. Gadiagellan, M. Counsell, N.K. Hamidi, Y. Koike, H. Q. Nguyen, An automated robotic interface for assays: facilitating machine learning in drug discovery by the automation of physicochemical property assays, *ACS Omega* 9 (23) (2024) 24948–24958.
- [25] R.S. Olson, N. Bartley, R.J. Urbanowicz, J.H. Moore, Evaluation of a Tree-Based Pipeline Optimization Tool for Automating Data Science, *Proceedings of the Genetic and Evolutionary Computation Conference 2016*, Association for Computing Machinery, Denver, Colorado, USA, 2016, pp. 485–492.
- [26] J. Luo, Y. Luo, X. Cheng, X. Liu, F. Wang, F. Fang, J. Cao, W. Liu, R. Xu, Prediction of Biological Nutrients Removal in Full-Scale Wastewater Treatment Plants Using H2O Automated Machine Learning and Back Propagation Artificial Neural Network Model: Optimization and Comparison, *Bioresour. Technol.* 390 (2023) 129842, <https://doi.org/10.1016/j.biortech.2023.129842>.
- [27] D. Venkata Vara Prasad, P. Senthil Kumar, L.Y. Venkataramana, G. Prasannamedha, S. Harshana, S. Jahnvi Srividya, K. Harrine, S. Indraganti, Automating water quality analysis using ML and auto ML techniques, *Environ. Res.* 202 (2021) 111720, <https://doi.org/10.1016/j.envres.2021.111720>.
- [28] S.M. Lundberg, S.I. Lee, A unified approach to interpreting model predictions, *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS* 30 (NIPS 2017), 2017.
- [29] J.T. Hancock, T.M. Khoshgoftaar, Q. Liang, A problem-agnostic approach to feature selection and analysis using SHAP, *J. Big Data* 12 (1) (2025) 12.
- [30] N. Bacanin, M. Perisic, G. Jovanovic, R. Damašević, S. Stanisic, V. Simic, M. Zivkovic, A. Stojic, The explainable potential of coupling hybridized metaheuristics, XGBoost, and SHAP in revealing toluene behavior in the atmosphere, *Sci. Total Environ.* 929 (2024) 172195.
- [31] W. Chu, C. Zhang, H. Li, L. Zhang, D. Shen, R. Li, SHAP-powered insights into spatiotemporal effects: unlocking explainable Bayesian-neural-network urban flood forecasting, *Int. J. Appl. Earth Obs. Geoinf.* 131 (2024) 103972.
- [32] K. Lin, Y. Gao, Model interpretability of financial fraud detection by group SHAP, *Expert Syst. Appl.* 210 (2022) 118354.
- [33] K. Miao, A. Houssou Hounye, L. Su, Q. Pan, J. Wang, M. Hou, L. Xiong, Exploring explainable machine learning and Shapley additive exPlanations (SHAP) technique

- to uncover key factors of HNSC cancer: An analysis of the best practices, *Biomedical Signal Processing and Control* 89 (2024) 105752.
- [34] K. Wang, J. Tian, C. Zheng, H. Yang, J. Ren, Y. Liu, Q. Han, Y. Zhang, Interpretable prediction of 3-year all-cause mortality in patients with heart failure caused by coronary heart disease based on machine learning and SHAP, *Comput. Biol. Med.* 137 (2021) 104813.
- [35] R. Li, K. Feng, T. An, P. Cheng, L. Wei, Z. Zhao, X. Xu, L. Zhu, Enhanced Insights into Effluent Prediction in Wastewater Treatment Plants: Comprehensive Deep Learning Model Explanation Based on SHAP, *ACS ES&T Water*, 2024.
- [36] R.K. Makumbura, L. Mampitiya, N. Rathnayake, D.P.P. Meddage, S. Henna, T. L. Dang, Y. Hoshino, U. Rathnayake, Advancing water quality assessment and prediction using machine learning models, coupled with explainable artificial intelligence (XAI) techniques like shapley additive explanations (SHAP) for interpreting the black-box nature, *Results in Engineering* 23 (2024) 102831, <https://doi.org/10.1016/j.rineng.2024.102831>.
- [37] J. Park, W.H. Lee, K.T. Kim, C.Y. Park, S. Lee, T.-Y. Heo, Interpretation of ensemble learning to predict water quality using explainable artificial intelligence, *Sci. Total Environ.* 832 (2022) 155070.
- [38] S. Narges, A. Ghorban, K. Hassan, K. Mohammad, Prediction of the optimal dosage of coagulants in water treatment plants through developing models based on artificial neural network fuzzy inference system (ANFIS), *J. Environ. Health Sci. Eng.* 19 (2) (2021) 1543–1553.
- [39] S. Lin, J. Kim, C. Hua, M.-H. Park, S. Kang, Coagulant dosage determination using deep learning-based graph attention multivariate time series forecasting model, *Water Res.* 232 (2023) 119665.
- [40] B. Celik, J. Vanschoren, Adaptation strategies for automated machine learning on evolving data, *IEEE Trans. Pattern Anal. Mach. Intell.* 43 (9) (2021) 3067–3078.
- [41] A. Abdollahi, D. Li, J. Deng, A. Amini, An explainable artificial-intelligence-aided safety factor prediction of road embankments, *Eng. Appl. Artif. Intell.* 136 (2024) 108854.
- [42] A. Abdollahi, B. Pradhan, Explainable artificial intelligence (XAI) for interpreting the contributing factors feed into the wildfire susceptibility prediction model, *Sci. Total Environ.* 879 (2023) 163004.
- [43] X. Ma, Y. Tang, C. Wang, Y. Li, J. Zhang, Y. Luo, Z. Xu, F. Wu, S. Wang, Interpretable XGBoost-SHAP model predicts nanoparticles delivery efficiency based on tumor genomic mutations and nanoparticle properties, *ACS Appl. Bio Mater.* 6 (10) (2023) 4326–4335.
- [44] D. Wang, L. Chen, T. Li, X. Chang, K. Ma, W. You, C. Tan, Successful prediction for coagulant dosage and effluent turbidity of a coagulation process in a drinking water treatment plant based on the Elman neural network and random forest models, *Environ. Sci.: Water Res. Technol.* 9 (9) (2023) 2263–2274.
- [45] S. Tan, R. Wang, G. Song, S. Qi, K. Zhang, Z. Zhao, Q. Yin, Machine learning and Shapley additive explanation-based interpretable prediction of the electrocatalytic performance of N-doped carbon materials, *Fuel* 355 (2024) 129469.
- [46] S. Lin, J. Kim, C. Hua, S. Kang, M.-H. Park, Comparing artificial and deep neural network models for prediction of coagulant amount and settled water turbidity: lessons learned from big data in water treatment operations, *Journal of Water Process Engineering* 54 (2023) 103949.
- [47] D.S. Wang, L. Chen, T.Y. Li, X. Chang, K.W. Ma, W.H. You, C.Q. Tan, Successful prediction for coagulant dosage and effluent turbidity of a coagulation process in a drinking water treatment plant based on the elman neural network and random forest models, *ENVIRONMENTAL SCIENCE-WATER RESEARCH & TECHNOLOGY* 9 (9) (2023) 2263–2274.
- [48] J. Kim, C. Hua, K. Kim, S. Lin, G. Oh, M.-H. Park, S. Kang, Optimizing coagulant dosage using deep learning models with large-scale data, *Chemosphere* 350 (2024) 140989.
- [49] P. Tsirikoglou, S. Abraham, F. Contino, C. Lacor, G. Ghorbaniasl, A hyperparameters selection technique for support vector regression models, *Appl. Soft Comput.* 61 (2017) 139–148.
- [50] A.-A. El Foulani, O. Ounas, M. Chafi, A comparative study of the performance of Polyaluminum chloride-sodium alginate and Polyaluminum chloride-chitosan composite coagulants in dam water treatment, *J. Polym. Environ.* 31 (11) (2023) 4909–4918.
- [51] E. Vunain, E.F. Masoamphambe, P.M.G. Mpekutela, M. Monjerezi, A. Etale, Evaluation of coagulating efficiency and water borne pathogens reduction capacity of *Moringa oleifera* seed powder for treatment of domestic wastewater from Zomba, Malawi, *J. Environ. Chem. Eng.* 7 (3) (2019) 103118, <https://doi.org/10.1016/j.jece.2019.103118>.
- [52] Campinas, M., Silva, C., Viegas, R.M.C., Coelho, R., Lucas, H., Rosa, M.J. . 2020. To what extent may pharmaceuticals and pesticides be removed by PAC conventional addition to low-turbidity surface waters and what are the potential bottlenecks?, *Journal of water Process Engineering*.
- [53] Z. Liu, H. Wei, A. Li, H. Yang, Enhanced coagulation of low-turbidity micro-polluted surface water: properties and optimization, *J. Environ. Manag.* 233 (2019) 739–747.
- [54] Z. Zhang, R. Jing, S. He, J. Qian, K. Zhang, G. Ma, X. Chang, M. Zhang, Y. Li, Coagulation of low temperature and low turbidity water: adjusting basicity of polyaluminum chloride (PAC) and using chitosan as coagulant aid, *Sep. Purif. Technol.* 206 (2018) 131–139.
- [55] P. Cañizares, C. Jiménez, F. Martínez, M.A. Rodrigo, C. Sáez, The pH as a key parameter in the choice between coagulation and electrocoagulation for the treatment of wastewaters, *J. Hazard. Mater.* 163 (1) (2009) 158–164.
- [56] X. Ji, Z. Li, M. Wang, Z. Yuan, L. Jin, Response surface methodology approach to optimize parameters for coagulation process using Polyaluminum chloride (PAC), *Water* 16 (11) (2024) 1470.
- [57] G. Kim, J. Ryu, T. Ryu, H.-i. Kim, J. Shin, D.-W. Cho, Effects of calcination temperature on the adsorption ability of polyaluminum chloride (PAC) sludge-derived granules for as(V), *Journal of water Process. Eng.* 57 (2023) 104688.
- [58] W.P. Cheng, F.H. Chi, C.C. Li, R.F. Yu, A study on the removal of organic substances from low-turbidity and low-alkalinity water with metal-polysilicate coagulants, *Colloids Surf. A Physicochem. Eng. Asp.* 312 (2-3) (2008) 238–244, <https://doi.org/10.1016/j.colsurfa.2007.06.060>.
- [59] J. Duan, J. Gregory, Coagulation by hydrolysing metal salts, *Adv. Colloid Interf. Sci.* 100-102 (2003) 475–502.
- [60] A. Chiavola, C. Di Marcantonio, M. D'Agostini, S. Leoni, M. Lazzazzara, A combined experimental-modeling approach for turbidity removal optimization in a coagulation-flocculation unit of a drinking water treatment plant, *J. Process Control* 130 (2023) 103068.
- [61] B. Ozbey-Unal, C. Balci-Canbolat, N. Dizge, B. Keskinler, Treatability studies on optimizing coagulant type and dosage in combined coagulation/membrane processes for table olive processing wastewater, *J. Water Process Eng.* 26 (2018) 301–307, <https://doi.org/10.1016/j.jwpe.2018.10.023>.
- [62] K. Wu, H. Wang, R. Liu, X. Zhao, H. Liu, J. Qu, Arsenic removal from a high-arsenic wastewater using in situ formed Fe-Mn binary oxide combined with coagulation by poly-aluminum chloride, *J. Hazard. Mater.* 158 (2–3) (2010) 990–995.
- [63] L. Luo, L. Zhang, H. Ye, Y. Dai, Y. Xie, Y. Chen, Z. Wang, Y. Zhang, Synchronous promotion of ZnIn2S4 sacrificial agent-free photocatalytic hydrogen production by non-metallic doping and construction of heterojunction, *Sep. Purif. Technol.* 360 (2025) 131102.
- [64] H. Yang, Y. Duan, Y. Dai, Y. Chen, Y. Xie, G. Zhang, Y. Zhang, CeO₂-x decorated CoFe-LDH on nickel foam with moderated oxygen vacancies for the oxygen evolution reaction, *Colloids Surf. A Physicochem. Eng. Asp.* 709 (2025) 136055.