


HIGHLIGHTS

ĐIỂM NỔI BẬT



- Tổng kết các nguyên lý và phương pháp học máy cho ứng dụng bể phản ứng sinh học màng (MBR).
- Đánh giá các mô hình hiện có về loại bỏ chất ô nhiễm và bám bẩn màng trong MBR.
- Cung cấp bài hướng dẫn minh họa các mô hình học máy dùng cho dự đoán bám bẩn màng.
- Thảo luận các hạn chế và định hướng cải tiến cho vận hành thông minh MBR.

Một ví dụ hướng dẫn minh họa quy trình mô hình hóa của SVM, rừng ngẫu nhiên (RF) và mạng nơ-ron lan truyền ngược (BPNN). Ví dụ này cũng minh họa mạng bộ nhớ dài-ngắn hạn (LSTM) và giải thuật di truyền kết hợp lan truyền ngược (GA-BP). Kết quả mô phỏng cho thấy cả năm phương pháp đều đạt độ chính xác dự đoán với $R^2 > 0,8$. Cuối cùng, nghiên cứu phân tích các thách thức hiện nay khi triển khai mô hình học máy trong MBR. Học sâu, học máy tự động (AutoML) và trí tuệ nhân tạo có thể giải thích (XAI) có thể kết hợp với nhau. Sự tích hợp này hỗ trợ triển khai mô hình vào thực tế kỹ thuật. Các hiểu biết này hướng tới thiết lập khung điều khiển thông minh cho quá trình MBR trong tương lai.

1 Introduction


****Tác giả liên hệ**:** □ E-mail: kxiao@ucas.ac.cn
****Lịch sử bài báo**:** Nhận ngày 26 tháng 8 năm 2024, Chỉnh sửa ngày 29 tháng 10 năm 2024, Chấp nhận ngày 22 tháng 11 năm 2024, Xuất bản trực tuyến ngày 20 tháng 12 năm 2024
© Higher Education Press 2025
Frontiers of Environmental Science & Engineering, 2025, 19(3): 34
DOI: <https://doi.org/10.1007/s11783-025-1954-2>
****BÀI BÁO TỔNG QUAN****

****TỪ KHÓA**:** Bể phản ứng sinh học màng, Học máy, Loại bỏ chất ô nhiễm, Bám bẩn màng, Dự đoán mô hình

Xử lý và tái sử dụng nước thải giúp giảm khủng hoảng do khan hiếm và ô nhiễm nước. Công nghệ bể phản ứng sinh học màng (MBR) kết hợp giữa phân tách màng và xử lý sinh học (Yamamoto et al., 1989). Công nghệ này được áp dụng rộng rãi trong các năm gần đây (Xiao et al., 2014; Krzeminski et al., 2017). MBR cho nước đầu ra ổn định và tốn ít diện tích. Hệ thống này cũng sinh ra ít bùn dư (Xiao et al., 2019; Qu et al., 2022). Tuy nhiên, bám bẩn màng trong vận hành MBR làm giảm thông lượng dòng thấm và giảm hiệu quả phân tách. Hiện tượng này làm tăng tiêu thụ năng lượng và rút ngắn tuổi thọ màng. Điều đó hạn chế tính bền vững kinh tế - kỹ thuật (Xiao et al., 2019; Qu et al., 2022).


Bám bẩn màng liên quan chặt chẽ đến tính chất màng, đặc tính bùn lỏng và điều kiện vận hành. Vật liệu màng gồm polyvinylidene fluoride, polyethersulfone, polyethylene và polyacrylonitrile. Hành vi bám bẩn thay đổi theo tính ưa/kỵ nước, cấu trúc lỗ và độ nhám bề mặt. Các yếu tố này đều ảnh hưởng đến tương tác giữa màng và chất gây bám bẩn (Yamato et al., 2006; Zhang et al., 2008). Nhìn chung, màng kỵ nước dễ bị bám bẩn hơn màng ưa nước (Choi et al., 2002). Kích thước lỗ màng và kích thước chất gây bám bẩn có vai trò tương tác lẫn nhau trong quá trình bám bẩn.

Chất rắn lơ lửng trong bùn lỏng (MLSS) gây bám bẩn màng trong MBR. Chất polyme ngoại bào (EPS) và sản phẩm vi sinh vật hòa tan (SMP) cũng gây bám bẩn. MLSS quyết định bám bẩn tổng thể, đặc biệt ở nồng độ trên 10 mg/L. Mặt khác, EPS và SMP là tác nhân chính gây ra bám bẩn không thể phục hồi vật lý. MLSS, EPS và SMP liên quan chặt chẽ đến các điều kiện vận hành của MBR (Huang et al., 2011). Các điều kiện này gồm thời gian lưu thủy lực (HRT), thời gian lưu bùn (SRT) và tỷ lệ thức ăn trên vi sinh vật. Ví dụ, HRT quá ngắn hoặc SRT quá dài làm tăng nồng độ MLSS và SMP, khiến bám bẩn màng trầm trọng hơn. Tuy vậy, nồng độ MLSS quá thấp cũng làm tăng bám bẩn, có thể do sự giải phóng quá mức của EPS (Yoon, 2015).



(a) Độ chính xác khớp chưa cao và khả năng khái quát còn yếu. Mô hình kém thích ứng với mẫu mới do đánh giá thấp độ phức tạp thực tế.

Học máy là một hướng phát triển thống kê hiện đại, bổ sung cho các mô hình thống kê truyền thống. Học máy là công nghệ trí tuệ nhân tạo tổng quát. Kỹ thuật môi trường ngày càng quan tâm nhiều hơn đến công nghệ này (Zhong et al., 2021). Học máy bắt nguồn từ thống kê nhưng tập trung ước tính chính xác hàm phức tạp bằng máy tính. Phương pháp này không chú trọng cung cấp khoảng tin cậy thống kê cho các hàm đó. Các thuật toán học máy tự động “học” từ kinh nghiệm (dữ liệu) để cải thiện hiệu suất hệ thống (Bishop, 2006).



Phần này chủ yếu giới thiệu ba phương pháp học máy (ML) phổ biến. Các phương pháp gồm máy vector hỗ trợ (SVM), mạng nơ-ron nhân tạo (ANN) và cây quyết định (DT). Phần này cũng cung cấp tổng quan ngắn gọn về thuật toán k-hàng xóm gần nhất (KNN). Bốn phương pháp này thể hiện hiệu quả khi giải quyết các bài toán phân loại với biến rời rạc. Chúng cũng giải quyết tốt các bài toán hồi quy với biến liên tục. Bảng 1 tóm tắt bốn phương pháp và phạm vi ứng dụng tương ứng.

Hình 1 Quy trình học máy: (a) quy trình tổng quát; (b) các bước chi tiết.

Hình 2 Phân loại các phương pháp học máy.

2.1.1 Máy vector hỗ trợ

2.1.2 Mạng nơ-ron nhân tạo


2.1.3 Cây quyết định và học kết hợp

2 Nguyên lý và phương pháp học máy


2.1.4 k-hàng xóm gần nhất (k-nearest neighbors)

2.1.5 Các phương pháp khác


Trong lĩnh vực môi trường, KNN có phạm vi ứng dụng hẹp hơn so với SVM, ANN và các mô hình cây. Dù vậy, mô hình vẫn giải quyết nhiều bài toán môi trường phức tạp. Các ví dụ gồm quan trắc chất lượng nước (Uddin et al., 2023) và kiểm soát xử lý nước thải (Xu et al., 2022). Mô hình cũng đánh giá quá trình hấp phụ (Nguyen et al., 2022) và dự đoán chất lượng không khí (Tella et al., 2021).




(a) MLP Model



(b) RBFNN Model



(c) CNN Model



(d) RNN Model

2.2 Tối ưu hóa mô hình

2.3 Đánh giá hiệu suất mô hình

2.4 Đánh giá khả năng giải thích mô hình

Với ANN và SVM, độ quan trọng tương đối của đặc trưng đầu vào có thể đánh giá bằng R^2 đơn giản (Hosseinzadeh et al., 2020). Độ quan trọng của biến cũng có thể được đánh giá thông qua phân tích độ nhạy (Cortez and Embrechts, 2013). Đối với mạng nơ-ron, người ta có thể tính độ quan trọng của biến đầu vào đối với đầu ra bằng trọng số liên kết nơ-ron. Một số phương pháp cho phép thực hiện đánh giá này gồm Garson (1991), Goh (1995), Gedeon (1997) và Olden (Olden et al., 2004). Đáng chú ý, phương pháp của Gedeon và Olden dùng trọng số của mọi liên kết. Trong đó phương pháp của Gedeon được thiết kế chuyên biệt cho học sâu.

Tiêu chuẩn thông tin giúp lựa chọn mô hình tối ưu bằng cách cân bằng giữa độ phức tạp và hiệu suất mô hình. Các ví dụ gồm tiêu chuẩn thông tin Akaike (AIC) (Akaike, 1974) và tiêu chuẩn thông tin Bayes (BIC) (Gideon, 1978). Một tiêu chuẩn khác là tiêu chuẩn Hannan-Quinn (HQC) (Hannan and Quinn, 1979). Với cỡ mẫu lớn, mức phạt tham số mô hình của ba tiêu chuẩn tăng dần theo thứ tự: $AIC < HQC < BIC$ (Tu and Xu, 2012). Mức phạt càng mạnh thì mô hình càng ưu tiên các đặc trưng số chiều thấp. Nhìn chung, giá trị AIC, BIC hoặc HQC càng nhỏ thể hiện mô hình khớp càng tốt và độ chính xác càng cao.



2.5 Hướng dẫn lựa chọn mô hình

3 Ứng dụng của học máy trong MBR

Hình 5(b) trình bày các mô hình dự đoán hiệu suất loại bỏ chất ô nhiễm trong MBR. Không có đầu vào mô hình nào sử dụng CFI. Thay vào đó, phần lớn mô hình dùng CCI (75,2%), OI (62,5%) và EI (54,2%) làm đặc trưng đầu vào. Chỉ có 20,8% số mô hình đưa MFI vào nhóm đặc trưng đầu vào. Về đầu ra, 79,2% mô hình dự đoán các chỉ số cacbon quan trọng như COD dòng ra và tỷ lệ loại bỏ COD. Các chỉ số nitơ chiếm 58,3%, gồm nồng độ dòng ra và tỷ lệ loại bỏ TN, amoni ($\text{NH}_3\text{-N}$) và nitrat ($\text{NO}_3\text{--N}$). Tỷ lệ thấp hơn (16,7%) tập trung vào dự đoán các chất ô nhiễm hữu cơ dạng vết. Về cấu trúc, tỷ lệ lớn nghiên cứu dùng mô hình ANN, trong đó MLP phổ biến nhất với 66,7%. So với mô hình băm bản màng, mô hình dự đoán loại bỏ chất ô nhiễm thường đơn giản hơn. Ít mô hình loại bỏ chất ô nhiễm sử dụng thuật toán tối ưu hóa hơn.

Những năm gần đây, học máy, một công nghệ trí tuệ nhân tạo, được sử dụng rộng rãi để dự đoán hiệu suất MBR. Từ năm 2015, số lượng bài báo về mô hình học máy trong MBR tăng rõ rệt (Hình S1 trong Phụ lục A). Số lượng công bố này tăng mạnh sau năm 2018. Phân tích thống kê về mô hình, đặc trưng và tối ưu hóa phản ánh toàn diện tiến trình nghiên cứu dự đoán hiệu suất MBR. Trong các bài báo được tổng quan, 34,3% nghiên cứu dự đoán loại bỏ chất ô nhiễm và 67,1% dự đoán bám bản màng.

Nhìn chung, học máy là công cụ phổ biến trong nghiên cứu MBR với hiệu quả tốt. Tuy nhiên, người nghiên cứu cần nhận biết các hạn chế hiện có. Các hạn chế gồm hệ thống chỉ số chưa đầy đủ và thiếu kiểm chứng ở quy mô kỹ thuật thực tế. Bên cạnh đó, việc dự đoán thời gian thực còn khó khăn và mô hình chưa giúp hiểu sâu về bản chất quá trình.




Bám bẩn màng thường bao gồm bám bẩn hữu cơ, vô cơ, sinh học và bám bẩn hỗn hợp. Các hợp chất hữu cơ như polysaccharit, protein và chất mùn tham gia vào nhiều giai đoạn bám bẩn màng. Quá trình này dẫn đến hiện tượng bám bẩn thuận nghịch hoặc bất thuận nghịch (Lin et al., 2014; Xu et al., 2020). Loại bỏ chất ô nhiễm trong MBR kết hợp giữa các quá trình sinh học và quá trình lưu giữ của màng. Do đó, sự hình thành bám bẩn màng liên kết chặt chẽ với quá trình loại bỏ chất ô nhiễm. So với việc chỉ xét loại bỏ chất ô nhiễm, bám bẩn màng phức tạp hơn với độ phi tuyến cao giữa các thông số. Độ phức tạp này tạo ra tiềm năng ứng dụng lớn cho các mô hình học máy.

Mô hình mạng nơ-ron nhân tạo (ANN) có khả năng khớp phi tuyến cao. Mô hình cho thấy hiệu suất tốt trong dự đoán bám bẩn màng. Dự đoán bám bẩn màng được phân thành hai nhóm: dự đoán trạng thái lọc và phân tích bám bẩn màng. Trạng thái lọc gồm các thông số như thông lượng, TMP và độ thấm. Phân tích bám bẩn màng gồm dạng bám bẩn, tốc độ phục hồi thông lượng và năng lượng tương tác màng. Bảng 2 tóm tắt các mô hình ANN dùng để dự đoán trạng thái lọc của MBR. Để cải thiện dự đoán, một số nhà nghiên cứu đã cải tiến mô hình MLP. Họ tối ưu thuật toán huấn luyện, thay đổi hàm kích hoạt lớp ẩn và điều chỉnh cấu trúc phân tầng mô hình. Phân tích độ nhạy được dùng để giải thích mô hình hoặc xác định các thông số quan trọng.

Thuật toán di truyền (GA) và logic mờ đã được áp dụng trong các mô hình MLP cải tiến. Levenberg-Marquardt (LM) là thuật toán huấn luyện được sử dụng rộng rãi. Nhiều nghiên cứu cũng dùng quy tắc Bayes, thuật toán hạ độ dốc hoặc thuật toán BFGS để huấn luyện mô hình. Wang và Wu (2015) dự đoán điểm nhảy vọt TMP với MSE tương đối đạt 0,024. Đầu vào gồm lưu lượng, tỷ lệ sục khí, TMP ban đầu, thời gian chạy và nồng độ chất bám bẩn đặc trưng (SMP và EPS). Họ thiết lập mô hình MLP với cấu trúc 6-8-1. Họ tối ưu trọng số và độ chệch bằng thuật toán GA, rồi huấn luyện mô hình bằng quy tắc Bayes. Họ cũng chỉ ra rằng mô hình MLP với kích thước mẫu nhỏ kém ổn định hơn các mô hình toán học truyền thống. Alkimi et al. (2020) thiết lập mô hình MLP cấu trúc 6-6-1. Mô hình được huấn luyện bằng thuật toán BFGS và tối ưu tham số bằng kiểm định chéo (CV). Họ dùng khả năng lọc của bùn, MLVSS, pH, COD đầu vào, nhiệt độ và chu kỳ rửa màng làm đặc trưng đầu vào. Mô hình dự đoán độ thấm màng đạt $R^2 = 0,93$. Các thuật toán tối ưu hóa và huấn luyện giúp cải thiện hiệu quả của mô hình. Đồng thời, ảnh hưởng của kích thước mẫu đến hiệu suất học máy trong xử lý bám bẩn màng vẫn là vấn đề đáng lưu tâm.

Bảng 2 Ví dụ về các mô hình ANN dùng để dự đoán trạng thái lọc màng trong các hệ MBR



3.3.2 Các ứng dụng mô hình khác

Các mô hình như SVM (gồm SVR), LSSVM, RF, limit GBDT và GBDT cũng được ứng dụng để dự đoán bám bẩn màng trong MBR, Bảng S4 trong Phụ lục A trình bày các ví dụ dùng SVM hoặc các mô hình dạng cây để dự đoán bám bẩn màng. Dù chưa được ứng dụng rộng rãi như ANN, các mô hình này vẫn thể hiện khả năng dự đoán tốt trong nhiều kịch bản khác nhau. Hamed et al. (2019) thiết lập mô hình LSSVM nhằm đơn giản hóa việc tối ưu hệ phương trình tuyến tính. Các thông số MLSS, TMP, thông lượng và nhiệt độ được chọn làm biến đầu vào để dự đoán trở lực lọc. Mô hình LSSVM vượt trội hơn mô hình PSO-MLP ($R^2 = 0.96$) và mô hình lập trình biểu thức gen ($R^2 = 0.98$), đạt $R^2 = 0.99$. Li et al. (2020) phát triển mô hình RF gồm 300 cây và 2 biến tại mỗi nút. Qua đánh giá sơ bộ bằng phân tích thành phần chính (PCA), MLSS, TMP và trở lực màng được chọn làm đặc trưng đầu vào để dự đoán thông lượng. Kết quả cho thấy mô hình RF ($R^2 = 0.95$) có hiệu suất cao hơn mô hình SVM ($R^2 = 0.92$) và mô hình MLP ($R^2 = 0.89$). Ví dụ này cho thấy mô hình RF có thể phù hợp hơn mô hình SVM và MLP trong dự đoán bám bẩn màng. Việc sử dụng PCA để chọn đặc trưng cho thấy khả năng tồn tại hiện tượng đa cộng tuyến giữa các yếu tố gây bám bẩn màng. Dù các yếu tố gây bám bẩn màng rất phức tạp, ta có thể chọn một số chỉ số đại diện để giám sát trực tuyến và dự đoán.

4 Ví dụ hướng dẫn

4.1 Phương pháp

Trước hết, cần xác định các biến độc lập (đặc trưng đầu vào) và biến phụ thuộc (đặc trưng đầu ra) từ bộ dữ liệu thô. Trong ví dụ này, TMP được chọn làm đầu ra mục tiêu để mô tả trạng thái bám bẩn. Dựa trên hiểu biết chung và các khảo sát sơ bộ, các yếu tố ảnh hưởng quan trọng được chọn làm đặc trưng đầu vào. Các biến đầu vào gồm nhiệt độ, MLSS, pH, DO vùng hiếu khí, chất lượng nước đầu vào (COD, TN và TP) và thông lượng màng. Hàm “mapminmax” trong MATLAB được dùng để chuẩn hóa dữ liệu đầu vào và đầu ra về khoảng $[0, 1]$. Thao tác này giúp loại bỏ ảnh hưởng bất lợi của dữ liệu dị biệt và tăng tốc độ hội tụ. Sau đó, 70% dữ liệu mẫu được chọn ngẫu nhiên cho tập huấn luyện, 30% còn lại dùng cho tập kiểm tra.

4.1.2 Lựa chọn mô hình và chiến lược

4.1.3 Đánh giá mô hình

4.2 Kết quả và thảo luận

****Bảng 3**** Hiệu suất của các mô hình học máy khác nhau cho ví dụ hướng dẫn

5 Tóm tắt và triển vọng

Lời cảm ơn

Nghiên cứu này nhận tài trợ từ Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc (Mã số 52370059). Nghiên cứu cũng được hỗ trợ bởi Quỹ Khoa học Tự nhiên Bắc Kinh (Mã số JQ22027). Công trình nhận thêm hỗ trợ từ Quỹ Nghiên cứu Cơ bản dành cho các Trường Đại học Trung ương (Mã số E2EG0502X2).

Xung đột lợi ích

Kang Xiao và Xia Huang là thành viên ban biên tập của tạp chí Frontiers of Environmental Science & Engineering. Các tác giả tuyên bố nghiên cứu này không có xung đột lợi ích về mặt thương mại hoặc tài chính.

Tài liệu bổ sung trực tuyến

Danh mục từ viết tắt

Tài liệu tham khảo

Ahmed I, Kajol M, Hasan U, Datta P P, Roy A, Reza M R (2024). ChatGPT versus Bard: a comparative study. Engineering Reports, 6(11): 12890

Aidan A, Abdel-Jabbar N, Ibrahim T H, Nenov V, Mjalli F (2008). Neural network modeling and optimization of scheduling backwash for membrane bioreactor. Clean Technologies and Environmental Policy, 10(4): 389–395

Akaike H (1974). New look at statistical-model identification. IEEE Transactions on Automatic Control, 19(6): 716–723

Aldreess A, Javed M F, Khan M, Siddiq B (2024a). Optimized prediction modeling of micropollutant removal efficiency in forward osmosis membrane systems using explainable machine learning algorithms. Journal of Water Process Engineering, 66: 105937

Alexandridis A K, Zapanis A D (2013). Wavelet neural networks: a practical guide. Neural Networks, 42: 1–27

4.2.2 Hiệu suất mô hình

Tập tham số mô hình được trình bày trong Phần 1 của Phụ lục A. Bảng 3 so sánh kết quả dự đoán của các phương pháp SVM, RF, BPNN, LSTM và GA-BP. Cả năm mô hình đều thể hiện khả năng khớp tốt cho toàn bộ dữ liệu. Các mô hình SVM, BPNN, LSTM và GA-BP hoạt động tương đương trên cả tập huấn luyện và kiểm tra. Ngược lại, RF cho khả năng khớp tốt nhưng khả năng dự đoán khái quát hóa yếu hơn.

Bishop C M (2006). Pattern recognition and machine learning. Springer New York, NY

Breiman L (2001). Random forests. Machine Learning, 45(1): 5–32

Browne M W (2000). Cross-validation methods. Journal of Mathematical Psychology, 44(1): 108–132

Cai Y H, Zaidi A A, Shi Y, Zhang K, Li X, Xiao S H, Lin A Q (2019b). Influence of salinity on the biological treatment of domestic ship sewage using an air-lift multilevel circulation membrane reactor. *Environmental Science and Pollution Research International*, 26(36): 37026–37036

Chen T, Guestrin C (2016). *XGBoost: A Scalable Tree Boosting System*. San Francisco: Association for Computing Machinery, 785–794

Choi J G, Bae T H, Kim J H, Tak T M, Randall A A (2002). The behavior of membrane fouling initiation on the crossflow membrane bioreactor system. *Journal of Membrane Science*, 203(1–2): 103–113

4.1 Method

Chang H M, Xu Y, Chen S S, He Z (2022). Enhanced understanding of osmotic membrane bioreactors through machine learning modeling of water flux and salinity. *Science of the Total Environment*, 838: 156009

de Campos Souza P V (2020). Fuzzy neural networks and neuro-fuzzy networks: a review the main techniques and applications used in the literature. *Applied Soft Computing*, 92: 106275

Geissler S, Wintgens T, Melin T, Vossenkaul K, Kullmann C (2005). Modelling approaches for filtration processes with novel submerged capillary modules in membrane bioreactors for wastewater treatment. *Desalination*, 178(1–3): 125–134

Hamed H, Ehteshami M, Mirbagheri S A, Zendehboudi S (2019). New deterministic tools to systematically investigate fouling occurrence in membrane bioreactors. *Chemical Engineering Research & Design*, 144: 334–353

Goh A T C (1995). Backpropagation neural networks for modeling complex-systems. *Artificial Intelligence in Engineering*, 9(3): 143–151

Grömping U (2015). Variable importance in regression models. *Wiley Interdisciplinary Reviews: Computational Statistics*, 7(2): 137–152

Kiranyaz S, Avci O, Abdeljaber O, Ince T, Gabbouj M, Inman D J (2021). 1D convolutional neural networks and applications: a survey. *Mechanical Systems and Signal Processing*, 151: 107398

Kruskal W (1987). Relative importance by averaging over orderings. *American Statistician*, 41(1): 6–10

6 Conclusions

Kurita T, Kimura K, Watanabe Y (2015). Energy saving in the operation of submerged MBRs by the insertion of baffles and the introduction of granular materials. *Separation and Purification Technology*, 141: 207–213

Li C Q, Yang Z X, Yan H Y, Wang T (2014). The application and research of the GA-BP neural network algorithm in the MBR membrane fouling. *Abstract and Applied Analysis*, 2014(1): 673156

Li G Y, Ji J Y, Ni J L, Wang S R, Guo Y T, Hu Y S, Liu S W, Huang S F, Li Y Y (2022). Application of deep learning for predicting the treatment performance of real municipal wastewater based on one-year operation of two anaerobic membrane bioreactors. *Science of the Total Environment*, 813: 151920

Abbreviations

Abbreviation Description

BFGS Broyden-Fletcher-Goldfarb-Shanno

CV Cross-validation

LM Levenberg-Marquardt

Yaqub M, Asif H, Kim S, Lee W (2020). Modeling of a full-scale sewage treatment plant to predict the nutrient removal efficiency using a long short-term memory (LSTM) neural network. *Journal of Water Process Engineering*, 37: 101388

Yoon S H (2015). *Membrane Bioreactor Processes: Principles and applications*. Boca Raton: Membrane Bioreactor Processes: Principles and Applications

Zadeh L A (2023). *Granular, Fuzzy, And Soft Computing*. Lin T Y, Liao C J, Kacprzyk J, eds. New York: Springer US, 19–49

Zagoruyko S, Komodakis N J A (2016). Wide residual networks. *ArXiv*,

Zhang G J, Ji S L, Gao X, Liu Z Z (2008). Adsorptive fouling of extracellular polymeric substances with polymeric ultrafiltration membranes. *Journal of Membrane Science*, 309(1–2): 28–35

T Temperature

Zhang Q, Yang L T, Chen Z, Li P (2018). A survey on deep learning for big data. *Information Fusion*, 42: 146–157

Zhang Q Y, Singh S, Stuckey D C (2017). Fouling reduction using adsorbents/flocculants in a submerged anaerobic membrane bioreactor. *Bioresource Technology*, 239: 226–235

References

Ghi chú chân trang và thông tin xuất bản:

Yizhe Lai và cs., *Front. Environ. Sci. Eng.* 2025, 19(3): 34
<https://doi.org/10.1007/s11783-025-1954-2>

Trang 26
<https://journal.hep.com.cn/fese> |
<https://link.springer.com/journal/11783>

- Chen C, Sun M Z, Chang J, Liu Z W, Zhu X Z, Xiao K, Song G Q, Wang H, Liu G L, Huang X (2022). Unravelling temperature-dependent fouling mechanism in a pilot-scale anaerobic membrane bioreactor via statistical modelling. *Journal of Membrane Science*, 644: 120145
- Chen J C, Ng W J, Luo R, Mu S, Zhang Z, Andersen M, Jorgensen P E (2012). Membrane bioreactor process modeling and optimization: ULU Pandan water reclamation plant. *Journal of Environmental Engineering*, 138(12): 1218–1226
- Chen T, Guestrin C (2016). XGBoost: A Scalable Tree Boosting System. San Francisco: Association for Computing Machinery, 785–794
- Chen W, Ran H, Cao X, Wang J, Teng D, Chen J, Zheng X (2020). Estimating PM_{2.5} with high-resolution 1-km AOD data and an improved machine learning model over Shenzhen, China. *Science of the Total Environment*, 746: 141093
- Choi J G, Bae T H, Kim J H, Tak T M, Randall A A (2002). The behavior of membrane fouling initiation on the crossflow membrane bioreactor system. *Journal of Membrane Science*, 203(1–2): 103–113
- Cortez P, Embrechts M J (2013). Using sensitivity analysis and visualization techniques to open black box data mining models. *Information Sciences*, 225: 1–17
- de Campos Souza P V (2020). Fuzzy neural networks and neuro-fuzzy networks: a review the main techniques and applications used in the literature. *Applied Soft Computing*, 92: 106275
- Dorigo M, Birattari M, Stützle T (2006). Ant colony optimization. *IEEE Computational Intelligence Magazine*, 1(4): 28–39
- Espel D, Courty S, Auda Y, Sheeren D, Elger A (2020). Submerged macrophyte assessment in rivers: an automatic mapping method using Pleiades imagery. *Water Research*, 186: 116353
- Gao Q, Li Z, Pan J (2019). A convolutional neural network for airport security inspection of dangerous goods. *IOP Conference Series. Earth and Environmental Science*, December 27–29, 2019, Guangzhou, China, 252(4): 042042
- Garson G D (1991). Interpreting neural-network connection weights. *AI Expert*, 6(4): 46–51
- Gedeon T D (1997). Data mining of inputs: analysing magnitude and functional measures. *International Journal of Neural Systems*, 8(2): 209–218
- Geissler S, Wintgens T, Melin T, Vossenkaul K, Kullmann C (2005). Modelling approaches for filtration processes with novel submerged capillary modules in membrane bioreactors for wastewater treatment. *Desalination*, 178(1–3): 125–134
- Gideon S (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2): 461–464
- Goh A T C (1995). Backpropagation neural networks for modeling complex-systems. *Artificial Intelligence in Engineering*, 9(3): 143–151
- Greff K, Srivastava R K, Koutník J, Steunebrink B R, Schmidhuber J (2017). LSTM: a search space odyssey. *IEEE Transactions on Neural Networks and Learning Systems*, 28(10): 2222–2232
- Grömping U (2015). Variable importance in regression models. *Wiley Interdisciplinary Reviews: Computational Statistics*, 7(2): 137–152
- Hamed H, Ehteshami M, Mirbagheri S A, Zendeheboudi S (2019). New deterministic tools to systematically investigate fouling occurrence in membrane bioreactors. *Chemical Engineering Research & Design*, 144: 334–353
- Hannan E J, Quinn B G (1979). The determination of the order of an autoregression. *Journal of the Royal Statistical Society. Series B, Statistical Methodology*, 41(2): 190–195
- Hazrati H, Moghaddam A H, Rostamizadeh M (2017). The influence of hydraulic retention time on cake layer specifications in the membrane bioreactor: experimental and artificial neural network modeling. *Journal of Environmental Chemical Engineering*, 5(3): 3005–3013
- Hosseinzadeh A, Zhou J L, Altaee A, Baziar M, Li X (2020). Modeling water flux in osmotic membrane bioreactor by adaptive network-based fuzzy inference system and artificial neural network. *Bioresource Technology*, 310: 123391
- Huang G, Liu Z, Maaten L V D, Weinberger K Q (2017). Densely connected convolutional networks. Honolulu, HI, USA: IEEE, 2261–2269
- Huang Z, Ong S L, Ng H Y (2011). Submerged anaerobic membrane bioreactor for low-strength wastewater treatment: effect of HRT and SRT on treatment performance and membrane fouling. *Water Research*, 45(2): 705–713
- Irfan M, Waqas S, Arshad U, Khan J A, Legutko S, Kruszelnicka I, Ginter-Kramarczyk D, Rahman S, Skrzypczak A (2022). Response surface methodology and artificial neural network modelling of membrane rotating biological contactors for wastewater treatment. *Materials*, 15(5): 1932
- Jiang M, He Y, Song C, Pan Y, Qiu T, Tian S (2021). Disaggregating climatic and anthropogenic influences on vegetation changes in Beijing-Tianjin-Hebei region of China. *Science of the Total Environment*, 786: 147574
- Juntawang C, Rongsayamanont C, Khan E (2017). Entrapped cells-based-anaerobic membrane bioreactor treating domestic

- wastewater: performances, fouling, and bacterial community structure. *Chemosphere*, 187: 147–155
- Karaboga D, Basturk B (2007). A powerful and efficient algorithm for numerical function optimization: artificial bee colony (ABC) algorithm. *Journal of Global Optimization*, 39(3): 459–471
- Katoch S, Chauhan S S, Kumar V (2021). A review on genetic algorithm: past, present, and future. *Multimedia Tools and Applications*, 80(5): 8091–8126
- Kawakatsu T, Nakao S, Kimura S (1993). Effects of size and compressibility of suspended particles and surface pore-size of membrane on flux in cross-flow filtration. *Journal of Membrane Science*, 81(1–2): 173–190
- Kim J H, Shin J K, Lee H, Lee D H, Kang J H, Cho K H, Lee Y G, Chon K, Baek S S, Park Y (2021a). Improving the performance of machine learning models for early warning of harmful algal blooms using an adaptive synthetic sampling method. *Water Research*, 207: 117821
- Kim S Y, Ćurko J, Gajdoš Kljusurić J, Matošić M, Crnek V, López-Vázquez C M, Garcia H A, Brdjanović D, Valinger D (2021b). Use of near-infrared spectroscopy on predicting wastewater constituents to facilitate the operation of a membrane bioreactor. *Chemosphere*, 272: 129899
- Kiranyaz S, Avci O, Abdeljaber O, Ince T, Gabbouj M, Inman D J (2021). 1D convolutional neural networks and applications: a survey. *Mechanical Systems and Signal Processing*, 151: 107398
- Kruskal W (1987). Relative importance by averaging over orderings. *American Statistician*, 41(1): 6–10
- Krzeminski P, Leverette L, Malamis S, Katsou E (2017). Membrane bioreactors: a review on recent developments in energy reduction, fouling control, novel configurations, LCA and market prospects. *Journal of Membrane Science*, 527: 207–227
- Kulkarni P, Chellam S (2010). Disinfection by-product formation following chlorination of drinking water: artificial neural network models and changes in speciation with treatment. *Science of the Total Environment*, 408(19): 4202–4210
- Kurita T, Kimura K, Watanabe Y (2014). The influence of granular materials on the operation and membrane fouling characteristics of submerged MBRs. *Journal of Membrane Science*, 469: 292–299
- Kurita T, Kimura K, Watanabe Y (2015). Energy saving in the operation of submerged MBRs by the insertion of baffles and the introduction of granular materials. *Separation and Purification Technology*, 141: 207–213
- Li C Q, Yang Z X, Yan H Y, Wang T (2014). The application and research of the GA-BP neural network algorithm in the MBR membrane fouling. *Abstract and Applied Analysis*, 2014(1): 673156
- Li G Y, Ji J Y, Ni J L, Wang S R, Guo Y T, Hu Y S, Liu S W, Huang S F, Li Y Y (2022). Application of deep learning for predicting the treatment performance of real municipal wastewater based on one-year operation of two anaerobic membrane bioreactors. *Science of the Total Environment*, 813: 151920
- Li H M, Wang J H, Wang Q G, Tian C H, Qian X, Leng X Z (2017). Magnetic properties as a proxy for predicting fine-particle-bound heavy metals in a support vector machine approach. *Environmental Science & Technology*, 51(12): 6927–6935
- Li S, Shi Z, Chen S C, Ji W J, Zhou L Q, Yu W, Webster R (2015). *In situ* measurements of organic carbon in soil profiles using vis-NIR spectroscopy on the Qinghai-Tibet Plateau. *Environmental Science & Technology*, 49(8): 4980–4987
- Li W W, Li C Q, Wang T (2020). Application of machine learning algorithms in MBR simulation under big data platform. *Water Practice & Technology*, 15(4): 1238–1247
- Li X A, Wu J, Tai X, Xu J, Wang Y G (2024a). Solving a class of multi-scale elliptic PDEs by Fourier-based mixed physics informed neural networks. *Journal of Computational Physics*, 508: 113012
- Li Y, Fan L, Liu Y, Huang Z, Chen Y, Wang N, Zhang Z (2024b). Fully sparse fusion for 3D object detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(11): 7217–7231
- Lin H J, Zhang M J, Wang F Y, Meng F G, Liao B Q, Hong H C, Chen J R, Gao W J (2014). A critical review of extracellular polymeric substances (EPSs) in membrane bioreactors: characteristics, roles in membrane fouling and control strategies. *Journal of Membrane Science*, 460: 110–125
- Liu C Q, Xiao J W, Li H Y, Chen Q, Sun D Z, Cheng X, Li P S, Dang Y, Smith J A, Holmes D E (2021). High efficiency *in-situ* biogas upgrading in a bioelectrochemical system with low energy input. *Water Research*, 197: 117055
- Liu J, Kang X, Luan X, Gao L, Tian H, Liu X (2020a). Performance and membrane fouling behaviors analysis with SVR-LibSVM model in a submerged anaerobic membrane bioreactor treating low-strength domestic sewage. *Environmental Technology & Innovation*, 19: 100844
- Liu Z, Wang Y, Vaidya S, Ruehle F, Halverson J, Soljacic M, Hou T Y, Tegmark M J A (2024). KAN: Kolmogorov-Arnold Networks. *ArXiv*,
- Liu Z W, Yu J L, Xiao K, Chen C, Ma H, Liang P, Zhang X Y, Huang X (2020b). Quantitative relationships for the impact of gas sparging conditions on membrane fouling in anaerobic membrane bioreactor. *Journal of Cleaner Production*, 276: 123139
- Lundberg S M, Erion G, Chen H, DeGrave A, Prutkin J M, Nair B, Katz R, Himmelfarb J, Bansal N, Lee S I (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1): 56–67
- Ma K, Tang C, Zhang W, Cui B, Ji K, Chen Z, Abraham A (2023). DC-CNN: Dual-channel Convolutional Neural Networks with attention-pooling for fake news detection. *Applied Intelligence*, 53(7): 8354–8369
- Madni H A, Umer M, Ishaq A, Abuzinadah N, Saidani O, Alsubai S, Hamdi M, Ashraf I (2023). Water-quality prediction based on H2O autoML and explainable AI techniques. *Water*, 15(3): 475
- Mallet A, Charnier C, Latrille E, Bendoula R, Roger J M, Steyer J P (2022). Fast and robust NIRS-based characterization of raw

- organic waste: using non-linear methods to handle water effects. *Water Research*, 227: 119308
- McMillan L, Fayaz J, Varga L (2024). Domain-informed variational neural networks and support vector machines based leakage detection framework to augment self-healing in water distribution networks. *Water Research*, 249: 120983
- Meireles M, Aimar P, Sanchez V (1991). Effects of protein fouling on the apparent pore-size distribution of sieving membranes. *Journal of Membrane Science*, 56(1): 13–28
- Meng F G, Zhang S Q, Oh Y, Zhou Z B, Shin H S, Chae S R (2017). Fouling in membrane bioreactors: an updated review. *Water Research*, 114: 151–180
- Mirbagheri S A, Bagheri M, Bagheri Z, Kamarkhani A M (2015a). Evaluation and prediction of membrane fouling in a submerged membrane bioreactor with simultaneous upward and downward aeration using artificial neural network-genetic algorithm. *Process Safety and Environmental Protection*, 96: 111–124
- Mirbagheri S A, Bagheri M, Boudaghpour S, Ehteshami M, Bagheri Z (2015b). Performance evaluation and modeling of a submerged membrane bioreactor treating combined municipal and industrial wastewater using radial basis function artificial neural networks. *Journal of Environmental Health Science & Engineering*, 13(1): 17
- Mirjalili S, Mirjalili S M, Lewis A (2014). Grey Wolf Optimizer. *Advances in Engineering Software*, 69: 46–61
- Mohammadi E, Stokholm-Bjerregaard M, Hansen A A, Nielsen P H, Ortiz-Arroyo D, Durdevic P (2024). Deep learning based simulators for the phosphorus removal process control in wastewater treatment via deep reinforcement learning algorithms. *Engineering Applications of Artificial Intelligence*, 133: 107992
- Molnar C (2019). *Interpretable Machine Learning: a Guide for Making Black Box Models Explainable*. München: Digital Reserch Academy
- Nguyen P C H, Nguyen Y T, Choi J B, Seshadri P K, Udaykumar H S, Baek S S (2023). PARC: physics-aware recurrent convolutional neural networks to assimilate meso scale reactive mechanics of energetic materials. *Science Advances*, 9(17): eadd6868
- Nguyen X C, Ly Q V, Nguyen T T H, Ngo H T T, Hu Y X, Zhang Z H (2022). Potential application of machine learning for exploring adsorption mechanisms of pharmaceuticals onto biochars. *Chemosphere*, 287: 132203
- Niu C, Zhang Z, Cai T, Pan Y, Lu X, Zhen G (2024). Sludge bound-EPS solubilization enhance CH₄ bioconversion and membrane fouling mitigation in electrochemical anaerobic membrane bioreactor: insights from continuous operation and interpretable machine learning algorithms. *Water Research*, 264: 122243
- Niu C X, Li X S, Dai R B, Wang Z W (2022). Artificial intelligence-incorporated membrane fouling prediction for membrane-based processes in the past 20 years: a critical review. *Water Research*, 216: 118299
- Olden J D, Joy M K, Death R G (2004). An accurate comparison of methods for quantifying variable importance in artificial neural networks using simulated data. *Ecological Modelling*, 178(3–4): 389–397
- Oliker N, Ostfeld A (2014). A coupled classification: evolutionary optimization model for contamination event detection in water distribution systems. *Water Research*, 51: 234–245
- Panda S R, Bhandaru N, Mukherjee R, De S (2015). Ultrafiltration of oily waste water: contribution of surface roughness in membrane properties and fouling characteristics of polyacrylonitrile membranes. *Canadian Journal of Chemical Engineering*, 93(11): 2031–2042
- Peter B, Yoav F, Wee Sun L, Robert E S (1998). Boosting the margin: a new explanation for the effectiveness of voting methods. *Annals of Statistics*, 26(5): 1651–1686
- Qian Y G, Zhou W Q, Yan J L, Li W F, Han L J (2015). Comparing machine learning classifiers for object-based land cover classification using very high resolution imagery. *Remote Sensing (Basel)*, 7(1): 153–168
- Qu J H, Dai X H, Hu H Y, Huang X, Chen Z, Li T, Cao Y S, Daigger G T (2022). Emerging trends and prospects for municipal wastewater management in China. *ACS ES&T Engineering*, 2(3): 323–336
- Quinlan J R (1993). *C4.5: Programs for Machine Learning*. San Francisco: Morgan Kaufmann Publishers Inc.
- Raychaudhuri S (2008). Introduction to Monte Carlo simulation, 2008 Winter Simulation Conference, 91–100, December 7–10, 2008, Miami, FL, USA,
- Rouet-Leduc B, Hulbert C (2024). Automatic detection of methane emissions in multispectral satellite imagery using a vision transformer. *Nature Communications*, 15(1): 3801
- Sadeghi I, Aroujalian A, Raisi A, Dabir B, Fathizadeh M (2013). Surface modification of polyethersulfone ultrafiltration membranes by corona air plasma for separation of oil/water emulsions. *Journal of Membrane Science*, 430: 24–36
- Salehin I, Islam M S, Saha P, Noman S M, Tuni A, Hasan M M, Baten M A (2024). AutoML: a systematic review on automated machine learning with neural architecture search. *Journal of Information and Intelligence*, 2(1): 52–81
- Samek W (2020). Learning with explainable trees. *Nature Machine Intelligence*, 2(1): 16–17
- Schmitt F, Banu R, Yeom I T, Do K U (2018). Development of artificial neural networks to predict membrane fouling in an anoxic-aerobic membrane bioreactor treating domestic wastewater. *Biochemical Engineering Journal*, 133: 47–58
- Senthil Kumar D, Arumugam S S, Lordwin Cecil Prabhaker M, Daisy Merina R (2024). Eamlm: Enhanced automated machine learning model for IoT based water quality analysis with real-time dataset. *Automatic Control and Computer Sciences*, 58(1): 66–77
- Shi Y K, Wang Z W, Du X J, Ling G B, Jia W C, Lu Y R (2022). Research on the membrane fouling diagnosis of MBR membrane module based on ECA-CNN. *Journal of Environmental Chemical Engineering*, 10(3): 107649
- Shimizu Y, Rokudai M, Tohya S, Kayawake E, Yazawa T, Tanaka

- H, Eguchi K (1990). Effect of membrane resistance on filtration characteristics for methanogenic waste. *Kagaku Kogaku Ronbunshu*, 16(1): 145–151
- Silver D, Huang A, Maddison C J, Guez A, Sifre L, Van Den Driessche G, Schrittwieser J, Antonoglou I, Panneershelvam V, Lanctot M, et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587): 484–489
- Suman B, Kumar P (2006). A survey of simulated annealing as a tool for single and multiobjective optimization. *Journal of the Operational Research Society*, 57(10): 1143–1160
- Sun X, Wang P, Lu W, Zhu Z, Lu X, He Q, Li J, Rong X, Yang Z, Chang H, et al. (2023). RingMo: a remote sensing foundation model with masked image modeling. *IEEE Transactions on Geoscience and Remote Sensing*, 61: 1–22
- Szegedy C, Ioffe S, Vanhoucke V, Alemi A a J A (2016). Inception-v4, Inception-ResNet and the impact of residual connections on learning. *ArXiv*,
- Szegedy C, Wei L, Yangqing J, Sermanet P, Reed S, Anguelov D, Erhan D, Vanhoucke V, Rabinovich A (2015). Going deeper with convolutions. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 1–9, June 7–12, 2015, Boston, MA, USA
- Taheri E, Amin M M, Fatehizadeh A, Rezakazemi M, Aminabhavi T M (2021). Artificial intelligence modeling to predict transmembrane pressure in anaerobic membrane bioreactor-sequencing batch reactor during biohydrogen production. *Journal of Environmental Management*, 292: 112759
- Tao Y, Li C (2018). Application of PSO-RBF neural network in MBR membrane pollution prediction. 2018 Eighth International Conference on Instrumentation & Measurement, Computer, Communication and Control (IMCCC), 873–877, July 19–21, 2018, Harbin, China
- Tella A, Balogun A L, Adebisi N, Abdullah S (2021). Spatial assessment of PM₁₀ hotspots using random forest, *k*-nearest neighbour and Naive Bayes. *Atmospheric Pollution Research*, 12(10): 101202
- Tu S, Xu L (2012). A theoretical investigation of several model selection criteria for dimensionality reduction. *Pattern Recognition Letters*, 33(9): 1117–1126
- Uddin M G, Nash S, Rahman A, Olbert A I (2023). Performance analysis of the water quality index model for predicting water state using machine learning techniques. *Process Safety and Environmental Protection*, 169: 808–828
- Vasilaki V, Conca V, Frison N, Eusebi A L, Fatone F, Katsou E (2020). A knowledge discovery framework to predict the N₂O emissions in the wastewater sector. *Water Research*, 178: 115799
- Vasu P K A, Gabriel J, Zhu J, Tuzel O, Ranjan A (2023). FastViT: A fast hybrid vision Transformer using structural reparameterization. Paris, France: IEEE, 5762–5772
- Vatanpour V, Madaeni S S, Moradian R, Zinadini S, Astinchap B (2011). Fabrication and characterization of novel antifouling nanofiltration membrane prepared from oxidized multiwalled carbon nanotube/polyethersulfone nanocomposite. *Journal of Membrane Science*, 375(1–2): 284–294
- Viet N D, Im S J, Kim C M, Jang A (2021). An osmotic membrane bioreactor-clarifier system with a deep learning model for simultaneous reduction of salt accumulation and membrane fouling. *Chemosphere*, 272: 129872
- Viet N D, Jang A (2021). Development of artificial intelligence-based models for the prediction of filtration performance and membrane fouling in an osmotic membrane bioreactor. *Journal of Environmental Chemical Engineering*, 9(4): 105337
- Wang H, Zeng J, Dai R, Wang Z (2024a). Understanding rejection mechanisms of trace organic contaminants by polyamide membranes via data-knowledge codriven machine learning. *Environmental Science & Technology*, 58(13): 5878–5888
- Wang X T, Sun X, Wu Y B, Gao F, Yang Y (2024b). Optimizing reverse osmosis desalination from brackish waters: predictive approach employing response surface methodology and artificial neural network models. *Journal of Membrane Science*, 704: 122883
- Wang Z W, Wu X H (2015). Mathematical and artificial neural network models to predict the membrane fouling behavior of an intermittently-aerated membrane bioreactor under sub-critical flux. *Clean*, 43(7): 1002–1009
- Wei S, Kang Y, Peng Z, Xiao X, Wang L, Yang Y, Salim F D J A (2024). STEMO: early spatio-temporal forecasting with multi-objective reinforcement learning. *ArXiv*,
- Wolf G, Almeida J S, Crespo J G, Reis M A M (2003). Monitoring of biofilm reactors using natural fluorescence fingerprints. *Water Science and Technology*, 47(5): 161–167
- Wolf G, Almeida J S, Pinheiro C, Correia V, Rodrigues C, Reis M A M, Crespo J G (2001). Two-dimensional fluorometry coupled with artificial neural networks: a novel method for on-line monitoring of complex biological processes. *Biotechnology and Bioengineering*, 72(3): 297–306
- Woo T, Nam K, Heo S, Lim J Y, Kim S, Yoo C (2022). Predictive maintenance system for membrane replacement time detection using AI-based functional profile monitoring: application to a full-scale MBR plant. *Journal of Membrane Science*, 649: 120400
- Wu J L, Chen F T, Huang X, Geng W Y, Wen X H (2006). Using inorganic coagulants to control membrane fouling in a submerged membrane bioreactor. *Desalination*, 197(1–3): 124–136
- Wu J L, Huang X (2008). Effect of dosing polymeric ferric sulfate on fouling characteristics, mixed liquor properties and performance in a long-term running membrane bioreactor. *Separation and Purification Technology*, 63(1): 45–52
- Wu Q, Ye Y, Liu Y, Ng M K (2012). SNP selection and classification of genome-wide SNP data using stratified sampling random forests. *IEEE Transactions on Nanobioscience*, 11(3): 216–227
- Xiao K, Liang S, Wang X M, Chen C S, Huang X (2019). Current state and challenges of full-scale membrane bioreactor applications: a critical review. *Bioresource Technology*, 271: 473–481

- Xiao K, Xu Y, Liang S, Lei T, Sun J Y, Wen X H, Zhang H X, Chen C S, Huang X (2014). Engineering application of membrane bioreactor for wastewater treatment in China: current state and future prospect. *Frontiers of Environmental Science & Engineering*, 8(6): 805–819
- Xie L, Luo S, Liu Y, Ruan X, Gong K, Ge Q, Li K, Valev V K, Liu G, Zhang L (2023). Automatic identification of individual nanoplastics by Raman spectroscopy based on machine learning. *Environmental Science & Technology*, 57(46): 18203–18214
- Xu H, Xiao K, Wang X M, Liang S, Wei C H, Wen X H, Huang X (2020). Outlining the roles of membrane-foulant and foulant-foulant interactions in organic fouling during microfiltration and ultrafiltration: a mini-review. *Frontiers in Chemistry*, 8: 417
- Xu J, Xu Z, Kuang J, Lin C, Xiao L, Huang X, Zhang Y (2021). An alternative to laboratory testing: random forest-based water quality prediction framework for inland and nearshore water bodies. *Water*, 13(22): 3262
- Xu Y R, Zeng X H, Bernard S, He Z (2022). Data-driven prediction of neutralizer pH and valve position towards precise control of chemical dosage in a wastewater treatment plant. *Journal of Cleaner Production*, 348: 131360
- Yamamoto K, Hiasa M, Mahmood T, Matsuo T (1989). Direct solid-liquid separation using hollow fiber membrane in an activated-sludge aeration tank. *Water Science and Technology*, 21(4–5): 43–54
- Yamato N, Kimura K, Miyoshi T, Watanabe Y (2006). Difference in membrane fouling in membrane bioreactors (MBRs) caused by membrane polymer materials. *Journal of Membrane Science*, 280(1–2): 911–919
- Yang F, Lu W H, Luo L K, Li T (2012). Margin optimization based pruning for random forest. *Neurocomputing*, 94: 54–63
- Yang X S (2009). Firefly algorithms for multimodal optimization. Watanabe O and Zeugmann T, eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 169–178
- Yang X S (2010). Nature inspired cooperative strategies for optimization (NICO 2010). González J R, Pelta D A, Cruz C, Terrazas G, Krasnogor N, eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 65–74
- Yao J Q, Wu Z Y, Liu Y, Zheng X Y, Zhang H B, Dong R J, Qiao W (2022). Predicting membrane fouling in a high solid AnMBR treating OFMSW leachate through a genetic algorithm and the optimization of a BP neural network model. *Journal of Environmental Management*, 307: 114585
- Yaqub M, Asif H, Kim S, Lee W (2020). Modeling of a full-scale sewage treatment plant to predict the nutrient removal efficiency using a long short-term memory (LSTM) neural network. *Journal of Water Process Engineering*, 37: 101388
- Yasmin N S A, Wahab N A, Yusuf Z (2017). Modeling of membrane bioreactor of wastewater treatment using support vector machine. Melaka, MALAYSIA: Springer, Singapore, 485–495
- Yoon S H (2015). *Membrane Bioreactor Processes: Principles and applications*. Boca Raton: Membrane Bioreactor Processes: Principles and Applications
- Yu Z, Ruan J, Xing D (2023). Explainable reinforcement learning via a causal world model. *ArXiv*,
- Zadeh L A (2023). *Granular, Fuzzy, And Soft Computing*. Lin T Y, Liao C J, Kacprzyk J, eds. New York: Springer US, 19–49
- Zagoruyko S, Komodakis N J A (2016). Wide residual networks. *ArXiv*,
- Zeiler M D, Fergus R (2014). Visualizing and understanding convolutional networks. Fleet D, Pajdla T, Schiele B, Tuytelaars T, eds. *Computer Vision – ECCV 2014*. ECCV 2014. Lecture Notes in Computer Science, Cham: Springer, 8689: 818–833
- Zhang B, Mao X, Tang X M, Tang H L, Zhang B, Shen Y, Shi W X (2022). Effect of modified microbial flocculant on membrane fouling alleviation in a hybrid aerobic granular sludge membrane system for wastewater reuse. *Separation and Purification Technology*, 290: 120819
- Zhang G J, Ji S L, Gao X, Liu Z Z (2008). Adsorptive fouling of extracellular polymeric substances with polymeric ultrafiltration membranes. *Journal of Membrane Science*, 309(1–2): 28–35
- Zhang H, Ma Y, Jiang T, Zhang G, Yang F (2012). Influence of activated sludge properties on flux behavior in osmosis membrane bioreactor (OMBR). *Journal of Membrane Science*, 390–391: 270–276
- Zhang Q, Yang L T, Chen Z, Li P (2018). A survey on deep learning for big data. *Information Fusion*, 42: 146–157
- Zhang Q Y, Singh S, Stuckey D C (2017). Fouling reduction using adsorbents/flocculants in a submerged anaerobic membrane bioreactor. *Bioresource Technology*, 239: 226–235
- Zhang X, Long T, Deng S, Chen Q, Chen S, Luo M, Yu R, Zhu X (2023). Machine learning modeling based on microbial community for prediction of natural attenuation in groundwater. *Environmental Science & Technology*, 57(50): 21212–21223
- Zhao B, Chen H, Gao D K, Xu L Z, Zhang Y Y (2020). Cleaning decision model of MBR membrane based on Bandelet neural network optimized by improved Bat algorithm. *Applied Soft Computing*, 91: 106211
- Zhao Z, Lou Y, Chen Y, Lin H, Li R, Yu G (2019). Prediction of interfacial interactions related with membrane fouling in a membrane bioreactor based on radial basis function artificial neural network (ANN). *Bioresource Technology*, 282: 262–268
- Zhong H, Yuan Y, Luo L, Ye J, Chen M, Zhong C (2022). Water quality prediction of MBR based on machine learning: a novel dataset contribution analysis method. *Journal of Water Process Engineering*, 50: 103296
- Zhong S F, Guan X H (2023). Count-based Morgan fingerprint: a more efficient and interpretable molecular representation in developing machine learning-based predictive regression models for water contaminants: activities and properties. *Environmental Science & Technology*, 57(46): 18193–18202
- Zhong S F, Zhang K, Bagheri M, Burken J G, Gu A, Li B K, Ma X M, Marrone B L, Ren Z J, Schrier J, et al. (2021). Machine learning: New ideas and tools in environmental science and engineering. *Environmental Science & Technology*, 55(19):

12741–12754

Zhou M, Li Y (2024). Spatial distribution and source identification of potentially toxic elements in Yellow River Delta soils, China: an interpretable machine-learning approach. *Science of the Total Environment*, 912: 169092

Zhuang L P, Tang B, Bin L Y, Li P, Huang S S, Fu F L (2021).

Performance prediction of an internal-circulation membrane bioreactor based on models comparison and data features analysis. *Biochemical Engineering Journal*, 166: 107850