

2.2.1. Thống kê đặc trưng vận hành

Các đại lượng thống kê mô tả được tính cho tất cả đặc trưng và biến mục tiêu. Các đại lượng này bao gồm giá trị trung bình, trung vị, độ lệch chuẩn (std), giá trị nhỏ nhất và giá trị lớn nhất. Phân tích này cung cấp tổng quan về xu hướng tập trung và độ biến thiên của dữ liệu. Phân tích cũng giúp xác định các điểm dị thường hoặc giá trị ngoại lai tiềm ẩn.

2.2.2. Biểu đồ cặp

Abstract

Để khảo sát mối quan hệ từng cặp giữa các đặc trưng và các thông số mục tiêu, biểu đồ cặp được tạo. Biểu đồ này cho thấy tương quan tuyến tính hoặc phi tuyến tiềm năng, dạng phân cụm và giá trị ngoại lai. Điều này giúp hiểu sâu hơn về tập dữ liệu trước khi phát triển mô hình. Biểu đồ cặp được xây dựng bằng thư viện Seaborn (0.13.2) trong Python (3.13.1). Biểu đồ kết hợp các đường hồi quy để quan sát xu hướng tuyến tính tiềm năng. Khoảng tin cậy cũng được đưa vào để đánh giá độ biến thiên.



<https://doi.org/10.3390/pr13082352>

2.2.3. Biểu đồ phân tán

1. Introduction

(<https://creativecommons.org/licenses/by/4.0/>).

2.2.5. Kiểm tra tính chuẩn


2.3. Tiền xử lý và kỹ thuật đặc trưng

2.3.1. Chuẩn hóa thang đo bền vững

2.3.2. Trung bình độ

Ngoài ra, trung bình động làm giảm ảnh hưởng của các giá trị cực trị, giúp phương pháp đặc biệt hiệu quả đối với các tập dữ liệu có mức độ nhiễu cao. Giá trị sau biến đổi được tính toán như sau (Phương trình (2)).

2.4. Các mô hình



Hồi quy tuyến tính là phương pháp thống kê cơ bản để mô hình hóa mối quan hệ giữa biến phụ thuộc Y và nhiều biến độc lập Xi. Mô hình được biểu diễn như sau (Phương trình (3)):

Hồi quy Lasso (Least Absolute Shrinkage and Selection Operator) bổ sung số hạng chính quy hóa L1 vào mô hình hồi quy tuyến tính. Phương pháp này thực hiện lựa chọn đặc trưng hiệu quả bằng cách phạt độ lớn tuyệt đối của các hệ số hồi quy. Hàm mục tiêu được định nghĩa như sau (Phương trình (4)):

Trong đó, λ là siêu tham số kiểm soát mức độ chính quy hóa. Hồi quy Lasso giúp giảm thiểu quá khớp bằng cách co một số hệ số về 0. Nhờ đó, phương pháp chỉ lựa chọn các đặc trưng phù hợp nhất.

Hồi quy Ridge mở rộng hồi quy tuyến tính bằng cách kết hợp số hạng chính quy hóa L2. Số hạng này phạt các hệ số hồi quy lớn và làm giảm phương sai của mô hình. Hàm mục tiêu được cho bởi (Phương trình (5)).

Hồi quy Ridge đặc biệt hiệu quả khi xử lý vấn đề đa cộng tuyến. Phương pháp này đảm bảo tính ổn định của mô hình và cải thiện khả năng tổng quát hóa.

Hồi quy Elastic Net kết hợp các kỹ thuật chính quy hóa L1 (Lasso) và L2 (Ridge) nhằm tận dụng ưu điểm của cả hai phương pháp. Hàm mục tiêu được thiết lập như sau (Phương trình (6)):

Trong đó, α kiểm soát sự cân bằng giữa các hình phạt L1 và L2, còn λ xác định mức độ chính quy hóa tổng thể. Mô hình này đặc biệt hiệu quả khi xử lý các tập dữ liệu nhiều chiều có các đặc trưng tương quan với nhau.

Mô hình học máy (ML) được sử dụng trong nghiên cứu này tuân theo một quy trình nhiều giai đoạn có hệ thống. Quy trình này bảo đảm cả độ chính xác dự đoán lẫn khả năng diễn giải. Các bước thực hiện chính gồm có:

1. XGBoost

Category boosting (CatBoost) là một thuật toán gradient boosting do Yandex phát triển. Thuật toán được thiết kế để xử lý hiệu quả các đặc trưng phân loại. Cơ chế ordered boosting giúp giảm thiểu độ lệch dự đoán. Hàm mục tiêu được xác định như sau (Phương trình (8)):

2.5. Trí tuệ nhân tạo có thể giải thích

2.4. Models

2.5.1. Độ quan trọng của đặc trưng

2.5.2. Giải thích phụ gia Shapley

Giải thích phụ gia Shapley (SHAP) là một kỹ thuật XAI dựa trên lý thuyết trò chơi. Kỹ thuật này được thiết kế để phân bổ công bằng mức đóng góp giữa các đặc trưng trong một mô hình dự đoán. Các giá trị SHAP định lượng mức đóng góp biên của từng đặc trưng vào kết quả đầu ra của mô hình. Giá trị này tính mức chênh lệch dự đoán khi đưa vào hoặc loại bỏ một đặc trưng khỏi mọi tập con đặc trưng.

Giá trị Shapley ϕ_i cho đặc trưng i được tính theo Phương trình (9) như sau:

Trong đó, ϕ_i biểu thị giá trị Shapley cho đặc trưng i . Giá trị này định lượng mức đóng góp trung bình của đặc trưng vào các dự đoán của mô hình. N ký hiệu tập hợp tất cả các đặc trưng. Trong khi đó, S là tập hợp con các đặc trưng không bao gồm đặc trưng i . Hàm $f(S)$ biểu diễn dự đoán của mô hình khi chỉ sử dụng tập hợp con đặc trưng S . Các số hạng giai thừa tính đến mọi tổ hợp tập con, giúp phân bổ công bằng mức đóng góp giữa các đặc trưng.

Bảng 2. Tóm tắt thống kê mô tả cho các thông số quy trình MBR.

Mức pH duy trì ổn định với giá trị trung bình 8.11 và độ lệch chuẩn 0.39, thể hiện mức độ dao động rất nhỏ. Các giá trị pH ghi nhận dao động từ 5.02 đến 8.97. Các phân vị thứ 25, 50 (trung vị) và 75 lần lượt đạt mức 7.85, 7.98 và 8.45. Các kết quả này xác nhận hệ thống duy trì môi trường pH được kiểm soát tốt. Điều này đóng vai trò thiết yếu đối với hoạt tính vi sinh vật và độ ổn định của màng.

Tỷ lệ F/M có độ biến thiên tương đối thấp, với giá trị trung bình 0.012 kgCOD/(kgMLSS·d) và độ lệch chuẩn 0.004 kgCOD/(kgMLSS·d). Các giá trị dao động từ 0.003 kgCOD/(kgMLSS·d) đến 0.024 kgCOD/(kgMLSS·d). Các phân vị thứ 25, 50 (trung vị) và 75 lần lượt là 0.009 kgCOD/(kgMLSS·d), 0.011 kgCOD/(kgMLSS·d) và 0.014 kgCOD/(kgMLSS·d). Điều này cho thấy điều kiện tải trọng hữu cơ duy trì khá ổn định trong suốt thời gian nghiên cứu. Nhờ đó, phản ứng của vi sinh vật trong hệ thống luôn giữ được sự nhất quán.

Tương tự, thông lượng đại diện cho tốc độ lọc, có giá trị trung bình 2.65 LMH (tức L/m²·h) và độ lệch chuẩn 0.52 LMH. Các giá trị này dao động trong khoảng từ 0.60 LMH đến 3.87 LMH. Các giá trị tứ phân vị lần lượt là 2.45 LMH, 2.73 LMH và 2.92 LMH. Kết quả này cho thấy hiệu suất lọc có mức độ biến thiên vừa phải.

Phân tích thống kê mô tả làm rõ độ biến thiên của các thông số vận hành chính trong quy trình MBR. Phân tích này cho phép đánh giá ban đầu về tác động tiềm tàng của chúng đối với sự nghẽn màng và hiệu suất lọc. Các phát hiện này tạo nền tảng cho phân tích tương quan tiếp theo và xây dựng mô hình dự đoán. Mục tiêu là xác định các yếu tố chính dẫn đến sự nghẽn màng. Hơn nữa, kết quả này định hướng xây dựng các chiến lược tối ưu hóa để kiểm soát quá trình và cải tiến vận hành. Việc này góp phần nâng cao hiệu suất tổng thể và tính bền vững của hệ thống.

3.1.2. Phân tích
biểu đồ cặp

Kết quả chỉ ra một số xu hướng đáng chú ý, trong đó mỗi tương quan âm xuất hiện giữa TMP và nồng độ DO. Điều này cho thấy lượng oxy dồi dào hơn đi liền với giá trị TMP thấp hơn. Xu hướng này có thể do vai trò của sức khí trong việc giảm tích tụ màng sinh học và giảm sự nghẽn màng. Ngược lại, TMP có tương quan dương yếu với MLSS, cho thấy nồng độ MLSS tăng cao có thể góp phần làm tăng TMP. Hiện tượng này có thể do nồng độ chất rắn lơ lửng cao hơn làm tăng cường sự nghẽn màng. Mỗi quan hệ âm mạnh giữa TMP và Spec. Flux khẳng định rằng khi sự nghẽn màng tiến triển, TMP tăng và hiệu suất lọc giảm.

Hình 2. Biểu đồ cặp của các thông số vận hành và thông số mục tiêu trong hệ thống MBR.

Phân tích sâu hơn về sự phụ thuộc lẫn nhau giữa các đặc trưng làm nổi bật tương quan dương mạnh giữa MLSS và SVI. Kết quả này phù hợp với kỳ vọng, vì MLSS tăng thường dẫn đến khả năng lắng của bùn cao hơn. Bên cạnh đó, mối liên hệ dương yếu giữa DO và pH được phát hiện. Điều này ngụ ý rằng các biến động pH có thể chịu ảnh hưởng từ mức độ sục khí và hoạt tính vi sinh vật. Mối quan hệ giữa hiệu suất khử COD và thông lượng cho thấy hiệu suất khử chất hữu cơ cao hơn giúp nâng cao hiệu suất màng. Hiện tượng này có khả năng bắt nguồn từ việc giảm sự nghẽn màng hữu cơ.

Những phát hiện sơ bộ này nhấn mạnh các tương tác phức tạp giữa thông số vận hành và động học sự nghẽn màng. Điều này đòi hỏi phải tiến hành thêm các phân tích tương quan định lượng (ví dụ: tương quan Pearson).

3.1.3. Phân tích tương quan Pearson

Bảng 3. Hệ số tương quan Pearson giữa các thông số vận hành và thông số mục tiêu trong hệ thống MBR.

1. XGBoost

Các dạng tương quan quan sát được cung cấp hiểu biết nền tảng về các thông số then chốt. Những thông số này ảnh hưởng đến sự nghẽn màng và hiệu suất lọc trong hệ thống MBR. Tương quan mạnh giữa TMP, Spec. Flux và các thông số vận hành then chốt nhấn mạnh tầm quan trọng của phân tích đa biến trong mô hình hóa dự đoán. Các phát hiện này nhấn mạnh sự cần thiết phải kết hợp nhiều yếu tố tương tác vào các mô hình dự đoán sự nghẽn màng. Cách tiếp cận này giúp nâng cao độ chính xác dự báo và định hướng các chiến lược vận hành.

2. CatBoost

3.1.4. Áp dụng kiểm tra tính chuẩn

Kết quả kiểm tra tính chuẩn nhấn mạnh tầm quan trọng của việc kết hợp các phương pháp xử lý phù hợp. Cần tích hợp các phép biến đổi đặc trưng và kỹ thuật tiền xử lý khi phát triển các mô hình dự đoán.

3.2.1. Ứng dụng chuẩn hóa thang đo bền vững

Hình 4. So sánh phân phối đặc trưng trước (a) và sau (b) khi chuẩn hóa thang đo bền vững.

Sau khi chuẩn hóa thang đo bền vững (Hình 4b), mọi đặc trưng được chuyển về cùng thang đo với trung vị quanh mức không. Phân phối của từng biến trở nên dễ so sánh hơn, ngăn các đặc trưng vượt trội làm sai lệch dự đoán của mô hình. Ngoài ra, các giá trị ngoại lai vẫn hiển thị nhưng tác động của chúng đã giảm đáng kể. Điều này đảm bảo phương pháp xây dựng mô hình ổn định hơn và có khả năng tổng quát hóa tốt hơn.

3.2.2. Ứng dụng trung bình động

3.3. Đánh giá hiệu suất mô hình

3. Results

Để đánh giá độ chính xác dự đoán của các mô hình khác nhau đối với TMP và thông lượng riêng, nhiều mô hình học máy và mô hình thống kê đã được huấn luyện và đánh giá trên bốn trường hợp khác nhau.

3.3.1. Hiệu suất mô hình dựa trên dữ liệu thô

Bảng 4. Hiệu suất mô hình (Trường hợp I: F/M, SV30, SVI, MLSS, DO, pH, Temp. → TMP).


Mô hình	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.3439	4.9834	0.1008	35.6655	5.9721
Ridge	0.3168	5.1590	0.1037	37.1352	6.0939
Lasso	0.3396	5.0665	0.1021	35.8953	5.9913
ElasticNet	0.3292	5.1052	0.1028	36.4606	6.0383
XGBoost	0.6769	3.0784	0.0602	17.5643	4.1910
CatBoost	0.7088	2.9686	0.0591	15.8281	3.9785

Ở Trường hợp II (Bảng 5, dự đoán TMP có COD RM), việc bổ sung COD RM cải thiện nhẹ hiệu suất mô hình. CatBoost ($R^2 = 0.7059$) và XGBoost ($R^2 = 0.6922$) tiếp tục là những mô hình hoạt động tốt nhất. Tuy nhiên, sự cải thiện RMSE không đáng kể (từ 3.9785 lên 3.9980). Điều này chỉ ra rằng COD RM đóng góp vào dự đoán TMP nhưng không nâng cao mạnh độ chính xác tổng thể.

Bảng 5. Hiệu suất mô hình (Trường hợp II: F/M, SV30, SVI, MLSS, DO, pH, Temp., COD RM → TMP).

Mô hình	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.3439	4.9834	0.1008	35.6655	5.9721
Ridge	0.3457	5.0564	0.1016	35.5654	5.9637
Lasso	0.3769	4.9247	0.0992	33.8710	5.8199
ElasticNet	0.3563	5.0050	0.1007	34.9865	5.9149
XGBoost	0.6922	3.1245	0.0610	16.7314	4.0904
CatBoost	0.7059	3.1014	0.0626	15.9842	3.9980

Bảng 6. Hiệu suất mô hình (Trường hợp III: F/M, SV30, SVI, MLSS, DO, pH, Temp. → Spec. Flux).



Bảng 7. Hiệu suất mô hình (Trường hợp IV: F/M, SV30, SVI, MLSS, DO, pH, Temp., COD RM → Spec. Flux).


Nhìn chung, các mô hình gradient boosting (XGBoost và CatBoost) liên tục vượt trội hơn các mô hình thống kê truyền thống. Trong đó, CatBoost là mô hình đạt hiệu suất cao nhất trong tất cả các trường hợp. Việc đưa vào COD RM đã nâng cao độ chính xác dự đoán, đặc biệt đối với Spec. Flux. Kết quả này làm nổi bật vai trò quan trọng của COD RM trong động học của sự nghiền màng. Các kết quả này khẳng định tính hiệu quả của khung dự đoán được đề xuất. Khung phương pháp tích hợp kỹ thuật đặc trưng nâng cao và trí tuệ nhân tạo có thể giải thích. Hệ thống nắm bắt tốt các cơ chế nghiền màng phức tạp. Hệ thống cũng ưu tiên các thông số vận hành then chốt để dự đoán Spec. Flux trong MBR quy mô thực tế.

Bảng 8. Hiệu suất mô hình cho Trường hợp IV với chuẩn hóa thang đo bền vững.

Bảng 9. Hiệu suất mô hình cho Trường hợp IV với chuẩn hóa thang đo bền vững và trung bình động (5 ngày).


Mô hình	R-Squared	MAE	MAPE	MSE	RMSE
Tuyến tính	0.6623	0.0065	0.1445	0.0001	0.0078
Ridge	0.6617	0.0065	0.1460	0.0001	0.0078
Lasso	-0.0048	0.0112	0.2392	0.0002	0.0134
ElasticNet	0.3145	0.0093	0.2022	0.0001	0.0110
XGBoost	0.7404	0.0055	0.1168	0.0000	0.0068
CatBoost	0.8374	0.0042	0.0863	0.0000	0.0054

3.4. Hiệu suất dự đoán cuối cùng



Hình 5. So sánh giá trị thực tế (đường liền màu xanh dương) và giá trị dự đoán (đường nét đứt màu đỏ) của Spec. Flux.

3.5. Trí tuệ nhân tạo có thể giải thích (XAI) để dự đoán sự nghiền màng



	Đặc trưng	Tích hợp (%)	Hoán vị (%)	SHAP (%)
---	---	---	---	---
F/M	12.05	16.19	13.23	
SV30	2.55	1.39	3.21	
SVI	3.40	2.16	2.83	
MLSS	9.22	12.18	10.03695	
DO	4.26	0.82	7.06	
pH	3.92	2.06	2.96	
Temp.	5.18	3.70	6.19	
COD RM	6.79	1.64	4.16	
F/M_MA5	22.65	33.70	26.17	
SV30_MA5	5.30	3.28	3.04	
SVI_MA5	4.47	1.25	2.54	
MLSS_MA5	3.56	2.37	3.05	
DO_MA5	2.93	1.51	3.38	
pH_MA5	9.16	11.03	7.19	
Temp._MA5	4.55	6.71	4.95	

Hình 7. Biểu đồ tóm tắt SHAP minh họa tác động của từng giá trị đặc trưng, với dải màu thể hiện độ lớn của đặc trưng.

Các giá trị độ quan trọng của đặc trưng thu được từ mô hình CatBoost (Bảng 10) cho thấy F/M_MA5 (trung bình động nam ngày của tỷ lệ F/M) có mức đóng góp cao nhất trên cả ba thước đo độ quan trọng, với 22.65% (tích hợp), 33.70% (hoán vị) và 26.17% (SHAP). Điều này xác nhận rằng các biến động ngắn hạn của tỷ lệ F/M đóng vai trò quan trọng trong hành vi của sự nghẽn màng. Tương tự, F/M, MLSS và pH_MA5 cũng được xác định là các yếu tố dự đoán then chốt. Kết quả này cho thấy cả điều kiện vận hành và các đặc trưng dựa trên trung bình động đều tác động đáng kể đến hiệu suất màng.

3.5.2. Phân tích SHAP

Ngoài ra, giá trị SHAP của pH_MA5 và nhiệt độ cho thấy pH thấp hơn thường làm tăng nguy cơ nghẽn màng. Kết quả này phù hợp với nghiên cứu trước đây về hoạt tính vi sinh vật và sự hình thành màng sinh học [7]. Phân tích XAI xác thực định lượng vai trò chi phối của tỷ lệ F/M và MLSS (đóng góp > 25% vào dự đoán). Kết quả này củng cố các mô hình cơ chế trong nghiên cứu trước [1]. Các mô hình đó xác định những thông số này là động lực chính của độ nhớt bùn và sự hình thành lớp bánh bùn. Tương tự, nhiệt độ cao hơn tương quan với độ ổn định thông lượng tăng lên. Điều này cho thấy điều kiện nhiệt độ ảnh hưởng đến hiệu suất lọc.

Những kết quả này khẳng định rằng CatBoost khi kết hợp với các phương pháp luận XAI mang lại một phương pháp tiếp cận đáng tin cậy và có thể giải thích để dự đoán sự nghẽn màng trong các hệ thống MBR. Bằng cách tận dụng các hiểu biết sâu sắc từ độ quan trọng của đặc trưng, người vận hành có thể tinh chỉnh các chiến lược vận hành, ưu tiên triển khai cải biến và nâng cao tính bền vững của quá trình xử lý nước thải bằng màng.

4. Kết luận

Tài liệu tham khảo

Processes 2025, 13, 2352
26 trên 26

Tuyên bố từ chối trách nhiệm/Ghi chú của nhà xuất bản: Các tuyên bố, ý kiến và dữ liệu trong tất cả các ấn phẩm chỉ thuộc về cá nhân tác giả và người đồng góp. Các nội dung này không đại diện cho MDPI hoặc các biên tập viên. MDPI và các biên tập viên từ chối trách nhiệm đối với thương tổn cho người hoặc thiệt hại tài sản phát sinh từ các ý tưởng, phương pháp, hướng dẫn hoặc sản phẩm trong tài liệu.

Overall, gradient-boosting models (XGBoost and CatBoost) consistently outperformed traditional statistical models, with CatBoost emerging as the best-performing model in all cases. The inclusion of COD RM improved prediction accuracy, particularly for Spec. Flux, highlighting its relevance in membrane fouling dynamics. These results highlight the effectiveness of the proposed predictive framework, which integrates advanced feature engineering and explainable AI, in capturing complex fouling mechanisms and prioritizing key operational parameters for the prediction of Spec. Flux in full-scale MBRs.

3.3.2. Enhanced Model Performance with Robust Scaling and Moving Average

To further refine the predictive accuracy of the models, robust scaling and moving average were applied to the dataset in Case IV (F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM → Spec. Flux). The impact of these preprocessing methods on model performance is summarized in Tables 8 and 9.

Table 8. Model performance for Case IV with robust scaling.

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6344	0.0066	0.1477	0.0001	0.0081
Ridge	0.6356	0.0066	0.1478	0.0001	0.0081
Lasso	−0.0048	0.0112	0.2392	0.0002	0.0134
ElasticNet	0.2953	0.0095	0.2077	0.0001	0.0112
XGBoost	0.6555	0.0059	0.1304	0.0001	0.0078
CatBoost	0.7969	0.0050	0.1074	0.0000	0.0060

Table 9. Model performance for Case IV with robust scaling and moving average (5 days).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6623	0.0065	0.1445	0.0001	0.0078
Ridge	0.6617	0.0065	0.1460	0.0001	0.0078
Lasso	−0.0048	0.0112	0.2392	0.0002	0.0134
ElasticNet	0.3145	0.0093	0.2022	0.0001	0.0110
XGBoost	0.7404	0.0055	0.1168	0.0000	0.0068
CatBoost	0.8374	0.0042	0.0863	0.0000	0.0054

Robust scaling was first applied to mitigate the influence of extreme values and improve model stability (Table 8). This transformation led to noticeable performance improvements, particularly for gradient-boosting models such as CatBoost and XGBoost. CatBoost exhibited the best predictive performance, achieving an R^2 value of 0.7969 and the lowest RMSE of 0.0060, demonstrating strong generalization capabilities. XGBoost also benefited from scaling, with an R^2 value of 0.6555, although it remained less accurate than CatBoost. Linear and Ridge regression models showed moderate improvements, with R^2 values around 0.63, whereas ElasticNet and Lasso regression continued to perform poorly, especially when dealing with complex relationships.

Recognizing that membrane fouling progresses cumulatively over time, a 5-day moving average was introduced to incorporate temporal dependencies into the predictive models (Table 9). As described in Section 3.2.2, the 5-day window was selected as optimal by systematically evaluating different day-shifting periods for each input feature within a one-week span and comparing model performance (R^2 and RMSE); the configuration yielding the best predictive accuracy was then applied for subsequent analysis. This adjustment led to further refinements in model performance. CatBoost improved further, reaching an R^2 value of 0.8374 and a reduced RMSE of 0.0054, highlighting the effectiveness of incorporating historical trends. This supports the findings of the previous study [12], which emphasized the cumulative impact of operational conditions on fouling. While prior statistical models struggled with temporal dependencies [14], the moving average approach in this study explicitly addresses time-delayed fouling dynamics, resulting in a >10% R^2 improvement over raw data models. XGBoost also demonstrated a significant increase in accuracy, with an R^2 value of 0.7404, benefiting from the smoothing effect of the moving average. Linear and Ridge regression models also showed slight but consistent improvements, with R^2 values around 0.66, suggesting that the moving average contributed to more stable feature representation even in simpler models.

The results confirm that applying robust scaling improved model performance by reducing the impact of extreme values, particularly for non-linear machine learning models. Additionally, incorporating a moving average further enhanced predictive accuracy, effectively capturing the time-dependent nature of membrane fouling. Because all models were evaluated on the same real-world time-series dataset from a single full-scale MBR, statistical tests such as *t*-tests or confidence intervals—which require independent repeated

samples—are not applicable in this context. Therefore, model comparison in this study emphasizes consistent performance and interpretability under actual operational conditions, rather than statistical significance based on repeated random sampling. CatBoost consistently outperformed all other models, confirming its robustness in handling complex non-linear relationships in MBR systems. XGBoost also benefited significantly from these refinements, reinforcing the importance of feature engineering in fouling prediction.

3.4. Final Prediction Performance

To evaluate the final predictive capability of the developed model, CatBoost was applied to Case IV with robust scaling and moving average (5 days). The dataset was split chronologically, with the first 80% of records used for training and the remaining 20% for testing, to preserve temporal dependencies. The time-series plot in Figure 5 presents the actual and predicted values for Spec. Flux in the test dataset, illustrating the ability of the model to capture temporal variations in membrane fouling. In accordance with standard time-series modeling practices, the dataset was divided chronologically, with the first 80% (155 records) used as training data and the last 20% (39 records) as test data. For visualization, instead of displaying individual points for the training and test sets, predicted data points were connected with dashed lines. This approach was selected because the relatively small number of data points would make point-based plots less effective at conveying overall trends. Using dashed lines allows for a clearer comparison of the trends and characteristics between the training and test sets, providing a more intuitive assessment of model performance across the entire period. The time-series visualization highlights the strong predictive performance of the model, as the predicted values (dashed red line) closely follow the actual values (solid blue line).




Figure 5. Comparison of actual (solid blue line) and predicted (dashed red line) Spec. Flux.

The performance metrics indicate that CatBoost achieved an R^2 score of 0.7712, with a low RMSE of 0.0064 and a minimal MAE of 0.0054. These metrics are calculated exclusively on the test set (20% of the data), providing an unbiased assessment of model performance on unseen data. Additionally, the mean absolute percentage error (MAPE) was only 0.11%, demonstrating the high accuracy of the model in predicting Spec. Flux. These results confirm that CatBoost effectively captures the complex non-linear dependencies between operational parameters and membrane fouling behavior. Although the dataset comprises 194 daily records, the application of advanced feature engineering (e.g., moving averages) and robust models (e.g., CatBoost) enabled effective prediction. Larger datasets would

further enhance model generalizability, and future work should validate the framework with extended datasets.

The model successfully tracks fluctuations in Spec. Flux, especially during peak variations, indicating its ability to generalize well under dynamic operational conditions. However, minor deviations are observed in certain regions, particularly during rapid fluctuations, suggesting that additional temporal dependencies or lagged features could further refine the model. While the dataset does not include severe fouling or cleaning events, it reflects typical operational variability and moderate fouling progression encountered in stable full-scale MBR operations. Should future datasets include more diverse event data, the proposed framework can readily incorporate these to further enhance its generalizability and event prediction capabilities.

3.5. Explainable AI (XAI) for Membrane Fouling Prediction

To enhance the interpretability of the machine learning model and understand the contribution of individual features to membrane fouling prediction, XAI techniques were applied. Specifically, feature importance was assessed using built-in feature importance, permutation importance, and SHAP values, as summarized in Table 10. Additionally, Figures 6 and 7 provide visual representations of feature importance from different perspectives, allowing for a more comprehensive analysis.

Table 10. Feature importance comparison using built-in, permutation, and SHAP values.

Feature	Built-In (%)	Permutation (%)	SHAP (%)
F/M	12.05	16.19	13.23
SV30	2.55	1.39	3.21
SVI	3.40	2.16	2.83
MLSS	9.22	12.18	10.03695
DO	4.26	0.82	7.06
pH	3.92	2.06	2.96
Temp.	5.18	3.70	6.19
COD RM	6.79	1.64	4.16
F/M_MA5	22.65	33.70	26.17
SV30_MA5	5.30	3.28	3.04
SVI_MA5	4.47	1.25	2.54
MLSS_MA5	3.56	2.37	3.05
DO_MA5	2.93	1.51	3.38
pH_MA5	9.16	11.03	7.19
Temp._MA5	4.55	6.71	4.95




Figure 6. Comparison of built-in and permutation feature importance.




Figure 7. SHAP summary plot illustrating the impact of individual feature values, with color gradients representing feature magnitudes.

3.5.1. Feature Importance Analysis

The feature importance values obtained from the CatBoost model (Table 10) highlight that F/M_MA5 (five-day moving average of F/M ratio) had the highest contribution across all three importance metrics, with 22.65% (built-in), 33.70% (permutation), and 26.17% (SHAP). This confirms that short-term variations in F/M ratio play a crucial role in membrane fouling behavior. Similarly, F/M, MLSSs, and pH_MA5 were also identified as key predictive factors, suggesting that both operational conditions and moving-average-based features significantly impact membrane performance.

The permutation importance method (Figure 6) further emphasizes the dominance of F/M_MA5, showing that removing this feature leads to the most significant drop in model performance. Other notable features include MLSSs, pH_MA5, and Temp., indicating their substantial influence on fouling dynamics.

3.5.2. SHAP Analysis

The SHAP summary plot in Figure 7 provides additional insights into the feature contributions by illustrating how individual feature values influence the model output. Higher F/M_MA5 values (shown in red) positively contributed to predicting membrane fouling severity, while lower values (shown in blue) had the opposite effect. This trend was also observed for F/M and MLSS, reinforcing the importance of biomass concentration and organic loading in fouling progression. The XAI techniques revealed critical insights into fouling mechanisms, identifying F/M ratio and MLSSs as dominant factors, consistent with conventional fouling studies [7,45]. Unlike purely empirical models [40], the framework

proposed in this study provides both high accuracy ($R^2 = 0.8374$) and interpretability, enabling operators to prioritize actionable parameters like F/M control.

Furthermore, the SHAP values for pH_MA5 and temperature reveal that lower pH values tend to increase membrane fouling risk, aligning with the previous study on microbial activity and biofilm formation [7]. Critically, the XAI analysis in this study quantitatively validated F/M ratio and MLSSs as dominant factors (contributing > 25% to predictions), corroborating mechanistic models in the previous study [1] that identified these parameters as primary drivers of sludge viscosity and cake layer formation. Similarly, higher temperatures correlated with increased flux stability, suggesting that thermal conditions impact filtration performance.

3.5.3. Implications for MBR Optimization

The integration of XAI techniques demonstrates that time-dependent features (moving averages) enhance the model's predictive power, particularly for short-term fluctuations in fouling indicators. This suggests that incorporating temporal dependencies in real-time monitoring systems could improve predictive accuracy and operational decision making. Additionally, the identification of F/M_MA5 and MLSSs as key variables indicates that process control strategies should focus on optimizing these parameters to mitigate membrane fouling risk. The CatBoost model was identified as the most suitable approach for AI-based analysis of membrane fouling factors and the prediction of specific flux in this study. Its predictive performance was further enhanced when combined with advanced techniques such as robust scaling and moving averages. These methods are expected to enable the application of the CatBoost model across a wide range of MBR scenarios. Furthermore, the incorporation of such preprocessing and feature engineering techniques is expected to improve the performance of other AI-based analysis and predictive models as well. Therefore, as demonstrated in this study, the universality and scalability of analysis and predictive models for MBR fouling can be significantly improved by applying appropriate feature engineering, robust scaling, and moving average methods tailored to the characteristics of real-world field data.

These results confirm that CatBoost, combined with XAI methodologies, provides a reliable and interpretable approach for membrane fouling prediction in MBR systems. By leveraging feature importance insights, practitioners can refine operational strategies, prioritize sensor deployments, and enhance the sustainability of membrane-based wastewater treatment.

4. Conclusions

This study presents a predictive framework for membrane fouling in full-scale MBR systems by integrating AI-driven feature engineering and explainable AI (XAI). The developed predictive framework is intended for direct application in real MBR plants. By utilizing parameters routinely measured in operational settings and incorporating robust interpretable AI models, the framework supports proactive fouling management and operational decision making. By refining the target parameter to specific flux (Flux/TMP) and incorporating COD removal efficiency as a biological performance indicator, the model captures the dynamic interplay between operational parameters and fouling behavior. The application of moving average techniques further enhanced temporal feature representation, addressing the cumulative effects of fouling progression. Among tested models, CatBoost demonstrated superior predictive accuracy, outperforming traditional statistical and machine learning approaches.

XAI techniques revealed critical insights into fouling mechanisms, identifying F/M ratio and MLSSs as dominant factors influencing fouling dynamics. These findings un-

underscore the importance of real-time monitoring and adaptive control strategies, such as optimizing organic loading and biomass concentration, to mitigate fouling risks. While the proposed framework is not intended to replace physics-based control models, its predictive capability and interpretability provide critical decision support inputs for optimizing maintenance schedules and informing adaptive control strategies in full-scale MBR operations. The framework's validation using real-world data from an operational MBR highlights its practical applicability under non-ideal conditions. The framework synergizes with physics-based models (e.g., biofilm dynamics simulations) by providing data-driven refinements to fouling predictions, while its compatibility with low-cost sensors bridges gaps in traditional monitoring tools. This integration enables adaptive control strategies that dynamically adjust operational parameters (e.g., aeration intensity, sludge retention) based on real-time fouling risk assessment. However, the relatively small dataset limits the generalizability of the model. Future studies should validate the framework using larger and more diverse datasets to enhance robustness and applicability across different MBR configurations.

This work demonstrates that prediction and interpretation of fouling behavior is achievable even under suboptimal data conditions, providing a critical bridge between academic research and industrial practice. In addition, this work bridges the gap between complex AI models and operational interpretability, offering a robust tool for proactive membrane management. Future research should prioritize the integration of these AI-based models with sensor networks and adaptive control systems, thereby enabling the dynamic optimization of operational parameters such as aeration, sludge retention, and filtration protocols in real time. Such efforts are expected to enhance the overall efficiency of MBR processes, reduce energy consumption, and contribute to the extension of membrane lifespan. The methodology's adaptability also holds promise for broader applications in membrane-based processes, including desalination and industrial wastewater treatment, fostering sustainable advancements in water resource management. The core principles of this framework—dynamic target parameters (e.g., specific flux), temporal feature engineering, and XAI interpretability—are transferable to other membrane processes like reverse osmosis (RO). For instance, RO fouling is similarly time-dependent and influenced by operational fluctuations (e.g., pressure, flux variations). Adaptations would require domain-specific adjustments (e.g., incorporating scaling indices for mineral fouling), but the methodology's foundation in handling noisy real-world data and capturing cumulative effects remains broadly applicable across membrane technologies. Future work will focus on integrating the model with online monitoring systems for real-time prediction and adaptive control in full-scale facilities.

Author Contributions: Conceptualization, J.L. and S.L.; methodology, J.P., S.-G.P. and J.-Y.K.; experiments, J.L. and J.-Y.K.; software, S.L. and J.P.; formal analysis, J.L., Y.G., J.P., S.-G.P. and J.-Y.K. data curation, J.L. Ren, X., Y.G. and J.P.; visualization, J.P. and S.L.; writing—original draft preparation, J.L. and S.L.; writing—review and editing, S.L., X.R. and M.-H.H.; supervision, X.R. and M.-H.H.; project administration, X.R. and M.-H.H.; funding acquisition, X.R. and M.-H.H. All authors have read and agreed to the published version of the manuscript.

Funding: This work was supported by the Korea Agency for Infrastructure Technology Advancement (KAIA) grant funded by the Ministry of Land, Infrastructure and Transport (Grant RS-2022-00144137).

Data Availability Statement: The original contributions presented in this study are included in the article. Further inquiries can be directed to the corresponding author.

Conflicts of Interest: All authors declare that the research was conducted in the absence of any commercial or financial relationships that could be construed as potential conflicts of interest.

References

- Meng, F.; Chae, S.-R.; Drews, A.; Kraume, M.; Shin, H.-S.; Yang, F. Recent advances in membrane bioreactors (MBRs): Membrane fouling and membrane material. *Water Res.* **2009**, *43*, 1489–1512. [\[CrossRef\]](#)
- Shi, Y.; Wang, Z.; Du, X.; Gong, B.; Jegatheesan, V.; Haq, I.U. Recent advances in the prediction of fouling in membrane bioreactors. *Membranes* **2021**, *11*, 381. [\[CrossRef\]](#) [\[PubMed\]](#)
- Rahman, T.U.; Roy, H.; Islam, M.R.; Tahmid, M.; Fariha, A.; Mazumder, A.; Tasnim, N.; Pervez, M.N.; Cai, Y.; Naddeo, V. The advancement in membrane bioreactor (MBR) technology toward sustainable industrial wastewater management. *Membranes* **2023**, *13*, 181. [\[CrossRef\]](#) [\[PubMed\]](#)
- Burman, I.; Sinha, A. A review on membrane fouling in membrane bioreactors: Control and mitigation. In *Environmental Contaminants: Measurement, Modelling and Control*; Springer: Singapore, 2018; pp. 281–315. [\[CrossRef\]](#)
- Meng, F.; Zhang, S.; Oh, Y.; Zhou, Z.; Shin, H.-S.; Chae, S.-R. Fouling in membrane bioreactors: An updated review. *Water Res.* **2017**, *114*, 151–180. [\[CrossRef\]](#)
- Kim, M.; Sankararao, B.; Yoo, C. Determination of MBR fouling and chemical cleaning interval using statistical methods applied on dynamic index data. *J. Membr. Sci.* **2011**, *375*, 345–353. [\[CrossRef\]](#)
- Iorhemen, O.T.; Hamza, R.A.; Tay, J.H. Membrane bioreactor (MBR) technology for wastewater treatment and reclamation: Membrane fouling. *Membranes* **2016**, *6*, 33. [\[CrossRef\]](#)
- Morales, N.; Mery-Araya, C.; Guerra, P.; Poblete, R.; Chacana-Olivares, J. Mitigation of Membrane Fouling in Membrane Bioreactors Using Granular and Powdered Activated Carbon: An Experimental Study. *Water* **2024**, *16*, 2556. [\[CrossRef\]](#)
- Lim, Y.J.; Goh, K.; Nadzri, N.; Wang, R. Thin-film composite (TFC) membranes for sustainable desalination and water reuse: A perspective. *Desalination* **2025**, *599*, 118451. [\[CrossRef\]](#)
- Mannina, G.; Ni, B.-J.; Makinia, J.; Harmand, J.; Alliet, M.; Brepols, C.; Ruano, M.V.; Robles, A.; Heran, M.; Gulhan, H. Biological processes modelling for MBR systems: A review of the state-of-the-art focusing on SMP and EPS. *Water Res.* **2023**, *242*, 120275. [\[CrossRef\]](#)
- Benyahia, B.; Charfi, A.; Lesage, G.; Heran, M.; Cherki, B.; Harmand, J. Coupling a simple and generic membrane fouling model with biological dynamics: Application to the modeling of an Anaerobic Membrane BioReactor (AnMBR). *Membranes* **2024**, *14*, 69. [\[CrossRef\]](#)
- Kim, M.; Sankararao, B.; Lee, S.; Yoo, C. Prediction and identification of membrane fouling mechanism in a membrane bioreactor using a combined mechanistic model. *Ind. Eng. Chem. Res.* **2013**, *52*, 17198–17205. [\[CrossRef\]](#)
- Sandoval-García, V.; Ruano, M.; Alliet, M.; Brepols, C.; Comas, J.; Harmand, J.; Heran, M.; Mannina, G.; Rodriguez-Roda, I.; Smets, I. Modeling MBR fouling: A critical review analysis towards establishing a framework for good modeling practices. *Water Res.* **2025**, *268*, 122611. [\[CrossRef\]](#)
- Paul, P. Investigation of a MBR membrane fouling model based on time series analysis system identification methods. *Desalination Water Treat.* **2011**, *35*, 92–100. [\[CrossRef\]](#)
- Galinha, C.; Carvalho, G.; Portugal, C.; Guglielmi, G.; Oliveira, R.; Crespo, J.; Reis, M. Real-time monitoring of membrane bioreactors with 2D-fluorescence data and statistically based models. *Water Sci. Technol.* **2011**, *63*, 1381–1388. [\[CrossRef\]](#) [\[PubMed\]](#)
- Fortunato, L.; Pathak, N.; Rehman, Z.U.; Shon, H.; Leiknes, T. Real-time monitoring of membrane fouling development during early stages of activated sludge membrane bioreactor operation. *Process Saf. Environ. Prot.* **2018**, *120*, 313–320. [\[CrossRef\]](#)
- Niu, B.; Yang, L.; Meng, S.; Liang, D.; Liu, H.; Yang, L.; Shen, L.; Zhao, Q. Time-dependent analysis of polysaccharide fouling by Hermia models: Reveal the structure of fouling layer. *Sep. Purif. Technol.* **2022**, *302*, 122093. [\[CrossRef\]](#)
- Wang, Y.; Zheng, X.; Xiao, K.; Xue, J.; Ulbricht, M.; Zhang, Y. How and why does time matter-A comparison of fouling caused by organic substances on membranes over adsorption durations. *Sci. Total Environ.* **2023**, *866*, 160655. [\[CrossRef\]](#)
- Ahmad Yasmin, N.S.; Abdul Wahab, N.; Yusuf, Z. Modeling of membrane bioreactor of wastewater treatment using support vector machine. In *Modeling, Design and Simulation of Systems, Proceedings of the 17th Asia Simulation Conference (AsiaSim 2017), Melaka, Malaysia, 27–29 August 2017*; Proceedings, Part II 17; Springer: Singapore, 2017; pp. 485–495. [\[CrossRef\]](#)
- Niu, C.; Li, X.; Dai, R.; Wang, Z. Artificial intelligence-incorporated membrane fouling prediction for membrane-based processes in the past 20 years: A critical review. *Water Res.* **2022**, *216*, 118299. [\[CrossRef\]](#)
- Abuwatfa, W.H.; AlSawaftah, N.; Darwish, N.; Pitt, W.G.; Hussein, G.A. A review on membrane fouling prediction using artificial neural networks (ANNs). *Membranes* **2023**, *13*, 685. [\[CrossRef\]](#)
- Niu, C.; Li, B.; Wang, Z. Using artificial intelligence-based algorithms to identify critical fouling factors and predict fouling behavior in anaerobic membrane bioreactors. *J. Membr. Sci.* **2023**, *687*, 122076. [\[CrossRef\]](#)
- Frontistis, Z.; Lykogiannis, G.; Sarmpanis, A. Artificial Neural Networks in Membrane Bioreactors: A Comprehensive Review—Overcoming Challenges and Future Perspectives. *Sci* **2023**, *5*, 31. [\[CrossRef\]](#)
- Frontistis, Z.; Lykogiannis, G.; Sarmpanis, A. Machine learning implementation in membrane bioreactor systems: Progress, challenges, and future perspectives: A review. *Environments* **2023**, *10*, 127. [\[CrossRef\]](#)

25. Maere, T.; Villez, K.; Marsili-Libelli, S.; Naessens, W.; Nopens, I. Membrane bioreactor fouling behaviour assessment through principal component analysis and fuzzy clustering. *Water Res.* **2012**, *46*, 6132–6142. [\[CrossRef\]](#)
26. Wang, Z.; Zeng, J.; Shi, Y.; Ling, G. MBR membrane fouling diagnosis based on improved residual neural network. *J. Environ. Chem. Eng.* **2023**, *11*, 109742. [\[CrossRef\]](#)
27. Zhong, H.; Yuan, Y.; Luo, L.; Ye, J.; Chen, M.; Zhong, C. Water quality prediction of MBR based on machine learning: A novel dataset contribution analysis method. *J. Water Process Eng.* **2022**, *50*, 103296. [\[CrossRef\]](#)
28. Zhang, S.; Jin, Y.; Chen, W.; Wang, J.; Wang, Y.; Ren, H. Artificial intelligence in wastewater treatment: A data-driven analysis of status and trends. *Chemosphere* **2023**, *336*, 139163. [\[CrossRef\]](#)
29. Savage, N. Breaking into the black box of artificial intelligence. *Nature* **2022**. [\[CrossRef\]](#)
30. Rudin, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nat. Mach. Intell.* **2019**, *1*, 206–215. [\[CrossRef\]](#)
31. Mersha, M.; Lam, K.; Wood, J.; AlShami, A.K.; Kalita, J. Explainable artificial intelligence: A survey of needs, techniques, applications, and future direction. *Neurocomputing* **2024**, *599*, 128111. [\[CrossRef\]](#)
32. Bourget, G. Statistical analysis of wastewater treatment plant data. *SN Appl. Sci.* **2023**, *5*, 130. [\[CrossRef\]](#)
33. Baarimah, A.O.; Bazel, M.A.; Alaloul, W.S.; Alazaiza, M.Y.; Al-Zghoul, T.M.; Almuhaya, B.; Khan, A.; Mushtaha, A.W. Artificial intelligence in wastewater treatment: Research trends and future perspectives through bibliometric analysis. *Case Stud. Chem. Environ. Eng.* **2024**, *10*, 100926. [\[CrossRef\]](#)
34. Cirillo, A.I.; Tomaiuolo, G.; Guido, S. Membrane fouling phenomena in microfluidic systems: From technical challenges to scientific opportunities. *Micromachines* **2021**, *12*, 820. [\[CrossRef\]](#) [\[PubMed\]](#)
35. Dagher, G.; Martin, A.; Galharret, J.M.; Moulin, L.; Croué, J.P.; Teychene, B. Forecasting multicycle hollow fiber ultrafiltration fouling using time series analysis. *J. Water Process Eng.* **2023**, *56*, 104441. [\[CrossRef\]](#)
36. Goi, Y.; Liang, Y. A general modeling framework for FO spiral-wound membrane and its fouling impact on FO-RO desalination system. *Desalination* **2025**, *593*, 118236. [\[CrossRef\]](#)
37. Hazrati, H.; Moghaddam, A.H.; Rostamizadeh, M. The influence of hydraulic retention time on cake layer specifications in the membrane bioreactor: Experimental and artificial neural network modeling. *J. Environ. Chem. Eng.* **2017**, *5*, 3005–3013. [\[CrossRef\]](#)
38. Schmitt, F.; Banu, R.; Yeom, I.-T.; Do, K.-U. Development of artificial neural networks to predict membrane fouling in an anoxic-aerobic membrane bioreactor treating domestic wastewater. *Biochem. Eng. J.* **2018**, *133*, 47–58. [\[CrossRef\]](#)
39. Viet, N.D.; Jang, A. Development of artificial intelligence-based models for the prediction of filtration performance and membrane fouling in an osmotic membrane bioreactor. *J. Environ. Chem. Eng.* **2021**, *9*, 105337. [\[CrossRef\]](#)
40. Li, C.; Tao, Y. Application of support vector machine with simulated annealing algorithm in MBR membrane pollution prediction. In Proceedings of the 2017 IEEE 15th International Conference on Software Engineering Research, Management and Applications (SERA), London, UK, 7–9 June 2017; pp. 211–217. [\[CrossRef\]](#)
41. Miller, D.J.; Kasemset, S.; Paul, D.R.; Freeman, B.D. Comparison of membrane fouling at constant flux and constant transmembrane pressure conditions. *J. Membr. Sci.* **2014**, *454*, 505–515. [\[CrossRef\]](#)
42. Hong, P.-N.; Noguchi, M.; Matsuura, N.; Honda, R. Mechanism of biofouling enhancement in a membrane bioreactor under constant trans-membrane pressure operation. *J. Membr. Sci.* **2019**, *592*, 117391. [\[CrossRef\]](#)
43. Yi, X.; Zhang, M.; Song, W.; Wang, X. Effect of Initial Water Flux on the Performance of Anaerobic Membrane Bioreactor: Constant Flux Mode versus Varying Flux Mode. *Membranes* **2021**, *11*, 203. [\[CrossRef\]](#)
44. Du, X.; Shi, Y.; Jegatheesan, V.; Haq, I.U. A review on the mechanism, impacts and control methods of membrane fouling in MBR system. *Membranes* **2020**, *10*, 24. [\[CrossRef\]](#)
45. Al-Asheh, S.; Bagheri, M.; Aidan, A. Membrane bioreactor for wastewater treatment: A review. *Case Stud. Chem. Environ. Eng.* **2021**, *4*, 100109. [\[CrossRef\]](#)
46. 5220; Standard Methods for the Examination of Water and Wastewater, 23rd ed. American Public Health Association (APHA): Washington, DC, USA, 2017. [\[CrossRef\]](#)

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.