

Một hướng phát triển công nghệ thứ ba đã xuất hiện: bản sao số (DT). Bản sao số đóng vai trò là khung tích hợp dự đoán ML, tính minh bạch XAI và mô hình hóa cơ chế [30–32]. Sự tích hợp này tạo ra một công cụ vận hành theo thời gian thực [30–32]. Bản sao số là bản sao ảo được ghép nối hai chiều và cập nhật liên tục từ hệ thống vật lý. Nó kết hợp mô hình quy trình độ trung thực cao với dữ liệu cảm biến thời gian thực và hiệu chỉnh từ dữ liệu. Hệ thống cho phép mô phỏng dự đoán, thử nghiệm kịch bản và tối ưu hóa mà không cần thí nghiệm thực tế [33]. Với MBR, bản sao số hoàn chỉnh sẽ tích hợp mô hình bùn hoạt tính [34,35] và mô hình phụ lọc màng [36]. Hệ thống này cũng tích hợp bộ dự đoán tắc nghẽn màng bằng ML, mô-đun giải thích XAI và bộ tối ưu năng lượng. Các thành phần tạo nền tảng thống nhất, cung cấp khuyến nghị vận hành cùng lập luận minh bạch cho người vận hành [37].

Abstract

Theo khung này, các phần tiếp theo trình bày phương pháp và thảo luận ứng dụng ML, XAI, DT trong hệ thống MBR. Cần lưu ý rằng từ ‘toàn diện’ trong tiêu đề thể hiện bề rộng của các mô hình nghiên cứu gồm ML, XAI và DT. Thuật ngữ này không mang hàm ý rằng lĩnh vực này đã hoàn thiện ở quy mô vận hành. Sự khan hiếm các triển khai DT thực tế và mức tích hợp XAI còn hạn chế là phát hiện trung tâm của bài viết. Những phát hiện này định hình lộ trình nghiên cứu được trình bày chi tiết trong Section 7.




Hình 1. Khung khái niệm của bài tổng quan, chỉ ra các thách thức vận hành chính trong bể phản ứng sinh học màng (MBR). Sơ đồ trình bày các mô hình phân tích gồm học máy, trí tuệ nhân tạo có thể giải thích và bản sao số. Nội dung này cũng nêu bật các ứng dụng chính, các khoảng trống nghiên cứu và định hướng tương lai được xác định.

1. Introduction

2. Phương pháp nghiên cứu

Quá trình tìm kiếm sử dụng các từ khóa tự do kết hợp với toán tử Boolean. Cú pháp tìm kiếm cụ thể gồm: (“membrane bioreactor” OR “MBR”) AND (“machine learning” OR “artificial neural network” OR “deep learning” OR “LSTM” OR “random forest” OR “support vector machine” OR “explainable AI” OR “XAI” OR “SHAP” OR “LIME” OR “digital twin”). Phạm vi tìm kiếm chỉ giới hạn ở các bài báo tạp chí bình duyệt bằng tiếng Anh. Danh mục tài liệu tham khảo của các bài báo thu thập được kiểm tra thủ công để tìm thêm nguồn liên quan. Nghiên cứu loại bỏ các bài báo thiếu chỉ số hiệu năng định lượng hoặc chỉ tập trung vào chế tạo vật liệu màng.

3. Học máy cho dự đoán tắc nghẽn màng




2. Methodology

Các mô hình cơ chế, như họ ASM [34,35] và BSM-MBR [36], nâng cao hiểu biết về động học sinh học. Chúng cũng làm rõ liên kết giữa động học này với hiệu suất phân tách của màng. Tuy nhiên, độ chính xác dự đoán của chúng dưới điều kiện tải trọng động bị giới hạn bởi nhiều yếu tố. Những yếu tố này gồm khó khăn khi xác định các phân đoạn EPS bùn lỏng theo thời gian thực. Các thông số mô hình cũng rất nhạy với nhiệt độ và lịch sử bùn. Ngoài ra, chi phí tính toán cho mô phỏng cơ chế toàn diện ở thang thời gian vận hành rất cao [23,40]. Cấu hình MBR thẩm thấu (OMBR) ghép bể phản ứng với màng thẩm thấu thuận (FO) qua lực thẩm thấu. Cấu hình này làm tăng độ phức tạp của hệ thống. Quá trình này tạo ra động học phân cực nồng độ, thúc đẩy các hướng tiếp cận dựa trên dữ liệu [22,41]. Những hạn chế trên tạo động lực cho các hướng tiếp cận ML được đánh giá trong các tiểu mục tiếp theo.

Mạng nơ-ron nhân tạo (ANN) là một trong những kiến trúc ML đầu tiên được áp dụng có hệ thống để dự đoán tắc nghẽn màng MBR. Mirbagheri và cộng sự so sánh mạng perceptron đa tầng (MLP) và hàm cơ sở xuyên tâm (RBF) trong hệ MBR ngập quy mô pilot [23]. Họ dự đoán áp suất xuyên màng (TMP) và độ thấm bằng các biến gồm thời gian, TSS, COD, SRT và MLSS qua đợt vận hành 60 ngày. Cả hai kiến trúc đều tạo ra kết quả dự đoán đạt yêu cầu. Trong đó, mạng RBF hội tụ nhanh hơn và giảm độ nhạy đối với trọng số ban đầu. Đây là ưu điểm thực tiễn quan trọng khi triển khai mô hình trực tuyến.

Các phương pháp dựa trên kernel ánh xạ dữ liệu đầu vào sang không gian đặc trưng nhiều chiều hơn. Kỹ thuật này giúp mô hình học các ranh giới quyết định phi tuyến mà không cần kiến trúc sâu. Những phương pháp này đã thể hiện hiệu năng mang tính cạnh tranh cao. Hamed và cộng sự thực hiện nghiên cứu so sánh nghiêm ngặt nhằm dự đoán trở lực tắc nghẽn trong MBR phòng thí nghiệm [42]. Họ so sánh ANN-MLP, ANN tối ưu hóa bầy đàn (ANN-PSO), lập trình biểu diễn gen (GEP) và máy vector hỗ trợ bình phương tối thiểu (LSSVM). LSSVM đạt hiệu năng tốt nhất với $R^2 = 0.990$ và $MSE = 0.0002$, vượt trội rõ rệt so với mọi biến thể ANN.



Một tổng quan của Queiroz và cộng sự đã phân tích 57 nghiên cứu ML về dự đoán hiệu năng MBR [45]. Trong đó, các mô hình ANN được sử dụng trong 88% trường hợp. Tổng quan này chỉ ra khoảng trống lớn: chưa có nghiên cứu nào dùng ML để dự đoán tuổi thọ hoặc thời điểm thay thế màng. Khoảng trống nghiên cứu này mang ý nghĩa kinh tế trực tiếp đối với các đơn vị vận hành nhà máy.

Shi và cộng sự đã tổng quan rộng hơn về các ứng dụng ML trong các quá trình lọc màng [38]. Các mô hình lai ML—cơ chế sử dụng phương trình cơ chế để tính toán các đặc trưng đầu vào dẫn xuất trước khi dự đoán bằng ML. Họ kết luận mô hình lai luôn vượt trội các phương pháp hộp đen thuần túy trong các nghiên cứu kiểm định chéo. Ưu thế này thể hiện đặc biệt rõ rệt khi ngoại suy ra ngoài phạm vi vận hành của dữ liệu huấn luyện [38].

Các phương pháp ensemble (tập hợp) kết hợp dự đoán từ nhiều mô hình cơ sở để giảm phương sai và tăng tính tổng quát. Nhóm phương pháp này đạt hiệu năng tổng thể cao nhất trong các tài liệu ML về MBR. Thuật toán rừng ngẫu nhiên (RF) [21] tổng hợp các dự đoán từ một tập hợp cây quyết định huấn luyện độc lập. Mỗi cây được xây dựng trên một tập con ngẫu nhiên của dữ liệu huấn luyện và đặc trưng đầu vào. RF rất phù hợp để dự đoán tắc nghẽn màng MBR. Thuật toán xử lý tốt các kiểu biến hỗn hợp và kháng ngoại lai trong dữ liệu vận hành. Ngoài ra, RF ước tính sẵn tầm quan trọng của đặc trưng mà không cần bước XAI riêng biệt. Tuy nhiên, rừng ngẫu nhiên vẫn có những hạn chế nhất định. Dung lượng bộ nhớ chiếm dụng tăng theo kích thước tập hợp. Điều này hạn chế việc triển khai trên phần cứng nhúng hoặc thiết bị biên trong hệ điều khiển MBR thời gian thực. Thứ hạng độ quan trọng đặc trưng từ RF mang tính toàn cục và có thể che khuất tính phi tuyến cục bộ. Do đó, phương pháp gán giá trị SHAP (Mục 4) được khuyến nghị đi kèm RF khi cần tính giải thích.

Kovacs và cộng sự thực hiện kiểm định ML quy mô đầy đủ toàn diện nhất trong lĩnh vực MBR [26]. Nghiên cứu áp dụng RF, ANN và bộ nhớ ngắn hạn dài (LSTM) trên hơn 80.000 mẫu từ nhà máy nước thải đô thị. Mô hình RF đạt $R^2 = 0.927\text{--}0.996$ và $RMSE = 0.264\text{--}0.904$ kPa qua các giai đoạn lọc MBR khác nhau. Các giai đoạn gồm tắc nghẽn ban đầu, vận hành ổn định, nén chặt giai đoạn muộn và phục hồi sau làm sạch. Các mô hình ANN và LSTM cho giá trị RMSE tổng thể cao hơn RF. Tuy nhiên, LSTM thể hiện ưu thế rõ rệt trong giai đoạn tắc nghẽn muộn có cấu trúc chuỗi thời gian. Lịch sử biến thiên thông lượng và áp suất xuyên màng (TMP) chứa thông tin quan trọng để dự đoán tiến trình tắc nghẽn. Đây là công trình đầu tiên kiểm định dự đoán TMP bằng ML ở quy mô đô thị với độ chính xác cao. Kết quả này chứng minh tính khả thi của mô hình dự đoán TMP dựa trên ML ở quy mô thực tế. Tuy nhiên, kiểm định trên dữ liệu SCADA lịch sử không tương đương với việc triển khai vận hành vòng kín. Kiểm định lịch sử chỉ xác nhận mô hình có thể tái hiện các quy luật quá khứ từ một cơ sở đơn lẻ. Mô hình chưa chắc chắn vận hành tin cậy khi gặp trôi cảm biến, nhiễu đo, trễ dữ liệu hoặc sự cố thiết bị. Hệ thống cần được thử nghiệm vòng kín bổ sung trong điều kiện vận hành trực tiếp. Sau thử nghiệm, kết quả mô hình mới có thể phục vụ việc ra quyết định vận hành.

Tính khả thi thực tiễn của kiến trúc LSTM và Transformer trong hệ thống MBR vận hành cần được xem xét cẩn trọng. Mạng LSTM cần tập dữ liệu lớn hơn nhiều so với mô hình nông, thường từ hàng nghìn đến hàng vạn bước thời gian. Kích thước này giúp mô hình học các phụ thuộc thời gian mà không bị quá khớp. Huấn luyện và suy luận LSTM đòi hỏi năng lực tính toán cao hơn rừng ngẫu nhiên (RF) hoặc máy vector hỗ trợ. Yêu cầu tính toán này có thể hạn chế việc triển khai trên các bộ điều khiển công nghiệp nhúng trong nhà máy MBR. Kiến trúc Transformer tạo ra gánh nặng dữ liệu và tính toán thậm chí còn lớn hơn. Các kỹ thuật nén mô hình gồm cắt tỉa, lượng tử hóa và chưng cất tri thức mở ra hướng triển khai gọn nhẹ. Tuy nhiên, các phương pháp này chưa được đánh giá trong bối cảnh MBR. Các nghiên cứu học sâu (DL) tương lai cần báo cáo rõ các ràng buộc này để đánh giá độ sẵn sàng triển khai.

3.4. Các hạn chế của bộ dữ liệu, nguy cơ quá khớp và khả năng tổng quát hóa liên cơ sở

Bảng 1. Hiệu năng mô hình ML đã xác nhận trong dự đoán tắc nghẽn màng và TMP của MBR.

Khả năng duy trì độ chính xác tại cơ sở thứ hai được định nghĩa là khả năng tổng quát hóa liên cơ sở. Cơ sở này có thể khác biệt về hình học màng, thành phần nước thải hoặc chế độ vận hành. Các tài liệu được tổng quan rất hiếm khi đánh giá chỉ tiêu này.

Các hạn chế của bộ dữ liệu và ràng buộc về khả năng tổng quát hóa ảnh hưởng trực tiếp đến việc áp dụng ML vào vận hành MBR. Kỹ sư vận hành và cơ quan quản lý không chỉ yêu cầu dự đoán chính xác mà còn cần giải trình minh bạch, có thể kiểm toán. Yêu cầu này thúc đẩy việc áp dụng các phương pháp trí tuệ nhân tạo có thể giải thích (XAI) ở phần tiếp theo.

Bảng 2. So sánh phản biện các thuật toán ML chính áp dụng cho dự đoán tắc nghẽn màng và TMP trong MBR.

4. Trí tuệ nhân tạo có thể giải thích trong các ứng dụng MBR

LSSVM

Kernel-based

4.3. LIME, biểu đồ phụ thuộc từng phần và các phương pháp dựa trên gradient

Bảng 3. Các phương pháp XAI được áp dụng trong MBR và các nghiên cứu xử lý nước liên quan: đặc điểm và ứng dụng.

5. Tối ưu hóa năng lượng dựa trên học máy trong các hệ thống MBR

5.1. Cấu trúc tiêu thụ năng lượng và các mục tiêu tối ưu hóa

Bảng 4. Chuẩn năng lượng đã xác nhận và bằng chứng tối ưu hóa cho các hệ thống MBR.

Khái niệm bản sao số lần đầu tiên do Grieves nêu rõ trong ngành sản xuất [30]. Sau đó, khái niệm này được mở rộng sang nhiều lĩnh vực công nghiệp [32]. Các lĩnh vực này gồm hàng không vũ trụ, hạ tầng năng lượng và sản xuất thông minh. Fuller cùng cộng sự xác định ba thành phần thiết yếu trong các triển khai DT công nghiệp [31]. Thứ nhất là thực thể vật lý với hệ thống cảm biến và cơ cấu chấp hành. Thứ hai là mô hình ảo mô phỏng hệ thống vật lý theo các thang thời gian phù hợp. Thứ ba là tầng kết nối dữ liệu giúp đồng bộ hóa liên tục trạng thái giữa miền vật lý và miền ảo. Mô hình ảo phải có tính đa độ chính xác (multi-fidelity). Mô hình kết hợp các mô hình dựa trên vật lý độ chính xác cao cho trạng thái biến đổi chậm. Đồng thời, mô hình dùng các mô hình dựa trên dữ liệu nhanh hơn cho các biến vận hành động. Sự cân bằng này duy trì cả tính khả thi tính toán và độ chính xác dự đoán [33].

Trên thực tế, các triển khai bản sao số MBR được phân thành ba cấp độ năng lực. Sự phân chia này phản ánh độ sâu tích hợp và khả năng ra quyết định tự chủ tăng dần. Bản sao số Cấp I (Mô tả) giám sát và trực quan hóa trạng thái nhà máy theo thời gian thực. Cấp này dùng bảng hiển thị cảm biến, hệ thống quản lý cảnh báo và phân tích xu hướng lịch sử. Các tính năng này đã có trên thị trường và được triển khai ở nhiều hệ thống MBR quy mô đầy đủ [5,15]. Sự phát triển nhanh của nghiên cứu DT trong ngành nước củng cố cách phân loại này. Một tổng quan gần đây đã khảo sát 147 nghiên cứu từ năm 2015 đến tháng 5 năm 2025. Số lượng công bố DT trong ngành tăng từ một bài năm 2015 lên 41 bài năm 2024 [60]. Trong số 147 nghiên cứu đó, có 41 nghiên cứu giải quyết bài toán xử lý nước thải.

6.2. Tích hợp XAI vào kiến trúc ra quyết định của bản sao số

Luồng dữ liệu và quyết định trong bản sao số MBR Cấp II/III tích hợp XAI diễn ra qua năm giai đoạn. Ở giai đoạn một, dữ liệu cảm biến thô truyền qua SCADA từ nhà máy đến lớp dữ liệu DT mỗi phút. Các cảm biến gồm oxy hòa tan, áp suất xuyên màng (TMP), thông lượng thẩm, độ đục, nhiệt độ và khí sục màng. Tại đây, hệ thống kiểm tra chất lượng, bù khuyết dữ liệu bằng nội suy và lưu vào cơ sở dữ liệu chuỗi thời gian. Ở giai đoạn hai, công cụ ML đã huấn luyện sẽ đưa ra dự báo trước từ 12 đến 72 giờ. Công cụ này tính toán dựa trên dữ liệu cảm biến gần nhất. Mô hình rừng ngẫu nhiên hoặc LSTM dùng để dự báo TMP. Mô hình tăng cường độ dốc (gradient boosting) dùng để ước tính chất lượng nước đầu ra. Ở giai đoạn ba, mô-đun giải thích tính giá trị phân bổ thuộc tính SHAP theo thời gian thực cho mỗi dự đoán. Mô-đun tạo ra biểu đồ đóng góp xếp hạng, chỉ rõ biến quy trình nào đang chi phối dự báo và chi phối bao nhiêu. Ở giai đoạn bốn, cả dự đoán và lời giải thích SHAP đều hiển thị trên bảng điều khiển cho người vận hành. Điều này giúp con người xem xét có cơ sở trước khi thực thi bất kỳ hành động điều khiển nào. Ở giai đoạn năm, các khuyến nghị được chấp nhận sẽ chuyển đến lớp điều khiển. Lớp điều khiển sẽ điều chỉnh giá trị đặt sục khí, mục tiêu thông lượng hoặc lịch làm sạch khi cần thiết. Dự đoán cùng lời giải thích tự động lưu vào vết kiểm toán phục vụ truy xuất quy định và đánh giá sau sự kiện. Kiến trúc này đảm bảo XAI được nhúng vào quy trình ra quyết định, thay vì chỉ là mô-đun hậu kiểm tùy chọn.

Hình 3 thể hiện bản đồ nhiệt định tính về mức độ hoàn thiện nghiên cứu cho các ứng dụng ML, XAI và bản sao số trong hệ thống MBR. Biểu đồ này giúp tổng hợp hiện trạng của lĩnh vực trên nhiều phạm vi ứng dụng và khía cạnh triển khai.

Hình 3. Bản đồ nhiệt về mức độ hoàn thiện nghiên cứu cho các nghiên cứu về phản ứng sinh học màng (MBR) xử lý nước thải thông minh. Hình này tổng hợp định tính các tài liệu tổng quan theo miền ứng dụng chính và khía cạnh triển khai. Biểu đồ chỉ ra rằng dự đoán tắc nghẽn màng là lĩnh vực hoàn thiện nhất.

Khoảng trống đầu tiên và cơ bản nhất là sự khan hiếm các bộ dữ liệu đối chuẩn (benchmark). Đại đa số nghiên cứu được đánh giá đã huấn luyện và kiểm chứng mô hình trên dữ liệu từ một cơ sở đơn lẻ. Dữ liệu này thường chỉ được thu thập trong vài tuần đến vài tháng. Điều này ngăn cản việc đánh giá khả năng tổng quát hóa liên cơ sở. Khi chuyển mô hình sang cơ sở khác biệt về màng, nước thải hay cách vận hành, hiệu năng thường giảm mạnh. Đây là hậu quả của trôi dạt dữ liệu (dataset shift). Hiện tượng này đã được ghi nhận rộng rãi trong kỹ thuật môi trường ứng dụng ML. Cộng đồng ML trong xử lý nước thải hiện thiếu các bộ dữ liệu đối chuẩn (benchmark) được tiêu chuẩn hóa tương đương. Các bộ dữ liệu chuẩn từng thúc đẩy mạnh thị giác máy tính, xử lý ngôn ngữ tự nhiên và hệ gen học. Việc xây dựng các bộ dữ liệu vận hành MBR đa cơ sở, truy cập mở là yêu cầu then chốt [17,24,47]. Dữ liệu cần bao quát đa dạng quy mô, cấu hình, loại nước thải và vùng khí hậu. Yêu cầu này giúp đánh giá chặt chẽ và nâng cao khả năng tổng quát hóa của mô hình ML. Nền tảng BSM-MBR [36,50] cung cấp chuẩn đối sánh dựa trên mô phỏng rất hữu ích. Tuy nhiên, dữ liệu mô phỏng không tái hiện đầy đủ các điều kiện bất định, nhiễu và những ràng buộc vận hành thực tế.

Khoảng trống thứ ba là thiếu hụt việc triển khai DT ở quy mô thực tế (full-scale) có tích hợp XAI. Mọi công bố về DT trong bài này đều dựa trên mô phỏng hoặc quy mô phòng thí nghiệm. Chưa có nghiên cứu nào ghi nhận triển khai DT cấp II hoặc cấp III hoàn chỉnh ở quy mô đô thị thực tế. Chưa hệ thống nào tích hợp tạo giải thích XAI tức thời cùng với sự can thiệp của người vận hành. Yêu cầu hạ tầng cho việc triển khai ở quy mô thực tế là rất lớn và đa chiều. Yêu cầu kỹ thuật gồm hiệu chuẩn cảm biến, đường ống dữ liệu, hạ tầng tính toán và an ninh mạng - vật lý. Yêu cầu tổ chức gồm đào tạo nhân viên, quản lý thay đổi và khung trách nhiệm hợp đồng cho điều khiển tự động. Các yếu tố tổ chức này chưa được ghi nhận đầy đủ trong tài liệu học thuật [33,37]. Cần có sự hợp tác bài bản giữa đơn vị cấp thoát nước, nhà cung cấp công nghệ và nhóm nghiên cứu học thuật. Nghiên cứu kiểm chứng ở quy mô thực tế (full-scale) của Kovacs và cộng sự [26] sẽ tạo cơ sở chứng cứ triển khai. Đây là nền tảng để cơ quan quản lý phê duyệt và thúc đẩy ứng dụng thương mại.

Khoảng trống thứ bảy liên quan đến yêu cầu nguồn nhân lực để vận hành hệ thống DT và XAI. Bản sao số cấp II hoặc III cần nhân sự chuyên về kỹ thuật dữ liệu, vận hành ML và điều khiển quy trình. Hầu hết các công ty cấp thoát nước hiện nay đều thiếu bộ kỹ năng nội bộ này. Khoảng cách giữa nghiên cứu và triển khai thực tế một phần do thiếu hụt nhân lực, không chỉ do công nghệ. Các nghiên cứu cần báo cáo rõ ràng các yêu cầu về nhân sự và đào tạo của khuôn khổ DT đề xuất.

8. Kết luận

Bài tổng quan toàn diện này tổng hợp bằng chứng từ các tài liệu bình duyệt. Nghiên cứu tập trung vào ứng dụng học máy (ML), trí tuệ nhân tạo có thể giải thích (XAI) và bản sao số (DT). Các ứng dụng này phục vụ xử lý nước thải bằng bể phản ứng sinh học màng (MBR). Các kết luận chính dưới đây giải quyết bốn mục tiêu tổng quan đã nêu tại Phần 1:

Tài trợ: Nghiên cứu này không nhận được tài trợ từ bên ngoài.

Xung đột lợi ích: Tác giả tuyên bố không có xung đột lợi ích.

as required, and the prediction, together with its explanation, is automatically logged to an audit trail for regulatory traceability and post-event review. This architecture ensures that XAI is structurally embedded in the decision pipeline rather than functioning as an optional post-hoc module.

Tao et al. [32] and Barricelli et al. [33] both identify interpretability as a fundamental design requirement for trustworthy industrial digital twins. They note that unexplained model recommendations under novel process conditions, even if quantitatively correct, will be systematically overridden by conservative operators. This negates the operational value of the twin. The incorporation of XAI into DT architecture is therefore not merely a regulatory convenience but a functional requirement for achieving the operator trust necessary for the transition from Tier II advisory to Tier III prescriptive operation. The convergence of ML prediction, XAI transparency, and mechanistic model consistency checking within a unified DT architecture represents the most complete available framework for intelligent, trustworthy MBR operation at the current state of the art [37]. Table 5 presents a structured overview of the three DT maturity tiers applicable to MBR systems, from descriptive monitoring through to closed-loop prescriptive control.

Table 5. Digital twin maturity tiers for MBR systems with capability and implementation characteristics.

Tier	Capabilities	Data Requirements	Implementation Complexity	Status in MBR Literature	References
I—Descriptive	Real-time monitoring, dashboards, alarm management	SCADA, online sensors	Low	Commercially deployed	[5,15]
II—Predictive	TMP forecast, effluent quality prediction, fault detection, 12–72 h ahead	SCADA + lab analytics + trained ML	Medium	Validated in simulation and full-scale data	[24,26,36]
III—Prescriptive	Closed-loop autonomous optimization, what-if scenario testing, XAI decision justification	Full DT + actuators + XAI + safety validation	High	No full-scale MBR deployment documented	[33,37]

The three tiers can also be characterized by their evidence status. Tier I is commercially deployed at full municipal and industrial scale worldwide [5,15] and therefore represents validated operational technology. Tier II has been demonstrated in BSM-MBR simulation studies [36] and validated using full-scale SCADA datasets (Kovacs et al., 2022 [26]), but has not yet been deployed as a continuously operating closed-loop advisory system in a commissioned plant; its evidence status is therefore simulation-to-full-scale data validation. Tier III remains at the conceptual and architectural proposal stage: no full-scale MBR implementation combining Tier III prescriptive control with integrated XAI decision justification has been documented in the peer-reviewed literature as of December 2025. The transition from Tier II to Tier III represents the field’s primary frontier and is directly linked to the research gaps discussed in Section 7.

To synthesize the current state of the field across application domains and deployment dimensions, Figure 3 presents a qualitative heat map of research maturity for ML, XAI, and digital twin applications in wastewater MBR systems.




Figure 3. Research maturity heat map for intelligent wastewater membrane bioreactor (MBR) studies. The figure provides a qualitative synthesis of the reviewed literature across major application domains and deployment dimensions, indicating that fouling prediction is the most mature area.

In the heat map, each cell represents a qualitative maturity rating based on three criteria: the volume of peer-reviewed evidence available, the availability of full-scale operational validation, and the extent of documented deployment in commissioned water treatment facilities. High-rated cells indicate substantial evidence base supported by multiple independent studies with consistent results. Moderate-rated cells indicate an emerging evidence base that includes at least some pilot or full-scale validation. Emerging cells indicate that the application area is recognized, but evidence is confined to conceptual proposals, simulation studies, or a small number of laboratory-scale demonstrations. Low-rated cells indicate that no peer-reviewed evidence for that combination was identified in the structured search.

Three patterns are immediately apparent. First, fouling prediction shows the strongest evidence base and predictive maturity, both rated High, reflecting the substantial body of ML literature reviewed in Section 3. Nevertheless, its interpretability integration, full-scale validation, and deployment readiness are all rated Emerging, indicating that predictive capability has substantially outpaced practical implementation. Second, XAI-supported interpretation shows a high-rating for interpretability integration, as expected for a technology whose primary function is interpretability, but Low full-scale validation and Emerging deployment readiness, confirming that XAI application in MBR systems remains largely an academic exercise. Third, digital twin deployment shows the lowest overall maturity profile, with Emerging or Low ratings across all five dimensions, reflecting the absence of full-scale operational deployments documented in the peer-reviewed literature. Each low-maturity cell in the figure maps directly to one or more of the nine research gaps identified in Section 7, providing a visual roadmap for prioritizing future research investment.

7. Research Gaps and Future Directions

This review reveals nine interconnected research gaps whose resolution is necessary before XAI-DT integration can achieve operational deployment at scale in MBR facilities. The first five gaps were identified in the original review. Four additional gaps were identified in response to reviewer comments and are presented as Gaps 6 through 9.

The first and most fundamental gap is the scarcity of benchmark datasets. The vast majority of reviewed studies trained and validated models on single-facility datasets, typically collected over weeks to months, precluding evaluation of cross-site generalization. When models trained on one MBR installation are applied to a second facility with a different membrane module configuration, influent composition, or operating regime, performance typically degrades significantly, a consequence of a dataset shift documented in the broader ML environmental engineering literature. The wastewater ML community currently lacks the equivalent of the standardized benchmark datasets that enabled rapid, systematic progress in computer vision, natural language processing, and genomics over the past decade. The development of openly accessible, multi-facility MBR operational datasets encompassing diverse scales, configurations, wastewater types, and climate zones is a key requirement for rigorously evaluating and improving ML model generalizability [17,24,47]. The BSM-MBR platform [36,50] provides a valuable simulation-based benchmark. However, simulation data remain valuable for benchmarking, but they do not fully reproduce the non-stationary, noisy, and operationally constrained conditions of real plant data.

Beyond dataset size, the capacity for cross-site generalization poses an equally fundamental challenge. When a model trained at one MBR installation is applied to a second facility operating under different conditions, predictive performance typically degrades because the statistical relationship between input features and fouling outcomes differs between plants in ways that single-site training data cannot capture. Dataset shift has several primary sources. These include differences in membrane module geometry between hollow-fiber and flat-sheet configurations, sludge microbiology shaped by local wastewater composition and temperature, and the specific SRT and HRT operating windows maintained at each facility. Industrial trade waste discharge events, which introduce rapid and large disturbances not captured in routine training data, are another key source. Transfer learning, in which a model pre-trained on a data-rich source facility is fine-tuned using a small amount of data from a target plant, and domain adaptation, which explicitly minimizes the distributional discrepancy between the source and target feature spaces, offer practical methodological pathways toward generalizable MBR ML models. Both approaches have demonstrated success in related environmental engineering and water quality monitoring applications [17,47]. They should be prioritized in future multi-facility MBR studies, ideally using openly accessible benchmark datasets as the shared testbed.

The second gap is the near-universal absence of uncertainty quantification in MBR ML predictions. Very few reviewed studies reported prediction intervals or confidence bounds alongside point estimates. This is a critical gap, since uncertainty is directly actionable in operational contexts. A control system with a TMP forecast uncertainty of ± 2 kPa will respond differently than one facing ± 12 kPa uncertainty. Yet the current literature overwhelmingly provides only deterministic point predictions. Bayesian neural networks, which maintain probability distributions over network weights rather than point estimates, provide principled uncertainty quantification but are computationally demanding; conformal prediction methods, which provide distribution-free coverage guarantees under exchangeability assumptions, offer a computationally efficient alternative increasingly used in safety-critical engineering applications [28,48]. Neither approach has been systematically evaluated in the MBR ML context. For Tier III prescriptive DT operation, where control decisions are executed, automatically calibrated uncertainty bounds are not merely desirable but operationally essential for safe autonomous control.

The third gap is the lack of full-scale DT deployments with integrated XAI. Of the DT-focused publications identified in this review, all described simulation-based or laboratory-scale frameworks; none documented a complete Tier II or Tier III DT implementation at full municipal scale with contemporaneous XAI explanation generation and operator

integration. The infrastructure requirements for full-scale deployment are substantial and multidimensional. Technical requirements include sensor calibration, data pipeline reliability, computational infrastructure, and cybersecurity. Organizational requirements include operator training, change management, and contractual liability frameworks for automated control. These organizational factors have not been well documented in the academic literature [33,37]. Structured collaboration between water utilities, technology providers, and academic research groups of the kind that has produced the full-scale ML validation work of Kovacs et al. [26] is needed to generate the deployment evidence base that will underpin regulatory and commercial adoption.

The fourth gap concerns dynamic influent characterization. Standard SCADA instrumentation measures bulk wastewater quality parameters (COD, BOD, TSS, turbidity, DO, pH, and conductivity) that provide only an aggregate characterization of the mixed liquor entering the biological system. Industrial trade waste discharge events, stormwater infiltration during rainfall, and diurnal variation in domestic sewage composition all introduce rapid, large-magnitude changes in influent characteristics that are poorly represented by daily composite samples or slow-response online sensors [3,22]. These uncharacterized disturbances are a primary source of MBR fouling events that are difficult to predict from standard sensor arrays. Integration of high-frequency online spectroscopic sensors (UV-Vis, fluorescence spectrophotometry), emerging optical coherence tomography for real-time cake layer characterization, and even molecular tools for microbial community fingerprinting into the DT sensor layer would substantially improve dynamic influent characterization and ML model predictive coverage of these high-consequence disturbance events.

The fifth gap concerns the regulatory dimension of XAI adoption. The theoretical case for XAI as a tool for building regulatory trust in ML-based water system management is well-developed in the academic literature [29,51]. However, no published study has empirically documented a case where SHAP explanations or equivalent XAI outputs directly influenced a permit condition, regulatory inspection outcome, operational license amendment, or other formal regulatory action in the water sector. This represents a critical missing link between the technical capability demonstrated in academic research and the regulatory permission structures that govern operational water systems. Proactive engagement between the water engineering community and environmental regulators to develop agreed-upon evidence standards for XAI validation, define acceptable use cases for automated ML-based control, and establish audit-trail requirements is a prerequisite for the transition from research demonstration to licensed operational deployment that the field currently needs. A sixth gap concerns the economic cost of ML model development and retraining. Developing a production-grade ML model for an MBR plant requires data infrastructure, engineering expertise, and computational resources. Retraining costs recur whenever influent characteristics shift, membrane modules are replaced, or plant configuration changes. These costs are rarely reported in academic studies. Future work should document the full cost of model development, validation, and maintenance cycles. This information is essential for water utilities evaluating whether ML-based control is economically justified relative to simpler alternatives. To contextualise this gap, a realistic deployment cost structure for an ML-based fouling prediction system at a medium-sized MBR plant includes the following components. Initial development covers sensor audit and data infrastructure (typically several months of SCADA historian cleanup), model development and cross-validation, and regulatory documentation for process change approval. Ongoing costs include periodic model retraining, edge computing hardware, IT security, and operator training. No peer-reviewed study has yet reported a full cost–benefit analysis for a deployed ML system in an MBR plant. This absence of data is itself a finding. Future studies should report total development cost, validation cost, and annual

maintenance cost alongside model performance metrics. Without this information, water utilities cannot assess whether ML-based control is economically justified relative to simpler alternatives such as PID controllers. Until such data are available, practitioners should commission site-specific feasibility assessments before committing to ML-based control deployment. A seventh gap concerns the human capital requirements for operating a DT and XAI system. A functioning Tier II or Tier III digital twin requires staff with expertise in data engineering, ML operations, and process control. Most water utilities lack this skill set in-house. The gap between research-grade demonstrations and practical utility deployment is partly a workforce gap, not only a technology gap. Studies should explicitly report the staffing and training requirements of proposed DT frameworks. An eighth gap concerns the limited comparison of ML-based control with established non-ML alternatives. Proportional–integral–derivative (PID) controllers and fuzzy logic controllers are well-understood, low-cost, and already deployed in most MBR facilities. Very few reviewed studies benchmarked ML models against these baselines under equivalent operating conditions. Without such comparisons, the incremental benefit of ML over conventional control cannot be quantified. Future studies should include PID and fuzzy logic as mandatory baselines when claiming performance improvements. A ninth gap concerns the carbon and energy footprint of ML model computation. Training deep learning models such as LSTM networks or Transformers on large SCADA datasets consumes substantial electrical energy. Inference on edge hardware adds ongoing energy demand. For MBR systems deployed specifically to reduce environmental impact, this computational footprint is a legitimate concern. Future studies should report training energy consumption and inference energy per prediction alongside model performance metrics.

8. Conclusions

This comprehensive review has synthesized evidence from peer-reviewed sources on machine learning, explainable artificial intelligence, and digital twin applications in membrane bioreactor wastewater treatment. The following principal conclusions address the four review objectives stated in Section 1:

- ML models for MBR fouling and TMP prediction have matured substantially over the review period. Ensemble methods (particularly RF) and kernel-based approaches (LSSVM) achieve $R^2 = 0.85\text{--}0.99$ across laboratory, pilot, and full-scale systems, consistently outperforming standard ANN architectures. Full-scale RF validation on 80,000+ operational samples ($R^2 = 0.927\text{--}0.996$, RMSE = 0.264–0.904 kPa) represents a strong historical validation result. It is important to clarify, however, that historical validation on archived SCADA data is not equivalent to operational deployment validation. Closed-loop performance under live conditions, including sensor drift, noise, and data latency, has not yet been demonstrated. Site-specific validation and governance safeguards remain prerequisites before deployment in operational MBR monitoring systems.
- SHAP-based analyses in MBR studies frequently identify MLSS, SRT, HRT, and aeration intensity as dominant predictors. These findings simultaneously validate mechanistic understanding and provide operator-actionable evidence of the variables most critical for fouling control [17,25,42]. SHAP's dominance across XAI-inclusive publications reflects both its theoretical grounding in cooperative game theory and its practical usability for engineering interpretation.
- Model-based and feedback-control approaches have confirmed up to 20% reductions in aeration energy demand at full-scale MBR installations [59], establishing a validated benchmark for model-informed control. Dedicated ML-specific energy optimization

demonstrations remain limited and represent the most immediately impactful research gap for operational energy efficiency.

- Digital twin frameworks integrating mechanistic ASM sub-models with ML corrections provide the architecture for Tier II predictive and Tier III prescriptive MBR management. The embedding of XAI decision-transparency modules within the DT architecture is a functional requirement, not merely a desirable feature for achieving the operator trust necessary for autonomous prescriptive control. No full-scale MBR Tier III deployment with integrated XAI has yet been documented, which represents the field's primary frontier.
- Nine critical research gaps require systematic investigation: standardized multi-facility benchmark datasets; calibrated uncertainty quantification in operational ML predictions; full-scale DT deployment evidence; dynamic integration of influent characterization technology; empirical evaluation of XAI within regulatory acceptance frameworks; transparent reporting of ML model development and retraining costs; workforce capacity building for DT and XAI operations at water utilities; systematic benchmarking of ML-based control against PID and fuzzy logic baselines; and reporting of computational energy footprints for deep learning models deployed in environmental systems.

The convergence of interpretable ML prediction, XAI transparency, and real-time digital twin simulation represents the most promising near-term pathway for intelligent, trustworthy MBR operation. Realizing this vision will require sustained, coordinated investment in open data infrastructure, uncertainty-aware model pipelines, full-scale deployment partnerships, and engagement with regulatory frameworks, contributions that must come from the water engineering, data science, and water governance communities acting in concert.

Supplementary Materials: The following supporting information can be downloaded at <https://www.mdpi.com/article/10.3390/membranes16050181/s1>. Table S1: Study-level data extraction for reviewed ML, XAI, and DT studies on MBR systems.

Funding: This research received no external funding.

Data Availability Statement: No new data were created or analyzed in this study.

Conflicts of Interest: The author declares no conflict of interest.

References

1. Judd, S. *The MBR Book: Principles and Applications of Membrane Bioreactors for Water and Wastewater Treatment*; Elsevier: Amsterdam, The Netherlands, 2010.
2. Kraume, M.; Drews, A. Membrane bioreactors in waste water treatment—status and trends. *Chem. Eng. Technol.* **2010**, *33*, 1251–1259.
3. Xiao, K.; Liang, S.; Wang, X.; Chen, C.; Huang, X. Current state and challenges of full-scale membrane bioreactor applications: A critical review. *Bioresour. Technol.* **2019**, *271*, 473–481. [[CrossRef](#)]
4. Le-Clech, P.; Chen, V.; Fane, T.A. Fouling in membrane bioreactors used in wastewater treatment. *J. Membr. Sci.* **2006**, *284*, 17–53. [[CrossRef](#)]
5. Judd, S. The status of membrane bioreactor technology. *Trends Biotechnol.* **2008**, *26*, 109–116. [[CrossRef](#)]
6. Yang, W.; Cicek, N.; Ilg, J. State-of-the-art of membrane bioreactors: Worldwide research and commercial applications in North America. *J. Membr. Sci.* **2006**, *270*, 201–211.
7. Rahman, T.U.; Roy, H.; Islam, M.R.; Tahmid, M.; Fariha, A.; Mazumder, A.; Tasnim, N.; Pervez, M.N.; Cai, Y.; Naddeo, V. The advancement in membrane bioreactor (MBR) technology toward sustainable industrial wastewater management. *Membranes* **2023**, *13*, 181. [[CrossRef](#)]
8. Meng, F.; Chae, S.-R.; Drews, A.; Kraume, M.; Shin, H.-S.; Yang, F. Recent advances in membrane bioreactors (MBRs): Membrane fouling and membrane material. *Water Res.* **2009**, *43*, 1489–1512. [[CrossRef](#)]
9. Drews, A. Membrane fouling in membrane bioreactors—Characterisation, contradictions, cause and cures. *J. Membr. Sci.* **2010**, *363*, 1–28. [[CrossRef](#)]

10. Wang, Z.; Ma, J.; Tang, C.Y.; Kimura, K.; Wang, Q.; Han, X. Membrane cleaning in membrane bioreactors: A review. *J. Membr. Sci.* **2014**, *468*, 276–307. [\[CrossRef\]](#)
11. Meng, F.; Zhang, S.; Oh, Y.; Zhou, Z.; Shin, H.-S.; Chae, S.-R. Fouling in membrane bioreactors: An updated review. *Water Res.* **2017**, *114*, 151–180. [\[CrossRef\]](#)
12. Liao, B.-Q.; Kraemer, J.T.; Bagley, D.M. Anaerobic membrane bioreactors: Applications and research directions. *Crit. Rev. Environ. Sci. Technol.* **2006**, *36*, 489–530. [\[CrossRef\]](#)
13. Jha, S.; Mishra, B.K. An overview of deploying different treatment processes with membrane bioreactor for enhanced treatment of wastewaters: Synergistic performances and reduced fouling of membrane. *Environ. Sci. Pollut. Res.* **2024**, *31*, 63603–63634. [\[CrossRef\]](#)
14. Verrecht, B.; Maere, T.; Nopens, I.; Brepols, C.; Judd, S. The cost of a large-scale hollow fibre MBR. *Water Res.* **2010**, *44*, 5274–5283. [\[CrossRef\]](#)
15. Krzeminski, P.; Leverette, L.; Malamis, S.; Katsou, E. Membrane bioreactors—a review on recent developments in energy reduction, fouling control, novel configurations, LCA and market prospects. *J. Membr. Sci.* **2017**, *527*, 207–227. [\[CrossRef\]](#)
16. Kamali, M.; Appels, L.; Yu, X.; Aminabhavi, T.M.; Dewil, R. Artificial intelligence as a sustainable tool in wastewater treatment using membrane bioreactors. *Chem. Eng. J.* **2021**, *417*, 128070. [\[CrossRef\]](#)
17. Newhart, K.B.; Holloway, R.W.; Hering, A.S.; Cath, T.Y. Data-driven performance analyses of wastewater treatment plants: A review. *Water Res.* **2019**, *157*, 498–513. [\[CrossRef\]](#)
18. Cortes, C.; Vapnik, V. Support-vector networks. *Mach. Learn.* **1995**, *20*, 273–297. [\[CrossRef\]](#)
19. Chen, T.; He, T.; Benesty, M.; Khotilovich, V.; Tang, Y.; Cho, H.; Chen, K.; Mitchell, R.; Cano, I.; Zhou, T. *Xgboost: Extreme Gradient Boosting*, R Package Version 0.4-2; R Foundation: Vienna, Austria, 2015.
20. Hochreiter, S.; Schmidhuber, J. Long short-term memory. *Neural Comput.* **1997**, *9*, 1735–1780. [\[CrossRef\]](#)
21. Breiman, L. Random forests. *Mach. Learn.* **2001**, *45*, 5–32. [\[CrossRef\]](#)
22. Viet, N.D.; Jang, A. Development of artificial intelligence-based models for the prediction of filtration performance and membrane fouling in an osmotic membrane bioreactor. *J. Environ. Chem. Eng.* **2021**, *9*, 105337. [\[CrossRef\]](#)
23. Mirbagheri, S.A.; Bagheri, M.; Bagheri, Z.; Kamarkhani, A.M. Evaluation and prediction of membrane fouling in a submerged membrane bioreactor with simultaneous upward and downward aeration using artificial neural network-genetic algorithm. *Process Saf. Environ. Prot.* **2015**, *96*, 111–124. [\[CrossRef\]](#)
24. Schmitt, F.; Do, K.-U. Prediction of membrane fouling using artificial neural networks for wastewater treated by membrane bioreactor technologies: Bottlenecks and possibilities. *Environ. Sci. Pollut. Res.* **2017**, *24*, 22885–22913. [\[CrossRef\]](#)
25. Schmitt, F.; Banu, R.; Yeom, I.-T.; Do, K.-U. Development of artificial neural networks to predict membrane fouling in an anoxic-aerobic membrane bioreactor treating domestic wastewater. *Biochem. Eng. J.* **2018**, *133*, 47–58. [\[CrossRef\]](#)
26. Kovacs, D.J.; Li, Z.; Baetz, B.W.; Hong, Y.; Donnaz, S.; Zhao, X.; Zhou, P.; Ding, H.; Dong, Q. Membrane fouling prediction and uncertainty analysis using machine learning: A wastewater treatment plant case study. *J. Membr. Sci.* **2022**, *660*, 120817. [\[CrossRef\]](#)
27. Ribeiro, M.T.; Singh, S.; Guestrin, C. Anchors: High-precision model-agnostic explanations. In Proceedings of the AAAI Conference on Artificial Intelligence, New Orleans, LA, USA, 2–7 February 2018; Volume 32.
28. Barredo, A.A.; Del Ser, J.; Gil-Lopez, S.; Díaz-Rodríguez, N.; Bennetot, A.; Chatila, R.; Tabik, S.; Garcia, S.; Molina, D.; Herrera, F. Explainable Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Inf. Fusion* **2020**, *58*, 82–115. [\[CrossRef\]](#)
29. Adadi, A.; Berrada, M. Peeking inside the black-box: A survey on explainable artificial intelligence (XAI). *IEEE Access* **2018**, *6*, 52138–52160. [\[CrossRef\]](#)
30. Grieves, M. Digital twin: Manufacturing excellence through virtual factory replication. *White Pap.* **2014**, *1*, 1–7.
31. Fuller, A.; Fan, Z.; Day, C.; Barlow, C. Digital twin: Enabling technologies, challenges and open research. *IEEE Access* **2020**, *8*, 108952–108971. [\[CrossRef\]](#)
32. Tao, F.; Zhang, H.; Liu, A.; Nee, A.Y. Digital twin in industry: State-of-the-art. *IEEE Trans. Ind. Inform.* **2018**, *15*, 2405–2415. [\[CrossRef\]](#)
33. Barricelli, B.R.; Casiraghi, E.; Fogli, D. A survey on digital twin: Definitions, characteristics, applications, and design implications. *IEEE Access* **2019**, *7*, 167653–167671. [\[CrossRef\]](#)
34. Henze, M.; Gujer, W.; Mino, T.; Van Loosdrecht, M. *Activated Sludge Models ASM1, ASM2, ASM2d and ASM3*; IWA Publishing: London, UK, 2006.
35. Gujer, W.; Henze, M.; Mino, T.; Van Loosdrecht, M. Activated sludge model No. 3. *Water Sci. Technol.* **1999**, *39*, 183–193. [\[CrossRef\]](#)
36. Maere, T.; Verrecht, B.; Moerenhout, S.; Judd, S.; Nopens, I. BSM-MBR: A benchmark simulation model to compare control and operational strategies for membrane bioreactors. *Water Res.* **2011**, *45*, 2181–2190. [\[CrossRef\]](#)
37. Wang, A.-J.; Li, H.; He, Z.; Tao, Y.; Wang, H.; Yang, M.; Savic, D.; Daigger, G.T.; Ren, N. Digital twins for wastewater treatment: A technical review. *Engineering* **2024**, *36*, 21–35. [\[CrossRef\]](#)

38. Shi, Y.; Wang, Z.; Du, X.; Gong, B.; Jegatheesan, V.; Haq, I.U. Recent advances in the prediction of fouling in membrane bioreactors. *Membranes* **2021**, *11*, 381. [\[CrossRef\]](#)
39. Ni, B.-J.; Rittmann, B.E.; Yu, H.-Q. Soluble microbial products and their implications in mixed culture biotechnology. *Trends Biotechnol.* **2011**, *29*, 454–463. [\[CrossRef\]](#)
40. Fenu, A.; Guglielmi, G.; Jimenez, J.; Spèrandio, M.; Saroj, D.; Lesjean, B.; Brepols, C.; Thoeve, C.; Nopens, I. Activated sludge model (ASM) based modelling of membrane bioreactor (MBR) processes: A critical review with special regard to MBR specificities. *Water Res.* **2010**, *44*, 4272–4294. [\[CrossRef\]](#)
41. Achilli, A.; Cath, T.Y.; Marchand, E.A.; Childress, A.E. The forward osmosis membrane bioreactor: A low fouling alternative to MBR processes. *Desalination* **2009**, *239*, 10–21. [\[CrossRef\]](#)
42. Hamed, H.; Ehteshami, M.; Mirbagheri, S.A.; Zendehboudi, S. New deterministic tools to systematically investigate fouling occurrence in membrane bioreactors. *Chem. Eng. Res. Des.* **2019**, *144*, 334–353. [\[CrossRef\]](#)
43. Giwa, A.; Daer, S.; Ahmed, I.; Marpu, P.; Hasan, S. Experimental investigation and artificial neural networks ANNs modeling of electrically-enhanced membrane bioreactor for wastewater treatment. *J. Water Process Eng.* **2016**, *11*, 88–97.
44. Nguyen, T.N.; Do, K.U.; Tran, T.P.N.; Van Nguyen, T.; Chu, Q.X. Predictive Modeling of Membrane Fouling in Domestic Wastewater Membrane Bioreactor Using Machine Learning. *Water Environ. Res.* **2025**, *97*, e70205. [\[CrossRef\]](#)
45. de Queiroz, M.M.; Moreira, V.R.; Amaral, M.C.S.; Oliveira, S.M.A.C. Machine learning algorithms for predicting membrane bioreactors performance: A review. *J. Environ. Manag.* **2025**, *380*, 124978. [\[CrossRef\]](#)
46. Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A.N.; Kaiser, Ł.; Polosukhin, I. Attention is all you need. *Adv. Neural Inf. Process. Syst.* **2017**, *30*, 6000–6010.
47. Frontistis, Z.; Lykogiannis, G.; Sarmanis, A. Machine learning implementation in membrane bioreactor systems: Progress, challenges, and future perspectives: A review. *Environments* **2023**, *10*, 127. [\[CrossRef\]](#)
48. Molnar, C. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 2nd ed.; Leanpub: Victoria, BC, Canada, 2022.
49. Liang, J.; Lee, S.; Ren, X.; Guo, Y.; Park, J.; Park, S.-G.; Kim, J.-Y.; Hwang, M.-H. Predictive Framework for Membrane Fouling in Full-Scale Membrane Bioreactors (MBRs): Integrating AI-Driven Feature Engineering and Explainable AI (XAI). *Processes* **2025**, *13*, 2352. [\[CrossRef\]](#)
50. Zhu, Y.; Wang, Y.; Zhu, E.; Ma, Z.; Wang, H.; Chen, C.; Guan, J.; Waite, T.D. Predicting membrane fouling of submerged membrane bioreactor wastewater treatment plants using machine learning. *Environ. Sci. Technol.* **2025**, *59*, 10010–10021. [\[CrossRef\]](#)
51. Rudin, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nat. Mach. Intell.* **2019**, *1*, 206–215. [\[CrossRef\]](#)
52. Lundberg, S.M.; Lee, S.-I. A unified approach to interpreting model predictions. *Adv. Neural Inf. Process. Syst.* **2017**, *30*, 4768–4777.
53. Lundberg, S.M.; Erion, G.; Chen, H.; DeGrave, A.; Prutkin, J.M.; Nair, B.; Katz, R.; Himmelfarb, J.; Bansal, N.; Lee, S.-I. From local explanations to global understanding with explainable AI for trees. *Nat. Mach. Intell.* **2020**, *2*, 56–67. [\[CrossRef\]](#)
54. LeCun, Y.; Bengio, Y.; Hinton, G. Deep learning. *Nature* **2015**, *521*, 436–444. [\[CrossRef\]](#)
55. Ribeiro, M.T.; Singh, S.; Guestrin, C. “Why should i trust you?” Explaining the predictions of any classifier. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, CA, USA, 13–17 August 2016; pp. 1135–1144. [\[CrossRef\]](#)
56. Verrecht, B.; Judd, S.; Guglielmi, G.; Brepols, C.; Mulder, J. An aeration energy model for an immersed membrane bioreactor. *Water Res.* **2008**, *42*, 4761–4770. [\[CrossRef\]](#)
57. Germain, E.; Nelles, F.; Drews, A.; Pearce, P.; Kraume, M.; Reid, E.; Judd, S.J.; Stephenson, T. Biomass effects on oxygen transfer in membrane bioreactors. *Water Res.* **2007**, *41*, 1038–1044. [\[CrossRef\]](#) [\[PubMed\]](#)
58. Diaz, O.; Gonzalez, E.; Vera, L. Influence of air scouring and residual fouling on cake build-up and compression in membrane bioreactors. *Ind. Eng. Chem. Res.* **2024**, *63*, 13740–13751. [\[CrossRef\]](#)
59. Sun, J.; Liang, P.; Yan, X.; Zuo, K.; Xiao, K.; Xia, J.; Qiu, Y.; Wu, Q.; Wu, S.; Huang, X. Reducing aeration energy consumption in a large-scale membrane bioreactor: Process simulation and engineering application. *Water Res.* **2016**, *93*, 205–213. [\[CrossRef\]](#)
60. Ghorbani Bam, P.; Rezaei, N.; Roubanis, A.; Austin, D.; Austin, E.; Tarroja, B.; Takacs, I.; Villez, K.; Rosso, D. Digital Twin Applications in the Water Sector: A Review. *Water* **2025**, *17*, 2957. [\[CrossRef\]](#)
61. Rodríguez-Alonso, C.; Pena-Regueiro, I.; García, Ó. Digital twin platform for water treatment plants using microservices architecture. *Sensors* **2024**, *24*, 1568. [\[CrossRef\]](#) [\[PubMed\]](#)
62. Xu, M.; Liu, D. AI-Enabled Membrane Bioreactors: A Review of Control Architectures and Operating-Parameter Optimization for Nitrogen and Phosphorus Removal. *Water* **2025**, *17*, 2899. [\[CrossRef\]](#)
63. Wei, Q.; Xu, Z.; Yin, H. Enhanced nitrogen prediction and mechanistic process analysis in high-salinity wastewater treatment using interpretable machine learning approach. *Bioresour. Technol.* **2025**, *426*, 132393. [\[CrossRef\]](#)
64. Leichtmann, B.; Humer, C.; Hinterreiter, A.; Streit, M.; Mara, M. Effects of explainable artificial intelligence on trust and human behavior in a high-risk decision task. *Comput. Hum. Behav.* **2023**, *139*, 107539.

65. Goncalves, A.; Correia, A. Engineering Explainable AI Systems for GDPR-Aligned Decision Transparency: A Modular Framework for Continuous Compliance. *J. Cybersecur. Priv.* **2025**, *6*, 7. [[CrossRef](#)]
66. Sheik, A.G.; Kumar, A.; Srungavarapu, C.S.; Azari, M.; Ambati, S.R.; Bux, F.; Patan, A.K. Insights into the application of explainable artificial intelligence for biological wastewater treatment plants: Updates and perspectives. *Eng. Appl. Artif. Intell.* **2025**, *144*, 110132. [[CrossRef](#)]
67. Teixeira, B.; Pinto, T.; Vale, Z. Detecting Concept Drift with SHapley Additive ExPlanations for Intelligent Model Retraining in Energy Generation Forecasting. In *World Conference on Explainable Artificial Intelligence*; Springer: Berlin/Heidelberg, Germany, 2025; pp. 156–168.

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.