

Automated machine learning and SHAP-based interpretation of PFOA removal via electrochemical oxidation

Haitham Elnakar^{a,b,*} 

^a Department of Civil and Environmental Engineering, King Fahd University of Petroleum & Minerals, Dhahran 31261, Saudi Arabia

^b Interdisciplinary Research Center for Construction and Building Materials, King Fahd University of Petroleum & Minerals, Dhahran 31261, Saudi Arabia

ARTICLE INFO

Keywords:
Perfluorooctanoic acid (PFOA)
PFAS
Electrochemical oxidation
Automated Machine Learning (AutoML)
FLAML (Fast Lightweight AutoML)
SHapley Additive exPlanations (SHAP)

ABSTRACT

The electrochemical oxidation of perfluorooctanoic acid (PFOA), a persistent and toxic environmental pollutant, presents significant operational complexities due to nonlinear interactions among numerous process variables. This study introduces a fully automated, robust machine learning (ML) framework based on Fast Lightweight AutoML (FLAML), integrated with SHapley Additive exPlanations (SHAP) to rigorously optimize and interpret PFOA electrochemical oxidation performance. The FLAML-optimized XGBoost model demonstrated exceptional predictive accuracy (RMSE=3.97, R²=0.98), significantly outperforming systematically tuned traditional ML models such as Random Forest, Gradient Boosting, and Deep Learning architectures. Rigorous statistical validation confirmed the superior generalizability and stability of the FLAML-optimized model, while SHAP-based interpretability analyses revealed electrolysis time and anode material as primary drivers of treatment efficacy, with electrolyte concentration and current density forming the next tier; consistent with established electrochemical degradation kinetics. Notably, FLAML-optimized XGBoost achieved a 72 % reduction in computational overhead compared to manually tuned models, establishing a reproducible, interpretable, and computationally efficient benchmark in environmental ML applications. The framework provides a systematic approach that improves predictive accuracy, enhances interpretability, and strengthens practical applicability to support optimization of remediation technologies and environmental decision-making.

1. Introduction

Perfluorooctanoic acid (PFOA), a legacy member of the per- and polyfluoroalkyl substances (PFAS) family, is among the most persistent environmental pollutants identified to date. Its exceptional chemical stability, rooted in the strength of its carbon–fluorine bonds, has enabled widespread contamination of aquatic and terrestrial ecosystems [1,2]. PFOA’s bioaccumulation and its links to immunotoxicity, liver dysfunction, cardiovascular disease, and cancer have triggered escalating regulatory scrutiny [3,4]. The International Agency for Research on Cancer now classifies PFOA as carcinogenic to humans (Group 1) [5], and the U.S. Environmental Protection Agency has set maximum contaminant levels as low as 4 ng/L in drinking water [6]. These developments have catalyzed an urgent search for effective, scalable, and sustainable remediation technologies capable of not just removing, but fully mineralizing PFOA into benign end products such as carbon dioxide and fluoride ions. This challenge mirrors a broader trajectory in

wastewater treatment, where established processes are being optimized to more effectively degrade persistent industrial pollutants [7,8].

Electrochemical oxidation (EO) has emerged as one of the most promising destructive technologies for PFAS remediation, offering the potential to mineralize PFOA into benign end products such as carbon dioxide and fluoride ions [9,10]. The process operates through two principal degradation pathways: direct electron transfer at the anode surface, which generates perfluoroalkyl radicals and initiates chain-shortening reactions, and hydroxyl radical-mediated oxidation via water electrolysis [11,12]. However, optimizing EO systems presents formidable challenges due to the complex interplay of multiple operational parameters, including current density, electrode spacing, electrolyte composition, pH, temperature, initial PFOA concentration, electrolysis time, and water matrix characteristics [13–15]. The high dimensionality and nonlinear interactions among these variables create a multifaceted optimization landscape where changes in one parameter can significantly influence the effectiveness of others, rendering

* Corresponding author at: Department of Civil and Environmental Engineering, King Fahd University of Petroleum & Minerals, Dhahran 31261, Saudi Arabia.
E-mail address: haitham.elnakar@kfupm.edu.sa.

<https://doi.org/10.1016/j.dwt.2025.101598>

Received 19 August 2025; Received in revised form 24 November 2025; Accepted 2 December 2025

Available online 4 December 2025

1944-3986/© 2025 The Author(s). Published by Elsevier Inc. This is an open access article under the CC BY license (<http://creativecommons.org/licenses/by/4.0/>).



Học máy tự động và diễn giải dựa trên SHAP về quá trình loại bỏ PF OA bằng phương pháp oxy hóa điện hóa

Haitham Elnakar^{a,b,*} 

^a Department of Civil and Environmental Engineering, King Fahd University of Petroleum & Minerals, Dhahran 31261, Saudi Arabia^b

Interdisciplinary Research Center for Construction and Building Materials, King Fahd University of Petroleum & Minerals, Dhahran 31261, Saudi Arabia

THÔNG TIN BÀI VIẾT

Keywords:
Axit perfluorooctanoic (PFOA) PFAS Oxy hóa điện hóa Học máy tự động (AutoML) FLAML (AutoML nhanh gọn) Giải thích cộng tính SHapley (SHAP)

TÓM TẮT

Quá trình oxy hóa điện hóa axit perfluorooctanoic (PFOA), một chất ô nhiễm môi trường độc hại và tồn lưu lâu dài, có độ phức tạp vận hành đáng kể do tương tác phi tuyến giữa nhiều biến quy trình. Nghiên cứu này giới thiệu một khuôn khổ học máy (ML) hoàn toàn tự động và mạnh mẽ, dựa trên Fast Lightweight AutoML (FLAML), kết hợp với các giải thích cộng tính Shapley (SHAP) để tối ưu hóa và diễn giải một cách chặt chẽ hiệu suất oxy hóa điện hóa PFOA. Mô hình XGBoost được FLAML tối ưu hóa cho thấy độ chính xác dự đoán vượt trội (RMSE=3.97, R²=0.98), tốt hơn đáng kể so với các mô hình ML truyền thống được tinh chỉnh cho hệ thống, như Random Forest, Gradient Boosting và các kiến trúc học sâu. Quá trình kiểm định thống kê nghiêm ngặt xác nhận khả năng khái quát hóa và độ ổn định vượt trội của mô hình được FLAML tối ưu hóa; trong khi đó, các phân tích khả năng diễn giải dựa trên SHAP cho thấy thời gian điện phân và vật liệu anốt là những yếu tố chính quyết định hiệu quả xử lý, tiếp theo là nồng độ chất điện ly và mật độ dòng điện; phù hợp với động học phân hủy điện hóa đã được xác lập. Đáng chú ý, XGBoost được FLAML tối ưu hóa giúp giảm 72 % chi phí tính toán so với các mô hình tinh chỉnh thủ công, qua đó thiết lập một chuẩn mực có tính tái lập, dễ diễn giải và hiệu quả về mặt tính toán trong các ứng dụng ML môi trường. Khuôn khổ này cung cấp một phương pháp tiếp cận có hệ thống, giúp cải thiện độ chính xác dự đoán, tăng cường khả năng diễn giải và nâng cao tính ứng dụng thực tiễn, hỗ trợ tối ưu hóa các công nghệ xử lý ô nhiễm và đưa ra quyết định về môi trường.

1. Giới thiệu

Axit perfluorooctanoic (PFOA), một thành viên thuộc nhóm chất cũ trong họ các chất per- và polyfluoroalkyl (PFAS), là một trong những chất ô nhiễm môi trường bền vững nhất được xác định cho đến nay. Độ ổn định hóa học vượt trội của chất này, bắt nguồn từ độ bền của các liên kết carbon–fluor, đã dẫn đến tình trạng ô nhiễm trên diện rộng ở các hệ sinh thái thủy sinh và trên cạn [1,2]. Khả năng tích lũy sinh học của PFOA và mối liên hệ của nó với độc tính miễn dịch, rối loạn chức năng gan, bệnh tim mạch và ung thư đã khiến các cơ quan quản lý ngày càng giám sát chặt chẽ hơn [3,4]. Cơ quan Ngăn ngừa Ung thư Quốc tế hiện xếp PFOA vào nhóm chất gây ung thư ở người (Nhóm 1) [5], còn Cơ quan Bảo vệ Môi trường Hoa Kỳ đã đặt mức giới hạn tối đa cho chất gây ô nhiễm trong nước uống ở mức thấp nhất là 4 ng/L [6]. Những diễn biến này đã thúc đẩy việc cấp thiết tìm kiếm các công nghệ xử lý hiệu quả, có khả năng mở rộng quy mô và bền vững, không chỉ loại bỏ mà còn khoáng hóa hoàn toàn PFOA thành các sản phẩm cuối vô hại như carbon dioxide và ion florua. Thách thức này phản ánh một xu hướng rộng hơn trong

xử lý nước thải, trong đó các quy trình đã được thiết lập đang được tối ưu hóa để phân hủy hiệu quả hơn các chất ô nhiễm công nghiệp khó phân hủy [7–8].

Oxy hóa điện hóa (EO) đã nổi lên như một trong những công nghệ phân hủy đầy hứa hẹn nhất để xử lý PFAS, có khả năng khoáng hóa PFOA thành các sản phẩm cuối vô hại như carbon dioxide và ion florua [9,10]. Quá trình này diễn ra thông qua hai con đường phân hủy chính: chuyển electron trực tiếp tại bề mặt anốt, tạo ra các gốc perfluoroalkyl và khởi phát các phản ứng rút ngắn chuỗi, và oxy hóa qua trung gian gốc hydroxyl thông qua quá trình điện phân nước [11,12]. Tuy nhiên, việc tối ưu hóa các hệ thống EO đặt ra những thách thức đáng kể do sự tương tác phức tạp giữa nhiều thông số vận hành, bao gồm mật độ dòng điện, khoảng cách điện cực, thành phần chất điện ly, pH, nhiệt độ, nồng độ PFOA ban đầu, thời gian điện phân và đặc tính của nền nước [13–15]. Số lượng biến lớn và các tương tác phi tuyến giữa chúng tạo nên một không gian tối ưu hóa đa chiều, trong đó sự thay đổi của một thông số có thể ảnh hưởng đáng kể đến hiệu quả của các thông số khác, khiến...

* Corresponding author at: Department of Civil and Environmental Engineering, King Fahd University of Petroleum & Minerals, Dhahran 31261, Saudi Arabia.
E-mail address: haitham.elnakar@kfupm.edu.sa.

<https://doi.org/10.1016/j.dwt.2025.101598>

Received 19 August 2025; Received in revised form 24 November 2025; Accepted 2 December 2025

Available online 4 December 2025

1944-3986/© 2025 The Author(s). Published by Elsevier Inc. This is an open access article under the CC BY license (<http://creativecommons.org/licenses/by/4.0/>).

traditional optimization approaches both time-consuming and resource-intensive [16,17]. This operational complexity necessitates advanced computational approaches that can systematically navigate the multidimensional parameter space and identify optimal conditions for effective PFOA destruction.

Machine learning (ML) approaches have demonstrated significant potential for addressing optimization challenges in electrochemical systems for water treatment applications [17,18]. Recent studies have successfully applied various ML algorithms to predict electrochemical process performance, with applications ranging from general electrochemical oxidation processes to specific PFAS treatment scenarios [19, 20]. Advanced ML frameworks have shown particular promise in electrochemical process optimization, with studies demonstrating the ability to achieve predictive accuracies exceeding $R^2 = 0.84$ while providing mechanistic insights through feature importance analysis [17]. The integration of interpretability tools such as SHAP (SHapley Additive exPlanations) has enabled researchers to extract actionable insights from complex electrochemical datasets, revealing key parameter relationships and guiding process optimization strategies [17,21]. However, most existing ML applications in this domain have relied on conventional modeling approaches requiring extensive manual hyperparameter tuning and expert-driven algorithm selection, limiting their accessibility and scalability for environmental practitioners [18,22,23].

Automated machine learning (AutoML) frameworks represent a transformative approach to data-driven process optimization by systematically exploring algorithm selection, hyperparameter optimization, and feature engineering without human intervention [24-26]. FLAML (Fast Lightweight AutoML), developed by Microsoft Research, implements cost-aware Bayesian optimization that dynamically allocates computational resources while prioritizing low-complexity models for rapid convergence [27]. Recent applications of AutoML in environmental modeling have demonstrated the ability to significantly reduce computational cost while achieving predictive performance that surpasses traditional, manually tuned models [28,29]. For instance, gradient boosting algorithms selected via AutoML outperformed conventional neural networks in predicting the impacts of microplastics on methane production in anaerobic digestion ($MSE = 17.0$ vs. 58.0) [29], while AutoML models also successfully captured complex antibiotic removal dynamics in constructed wetlands across varying training durations ($MAE = 9.94$ – 13.68 , $R^2 = 0.780$ – 0.877) [28]. The integration of efficient AutoML frameworks such as FLAML with explainable AI techniques like SHAP directly addresses two critical requirements of environmental engineering applications: delivering high predictive accuracy and generating transparent, interpretable insights that support regulatory compliance, operational optimization, and stakeholder confidence [28,29].

In this study, a reproducible and interpretable AutoML workflow is developed for electrochemical oxidation of PFOA. The aim is to show that cost-aware automated model selection and tuning (FLAML), coupled with SHAP-based explanation, can deliver (i) reliable predictive performance, (ii) transparent, model-based attribution of operational drivers, and (iii) a portable pipeline that reduces manual trial-and-error. Use of a previously curated dataset enables direct comparability while isolating the methodological contribution (automation plus interpretability). Throughout, FLAML is treated as an optimization framework distinct from the final predictive learner (XGBoost), and performance is evaluated under repeated holdout with statistical testing and learning-curve diagnostics to assess generalization.

2. Methodology

2.1. Dataset characteristics and preprocessing

This study leverages a dataset originally curated by Alnaimat et al. [30], which captures the electrochemical degradation of PFOA under varied conditions. The dataset comprises unique treatment scenarios,

each defined by a combination of operational parameters and environmental contexts. Key independent variables include electrolysis duration, current density, anode and cathode material types, electrolyte concentration and composition, and the water matrix. Exploratory analyses were performed to characterize the inputs and the target prior to modeling. The dependence structure among predictors is shown in Figure S1 (Spearman rank-correlation heatmap with significance marks). Bivariate relationships are visualized in Figure S2 (pairwise scatterplots with LOWESS fits and Pearson/Spearman annotations). The target distribution, together with a Shapiro–Wilk normality diagnostic, appears in Figure S3. Several electrochemical variables exhibit moderate positive association (for example, electrolysis time with current density; $|p| \approx 0.35$ – 0.55), reflecting typical experimental co-variation. Preprocessing followed algorithm-appropriate conventions. Continuous variables were standardized (z-score) for distance- and gradient-based baselines to ensure numerical stability and commensurate scaling, whereas tree-based learners were trained on unscaled inputs given the scale-invariance of split criteria. Categorical descriptors (anode, cathode, electrolyte, water matrix) were one-hot encoded to maintain parity across baseline algorithms and to permit later aggregation by parent feature in model interpretation. Cardinalities were small (≤ 6 per field), limiting sparsity and dimensionality.

2.2. Data splitting and evaluation protocol

Model evaluation used an 80:20 holdout stratified on anode type to mitigate covariate shift arising from uneven anode distribution across the dataset. The target variable (removal, %) was not stratified, consistent with the regression setting. A fixed random seed (42) was used for reproducibility. Stability of this protocol across repeated runs and alternative split realizations is documented in Figure S4 (stratification sensitivity), and the internal model-selection procedure and performance consistency are summarized in Figure S5 (nested cross-validation diagnostics)

2.3. Automated model selection via FLAML

Automated model and hyperparameter selection was conducted with FLAML, a cost-aware AutoML framework that replaces manual, grid-style tuning with budgeted, early-stopped search. A wall-time budget of 300 s was enforced for FLAML’s search. FLAML initializes with inexpensive configurations, adaptively allocates trials toward promising learner–hyperparameter regions, and prunes underperforming runs when validation error plateaus within the allotted budget. The optimization objective was 5-fold cross-validation RMSE, with early stopping applied at both the boosting-iteration level (for iterative learners) and the trial level (for unpromising configurations). Convergence was declared when no improvement was observed within the budget window and the incumbent remained unchanged across successive evaluations. The best-performing model selected by FLAML was an XGBoost regressor (learning rate = 0.1403; n_estimators = 379; max_leaves = 13; L1/L2 regularization $\alpha = 0.0995$, $\lambda = 0.0010$), with subsample = 0.85 and colsample_bytree = 0.83. This configuration balances bias–variance by combining a moderate learning rate with constrained tree complexity and regularization. The full search space and the selected hyperparameters for XGBoost and all baseline learners are summarized in SI Table S1.

2.4. Comparative benchmarking and statistical validation

To contextualize performance, the FLAML-optimized XGBoost model was benchmarked against five commonly used regressors: Decision Trees (DT), Random Forests (RF), Gradient Boosting Decision Trees (GBDT), Deep Learning (DL), and k-Nearest Neighbors (KNN). Each model was evaluated on the same one-hot encoded dataset and subjected to identical stratified train-test splits to ensure methodological

consistency across comparisons. The baseline models were configured using standard best practices for each algorithm. The XGBoost model was configured with the hyperparameters selected by FLAML. The DL model was a simple fully connected neural network with one hidden layer. The KNN model used Euclidean distance and a nearest neighbor search. The DT and RF models used default parameters. The GBDT model used the same parameters as the XGBoost model. The results of the benchmarking are presented in Table 1.

Các phương pháp học máy (ML) đã cho thấy tiềm năng đáng kể trong việc giải quyết các thách thức tối ưu hóa ở các hệ thống điện hóa ứng dụng trong xử lý nước [17,18]. Các nghiên cứu gần đây đã ứng dụng thành công nhiều thuật toán ML để dự đoán hiệu suất của các quy trình điện hóa, với phạm vi ứng dụng từ các quy trình oxy hóa điện hóa nói chung đến những tình huống xử lý PFAS cụ thể [19, 20]. Các khung ML tiên tiến đặc biệt hứa hẹn trong việc tối ưu hóa quy trình điện hóa; các nghiên cứu cho thấy chúng có thể đạt độ chính xác dự đoán vượt quá $R^2 = 0.84$, đồng thời cung cấp thông tin chi tiết về cơ chế thông qua phân tích mức độ quan trọng của các đặc trưng [17]. Việc tích hợp các công cụ giải thích như SHAP (giải thích cộng tính Shapley) đã giúp các nhà nghiên cứu rút ra những thông tin hữu ích từ các bộ dữ liệu điện hóa phức tạp, làm sáng tỏ các mối quan hệ quan trọng giữa những thông số và định hướng các chiến lược tối ưu hóa quy trình [17,21]. Tuy nhiên, phần lớn các ứng dụng ML hiện có trong lĩnh vực này dựa vào các phương pháp mô hình hóa truyền thống, đòi hỏi phải tinh chỉnh siêu tham số thủ công trên diện rộng và lựa chọn thuật toán dựa vào chuyên gia, từ đó hạn chế khả năng tiếp cận và mở rộng quy mô ứng dụng đối với các chuyên gia môi trường [18,22,23].

Các khung học máy tự động (AutoML) là một phương pháp mang tính chuyển đổi để tối ưu hóa quy trình dựa trên dữ liệu, thông qua việc khám phá một cách có hệ thống các thuật toán, tối ưu hóa siêu tham số và kỹ thuật đặc trưng mà không cần sự can thiệp của con người [24-26]. FLAML (Fast Lightweight AutoML), do Microsoft Research phát triển, áp dụng phương pháp tối ưu hóa Bayes có xét đến chi phí, tự động phân bổ tài nguyên tính toán đồng thời ưu tiên các mô hình có độ phức tạp thấp để hội tụ nhanh [27]. Những ứng dụng gần đây của AutoML trong mô hình hóa môi trường cho thấy phương pháp này có thể giảm đáng kể chi phí tính toán, đồng thời đạt hiệu năng dự đoán vượt trội so với các mô hình truyền thống được tinh chỉnh thủ công [28,29]. Chẳng hạn, các thuật toán tăng cường độ dốc được AutoML lựa chọn đã dự đoán tác động của vi nhựa đến quá trình sản sinh khí mê-tan trong phân hủy kỵ khí tốt hơn các mạng nơ-ron thông thường ($MSE = 17.0$ so với 58.0) [29]; các mô hình AutoML cũng nắm bắt thành công động thái loại bỏ kháng sinh phức tạp trong các vùng đất ngập nước nhân tạo với thời lượng huấn luyện khác nhau ($MAE = 9.94$ – 13.68 , $R^2 = 0.780$ – 0.877) [28]. Việc kết hợp các khung AutoML hiệu quả như FLAML với những kỹ thuật AI có khả năng giải thích như SHAP trực tiếp đáp ứng hai yêu cầu then chốt của các ứng dụng kỹ thuật môi trường: đạt độ chính xác dự đoán cao và tạo ra những hiểu biết minh bạch, có thể diễn giải, hỗ trợ tuân thủ quy định, tối ưu hóa vận hành và củng cố niềm tin của các bên liên quan [28,29].

Trong nghiên cứu này, một quy trình AutoML có khả năng tái lập và diễn giải được được phát triển cho quá trình oxy hóa điện hóa PFOA. Mục tiêu là chứng minh rằng việc lựa chọn và tinh chỉnh mô hình tự động có tính đến chi phí (FLAML), kết hợp với phương pháp giải thích dựa trên SHAP, có thể mang lại (i) hiệu năng dự đoán đáng tin cậy, (ii) khả năng quy kết minh bạch, dựa trên mô hình, đối với các yếu tố vận hành và (iii) một quy trình có thể chuyển giao, giúp giảm vi phạm sai sót và sai thủ công. Việc sử dụng một bộ dữ liệu đã được tuyển chọn trước đây cho phép so sánh trực tiếp, đồng thời tách biệt đóng góp về phương pháp luận (tự động hóa và khả năng diễn giải). Xu hướng suốt nghiên cứu, FLAML được xem là một khung tối ưu hóa, khác biệt với mô hình học dự đoán cuối cùng (XGBoost); hiệu năng được đánh giá bằng phương pháp giữ lại lặp lại, kết hợp kiểm định thống kê và chẩn đoán đường cong học tập để đánh giá khả năng tổng quát hóa.

2. Phương pháp luận

2.1. Dataset characteristics and preprocessing

Nghiên cứu này sử dụng bộ dữ liệu do Alnaimat và cộng sự [30] biên soạn ban đầu, ghi nhận quá trình phân hủy điện hóa PFOA trong các điều kiện khác nhau. Bộ dữ liệu bao gồm các kịch bản xử lý riêng biệt,

mỗi trường hợp được xác định bởi sự kết hợp giữa các thông số vận hành và bối cảnh môi trường. Các biến độc lập chính bao gồm thời gian điện phân, mật độ dòng điện, loại vật liệu anốt và catốt, nồng độ và thành phần chất điện phân, cùng nồng độ mẫu nước. Các phân tích thăm dò được tiến hành để mô tả đầu vào và biến mục tiêu trước khi lập mô hình. Cấu trúc phụ thuộc giữa các biến dự báo được thể hiện trong Hình S1 (bản đồ nhiệt tương quan thứ hạng Spearman kèm các ký hiệu mức ý nghĩa). Các mối quan hệ hai biến được minh họa trong Hình S2 (biểu đồ phân tán từng cặp với đường khớp LOWESS và chú thích Pearson/Spearman). Phân bố của biến mục tiêu, cùng với phép chẩn đoán tính chuẩn Shapiro–Wilk, được trình bày trong Hình S3. Một số biến điện hóa có mối tương quan tương đối mạnh với nhau (chẳng hạn, thời gian điện phân với mật độ dòng điện; $|p| \approx 0.35$ – 0.55), phản ánh sự đồng biến thiên thường gặp trong thực nghiệm. Tiền xử lý tuân theo các quy ước phù hợp với từng thuật toán. Các biến liên tục được chuẩn hóa (điểm z) cho các mô hình cơ sở dựa trên khoảng cách và gradient nhằm đảm bảo tính ổn định số và thay đổi đo tương thích, trong khi các mô hình học dựa trên cây được huấn luyện bằng đầu vào chưa chuẩn hóa do tiêu chí phân tách bất biến theo thang đo. Các biến mô tả phân loại (anốt, catốt, chất điện phân, nền mẫu nước) được mã hóa one-hot để đảm bảo tính tương đương giữa các thuật toán cơ sở và cho phép tổng hợp sau này theo đặc trưng cha khi diễn giải mô hình. Số lượng giá trị phân loại của mỗi trường đều nhỏ (≤ 6), giúp hạn chế độ thừa và số chiều.

2.2. Data splitting and evaluation protocol

Việc đánh giá mô hình sử dụng phương pháp giữ lại dữ liệu theo tỷ lệ 80:20, phân tầng theo loại anốt nhằm giảm thiểu sự dịch chuyển hệ số phân bố anốt không đồng đều trong toàn bộ tập dữ liệu. Biến mục tiêu (mức loại bỏ, %) không được phân tầng, phù hợp với thiết lập hồi quy. Hạt giống ngẫu nhiên cố định (42) được sử dụng để đảm bảo khả năng tái lập. Tính ổn định của quy trình này qua các lần chạy lặp lại và các cách phân chia thay thế được trình bày trong Hình S4 (độ nhạy của phương pháp phân tầng); quy trình lựa chọn mô hình nội bộ và tính nhất quán về hiệu suất được tóm tắt trong Hình S5 (chẩn đoán kiểm định chéo lồng nhau).

2.3. Automated model selection via FLAML

Quá trình lựa chọn mô hình và siêu tham số tự động được thực hiện bằng FLAML, một khung AutoML có xét đến chi phí, thay thế phương pháp tinh chỉnh thủ công kiểu lưới bằng quy trình tìm kiếm có giới hạn ngân sách và dừng sớm. Thời gian thực thi tối đa dành cho quá trình tìm kiếm của FLAML là 300 s. FLAML khởi tạo bằng các cấu hình ít tốn kém, phân bổ thích ứng các lượt thử nghiệm vào những vùng kết hợp bộ học–siêu tham số có triển vọng và loại bỏ các lần chạy kém hiệu quả khi lỗi xác thực chứng lại trong giới hạn ngân sách. Hàm mục tiêu tối ưu hóa là RMSE qua kiểm định chéo 5 phần, với cơ chế dừng sớm được áp dụng ở cả cấp độ vòng lặp tăng cường (đối với các bộ học lặp) và cấp độ lượt thử nghiệm (đối với các cấu hình không có triển vọng). Quá trình được xem là hội tụ khi không ghi nhận cải thiện nào trong khoảng thời gian ngân sách và cấu hình tốt nhất hiện tại không thay đổi qua các lần đánh giá liên tiếp. Mô hình hoạt động tốt nhất do FLAML lựa chọn là bộ hồi quy XGBoost (learning rate = 0.1403; n_estimators = 379; max_leaves = 13; điều chỉnh L1/L2 $\alpha = 0.0995$, $\lambda = 0.0010$), với subsample = 0.85 và colsample_bytree = 0.83. Cấu hình này cân bằng độ chệch–phương sai bằng cách kết hợp tốc độ học vừa phải với độ phức tạp cây được giới hạn và cơ chế điều chuẩn. Không gian tìm kiếm đầy đủ và các siêu tham số được chọn cho XGBoost cùng tất cả các bộ học cơ sở được tóm tắt trong Bảng S1 của SI.

2.4. Comparative benchmarking and statistical validation

Để đặt hiệu suất vào bối cảnh, mô hình XGBoost được tối ưu hóa bằng FLAML đã được so sánh với năm mô hình hồi quy thường dùng: Cây quyết định (DT), Rừng ngẫu nhiên (RF), Cây quyết định tăng cường độ dốc (GBDT), Học sâu (DL) và k-Láng giềng gần nhất (KNN). Mỗi mô hình được đánh giá trên cùng một tập dữ liệu đã mã hóa one-hot và được áp dụng các lần chia tập huấn luyện–kiểm tra phân tầng giống hệt nhau nhằm đảm bảo tính nhất quán về phương pháp

parity. Model assessment employed ten independent repetitions of the stratified 80:20 partition to quantify stability across split realizations. For each repetition, five metrics were computed: root mean squared error (RMSE), mean absolute error (MAE), mean absolute percentage error (MAPE), correlation coefficient (CC; Pearson's r), and coefficient of determination (R^2). RMSE, MAE, and MAPE quantify error magnitude, whereas CC (r) and R^2 summarize association and explained variance. Statistical significance of pairwise differences was evaluated with paired two-tailed t -tests ($\alpha = 0.01$) across the ten repetitions, using Bonferroni correction to control the family-wise error rate. Cohen's d was additionally reported to quantify effect sizes. This protocol provides a split-robust comparison under identical data and preprocessing conditions, aligning the benchmarking with the data-splitting framework described in [Section 2.2](#).

2.5. Interpretability via SHAP analysis

Model interpretability was assessed using SHapley Additive exPlanations (SHAP), which attribute to each feature its marginal contribution to individual predictions under the cooperative game-theoretic formulation. SHAP values were computed for the trained XGBoost model and summarized as grouped importances by aggregating the absolute SHAP values across the one-hot levels of each parent categorical variable (anode, cathode, electrolyte, water matrix). Given the observed interdependence among electrochemical predictors ([Figures S1 & S2](#)), the potential influence of correlation on TreeSHAP attributions was examined by comparing the grouped SHAP ranking with a correlation-aware conditional permutation importance (CPI) analysis. Conditional permutation importance was computed by conditionally resampling within strata of correlated predictors to attenuate correlation bias. Agreement was quantified using Kendall's τ with 95 % confidence intervals in [Table S2](#). Together, they provide a transparent, correlation-contextualized view of feature influence relevant to treatment design and electrochemical optimization.

To probe stability and dose–response behaviour, we implemented two additional analyses. First, SHAP dependence plots were generated for the three most influential continuous variables (electrolysis time, electrolyte concentration, and current density), with point colour used to show interactions with a secondary electrochemical parameter. Second, a leave-one-out (LOO) stability test was conducted on grouped mean |SHAP|: feature rankings were obtained on the full dataset, then the top-ranked feature (electrolysis time) was removed and SHAP importances were recomputed on the reduced dataset. Agreement between the two rankings was summarized using Kendall's τ .

2.6. Reproducibility and deployment considerations

All computations were executed in Python 3.10 using version-controlled dependencies: FLAML 1.2.0, SHAP 0.44.0, and scikit-learn 1.4.0. The entire modeling pipeline was encapsulated in a Docker container to guarantee cross-platform reproducibility and facilitate peer validation. This containerized approach marks a significant improvement over the untracked scripting environments used in earlier electrochemical machine learning studies.

2.7. Methodological contributions and distinctions

Relative to Alnaimat et al. [30], this study introduces a cost-aware, fully automated model-selection workflow (FLAML) in place of manual/grid tuning ([Table S1](#)), a split-robust benchmarking protocol with repeated evaluations and formal significance/effect-size testing, and a correlation-contextualized interpretability scheme that reports grouped TreeSHAP alongside conditional permutation importance with agreement statistics ([Table S2](#)). The pipeline is containerized with pinned dependencies to enable end-to-end reproducibility. Taken together, these elements provide a transparent, efficient, and reproducible

methodology tailored to electrochemical treatment datasets, clarifying performance gains and interpretability under documented assumptions and validation settings.

3. Results and discussion

3.1. Model performance and statistical validation

The FLAML-optimized XGBoost model demonstrated exceptional predictive performance in modeling PFOA electrochemical oxidation efficiency, significantly outperforming all baseline models across every evaluation metric ([Table 1](#)). The FLAML-optimized XGBoost achieved an RMSE of 3.97 ± 0.45 and R^2 of 0.98 ± 0.01 , representing a 51 % reduction in prediction error and 7 % improvement in explained variance compared to the best-performing baseline model (Random Forest: RMSE = 8.05 ± 1.02 , $R^2 = 0.91 \pm 0.02$). This performance advantage was statistically significant across all metrics ($p < 10^{-5}$), as confirmed by paired t -tests ([Table 2](#)), with particularly pronounced differences against gradient boosting decision trees ($p < 1.1 \times 10^{-8}$ for RMSE) and deep learning approaches ($p < 2.8 \times 10^{-9}$ for RMSE). The ranking analysis ([Table 3](#)) further corroborated the FLAML-optimized XGBoost model's consistent superiority, securing first place across all performance metrics with an average rank of 1.0, while Random Forest ranked second (average rank = 2.2).

These results establish FLAML as a highly effective tool for electrochemical process modeling, achieving accuracy levels that previously required extensive manual tuning. The performance aligns with recent demonstrations of AutoML's capacity to reduce computational costs while maintaining accuracy in complex environmental systems [28,29]. Notably, FLAML accomplished this within a 300-second optimization budget. This represents a 72 % reduction in tuning time compared to conventional grid search implementations described in the original study [30]. This efficiency addresses critical computational barriers in environmental research, where resource constraints often limit model optimization [23].

Robustness to overfitting was assessed using ten independent repetitions of the stratified 80:20 holdout. Stable test-set performance across repetitions supports reliable generalization; protocol stability is documented in SI [Figure S4](#) (stratification sensitivity) and the internal selection procedure in SI [Figure S5](#) (nested CV diagnostics). Learning curves ([Fig. 1](#)) show a monotonically decreasing validation RMSE with diminishing returns and a modest, stable train–validation gap (≈ 3 –4 RMSE units at the largest training size), indicating no divergence or overfitting under the reported protocol.

Residual distribution analysis ([Fig. 2](#)) provided deeper insights into model reliability. FLAML exhibited the most symmetric and tightly distributed residuals (interquartile range ≈ 6 %), indicating minimal systematic bias and consistent predictive accuracy across the operational parameter space. In contrast, traditional algorithms displayed broader residual distributions with notable outliers: k-nearest neighbors showed extreme negative residuals (< -70 %), while deep learning approaches exhibited positive bias tendencies. This precision is critical for reactor design applications where prediction uncertainty propagates through energy efficiency calculations [31,32]. The observed residual patterns align with theoretical expectations for cost-aware optimization algorithms that systematically minimize cross-validation error under constrained resources [33].

3.2. Feature importance and electrochemical mechanisms

The SHAP-based feature importance assessment ([Fig. 3](#)) delivers critical insights into the factors influencing the electrochemical removal efficiency of PFOA. The two machine learning frameworks, FLAML-optimized XGBoost and conventional Random Forest, consistently identify electrolysis time as the most critical factor, registering mean absolute SHAP values of approximately 16.4 and 13.6, respectively. This

tính chắn lẻ. Việc đánh giá mô hình sử dụng mười lần lặp độc lập của phép chia phân tầng 80:20 để định lượng độ ổn định giữa các lần chia dữ liệu. Với mỗi lần lặp, năm chỉ số được tính toán: sai số bình phương trung bình căn (RMSE), sai số tuyệt đối trung bình (MAE), sai số phần trăm tuyệt đối trung bình (MAPE), hệ số tương quan (CC; r của Pearson) và hệ số xác định (R^2). RMSE, MAE và MAPE định lượng độ lớn sai số, trong khi CC (r) và R^2 tóm tắt mức độ liên hệ và phương sai được giải thích. Ý nghĩa thống kê của các khác biệt theo cặp được đánh giá bằng các phép kiểm định t hai phía có ghép cặp ($\alpha = 0.01$) trên mười lần lặp, sử dụng hiệu chỉnh Bonferroni để kiểm soát tỷ lệ sai số toàn cục. Cohen's d cũng được báo cáo để định lượng kích thước hiệu ứng. Quy trình này cung cấp phép so sánh vững chắc về cách chia dữ liệu trong cùng điều kiện dữ liệu và tiền xử lý, qua đó giúp việc đánh giá chuẩn phù hợp với khuôn khổ chia dữ liệu được mô tả tại Mục 2.2.

2.5. Interpretability via SHAP analysis

Khả năng diễn giải của mô hình được đánh giá bằng phương pháp SHAP (giải thích cộng tính Shapley), trong đó quy cho mỗi đặc trưng phần đóng góp biên của nó vào từng dự đoán theo khuôn khổ lý thuyết trò chơi hợp tác. Giá trị SHAP được tính cho mô hình XGBoost đã huấn luyện và được tóm tắt thành mức độ quan trọng theo nhóm bằng cách cộng góp giá trị SHAP tuyệt đối trên các mức mã hóa one-hot của từng biến phân loại cha (anốt, catốt, chất điện phân, nền nước). Xét đến sự phụ thuộc lẫn nhau được quan sát giữa các biến dự đoán điện hóa (Hình S1 và S2), ảnh hưởng tiềm tàng của tương quan đến các giá trị quy kết TreeSHAP được khảo sát bằng cách so sánh thứ hạng SHAP theo nhóm với phân tích mức độ quan trọng của phép hoán vị có điều kiện, có xét đến tương quan (CPI). Mức độ quan trọng của phép hoán vị có điều kiện được tính bằng cách lấy mẫu lại có điều kiện trong các tầng của những biến dự đoán tương quan nhằm giảm thiểu sai lệch do tương quan. Mức độ đồng thuận được định lượng bằng hệ số Kendall τ , với khoảng tin cậy 95% trong Bảng S2. Kết hợp lại, các phương pháp này cung cấp cái nhìn minh bạch, có xét đến bối cảnh tương quan về ảnh hưởng của các đặc trưng, hữu ích cho việc thiết kế xử lý và tối ưu hóa điện hóa.

Để khảo sát độ ổn định và hành vi liều–đáp ứng, chúng tôi thực hiện thêm hai phân tích. Thứ nhất, các biểu đồ phụ thuộc SHAP được tạo cho ba biến liên tục có ảnh hưởng lớn nhất (thời gian điện phân, nồng độ chất điện ly và mật độ dòng điện), trong đó màu sắc của điểm biểu thị tương tác với một thông số điện hóa thứ cấp. Thứ hai, phép kiểm tra độ ổn định loại bỏ từng biến một (LOO) được thực hiện trên giá trị trung bình |SHAP| theo nhóm: thứ hạng đặc trưng được xác định trên toàn bộ tập dữ liệu, sau đó đặc trưng xếp hạng cao nhất (thời gian điện phân) được loại bỏ và mức độ quan trọng SHAP được tính lại trên tập dữ liệu rút gọn. Mức độ tương đồng giữa hai thứ hạng được tóm tắt bằng τ .

2.6. Reproducibility and deployment considerations

Tất cả các phép tính được thực hiện bằng Python 3.10 với các thư viện phụ thuộc được quản lý phiên bản: FLAML 1.2.0, SHAP 0.44.0 và scikit-learn 1.4.0. Toàn bộ quy trình mô hình hóa được đóng gói trong một container Docker nhằm bảo đảm khả năng tái lập trên nhiều nền tảng và tạo điều kiện cho việc thẩm định ngang hàng. Cách tiếp cận dựa trên container này là một cải tiến đáng kể so với các mô hình chạy tập lệnh không được quản lý phiên bản từng được sử dụng trong các nghiên cứu học máy điện hóa trước đây.

2.7. Methodological contributions and distinctions

So với Alnaimat và cộng sự [30], nghiên cứu này đưa ra quy trình lựa chọn mô hình hoàn toàn tự động và có xét đến chi phí (FLAML) thay cho việc tinh chỉnh thủ công/theo lưới (Bảng S1), một quy trình đánh giá chuẩn vững trước các cách chia dữ liệu với các lần đánh giá lặp lại và kiểm định chính thức về ý nghĩa thống kê/kích thước hiệu ứng, cùng một phương pháp diễn giải có xét đến bối cảnh tương quan, báo cáo TreeSHAP theo nhóm song song với tầm quan trọng hoán vị có điều kiện và các thống kê mức độ đồng thuận (Bảng S2). Quy trình được đóng gói trong container với các phần phụ thuộc được xác định phiên bản để bảo đảm khả năng tái lập từ đầu đến cuối. Xét tổng thể, những yếu tố này tạo nên một phương pháp minh bạch, hiệu quả và có khả năng tái lập

phương pháp luận được điều chỉnh phù hợp với các bộ dữ liệu xử lý điện hóa, làm rõ mức cải thiện hiệu năng và khả năng diễn giải trong các giả định và thiết lập xác thực đã được ghi nhận.

3. Kết quả và thảo luận

3.1. Model performance and statistical validation

Mô hình XGBoost được FLAML tối ưu hóa cho thấy hiệu suất dự đoán vượt trội trong việc mô hình hóa hiệu suất oxy hóa điện hóa PFOA, vượt xa tất cả các mô hình cơ sở trên mọi chỉ số đánh giá (Bảng 1). XGBoost được FLAML tối ưu hóa đạt RMSE là 3.97 ± 0.45 và R^2 là 0.98 ± 0.01 , tương ứng với mức giảm 51 % sai số dự đoán và mức cải thiện 7 % về phương sai được giải thích so với mô hình cơ sở có hiệu suất tốt nhất (Random Forest: RMSE = 8.05 ± 1.02 , $R^2 = 0.91 \pm 0.02$). Ưu thế về hiệu suất này có ý nghĩa thống kê trên tất cả các chỉ số ($p < 10^{-5}$), như được xác nhận bằng các kiểm định t ghép cặp (Bảng 2), với khác biệt đặc biệt rõ rệt so với các cây quyết định tăng cường gradient ($p < 1.1 \times 10^{-8}$ đối với RMSE) và các phương pháp học sâu ($p < 2.8 \times 10^{-9}$ đối với RMSE). Phân tích xếp hạng (Bảng 3) tiếp tục xác nhận ưu thế nhất quán của mô hình XGBoost được FLAML tối ưu hóa, đứng đầu ở tất cả các chỉ số hiệu suất với thứ hạng trung bình là 1,0, trong khi Random Forest đứng thứ hai (thứ hạng trung bình = 2,2).

Những kết quả này khẳng định FLAML là một công cụ rất hiệu quả để mô hình hóa các quá trình điện hóa, đạt độ chính xác mà trước đây đòi hỏi phải tinh chỉnh thủ công trên diện rộng. Hiệu năng này phù hợp với những minh chứng gần đây về khả năng của AutoML trong việc giảm chi phí tính toán mà vẫn duy trì độ chính xác trong các hệ thống môi trường phức tạp [28,29]. Đáng chú ý, FLAML đạt được điều này trong ngân sách tối ưu hóa 300 giây. Đây là mức giảm 72 % thời gian tinh chỉnh so với các phương pháp triển khai tìm kiếm lưới thông thường được mô tả trong nghiên cứu ban đầu [30]. Hiệu quả này góp phần giải quyết những rào cản tính toán trọng yếu trong nghiên cứu môi trường, nơi các hạn chế về nguồn lực thường gây trở ngại cho việc tối ưu hóa mô hình [23].

Độ vững trước hiện tượng quá khớp được đánh giá qua mười lần lặp độc lập của phép chia giữ lại phân tầng 80:20. Hiệu suất ổn định trên tập kiểm tra qua các lần lặp cho thấy khả năng khái quát hóa đáng tin cậy; độ ổn định của quy trình được ghi lại trong Hình S4 của SI (độ nhạy với phân tầng), còn quy trình lựa chọn nội bộ được trình bày trong Hình S5 của SI (chẩn đoán CV lồng nhau). Các đường cong học tập (Hình 1) cho thấy RMSE xác thực giảm đơn điệu với mức cải thiện ngày càng nhỏ và khoảng cách huấn luyện–xác thực khi êm tốn, ổn định (≈ 3 –4 đơn vị RMSE ở kích thước tập huấn luyện lớn nhất), cho thấy không có sự phân kỳ hay quá khớp theo quy trình được báo cáo.

Phân tích phân bố phần dư (Hình 2) cung cấp những hiểu biết sâu hơn về độ tin cậy của mô hình. FLAML có phần dư phân bố chặt chẽ và đối xứng nhất (khoảng tứ phân vị ≈ 6 %), cho thấy độ lệch hệ thống ở mức tối thiểu và độ chính xác dự đoán nhất quán trên toàn bộ không gian tham số vận hành. Ngược lại, các thuật toán truyền thống có phân bố phần dư rộng hơn, với các giá trị ngoại lệ đáng kể: phương pháp k láng giềng gần nhất cho thấy phần dư âm cực lớn (< -70 %), trong khi các phương pháp học sâu có xu hướng thiên lệch dương. Độ chính xác này rất quan trọng trong các ứng dụng thiết kế lò phản ứng, nơi độ bất định của dự đoán lan truyền qua các phép tính hiệu suất năng lượng [31,32]. Các mô hình phần dư quan sát được phù hợp với kỳ vọng lý thuyết về các thuật toán tối ưu hóa có xét đến chi phí, vốn giảm thiểu một cách có hệ thống sai số kiểm định chéo trong điều kiện tài nguyên hạn chế [33].

3.2. Feature importance and electrochemical mechanisms

Đánh giá mức độ quan trọng của các đặc trưng dựa trên SHAP (Hình 3) cung cấp những hiểu biết quan trọng về các yếu tố ảnh hưởng đến hiệu suất loại bỏ PFOA bằng phương pháp điện hóa. Hai mô hình học máy, XGBoost được tối ưu hóa bằng FLAML và Random Forest truyền thống, đều nhất quán xác định thời gian điện phân là yếu tố quan trọng nhất, với giá trị SHAP tuyệt đối trung bình lần lượt xấp xỉ 16,4 và 13,6. Điều này

Table 1
Mean ± Std Dev of each metric across 10 runs.

Index	RMSE	MAE	MAPE	CC	R ²
DT	10.31 ± 2.17	7.33 ± 1.11	24.75 ± 13.5	0.93 ± 0.03	0.86 ± 0.07
RF	8.05 ± 1.02	5.97 ± 0.57	25.17 ± 10.94	0.96 ± 0.01	0.91 ± 0.02
GBDT	9.35 ± 0.77	7.49 ± 0.58	32.39 ± 10.18	0.95 ± 0.01	0.89 ± 0.01
DL	12.41 ± 1.46	8.9 ± 0.55	51.78 ± 32.25	0.9 ± 0.02	0.8 ± 0.05
KNN	19.6 ± 2.38	14.35 ± 1.38	101.09 ± 51.01	0.71 ± 0.06	0.49 ± 0.11
FLAML-optimized XGBoost	3.97 ± 0.45	2.93 ± 0.31	10.02 ± 3.08	0.99 ± 0.0	0.98 ± 0.01

DT, decision tree; RF, random forest; GBDT, gradient boosting decision tree; DL, deep learning; KNN, k-nearest neighbors; FLAML-optimized XGBoost, fast lightweight AutoML-optimized extreme gradient boosting model; RMSE, root mean square error; MAE, mean absolute error; MAPE, mean absolute percentage error; CC, correlation coefficient; R², coefficient of determination.

Table 2
Paired *t*-test p-values (comparing each model vs. FLAML-optimized XGBoost).

	RMSE	MAE	MAPE	CC	R ²
DT	3.20401610 × 10 ^{−6}	3.111270 × 10 ^{−7}	0.004675	1.247765 × 10 ^{−4}	1.414884 × 10 ^{−4}
RF	9.616685 × 10 ^{−7}	1.547798 × 10 ^{−7}	0.000610	2.953061 × 10 ^{−5}	1.260622 × 10 ^{−5}
GBDT	1.106071 × 10 ^{−8}	5.052537 × 10 ^{−9}	0.000009	2.678730 × 10 ^{−8}	1.228068 × 10 ^{−8}
DL	2.846609 × 10 ^{−9}	3.311756 × 10 ^{−11}	0.001801	3.080667 × 10 ^{−7}	4.826925 × 10 ^{−7}
KNN	6.734575 × 10 ^{−9}	1.336126 × 10 ^{−9}	0.000225	2.164031 × 10 ^{−7}	1.738757 × 10 ^{−7}

DT, decision tree; RF, random forest; GBDT, gradient boosting decision tree; DL, deep learning; KNN, k-nearest neighbors; FLAML-optimized XGBoost, fast lightweight AutoML-optimized extreme gradient boosting model; RMSE, root mean square error; MAE, mean absolute error; MAPE, mean absolute percentage error; CC, correlation coefficient; R², coefficient of determination.

Table 3
Average ranking of models across metrics.

	RMSE	MAE	MAPE	CC	R ²	Average Rank
FLAML-optimized XGBoost	1.0	1.0	1.0	1.0	1.0	1.0
RF	2.0	2.0	3.0	2.0	2.0	2.2
DT	4.0	3.0	2.0	4.0	4.0	3.4
GBDT	3.0	4.0	4.0	3.0	3.0	3.4
DL	5.0	5.0	5.0	5.0	5.0	5.0
KNN	6.0	6.0	6.0	6.0	6.0	6.0

DT, decision tree; RF, random forest; GBDT, gradient boosting decision tree; DL, deep learning; KNN, k-nearest neighbors; FLAML-optimized XGBoost, fast lightweight AutoML-optimized extreme gradient boosting model; RMSE, root mean square error; MAE, mean absolute error; MAPE, mean absolute percentage error; CC, correlation coefficient; R², coefficient of determination.

observation is consistent with fundamental electrochemical oxidation theory, which underscores the dependency of pollutant degradation efficacy on the cumulative applied charge, a function directly proportional to electrolysis duration [34]. Electrolysis time governs the generation and sustained availability of reactive oxidants, primarily hydroxyl radicals (•OH), instrumental in initiating and perpetuating the mineralization of highly stable contaminants like PFOA [35,36]. Interpretation considers observed correlations among inputs (SI Figures S1–S2) and agreement statistics with conditional permutation importance (SI Table S2).

A notable divergence is observed for the anode factor. In the FLAML-optimized XGBoost model, Anode ranks second (mean |SHAP| ≈ 12.1 % age points), whereas its influence is much lower in the tuned Random Forest (mean |SHAP| ≈ 1.5–2.0). This elevated anode signal is mechanistically plausible given the superior radical generation on high-OER-overpotential anodes (e.g., BDD) during PFAS electro-oxidation. Because grouped TreeSHAP is used in both panels of Fig. 3, the discrepancy is ascribed to model capacity rather than the importance metric: XGBoost captures non-linear and interaction effects (e.g., Anode x Current Density) that are diluted when Random Forest averages across trees. For context, Alnaimat et al. [30] likewise reported low anode importance using Gini/permutation measures on a conventional RF model, which are different constructs than SHAP. While this finding is

robust, importance magnitudes remain model- and correlation-dependent; agreement with conditional permutation importance is reported in SI Table S2.

Following Anode, the XGBoost model highlights Electrolyte Concentration in the next tier of importance (mean SHAP ≈ 6.5). Electrolyte concentration directly modulates the solution’s conductivity, subsequently affecting the efficiency of radical production and pollutant oxidation [37]. Oturan and Aaron [38] have documented how optimized ionic strength, achieved through precise electrolyte concentration adjustments, enhances hydroxyl radical production efficiency while limiting undesired side reactions such as oxygen evolution at the anode. This nuanced recognition by the XGBoost model aligns with detailed electrochemical kinetic analyses demonstrating improved degradation efficiencies at moderate electrolyte concentrations due to an optimized balance between ionic mobility and radical-scavenging side reactions [39].

In contrast, the Random Forest model highlights the initial PFOA concentration as the second most influential variable after electrolysis time. While the pollutant initial concentration undoubtedly influences the overall degradation efficacy, primarily via reaction kinetics that follow pseudo-first-order degradation patterns in electrochemical oxidation processes [40], the emphasis on initial concentration in the Random Forest ranking suggests greater sensitivity to direct concentration gradients, whereas the boosted-tree model captures interactions involving electrolyte characteristics. The optimized XGBoost model thus demonstrates enhanced sensitivity towards the subtle yet significant interactions between electrolyte characteristics and electrochemical reaction mechanisms.

Both models attribute significant influence to current density, identified by the SHAP values as approximately 5.9 for XGBoost and 5.2 for Random Forest. The critical role of current density aligns with established electrochemical knowledge; appropriate current densities sustain efficient generation of reactive radicals at the electrode interfaces [41]. However, excessively high current densities have been shown to lead to increased energy consumption and secondary reactions such as oxygen evolution, reducing overall treatment effectiveness [42]. This dual-faceted role of current density highlights the importance of precise operational optimization; the boosted-tree architecture is capable of capturing nonlinear effects and threshold behaviors relevant to this trade-off [43].

Bảng 1 Giá trị trung bình ± và độ lệch chuẩn của mỗi chỉ số qua 10 lần chạy.

Index	RMSE	MAE	MAPE	CC	R ²
DT	10.31 ± 2.17	7.33 ± 1.11	24.75 ± 13.5	0.93 ± 0.03	0.86 ± 0.07
RF	8.05 ± 1.02	5.97 ± 0.57	25.17 ± 10.94	0.96 ± 0.01	0.91 ± 0.02
GBDT	9.35 ± 0.77	7.49 ± 0.58	32.39 ± 10.18	0.95 ± 0.01	0.89 ± 0.01
DL	12.41 ± 1.46	8.9 ± 0.55	51.78 ± 32.25	0.9 ± 0.02	0.8 ± 0.05
KNN	19.6 ± 2.38	14.35 ± 1.38	101.09 ± 51.01	0.71 ± 0.06	0.49 ± 0.11
FLAML-optimized XGBoost	3.97 ± 0.45	2.93 ± 0.31	10.02 ± 3.08	0.99 ± 0.0	0.98 ± 0.01

DT, cây quyết định; RF, rừng ngẫu nhiên; GBDT, cây quyết định tăng cường gradient; DL, học sâu; KNN, k láng giềng gần nhất; XGBoost được FLAML tối ưu hóa, mô hình tăng cường gradient cực đại được tối ưu hóa bằng AutoML nhanh và nhẹ; RMSE, căn bậc hai của sai số bình phương trung bình; MAE, sai số tuyệt đối trung bình; MAPE, sai số phần trăm tuyệt đối trung bình; CC, hệ số tương quan; R², hệ số xác định.

Bảng 2 Giá trị p của kiểm định t ghép cặp *t* (so sánh từng mô hình với XGBoost được tối ưu hóa bằng FLAML).

	RMSE	MAE	MAPE	CC	R ²
DT	3.20401610 × 10 ^{−6}	3.111270 × 10 ^{−7}	0.004675	1.247765 × 10 ^{−4}	1.414884 × 10 ^{−4}
RF	9.616685 × 10 ^{−7}	1.547798 × 10 ^{−7}	0.000610	2.953061 × 10 ^{−5}	1.260622 × 10 ^{−5}
GBDT	1.106071 × 10 ^{−8}	5.052537 × 10 ^{−9}	0.000009	2.678730 × 10 ^{−8}	1.228068 × 10 ^{−8}
DL	2.846609 × 10 ^{−9}	3.311756 × 10 ^{−11}	0.001801	3.080667 × 10 ^{−7}	4.826925 × 10 ^{−7}
KNN	6.734575 × 10 ^{−9}	1.336126 × 10 ^{−9}	0.000225	2.164031 × 10 ^{−7}	1.738757 × 10 ^{−7}

DT, cây quyết định; RF, rừng ngẫu nhiên; GBDT, cây quyết định tăng cường gradient; DL, học sâu; KNN, k láng giềng gần nhất; XGBoost được FLAML tối ưu hóa, mô hình tăng cường gradient cực đại được tối ưu hóa bằng AutoML nhanh và nhẹ; RMSE, căn bậc hai của sai số bình phương trung bình; MAE, sai số tuyệt đối trung bình; MAPE, sai số phần trăm tuyệt đối trung bình; CC, hệ số tương quan; R², hệ số xác định.

Bảng 3 Thứ hạng trung bình của các mô hình trên các chỉ số.

	RMSE	MAE	MAPE	CC	R ²	Average Rank
FLAML-optimized XGBoost	1.0	1.0	1.0	1.0	1.0	1.0
RF	2.0	2.0	3.0	2.0	2.0	2.2
DT	4.0	3.0	2.0	4.0	4.0	3.4
GBDT	3.0	4.0	4.0	3.0	3.0	3.4
DL	5.0	5.0	5.0	5.0	5.0	5.0
KNN	6.0	6.0	6.0	6.0	6.0	6.0

DT, cây quyết định; RF, rừng ngẫu nhiên; GBDT, cây quyết định tăng cường độ dốc; DL, học sâu; KNN, k láng giềng gần nhất; XGBoost được tối ưu hóa bằng FLAML, mô hình tăng cường độ dốc cực đại được tối ưu hóa bằng AutoML nhanh và nhẹ; RMSE, căn bậc hai của sai số bình phương trung bình; MAE, sai số tuyệt đối trung bình; MAPE, sai số phần trăm tuyệt đối trung bình; CC, hệ số tương quan; R², hệ số xác định.

quan sát này phù hợp với lý thuyết oxy hóa điện hóa cơ bản, nhấn mạnh rằng hiệu quả phân hủy chất ô nhiễm phụ thuộc vào tổng điện lượng được cung cấp, đại lượng tỷ lệ thuận trực tiếp với thời gian điện phân [34]. Thời gian điện phân chi phối quá trình hình thành và duy trì sự hiện diện của các chất oxy hóa hoạt tính, chủ yếu là các gốc hydroxyl (•OH), đóng vai trò quan trọng trong việc khởi phát và duy trì quá trình khoáng hóa các chất ô nhiễm có độ bền cao như PFOA [35,36]. Việc diễn giải xem xét các mối tương quan quan sát được giữa các biến đầu vào (SI Figures S1–S2) và các số liệu thống kê về mức độ phù hợp với độ quan trọng của phép hoán vị có điều kiện (SI Table S2).

Có sự khác biệt đáng kể ở yếu tố Anode. Trong mô hình XGBoost được tối ưu hóa bằng FLAML, Anode đứng thứ hai (giá trị trung bình |SHAP| ≈ 12.1 % điểm tuổi), trong khi ảnh hưởng của yếu tố này thấp hơn nhiều trong mô hình Random Forest được tinh chỉnh (giá trị trung bình |SHAP| ≈ 1.5–2.0). Tín hiệu Anode cao này hợp lý về mặt cơ chế, xét đến khả năng tạo gốc tự do vượt trội trên các anode có quá thế OER cao (ví dụ: BDD) trong quá trình điện oxy hóa PFAS. Vì cả hai biểu đồ trong Hình 3 đều sử dụng TreeSHAP theo nhóm, sự khác biệt này được cho là xuất phát từ năng lực của mô hình chứ không phải từ thước đo mức độ quan trọng: XGBoost nắm bắt được các hiệu ứng phi tuyến và tương tác (ví dụ: Anode × Mật độ dòng điện), vốn bị làm suy giảm khi Random Forest lấy trung bình trên các cây. Để đối chiếu, Alnaimat và cộng sự [30] cũng báo cáo mức độ quan trọng thấp của anode khi sử dụng các thước đo Gini/hoán vị trên mô hình RF thông thường; đây là những khái niệm khác với SHAP. Mặc dù phát hiện này là

vững chắc, độ lớn mức độ quan trọng vẫn phụ thuộc vào mô hình và mối tương quan; sự nhất quán với mức độ quan trọng của phép hoán vị có điều kiện được trình bày trong Bảng S2 của Tài liệu bổ sung.

Sau Anode, mô hình XGBoost xác định Nồng độ chất điện ly là yếu tố quan trọng tiếp theo (giá trị SHAP trung bình ≈ 6.5). Nồng độ chất điện ly trực tiếp điều chỉnh độ dẫn điện của dung dịch, từ đó ảnh hưởng đến hiệu suất tạo gốc tự do và oxy hóa chất ô nhiễm [37]. Oturan và Aaron [38] đã ghi nhận rằng việc tối ưu hóa lực ion thông qua điều chỉnh chính xác nồng độ chất điện ly giúp nâng cao hiệu suất tạo gốc hydroxyl, đồng thời hạn chế các phản ứng phụ không mong muốn như quá trình tạo oxy ở anot. Nhận định tinh tế này của mô hình XGBoost phù hợp với các phân tích động học điện hóa chi tiết, cho thấy hiệu suất phân hủy được cải thiện ở nồng độ chất điện ly vừa phải nhờ sự cân bằng tối ưu giữa độ linh động của ion và các phản ứng phụ tiêu thụ gốc tự do [39].

Ngược lại, mô hình Random Forest cho thấy nồng độ PFOA ban đầu là biến có mức độ ảnh hưởng lớn thứ hai, sau thời gian điện phân. Mặc dù nồng độ ban đầu của chất ô nhiễm chắc chắn ảnh hưởng đến hiệu quả phân hủy tổng thể, chủ yếu thông qua động học phản ứng tuân theo các mô hình phân hủy giả nhất định trong các quá trình oxy hóa điện hóa [40], việc nồng độ ban đầu được xếp hạng cao trong mô hình Random Forest cho thấy mô hình này nhạy hơn với các gradient nồng độ trực tiếp, trong khi mô hình cây tăng cường nắm bắt được các tương tác liên quan đến đặc tính chất điện ly. Do đó, mô hình XGBoost được tối ưu hóa cho thấy độ nhạy cao hơn đối với những tương tác tinh tế nhưng đáng kể giữa đặc tính chất điện ly và cơ chế phản ứng điện hóa.

Cả hai mô hình đều cho thấy mật độ dòng điện có ảnh hưởng đáng kể, với giá trị SHAP xấp xỉ 5,9 đối với XGBoost và 5,2 đối với Random Forest. Vai trò then chốt của mật độ dòng điện phù hợp với kiến thức điện hóa đã được xác lập; mật độ dòng điện thích hợp duy trì quá trình tạo ra các gốc phản ứng hiệu quả tại các bề mặt phân cách điện cực [41]. Tuy nhiên, mật độ dòng điện quá cao được chứng minh là làm tăng mức tiêu thụ năng lượng và các phản ứng phụ như sự hình thành oxy, từ đó làm giảm hiệu quả xử lý tổng thể [42]. Vai trò của hai mật này của mật độ dòng điện nhấn mạnh tầm quan trọng của việc tối ưu hóa chính xác các thông số vận hành; kiến trúc cây tăng cường có khả năng nắm bắt các tác động phi tuyến và hành vi ngưỡng liên quan đến sự đánh đổi này [43].




Fig. 1. Learning curves (train/validation RMSE vs. training size) for FLAML-optimized XGBoost.






Fig. 2. Box plot of residuals for each model.

Further examination of SHAP values indicates a moderate yet meaningful influence for initial solution pH, consistent with electrochemical fundamentals. Solution pH critically impacts electrode surface chemistry and radical speciation, thereby modulating radical stability and reactivity [34,41]. The observed moderate importance attributed to temperature confirms previous experimental findings indicating that,

within operationally relevant ranges, temperature influences on electrochemical oxidation are relatively subtle compared to electrochemical parameters such as electrolyte concentration and current density [44]. The divergence between the two modeling approaches, FLAML-optimized XGBoost and Random Forest, in their feature-ranking profile underscores differences in their algorithmic architectures. XGBoost's



Hình 1. Đường cong học tập (RMSE trên tập huấn luyện/tập xác thực theo kích thước tập huấn luyện) của XGBoost được tối ưu hóa bằng FLAML.



Hình 2. Biểu đồ hộp của phần dư cho từng mô hình.

Phân tích sâu hơn về các giá trị SHAP cho thấy pH ban đầu của dung dịch có ảnh hưởng ở mức vừa phải nhưng đáng kể, phù hợp với các nguyên lý cơ bản của điện hóa. pH dung dịch tác động đáng kể đến hóa học bề mặt điện cực và dạng tồn tại của các gốc tự do, qua đó điều chỉnh độ ổn định và khả năng phản ứng của chúng [34,41]. Mức độ quan trọng vừa phải được ghi nhận của nhiệt độ xác nhận các kết quả thực nghiệm trước đây cho thấy rằng,

Trong các phạm vi có ý nghĩa về mặt vận hành, ảnh hưởng của nhiệt độ đến quá trình oxy hóa điện hóa tương đối nhỏ so với các thông số điện hóa như nồng độ chất điện phân và mật độ dòng điện [44]. Sự khác biệt giữa hai phương pháp mô hình hóa, XGBoost được tối ưu hóa bằng FLAML và Random Forest, trong hồ sơ xếp hạng đặc trưng của chúng làm nổi bật sự khác nhau trong kiến trúc thuật toán. XGBoost's





Fig. 3. Grouped SHAP feature importance for XGBoost (FLAML-optimized) and Random Forest.



Hình 3. Mức độ quan trọng của các đặc trưng SHAP được nhóm cho XGBoost (tối ưu hóa bằng FLAML) và Random Forest.





Fig. 4. SHAP dependence plots for (A) electrolysis time coloured by current density, (B) electrolyte concentration coloured by electrolysis time, and (C) current density coloured by electrolysis time. Each point represents one experiment; the x-axis shows the feature value and the y-axis the SHAP contribution to removal (percentage points).



Hình 4 Biểu đồ phụ thuộc SHAP cho (A) thời gian điện phân được tô màu theo mật độ dòng điện, (B) nồng độ chất điện phân được tô màu theo thời gian điện phân và mật độ dòng điện. Mỗi điểm đại diện cho một thí nghiệm; trục x biểu thị giá trị đặc trưng và trục y biểu thị mức đóng góp SHAP vào quá trình điện phân (phần trăm).

boosted-tree algorithm, through iterative fitting and robust regularization, inherently prioritizes capturing complex nonlinear interactions and subtle threshold effects [43]. Conversely, Random Forest averages the effects of individual features across its ensemble, thereby potentially diluting nuanced feature importance differences and underestimating interactions.

The automated hyperparameter optimization provided by FLAML significantly enhanced the accuracy and interpretability of the XGBoost model. Unlike manual tuning procedures, FLAML automatically identifies optimal complexity constraints and regularization terms, ensuring that the selected model configurations simultaneously achieve high predictive performance and generalizability [27]. This methodological enhancement bridges the gap between predictive modeling and mechanistic electrochemical theory, offering valuable insights into underlying degradation kinetics and operational optimization strategies. Second-tier rank stability is consistent with repeated runs used in the evaluation protocol (Section 2.2).

3.3. Dose–response patterns and stability of SHAP explanations

Within-dataset dose–response behavior for the main continuous variables is shown in Fig. 4A–C. The SHAP dependence for electrolysis time (Fig. 4A) is strongly monotonic: very short times give negative contributions to removal, whereas longer electrolysis times progressively increase the SHAP contribution and then plateau at about 20–30 %age points, in line with the effect of cumulative charge. Electrolyte concentration (Fig. 4B) shows a threshold pattern: sub-optimal concentrations are associated with negative contributions, while moderate concentrations shift SHAP values towards neutral or positive, with little additional gain and occasional penalties at the highest tested levels. For current density (Fig. 4C), SHAP values increase approximately monotonically, with low current densities giving near-zero or negative contributions and higher current densities yielding increasingly positive contributions, again with signs of diminishing returns at the upper end of the range.

Figure S6 reports a leave-one-out stability analysis of grouped mean |SHAP|. When the electrolysis time, the top-ranked feature, is removed and the model is refit, anode and current density remain in the leading tier, while initial pH, cathode, temperature, and electrode spacing remain in the mid-/low-importance tier. The Kendall’s τ between the two rankings is 0.600 ($p = 0.136$), indicating moderate concordance given the small number of features. These results support a stable feature hierarchy, with electrolysis time, anode, and current density as the dominant drivers, while all SHAP values are explicitly interpreted as model-based attributions rather than causal effects.

3.4. Implications for PFAS treatment optimization

The feature importance results provide actionable guidance for electrochemical reactor design. The dominance of electrolysis time indicates that removal gains are primarily governed by cumulative charge passage; operational planning should prioritize sufficient reaction time within energy and throughput constraints. Anode selection appears as a high-influence factor in the XGBoost ranking (Fig. 3), consistent with literature reports of material-dependent radical generation; specific material choices should be matched to the targeted current-density regime and cost constraints, with performance–cost trade-offs evaluated on a case-by-case basis. Water-matrix effects rank low in the grouped SHAP profile (e.g., “Water Matrix” near the bottom of Fig. 3), suggesting that within the studied range, technology transfer to varied matrices may require less re-optimization than electrochemical set-points (subject to validation in new matrices) [45,46].

FLAML’s predictive accuracy supports tighter setpoint control (e.g., current density and time) for energy-aware operation within the tested domain. Quantitative energy projections (e.g., kWh·m^{−3}) are not drawn from the present model outputs and require dedicated electro-energy

auditing under experimental validation. The model’s generalization capability across operational conditions within this dataset suggests potential for transfer-learning extensions to related PFAS (e.g., PFOS, GenX), contingent on coverage of comparable operating ranges and external validation [47].

3.5. Limitations and future directions

Although FLAML demonstrated exceptional predictive accuracy and robustness when applied to the dataset curated by [30], several avenues remain promising for further exploration. First, future research could assess the adaptability of this modeling framework to broader operational parameter spaces and validate its performance using external datasets from different experimental setups. This would also include a wider spectrum of PFAS compounds, such as PFOS and co-contaminants, to ascertain the generalizability of insights across diverse treatment systems. Transfer learning methodologies hold particular promise in this regard, as they could efficiently leverage knowledge from the current model to accelerate predictive capabilities in related electrochemical systems.

Additionally, while the current study prioritized removal efficiency, extending the analytical framework towards integrated multi-objective optimization could significantly enhance practical applicability. Such an extension would consider critical performance indicators beyond contaminant removal, including energy consumption metrics, byproduct formation, and the computational trade-offs between optimization speed and final model performance. Furthermore, enhancing real-time adaptive process control represents another promising direction. Integrating FLAML with in situ sensing technologies would enable dynamic process optimization, facilitating immediate adjustments to operational parameters based on real-time feedback.

Finally, while SHAP analysis provided valuable initial insights, deeper interpretability could be achieved by developing hybrid modeling frameworks that combine FLAML with physics-based electrochemical models. Future methodological refinements could also include exploring the use of native categorical handling within tree-based models as a potential alternative to one-hot encoding. Collectively, these future research directions promise substantial advancements in predictive analytics, interpretability, and operational applicability, reinforcing the potential of AutoML as a transformative approach for environmental electrochemical remediation technologies.

4. Conclusions

This study demonstrates a reproducible AutoML-based workflow for integrating automated machine learning with electrochemical oxidation processes targeting persistent environmental contaminants. The FLAML-driven XGBoost model outperformed conventional manually optimized ML approaches, delivering significantly enhanced predictive accuracy and interpretability, as evidenced by rigorous benchmarking and statistical validation. The analysis identified electrolysis time and anode material as primary operational drivers, offering actionable insights grounded in fundamental electrochemical principles and validated through SHAP-based interpretability. Crucially, the automated FLAML framework substantially reduced computational demands (72 % reduction in tuning time), thereby enhancing the accessibility and reproducibility of advanced ML techniques for environmental practitioners. By demonstrating superior predictive power alongside scientifically robust mechanistic insights, this research directly addresses critical methodological limitations in the current literature. The containerized, version-pinned pipeline ensures reproducibility and transparency, promoting wider adoption and methodological standardization within environmental remediation. Moving forward, integrating the developed methodology with hybrid physics-based models, real-time adaptive process controls, and broader PFAS compound scenarios can further elevate electrochemical treatment efficacy and

thuật toán cây tăng cường, thông qua quá trình khớp lặp và chính quy hóa vững, vốn ưu tiên nắm bắt các tương tác phi tuyến phức tạp và những hiệu ứng ngưỡng tinh tế [43]. Ngược lại, Random Forest lầy trung bình tác động của các đặc trưng riêng lẻ trong toàn bộ tổ hợp cây, do đó có thể làm giảm sự khác biệt tinh tế về tầm quan trọng của các đặc trưng và đánh giá thấp các tương tác.

Việc tối ưu hóa siêu tham số tự động do FLAML cung cấp đã cải thiện đáng kể độ chính xác và khả năng diễn giải của mô hình XGBoost. Không giống như các quy trình tinh chỉnh thủ công, FLAML tự động xác định các ràng buộc về độ phức tạp và các hạng tử điều chu ẩn tối ưu, bảo đảm các cấu hình mô hình được chọn đồng thời đạt hiệu suất dự đoán cao và khả năng khái quát hóa tốt [27]. Cải tiến về phương pháp luận này thu hẹp khoảng cách giữa mô hình hóa dự đoán và lý thuyết điện hóa cơ chế, đồng thời mang lại những hiểu biết có giá trị về động học suy giảm tiềm ẩn và các chiến lược tối ưu hóa vận hành. Độ ổn định thứ hạng ở nhóm thứ hai phù hợp với các lần chạy lặp lại được sử dụng trong quy trình đánh giá (Mục 2.2).

3.3. Dose–response patterns and stability of SHAP explanations

Hành vi đáp ứng theo liều trong từng bộ dữ liệu của các biến liên tục chính được thể hiện trong Hình 4A–C. Mỗi phụ thuộc SHAP của thời gian điện phân (Hình 4A) có tính đơn điệu rõ rệt: thời gian rất ngắn tạo ra đóng góp âm cho hiệu suất loại bỏ, trong khi thời gian điện phân dài hơn làm tăng dần đóng góp SHAP, sau đó đạt trạng thái bão hòa ở khoảng 20–30 điểm phần trăm, phù hợp với tác động của điện lượng tích lũy. Nồng độ chất điện giải (Hình 4B) cho thấy một dạng ngưỡng: nồng độ dưới mức tối ưu gắn với các đóng góp âm, trong khi nồng độ vừa phải làm dịch chuyển giá trị SHAP về mức trung tính hoặc dương, với ít mức tăng thêm và đôi khi có tác động bất lợi ở các mức cao nhất được thử nghiệm. Đối với mật độ dòng điện (Hình 4C), giá trị SHAP tăng gần như đơn điệu; mật độ dòng điện thấp tạo ra đóng góp gần bằng không hoặc âm, còn mật độ dòng điện cao hơn tạo ra đóng góp ngày càng dương, đồng thời cũng cho thấy lợi ích giảm dần ở khoảng giá trị cao nhất.

Hình S6 trình bày phân tích độ ổn định kiểu loại bỏ từng biến đối với giá trị SHAP trung bình theo nhóm [1]. Khi loại bỏ thời gian điện phân, đặc trưng được xếp hạng cao nhất, rồi huấn luyện lại mô hình, anot và mật độ dòng điện vẫn thuộc nhóm dẫn đầu, trong khi pH ban đầu, catốt, nhiệt độ và khoảng cách điện cực vẫn thuộc nhóm có mức độ quan trọng trung bình/thấp. Hệ số Kendall τ giữa hai bảng xếp hạng là 0.600 ($p = 0.136$), cho thấy mức độ tương hợp vừa phải xét đến số lượng đặc trưng ít. Các kết quả này ủng hộ một hệ thứ bậc đặc trưng ổn định, trong đó thời gian điện phân, anot và mật độ dòng điện là những yếu tố chi phối chính; đồng thời, mọi giá trị SHAP đều được diễn giải rõ ràng là các quy kết dựa trên mô hình chứ không phải tác động nhân quả.

3.4. Implications for PFAS treatment optimization

Kết quả về mức độ quan trọng của các đặc trưng đưa ra hướng dẫn thiết thực cho việc thiết kế thiết bị phản ứng điện hóa. Thời gian điện phân chiếm ưu thế, cho thấy mức độ loại bỏ chủ yếu phụ thuộc vào tổng điện lượng truyền qua; việc lập kế hoạch vận hành cần ưu tiên thời gian phản ứng đủ dài trong giới hạn về năng lượng và công suất xử lý. Trong bảng xếp hạng XGBoost, việc lựa chọn anot là yếu tố có ảnh hưởng lớn (Hình 3), phù hợp với các báo cáo trong tài liệu về sự phụ thuộc của quá trình tạo gốc tự do vào vật liệu. Cần lựa chọn vật liệu phù hợp với chế độ mật độ dòng điện mục tiêu và các giới hạn chi phí, đồng thời đánh giá sự đánh đổi giữa hiệu suất và chi phí cho từng trường hợp cụ thể. Các ảnh hưởng của nền nước xấp xỉ ở mức thấp trong hồ sơ SHAP tổng hợp (chẳng hạn, “Nền nước” nằm gần cuối Hình 3), cho thấy trong phạm vi nghiên cứu, việc chuyển giao công nghệ sang các nền nước khác nhau có thể đòi hỏi ít điều chỉnh lại hơn so với các thông số điện hóa (cần được xác nhận trên các nền nước mới) [45,46].

Độ chính xác dự đoán của FLAML hỗ trợ kiểm soát điểm đặt chặt chẽ hơn (ví dụ: mật độ dòng điện và thời gian) để vận hành tiết kiệm năng lượng trong phạm vi đã thử nghiệm. Các dự báo năng lượng định lượng (ví dụ: kWh·m^{−3}) không được suy ra từ đầu ra của mô hình hiện tại và cần có nghiên cứu điện năng chuyên biệt

kiểm toán trong quá trình xác thực thực nghiệm. Khả năng khái quát hóa của mô hình trên các điều kiện vận hành trong tập dữ liệu này cho thấy tiềm năng mở rộng học chuyển giao sang các PFAS liên quan (ví dụ: PFOS, GenX), với điều kiện dữ liệu bao phủ các phạm vi vận hành tương đương và được xác thực bên ngoài [47].

3.5. Limitations and future directions

Mặc dù FLAML cho thấy độ chính xác dự đoán và tính mạnh mẽ vượt trội khi được áp dụng cho bộ dữ liệu do [30] tuyển chọn, vẫn còn nhiều hướng đầy triển vọng cần được khám phá thêm. Trước tiên, các nghiên cứu trong tương lai có thể đánh giá khả năng thích ứng của khuôn khổ mô hình hóa này với các không gian tham số vận hành rộng hơn, đồng thời xác thực hiệu năng bằng các bộ dữ liệu bên ngoài từ những thiết lập thí nghiệm khác nhau. Việc này cũng sẽ bao gồm một phổ rộng hơn các hợp chất PFAS, chẳng hạn như PFOA và các chất đồng nhiễm, nhằm xác định khả năng khái quát hóa những hiểu biết thu được trên các hệ thống xử lý đa dạng. Các phương pháp học chuyển giao đặc biệt có triển vọng trong lĩnh vực này, vì chúng có thể tận dụng hiệu quả kiến thức từ mô hình hiện tại để đẩy nhanh năng lực dự đoán trong các hệ điện hóa liên quan.

Ngoài ra, mặc dù nghiên cứu hiện tại ưu tiên hiệu suất loại bỏ, việc mở rộng khuôn khổ phân tích theo hướng tối ưu hóa đa mục tiêu tích hợp có thể cải thiện đáng kể khả năng ứng dụng thực tiễn. Vì các mở rộng này sẽ xem xét các chỉ số hiệu suất quan trọng bên cạnh khả năng loại bỏ chất ô nhiễm, bao gồm các chỉ số tiêu thụ năng lượng, sự hình thành sản phẩm phụ và sự đánh đổi về tính toán giữa tốc độ tối ưu hóa với hiệu suất cuối cùng của mô hình. Hơn nữa, tăng cường khả năng kiểm soát quy trình thích ứng theo thời gian thực là một hướng đi đầy hứa hẹn khác. Việc tích hợp FLAML với các công nghệ cảm biến tại chỗ sẽ cho phép tối ưu hóa quy trình một cách linh hoạt, tạo điều kiện điều chỉnh ngay lập tức các thông số vận hành dựa trên phản hồi theo thời gian thực.

Cuối cùng, mặc dù phân tích SHAP mang lại những hiểu biết ban đầu có giá trị, khả năng diễn giải sâu hơn có thể đạt được bằng các phát triển các khung mô hình lai kết hợp FLAML với các mô hình dựa trên cơ sở vật lý. Những cải tiến phương pháp luận trong tương lai cũng có thể bao gồm việc tìm hiểu cách xử lý biến phân loại nguyên bản trong các mô hình dựa trên cây như một giải pháp thay thế tiềm năng cho mã hóa one-hot. Nhìn chung, các hướng nghiên cứu này hứa hẹn mang lại những tiến bộ đáng kể trong phân tích dự đoán, khả năng diễn giải và tính ứng dụng trong vận hành, qua đó củng cố tiềm năng của AutoML như một phương pháp mang tính chuyển đổi đối với các công nghệ xử lý khắc phục môi trường bằng điện hóa.

4. Kết luận

Nghiên cứu này trình bày một quy trình làm việc dựa trên AutoML có thể tái lập, kết hợp học máy tự động với các quy trình oxy hóa điện hóa nhằm xử lý các chất ô nhiễm môi trường khó phân hủy. Mô hình XGBoost được tối ưu hóa bằng FLAML vượt trội hơn các phương pháp học máy thông thường được tối ưu hóa thủ công, mang lại độ chính xác dự đoán và khả năng diễn giải cao hơn đáng kể, như được chứng minh qua các phép đối chiếu nghiêm ngặt và kiểm định thống kê. Phân tích xác định thời gian điện phân và vật liệu anot là những yếu tố vận hành chủ đạo, cung cấp các thông tin hữu ích cơ sở từ những nguyên lý điện hóa nền tảng và được kiểm chứng thông qua khả năng diễn giải dựa trên SHAP. Đáng chú ý, khung FLAML tự động giúp giảm đáng kể nhu cầu tính toán (giảm 72% thời gian tính chỉnh), qua đó giúp các kỹ thuật học máy tiên tiến trở nên dễ tiếp cận và dễ tái lập hơn đối với những người hoạt động trong lĩnh vực môi trường. Bằng cách thể hiện năng lực dự đoán vượt trội đồng thời cung cấp những hiểu biết cơ chế vững chắc về mặt khoa học, nghiên cứu này trực tiếp giải quyết các hạn chế quan trọng về phương pháp luận trong tài liệu hiện có. Quy trình dạng container, với các phiên bản được cố định, bảo đảm khả năng tái lập và tính minh bạch, thúc đẩy việc áp dụng rộng rãi hơn cũng như chuẩn hóa phương pháp luận trong lĩnh vực xử lý ô nhiễm môi trường. Trong tương lai, việc tích hợp phương pháp luận đã phát triển với các mô hình lai dựa trên vật lý, hệ thống điều khiển quy trình thích ứng theo thời gian thực và các kịch bản bao quát nhiều hợp chất PFAS hơn có thể tiếp tục nâng cao hiệu quả xử lý điện hóa và

versatility. Overall, this work firmly positions automated and interpretable machine learning as an essential pillar of environmental engineering innovation, advancing the global effort towards sustainable remediation of persistent environmental contaminants.

CRedit authorship contribution statement

Haitham Elnakar: Writing – review & editing, Writing – original draft, Visualization, Methodology, Formal analysis, Conceptualization.

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgment

The author acknowledges the support of King Fahd University of Petroleum and Minerals (KFUPM) for this publication.

Appendix A. Supporting information

Supplementary data associated with this article can be found in the online version at [doi:10.1016/j.dwt.2025.101598](https://doi.org/10.1016/j.dwt.2025.101598).

Data Availability

The dataset used in this research has been cited in the methodology section.

References

[1] Elnakar H, Ismail UM, Khan MF, Alnaimat S. Tackling the dust-microplastic nexus: sources, fate, and detection. *J Hazard Mater Adv* 2024;14:100418. <https://doi.org/10.1016/J.HAZADV.2024.100418>.
[2] Ismail UM, Elnakar H, Khan MF. Sources, fate, and detection of dust-associated perfluoroalkyl and polyfluoroalkyl substances (PFAS): a review. *Toxics* 2023. <https://doi.org/10.3390/toxics11040335>.
[3] EPA, 2017. Technical Fact Sheet – Perfluorooctane Sulfonate (PFOS) and Perfluorooctanoic Acid (PFOA).
[4] Wee SY, Aris AZ. Revisiting the “forever chemicals”, PFOA and PFOS exposure in drinking water. *NPJ clean Water* 2023;6:1–16. <https://doi.org/10.1038/S41545-023-00274-6>.
[5] Zahm S, Bonde JP, Chiu WA, Hoppin J, Kanno J, Abdallah M, et al. Carcinogenicity of perfluorooctanoic acid and perfluorooctanesulfonic acid. *Lancet Oncol* 2024;25:16–7. [https://doi.org/10.1016/S1470-2045\(23\)00622-8](https://doi.org/10.1016/S1470-2045(23)00622-8).
[6] EPA, 2025. Per- and Polyfluoroalkyl Substances (PFAS) Final PFAS National Primary Drinking Water Regulation [WWW Document]. Safe Drinking Water Act.
[7] Elnakar H, Buchanan ID. Pulp and paper mill effluent management. *Water Environ Res* 2018;90:1065–72. <https://doi.org/10.2175/106143018X15289915807164>.
[8] Elnakar H, Khan MF, Ismail UM. Emerging trends in sequencing batch reactor operation and enhancement for improved phenol removal. *Desalin Water Treat* 2024;317:100310. <https://doi.org/10.1016/J.DWT.2024.100310>.
[9] Calvillo Solís JJ, Sandoval-Pauker C, Bai D, Yin S, Senftle TP, Villagrán D. Electrochemical reduction of perfluorooctanoic acid (PFOA): an experimental and theoretical approach. *J Am Chem Soc* 2024;146:10687–98. <https://doi.org/10.1021/jacs.4c00443>.
[10] Tri DVan, Anh NT, Luu T, Le, Trippel J, Wagner M. Electrochemical degradation of perfluorooctanoic acid (PFOA) and perfluorooctane sulfonate (PFOS) in water with persulfate catalyst support. *Sep Purif Technol* 2025;363:132076. <https://doi.org/10.1016/J.SEPPUR.2025.132076>.
[11] Das A, Adak A. Electrochemical oxidation of perfluorooctanoic acid (PFOA) using graphite substrate lead dioxide (GSLD) as anode: investigating reaction mechanism, degradation byproducts and influences of process parameters. *J Environ Chem Eng* 2025;13:116869. <https://doi.org/10.1016/J.JECE.2025.116869>.
[12] Elnakar H. Disinfection and antimicrobial processes. *Water Environ Res* 2020;92:1625–8. <https://doi.org/10.1002/WER.1409>.
[13] Kim N, Elbert J, Shchukina E, Su X. Integrating redox-electrodialysis and electrosorption for the removal of ultra-short- to long-chain PFAS. *15 Nat Commun* 2024 2024;15(1):1–14. <https://doi.org/10.1038/s41467-024-52630-w>.
[14] Liang Y, Wang A, Liang S, Sun K, Xie R, Zheng C, et al. Durable Ti4O7 heterojunction composite membrane encapsulating N-doped graphene nanosheets for efficient electro-oxidation of GenX and other PFAS in fluorochemical

wastewater. *Environ Sci Technol* 2025. https://doi.org/10.1021/ACS.EST.4C09423/SUPPL_FILE/ES4C09423_SI_001.DOCX.
[15] Samuel MS, Kadarkarai G, Ryan DR, McBeath ST, Mayer BK, McNamara PJ. Enhanced perfluorooctanoic acid (PFOA) degradation by electrochemical activation of peroxydisulfate (PDS) during electrooxidation for water treatment. *Sci Total Environ* 2024;942:173736. <https://doi.org/10.1016/J.SCITOTENV.2024.173736>.
[16] Ismail UM, Bani-Melhem K, Khan MF, Elnakar H. Optimizing membrane bioreactor performance in wastewater treatment using machine learning and meta-heuristic techniques. *Results Eng* 2025;25:104626. <https://doi.org/10.1016/J.RINENG.2025.104626>.
[17] Sun Y, Zhao Z, Tong H, Sun B, Liu Y, Ren N, et al. Machine learning models for inverse design of the electrochemical oxidation process for water purification. *Environ Sci Technol* 2023;57:17990–8000. <https://doi.org/10.1021/acs.est.2c08771>.
[18] Shirkoohi MG, Tyagi RD, Vanrolleghem PA, Drogui P. Artificial intelligence techniques in electrochemical processes for water and wastewater treatment: a review. *20 J Environ Health Sci Eng* 2022 2022;20(2):1089–109. <https://doi.org/10.1007/S40201-022-00835-W>.
[19] Jeong N, Park S, Mahajan S, Zhou J, Blotevogel J, Li Y, et al. Elucidating governing factors of PFAS removal by polyamide membranes using machine learning and molecular simulations. *Nat Commun* 2024;15:1–13. <https://doi.org/10.1038/S41467-024-55320-9>.
[20] Raza A, Bardhan S, Xu L, Yamijala SSRKC, Lian C, Kwon H, Wong BN. A machine learning approach for predicting defluorination of per- and polyfluoroalkyl substances (PFAS) for their efficient treatment and removal. *Environ Sci Technol Lett* 2019;6:624–9. <https://doi.org/10.1021/acs.estlett.9b00476>.
[21] Lin DZ, Pan KJ, Li Y, Musgrave CB, Zhang L, Jayarapu KN, et al. A high-throughput experimentation platform for data-driven discovery in electrochemistry. *Sci Adv* 2025;11:4391. <https://doi.org/10.1126/sciadv.adu4391>.
[22] Zhu JJ, Boehm AB, Ren ZJ. Environmental machine learning, baseline reporting, and comprehensive evaluation: the EMBRACE checklist. *Environ Sci Technol* 2024;58(24). <https://doi.org/10.1021/acs.est.4c09611>.
[23] Zhu JJ, Yang M, Ren ZJ. Machine learning in environmental research: common pitfalls and best practices. *Environ Sci Technol* 2023;57:17671–89. <https://doi.org/10.1021/acs.est.3c00026>.
[24] Feng L, Zhang Y, Wei X, Wang M, Niu Z, Wang C. Interpretable prediction of coagulant dosage in drinking water treatment plant based on automated machine learning and SHAP method. *J Water Process Eng* 2025;75:107925. <https://doi.org/10.1016/J.JWPE.2025.107925>.
[25] Han H, Shaker B, Lee JH, Choi Sunghwan, Yoon S, Singh M, et al. Employing automated machine learning (AutoML) methods to facilitate the in silico ADMET properties prediction. *J Chem Inf Model* 2025;65:43. https://doi.org/10.1021/ACS.JCIM.4C02122/ASSET/IMAGES/LARGE/C14C02122_0002.JPEG.
[26] Kazadi Mbamba C, Keymer P, Alvi M, Topalian SON, Ud Din F, Batstone DJ. Enhancing data quality in wastewater processes: missing data imputation with deep Variational Autoencoders and genetic algorithms. *Comput Chem Eng* 2025;199:109123. <https://doi.org/10.1016/J.COMPCHEMENG.2025.109123>.
[27] Wang, C., Wu, Q., Weimer, M., Zhu, E., 2021. FLAML: A Fast and Lightweight AutoML Library [WWW Document]. GitHub. URL (<https://github.com/microsoft/FLAML>) (accessed 6.30.25).
[28] Bao H, Yin W, Wang H, Lu Y, Jiang S, Ajibade FO, et al. Automated machine learning-based models for predicting and evaluating antibiotic removal in constructed wetlands. *Bioresour Technol* 2023;385:129436. <https://doi.org/10.1016/J.BIORTECH.2023.129436>.
[29] Xu RZ, Cao JS, Ye T, Wang SN, Luo JY, Ni BJ, et al. Automated machine learning-based prediction of microplastics induced impacts on methane production in anaerobic digestion. *Water Res* 2022;223:118975. <https://doi.org/10.1016/J.WATRES.2022.118975>.
[30] Alnaimat S, Mohsen O, Elnakar H. Perfluorooctanoic Acids (PFOA) removal using electrochemical oxidation: a machine learning approach. *J Environ Manag* 2024;370:122857. <https://doi.org/10.1016/J.JENVMAN.2024.122857>.
[31] Khalid YS, Misal SN, Mehraeen S, Chaplin BP. Reactive-transport modeling of electrochemical oxidation of perfluoroalkyl substances in porous flow-through electrodes. *ACS ES T Eng* 2022;2:713–25. <https://doi.org/10.1021/acsestengg.1c00362>.
[32] Xu X, Li Y, Vo PHN, Shukla P, Ge L, Zhao CX. Electrochemical advanced oxidation of per- and polyfluoroalkyl substances (PFASs): development, challenges and perspectives. *Chem Eng J* 2024;500:157222. <https://doi.org/10.1016/J.CEJ.2024.157222>.
[33] Lundberg SM, Lee SI. A Unified Approach to Interpreting Model Predictions. *31st Conference on Neural Information Processing Systems. Neural information processing systems foundation; 2017. p. 1–10*.
[34] Mukherjee P, Sathiyam K, Zidki T, Nadagouda MN, Sharma VK. Electrochemical degradation of per- and poly-fluoroalkyl substances in the presence of natural organic matter. *Sep Purif Technol* 2023;325:124639. <https://doi.org/10.1016/J.SEPPUR.2023.124639>.
[35] Schaefer CE, Tran D, Fang Y, Choi YJ, Higgins CP, Strathmann TJ. Electrochemical treatment of poly- and perfluoroalkyl substances in brines. *Environ Sci (Camb)* 2020;6:2704–12. <https://doi.org/10.1039/D0EW00377H>.
[36] Vecitis CD, Park H, Cheng J, Mader BT, Hoffmann MR. Treatment technologies for aqueous perfluorooctanesulfonate (PFOS) and perfluorooctanoate (PFOA). *3 Front Environ Sci Eng China* 2009 2009;3(2):129–51. <https://doi.org/10.1007/S11783-009-0022-7>.

tính linh hoạt. Nhìn chung, công trình này khẳng định vững chắc vai trò của học máy tự động và có thể diễn giải như một trụ cột thiết yếu trong đổi mới kỹ thuật môi trường, góp phần thúc đẩy nỗ lực toàn cầu hướng tới xử lý bền vững các chất ô nhiễm môi trường khó phá n hủy.

Tuyên bố về đóng góp của tác giả theo CRediT

Haitham Elnakar: Viết – rà soát và biên tập, Viết – bản thảo gốc, T rục quan hóa, Phương pháp luận, Phân tích chính thức, Xây dựng ý tưởng.

Tuyên bố về lợi ích cạnh tranh

Các tác giả tuyên bố rằng họ không có bất kỳ lợi ích tài chính cạnh tranh hoặc mối quan hệ cá nhân nào đã biết có thể ảnh hưởng đến công trình được trình bày trong bài báo này.

Lời cảm ơn

Tác giả ghi nhận sự hỗ trợ của Đại học Dầu mỏ và Khoáng sản King Fahd (KFUPM) cho ấn phẩm này.

Phụ lục A. Thông tin bổ trợ

Dữ liệu bổ sung liên quan đến bài viết này có thể được tìm thấy trong phiên bản trực tuyến tại doi:10.1016/j.dwt.2025.101598.

Tính khả dụng của dữ liệu

Tập dữ liệu được sử dụng trong nghiên cứu này đã được trích dẫn trong phần phương pháp luận.

Tài liệu tham khảo

[1] Elnakar H, Ismail UM, Khan MF, Alnaimat S. Giải quyết mối liên hệ giữa bụi và vi nhựa: nguồn phát sinh, số phận và phương pháp phát hiện. *J Hazard Mater Adv* 2024;14:100418. <https://doi.org/10.1016/J.HAZADV.2024.100418>. [2] Ismail UM, Elnakar H, Khan MF. Nguồn phát sinh, số phận và phương pháp phát hiện các chất perfluoroalkyl và polyfluoroalkyl (PFAS) liên kết với bụi: bài tổng quan. *Toxics* 2023. <https://doi.org/10.3390/toxics11040335>. [3] EPA, 2017. Tài liệu thông tin kỹ thuật – Perfluorooctane Sulfonate (PFOS) và Perfluorooctanoic Acid (PFOA). [4] Wee SY, Aris AZ. Xem xét lại việc phơi nhiễm với các “hóa chất vĩnh cửu” PFOA và PFOS trong nước uống. *NPJ clean Water* 2023;6:1–16. <https://doi.org/10.1038/S41545-023-00274-6>. [5] Zahm S, Bonde JP, Chiu WA, Hoppin J, Kanno J, Abdallah M, et al. Khả năng gây ung thư của axit perfluorooctanoic và axit perfluorooctanesulfonic. *Lancet Oncol* 2024;25:16–7. [https://doi.org/10.1016/S1470-2045\(23\)00622-8](https://doi.org/10.1016/S1470-2045(23)00622-8). [6] EPA, 2025. Các chất per- và polyfluoroalkyl (PFAS): Quy định cuối cùng về tiêu chuẩn quốc gia chính thức đối với PFAS trong nước uống [Tài liệu WWW]. Đạo luật Nước uống An toàn. [7] Elnakar H, Buchanan ID. Quản lý nước thải từ nhà máy bột giấy và giấy. *Water Environ Res* 2018;90:1065–72. <https://doi.org/10.2175/106143018X15289915807164>. [8] Elnakar H, Khan MF, Ismail UM. Các xu hướng mới nổi trong vận hành và cải tiến bể phản ứng theo mẻ tuần tự nhằm nâng cao hiệu quả loại bỏ phenol. *Desalin Water Treat* 2024;317:100310. <https://doi.org/10.1016/J.DWT.2024.100310>. [9] Calvillo Solís JJ, Sandoval-Pauker C, Bai D, Yin S, Senftle TP, Villagrán D. Khử axit perfluorooctanoic (PFOA) bằng điện hóa: phương pháp thực nghiệm và lý thuyết. *J Am Chem Soc* 2024;146:10687–98. <https://doi.org/10.1021/jacs.4c00443>. [10] Tri DVan, Anh NT, Luu T, Le, Trippel J, Wagner M. Phân hủy axit perfluorooctanoic (PFOA) và perfluorooctane sulfonate (PFOS) trong nước bằng điện hóa với chất xúc tác persulfate. *Sep Purif Technol* 2025;363:132076. <https://doi.org/10.1016/J.SEPPUR.2025.132076>. [11] Das A, Adak A. Oxy hóa axit perfluorooctanoic (PFOA) bằng điện hóa, sử dụng chì dioxide trên nền graphite (GSLD) làm anốt: khảo sát cơ chế phản ứng, sản phẩm phụ phân hủy và ảnh hưởng của các thông số quy trình. *J Environ Chem Eng* 2025;13:116869. <https://doi.org/10.1016/J.JECE.2025.116869>. [12] Elnakar H. Các quy trình khử trùng và kháng vi sinh vật t. *Water Environ Res* 2020;92:1625–8. <https://doi.org/10.1002/WER.1409>. [13] Kim N, Elbert J, Shchukina E, Su X. Kết hợp điện thẩm tách oxy hóa-khử và hấp phụ điện để loại bỏ PFAS từ chuỗi siêu ngắn đến chuỗi dài. *15 Nat Commun* 2024 2024;15(1):1–14. <https://doi.org/10.1038/s41467-024-52630-w>. [14] Liang Y, Wang A, Liang S, Sun K, Xie R, Zheng C, et al. Màng composite dị tiếp xúc Ti4O7 bền chắc, bao bọc các tấm nano graphene pha tạp N, để oxy hóa điện hóa hiệu quả GenX và các PFAS khác trong fluorochemical

nước thải. *Environ Sci Technol* 2025. https://doi.org/10.1021/ACS.EST.4C09423/SUPPL_FILE/ES4C09423_SI_001.DOCX. [15] Samuel MS, Kadarkarai G, Ryan DR, McBeath ST, Mayer BK, McNamara PJ. Tăng cường phân hủy axit perfluorooctanoic (PFOA) bằng hoạt hóa điện hóa peroxydisulfate (PDS) trong quá trình điện oxy hóa để xử lý nước. *Sci Total Environ* 2024;942:173736. <https://doi.org/10.1016/J.SCITOTENV.2024.173736>. [16] Ismail UM, Bani-Melhem K, Khan MF, Elnakar H. Tối ưu hóa hiệu suất của bể phản ứng sinh học màng trong xử lý nước thải bằng học máy và các kỹ thuật meta-heuristic. *Results Eng* 2025;25:104626. <https://doi.org/10.1016/J.RINENG.2025.104626>. [17] Sun Y, Zhao Z, Tong H, Sun B, Liu Y, Ren N, et al. Các mô hình học máy cho thiết kế ngược quy trình oxy hóa điện hóa để làm sạch nước. *Environ Sci Technol* 2023;57:17990–8000. <https://doi.org/10.1021/acs.est.2c08771>. [18] Shirkoohi MG, Tyagi RD, Vanrolleghem PA, Drogui P. Các kỹ thuật trí tuệ nhân tạo trong quy trình điện hóa để xử lý nước và nước thải: tổng quan. *20 J Environ Health Sci Eng* 2022 2022;20(2):1089–109. <https://doi.org/10.1007/S40201-022-00835-W>. [19] Jeong N, Park S, Mahajan S, Zhou J, Blotevogel J, Li Y, et al. Làm sáng tỏ các yếu tố chỉ quyết định việc loại bỏ PFAS bằng màng polyamide sử dụng học máy và mô phỏng phân tử. *Nat Commun* 2024;15:1–13. <https://doi.org/10.1038/S41467-024-55320-9>. [20] Raza A, Bardhan S, Xu L, Yamijala SSRKC, Lian C, Kwon H, Wong BN. Phương pháp học máy để dự đoán quá trình khử flo của các chất per- và polyfluoroalkyl (PFAS), nhằm xử lý và loại bỏ chúng hiệu quả. *Environ Sci Technol Lett* 2019;6:624–9. <https://doi.org/10.1021/acs.estlett.9b00476>. [21] Lin DZ, Pan KJ, Li Y, Musgrave CB, Zhang L, Jayarapu KN, et al. Nền tảng thí nghiệm thông lượng cao cho khám phá dựa trên dữ liệu trong điện hóa học. *Sci Adv* 2025;11:4391. <https://doi.org/10.1126/sciadv.adu4391>. [22] Zhu JJ, Boehm AB, Ren ZJ. Học máy môi trường, báo cáo đường cơ sở và đánh giá toàn diện: danh mục kiểm tra EMBRACE. *Environ Sci Technol* 2024;58(24). <https://doi.org/10.1021/acs.est.4c09611>. [23] Zhu JJ, Yang M, Ren ZJ. Học máy trong nghiên cứu môi trường: những sai lầm phổ biến và thực hành tốt nhất. *Environ Sci Technol* 2023;57:17671–89. <https://doi.org/10.1021/acs.est.3c00026>. [24] Feng L, Zhang Y, Wei X, Wang M, Niu Z, Wang C. Dự đoán có thể diễn giải liều lượng chất keo tụ tại nhà máy xử lý nước uống dựa trên học máy tự động và phương pháp SHAP. *J Water Process Eng* 2025;75:107925. <https://doi.org/10.1016/J.JWPE.2025.107925>. [25] Han H, Shaker B, Lee JH, Choi Sunghwan, Yoon S, Singh M, et al. Sử dụng các phương pháp học máy tự động (AutoML) để hỗ trợ dự đoán thuộc tính ADMET in silico. *J Chem Inf Model* 2025;65:43. https://doi.org/10.1021/ACS.JCIM.4C02122/ASSET/IMAGES/LARGE/C14C02122_0002.JPEG. [26] Kazadi Mbamba C, Keymer P, Alvi M, Topalian SON, Ud Din F, Batstone DJ. Nâng cao chất lượng dữ liệu trong các quy trình xử lý nước thải: nội suy dữ liệu thiếu bằng bộ tự mã hóa biến phân sâu và thuật toán di truyền. *Comput Chem Eng* 2025;199:109123. <https://doi.org/10.1016/J.COMPCHEMENG.2025.109123>. [27] Wang, C., Wu, Q., Weimer, M., Zhu, E., 2021. FLAML: Thư viện AutoML nhanh và gọn nhẹ [Tài liệu WWW]. GitHub. URL (<https://github.com/microsoft/FLAML>) (truy cập ngày 6.30.25). [28] Bao H, Yin W, Wang H, Lu Y, Jiang S, Ajibade FO, et al. Các mô hình dựa trên học máy tự động để dự đoán và đánh giá khả năng loại bỏ kháng sinh trong các vùng đất ngập nước kiến tạo. *Bioresour Technol* 2023;385:129436. <https://doi.org/10.1016/J.BIORTECH.2023.129436>. [29] Xu RZ, Cao JS, Ye T, Wang SN, Luo JY, Ni BJ, et al. Dự đoán dựa trên học máy tự động về tác động do vi nhựa gây ra đối với quá trình sản xuất methane trong phân hủy kỵ khí. *Water Res* 2022;223:118975. <https://doi.org/10.1016/J.WATRES.2022.118975>. [30] Alnaimat S, Mohsen O, Elnakar H. Loại bỏ axit perfluorooctanoic (PFOA) bằng oxy hóa điện hóa: phương pháp học máy. *J Environ Manag* 2024;370:122857. <https://doi.org/10.1016/J.JENVMAN.2024.122857>. [31] Khalid YS, Misal SN, Mehraeen S, Chaplin BP. Mô hình hóa phản ứng-vận chuyển của quá trình oxy hóa điện hóa các chất perfluoroalkyl trong điện cực xốp dòng chảy xuyên qua. *ACS ES T Eng* 2022;2:713–25. <https://doi.org/10.1021/acsestengg.1c00362>. [32] Xu X, Li Y, Vo PHN, Shukla P, Ge L, Zhao CX. Oxy hóa nâng cao điện hóa các chất per- và polyfluoroalkyl (PFAS): phát triển, thách thức và triển vọng. *Chem Eng J* 2024;500:157222. <https://doi.org/10.1016/J.CEJ.2024.157222>. [33] Lundberg SM, Lee SI. Phương pháp thống nhất để diễn giải các dự đoán của mô hình. *Hội nghị lần thứ 31 về Hệ thống xử lý thông tin thần kinh. Quỹ Hệ thống xử lý thông tin thần kinh*; 2017. tr. 1–10. [34] Mukherjee P, Sathiyam K, Zidki T, Nadagouda MN, Sharma VK. Phân hủy điện hóa các chất per- và polyfluoroalkyl khi có mặt chất hữu cơ tự nhiên. *Sep Purif Technol* 2023;325:124639. <https://doi.org/10.1016/J.SEPPUR.2023.124639>. [35] Schaefer CE, Tran D, Fang Y, Choi YJ, Higgins CP, Strathmann TJ. Xử lý điện hóa các chất poly- và perfluoroalkyl trong nước muối đậm đặc. *Environ Sci (Camb)* 2020;6:2704–12. <https://doi.org/10.1039/D0EW00377H>. [36] Vecitis CD, Park H, Cheng J, Mader BT, Hoffmann MR. Các công nghệ xử lý perfluorooctanesulfonate (PFOS) và perfluorooctanoate (PFOA) trong nước. *3 Front Environ Sci Eng China* 2009 2009;3(2):129–51. <https://doi.org/10.1007/S11783-009-0022-7>.

[37] Anglada Á, Urtiaga A, Ortiz I. Contributions of electrochemical oxidation to waste-water treatment: fundamentals and review of applications. J Chem Technol Biotechnol 2009;84:1747–55. <https://doi.org/10.1002/JCTB.2214>. [38] Oturan MA, Aaron JJ. Advanced oxidation processes in water/wastewater treatment: principles and applications. a review. Crit Rev Environ Sci Technol 2014;44:2577–641. <https://doi.org/10.1080/10643389.2013.829765>. [39] Martínez-Huitle CA, Panizza M. Electrochemical oxidation of organic pollutants for wastewater treatment. Curr Opin Electrochem 2018;11:62–71. <https://doi.org/10.1016/J.COEEC.2018.07.010>. [40] Wang C, Zhang T, Yin L, Ni C, Ni JP, Hou LA. Enhanced perfluorooctane acid mineralization by electrochemical oxidation using Ti3+ self-doping TiO2 nanotube arrays anode. Chemosphere 2022;286:131804. <https://doi.org/10.1016/J.CHEMOSPHERE.2021.131804>. [41] Panizza M, Cerisola G. Direct and mediated anodic oxidation of organic pollutants. Chem Rev 2009;109:6541–69. <https://doi.org/10.1021/cr9001319>. [42] Chaplin BP. Critical review of electrochemical advanced oxidation processes for water treatment applications. Environ Sci Process Impacts 2014;16:1182–203. <https://doi.org/10.1039/C3EM00679D>.

[43] Chen T, Guestrin C. XGBoost: A scalable tree boosting system. In: KDD '16: Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Association for Computing Machinery; 2016. p. 785–94. <https://doi.org/10.1145/2939672.2939785>. [44] Asadi Zeidabadi F, Banayan Esfahani E, McBeath ST, Dubrawski KL, Mohseni M. Electrochemical degradation of PFOA and its common alternatives: assessment of key parameters, roles of active species, and transformation pathway. Chemosphere 2023;315:137743. <https://doi.org/10.1016/J.CHEMOSPHERE.2023.137743>. [45] Karatas O, Kobya M, Khataee A, Yoon Y. Perfluorooctanoic acid (PFOA) removal from real landfill leachate wastewater and simulated soil leachate by electrochemical oxidation process. Environ Technol Innov 2022;28:102954. <https://doi.org/10.1016/J.ETI.2022.102954>. [46] Schaefer CE, Andaya C, Burant A, Condee CW, Urtiaga A, Strathmann TJ, et al. Electrochemical treatment of perfluorooctanoic acid and perfluorooctane sulfonate: Insights into mechanisms and application to groundwater treatment. Chem Eng J 2017;317:424–32. <https://doi.org/10.1016/J.CEJ.2017.02.107>. [47] EPA, 2023. EPA's PFAS Strategic Roadmap: Second Annual Progress Report.

[37] Anglada Á, Urtiaga A, Ortiz I. Đóng góp của quá trình oxy hóa điện hóa đối với xử lý nước thải: cơ sở lý thuyết và tổng quan các ứng dụng. J Chem Technol Biotechnol 2009;84:1747–55. <https://doi.org/10.1002/JCTB.2214>. [38] Oturan MA, Aaron JJ. Các quá trình oxy hóa nâng cao trong xử lý nước/nước thải: nguyên lý và ứng dụng. Một bài tổng quan. Crit Rev Environ Sci Technol 2014;44:2577–641. <https://doi.org/10.1080/10643389.2013.829765>. [39] Martínez-Huitle CA, Panizza M. Oxy hóa điện hóa các chất ô nhiễm hữu cơ để xử lý nước thải. Curr Opin Electrochem 2018;11:62–71. <https://doi.org/10.1016/J.COEEC.2018.07.010>. [40] Wang C, Zhang T, Yin L, Ni C, Ni JP, Hou LA. Tăng cường quá trình khoáng hóa axit perfluorooctanoic bằng oxy hóa điện hóa sử dụng anode màng ống nano TiO2 tự pha tạp Ti3+. Chemosphere 2022;286:131804. <https://doi.org/10.1016/J.CHEMOSPHERE.2021.131804>. [41] Panizza M, Cerisola G. Oxy hóa anot trực tiếp và gián tiếp các chất ô nhiễm hữu cơ. Chem Rev 2009;109:6541–69. <https://doi.org/10.1021/cr9001319>. [42] Chaplin BP. Tổng quan phê bình về các quá trình oxy hóa điện hóa nâng cao trong ứng dụng xử lý nước. Environ Sci Process Impacts 2014;16:1182–203. <https://doi.org/10.1039/C3EM00679D>.

[43] Chen T, Guestrin C. XGBoost: Một hệ thống tăng cường cây có khả năng mở rộng. Trong: KDD '16: Hội nghị quốc tế ACM SIGKDD về khám phá tri thức và khai phá dữ liệu. Hiệp hội Máy tính; 2016. tr. 785–94. <https://doi.org/10.1145/2939672.2939785>. [44] Asadi Zeidabadi F, Banayan Esfahani E, McBeath ST, Dubrawski KL, Mohseni M. Phân hủy điện hóa PFOA và các chất thay thế phổ biến: đánh giá các thông số then chốt, vai trò của các tác nhân hoạt tính và con đường chuyển hóa. Chemosphere 2023;315:137743. <https://doi.org/10.1016/J.CHEMOSPHERE.2023.137743>. [45] Karatas O, Kobya M, Khataee A, Yoon Y. Loại bỏ axit perfluorooctanoic (PFOA) khỏi nước rỉ rác bãi chôn lấp thực tế và nước rỉ đất mỏ phồng bằng quy trình oxy hóa điện hóa. Environ Technol Innov 2022;28:102954. <https://doi.org/10.1016/J.ETI.2022.102954>. [46] Schaefer CE, Andaya C, Burant A, Condee CW, Urtiaga A, Strathmann TJ, và cs. Xử lý điện hóa axit perfluorooctanoic và perfluorooctanesulfonate: Những hiểu biết về cơ chế và ứng dụng trong xử lý nước ngầm. Chem Eng J 2017;317:424–32. <https://doi.org/10.1016/J.CEJ.2017.02.107>. [47] EPA, 2023. Lộ trình chiến lược PFAS của EPA: Báo cáo tiến độ thường niên lần thứ hai.