

Data-Driven Prediction of SAnMBR Performance under Phenolic Shock Loads: A Comparative Machine Learning Study

Milad Mousazadehgavan¹ · B. Abdullhadi² · Milad Basirifard³ · Farideh Malekdar⁴ · Mahsa Shahi Jouneghani⁵ · Adel Kamyab Rudsari⁶ · Reza Ghanbari⁶

Received: 27 March 2026 / Revised: 1 May 2026 / Accepted: 18 May 2026 / Published online: 10 June 2026
© The Author(s) 2026

Abstract

Treating phenolic wastewater remains a major challenge due to the toxicity and inhibitory effects of compounds such as 2,4-dichlorophenol (2,4-DCP), which destabilize biological processes. This study investigates the performance of a pilot-scale submerged anaerobic membrane bioreactor(SAnMBR) treating 2,4-DCP-contaminated wastewater over 189 days and develops a data-driven machine learning framework to predict COD removal efficiency. Based on 189 experimental observations and six key operational parameters, three algorithms, namely multiple linear regression, artificial neural networks, and support vector regression were trained. SVR outperformed the other models, achieving a test R^2 of 0.952, an RMSE of 2.96, and strong generalization performance. The results indicate that optimal COD removal occurred within a narrow pH range (8–9) and at low 2,4-DCP loads (<50 mg/L), with steep performance declines observed under inhibitory concentrations (>150 mg/L). In addition to COD, SAnMBRs also achieved high removal efficiencies for turbidity (>75%), TSS (>90%), and 2,4-DCP (>80%). These findings demonstrate that integrating long-term experimental data with interpretable machine learning enables reliable performance prediction and provides actionable insights for optimizing the SAnMBR operation in treating toxic industrial wastewater.

Milad Mousazadehgavan and Adel Kamyab Rudsari: Co-first author.

✉ Milad Mousazadehgavan
m.mousazadehgavan@2024.ljmu.ac.uk

- ¹ Faculty of Engineering and Technology, School of Civil Engineering and Built Environment, Liverpool John Moores University (LJMU), Liverpool L3 3AF, UK
- ² Building and Construction Techniques Engineering Department, Technical Engineering College, Al Mustaqbal University, Babylon 51001, Iraq
- ³ School for Environment and Sustainability, University of Michigan, Ann Arbor, MI 48109, USA
- ⁴ Department of Civil and Environmental Engineering, Institute of Science Tokyo (Science Tokyo), Tokyo, Japan
- ⁵ Department of Sustainable Systems Engineering, Albert Ludwig University of Freiburg, Freiburg im Breisgau, Germany
- ⁶ Department of Environmental Health Engineering, School of Health, Qazvin University of Medical Sciences, Qazvin, Iran

Dự đoán hiệu suất SAnMBR dựa trên dữ liệu khi chịu tải sốc phenolic: Nghiên cứu so sánh về học máy

Milad Mousazadehgavan¹ · B. Abdullhadi² · Milad Basirifard³ · Farideh Malekdar⁴ · Mahsa Shahi Jouneghani⁵ · Adel Kamyab Rudsari⁶ · Reza Ghanbari⁶

Ngày nhận: 27 tháng 3 năm 2026 / Ngày sửa đổi: 1 tháng 5 năm 2026 / Ngày chấp nh
ận: 18 tháng 5 năm 2026 / Xuất bản trực tuyến: 10 tháng 6 năm 2026 © Tác giả 2026

Tóm tắt


Xử lý nước thải chứa phenol vẫn là một thách thức lớn do độc tính và tác động ức chế của các hợp chất nh
ư 2,4-dichlorophenol (2,4-DCP), vốn làm mất ổn định các quá trình sinh học. Nghiên cứu này đánh giá hiệ
u suất của một thiết bị phản ứng sinh học màng kỵ khí chìm (SAnMBR) quy mô thí điểm trong xử lý nước t
hải nhiễm 2,4-DCP trong 189 ngày, đồng thời xây dựng một khung học máy dựa trên dữ liệu để dự đoán
hiệu suất loại bỏ COD. Dựa trên 189 quan sát thực nghiệm và sáu thông số vận hành chính, ba thuật toán
gồm hồi quy tuyến tính đa biến, mạng nơ-ron nhân tạo và hồi quy véc-tơ hỗ trợ đã được huấn luyện. SVR
vượt trội hơn các mô hình còn lại, đạt R^2 trên tập kiểm tra là 0,952, RMSE là 2,96 và khả năng khái quát hó
a tốt. Kết quả cho thấy hiệu suất loại bỏ COD tối ưu đạt được trong khoảng pH hẹp (8–9) và ở tải lượng 2,4
-DCP thấp (< 50 mg/L); hiệu suất giảm mạnh khi nồng độ đạt mức ức chế (> 150 mg/L). Ngoài COD, SAnM
BR còn đạt hiệu suất loại bỏ cao đối với độ đục (> 75%), TSS (> 90%) và 2,4-DCP (> 80%). Những phát hiện n
ày cho thấy việc kết hợp dữ liệu thực nghiệm dài hạn với học máy có khả năng diễn giải giúp dự đoán hiệ
u suất đáng tin cậy và cung cấp những thông tin hữu ích để tối ưu hóa vận hành SAnMBR trong xử lý nướ
c thải công nghiệp độc hại.

Milad Mousazadehgavan and Adel Kamyab Rudsari: Co-first author.

✉ Milad Mousazadehgavan
m.mousazadehgavan@2024.ljmu.ac.uk

- ¹ Faculty of Engineering and Technology, School of Civil Engineering and Built Environment, Liverpool John Moores University (LJMU), Liverpool L3 3AF, UK
- ² Building and Construction Techniques Engineering Department, Technical Engineering College, Al Mustaqbal University, Babylon 51001, Iraq
- ³ School for Environment and Sustainability, University of Michigan, Ann Arbor, MI 48109, USA
- ⁴ Department of Civil and Environmental Engineering, Institute of Science Tokyo (Science Tokyo), Tokyo, Japan
- ⁵ Department of Sustainable Systems Engineering, Albert Ludwig University of Freiburg, Freiburg im Breisgau, Germany
- ⁶ Department of Environmental Health Engineering, School of Health, Qazvin University of Medical Sciences, Qazvin, Iran

Graphical Abstract




This graphical abstract presents a structured visual pathway linking long-term experimental operation with data-driven predictive modelling for a submerged anaerobic membrane bioreactor (SANMBR) treating phenolic wastewater. The first segment illustrates the pilot-scale system, highlighting the continuous operation under progressively increasing 2,4-dichlorophenol (2,4-DCP) shock loads over 189 days. Key operational variables, including influent COD, organic loading rate, turbidity, total suspended solids, pH, and 2,4-DCP concentration, are introduced as the primary data inputs. The second segment focuses on the analytical and modelling framework, where experimental data are processed and fed into three machine learning models (MLR, ANN, and SVR). The model comparison is visually emphasized to demonstrate the superiority of the SVR model in capturing non-linear system behaviour. The final segment summarizes the key outcomes by linking model predictions with process understanding. It highlights the existence of a narrow optimal operational window governed by pH and 2,4-DCP concentration, where maximum COD removal efficiency is achieved. Additionally, it distinguishes between biological performance drivers and operational constraints, particularly membrane fouling associated with suspended solids. Overall, the graphical abstract provides a concise integration of experimental operation, machine learning modelling, and process interpretation, enabling rapid understanding of how data-driven approaches can enhance the prediction, optimization, and control of SANMBR systems treating toxic industrial wastewater.

Highlight

Long-term pilot SANMBR operated under progressive 2,4-DCP shock loading (189 days).
 Stable high removal achieved: COD (80–95%), TSS (> 90%), 2,4-DCP (> 80%).
 SVR outperformed ANN and MLR with high accuracy ($R^2 = 0.952$, RMSE = 2.96).
 pH (8–9) and 2,4-DCP identified as dominant non-linear drivers.
 Optimal performance was confined to low 2,4-DCP (< 50 mg/L) and narrow pH window.

Keywords Submerged anaerobic membrane bioreactor · 2,4-dichlorophenol · Phenolic wastewater · COD removal · Support vector regression

Tóm tắt đồ họa



Hình tóm tắt đồ họa này trình bày lộ trình trực quan có cấu trúc, liên kết quá trình vận hành thực nghiệm dài hạn với mô hình dự đoán dựa trên dữ liệu cho hệ thống phản ứng sinh học màng kỵ khí chìm (SANMBR) xử lý nước thải chứa phenol. Phần đầu minh họa hệ thống quy mô thí điểm, làm nổi bật quá trình vận hành liên tục trong 189 ngày với tải sốc 2,4-dichlorophenol (2,4-DCP) tăng dần. Các biến vận hành chính, gồm COD đầu vào, tải trọng hữu cơ, độ đục, tổng chất rắn lơ lửng, pH và nồng độ 2,4-DCP, được giới thiệu là các dữ liệu đầu vào chủ yếu. Phần thứ hai tập trung vào khuôn khổ phân tích và mô hình hóa, trong đó dữ liệu thực nghiệm được xử lý và đưa vào ba mô hình học máy (MLR, ANN và SVR). Phần so sánh mô hình được nhấn mạnh bằng hình ảnh nhằm cho thấy ưu thế của mô hình SVR trong việc mô tả hành vi phi tuyến của hệ thống. Phần cuối tổng kết các kết quả chính bằng cách liên kết dự đoán của mô hình với hiểu biết về quy trình. Phần này nhấn mạnh sự tồn tại của một khoảng vận hành tối ưu hẹp, chịu chi phối bởi pH và nồng độ 2,4-DCP, trong đó đạt được hiệu suất loại bỏ COD cao nhất. Ngoài ra, phần này phân biệt các yếu tố chi phối hiệu quả sinh học với những giới hạn vận hành, đặc biệt là hiện tượng tắc nghẽn màng liên quan đến chất rắn lơ lửng. Nhìn chung, hình tóm tắt đồ họa tích hợp súc tích quá trình vận hành thực nghiệm, mô hình hóa bằng học máy và diễn giải quy trình, giúp nhanh chóng hiểu được cách các phương pháp dựa trên dữ liệu có thể cải thiện việc dự đoán, tối ưu hóa và kiểm soát các hệ thống SANMBR xử lý nước thải công nghiệp độc hại.

Điểm nổi bật

SANMBR thí điểm vận hành dài hạn dưới tải sốc 2,4-DCP tăng dần (189 ngày).
 Hiệu suất loại bỏ cao và ổn định: COD (80–95%), TSS (> 90%), 2,4-DCP (> 80%).
 SVR vượt trội hơn ANN và MLR với độ chính xác cao ($R^2 = 0.952$, RMSE = 2.96).
 pH (8–9) và 2,4-DCP được xác định là các yếu tố chi phối phi tuyến chính.
 Hiệu suất tối ưu chỉ đạt được khi nồng độ 2,4-DCP thấp (< 50 mg/L) và pH nằm trong khoảng hẹp.

Từ khóa Lò phản ứng sinh học màng kỵ khí chìm · 2,4-dichlorophenol · Nước thải chứa phenol · Loại bỏ COD · Hồi quy vector hỗ trợ

1 Introduction

Phenolic compounds, including phenol and its derivatives, represent a class of priority pollutants often found in industrial effluents (e.g., petrochemical, pharmaceutical, dye, and pulp and paper industries). These compounds are characterized by aromatic ring structure bearing one or more hydroxyl groups, which contribute to their chemical stability and solubility, allowing them to persist and disperse in aquatic environment (Catherine et al. 2016). Their persistence, coupled with their bioaccumulative potential, raises severe environmental and public health concerns. Ecotoxicological studies have demonstrated that phenolic compounds can exhibit carcinogenicity, mutagenicity, and endocrine-disrupting effects, even at relatively low environmental concentrations (Menon and Kalyanraman 2025). Quantitatively, phenolic compounds can exert acute toxicity at relatively low concentrations, with reported LC50 values for aquatic organisms typically ranging from 5 to 25 mg/L, while sub-lethal effects such as enzymatic inhibition and oxidative stress have been observed at concentrations below 1 mg/L. Moreover, phenols and chlorophenols are often listed as priority pollutants by regulatory agencies due to their deleterious effects and recalcitrant behaviour. From a human health perspective, phenolic compounds pose a significant risk. For example, chronic exposure through ingestion or dermal contact can lead to neurological, hematological, and hepatic toxicity (Wang et al. 2019). Their removal from wastewater is therefore not only desirable but necessary to avoid environmental accumulation and potential health hazards. However, because of their chemical stability, conventional biological treatment processes sometimes fail to consistently degrade phenols, especially when concentrations are high or the influent composition is complex.

Biological treatment performance is highly dependent on phenolic concentration, as elevated levels can strongly inhibit microbial activity and destabilize reactor performance. In addition, the speciation and toxicity of chlorinated phenolic compounds such as 2,4-dichlorophenol (2,4-DCP) are strongly pH-dependent. Due to its weakly acidic nature ($pK_a \approx 7.9$), 2,4-DCP exists in both dissociated (ionized) and undissociated (non-ionized) forms depending on the solution pH. Azed form predominates, which is more hydrophobic at lower pH values, the non-ionized form can readily diffuse through microbial cell membranes, thereby increasing its inhibitory effects on biological processes, whereas under neutral to slightly alkaline conditions, the ionized form becomes dominant, reducing membrane permeability and overall toxicity. This pH-dependent behaviour plays a critical role in determining the bioavailability and inhibitory impact of 2,4-DCP in anaerobic systems. Therefore, high-strength phenolic wastewater often requires dilution or

appropriate pretreatment to reduce toxicity prior to biological treatment, ensuring stable and efficient operation (Al-Qodah et al. 2019).

Anaerobic membrane bioreactors (AnMBRs) have emerged as a compelling technology for treating industrial wastewaters, including those containing phenolic compounds. Unlike conventional aerobic treatment, AnMBRs combine anaerobic biodegradation with membrane filtration, enabling high biomass retention, long solids retention time (SRT), and efficient recovery of biogas (Muñoz Sierra et al. 2020). Submerged configurations (SAnMBRs), in which the membrane module is immersed directly in the bioreactor, offer additional benefits such as reduced footprint, lower energy demand, and enhanced process stability. In the context of phenolic wastewater, such systems are particularly attractive because the slow-growing anaerobic microbial communities (e.g., phenol-degrading syntrophic bacteria) can be retained within the reactor over long timescales, maximizing the contact time necessary for degradation (Rezakazemi et al. 2018). These microbial consortia typically include syntrophic bacteria such as *Syntrophus* and *Syntrophorhabdus*, which are involved in the initial degradation of aromatic compounds, as well as methanogenic archaea such as *Methanosaeta* and *Methanosarcina*, which facilitate the final conversion of intermediates to methane (García Rea et al. 2020). Indeed, studies have demonstrated that submerged AnMBRs can achieve high removal efficiencies: in one long-term experiment treating kraft evaporator condensate, chemical oxygen demand (COD) removal exceeded 93–99% with stable methane production, and biogas sparging was effective for controlling fouling (Muñoz Sierra et al. 2020). However, AnMBRs, especially submerged ones, face nontrivial operational challenges. Membrane fouling remains a primary limitation including cake formation, pore blocking, and the accumulation of extracellular polymeric substances (EPS) or soluble microbial products (SMP) can degrade membrane performance, increase transmembrane pressure (TMP), and shorten membrane lifespan (Viet and Jang 2021). In addition, the complex and nonlinear interactions among operational variables, microbial dynamics, and physicochemical properties make predictive modelling and control difficult.

In order to improve efficacy and parameter optimization, machine learning focuses on developing algorithms that learn patterns from data and support prediction or decision-making. In artificial intelligence (AI), machine learning focuses on developing computer algorithms to facilitate intelligent actions through data processing. AI also offers potential for real-time optimization and control, enabling dynamic operational strategies that adapt to changing conditions. However, in SAnMBR systems treating phenolic wastewater, the necessity of ML is not merely

1 Giới thiệu

Các hợp chất phenolic, bao gồm phenol và các dẫn xuất của nó, đại diện cho một nhóm chất ô nhiễm ưu tiên thường có trong nước thải công nghiệp (ví dụ: hóa dầu, dược phẩm, thuốc nhuộm và ngành công nghiệp bột giấy và giấy). Các hợp chất này được đặc trưng bởi cấu trúc vòng thơm mang một hoặc nhiều nhóm hydroxyl. Các nhóm, góp phần tạo nên tính ổn định hóa học và khả năng hòa tan của chúng, cho phép chúng tồn tại lâu dài và phân tán trong môi trường nước (Catherine et al. 2016). Tính bền vững của chúng, cùng với khả năng tích lũy sinh học, chúng làm dấy lên những lo ngại nghiêm trọng về môi trường và sức khỏe cộng đồng. Các nghiên cứu độc chất sinh thái đã chứng minh rằng các hợp chất phenolic có thể gây ung thư, khả năng gây đột biến và khả năng gây rối loạn nội tiết. Ngay cả ở nồng độ tương đối thấp trong môi trường (Menon và Kalyanraman 2025). Về mặt định lượng, phenol và các hợp chất có thể gây độc tính cấp tính ở nồng độ tương đối thấp, với các giá trị LC50 được báo cáo ở sinh vật thủy sinh thường dao động từ 5 đến 25 mg/L, trong khi các mức dưới ngưỡng gây chết gây tác động như ức chế enzym và stress oxy hóa đã được quan sát thấy ở nồng độ dưới 1 mg/L. Hơn nữa, phenol và chlorophenol thường được liệt kê là các chất ưu tiên ảnh hưởng và hành vi khó kiểm soát. Đối với sức khỏe con người, phơi nhiễm mãn tính qua đường tiêu hóa hoặc tiếp xúc có thể dẫn đến các vấn đề thần kinh, huyết học và độc tính (Wang et al. 2019). Do đó, việc loại bỏ chúng khỏi nước thải không chỉ đáng mong muốn mà còn cần thiết để tránh sự tích tụ trong môi trường và các nguy cơ tiềm ẩn đối với sức khỏe con người. Tuy nhiên, do tính ổn định hóa học của chúng, các quy trình xử lý sinh học đôi khi không phân hủy phenol một cách nhất quán, đặc biệt khi nồng độ cao hoặc thành phần nước đầu vào phức tạp.

Hiệu suất xử lý sinh học phụ thuộc rất nhiều ở nồng độ phenolic, vì mức độ cao có thể ảnh hưởng ức chế hoạt động của vi sinh vật và làm mất ổn định hiệu suất của thiết bị phản ứng. Ngoài ra, dạng tồn tại và độc tính của các hợp chất phenol clo hóa như 2,4-dichlorophenol (2,4-DCP) phụ thuộc mạnh vào pH. Do tính chất axit yếu của nó, 2,4-DCP tồn tại ở cả dạng phân tử và các dạng ion hóa và không phân ly (không ion hóa) tùy thuộc vào pH của dung dịch. Dạng Azed chiếm ưu thế, và dạng này có tiềm năng xuyên màng tế bào vi sinh vật, qua đó làm tăng tác dụng ức chế của nó đối với các quá trình sinh học, trong khi dạng này trở nên chiếm ưu thế, làm giảm tính thấm của màng và độc tính tổng thể. Hành vi phụ thuộc vào pH này đóng vai trò then chốt trong việc xác định sinh khả dụng và tác động ức chế của 2,4-DCP trong các hệ thống xử lý nước thải phenolic nồng độ cao thường cần được pha loãng hoặc

tiền xử lý thích hợp để giảm độc tính trước khi xử lý sinh học, đảm bảo hệ thống vận hành ổn định và hiệu quả (Al-Qodah và cộng sự, 2019).

Bể phản ứng sinh học màng kỵ khí (AnMBR) đã nổi lên như một công nghệ đầy tiềm năng để xử lý nước thải công nghiệp, bao gồm cả nước thải chứa các hợp chất phenolic. Khác với phương pháp xử lý hiếu khí thông thường, AnMBR kết hợp quá trình phân hủy sinh học kỵ khí với lọc màng, cho phép duy trì lượng sinh khối cao, thời gian lưu chất rắn (SRT) dài và thu hồi khí sinh học hiệu quả (Muñoz Sierra et al. 2020). Cấu hình màng chìm (SAnMBR), trong đó mô-đun màng được đặt trực tiếp trong bể phản ứng sinh học, mang lại những lợi ích bổ sung như diện tích chiếm chỗ nhỏ hơn, nhu cầu năng lượng thấp hơn và giảm thiểu chi phí vận hành. Trong bối cảnh xử lý nước thải phenolic, các hệ thống này đặc biệt hấp dẫn vì các quần thể vi sinh vật kỵ khí phát triển chậm (ví dụ: vi khuẩn cộng dưỡng phân hủy phenol) có thể được giữ lại trong bể phản ứng trong thời gian dài, tối đa hóa thời gian tiếp xúc cần thiết cho quá trình phân hủy (Rezakazemi et al. 2018). Các quần xã vi sinh vật này thường bao gồm những vi khuẩn cộng dưỡng như *Syntrophus* và *Syntrophorhabdus*, tham gia vào giai đoạn phân hủy ban đầu các hợp chất thơm, cùng với các vi khuẩn cổ sinh methane như *Methanosaeta* và *Methanosarcina*, giúp chuyển hóa các chất trung gian thành methane ổn định (García Rea et al. 2020). Trên thực tế, các nghiên cứu đã chứng minh rằng AnMBR màng chìm có thể đạt hiệu suất loại bỏ cao: trong một thí nghiệm dài hạn xử lý nước ngưng tụ từ thiết bị cô đặc của quy trình kraft, mức loại bỏ nhu cầu oxy hóa học (COD) vượt 93–99%, đồng thời duy trì sản lượng methane ổn định; sự khí sinh học cũng cho thấy hiệu suất trung bình cao (Muñoz Sierra et al. 2020). Tuy nhiên, AnMBR, đặc biệt là loại màng chìm, phải đối mặt với những thách thức vận hành đáng kể. Tắc màng vẫn là một hạn chế chủ yếu; sự hình thành lớp bám, bít lỗ màng và tích tụ các chất polyme ngoại bào (EPS) hoặc sản phẩm vi sinh vật hòa tan (SMP) có thể làm suy giảm hiệu suất màng, tăng áp suất xuyên màng (TMP) và rút ngắn tuổi thọ màng (Viet and Jang 2021). Ngoài ra, các tương tác phức tạp và phi tuyến giữa các biến vận hành, động thái vi sinh vật và tính chất của nước thải khiến việc mô hình hóa và kiểm soát dự báo trở nên khó khăn.

Để nâng cao hiệu quả và tối ưu hóa tham số vận hành, các thuật toán học máy dựa trên dữ liệu, hỗ trợ dự đoán hoặc ra quyết định. Trong trí tuệ nhân tạo (AI), học máy tập trung phát triển các thuật toán máy tính nhằm thúc đẩy những hành động thông minh thông qua xử lý dữ liệu. AI cũng có tiềm năng tối ưu hóa và điều khiển theo thời gian thực, cho phép triển khai các chiến lược vận hành linh hoạt thích ứng với điều kiện thay đổi. Tuy nhiên, trong các hệ thống SAnMBR xử lý nước thải phenolic, sự cần thiết của học máy không chỉ dừng lại ở việc tối ưu hóa các tham số vận hành mà còn là

due to its general predictive capability, but arises from the intrinsically complex and non-linear interactions between inhibitory compounds (e.g., 2,4-DCP), microbial activity, and operational parameters such as pH and organic loading rate (OLR), which cannot be adequately captured by conventional mechanistic or linear models. These interactions are further complicated by toxicity thresholds and microbial acclimation effects, where system performance can shift abruptly under phenolic shock loading, making deterministic modelling approaches insufficient. The application of ML in membrane bioreactor (MBR) systems has grown substantially in recent years (Muniz de Queiroz et al. 2025). In particular, previous studies have shown that data-driven models can successfully capture the non-linear dynamics and inhibition effects in anaerobic membrane systems, where process behaviour is strongly influenced by microbial adaptation and toxicity thresholds (Lai et al. 2024; Xu et al. 2026; Yu et al. 2026). As an example, Zhong et al. (Zhong et al. 2022) used a linear model, decision tree, ensemble learning, nearest neighbor model, and support vector machine to predict the water quality of a MBR that treats high-salinity ammonia-nitrogen wastewater. Yaqub and Lee (Yaqub and Lee 2022) used an ensemble model referred to as extreme gradient boosting (XGB) to predict total nitrogen (TN), total phosphorus (TP) and ammonium (NH_4^+) removal from an anaerobic-anoxic-oxic MBR at a wastewater treatment plant, alongside ANNs. To predict effluent (NH_4^+) and TN concentrations in a MBR treating domestic wastewater, Zhuang et al. (Zhuang et al. 2021) evaluated multiple models including regression tree, random forest, adaptive boosting, gradient boosting regression, and deep neural networks. Despite these advances, most existing studies remain focused on predictive accuracy, with limited attention to extracting engineering-relevant insights

such as operational thresholds and system stability limits. Therefore, the application of ML in this study is specifically justified to resolve non-linear inhibition behaviour and to identify the operational window governing COD removal efficiency under phenolic shock conditions. This approach enables the translation of complex process data into actionable engineering insights, which cannot be obtained using conventional modelling approaches.


While ML is widely used in MBRs, a systematic comparison of advanced non-linear techniques as well as interpretability analyses remains limited, particularly when operating Submerged Anaerobic MBRs (SAnMBRs) under high phenolic shock loads for long periods of time. Studies often focus only on maximizing correlation coefficients, failing to investigate why the model works. Accordingly, the objective of this study is not limited to comparing model performance, but to link predictive capability with process understanding by identifying the key drivers and critical thresholds governing reactor stability. In this study, multiple linear regression (MLR), artificial neural networks (ANN), and support vector regression (SVR) are evaluated to predict COD removal efficiency in the treatment of 2,4-dichlorophenol wastewater using a pilot-scale SAnMBR, addressing a key gap in the existing literature. The selection of 2,4-DCP as the target compound is specifically motivated by its well-documented inhibitory effects on anaerobic biological processes and its persistence in industrial effluents, making it a representative model pollutant for assessing system behaviour under phenolic shock loading conditions. Unlike readily biodegradable organics, 2,4-DCP introduces toxicity-driven non-linear responses that manifest at the system level, influencing overall reactor performance and stability rather than directly measured microbial activity (Li et al. 2024). Given the highly non-linear and coupled

nhờ khả năng dự báo tổng quát, nhưng bắt nguồn từ các tương tác vốn phức tạp và phi tuyến giữa các hợp chất ức chế (ví dụ: 2,4-DCP), hoạt động của vi sinh vật và các thông số vận hành như pH và tải hữu cơ (OLR), vốn không thể được mô tả đầy đủ bằng các mô hình cơ chế hoặc tuyến tính thông thường. Các tương tác này còn trở nên phức tạp hơn do ngưỡng độc tính và hiện tượng vi sinh vật thích nghi, trong đó hiệu suất hệ thống có thể thay đổi đột ngột khi chịu tải sốc phenol, khiến các phương pháp mô hình hóa tất định không còn đủ hiệu quả. Việc ứng dụng học máy (ML) trong các hệ thống bể phản ứng sinh học màng (MBR) đã tăng đáng kể trong những năm gần đây (Muniz de Queiroz et al. 2025). Cụ thể, các nghiên cứu trước đây cho thấy các mô hình dựa trên dữ liệu có thể mô tả thành công động lực phi tuyến và tác động ức chế trong các hệ thống màng kỵ khí, nơi hành vi của quá trình chịu ảnh hưởng mạnh từ sự thích nghi của vi sinh vật và các ngưỡng độc tính (Lai et al. 2024; Xu et al. 2026; Yu et al. 2026). Chẳng hạn, Zhong và cộng sự (Zhong et al. 2022) đã sử dụng mô hình tuyến tính, cây quyết định, học tập tổ hợp, mô hình láng giềng gần nhất và máy véc-tơ hỗ trợ để dự báo chất lượng nước của một MBR xử lý nước thải có độ mặn cao chứa amoni nitơ. Yaqub và Lee (Yaqub and Lee 2022) đã sử dụng một mô hình tổ hợp có tên là tăng cường gradient cực đại (XGB) để dự báo lượng nitơ tổng (TN), photpho tổng (TP) và amoni (NH_4^+) được loại bỏ trong một MBR kỵ khí-thiếu khí-hiếu khí tại nhà máy xử lý nước thải, đồng thời sử dụng các mạng nơ-ron nhân tạo (ANN). Để dự báo nồng độ (NH_4^+) và TN trong nước đầu ra của một MBR xử lý nước thải sinh hoạt, Zhuang và cộng sự (Zhuang et al. 2021) đã đánh giá nhiều mô hình, bao gồm cây hồi quy, rừng ngẫu nhiên, tăng cường thích ứng, hồi quy tăng cường gradient và mạng nơ-ron sâu. Bất chấp những tiến bộ này, hầu hết các nghiên cứu hiện có vẫn tập trung vào độ chính xác dự báo, ít chú ý đến việc rút ra các hiểu biết có giá trị cho kỹ thuật.


chẳng hạn như các ngưỡng vận hành và giới hạn ổn định của hệ thống. Do đó, việc ứng dụng ML trong nghiên cứu này được biện minh cụ thể nhằm giải quyết hành vi ức chế phi tuyến và xác định khoảng vận hành chi phối hiệu suất loại bỏ COD trong điều kiện sốc phenolic. Cách tiếp cận này giúp chuyển đổi dữ liệu quy trình phức tạp thành những hiểu biết kỹ thuật có thể áp dụng, điều mà các phương pháp mô hình hóa thông thường không thể đạt được.

Mặc dù ML được sử dụng rộng rãi trong các MBR, việc so sánh có hệ thống các kỹ thuật phi tuyến tiên tiến cũng như phân tích khả năng diễn giải vẫn còn hạn chế, đặc biệt khi vận hành các MBR kỵ khí chìm (SAnMBR) dưới tải sốc phenolic cao trong thời gian dài. Các nghiên cứu thường chỉ tập trung tối đa hóa hệ số tương quan mà không tìm hiểu lý do mô hình hoạt động hiệu quả. Vì vậy, mục tiêu của nghiên cứu này không chỉ là so sánh hiệu suất mô hình mà còn kết nối năng lực dự đoán với hiểu biết về quy trình bằng cách xác định các yếu tố chi phối chính và ngưỡng tới hạn quyết định độ ổn định của thiết bị phản ứng. Trong nghiên cứu này, hồi quy tuyến tính bội (MLR), mạng nơ-ron nhân tạo (ANN) và hồi quy véc-tơ hỗ trợ (SVR) được đánh giá nhằm dự đoán hiệu suất loại bỏ COD trong quá trình xử lý nước thải chứa 2,4-dichlorophenol bằng SAnMBR quy mô thí điểm, qua đó giải quyết một khoảng trống quan trọng trong các tài liệu hiện có. Việc lựa chọn 2,4-DCP làm hợp chất mục tiêu xuất phát từ tác động ức chế đã được ghi nhận rõ ràng của chất này đối với các quá trình sinh học kỵ khí và tính bền vững của nó trong nước thải công nghiệp, khiến nó trở thành chất ô nhiễm mô hình tiêu biểu để đánh giá trạng thái hoạt động của hệ thống trong điều kiện tải sốc phenolic. Khác với các hợp chất hữu cơ dễ phân hủy sinh học, 2,4-DCP gây ra các đáp ứng phi tuyến do độc tính, biểu hiện ở cấp độ hệ thống và ảnh hưởng đến hiệu suất cũng như độ ổn định tổng thể của thiết bị phản ứng, thay vì tác động trực tiếp đến hoạt động vi sinh vật được đo lường (Li et al. 2024). Xét đến tính phi tuyến cao và sự liên kết chặt chẽ giữa các yếu tố...

Fig. 1 Schematic diagram of the submerged anaerobic membrane bioreactor



Hình 1. Sơ đồ nguyên lý của thiết bị phản ứng sinh học màng kỵ khí chìm



nature of the SAnMBR system, particularly under phenolic shock conditions, model interpretability cannot rely on simple coefficient-based or linear sensitivity approaches. Therefore, Partial Dependence Plots (PDPs) are specifically employed to isolate and visualize the marginal effect of individual input variables (e.g., pH and 2,4-DCP) on COD removal while averaging out the influence of other interacting parameters. In parallel, sensitivity analysis is applied to quantitatively rank the relative importance of each variable across its full operational range, enabling identification of dominant drivers under varying conditions. The most effective model is quantified by PDPs and Sensitivity Analysis on the best-performing parameter (e.g., pH, 2,4-DCP concentration). The combined use of these two complementary methods is essential, as PDPs enable the interpretation of non-linear response behaviour and threshold effects, while sensitivity analysis provides a quantitative measure of parameter importance across the operational range, supporting engineering decision-making in complex biological systems (Lai et al. 2024). These interpretability tools enable the translation of model outputs into engineering insights, such as defining safe loading limits, identifying inhibition zones, and distinguishing between biologically controlled processes and fouling-driven operational constraints. To the best of our knowledge, this is the first study to compare these models for long-term SAnMBR treatment of phenolic wastewater. Therefore, this work advances beyond conventional ML applications by integrating prediction with operational decision-making in SAnMBR systems. By combining high-accuracy prediction with deep interpretability, the resulting framework can support the development of real-time control strategies (optimal pH ranges, safe 2,4-DCP loading limits), enhancing process stability, reducing operational expenditure, and advancing the practical digital deployment of SAnMBR technology.

2 Materials and Methods

2.1 Experimental Setup

The experimental setup of the SAnMBR is shown in Fig. 1. The reactor was made of Plexiglas with an effective volume of 8 L and a total volume of 8.733 L. The system was operated as a continuous-flow SAnMBR under long-term dynamic loading conditions (189 days), incorporating a full membrane module and process control strategy representative of practical operation. This SAnMBR was operated over a period of 189 days. The injection of 2,4-dichlorophenol (2,4-DCP) commenced on day 118, after achieving stable baseline reactor performance, in order to systematically evaluate the system response to controlled phenolic shock

loading. The organic loading rate (OLR) was gradually varied between 0.125 and 0.798 kg COD/m³·day to assess system performance under diverse operational conditions. Water-jacket compartments were installed on bothsides of the reactor and the reactor temperature was maintained at 36±1 °C by a circulating water bath. This controlled mesophilic temperature was selected to maintain stable anaerobic conditions and eliminate external variability associated with ambient temperature fluctuations. The membrane module was composed of a submerged hollow fiber polypropylene membrane (Hydrol, UK) with an area of 0.1 m². Influent and effluent flows were regulated using two parallel peristaltic pumps (Shiva Amvaj, Iran), controlled via a digital multi-timer (Shiva Amvaj, Isfahan, Iran). To minimize evaporation and salt accumulation in the water bath, distilled water was used, and the bath surface was covered with plastic film.

2.2 Experimental Procedure

The reactor was seeded with 2000 mL of digested sludge obtained from the South Tehran municipal wastewater treatment plant. Prior to seeding, the sludge was thoroughly washed with tap water to remove impurities and characterized for total suspended solids (TSS: 21,082 mg/L) and volatile suspended solids (VSS: 12,937 mg/L).

Synthetic wastewater was freshly prepared daily, containing glucose as the primary carbon source along with essential macro- and micronutrients sourced from Merck (KGaA, Germany). Nutrient concentrations were dosed per gram of COD as follows: NH₄Cl (76.45 mg/g COD), KH₂PO₄ (10.00 mg/g COD), and trace elements including K₂HPO₄ (25.32), FeCl₃ (1.021), CaCl₂·2 H₂O (2.06), MgSO₄·7 H₂O (2.14), MnSO₄·H₂O (0.355), CoCl₂·6 H₂O (0.092), NiSO₄·6 H₂O (0.0763), ZnSO₄ (0.1055), (NH₄) Mo₇O₂₄·4 H₂O (0.4198), CuSO₄·5 H₂O (0.0321), and H₃BO₃ (0.020). The reactor was operated continuously, with 2,4-DCP concentrations gradually increased from 5 mg/L to 300 mg/L following its initial injection. System performance was assessed by monitoring COD and 2,4-DCP removal efficiencies under different loading regimes.

2.3 Analytical Methods

Physicochemical parameters including temperature, pH, COD, turbidity, TSS, TDS, VSS, 2,4-DCP concentration and electrical conductivity (EC) were monitored throughout the study. COD and phenol concentrations were determined using the closed reflux colorimetric method (APHA 5220D) and direct photometric method (APHA 5530D), respectively, with a DR 6000 spectrophotometer (Hach, Germany). Turbidity was measured using the nephelometric method with a Hach 2100AN turbidimeter..

do đặc thù của hệ thống SAnMBR, đặc biệt trong điều kiện sốc phenol, không thể diễn giải mô hình chỉ dựa trên các hệ số đơn giản hoặc phương pháp phân tích độ nhạy tuyến tính. Vì vậy, Biểu đồ phụ thuộc từng phần (PDP) được sử dụng riêng để cô lập và trực quan hóa tác động biên của từng biến đầu vào (ví dụ: pH và 2,4-DCP) lên hiệu suất loại bỏ COD, đồng thời lấy trung bình ảnh hưởng của các thông số tương tác khác. Song song đó, phân tích độ nhạy được áp dụng để xếp hạng định lượng tầm quan trọng tương đối của từng biến trong toàn bộ phạm vi vận hành, qua đó xác định các yếu tố chi phối trong những điều kiện khác nhau. Mô hình hiệu quả nhất được định lượng bằng PDP và phân tích độ nhạy đối với thông số có hiệu suất tốt nhất (ví dụ: pH, nồng độ 2,4-DCP). Việc kết hợp hai phương pháp bổ trợ này là thiết yếu: PDP giúp diễn giải hành vi đáp ứng phi tuyến và các hiệu ứng ngưỡng, trong khi phân tích độ nhạy cung cấp thước đo định lượng về tầm quan trọng của thông số trong toàn bộ phạm vi vận hành, hỗ trợ ra quyết định kỹ thuật trong các hệ thống sinh học phức tạp (Lai và cộng sự, 2024). Những công cụ diễn giải này cho phép chuyển đổi đầu ra mô hình thành các thông tin chuyên môn kỹ thuật, chẳng hạn như xác định giới hạn tải an toàn, nhận diện vùng ức chế và phân biệt các quá trình được kiểm soát về mặt sinh học với những hạn chế vận hành do tắc nghẽn gây ra. Theo hiểu biết của chúng tôi, đây là nghiên cứu đầu tiên so sánh các mô hình này trong xử lý nước thải chứa phenol dài hạn bằng SAnMBR. Vì vậy, nghiên cứu này vượt ra ngoài các ứng dụng được máy thông thường khi kết hợp dự đoán với việc ra quyết định vận hành trong các hệ thống SAnMBR. Bằng cách kết hợp khả năng dự đoán có độ chính xác cao với khả năng diễn giải sâu, khuôn khổ này có thể hỗ trợ phát triển các chiến lược điều khiển thời gian thực (phạm vi pH tối ưu, giới hạn tải 2,4-DCP an toàn), tăng cường độ ổn định của quy trình, giảm chi phí vận hành và thúc đẩy triển khai thực tiễn công nghệ SAnMBR trên nền tảng số.

2 Vật liệu và Phương pháp

2.1 Thiết lập thí nghiệm

Thiết lập thí nghiệm của SAnMBR được trình bày trong Fig. 1. Lò phản ứng được chế tạo bằng Plexiglas, có thể tích hiệu dụng 8 L và tổng thể tích 8.733 L. Hệ thống vận hành như một SAnMBR dòng chảy liên tục trong điều kiện tải động (189 ngày), bao gồm một màng lọc mô-đun màng và chiến lược điều khiển quy trình đại diện cho hoạt động thực tế. SAnMBR này được vận hành trong khoảng thời gian 189 ngày. Việc bổ sung 2,4-dichlorophenol (2,4-DCP) bắt đầu vào ngày thứ 118, sau khi hiệu suất nền của thiết bị phản ứng đã ổn định, nhằm tiến hành một cách có hệ thống đánh giá phản ứng của hệ thống trước cú sốc phenolic có kiểm soát.

tải trọng. Tốc độ tải trọng hữu cơ (OLR) được điều chỉnh dần trong khoảng 0.125–0.798 kg COD/m³·ngày để đánh giá hiệu suất hệ thống trong các điều kiện vận hành đa dạng. Các khoang áo nước được lắp ở hai bên của thiết bị phản ứng, và nhiệt độ thiết bị được duy trì ở mức 36 ± 1 °C bằng bể nước tuần hoàn. Nhiệt độ trung ôn được kiểm soát này nhằm duy trì điều kiện kỵ khí ổn định và loại bỏ sự biến động bên ngoài do dao động nhiệt độ môi trường. Mô-đun màng gồm một màng sợi rỗng polypropylene ngập nước (Hydrol, Vương quốc Anh), có diện tích 0,1 m². Lưu lượng dòng vào và dòng ra được điều chỉnh bằng hai bơm nhu động song song (Shiva Amvaj, Iran), điều khiển thông qua bộ hẹn giờ kỹ thuật số đa năng (Shiva Amvaj, Isfahan, Iran). Để giảm thiểu sự bay hơi và tích tụ muối trong bể nước, nước cất được sử dụng và bề mặt bể được phủ màng nhựa.

2.2 Quy trình thực nghiệm

Lò phản ứng được nạp 2000 mL bùn đã phân hủy lấy từ nhà máy xử lý nước thải đô thị Nam Tehran. T rước khi nạp, bùn được rửa kỹ bằng nước máy để loại bỏ tạp chất, đồng thời xác định hàm lượng chất rắn lơ lửng tổng số (TSS: 21.082 mg/L) và chất rắn lơ lửng bay hơi (VSS: 12.937 mg/L).

Nước thải tổng hợp được pha mới mỗi ngày, sử dụng glucose làm nguồn carbon chính cùng với các nguyên tố đa lượng và vi lượng thiết yếu từ Merck (KGaA, Đức). Nồng độ các chất dinh dưỡng được định lượng theo mỗi gam COD như sau: NH₄Cl (76.45 mg/g COD), KH₂PO₄ (10.00 mg/g COD) và các nguyên tố vi lượng gồm K₂HPO₄ (25.32), FeCl₃ (1.021), CaCl₂·2 H₂O (2.06), MgSO₄·7 H₂O (2.14), MnSO₄·H₂O (0.355), CoCl₂·6 H₂O (0.092), NiSO₄·6 H₂O (0.0763), ZnSO₄ (0.1055), (NH₄) Mo₇O₂₄·4 H₂O (0.4198), CuSO₄·5 H₂O (0.0321) và H₃BO₃ (0.020). Thiết bị phản ứng được vận hành liên tục; sau lần cấp ban đầu, nồng độ 2,4-DCP được tăng dần từ 5 mg/L lên 300 mg/L. Hiệu suất hệ thống được đánh giá bằng cách theo dõi hiệu suất loại bỏ COD và 2,4-DCP ở các chế độ tải trọng khác nhau.

2.3 Các phương pháp phân tích

Các thông số hóa lý bao gồm nhiệt độ, pH, COD, độ đục, TSS, TDS, VSS, nồng độ 2,4-DCP và độ dẫn điện (EC) được theo dõi trong suốt nghiên cứu. Nồng độ COD và phenol lần lượt được xác định bằng phương pháp hồi lưu kín đơ màu (APHA 5220D) và phương pháp đo quang trực tiếp (APHA 5530D), sử dụng máy quang phổ DR 6000 (Hach, Đức). Độ đục được đo bằng phương pháp đo độ đục nephelometric với máy đo độ đục Hach 2100AN.




Fig. 2 Architecture of the ANN model (6-N-1 structure)




Fig. 3 Schematic workflow of the machine learning modelling process, including data preprocessing, model development, evaluation, and interpretability analysis

pH was adjusted using 0.1 N H_2SO_4 and 0.1 N NaOH and measured with a multi-parameter analyser (CON-SORT C831, Belgium). TSS, TDS, and VSS were analysed in accordance with APHA Standard Methods 2540 C, 2540D, and 2540E. For TSS, 25 mL samples were filtered through pre-weighed Whatman GF/C filters (UK), dried at 103–105 °C for 24 h (Mettler oven), cooled in a desiccator, and reweighed. TDS was determined by evaporating 25 mL samples at 180 °C until a constant weight was achieved.

VSS was calculated by igniting the TSS filters at 550 °C for 30 min in a muffle furnace (Nabertherm, Germany), followed by cooling and reweighing. All measurements were conducted in triplicate, and average values were reported.

2.4 Data Acquisition and Pre-processing


The predictive modelling analysis was based on an experimental dataset collected throughout the operational period of the Submerged Anaerobic Membrane Bioreactor (SAnMBR). In total, 189 valid data points were obtained, with no missing entries. The selection of input features (X) was guided by their known relevance to biological wastewater treatment and their operational importance in the SAnMBR process. Six independent variables were used in the modelling: influent COD (mg/L), organic loading rate (OLR, gCOD/m³·day), influent 2,4-dichlorophenol (mg/L), influent turbidity (NTU), influent TSS (g/L), and influent pH. The dependent variable (Y) was the COD removal percentage (%). To ensure reliable model training and evaluation, the dataset was randomly divided into two parts: 70% (around 132 samples) for model training and the remaining 30% (around 56 samples) for testing. This division allowed the trained models to be evaluated on data they had not previously encountered, providing a fair assessment of their generalization capability. Prior to normalization, the dataset was first split into training and testing subsets. The Min–Max scaling parameters were then fitted using only the training data and subsequently applied to both training and testing sets. All input features were normalized using the Min–Max scaling method to rescale their values to the [0,1] range. This normalization step avoided bias toward variables with larger numerical ranges and ensured that each input contributed equally during training.

2.5 Predictive Machine Learning Model Implementation


Three distinct machine learning algorithms, Support Vector Regression (SVR), Artificial Neural Networks (ANN), and Multiple Linear Regression (MLR), were implemented and benchmarked to predict the COD removal efficiency.

2.5.1 Multiple Linear Regression (MLR)

Regression models are widely used in a variety of fields to define relationships among multiple parameters; resulting equations can then be applied to water and wastewater treatment problems. In order to evaluate the inherent linearity of the SAnMBR system's response, the MLR model served as the foundational baseline. MLR uses an ordinary least-squares method in order to establish a simple linear



Hình 2 Kiến trúc của mô hình ANN (cấu trúc 6-N-1)



Hình 3. Sơ đồ quy trình mô hình hóa học máy, bao gồm tiền xử lý dữ liệu, phát triển mô hình, đánh giá và phân tích khả năng diễn giải

pH được điều chỉnh bằng H_2SO_4 0,1 N và NaOH 0,1 N, sau đó đo bằng máy phân tích đa thông số (CON-SORT C831, Bỉ). TSS, TDS và VSS được phân tích theo các Phương pháp Tiêu chuẩn APHA 2540 C, 2540D và 2540E. Để xác định TSS, mẫu 25 mL được lọc qua giấy lọc Whatman GF/C (Vương quốc Anh) đã cân trước, sấy ở 103–105 °C trong 24 giờ (tủ sấy Mettler), làm nguội trong bình hút ẩm rồi cân lại. TDS được xác định bằng cách làm bay hơi mẫu 25 mL ở 180 °C cho đến khi đạt khối lượng không đổi.

VSS được xác định bằng cách nung các màng lọc TS ở 550 °C trong 30 phút trong lò nung (Nabertherm, Đức), sau đó để nguội và cân lại. Tất cả các phép đo được thực hiện ba lần và báo cáo giá trị trung bình.

2.4 Thu thập dữ liệu và tiền xử lý

Phân tích mô hình dự đoán dựa trên bộ dữ liệu thực nghiệm được thu thập trong suốt thời gian vận hành của hệ thống sinh học màng kỵ khí chìm (SAnMBR). Tổng cộng thu được 189 điểm dữ liệu hợp lệ, không có giá trị nào bị thiếu. Việc lựa chọn các đặc trưng đầu vào (X) được định hướng bởi mức độ liên quan đã biết của chúng đối với xử lý nước thải sinh học và tầm quan trọng trong vận hành quy trình SAnMBR. Sáu biến độc lập được sử dụng trong mô hình: COD đầu vào (mg/L), tốc độ tải hữu cơ (OLR, gCOD/m³·ngày), 2,4-dichlorophenol đầu vào (mg/L), độ đục đầu vào (NTU), TSS đầu vào (g/L) và pH đầu vào. Biến phụ thuộc (Y) là tỷ lệ loại bỏ COD (%). Để đảm bảo quá trình huấn luyện và đánh giá mô hình đáng tin cậy, bộ dữ liệu được chia ngẫu nhiên thành hai phần: 70% (khoảng 132 mẫu) dùng để huấn luyện mô hình và 30% còn lại (khoảng 56 mẫu) dùng để kiểm tra. Cách phân chia này cho phép đánh giá các mô hình đã huấn luyện trên những dữ liệu mà chúng chưa từng gặp trước đó, qua đó đánh giá công bằng khả năng khái quát hóa. Trước khi chuẩn hóa, bộ dữ liệu được chia thành các tập huấn luyện và kiểm tra. Sau đó, các tham số chuẩn hóa Min–Max chỉ được khớp bằng dữ liệu huấn luyện rồi áp dụng cho cả tập huấn luyện lẫn tập kiểm tra. Tất cả các đặc trưng đầu vào đều được chuẩn hóa bằng phương pháp Min–Max để đưa giá trị về khoảng [0,1]. Bước chuẩn hóa này giúp tránh thiên lệch về phía các biến có phạm vi giá trị số lớn hơn và đảm bảo mỗi đầu vào đóng góp như nhau trong quá trình huấn luyện.

2.5 Triển khai mô hình học máy dự đoán

Ba thuật toán học máy khác nhau, Hồi quy Vector Hỗ trợ (SVR), Mạng Nơ-ron Nhân tạo (ANN) và Hồi quy Tuyến tính Đa biến (MLR), đã được triển khai và đánh giá để dự đoán hiệu suất loại bỏ COD.

2.5.1 Hồi quy tuyến tính bội (MLR)

Các mô hình hồi quy được sử dụng rộng rãi trong nhiều lĩnh vực để xác định mối quan hệ giữa nhiều tham số; các phương trình thu được sau đó có thể được áp dụng cho các bài toán xử lý nước và nước thải. Để đánh giá tính tuyến tính vốn có trong phản hồi của hệ thống SAnMBR, mô hình MLR được dùng làm đường cơ sở nền tảng. MLR sử dụng phương pháp bình phương tối thiểu thông thường để thiết lập một mô hình tuyến tính đơn giản.

relationship between the six input variables (X) and the target output (Y). The MLR model is represented by the linear Eq. (1) (Gyparakis et al. 2025):

$$Y = \beta_0 + \sum_{i=1}^6 \beta_i x_i$$
 (1)

Here, Y represents the predicted COD removal percentage, x_i are the independent parameters, β_i are the corresponding constant coefficients (or weights), and β₀ is the intercept. The primary purpose of MLR was to provide a quantitative benchmark against which the performance gains achieved by the non-linear SVR and ANN models could be judged.

2.5.2 Support Vector Regression (SVR)

In order to address the complex, non-linear nature of environmental datasets, SVR was selected as the primary non-linear predictive tool. This model was chosen because of its highgeneralization capacity, which is crucial when using complex, non-linear environmental datasets. This model uses a kernel function to map the six input features to a high-dimensional space, converting the non-linear regression problem into a linear one. As a result of rigorous optimization, the Radial Basis Function (RBF) kernel was selected, as it was most effective at capturing biological treatment dynamics. The model’s performance was fine-tuned by optimizing the key hyperparameters, namely the penalty parameter (C) and the kernel width (γ) (Najafzadeh and Niazmardi 2021).

2.5.3 Artificial Neural Network (ANN)

Artificial neural network conceptsdate back to early artificial neuron models introduced in the 1940s is fundamentally based on simulating the structure and function of biological nervous systems. As a result of the introduction of the

backpropagation training algorithm, artificial neural networks can represent complex, non-linear functionality using fewer parameters. This capability has led to extensive use in a variety of fields, including water quality modelling, medicine, and engineering (Reza et al. 2024). In order to balance the complexity against the risk of overfitting, the developed MLP network structure (6-N-1) was systematically tuned to determine the optimal number of neurons (N) in the hidden layer. The network architecture, which defines the flow of information through the system, is visually represented in Fig. 2. The architecture consists of: (1) an Input Layer with 6 neurons, receiving the normalized input features; (2) one Hidden Layer using the tansig (tangent sigmoid) transfer function to introduce non-linearity; and (3) a single Output Layer neuron using the purelin (linear) function to yield the final COD Removal prediction. The network was trained in a standard computational environment (Python), replicating the desired output based on unseen inputs in accordance with the provided training data.

2.5.4 Computational Tools and Environment

All machine learning models, including SVR, ANN, and MLR, as well as the interpretability analyses such as Partial Dependence Plots (PDP) and sensitivity analysis, were implemented using Python (Version 3.10). The modelling tasks were performed using the Scikit-learn library (version 1.2.2) for SVR and MLR, while the ANN model was developed using the TensorFlow/Keras framework. Data preprocessing, including normalization and dataset splitting, was carried out using the Pandas library, and visualization was performed using Matplotlib and Seaborn.

The overall modelling workflow is illustrated in Fig. 3, which summarizes the sequential steps from data acquisition to model interpretation.

As shown in Fig. 3, the modelling workflow follows a sequential process from data acquisition to model

mối quan hệ giữa sáu biến đầu vào (X) và đầu ra mục tiêu (Y). Mô hình MLR được biểu diễn bằng phương trình tuyến tính (1) (Gyparakis et al. 2025):

$$Y = \beta_0 + \sum_{i=1}^6 \beta_i x_i$$
 (1)

Ở đây, Y biểu thị tỷ lệ phần trăm loại bỏ COD dự đoán, x_i là các tham số độc lập, β_i là các hệ số hằng tương ứng (hoặc trọng số), và β₀ là hệ số chặn. Mục đích chính của MLR là cung cấp một hiệu suất so với chuẩn định lượng các mức cải thiện đạt được nhờ các mô hình SVR và ANN phi tuyến tính có thể được đánh giá.

2.5.2 Hồi quy vectơ hỗ trợ (SVR)

Để xử lý bản chất phức tạp, phi tuyến của các tập dữ liệu môi trường, SVR được chọn làm công cụ dự báo phi tuyến chính. Mô hình này được lựa chọn vì khả năng khái quát hóa cao của nó, điều rất quan trọng khi sử dụng các bộ dữ liệu môi trường phức tạp, phi tuyến. Mô hình SVR sử dụng một hàm kernel để ánh xạ sáu đặc trưng đầu vào thành một không gian nhiều chiều, chuyển đổi bài toán hồi quy phi tuyến thành bài toán tuyến tính. Là kết quả của quá trình nghiên cứu, kernel Hàm Cơ sở Hướn tâm (RBF) được chọn vì đây là cách hiệu quả nhất để nắm bắt các đặc điểm sinh học động lực học điều trị. Hiệu suất của mô hình được tinh chỉnh bằng cách tối ưu hóa các siêu tham số chính, cụ thể là các tham số phạt (C) và độ rộng kernel (γ) (Najafzadeh và Niazmardi 2021).

2.5.3 Mạng nơ-ron nhân tạo (ANN)

Các khái niệm về mạng nơ-ron nhân tạo có từ những mô hình nơ-ron nhân tạo sơ khai được giới thiệu vào những năm 1940, về cơ bản dựa trên việc mô phỏng cấu trúc và chức năng của các hệ thần kinh sinh học. Do việc đưa vào của

Với thuật toán huấn luyện lan truyền ngược, mạng nơ-ron nhân tạo có thể biểu diễn các hàm phi tuyến phức tạp bằng cách sử dụng ít tham số hơn. Khả năng này đã dẫn đến việc ứng dụng rộng rãi trong nhiều lĩnh vực, bao gồm mô hình hóa chất lượng nước, y học và kỹ thuật (Reza et al. 2024). Để cân bằng độ phức tạp với nguy cơ quá khớp, cấu trúc mạng MLP được phát triển (6-N-1) đã được tinh chỉnh có hệ thống nhằm xác định số nơ-ron tối ưu (N) trong lớp ẩn. Kiến trúc mạng, xác định luồng thông tin qua hệ thống, được minh họa trực quan trong Hình 2. Kiến trúc gồm: (1) Lớp đầu vào với 6 nơ-ron, tiếp nhận các đặc trưng đầu vào đã chuẩn hóa; (2) một lớp ẩn sử dụng hàm truyền tansig (sigmoid tang) để tạo tính phi tuyến; và (3) một nơ-ron duy nhất ở lớp đầu ra sử dụng hàm purelin (tuyến tính) để đưa ra dự đoán cuối cùng về mức loại bỏ COD. Mạng được huấn luyện trong môi trường tính toán tiêu chuẩn (Python), tái tạo đầu ra mong muốn dựa trên các đầu vào chưa từng thấy, phù hợp với dữ liệu huấn luyện được cung cấp.


2.5.4 Công cụ tính toán và môi trường

Tất cả các mô hình học máy, bao gồm SVR, ANN và MLR, cũng như các phân tích khả năng diễn giải như PDP và phân tích độ phụ thuộc từng phần (PDP) và phân tích độ nhạy đều được triển khai bằng Python (phiên bản 3.10). Các tác vụ mô hình hóa được thực hiện bằng thư viện Scikit-learn (phiên bản 1.2.2) cho SVR và MLR, trong khi mô hình ANN được phát triển bằng khung TensorFlow/Keras. Việc tiền xử lý dữ liệu, bao gồm chuẩn hóa và chia tập dữ liệu, được thực hiện bằng thư viện Pandas; quá trình trực quan hóa được thực hiện bằng Matplotlib và Seaborn.


Quy trình mô hình hóa tổng thể được minh họa trong Hình 3, tóm tắt các bước tuần tự từ thu thập dữ liệu đến diễn giải mô hình.

Như thể hiện trong Hình 3, quy trình mô hình hóa tuân theo trình tự từ thu thập dữ liệu đến mô hình.

Fig. 4 Time series of COD removal efficiency and OLR in the SAnMBR system



Hình 4 Chuỗi thời gian về hiệu suất loại bỏ COD và OLR trong hệ thống SAnMBR



interpretation. The process begins with experimental data collection (189 observations), followed by data preprocessing, including Min–Max normalization and division of the dataset into training (70%) and testing (30%) subsets. Subsequently, three machine learning models (MLR, ANN, and SVR) were developed to capture the relationship between input variables and COD removal efficiency. Model performance was then evaluated using statistical metrics, including the coefficient of determination (R^2) and root mean square error (RMSE), along with residual analysis. Based on these criteria, the best-performing model (SVR) was selected for further analysis.

The modelling process consisted of data preparation, model training using the training dataset, and performance evaluation using an independent test dataset based on R^2 and RMSE metrics. For model interpretation, PDPs were generated to examine the influence of individual input variables on the predicted COD removal by varying one parameter while keeping others unchanged within the dataset context. In addition, sensitivity analysis was conducted by systematically varying each input variable within its observed range and evaluating the corresponding changes in the model output to quantify the relative importance of the parameters.

2.6 Model Evaluation Criteria


In order to assess the predictive accuracy and robustness of the MLR, ANN, and SVR models, an independent test set was utilized. The coefficient of determination (R^2) and the root mean square error (RMSE) were used as two universally accepted statistical metrics. The R^2 value is defined by Eq. (2):

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2)$$

where y_i represents the observed values, $\hat{y}_i$ denotes the predicted values, $\bar{y}$ is the mean of the observed values, and n is the total number of data points. A positive R^2 value indicates that a portion of the target variable's variance is successfully predicted by the model, indicating a good fit (values close to 1 are considered ideal). The RMSE is calculated as Eq. (3):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

Fig. 5 Temporal variation of removal efficiencies (left axis) and corresponding influent and effluent concentrations (right axis) of COD, 2,4-dichlorophenol (2,4-DCP), turbidity, and TSS during the 189-day operation of the SAnMBR system.




diễn giải. Quá trình bắt đầu với dữ liệu thực nghiệm tập hợp (189 quan sát), tiếp theo là tiền xử lý dữ liệu, bao gồm chuẩn hóa Min–Max và chia tập chia tập dữ liệu thành các tập con huấn luyện (70%) và kiểm thử (30%). Sau đó, ba mô hình học máy (MLR, ANN và SVR) được phát triển để nắm bắt mối quan hệ giữa các biến đầu vào và hiệu suất loại bỏ COD. Hiệu năng của mô hình sau đó được đánh giá bằng các chỉ số thống kê, bao gồm hệ số xác định (R^2) và căn bậc hai của giá trị trung bình sai số bình phương trung bình căn (RMSE), cùng với phân tích phần dư. Dựa trên các tiêu chí này, mô hình hoạt động tốt nhất (SVR) là được chọn để phân tích sâu hơn.

Quy trình mô hình hóa bao gồm việc chuẩn bị dữ liệu, trong đó y_i biểu thị các giá trị quan sát được, $\hat{y}_i$ biểu thị các giá trị dự đoán, $\bar{y}$ là giá trị trung bình của các giá trị quan sát được và n là tổng số điểm dữ liệu. Giá trị R^2 dương cho biết mô hình dự đoán thành công một phần phương sai của biến mục tiêu, cho thấy mức độ phù hợp tốt (các giá trị gần 1 được xem là lý tưởng). RMSE được tính theo Công thức (3):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

Hình 5 Biến thiên theo thời gian của hiệu suất loại bỏ (trục bên trái) và nồng độ nước đầu vào, nước đầu ra tương ứng (trục bên phải) của COD, 2,4-dichlorophenol (2,4-DCP), độ đục và TSS trong quá trình vận hành hệ thống SAnMBR trong 189 ngày.



where the terms have the same meaning as defined above. RMSE quantified the average magnitude of prediction errors, with lower values indicating higher predictive accuracy.

3 Results and Discussion

3.1 SAnMBR Experimental Performance

The 189-day time series (Fig. 4) shows that COD removal rose during an initial acclimation period (Days 1–50) from ~43% to roughly 85–90% and then remained mostly between 80% and 95% despite large, staged increases in OLR (from ~125 to ~800 g COD m⁻³·d⁻¹). Several non-exclusive mechanisms can explain this behaviour.

A core advantage lies in membrane retention, which effectively decouples the Solids Retention Time (SRT) from hydraulic retention time (HRT). This separation enables the accumulation of slow-growing biomass, particularly methanogens, allowing the system to sustain efficient conversion of soluble organic matter (COD) into methane. As a result, stable COD removal is maintained under varying loading conditions, and the impact of transient hydraulic and organic stress is significantly reduced. This critical SRT effect has been repeatedly observed as a primary advantage of SAnMBR configurations (Robles et al. 2018). Furthermore, the maintained mesophilic temperature (36 ± 1 °C) and high mixed liquor concentrations typical of long-term MBR systems enhance COD degradation kinetics by stabilizing microbial activity and promoting enzyme-mediated reactions involved in hydrolysis and methanogenesis. Under mesophilic conditions, substrate utilization rates are more consistent and less sensitive to fluctuations, which supports

efficient conversion of soluble organic matter and reduces the risk of kinetic limitations at elevated OLRs (Khan et al. 2024). As a result, higher apparent degradation rates and improved process stability are achieved under variable loading conditions. System-level control strategies are also key contributors to resilience. This includes controlled feed step-changes and proactive fouling management (such as gas sparging, regular backwash, and chemical cleaning), all of which limit the likelihood that transient high loads or membrane fouling translate into long-term performance loss.

Additionally, the observed stability is partially attributable to microbial community adaptation. Under prolonged exposure to persistent substrates and phenolic compounds, a selective pressure is applied, which can increase the relative abundance of degraders and methanogens adapted to these recalcitrant substrates. Representative genera reported in similar anaerobic systems include syntrophic bacteria such as *Syntrophus* and *Syntrophorhabdus*, which are involved in the initial breakdown of aromatic compounds, and methanogenic archaea such as *Methanosaeta* and *Methanosarcina*, responsible for the final conversion of intermediates to methane (Muñoz Sierra et al. 2020). These microbial functions are consistent with those reported in comparable phenolic wastewater treatment systems. Where such favourable adaptation occurs, reactors show improved stability, which is highly consistent with the high removal rates seen in this campaign. However, it is important to note that performance can significantly decline past reactor-specific OLR thresholds.

Figure 5 illustrates the variation in COD, 2,4-DCP, turbidity, and TSS removal efficiencies during stepwise increases in the organic loading rate (OLR).

The COD removal rate remained high throughout the experiment (85–95%), with short-term decreases of 5–8% following each increase in OLR, followed by rapid recovery. There was a transient accumulation of soluble microbial products (SMP) and extracellular polymeric substances (EPS) during stress conditions, which can cause these temporary drops. The EPS produced and released by microorganisms, together with SMP, can accumulate on membrane surfaces, causing fouling and limiting substrate diffusion. Comparable EPS and SMP accumulation has also been observed in AnMBRs operated under fluctuating organic loads and temperatures, where it was linked to reduced biodegradation performance (AbuKhadra et al. 2024; Medina et al. 2020).

Turbidity removal improved progressively from 60–65% in the early phases to approximately 75–80% in later stages, reflecting the gradual maturation of biomass and enhanced floc formation that improves colloid capture. TSS removal remained consistently high (>90–95%) across all phases,

trong đó các thuật ngữ có cùng ý nghĩa như đã được định nghĩa ở trên. RMSE định lượng độ lớn trung bình của dự đoán lỗi, trong đó các giá trị thấp hơn cho thấy khả năng dự đoán độ chính xác.

3 Kết quả và Thảo luận

3.1 Hiệu suất thực nghiệm của SAnMBR

Chuỗi thời gian 189 ngày (Hình 4) cho thấy khả năng loại bỏ COD tăng trong giai đoạn thích nghi ban đầu (Ngày 1–50) từ ~43% lên khoảng 85–90% rồi sau đó hầu như duy trì ở mức này từ 80% đến 95% bất chấp những mức tăng lớn, được thực hiện theo từng giai đoạn trong OLR (từ ~125 đến ~800 g COD m⁻³·d⁻¹). Có thể giải thích hiện tượng này bằng một số cơ chế không loại trừ lẫn nhau. Một lợi thế cốt lõi nằm ở khả năng giữ sinh khối của màng, giúp tách biệt hiệu quả thời gian lưu chất rắn (SRT) khỏi thời gian lưu thủy lực (HRT). Sự tách biệt này cho phép tích lũy sinh khối phát triển chậm, đặc biệt là các vi sinh vật sinh methane, giúp hệ thống duy trì quá trình chuyển hóa hiệu quả chất hữu cơ hòa tan (COD) thành methane. Nhờ đó, hiệu suất loại bỏ COD ổn định được duy trì trong các điều kiện tải lượng thay đổi, đồng thời tác động của các cú sốc thủy lực và hữu cơ nhất thời được giảm đáng kể. Tác động quan trọng của SRT này đã nhiều lần được ghi nhận là một ưu điểm chính của các cấu hình SAnMBR (Robles và cộng sự, 2018). Hơn nữa, nhiệt độ ưa ấm được duy trì (36 ± 1 °C) và nồng độ hỗn hợp bùn cao, vốn điển hình ở các hệ thống MBR vận hành dài hạn, giúp tăng cường động học phân hủy COD bằng cách ổn định hoạt động của vi sinh vật và thúc đẩy các phản ứng do enzyme xúc tác liên quan đến quá trình thủy phân và sinh methane. Trong điều kiện ưa ấm, tốc độ sử dụng cơ chất ổn định hơn và ít nhạy cảm với biến động hơn, qua đó hỗ trợ

chuyển hóa chất hữu cơ hòa tan hiệu quả và giảm nguy cơ giới hạn động học ở OLR cao (Khan et al. 2024). Nhờ đó, đạt được tốc độ phân hủy biểu kiến cao hơn và độ ổn định quy trình được cải thiện trong điều kiện tải biến động. Các chiến lược kiểm soát ở cấp hệ thống cũng góp phần quan trọng vào khả năng chống chịu. Những chiến lược này bao gồm điều chỉnh tải cấp liệu theo từng bước có kiểm soát và quản lý cấu bản chủ động (chẳng hạn như súc khí, rửa ngược định kỳ và vệ sinh bằng hóa chất), tất cả đều giúp hạn chế nguy cơ tải cao nhất thời hoặc hiện tượng cấu bản màng dẫn đến suy giảm hiệu suất lâu dài.

Ngoài ra, độ ổn định quan sát được một phần là nhờ sự thích nghi của quần xã vi sinh vật. Khi tiếp xúc kéo dài với các cơ chất khó phân hủy và hợp chất phenolic, áp lực chọn lọc được tạo ra, có thể làm tăng tỷ lệ tương đối của các vi sinh vật phân hủy và vi sinh vật sinh methane thích nghi với những cơ chế khó phân hủy này. Các chỉ đại diện được ghi nhận trong những hệ thống kỵ khí tương tự bao gồm các vi khuẩn cộng dưỡng như *Syntrophus* và *Syntrophorhabdus*, tham gia vào giai đoạn phân hủy ban đầu các hợp chất thơm, và các vi khuẩn cổ sinh methane như *Methanosaeta* và *Methanosarcina*, chịu trách nhiệm chuyển hóa các chất trung gian cuối cùng thành methane (Muñoz Sierra et al. 2020). Những chức năng vi sinh vật này phù hợp với các chức năng được ghi nhận trong những hệ thống xử lý nước thải chứa phenolic tương tự. Khi xảy ra sự thích nghi thuận lợi như vậy, các bể phản ứng cho thấy độ ổn định được cải thiện, hoàn toàn phù hợp với tỷ lệ loại bỏ cao ghi nhận trong đợt khảo sát này. Tuy nhiên, cần lưu ý rằng hiệu suất có thể giảm đáng kể khi vượt quá ngưỡng OLR riêng của từng bể phản ứng.

Hình 5 minh họa sự thay đổi hiệu suất loại bỏ COD, 2,4-DCP, độ đục và TSS trong quá trình tăng dần tải trọng hữu cơ (OLR).

Tỷ lệ loại bỏ COD duy trì ở mức cao trong suốt thí nghiệm (85–95%), với mức giảm ngắn hạn 5–8% sau mỗi lần tăng OLR, rồi nhanh chóng phục hồi. Trong điều kiện căng thẳng, các sản phẩm vi sinh hòa tan (SMP) và các chất polyme ngoại bào (EPS) tích tụ tạm thời, có thể gây ra những đợt sụt giảm này. EPS do vi sinh vật tạo ra và giải phóng, cùng với SMP, có thể tích tụ trên bề mặt màng, gây tắc nghẽn và hạn chế sự khuếch tán cơ chất. Tình trạng tích tụ EPS và SMP tương tự cũng được ghi nhận ở các AnMBR vận hành dưới tải trọng hữu cơ và nhiệt độ biến động, trong đó hiện tượng này có liên quan đến hiệu suất phân hủy sinh học suy giảm (AbuKhadra et al. 2024; Medina et al. 2020).

Hiệu quả loại bỏ độ đục tăng dần từ 60–65% ở các giai đoạn đầu lên khoảng 75–80% ở các giai đoạn sau, phản ánh sự trưởng thành dần của sinh khối và sự hình thành bông cặn được cải thiện, giúp tăng khả năng bắt giữ các hạt keo. Hiệu quả loại bỏ TSS duy trì ở mức cao ổn định (> 90–95%) trong tất cả các giai đoạn,





Fig. 6 Two-way partial dependence plot: influent pH versus influent 2,4-DCP



Hình 6 Biểu đồ phụ thuộc từng phần hai chiều: pH dòng vào so với 2,4-DCP dòng vào




Fig. 7 Pearson correlation heatmap showing the relationships between the six input variables and COD removal efficiency in the SAnMBR system.

Table 1 Comparative performance of the ANN, SVR, and MLR models based on statistical indicators (R^2 and RMSE) for the training and testing stages

Model	R^2 (Train)	R^2 (Test)	RMSE (Train)	RMSE (Test)
ANN	0.603	0.397	7.89	10.56
SVR	0.975	0.952	1.97	2.96
MLR	0.734	0.717	6.45	7.23

demonstrating the membrane’s reliable capacity for solids retention even during load disturbances. This stability aligns with findings from recent SAnMBR and AnMBR research, where membrane separation effectively maintains effluent clarity and solids polishing despite fluctuations in organic removal efficiency (He et al. 2020; Pacheco-Ruiz et al. 2021).

The removal of 2,4-DCP exhibited a more dynamic trend than bulk COD. During the initial period, removal efficiency was relatively low (<20–30%), but after microbial acclimation it increased steadily and stabilized at 80–95%. Minor reductions were observed after OLR increases, which were followed by rapid recovery. This lag compared to COD removal is typical for chlorinated phenolic compounds, where dechlorination and aromatic ring-cleavage steps are kinetically limiting and highly sensitive to substrate or toxicity shocks until dehalogenating microbial populations become fully established (Geng et al. 2020). Under longer hydraulic retention times (HRTs) and steady operating conditions, AnMBRs have been shown to achieve parallel high removals of COD and chlorophenols, as shown by Zhu et al. (2020), who reported average COD and 2-chlorophenol removals of approximately 93% and 94%, respectively, at HRTs of 48–96 h for an influent 2-chlorophenol concentration of 5–200 mg/L (Zhu et al. 2020).





Fig. 8 Residual Analysis of the Optimal SVR Model (Test Set). The plot shows the distribution of prediction errors (residuals) against the SVR model’s predicted COD removal values

When compared with recent literature on SAnMBR and AnMBR systems, the steady-state removal efficiencies observed in this study fall within the upper range of reported values, and the transient fluctuations are consistent with expected operational dynamics. A 189-day SAnMBR experiment treating 2,4-DCP wastewater achieved almost complete removal at stable load (COD≈99.6%, 2,4-DCP≈99.6%), confirming that once microbial communities are acclimated, phenolic degradation can reach efficiencies comparable to bulk organics. Other hybrid and submerged anaerobic membrane configurations have similarly demonstrated strong solids capture and high COD removal, with transient performance variations primarily governed by OLR step changes, HRT, and fouling management strategies (Wang et al. 2015). The slight differences between the present results and the plateau values reported in the literature may reflect differences in OLR ramping strategy, acclimation duration, phenolic compound type (2,4-DCP versus 2-CP), and fouling behaviour driven by SMP and EPS accumulation(Chen et al. 2017).

The two-dimensional partial dependence analysis was performed to investigate the complex bivariate interaction between influent pH and 2,4-DCP concentration, which were identified as the most influential parameters based on the sensitivity analysis results (Fig. 6), where they exhibited the highest relative impact compared to other operational variables. This analysis extends the interpretation beyond single-factor effects by examining how interacting operational variables influence SAnMBR performance. As shown in Fig. 6, the highest predicted COD removal efficiency (92–95%) is achieved only under the strict combination of low 2,4-DCP concentrations (<50 mg/L) and the optimal pH range (pH 8–9). This confirms the primary role of pH in maximizing microbial enzyme activity (Zhang et al. 2023).




Hình 7 Bản đồ nhiệt tương quan Pearson thể hiện mối quan hệ giữa sáu biến đầu vào và hiệu suất loại bỏ COD trong hệ thống SAnMBR.

Bảng 1 So sánh hiệu suất của các mô hình ANN, SVR và MLR dựa trên các chỉ số thống kê (R^2 và RMSE) trong giai đoạn huấn luyện và kiểm tra

Model	R^2 (Train)	R^2 (Test)	RMSE (Train)	RMSE (Test)
ANN	0.603	0.397	7.89	10.56
SVR	0.975	0.952	1.97	2.96
MLR	0.734	0.717	6.45	7.23

chứng minh khả năng xử lý chất rắn đáng tin cậy của màng lọc sinh học kỵ khí lai và màng ngập khác cũng như khả năng duy trì ngay cả khi xảy ra nhiễu tải. Sự ổn định này phải nhờ màng giữ chất rắn hiệu quả và mức lọc cùng với những phát hiện từ các nghiên cứu SAnMBR và AnMBR gần đây về những biến động hiệu suất nhất t nơi quá trình phân tách bằng màng duy trì hiệu quả dòng chảy và chịu ảnh hưởng của các thay đổi theo b độ trong và khả năng đánh bóng chất rắn bất chấp sự dao động của chất hữu cơ.

Khả năng loại bỏ 2,4-DCP có xu hướng biến động mạnh hơn so với COD tổng. Trong giai đoạn đầu, hiệu suất loại bỏ tương đối thấp (< 20–30%), nhưng sau khi vi sinh vật thích nghi, hiệu suất tăng đều và ổn định ở mức 80–95%. Hiệu suất giảm nhẹ sau các lần tăng OLR, rồi nhanh chóng phục hồi. Độ trễ này so với quá trình loại bỏ COD là đặc trưng của các hợp chất phenol clo hóa, trong đó các bước khử clo và phân cắt vòng thơm bị giới hạn về động học, đồng thời rất nhạy cảm với các cú sốc về cơ chất hoặc độc tính cho đến khi quần thể vi sinh vật khử halogen được thiết lập đầy đủ (Geng et al. 2020). Ở thời gian lưu thủy lực (HRT) dài hơn và điều kiện vận hành ổn định, các AnMBR đã cho thấy khả năng loại bỏ COD và chlorophenol đồng thời ở mức cao, như Zhu et al. (2020) đã chứng minh: hiệu suất loại bỏ COD và 2-chlorophenol trung bình lần lượt đạt khoảng 93% và 94% ở HRT 48–96 h, với nồng độ 2-chlorophenol đầu vào là 5–200 mg/L (Zhu et al. 2020).



Hình 8. Phân tích phần dư của mô hình SVR tối ưu (tập kiểm tra). Biểu đồ thể hiện phân bố sai số dự đoán (phần dư) theo các giá trị loại bỏ COD được mô hình SVR dự đoán.

Khi so sánh với các tài liệu gần đây về hệ thống SAnMBR và AnMBR, hiệu suất loại bỏ ở trạng thái ổn định quan sát được trong nghiên cứu này nằm trong nhóm giá trị cao được báo cáo, còn các dao động nhất thời phù hợp với động thái vận hành dự kiến. Một thí nghiệm SAnMBR kéo dài 189 ngày xử lý nước thải 2,4-DCP đạt mức loại bỏ gần như hoàn toàn ở tải trọng ổn định (COD ≈ 99.6%, 2,4-DCP ≈ 99.6%), xác nhận rằng khi quần xã vi sinh vật đã thích nghi, quá trình phân hủy hợp chất phenol có thể đạt hiệu suất tương đương với các chất hữu cơ tổng thể. Các nghiên cứu gần đây về màng lọc kỵ khí lai và màng ngập khác cũng đã chứng minh khả năng duy trì ngay cả khi xảy ra nhiễu tải. Sự ổn định này phải nhờ màng giữ chất rắn hiệu quả và mức lọc cùng với những phát hiện từ các nghiên cứu SAnMBR và AnMBR gần đây về những biến động hiệu suất nhất t nơi quá trình phân tách bằng màng duy trì hiệu quả dòng chảy và chịu ảnh hưởng của các thay đổi theo b độ trong và khả năng đánh bóng chất rắn bất chấp sự dao động của chất hữu cơ.

Phân tích phụ thuộc từng phần hai chiều được thực hiện nhằm khảo sát tương tác hai biến phức tạp giữa pH dòng vào và nồng độ 2,4-DCP. Dựa trên kết quả phân tích độ nhạy (Hình 6), hai thông số này được xác định là có ảnh hưởng lớn nhất, với tác động tương đối cao hơn các biến vận hành khác. Phân tích này mở rộng cách diễn giải vượt ra ngoài ảnh hưởng của từng yếu tố riêng lẻ bằng cách xem xét tác động của các biến vận hành tương tác đến hiệu suất SAnMBR. Như thể hiện trong Hình 6, hiệu suất loại bỏ COD dự đoán cao nhất (92–95%) chỉ đạt được khi kết hợp nồng độ 2,4-DCP thấp (< 50 mg/L) với khoảng pH tối ưu (pH 8–9). Điều này khẳng định vai trò chủ đạo của pH trong việc tối đa hóa hoạt tính enzyme của vi sinh vật (Zhang và cộng sự, 2023).




Fig. 9 Comparison of actual (experimental) and predicted COD removal (%) by the SVR, MLR, and ANN models. The R^2 values for the training phase (blue data) and testing phase (red data) are shown





Fig. 10 Distribution of Percentage Error (%) versus Actual COD removal (%) for the SVR (left), MLR (center), and ANN (right) models. Training and testing data are represented by blue and red points, respectively

Crucially, the plot reveals a non-linear, compounding inhibitory effect outside this optimal zone. The steepest decline in COD removal is observed along the increasing 2,4-DCP concentration axis. While performance remains relatively high when 2,4-DCP is low (regardless of minor pH changes), performance rapidly deteriorates as 2,4-DCP concentration increases above 150 mg/L. This deterioration is exacerbated outside the optimal pH zone. This behaviour is likely due to two factors: (1) Low pH (acidic conditions) increases the proportion of 2,4-DCP present in its undissociated, non-ionized form, which readily penetrates microbial cell membranes, dramatically increasing its toxicity; and (2) pH values outside the methanogenic ideal already stress the system, making the biomass less resilient to additional chemical inhibition (Fernandez et al. 2022; Zhang et al. 2023). This finding has direct operational significance for the SAnMBR system, as it demonstrates that optimization is not merely about minimizing 2,4-DCP but is a dynamic trade-off. Maintaining rigorous pH control provides a critical buffering mechanism against moderate toxic spikes.


3.2 Correlation Analysis of Model Variables

The correlation matrix (Fig. 7) was instrumental in evaluating the linear dependencies among the six selected input parameters and the target output, COD Removal Percentage, serving as a critical step before non-linear machine learning modelling for the SAnMBR system.

Influent COD and OLR showed a very strong positive correlation ($r = 1.00$), which is expected because OLR is partly derived from influent COD. Although such a relationship may cause multicollinearity in linear models, both variables were retained in the SVR model to preserve the operational description of the SAnMBR system. Regarding the target output, influent COD and OLR showed the strongest positive linear associations with COD removal ($r = 0.74$), while pH showed a weaker but still positive correlation ($r = 0.36$). Conversely, influent TSS showed an almost negligible correlation with COD removal ($r = 0.07$), whereas turbidity exhibited a weak negative association ($r = -0.26$). This suggests that suspended solids alone were not a primary linear driver of COD removal, while increased turbidity may be linked to conditions that reduce treatment



Hình 9 So sánh hiệu suất loại bỏ COD thực tế (thực nghiệm) và dự đoán (%) bằng các mô hình SVR, MLR và ANN. Các giá trị R^2 cho quá trình giai đoạn (dữ liệu màu xanh lam) và giai đoạn kiểm thử (dữ liệu màu đỏ) được hiển thị




Hình 10 Phân bố sai số phần trăm (%) theo tỷ lệ loại bỏ COD thực tế (%) của các mô hình SVR (trái), MLR (giữa) và ANN (phải). Dữ liệu huấn luyện và kiểm tra lần lượt được biểu thị bằng các điểm màu xanh lam và đỏ.

Điều quan trọng là, biểu đồ cho thấy sự tích lũy theo 2,4-DCP, tương quan giữa các biến của mô hình tác động ức chế bên ngoài vùng tối ưu này. Độ dốc lớn nhất Mức suy giảm khả năng loại bỏ COD được ghi nhận khi nồng độ 2,4-DCP tăng (Hình 7) đóng vai trò quan trọng trong việc đánh giá các mối phụ thuộc tuyến tính giữa sáu tham số đầu vào được chọn và đầu ra mục tiêu, tỷ lệ loại bỏ COD, đây là bước thiết yếu trước khi mô hình hóa bằng học máy phi tuyến cho hệ thống SAnMBR.

Nồng độ tăng vượt quá 150 mg/L. Sự suy giảm này trở nên nghiêm trọng hơn khi nằm ngoài vùng pH tối ưu. COD đầu vào và OLR có mối tương quan thuận rất mạnh ($r = 1.00$), điều này được dự đoán vì OLR được tính toán một phần từ COD đầu vào. Mặc dù mối quan hệ như vậy có thể gây ra hiện tượng đa cộng tuyến trong các mô hình tuyến tính, cả hai biến vẫn được giữ lại trong mô hình SVR để duy trì mô tả vận hành của hệ thống SAnMBR. Kết đầu ra mục tiêu là COD loại bỏ, OLR cũng có mối liên hệ tuyến tính mạnh mẽ nhất với mức loại bỏ COD ($r = 0.74$), trong khi pH có tương quan thuận yếu hơn nhưng vẫn đáng kể ($r = 0.36$). Ngược lại, TSS đầu vào hầu như không tương quan với mức loại bỏ COD ($r = 0.07$), cũng không đơn thuần là giảm thiểu 2,4-DCP mà còn là một quá trình liên hệ nghịch yếu ($r = -0.26$). Điều này cho thấy rằng chất rắn lơ lửng không phải là yếu tố tuyến tính chính chi phối mức loại bỏ COD, trong khi độ đục tăng có thể liên quan đến các điều kiện làm giảm hiệu quả xử lý.

Fig. 11 PDPs for the 6 numerical input parameters based on the SVR



performance. Influent 2,4-DCP showed a weak positive correlation with COD removal ($r = 0.26$), indicating that its direct linear association with treatment performance was limited. Therefore, correlation analysis alone may not adequately describe the role of 2,4-DCP, particularly if its effect depends on concentration thresholds or interactions with other operational variables, as further examined through PDP analysis. Influent COD and OLR showed the strongest positive correlations with COD removal ($r = 0.74$ for both), followed by influent pH with a moderate positive correlation ($r = 0.36$). These results suggest that organic loading variables had the closest linear association with COD removal, while pH showed a weaker but still noticeable relationship.

3.3 Model results for COD Removal Prediction

The predictive performance of the three developed models (SVR, MLR, and ANN) was evaluated using the coefficient of determination (R^2) and Root Mean Square Error (RMSE), as presented in Table 1.

The SVR model demonstrated the most robust and accurate predictions, achieving the best results for the testing dataset ($R^2 = 0.952$ and $RMSE = 2.96$). Whereas for the training data, as demonstrated by Table 1, SVR also shows the best results for the chosen statistical indicators ($R^2 = 0.975$ and $RMSE = 1.97$). The significant difference between the ANN model's performance on the training data ($R^2 = 0.603$) relative to its testing data ($R^2 = 0.397$) is likely due to the limited predictive capacity of the. The effects of this become apparent when observing the model's performance in the testing dataset, as its performance was exceeded by both the MLR and SVR models.

To further validate the reliability and non-systematic nature of the errors produced by the optimal SVR model, a residual analysis was performed. The residual plot (Fig. 8) displays the difference between the actual and predicted COD removal values (the residual error) plotted against the model's predicted output for the independent test set.


The distribution of data points exhibits a random, uniform scatter around the horizontal zero line ($y=0$). The absence of any discernible patterns such as a cone shape, a trend, or clustering at specific predicted values is a critical finding. This confirms that the SVR model's high predictive accuracy ($R^2 = 0.952$) is robust and that the model has successfully accounted for all systematic dependencies within the SAnMBR process, suggesting that the remaining errors were largely random.

Furthermore, Fig. 9 shows the residual plots with percentage errors for the models. This plot validates the SVR's accuracy, most of its percentage errors (both blue and red points) are distributed randomly and very close to the zero-error line.

The ANN and MLR models, however, show a much wider distribution of errors (Fig. 10), with the ANN model exhibiting clear non-random patterns (heteroscedasticity), reinforcing its unsuitability.

The test-set R^2 for the SVR model based on the testing dataset was 0.952 (or 95.2%), clearly demonstrating its superior ability to model the non-linear SAnMBR process. The training and testing data points are represented using blue and red, respectively. The plots also have a visual aid in the form of a 20% error bound (gray dotted lines) to indicate relative deviation between actual and predicted results. Here, the SVR model is shown to excel in its prediction

Hình 11 Các PDP cho 6 tham số đầu vào dạng số dựa trên SVR



hiệu suất. 2,4-DCP đầu vào cho thấy mối tương quan thuận yếu với mức loại bỏ COD ($r = 0.26$), cho thấy mối liên hệ tuyến tính trực tiếp với hiệu quả điều trị còn hạn chế. Do đó, chỉ phân tích tương quan có thể không mô tả đầy đủ vai trò của 2,4-DCP, đặc biệt phụ thuộc vào các ngưỡng nồng độ hoặc sự tương tác với

các biến vận hành khác, sẽ được xem xét thêm thông qua Phân tích PDP. COD trong dòng vào và OLR cho thấy mối tương quan thuận với khả năng loại bỏ COD ($r = 0.74$ cho cả hai), tiếp theo là pH của dòng nước đầu vào, với tương quan trung bình ($r = 0.36$). Những kết quả này cho thấy các biến tải lượng hữu cơ có mối liên hệ tuyến tính chặt chẽ nhất với hiệu suất loại bỏ COD, trong khi pH thể hiện mối tương quan yếu hơn nhưng vẫn đáng chú ý.

3.3 Kết quả mô hình dự đoán loại bỏ COD

Hiệu suất dự đoán của ba mô hình đã phát triển (SVR, MLR và ANN) được đánh giá bằng hệ số hệ số xác định (R^2) và Sai số bình phương trung bình (RMSE), như được trình bày trong Bảng 1.

Mô hình SVR cho thấy các dự đoán vững chắc và chính xác nhất, đạt kết quả tốt nhất trên tập dữ liệu kiểm tra ($R^2 = 0.952$ và $RMSE = 2.96$). Đối với dữ liệu huấn luyện, như được trình bày trong Bảng 1, SVR cũng cho kết quả tốt nhất theo các chỉ số thống kê được lựa chọn ($R^2 = 0.975$ và $RMSE = 1.97$). Sự khác biệt đáng kể giữa hiệu suất của mô hình ANN trên dữ liệu huấn luyện ($R^2 = 0.603$) so với dữ liệu kiểm tra ($R^2 = 0.397$) có thể là do năng lực dự đoán hạn chế của mô hình này. Tác động của điều này thể hiện rõ khi xem xét hiệu suất của mô hình trên tập dữ liệu kiểm tra, vì hiệu suất của mô hình này thấp hơn cả mô hình MLR lẫn SVR.

Để xác nhận thêm độ tin cậy và tính không có hệ thống của các sai số do mô hình SVR tối ưu tạo ra, phân tích phần dư đã được thực hiện. Biểu đồ phần dư (Hình 8) thể hiện chênh lệch giữa các giá trị loại bỏ COD thực tế và dự đoán (sai số phần dư) theo đầu ra dự đoán của mô hình trên tập kiểm tra độc lập.


Phân bố các điểm dữ liệu cho thấy sự phân tán ngẫu nhiên đồng đều quanh đường ngang tại giá trị 0 ($y_e = 0$). Việc không nhận thấy bất kỳ dạng mẫu nào, chẳng hạn như hình nón, xu hướng hoặc sự tập trung tại các giá trị dự đoán cụ thể, là một phát hiện quan trọng. Điều này xác nhận rằng độ chính xác dự đoán cao của mô hình SVR ($R^2 = 0.952$) là đáng tin cậy và mô hình đã tính đến thành công mọi mối phụ thuộc có tính hệ thống trong quy trình SAnMBR, cho thấy các sai số còn lại phần lớn mang tính ngẫu nhiên.

Hơn nữa, Hình 9 cho thấy các biểu đồ phần dư cùng với sai số phần trăm của các mô hình. Biểu đồ này xác nhận độ chính xác của SVR; phần lớn sai số phần trăm (cả các điểm màu xanh lam và đỏ) phân bố ngẫu nhiên và rất gần với đường sai số bằng không.

Tuy nhiên, các mô hình ANN và MLR có phân bố sai số rộng hơn nhiều (Hình 10), trong đó mô hình ANN thể hiện rõ các dạng không ngẫu nhiên (phương sai thay đổi), càng củng cố sự không phù hợp của mô hình này.

R^2 trên tập kiểm tra của mô hình SVR, dựa trên bộ dữ liệu kiểm tra, đạt 0.952 (hay 95.2%), cho thấy rõ khả năng vượt trội của mô hình trong việc mô hình hóa quy trình SAnMBR phi tuyến. Các điểm dữ liệu huấn luyện và kiểm tra lần lượt được biểu thị bằng màu xanh lam và đỏ. Biểu đồ còn có đường giới hạn sai số 20% (các đường chấm màu xám) để minh họa độ lệch tương đối giữa kết quả thực tế và kết quả dự đoán. Ở đây, mô hình SVR cho thấy khả năng dự đoán xuất sắc.

Fig. 12 Sensitivity analysis plot for six input parameters used in the SVR model



ability. In its corresponding parity plot in Fig. 9, the testing data points (red) are tightly clustered around the ideal 1:1 line and fall almost entirely within the error bounds. In contrast, the ANN model’s parity plot shows significant scatter and multiple data points outside this bound, confirming the overfitting observed in Table 1.

3.3.1 Partial Dependence Plots (PDPs)

PDPs are used to visualize the interaction between individual input features and their respective effect on the machine learning model’s output prediction, assuming all other features remain constant. These plots illustrate the impact of changing a single feature on the prediction of the dependent variable, thereby making the results of the advanced SVR model more interpretable and understandable. Fig. 11 shows the PDPs for six key numerical input parameters employed in the current study.

The PDP for influent 2,4-dichlorophenol (2,4-DCP) concentration reveals a non-linear response pattern. An initial increase in partial dependence values is observed within the lower concentration range (0–150 mg/L), indicating that the model predicts relatively stable or slightly improved COD removal performance in this interval. This behaviour suggests that, within this range, the system is not immediately limited by toxicity effects. However, beyond 150 mg/L, the trend gradually plateaus and begins to decline, reflecting the onset of inhibitory effects on microbial activity. This transition highlights the balance between substrate availability and toxicity, where increasing pollutant concentration initially does not suppress system performance but eventually leads to inhibition, particularly affecting methanogenic processes (Li et al. 2024).


For influent pH, the PDP showed a clear non-linear relationship, with the highest predicted COD removal efficiency observed in the pH range of approximately 8–9. Outside this optimal window, particularly under acidic (pH<7) or strongly alkaline (pH>9) conditions, the predicted performance declines. This trend is consistent with the known sensitivity of anaerobic microbial communities to pH, where deviations from the optimal range negatively affect enzymatic activity and metabolic stability (Meegoda et al. 2018).

Comparatively, influent COD (mg/L) and OLR (gCOD/m³.day) exhibit relatively minor influence on the predicted COD removal efficiency within the studied ranges, indicating that the system operated below its critical loading threshold. Similarly, influent turbidity (NTU) and TSS (g/L) show a slight negative trend, where increasing values correspond to marginal decreases in predicted efficiency. This is consistent with the rate-limiting nature of particulate hydrolysis in anaerobic systems, as particulate matter requires additional processing steps compared to soluble substrates (Wang et al. 2022).

3.3.2 Sensitivity Analysis

This section quantifies the influence of individual input features on the optimal SVR model’s prediction of COD removal using univariate sensitivity analysis framework. Unlike model-specific explainability methods such as SHapley Additive exPlanations (SHAP), which rely on internal model structures or game-theoretic formulations, the present approach is a model-agnostic sensitivity analysis designed to evaluate the response of the trained model to controlled variations in input variables. This approach provides a direct and computationally efficient assessment of global feature influence, suitable for identifying dominant

Hình 12 Biểu đồ phân tích độ nhạy của sáu tham số đầu vào được sử dụng trong mô hình SVR



khả năng. Trong biểu đồ parity tương ứng ở Hình 9, tập dữ liệu (màu đỏ) tập trung sát quanh đường parity tuyến rõ rệt, với hiệu suất loại bỏ COD dự đoán cao nhất được ghi nhận trong khoảng pH 8–9. Nằm ngoài khoảng tối ưu này, đặc biệt trong điều kiện axit (pH < 7) hoặc kiềm mạnh (pH > 9), hiệu suất dự đoán giảm. Xu hướng này phù hợp với mức độ nhạy cảm đã biết của các quần thể vi sinh vật kỵ khí đối với pH, trong đó sự sai lệch khỏi khoảng tối ưu ảnh hưởng tiêu cực đến hoạt động enzyme và sự ổn định trao đổi chất (Meegoda et al. 2018).

3.3.1 Biểu đồ phụ thuộc từng phần (PDP)


PDP được sử dụng để trực quan hóa mối tương tác giữa từng đặc trưng đầu vào riêng lẻ và ảnh hưởng tương ứng của chúng đến dự đoán đầu ra của mô hình học máy, với giả định rằng tất cả các đặc trưng khác đều không đổi. Các biểu đồ này minh họa tác động của việc thay đổi một đặc trưng duy nhất lên dự đoán của biến phụ thuộc, qua đó giúp các kết quả của mô hình SVR tiên tiến trở nên dễ diễn giải và dễ hiểu hơn. Hình 11 trình bày PDP của sáu tham số đầu vào dạng số quan trọng được sử dụng trong nghiên cứu này.

PDP về nồng độ 2,4-dichlorophenol (2,4-DCP) trong nước đầu vào cho thấy một dạng đáp ứng phi tuyến. Ban đầu, khi gia tăng các giá trị phụ thuộc từng phần trong khoảng nồng độ thấp hơn (0–150 mg/L), cho thấy rằng mô hình dự đoán COD tương đối ổn định hoặc cải thiện nhẹ khả năng loại bỏ trong khoảng này. Hành vi này gợi ý rằng, trong phạm vi này, hệ thống không ngay lập tức bị giới hạn bởi các tác động độc tính. Tuy nhiên, trên 150 mg/L, xu hướng dần chững lại và bắt đầu suy giảm, phản ánh sự khởi phát của các tác động ức chế hoạt động của vi sinh vật. Sự chuyển đổi này làm nổi bật sự cân bằng giữa mức độ sẵn có của cơ chất và độc tính, trong đó nồng độ chất ô nhiễm tăng lên ban đầu không làm suy giảm hiệu suất hệ thống nhưng cuối cùng dẫn đến sự ức chế, đặc biệt ảnh hưởng đến các quá trình sinh methane (Li et al. 2024).

So sánh cho thấy COD đầu vào (mg/L) và OLR (gCOD/m³.ngày) có ảnh hưởng tương đối nhỏ đến hiệu suất loại bỏ COD dự đoán trong các khoảng khảo sát, cho thấy hệ thống vận hành dưới ngưỡng tải trọng tới hạn. Tương tự, độ đục đầu vào (NTU) và TSS (g/L) thể hiện xu hướng âm nhẹ, trong đó các giá trị tăng lên tương ứng với mức giảm không đáng kể về hiệu suất dự đoán. Điều này phù hợp với đặc tính thủy phân hạt là bước giới hạn tốc độ trong các hệ thống kỵ khí, vì vật chất dạng hạt cần thêm các bước xử lý so với cơ chất hòa tan (Wang và cs., 2022).

Phân tích độ nhạy của mô hình SVR tối ưu bằng khung phân tích độ nhạy đơn biến. Khác với các phương pháp giải thích dựa theo mô hình như SHapley Additive exPlanations (SHAP), vốn dựa vào cấu trúc nội tại của mô hình hoặc các công thức lý thuyết trò chơi, phương pháp hiện tại là một phân tích độ nhạy không phụ thuộc mô hình, được thiết kế để đánh giá phản hồi của mô hình đã huấn luyện trước những biến thiên có kiểm soát của các biến đầu vào. Phương pháp này cung cấp đánh giá trực tiếp và hiệu quả về mặt tính toán đối với ảnh hưởng tổng thể của các đặc trưng, phù hợp để xác định các yếu tố chi phối chủ đạo.

Fig. 13 Schematic illustration of membrane fouling mechanisms in the SAnMBR



process variables. In this approach, each input feature was varied independently across its observed range using a systematic discretization procedure, while all other input variables were held constant at their baseline values. Specifically, the baseline inputs were defined using the mean values of the original dataset, and each variable was perturbed across its minimum–maximum range using a fixed number of uniformly spaced intervals. For each variable, a series of uniformly spaced points within its range was generated, and the trained SVR model was used to predict COD removal for each modified input set. The sensitivity index was then calculated as the mean absolute deviation between the predicted outputs obtained from the perturbed inputs and the baseline predictions. This metric quantifies the extent to which variations in each input feature influence the model output. Higher sensitivity values indicate stronger influence, while values approaching zero suggest minimal impact. The sensitivity analysis plot (Fig. 12) shows the relative importance of each input variable, with 2,4-DCP concentration and pH emerging as the main factors influencing predicted COD removal.


The analysis clearly establishes the crucial role of specific input parameters. Influent 2,4-dichlorophenol (mg/L) exhibits the highest sensitivity, confirming its status as the most influential feature in the SVR model. This finding is highly consistent with the partial dependence plot (PDP) results, which showed a strong negative impact on COD removal (a predicted decline from a stable 90% to below 70%) as its concentration increased. The high sensitivity to 2,4-DCP highlights the need to control inhibitory compounds, as this response is consistent with the known toxicity of chlorophenols toward methanogenic archaea in anaerobic systems.

Influent pH is the second most influential parameter, which accurately reflects the SAnMBR system's biological nature and its dependence on a narrow optimal range. The PDPs demonstrate that removal efficiency is maximized within an optimal pH range of approximately 8–9, beyond which system performance progressively declines due to reduced microbial activity under non-optimal conditions. Furthermore, parameters related to bulk organic load, such as influent COD and OLR, displayed lower sensitivity. Their limited influence is consistent with the PDPs showing largely flat impact curves, suggesting that the SAnMBR system was highly robust and operated below its peak loading capacity throughout the dataset range. Influent turbidity and influent TSS had the lowest sensitivity scores, indicating that changes in these variables had only a minor effect on the SVR-predicted COD removal. This may be because particulate matter affects anaerobic treatment mainly through hydrolysis, which is typically slower than the degradation of soluble organic compounds. As a result, marginal changes in TSS or turbidity were less influential than soluble inhibitory factors such as 2,4-DCP.

3.4 Operational Implications and Fouling Risk Analysis

The interpretation of the SVR model provides insight into both biological treatment performance and membrane-related operation within the SAnMBR system. Although influent TSS and turbidity showed low sensitivity toward predicted COD removal, their role should be interpreted within the broader operating context rather than dismissed as irrelevant. Within the investigated range, the low sensitivity

Hình 13 Sơ đồ minh họa các cơ chế cấu bẩn màng trong SAnMBR



các biến đầu vào. Trong phương pháp này, từng đặc trưng đầu vào được thay đổi độc lập trong phạm vi giá trị quan sát được bằng một quy trình rời rạc hóa có hệ thống, trong khi tất cả các biến đầu vào khác được giữ cố định ở giá trị cơ sở. Cụ thể, các giá trị đầu vào cơ sở được xác định bằng giá trị trung bình của tập dữ liệu ban đầu, và mỗi biến được thay đổi trong phạm vi từ giá trị nhỏ nhất đến lớn nhất bằng một số lượng cố định các khoảng cách đều nhau. Với mỗi biến, một loạt điểm cách đều nhau trong phạm vi giá trị của biến được tạo ra, sau đó mô hình SVR đã huấn luyện được dùng để dự đoán mức loại bỏ COD cho từng bộ đầu vào đã điều chỉnh. Chỉ số độ nhạy được tính bằng độ lệch tuyệt đối trung bình giữa các đầu ra dự đoán từ các đầu vào đã thay đổi và các dự đoán cơ sở. Thước đo này định lượng mức độ ảnh hưởng của sự biến thiên ở từng đặc trưng đầu vào đến đầu ra của mô hình. Giá trị độ nhạy cao hơn cho thấy ảnh hưởng mạnh hơn, trong khi các giá trị gần bằng không cho thấy tác động tối thiểu. Biểu đồ phân tích độ nhạy (Hình 12) thể hiện tầm quan trọng tương đối của từng biến đầu vào; nồng độ 2,4-DCP và pH nổi lên là các yếu tố có hình ảnh hưởng đến mức loại bỏ COD dự đoán.

Phân tích cho thấy rõ vai trò then chốt của các thông số đầu vào cụ thể. Nồng độ 2,4-dichlorophenol trong dòng vào (mg/L) có độ nhạy cao nhất, xác nhận đây là đặc trưng có ảnh hưởng lớn nhất trong mô hình SVR. Phát hiện này hoàn toàn nhất quán với kết quả từ biểu đồ phụ thuộc từng phần (PDP), vốn cho thấy tác động tiêu cực mạnh đến hiệu suất loại bỏ COD (mức dự đoán giảm từ 90% ổn định xuống dưới 70%) khi nồng độ chất này tăng. Độ nhạy cao đối với 2,4-DCP nhấn mạnh sự cần thiết phải kiểm soát các hợp chất ức chế, bởi phản ứng này phù hợp với độc tính đã biết của chlorophenol đối với vi khuẩn cố sinh methane trong các hệ thống kỵ khí.

pH đầu vào là thông số có mức độ ảnh hưởng lớn thứ hai, phản ánh chính xác bản chất sinh học của hệ thống SAnMBR và sự phụ thuộc của hệ thống vào một khoảng tối ưu hẹp. Các đồ thị phụ thuộc từng phần (PDP) cho thấy hiệu suất loại bỏ đạt mức tối đa trong khoảng pH tối ưu xấp xỉ 8–9; vượt quá khoảng này, hiệu suất hệ thống giảm dần do hoạt tính vi sinh vật suy giảm trong điều kiện không tối ưu. Hơn nữa, các thông số liên quan đến tải lượng hữu cơ tổng thể, chẳng hạn như COD đầu vào và OLR, có độ nhạy thấp hơn. Ảnh hưởng hạn chế của chúng phù hợp với các PDP, vốn cho thấy đường cong tác động nhìn chung khá phẳng; điều này gợi ý rằng hệ thống SAnMBR có độ ổn định cao và vận hành dưới mức tải tối đa trong toàn bộ phạm vi dữ liệu. Độ đục đầu vào và TSS đầu vào có điểm độ nhạy thấp nhất, cho thấy những thay đổi của các biến này chỉ ảnh hưởng nhỏ đến mức loại bỏ COD do SVR dự đoán. Nguyên nhân có thể là do vật chất dạng hạt tác động đến quá trình xử lý kỵ khí chủ yếu thông qua quá trình thủy phân, vốn thường diễn ra chậm hơn quá trình phân hủy các hợp chất hữu cơ hòa tan. Do đó, những thay đổi nhỏ về TSS hoặc độ đục ít ảnh hưởng hơn các yếu tố ức chế dạng hòa tan như 2,4-DCP.

3.4 Phân tích các hàm ý vận hành và nguy cơ đóng cặn

Việc diễn giải mô hình SVR giúp làm sáng tỏ cả hiệu suất xử lý sinh học lẫn hoạt động liên quan đến màng trong hệ thống SAnMBR. Mặc dù TSS và độ đục của dòng đầu vào có độ nhạy thấp đối với khả năng loại bỏ COD dự đoán, vai trò của chúng cần được xem xét trong bối cảnh vận hành rộng hơn thay vì bị xem là không liên quan. Trong phạm vi khảo sát, độ nhạy thấp

of TSS and turbidity indicates that particulate-related variables had a limited effect on SVR-predicted COD removal compared with pH and 2,4-DCP concentration. This observation is specific to the operating conditions investigated in this study and should not be generalized across anaerobic treatment systems. COD comprises both soluble and particulate fractions, and the hydrolysis of particulate organic matter is often the rate-limiting step in anaerobic digestion. In SAnMBRs, however, extended solids retention and effective biomass retention can promote particulate hydrolysis, which may explain why TSS and turbidity showed limited influence on predicted COD removal under stable operating conditions(Sandoval-García et al. 2025; Turan 2025).

Despite their relatively minor contribution to predicted COD removal, particulate-related parameters remain critically important from an operational perspective, particularly in relation to membrane fouling behaviour. As illustrated in Fig. 13, membrane fouling in the SAnMBR system is governed by multiple interacting mechanisms rather than a single dominant process. Initially, the accumulation of suspended solids and colloidal matter near the membrane surface leads to concentration polarization, which increases local solute concentration and promotes further deposition. This is followed by the formation of an external bio-cake layer composed of biomass, TSS, and extracellular polymeric substances (EPS). Over time, EPS production and microbial activity facilitate the penetration of organic matter into membrane pores, resulting in pore blocking and, ultimately, internal pore clogging. These sequential and overlapping mechanisms contribute to increased hydraulic resistance and progressive decline in membrane performance, leading to elevated transmembrane pressure and more frequent maintenance requirements (Du et al. 2020; Zhang and Hao 2022).

These results highlight a fundamental decoupling between biological treatment efficiency and operational sustainability. While the SVR model identifies COD removal as primarily governed by biochemical and inhibitory factors (e.g., pH and 2,4-DCP concentration), particulate matter exerts a dominant influence on membrane fouling dynamics and long-term system stability. The low sensitivity of TSS in the SVR model should therefore not be interpreted as operational insignificance, but rather as an indication that fouling-related impacts are not captured by COD-based performance metrics.

From an operational standpoint, this dual behaviour underscores the necessity of adopting a multi-objective optimization strategy. Optimization based solely on COD removal may lead to suboptimal operating conditions, where membrane fouling accelerates despite stable treatment performance. Although increasing TSS may not significantly affect COD removal efficiency within the studied range, it

directly contributes to more frequent cleaning, increased chemical consumption, and elevated operational costs (Ma et al. 2015). This suggests that, beyond a critical particulate threshold, the system transitions from a performance-controlled regime to a fouling-controlled regime, even when apparent treatment efficiency remains unchanged. Therefore, controlling particulate load is essential not only for fouling mitigation but also for maintaining overall system efficiency and cost-effectiveness. These findings emphasize that optimal SAnMBR operation cannot be defined solely by treatment performance indicators, but must incorporate fouling propensity, membrane resistance development, and operational resilience under variable process conditions.

4 Conclusion

This study shows that a data-driven modelling approach can capture the non-linear behaviour of SAnMBR systems under phenolic shock conditions, with SVR providing reliable prediction of COD removal in a biologically sensitive process. Model interpretation showed that performance was strongly affected by the interaction between pH and inhibitory phenolic compounds, suggesting that stable operation depends not only on organic loading but also on keeping toxicity below critical thresholds. The decline in biological performance at elevated 2,4-DCP concentrations further indicates that high-strength phenolic wastewater may require dilution, pretreatment, or selective recovery of phenolic compounds before biological treatment. This agrees with previous studies showing that detoxification can improve microbial activity and enhance subsequent anaerobic treatment. The results also show that biological removal and membrane operation are controlled by different factors. COD removal was mainly influenced by biochemical conditions, whereas particulate matter remains important for membrane fouling and long-term process stability. Although phenolic compounds were treated as inhibitory pollutants in this study, their recovery before biological treatment is gaining attention because of their potential value as antioxidants and industrial precursors. These findings support the use of interpretable machine-learning models for digital monitoring and adaptive control of SAnMBR systems treating complex industrial wastewater. Future work should integrate the developed SVR model into real-time control frameworks to support dynamic adjustment of key variables such as pH and influent 2,4-DCP concentration. Including fouling-related indicators, such as EPS, SMP, and transmembrane pressure, would also allow multi-objective optimisation of biological performance and membrane operation.

Author Contributions Milad Mousazadehgavan: Conceptualization, Writing – original draft, Software, Methodology, Investigation, For-

của TSS và độ đục cho thấy các biến liên quan đến hạt vật chất chỉ ảnh hưởng hạn chế đến hiệu suất loại bỏ COD được SVR dự đoán. Nhận định này chỉ áp dụng cho các điều kiện vận hành được khảo sát trong nghiên cứu này và không nên khái quát hóa cho tất cả các điều kiện khác của hệ thống xử lý. COD bao gồm cả phân hòa tan và phần dạng hạt, và sự thủy phân chất hữu cơ dạng hạt vật chất thường là bước giới hạn tốc độ trong quá trình phân hủy kỵ khí. Tuy nhiên, trong các SAnMBR, thời gian lưu giữ chất rắn kéo dài và khả năng giữ sinh khối hiệu quả có thể thúc đẩy quá trình thủy phân các hạt rắn ảnh hưởng đến hiệu suất loại bỏ COD dự đoán trong điều kiện (Sandoval-García et al. 2025; Turan 2025).

Mặc dù đóng góp tương đối nhỏ vào mức loại bỏ COD dự đoán, các thông số liên quan đến hạt vẫn có vai trò cực kỳ quan trọng xét từ góc độ vận hành, đặc biệt là đối với hiện tượng tắc nghẽn màng. Như minh họa trong Hình 13, hiện tượng tắc nghẽn màng trong hệ thống SAnMBR bị chi phối bởi nhiều cơ chế tương tác với nhau chứ không phải một quá trình chủ đạo duy nhất. Ban đầu, sự tích tụ chất rắn lơ lửng và vật chất dạng keo gần bề mặt màng dẫn đến phân cực nồng độ, làm tăng nồng độ chất tan cục bộ và thúc đẩy sự lắng đọng thêm. Tiếp đó là sự hình thành lớp bánh sinh học bên ngoài, gồm sinh khối, TSS và các chất polymer ngoại bào (EPS). Theo thời gian, quá trình sản sinh EPS và hoạt động của vi sinh vật tạo điều kiện cho vật chất hữu cơ thâm nhập vào các lỗ màng, gây bít lỗ và cuối cùng là tắc nghẽn bên trong lỗ màng. Các cơ chế nối tiếp và chồng lấn này làm tăng sức cản thủy lực và khiến hiệu suất màng suy giảm dần, dẫn đến áp suất xuyên màng tăng cao và cần bảo trì thường xuyên hơn (Du và cộng sự, 2020; Zhang và Hao, 2022).

Những kết quả này làm nổi bật sự tách biệt căn bản giữa hiệu quả xử lý sinh học và tính bền vững trong vận hành. Trong khi mô hình SVR xác định mức loại bỏ COD chủ yếu được chi phối bởi các yếu tố sinh hóa và ức chế (ví dụ: pH và nồng độ 2,4-DCP), vật chất dạng hạt tác động chi phối đến động lực học bám bẩn màng và độ ổn định lâu dài của hệ thống. Độ nhạy thấp của TSS, không nên diễn giải TSS trong mô hình SVR như một sự không đáng kể về mặt vận hành, mà đúng hơn là một dấu hiệu cảnh báo. Các tác động liên quan đến hiện tượng bám bẩn không được phản ánh trong các chỉ số hiệu suất dự đoán COD. Xét từ góc độ vận hành, hành vi kép này nhấn mạnh sự cần thiết phải áp dụng một phương pháp đánh giá toàn diện, chẳng hạn như EPS, SMP và áp suất xuyên màng, cũng sẽ cho phép tối ưu hóa đa mục tiêu hiệu suất sinh học và quá trình vận hành màng.

Author Contributions Milad Mousazadehgavan: Xây dựng ý tưởng, Viết – bản thảo gốc, Phần mềm, Phương pháp luận, Điều tra, For-

trực tiếp góp phần làm tăng tần suất vệ sinh, mức tiêu thụ hóa chất và chi phí vận hành (Ma et al. 2015). Điều này cho thấy rằng, khi vượt quá ngưỡng hạt vật chất tối hạn, hệ thống chuyển từ chế độ được kiểm soát bởi hiệu suất sang chế độ bị chi phối bởi hiện tượng tắc nghẽn màng, ngay cả khi hiệu suất xử lý biểu kiến vẫn không đổi. Do đó, kiểm soát tải lượng hạt vật chất là điều thiết yếu không chỉ để giảm thiểu hiện tượng tắc nghẽn mà còn để duy trì hiệu suất tổng thể và tính hiệu quả về chi phí của hệ thống. Những phát hiện này nhấn mạnh rằng không thể xác định chế độ vận hành tối ưu của SAnMBR chỉ dựa trên các chỉ số hiệu suất xử lý, mà còn phải tính đến xu hướng tắc nghẽn, sự phát triển sức cản màng và khả năng vận hành ổn định trong các điều kiện quy trình biến đổi.

4 Kết luận

Nghiên cứu này cho thấy phương pháp mô hình hóa dựa trên dữ liệu có thể nắm bắt hành vi phi tuyến của các hệ thống SAnMBR trong điều kiện sốc phenolic, trong đó SVR dự đoán đáng tin cậy mức loại bỏ COD ở một quy trình nhạy cảm về mặt sinh học. Kết quả diễn giải mô hình cho thấy hiệu suất chịu ảnh hưởng mạnh bởi tương tác giữa pH và các hợp chất phenolic ức chế, cho thấy vận hành ổn định không chỉ phụ thuộc vào tải lượng hữu cơ mà còn vào việc duy trì độc tính dưới các ngưỡng tới hạn. Sự suy giảm hiệu suất sinh học ở nồng độ 2,4-DCP cao hơn càng cho thấy nước thải phenolic có nồng độ cao có thể cần được pha loãng, tiền xử lý hoặc thu hồi chọn lọc các hợp chất phenolic trước khi xử lý sinh học. Điều này phù hợp với các nghiên cứu trước đây cho thấy khử độc có thể cải thiện hoạt động của vi sinh vật và nâng cao hiệu quả xử lý kỵ khí tiếp theo. Kết quả cũng cho thấy quá trình loại bỏ sinh học và vận hành màng chịu sự chi phối của các yếu tố khác nhau. Việc loại bỏ COD chủ yếu chịu ảnh hưởng của các điều kiện sinh hóa, trong khi vật chất dạng hạt vẫn đóng vai trò quan trọng đối với hiện tượng tắc nghẽn màng và độ ổn định lâu dài của quy trình. Mặc dù các hợp chất phenolic được xem là chất ô nhiễm ức chế trong nghiên cứu này, việc thu hồi chúng trước xử lý sinh học đang ngày càng được quan tâm do tiềm năng sử dụng làm chất chống oxy hóa và tiền chất công nghiệp. Những phát hiện này ủng hộ việc sử dụng các mô hình học máy có thể diễn giải để giám sát số và điều khiển thích ứng các hệ thống SAnMBR xử lý nước thải công nghiệp phức tạp. Các nghiên cứu trong tương lai nên tích hợp mô hình SVR đã phát triển vào các khuôn khổ điều khiển thời gian thực nhằm hỗ trợ điều chỉnh linh hoạt những biến số quan trọng như pH và nồng độ 2,4-DCP trong dòng vào. Việc bổ sung các chỉ số liên quan đến tắc nghẽn, chẳng hạn như EPS, SMP và áp suất xuyên màng, cũng sẽ cho phép tối ưu hóa đa mục tiêu hiệu suất sinh học và quá trình vận hành màng.

Author Contributions Milad Mousazadehgavan: Xây dựng ý tưởng, Viết – bản thảo gốc, Phần mềm, Phương pháp luận, Điều tra, For-

mal analysis, Project administration, Validation. B. Abdullhadi: Writing – original draft, Investigation, Writing – review & editing. Milad Basirifard: Software, Formal analysis, Writing – original draft. Farideh Malekdar: Writing – original draft, Writing – review & editing. Mahsa Shahi Jouneghani: Writing – original draft, Investigation, Formal analysis. Adel Kamyab Rudsari: Conceptualization, Data Collection, Writing – original draft, Methodology, Investigation. Reza Ghanbari: Writing – review & editing, Supervision.

Funding There is no funding.

Data Availability The datasets used and/or analysed during the current study are available from the corresponding author on reasonable request.

Declarations

Competing Interests The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Open Access This article is licensed under a Creative Commons Attribution 4.0 International License, which permits use, sharing, adaptation, distribution and reproduction in any medium or format, as long as you give appropriate credit to the original author(s) and the source, provide a link to the Creative Commons licence, and indicate if changes were made. The images or other third party material in this article are included in the article’s Creative Commons licence, unless indicated otherwise in a credit line to the material. If material is not included in the article’s Creative Commons licence and your intended use is not permitted by statutory regulation or exceeds the permitted use, you will need to obtain permission directly from the copyright holder. To view a copy of this licence, visit <http://creativecommons.org/licenses/by/4.0/>.

References

AbuKhadra D, Grossman AD, Al-Ashhab A, Al-Sharabati I, Bernstein R, Herzberg M (2024) The effect of temperature on fouling in anaerobic membrane bioreactor: SMP-and EPS-membrane interactions. *Water Res* 260:121867

Al-Qudah Z, Al-Qudah Y, Omar W (2019) On the performance of electrocoagulation-assisted biological treatment processes: a review on the state of the art. *Environ Sci Pollut Res* 26(28):28689–28713

Catherine H, Penninckx M, Frédéric D (2016) Product formation from phenolic compounds removal by laccases: A review. *Environ Technol Innov* 5:250–266

Chen R, Nie Y, Hu Y, Miao R, Utashiro T, Li Q, Xu M, Li Y-Y (2017) Fouling behaviour of soluble microbial products and extracellular polymeric substances in a submerged anaerobic membrane bioreactor treating low-strength wastewater at room temperature. *J Membr Sci* 531:1–9

Du X, Shi Y, Jegatheesan V, Haq IU (2020) A Review on the Mechanism, Impacts and Control Methods of Membrane Fouling in MBR System. *Membranes* 10(2):24

Fernandez ME, Morel MdR, Clebot AC, Zalazar CS, Ballari MdIM (2022) Effectiveness of a simple biomixture for the adsorption and elimination of 2,4-dichlorophenoxyacetic acid (2,4-D) herbicide and its metabolite, 2,4-dichlorophenol (2,4-DCP), for a biobed system. *J Environ Chem Eng* 10(1):106877

García Rea VS, Muñoz Sierra JD, Fonseca Aponte LM, Cerqueda-García D, Quchani KM, Spanjers H and van Lier JB (2020) Enhancing Phenol Conversion Rates in Saline Anaerobic Membrane

Bioreactor Using Acetate and Butyrate as Additional Carbon and Energy Sources. *Front Microbiol* 11:604173. <https://doi.org/10.3389/fmicb.2020.604173>

Geng Y, Li Z, Yuan L, Pan X, Sheng G (2020) Degradation and mineralization of 2-chlorophenol in a single-stage anaerobic fixed-bed bioreactor. *Sci China Technological Sci* 63(1):86–95

Gyparakis S, Trichakis I, Daras T, Diamadopoulos E (2025) Artificial neural networks (ANNs) and multiple linear regression (MLR) analysis modelling for predicting chemical dosages of a water treatment plant (WTP) of drinking water. *Water* 17(2):227

He C, Yang C, Yuan S, Hu Z, Wang W (2020) Effects of Sludge Retention Time on the Performance of Anaerobic Ceramic Membrane Bioreactor Treating High-Strength Phenol Wastewater. *Archaea* 20201:8895321

Khan MJ, Wibowo A, Karim Z, Posoknistakul P, Matsagar BM, Wu KC-W, Sakdaronnarong C (2024) Wastewater treatment using membrane bioreactor technologies: removal of phenolic contaminants from oil and coal refineries and pharmaceutical industries. *Polymers* 16(3):443

Lai Y, Xiao K, He Y, Liu X, Tan J, Xue W, Zhang A, Huang X (2024) Machine learning for membrane bioreactor research: principles, methods, applications, and a tutorial. *Front Environ Sci Eng* 19(3):34

Li M, Han F, Zhang Z, Zeng H, Li D, Zhang J (2024) Effect of 2,4-dichlorophenol on the production of methane from anaerobic granular sludge during anaerobic digestion through spectroscopy analysis. *Environ Technol* 45(5):916–925

Ma J, Wang Z, He D, Li Y, Wu Z (2015) Long-term investigation of a novel electrochemical membrane bioreactor for low-strength municipal wastewater treatment. *Water Res* 78:98–110

Medina SC, Zamora-Vacca N, Luna HJ, Ratkovich N, Rodríguez Susa M (2020) SMP production in an anaerobic submerged membrane bioreactor (AnMBR) at different organic loading rates. *Membranes* 10(11):317

Meegoda JN, Li B, Patel K and Wang LB (2018) A Review of the Processes, Parameters, and Optimization of Anaerobic Digestion. *Int J Environ Res Public Health* 15:2224. doi: 10.3390/ijerph-15102224Meegoda JN, Li B, Patel K, Wang LB 2018 A Review of the Processes, Parameters, and Optimization of Anaerobic Digestion

Menon SS, Kalyanraman V (2025) A comprehensive review of anaerobic membrane bioreactor (AnMBR) technology: advancements and trends from 2010 to 2024. *Environ Technol Reviews* 14(1):17–39

Muniz de Queiroz M, Moreira VR, Amaral MCS, Oliveira SMAC (2025) Machine learning algorithms for predicting membrane bioreactors performance: A review. *J Environ Manage* 380:124978

Muñoz Sierra JD, García Rea VS, Cerqueda-García D, Spanjers H, van Lier JB (2020) Anaerobic conversion of saline phenol-containing wastewater under thermophilic conditions in a membrane bioreactor. *Front Bioeng Biotechnol* 8:565311

Najafzadeh M, Niazmardi S (2021) A Novel Multiple-Kernel Support Vector Regression Algorithm for Estimation of Water Quality Parameters. *Nat Resour Res* 30(5):3761–3775

Pacheco-Ruiz S, Heaven S, Banks CJ (2021) Operation of submerged anaerobic membrane bioreactors at 20 C: Effect of solids retention time on flux, mixed liquor characteristics and performance. *Processes* 9(9):1525

Reza AF, Singh R, Verma RK, Singh A, Ahn Y-H, Ray SS (2024) An integral and multidimensional review on multi-layer perceptron as an emerging tool in the field of water treatment and desalination processes. *Desalination* 586:117849

Rezakazemi M, Maghami M, Mohammadi T (2018) Wastewaters treatment containing phenol and ammonium using aerobic submerged membrane bioreactor. *Chem Cent J* 12(1):79

phân tích, quản lý dự án, xác thực. B. Abdullhadi: Viết – bản thảo gốc, điều tra, viết – rà soát và biên tập. Milad Basirifard: Phần mềm, phân tích chính thức, viết – bản thảo gốc. Farideh Malekdar: Viết – bản thảo gốc, viết – rà soát và biên tập. Mahsa Shahi Jouneghani: Viết – bản thảo gốc, điều tra, phân tích chính thức. Adel Kamyab Rudsari: Xây dựng ý tưởng, thu thập dữ liệu, viết – bản thảo gốc, phương pháp luận, điều tra. Reza Ghanbari: Viết – rà soát và biên tập, giám sát.

Kinh phí Không có kinh phí.

Tính khả dụng của dữ liệu Các bộ dữ liệu được sử dụng và/hoặc phân tích trong nghiên cứu hiện tại có thể được cung cấp bởi các tác giả liên hệ khi có yêu cầu hợp lý

Khai báo

Xung đột lợi ích Các tác giả tuyên bố rằng họ không có lợi ích tài chính cạnh tranh đã biết hoặc mối quan hệ cá nhân nào có thể ảnh hưởng đến công trình được trình bày trong bài báo này.

Truy cập Mở Bài viết này được cấp phép theo Giấy phép Creative Commons Ghi công 4.0 Quốc tế, cho phép sử dụng, chia sẻ, chỉnh sửa, phân phối và sao chép trên mọi phương tiện hoặc định dạng, miễn là bạn ghi nhận phù hợp tác giả gốc và nguồn, cung cấp liên kết đến giấy phép Creative Commons và cho biết nếu có thay đổi. Hình ảnh hoặc tài liệu khác của bên thứ ba trong bài viết này được bao gồm trong giấy phép Creative Commons của bài viết, trừ khi có ghi chú khác trong dòng ghi công của tài liệu. Nếu tài liệu không thuộc giấy phép Creative Commons của bài viết và mục đích sử dụng của bạn không được quy định pháp luật cho phép hoặc vượt quá phạm vi sử dụng được cho phép, bạn cần xin phép trực tiếp chủ sở hữu bản quyền. Để xem bản sao giấy phép này, hãy truy cập <http://creativecommons.org/licenses/by/4.0/>.

Tài liệu tham khảo

AbuKhadra D, Grossman AD, Al-Ashhab A, Al-Sharabati I, Bernstein R, Herzberg M (2024) Ảnh hưởng của nhiệt độ đến hiện tượng bám bẩn trong bể phản ứng sinh học màng kỵ khí: tương tác giữa SMP và EPS với màng. *Water Res* 260:121867

Al-Qodah Z, Al-Qudah Y, Omar W (2019) Về hiệu quả của các quy trình xử lý sinh học hỗ trợ keo tụ điện hóa: tổng quan về tình hình hiện tại. *Environ Sci Pollut Res* 26(28):28689–28713

Catherine H, Penninckx M, Frédéric D (2016) Sản phẩm hình thành từ quá trình loại bỏ các hợp chất phenolic bằng laccase: Tổng quan. *Environ Technol Innov* 5:250–266

Chen R, Nie Y, Hu Y, Miao R, Utashiro T, Li Q, Xu M, Li Y-Y (2017) Đặc tính bám bẩn của các sản phẩm vi sinh hòa tan và các chất polymer ngoại bào trong bể phản ứng sinh học màng kỵ khí chìm xử lý nước thải có nồng độ chất ô nhiễm thấp ở nhiệt độ phòng. *J Membr Sci* 531:1–9

Du X, Shi Y, Jegatheesan V, Haq IU (2020) Tổng quan về cơ chế, tác động và các phương pháp kiểm soát hiện tượng bám bẩn màng trong hệ thống MBR. *Membranes* 10(2):24

Fernandez ME, Morel MdR, Clebot AC, Zalazar CS, Ballari MdIM (2022) Hiệu quả của một hỗn hợp sinh học đơn giản trong việc hấp phụ và loại bỏ thuốc diệt cỏ axit 2,4-dichlorophenoxyacetic (2,4-D) cùng chất chuyển hóa của nó là 2,4-dichlorophenol (2,4-DCP) trong hệ thống biobed. *J Environ Chem Eng* 10(1):106877

García Rea VS, Muñoz Sierra JD, Fonseca Aponte LM, Cerqueda-García D, Quchani KM, Spanjers H and van Lier JB (2020) Tăng cường tốc độ chuển hóa phenol trong màng kỵ khí độ mặn cao

Lò phản ứng sinh học sử dụng axetat và butyrat làm nguồn carbon và năng lượng bổ sung. *Front Microbiol* 11:604173. <https://doi.org/10.3389/fmicb.2020.604173>

Geng Y, Li Z, Yuan L, Pan X, Sheng G (2020) Phân hủy và khoáng hóa 2-chlorophenol trong lò phản ứng sinh học kỵ khí tầng cố định một giai đoạn. *Sci China Technological Sci* 63(1):86–95

Gyparakis S, Trichakis I, Daras T, Diamadopoulos E (2025) Mô hình hóa bằng mạng nơ-ron nhân tạo (ANN) và phân tích hồi quy tuyến tính đa biến (MLR) để dự đoán liều lượng hóa chất tại nhà máy xử lý nước (WTP) cấp nước uống. *Water* 17(2):227

He C, Yang C, Yuan S, Hu Z, Wang W (2020) Ảnh hưởng của thời gian lưu bùn đến hiệu suất của lò phản ứng sinh học màng cố định kỵ khí xử lý nước thải phenol nồng độ cao. *Archaea* 20201:8895321

Khan MJ, Wibowo A, Karim Z, Posoknistakul P, Matsagar BM, Wu KC-W, Sakdaronnarong C (2024) Xử lý nước thải bằng công nghệ lò phản ứng sinh học màng: loại bỏ các chất ô nhiễm phenolic từ các nhà máy lọc dầu, than đá và ngành dược phẩm. *Polymers* 16(3):443

Lai Y, Xiao K, He Y, Liu X, Tan J, Xue W, Zhang A, Huang X (2024) Học máy trong nghiên cứu lò phản ứng sinh học màng: nguyên lý, phương pháp, ứng dụng và hướng dẫn thực hành. *Front Environ Sci Eng* 19(3):34

Li M, Han F, Zhang Z, Zeng H, Li D, Zhang J (2024) Ảnh hưởng của 2,4-dichlorophenol đến quá trình sản sinh metan từ bùn hạt kỵ khí trong quá trình phân hủy kỵ khí, qua phân tích quang phổ. *Environ Technol* 45(5):916–925

Ma J, Wang Z, He D, Li Y, Wu Z (2015) Nghiên cứu dài hạn về lò phản ứng sinh học màng điện hóa mới để xử lý nước thải đô thị nồng độ thấp. *Water Res* 78:98–110

Medina SC, Zamora-Vacca N, Luna HJ, Ratkovich N, Rodríguez Susa M (2020) Sản sinh SMP trong lò phản ứng sinh học màng chìm kỵ khí (AnMBR) ở các mức tải trọng hữu cơ khác nhau. *Membranes* 10(11):317

Meegoda JN, Li B, Patel K và Wang LB (2018) Tổng quan về các quá trình, thông số và tối ưu hóa quá trình phân hủy kỵ khí. *Int J Environ Res Public Health* 15:2224. doi: 10.3390/ijerph-15102224

Meegoda JN, Li B, Patel K, Wang LB 2018 Tổng quan về các quá trình, thông số và tối ưu hóa quá trình phân hủy kỵ khí

Menon SS, Kalyanraman V (2025) Tổng quan toàn diện về công nghệ lò phản ứng sinh học màng kỵ khí (AnMBR): những tiến bộ và xu hướng từ năm 2010 đến 2024. *Environ Technol Reviews* 14(1):17–39

Muniz de Queiroz M, Moreira VR, Amaral MCS, Oliveira SMAC (2025) Các thuật toán học máy để dự đoán hiệu suất của lò phản ứng sinh học màng: Tổng quan. *J Environ Manage* 380:124978

Muñoz Sierra JD, García Rea VS, Cerqueda-García D, Spanjers H, van Lier JB (2020) Chuển hóa kỵ khí nước thải chứa phenol và muối trong điều kiện ưa nhiệt bằng lò phản ứng sinh học màng. *Front Bioeng Biotechnol* 8:565311

Najafzadeh M, Niazmardi S (2021) Thuật toán hồi quy vectơ hỗ trợ đa hạt nhân mới để ước tính các thông số chất lượng nước. *Nat Resour Res* 30(5):3761–3775

Pacheco-Ruiz S, Heaven S, Banks CJ (2021) Vận hành lò phản ứng sinh học màng kỵ khí chìm ở 20 C: Ảnh hưởng của thời gian lưu bùn đến thông lượng, đặc tính hỗn hợp bùn và hiệu suất. *Processes* 9(9):1525

Reza AF, Singh R, Verma RK, Singh A, Ahn Y-H, Singh A, Ahn Y-H, Ray SS (2024) Tổng quan toàn diện và đa chiều về perceptron đa tầng như một công cụ mới nổi trong lĩnh vực xử lý nước và khử mặn. *Desalination* 586:117849

Rezakazemi M, Maghami M, Mohammadi T (2018) Xử lý nước thải chứa phenol và amoni bằng lò phản ứng sinh học màng chìm hiếu khí. *Chem Cent J* 12(1):79

Robles Á, Ruano MV, Charfi A, Lesage G, Heran M, Harmand J, Seco A, Steyer J-P, Batstone DJ, Kim J (2018) A review on anaerobic membrane bioreactors (AnMBRs) focused on modelling and control aspects. *Bioresour Technol* 270:612–626

Sandoval-García V, Ruano MV, Alliet M, Brepols C, Comas J, Harmand J, Heran M, Mannina G, Rodriguez-Roda I, Smets I, Robles A (2025) Modeling MBR fouling: A critical review analysis towards establishing a framework for good modeling practices. *Water Res* 268:122611

Turan M (2025) Membrane Fouling and Control Approaches in Membrane Bioreactor Systems: A Review. *Water Air Soil Pollut* 236(3):159

Viet ND, Jang A (2021) Development of artificial intelligence-based models for the prediction of filtration performance and membrane fouling in an osmotic membrane bioreactor. *J Environ Chem Eng* 9(4):105337

Wang J, Sun Y, Zhang D, Broderick T, Strawn M, Santha H, Pallansch K, Deines A and Wang Z-W (2022) Unblocking the Rate-Limiting Step of the Municipal Sludge Anaerobic Digestion. *Water Environ Res* 94(10):e10793. doi: 10.1002/wer.10793

Wang J, Sun Y, Zhang D, Broderick T, Strawn M, Santha H, Pallansch K, Deines A, Wang Z-W (2022) Unblocking the rate-limiting step of the municipal sludge anaerobic digestion. *Water Environ Res* 94(10), e10793

Wang S, Ma C, Pang C, Hu Z, Wang W (2019) Membrane fouling and performance of anaerobic ceramic membrane bioreactor treating phenol-and quinoline-containing wastewater: granular activated carbon vs polyaluminum chloride. *Environ Sci Pollut Res* 26(33):34167–34176

Wang Y-K, Pan X-R, Sheng G-P, Li W-W, Shi B-J, Yu H-Q (2015) Development of an energy-saving anaerobic hybrid membrane

bioreactors for 2-chlorophenol-contained wastewater treatment. *Chemosphere* 140:79–84

Xu X, Zhang M, Wu J, Wang S, Chen W, Dong C, Hu B, Zheng P, Qu D (2026) Big data analytics of antibiotic toxicity and inhibition in anammox systems: A review. *Bioresour Technol* 441:133656

Yaqub M, Lee W (2022) Modeling nutrient removal by membrane bioreactor at a sewage treatment plant using machine learning models. *J Water Process Eng* 46:102521

Yu J, Zheng Z, Ni J, Ji J (2026) Empowerment of accurate modeling of anaerobic membrane bioreactors by automated machine learning. *J Environ Manage* 401:128801

Zhang J, Bing W, Hu T, Zhou X, Zhang J, Liang J, Li Y (2023) Enhanced biodegradation of phenol by microbial collaboration: Resistance, metabolite utilization, and pH stabilization. *Environ Res* 238:117269

Zhang W, Hao T (2022) Insights into the role of concentration polarization on the membrane fouling and cleaning during the aerobic granular sludge filtration process. *Sci Total Environ* 813:151871

Zhong H, Yuan Y, Luo L, Ye J, Chen M, Zhong C (2022) Water quality prediction of MBR based on machine learning: A novel dataset contribution analysis method. *J Water Process Eng* 50:103296

Zhuang L, Tang B, Bin L, Li P, Huang S, Fu F (2021) Performance prediction of an internal-circulation membrane bioreactor based on models comparison and data features analysis. *Biochem Eng J* 166:107850

Zhu M, Li N, Lu Y, Hu Z, Chen S, Zeng RJ (2020) The performance and microbial communities of an anaerobic membrane bioreactor for treating fluctuating 2-chlorophenol wastewater. *Bioresour Technol* 317:124001

Publisher’s Note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.

Robles Á, Ruano MV, Charfi A, Lesage G, Heran M, Harmand J, Seco A, Steyer J-P, Batstone DJ, Kim J (2018) Tổng quan về các khía cạnh mô hình hóa và điều khiển của thiết bị phản ứng sinh học màng kỵ khí (AnMBR). *Bioresour Technol* 270:612–626

Sandoval-García V, Ruano MV, Alliet M, Brepols C, Comas J, Harmand J, Heran M, Mannina G, Rodriguez-Roda I, Smets I, Robles A (2025) Mô hình hóa hiện tượng tắc nghẽn màng trong MBR: Phân tích tổng quan có phê bình nhằm thiết lập khuôn khổ cho các thực hành mô hình hóa tốt. *Water Res* 268:122611

Turan M (2025) Hiện tượng tắc nghẽn màng và các phương pháp kiểm soát trong hệ thống thiết bị phản ứng sinh học màng: Tổng quan. *Water Air Soil Pollut* 236(3):159

Viet ND, Jang A (2021) Phát triển các mô hình dựa trên trí tuệ nhân tạo để dự đoán hiệu suất lọc và hiện tượng tắc nghẽn màng trong thiết bị phản ứng sinh học màng thẩm thấu. *J Environ Chem Eng* 9(4):105337

Wang J, Sun Y, Zhang D, Broderick T, Strawn M, Santha H, Pallansch K, Deines A và Wang Z-W (2022) Khởi thông bước giới hạn tốc độ của quá trình phân hủy kỵ khí bùn đô thị. *Water Environ Res* 94(10):e10793. doi: 10.1002/wer.10793

Wang J, Sun Y, Zhang D, Broderick T, Strawn M, Santha H, Pallansch K, Deines A, Wang Z-W (2022) Khởi thông bước giới hạn tốc độ của quá trình phân hủy kỵ khí bùn đô thị. *Water Environ Res* 94(10), e10793

Wang S, Ma C, Pang C, Hu Z, Wang W (2019) Hiện tượng tắc nghẽn màng và hiệu suất của thiết bị phản ứng sinh học màng gồm kỵ khí xử lý nước thải chứa phenol và quinoline: than hoạt tính dạng hạt so với polyaluminium chloride. *Environ Sci Pollut Res* 26(33):34167–34176

Wang Y-K, Pan X-R, Sheng G-P, Li W-W, Shi B-J, Yu H-Q (2015) Phát triển thiết bị phản ứng sinh học màng lại kỵ khí tiết kiệm năng lượng

bể phản ứng sinh học xử lý nước thải chứa 2-chlorophenol. *Chemosphere* 140:79–84

Xu X, Zhang M, Wu J, Wang S, Chen W, Dong C, Hu B, Zheng P, Qu D (2026) Phân tích dữ liệu lớn về độc tính và khả năng ức chế của kháng sinh trong các hệ thống anammox: Tổng quan. *Bioresour Technol* 441:133656

Yaqub M, Lee W (2022) Mô hình hóa quá trình loại bỏ chất dinh dưỡng bằng bể phản ứng sinh học màng tại nhà máy xử lý nước thải bằng các mô hình học máy. *J Water Process Eng* 46:102521

Yu J, Zheng Z, Ni J, Ji J (2026) Nâng cao độ chính xác trong mô hình hóa bể phản ứng sinh học màng kỵ khí bằng học máy tự động. *J Environ Manage* 401:128801

Zhang J, Bing W, Hu T, Zhou X, Zhang J, Liang J, Li Y (2023) Tăng cường phân hủy sinh học phenol nhờ sự hợp tác của vi sinh vật: Khả năng kháng chịu, sử dụng chất chuyển hóa và ổn định pH. *Environ Res* 238:117269

Zhang W, Hao T (2022) Những hiểu biết về vai trò của phân cực nồng độ đối với hiện tượng tắc nghẽn màng và quá trình làm sạch trong quá trình lọc bùn hạt hiếu khí. *Sci Total Environ* 813:151871

Zhong H, Yuan Y, Luo L, Ye J, Chen M, Zhong C (2022) Dự đoán chất lượng nước của MBR dựa trên học máy: Phương pháp phân tích đóng góp dữ liệu mới. *J Water Process Eng* 50:103296

Zhuang L, Tang B, Bin L, Li P, Huang S, Fu F (2021) Dự đoán hiệu suất của bể phản ứng sinh học màng tuần hoàn bên trong dựa trên so sánh mô hình và phân tích đặc trưng dữ liệu. *Biochem Eng J* 166:107850

Zhu M, Li N, Lu Y, Hu Z, Chen S, Zeng RJ (2020) Hiệu suất và quần xã vi sinh vật của bể phản ứng sinh học màng kỵ khí xử lý nước thải 2-chlorophenol biến động. *Bioresour Technol* 317:124001

Publisher’s Note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.