



Contents lists available at ScienceDirect

Journal of Environmental Management

journal homepage: www.elsevier.com/locate/jenvman



Research article

Empowerment of accurate modeling of anaerobic membrane bioreactors by automated machine learning

Junjie Yu ^{a,1}, Zhonghua Zheng ^{a,1} , Jialing Ni ^{b,c}, Jiayuan Ji ^{d,*}

^a Department of Earth and Environmental Sciences, The University of Manchester, Manchester, M13 9PL, UK

^b Research Center for Advanced Science and Technology, The University of Tokyo, Tokyo, 153-8904, Japan

^c UTokyo LCA Center for Future Strategy, The University of Tokyo, Tokyo, 153-8904, Japan

^d Institute for Future Initiatives, The University of Tokyo, Tokyo, 113-8654, Japan

ARTICLE INFO

Keywords:

Small datasets
Wastewater treatment
Prediction modeling
Feature importance
Data-driven modeling
Auto tuning

ABSTRACT

Machine learning (ML) is a promising approach for anaerobic membrane bioreactor (AnMBR) modeling. However, its complexity poses challenges for researchers who lack expertise in ML. To address the challenges of model selection and hyperparameter optimization in ML, we employed automated machine learning (AutoML) to model the removal of chemical oxygen demand (COD) in AnMBR treating municipal wastewater. The results show that AutoML achieved better modeling performance than previously applied deep neural models, with a mean absolute percentage error of 3.11%. We further investigated the impact of expanding the feature set and increasing the amount of data on modeling performance. The results demonstrate that the features of operation time can improve performance. However, adding more data does not markedly contribute to ML-based modeling. An analysis of ensemble feature importance indicates that the concentration of COD in influent is the most important feature for predicting the removal of COD. This study demonstrates the efficacy of AutoML for modeling AnMBRs and provides insights into the modeling of wastewater treatment processes with small datasets.

1. Introduction

In the near future, humans will use and pollute freshwater at levels where water scarcity could limit food production, ecosystem functioning, and urban water supply (Jury and Vaux, 2007). The water industry has identified wastewater as a viable and sustainable source of resource recovery (Winkler and van Loosdrecht, 2022), and activated sludge is at the core of wastewater treatment technologies (van Loosdrecht and Brdjanovic, 2014). Among the wastewater treatment technologies, the anaerobic membrane bioreactor (AnMBR) is a promising solution because of its low operational cost, reduced waste sludge production, and high potential for energy recovery (Ho and Sung, 2010; Pretel et al., 2015; Robles et al., 2022). By integrating anaerobic digestion with membrane filtration, AnMBRs not only achieves effective wastewater treatment but also facilitates resource recovery, such as biogas production, rendering it an effective technology for a circular economy and sustainable development (Krzeminski et al., 2017; Moideen et al., 2023). Additionally, AnMBRs offer a fast start-up and a

smaller footprint for wastewater treatment (Robles et al., 2018). However, the development of AnMBRs primarily relies on laboratory experiments, followed by pilot-scale trial (Q. Li et al., 2024; Z. Li et al., 2024; Ren et al., 2024). Operating such systems generally consumes large amounts of chemical reagents, needs professional equipment support (Li et al., 2022), and requires months to years, rendering them time- and resource-intensive. These constraints on laboratory resources and space further limit the number and duration of reactor runs, impeding the development of AnMBRs.

To overcome these constraints, data-driven modeling, particularly machine learning (ML), has gained considerable attention as a tool for advancing AnMBR technologies and processes (Li et al., 2022; Robles et al., 2018; Wang and Li, 2024). ML models enable simulations of reactor performance by utilizing operational parameters and influent water quality as inputs and predicting effluent water quality as outputs (Li et al., 2022; Mahanna et al., 2024; Pal et al., 2024). This approach facilitates the analysis of the complex relationships between influent and effluent characteristics and offers valuable insights into reactor

* Corresponding author.

E-mail addresses: kikaen@ifi.u-tokyo.ac.jp, kikaen@tohoku.ac.jp (J. Ji).

¹ These authors contributed equally to this work.

<https://doi.org/10.1016/j.jenvman.2026.128801>

Received 12 December 2025; Received in revised form 21 January 2026; Accepted 30 January 2026

Available online 9 February 2026

0301-4797/© 2026 The Authors. Published by Elsevier Ltd. This is an open access article under the CC BY-NC-ND license (<http://creativecommons.org/licenses/by-nc-nd/4.0/>).



Contents lists available at ScienceDirect

Journal of Environmental Management

journal homepage: www.elsevier.com/locate/jenvman



Bài báo nghiên cứu

Tăng cường khả năng mô hình hóa chính xác các bể phản ứng sinh học màng kỵ khí bằng học máy tự động

Junjie Yu ^{a,1}, Zhonghua Zheng ^{a,1} , Jialing Ni ^{b,c}, Jiayuan Ji ^{d,*}

^a Department of Earth and Environmental Sciences, The University of Manchester, Manchester, M13 9PL, UK

^b Research Center for Advanced Science and Technology, The University of Tokyo, Tokyo, 153-8904, Japan

^c UTokyo LCA Center for Future Strategy, The University of Tokyo, Tokyo, 153-8904, Japan

^d Institute for Future Initiatives, The University of Tokyo, Tokyo, 113-8654, Japan

THÔNG TIN BÀI VIẾT

Keywords:

Bộ dữ liệu nhỏ Xử lý nước thải Mô hình dự đoán Tầm quan trọng của đặc trưng Mô hình hóa dựa trên dữ liệu Tự động tinh chỉnh

TÓM TẮT

Học máy (ML) là một phương pháp đầy hứa hẹn để mô hình hóa bể phản ứng sinh học màng kỵ khí (AnMBR). Tuy nhiên, tính phức tạp của phương pháp này gây khó khăn cho các nhà nghiên cứu thiếu chuyên môn về ML. Để giải quyết những thách thức trong việc lựa chọn mô hình và tối ưu hóa siêu tham số trong ML, chúng tôi sử dụng học máy tự động (AutoML) để mô hình hóa quá trình loại bỏ nhu cầu oxy hóa học (COD) trong AnMBR xử lý nước thải đô thị. Kết quả cho thấy AutoML đạt hiệu quả mô hình hóa tốt hơn các mô hình mạng nơ-ron sâu từng được áp dụng trước đây, với sai số phần trăm tuyệt đối trung bình là 3,11%. Chúng tôi tiếp tục khảo sát tác động của việc mở rộng tập đặc trưng và tăng lượng dữ liệu đến hiệu quả mô hình hóa. Kết quả cho thấy các đặc trưng về thời gian vận hành có thể cải thiện hiệu quả. Tuy nhiên, việc bổ sung dữ liệu không đóng góp đáng kể cho mô hình hóa dựa trên ML. Phân tích tầm quan trọng của đặc trưng trong mô hình tổ hợp cho thấy nồng độ COD trong dòng vào là đặc trưng quan trọng nhất để dự đoán mức loại bỏ COD. Nghiên cứu này chứng minh hiệu quả của AutoML trong việc mô hình hóa AnMBR, đồng thời cung cấp những hiểu biết về mô hình hóa các quy trình xử lý nước thải với bộ dữ liệu nhỏ.

1. Giới thiệu

Trong tương lai gần, con người sẽ sử dụng và làm ô nhiễm nước ngọt ở mức độ có thể khiến tình trạng khan hiếm nước hạn chế sản xuất lương thực, chức năng của hệ sinh thái và nguồn cung cấp nước đô thị (Jury and Vaux, 2007). Ngành nước đã xác định nước thải là nguồn thu hồi tài nguyên khả thi và bền vững (Winkler and van Loosdrecht, 2022), còn bùn hoạt tính là công nghệ cốt lõi trong xử lý nước thải (van Loosdrecht and Brdjanovic, 2014). Trong số các công nghệ xử lý nước thải, bể phản ứng sinh học màng kỵ khí (AnMBR) là một giải pháp đầy hứa hẹn nhờ chi phí vận hành thấp, giảm lượng bùn thải phát sinh và tiềm năng thu hồi năng lượng cao (Ho and Sung, 2010; Pretel et al., 2015; Robles et al., 2022). Bằng cách kết hợp quá trình phân hủy kỵ khí với lọc màng, AnMBR không chỉ xử lý nước thải hiệu quả mà còn thúc đẩy thu hồi tài nguyên, chẳng hạn như sản xuất khí sinh học, qua đó trở thành một công nghệ hiệu quả cho nền kinh tế tuần hoàn và phát triển bền vững (Krzeminski et al., 2017; Moideen et al., 2023). Ngoài ra, AnMBR có thời gian khởi động nhanh và một

diện tích nhỏ hơn cho xử lý nước thải (Robles và cộng sự, 2018). Tuy nhiên, quá trình phát triển AnMBR chủ yếu dựa vào các thí nghiệm trong phòng thí nghiệm, sau đó là thử nghiệm ở quy mô thí điểm (Q. Li và cộng sự, 2024; Z. Li và cộng sự, 2024; Ren và cộng sự, 2024). Việc vận hành các hệ thống như vậy thường tiêu tốn lượng lớn hóa chất, cần có thiết bị chuyên dụng hỗ trợ (Li và cộng sự, 2022) và kéo dài từ vài tháng đến vài năm, khiến chúng đòi hỏi nhiều thời gian và nguồn lực. Những hạn chế về nguồn lực và không gian phòng thí nghiệm này càng làm giảm số lượng và thời gian vận hành các thiết bị phản ứng, cản trở sự phát triển của AnMBR.

Để khắc phục những hạn chế này, mô hình hóa dựa trên dữ liệu, đặc biệt là học máy (ML), đã thu hút sự chú ý đáng kể như một công cụ thúc đẩy các công nghệ và quy trình AnMBR (Li et al., 2022; Robles et al., 2018; Wang and Li, 2024). Các mô hình ML cho phép mô phỏng hiệu suất của lò phản ứng bằng cách sử dụng các thông số vận hành và chất lượng nước đầu vào làm dữ liệu đầu vào, đồng thời dự đoán chất lượng nước đầu ra (Li et al., 2022; Mahanna et al., 2024; Pal et al., 2024). Phương pháp này tạo điều kiện phân tích các mối quan hệ phức tạp giữa đặc tính nước đầu vào và đầu ra, đồng thời cung cấp những hiểu biết có giá trị về lò phản ứng

* Corresponding author.

E-mail addresses: kikaen@ifi.u-tokyo.ac.jp, kikaen@tohoku.ac.jp (J. Ji).

¹ These authors contributed equally to this work.

<https://doi.org/10.1016/j.jenvman.2026.128801>

Received 12 December 2025; Received in revised form 21 January 2026; Accepted 30 January 2026

Available online 9 February 2026

0301-4797/© 2026 The Authors. Published by Elsevier Ltd. This is an open access article under the CC BY-NC-ND license (<http://creativecommons.org/licenses/by-nc-nd/4.0/>).

operation and performance optimization. In addition, ML-based simulations provide a cost-effective alternative to traditional experimental methods, enabling the evaluation of numerous potential operational scenarios with minimal resource consumption. Such capabilities are particularly valuable for guiding the design and operation of AnMBR systems, particularly in contexts where real-world experiments are impractical or resource constrained.

However, the application of ML in AnMBR modeling remains challenging. One major obstacle is the significant heterogeneity of AnMBR systems, which stems from variations in the microbial community structures, physical configurations, and influent water quality. These factors fundamentally affect reactor performance and resource recovery efficiency. For instance, Ji et al. (2020) observed that the membrane pore size in an AnMBR can influence the effluent chemical oxygen demand (COD) concentrations and the reactor's microbial composition (Ji et al., 2020), thereby affecting the effluent quality and resource recovery efficiency. This variability limits the development of generalized ML models that can be reliably applied to different reactors and environmental conditions. Instead, ML models often require customization to account for the unique configurations of individual reactors. This demands for tailored modeling for flexible and adaptive approaches for ML-driven AnMBR optimization. Another complication is that developing effective ML models for AnMBR systems involves a series of complex tasks, including ML algorithm selection and hyperparameter optimization, which typically require substantial ML expertise (He et al., 2021; Karmaker ("Santu") et al., 2021). To address these challenges, automated machine learning (AutoML) has emerged as a promising solution to reduce the complexity of repetitive tasks in ML pipelines (Truong et al., 2019). Although ML models have been implemented in MBRs, their real-world uptake remains limited. AutoML has been highlighted as a promising method for facilitating the practical deployment of ML models (Lai et al., 2024). In particular, AutoML

automates key steps, such as ML algorithm selection and hyperparameter optimization, thereby reducing the technical complexity and time required for developing high-performance ML models. In addition, by democratizing access to ML techniques, AutoML has the potential to empower a wider range of users to leverage data-driven approaches in AnMBR development, thereby fostering broader adoption and innovation in this field (Li et al., 2021).

This study aims to leverage an AutoML framework for rapid modeling of the complex nonlinear dynamics of the AnMBR during wastewater treatment. Within the proposed rapid modeling framework, we investigated the impact of increasing the features (predictive variables) and training dataset size on the model performance by comparing the results with those of existing models based on neural networks. Additionally, we proposed an ensemble learning interpretation framework to explain the AutoML-based model. The findings of this study contribute to the broader application of AutoML in wastewater treatment reactor modeling and provide valuable guidance for developing effective models for AnMBR systems.

2. Methods

The overall workflow includes data collection from on-site lab-scale experiments, AutoML model development with different inputs, and ensemble ranking analysis of feature importance (Fig. 1). Data collection is described in Section 2.1. AutoML model development is detailed in Section 2.2 and 2.3, and feature importance calculations and analyses are presented in Section 2.4.

2.1. Data

The data were obtained from two AnMBRs that operated continuously in long-term experiments treating municipal sewage (Ji et al.,

tối ưu hóa vận hành và hiệu suất. Ngoài ra, các mô phỏng dựa trên học máy mang đến một giải pháp thay thế tiết kiệm chi phí cho các phương pháp thực nghiệm truyền thống, cho phép đánh giá nhiều kịch bản vận hành tiềm năng với mức tiêu thụ tài nguyên tối thiểu. Những khả năng này đặc biệt hữu ích trong việc định hướng thiết kế và vận hành các hệ thống AnMBR, nhất là trong những bối cảnh khó có thể tiến hành thí nghiệm thực tế hoặc bị hạn chế về nguồn lực.

Tuy nhiên, việc ứng dụng ML trong mô hình hóa AnMBR vẫn còn nhiều thách thức. Một trở ngại lớn là tính không đồng nhất đáng kể của các hệ thống AnMBR, bắt nguồn từ sự khác biệt về cấu trúc quần xã vi sinh vật, cấu hình vật lý và chất lượng nước đầu vào. Những yếu tố này ảnh hưởng căn bản đến hiệu suất của bể phản ứng và hiệu quả thu hồi tài nguyên. Chẳng hạn, Ji và cộng sự (2020) nhận thấy kích thước lỗ màng trong AnMBR có thể ảnh hưởng đến nồng độ nhu cầu oxy hóa học (COD) trong nước đầu ra và thành phần vi sinh vật của bể phản ứng (Ji và cộng sự, 2020), qua đó tác động đến chất lượng nước đầu ra và hiệu quả thu hồi tài nguyên. Sự biến thiên này hạn chế việc phát triển các mô hình ML tổng quát có thể được áp dụng một cách đáng tin cậy cho những bể phản ứng và điều kiện môi trường khác nhau. Thay vào đó, các mô hình ML thường cần được tùy chỉnh để tính đến cấu hình riêng của từng bể phản ứng. Điều này đòi hỏi việc mô hình hóa phù hợp với từng trường hợp, hướng đến các phương pháp linh hoạt và thích ứng để tối ưu hóa AnMBR dựa trên ML. Một vấn đề phức tạp khác là việc phát triển các mô hình ML hiệu quả cho hệ thống AnMBR bao gồm một loạt tác vụ phức tạp, như lựa chọn thuật toán ML và tối ưu hóa siêu tham số, vốn thường đòi hỏi chuyên môn đáng kể về ML (He và cộng sự, 2021; Karmaker ("Santu") và cộng sự, 2021). Để giải quyết những thách thức này, học máy tự động (AutoML) đã nổi lên như một giải pháp đầy triển vọng nhằm giảm độ phức tạp của các tác vụ lặp lại trong quy trình ML (Truong và cộng sự, 2019). Mặc dù các mô hình ML đã được triển khai trong MBR, mức độ ứng dụng thực tế vẫn còn hạn chế. AutoML được xem là một phương pháp triển vọng để thúc đẩy việc triển khai hai các mô hình ML vào thực tiễn (Lai và cộng sự, 2024). Cụ thể, AutoML

tự động hóa các bước then chốt, chẳng hạn như lựa chọn thuật toán ML và tối ưu hóa siêu tham số, qua đó giảm độ phức tạp về kỹ thuật và thời gian cần thiết để phát triển các mô hình ML hiệu suất cao. Ngoài ra, bằng cách dân chủ hóa quyền tiếp cận các kỹ thuật ML, AutoML có tiềm năng trao quyền cho nhiều đối tượng người dùng hơn trong việc khai thác các phương pháp dựa trên dữ liệu để phát triển AnMBR, qua đó thúc đẩy việc ứng dụng rộng rãi hơn và đổi mới trong lĩnh vực này (Li và cộng sự, 2021).

Nghiên cứu này nhằm tận dụng một khuôn khổ AutoML để mô hình hóa nhanh các động lực phi tuyến phức tạp của AnMBR trong quá trình xử lý nước thải. Trong khuôn khổ mô hình hóa nhanh được đề xuất, chúng tôi đã khảo sát tác động của việc tăng số lượng đặc trưng (biến dự đoán) và quy mô tập dữ liệu huấn luyện đến hiệu suất mô hình bằng cách so sánh kết quả với các mô hình hiện có dựa trên mạng nơ-ron. Ngoài ra, chúng tôi đề xuất một khuôn khổ diễn giải học tập tổ hợp để giải thích mô hình dựa trên AutoML. Những phát hiện của nghiên cứu này góp phần mở rộng ứng dụng AutoML trong mô hình hóa các thiết bị phản ứng xử lý nước thải và cung cấp hướng dẫn hữu ích để phát triển các mô hình hiệu quả cho hệ thống AnMBR.

2. Phương pháp

Quy trình tổng thể bao gồm thu thập dữ liệu từ các thí nghiệm quy mô phòng thí nghiệm tại hiện trường, phát triển mô hình AutoML với các đầu vào khác nhau và phân tích xếp hạng tổng hợp về mức độ quan trọng của các đặc trưng (Hình 1). Việc thu thập dữ liệu được mô tả trong Mục 2.1. Quá trình phát triển mô hình AutoML được trình bày chi tiết trong Mục 2.2 và 2.3; các phép tính và phân tích mức độ quan trọng của các đặc trưng được trình bày trong Mục 2.4.

2.1. Data

Dữ liệu được thu thập từ hai AnMBR vận hành liên tục trong các thí nghiệm dài hạn xử lý nước thải đô thị (Ji et al.,





Fig. 1. Overview of the workflow. (a) Flowchart of AnMBR experiment. (b) Modeling framework. T-R: reactor operation temperature; pH-in: influent pH; T-in: influent temperature; T-env: environment temperature; COD-in: influent chemical oxygen demand; OD: operation days; ORP: oxidation-reduction potential; HRTs: hydraulic retention times; MLSS: mixed liquor suspended solids; MVLSS: mixed liquor volatile suspended solids; FLMAL: the automated machine learning package; FCN: fully connected network; CNN: convolutional neural network; and DenseNet: densely connected convolutional network. Tree-based, permutation, and SHAP indicate different interpretation methods for machine learning models.



Hình 1. Tổng quan quy trình. (a) Lưu đồ thí nghiệm AnMBR. (b) Khung mô hình hóa. T-R: nhiệt độ vận hành của thiết bị phản ứng; pH-in: pH nước đầu vào; T-in: nhiệt độ nước đầu vào; T-env: nhiệt độ môi trường; COD-in: nhu cầu oxy hóa học của nước đầu vào; OD: số ngày vận hành; ORP: thế oxy hóa-khử; HRTs: thời gian lưu thủy lực; MLSS: chất rắn lơ lửng trong hỗn hợp bùn; MVLSS: chất rắn lơ lửng bay hơi trong hỗn hợp bùn; FLMAL: gói học máy tự động; FCN: mạng kết nối đầy đủ; CNN: mạng nơ-ron tích chập; và DenseNet: mạng nơ-ron tích chập kết nối đầy đủ. Các phương pháp dựa trên cây, hoán vị và SHAP là những phương pháp diễn giải khác nhau dành cho các mô hình học máy.

2020, 2021a, 2021b). The volume of each reactor was 20 L, and the reactors were installed at a wastewater treatment plant (WWTP) for better access to raw municipal sewage. The membrane modules used in both AnMBRs were hollow fiber polyvinylidene difluoride membranes, but with pore sizes of $0.4 \mu\text{m}$ and $0.05 \mu\text{m}$. The operating temperature was maintained between 20°C and 25°C using water baths (NTT-20S, EYELA, Japan). Hydraulic retention times (HRTs) of 4–24 h were applied to AnMBR1, whereas HRTs of 10–24 h were applied to AnMBR2. Additional details, including the basic water quality of the raw municipal wastewater, experimental equipment, and conditions, have been reported in previous studies (Ji et al., 2020, 2021a, 2021b). The COD, mixed liquor suspended solids (MLSS), and mixed liquor volatile suspended solids (MLVSS) were measured by standard methods (Bridgewater et al., 2017). The MLSS and MLVSS data were sampled weekly, and these data were filled using linear interpolation to match the frequency of COD data. The oxidation-reduction potential (ORP) of the anaerobically activated sludge was measured using an ORP meter (TOADKK, RM-30P, Japan). A total of 11 features were included in this study, including the reactor operation days (OD; Unit: day), reactor operation temperature (T-R; Unit: $^\circ\text{C}$), influent temperature (T-in; Unit: $^\circ\text{C}$), environment temperature (T-env; Unit: $^\circ\text{C}$), influent pH (pH-in; Unitless), influent COD (COD-in; Unit: mg/L), flux (Unit: m/day), ORP (Unit: mV), HRT (Unit: hour), MLSS (Unit: mg/L), and MLVSS (Unit: mg/L). The output was the COD removal rate (COD-re; Unit: %). The total sample size of this dataset was 185, which was divided into training and testing sets using a 9:1 split ratio (166:19) in previous study (Li et al., 2022). The above data was obtained by running the reactors in 50–414 days.

We designed comparative studies to investigate: (1) the permanence of AutoML, (2) the impact of feature selection on modeling performance, and (3) the effects of data volume (Fig. 1). First, for comparing with the previous models, we used the same training set and testing data as in a previous study that applied deep learning models, in which T-R, T-in, T-env, pH-in, COD-in, and flux were used as inputs and COD-re was used as a label (Li et al., 2022). The results of deep learning networks from Li et al. (2022), including a fully connected network (FCN), a convolutional neural network (CNN), and a densely connected convolutional network (DenseNet), were adopted. These existing models serve as baselines (Fig. 1). Subsequently, we examined feature contribution by integrating OD, ORP, HRT, MLSS, and MLVSS (more feature modeling experiment in Fig. 1). These variables were analysed through both individual and combined inclusion to delineate their effects on modeling performance. Lastly, to explore whether the size of the training dataset would improve ML model performance, we used additional data collected from longer operational times of the same AnMBRs (more data modeling experiment in Fig. 1). The sample size of the additional data was 135, which was obtained by running the reactors in 7–546 days. In addition to benchmarking against Li et al. (2022), we employed 10-fold cross-validation to evaluate the AutoML models. During 10-fold cross-validation, 10 independent models were trained, with each iteration using a distinct 90% training and 10% testing split. This approach assesses the variance in model performance and ensures that the reported results are robust to data perturbations.

2.2. Modeling

The model of AnMBR is constructed as follows:

$$Y = f_{\theta}(X), \quad (1)$$

where Y is the COD-re, X is the matrix of input features, and f_{θ} is the model parameterized with θ . Data-driven modeling aims to estimate the optimal set of parameters, θ , that best represents the given data.

However, identifying suitable model parameters can be difficult because the process often depends on appropriately configuring hyperparameters (e.g., learning rate, batch size, epochs for neural networks,

estimator number, learning rate, and maximum depth of tree for tree-based models) to guide the learning process. Hyperparameters are settings that influence the training process and model performance but are not learned through the training process.

Hyperparameter tuning is a crucial step in optimizing the model's performance. Common methods for hyperparameter optimization include grid search, random search, Bayesian optimization, and genetic algorithms. Although these methods assist in hyperparameter tuning, they often require substantial ML expertise and computational resources, which limit their accessibility. Consequently, AutoML has been developed to streamline the process of hyperparameter tuning and make it more accessible.

In this study, we employed a Fast Library for AutoML and tuning (FLAML), supporting fast and economical automatic tuning for machine learning (Wang et al., 2021b). This library selects a search order optimized for both computational cost and model error, iteratively selecting the models, hyperparameters, sample size, and resampling strategy. FLAML demonstrated remarkable performance, outperforming other leading libraries of AutoML (e.g., Auto-sklearn, H2O AutoML, and Alpine Meadow) (Wang et al., 2021b). Studies from environmental sciences, atmospheric sciences, and climate sciences are benefited from this package (Dong et al., 2025; Xia et al., 2023; Zheng et al., 2023). As tree-based models are suitable for tabular data, they were selected as base candidates for the FLAML model selection process, including the random forests (RF) (Breiman, 2001), extremely randomized trees (Geurts et al., 2006), XGBoost (a scalable end-to-end tree boosting system) (Chen and Guestrin, 2016), LightBGM (a highly efficient gradient boosting decision tree) (Ke et al., 2017), and Catboost (gradient boosting with categorical features support) (Dorogush et al., 2018). FLAML implements a Cost-Frugal Optimization (CFO) strategy, which starts with a low-cost configuration (e.g., small model size) and iteratively moves to more complex configurations only when the performance gain justifies the additional computational cost (Wu et al., 2021). Thus, this method can control cost during the optimization process compared to traditional hyperparameters optimization processes. Further, BlendSearch was applied by default, which is a hierarchical search algorithm that combines global exploration with local optimization to minimize the total cost spent in finding good configurations (Wang et al., 2021a). The optimization process was constrained by a global time budget of 300 s. The optimization will be terminated when time budget is exhausted. To prevent overfitting, we adopted a 5-fold cross-validation strategy with a mean squared error (MSE) criterion during each AutoML optimization. Notably, the search spaces for the select learners above are dynamically included the number of estimators, number of leaves, learning rate, and regularization parameters. The specific search ranges were then determined by CFO strategy based on the training dataset size. The optimal sets of hyperparameters and settings of all models are provided in Supporting Information.

2.3. Evaluation

The evaluation metrics utilized in this study included the MSE, mean absolute error (MAE), root mean squared error (RMSE), mean absolute percentage error (MAPE), and coefficient of determination (R^2), which were calculated as follows:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (2)$$

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (3)$$

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| * 100, \quad (4)$$

2020, 2021a, 2021b). Thể tích của mỗi thiết bị phản ứng là 20 L, và các thiết bị được lắp đặt tại một nhà máy xử lý nước thải (WWTP) để thuận tiện hơn cho việc tiếp cận nước thải đô thị thô. Các mô-đun màng được sử dụng trong cả hai AnMBR là màng sợi rỗng polyvinylidene difluoride, với kích thước lỗ lần lượt là $0.4 \mu\text{m}$ và $0.05 \mu\text{m}$. Nhiệt độ vận hành được duy trì trong khoảng 20°C đến 25°C bằng các bể điều nhiệt (NTT-20S, EYELA, Nhật Bản). Thời gian lưu thủy lực (HRT) từ 4–24 h được áp dụng cho AnMBR1, trong khi HRT từ 10–24 h được áp dụng cho AnMBR2. Các chi tiết bổ sung, bao gồm chất lượng nước cơ bản của nước thải đô thị thô, thiết bị thí nghiệm và điều kiện vận hành, đã được báo cáo trong các nghiên cứu trước đây (Ji et al., 2020, 2021a, 2021b). COD, chất rắn lơ lửng trong hỗn hợp bùn (MLSS) và chất rắn lơ lửng bay hơi trong hỗn hợp bùn (MLVSS) được đo theo các phương pháp tiêu chuẩn (Bridgewater et al., 2017). Dữ liệu MLSS và MLVSS được lấy mẫu hằng tuần, sau đó được nội suy tu yển tính để khớp với tần suất của dữ liệu COD. Thế oxy hóa-khử (ORP) của bùn hoạt tính kỵ khí được đo bằng máy đo ORP (TOADKK, RM-30P, Nhật Bản). Nghiên cứu này bao gồm tổng cộng 11 đặc trưng: số ngày vận hành thiết bị phản ứng (OD; đơn vị: ngày), nhiệt độ vận hành thiết bị phản ứng (T-R; đơn vị: $^\circ\text{C}$), nhiệt độ nước đầu vào (T-in; đơn vị: $^\circ\text{C}$), nhiệt độ môi trường (T-env; đơn vị: $^\circ\text{C}$), pH đầu vào (pH-in; không thứ nguyên), COD đầu vào (COD-in; đơn vị: mg/L), thông lượng (đơn vị: m/ngày), ORP (đơn vị: mV), HRT (đơn vị: giờ), MLSS (đơn vị: mg/L) và MLVSS (đơn vị: mg/L). Đầu ra là tỷ lệ loại bỏ COD (COD-re; đơn vị: %). Tổng số mẫu của bộ dữ liệu này là 185, được chia thành tập huấn luyện và tập kiểm tra theo tỷ lệ 9:1 (166:19) trong nghiên cứu trước đây (Li et al., 2022). Dữ liệu trên được thu thập khi vận hành các thiết bị phản ứng trong 50–414 ngày.

Chúng tôi thiết kế các nghiên cứu so sánh để khảo sát: (1) tính ổn định của AutoML, (2) tác động của việc lựa chọn đặc trưng đến hiệu suất mô hình hóa và (3) ảnh hưởng của lượng dữ liệu (Hình 1). Trước tiên, để so sánh với các mô hình trước đây, chúng tôi sử dụng cùng tập huấn luyện và dữ liệu kiểm tra như trong một nghiên cứu trước đó áp dụng các mô hình học sâu, trong đó T-R, T-in, T-env, pH-in, COD-in và lưu lượng được dùng làm đầu vào, còn COD-re được dùng làm nhãn (Li et al., 2022). Chúng tôi sử dụng kết quả của các mạng học sâu từ Li et al. (2022), bao gồm mạng kết nối đầy đủ (FCN), mạng nơ-ron tích chập (CNN) và mạng tích chập kết nối dày đặc (DenseNet). Các mô hình hiện có này đóng vai trò làm đường cơ sở (Hình 1). Tiếp đó, chúng tôi khảo sát mức độ đóng góp của các đặc trưng bằng cách bổ sung OD, ORP, HRT, MLSS và MLVSS (thí nghiệm mô hình hóa với nhiều đặc trưng hơn trong Hình 1). Các biến này được phân tích bằng cách đưa vào riêng lẻ và kết hợp để xác định tác động của chúng đến hiệu suất mô hình hóa. Cuối cùng, để tìm hiểu liệu quy mô tập dữ liệu huấn luyện có cải thiện hiệu suất mô hình ML hay không, chúng tôi sử dụng dữ liệu bổ sung được thu thập trong thời gian vận hành dài hơn của cùng các AnMBR (thí nghiệm mô hình hóa với nhiều dữ liệu hơn trong Hình 1). Cỡ mẫu của dữ liệu bổ sung là 135, thu được bằng cách vận hành các thiết bị phản ứng trong 7–546 ngày. Ngoài việc đối chiếu với Li et al. (2022), chúng tôi sử dụng kiểm định chéo 10 phần để đánh giá các mô hình AutoML. Trong quá trình kiểm định chéo 10 phần, 10 mô hình độc lập được huấn luyện; mỗi vòng lặp sử dụng một cách chia riêng biệt gồm 90% dữ liệu huấn luyện và 10% dữ liệu kiểm tra. Phương pháp này đánh giá mức độ biến thiên trong hiệu suất mô hình và bảo đảm rằng các kết quả đã được báo cáo vẫn vững chắc trước những biến động của dữ liệu.

2.2. Modeling

Mô hình AnMBR được xây dựng như sau:

$$Y = f_{\theta}(X), \quad (1)$$

trong đó Y là COD-re, X là ma trận các đặc trưng đầu vào, và f_{θ} là mô hình được tham số hóa với θ . Mô hình hóa dựa trên dữ liệu nhằm ước lượng tập tham số tối ưu θ , biểu diễn tốt nhất dữ liệu đã cho.

Tuy nhiên, việc xác định các tham số mô hình phù hợp có thể khó khăn vì quá trình này thường phụ thuộc vào việc cấu hình siêu tham số thích hợp (ví dụ: tốc độ học, kích thước lỗ, số epoch đối với mạng nơ-ron,

số lượng bộ ước lượng, tốc độ học và độ sâu tối đa của cây đối với các mô hình dựa trên cây) để định hướng quá trình học. Siêu tham số là các thiết lập ảnh hưởng đến quá trình huấn luyện và hiệu suất của mô hình nhưng không được học trong quá trình huấn luyện.

Tinh chỉnh siêu tham số là một bước quan trọng để tối ưu hóa hiệu suất của mô hình. Các phương pháp phổ biến để tối ưu hóa siêu tham số bao gồm tìm kiếm theo lưới, tìm kiếm ngẫu nhiên, tối ưu hóa Bayes và thuật toán di truyền. Mặc dù các phương pháp này hỗ trợ tinh chỉnh siêu tham số, chúng thường đòi hỏi chuyên môn đáng kể về học máy và tài nguyên tính toán, khiến chúng khó tiếp cận hơn. Vì vậy, AutoML đã được phát triển để hợp lý hóa quy trình tinh chỉnh siêu tham số và giúp quy trình này dễ tiếp cận hơn.

Trong nghiên cứu này, chúng tôi sử dụng thư viện Fast Library for AutoML and Tuning (FLAML), hỗ trợ điều chỉnh tự động nhanh chóng và tiết kiệm cho học máy (Wang et al., 2021b). Thư viện này lựa chọn thứ tự tìm kiếm được tối ưu hóa đồng thời theo chi phí tính toán và sai số mô hình, lần lượt lựa chọn mô hình, siêu tham số, kích thước mẫu và chiến lược lấy mẫu lại. FLAML thể hiện hiệu suất vượt trội, tốt hơn các thư viện AutoML hàng đầu khác (ví dụ: Auto-sklearn, H2O AutoML và Alpine Meadow) (Wang et al., 2021b). Các nghiên cứu trong lĩnh vực khoa học môi trường, khoa học khí quyển và khoa học khí hậu đều hưởng lợi từ gói này (Dong et al., 2025; Xia et al., 2023; Zheng et al., 2023). Vì các mô hình dựa trên cây phù hợp với dữ liệu dạng bảng, chúng được chọn làm ứng viên cơ sở cho quy trình lựa chọn mô hình của FLAML, bao gồm rừng ngẫu nhiên (RF) (Breiman, 2001), cây cực kỳ ngẫu nhiên (Geurts et al., 2006), XGBoost (hệ thống tăng cường cây đầu cuối có khả năng mở rộng) (Chen and Guestrin, 2016), LightBGM (cây quyết định tăng cường gradient có hiệu suất cao) (Ke et al., 2017) và Catboost (tăng cường gradient hỗ trợ các đặc trưng phân loại) (Dorogush et al., 2018). FLAML triển khai chiến lược Tối ưu hóa Tiết kiệm Chi phí (CFO), bắt đầu với một cấu hình có chi phí thấp (ví dụ: kích thước mô hình nhỏ) rồi lần lượt chuyển sang các cấu hình phức tạp hơn chỉ khi mức cải thiện hiệu suất xứng đáng với chi phí tính toán bổ sung (Wu et al., 2021). Vì vậy, so với các quy trình tối ưu hóa siêu tham số truyền thống, phương pháp này có thể kiểm soát chi phí trong quá trình tối ưu hóa. Ngoài ra, BlendSearch được áp dụng theo mặc định. Đây là một thuật toán tìm kiếm phân cấp, kết hợp khám phá toàn cục với tối ưu hóa cục bộ nhằm giảm thiểu tổng chi phí để tìm ra các cấu hình tốt (Wang et al., 2021a). Quá trình tối ưu hóa bị giới hạn bởi ngân sách thời gian tổng thể là 300 giây và sẽ kết thúc khi hết ngân sách thời gian. Để tránh hiện tượng quá khớp, chúng tôi áp dụng chiến lược kiểm định chéo 5 phần với tiêu chí sai số bình phương trung bình (MSE) trong mỗi lần tối ưu hóa AutoML. Đáng chú ý, không gian tìm kiếm của các thuật toán học được lựa chọn nêu trên bao gồm động số lượng bộ ước lượng, số lá, tốc độ học và các tham số chính quy hóa. Các phạm vi tìm kiếm cụ thể sau đó được xác định bằng chiến lược CFO dựa trên kích thước tập dữ liệu huấn luyện. Các bộ siêu tham số tối ưu và thiết lập của tất cả mô hình được trình bày trong Thông tin bổ trợ.

2.3. Evaluation

Các chỉ số đánh giá được sử dụng trong nghiên cứu này bao gồm MSE, sai số tuyệt đối trung bình (MAE), căn bậc hai của sai số bình phương trung bình (RMSE), sai số phần trăm tuyệt đối trung bình (MAPE) và hệ số xác định (R^2), được tính như sau:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (2)$$

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (3)$$

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| * 100, \quad (4)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (5)$$

where y_i and $\hat{y}_i$ are the observations and model predictions, respectively, and n is the number of samples. MAE is the average of the absolute differences between y_i and $\hat{y}_i$. RMSE is the square root of the mean of the squared differences between y_i and $\hat{y}_i$. It assigns higher weights to larger errors owing to the squaring of errors compared with MAE. RMSE and MAE represent the precision of model predictions. MAPE is the average percentage difference between y_i and $\hat{y}_i$. An R^2 value of one signifies a perfect fit of the model to the data. When R^2 value is close to zero, it indicates that the model has minimal explanatory power over the target variable. When R^2 value is negative, it indicates that prediction error exceeds the inherent variance of the dataset. In general, the R^2 value is better when closer to 1. Notably, the units of MAE and RMSE in this study are percentages (%) (same as the output unit), and the unit of MAPE is also percentage (%) (relative error that calculated by equation (4)).

While error metrics (e.g., RMSE) assess the overall predictive performance, they do not explicitly quantify the agreement between the predicted values and the ground truth (Martin Bland and Altman, 1986). Therefore, to evaluate the concordance between the predicted COD removal efficiency and the ground truth, the Bland-Altman analysis was performed (Martin Bland and Altman, 1986). The Bland-Altman method analyses the difference between the two methods against their average. In this study, the difference is calculated as the ground truth subtracting the prediction. A non-zero difference reveals that the model generally overestimates (difference <0) or underestimates (difference >0) the measurement. If the limits of agreement did not exceed the professionally acceptable value range and 95% of the differences lie within 95% limits of agreement, then the consistency of the two methods was considered to be good (Li et al., 2022). The 95% limits of agreement were determined by adding and subtracting 1.96 standard deviations to the mean difference.

2.4. Ablation studies

We conducted ablation studies to evaluate the contributions of different features to the performances of the ML models. An ablation study is a technique used to assess the impact of specific components (e.g., features, parameters, or data) by removing or modifying them and observing the resulting changes in model performance. Specifically, we assessed the impact of OD, ORP, HRT, MLSS, and MLVSS on model performance. By comparing the performance of models with and without specific features, we can infer how these features influence modeling. Additionally, given that we collected more data than the previous study, we investigated the effect of this extended dataset on modeling performance. Throughout the ablation studies, the training and testing data, as well as the model training parameters, were maintained consistently with the previous setup.

2.5. Feature ranking score

We developed an ensemble framework using ranking score tailored for AutoML tasks. This framework combines tree-based feature importance, permutation feature importance, and shapley additive explanations (SHAP) values (Schreck et al., 2023; Yu et al., 2025; Zheng et al., 2023), and produces an ensemble score with feature importance ranking. This approach provides a more balanced assessment by combining multiple perspectives, rather than relying on a single method.

In tree-based models, feature importance is derived directly from the structure of the models. For example, in RF, importance is calculated

using the Gini importance, which measures the normalized reduction in the Gini criterion contributed by each feature. In this paper, this method is referred to as a tree-based method.

The permutation method calculates feature importance by evaluating the change in model performance when the values of a feature are randomly shuffled (Breiman, 2001), which can be applied to any model using tabular data. Specifically, the importance of feature j is defined as

$$i_j = s - \frac{1}{K} \sum_{k=1}^K s_{k,j}, \quad (6)$$

where i_j represents the importance of feature j , s represents the reference model score (RMSE), and $s_{k,j}$ represents the model score after shuffling feature j at k^{th} repetition. K is the total number of repetitions (30).

In addition, we employed SHAP, a model-agnostic framework for explaining predictions based on Shapley values (Lundberg et al., 2018; Lundberg and Lee, 2017). The SHAP method calculates the contribution of each feature to the output of the model (SHAP value) as follows:

$$\phi_i(f, x) = \sum_{S \subseteq \mathcal{S}_{\text{all}} \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_x(S \cup \{i\}) - f_x(S)], \quad (7)$$

where $\phi_i(f, x)$ represents the SHAP value for feature i , $f(S)$ represents the model output for a subset of features S ($S \subseteq (0, 1)^M$), and M represents the set of all M input variables. $|S|$ is the number of nonzero entries in S , and the summation iterates over all possible feature subsets. The contribution of feature i is determined by comparing the model output with and without this feature, weighted by the subset size.

The feature importance metrics obtained from the aforementioned methods are difficult to compare because of their different underlying principles. To address this, we introduced a “ranking score” metric to standardize the comparison of feature importance across the methods (Zheng et al., 2023). Feature importance values obtained from each method were sorted in ascending order, and each feature received a ranking corresponding to its position in the order-list. Specifically, the least important feature has a lowest score (1), and the second least important is 2, with higher scores given to increasingly important features. This process ensured that the ranking scores ranged from one (indicating the least important feature) to the total number of features (indicating the most important feature). By normalizing the feature importance values in this manner, the feature importance from the different methods was consistent, facilitating direct comparison.

3. Results and discussion

3.1. AutoML for efficient AnMBR modeling

We constructed the AutoML model on the same dataset (including features and targets) as Li et al. (2022) and benchmarked its performance against their results. The results showed that AutoML achieves competitive performance compared to the reported results of previous deep learning models (FCN, CNN, and DenseNet) (Table 1 and Fig. 2). The negative R^2 values observed for previously deep learning architectures may originate from overfitting, limited dataset size, lack of relevant features, and model suitability for the task (Jiang et al., 2025). By using AutoML, the R^2 value increased from negative to positive, highlighting a marked improvement in model performance. Further, we evaluated the AutoML using 10-fold cross-validation. The narrow RMSE confidence interval ($\pm 0.33\%$) validates the robustness of AutoML. Notably, tree-based models were used as base learners for the AutoML tasks. These models exhibit notable differences from neural networks, particularly in handling tabular data (Grinsztajn et al., 2022; Shwartz-Ziv and Armon, 2022). Existing evidence also suggests that tree-based algorithms often outperform deep learning methods when applied to structured tabular data and do not require extensive data preprocessing (McElfresh et al., 2023). Consequently, the adoption of

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (5)$$

trong đó y_i và $\hat{y}_i$ lần lượt là các quan sát và dự đoán của mô hình, còn n là số lượng mẫu. MAE là giá trị trung bình của độ chênh lệch tuyệt đối giữa y_i và $\hat{y}_i$. RMSE là căn bậc hai của giá trị trung bình bình phương độ chênh lệch giữa y_i và $\hat{y}_i$. Chỉ số này gán trọng số cao hơn cho các sai số lớn do bình phương sai số, so với MAE. RMSE và MAE biểu thị độ chính xác của các dự đoán của mô hình. MAPE là độ chênh lệch phần trăm trung bình giữa y_i và $\hat{y}_i$. Giá trị R^2 bằng một biểu thị mô hình khớp hoàn hảo với dữ liệu. Khi giá trị R^2 gần bằng không, điều đó cho thấy mô hình có rất ít khả năng giải thích biến mục tiêu. Khi giá trị R^2 âm, điều đó cho thấy sai số dự đoán vượt quá phương sai vốn có của tập dữ liệu. Nhìn chung, giá trị R^2 càng gần 1 càng tốt. Đáng chú ý, đơn vị của MAE và RMSE trong nghiên cứu này là phần trăm (%) (giống với đơn vị đầu ra), và đơn vị của MAPE cũng là phần trăm (%) (sai số tương đối được tính theo phương trình (4)).

Trong khi các chỉ số sai số (ví dụ: RMSE) đánh giá hiệu suất dự đoán tổng thể, chúng không trực tiếp định lượng mức độ nhất quán giữa các giá trị dự đoán và giá trị thực tế (Martin Bland and Altman, 1986). Vì vậy, để đánh giá mức độ tương hợp giữa hiệu suất loại bỏ COD dự đoán và giá trị thực tế, phân tích Bland-Altman đã được thực hiện (Martin Bland and Altman, 1986). Phương pháp Bland-Altman phân tích hiệu số giữa hai phương pháp theo giá trị trung bình của chúng. Trong nghiên cứu này, hiệu số được tính bằng cách lấy giá trị thực tế trừ đi giá trị dự đoán. Hiệu số khác không cho thấy mô hình thường đánh giá quá cao (hiệu số <0) hoặc đánh giá thấp (hiệu số >0) giá trị đo. Nếu các giới hạn đồng thuận không vượt quá khoảng giá trị được chấp nhận về mặt chuyên môn và 95% hiệu số nằm trong giới hạn đồng thuận 95%, thì tính nhất quán của hai phương pháp được xem là tốt (Li et al., 2022). Giới hạn đồng thuận 95% được xác định bằng cách cộng và trừ 1,96 độ lệch chuẩn vào giá trị hiệu số trung bình.

2.4. Ablation studies

Chúng tôi đã tiến hành các nghiên cứu loại bỏ thành phần để đánh giá mức độ đóng góp của các đặc trưng khác nhau đối với hiệu suất của các mô hình ML. Nghiên cứu loại bỏ thành phần là một kỹ thuật dùng để đánh giá tác động của các thành phần cụ thể (ví dụ: đặc trưng, tham số hoặc dữ liệu) bằng cách loại bỏ hoặc điều chỉnh chúng, sau đó quan sát những thay đổi về hiệu suất của mô hình. Cụ thể, chúng tôi đánh giá tác động của OD, ORP, HRT, MLSS và MLVSS đối với hiệu suất mô hình. Bằng cách so sánh hiệu suất của các mô hình có và không có những đặc trưng cụ thể, chúng tôi có thể suy luận cách các đặc trưng này ảnh hưởng đến quá trình mô hình hóa. Ngoài ra, do đã thu thập được nhiều dữ liệu hơn so với nghiên cứu trước, chúng tôi khảo sát ảnh hưởng của tập dữ liệu mở rộng này đến hiệu suất mô hình hóa. Trong suốt các nghiên cứu loại bỏ thành phần, dữ liệu huấn luyện và kiểm thử cũng như các tham số huấn luyện mô hình được duy trì nhất quán với thiết lập trước đó.

2.5. Feature ranking score

Chúng tôi đã phát triển một khung tổng hợp sử dụng điểm xếp hạng được thiết kế riêng cho các tác vụ AutoML. Khung này kết hợp mức độ quan trọng của đặc trưng dựa trên cây, mức độ quan trọng của đặc trưng theo phương pháp hoán vị và các giá trị giải thích cộng tính Shapley (SHAP) (Schreck et al., 2023; Yu et al., 2025; Zheng et al., 2023), đồng thời tạo ra điểm tổng hợp kèm xếp hạng mức độ quan trọng của đặc trưng. Cách tiếp cận này đưa ra đánh giá cân bằng hơn bằng cách kết hợp nhiều góc nhìn, thay vì chỉ dựa vào một phương pháp duy nhất.

Trong các mô hình dựa trên cây, độ quan trọng của đặc trưng được suy ra trực tiếp từ cấu trúc của mô hình. Ví dụ, trong RF, độ quan trọng được tính toán

sử dụng độ quan trọng Gini, đo lường mức giảm chuẩn hóa của tiêu chí Gini do mỗi đặc trưng đóng góp. Trong bài báo này, phương pháp này được gọi là phương pháp dựa trên cây.

Phương pháp hoán vị tính toán mức độ quan trọng của đặc trưng bằng cách đánh giá sự thay đổi trong hiệu suất mô hình khi các giá trị của một đặc trưng được xáo trộn ngẫu nhiên (Breiman, 2001). Phương pháp này có thể áp dụng cho mọi mô hình sử dụng dữ liệu dạng bảng. Cụ thể, mức độ quan trọng của đặc trưng j được định nghĩa là

$$i_j = s - \frac{1}{K} \sum_{k=1}^K s_{k,j}, \quad (6)$$

trong đó i_j biểu thị mức độ quan trọng của đặc trưng j , s biểu thị điểm số tham chiếu của mô hình (RMSE), và $s_{k,j}$ biểu thị điểm số của mô hình sau khi xáo trộn đặc trưng j ở lần lặp thứ k^{th} . K là tổng số lần lặp (30).

Ngoài ra, chúng tôi sử dụng SHAP, một khuôn khổ độc lập với mô hình để giải thích các dự đoán dựa trên giá trị Shapley (Lundberg và cộng sự, 2018; Lundberg và Lee, 2017). Phương pháp SHAP tính toán mức đóng góp của từng đặc trưng vào đầu ra của mô hình (giá trị SHAP) như sau:

$$\phi_i(f, x) = \sum_{S \subseteq \mathcal{S}_{\text{all}} \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_x(S \cup \{i\}) - f_x(S)], \quad (7)$$

trong đó $\phi_i(f, x)$ biểu thị giá trị SHAP của đặc trưng i , $f(S)$ biểu thị đầu ra của mô hình đối với một tập hợp con các đặc trưng S ($S \subseteq (0, 1)^M$), và M biểu thị tập hợp gồm tất cả M biến đầu vào. $|S|$ là số lượng phần tử khác 0 trong S , và phép tính tổng lặp qua tất cả các tập hợp con đặc trưng có thể. Mức đóng góp của đặc trưng i được xác định bằng cách so sánh đầu ra của mô hình khi có và khi không có đặc trưng này, có tính đến trọng số theo kích thước tập hợp con.

Các thước đo mức độ quan trọng của đặc trưng thu được từ các phương pháp nêu trên khó so sánh do các nguyên lý nền tảng khác nhau. Để giải quyết vấn đề này, chúng tôi đưa ra thước đo “điểm xếp hạng” nhằm chuẩn hóa việc so sánh mức độ quan trọng của đặc trưng giữa các phương pháp (Zheng et al., 2023). Các giá trị mức độ quan trọng của đặc trưng thu được từ từng phương pháp được sắp xếp theo thứ tự tăng dần, và mỗi đặc trưng được gán một thứ hạng tương ứng với vị trí trong danh sách. Cụ thể, đặc trưng kém quan trọng nhất có điểm thấp nhất (1), đặc trưng kém quan trọng thứ hai có điểm 2, và các đặc trưng ngày càng quan trọng hơn được gán điểm cao hơn. Quy trình này đảm bảo điểm xếp hạng nằm trong khoảng từ một (biểu thị đặc trưng kém quan trọng nhất) đến tổng số đặc trưng (biểu thị đặc trưng quan trọng nhất). Bằng cách chuẩn hóa các giá trị mức độ quan trọng của đặc trưng theo cách này, mức độ quan trọng của đặc trưng từ các phương pháp khác nhau trở nên nhất quán, tạo điều kiện thuận lợi cho việc so sánh trực tiếp.

3. Kết quả và thảo luận

3.1. AutoML for efficient AnMBR modeling

Chúng tôi xây dựng mô hình AutoML trên cùng bộ dữ liệu (bao gồm các đặc trưng và mục tiêu) như Li et al. (2022) và đối chiếu hiệu suất của mô hình với kết quả của họ. Kết quả cho thấy AutoML đạt hiệu suất cạnh tranh so với các kết quả đã công bố của những mô hình học sâu trước đây (FCN, CNN và DenseNet) (Bảng 1 và Hình 2). Các giá trị R^2 âm quan sát được ở những kiến trúc học sâu trước đây có thể bắt nguồn từ hiện tượng quá khớp, kích thước bộ dữ liệu hạn chế, thiếu các đặc trưng phù hợp và mức độ phù hợp của mô hình với tác vụ (Jiang et al., 2025). Khi sử dụng AutoML, giá trị R^2 tăng từ âm lên dương, cho thấy hiệu suất mô hình được cải thiện đáng kể. Ngoài ra, chúng tôi đánh giá AutoML bằng kiểm định chéo 10 phần. Khoảng tin cậy RMSE hẹp ($\pm 0.33\%$) xác nhận tính vững chắc của AutoML. Đáng chú ý, các mô hình dựa trên cây được sử dụng làm mô hình học cơ sở cho các tác vụ AutoML. Những mô hình này khác biệt đáng kể so với mạng nơ-ron, đặc biệt là trong cách xử lý dữ liệu dạng bảng (Grinsztajn et al., 2022; Shwartz-Ziv and Armon, 2022). Các bằng chứng hiện có cũng cho thấy các thuật toán dựa trên cây thường vượt trội hơn các phương pháp học sâu khi áp dụng cho dữ liệu dạng bảng có cấu trúc và không đòi hỏi tiền xử lý dữ liệu chuyên sâu (McElfresh et al., 2023). Do đó, việc áp dụng

Table 1
Model performance and comparison.

	RMSE (%) ^a	MAE (%) ^a	MAPE (%) ^b	R ²	Evaluation Methods
AutoML	2.47 [2.14, 2.81]	1.90 [1.68, 2.11]	2.19 [1.93, 2.46]	0.44 [0.22, 0.65]	10-fold CV ^c
AutoML	3.09	2.76	3.11	0.47	Li et al. (2022) ^d
FCN	6.29	5.71	6.49	−1.19	Li et al. (2022) ^d
CNN	5.98	5.34	6.02	−0.97	Li et al. (2022) ^d
Dense	4.69	4.34	4.93	−0.21	Li et al. (2022) ^d

^a The unit is equal to COD-re (%).
^b The unit is percentage according to equation (4).
^c The error metrics are reported as the mean and 95% confidence intervals of the error metrics from 10-fold cross validation (CV) using Student's t-based distribution.
^d The model was evaluated by splitting the data using the method from Li et al. (2022).

tree-based AutoML not only enhances the model accuracy but also improves the efficiency of the AnMBR modeling workflow.

Furthermore, Bland-Altman analysis was employed to evaluate the consistency between predictions and observations (the ground truth), providing insights into the predictive accuracy and stability of the models. It shows the average difference (bias) and calculates the limits of agreement, which capture the expected range for most differences. A wider limit of agreement boundary indicates poorer consistency between the model and the observations. The AutoML results were distributed in a lower limit of agreement range than those of the deep learning models, with a more uniform error distribution (Fig. 3). This suggests that the AutoML approach yields more consistent and stable predictions. In our analysis, the majority of data points were within the 95% confidence interval, demonstrating a strong agreement between the observed values and model predictions.

For the deep learning models, a trend was observed in which the difference between the predicted and observed values decreased as the mean value increased. By contrast, the AutoML results displayed no discernible pattern, with differences evenly distributed across the range of mean values, highlighting the stability and robustness of AutoML. It is

noteworthy that all the analysis results show a positive mean difference (Fig. 3). This indicates a systematic tendency to underestimate the COD removal rate using these models. This underestimation may be attributed to the imbalanced data distribution between the training and testing sets. Additionally, data-driven models tend to smooth out the noise introduced by measurement uncertainty and the dynamic nature of the biological process. Despite this, the AutoML achieved an RMSE of 3.09(%), which is lower than the standard deviation of the experimental COD removal efficiency reported in long-term AnMBR operations (Robles et al., 2022; Uman et al., 2021). This result indicates that the model's overall accuracy is sufficient to describe the AnMBR dynamics. However, as we discussed, overfitting, limited dataset size, model suitability for the task, and testing methods affect the performance, thus the comparison results are indicative rather than definitive.

3.2. Improved ML performance with operation time as a feature

The treatment efficiency of the AnMBR is not only affected by T-R, T-in, T-env, pH-in, COD-in, and flux but also by the reactor operation conditions. For instance, the microbial community structure and activity in an AnMBR are key factors that affect its efficiency (Hu et al., 2017; Xie et al., 2014). However, measuring microbial community structure is a difficult task because it is time-consuming and costly, which restricts the availability of community structure data. Consequently, this limitation may also hinder data-driven AnMBR modeling from effectively uncovering the underlying mechanisms.

Based on the hypothesis that additional information may correlate with operation time, we incorporated reactor OD into the modeling process, assuming that OD may be a potential proxy for the microbial dynamics. The inclusion of OD resulted in a substantial improvement in model performance compared to the baseline feature set (T-R, T-in, T-env, pH-in, COD-in, and flux) (Fig. 4 and Fig. S1), with the mean of R² value increasing from 0.44 to 0.55 and mean of RMSE decreasing from 2.47 to 2.20 (Fig. 4). Spearman correlation analysis indicates a weak association between OD and the target variable, suggesting a low likelihood of data leakage (see supplementary material). Thus, such enhancement suggests that the additional information carried by OD may have been effectively learned by the ML model. It is important to note that rather than being a direct causal parameter, OD acts as a surrogate variable capturing unmeasured temporal dynamics inherent to the AnMBRs process. This includes the gradual acclimatization of the microbial community (e.g., biofilm development) and the cumulative




Fig. 2. Model prediction results and comparison with actual measured values.

Bảng 1
Hiệu suất và so sánh mô hình.


	RMSE (%) ^a	MAE (%) ^a	MAPE (%) ^b	R ²	Evaluation Methods
AutoML	2.47 [2.14, 2.81]	1.90 [1.68, 2.11]	2.19 [1.93, 2.46]	0.44 [0.22, 0.65]	10-fold CV ^c
AutoML	3.09	2.76	3.11	0.47	Li et al. (2022) ^d
FCN	6.29	5.71	6.49	−1.19	Li et al. (2022) ^d
CNN	5.98	5.34	6.02	−0.97	Li et al. (2022) ^d
Dense	4.69	4.34	4.93	−0.21	Li et al. (2022) ^d

^a Đơn vị bằng COD-re (%). ^b Đơn vị là phần trăm theo phương trình (4). ^c Các chỉ số sai số được báo cáo dưới dạng giá trị trung bình và khoảng tin cậy 95% của các chỉ số sai số từ kiểm định chéo (CV) 10 lần, sử dụng phân phối dựa trên t của Student. ^d Mô hình được đánh giá bằng cách chia dữ liệu theo phương pháp của Li và cộng sự (2022).

AutoML dựa trên cây không chỉ cải thiện độ chính xác của mô hình mà còn nâng cao hiệu quả của quy trình mô hình hóa AnMBR.

Hơn nữa, phân tích Bland-Altman được sử dụng để đánh giá mức độ nhất quán giữa các dự đoán và quan sát (giá trị thực), qua đó cung cấp thông tin về độ chính xác dự đoán và tính ổn định của các mô hình. Phân tích này cho thấy chênh lệch trung bình (độ chệch) và ự kiến của phần lớn các điểm dữ liệu. Giới hạn đồng thuận càng rộng thì mức độ nhất quán giữa mô hình và các giá trị quan sát càng thấp. Kết quả AutoML có khoảng giới hạn đồng thuận thấp hơn so với các mô hình học sâu, đồng thời phân bố sai số đồng đều hơn (Hình 3). Điều này cho thấy phương pháp AutoML tạo ra các dự đoán nhất quán và ổn định hơn. Trong phân tích của chúng tôi, phần lớn các điểm dữ liệu nằm trong khoảng tin cậy 95%, cho thấy mức độ phù hợp cao giữa các giá trị quan sát và dự đoán của mô hình.

Đối với các mô hình học sâu, người ta nhận thấy xu hướng chênh lệch giữa giá trị dự đoán và giá trị quan sát giảm khi giá trị trung bình tăng. Ngược lại, kết quả AutoML không cho thấy quy luật rõ rệt nào; mức chênh lệch phân bố đồng đều trên toàn bộ dải giá trị trung bình, qua đó làm nổi bật tính ổn định và độ bền vững của AutoML. Điều đó là



Hình 2. Kết quả dự đoán của mô hình và so sánh với các giá trị đo thực tế.

Đáng chú ý là tất cả các kết quả phân tích đều cho thấy mức chênh lệch trung bình dương (Hình 3). Điều này cho thấy các mô hình này có xu hướng đánh giá thấp một cách có hệ thống tỷ lệ loại bỏ COD. Sự đánh giá thấp này có thể là do phân bố dữ liệu giữa tập huấn luyện và tập kiểm tra không cân bằng. Ngoài ra, các mô hình dựa trên dữ liệu thường có xu hướng làm mượt nhiều phát sinh từ độ không chắc chắn của phép đo và tính chất động của quá trình sinh học. Mặc dù vậy, AutoML đạt RMSE là 3,09(%), thấp hơn độ lệch chuẩn của hiệu suất loại bỏ COD thực nghiệm được báo cáo trong các hoạt động AnMBR dài hạn (Robles và cộng sự, 2022; Uman và cộng sự, 2021). Kết quả này cho thấy độ chính xác tổng thể của mô hình đủ để mô tả động lực học của AnMBR. Tuy nhiên, như đã thảo luận, hiện tượng quá khớp, quy mô tập dữ liệu hạn chế, mức độ phù hợp của mô hình với nhiệm vụ và các phương pháp kiểm tra đều ảnh hưởng đến hiệu suất; do đó, kết quả so sánh chỉ mang tính tham khảo chứ không mang tính kết luận.

3.2. Improved ML performance with operation time as a feature

Hiệu quả xử lý của AnMBR không chỉ chịu ảnh hưởng của T-R, T-in, T-env, pH-in, COD-in và thông lượng mà còn phụ thuộc vào các điều kiện vận hành của thiết bị phản ứng. Chẳng hạn, cấu trúc và hoạt tính của quần xã vi sinh vật trong AnMBR là những yếu tố then chốt ảnh hưởng đến hiệu quả xử lý (Hu et al., 2017; Xie et al., 2014). Tuy nhiên, việc đo lường cấu trúc quần xã vi sinh vật là một nhiệm vụ khó khăn vì tốn nhiều thời gian và chi phí, hạn chế khả năng thu thập dữ liệu về cấu trúc quần xã. Do đó, hạn chế này cũng có thể cản trở các mô hình AnMBR dựa trên dữ liệu trong việc khám phá hiệu quả của các cơ chế nền tảng.

Dựa trên giả thuyết rằng thông tin bổ sung có thể tương quan với thời gian vận hành, chúng tôi đã đưa OD của thiết bị phản ứng vào quy trình mô hình hóa, với giả định rằng OD có thể là đại diện tiềm năng cho động lực học của vi sinh vật. Việc đưa OD vào đã cải thiện đáng kể hiệu suất mô hình so với tập đặc trưng cơ sở (T-R, T-in, T-env, pH-in, COD-in và thông lượng) (Hình 4 và Hình S1), trong đó giá trị trung bình của R² tăng từ 0,44 lên 0,55 và RMSE trung bình giảm từ 2,47 xuống 2,20 (Hình 4). Phân tích tương quan Spearman cho thấy mối liên hệ yếu giữa OD và biến mục tiêu, gợi ý khả năng rò rỉ dữ liệu thấp (xem tài liệu bổ sung). Do đó, sự cải thiện này cho thấy mô hình ML có thể đã học hiệu quả thông tin bổ sung do OD mang lại. Cần lưu ý rằng OD không phải là một tham số nhân quả trực tiếp, mà đóng vai trò là biến đại diện ghi nhận các động lực theo thời gian chưa được đo lường vốn có trong quy trình AnMBR. Điều này bao gồm sự thích nghi dần dần của quần xã vi sinh vật (ví dụ: sự phát triển màng sinh học) và quá trình tích lũy...




Fig. 3. Bland-Altman analysis of (a) AutoML, (b) FCN, (c) CNN, and (d) Dense. The difference of COD-re is calculated by ground truth substrates prediction. The values of the central line are the mean difference of COD-re. The three horizontal lines in each plot, from top to bottom, represent the upper limit of agreement (mean difference + $1.96 \times$ standard deviation), the mean difference, and the lower limit of agreement (mean difference - $1.96 \times$ standard deviation). The results were obtained using the same dataset from Li et al. (2022).




Fig. 4. Model performance with different input features. Baseline indicates using T-R, T-in, T-env, pH-in, COD-in, and flux as features. Error bar is the 95% confidence intervals of the error metrics from 10-fold cross validation.


changes in membrane surface properties over time. By incorporating this temporal dimension, the model effectively learns such non-stationary behaviors of the reactor during long-term operation. Furthermore, the inclusion of the OD may pose a challenge for extrapolation. Despite the good performance observed in this study, tree-based models often struggle to make reliable predictions beyond the training data range.

The inclusion of ORP, HRT, MLSS, and MLVSS data did not markedly contribute to the model performance. When OD, ORP, HRT, MLSS, and MLVSS were used simultaneously to train the model, the overall effect was similar to that of the inclusion of OD alone. The Bland-Altman analysis showed that incorporating OD into the model reduced the differences between the prediction and ground truth, rendering the difference more evenly distributed around zero compared to models without operation time (Fig. 5 and Fig. S2). This further confirms that including the operation time improves the modeling performance,


whereas adding other input parameters yields only a limited improvement. The limited contribution of typically parameters (e.g., ORP, HRT, MLSS, and MLVSS) likely reflects the specific constraints of the data to this study, such as measurement frequency and signal-to-noise ratio, rather than a lack of physical and biological relevance. Additionally, feature collinearity may have masked their importance, as the model could derive sufficient information from other correlated predictors. These results highlight the importance of feature selection for modeling.

3.3. Impact of data volume on predictive performance

ML-based modeling is a data-driven approach whose performance primarily depends on the quality and quantity of data (Fan and Shi, 2022; Liu et al., 2023). However, when applied to experimental datasets, ML has inherent challenges in terms of data availability and reliability.



Hình 3. Phân tích Bland-Altman của (a) AutoML, (b) FCN, (c) CNN và (d) Dense. Chênh lệch COD-re được tính bằng dự đoán các chất nền theo giá trị thực. Giá trị của đường trung tâm là chênh lệch trung bình của COD-re. Ba đường ngang trong mỗi biểu đồ, từ trên xuống dưới, lần lượt biểu thị giới hạn thỏa thuận trên (chênh lệch trung bình + $1.96 \times$ độ lệch chuẩn), chênh lệch trung bình và giới hạn thỏa thuận dưới (chênh lệch trung bình - $1.96 \times$ độ lệch chuẩn). Các kết quả được thu được bằng cách sử dụng cùng bộ dữ liệu của Li và cộng sự (2022).



Hình 4. Hiệu suất mô hình với các đặc trưng đầu vào khác nhau. Đường cơ sở cho biết việc sử dụng T-R, T-in, T-env, pH-in, COD-in và thông lượng làm đặc trưng. Thanh lỗi thể hiện khoảng của các chỉ số sai số từ kiểm định chéo 10 lần.

những thay đổi về đặc tính bề mặt màng theo thời gian. Bằng cách tích hợp chiều thời gian này, mô hình có thể học hiệu quả các hành vi không dừng của thiết bị phản ứng trong quá trình vận hành dài hạn. Hơn nữa, việc đưa OD vào có thể gây khó khăn cho việc ngoại suy. Mặc dù nghiên cứu này ghi nhận hiệu suất tốt, các mô hình dựa trên cây thường gặp khó khăn trong việc đưa ra dự đoán đáng tin cậy vượt ra ngoài phạm vi dữ liệu huấn luyện.

Việc bổ sung dữ liệu ORP, HRT, MLSS và MLVSS không cải thiện đáng kể hiệu suất mô hình. Khi sử dụng đồng thời OD, ORP, HRT, MLSS và MLVSS để huấn luyện mô hình, hiệu quả tổng thể tương tự như khi chỉ bổ sung OD. Phân tích Bland-Altman cho thấy việc đưa OD vào mô hình làm giảm chênh lệch giữa giá trị dự đoán và giá trị thực, khiến chênh lệch phân bố đồng đều hơn quanh mức 0 so với các mô hình không có thời gian vận hành (Hình 5 và Hình S2). Điều này càng khẳng định rằng việc đưa thời gian vận hành vào giúp cải thiện hiệu suất mô hình,

trong khi việc bổ sung các tham số đầu vào khác chỉ giúp cải thiện ở mức hạn chế. Đóng góp hạn chế của các tham số thường dùng (ví dụ: ORP, HRT, MLSS và MLVSS) có thể phản ánh những hạn chế cụ thể của dữ liệu trong nghiên cứu này, chẳng hạn như tần suất đo và tỷ lệ tín hiệu trên nhiễu, thay vì cho thấy chúng thiếu ý nghĩa về mặt vật lý và sinh học. Ngoài ra, hiện tượng đa cộng tuyến giữa các đặc trưng có thể đã che khuất tầm quan trọng của chúng, vì mô hình có thể thu được đủ thông tin từ các biến dự báo khác có tương quan. Những kết quả này nhấn mạnh tầm quan trọng của việc lựa chọn đặc trưng trong mô hình hóa.

3.3. Impact of data volume on predictive performance

Mô hình hóa dựa trên học máy (ML) là một phương pháp dựa trên dữ liệu, trong đó hiệu năng chủ yếu phụ thuộc vào chất lượng và số lượng dữ liệu (Fan and Shi, 2022; Liu et al., 2023). Tuy nhiên, khi áp dụng cho các bộ dữ liệu thực nghiệm, ML gặp phải những thách thức cố hữu về tính sẵn có và độ tin cậy của dữ liệu.




Fig. 5. Bland-Altman analysis of AutoML models. (a) Baseline, (b) add OD, (c) add OD, ORP, HRT, MLSS, and MLVSS, and (d) add all without OD in the feature. The difference of COD-re is calculated by ground truth minus prediction. The values of the central line are the mean difference of COD-re. The three horizontal lines in each plot, from top to bottom, represent the upper limit of agreement (mean difference + $1.96 \times$ standard deviation), the mean difference, and the lower limit of agreement (mean difference - $1.96 \times$ standard deviation).

Laboratory experiments often yield small sample sizes because of constraints such as time, cost, and space availability. Moreover, the experimental data are susceptible to various sources of error, including human and instrumental errors. These limitations increase the difficulty of applying ML-based modeling approaches effectively. Furthermore, the ability of a small, high-quality dataset to yield better inferences than a larger, low-quality one is often debatable (Faraway and Augustin, 2018; Kokol et al., 2022). To explore this, we examined the impact of increasing the amount of experimental data on AnMBR modeling. We incorporated additional data and compared the results using the same testing sets to ensure uniform evaluation. The additional data originated from the same AnMBR reactors, but with a different operational time range. We utilized the original dataset (M1, 50–414 d) and the extended dataset (M2, 7–546 d) to establish three validation schemes based on

10-fold cross-validation (Fig. 6). First, M1T1 represents the baseline performance using standard cross-validation on M1, in which T1 indicates the testing data were split from M1. Second, for M2T1, the additional data was integrated into the training folds only, allowing the model to learn from a broader range (M2) while being tested on the T1. Finally, M2T2 involves standard cross-validation on the full M2 dataset, in which T2 was split from M2.

A comparison between the M1T1 and M2T1 groups indicated that adding more data decreased the R^2 value and increased RMSE, MAE and MAPE (Fig. 6). A comparison between M1T1 and M2T2 also showed that adding more data increased the prediction error, with M2T2 showing worse modeling performance (Fig. 6). These findings suggest that the addition of more data is not necessarily beneficial for modeling. A likely explanation is that data collected under varying experimental conditions





Fig. 6. Impact of dataset size on model performance. M1: original dataset with 50–414 operation days. M2: extended dataset with 7–546 operation days. M1T1: the baseline performance using standard cross-validation on M1. M2T1: the additional data was integrated into the training folds only. M2T2: standard cross-validation on the full M2 dataset.




Hình 5. Phân tích Bland-Altman của các mô hình AutoML. (a) Cơ sở, (b) bổ sung OD, (c) bổ sung OD, ORP, HRT, MLSS và MLVSS, và (d) bổ sung tất cả các biến ngoại trừ OD vào đặc trưng. Chênh lệch COD-re được tính bằng giá trị thực trừ đi giá trị dự đoán. Giá trị của đường trung tâm là chênh lệch trung bình của COD-re. Ba đường ngang trong mỗi biểu đồ, từ trên xuống dưới, lần lượt biểu thị giới hạn thỏa thuận trên (chênh lệch trung bình + $1.96 \times$ độ lệch chuẩn), chênh lệch trung bình và giới hạn thỏa thuận dưới (chênh lệch trung bình - $1.96 \times$ độ lệch chuẩn).

Các thí nghiệm trong phòng thí nghiệm thường có cỡ mẫu nhỏ do những hạn chế như thời gian, chi phí và không gian sẵn có. Hơn nữa, dữ liệu thực nghiệm dễ chịu ảnh hưởng từ nhiều nguồn sai số khác nhau, bao gồm sai số do con người và thiết bị. Những hạn chế này khiến việc áp dụng hiệu quả các phương pháp mô hình hóa dựa trên ML trở nên khó khăn hơn. Ngoài ra, khả năng một bộ dữ liệu nhỏ hơn nhưng có chất lượng cao đưa ra suy luận tốt hơn một bộ dữ liệu lớn hơn nhưng chất lượng thấp thường là vấn đề gây tranh luận (Faraway và Augustin, 2018; Kokol và cộng sự, 2022). Để tìm hiểu vấn đề này, chúng tôi đã khảo sát tác động của việc tăng lượng dữ liệu thực nghiệm đối với quá trình mô hình hóa AnMBR. Chúng tôi bổ sung dữ liệu và so sánh kết quả bằng cùng một tập kiểm thử để đảm bảo đánh giá nhất quán. Dữ liệu bổ sung được thu thập từ cùng các thiết bị phản ứng AnMBR, nhưng trong một khoảng thời gian vận hành khác. Chúng tôi sử dụng bộ dữ liệu ban đầu (M1, 50–414 ngày) và bộ dữ liệu mở rộng (M2, 7–546 ngày) để xây dựng ba phương án kiểm định dựa trên

kiểm định chéo 10 lần (Hình 6). Đầu tiên, M1T1 biểu thị hiệu năng cơ sở khi sử dụng kiểm định chéo tiêu chuẩn trên M1, trong đó T1 chỉ o biết dữ liệu kiểm tra được tách từ M1. Thứ hai, với M2T1, dữ liệu bổ sung chỉ được đưa vào các phần huấn luyện, cho phép mô hình học từ phạm vi dữ liệu rộng hơn (M2) trong khi được kiểm tra trên T1. Cuối cùng, M2T2 áp dụng kiểm định chéo tiêu chuẩn trên toàn bộ tập dữ liệu M2, trong đó T2 được tách từ M2.

So sánh giữa các nhóm M1T1 và M2T1 cho thấy việc bổ sung thêm dữ liệu làm giảm giá trị R^2 và tăng RMSE, MAE và MAPE (Hình 6). So sánh giữa M1T1 và M2T2 cũng cho thấy việc bổ sung thêm dữ liệu làm tăng sai số dự đoán, trong đó M2T2 có hiệu suất mô hình hóa kém hơn (Hình 6). Những phát hiện này cho thấy việc bổ sung thêm dữ liệu không nhất thiết có lợi cho quá trình mô hình hóa. Một cách giải thích hợp lý là dữ liệu được thu thập trong các điều kiện thí nghiệm khác nhau



Hình 6. Ảnh hưởng của kích thước tập dữ liệu đến hiệu suất mô hình. M1: tập dữ liệu ban đầu với 50–414 ngày vận hành. M2: tập dữ liệu mở rộng với 7–546 ngày vận hành. M1T1: hiệu suất cơ sở khi sử dụng kiểm định chéo tiêu chuẩn trên M1. M2T1: dữ liệu bổ sung chỉ được tích hợp vào các phần huấn luyện. M2T2: kiểm định chéo tiêu chuẩn trên toàn bộ tập dữ liệu M2.

introduce variability, biases, and specific errors, which collectively degrade the model performance. Spearman's correlation analysis of M1 and M2 further revealed that the features in M2 were less correlated with COD removal than those in M1 (Figure S3 and Figure S4). In other words, the relevance of data is important for modeling. The irrelevance of data may stem from distribution shift in influent/AnMBR states or unmeasured disturbances, which can introduce noise that outweighs the benefits of a larger sample size. Therefore, the degrading performance with larger datasets should be interpreted as a signal of including the irrelevant data. This result highlights the need for data curation that prioritize high-quality and context-specific data rather than broad but indiscriminate data aggregation.

These results highlight the importance of carefully considering the data sources, quality, and applicability when applying ML to small experimental datasets. Increasing the volume of data without accounting for heterogeneity or relevance to the modeling can lead to diminished model accuracy and robustness. Future studies should focus on methods to effectively integrate multi-source data while mitigating potential biases, ensuring the reliability and precision of ML models for experimental applications.

3.4. Ensemble feature-based importance analysis

Using the ranking score approach (Section 2.4) to evaluate feature importance, the results of the three methods indicated that COD-in was the most important feature of all models (Fig. 7). For the model without




Fig. 7. Ranking score of models. (a) model trained with original data, (c) model trained with original data and additional data, (e) same as (a) with OD added in the feature, and (g) same as (c) with OD in the feature. (b), (d), (f), and (h) are the components of the ranking score of (a), (c), (e), and (g), respectively.

OD and trained without additional data, T-env appeared to be the second most important feature (Fig. 7 (a)), whereas for the model without OD but trained with additional data, pH-in became the second most important feature (Fig. 7 (e)). When the OD was included, it became the second most important feature, highlighting its important role in the modeling process (Fig. 7(c–g)). Overall, the COD-in is reasonable for the most important feature for predicting the COD removal of AnMBR as it can be served as an important indicator of reactor loading. In contrast, other features, such as ambient temperature, influent temperature, and pH, exhibited lower importance in the model, suggesting that these environmental parameters have a limited impact on the AnMBR performance.

According to Fig. 7(b–d, f, h), significant differences exist in the feature importance rankings among the interpretation methods. For instance, the results of the model trained with additional data showed notable discrepancies for T-env, flux, and pH-in across the different interpretation methods. Because determining the optimal interpretation method is difficult, we recommend employing a ranking score that integrates the results of multiple methods to ensure robustness. In addition, we examined the changes in feature importance when additional data were included. The results indicated substantial shifts in feature importance rankings, deviating significantly from the results of model trained with additional data. The interpretation results of the model trained with the additional data (Fig. 7 (h)) were not identical to those of the original model (Fig. 7 (f)). The methods selected for interpretation were based on the structure and prediction of the models. Thus, the deviations between them can be attributed to the incorporation of additional data that may introduce noise into the model, potentially reducing the predictive performance. This result supports the findings in Section 3.3 indicating that the additional data used in this study did not contribute to developing a robust AnMBR ML model.

The variability of feature importance reflects the uncertainty associated with different mathematical methods for calculating the feature importance. However, despite these fluctuations, the top-tier features (COD-in and/or OD) consistently ranked highest across methods and models. This consistently suggests that while the lower-ranked variables carry uncertainty, the identification of the primary features is robust. The dominance of COD-in highlights the sensitivity to COD loadings, suggesting that COD-in can be a warning signal for COD-re prediction. For instance, when a high COD load is detected, the system can automatically reduce the inflow rate to give the biological process more time to treat the water. The importance of OD underscores the non-stationary nature of the AnMBR process (e.g., membrane fouling and biomass maturation). This implies that process monitoring should not rely solely on instantaneous sensor readings but must also incorporate time-dependent maintenance schedules.

3.5. Limitations and future perspectives


While this study indicates AutoML as a potential tool for AnMBR modeling with limited data, several limitations warrant attention. First, although AutoML outperformed previous models under the identical fixed data split strategy, these results should be interpreted as indicative within this specific experimental setup rather than definitively superior across all models and scenarios. Second, the observation that certain features (e.g., MLSS and MLVSS) contributed less to the model should not be interpreted as the physical or biological aspect, but reflects modeling results. Thus, these findings represent statistical feature importance, not mechanistic causality. Third, the performance failed to improve with a larger dataset does not imply data volume being useless. Instead, it underscores the critical importance of data consistency and quality over mere quantity, highlighting the impact of distribution shifts in dynamic processes of AnMBR treating wastewater. Finally, this study provides deterministic point estimates. To further enhance operational decision-making, future works could integrate probabilistic approaches. Such approaches can provide prediction intervals and quantify

đưa vào biến thiên, thiên lệch và các sai số cụ thể, tổng hợp lại làm suy giảm hiệu suất của mô hình. Phân tích tương quan Spearman giữa M1 và M2 cho thấy thêm rằng các đặc trưng trong M2 ít tương quan với mức loại bỏ COD hơn so với các đặc trưng trong M1 (Hình S3 và Hình S4). Nói cách khác, mức độ liên quan của dữ liệu rất quan trọng đối với việc mô hình hóa. Dữ liệu không liên quan có thể bắt nguồn từ sự thay đổi phân phối trong trạng thái nước đầu vào/AnMBR hoặc từ các nhiễu chưa được đo lường, vốn có thể tạo ra nhiễu ẩn lợi ích của việc tăng kích thước mẫu. Do đó, hiệu suất suy giảm khi tập dữ liệu lớn hơn nên được hiểu là dấu hiệu cho thấy dữ liệu không liên quan đã được đưa vào. Kết quả này nhấn mạnh nhu cầu tuyển chọn dữ liệu, ưu tiên dữ liệu chất lượng cao và phù hợp với bối cảnh cụ thể thay vì thu thập dữ liệu rộng khắp nhưng thiếu chọn lọc.

Những kết quả này nhấn mạnh tầm quan trọng của việc cân nhắc kỹ lưỡng các nguồn dữ liệu, chất lượng và tính phù hợp khi áp dụng ML vào các tập dữ liệu thực nghiệm nhỏ. Việc tăng khối lượng dữ liệu mà không tính đến tính không đồng nhất hoặc mức độ liên quan với mô hình hóa có thể làm giảm độ chính xác và độ vững chắc của mô hình. Các nghiên cứu trong tương lai nên tập trung vào những phương pháp tích hợp hiệu quả dữ liệu từ nhiều nguồn, đồng thời giảm thiểu các sai lệch tiềm ẩn, nhằm đảm bảo độ tin cậy và độ chính xác của các mô hình ML trong ứng dụng thực nghiệm.

3.4. Ensemble feature-based importance analysis

Sử dụng phương pháp điểm xếp hạng (Mục 2.4) để đánh giá mức độ quan trọng của đặc trưng, kết quả của ba phương pháp cho thấy COD-in là đặc trưng quan trọng nhất trong tất cả các mô hình (Hình 7). Đối với mô hình không có



Hình 7. Điểm xếp hạng của các mô hình. (a) mô hình được huấn luyện bằng dữ liệu gốc, (c) mô hình được huấn luyện bằng dữ liệu gốc và dữ liệu bổ sung, (e) tương tự như (a) nhưng có thêm OD trong đặc trưng, và (g) tương tự như (c) nhưng có OD trong đặc trưng. (b), (d), (f) và (h) lần lượt là các thành phần của điểm xếp hạng trong (a), (c), (e) và (g).

Với OD và không được huấn luyện bằng dữ liệu bổ sung, T-env dường như là đặc trưng quan trọng thứ hai (Hình 7 (a)); trong khi đó, đối với mô hình không có OD nhưng được huấn luyện bằng dữ liệu bổ sung, pH-in trở thành đặc trưng quan trọng thứ hai (Hình 7 (e)). Khi OD được đưa vào, nó trở thành đặc trưng quan trọng thứ hai, làm nổi bật vai trò quan trọng của nó trong quá trình mô hình hóa (Hình 7(c–g)). Nhìn chung, COD-in là đặc trưng quan trọng nhất hợp lý để dự đoán mức loại bỏ COD của AnMBR, vì đây có thể là chỉ báo quan trọng về tải trọng của lò phản ứng. Ngược lại, các đặc trưng khác như nhiệt độ môi trường, nhiệt độ nước đầu vào và pH có mức độ quan trọng thấp hơn trong mô hình, cho thấy các thông số môi trường này chỉ tác động hạn chế đến hiệu suất của AnMBR.

Theo Hình 7(b–d, f, h), thứ hạng mức độ quan trọng của các đặc trưng khác biệt đáng kể giữa các phương pháp diễn giải. Chẳng hạn, kết quả của mô hình được huấn luyện với dữ liệu bổ sung cho thấy sự khác biệt đáng kể về T-env, flux và pH-in giữa các phương pháp diễn giải. Do khó xác định phương pháp diễn giải tối ưu, chúng tôi khuyến nghị sử dụng điểm xếp hạng tổng hợp kết quả của nhiều phương pháp để đảm bảo tính vững chắc. Ngoài ra, chúng tôi đã khảo sát sự thay đổi về mức độ quan trọng của các đặc trưng khi đưa thêm dữ liệu vào. Kết quả cho thấy thứ hạng mức độ quan trọng của các đặc trưng thay đổi đáng kể, khác biệt rõ rệt so với kết quả của mô hình được huấn luyện với dữ liệu bổ sung. Kết quả diễn giải của mô hình được huấn luyện với dữ liệu bổ sung (Hình 7(h)) không giống với kết quả của mô hình ban đầu (Hình 7(f)). Các phương pháp được chọn để diễn giải dựa trên cấu trúc và khả năng dự đoán của mô hình. Do đó, sự khác biệt giữa chúng có thể bắt nguồn từ việc đưa thêm dữ liệu vào, vốn có thể làm nhiễu mô hình và có khả năng làm giảm hiệu suất dự đoán. Kết quả này củng cố các phát hiện ở Mục 3.3, cho thấy dữ liệu bổ sung được sử dụng trong nghiên cứu này không góp phần xây dựng một mô hình ML AnMBR vững chắc.

Sự biến thiên về mức độ quan trọng của đặc trưng phản ánh độ bất định gắn với các phương pháp toán học khác nhau dùng để tính mức độ quan trọng của đặc trưng. Tuy nhiên, bất chấp những dao động này, các đặc trưng hàng đầu (COD-in và/hoặc OD) luôn được xếp hạng cao nhất ở các phương pháp và mô hình. Điều này cho thấy nhất quán rằng dù các biến xếp hạng thấp hơn còn nhiều bất định, việc xác định các đặc trưng chính vẫn đáng tin cậy. Vai trò vượt trội của COD-in cho thấy độ nhạy với tải trọng COD, gợi ý rằng COD-in có thể là tín hiệu cảnh báo để dự đoán COD-re. Chẳng hạn, khi phát hiện tải trọng COD cao, hệ thống có thể tự động giảm lượng nước đầu vào để quá trình sinh học có thêm thời gian xử lý nước. Tầm quan trọng của OD nhấn mạnh tính phi dừng của quá trình AnMBR (ví dụ: hiện tượng tắc nghẽn màng và sự trưởng thành của sinh khối). Điều này hàm ý rằng việc giám sát quy trình không nên chỉ dựa vào các số đo tức thời của cảm biến mà còn phải tính đến các lịch báo tri phụ thuộc vào thời gian.

3.5. Limitations and future perspectives

Mặc dù nghiên cứu này cho thấy AutoML là một công cụ tiềm năng để mô hình hóa AnMBR khi dữ liệu còn hạn chế, một số hạn chế cần được lưu ý. Thứ nhất, dù AutoML vượt trội hơn các mô hình trước đây khi sử dụng cùng một chiến lược phân chia dữ liệu cố định, các kết quả này nên được xem là chỉ mang tính gợi ý trong bối cảnh thực nghiệm cụ thể này, thay vì chứng minh một sự tuyệt đối trong mọi mô hình và tình huống. Thứ hai, việc một số đặc trưng nhất định (ví dụ: MLSS và MLVSS) đóng góp ít hơn cho mô hình không nên được diễn giải theo khía cạnh vật lý hoặc sinh học, mà phản ánh kết quả mô hình hóa. Do đó, những phát hiện như thế hiện mức độ quan trọng của đặc trưng về mặt thống kê, chứ không phải quan hệ nhân quả về cơ chế. Thứ ba, việc hiệu năng không được cải thiện khi tăng kích thước tập dữ liệu không có nghĩa là khối lượng dữ liệu không có ích. Thay vào đó, điều này nhấn mạnh tầm quan trọng then chốt của tính nhất quán và chất lượng dữ liệu so với số lượng đơn thuần, đồng thời làm nổi bật tác động của sự dịch chuyển phân phối trong các quá trình động của AnMBR xử lý nước thải. Cuối cùng, nghiên cứu này đưa ra các ước lượng điểm xác định. Để hỗ trợ tốt hơn cho việc ra quyết định vận hành, các nghiên cứu trong tương lai có thể tích hợp các phương pháp tiếp cận xác suất. Những phương pháp này có thể cung cấp các khoảng dự đoán và định lượng

uncertainty, offering more comprehensive information for biological wastewater treatment modeling.

4. Conclusions

Modeling wastewater treatment processes deepens mechanisms insight and reduces experimental resources. However, practitioners without data-driven expertise often struggle with model selection and tuning, limiting the practical application of machine learning. To address this challenge, this study applied AutoML to AnMBR modeling in wastewater treatment. The results demonstrated that AutoML improved modeling performance compared to the previous study. An in-depth investigation of input features and data volume revealed that the features selected through modeling significantly improved the capability of ML to model the AnMBR process. By incorporating reactor OD, the R^2 value further increased. However, increasing data volume did not consistently enhance model performance, underscoring the importance of data quality in wastewater treatment modeling. Based on these findings, using AnMBR modeling as a case study, this work demonstrates the efficiency and convenience of AutoML in small-sample modeling and ablation analysis. Furthermore, an integrated feature importance analysis method was proposed to evaluate the feature importance for AutoML model applications. Overall, this study provides new perspectives and references for advancing the application of AutoML in wastewater treatment, especially for modeling in data-scarce scenarios such as laboratory-scale and pilot-scale experiments.

CRedit authorship contribution statement

Junjie Yu: Writing – original draft, Visualization, Software, Investigation. **Zhonghua Zheng:** Writing – review & editing, Resources, Methodology, Investigation. **Jialing Ni:** Writing – review & editing, Resources. **jiayuan Ji:** Writing – review & editing, Writing – original draft, Methodology, Investigation, Funding acquisition, Data curation, Conceptualization.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgements

This study was supported by JSPS KAKENHI (Grant No. JP24K17380). Part of the dataset construction work was supported by the Japan Construction Information Center Foundation (Grant No. 2022-7). Z.Z. appreciates the support provided by the academic start-up funds from the Department of Earth and Environmental Sciences at the University of Manchester. The authors acknowledge Editage for providing professional English language editing services.

Appendix A. Supplementary data

Supplementary data to this article can be found online at <https://doi.org/10.1016/j.jenvman.2026.128801>.

Data availability

The authors do not have permission to share data.

References

- Breiman, L., 2001. Random forests. *Mach. Learn.* 45, 5–32. <https://doi.org/10.1023/A:1010933404324>.
Bridgewater, L.L., Baird, R.B., Eaton, A.D., Rice, E.W., 2017. American public health association, American water works association, water environment Federation.

- Standard Methods for the Examination of Water and Wastewater, 23rd edition. American Public Health Association, Washington, DC.
Chen, T., Guestrin, C., 2016. XGBoost: a scalable tree boosting system. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD '16. Association for Computing Machinery, New York, NY, USA, pp. 785–794. <https://doi.org/10.1145/2939672.2939785>.
Dong, W., Yuan, H., Lin, W., Liu, Z., Xiang, J., Wei, Z., Li, L., Li, Q., Dai, Y., 2025. A global urban tree leaf area index dataset for urban climate modeling. *Sci. Data* 12, 426. <https://doi.org/10.1038/s41597-025-04729-y>.
Dorogush, A.V., Ershov, V., Gulin, A., 2018. CatBoost: gradient boosting with categorical features support. <https://doi.org/10.48550/arXiv.1810.11363>.
Fan, F.J., Shi, Y., 2022. Effects of data quality and quantity on deep learning for protein-ligand binding affinity prediction. *Bioorg. Med. Chem.* 72, 117003. <https://doi.org/10.1016/j.bmc.2022.117003>.
Faraway, J.J., Augustin, N.H., 2018. When small data beats big data. *Role Stat. Era Big Data* 136, 142–145. <https://doi.org/10.1016/j.spl.2018.02.031>.
Geurts, P., Ernst, D., Wehenkel, L., 2006. Extremely randomized trees. *Mach. Learn* 63, 3–42. <https://doi.org/10.1007/s10994-006-6226-1>.
Grinsztajn, L., Oyallon, E., Varoquaux, G., 2022. Why do tree-based models still outperform deep learning on typical tabular data? In: Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., Oh, A. (Eds.), *Advances in Neural Information Processing Systems*. Curran Associates, Inc., pp. 507–520.
He, X., Zhao, K., Chu, X., 2021. AutoML: a survey of the state-of-the-art. *Knowl.-Based Syst.* 212, 106622. <https://doi.org/10.1016/j.knosys.2020.106622>.
Ho, J., Sung, S., 2010. Methanogenic activities in anaerobic membrane bioreactors (AnMBR) treating synthetic municipal wastewater. *Bioresour. Technol.* 101, 2191–2196. <https://doi.org/10.1016/j.biortech.2009.11.042>.
Hu, D., Su, H., Chen, Z., Cui, Y., Ran, C., Xu, J., Xiao, T., Li, X., Wang, H., Tian, Y., Ren, N., 2017. Performance evaluation and microbial community dynamics in a novel AnMBR for treating antibiotic solvent wastewater. *Bioresour. Technol.* 243, 218–227. <https://doi.org/10.1016/j.biortech.2017.06.095>.
Ji, J., Chen, Y., Hu, Y., Ohtsu, A., Ni, J., Li, Y., Sakuma, S., Hojo, T., Chen, R., Li, Y.-Y., 2021a. One-year operation of a 20-L submerged anaerobic membrane bioreactor for real domestic wastewater treatment at room temperature: pursuing the optimal HRT and sustainable flux. *Sci. Total Environ.* 775, 145799. <https://doi.org/10.1016/j.scitotenv.2021.145799>.
Ji, J., Ni, J., Ohtsu, A., Isozumi, N., Hu, Y., Du, R., Chen, Y., Qin, Y., Kubota, K., Li, Y.-Y., 2021b. Important effects of temperature on treating real municipal wastewater by a submerged anaerobic membrane bioreactor: removal efficiency, biogas, and microbial community. *Bioresour. Technol.* 336, 125306. <https://doi.org/10.1016/j.biortech.2021.125306>.
Ji, J., Sakuma, S., Ni, J., Chen, Y., Hu, Y., Ohtsu, A., Chen, R., Cheng, H., Qin, Y., Hojo, T., Kubota, K., Li, Y.-Y., 2020. Application of two anaerobic membrane bioreactors with different pore size membranes for municipal wastewater treatment. *Sci. Total Environ.* 745, 140903. <https://doi.org/10.1016/j.scitotenv.2020.140903>.
Jiang, F., Zheng, Z., Coe, H., Healy, R.M., Poulain, L., Gros, V., Zhang, H., Li, W., Liu, D., West, M., Topping, D., Riemer, N., 2025. Integrating simulations and observations: a foundation model for estimating the aerosol mixing state index. *ACS EST Air* 2, 877–890. <https://doi.org/10.1021/acsestair.4c00329>.
Jury, W.A., Vaux, H.J., 2007. The emerging global water crisis: managing scarcity and conflict between water users. In: *Advances in Agronomy*. Elsevier, pp. 1–76. [https://doi.org/10.1016/S0065-2113\(07\)95001-4](https://doi.org/10.1016/S0065-2113(07)95001-4).
Karmaker (“Santu”), S.K., Hassan, Md.M., Smith, M.J., Xu, L., Zhai, C., Veeramachaneni, K., 2021. AutoML to date and beyond: challenges and opportunities. *ACM Comput. Surv.* 54. <https://doi.org/10.1145/3470918>.
Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.-Y., 2017. LightGBM: a highly efficient gradient boosting decision tree. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc.
Kokol, P., Kokol, M., Zagoranski, S., 2022. Machine learning on small size samples: a synthetic knowledge synthesis. *Sci. Prog.* 105, 00368504211029777. <https://doi.org/10.1177/00368504211029777>.
Krzeminski, P., Leverette, L., Malamis, S., Katsou, E., 2017. Membrane bioreactors – a review on recent developments in energy reduction, fouling control, novel configurations, LCA and market prospects. *J. Membr. Sci.* 527, 207–227. <https://doi.org/10.1016/j.memsci.2016.12.010>.
Lai, Y., Xiao, K., He, Y., Liu, X., Tan, J., Xue, W., Zhang, A., Huang, X., 2024. Machine learning for membrane bioreactor research: principles, methods, applications, and a tutorial. *Front. Environ. Sci. Eng.* 19, 34. <https://doi.org/10.1007/s11783-025-1954-2>.
Li, G., Ji, J., Ni, J., Wang, S., Guo, Y., Hu, Y., Liu, S., Huang, S.-F., Li, Y.-Y., 2022. Application of deep learning for predicting the treatment performance of real municipal wastewater based on one-year operation of two anaerobic membrane bioreactors. *Sci. Total Environ.* 813, 151920. <https://doi.org/10.1016/j.scitotenv.2021.151920>.
Li, Q., Zhao, W., Cui, S., Gadow, S.I., Qin, Y., Li, Y.-Y., 2024. Synergetic association of hydroxyapatite-mediated biofilm and suspended sludge enhances resilience of partial nitrification/anammox (PN/A) system treating high-strength anaerobic membrane bioreactor (AnMBR) permeate. *Bioresour. Technol.* 412, 131391. <https://doi.org/10.1016/j.biortech.2024.131391>.
Li, Y., Wang, Z., Xie, Y., Ding, B., Zeng, K., Zhang, C., 2021. AutoML: from methodology to application. In: Proceedings of the 30th ACM International Conference on Information & Knowledge Management, Cikm '21. Association for Computing Machinery, New York, NY, USA, pp. 4853–4856. <https://doi.org/10.1145/3459637.3483279>.
Li, Z., Jiang, T., Zhao, P., Qu, D., Liu, X., 2024. Enhanced DCH4 recovery via wave pulse mixing coupled in-situ hydrophobic membrane in AnMBR treating municipal

độ không chắc chắn, cung cấp thông tin toàn diện hơn cho việc mô hình hóa xử lý nước thải sinh học.

4. Kết luận

Việc mô hình hóa các quy trình xử lý nước thải giúp hiểu sâu hơn về cơ chế và giảm nguồn lực dành cho thực nghiệm. Tuy nhiên, nhữn người làm trong lĩnh vực này thiếu chuyên môn về khoa học dữ l iệu thường gặp khó khăn khi lựa chọn và tinh chỉnh mô hình, hạn c hể khả năng ứng dụng thực tiễn của học máy. Để giải quyết thách t hực này, nghiên cứu đã áp dụng AutoML vào việc mô hình hóa AnM BR trong xử lý nước thải. Kết quả cho thấy AutoML cải thiện hiệu su ất mô hình so với nghiên cứu trước đây. Phân tích chuyên sâu các đ ặc trưng đầu vào và lượng dữ liệu cho thấy những đặc trưng được l ựa chọn thông qua quá trình mô hình hóa đã cải thiện đáng kể khả năng mô hình hóa quy trình AnMBR của ML. Việc đưa OD của thiết bị phản ứng vào mô hình còn giúp giá trị R^2 tăng thêm. Tuy nhiên, t ăng lượng dữ liệu không phải lúc nào cũng nâng cao hiệu suất mô hình, qua đó nhấn mạnh tầm quan trọng của chất lượng dữ liệu tro ng mô hình hóa xử lý nước thải. Dựa trên những phát hiện này, sử dụng mô hình hóa AnMBR làm nghiên cứu điển hình, công trình ch ứng minh tính hiệu quả và tiện lợi của AutoML trong mô hình hóa v ới mẫu nhỏ và phân tích loại bỏ đặc trưng. Ngoài ra, một phương p háp phân tích tổng hợp mức độ quan trọng của đặc trưng được đề xuất nhằm đánh giá tầm quan trọng của các đặc trưng trong ứng d ụng mô hình AutoML. Nhìn chung, nghiên cứu này cung cấp những góc nhìn và tài liệu tham khảo mới để thúc đẩy ứng dụng AutoML tr ong xử lý nước thải, đặc biệt là mô hình hóa trong các bối cảnh kha n hiếm dữ liệu như thí nghiệm quy mô phòng thí nghiệm và quy m ô thí điểm.

Tuyên bố về đóng góp của tác giả theo CRediT

Junjie Yu: Viết – bản thảo gốc, Trực quan hóa, Phần mềm, Nghiê n cứu. Zhonghua Zheng: Viết – hiệu đính và biên tập, Nguồn lực, Ph ương pháp luận, Nghiên cứu. Jialing Ni: Viết – hiệu đính và biên tập, Nguồn lực. Jiayuan Ji: Viết – hiệu đính và biên tập, Viết – bản thảo gồ c, Phương pháp luận, Nghiên cứu, Huy động kinh phí, Quản lý dữ li ệu, Xây dựng ý tưởng.

Tuyên bố về xung đột lợi ích

Các tác giả tuyên bố rằng họ không có bất kỳ lợi ích tài chính cạ n tranh hoặc mối quan hệ cá nhân nào đã biết có thể ảnh hưởng đế n công trình được trình bày trong bài báo này.

Lời cảm ơn

Nghiên cứu này được hỗ trợ bởi JSPS KAKENHI (Mã số tài trợ JP2 4K17380). Một phần công việc xây dựng bộ dữ liệu được hỗ trợ bởi Quỹ Trung tâm Thông tin Xây dựng Nhật Bản (Mã số tài trợ 2022-7). Z.Z. trân trọng cảm ơn nguồn kinh phí khởi nghiệp học thuật do Kh oa Khoa học Trái đất và Môi trường thuộc Đại học Manchester hỗ tr ợ. Các tác giả cảm ơn Editage đã cung cấp dịch vụ hiệu đính tiếng A nh chuyên nghiệp.

Phụ lục A. Dữ liệu bổ sung

Dữ liệu bổ sung cho bài viết này có thể được tìm thấy trực tuyến tại <https://doi.org/10.1016/j.jenvman.2026.128801>.

Tính khả dụng của dữ liệu

Các tác giả không được phép chia sẻ dữ liệu.

Tài liệu tham khảo

- Breiman, L., 2001. Random forests. *Mach. Learn.* 45, 5–32. <https://doi.org/10.1023/A:1010933404324>.
Bridgewater, L.L., Baird, R.B., Eaton, A.D., Rice, E.W., 2017. American public health association, American water works association, water environment Federation.

- Các phương pháp tiêu chuẩn dùng để kiểm nghiệm nước và nước thải, ấn bản t hứ 23. Hiệp hội Y tế Công cộng Hoa Kỳ, Washington, DC. Chen, T., Guestrin, C., 2016 . XGBoost: hệ thống tăng cường cây có khả năng mở rộng. Trong: Kỷ yếu Hội nghị Q uốc tế ACM SIGKDD lần thứ 22 về Khám phá Tri thức và Khai phá Dữ liệu, KDD '16. A ssociation for Computing Machinery, New York, NY, USA, tr. 785–794. <https://doi.org/10.1145/2939672.2939785>.
Dong, W., Yuan, H., Lin, W., Liu, Z., Xiang, J., Wei, Z., Li, L., Li, Q., Dai, Y., 2025. Bộ dữ liệu toàn cầu về chỉ số diện tích lá cây đô thị phục vụ m ô hình hóa khí hậu đô thị. *Sci. Data* 12, 426. <https://doi.org/10.1038/s41597-025-04729-y>.
Dorogush, A.V., Ershov, V., Gulin, A., 2018. CatBoost: tăng cường gradient với h ỗ trợ các đặc trưng phân loại. <https://doi.org/10.48550/arXiv.1810.11363>.
Fan, F.J., S hi, Y., 2022. Ảnh hưởng của chất lượng và số lượng dữ liệu đến học sâu trong dự đo án ái lực liên kết protein–phối tử. *Bioorg. Med. Chem.* 72, 117003. <https://doi.org/10.1016/j.bmc.2022.117003>.
Faraway, J.J., Augustin, N.H., 2018. Khi dữ liệu nhỏ tốt hơn dữ liệu lớn. *Role Stat. Era Big Data* 136, 142–145. <https://doi.org/10.1016/j.spl.2018.02.031>.
Geurts, P., Ernst, D., Wehenkel, L., 2006. Cây ngẫu nhiên cực độ. *Mach. Lear n* 63, 3–42. <https://doi.org/10.1007/s10994-006-6226-1>.
Grinsztajn, L., Oyallon, E., Varoquaux, G., 2022. Vì sao các mô hình dựa trên cây vẫn vượt trội hơn học sâu trên đ ữ liệu dạng bảng thông thường? Trong: Koyejo, S., Mohamed, S., Agarwal, A., Belgra ve, D., Cho, K., Oh, A. (Chủ biên), Những tiến bộ trong hệ thống xử lý thông tin thần kinh. Curran Associates, Inc., tr. 507–520. He, X., Zhao, K., Chu, X., 2021. AutoML: kh ả o sát tình hình tiên tiến nhất. *Knowl.-Based Syst.* 212, 106622. <https://doi.org/10.1016/j.knosys.2020.106622>.
Ho, J., Sung, S., 2010. Hoạt tính sinh methane trong các thiế t bị phản ứng sinh học màng kỵ khí (AnMBR) xử lý nước thải đô thị tổng hợp. *Biores our. Technol.* 101, 2191–2196. <https://doi.org/10.1016/j.biortech.2009.11.042>.
Hu, D. , Su, H., Chen, Z., Cui, Y., Ran, C., Xu, J., Xiao, T., Li, X., Wang, H., Tian, Y., Ren, N., 201 7. Đánh giá hiệu suất và động thái quần xã vi sinh vật trong một AnMBR mới xử lý n ước thải dung môi kháng sinh. *Bioresour. Technol.* 243, 218–227. <https://doi.org/10.1016/j.biortech.2017.06.095>.
Ji, J., Chen, Y., Hu, Y., Ohtsu, A., Ni, J., Li, Y., Sakuma, S., Hojo, T., Chen, R., Li, Y.-Y., 2021a. Vận hành trong một năm thiết bị phản ứng sinh h ọc màng kỵ khí chìm 20 L để xử lý nước thải sinh hoạt thực tế ở nhiệt độ phòng: tìm kiếm HRT tối ưu và thông lượng bền vững. *Sci. Total Environ.* 775, 145799. <https://doi.org/10.1016/j.scitotenv.2021.145799>.
Ji, J., Ni, J., Ohtsu, A., Isozumi, N., Hu, Y., Du, R., Chen, Y., Qin, Y., Kubota, K., Li, Y.-Y., 2021b. Ảnh hưởng quan trọng của nhiệt độ đến việc xử lý nước thải đô thị thực tế bằng thiết bị phản ứng sinh học màng kỵ khí chìm: hiệu suất loại bỏ, khí sinh học và quần xã vi sinh vật. *Bioresour. Technol.* 336, 125306. <https://doi.org/10.1016/j.biortech.2021.125306>.
Ji, J., Sakuma, S., Chen, R., Cheng, H., Qin, Y., Hojo, T., Kubota, K., Li, Y.-Y., 2020. Ứng dụng hai thiết bị phản ứng sinh học màng kỵ khí với màng có kích thước lỗ khá c nhau để xử lý nước thải đô thị. *Sci. Total Environ.* 745, 140903. <https://doi.org/10.1016/j.scitotenv.2020.140903>.
Jiang, F., Zheng, Z., Coe, H., Healy, R.M., Poulain, L., Gros, V., Zhang, H., Li, W., Liu, D., Gro s, V., Zhang, H., Li, W., Liu, D., West, M., Topping, D., Riemer, N., 2025. Kết hợp mô p hống và quan trắc: mô hình nền tảng để ước tính chỉ số trạng thái trộn của sol khí. *ACS EST Air* 2, 877–890. <https://doi.org/10.1021/acsestair.4c00329>.
Jury, W.A., Vaux, H.J., 2007. Khủng hoảng nước toàn cầu đang nổi lên: quản lý tình trạng khan hiếm v à xung đột giữa những người sử dụng nước. Trong: Những tiến bộ trong nông học. Elsevier, tr. 1–76. [https://doi.org/10.1016/S0065-2113\(07\)95001-4](https://doi.org/10.1016/S0065-2113(07)95001-4).
Karmaker (“Santu”), S.K., Hassan, Md.M., Smith, M.J., Xu, L., Zhai, C., Veeramachaneni, K., 2021. AutoM L đến nay và trong tương lai: thách thức và cơ hội. *ACM Comput. Surv.* 54. <https://doi.org/10.1145/3470918>.
Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.-Y., 2017. LightGBM: cây quyết định tăng cường gradient có hiệu suất cao. Tr ong: Những tiến bộ trong hệ thống xử lý thông tin thần kinh. Curran Associates, Inc .
Kokol, P., Kokol, M., Zagoranski, S., 2022. Học máy trên các mẫu có kích thước nhỏ: tổng hợp tri thức tổng hợp. *Sci. Prog.* 105, 00368504211029777. <https://doi.org/10.1177/00368504211029777>.
Krzeminski, P., Leverette, L., Malamis, S., Katsou, E., 2017. Thiết bị phản ứng sinh học màng – tổng quan về những phát triển gần đây trong kỹ ảm tiêu thụ năng lượng, kiểm soát bám bẩn, cấu hình mới, đánh giá vòng đời và triế n vọng thị trường. *J. Membr. Sci.* 527, 207–227. <https://doi.org/10.1016/j.memsci.2016.12.010>.
Lai, Y., Xiao, K., He, Y., Liu, X., Tan, J., Xue, W., Zhang, A., Huang, X., 2024. Học máy trong nghiên cứu thiết bị phản ứng sinh học màng: nguyên lý, phương ph áp, ứng dụng và hướng dẫn thực hành. *Front. Environ. Sci. Eng.* 19, 34. <https://doi.org/10.1007/s11783-025-1954-2>.
Li, G., Ji, J., Ni, J., Wang, S., Guo, Y., Hu, Y., Liu, S., Huang, S., Guo, Y., Hu, Y., Liu, S., Hua ng, S.-F., Li, Y.-Y., 2022. Ứng dụng học sâu để dự đoán hiệu suất xử lý nước thải đô t hị thực tế dựa trên quá trình vận hành một năm của hai thiết bị phản ứng sinh học màng kỵ khí. *Sci. Total Environ.* 813, 151920. <https://doi.org/10.1016/j.scitotenv.2021.151920>.
Li, Q., Zhao, W., Cui, S., Gadow, S.I., Qin, Y., Li, Y.-Y., 2024. Sự kết hợp hiệp đồng giữa màng sinh học có hydroxyapatite làm môi trường và bùn lơ lửng giúp tă ng cường khả năng chống chịu của hệ thống nitrit hóa một phần/anammox (PN/A) xử lý nước thải qua có nồng độ cao từ thiết bị phản ứng sinh học màng kỵ khí (An MBR). *Bioresour. Technol.* 412, 131391. <https://doi.org/10.1016/j.biortech.2024.131391>.
Li, Y., Wang, Z., Xie, Y., Ding, B., Zeng, K., Zhang, C., 2021. AutoML: từ phương ph áp luận đến ứng dụng. Trong: Kỷ yếu Hội nghị Quốc tế ACM lần thứ 30 về Quản lý T hông tin và Tri thức, Cikm '21. Association for Computing Machinery, New York, NY, USA, tr. 4853–4856. <https://doi.org/10.1145/3459637.3483279>.
Li, Z., Jiang, T., Zhao, P., Qu, D., Liu, X., 2024. Tăng cường thu hồi DCH4 thông qua khuấy trộn bằng xung sóng kết hợp với màng kỵ nước lắp đặt bên trong AnMBR xử lý nước thải đô thị.

wastewater. Resour. Conserv. Recycl. 209, 107773. <https://doi.org/10.1016/j.resconrec.2024.107773>.

Liu, Y., Yang, Z., Zou, X., Ma, S., Liu, D., Avdeev, M., Shi, S., 2023. Data quantity governance for machine learning in materials science. Natl. Sci. Rev. 10. <https://doi.org/10.1093/nsr/nwad125> nwad125.

Lundberg, S.M., Lee, S.-I., 2017. A unified approach to interpreting model predictions. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS'17*. Curran Associates Inc., Red Hook, NY, USA, pp. 4768–4777.

Lundberg, S.M., Nair, B., Vavilala, M.S., Horibe, M., Eisses, M.J., Adams, T., Liston, D.E., Low, D.K.-W., Newman, S.-F., Kim, J., Lee, S.-I., 2018. Explainable machine-learning predictions for the prevention of hypoxaemia during surgery. Nat. Biomed. Eng. 2, 749–760. <https://doi.org/10.1038/s41551-018-0304-0>.

Mahanna, H., El-Rashidy, N., Kaloop, M.R., El-Sapakh, S., Alluqmani, A., Hassan, R., 2024. Prediction of wastewater treatment plant performance through machine learning techniques. Desalination Water Treat. 319, 100524. <https://doi.org/10.1016/j.dwt.2024.100524>.

Martin Bland, J., Altman, DouglasG., 1986. Statistical methods for assessing agreement between two methods of clinical measurement. Lancet 327, 307–310. [https://doi.org/10.1016/S0140-6736\(86\)90837-8](https://doi.org/10.1016/S0140-6736(86)90837-8).

McElfresh, D., Khandagale, S., Valverde, J., Prasad C, V., Ramakrishnan, G., Goldblum, M., White, C., 2023. When do neural nets outperform boosted trees on tabular data? In: Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., Levine, S. (Eds.), *Advances in Neural Information Processing Systems. Curran Associates, Inc.*, pp. 76336–76369.

Moideen, S.N.F., Krishnan, S., Li, Y.-Y., Hassim, M.H., Kamyab, H., Nasrullah, M., Din, M. F.M., Halim, K.A., Chairapat, S., 2023. Performance evaluation and energy potential analysis of anaerobic membrane bioreactor (AnMBR) in the treatment of simulated milk wastewater. Chemosphere 317, 137923. <https://doi.org/10.1016/j.chemosphere.2023.137923>.

Pal, R., Arcamo, L., Farnood, R., 2024. Predicting the occurrence of substituted and unsubstituted, polycyclic aromatic compounds in coking wastewater treatment plant effluent using machine learning regression. Chemosphere 361, 142476. <https://doi.org/10.1016/j.chemosphere.2024.142476>.

Pretel, R., Durán, F., Robles, A., Ruano, M.V., Ribes, J., Serralta, J., Ferrer, J., 2015. Designing an AnMBR-based WWTP for energy recovery from urban wastewater: the role of primary settling and anaerobic digestion. Sep. Purif. Technol. 156, 132–139. <https://doi.org/10.1016/j.seppur.2015.09.047>.

Ren, L., Chen, X., Wu, J., Huang, S., Williams, A., Su, Q., 2024. Study on membrane fouling mechanisms and mitigation strategies in a pilot-scale anaerobic membrane bioreactor (P-AnMBR) treating digestate. Water Res. 263, 122166. <https://doi.org/10.1016/j.watres.2024.122166>.

Robles, Á., Jiménez-Benítez, A., Giménez, J.B., Durán, F., Ribes, J., Serralta, J., Ferrer, J., Rogalla, F., Seco, A., 2022. A semi-industrial scale AnMBR for municipal wastewater treatment at ambient temperature: performance of the biological process. Water Res. 215, 118249. <https://doi.org/10.1016/j.watres.2022.118249>.

Robles, Á., Ruano, M.V., Charfi, A., Lesage, G., Heran, M., Harmand, J., Seco, A., Steyer, J.-P., Batstone, D.J., Kim, J., Ferrer, J., 2018. A review on anaerobic membrane bioreactors (AnMBRs) focused on modelling and control aspects. Bioresour. Technol. 270, 612–626. <https://doi.org/10.1016/j.biortech.2018.09.049>.

Schreck, J.S., Petzke, W., Jiménez, P.A., Brummet, T., Knievel, J.C., James, E., Kosović, B., Gagne, D.J., 2023. Machine learning and VIIRS satellite retrievals for skillful fuel moisture content monitoring in wildfire management. Remote Sens. 15, 3372. <https://doi.org/10.3390/rs15133372>.

Shwartz-Ziv, R., Armon, A., 2022. Tabular data: deep learning is not all you need. Inf. Fusion 81, 84–90. <https://doi.org/10.1016/j.inffus.2021.11.011>.

Truong, A., Walters, A., Goodsitt, J., Hines, K., Bruss, C.B., Farivar, R., 2019. Towards automated machine learning: evaluation and comparison of AutoML approaches and tools. In: 2019 IEEE 31st International Conference on Tools with Artificial Intelligence (ICTAI), pp. 1471–1479. <https://doi.org/10.1109/ICTAI.2019.00209>.

Uman, A.E., Bair, R.A., Yeh, D.H., 2021. Assessment of an anaerobic membrane bioreactor (AnMBR) treating medium-strength synthetic wastewater under cyclical membrane operation. Membranes 11. <https://doi.org/10.3390/membranes11060415>.

van Loosdrecht, M.C.M., Brdjanovic, D., 2014. Anticipating the next century of wastewater treatment. Science 344, 1452–1453. <https://doi.org/10.1126/science.1255183>.

Wang, C., Wu, Q., Huang, S., Saied, A., 2021a. Economical hyperparameter optimization with blended search strategy. In: *The Ninth International Conference on Learning Representations (ICLR 2021)*.

Wang, C., Wu, Q., Weimer, M., Zhu, E.Eric, 2021b. FLAML: a fast and lightweight AutoML library. Presented at the Fourth Conference on Machine Learning and Systems (MLSys 2021).

Wang, T., Li, Y.-Y., 2024. Predictive modeling based on artificial neural networks for membrane fouling in a large pilot-scale anaerobic membrane bioreactor for treating real municipal wastewater. Sci. Total Environ. 912, 169164. <https://doi.org/10.1016/j.scitotenv.2023.169164>.

Winkler, M.-K.H., van Loosdrecht, M.C.M., 2022. Intensifying existing urban wastewater. Science 375, 377–378. <https://doi.org/10.1126/science.abm3900>.

Wu, Q., Wang, C., Huang, S., 2021. Frugal optimization for cost-related hyperparameters. Proc. Thirty-Fifth AAAI Conf. Artif. Intell. AAAI-21. <https://doi.org/10.48550/arXiv.2005.01571>.

Xia, Xinran, Fu, D., Shao, W., Jiang, R., Wu, S., Zhang, P., Yang, D., Xia, Xiangao, 2023. Retrieving precipitable water vapor over land from satellite passive microwave radiometer measurements using automated machine learning. Geophys. Res. Lett. 50. <https://doi.org/10.1029/2023GL105197> e2023GL105197.

Xie, Z., Wang, Z., Wang, Q., Zhu, C., Wu, Z., 2014. An anaerobic dynamic membrane bioreactor (AnDMBR) for landfill leachate treatment: performance and microbial community identification. Bioresour. Technol. 161, 29–39. <https://doi.org/10.1016/j.biortech.2014.03.014>.

Yu, J., Zheng, Z., Lindley, S., Zhao, L., Wang, C., Wu, Q., Li, L., Topping, D.O., Schreck, J. S., Gagne, D.J., Oleson, K.W., 2025. Leveraging automated machine learning (AutoML) for urban climate emulation. Big Data Earth Syst 1, 100040. <https://doi.org/10.1016/j.bdes.2025.100040>.

Zheng, Z., Fiore, A.M., Westervelt, D.M., Milly, G.P., Goldsmith, J., Karambelas, A., Curci, G., Randles, C.A., Paiva, A.R., Wang, C., Wu, Q., Dey, S., 2023. Automated machine learning to evaluate the information content of tropospheric trace gas columns for fine particle estimates over India: a modeling testbed. J. Adv. Model. Earth Syst. 14, 17727–17741. <https://doi.org/10.1029/2022ms003099>.

wastewater. Resour. Conserv. Recycl. 209, 107773. <https://doi.org/10.1016/j.resconrec.2024.107773>.

Liu, Y., Yang, Z., Zou, X., Ma, S., Liu, D., Avdeev, M., Shi, S., 2023. Quản trị số lượng dữ liệu cho học máy trong khoa học vật liệu. Natl. Sci. Rev. 10. <https://doi.org/10.1093/nsr/nwad125> nwad125.

Lundberg, S.M., Lee, S.-I., 2017. Phương pháp thống nhất để diễn giải các dự đoán của mô hình. In: *Kỷ yếu Hội nghị Quốc tế lần thứ 31 về Hệ thống Xử lý Thông tin Thần kinh, NIPS'17*. Curran Associates Inc., Red Hook, NY, Hoa Kỳ, tr. 4768–4777.

Lundberg, S.M., Nair, B., Vavilala, M.S., Horibe, M., Eisses, M.J., Adams, T., Liston, D.E., Low, D.K.-W., Newman, S.-F., Kim, J., Lee, S.-I., 2018. Các dự đoán có thể giải thích bằng học máy nhằm ngăn ngừa tình trạng thiếu oxy máu trong phẫu thuật. Nat. Biomed. Eng. 2, 749–760. <https://doi.org/10.1038/s41551-018-0304-0>.

Mahanna, H., El-Rashidy, N., Kaloop, M.R., El-Sapakh, S., Alluqmani, A., Hassan, R., 2024. Dự đoán hiệu suất của nhà máy xử lý nước thải bằng các kỹ thuật học máy. Desalination Water Treat. 319, 100524. <https://doi.org/10.1016/j.dwt.2024.100524>.

Martin Bland, J., Altman, DouglasG., 1986. Các phương pháp thống kê để đánh giá mức độ đồng thuận giữa hai phương pháp đo lường lâm sàng. Lancet 327, 307–310. [https://doi.org/10.1016/S0140-6736\(86\)90837-8](https://doi.org/10.1016/S0140-6736(86)90837-8).

McElfresh, D., Khandagale, S., Valverde, J., Prasad C, V., Ramakrishnan, G., Goldblum, M., White, C., 2023. Khó nào mạng nơ-ron vượt trội hơn cây tăng cường trên dữ liệu dạng bảng? In: Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., Levine, S. (Eds.), *Những tiến bộ trong hệ thống xử lý thông tin thần kinh*. Curran Associates, Inc., tr. 76336–76369.

Moideen, S.N.F., Krishnan, S., Li, Y.-Y., Hassim, M.H., Kamyab, H., Nasrullah, M., Din, M. F.M., Halim, K.A., Chairapat, S., 2023. Đánh giá hiệu suất và phân tích tiềm năng năng lượng của thiết bị phản ứng sinh học màng kỵ khí (AnMBR) trong xử lý nước thải sữa mô phỏng. Chemosphere 317, 137923. <https://doi.org/10.1016/j.chemosphere.2023.137923>.

Pal, R., Arcamo, L., Farnood, R., 2024. Dự đoán sự hiện diện của các hợp chất thơm đa vòng có và không có nhóm thế trong nước thải đầu ra của nhà máy xử lý nước thải luyện cốc bằng hồi quy học máy. Chemosphere 361, 142476. <https://doi.org/10.1016/j.chemosphere.2024.142476>.

Pretel, R., Durán, F., Robles, A., Ruano, M.V., Ribes, J., Serralta, J., Ferrer, J., 2015. Thiết kế nhà máy xử lý nước thải đô thị dựa trên AnMBR để thu hồi năng lượng: vai trò của lắng sơ cấp và phân hủy kỵ khí. Sep. Purif. Technol. 156, 132–139. <https://doi.org/10.1016/j.seppur.2015.09.047>.

Ren, L., Chen, X., Wu, J., Huang, S., Williams, A., Su, Q., 2024. Nghiên cứu cơ chế cấu trúc màng và các chiến lược giảm thiểu trong thiết bị phản ứng sinh học màng kỵ khí quy mô thí điểm (P-AnMBR) xử lý bã thải tiêu hóa. Water Res. 263, 122166. <https://doi.org/10.1016/j.watres.2024.122166>.

Robles, Á., Jiménez-Benítez, A., Giménez, J.B., Durán, F., Ribes, J., Serralta, J., Ferrer, J., Rogalla, F., Seco, A., 2022. AnMBR quy mô bán công nghiệp xử lý nước thải đô thị ở nhiệt độ môi trường: hiệu suất của quá trình sinh học. Water Res. 215, 118249. <https://doi.org/10.1016/j.watres.2022.118249>.

Robles, Á., Ruano, M.V., Charfi, A., Lesage, G., Heran, M., Harmand, J., Seco, A., Steyer, J.-P., Batstone, D.J., Kim, J., Ferrer, J., 2018. Tổng quan về các thiết bị phản ứng sinh học màng kỵ khí (AnMBR), tập trung vào các khía cạnh mô hình hóa và điều khiển. Bioresour. Technol. 270, 612–626. <https://doi.org/10.1016/j.biortech.2018.09.049>.

Schreck, J.S., Petzke, W., Jiménez, P.A., Brummet, T., Knievel, J.C., James, E., Kosović, B., Gagne, D.J., 2023. Học máy và dữ liệu truy xuất từ vệ tinh VIIRS để giám sát hiệu quả hàm lượng ẩm nhiên liệu trong quản lý cháy rừng. Remote Sens. 15, 3372. <https://doi.org/10.3390/rs15133372>.

Shwartz-Ziv, R., Armon, A., 2022. Dữ liệu dạng bảng: học sâu không phải là tất cả những gì bạn cần. Inf. Fusion 81, 84–90. <https://doi.org/10.1016/j.inffus.2021.11.011>.

Truong, A., Walters, A., Goodsitt, J., Hines, K., Bruss, C.B., Farivar, R., 2019. Hướng tới học máy tự động: đánh giá và so sánh các phương pháp và công cụ AutoML. Trong: *Hội nghị quốc tế IEEE lần thứ 31 về Công cụ cho trí tuệ nhân tạo (ICTAI)* năm 2019, tr. 1471–1479. <https://doi.org/10.1109/ICTAI.2019.00209>.

Uman, A.E., Bair, R.A., Yeh, D.H., 2021. Đánh giá một thiết bị phản ứng sinh học màng kỵ khí (AnMBR) xử lý nước thải tổng hợp có nồng độ trung bình trong điều kiện vận hành màng theo chu kỳ. Membranes 11. <https://doi.org/10.3390/membranes11060415>.

van Loosdrecht, M.C.M., Brdjanovic, D., 2014. Dự báo thế kỷ tiếp theo của xử lý nước thải. Science 344, 1452–1453. <https://doi.org/10.1126/science.1255183>.

Wang, C., Wu, Q., Huang, S., Saied, A., 2021a. Tối ưu hóa siêu tham số tiết kiệm chi phí bằng chiến lược tìm kiếm kết hợp. Trong: *Hội nghị quốc tế lần thứ chín về Biểu diễn học tập (ICLR 2021)*. Wang, C., Wu, Q., Weimer, M., Zhu, E.Eric, 2021b. FLAML: thư viện AutoML nhanh và gọn nhẹ. Trình bày tại *Hội nghị lần thứ tư về Học máy và Hệ thống (MLSys 2021)*. Wang, T., Li, Y.-Y., 2024. Mô hình hóa dự báo dựa trên mạng nơ-ron nhân tạo về hiện tượng tắc nghẽn màng trong thiết bị phản ứng sinh học màng kỵ khí quy mô thí điểm lớn xử lý nước thải đô thị thực tế. Sci. Total Environ. 912, 169164. <https://doi.org/10.1016/j.scitotenv.2023.169164>.

Winkler, M.-K.H., van Loosdrecht, M.C.M., 2022. Tăng cường xử lý nước thải đô thị hiện có. Science 375, 377–378. <https://doi.org/10.1126/science.abm3900>.

Wu, Q., Wang, C., Huang, S., 2021. Tối ưu hóa các siêu tham số liên quan đến chi phí. Kỷ yếu Hội nghị AAAI lần thứ 35 về Trí tuệ nhân tạo, AAAI-21. <https://doi.org/10.48550/arXiv.2005.01571>.

Xia, Xinran, Fu, D., Shao, W., Jiang, R., Wu, S., Zhang, P., Yang, D., Xia, Xiangao, 2023. Ước tính lượng hơi nước có thể ngưng tụ trên đất liền từ các phép đo của thiết bị đo bức xạ vi sóng thụ động trên vệ tinh bằng học máy tự động. Geophys. Res. Lett. 50. <https://doi.org/10.1029/2023GL105197> e2023GL105197.

Xie, Z., Wang, Z., Wang, Q., Zhu, C., Wu, Z., 2014. Thiết bị phản ứng sinh học màng động kỵ khí (AnDMBR) xử lý nước rỉ bãi chôn lấp: hiệu suất và nhận diện quần xã vi sinh vật. Bioresour. Technol. 161, 29–39. <https://doi.org/10.1016/j.biortech.2014.03.014>.

Yu, J., Zheng, Z., Lindley, S., Zhao, L., Wang, C., Wu, Q., Li, L., Topping, D.O., Schreck, J. S., Gagne, D.J., Oleson, K.W., 2025. 100040. <https://doi.org/10.1016/j.bdes.2025.100040>.

Zheng, Z., Fiore, A.M., Westervelt, D.M., Milly, G.P., Goldsmith, J., Karambelas, A., Curci, G., Randles, C.A., Paiva, A.R., Wang, C., Wu, Q., Dey, S., 2023. Học máy tự động để đánh giá hàm lượng thông tin của các cột khí vi lượng tăng đối lưu phục vụ ước tính hạt mịn ở Ấn Độ: nền tảng thử nghiệm mô hình hóa. J. Adv. Model. Earth Syst. 14, 17727–17741. <https://doi.org/10.1029/2022ms003099>.