




Contents lists available at ScienceDirect

Journal of Hydrology

journal homepage: www.elsevier.com/locate/jhydrol



Explainable AutoML-driven surface water quality classification with key indicators identification

Wenjie Qin^{a,b}, Heng Zhong^{a,b}, Jingping Hu^{a,b,c,*}, Wei Luo^{a,b}, Zhe Shao^{a,b},
Huijie Hou^{a,b}, Zhenzhen Liu^d, Xiaotong Zhang^d, Sha Liang^{a,b}, Jiakuan Yang^{a,b,c}

^a Hubei Key Laboratory of Multi-media Pollution Cooperative Control in Yangtze Basin, School of Environmental Science & Engineering, Huazhong University of Science and Technology (HUST), 1037 Luoyu Road, Wuhan 430074, China

^b Hubei Provincial Engineering Laboratory of Solid Waste Treatment, Disposal and Recycling, 1037 Luoyu Road, Wuhan 430074, China

^c State Key Laboratory of Coal Combustion, Huazhong University of Science and Technology (HUST), 1037 Luoyu Road, Wuhan 430074, China

^d Hubei Provincial Eco-Environmental Monitoring Centre, 338 Bayi Road, Wuhan 430072, China

ARTICLE INFO

This manuscript was handled by Huaming Guo, Editor-in-Chief

Keywords:

Water quality classification
Automated machine learning
Interpretable ensemble learning
Feature importance

ABSTRACT

Surface water quality monitoring and classification face dual challenges: prohibitive costs of comprehensive indicators monitoring and the labor-intensive process of traditional machine learning (ML) implementation, which jointly constrain the development of efficient water quality assessment systems. This study presents an automated and interpretable framework: Auto-sklearn automates the machine learning workflow to address model selection complexity, while SHAP analysis quantifies feature contributions to reduce water quality indicator requirements. Using monitoring data from major river basins of China, we evaluated Auto-sklearn against conventional ML algorithms and modern ensemble methods. Auto-sklearn achieved the highest mean performance (Weighted F1: 0.9633 ± 0.0027) via an optimized ensemble. Crucially, this high performance proved to be robust and generalizable, as the framework maintained its superiority across rigorous temporal and spatial validation schemes. Through Kernel SHAP analysis, we identified COD_{Mn} , TP, and DO as the key indicators. A 3-indicator Auto-sklearn model achieved a high Weighted F1 (0.9205 ± 0.0097) and outperformed the rule-based baseline, with higher F1-scores across all classes and an 18.9 % relative improvement for Class WV water. This suggests that monitoring costs can be substantially reduced while simultaneously improving assessment reliability. Further regional analysis revealed spatial variations, with most basins aligning with the nationwide set, but the Song-Liao and Yellow River Basins also requiring $\text{NH}_3\text{-N}$ monitoring. This framework provides a practical, cost-effective solution for water environment management, especially in developing regions.

1. Introduction

Water quality monitoring and early warning systems play a crucial role in environmental protection and public health, particularly in developing countries facing rapid industrialization and urbanization (Michalak, 2016; Greenhill et al., 2024; Qian et al., 2024). While the United Nations has emphasized water quality management in its Sustainable Development Goals (SDGs 6 and 14), implementing effective monitoring systems remains challenging due to technical and resource constraints (Herrera, 2019; Byrne, 2024). Surface water quality classification based on monitoring indicators is fundamental to sustainable water environment management, yet achieving both cost-effectiveness

and reliability in such classification systems remains a significant challenge in developing regions (Baccour et al., 2024).

Automatic water quality monitoring stations started to be deployed in major river basins in China since 1999, implementing classification based on the single-factor evaluation method (Table S1). This evaluation method requires monitoring of up to 24 water quality indicators. The list includes not only conventional parameters but also numerous indicators such as heavy metals (e.g., mercury, lead) and specific organic pollutants (e.g., volatile phenols), which are notoriously difficult to monitor continuously in the field. This comprehensiveness poses significant practical challenges. Specifically, sensors for pollutants such as heavy metals and organics are expensive and less robust, leading to high

* Corresponding author at: Hubei Key Laboratory of Multi-media Pollution Cooperative Control in Yangtze Basin, School of Environmental Science & Engineering, Huazhong University of Science and Technology (HUST), 1037 Luoyu Road, Wuhan 430074, China.
E-mail address: hujp@hust.edu.cn (J. Hu).

<https://doi.org/10.1016/j.jhydrol.2025.134634>

Received 29 May 2025; Received in revised form 17 November 2025; Accepted 18 November 2025

Available online 22 November 2025


0022-1694/© 2025 Elsevier B.V. All rights are reserved, including those for text and data mining, AI training, and similar technologies.



Contents lists available at ScienceDirect

Journal of Hydrology

journal homepage: www.elsevier.com/locate/jhydrol



Phân loại chất lượng nước mặt bằng AutoML có khả năng giải thích, đồng thời xác định các chỉ số then chốt

Wenjie Qin^{a,b}, Heng Zhong^{a,b}, Jingping Hu^{a,b,c,*}, Wei Luo^{a,b}, Zhe Shao^{a,b}, Hu
ijie Hou^{a,b}, Zhenzhen Liu^d, Xiaotong Zhang^d, Sha Liang^{a,b}, Jiakuan Yang^{a,b,c}

^a Hubei Key Laboratory of Multi-media Pollution Cooperative Control in Yangtze Basin, School of Environmental Science & Engineering, Huazhong University of Science and Technology (HUST), 1037 Luoyu Road, Wuhan 430074, China

^b Hubei Provincial Engineering Laboratory of Solid Waste Treatment, Disposal and Recycling, 1037 Luoyu Road, Wuhan 430074, China

^c State Key Laboratory of Coal Combustion, Huazhong University of Science and Technology (HUST), 1037 Luoyu Road, Wuhan 430074, China

^d Hubei Provincial Eco-Environmental Monitoring Centre, 338 Bayi Road, Wuhan 430072, China

THÔNG TIN BÀI VIẾT

Bản thảo này được Huaming Guo, Tổng biên tập, xử lý.

Keywords:

Phân loại chất lượng nước H
ọc tổ hợp có
khả năng diễn giải Mức độ qu
an trọng của đặc trưng

TÓM TẮT

Việc giám sát và phân loại chất lượng nước mặt phải đối mặt với hai thách thức: chi phí quá cao để giám sát toàn diện các chỉ tiêu và quy trình triển khai học máy (ML) truyền thống tốn nhiều công sức. Cả hai cùng hạn chế sự phát triển của các hệ thống đánh giá chất lượng nước hiệu quả. Nghiên cứu này giới thiệu một khuôn khổ tự động và có khả năng diễn giải: Auto-sklearn tự động hóa quy trình học máy nhằm giải quyết sự phức tạp trong lựa chọn mô hình, trong khi phân tích SHAP định lượng mức đóng góp của các đặc trưng để giảm số lượng chỉ tiêu chất lượng nước cần thiết. Sử dụng dữ liệu giám sát từ các lưu vực sông lớn của Trung Quốc, chúng tôi đánh giá Auto-sklearn so với các thuật toán ML thông thường và các phương pháp tổ hợp hiện đại. Auto-sklearn đạt hiệu suất trung bình cao nhất ($F1$ có trọng số: 0.9633 ± 0.0027) nhờ mô hình tổ hợp được tối ưu hóa. Đáng chú ý, hiệu suất cao này tỏ ra vững chắc và có khả năng khái quát hóa, khi khuôn khổ này duy trì ưu thế trong các phương thức kiểm định thời gian và không gian nghiêm ngặt. Thông qua phân tích Kernel SHAP, chúng tôi xác định COD_{Mn} , TP và DO là các chỉ tiêu then chốt. Mô hình Auto-sklearn sử dụng 3 chỉ tiêu đạt $F1$ có trọng số cao (0.9205 ± 0.0097) và vượt trội so với phương pháp cơ sở dựa trên quy tắc, với điểm $F1$ cao hơn ở tất cả các lớp và mức cải thiện tương đối 18.9 % đối với nước loại WV. Điều này cho thấy có thể giảm đáng kể chi phí giám sát, đồng thời cải thiện độ tin cậy của việc đánh giá. Phân tích sâu hơn theo khu vực cho thấy có sự khác biệt về không gian: phần lớn các lưu vực phù hợp với bộ chỉ tiêu trên toàn quốc, nhưng các lưu vực Tùng-Liêu và Hoàng Hà cũng cần được giám sát $\text{NH}_3\text{-N}$. Khuôn khổ này mang đến giải pháp thiết thực, tiết kiệm chi phí cho công tác quản lý môi trường nước, đặc biệt tại các khu vực đang phát triển.

1. Giới thiệu

Các hệ thống giám sát chất lượng nước và cảnh báo sớm đóng vai trò then chốt trong bảo vệ môi trường và sức khỏe cộng đồng, đặc biệt tại các quốc gia đang phát triển phải đối mặt với quá trình công nghiệp hóa và đô thị hóa nhanh chóng (Michalak, 2016; Greenhill et al., 2024; Qian et al., 2024). Mặc dù Liên Hợp Quốc đã nhấn mạnh công tác quản lý chất lượng nước trong các Mục tiêu Phát triển Bền vững (SDG 6 và 14), việc triển khai các hệ thống giám sát hiệu quả vẫn gặp nhiều thách thức do hạn chế về kỹ thuật và nguồn lực (Herrera, 2019; Byrne, 2024). Phân loại chất lượng nước mặt dựa trên các chỉ số giám sát là nền tảng cho công tác quản lý môi trường nước bền vững, nhưng việc đồng thời đạt được hiệu quả về chi phí ...

độ tin cậy của các hệ thống phân loại như vậy vẫn là một thách thức đáng kể ở các khu vực đang phát triển (Baccour et al., 2024).

Các trạm quan trắc chất lượng nước tự động bắt đầu được triển khai tại các lưu vực sông lớn ở Trung Quốc từ năm 1999, áp dụng phương pháp phân loại dựa trên đánh giá đơn yếu tố (Bảng S1). Phương pháp đánh giá này yêu cầu quan trắc tới 24 chỉ tiêu chất lượng nước. Danh sách này không chỉ bao gồm các thông số thông thường mà còn có nhiều chỉ tiêu như kim loại nặng (ví dụ: thủy ngân, chì) và các chất ô nhiễm hữu cơ đặc thù (ví dụ: phenol dễ bay hơi), vốn nổi tiếng là khó quan trắc liên tục ngoài hiện trường. Tính toàn diện này đặt ra những thách thức đáng kể trong thực tiễn. Cụ thể, các cảm biến dùng để phát hiện những chất ô nhiễm như kim loại nặng và hợp chất hữu cơ có giá thành cao, độ bền thấp, dẫn đến chi phí cao.

* Corresponding author at: Hubei Key Laboratory of Multi-media Pollution Cooperative Control in Yangtze Basin, School of Environmental Science & Engineering, Huazhong University of Science and Technology (HUST), 1037 Luoyu Road, Wuhan 430074, China.
E-mail address: hujp@hust.edu.cn (J. Hu).

<https://doi.org/10.1016/j.jhydrol.2025.134634>

Received 29 May 2025; Received in revised form 17 November 2025; Accepted 18 November 2025

Available online 22 November 2025

0022-1694/© 2025 Elsevier B.V. All rights are reserved, including those for text and data mining, AI training, and similar technologies.

operational costs and frequent data interruptions (Durgun, 2024). As a direct consequence of these operational and financial constraints, the national online monitoring network of China pragmatically focuses on a core subset of more feasible indicators rather than the full 24 indicators. This reality highlights the urgent need to identify the most critical indicators even within this reduced set to further enhance monitoring efficiency and cost-effectiveness (Othman et al., 2020; Wu et al., 2023).

Traditional statistical approaches, such as principal component analysis and Pearson correlation analysis, have been widely used for water quality indicator selection (Tripathi and Singal, 2019; Uddin et al., 2021; Asadollah et al., 2021). With the advancement of artificial intelligence, machine learning (ML) methods have demonstrated superior capability in handling complex nonlinear relationships in water quality prediction and key indicator selection (Zhu et al., 2022; Ding et al., 2023; Zhang et al., 2024). However, developing an optimal and robust predictive system using ML presents significant challenges. The process involves a complex, multi-stage workflow, including systematically selecting the most suitable algorithm, performing robust feature engineering, and conducting rigorous, computationally intensive hyperparameter optimization (HPO). While a single model might work efficiently with default parameters, the HPO process, which systematically evaluates hundreds or thousands of configurations to maximize predictive accuracy, is often computationally prohibitive, demanding substantial resources and specialized expertise (Peng et al., 2022; Xia and Zeng, 2022; Li et al., 2024). To address these specific workflow challenges, automated machine learning (AutoML) has emerged as a powerful paradigm. It is designed to automate this entire end-to-end pipeline, from data preprocessing and feature selection to model choice and HPO, thereby greatly reducing the demand for domain-specific expertise and computational oversight (Zöller and Huber, 2021). Several AutoML methods have been developed, such as TPOT, H2O, and Auto-sklearn (Feurer et al., 2015; Olson et al., 2016; LeDell and Poirier, 2020). Among them, Auto-sklearn has demonstrated superior performance in multiple competitions through its integration of Bayesian optimization, *meta*-learning, and ensemble construction. Even in specially designed “Beat Auto-sklearn” challenges, manual parameter tuning by experienced data scientists could not surpass its automated optimization performance (Guyon et al., 2019).

However, the automated model selection and ensemble processes of AutoML intensify the “black box” nature of models, challenging the understanding and interpretation of model decision processes (Barredo Arrieta et al., 2020). This is particularly crucial in water quality management, where models must maintain both prediction accuracy and transparency in decision-making. The Kernel SHAP (SHapley Additive exPlanations) method offers a promising solution by combining LIME (Local Interpretable Model-agnostic Explanations) with Shapley values to construct a unified interpretation framework. Through quantitative feature importance attribution derived from cooperative game theory, SHAP effectively measures the contribution of features to model predictions (Lundberg and Lee, 2017a; Russo et al., 2023). While SHAP values show great potential, their application in water quality indicator screening remains unexplored, especially as an alternative to computationally prohibitive “best subset” selection methods. These brute-force approaches test every possible feature combination to guarantee finding the optimal set, but their computational cost grows exponentially, making them impractical for larger feature sets (Chen et al., 2020).

Herein, this study develops an automated and interpretable framework for water quality classification using monitoring data from the China National Environmental Monitoring Center (CNEMC). The framework classifies surface water quality into a six-level system (Class I-V and worse than V) based on the nine core indicators reliably monitored by the national online monitoring network of China. The specific objectives are to: (i) evaluate the performance of Auto-sklearn against conventional ML algorithms and modern ensemble methods through comprehensive metrics (Precision, Recall, Weighted F1, Macro F1,

confusion matrix, and AUC-ROC curves); (ii) interpret the Auto-sklearn ensemble model using Kernel SHAP to quantify indicator contributions to model predictions; and (iii) identify key water quality indicators for optimizing monitoring schemes. Through this integrated approach, we aim to establish a cost-effective framework that can enhance water quality management and decision-making processes while simultaneously improving assessment reliability.

2. Materials and methods

2.1. Study area and water quality dataset

Datasets of surface water quality were collected from the CNEMC, covering nine major river basins, including Continental, Hai, Huai, Pearl, Song-Liao, Southeast, Southwest, Yangtze, and Yellow rivers. The data were collected from approximately 1900 monitoring sites from January 2021 to June 2024, with a time step of 4 h (Fig. 1a). The national online monitoring system of CNEMC focuses on a core set of 11 feasible indicators for real-time tracking. However, after assessing data quality, two of these indicators [chlorophyll-a (Chl-a, mg/L) and algal density (cells/L)] were excluded from our study due to severe data missingness (>70 %, Table S3). The final analysis was therefore conducted on the remaining nine robustly-monitored indicators: water temperature (WT, °C), pH, dissolved oxygen (DO, mg/L), electrical conductivity (EC, µS/cm), chemical oxygen demand (COD_{Mn}, mg/L), ammonia nitrogen (NH₃-N, mg/L), total phosphorus (TP, mg/L), total nitrogen (TN, mg/L), and turbidity (NTU).

According to the Environmental Quality Standards for Surface Water (MEEPRC, 2002), water quality was classified into six classes from best to worst (I-WV). This classification serves as the target variable for our supervised learning models. The classification for each data record was pre-determined by the CNEMC based on the “single-factor evaluation method”, where the final class is assigned based on the poorest-performing individual indicator relative to the standard limits as shown in Table S1. Our objective is therefore to predict this official classification using the nine selected water quality indicators as input features.

To ensure computational feasibility for the extensive automated model search and subsequent SHAP analysis, a subset of 50,000 samples was extracted from the cleaned dataset (n = 10,159,876) using stratified random sampling. This sampling approach was chosen to prioritize model stability, as our analysis showed that training on the full dataset produced unstable, high-variance results and required computationally prohibitive runtimes (Fig. S1). To rigorously evaluate the stability and robustness of our findings against sampling variability, this entire sampling process was repeated five times using different random seeds (42, 123, 777, 1024, and 2048).

This sampling methodology not only preserved the proportional distribution of the water quality classes (Fig. 1b) but also maintained a broadly consistent distribution across the major river basins. As detailed in Table S2, the proportional representation of each basin in the sampled subsets shows strong alignment with the full dataset, exhibiting only minor deviations, thereby confirming that the sampling process did not introduce significant regional bias. For the regional analysis, the same stratified sampling approach was applied to each major basin separately. Spearman correlation analysis was performed on the stratified dataset, and indicated no significant relationships among the selected water quality indicators (Fig. 1c), thus eliminating the need for removal of multicollinearity features.

2.2. Model development and validation strategies

For model inputs, all nine water quality indicators (WT, pH, DO, EC, COD_{Mn}, NH₃-N, TP, TN, and NTU) were used as input features, with water quality classes (I-WV) as the output target. To rigorously evaluate model performance and stability, three distinct validation schemes were

chi phí vận hành và tình trạng gián đoạn dữ liệu thường xuyên (Durgun, 2024). Là hệ quả trực tiếp của những hạn chế về vận hành và tài chính này, mạng lưới giám sát trực tuyến quốc gia của Trung Quốc tập trung một cách thực tế vào một nhóm cốt lõi gồm các chỉ số khả thi hơn, thay vì toàn bộ 24 chỉ số. Thực tế này cho thấy nhu cầu cần thiết phải xác định những chỉ số quan trọng nhất ngay cả trong nhóm đã được thu hẹp này, nhằm nâng cao hơn nữa hiệu quả và tính kinh tế của hoạt động giám sát (Othman et al., 2020; Wu et al., 2023).

Các phương pháp thống kê truyền thống, chẳng hạn như phân tích thành phần chính và phân tích tương quan Pearson, đã được sử dụng rộng rãi để lựa chọn các chỉ tiêu chất lượng nước (Tripathi và Singal, 2019; Uddin và cộng sự, 2021; Asadollah và cộng sự, 2021). Cùng với sự phát triển của trí tuệ nhân tạo, các phương pháp học máy (ML) đã cho thấy năng lực vượt trội trong việc xử lý các mối quan hệ phi tuyến phức tạp khi dự đoán chất lượng nước và lựa chọn các chỉ tiêu then chốt (Zhu và cộng sự, 2022; Ding và cộng sự, 2023; Zhang và cộng sự, 2024). Tuy nhiên, việc phát triển một hệ thống dự đoán tối ưu và mạnh mẽ bằng ML đặt ra những thách thức đáng kể. Quy trình này bao gồm một quy trình làm việc phức tạp, nhiều giai đoạn, trong đó có việc lựa chọn một cách có hệ thống thuật toán phù hợp nhất, thực hiện kỹ thuật đặc trưng vững chắc và tiến hành tối ưu hóa siêu tham số (HPO) nghiêm ngặt, đòi hỏi nhiều tài nguyên tính toán. Mặc dù một mô hình đơn lẻ có thể hoạt động hiệu quả với các tham số mặc định, quy trình HPO—đánh giá có hệ thống hàng trăm hoặc hàng nghìn cấu hình để tối đa hóa độ chính xác dự đoán—thường đòi hỏi chi phí tính toán quá lớn, cần nhiều tài nguyên và chuyên môn chuyên biệt (Peng và cộng sự, 2022; Xia và Zeng, 2022; Li và cộng sự, 2024). Để giải quyết những thách thức cụ thể trong quy trình làm việc này, học máy tự động (AutoML) đã nổi lên như một phương pháp mạnh mẽ. AutoML được thiết kế để tự động hóa toàn bộ quy trình đầu cuối, từ tiền xử lý dữ liệu và lựa chọn đặc trưng đến lựa chọn mô hình và HPO, qua đó giảm đáng kể nhu cầu về chuyên môn chuyên ngành cũng như việc giám sát tính toán (Zöller và Huber, 2021). Một số phương pháp AutoML đã được phát triển, chẳng hạn như TPOT, H2O và Auto-sklearn (Feurer và cộng sự, 2015; Olson và cộng sự, 2016; LeDell và Poirier, 2020). Trong số đó, Auto-sklearn đã chứng minh hiệu suất vượt trội trong nhiều cuộc thi nhờ kết hợp tối ưu hóa Bayes, học *meta* và xây dựng mô hình tổ hợp. Ngay cả trong các thử thách được thiết kế riêng với tên gọi “Beat Auto-sklearn”, việc tinh chỉnh tham số thủ công của các nhà khoa học dữ liệu giàu kinh nghiệm cũng không thể vượt qua hiệu suất tối ưu hóa tự động của phương pháp này (Guyon và cộng sự, 2019).

Tuy nhiên, các quy trình lựa chọn mô hình và kết hợp mô hình tự động của AutoML làm gia tăng tính “hộp đen” của các mô hình, gây khó khăn cho việc hiểu và diễn giải quá trình ra quyết định của mô hình (Barredo Arrieta et al., 2020). Điều này đặc biệt quan trọng trong quản lý chất lượng nước, nơi các mô hình phải đồng thời duy trì độ chính xác dự báo và tính minh bạch trong quá trình ra quyết định. Phương pháp Kernel SHAP (SHapley Additive exPlanations) mang đến một giải pháp đầy hứa hẹn bằng cách kết hợp LIME (Local Interpretable Model-agnostic Explanations) với các giá trị Shapley để xây dựng một khuôn khổ diễn giải thống nhất. Thông qua việc quy thuộc độ chính xác dự đoán của đặc trưng dựa trên lý thuyết trò chơi hợp tác, SHAP đo lường hiệu quả mức đóng góp của các đặc trưng vào dự đoán của mô hình (Lundberg và Lee, 2017a; Russo et al., 2023). Mặc dù các giá trị SHAP cho thấy tiềm năng lớn, việc ứng dụng chúng trong sàng lọc chỉ số chất lượng nước vẫn chưa được nghiên cứu, đặc biệt là như một phương án thay thế cho các phương pháp lựa chọn “tập con tốt nhất” có chi phí tính toán quá cao. Các phương pháp vét cạn này kiểm tra mọi tổ hợp đặc trưng có thể để đảm bảo tìm được tập hợp tối ưu, nhưng chi phí tính toán tăng theo cấp số nhân, khiến chúng không khả thi với các tập đặc trưng lớn hơn (Chen et al., 2020).

Trong nghiên cứu này, chúng tôi phát triển một khung tự động và có khả năng diễn giải để phân loại chất lượng nước, sử dụng dữ liệu quan trắc từ Trung tâm Giám sát Môi trường Quốc gia Trung Quốc (CNEMC). Khung này phân loại chất lượng nước mặt thành hệ thống sáu cấp (Loại I-V và kém hơn Loại V), dựa trên chín chỉ tiêu cốt lõi được mạng lưới quan trắc trực tuyến quốc gia Trung Quốc giám sát một cách đáng tin cậy. Các mục tiêu cụ thể là: (i) đánh giá hiệu quả của Auto-sklearn so với các thuật toán học máy truyền thống và các phương pháp tổ hợp hiện đại thông qua các thước đo toàn diện (Precision, Recall, F1 có trọng số, F1 macro,

ma trận nhầm lẫn và các đường cong AUC-ROC); (ii) diễn giải mô hình tổ hợp Auto-sklearn bằng Kernel SHAP để định lượng mức độ đóng góp của các chỉ số vào dự đoán của mô hình; và (iii) xác định các chỉ số chất lượng nước then chốt nhằm tối ưu hóa các chương trình quan trắc. Thông qua phương pháp tích hợp này, chúng tôi hướng đến xây dựng một khuôn khổ tiết kiệm chi phí, có thể nâng cao công tác quản lý chất lượng nước và quy trình ra quyết định, đồng thời cải thiện độ tin cậy của việc đánh giá.

2. Vật liệu và phương pháp

2.1. Study area and water quality dataset

Dữ liệu về chất lượng nước mặt được thu thập từ CNEMC, bao phủ chín lưu vực sông lớn, gồm các sông Continental, Hai, Huai, Pearl, Song-Liao, Southeast, Southwest, Yangtze và Yellow. Dữ liệu được thu thập tại khoảng 1.900 điểm quan trắc từ tháng 1 năm 2021 đến tháng 6 năm 2024, với bước thời gian 4 giờ (Hình 1a). Hệ thống quan trắc trực tuyến quốc gia của CNEMC tập trung theo dõi thời gian thực một nhóm cốt lõi gồm 11 chỉ số khả thi. Tuy nhiên, sau khi đánh giá chất lượng dữ liệu, hai chỉ số trong số này [chlorophyll-a (Chl-a, mg/L) và mật độ tảo (tế bào/L)] đã bị loại khỏi nghiên cứu do thiếu dữ liệu nghiêm trọng (>70 %, Bảng S3). Vì vậy, phân tích cuối cùng được thực hiện trên chín chỉ số còn lại được quan trắc đáng tin cậy: nhiệt độ nước (WT, °C), pH, oxy hòa tan (DO, mg/L), độ dẫn điện (EC, µS/cm), nhu cầu oxy hóa học (COD_{Mn}, mg/L), nitơ amoni (NH₃-N, mg/L), tổng photpho (TP, mg/L), tổng nitơ (TN, mg/L) và độ đục (NTU).

Theo Tiêu chuẩn chất lượng môi trường nước mặt (MEEPRC, 2002), chất lượng nước được phân thành sáu cấp, từ tốt nhất đến kém nhất (I-WV). Phân loại này đóng vai trò là biến mục tiêu cho các mô hình học có giám sát của chúng tôi. Cấp phân loại cho mỗi bản ghi dữ liệu đã được CNEMC xác định trước dựa trên “phương pháp đánh giá đơn yếu tố”, trong đó cấp cuối cùng được ấn định dựa trên chỉ tiêu riêng lẻ có kết quả kém nhất so với các giới hạn tiêu chuẩn, như trình bày trong Bảng S1. Do đó, mục tiêu của chúng tôi là dự đoán phân loại chính thức này bằng cách sử dụng chín chỉ tiêu chất lượng nước đã chọn làm đặc trưng đầu vào.

Để đảm bảo tính khả thi về mặt tính toán cho quá trình tìm kiếm mô hình tự động trên diện rộng và phân tích SHAP tiếp theo, một tập con gồm 50.000 mẫu được trích xuất từ bộ dữ liệu đã làm sạch (n = 10.159.876) bằng phương pháp lấy mẫu ngẫu nhiên phân tầng. Phương pháp lấy mẫu này được lựa chọn nhằm ưu tiên tính ổn định của mô hình, vì phân tích của chúng tôi cho thấy việc huấn luyện trên toàn bộ bộ dữ liệu tạo ra các kết quả không ổn định, có phương sai cao và đòi hỏi thời gian tính toán quá lớn (Hình S1). Để đánh giá nghiêm ngặt tính ổn định và độ vững chắc của các phát hiện trước sự biến thiên do lấy mẫu, toàn bộ quy trình lấy mẫu này được lặp lại năm lần với các hạt giống ngẫu nhiên khác nhau (42, 123, 777, 1024 và 2048).

Phương pháp lấy mẫu này không chỉ bảo toàn phân bố tỷ lệ của các nhóm chất lượng nước (Hình 1b) mà còn duy trì phân bố tương đối nhất quán giữa các lưu vực sông chính. Như trình bày chi tiết trong Bảng S2, tỷ lệ đại diện của từng lưu vực trong các tập con được lấy mẫu tương đồng đáng kể với toàn bộ tập dữ liệu, chỉ có sai lệch nhỏ, qua đó xác nhận rằng quá trình lấy mẫu không gây ra sai lệch đáng kể giữa các vùng. Đối với phân tích khu vực, cùng phương pháp lấy mẫu phân tầng được áp dụng riêng cho từng lưu vực chính. Phân tích tương quan Spearman được thực hiện trên tập dữ liệu phân tầng và cho thấy không có mối quan hệ đáng kể nào giữa các chỉ số chất lượng nước được chọn (Hình 1c), do đó không cần loại bỏ các đặc trưng đa cộng tuyến.

2.2. Model development and validation strategies

Đối với đầu vào mô hình, cả chín chỉ tiêu chất lượng nước (WT, pH, DO, EC, COD_{Mn}, NH₃-N, TP, TN và NTU) đều được sử dụng làm đặc trưng đầu vào, với các cấp chất lượng nước (I-WV) làm mục tiêu đầu ra. Để đánh giá nghiêm ngặt hiệu suất và độ ổn định của mô hình, ba phương pháp xác thực riêng biệt đã được





Fig. 1. Study area and dataset: (a) distribution of water quality monitoring sites in the study area; (b) distribution of water quality classes before and after stratified sampling, a process repeated five times with unique random seeds; (c) Spearman correlation heatmap of water quality indicators.

employed.

i. Stratified random split: This was the baseline validation method. For each of the five runs, the 50,000-sample subset was randomly

partitioned into a training set (80 %, $n = 40,000$) and a test set (20 %, $n = 10,000$) while maintaining class proportions.

ii. Temporal hold-out validation: To assess the models' ability to perform on future, unseen data, the entire clean dataset ($n = 10,159,876$) was divided based on a timestamp of "2024-01-01



Hình 1. Khu vực nghiên cứu và bộ dữ liệu: (a) phân bố các trạm giám sát chất lượng nước trong khu vực nghiên cứu; (b) phân bố các cấp chất lượng nước trước và sau khi lấy mẫu phân tầng, quy trình được lặp lại năm lần với các giá trị hạt giống ngẫu nhiên khác nhau; (c) bản đồ nhiệt tương quan Spearman giữa các chỉ số chất lượng nước.

có việc làm.

i. Chia ngẫu nhiên phân tầng: Đây là phương pháp xác thực cơ sở. Trong mỗi lần chạy trong số năm lần chạy, tập hợp con gồm 50.000 mẫu được chọn ngẫu nhiên

được chia thành tập huấn luyện (80 %, $n = 40,000$) và tập kiểm tra (20 %, $n = 10,000$), đồng thời duy trì tỷ lệ các lớp. ii. Kiểm định giữ lại theo thời gian: Để đánh giá khả năng của các mô hình trong việc dự đoán trên dữ liệu tương lai chưa từng thấy, toàn bộ tập dữ liệu sạch ($n = 10,159,876$) được chia dựa trên mốc thời gian "2024-01-01





Fig. 2. Comparison of ML pipelines: (a) traditional ML pipeline requiring manual intervention at multiple stages; (b) AutoML pipeline utilizing Auto-sklearn framework, which automates the model development process through *meta*-learning, Bayesian optimization, and ensemble construction.



Hình 2 So sánh các quy trình ML: (a) quy trình ML truyền thống cần sự can thiệp thủ công ở nhiều giai đoạn; (b) quy trình AutoML sử dụng Auto-sklearn framework, tự động hóa quy trình phát triển mô hình thông qua học *meta*, tối ưu hóa Bayes và xây dựng mô hình tổ hợp.

00:00:00". The training set ($n = 40,000$) was then sampled exclusively from data recorded before this timestamp, while the test set ($n = 10,000$) was sampled from data recorded after this point. This process was also repeated five times using different random seeds.

- iii. Spatial hold-out validation: Finally, to evaluate geographic generalizability, a leave-one-basin-out validation was conducted. This process consisted of nine iterations where each major river basin was sequentially designated as the hold-out basin. For each iteration, a training set ($n = 40,000$) was sampled from the remaining eight basins, and a test set ($n = 10,000$) was sampled from the single hold-out basin.

Consequently, all quantitative performance metrics reported in this study are presented as the mean $\pm$ Standard Deviation (SD) across the respective runs or hold-out basins to ensure the robustness of our conclusions.

2.3. Traditional and automated machine learning

Traditional ML pipelines require substantial human intervention across multiple stages, including data preprocessing, feature engineering, model selection, and hyperparameter tuning (Fig. 2a). For traditional ML models, each input feature was standardized using Z-score normalization ($\mu = 0$, $\sigma = 1$) to ensure all variables had comparable scales, as illustrated in Fig. S2. And Gaussian process-based Bayesian optimization was employed for hyperparameter tuning in traditional ML approaches (Snoek et al., 2012).

In contrast, for AutoML implementation, raw data was used without any preprocessing, allowing the algorithm to automatically determine the optimal preprocessing methods (Fig. 2b). The Auto-sklearn (version 0.15.0) framework combines Bayesian optimization, meta-learning, and ensemble construction for AutoML pipeline selection (Feurer et al., 2015). This framework incorporates comprehensive ML tools, including classification algorithms, feature preprocessing methods, and data preprocessing techniques. No manual adjustments were made to the model selection process, with Auto-sklearn automatically defining the search space for hyperparameter optimization. For the accurate assessment of model performance, due to the highly imbalanced distribution of water quality classes in the dataset, both traditional ML and AutoML utilized 5-fold stratified cross-validation during model training (Fig. S3).

For comprehensive evaluation, Auto-sklearn was compared with both conventional ML models implemented through scikit-learn [Logistic Regression (LR), k-Nearest Neighbors (KNN), Decision Tree (DT), Random Forest (RF)] and state-of-the-art ensemble learning models [CatBoost (CatB), LightGBM (LGBM), XGBoost (XGB)]. All implementations were conducted using Python 3.8.13. Detailed information about traditional ML methods is provided in the Supplementary Materials (Text S1).

2.4. Model evaluation metrics

The predictive performance of the models was assessed through a comprehensive suite of multi-dimensional evaluation metrics. These metrics, including their mathematical formulas and detailed statistical interpretations, are summarized in Table S4. For this multi-class classification task, we employed key metrics such as Precision, Recall, and the Weighted F1, which effectively accounts for class imbalance. Additionally, confusion matrices were used for a visual breakdown of classification performance across all classes, while Receiver Operating Characteristic (ROC) curves and the corresponding Area Under the Curve (AUC) values were used to evaluate the overall discriminative ability of the models.

2.5. Explanation of Auto-sklearn

To interpret the ensemble model generated by Auto-sklearn, we employed the SHapley Additive exPlanations (SHAP) method, which calculates feature importance through game theory principles (Kuhn, 2020). In ML context, Shapley values measure the individual impact of each feature in the model, collectively contributing to the prediction. Various versions of SHAP have been developed by Lundberg and Lee, including DeepSHAP, Kernel SHAP, LinearSHAP, and TreeSHAP, each designed to approximate SHAP values for different types of ML models. A critical prerequisite for a meaningful SHAP analysis is the high predictive accuracy of the model being explained. The SHAP interpretation was therefore performed only after the high predictive performance of the Auto-sklearn ensemble had been established.

Auto-sklearn can produce heterogeneous ensembles of different algorithm types. Therefore, the model-agnostic Kernel SHAP was selected for interpretation, as it is well-suited for such ensembles and requires no model-specific adjustments. It approximates SHAP values through a weighted local regression that bridges Model-agnostic Explanations (LIME) methods with Shapley values from cooperative game theory (Lundberg and Lee, 2017b). The SHAP value ϕ_i for feature i is calculated as follows:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_x(S \cup \{i\}) - f_x(S)] \quad (1)$$

where $f_x(S)$ is defined as:

$$f_x(S) = E[f(x)|x_S] \quad (2)$$

where S represents the subset of features excluding feature i , F is the set of all features, M is the total number of features, and $f_x(S)$ represents the expected model prediction when only features in subset S are known. Kernel SHAP approximates these values by sampling feature coalitions and computing model predictions, making it particularly suitable for ensemble models where direct interpretation of model internals is challenging (Moradi and Samwald, 2021).

3. Results

3.1. Runtime optimization and ensemble configuration of Auto-sklearn for water quality classification

To optimize performance of Auto-sklearn for water quality classification, the impact of different training durations ranging from 0.5 to 12 h was investigated while maintaining a constant data partitioning ratio of 0.8 (training dataset = 40,000, testing dataset = 10,000). Fig. 3 presents the trend of Weighted F1 and relative improvements across different runtime periods. The Weighted F1 was chosen as the primary evaluation metric because it provides a balanced assessment of model performance by combining both Precision and Recall, being particularly suitable for evaluating the overall effectiveness of the model (detailed results for Precision and Recall are provided in Table S5). The Weighted F1 exhibited a substantial and statistically significant improvement during the initial 4 h of training, increasing from 0.9537 ± 0.0002 (0.5 h) to 0.9627 ± 0.0002 (4 h). A one-way ANOVA followed by Tukey's post-hoc test confirmed that the performance at 0.5 h, 1 h, 2 h, and 4 h were all significantly different from each other ($p < 0.05$). The high baseline performance reflects the strong, inherent relationship between the input indicators and the target classes, which are determined by these same indicators according to the national standard (Section 2.1).

With the increase in training time, a trend of diminishing returns was observed. Crucially, while the Weighted F1 increased to 0.9631 ± 0.0002 after 8 h, this improvement was not statistically significant compared to the 4-hour result ($p > 0.05$). The mean Weighted F1 increase dropped from 0.0040 (1–2 h) to 0.0029 (2–4 h), and further

00:00:00". Tập huấn luyện ($n = 40,000$) sau đó chỉ được lấy mẫu từ dữ liệu ghi nhận trước mốc thời gian này, trong khi tập kiểm tra ($n = 10,000$) được lấy mẫu từ dữ liệu ghi nhận sau thời điểm này. Quy trình này cũng được lặp lại năm lần với các giá trị khởi tạo ngẫu nhiên khác nhau.

- iii. Kiểm định giữ lại không gian: Cuối cùng, để đánh giá khả năng khái quát hóa về mặt địa lý, kiểm định lần lượt bỏ từng lưu vực đã được tiến hành. Quy trình này gồm chín vòng lặp, trong đó mỗi lưu vực sông lớn lần lượt được chỉ định làm lưu vực giữ lại. Ở mỗi vòng lặp, một tập huấn luyện ($n = 40,000$) được lấy mẫu từ tám lưu vực còn lại, và một tập kiểm tra ($n = 10,000$) được lấy mẫu từ lưu vực duy nhất được giữ lại.

Do đó, tất cả các chỉ số hiệu suất định lượng được báo cáo trong nghiên cứu này đều được trình bày dưới dạng giá trị trung bình $\pm$ Độ lệch chuẩn (SD) qua các lần chạy hoặc lưu vực kiểm định tương ứng, nhằm đảm bảo tính vững chắc của các kết luận.

2.3. Traditional and automated machine learning

Các quy trình ML truyền thống đòi hỏi sự can thiệp đáng kể của con người ở nhiều giai đoạn, bao gồm tiền xử lý dữ liệu, thiết kế đặc trưng, lựa chọn mô hình và tinh chỉnh siêu tham số (Hình 2a). Đối với các mô hình ML truyền thống, từng đặc trưng đầu vào được chuẩn hóa bằng chuẩn hóa điểm Z ($\mu = 0$, $\sigma = 1$) để đảm bảo tất cả các biến có thang đo tương đương, như minh họa trong Hình S2. Ngoài ra, tối ưu hóa Bayes dựa trên quá trình Gaussian được sử dụng để tinh chỉnh siêu tham số trong các phương pháp ML truyền thống (Snoek và cộng sự, 2012).

Ngược lại, đối với việc triển khai AutoML, dữ liệu thô được sử dụng mà không qua bất kỳ bước tiền xử lý nào, cho phép thuật toán tự động xác định các phương pháp tiền xử lý tối ưu (Hình 2b). Khung Auto-sklearn (phiên bản 0.15.0) kết hợp tối ưu hóa Bayes, học meta và xây dựng tổ hợp để lựa chọn quy trình AutoML (Feurer và cộng sự, 2015). Khung này tích hợp các công cụ ML toàn diện, bao gồm các thuật toán phân loại, phương pháp tiền xử lý đặc trưng và kỹ thuật tiền xử lý dữ liệu. Không có điều chỉnh thủ công nào được thực hiện đối với quá trình lựa chọn mô hình; Auto-sklearn tự động xác định không gian tìm kiếm để tối ưu hóa siêu tham số. Để đánh giá chính xác hiệu suất mô hình, do phân bố các lớp chất lượng nước trong bộ dữ liệu mất cân bằng nghiêm trọng, cả ML truyền thống và AutoML đều sử dụng kiểm định chéo phân tầng 5 phần trong quá trình huấn luyện mô hình (Hình S3).

Để đánh giá toàn diện, Auto-sklearn được so sánh với cả các mô hình học máy (ML) truyền thống được triển khai thông qua scikit-learn [Hồi quy Logistic (LR), k-Láng giềng gần nhất (KNN), Cây quyết định (DT), Rừng ngẫu nhiên (RF)] và các mô hình học tập tổ hợp tiên tiến nhất [CatBoost (CatB), LightGBM (LGBM), XGBoost (XGB)]. Tất cả các triển khai đều được thực hiện bằng Python 3.8.13. Thông tin chi tiết về các phương pháp ML truyền thống được trình bày trong Tài liệu bổ sung (Văn bản S1).

2.4. Model evaluation metrics

Hiệu suất dự đoán của các mô hình được đánh giá thông qua một bộ chỉ số đánh giá đa chiều toàn diện. Các chỉ số này, bao gồm công thức toán học và diễn giải thống kê chi tiết, được tóm tắt trong Bảng S4. Đối với tác vụ phân loại đa lớp này, chúng tôi sử dụng các chỉ số chính như Độ chính xác (Precision), Độ bao phủ (Recall) và F1 có trọng số (Weighted F1), vốn tính đến hiệu quả sự mất cân bằng giữa các lớp. Ngoài ra, ma trận nhầm lẫn được dùng để trực quan hóa hiệu suất phân loại trên tất cả các lớp, trong khi các đường cong Đặc tính hoạt động của bộ thu (ROC) và các giá trị Diện tích dưới đường cong (AUC) tương ứng được dùng để đánh giá khả năng phân biệt tổng thể của các mô hình.

2.5. Explanation of Auto-sklearn

Để diễn giải mô hình tổ hợp do Auto-sklearn tạo ra, chúng tôi sử dụng phương pháp SHapley Additive exPlanations (SHAP), phương pháp tính mức độ quan trọng của đặc trưng dựa trên các nguyên lý lý thuyết trò chơi (Kuhn, 2020). Trong bối cảnh học máy, các giá trị SHapley đo lường tác động riêng lẻ của từng đặc trưng trong mô hình, cùng nhau đóng góp vào dự đoán. Lundberg và Lee đã phát triển nhiều biến thể SHAP, bao gồm DeepSHAP, Kernel SHAP, LinearSHAP và TreeSHAP, mỗi biến thể được thiết kế để ước tính các giá trị SHAP cho những loại mô hình học máy khác nhau. Một điều kiện tiên quyết quan trọng để phân tích SHAP có ý nghĩa là mô hình được giả i thích phải có độ chính xác dự đoán cao. Vì vậy, việc diễn giải bằng SHAP chỉ được thực hiện sau khi hiệu suất dự đoán cao của mô hình tổ hợp Auto-sklearn đã được xác lập.

Auto-sklearn có thể tạo ra các tổ hợp mô hình không đồng nhất gồm nhiều loại thuật toán khác nhau. Vì vậy, Kernel SHAP không phụ thuộc vào mô hình được chọn để diễn giải, vì phương pháp này rất phù hợp với các tổ hợp mô hình như vậy và không cần điều chỉnh riêng cho từng mô hình. Phương pháp này xấp xỉ các giá trị SHAP thông qua hồi quy cục bộ có trọng số, kết hợp các phương pháp Giải thích không phụ thuộc vào mô hình (LIME) với các giá trị Shapley trong lý thuyết trò chơi hợp tác (Lundberg và Lee, 2017b). Giá trị SHAP ϕ_i cho đặc trưng i được tính như sau:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_x(S \cup \{i\}) - f_x(S)] \quad (1)$$

trong đó $f_x(S)$ được định nghĩa như sau:

$$f_x(S) = E[f(x)|x_S] \quad (2)$$

trong đó S biểu thị tập con các đặc trưng không bao gồm đặc trưng i , F là tập hợp tất cả các đặc trưng, M là tổng số đặc trưng và $f_x(S)$ biểu thị giá trị dự đoán kỳ vọng của mô hình khi chỉ biết các đặc trưng trong tập con S . Kernel SHAP xấp xỉ các giá trị này bằng cách lấy mẫu các liên minh đặc trưng và tính toán các dự đoán mô hình, khiến phương pháp này đặc biệt phù hợp với các mô hình tổ hợp, vốn khó diễn giải trực tiếp cấu trúc bên trong của mô hình (Moradi và Samwald, 2021).

3. Kết quả

3.1. Runtime optimization and ensemble configuration of Auto-sklearn for water quality classification

Để tối ưu hóa hiệu năng của Auto-sklearn trong phân loại chất lượng nước, nghiên cứu này đã khảo sát ảnh hưởng của các thời lượng huấn luyện khác nhau, từ 0.5 đến 12 h, trong khi duy trì tỷ lệ phân chia dữ liệu cố định ở mức 0.8 (tập dữ liệu huấn luyện = 40,000, tập dữ liệu kiểm tra = 10,000). Hình 3 trình bày xu hướng của F1 có trọng số và mức cải thiện tương đối theo các khoảng thời gian chạy khác nhau. F1 có trọng số được chọn làm thước đo đánh giá chính vì chỉ số này đánh giá cân bằng hiệu năng mô hình bằng cách kết hợp cả Precision và Recall, đặc biệt phù hợp để đánh giá hiệu quả tổng thể của mô hình (kết quả chi tiết về Precision và Recall được trình bày trong Bảng S5). F1 có trọng số cho thấy mức cải thiện đáng kể và có ý nghĩa thống kê trong 4 h huấn luyện đầu tiên, tăng từ 0.9537 ± 0.0002 (0.5 h) lên 0.9627 ± 0.0002 (4 h). Phân tích ANOVA một yếu tố, tiếp theo là kiểm định hậu nghiệm Tukey, xác nhận rằng hiệu năng tại các mốc 0.5 h, 1 h, 2 h và 4 h đều khác biệt có ý nghĩa thống kê với nhau ($p < 0.05$). Hiệu năng cơ sở cao phản ánh mối quan hệ vốn có chặt chẽ giữa các chỉ báo đầu vào và các lớp mục tiêu, vốn được xác định dựa trên chính những chỉ báo này theo tiêu chuẩn quốc gia (Mục 2.1).

Khi thời gian huấn luyện tăng lên, xu hướng lợi ích giảm dần đã được ghi nhận. Đáng chú ý, mặc dù Weighted F1 tăng lên 0.9631 ± 0.0002 sau 8 giờ, mức cải thiện này không có ý nghĩa thống kê so với kết quả sau 4 giờ ($p > 0.05$). Mức tăng trung bình của Weighted F1 giảm từ 0.0040 (1–2 giờ) xuống 0.0029 (2–4 giờ), và tiếp tục####
+




Fig. 3. Performance improvement of Auto-sklearn in water quality classification with different training runtimes. The red line shows the Weighted F1, and the blue bars indicate the mean increase compared to the previous time point. Different letters denote statistically significant differences among the runtimes (Tukey’s HSD, $p < 0.05$). (For interpretation of the references to colour in this figure legend, the reader is referred to the web version of this article.)

decreased to just 0.0004 for the 4–8 h interval. Although a further significant improvement was noted at 12 h, the marginal gain was minimal relative to the extensive additional computation time. Therefore, based on these results, the 4-hour training period was selected as the optimal parameter for subsequent studies, as it strikes an effective balance between model performance and computational cost.

Through automated model selection and optimization, Auto-sklearn generated a final ensemble model consisting of 7 ML pipelines. The detailed configurations of this ensemble are now provided in the [Supplementary Materials](#) (Table S6). In summary, the automated process consistently selected RF as the optimal classifier across all pipelines, applying various data preprocessing and distribution-based balancing strategies to optimize performance. This strong preference for RF classifiers suggests that tree-based ensemble methods with moderate complexity are particularly effective for this water quality classification task.

3.2. Water quality classification performance and generalization

3.2.1. Comparative performance of models

The performance of Auto-sklearn was comprehensively evaluated against seven machine learning models. Based on five independent runs using a stratified random split, a Tukey’s HSD statistical test ($p < 0.05$) grouped the models into distinct performance tiers. As shown in [Table 1](#), Auto-sklearn, RF, and CatB constituted the top tier, with no statistically significant performance difference among them. Within this top group, however, Auto-sklearn consistently achieved the highest mean scores

Table 1
Benchmarking results for water quality classification models, presented as mean $\pm$ SD.

	Precision	Recall	Weighted F1
Auto-sklearn	0.9636 $\pm$ 0.0027 ^a	0.9635 $\pm$ 0.0027 ^a	0.9633 $\pm$ 0.0027 ^a
RF	0.9612 $\pm$ 0.0028 ^a	0.9610 $\pm$ 0.0029 ^a	0.9607 $\pm$ 0.0029 ^a
CatB	0.9597 $\pm$ 0.0027 ^{ab}	0.9599 $\pm$ 0.0026 ^a	0.9596 $\pm$ 0.0027 ^a
DT	0.9571 $\pm$ 0.0024 ^{bc}	0.9570 $\pm$ 0.0024 ^b	0.9566 $\pm$ 0.0024 ^b
LGBM	0.9560 $\pm$ 0.0034 ^c	0.9564 $\pm$ 0.0034 ^b	0.9560 $\pm$ 0.0035 ^b
XGB	0.9546 $\pm$ 0.0030 ^c	0.9549 $\pm$ 0.0031 ^b	0.9545 $\pm$ 0.0030 ^b
KNN	0.8509 $\pm$ 0.0023 ^d	0.8523 $\pm$ 0.0023 ^c	0.8492 $\pm$ 0.0023 ^c
LR	0.6503 $\pm$ 0.0025 ^e	0.6787 $\pm$ 0.0023 ^d	0.6457 $\pm$ 0.0026 ^d

Note: For each column, different letters in superscript indicate a statistically significant difference between models (Tukey’s HSD, $p < 0.05$).

across all evaluation metrics, with a precision of 0.9636 ± 0.0027 , recall of 0.9635 ± 0.0027 , and a weighted F1-score of 0.9633 ± 0.0027 . A detailed, per-class analysis presented in [Table S7](#) further underscores this leading performance, showing that Auto-sklearn also attained the highest Macro F1-score. The remaining models were grouped into subsequent performance tiers, with KNN and LR performing significantly poorer than all other methods.

The classification performance is further detailed in the confusion matrices ([Fig. 4](#)). Among the evaluated models, Auto-sklearn ([Fig. 4a](#)) emerged as the top-performing solution, demonstrating exceptional and well-balanced accuracy across all water quality classes. It achieved near-perfect scores for Class I (99.1 %) and Class II (98.4 %) and maintained high accuracy on the ambiguous intermediate classes: 96.1 % for Class III, 91.0 % for Class IV, and 84.4 % for Class V. This capability starkly contrasts with traditional models like LR ([Fig. 4d](#)), whose accuracy collapsed to just 53.3 % for Class III, 30.8 % for Class IV, and even 0 % for Class V, highlighting the severe limitations of linear models. The confusion matrices for other models are presented in [Fig. S4](#).

The Receiver Operating Characteristic (ROC) curves and corresponding Area Under the Curve (AUC) values in [Fig. 5](#) further validate the models’ discriminative ability. Auto-sklearn ([Fig. 5a](#)) achieved the highest macro-average AUC (MA-AUC) of 0.9963, followed closely by other top-tier models like RF (MA-AUC = 0.9961) and CatB (MA-AUC = 0.9960). In contrast, LR ([Fig. 5d](#)) was substantially weaker with a MA-AUC of 0.9027, showing particular difficulty with Class III (AUC = 0.8257) and Class IV (AUC = 0.8762). Additional ROC analyses for the remaining models are available in [Fig. S5](#).

This comprehensive comparison underscores the ability of the Auto-sklearn framework to automatically construct a model that achieves superior water quality classification performance.

3.2.2. Generalization assessment with temporal and spatial validation


To more rigorously assess model robustness and address potential data leakage from simple random splits, two additional validation schemes were implemented: a temporal hold-out (training on data before Jan 1, 2024, and testing on data after) and a spatial hold-out (leave-one-basin-out cross-validation). The results are summarized in [Table 2](#).

The temporal validation results demonstrate the model’s robust classification performance, which remains stable across different time periods. The performance of models remained remarkably stable, with no statistically significant drop in the Weighted F1-score when predicting on future, unseen data. This indicates that the models effectively learned underlying patterns that are consistent over time.

The spatial validation provided critical insights into the geographic generalizability of models. While the average performance across the basin-level cross-validation remained high, the standard deviation increased significantly—for Auto-sklearn, from 0.0027 in the random split to 0.0154. This high variance is strong quantitative evidence of underlying regional heterogeneity, indicating that the model’s performance, while strong overall, varies across basins with distinct characteristics ([Table S8](#)). Crucially, despite this performance variability, the relative ranking of the models remained consistent. This stability in relative performance confirms that the Auto-sklearn framework is a robust and reliable choice for nationwide water quality classification.

3.3. Screening of key water quality indicators based on SHAP importance ranking

To interpret the decision-making process of the Auto-sklearn model, a SHAP analysis was performed on the single representative run (selected based on its Weighted F1 being closest to the five-run average). The analysis quantified the impact of each water quality indicator on class predictions, with each point in [Fig. 6](#) representing a Shapley value where color indicates the relative magnitude of the indicator value. For Class I waters ([Fig. 6a](#)), pH demonstrated the highest importance,



Hình 3. Mức cải thiện hiệu năng của Auto-sklearn trong phân loại chất lượng nước với các thời lượng huấn luyện khác nhau. Đường màu đỏ biểu thị F1 có trọng số, còn các cột màu xanh biểu thị mức tăng trung bình so với thời điểm trước đó. Các chữ cái khác nhau biểu thị sự khác biệt có ý nghĩa thống kê giữa các thời lượng huấn luyện (kiểm định HSD của Tukey, $p < 0.05$). (Để diễn giải các tham chiếu đến màu sắc trong chú giải hình này, độc giả vui lòng xem phiên bản trực tuyến của bài viết.)

giảm xuống chỉ còn 0.0004 trong khoảng thời gian 4–8 giờ. Mặc dù ghi nhận mức cải thiện đáng kể hơn tại thời điểm 12 giờ, lợi ích tăng thêm rất nhỏ so với thời gian tính toán bổ sung đáng kể. Do đó, dựa trên các kết quả này, thời gian huấn luyện 4 giờ được chọn làm tham số tối ưu cho các nghiên cứu tiếp theo, vì nó tạo ra sự cân bằng giữa hiệu quả hiệu suất mô hình và chi phí tính toán.

Thông qua quá trình lựa chọn và tối ưu hóa mô hình tự động, Auto-sklearn đã tạo ra một mô hình tổ hợp cuối cùng gồm 7 quy trình ML. Các cấu hình chi tiết của mô hình tổ hợp này được trình bày trong Tài liệu bổ sung (Bảng S6). Tóm lại, quy trình tự động luôn chọn RF làm bộ phân loại tối ưu trong tất cả các quy trình, đồng thời áp dụng nhiều chiến lược tiền xử lý dữ liệu và cân bằng dựa trên phân phối để tối ưu hóa hiệu năng. Sự ưu tiên rõ rệt dành cho các bộ phân loại RF cho thấy các phương pháp tổ hợp dựa trên cây có độ phức tạp vừa phải đặc biệt hiệu quả đối với nhiệm vụ phân loại chất lượng nước này.

3.2. Water quality classification performance and generalization

3.2.1. Comparative performance of models

Hiệu suất của Auto-sklearn được đánh giá toàn diện và so sánh với bảy mô hình học máy. Dựa trên năm lần chạy độc lập sử dụng phép chia ngẫu nhiên có phân tầng, kiểm định thống kê HSD của Tukey ($p < 0.05$) đã phân nhóm các mô hình thành những bậc hiệu suất riêng biệt. Như trình bày trong Bảng 1, Auto-sklearn, RF và CatB thuộc nhóm dẫn đầu, không có sự khác biệt có ý nghĩa thống kê về hiệu suất giữa chúng. Tuy nhiên, trong nhóm dẫn đầu này, Auto-sklearn luôn đạt điểm trung bình cao nhất.

Bảng 1 Kết quả đánh giá các mô hình phân loại chất lượng nước, được trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn.

	Precision	Recall	Weighted F1
Auto-sklearn	0.9636 $\pm$ 0.0027 ^a	0.9635 $\pm$ 0.0027 ^a	0.9633 $\pm$ 0.0027 ^a
RF	0.9612 $\pm$ 0.0028 ^a	0.9610 $\pm$ 0.0029 ^a	0.9607 $\pm$ 0.0029 ^a
CatB	0.9597 $\pm$ 0.0027 ^{ab}	0.9599 $\pm$ 0.0026 ^a	0.9596 $\pm$ 0.0027 ^a
DT	0.9571 $\pm$ 0.0024 ^{bc}	0.9570 $\pm$ 0.0024 ^b	0.9566 $\pm$ 0.0024 ^b
LGBM	0.9560 $\pm$ 0.0034 ^c	0.9564 $\pm$ 0.0034 ^b	0.9560 $\pm$ 0.0035 ^b
XGB	0.9546 $\pm$ 0.0030 ^c	0.9549 $\pm$ 0.0031 ^b	0.9545 $\pm$ 0.0030 ^b
KNN	0.8509 $\pm$ 0.0023 ^d	0.8523 $\pm$ 0.0023 ^c	0.8492 $\pm$ 0.0023 ^c
LR	0.6503 $\pm$ 0.0025 ^e	0.6787 $\pm$ 0.0023 ^d	0.6457 $\pm$ 0.0026 ^d

Lưu ý: Đối với mỗi cột, các chữ cái khác nhau ở dạng chỉ số trên cho biết sự khác biệt có ý nghĩa thống kê giữa các mô hình (phép kiểm định HSD của Tukey, $p < 0,05$).

trên tất cả các chỉ số đánh giá, với độ chính xác 0.9636 ± 0.0027 , độ thu hồi 0.9635 ± 0.0027 và điểm F1 có trọng số 0.9633 ± 0.0027 . Phân tích chi tiết theo từng lớp được trình bày trong Bảng S7 càng khẳng định hiệu suất dẫn đầu này, cho thấy Auto-sklearn cũng đạt điểm F1 Macro cao nhất. Các mô hình còn lại được xếp vào những nhóm hiệu suất tiếp theo, trong đó KNN và LR hoạt động kém hơn đáng kể so với tất cả các phương pháp khác.

Hiệu suất phân loại được trình bày chi tiết hơn trong các ma trận nhầm lẫn (Hình 4). Trong số các mô hình được đánh giá, Auto-sklearn (Hình 4a) là giải pháp có hiệu suất cao nhất, cho thấy độ chính xác vượt trội và cân bằng tốt trên tất cả các lớp chất lượng nước. Mô hình đạt điểm số gần như hoàn hảo ở Lớp I (99.1 %) và Lớp II (98.4 %), đồng thời duy trì độ chính xác cao ở các lớp trung gian khó phân biệt: 96.1 % ở Lớp III, 91.0 % ở Lớp IV và 84.4 % ở Lớp V. Năng lực này tương phản rõ rệt với các mô hình truyền thống như LR (Hình 4d), có độ chính xác giảm mạnh xuống chỉ còn 53.3 % ở Lớp III, 30.8 % ở Lớp IV và thậm chí 0 % ở Lớp V, qua đó làm nổi bật những hạn chế nghiêm trọng của các mô hình tuyến tính. Ma trận nhầm lẫn của các mô hình khác được trình bày trong Hình S4.

Các đường cong Đặc tính hoạt động của bộ thu (ROC) và các giá trị Diện tích dưới đường cong (AUC) tương ứng trong Hình 5 tiếp tục xác thực khả năng phân biệt của các mô hình. Auto-sklearn (Hình 5a) đạt AUC trung bình vĩ mô (MA-AUC) cao nhất, ở mức 0.9963, theo sát là các mô hình hàng đầu khác như RF (MA-AUC = 0.9961) và CatB (MA-AUC = 0.9960). Ngược lại, LR (Hình 5d) yếu hơn đáng kể với MA-AUC đạt 0.9027, đặc biệt gặp khó khăn với Lớp III (AUC = 0.8257) và Lớp IV (AUC = 0.8762). Các phân tích ROC bổ sung cho những mô hình còn lại được trình bày trong Hình S5.

So sánh toàn diện này nhấn mạnh khả năng của khuôn khổ Auto-sklearn trong việc tự động xây dựng một mô hình đạt hiệu suất phân loại chất lượng nước vượt trội.

3.2.2. Generalization assessment with temporal and spatial validation

Để đánh giá độ bền vững của mô hình một cách nghiêm ngặt hơn và xử lý nguy cơ rò rỉ dữ liệu từ phương pháp chia ngẫu nhiên đơn giản, hai phương pháp kiểm định bổ sung đã được triển khai: kiểm định giữ lại theo thời gian (huấn luyện trên dữ liệu trước ngày 1 tháng 1 năm 2024 và kiểm tra trên dữ liệu sau ngày này) và kiểm định giữ lại theo không gian (kiểm định chéo lần lượt loại bỏ từng lưu vực). Kết quả được tóm tắt trong Bảng 2.

Kết quả xác thực theo thời gian cho thấy hiệu suất phân loại mạnh mẽ của mô hình, duy trì ổn định qua các giai đoạn khác nhau. Hiệu suất của các mô hình vẫn ổn định đáng kể, không có sự sụt giảm có ý nghĩa thống kê nào về điểm F1 có trọng số khi dự đoán trên dữ liệu tương lai chưa từng thấy. Điều này cho thấy các mô hình đã học hiệu quả những mẫu hình nền tảng quan trọng theo thời gian.

Đánh giá không gian đã cung cấp những thông tin quan trọng về khả năng khái quát hóa theo địa lý của các mô hình. Mặc dù hiệu suất trung bình trong kiểm định chéo ở cấp lưu vực vẫn cao, độ lệch chuẩn đã tăng đáng kể—for Auto-sklearn, từ 0.0027 ở phép chia ngẫu nhiên lên 0.0154. Mức phương sai cao này là bằng chứng định lượng rõ rệt về tính không đồng nhất tiềm ẩn giữa các vùng, cho thấy hiệu suất của mô hình, dù nhìn chung tốt, vẫn khác nhau giữa các lưu vực có đặc điểm riêng biệt (Bảng S8). Điều quan trọng là, bất chấp sự biến động về hiệu suất này, thứ hạng tương đối của các mô hình vẫn nhất quán. Sự ổn định về hiệu suất tương đối này khẳng định khung Auto-sklearn là một lựa chọn vững chắc và đáng tin cậy để phân loại chất lượng nước trên phạm vi toàn quốc.

3.3. Screening of key water quality indicators based on SHAP importance ranking

Để diễn giải quá trình ra quyết định của mô hình Auto-sklearn, phân tích SHAP được thực hiện trên một lần chạy đại diện duy nhất (được chọn dựa trên chỉ số F1 có trọng số gần nhất với mức trung bình của năm lần chạy). Phân tích định lượng tác động của từng chỉ số chất lượng nước đến các dự đoán lớp; mỗi điểm trong Hình 6 biểu thị một giá trị Shapley, trong đó màu sắc cho biết độ lớn tương đối của giá trị chỉ số. Đối với nước Loại I (Hình 6a), pH có mức độ quan trọng cao nhất,





Fig. 4. Comparison of confusion matrices for water quality classification using different ML models: (a) Auto-sklearn, (b) XGB, (c) RF, and (d) LR. The results shown are from a representative run for each model.



Hình 4. So sánh các ma trận nhầm lẫn trong phân loại chất lượng nước bằng các mô hình ML khác nhau: (a) Auto-sklearn, (b) XGB, (c) RF và (d) LR. Các kết quả được trình bày là từ một lần chạy đại diện cho mỗi mô hình.



Fig. 5. ROC curves and AUC values for different water quality classification algorithms: (a) AutoML, (b) XGB, (c) RF, and (d) LR. Both the plotted curves and the corresponding AUC values are from a representative run for each model.

Hình 5. Đường cong ROC và giá trị AUC của các thuật toán phân loại chất lượng nước khác nhau: (a) AutoML, (b) XGB, (c) RF và (d) LR. Cả các đường cong được biểu diễn và các giá trị AUC tương ứng được lấy từ một lần chạy đại diện cho mỗi mô hình.

Table 2
Model performance (Weighted F1, Mean $\pm$ SD) across different validation strategies.

Model	Random split validation	Temporal validation	Spatial validation
Auto-sklearn	0.9633 $\pm$ 0.0027	0.9627 $\pm$ 0.0005	0.9675 $\pm$ 0.0154
RF	0.9607 $\pm$ 0.0029	0.9612 $\pm$ 0.0018	0.9670 $\pm$ 0.0157
CatB	0.9596 $\pm$ 0.0027	0.9595 $\pm$ 0.0004	0.9620 $\pm$ 0.0155
DT	0.9566 $\pm$ 0.0024	0.9572 $\pm$ 0.0026	0.9640 $\pm$ 0.0160
LGBM	0.9560 $\pm$ 0.0035	0.9563 $\pm$ 0.0011	0.9577 $\pm$ 0.0146
XGB	0.9545 $\pm$ 0.0030	0.9533 $\pm$ 0.0006	0.9544 $\pm$ 0.0148
KNN	0.8492 $\pm$ 0.0023	0.8453 $\pm$ 0.0036	0.8337 $\pm$ 0.0138
LR	0.6457 $\pm$ 0.0026	0.6427 $\pm$ 0.0031	0.6453 $\pm$ 0.0610

followed by DO and TP, where higher pH values (red points) significantly contributed to Class I classification. In Class II (Fig. 6b), TP emerged as the dominant indicator, with COD_{Mn} and NH₃-N showing secondary importance.

For intermediate classes (III and IV), COD_{Mn} exhibited the strongest influence, with notably negative SHAP values for high indicator concentrations (Figs. 6c, d). The impact of TP and DO are showed varying patterns between these classes, suggesting their role in fine-tuning classification decisions. Class V and WV predictions (Figs. 6e, f) were primarily driven by COD_{Mn}, DO, and TP, with their extreme values being particularly indicative of degraded water quality. Across all classes, TP, COD_{Mn}, and DO consistently demonstrate high importance, while indicators such as WT, NTU, and EC showed relatively minor contributions to the classification decisions. These SHAP importance rankings align

logically with the single-factor classification standard (Table S1). The SHAP analysis effectively quantifies which indicators most frequently serve as the “limiting factor” in the official classification rule. For instance, the high importance of COD_{Mn} for predicting poorer water quality classes (e.g., Class V, WV) is expected. This finding aligns perfectly with the national standard (Table S1), in which high COD_{Mn} values are a key condition that defines these poor water quality classifications.

A comprehensive importance ranking of the water quality indicators was established (Fig. 7a). This was achieved by first calculating the mean absolute SHAP values for each indicator within each of the five independent runs. These values were then normalized within each run to sum to one. The final importance scores shown are the average of these five normalized values. A one-way ANOVA with Tukey’s post-hoc test was performed on these final scores to assess statistical significance ($p < 0.05$). As denoted by the letters on the chart, the analysis identified COD_{Mn} and TP as the most influential indicators; their importances were not statistically different from each other but were significantly greater than all other indicators. DO ranked third, representing the next distinct level of statistical importance. A detailed visualization of the cumulative importance for each indicator, broken down by class, is provided in the supplementary materials (Fig. S6).

To screen for the key water quality indicators, we progressively incorporated them into the Auto-sklearn model according to the importance ranking. As shown in Fig. 7b, model performance (Weighted F1) improved rapidly, reaching 0.9205 ± 0.0097 with the top three indicators (COD_{Mn}, TP, and DO). Crucially, the addition of the fourth indicator (NH₃-N) did not yield a statistically significant improvement in model performance ($p > 0.05$), which is visually supported by the

Bảng 2 Hiệu suất mô hình (F1 có trọng số, trung bình $\pm$ độ lệch chuẩn) theo các chiến lược xác thực khác nhau.

Model	Random split validation	Temporal validation	Spatial validation
Auto-sklearn	0.9633 $\pm$ 0.0027	0.9627 $\pm$ 0.0005	0.9675 $\pm$ 0.0154
RF	0.9607 $\pm$ 0.0029	0.9612 $\pm$ 0.0018	0.9670 $\pm$ 0.0157
CatB	0.9596 $\pm$ 0.0027	0.9595 $\pm$ 0.0004	0.9620 $\pm$ 0.0155
DT	0.9566 $\pm$ 0.0024	0.9572 $\pm$ 0.0026	0.9640 $\pm$ 0.0160
LGBM	0.9560 $\pm$ 0.0035	0.9563 $\pm$ 0.0011	0.9577 $\pm$ 0.0146
XGB	0.9545 $\pm$ 0.0030	0.9533 $\pm$ 0.0006	0.9544 $\pm$ 0.0148
KNN	0.8492 $\pm$ 0.0023	0.8453 $\pm$ 0.0036	0.8337 $\pm$ 0.0138
LR	0.6457 $\pm$ 0.0026	0.6427 $\pm$ 0.0031	0.6453 $\pm$ 0.0610

tiếp theo là DO và TP, trong đó các giá trị pH cao hơn (điểm màu đỏ) đóng góp đáng kể vào việc phân loại Lớp I. Trong Lớp II (Hình 6b), TP nổi lên là chỉ báo chi phối, còn COD_{Mn} và NH₃-N có tầm quan trọng thứ yếu.

Đối với các lớp trung gian (III và IV), COD_{Mn} có ảnh hưởng mạnh nhất, với các giá trị SHAP âm đáng kể khi nồng độ chỉ thị cao (Hình 6c, d). Tác động của TP và DO cho thấy các xu hướng khác nhau giữa những lớp này, cho thấy vai trò của chúng trong việc tinh chỉnh các quyết định phân loại. Các dự đoán cho lớp V và WV (Hình 6e, f) chủ yếu chịu ảnh hưởng của COD_{Mn}, DO và TP, trong đó các giá trị cực đoan của chúng đặc biệt cho thấy chất lượng nước suy giảm. Ở tất cả các lớp, TP, COD_{Mn} và DO luôn thể hiện mức độ quan trọng cao, trong khi các chỉ thị như WT, NTU và EC đóng góp tương đối ít vào các quyết định phân loại. Các thứ hạng mức độ quan trọng SHAP này phù hợp

một cách logic với tiêu chuẩn phân loại theo yếu tố đơn lẻ (Bảng S1). Phân tích SHAP định lượng hiệu quả những chỉ số nào thường xuyên đóng vai trò là “yếu tố hạn chế” trong quy tắc phân loại chính thức. Chẳng hạn, tầm quan trọng cao của COD_{Mn} trong việc dự đoán các cấp chất lượng nước kém hơn (ví dụ: Cấp V, WV) là điều dễ hiểu. Phát hiện này hoàn toàn phù hợp với tiêu chuẩn quốc gia (Bảng S1), trong đó giá trị COD_{Mn} cao là điều kiện then chốt xác định các cấp phân loại chất lượng nước kém này.

Đã xây dựng bảng xếp hạng toàn diện về mức độ quan trọng của các chỉ số chất lượng nước (Hình 7a). Trước tiên, giá trị SHAP tuyệt đối trung bình của từng chỉ số được tính trong mỗi lần chạy độc lập trong số năm lần chạy. Sau đó, các giá trị này được chuẩn hóa trong từng lần chạy sao cho tổng bằng một. Điểm mức độ quan trọng cuối cùng được trình bày là giá trị trung bình của năm giá trị đã chuẩn hóa này. Phân tích phương sai một yếu tố (ANOVA) kèm kiểm định hậu nghiệm Tukey được thực hiện trên các điểm số cuối cùng này để đánh giá ý nghĩa thống kê ($p < 0,05$). Như thể hiện qua các chữ cái trên biểu đồ, phân tích xác định COD_{Mn} và TP là các chỉ số có ảnh hưởng lớn nhất; mức độ quan trọng của chúng không khác biệt có ý nghĩa thống kê với nhau nhưng cao hơn có ý nghĩa so với tất cả các chỉ số còn lại. DO xếp thứ ba, đại diện cho cấp độ quan trọng thứ ba kế tiếp theo. Hình minh họa chi tiết về mức độ quan trọng tích lũy của từng chỉ số, phân tách theo lớp, được cung cấp trong tài liệu bổ sung (Hình S6).

Để sàng lọc các chỉ số chất lượng nước then chốt, chúng tôi lần lượt đưa chúng vào mô hình Auto-sklearn theo thứ hạng mức độ quan trọng. Như thể hiện trong Hình 7b, hiệu suất mô hình (F1 có trọng số) cải thiện nhanh chóng, đạt $0,9205 \pm 0,0097$ với ba chỉ số đứng đầu (COD_{Mn}, TP và DO). Điều quan trọng là việc bổ sung chỉ số thứ tư (NH₃-N) không cải thiện đáng kể về mặt thống kê hiệu suất mô hình ($p > 0,05$), điều này được minh họa trực quan bằng




Fig. 6. SHAP importance plots showing the contribution of different water quality indicators to each water quality classes prediction: (a) Class I, (b) Class II, (c) Class III, (d) Class IV, (e) Class V, and (f) Class WV. These plots were generated from the representative run of the Auto-sklearn model.

Hình 6. Các biểu đồ tầm quan trọng SHAP cho thấy mức độ đóng góp của các chỉ số chất lượng nước khác nhau vào dự đoán từng cấp chất lượng nước: (a) Cấp I, (b) Cấp II, (c) Cấp III, (d) Cấp IV, (e) Cấp V và (f) Cấp WV. Các biểu đồ này được tạo từ lần chạy đại diện của mô hình Auto-sklearn.




Fig. 7. Screening of key water quality indicators. (a) Overall indicator importance ranking showing the five-run mean of normalized SHAP values (where values within each run were normalized to sum to one). (b) Model performance evolution (Weighted F1, red line) and the incremental F1 increase (blue bars) as top-ranked indicators are sequentially added to the model. Different letters denote statistically significant differences (Tukey’s HSD, $p < 0.05$). (For interpretation of the references to colour in this figure legend, the reader is referred to the web version of this article.)

significance letters on the chart. The mean Weighted F1 increase, as shown by the blue bars, was most substantial for the second (0.1851) and third indicators (0.1305). This lack of significant improvement beyond the top three provides strong evidence that COD_{Mn}, TP, and DO can serve as a core set for efficient and cost-effective water quality monitoring at a national scale.

3.4. Regional variations in key water quality indicators across major basins

Building upon the identification of COD_{Mn}, TP, and DO as the key water quality indicators at the national scale, the SHAP analysis was extended to evaluate regional variations. To ensure the robustness of these regional findings, the analysis for each basin was performed using five independent model runs with different random seeds. The final importance scores, representing the mean of the five normalized SHAP values, are visualized in Fig. 8. The detailed results, including the mean and SD for each indicator in every basin, are available in the supplementary material (Table S9).

The results revealed a high degree of consistency across most of China. Specifically, seven of the nine major river basins—the


Continental, Hai, Huai, Pearl, Southeast, Southwest, and Yangtze River Basins—retained COD_{Mn}, TP, and DO as their three most critical indicators, mirroring the national-level analysis. This widespread agreement across diverse geographical regions further validates the fundamental significance of these three indicators in water quality assessment.

However, notable regional variations emerged in the two northern basins. In both the Song-Liao and the Yellow River Basins, NH₃-N replaced DO as one of the top three key indicators (Table S9). These findings highlight that while COD_{Mn}, TP, and DO form an effective national minimum indicator set, regional hydro-environmental characteristics may necessitate tailored monitoring approaches.

4. Discussion

4.1. Advantages of Auto-sklearn in water quality classification

In this study, Auto-sklearn demonstrated leading performance in water quality classification compared to traditional ML models, achieving the highest scores across multiple evaluation metrics (Table 1). Through automated model selection and optimization, Auto-



Hình 7. Sàng lọc các chỉ số chất lượng nước chính. (a) Xếp hạng mức độ quan trọng tổng thể của các chỉ số, thể hiện giá trị trung bình qua năm lần chạy của các giá trị SHAP đã chuẩn hóa (trong đó các giá trị trong mỗi lần chạy được chuẩn hóa để tổng bằng một). (b) Diễn biến hiệu suất mô hình (F1 có trọng số, đường màu đỏ) và mức tăng F1 gia tăng (các cột màu xanh) khi lần lượt thêm các chỉ số xếp hạng cao nhất vào mô hình. Các chữ cái khác nhau biểu thị sự khác biệt có ý nghĩa thống kê (Tukey’s HSD, $p < 0.05$). (Để diễn giải các tham chiếu đến màu sắc trong chú giải hình này, độc giả vui lòng xem phiên bản trực tuyến của bài viết.)

ý nghĩa của các chữ cái trên biểu đồ. Mức tăng F1 có trọng số trung bình, thể hiện bằng các cột màu xanh lam, lớn nhất ở chỉ báo thứ hai (0.1851) và thứ ba (0.1305). Việc không có cải thiện đáng kể ngoài ba chỉ báo hàng đầu là bằng chứng thuyết phục cho thấy COD_{Mn}, TP và DO có thể tạo thành một bộ chỉ báo cốt lõi để giám sát chất lượng nước hiệu quả và tiết kiệm chi phí trên phạm vi toàn quốc.

3.4. Regional variations in key water quality indicators across major basins

Dựa trên việc xác định COD_{Mn}, TP và DO là các chỉ tiêu chất lượng nước chủ chốt ở cấp quốc gia, phân tích SHAP được mở rộng để đánh giá sự khác biệt giữa các vùng. Để đảm bảo tính vững chắc của các kết quả theo vùng này, phân tích cho từng lưu vực được thực hiện qua năm lần chạy mô hình độc lập với các hạt giống ngẫu nhiên khác nhau. Điểm số mức độ quan trọng cuối cùng, biểu thị giá trị trung bình của năm giá trị SHAP đã chuẩn hóa, được minh họa trong Hình 8. Kết quả chi tiết, bao gồm giá trị trung bình và độ lệch chuẩn (SD) của từng chỉ tiêu trong mỗi lưu vực, được trình bày trong tài liệu bổ sung (Bảng S9).

Các kết quả cho thấy mức độ nhất quán cao trên hầu hết lãnh thổ Trung Quốc. Cụ thể, bảy trong số chín lưu vực sông lớn—

Các lưu vực Continental, Hai, Hoài, Châu Giang, Đông Nam, Tây Nam và Trường Giang đều giữ COD_{Mn}, TP và DO là ba chỉ tiêu quan trọng nhất, phù hợp với phân tích ở cấp quốc gia. Sự đồng thuận rộng rãi giữa các khu vực địa lý đa dạng này càng khẳng định ý nghĩa cốt lõi của ba chỉ tiêu trong đánh giá chất lượng nước.

Tuy nhiên, những khác biệt đáng kể giữa các vùng đã xuất hiện ở hai lưu vực phía Bắc. Tại cả lưu vực Tùng-Liêu và lưu vực Hoàng Hà, NH₃-N thay thế DO để trở thành một trong ba chỉ số then chốt hàng đầu (Bảng S9). Những phát hiện này cho thấy mặc dù COD_{Mn}, TP và DO tạo thành bộ chỉ số tối thiểu cấp quốc gia hiệu quả, các đặc điểm thủy văn-môi trường theo vùng có thể đòi hỏi những phương thức giám sát phù hợp riêng.

4. Thảo luận

4.1. Advantages of Auto-sklearn in water quality classification

Trong nghiên cứu này, Auto-sklearn cho thấy hiệu suất vượt trội trong phân loại chất lượng nước so với các mô hình ML truyền thống, đạt điểm số cao nhất ở nhiều chỉ số đánh giá (Bảng 1). Thông qua việc tự động lựa chọn và tối ưu hóa mô hình, Auto-





Fig. 8. Regional variations in key water quality indicators across major basins in China. The bubble size represents the relative importance of each indicator for water quality classification in different basins, quantified as the mean normalized SHAP value calculated from five independent runs.



Hình 8. Sự khác biệt theo vùng về các chỉ số chất lượng nước chính tại các lưu vực lớn ở Trung Quốc. Kích thước bong bóng biểu thị tầm quan trọng tương đối của từng phân loại chất lượng nước ở các lưu vực khác nhau, được định lượng bằng giá trị SHAP chuẩn hóa trung bình tính từ năm lần chạy độc lập.

sklearn successfully identified and combined complementary models into an ensemble of 7 ML pipelines (Table 1), automating the multi-stage manual workflow required by traditional ML approaches into an integrated process (Fig. 2). While we compared Auto-sklearn with various ML models both inside and outside the framework to validate its performance, it is important to note that conventional ML models theoretically cannot outperform AutoML since they are part of the model selection library of Auto-sklearn. This aligns with previous findings where even experienced data scientists could not surpass automated optimization of Auto-sklearn in specially designed challenge competitions (Guyon et al., 2019).

The performance improvement of Auto-sklearn over RF was relatively modest (Table 1), as RF was automatically selected as the optimal classifier across all seven ensemble pipelines (Table 1), which aligns with findings from previous studies in clinical diagnostic applications (Bifarin and Fernández, 2024). The consistent selection of RF validates the automated model search effectiveness of Auto-sklearn and indicates tree-based ensemble methods with moderate complexity work particularly well for classification tasks (Chan et al., 2023; Senocak et al., 2023).

All in all, AutoML frameworks such as Auto-sklearn are suggested to be employed directly for ML tasks in environmental monitoring instead of conducting extensive model screening and hyperparameter tuning. This approach not only ensures optimal model selection through automated processes but also saves considerable time typically spent on comparing various standalone algorithms. Although AutoML may require substantial computational resources, with the rapid advancement of computing infrastructure and increasing accessibility to high-performance computing resources, computational demands are becoming less of a constraint. The successful application in water quality classification demonstrated here provides a representative case for broader adoption of AutoML in environmental science research.

4.2. Rationality and practicality of key water quality indicators screening

4.2.1. A cost-effective nationwide indicator set

Water quality classification assessment traditionally relies on a comprehensive set of indicators, with national standards such as GB3838-2002 requiring monitoring of 24 fundamental indicators (MEEPRC, 2002). While this extensive monitoring approach ensures accuracy, it poses significant challenges in terms of cost and time efficiency (Sun et al., 2021). Our SHAP-based analysis identified COD_{Mn}, TP, and DO as the most influential indicators for water quality classification in China (Fig. 7a), offering a potential solution to this practical challenge.

The statistical effectiveness of this three-indicator set is robust. Our SHAP-based sequential analysis showed that these indicators alone could achieve a high Weighted F1 of 0.9205 ± 0.0097 , capturing the majority of information necessary for accurate classification. To validate this further, we compared the Auto-sklearn trained on these three indicators against a programmatic baseline applying the standard single-factor rule to the same limited set. As detailed in Table 3, the Auto-sklearn model achieved a statistically significantly higher Weighted F1-score (0.9205 ± 0.0097) compared to the rule-based baseline (0.8976 ± 0.0038). More importantly, the Auto-sklearn model demonstrated superior performance across all classes, most critically for Class WV, where it achieved an F1-score of 0.8285—a substantial 18.9 % relative improvement over the baseline’s 0.6968. This superiority stems from the Auto-sklearn’s ability to capture complex, non-linear interactions that the rigid rule inherently misses, confirming that the combination of our key indicators with an intelligent model provides a more accurate and practically valuable assessment, especially for managing the most polluted water bodies.

The identification of these key indicators provides a practical solution to the prohibitive costs associated with comprehensive water quality monitoring. By focusing on just three indicators (COD_{Mn}, TP, and

Table 3

Benchmarking of the Rule-Based Baseline against Auto-sklearn using the nationwide key indicator set (COD_{Mn}, TP, and DO), presented as mean $\pm$ SD.

	Rule-Based Baseline	Auto-sklearn
Precision	0.9030 ± 0.0036^a	0.9245 ± 0.0026^b
Recall	0.9017 ± 0.0037^a	0.9236 ± 0.0024^b
Weighted F1	0.8976 ± 0.0038^a	0.9205 ± 0.0156^b
Macro F1	0.8498 ± 0.0053^a	0.8885 ± 0.0078^b
Class I	0.9279 ± 0.0044^a	0.9447 ± 0.0025^b
Class II	0.9255 ± 0.0035^a	0.9429 ± 0.0026^b
Class III	0.8939 ± 0.0049^a	0.9142 ± 0.0052^b
Class IV	0.8645 ± 0.0091^a	0.8878 ± 0.0015^b
Class V	0.7902 ± 0.0182^a	0.8128 ± 0.0217^b
Class WV	0.6968 ± 0.0077^a	0.8285 ± 0.0097^b

Note: Different letters in superscript indicate a statistically significant difference between the Rule-Based Baseline and the 3-indicator Auto-sklearn model (Tukey’s HSD, $p < 0.05$).

DO), monitoring programs can achieve reliable assessment while reducing both capital investment for equipment and operational expenses for chemical analysis. This simplified approach is particularly valuable for developing regions with resource constraints, making systematic water quality monitoring more economically feasible and widely implementable.

4.2.2. Regional heterogeneity

While our reduced indicator set (COD_{Mn}, TP, and DO) performs well for general classification at the national scale, our regional analysis critically demonstrates that optimal indicator combinations vary in response to distinct, regional-scale anthropogenic pressures. As shown in Fig. 8 and Table S9, the Song-Liao and Yellow River Basins required a different key indicator set where NH₃-N replaced DO. This shift is a direct reflection of the region-specific pollution drivers.

The exceptional severity of nitrogen pollution in these basins is quantitatively supported. The Song-Liao River Basin, for instance, has a Net Anthropogenic Nitrogen Input estimated at a staggering 9453 kg N km⁻² yr⁻¹, a value noted to be higher than that of southern basins (Cao et al., 2025). Similarly, the Yellow River Basin is the most severe region for agricultural non-point source pollution in China, with its provinces contributing a disproportionately high 42.67 % of the entire nation’s agricultural TN emissions (Tan et al., 2025). This extreme loading means that raw pollutants, rich in NH₃-N, are the dominant feature of the pollution profile.

This immense pollution pressure is critically amplified by the region’s distinct hydrological conditions, which starkly contrast with other major basins. The northern basins are characterized by extremely low water availability. The annual average runoff of the Liaohe (36.7 km³) and Yellow (52.1 km³) rivers is an order of magnitude lower than that of the southern Yangtze and Pearl rivers, which both exceed 300 km³ (Gao et al., 2020). The Yellow River exemplifies this stress, irrigating 13 % of the nation’s cropland with only 3 % of its total river runoff (Ren et al., 2016). This “high load, low flow” dynamic means that the immense nitrogen inputs are concentrated in a minimal volume of water, leading to exceptionally high pollutant concentrations that are not seen in high-flow southern basins.

This comparative analysis confirms that the nitrogen pollution in the Song-Liao and Yellow River Basins is uniquely prominent. While southern basins like the Yangtze may have large total nitrogen loads, their vast dilution capacity mitigates the concentration and, thus, the immediate severity (Wang et al., 2020). In contrast, the combination of extreme nitrogen input intensity and severely limited dilution capacity in the Song-Liao and Yellow River Basins creates an environment where primary pollutants like NH₃-N are a more direct and sensitive signal of degradation than secondary ecosystem responses like DO. This evidence validates the findings of our model and underscores the necessity of basin-specific indicator sets for effective water quality management.

sklearn đã xác định và kết hợp thành công các mô hình hỗ trợ thành một tập hợp gồm 7 quy trình ML (Bảng 1), tự động hóa quy trình tích hợp nhiều giai đoạn cần thiết trong các phương pháp ML truyền thống thành một quy trình tích hợp (Hình 2). Mặc dù chúng tôi đã so sánh Auto-sklearn với nhiều mô hình ML cả bên trong lẫn bên ngoài khuôn khổ này để xác thực hiệu năng, cần lưu ý rằng về mặt lý thuyết, các mô hình ML thông thường không thể vượt trội hơn Auto ML vì chúng là một phần trong thư viện lựa chọn mô hình của Auto-sklearn. Điều này phù hợp với các phát hiện trước đây, theo đó ngay cả những nhà khoa học dữ liệu giàu kinh nghiệm cũng không thể vượt qua khả năng tối ưu hóa tự động của Auto-sklearn trong các cuộc thi thử thách được thiết kế đặc biệt (Guyon et al., 2019).

Mức cải thiện hiệu năng của Auto-sklearn so với RF tương đối khiêm tốn (Bảng 1), vì RF được tự động chọn làm bộ phân loại tối ưu trong cả bảy quy trình phân nhóm (Bảng 1), phù hợp với các phát hiện từ những nghiên cứu trước đây về ứng dụng chẩn đoán lâm sàng (Bifarin và Fernández, 2024). Việc RF luôn được lựa chọn xác nhận hiệu quả tìm kiếm mô hình tự động của Auto-sklearn và cho thấy các phương pháp tổ hợp dựa trên cây có độ phức tạp vừa phải đặc biệt phù hợp với các tác vụ phân loại (Chan và cộng sự, 2023; Senocak và cộng sự, 2023).

Nhìn chung, nên sử dụng trực tiếp các khung AutoML như Auto-sklearn cho các tác vụ học máy trong giám sát môi trường, thay vì tiến hành sàng lọc mô hình và tinh chỉnh siêu tham số trên diện rộng. Cách tiếp cận này không chỉ đảm bảo lựa chọn mô hình tối ưu thông qua các quy trình tự động mà còn tiết kiệm đáng kể thời gian thử nghiệm dành cho việc so sánh nhiều thuật toán độc lập. Mặc dù Auto ML có thể đòi hỏi nguồn lực tính toán đáng kể, nhưng với sự phát triển nhanh chóng của hạ tầng tính toán và khả năng tiếp cận ngày càng tăng với các tài nguyên tính toán hiệu năng cao, nhu cầu tính toán đang dần bớt trở thành một hạn chế. Ứng dụng thành công trong phân loại chất lượng nước được trình bày ở đây là một trường hợp tiêu biểu cho việc áp dụng AutoML rộng rãi hơn trong nghiên cứu khoa học môi trường.

4.2. Rationality and practicality of key water quality indicators screening

4.2.1. A cost-effective nationwide indicator set

Việc đánh giá phân loại chất lượng nước theo truyền thống dựa vào một bộ chỉ thị toàn diện, trong đó các tiêu chuẩn quốc gia như GB3838-2002 yêu cầu giám sát 24 chỉ tiêu cơ bản (MEEPRC, 2002). Mặc dù cách tiếp cận giám sát toàn diện này đảm bảo độ chính xác, nhưng lại đặt ra những thách thức đáng kể về chi phí và hiệu quả thời gian (Sun et al., 2021). Phân tích dựa trên SHAP của chúng tôi xác định COD_{Mn}, TP và DO là những chỉ tiêu có ảnh hưởng lớn nhất đến việc phân loại chất lượng nước tại Trung Quốc (Hình 7a), qua đó đưa ra một giải pháp tiềm năng cho thách thức thực tiễn này.

Hiệu quả thống kê của bộ ba chỉ báo này rất vững chắc. Phân tích tuần tự dựa trên SHAP của chúng tôi cho thấy chỉ riêng các chỉ báo này đã có thể đạt Weighted F1 cao, ở mức 0.9205 ± 0.0097 , nắm bắt phần lớn thông tin cần thiết để phân loại chính xác. Để kiểm chứng thêm, chúng tôi so sánh Auto-sklearn được huấn luyện trên bộ chỉ báo này với một mô hình cơ sở lập trình áp dụng quy tắc một yếu tố tiêu chuẩn trên cùng tập dữ liệu giới hạn. Như trình bày chi tiết trong Bảng 3, mô hình Auto-sklearn đạt điểm Weighted F1 cao hơn đáng kể so với mô hình cơ sở dựa trên quy tắc (0.8976 ± 0.0038). Quan trọng hơn, mô hình Auto-sklearn thể hiện hiệu suất vượt trội ở tất cả các lớp, đặc biệt là Lớp WV, với điểm m F1 đạt 0.8285—cao hơn đáng kể 18.9 % so với mức 0.6968 của mô hình cơ sở. Ưu thế này bắt nguồn từ khả năng nắm bắt các tương tác phức tạp, phi tuyến mà quy tắc cứng nhắc vốn bỏ sót của Auto-sklearn, qua đó khẳng định rằng việc kết hợp các chỉ báo cốt lõi của hệ thống với một mô hình thông minh mang lại đánh giá chính xác và có giá trị thực tiễn hơn, đặc biệt trong công tác quản lý các vùng nước ô nhiễm nghiêm trọng.

Việc xác định các chỉ số then chốt này đưa ra một giải pháp thiết thực cho chi phí quá cao liên quan đến việc giám sát toàn diện chất lượng nước. Bằng cách tập trung vào ba chỉ số (COD_{Mn}, TP và

Bảng 3 So sánh hiệu năng của mô hình cơ sở dựa trên quy tắc với Auto-sklearn bằng bộ chỉ số chính trên toàn quốc (COD_{Mn}, TP và DO), được trình bày dưới dạng giá trị trung bình $\pm$ độ lệch chuẩn (SD).

	Rule-Based Baseline	Auto-sklearn
Precision	0.9030 ± 0.0036^a	0.9245 ± 0.0026^b
Recall	0.9017 ± 0.0037^a	0.9236 ± 0.0024^b
Weighted F1	0.8976 ± 0.0038^a	0.9205 ± 0.0156^b
Macro F1	0.8498 ± 0.0053^a	0.8885 ± 0.0078^b
Class I	0.9279 ± 0.0044^a	0.9447 ± 0.0025^b
Class II	0.9255 ± 0.0035^a	0.9429 ± 0.0026^b
Class III	0.8939 ± 0.0049^a	0.9142 ± 0.0052^b
Class IV	0.8645 ± 0.0091^a	0.8878 ± 0.0015^b
Class V	0.7902 ± 0.0182^a	0.8128 ± 0.0217^b
Class WV	0.6968 ± 0.0077^a	0.8285 ± 0.0097^b

Lưu ý: Các chữ cái khác nhau ở dạng chữ trên cho biết sự khác biệt có ý nghĩa thống kê giữa Mô hình cơ sở dựa trên quy tắc và mô hình Auto-sklearn 3 chỉ báo (kiểm định HSD của Tukey, $p < 0,05$).

DO), các chương trình giám sát có thể đánh giá đáng tin cậy, đồng thời giảm cả vốn đầu tư thiết bị lẫn chi phí vận hành cho phân tích hóa học. Phương pháp đơn giản hóa này đặc biệt hữu ích cho các khu vực đang phát triển còn hạn chế về nguồn lực, giúp việc giám sát chất lượng nước một cách có hệ thống trở nên khả thi hơn về mặt kinh tế và dễ triển khai rộng rãi.

4.2.2. Regional heterogeneity

Mặc dù bộ chỉ thị rút gọn của chúng tôi (COD_{Mn}, TP và DO) hoạt động tốt trong phân loại tổng quát ở quy mô quốc gia, phân tích cấp vùng cho thấy rõ ràng rằng các tổ hợp chỉ thị tối ưu thay đổi tùy theo những áp lực do con người gây ra đặc thù ở quy mô vùng. Như thể hiện trong Hình 8 và Bảng S9, các lưu vực Tùng Liêu và Hoàng Hà cần một bộ chỉ thị then chốt khác, trong đó NH₃-N thay thế DO. Sự thay đổi này phản ánh trực tiếp các tác nhân gây ô nhiễm đặc thù của từng vùng.

Mức độ nghiêm trọng đặc biệt của tình trạng ô nhiễm nitơ tại các lưu vực này được chứng minh bằng các số liệu định lượng. Chẳng hạn, lưu vực sông Tùng Hoa-Liêu có lượng nitơ đầu vào do hoạt động nhân sinh ròng ước tính lên tới 9453 kg N km⁻² yr⁻¹, cao hơn so với các lưu vực phía nam (Cao et al., 2025). Tương tự, lưu vực sông Hoàng Hà là khu vực chịu ô nhiễm từ nguồn phân tán nông nghiệp nghiêm trọng nhất Trung Quốc, trong đó các tỉnh thuộc lưu vực đóng góp tới 42.67 % tổng lượng phát thải TN từ nông nghiệp của cả nước (Tan et al., 2025). Tải lượng cực lớn này đồng nghĩa với việc các chất ô nhiễm thô, giàu NH₃-N, là đặc trưng chủ đạo của hồ sơ ô nhiễm.

Áp lực ô nhiễm khổng lồ này càng trở nên nghiêm trọng do các điều kiện thủy văn đặc thù của khu vực, tương phản rõ rệt với các lưu vực lớn khác. Các lưu vực phía Bắc có nguồn nước cực kỳ khan hiếm. Lưu lượng dòng chảy trung bình hằng năm của sông Liêu Hà (36.7 km³) và sông Hoàng Hà (52.1 km³) thấp hơn một bậc độ lớn so với sông Dương Tử và sông Châu Giang ở phía Nam, vốn đều vượt quá 300 km³ (Gao et al., 2020)). Sông Hoàng Hà là minh chứng điển hình cho tình trạng này: sông tưới tiêu cho 13 % diện tích đất canh tác của cả nước nhưng chỉ chiếm 3 % tổng lượng dòng chảy sông ngòi (Ren et al., 2016). Động thái “tải lượng cao, dòng chảy thấp” này khiến lượng nitơ khổng lồ đổ vào bị tập trung trong một thể tích nước tối thiểu, dẫn đến nồng độ chất ô nhiễm đặc biệt cao, điều không thấy ở các lưu vực phía Nam có dòng chảy lớn.

Phân tích so sánh này xác nhận rằng ô nhiễm nitơ ở các lưu vực Tùng Liêu và Hoàng Hà nổi bật một cách đặc biệt. Mặc dù các lưu vực phía nam như lưu vực Trường Giang có thể có tổng tải lượng nitơ lớn, khả năng pha loãng dồi dào giúp giảm nồng độ và do đó làm dịu mức độ nghiêm trọng trước mắt (Wang et al., 2020). Ngược lại, sự kết hợp giữa cường độ đầu vào nitơ cực cao và khả năng pha loãng rất hạn chế ở các lưu vực Tùng Liêu và Hoàng Hà tạo ra môi trường trong đó các chất ô nhiễm sơ cấp như NH₃-N là chỉ dấu trực tiếp và nhạy bén hơn về sự suy thoái so với các phản ứng thứ cấp của hệ sinh thái như DO. Bằng chứng này xác nhận các phát hiện từ mô hình của chúng tôi và nhấn mạnh sự cần thiết của các bộ chỉ thị đặc thù cho từng lưu vực nhằm quản lý chất lượng nước hiệu quả.

4.3. Limitations and future perspectives

Several limitations of this study should be acknowledged from both technical and methodological perspectives. Firstly, the indicator optimization in this study was confined to only nine commonly monitored indicators, which represents a subset of the comprehensive indicator system required by Chinese national standards (Table S1). Many important indicators specified in the standards, such as heavy metals, volatile phenols, and petroleum, were not included in our analysis. Moreover, biological indicators like Chlorophyll-a and algal density had to be excluded due to significant missing values in the monitoring data. These data availability constraints mean that our key indicator screening results might not fully reflect all aspects of water quality assessment required by national standards, particularly in terms of biological water quality and specific pollutants. To address this limitation, future studies should expand the scope of indicator analysis to include all indicators specified in national standards, which would provide a more comprehensive basis for key indicator selection.

Secondly, while our current AutoML framework successfully reduces the dimensionality of water quality indicators, it can only perform classification when all key indicators (COD_{Mn} , TP, and DO) are available. The model becomes inoperable when any of these key indicators are missing due to monitoring equipment malfunction or data transmission issues, which is a common scenario in environmental monitoring. To address this temporal missing data challenge, future research should incorporate time series models (e.g., RNNs, Transformers) to first predict missing key water quality indicators using their historical measurements, and then feed these predictions into the AutoML classification framework. This two-stage approach would enable continuous water quality classification even during periods of missing measurements, further enhancing the practical applicability of the system.

Despite these limitations, the framework presented in this study offers significant practical implications. Our work provides a data-driven pathway to design more cost-effective monitoring networks, first by identifying a generalizable set of core indicators (COD_{Mn} , TP, and DO) at the national scale. Crucially, the framework also demonstrates its ability to adapt to local conditions by identifying different key indicators (e.g., NH_3-N) in basins with unique pollution pressures. This adaptability is particularly valuable for regions with limited financial or technical resources. Moreover, the integration of an AutoML framework automates the otherwise complex and labor-intensive process of model selection and hyperparameter tuning, lowering the technical barrier for environmental agencies to implement predictive analytics. Ultimately, this study provides a scalable and adaptable template for creating more efficient and intelligent water quality management systems, enabling a more strategic allocation of resources in environmental protection.

5. Conclusion

This study demonstrates the effectiveness of integrating Auto-sklearn with interpretable ML techniques for water quality monitoring and classification optimization. Auto-sklearn outperformed most traditional machine learning approaches in water quality classification, achieving the top-tier performance with a Weighted F1 of 0.9633 ± 0.0027 . Crucially, the framework exhibited robust and generalizable performance, maintaining its superiority across rigorous temporal and spatial validation schemes. Furthermore, SHAP analysis revealed COD_{Mn} , TP, and DO as the most influential indicators. Crucially, a model using only these three indicators achieved a high Weighted F1-score (0.9205 ± 0.0097) and outperformed the rule-based baseline, yielding higher F1-scores across all classes and a 18.9 % relative improvement for Class WV water, offering potential for streamlined monitoring strategies. Regional analysis demonstrated that while most river basins aligned with the nationwide key indicator set, spatial heterogeneity exists in Song-Liao and Yellow River Basin where NH_3-N emerged as a key indicator.

The proposed framework addresses two critical challenges in water quality assessment: it eliminates the labor-intensive process of traditional ML implementation through automated workflow of Auto-sklearn, while SHAP-based indicator screening substantially reduces monitoring costs by identifying key indicators. This integration provides a practical solution for water environment management, particularly valuable for developing regions where both technical expertise and monitoring resources are limited.

CRedit authorship contribution statement

Wenjie Qin: Writing – review & editing, Writing – original draft, Visualization, Conceptualization. **Heng Zhong:** Writing – review & editing. **Jingping Hu:** Writing – review & editing, Funding acquisition. **Wei Luo:** Investigation. **Zhe Shao:** Validation. **Huijie Hou:** Writing – review & editing, Funding acquisition. **Zhenzhen Liu:** Data curation. **Xiaotong Zhang:** Validation. **Sha Liang:** Validation. **Jiakuan Yang:** Funding acquisition.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgments

This work was supported by the financial support from the National Natural Science Foundation of China (52170134, 52222006, and 52070083), the National Key Research and Development Program of China (2023YFC3902802), the Interdisciplinary Research Program of Huazhong University of Science and Technology (HUST, 2023JCYJ005), the Wuhan Power Battery Low-carbon Recycling Industry Innovation Joint Laboratory (2025020802040290), and the Hubei Provincial Science and Technology Research Project (2024BAA012). The researchers also acknowledge the support from the High-Performance Computing platform at HUST.

Appendix A. Supplementary data

Supplementary data to this article can be found online at <https://doi.org/10.1016/j.jhydrol.2025.134634>.

Data availability

Data will be made available on request.

References

- Asadollah, S.B.H.S., Sharafati, A., Motta, D., Yaseen, Z.M., 2021. River water quality index prediction and uncertainty analysis: a comparative study of machine learning models. J. Environ. Chem. Eng. 9, 104599. <https://doi.org/10.1016/j.jece.2020.104599>.
- Baccour, S., Goelema, G., Kahil, T., Albiac, J., van Vliet, M.T.H., Zhu, X., Strokai, M., 2024. Water quality management could halve future water scarcity cost-effectively in the Pearl River Basin. Nat. Commun. 15, 5669. <https://doi.org/10.1038/s41467-024-49929-z>.
- Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., Herrera, F., 2020. Explainable Artificial Intelligence (XAI): concepts, taxonomies, opportunities and challenges toward responsible AI. Inf. Fusion 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>.
- Bifarin, O.O., Fernández, F.M., 2024. Automated machine learning and explainable AI (AutoML-XAI) for Metabolomics: improving cancer diagnostics. J. Am. Soc. Mass Spectrom. 35, 1089–1100. <https://doi.org/10.1021/jasms.3c00403>.
- Byrne, D., 2024. A checklist for delivering the sustainable development goals. Nature. <https://doi.org/10.1038/d41586-024-02903-7>.
- Cao, M., Gao, W., Zhang, Y., Guo, F., 2025. Riverine nitrogen and phosphorus output in an arid watershed: combined effects of anthropogenic nutrient inputs, land use, and hydrology. Environ. Syst. Res. 14, 8. <https://doi.org/10.1186/s40068-025-00399-2>.

4.3. Limitations and future perspectives

Cần thừa nhận một số hạn chế của nghiên cứu này xét trên cả phương diện kỹ thuật lẫn phương pháp luận. Thứ nhất, việc tối ưu hóa chỉ tiêu trong nghiên cứu chỉ giới hạn ở chín chỉ tiêu được theo dõi phổ biến, vốn chỉ là một phần trong hệ thống chỉ tiêu toàn diện theo yêu cầu của các tiêu chuẩn quốc gia Trung Quốc (Bảng S1). Nhiều chỉ tiêu quan trọng được quy định trong các tiêu chuẩn, như kim loại nặng, phenol dễ bay hơi và dầu mỡ, không được đưa vào phân tích. Ngoài ra, các chỉ tiêu sinh học như điệp lục-a và mật độ tảo cũng phải bị loại trừ do dữ liệu quan trắc thiếu hụt đáng kể. Những hạn chế về tính sẵn có của dữ liệu này đồng nghĩa với việc kết quả sàng lọc chỉ tiêu chính có thể chưa phản ánh đầy đủ mọi khía cạnh đánh giá chất lượng nước theo yêu cầu của tiêu chuẩn quốc gia, đặc biệt là chất lượng nước sinh học và các chất ô nhiễm cụ thể. Để khắc phục hạn chế này, các nghiên cứu trong tương lai nên mở rộng phạm vi phân tích chỉ tiêu, bao gồm tất cả các chỉ tiêu được quy định trong tiêu chuẩn quốc gia, qua đó tạo cơ sở toàn diện hơn cho việc lựa chọn các chỉ tiêu chính.

Thứ hai, mặc dù khung AutoML hiện tại của chúng tôi đã giảm thiểu công sức chiểu của các chỉ tiêu chất lượng nước, khung này chỉ có thể phân loại khi có đầy đủ tất cả các chỉ tiêu then chốt (COD_{Mn} , TP và DO). Mô hình không thể hoạt động khi thiếu bất kỳ chỉ tiêu nào, do đó thiết bị giám sát gặp trục trặc hoặc sự cố truyền dữ liệu—một tình huống phổ biến trong hoạt động giám sát môi trường. Để giải quyết thách thức về dữ liệu thiếu theo thời gian này, các nghiên cứu trong tương lai nên tích hợp các mô hình chuỗi thời gian (ví dụ: RNN, Transformer) để trước tiên dự đoán các chỉ tiêu chất lượng nước then chốt còn thiếu dựa trên các phép đo trong quá khứ, sau đó đưa những dự đoán này vào khung phân loại AutoML. Cách tiếp cận gồm hai giai đoạn này sẽ cho phép phân loại chất lượng nước liên tục ngay cả trong những khoảng thời gian thiếu số liệu đo, qua đó nâng cao hơn nữa tính ứng dụng thực tiễn của hệ thống.

Bất chấp những hạn chế này, khuôn khổ được trình bày trong nghiên cứu mang lại những hàm ý thực tiễn đáng kể. Nghiên cứu của chúng tôi đề xuất một phương thức dựa trên dữ liệu để thiết kế các mạng lưới quan trắc hiệu quả về chi phí hơn, trước hết bằng cách xác định một tập hợp các chỉ số cốt lõi có khả năng khái quát hóa (COD_{Mn} , TP và DO) ở quy mô quốc gia. Quan trọng hơn, khuôn khổ này cũng chứng minh khả năng thích ứng với điều kiện địa phương thông qua việc xác định các chỉ số then chốt khác nhau (ví dụ: NH_3-N) tại các lưu vực có áp lực ô nhiễm đặc thù. Khả năng thích ứng này đặc biệt có giá trị đối với những khu vực có nguồn tài chính hạn chế kỹ thuật hạn chế. Hơn nữa, việc tích hợp khuôn khổ AutoML tự động hóa quy trình lựa chọn mô hình và tinh chỉnh siêu tham số vốn phức tạp, tốn nhiều công sức, qua đó hạ thấp rào cản kỹ thuật để các cơ quan môi trường triển khai phân tích dự báo. Cuối cùng, nghiên cứu này cung cấp một khuôn mẫu có khả năng mở rộng và thích ứng để xây dựng các hệ thống quản lý chất lượng nước hiệu quả và thông minh hơn, giúp phân bổ nguồn lực chiến lược hơn cho công tác bảo vệ môi trường.

5. Kết luận

Nghiên cứu này chứng minh hiệu quả của việc tích hợp Auto-sklearn với các kỹ thuật học máy có thể diễn giải nhằm tối ưu hóa công tác giám sát và phân loại chất lượng nước. Auto-sklearn vượt trội hơn phần lớn các phương pháp học máy truyền thống trong phân loại chất lượng nước, đạt hiệu suất hàng đầu với điểm F1 có trọng số là 0.9633 ± 0.0027 . Đáng chú ý, khung này thể hiện hiệu suất vững chắc và có khả năng khái quát hóa, duy trì ưu thế qua các phương pháp thẩm định nghiêm ngặt theo thời gian và không gian. Hơn nữa, phân tích SHAP cho thấy COD_{Mn} , TP và DO là những chỉ số có ảnh hưởng lớn nhất. Đáng chú ý, mô hình chỉ sử dụng ba chỉ số này đạt điểm F1 có trọng số cao (0.9205 ± 0.0097) và vượt trội hơn mô hình cơ sở dựa trên quy tắc, cho điểm F1 cao hơn ở tất cả các lớp và cải thiện tương đối 18.9 % ở lớp nước WV, mở ra tiềm năng xây dựng các chiến lược giám sát tinh gọn hơn. Phân tích theo khu vực cho thấy, mặc dù hầu hết các lưu vực sông phù hợp với bộ chỉ số chính trên toàn quốc, vẫn tồn tại sự khác biệt về không gian tại lưu vực Tùng-Liêu và lưu vực sông Hoàng Hà, nơi NH_3-N nổi lên như một chỉ số quan trọng.

Khung đề xuất giải quyết hai thách thức then chốt trong đánh giá chất lượng nước: tự động hóa quy trình của Auto-sklearn giúp loại bỏ công đoạn triển khai ML truyền thống tốn nhiều công sức, trong khi việc sàng lọc chỉ số dựa trên SHAP giúp giảm đáng kể chi phí giám sát bằng cách xác định các chỉ số then chốt. Sự kết hợp này mang đến một giải pháp thiết thực cho công tác quản lý môi trường nước, đặc biệt hữu ích tại các khu vực đang phát triển, nơi cả chuyên môn kỹ thuật lẫn nguồn lực giám sát đều hạn chế.

Tuyên bố về đóng góp của tác giả theo CRediT

Wenjie Qin: Viết – rà soát và biên tập, viết bản thảo gốc, trực quan hóa, hình thành ý tưởng. Heng Zhong: Viết – rà soát và biên tập. Jingping Hu: Viết – rà soát và biên tập, huy động kinh phí. Wei Luo: Nghiên cứu. Zhe Shao: Xác nhận. Huijie Hou: Viết – rà soát và biên tập, huy động kinh phí. Zhenzhen Liu: Quản lý dữ liệu. Xiaotong Zhang: Xác nhận. Sha Liang: Xác nhận. Jiakuan Yang: Huy động kinh phí.

Tuyên bố về xung đột lợi ích

Các tác giả tuyên bố rằng họ không có bất kỳ lợi ích tài chính cạnh tranh hoặc mối quan hệ cá nhân nào đã biết có thể ảnh hưởng đến công trình được trình bày trong bài báo này.

Lời cảm ơn

Nghiên cứu này được hỗ trợ kinh phí từ Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc (52170134, 52222006 và 52070083), Chương trình Nghiên cứu và Phát triển Trọng điểm Quốc gia Trung Quốc (2023YFC3902802), Chương trình Nghiên cứu Liên ngành của Đại học Khoa học và Công nghệ Hoa Trung (HUST, 2023JCYJ005), Phòng thí nghiệm Liên kết Đối mới Công nghiệp Tái chế Pin Điện Carbon thấp Vũ Hán (2025020802040290) và Dự án Nghiên cứu Khoa học và Công nghệ tỉnh Hồ Bắc (2024BAA012). Các nhà nghiên cứu cũng ghi nhận sự hỗ trợ từ nền tảng Điện toán Hiệu năng cao của HUST.

Phụ lục A. Dữ liệu bổ sung

Có thể tìm thấy dữ liệu bổ sung cho bài viết này trực tuyến tại <https://doi.org/10.1016/j.jhydrol.2025.134634>

Tính khả dụng của dữ liệu

Dữ liệu sẽ được cung cấp khi có yêu cầu.

Tài liệu tham khảo

- Asadollah, S.B.H.S., Sharafati, A., Motta, D., Yaseen, Z.M., 2021. Dự báo chỉ số chất lượng nước sông và phân tích độ bất định: nghiên cứu so sánh các mô hình học máy. J. Environ. Chem. Eng. 9, 104599. <https://doi.org/10.1016/j.jece.2020.104599>.
- Baccour, S., Goelema, G., Kahil, T., Albiac, J., van Vliet, M.T.H., Zhu, X., Strokai, M., 2024. Quản lý chất lượng nước có thể giúp giảm một nửa tình trạng khan hiếm nước trong tương lai với chi phí hợp lý tại lưu vực sông Châu Giang. Nat. Commun. 15, 5669. <https://doi.org/10.1038/s41467-024-49929-z>.
- Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., Herrera, F., 2020. Trí tuệ nhân tạo có thể giải thích (XAI): các khái niệm, hệ phân loại, cơ hội và thách thức hướng tới AI có trách nhiệm. Inf. Fusion 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>.
- Bifarin, O.O., Fernández, F.M., 2024. Danh sách kiểm tra để hiện thực hóa các Mục tiêu Phát triển Bền vững. Nature. <https://doi.org/10.1038/d41586-024-02903-7>.
- Cao, M., Gao, W., Zhang, Y., Guo, F., 2025. Lượng nitơ và photpho phát thải từ sông trong lưu vực khô hạn: tác động kết hợp của nguồn dinh dưỡng do con người đưa vào, sử dụng đất và thủy văn. Environ. Syst. Res. 14, 8. <https://doi.org/10.1186/s40068-025-00399-2>.

- Chan, W.H., Fung, B.S.B., Tsang, D.H.K., Lo, I.M.C., 2023. A freshwater algae classification system based on machine learning with StyleGAN2-ADA augmentation for limited and imbalanced datasets. *Water Res.* 243, 120409. <https://doi.org/10.1016/j.watres.2023.120409>.
- Chen, K., Chen, H., Zhou, C., Huang, Y., Qi, X., Shen, R., Liu, F., Zuo, M., Zou, X., Wang, J., Zhang, Y., Chen, D., Chen, X., Deng, Y., Ren, H., 2020. Comparative analysis of surface water quality prediction performance and identification of key water parameters using different machine learning models based on big data. *Water Res.* 171, 115454. <https://doi.org/10.1016/j.watres.2019.115454>.
- Ding, F., Zhang, W., Cao, S., Hao, S., Chen, L., Xie, X., Li, W., Jiang, M., 2023. Optimization of water quality index models using machine learning approaches. *Water Res.* 243, 120337. <https://doi.org/10.1016/j.watres.2023.120337>.
- Durgun, Y., 2024. Real-time water quality monitoring using AI-enabled sensors: Detection of contaminants and UV disinfection analysis in smart urban water systems. *Journal of King Saud University - Science* 36, 103409. <https://doi.org/10.1016/j.jksus.2024.103409>.
- Feurer, M., Klein, A., Eggenberger, K., Springenberg, J.T., Blum, M., Hutter, F., 2015. Efficient and robust automated machine learning, in: *Proceedings of the 29th International Conference on Neural Information Processing Systems - Volume 2*, NIPS'15. MIT Press, Cambridge, MA, USA, pp. 2755–2763.
- Gao, Y., Zhou, F., Ciais, P., Miao, C., Yang, T., Jia, Y., Zhou, X., Klaus, B.-B., Yang, T., Yu, G., 2020. Human activities aggravate nitrogen-deposition pollution to inland water over China. *Natl. Sci. Rev.* 7, 430–440. <https://doi.org/10.1093/nsr/nwz073>.
- Greenhill, S., Druckenmiller, H., Wang, S., Keiser, D.A., Girotto, M., Moore, J.K., Yamaguchi, N., Todeschini, A., Shapiro, J.S., 2024. Machine learning predicts which rivers, streams, and wetlands the Clean Water Act regulates. *Science* 383, 406–412. <https://doi.org/10.1126/science.adi3794>.
- Guyon, I., Sun-Hosoya, L., Boullé, M., Escalante, H.J., Escalera, S., Liu, Z., Jajetic, D., Ray, B., Saeed, M., Sebag, M., Statnikov, A., Tu, W.-W., Viegas, E., 2019. Analysis of the AutoML Challenge Series 2015–2018, in: Hutter, F., Kotthoff, L., Vanschoren, J. (Eds.), *Automated Machine Learning: Methods, Systems, Challenges*. Springer International Publishing, Cham, pp. 177–219. doi:10.1007/978-3-030-05318-5_10.
- Herrera, V., 2019. Reconciling global aspirations and local realities: challenges facing the sustainable development goals for water and sanitation. *World Dev.* 118, 106–117. <https://doi.org/10.1016/j.worlddev.2019.02.009>.
- Kuhn, H.W., 2020. *Classics in Game Theory* 1–328.
- LeDell, E., Poirier, S., 2020. H2O AutoML: Scalable Automatic Machine Learning.
- Li, Z., Ma, W., Zhong, D., Ma, J., Zhang, Q., Yuan, Y., Liu, X., Wang, X., Zou, K., 2024. Applications of machine learning in drinking water quality management: a critical review on water distribution system. *J. Clean. Prod.* 481, 144171. <https://doi.org/10.1016/j.jclepro.2024.144171>.
- Lundberg, S.M., Lee, S.-I., 2017a. A unified approach to interpreting model predictions, in: *Proceedings of the 31st International Conference on Neural Information Processing Systems*, NIPS'17. Curran Associates Inc., Red Hook, NY, USA, pp. 4768–4777.
- Lundberg, S.M., Lee, S.-I., 2017b. A Unified Approach to Interpreting Model Predictions, in: Guyon, I., Luxburg, U.V., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., Garnett, R. (Eds.), *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS 30* (NIPS 2017), *Advances in Neural Information Processing Systems*. Presented at the 31st Annual Conference on Neural Information Processing Systems (NIPS), Neural Information Processing Systems (nips), La Jolla.
- Michalak, A.M., 2016. Study role of climate change in extreme threats to water quality. *Nature* 535, 349–350. <https://doi.org/10.1038/535349a>.
- Moradi, M., Samwald, M., 2021. Post-hoc explanation of black-box classifiers using confident itemsets. *Expert Syst. Appl.* 165, 113941. <https://doi.org/10.1016/j.eswa.2020.113941>.
- MEEPRC, 2002. National Environmental quality standards of surface water of China, GB3838-2002. Ministry of Ecology and Environment of the People's Republic of China. https://www.mee.gov.cn/ywgz/fgbz/bz/bzwb/shjbh/shjzlbz/200206/t20020601_66497.shtml.
- Olson, R.S., Bartley, N., Urbanowicz, R.J., Moore, J.H., 2016. Evaluation of a Tree-based Pipeline Optimization Tool for Automating Data Science, in: *Proceedings of the Genetic and Evolutionary Computation Conference 2016, GECCO '16. Association for Computing Machinery*, New York, NY, USA, pp. 485–492. doi:10.1145/2908812.2908918.
- Othman, F., Alaaeldin, M.E., Seyam, M., Ahmed, A.N., Teo, F.Y., Ming Fai, C., Afan, H.A., Sherif, M., Sefelnasr, A., El-Shafie, A., 2020. Efficient river water quality index prediction considering minimal number of inputs variables. *Eng. Appl. Comput. Fluid Mech.* 14, 751–763. <https://doi.org/10.1080/19942060.2020.1760942>.
- Peng, L., Wu, H., Gao, M., Yi, H., Xiong, Q., Yang, L., Cheng, S., 2022. TLT: Recurrent fine-tuning transfer learning for water quality long-term prediction. *Water Res.* 225, 119171. <https://doi.org/10.1016/j.watres.2022.119171>.
- Qian, J., Qian, L., Pu, N., Bi, Y., Wilhelms, A., Norra, S., 2024. An intelligent early warning system for harmful algal blooms: harnessing the power of big data and deep learning. *Environ. Sci. Technol.* 58, 15607–15618. <https://doi.org/10.1021/acs.est.3c03906>.
- Ren, D., Xu, X., Hao, Y., Huang, G., 2016. Modeling and assessing field irrigation water use in a canal system of Hetao, upper Yellow River basin: application to maize, sunflower and watermelon. *J. Hydrol.* 532, 122–139. <https://doi.org/10.1016/j.jhydrol.2015.11.040>.
- Russo, C., Castro, A., Gioia, A., Iacobellis, V., Gorgoglione, A., 2023. A stormwater management framework for predicting first flush intensity and quantifying its influential factors. *Water Resour. Manage.* 37, 1437–1459. <https://doi.org/10.1007/s11269-023-03438-8>.
- Senocak, A.U.G., Yilmaz, M.T., Kalkan, S., Yucel, I., Amjad, M., 2023. An explainable two-stage machine learning approach for precipitation forecast. *J. Hydrol.* 627, 130375. <https://doi.org/10.1016/j.jhydrol.2023.130375>.
- Snoek, J., Larochelle, H., Adams, R.P., 2012. Practical Bayesian Optimization of Machine Learning Algorithms. <https://doi.org/10.48550/arXiv.1206.2944>.
- Sun, F., Mu, Y., Leung, K.M.Y., Su, H., Wu, F., Chang, H., 2021. China is establishing its water quality standards for enhancing protection of aquatic life in freshwater ecosystems. *Environ. Sci. Policy* 124, 413–422. <https://doi.org/10.1016/j.envsci.2021.07.008>.
- Tan, Q., Su, H., Zhang, Y., 2025. Evolution characteristics and control suggestions for agricultural non-point source pollution in the Yellow River Basin of China. *Water* 17, 1626. <https://doi.org/10.3390/w17111626>.
- Tripathi, M., Singal, S.K., 2019. Use of principal component analysis for parameter selection for development of a novel water quality index: a case study of river Ganga India. *Ecol. Ind.* 96, 430–436. <https://doi.org/10.1016/j.ecolind.2018.09.025>.
- Uddin, M.G., Nash, S., Olbert, A.I., 2021. A review of water quality index models and their use for assessing surface water quality. *Ecol. Ind.* 122, 107218. <https://doi.org/10.1016/j.ecolind.2020.107218>.
- Wang, A., Yang, D., Tang, L., 2020. Spatiotemporal variation in nitrogen loads and their impacts on river water quality in the upper Yangtze River basin. *J. Hydrol.* 590, 125487. <https://doi.org/10.1016/j.jhydrol.2020.125487>.
- Wu, J., Cheng, S.-P., He, L.-Y., Wang, Y.-C., Yue, Y., Zeng, H., Xu, N., 2023. Assessing water quality in the Pearl River for the last decade based on clustering: characteristic, evolution and policy implications. *Water Res.* 244, 120492. <https://doi.org/10.1016/j.watres.2023.120492>.
- Xia, J., Zeng, J., 2022. Environmental factors assisted the evaluation of entropy water quality indices with efficient machine learning technique. *Water Resour. Manage.* 36, 2045–2060. <https://doi.org/10.1007/s11269-022-03126-z>.
- Zhang, H., Ren, X., Chen, S., Xie, G., Hu, Y., Gao, D., Tian, X., Xiao, J., Wang, H., 2024. Deep optimization of water quality index and positive matrix factorization models for water quality evaluation and pollution source apportionment using a random forest model. *Environ. Pollut.* 347, 123771. <https://doi.org/10.1016/j.envpol.2024.123771>.
- Zhu, M., Wang, J., Yang, X., Zhang, Y., Zhang, L., Ren, H., Wu, B., Ye, L., 2022. A review of the application of machine learning in water quality evaluation. *Eco-Environ. Health* 1, 107–116. <https://doi.org/10.1016/j.eehl.2022.06.001>.
- Zöller, M.-A., Huber, M.F., 2021. Benchmark and survey of automated machine learning frameworks. *J. Artif. Intell. Res.* 70, 409–472. <https://doi.org/10.1613/jair.1.11854>.
- Chan, W.H., Fung, B.S.B., Tsang, D.H.K., Lo, I.M.C., 2023. Hệ thống phân loại tảo nước ngọt dựa trên học máy, sử dụng tăng cường dữ liệu StyleGAN2-ADA cho các tập dữ liệu hạn chế và mất cân bằng. *Water Res.* 243, 120409. <https://doi.org/10.1016/j.watres.2023.120409>. Chen, K., Chen, H., Zhou, C., Huang, Y., Qi, X., Shen, R., Liu, F., Zuo, M., Zou, X., Wang, J., Zhang, Y., Chen, D., Chen, X., Deng, Y., Ren, H., 2020. Phân tích so sánh hiệu suất dự đoán chất lượng nước mặt và xác định các thông số nước thải sinh hoạt bằng cách sử dụng các mô hình học máy khác nhau dựa trên dữ liệu lớn. *Water Res.* 171, 115454. <https://doi.org/10.1016/j.watres.2019.115454>. Ding, F., Zhang, W., Cao, S., Hao, S., Chen, L., Xie, X., Li, W., Jiang, M., 2023. Tối ưu hóa các mô hình chỉ số chất lượng nước bằng các phương pháp học máy. *Water Res.* 243, 120337. <https://doi.org/10.1016/j.watres.2023.120337>. Durgun, Y., 2024. Giám sát chất lượng nước theo thời gian thực bằng cảm biến tích hợp AI: Phát hiện chất gây ô nhiễm và phân tích khử trùng bằng tia UV trong các hệ thống nước đô thị thông minh. *Journal of King Saud University - Science* 36, 103409. <https://doi.org/10.1016/j.jksus.2024.103409>. Feuerer, M., Klein, A., Eggenberger, K., Springenberg, J.T., Blum, M., Hutter, F., 2015. Học máy tự động hiệu quả và mạnh mẽ, trong: *Kỷ yếu Hội nghị Quốc tế lần thứ 29 về Hệ thống xử lý thông tin thần kinh - Tập 2*, NIPS'15. MIT Press, Cambridge, MA, Hoa Kỳ, tr. 2755–2763. Gao, Y., Zhou, F., Ciais, P., Miao, C., Yang, T., Jia, Y., Zhou, X., Klaus, B.-B., Yang, T., Yu, G., 2020. Hoạt động của con người làm trầm trọng thêm tình trạng ô nhiễm do lắng đọng nitơ ở các vùng nước nội địa tại Trung Quốc. *Nat. Sci. Rev.* 7, 430–440. <https://doi.org/10.1093/nsr/nwz073>. Greenhill, S., Druckenmiller, H., Wang, S., Keiser, D.A., Yamaguchi, N., Todeschini, A., Shapiro, J.S., 2024. Học máy dự đoán những con sông, dòng suối và vùng đất ngập nước nào thuộc phạm vi điều chỉnh của Đạo luật Nước sạch. *Science* 383, 406–412. <https://doi.org/10.1126/science.adi3794>. Guyon, I., Sun-Hosoya, L., Boullé, M., Escalera, S., Liu, Z., Jajetic, D., Ray, B., Saeed, M., Sebag, M., Statnikov, A., Tu, W.-W., Viegas, E., 2019. Phân tích chuỗi Thử thách AutoML 2015–2018, trong: Hutter, F., Kotthoff, L., Vanschoren, J. (Chủ biên), *Automated Machine Learning: Phương pháp, Hệ thống, Thách thức*. Springer International Publishing, Cham, tr. 177–219. doi:10.1007/978-3-030-05318-5_10. Herrera, V., 2019. Dung hòa khát vọng toàn cầu với thực tế địa phương: những thách thức đối với các mục tiêu phát triển bền vững về nước và vệ sinh. *World Dev.* 118, 106–117. <https://doi.org/10.1016/j.worlddev.2019.02.009>. Kuhn, H.W., 2020. *Classics in Game Theory* 1–328. LeDell, E., Poirier, S., 2020. H2O AutoML: Scalable Automatic Machine Learning. Li, Z., Ma, W., Zhong, D., Ma, J., Zhang, Q., Yuan, Y., Liu, X., Wang, X., Zou, K., 2024. Ứng dụng học máy trong quản lý chất lượng nước uống: tổng quan phê bình về hệ thống phân phối nước. *J. Clean. Prod.* 481, 144171. <https://doi.org/10.1016/j.jclepro.2024.144171>. Lundberg, S.M., Lee, S.-I., 2017a. Một phương pháp thống nhất để diễn giải các dự đoán của mô hình, trong: *Proceedings of the 31st International Conference on Neural Information Processing Systems*, NIPS'17. Curran Associates Inc., Red Hook, NY, Hoa Kỳ, tr. 4768–4777. Lundberg, S.M., Lee, S.-I., 2017b. Một phương pháp thống nhất để diễn giải các dự đoán của mô hình, trong: Guyon, I., Luxburg, U.V., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., Garnett, R. (Chủ biên), *NHỮNG TIẾN BỘ TRONG HỆ THỐNG XỬ LÝ THÔNG TIN THẦN KINH 30* (NIPS 2017), *Advances in Neural Information Processing Systems*. Trình bày tại Hội nghị thường niên lần thứ 31 về Hệ thống xử lý thông tin thần kinh (NIPS), Neural Information Processing Systems (nips), La Jolla. Michalak, A.M., 2016. Giải thích hậu nghiệm các bộ phân loại hộp đen bằng cách sử dụng các tập mục có độ tin cậy cao. *Expert Syst. Appl.* 165, 113941. <https://doi.org/10.1016/j.eswa.2020.113941>. MEEPRC, 2002. Tiêu chuẩn chất lượng môi trường quốc gia đối với nước mặt của Trung Quốc, GB3838-2002. Bộ Sinh thái và Môi trường nước Cộng hòa Nhân dân Trung Hoa. https://www.mee.gov.cn/ywgz/fgbz/bz/bzwb/shjbh/shjzlbz/200206/t20020601_66497.shtml. Olson, R.S., Bartley, N., Urbanowicz, R.J., Moore, J.H., 2016. Đánh giá công cụ tối ưu hóa quy trình dựa trên cây để tự động hóa khoa học dữ liệu, trong: *Kỷ yếu của大会规模律*