



Contents lists available at ScienceDirect

Journal of Membrane Science

journal homepage: www.elsevier.com/locate/memsci



Explainable cross-plant transfer learning for fouling prediction in data-limited pilot-scale membrane bioreactors

Xiaohang Han^{a,1}, Liu Yang^{a,1}, Huan Qin^a, Shujuan Huang^b, Han Zhang^c, Boyan Xu^{a,*}, How Yong Ng^{a,d,**}

^a School of Technology for Sustainability, Beijing Normal University, China

^b School of Environmental and Municipal Engineering, Qingdao University of Technology, China

^c State Key Laboratory of Urban Water Resource and Environment, Harbin Institute of Technology, China

^d Department of Civil and Environmental Engineering, National University of Singapore, Singapore

ARTICLE INFO

Keywords:

Pilot-scale membrane bioreactors
Membrane fouling prediction
Transfer learning
Extracellular polymeric substances
Explainable machine learning

ABSTRACT

Accurate membrane fouling prediction is essential for feedforward control and low-energy operation of membrane bioreactors (MBRs). However, reliable model development for data-limited plants is constrained by sparse measurements of mechanistically informative extracellular polymeric substances (EPS) and soluble microbial products (SMP). Here, we developed an explainable cross-plant transfer learning framework for transmembrane pressure (TMP) prediction in data-limited pilot-scale MBRs. Long short-term memory (LSTM) and extreme gradient boosting (XGBoost) base models were pretrained on three data-richer source MBRs treating domestic wastewater, and fine-tuned with limited data from a domestic target plant. The base models predicted source-domain TMP ($R^2 = 0.87$ and 0.86). SHapley Additive exPlanations (SHAP) identified EPS carbohydrates (EPSc), EPS proteins (EPSp), and SMP proteins (SMPp) as the dominant fouling-related drivers. Direct transfer to the target plant yielded limited accuracy ($R^2 = 0.39$ – 0.41), suggesting that the base models did not fully capture its fouling behavior. In contrast, fine-tuning improved prediction accuracy, and the fine-tuned LSTM (LSTM-FT) reached $R^2 = 0.89$ at a 40% fine-tuning ratio. SHAP and leave-one-feature-out (LOFO) analyses revealed that EPSc remained the critical transferable fouling signal, whereas EPSp became increasingly important after fine-tuning. This shift points to an EPSp-related fouling pathway linked to the plant's Fe-enriched influent. The framework was validated on a pilot-scale MBR treating industrial wastewater, where LSTM-FT achieved $R^2 \approx 0.9$, with SMPp emerging as a critical feature. Collectively, the framework preserves shared EPS-centered fouling information while adaptively recalibrating plant-specific drivers, offering a practical route for mechanism-informed fouling prediction in data-limited MBRs.

1. Introduction

Urbanization and increasing wastewater reuse requirements continue to push wastewater treatment toward intensified processes, which need to deliver stable, high-quality effluent within constrained infrastructure footprints [1]. Membrane bioreactors (MBRs), which integrate biological treatment with membrane separation, have therefore been widely adopted for domestic and industrial applications, due to their superior effluent quality and compact configuration. However, membrane fouling remains the principal obstacle to fully realizing these

advantages [2]. Under constant-flux operation, fouling progressively increases filtration resistance and is reflected by a rise in transmembrane pressure (TMP), which in turn increases aeration and pumping demand, intensifies chemical cleaning requirements, accelerates membrane aging, and raises lifecycle costs [3]. Consequently, MBRs typically consume more energy than conventional activated sludge processes (0.4 – 1.6 vs. 0.3 – 0.8 kWh m^{−3}) [4]. Accurate prediction of fouling evolution/TMP is therefore essential for enabling feedforward fouling control and low-energy MBR operation [5,6]. Nevertheless, despite substantial progress in fouling characterization and mitigation,

* Corresponding author.

** Corresponding author. School of Technology for Sustainability, Beijing Normal University, China.

E-mail addresses: xuboyan@bnu.edu.cn (B. Xu), huanghy@bnu.edu.cn (H.Y. Ng).

¹ First Authors.

<https://doi.org/10.1016/j.memsci.2026.126065>

Received 8 June 2026; Received in revised form 21 July 2026; Accepted 18 August 2026

Available online 19 August 2026

0376-7388/© 2026 Elsevier B.V. All rights are reserved, including those for text and data mining, AI training, and similar technologies.



Contents lists available at ScienceDirect

Journal of Membrane Science

journal homepage: www.elsevier.com/locate/memsci



Học chuyển giao liên nhà máy có khả năng giải thích để dự đoán hiện tượng bám bẩn trong các thiết bị phản ứng sinh học màng quy mô thí điểm với dữ liệu hạn chế

Xiaohang Han^{a,1}, Liu Yang^{a,1}, Huan Qin^a, Shujuan Huang^b, Han Zhang^c, Boyan Xu^{a,*}, Cách Yong Ng^{a,d,*}

^a School of Technology for Sustainability, Beijing Normal University, China^b

School of Environmental and Municipal Engineering, Qingdao University of Technology, China^c

State Key Laboratory of Urban Water Resource and Environment, Harbin Institute of Technology, China^d

Department of Civil and Environmental Engineering, National University of Singapore, Singapore

THÔNG TIN BÀI VIẾT

Keywords:

Bể phản ứng sinh học màng quy mô thử nghiệm Dự đoán sự tắc nghẽn màng Học chuyển giao Các chất polymer ngoại bào Học máy có thể giải thích

TÓM TẮT

Dự đoán chính xác sự fouling màng là thiết yếu cho điều khiển truyền thẳng và vận hành tiết kiệm năng lượng các bể phản ứng sinh học màng (MBR). Tuy nhiên, việc phát triển mô hình đáng tin cậy cho các nhà máy hạn chế dữ liệu bị cản trở bởi số phép đo thưa thớt đối với các chất polymer ngoại bào (EPS) và sản phẩm vi sinh hòa tan (SMP), vốn cung cấp thông tin về cơ chế. Trong nghiên cứu này, chúng tôi phát triển một khuôn khổ học chuyển giao liên nhà máy có khả năng giải thích để dự đoán áp suất xuyên màng (TMP) tại các MBR quy mô thí điểm hạn chế dữ liệu. Các mô hình cơ sở bộ nhớ dài-ngắn hạn (LSTM) và tăng cường gradient cực đại (XGBoost) được tiền huấn luyện trên dữ liệu từ ba MBR nguồn có dữ liệu phong phú hơn, xử lý nước thải sinh hoạt, sau đó được tinh chỉnh bằng lượng dữ liệu hạn chế từ một nhà máy đích xử lý nước thải sinh hoạt. Các mô hình cơ sở dự đoán TMP trong miền nguồn ($R^2 = 0.87$ và 0.86). Phương pháp giải thích SHapley Additive exPlanations (SHAP) xác định carbohydrate EPS (EPSc), protein EPS (EPSp) và protein SMP (SMPp) là các yếu tố chi phối liên quan đến fouling. Chuyển giao trực tiếp sang nhà máy đích chỉ đạt độ chính xác hạn chế ($R^2 = 0.39$ – 0.41), cho thấy các mô hình cơ sở chưa nắm bắt đầy đủ đặc tính fouling của nhà máy này. Ngược lại, tinh chỉnh giúp cải thiện độ chính xác dự đoán; mô hình LSTM được tinh chỉnh (LSTM-FT) đạt $R^2 = 0.89$ với tỷ lệ tinh chỉnh 40%. Các phân tích SHAP và loại bỏ từng đặc trưng một (LOFO) cho thấy EPSc vẫn là tín hiệu fouling có thể chuyển giao quan trọng, trong khi EPSp ngày càng trở nên quan trọng sau khi tinh chỉnh. Sự dịch chuyển này cho thấy một con đường fouling liên quan đến EPSp, gắn với nước đầu vào giàu Fe của nhà máy. Khuôn khổ được kiểm chứng trên một MBR quy mô thí điểm xử lý nước thải công nghiệp, tại đó LSTM-FT đạt $R^2 \approx 0.9$ và SMPp nổi lên như một đặc trưng then chốt. Nhìn chung, khuôn khổ này bảo toàn thông tin fouling chung tập trung quanh EPS, đồng thời hiệu chỉnh thích ứng các yếu tố chi phối đặc thù từng nhà máy, mở ra hướng thực tiễn để dự đoán fouling dựa trên cơ chế tại các MBR hạn chế dữ liệu.

1. Giới thiệu

Đô thị hóa và các yêu cầu ngày càng cao về tái sử dụng nước thải tiếp tục thúc đẩy các quy trình xử lý nước thải theo hướng tăng cường, nhằm tạo ra nước đầu ra ổn định, chất lượng cao trong phạm vi hạ tầng hạn chế [1]. Vi tích hợp xử lý sinh học với quá trình tách màng, các hệ thống phản ứng sinh học màng (MBR) đã được ứng dụng rộng rãi trong các lĩnh vực dân dụng và công nghiệp nhờ khả năng tiết kiệm nước đầu ra vượt trội và cấu hình nhỏ gọn. Tuy nhiên, hiện tượng tắc nghẽn màng vẫn là trở ngại chính cản trở việc khai thác tối đa các ưu điểm này.

các ưu điểm [2]. Khi vận hành với thông lượng không đổi, hiện tượng cấu bẩn làm tăng dần sức cản lọc và được thể hiện qua sự gia tăng áp suất xuyên màng (TMP), từ đó làm tăng nhu cầu sục khí và bơm, đòi hỏi vệ sinh hóa chất thường xuyên hơn, đẩy nhanh quá trình lão hóa màng và làm tăng chi phí vòng đời [3]. Do đó, MBR thường yêu cầu nhiều năng lượng hơn các quy trình bùn hoạt tính thông thường (0.4 – 1.6 so với 0.3 – 0.8 kWh m^{−3}) [4]. Vì vậy, dự đoán chính xác diễn biến cấu bẩn/TMP là thiết yếu để triển khai kiểm soát cấu bẩn dự báo trước và vận hành MBR tiết kiệm năng lượng [5,6]. Tuy nhiên, bất chấp những tiến bộ đáng kể trong việc mô tả và giảm thiểu hiện tượng cấu bẩn,

* Corresponding author.

** Corresponding author. School of Technology for Sustainability, Beijing Normal University, China.

E-mail addresses: xuboyan@bnu.edu.cn (B. Xu), huanghy@bnu.edu.cn (H.Y. Ng).

¹ First Authors.

<https://doi.org/10.1016/j.memsci.2026.126065>

Received 8 June 2026; Received in revised form 21 July 2026; Accepted 18 August 2026

Available online 19 August 2026

0376-7388/© 2026 Elsevier B.V. All rights are reserved, including those for text and data mining, AI training, and similar technologies.

proactive fouling management remains difficult in MBRs.

To support proactive management, both mechanistic and data-driven approaches have been explored to predict fouling evolution. Mechanistic and hybrid biological–physical models can enhance interpretability, but they are often challenging to parameterize and recalibrate in real plants [7]. In parallel, machine learning (ML) and deep learning (DL) models have emerged as attractive alternatives, because they can capture nonlinear relationships among operational, water-quality, and biomass-related variables [7–9]. Within this landscape, tree-based ML models (e.g., gradient-boosting families such as Extreme Gradient Boosting (XGBoost)) are attractive for tabular process data, whereas recurrent DL architectures (e.g., long short-term memory (LSTM) networks) are particularly suitable for fouling prediction, because membrane fouling is an intrinsically cumulative and path-dependent process, driven by temporal changes in sludge properties and hydrodynamic conditions [10–12].

Notably, comprehensive and rationally designed inputs for model development are key to achieving accurate AI modeling [13]. However, many existing TMP prediction models, particularly those developed at pilot-scale/full-scale MBRs, are built primarily on routinely monitored “conventional” variables, such as mixed liquor suspended solids (MLSS), mixed liquor volatile suspended solids (MLVSS), hydraulic retention time (HRT), and sludge retention time (SRT). Thus, the current approaches for tracking fouling dynamics in MBRs are often insufficient [14,15]. In contrast, mechanistically informative biochemical descriptors such as extracellular polymeric substances (EPS) and soluble microbial products (SMP) are often missing or severely under-sampled at pilot-scale/full-scale MBRs [15,16]. This is a critical limitation, because extensive evidence shows that EPS and SMP, particularly their proteinaceous and polysaccharide fractions, strongly influence fouling propensity by shaping cake formation, compressibility, and pore-blocking behavior [17], although humic and fulvic acids can also contribute to membrane fouling [18–20]. Collectively, this evidence suggests that explicitly introducing EPS and SMP as model inputs could be both scientifically justified and a promising route to improve TMP prediction and interpretability in MBR plants.

Even when these key biochemical indicators are available, pilot-/full-scale MBR datasets are often still insufficient to support the development of robust site-specific fouling prediction models. In practice, measurements of EPS and SMP fractions are usually sparse and irregular, because they rely on labor-intensive laboratory analyses rather than online sensing. Together with missing values, sensor errors, and outliers in routine operational records and key biochemical datasets, these limitations make it difficult for a **single data-limited MBR plant** to independently train a high-quality predictive model [21,22]. Most existing ML-based MBR fouling prediction models have also been developed and validated using relatively long or dense plant-specific historical records, leaving their cross-plant generalizability under data-limited conditions insufficiently established [7,8,23]. Nevertheless, different MBR plants often share comparable fouling mechanisms, including cake-layer accumulation, pore blocking, and the contribution of microbial products to membrane fouling. This suggests that **transferable models for fouling formation/prediction** may exist across MBR plants. From this perspective, transfer learning provides a promising strategy to address both data scarcity and data silos in MBR fouling prediction [24,25]. Specifically, a base model can be pretrained on multi-source data from different MBR plants to learn generalized relationships among operational conditions, EPS/SMP signatures, and TMP evolution. Then it could be fine-tuned using a small amount of data from the target MBR to learn the plant-specific fouling drivers.

However, cross-plant transfer learning for MBR fouling prediction is not a simple model-porting problem. First, source and target MBRs may differ substantially in influent composition, sludge physicochemical properties, EPS/SMP profiles, metal–organic interactions, and operating conditions. Moreover, even after fine-tuning, limited target plant data may still be insufficient for the model to fully capture newly dominant

fouling drivers that were weak or absent in the source plants. Furthermore, the success of transfer learning should not be evaluated by predictive accuracy alone, but also by **how** and **why** physically meaningful fouling signals are retained, discarded, or reweighted during transfer. Explainable analyses, such as SHAP and leave-one-feature-out (LOFO) analysis, are needed to determine how key EPS/SMP-related indicators function as transferable fouling drivers or plant-specific recalibrated signals. Prior applications of these methods to membrane-fouling prediction have focused mainly on model-level feature ranking [26]. However, SHAP attributions are inherently model-dependent and lack a ground truth for validation, so high predictive accuracy alone does not ensure that the highlighted features reliably reflect the true fouling behavior [27]. Accordingly, independent physicochemical characterization, including excitation–emission matrix (EEM), liquid chromatography–organic carbon detection (LC-OCD), and foulant analysis, is needed to evaluate the plausibility of these attribution shifts and support their mechanistic interpretation.

To address these gaps, this study proposes an explainable transfer learning strategy for fouling prediction in pilot-scale MBRs under data-limited conditions. Specifically, (1) base models (based on LSTM and XGBoost) were first pretrained on multi-source datasets collected from three pilot-scale MBR plants (source plants) treating domestic wastewater, covering diverse operating conditions, routine biochemical characteristics, and key components in EPS and SMP. We then (2) fine-tuned the base models using the target plant dataset to establish a fouling prediction model for the data-limited target plant (treating domestic wastewater), while quantifying the relationship between fine-tuning ratio and predictive performance and examining how LSTM and XGBoost architectures influenced transfer performance after fine-tuning. Next, (3) the transfer behavior and transferable fouling-related information were examined using explainable analyses, including SHAP and LOFO analyses, together with physicochemical characterization by EEM, LC-OCD, and foulant analysis. These analyses were used to clarify **how** key fouling-related indicators, particularly EPS and SMP, were retained or reweighted during pretraining and fine-tuning, and provided **mechanistic** support for these changes. Finally, (4) the transfer learning framework was further examined in a pilot-scale MBR treating industrial wastewater to test whether cross-plant transfer learning remains feasible under a more distinct wastewater background. Collectively, this study aims to provide a practical and explainable route for establishing fouling prediction models in data-limited MBR facilities through cross-plant transfer learning.

2. Materials and methods

2.1. Data collection

A pilot-scale MBR plant treating domestic wastewater in Singapore was selected as the target plant. The system received Fe-enriched influent, with an Fe dosage of approximately 10–30 mg/L. It had a treatment capacity of 24 m³/d and a process configuration comprising pretreatment, a five-pass step-feed bioreactor with anaerobic/oxic zonation, and a membrane tank (Fig. 1(a)). The TMP profile of the target plant during the monitoring period is shown in Fig. 2(a), the membrane module is shown in Fig. 2(b), and the detailed process and operating parameters are summarized in Text S1. The target plant dataset covered the period from September 2021 to June 2022. Owing to the twice-weekly measurement frequency of EPS and SMP, model development was based only on dates with complete matched measurements for all input variables and TMP, yielding 71 valid temporally matched records. This data-limited target plant setting reflected the practical monitoring constraints of pilot-scale MBR operation and provided a realistic scenario for evaluating the proposed cross-plant transfer learning framework.

Three pilot-scale submerged MBR plants treating domestic wastewater in Singapore were selected as source plants, yielding 332 records

Việc quản lý chủ động hiện tượng tắc nghẽn vẫn còn khó khăn trong các nhà máy MBR. Hơn nữa, không nên chỉ đánh giá mức độ thành công của học chuyển giao qua độ chính xác dự đoán, mà còn cần xem xét cách thức và lý do các tín hiệu tắc nghẽn có ý nghĩa vật lý được giữ lại, loại bỏ hoặc gán trọng số lại trong quá trình chuyển giao. Cần có các phân tích khả năng giải thích, chẳng hạn như SHAP và phân tích loại bỏ lần lượt từng đặc trưng (LOFO), để xác định cách các chỉ thị quan trọng liên quan đến EPS/SMP hoạt động như những yếu tố chỉ phối sự tắc nghẽn có thể chuyển giao hoặc những tín hiệu được hiệu chỉnh lại riêng cho từng nhà máy. Các ứng dụng trước đây của những phương pháp này trong dự đoán tắc nghẽn màng chủ yếu tập trung vào xếp hạng đặc trưng ở cấp độ mô hình [26]. Tuy nhiên, các giá trị quy thuộc SHAP vốn phụ thuộc vào mô hình và không có giá trị chuẩn thực để kiểm chứng; do đó, chỉ riêng độ chính xác dự đoán cao không đảm bảo rằng các đặc trưng được làm nổi bật phản ánh đáng tin cậy hành vi tắc nghẽn thực tế [27]. Vì vậy, cần có các phép đặc trưng hóa hóa lý tắc nghẽn được lập, bao gồm ma trận kích thích–phát xạ (EEM), sắc ký lỏng–phát hiện carbon hữu cơ (LC-OCD) và phân tích chất gây tắc nghẽn, để đánh giá tính hợp lý của những thay đổi trong giá trị quy thuộc này và hỗ trợ diễn giải cơ chế của chúng.

Đáng chú ý, các đầu vào toàn diện và được thiết kế hợp lý cho quá trình phát triển mô hình là yếu tố then chốt để đạt được khả năng mô hình hóa AI chính xác [13]. Tuy nhiên, nhiều mô hình dự đoán TMP hiện có, đặc biệt là những mô hình được phát triển cho các hệ thống MBR quy mô thí điểm/quy mô toàn phần, chủ yếu dựa trên các biến “thông thường” được giám sát định kỳ, chẳng hạn như chất rắn lơ lửng trong hỗn hợp bùn (MLSS), chất rắn lơ lửng bay hơi trong hỗn hợp bùn (MLVSS), thời gian lưu thủy lực (HRT) và thời gian lưu bùn (SRT). Do đó, các phương pháp hiện nay để theo dõi động thái của bùn trong MBR thường chưa đủ hiệu quả [14,15]. Ngược lại, các chỉ số sinh hóa mang thông tin về cơ chế, chẳng hạn như các chất polymer ngoại bào (EPS) và các sản phẩm vi sinh hòa tan (SMP), thường không được đo lường hoặc được lấy mẫu quá thưa tại các hệ thống MBR quy mô thí điểm/quy mô toàn phần [15,16]. Đây là một hạn chế nghiêm trọng, bởi nhiều bằng chứng cho thấy EPS và SMP, đặc biệt là các thành phần giàu protein và polysaccharide, ảnh hưởng mạnh mẽ đến xu hướng cấu trúc thông qua việc định hình sự hình thành lớp bọt bánh bùn, khả năng nén và hiện tượng bít lỗ màng [17], dù axit humic và axit fulvic cũng có thể góp phần gây cấu trúc màng [18–20]. Nhìn chung, những bằng chứng này cho thấy việc đưa EPS và SMP vào làm các đầu vào của mô hình một cách rõ ràng vừa có cơ sở khoa học, vừa là hướng đi đầy hứa hẹn để cải thiện khả năng dự đoán TMP và tính diễn giải của mô hình tại các nhà máy MBR.

Ngay cả khi có các chỉ số sinh hóa quan trọng này, dữ liệu từ các hệ thống MBR ở quy mô thí điểm/toàn phần thường vẫn chưa đủ để phát triển các mô hình dự đoán cấu trúc đáng tin cậy, đặc thù cho từng địa điểm. Trên thực tế, các phép đo các phân đoạn EPS và SMP thường thưa thớt và không đều, vì chúng đòi hỏi các phân tích trong phòng thí nghiệm tốn nhiều công sức thay vì cảm biến trực tuyến. Cùng với các giá trị bị thiếu, lỗi cảm biến và giá trị ngoại lai trong hồ sơ vận hành thường quy cũng như các bộ dữ liệu sinh hóa quan trọng, những hạn chế này khiến một nhà máy MBR đơn lẻ có dữ liệu hạn chế khó có thể tự huấn luyện một mô hình dự đoán chất lượng cao [21,22]. Hầu hết các mô hình dự đoán cấu trúc MBR dựa trên học máy hiện có cũng được phát triển và kiểm định bằng các hồ sơ lịch sử đặc thù cho từng nhà máy tương đối dài hoặc dày đặc, khiến khả năng khái quát hóa giữa các nhà máy trong điều kiện hạn chế dữ liệu vẫn chưa được xác lập đầy đủ [7,8,23]. Tuy vậy, các nhà máy MBR khác nhau thường có chung những cơ chế cấu trúc màng tự, bao gồm sự tích tụ lớp bánh, hiện tượng bít lỗ màng và tác động của các sản phẩm vi sinh vật đến hiện tượng cấu trúc màng. Điều này cho thấy có thể tồn tại các mô hình có khả năng chuyển giao để hình thành dự đoán cấu trúc giữa các nhà máy MBR. Từ góc độ này, học chuyển giao là một chiến lược đầy triển vọng để giải quyết các tình trạng khan hiếm dữ liệu lần các ốc đảo dữ liệu trong dự đoán cấu trúc MBR [24,25]. Cụ thể, có thể huấn luyện một mô hình cơ sở trên dữ liệu đa nguồn từ các nhà máy MBR khác nhau để học các mối quan hệ khái quát giữa điều kiện vận hành, đặc trưng EPS/SMP và diễn biến TMP. Sau đó, mô hình có thể được tinh chỉnh bằng một lượng nhỏ dữ liệu từ hệ thống MBR mục tiêu để học các yếu tố gây cấu trúc đặc thù của nhà máy.

Tuy nhiên, học chuyển giao giữa các nhà máy để dự đoán sự tắc nghẽn màng MBR không phải là một bài toán chuyển đổi mô hình đơn giản. Trước hết, các hệ thống MBR nguồn và đích có thể khác biệt đáng kể về thành phần nước đầu vào, đặc tính hóa lý của bùn, cấu hình EPS/SMP, tương tác kim loại–hữu cơ và điều kiện vận hành. Hơn nữa, ngay cả sau khi tinh chỉnh, dữ liệu hạn chế từ nhà máy đích vẫn có thể không đủ để mô hình nắm bắt đầy đủ các yếu tố mới đặc trưng của chúng.

Để khắc phục những khoảng trống này, nghiên cứu đề xuất một chiến lược học chuyển giao có khả năng giải thích nhằm dự đoán hiện tượng fouling trong các hệ MBR quy mô thí điểm trong điều kiện hạn chế dữ liệu. Cụ thể, (1) các mô hình cơ sở (dựa trên LSTM và XGBoost) được huấn luyện trên các bộ dữ liệu đa nguồn thu thập từ ba nhà máy MBR quy mô thí điểm (nhà máy nguồn) xử lý nước thải sinh hoạt, bao quát nhiều điều kiện vận hành, các đặc tính sinh hóa thường quy và những thành phần chính trong EPS và SMP. Sau đó, (2) các mô hình cơ sở được tinh chỉnh bằng bộ dữ liệu của nhà máy đích để xây dựng mô hình dự đoán fouling cho nhà máy đích có dữ liệu hạn chế (xử lý nước thải sinh hoạt), đồng thời định lượng mối quan hệ giữa tỷ lệ tinh chỉnh và hiệu năng dự đoán, cũng như khảo sát ảnh hưởng của kiến trúc LSTM và XGBoost đến hiệu quả chuyển giao sau khi tinh chỉnh. Tiếp theo, (3) hành vi chuyển giao và thông tin liên quan đến fouling có thể chuyển giao được khảo sát bằng các phân tích có khả năng giải thích, bao gồm phân tích SHAP và LOFO, kết hợp với đặc trưng hóa lý hóa bằng EEM, LC-OCD và phân tích chất gây fouling. Các phân tích này được sử dụng để làm rõ cách các chỉ thị chính liên quan đến fouling, đặc biệt là EPS và SMP, được duy trì hoặc gán trọng số lại trong quá trình huấn luyện và tinh chỉnh, đồng thời cung cấp cơ sở cơ chế cho những thay đổi này. Cuối cùng, (4) khung học chuyển giao được tiếp tục đánh giá tại một hệ MBR quy mô thí điểm xử lý nước thải công nghiệp nhằm kiểm tra tính khả thi của học chuyển giao giữa các nhà máy trong bối cảnh nhiễu thải khác biệt rõ rệt hơn. Nhìn chung, nghiên cứu hướng đến việc cung cấp một phương thức thực tiễn và có khả năng giải thích để xây dựng các mô hình dự đoán fouling tại những cơ sở MBR hạn chế dữ liệu thông qua học chuyển giao giữa các nhà máy.

Để khắc phục những khoảng trống này, nghiên cứu đề xuất một chiến lược học chuyển giao có khả năng giải thích nhằm dự đoán hiện tượng fouling trong các hệ MBR quy mô thí điểm trong điều kiện hạn chế dữ liệu. Cụ thể, (1) các mô hình cơ sở (dựa trên LSTM và XGBoost) được huấn luyện trên các bộ dữ liệu đa nguồn thu thập từ ba nhà máy MBR quy mô thí điểm (nhà máy nguồn) xử lý nước thải sinh hoạt, bao quát nhiều điều kiện vận hành, các đặc tính sinh hóa thường quy và những thành phần chính trong EPS và SMP. Sau đó, (2) các mô hình cơ sở được tinh chỉnh bằng bộ dữ liệu của nhà máy đích để xây dựng mô hình dự đoán fouling cho nhà máy đích có dữ liệu hạn chế (xử lý nước thải sinh hoạt), đồng thời định lượng mối quan hệ giữa tỷ lệ tinh chỉnh và hiệu năng dự đoán, cũng như khảo sát ảnh hưởng của kiến trúc LSTM và XGBoost đến hiệu quả chuyển giao sau khi tinh chỉnh. Tiếp theo, (3) hành vi chuyển giao và thông tin liên quan đến fouling có thể chuyển giao được khảo sát bằng các phân tích có khả năng giải thích, bao gồm phân tích SHAP và LOFO, kết hợp với đặc trưng hóa lý hóa bằng EEM, LC-OCD và phân tích chất gây fouling. Các phân tích này được sử dụng để làm rõ cách các chỉ thị chính liên quan đến fouling, đặc biệt là EPS và SMP, được duy trì hoặc gán trọng số lại trong quá trình huấn luyện và tinh chỉnh, đồng thời cung cấp cơ sở cơ chế cho những thay đổi này. Cuối cùng, (4) khung học chuyển giao được tiếp tục đánh giá tại một hệ MBR quy mô thí điểm xử lý nước thải công nghiệp nhằm kiểm tra tính khả thi của học chuyển giao giữa các nhà máy trong bối cảnh nhiễu thải khác biệt rõ rệt hơn. Nhìn chung, nghiên cứu hướng đến việc cung cấp một phương thức thực tiễn và có khả năng giải thích để xây dựng các mô hình dự đoán fouling tại những cơ sở MBR hạn chế dữ liệu thông qua học chuyển giao giữa các nhà máy.

2. Vật liệu và phương pháp

2.1. Data collection

Một nhà máy MBR quy mô thí điểm xử lý nước thải sinh hoạt tại Singapore được chọn làm nhà máy mục tiêu. Hệ thống tiếp nhận nước thải đầu vào giàu Fe, với liều lượng Fe khoảng 10–30 mg/L. Nhà máy có công suất xử lý 24 m³/d và cấu hình quy trình gồm tiền xử lý, bể phản ứng sinh học cấp dòng theo năm bậc với các vùng kỵ khí/hiếu khí, và bể màng (Hình 1(a)). Diễn biến TMP của nhà máy mục tiêu trong thời gian theo dõi được trình bày trong Hình 2(a), mô-đun màng được thể hiện trong Hình 2(b), còn các thông số quy trình và vận hành chi tiết được tóm tắt trong Văn bản S1. Bộ dữ liệu của nhà máy mục tiêu bao quát giai đoạn từ tháng 9 năm 2021 đến tháng 6 năm 2022. Do EPS và SMP được đo hai lần mỗi tuần, quá trình phát triển mô hình chỉ sử dụng những ngày có số đo khớp đầy đủ cho tất cả biến đầu vào và TMP, thu được 71 bản ghi hợp lệ được ghép cặp theo thời gian. Bối cảnh nhà máy mục tiêu có dữ liệu hạn chế này phản ánh những ràng buộc giám sát thực tế trong vận hành MBR quy mô thí điểm, đồng thời cung cấp một kịch bản thực tiễn để đánh giá khung học chuyển giao liên nhà máy được đề xuất.

Ba nhà máy MBR chìm quy mô thí điểm xử lý nước thải sinh hoạt ở Singapore được chọn làm nhà máy nguồn, thu được 332 bản ghi.





Fig. 1. Framework for transfer learning-based TMP prediction in MBRs: (a) treatment process of the target plant, and the associated prediction challenges: limited data, missing data and noisy measurements, (b) key characteristics of the three source plants: larger dataset size, higher data quality, and similar process configurations, (c) pretraining workflow of the LSTM and XGBoost models using data from the three source plants, (d) workflow for fine-tuning the base models using the target plant dataset to obtain the transfer learning models, (e) model interpretability and statistical analysis using LOFO and SHAP analyses.



Hình 1. Khung dự đoán TMP dựa trên học chuyển giao trong các MBR: (a) quy trình xử lý của nhà máy mục tiêu và các thách thức dự đoán liên quan: dữ liệu hạn chế, dữ liệu thiếu và phép đo nhiễu, (b) các đặc điểm chính của ba nhà máy nguồn: bộ dữ liệu lớn hơn, chất lượng dữ liệu cao hơn và cấu hình quy trình tương tự, (c) quy trình huấn luyện các mô hình LSTM và XGBoost bằng dữ liệu từ ba nhà máy nguồn, (d) quy trình tinh chỉnh các mô hình cơ sở bằng bộ dữ liệu của nhà máy mục tiêu để thu được các mô hình học chuyển giao, (e) khả năng diễn giải mô hình và phân tích thống kê bằng các phương pháp phân tích LOFO và SHAP.




Fig. 2. Operational context of the target MBR plant and source-target dataset characteristics: (a) TMP profile of the target plant during the monitoring period, (b) photograph of the MBR module at the target plant, (c) distributions of the operational and physicochemical variables in the three source plants and the target plant, (d) mean values of these variables for each plant.


in total, including 100 records from Plant 1, 132 records from Plant 2, and 100 records from Plant 3 (Fig. 1(b)). Photographs of the source plants are provided in Fig. S1, and their TMP profiles during the monitoring periods are shown in Fig. S2. These plants had comparable process configurations, consisting of anoxic/oxic biological treatment followed by immersed membrane separation, with conventional sludge recirculation and wasting. Detailed membrane-system characteristics and operating settings are summarized in Table S1. Although the target plant differed in influent composition due to upstream Fe addition, it remained comparable to the source plants in overall treatment configuration, with broadly similar MBR fouling mechanisms, supporting the application of transfer learning between source and target plants.

For each plant, the dataset included 11 variables: HRT, SRT, membrane flux (FLUX), total and soluble chemical oxygen demand (TCOD and SCOD), MLSS, MLVSS, EPSp, EPSc, SMPp, and SMPc. TMP was obtained from routine online monitoring and aligned with each sampling date for subsequent analysis.

2.2. Physicochemical analytical methods

HRT, SRT, and FLUX were recorded as routine operational parameters. TCOD and SCOD were determined by the APHA 5220D closed

reflux colorimetric method, and MLSS and MLVSS were measured according to Standard Methods [28]. SMP was defined as the dissolved fraction of the supernatant after 0.45 μ m membrane filtration and EPS was extracted from the residual biomass using the heat method [29]. Proteins and polysaccharides in SMP and EPS, including SMPp, SMPc, EPSp, and EPSc, were quantified using the Modified Lowry Protein Assay and Dubois Method, respectively [30]. Liquid chromatography-organic carbon detection (LC-OCD) was employed to characterize the dissolved organic matter, including biopolymers with molecular weight (MW) greater than 20 kDa and low-molecular-weight (LMW) compounds with MW less than 1000 Da, such as humics, building blocks, LMW acids, and LMW neutrals. The particle size distribution (PSD) of mixed liquor was analyzed using a laser diffraction particle analyzer. Capillary suction time (CST) was measured using a CST apparatus [31]. Total organic carbon (TOC) was measured using a TOC analyzer (TOC-VCSH, Shimadzu, Japan). Excitation-emission matrix (EEM) spectra were measured using a fluorescence spectrophotometer [32]. Total iron was measured using inductively coupled plasma optical emission spectroscopy (ICP-OES).



Hình 2. Bối cảnh vận hành của nhà máy MBR đích và đặc điểm bộ dữ liệu nguồn-đích: (a) biểu đồ TMP của nhà máy đích trong thời gian giám sát, (b) ảnh chụp mô-đun MBR tại nhà máy đích, (c) phân bố các biến vận hành và hóa lý tại ba nhà máy nguồn và nhà máy đích, (d) giá trị trung bình của các biến này tại từng nhà máy.

tổng cộng, bao gồm 100 bản ghi từ Nhà máy 1, 132 bản ghi từ Nhà máy 2 và 100 bản ghi từ Nhà máy 3 (Hình 1(b)). Ảnh chụp các nhà máy nguồn được trình bày trong Hình S1, còn các hồ sơ TMP của chúng trong các giai đoạn giám sát được trình bày trong Hình S2. Các nhà máy này có cấu hình quy trình tương đương, gồm xử lý sinh học thiếu khí/hiếu khí, tiếp theo là quá trình phân tách bằng màng nhúng, với phương thức tuần hoàn và thải bỏ bùn thông thường. Các đặc điểm chi tiết của hệ thống màng và các thông số vận hành được tóm tắt trong Bảng S1. Mặc dù thành phần nước đầu vào của nhà máy đích khác với các nhà máy nguồn do có bổ sung Fe ở công đoạn phía trước, cấu hình xử lý tổng thể của nhà máy này vẫn tương đương với các nhà máy nguồn, với cơ chế gây bám bẩn màng MBR nhìn chung tương tự, qua đó hỗ trợ việc áp dụng học chuyển giao giữa các nhà máy nguồn và nhà máy đích.

Đối với mỗi nhà máy, bộ dữ liệu bao gồm 11 biến: HRT, SRT, thông lượng màng (FLUX), nhu cầu oxy hóa học tổng và hòa tan (TCOD và SCOD), MLSS, MLVSS, EPSp, EPSc, SMPp và SMPc. TMP được thu thập từ hoạt động giám sát trực tuyến thường quy và căn chỉnh theo từng ngày lấy mẫu để phục vụ phân tích tiếp theo.

2.2. Physicochemical analytical methods

HRT, SRT và FLUX được ghi nhận là các thông số vận hành thường quy. TCOD và SCOD được xác định bằng phương pháp APHA 5220D kín

phương pháp so màu hồi lưu, MLSS và MLVSS được đo theo Standard Methods [28]. SMP được xác định là phần hòa tan của dịch nổi sau khi lọc qua màng 0,45 μ m, còn EPS được chiết từ sinh khối còn lại bằng phương pháp gia nhiệt [29]. Protein và polysaccharide trong SMP và EPS, bao gồm SMPp, SMPc, EPSp và EPSc, lần lượt được định lượng bằng phép thử protein Lowry cải tiến và phương pháp Dubois [30]. Sắc ký lỏng-phát hiện carbon hữu cơ (LC-OCD) được sử dụng để đặc trưng chất hữu cơ hòa tan, bao gồm các polyme sinh học có khối lượng phân tử (MW) lớn hơn 20 kDa và các hợp chất có khối lượng phân tử thấp (LMW) với MW dưới 1000 Da, chẳng hạn như các chất humic, khối cấu tạo, axit LMW và các chất trung tính LMW. Phân bố kích thước hạt (PSD) của hỗn hợp bùn được phân tích bằng máy phân tích hạt nhiễu xạ laser. Thời gian hút mao dẫn (CST) được đo bằng thiết bị CST [31]. Tổng carbon hữu cơ (TOC) được đo bằng máy phân tích TOC (TOC-VCSH, Shimadzu, Nhật Bản). Phổ ma trận kích thích-phát xạ (EEM) được đo bằng máy quang phổ huỳnh quang [32]. Tổng sắt được đo bằng phương pháp quang phổ phát xạ quang học plasma cảm ứng cao tần (ICP-OES).

2.3. Data preprocessing and feature selection

To ensure reliable model development, the raw datasets were first preprocessed by outlier treatment and missing-value imputation (**Text S2**). To place variables on comparable scales and prevent variables with larger numerical ranges from dominating model training, z-score standardization was applied during preprocessing (**Text S3**). The scaler was fitted using the training data only, and model outputs were inverse-transformed to the original scale after training.

The final prediction target of this study was next-day TMP, whereas dTMP was used only as an intermediate training target to alleviate non-stationarity and improve output comparability across plants [33,34]. Compared with raw TMP values, dTMP reduced inter-plant differences in TMP level and produced distributions more centered around zero (**Fig. S3**). Predicted dTMP values were then added to the current-day TMP to reconstruct next-day TMP for model evaluation and presentation.

To assess source–target distribution discrepancy and overlap relevant to transfer learning, joint principal component analysis (PCA) was performed using the input variables together with dTMP. The input and output blocks were standardized separately and assigned equal overall weights (**Text S4**).

The sample-size-to-feature ratio (SFR) is an important indicator of whether model complexity is appropriate for a given dataset size, and in small-sample modeling an SFR greater than 10 is generally considered desirable [35]. Therefore, Pearson correlation analysis was used as a coarse pre-screening step (**Text S5**). Because the final prediction target remained next-day TMP, this initial screening was performed against TMP rather than dTMP. It considered both feature–target association and inter-feature collinearity, but served only as a pragmatic dimensionality-control procedure rather than a definitive assessment of nonlinear predictive relevance.

2.4. Construction of base models based on source plants

Given the time-series nature of the data, the source datasets were split within each plant according to chronological order rather than randomly, thereby reducing the risk of information leakage between temporally adjacent samples. Considering the limited sample sizes and short input window, LSTM was selected as a compact recurrent architecture for sequence learning [36]. Transformer- and TCN-based models may offer advantages when larger MBR datasets or longer temporal contexts are available, and systematic benchmarking under such conditions remains a direction for future work [37,38]. Accordingly, two base models were developed: LSTM-base for recurrent sequence learning and XGBoost-base for tree-based learning (**Fig. 1(c)**). LSTM-base used standardized feature sequences with a sequence length of 3 time steps, whereas XGBoost-base used the same three-step historical information encoded as lagged features. This design ensured that the two base models used the same amount of historical information, allowing a fair comparison of their predictive performance. Additional implementation details are provided in **Text S6**.

Hyperparameters for both base models were optimized using the training split of the source plant datasets. Because the data were time-ordered, five-fold time-series cross-validation was combined with Optuna-based hyperparameter search to prevent leakage from future samples and improve the robustness of model selection. After optimization, both base models were trained on the same training split, and the trained models were saved to initialize the transfer learning models. The hyperparameter search spaces, final settings, and training details are provided in **Table S2–S3** and **Text S7**.

2.5. Construction of the baseline model for the target plant

Before establishing transfer learning models, a baseline model was developed using only the target plant dataset, and its performance was

compared with that of the transfer learning models. To ensure comparability, the target plant dataset was partitioned in chronological order, with the first 50% used for model training and the final 50% reserved for testing. Under this split, only a limited amount of target plant data was available for model training. With such a small training set, a standalone target-trained LSTM baseline would be more prone to unstable fitting and overfitting, making the resulting comparison less reliable [39]. An independent XGBoost model was therefore adopted as the baseline. It was trained on the training portion of the target plant dataset using the same feature set as the transfer learning models, and the scaler for the target variable was fitted independently using the same training portion. Detailed settings are listed in **Table S4**.

2.6. Construction of transfer learning models

For transfer learning, the target plant dataset was partitioned chronologically using the same 50:50 split: the first 50% was used as the fine-tuning pool, whereas the final 50% was kept unseen during fine-tuning and reserved as an independent testing set (**Fig. 1(d)**), thereby reducing the risk of temporal information leakage. The fine-tuning ratio (FT) was defined as the proportion of the total target plant dataset used for fine-tuning, and was examined at 0, 10%, 20%, 30%, 40%, and 50%. The exact numbers of target plant records in the fine-tuning pool, testing set, and each FT setting are summarized in **Table S5**. The resulting transfer models were denoted as LSTM-FT and XGBoost-FT. At FT = 0, no target plant samples were used for fine-tuning, and the two models therefore corresponded to direct transfer without target plant adaptation.

For each nonzero FT setting, multiple fine-tuning segments of the corresponding length were sampled from the fine-tuning pool to reduce dependence on any single local history (**Text S8**). Each segment-level experiment was repeated with five random seeds, and performance was reported as the mean $\pm$ standard deviation across all fine-tuning segments and repeated runs. LSTM-FT and XGBoost-FT were fine-tuned using different update strategies, with implementation details and hyperparameter settings provided in **Table S6–S7** and **Text S9**.

All experiments were implemented in Python 3.10.18 using relevant third-party libraries. The deep-learning models were built and trained in PyTorch 2.7.0. The computing environment included an Intel Core i7-14700KF processor (28 logical cores), 32 GB RAM, and an NVIDIA GeForce RTX 5060 Ti GPU.

2.7. Evaluation of model performance

Model performance was evaluated using R^2 , RMSE, and MAE (details in **Text S10**). Model interpretability was examined using LOFO and SHAP analyses (**Fig. 1(e)**), as detailed in **Text S11** and **Text S12**, respectively.

2.8. Model adaptability under cross-scenario conditions

Additional validation was conducted using data from a pilot-scale MBR treating mixed petrochemical and pharmaceutical industrial wastewater in Singapore. Detailed process configuration and operating parameters are provided in **Table S8**. This validation was performed using LSTM-FT under two fine-tuning conditions, FT = 0 and FT = 40%. To maintain consistency with the main analysis, the pretrained model, chronological fine-tuning/testing logic, data preprocessing procedure, and model settings were kept the same. Accordingly, this test was intended to assess whether the established workflow could remain effective under industrial wastewater conditions, without additional model optimization.

2.3. Data preprocessing and feature selection

Để đảm bảo quá trình phát triển mô hình đáng tin cậy, các bộ dữ liệu thô trước tiên được tiền xử lý bằng cách xử lý giá trị ngoại lai và bù đắp các giá trị thiếu (Văn bản S2). Để đưa các biến về cùng thang đo và ngăn các biến có phạm vi giá trị số lớn hơn chi phối quá trình huấn luyện mô hình, phép chuẩn hóa z-score được áp dụng trong quá trình tiền xử lý (Văn bản S3). Bộ chuẩn hóa chỉ được khớp trên dữ liệu huấn luyện, và đầu ra của mô hình được biến đổi ngược về thang đo ban đầu sau khi huấn luyện.

Mục tiêu dự đoán cuối cùng của nghiên cứu này là TMP ngày tiếp, trong khi dTMP chỉ được dùng làm mục tiêu huấn luyện trung gian nhằm giảm thiểu tình không dùng và cải thiện khả năng so sánh đầu ra giữa các nhà máy [33,34]. So với các giá trị TMP thô, dTMP làm giảm khác biệt giữa các nhà máy về mức TMP và tạo ra các phân phối tập trung hơn quanh giá trị không (Hình S3). Sau đó, các giá trị dTMP dự đoán được cộng với TMP của ngày hiện tại để khôi phục TMP ngày kế tiếp, phục vụ việc đánh giá và trình bày mô hình.

Để đánh giá độ chênh lệch và mức độ chồng lấp giữa phân phối nguồn–đích liên quan đến học chuyển giao, phân tích thành phần chính (PCA) được thực hiện bằng cách sử dụng các biến đầu vào cùng với dTMP. Các khối đầu vào và đầu ra được chuẩn hóa riêng biệt và được gán trọng số tổng thể bằng nhau (Văn bản S4).

Tỷ lệ giữa kích thước mẫu và số lượng đặc trưng (SFR) là một chỉ báo quan trọng để đánh giá liệu độ phức tạp của mô hình có phù hợp với quy mô của tập dữ liệu hay không; trong mô hình hóa với mẫu nhỏ, SFR lớn hơn 10 thường được xem là mong muốn [35]. Do đó, phân tích tương quan Pearson được sử dụng như một bước sàng lọc sơ bộ ở mức độ khái quát (Văn bản S5). Vì mục tiêu dự đoán cuối cùng vẫn là TMP của ngày tiếp theo, bước sàng lọc ban đầu này được thực hiện đối với TMP thay vì dTMP. Bước này xem xét cả mối liên hệ giữa đặc trưng và mục tiêu lẫn tính đa cộng tuyến giữa các đặc trưng, nhưng chỉ đóng vai trò là một quy trình kiểm soát sơ bộ, không tính thực tiễn, chứ không phải là đánh giá cuối cùng về mức độ liên quan của các đặc trưng đối với khả năng dự đoán phi tuyến.

2.4. Construction of base models based on source plants

Do đặc tính chuỗi thời gian của dữ liệu, các tập dữ liệu nguồn được chia trong từng nhà máy theo thứ tự thời gian thay vì ngẫu nhiên, qua đó giảm nguy cơ rò rỉ thông tin giữa các mẫu liên tiếp về thời gian. Xét đến kích thước mẫu hạn chế và cửa sổ đầu vào ngắn, LSTM được chọn làm kiến trúc hồi quy gọn nhẹ để học chuỗi [36]. Các mô hình dựa trên Transformer và TCN có thể có ưu thế khi có sẵn các tập dữ liệu MBR lớn hơn hoặc ngữ cảnh thời gian dài hơn; việc đánh giá chuẩn một cách có hệ thống trong những điều kiện như vậy vẫn là hướng nghiên cứu trong tương lai [37,38]. Theo đó, hai mô hình cơ sở được xây dựng: LSTM-base để học chuỗi hồi quy và XGBoost-base để học dựa trên cây (Hình 1(c)). LSTM-base sử dụng các chu kỳ đặc trưng đã chuẩn hóa với độ dài chuỗi là 3 bước thời gian, trong khi XGBoost-base sử dụng cùng thông tin lịch sử ba bước được mã hóa thành các đặc trưng trễ. Thiết kế này bảo đảm hai mô hình cơ sở sử dụng lượng thông tin lịch sử như nhau, cho phép so sánh công bằng hiệu suất dự đoán của chúng. Chi tiết triển khai bổ sung được trình bày trong Văn bản S6.

Các siêu tham số của cả hai mô hình cơ sở được tối ưu hóa bằng tập huấn luyện của các bộ dữ liệu từ nhà máy nguồn. Do dữ liệu được sắp xếp theo thời gian, phương pháp kiểm định chéo chuỗi thời gian năm phần được kết hợp với tìm kiếm siêu tham số bằng Optuna để ngăn rò rỉ thông tin từ các mẫu trong tương lai và cải thiện độ tin cậy của quá trình lựa chọn mô hình. Sau khi tối ưu hóa, cả hai mô hình cơ sở đều được huấn luyện trên cùng một tập huấn luyện, rồi được lưu lại để khởi tạo các mô hình học chuyển giao. Không gian tìm kiếm siêu tham số, các thiết lập cuối cùng và chi tiết huấn luyện được trình bày trong Bảng S2–S3 và Văn bản S7.

2.5. Construction of the baseline model for the target plant

Trước khi xây dựng các mô hình học chuyển giao, một mô hình cơ sở đã được phát triển chỉ bằng tập dữ liệu của nhà máy mục tiêu, và hiệu suất của mô hình này là

so với các mô hình học chuyển giao. Để đảm bảo khả năng so sánh, tập dữ liệu của nhà máy mục tiêu được chia theo thứ tự thời gian, trong đó 50% đầu tiên được dùng để huấn luyện mô hình và 50% cuối cùng được dành cho kiểm thử. Với cách chia này, chỉ có một lượng dữ liệu hạn chế từ nhà máy mục tiêu được sử dụng để huấn luyện mô hình. Với tập huấn luyện nhỏ như vậy, mô hình LSTM cơ sở được huấn luyện độc lập trên dữ liệu mục tiêu sẽ dễ gặp tình trạng không ổn định và quá khớp hơn, khiến kết quả so sánh kém tin cậy hơn [39]. Vì vậy, một mô hình XGBoost độc lập được chọn làm mô hình cơ sở. Mô hình được huấn luyện trên phần dữ liệu huấn luyện của tập dữ liệu nhà máy mục tiêu bằng cùng tập đặc trưng như các mô hình học chuyển giao; bộ chuẩn hóa cho biến mục tiêu cũng được khớp độc lập trên cùng phần dữ liệu huấn luyện. Các thiết lập chi tiết được liệt kê trong Bảng S4.

2.6. Construction of transfer learning models

Đối với học chuyển giao, tập dữ liệu của nhà máy đích được phân chia theo trình tự thời gian bằng cùng tỷ lệ 50:50: 50% đầu tiên được dùng làm tập dữ liệu tinh chỉnh, trong khi 50% cuối cùng không được sử dụng trong quá trình tinh chỉnh và được dành làm tập kiểm tra độc lập (Hình 1(d)), qua đó giảm nguy cơ rò rỉ thông tin theo thời gian. Tỷ lệ tinh chỉnh (FT) được xác định là tỷ lệ của toàn bộ tập dữ liệu nhà máy đích được sử dụng để tinh chỉnh, và được khảo sát ở các mức 0, 10%, 20%, 30%, 40% và 50%. Số lượng chính xác các báo cáo của nhà máy đích trong tập dữ liệu tinh chỉnh, tập kiểm tra và từng mức FT được tóm tắt trong Bảng S5. Các mô hình chuyển giao thu được được ký hiệu là LSTM-FT và XGBoost-FT. Ở FT = 0, không có mẫu nào từ nhà máy đích được sử dụng để tinh chỉnh; do đó, hai mô hình tương ứng với việc chuyển giao trực tiếp mà không thích ứng với nhà máy đích.

Với mỗi thiết lập FT khác 0, nhiều đoạn tinh chỉnh có độ dài tương ứng được lấy mẫu từ tập dữ liệu tinh chỉnh nhằm giảm sự phụ thuộc vào bất kỳ lịch sử cục bộ đơn lẻ nào (Văn bản S8). Mỗi thí nghiệm ở cấp độ đoạn được lặp lại với năm hạt giống ngẫu nhiên, và hiệu năng được báo cáo bằng giá trị trung bình $\pm$ độ lệch chuẩn trên tất cả các đoạn tinh chỉnh và các lần chạy lặp lại. LSTM-FT và XGBoost-FT được tinh chỉnh bằng các chiến lược cập nhật khác nhau; chi tiết triển khai và các thiết lập siêu tham số được trình bày trong Bảng S6–S7 và Văn bản S9.

Tất cả các thí nghiệm được triển khai bằng Python 3.10.18 với các thư viện bên thứ ba phù hợp. Các mô hình học sâu được xây dựng và huấn luyện bằng PyTorch 2.7.0. Môi trường tính toán bao gồm bộ xử lý Intel Core i7-14700KF (28 lõi logic), RAM 32 GB và GPU NVIDIA GeForce RTX 5060 Ti.

2.7. Evaluation of model performance

Hiệu suất mô hình được đánh giá bằng R^2 , RMSE và MAE (chi tiết trong Văn bản S10). Khả năng diễn giải của mô hình được khảo sát bằng các phân tích LOFO và SHAP (Hình 1(e)), lần lượt được trình bày chi tiết trong Văn bản S11 và Văn bản S12.

2.8. Model adaptability under cross-scenario conditions

Việc xác thực bổ sung được thực hiện bằng dữ liệu từ một hệ thống MBR quy mô thí điểm xử lý nước thải công nghiệp hỗn hợp từ ngành hóa dầu và được phẩm tại Singapore. Cấu hình quy trình và các thông số vận hành chi tiết được trình bày trong Bảng S8. Việc xác thực này được thực hiện bằng LSTM-FT với hai điều kiện tinh chỉnh, FT = 0 và FT = 40%. Để duy trì tính nhất quán với phân tích chính, mô hình tiền huấn luyện, logic tinh chỉnh/kiểm thử theo trình tự thời gian, quy trình tiền xử lý dữ liệu và các thiết lập mô hình được giữ nguyên. Theo đó, phép thử này nhằm đánh giá liệu quy trình đã thiết lập có tiếp tục hoạt động hiệu quả trong điều kiện nước thải công nghiệp hay không, mà không cần tối ưu hóa mô hình bổ sung.

3. Results and discussion

3.1. Source–target distribution and PCA analysis

The distributions of the measured variables across the source and target plants are presented in Fig. 2(c), and the corresponding average values are summarized in Fig. 2(d). At the level of core operating variables, the target plant remained within or close to the ranges of the source plants (HRT of 5.5 h versus 5.0–5.5 h, SRT of 6.8 d versus 5.0–7.0 d, and FLUX of 25 LMH versus 25–44 LMH). Across the source plants, the measured variables covered relatively broad ranges of biomass-related and fouling-related properties (e.g., MLSS of 900–9730 mg/L, MLVSS of 639–7671 mg/L, EPSp of 25.0–658.8 mg/L, EPSc of 0.0–117.1 mg/L, SMPc of 0.8–33.3 mg/L, and SMPp of 2.7–44.5 mg/L). By contrast, the target plant showed comparatively narrower distributions for the biomass-related and fouling-related variables (e.g., MLSS of 3580–7340 mg/L, MLVSS of 3340–5920 mg/L,

EPSp of 73.5–469.9 mg/L, EPSc of 17.1–81.3 mg/L, SMPc of 2.6 to 20.1 mg/L, and SMPp of 4.8–10.8 mg/L). These distributional relationships were further examined by PCA (Fig. 3(a)). The first two principal components explained 74.0% of the total variance, indicating that the major variability in the dataset was captured in a two-dimensional projection. The source plant datasets showed substantial overlap, indicating broadly similar fouling-related variable patterns across the source plants. By contrast, the target plant dataset formed a more compact cluster with partial separation from the source plants, indicating a measurable distribution shift. Importantly, a clear overlap region remained between the target and source datasets. This overlap provided a reasonable basis for developing base models using the source plant datasets and supported the feasibility of subsequent transfer learning.





Fig. 3. Source–target data distribution, feature collinearity, and predictive performance of the base models: (a) joint PCA of the source and target plant datasets, (b) feature–feature (X–X) Pearson correlation heatmap, and prediction scatter plots for (c) XGBoost-base and (d) LSTM-base.

3. Kết quả và thảo luận

3.1. Source–target distribution and PCA analysis

Phân bố các biến đo được tại các nhà máy nguồn và nhà máy đích đã được trình bày trong Hình 2(c), còn các giá trị trung bình tương ứng đã được tóm tắt trong Hình 2(d). Xét các biến vận hành cốt lõi, nhà máy đích nằm trong hoặc gần với phạm vi của các nhà máy nguồn (HRT là 5,5 h so với 5,0–5,5 h, SRT là 6,8 d so với 5,0–7,0 d và FLUX là 25 LMH so với 25–44 LMH). Tại các nhà máy nguồn, các biến đo được bao phủ phạm vi tương đối rộng về các đặc tính liên quan đến sinh khối và cấu bẩn (ví dụ: MLSS là 900–9730 mg/L, MLVSS là 639–7671 mg/L, EPSp là 25,0–658,8 mg/L, EPSc là 0,0–117,1 mg/L, SMPc là 0,8–33,3 mg/L và SMPp là 2,7–44,5 mg/L). Ngược lại, nhà máy đích có phân bố hẹp hơn đáng kể đối với các biến liên quan đến sinh khối và cấu bẩn (ví dụ: MLSS là 3580–7340 mg/L, MLVSS là 3340–5920 mg/L,

EPSp ở mức 73,5–469,9 mg/L, EPSc ở mức 17,1–81,3 mg/L, SMPc ở mức 2,6–20,1 mg/L và SMPp ở mức 4,8–10,8 mg/L). Các mối quan hệ phân bố này được khảo sát sâu hơn bằng PCA (Hình 3(a)). Hai thành phần chính đầu tiên giải thích 74,0% tổng phương sai, cho thấy phần lớn biến thiên trong tập dữ liệu được thể hiện trong phép chiếu hai chiều. Các tập dữ liệu của các nhà máy nguồn chồng lấn đáng kể, cho thấy các kiểu biến liên quan đến cấu bẩn nhìn chung tương tự nhau giữa các nhà máy nguồn. Ngược lại, tập dữ liệu của nhà máy đích tạo thành một cụm tập trung hơn và tách biệt một phần khỏi các nhà máy nguồn, cho thấy có sự dịch chuyển phân bố đáng kể. Đáng chú ý, vẫn có một vùng chồng lấn rõ rệt giữa các tập dữ liệu đích và nguồn. Vùng chồng lấn này tạo cơ sở hợp lý để xây dựng các mô hình cơ sở bằng tập dữ liệu của các nhà máy nguồn, đồng thời củng cố tính khả thi của việc học chuyển giao sau đó.



Hình 3. Phân bố dữ liệu nguồn–đích, tính đa cộng tuyến giữa các đặc trưng và hiệu suất dự đoán của các mô hình cơ sở: (a) PCA kết hợp của bộ dữ liệu cây trồng nguồn và đích, (b) nhiệt tương quan Pearson giữa các đặc trưng (X–X) và biểu đồ phân tán dự đoán cho (c) mô hình nền XGBoost và (d) mô hình nền LSTM.

3.2. Construction and evaluation of base models

3.2.1. Correlation-based feature selection

Feature–target (X–y) Pearson correlation analysis was further conducted, and the ranking results are shown in Fig. S4. Overall, FLUX, EPSc, HRT, and SMPp showed relatively strong correlations with TMP, with $|r_{x,y}|$ values of 0.471, 0.462, 0.440, and 0.347, respectively. In contrast, SCOD, SMPc, and TCOD showed weak correlations with TMP, with $|r_{x,y}|$ values all below 0.1, and were therefore excluded from the reduced input set used for subsequent modeling. The remaining variables were kept for the subsequent collinearity screening step.

Feature–feature (X–X) Pearson correlation analysis was then performed to further control inter-feature collinearity (Fig. 3(b)). HRT was strongly negatively correlated with FLUX ($r_{x_i,x_k} = -0.86$), likely reflecting their operational coupling: HRT is inversely related to treatment flow rate, whereas FLUX represents the permeate throughput per unit membrane area [8]. MLSS and MLVSS showed a very strong positive correlation ($r_{x_i,x_k} = 0.96$), consistent with MLVSS representing the volatile biomass fraction of MLSS [40]. Within these two collinear feature pairs, FLUX and MLVSS had higher $|r_{x,y}|$ values with TMP and were therefore retained. Accordingly, FLUX, SRT, MLVSS, EPSc, EPSp, and SMPp were retained as a reduced input set for subsequent base model development.

3.2.2. Performance evaluation of base models

The prediction scatter plots for both base models show that most training and testing points were distributed close to the line of equality, indicating good agreement between the predicted and observed TMP values in the source plants. XGBoost-base achieved an R^2 of 0.86, an RMSE of 3.01 kPa, and an MAE of 1.94 kPa on the test set (Fig. 3(c)). LSTM-base showed slightly better performance, with an R^2 of 0.87, an RMSE of 2.86 kPa, and an MAE of 1.68 kPa (Fig. 3(d)). Larger prediction deviations were observed at higher TMP values in both models, suggesting that TMP prediction became more difficult under more severe fouling conditions, possibly due to intensified fouling-layer compression and nonlinear fouling resistance at elevated TMP levels [41]. Overall, both models captured the main TMP variations in the source datasets, with LSTM-base showing a small but consistent advantage over XGBoost-base.

3.2.3. SHAP interpretation of base models and physicochemical characterization

SHAP attribution patterns were further analyzed for both base models. ChatGPT-5.4 was used only as an auxiliary tool to support the summarization of these attribution patterns, while the final interpretation was performed by the authors based on the SHAP plots and corresponding feature-attribution results (Fig. 6(d)). For LSTM-base, the SHAP summary plots showed that EPSc, MLVSS, EPSp, and SMPp made the largest contributions (Fig. 6(a); Fig. S5), whereas FLUX and SRT were comparatively less influential. XGBoost-base showed a much more concentrated attribution pattern, with FLUX dominating the SHAP attribution and contributing more than the other input variables (Fig. S6(a); Fig. S6(b)). These results indicate that the two base models achieved similar predictive performance but relied on different predictive structures during pretraining on the source plants. The broader dependence of LSTM-base on EPSc, MLVSS, EPSp, and SMPp may partly reflect the greater suitability of sequence-learning architectures for variables with stronger temporal continuity and gradual variation [42]. In contrast, the FLUX-dominated attribution pattern in XGBoost-base was consistent with the X–y correlation analysis and may partly reflect the tendency of tree-based models to rely heavily on a dominant predictive signal [43, 44]. These results were consistent with the subsequent transfer learning results, which showed that XGBoost-FT achieved only limited improvement compared with LSTM-FT (discussed in Section 3.3).

Given that LSTM-base achieved strong source-domain predictive

performance and showed much more promise in transfer learning (discussed in Section 3.3), the physicochemical characteristics of biomass in the source plants were further examined to determine whether its learned attribution pattern was consistent with real fouling mechanisms. EPS and SMP were emphasized, because they were identified as important features in the SHAP analysis. Specifically, EPS is more closely associated with sludge flocs and membrane-associated fouling [45], whereas SMP mainly represents soluble organics [46].

Concretely, the three source plants showed a consistent EPS-related signature, including a shared aromatic protein-like peak in the EPS EEM spectra ($E_x/E_m \approx 220\text{--}225/325\text{--}355$ nm; Fig. 4(a)–(c)), and sludge particle-size distributions dominated by particles of 20–40 μm (Fig. 4(d)). These features generally suggested a readily depositable sludge structure that could promote cake-layer formation in MBRs [47]. Moreover, the protein fraction represented by EPSp likely comprises aromatic protein-like components, which could be associated with sludge floc aggregation and the initial adhesion of foulants to the membrane surface [48]. By comparison, EPSc may be more closely related to the gel-forming and resistance-enhancing effects of the polysaccharide matrix, thereby further increasing the hydraulic resistance of the fouling layer [49]. The relatively high attribution of MLVSS (revealed by SHAP) was also physically reasonable, as MLVSS represents the biomass fraction that carries EPS and contributes to sludge deposition on the membrane surface [3].

Additionally, SMP from the three source plants exhibited similar EEM spectral features, with a shared aromatic protein-like fluorescence peak ($E_x/E_m \approx 220\text{--}230/330\text{--}350$ nm; Fig. S7(a)–(c)). These aromatic protein-like SMP components may contribute to fouling development through membrane-surface adsorption or retention within the developing fouling layer, particularly during the early stage of membrane fouling [50,51]. This interpretation was further supported by the LC-OCD results (Fig. 4(e) and (f); Table S9), which showed that SMP in the three source plants was dominated by hydrophilic DOC, with humics and biopolymers as the major fractions. For each LC-OCD fraction, rejection was calculated as the percentage decrease from its concentration in SMP to that in the corresponding effluent, relative to its concentration in SMP. On this basis, biopolymers showed the highest rejection across the three source plants, ranging from 90.0 to 95.3%. These results suggest that SMPp may mainly reflect the aromatic protein-like component within the biopolymer pool that was preferentially retained by the membrane and could therefore participate directly in organic membrane fouling [52].

Overall, the shared physicochemical characteristics of source plants provide clear mechanism-informed support for the EPS- and SMP-related attribution pattern learned by LSTM-base. This indicates that the learned structure was not merely statistical but grounded in real fouling-related properties. In turn, this supports the use of LSTM-base as a reliable pretrained model for subsequent transfer learning.

3.3. Transfer learning performance and interpretation

3.3.1. Effect of fine-tuning ratio on transfer learning performance

The effect of fine-tuning ratio (FT) on transfer learning performance was examined to determine the amount of target-plant data required for effective adaptation. At FT = 0, representing direct transfer without target plant adaptation, the pretrained LSTM and XGBoost models showed similarly low R^2 values of 0.41 and 0.39, respectively, indicating limited predictive power under zero-shot transfer. Together with the PCA results showing a measurable source–target distribution shift, this finding suggests that direct transfer alone was insufficient for reliable TMP prediction in the target plant [53].

For LSTM-FT, the largest gain occurred between FT = 0 and FT = 10%, with R^2 increasing from 0.41 to 0.81 (Fig. 5(a)). As FT further increased, the performance improved more gradually, reaching R^2 , RMSE, and MAE values of 0.89, 0.50 kPa, and 0.33 kPa, respectively, at FT = 40% (Fig. 5(b) and (c)). At FT = 50%, the improvement relative to

3.2. Construction and evaluation of base models

3.2.1. Correlation-based feature selection

Phân tích tương quan Pearson giữa đặc trưng và mục tiêu (X–y) cũng được tiến hành, và kết quả xếp hạng được thể hiện trong Hình S4. Nhìn chung, FLUX, EPSc, HRT và SMPp có tương quan tương đối mạnh với TMP, với các giá trị $|r_{x,y}|$ lần lượt là 0.471, 0.462, 0.440 và 0.347. Ngược lại, SCOD, SMPc và TCOD có tương quan yếu với TMP, với các giá trị $|r_{x,y}|$ đều dưới 0.1, do đó bị loại khỏi tập đầu vào rút gọn dùng cho các bước mô hình hóa tiếp theo. Các biến còn lại được giữ lại để thực hiện bước sàng lọc đa cộng tuyến tiếp theo.

Sau đó, phân tích tương quan Pearson giữa các đặc trưng (X–X) được thực hiện nhằm kiểm soát thêm hiện tượng đa cộng tuyến giữa các đặc trưng (Hình 3(b)). HRT tương quan âm mạnh với FLUX ($r_{x_i,x_k} = -0.86$), có thể phản ánh mối liên hệ trong vận hành giữa chúng: HRT tỷ lệ nghịch với lưu lượng xử lý, trong khi FLUX biểu thị lưu lượng nước thấm trên mỗi đơn vị diện tích màng [8]. MLSS và MLVSS có tương quan dương rất mạnh ($r_{x_i,x_k} = 0.96$), phù hợp với việc MLVSS biểu thị phần sinh khối dễ bay hơi trong MLSS [40]. Trong hai cặp đặc trưng đa cộng tuyến này, FLUX và MLVSS có giá trị $|r_{x,y}|$ cao hơn với TMP nên được giữ lại. Theo đó, FLUX, SRT, MLVSS, EPSc, EPSp và SMPp được giữ làm tập đầu vào rút gọn để phát triển mô hình cơ sở tiếp theo.

3.2.2. Performance evaluation of base models

Các biểu đồ phân tán dự đoán của cả hai mô hình cơ sở cho thấy hầu hết các điểm dữ liệu huấn luyện và kiểm tra phân bố gần đường bình đẳng, cho thấy mức độ phù hợp cao giữa các giá trị TMP dự đoán và quan sát được tại các nhà máy nguồn. XGBoost-base đạt R^2 bằng 0,86, RMSE là 3,01 kPa và MAE là 1,94 kPa trên tập kiểm tra (Hình 3(c)). LSTM-base có hiệu suất nhìn hơn đôi chút, với R^2 bằng 0,87, RMSE là 2,86 kPa và MAE là 1,68 kPa (Hình 3(d)). Cả hai mô hình đều cho thấy sai lệch dự đoán lớn hơn ở các giá trị TMP cao, cho thấy việc dự đoán TMP trở nên khó khăn hơn trong điều kiện cấu trúc màng nghiêm trọng hơn, có thể do sự nén lớp cấu trúc tăng cường và điên trở cấu trúc phi tuyến ở mức TMP cao [41]. Nhìn chung, cả hai mô hình đều nằm bất được những biến thiên TMP chính trong các bộ dữ liệu nguồn, trong đó LSTM-base thể hiện ưu thế nhỏ nhưng nhất quán so với XGBoost-base.

3.2.3. SHAP interpretation of base models and physicochemical characterization

Các mẫu quy kết SHAP được phân tích sâu hơn cho cả hai mô hình cơ sở. ChatGPT-5.4 chỉ được sử dụng như một công cụ hỗ trợ tóm tắt các mẫu quy kết này, còn phần diễn giải cuối cùng do các tác giả thực hiện dựa trên biểu đồ SHAP và kết quả quy kết đặc trưng tương ứng (Hình 6(d)). Đối với LSTM-base, các biểu đồ tóm tắt SHAP cho thấy EPSc, MLVSS, EPSp và SMPp đóng góp nhiều nhất (Hình 6(a); Hình S5), trong khi FLUX và SRT có ảnh hưởng tương đối ít hơn. XGBoost-base cho thấy mẫu quy kết tập trung hơn nhiều, trong đó FLUX chi phối phần quy kết SHAP và đóng góp nhiều hơn các biến đầu vào khác (Hình S6(a); Hình S6(b)). Những kết quả này cho thấy hai mô hình cơ sở đạt hiệu suất dự đoán tương tự nhau nhưng dựa vào các cấu trúc dự đoán khác nhau trong quá trình tiền huấn luyện trên các nhà máy nguồn. Mức độ phụ thuộc rộng hơn của LSTM-base vào EPSc, MLVSS, EPSp và SMPp có thể phản ánh phần nào phản ánh sự phù hợp cao hơn của các kiến trúc học chuỗi đối với những biến có tính liên tục theo thời gian mạnh hơn và biến thiên từ từ [42]. Ngược lại, mẫu quy kết chi phối bởi FLUX ở XGBoost-base phù hợp với phân tích tương quan X–y và có thể phần nào phản ánh xu hướng các mô hình dựa trên cây phụ thuộc nhiều vào một tín hiệu dự đoán chủ đạo [43, 44]. Những kết quả này nhất quán với kết quả học chuyển giao tiếp theo, cho thấy XGBoost-FT chỉ cải thiện ở mức hạn chế so với LSTM-FT (được thảo luận ở Mục 3.3).

Cho thấy LSTM-base đạt khả năng dự đoán mạnh mẽ trong miền nguồn

có hiệu suất và cho thấy nhiều triển vọng hơn trong học chuyển giao (được thảo luận ở Mục 3.3), các đặc tính hóa lý của sinh khối tại các nhà máy nguồn được khảo sát thêm để xác định liệu mô hình quy kết mà nó học được có nhất quán với các cơ chế bám bẩn thực tế hay không. EPS và SMP được nhấn mạnh vì chúng được xác định là những đặc trưng quan trọng trong phân tích SHAP. Cụ thể, EPS liên quan chặt chẽ hơn đến các bông bùn và hiện tượng bám bẩn liên quan đến màng [45], trong khi SMP chủ yếu đại diện cho các chất hữu cơ hòa tan [46].

Cụ thể, ba nhà máy nguồn cho thấy dấu hiệu liên quan đến EPS nhất quán, bao gồm đỉnh giống protein thơm chung trong phổ EEM của EPS ($E_x/E_m \approx 220\text{--}225/325\text{--}355$ nm; Hình 4(a)–(c)) và phân bố kích thước hạt bùn chủ yếu gồm các hạt 20–40 μm (Hình 4(d)). Những đặc điểm này nhìn chung cho thấy cấu trúc bùn dễ lắng đọng, có thể thúc đẩy hình thành lớp bánh trong MBR [47]. Hơn nữa, phần protein được biểu thị bởi EPSp có khả năng bao gồm các thành phần glycosyl protein thơm, có thể liên quan đến sự kết tụ bông bùn và sự bám dính ban đầu của các chất gây bám bẩn lên bề mặt màng [48]. Ngược lại, EPSc có thể liên quan chặt chẽ hơn đến tác động tạo gel và làm tăng sức cản của nền polysaccharide, qua đó tiếp tục làm tăng sức cản thủy lực của lớp bám bẩn [49]. Mức đóng góp tương đối cao của MLVSS (được SHAP thể hiện) cũng hợp lý về mặt vật lý, vì MLVSS biểu thị phần sinh khối mang EPS và góp phần làm bùn lắng đọng trên bề mặt màng [3].

Ngoài ra, SMP từ ba nhà máy nguồn thể hiện các đặc điểm phổ EEM tương tự nhau, với đỉnh huỳnh quang dạng protein thơm chung ($E_x/E_m \approx 220\text{--}230/330\text{--}350$ nm; Hình S7(a)–(c)). Các thành phần SMP dạng protein thơm này có thể góp phần thúc đẩy quá trình hình thành cấu trúc thông qua sự hấp phụ lên bề mặt màng hoặc sự lưu giữ trong lớp cấu trúc đang hình thành, đặc biệt ở giai đoạn đầu của quá trình cấu trúc màng [50,51]. Cách diễn giải này được củng cố thêm bởi kết quả LC-OCD (Hình 4(e) và (f); Bảng S9), cho thấy SMP tại ba nhà máy nguồn chủ yếu là DOC ưa nước, trong đó các chất humic và polyme sinh học là những phân đoạn chính. Với mỗi phân đoạn LC-OCD, tỷ lệ loại bỏ được tính bằng phần trăm giảm nồng độ từ SMP xuống nước thải tương ứng, so với nồng độ trong SMP. Theo cơ sở này, polyme sinh học có tỷ lệ loại bỏ cao nhất ở cả ba nhà máy nguồn, dao động từ 90,0 đến 95,3%. Các kết quả này cho thấy SMPp có thể chủ yếu phản ánh thành phần dạng protein thơm trong nhóm polyme sinh học, vốn được màng giữ lại ưu tiên và do đó có thể trực tiếp tham gia vào quá trình cấu trúc hữu cơ của màng [52].

Nhìn chung, các đặc tính lý hóa chung của thực vật nguồn cung cấp cơ sở rõ ràng, có xét đến cơ chế, để lý giải kiểu quy kết liên quan đến EPS và SMP mà LSTM-base đã học được. Điều này cho thấy cấu trúc được học không chỉ mang tính thống kê mà còn dựa trên các đặc tính thực sự liên quan đến hiện tượng cấu trúc. Từ đó, kết quả này ủng hộ việc sử dụng LSTM-base làm mô hình tiền huấn luyện đáng tin cậy cho quá trình học chuyển giao tiếp theo.

3.3. Transfer learning performance and interpretation

3.3.1. Effect of fine-tuning ratio on transfer learning performance

Ảnh hưởng của tỷ lệ tinh chỉnh (FT) đến hiệu suất học chuyển giao được khảo sát nhằm xác định lượng dữ liệu từ nhà máy đích cần thiết để thích nghi hiệu quả. Ở FT = 0, tương ứng với chuyển giao trực tiếp mà không thích nghi với nhà máy đích, các mô hình LSTM và XGBoost được huấn luyện trước có giá trị R^2 thấp tương tự, lần lượt là 0.41 và 0.39, cho thấy khả năng dự đoán hạn chế trong điều kiện chuyển giao zero-shot. Cùng với kết quả PCA cho thấy sự dịch chuyển phân phối đáng kể giữa nguồn và đích, phát hiện này gợi ý rằng chỉ chuyển giao trực tiếp là chưa đủ để dự đoán TMP đáng tin cậy tại nhà máy đích [53].

Đối với LSTM-FT, mức cải thiện lớn nhất diễn ra khi FT = tăng từ 0 lên 10%, với R^2 tăng từ 0,41 lên 0,81 (Hình 5(a)). Khi FT tiếp tục tăng, hiệu suất cải thiện dần chậm hơn, đạt các giá trị R^2 , RMSE và MAE lần lượt là 0,89, 0,50 kPa và 0,33 kPa tại FT = 40% (Hình 5(b) và (c)). Ở FT = 50%, mức cải thiện so với





Fig. 4. Physicochemical evidence supporting the EPS- and SMP-related attribution pattern learned by LSTM-base in the source plants: EEM spectra of EPS from (a) Plant 1, (b) Plant 2, and (c) Plant 3; (d) sludge particle-size distributions of Plants 1–3 and the target plant; LC-OCD-derived organic fraction concentrations in (e) SMP and (f) effluent from Plants 1–3.



Hình 4. Bằng chứng lý hóa hỗ trợ mô hình quy kết liên quan đến EPS và SMP được LSTM-base học từ các nhà máy nguồn: phổ EEM của EPS từ (a) Nhà máy 1, (b) Nhà máy 2 và (c) Nhà máy 3; (d) phân bố kích thước hạt bùn của các Nhà máy 1–3 và nhà máy đích; nồng độ các phân đoạn hữu cơ suy ra từ LC-OCD từ (e) SMP và (f) nước thải đầu ra của các Nhà máy 1–3.





Fig. 5. Effect of fine-tuning ratio on target plant prediction performance and LOFO analysis: (a) R^2 , (b) RMSE, and (c) MAE as functions of fine-tuning ratio, (d) observed versus predicted TMP values for the baseline model, XGBoost-FT, and LSTM-FT on the target plant testing set, with the transfer models evaluated at FT = 40%, and (e) LOFO analysis results for LSTM-FT at FT = 40%. For each nonzero FT setting in (a)–(c), performance is reported as mean $\pm$ standard deviation across all fine-tuning segments and repeated runs, using up to six contiguous segments sampled from the fine-tuning pool and five random seeds for each retained segment.

FT = 40% was only marginal. In comparison, XGBoost-FT also improved with increasing FT, but the gains were smaller and more gradual, with



Hình 5. Ảnh hưởng của tỷ lệ tinh chỉnh đến hiệu suất dự đoán tại nhà máy mục tiêu và phân tích LOFO: (a) R^2 , (b) RMSE và (c) MAE theo tỷ lệ tinh chỉnh, (d) các giá trị TMP quan sát được so với giá trị dự đoán của mô hình cơ sở, XGBoost-FT và LSTM-FT trên tập kiểm thử của nhà máy mục tiêu, trong đó các mô hình chuyển giao được đánh giá ở mức FT = 40%, và (e) kết quả phân tích LOFO cho LSTM-FT ở mức FT = 40%. Với mỗi thiết lập FT khác 0 trong (a)–(c), hiệu suất được báo cáo dưới dạng giá trị trung bình $\pm$ độ lệch chuẩn qua tất cả các đoạn tinh chỉnh và các lần chạy lặp lại, sử dụng tối đa sáu đoạn liên tiếp được lấy mẫu từ tập dữ liệu tinh chỉnh và năm hạt giống ngẫu nhiên cho mỗi đoạn được giữ lại.

FT = 40% was only marginal. In comparison, XGBoost-FT also improved khi FT tăng, nhưng mức tăng nhỏ hơn và diễn ra từ từ hơn, với




Fig. 6. SHAP attribution patterns and LLM-assisted summary for LSTM-base and LSTM-FT: SHAP summary plots of (a) LSTM-base, (b) LSTM-FT at FT = 0, (c) LSTM-FT at FT = 40%, (d) LLM-assisted summary of the corresponding SHAP observations.

R^2 increasing from 0.39 at FT = 0 to 0.58 at FT = 40% and only slightly further to 0.61 at FT = 50%. Overall, LSTM-FT showed larger performance gains at low FT levels than XGBoost-FT, and increasing FT beyond 40% provided limited additional improvement. Because both transfer models were adapted from models pretrained on the source plant datasets, these performance improvements should be interpreted as target plant adaptation through transfer learning under realistic data-limited conditions, rather than as conventional model development based solely on the 71 target plant records. In addition, for both transfer models the standard deviation across the fine-tuning segments and repeated runs was largest at FT = 10% and decreased at higher FT, becoming small by FT = 40%. This indicates that too few target records reduced the robustness of adaptation, whereas a moderate amount of target data was sufficient for stable performance. Accordingly, FT = 40% was selected as the representative fine-tuning condition for the subsequent analyses.

3.3.2. Performance comparison of baseline model and transfer learning models

To compare predictive performance on the target plant, the baseline model (specifically trained based on target plant datasets) together with LSTM-FT and XGBoost-FT was evaluated (Fig. 5(d)).

The testing samples were mainly distributed within a TMP range of approximately 19–21.5 kPa, with fewer samples at lower TMP values of around 15.5–18 kPa. Within the main TMP range, LSTM-FT showed the tightest clustering around the line of equality, indicating the best agreement between predicted and observed TMP values. The baseline model showed moderate deviations, whereas XGBoost-FT exhibited the largest scatter and the most evident departure from the line of equality. These patterns suggest that transfer learning improved target plant prediction when implemented with LSTM, whereas XGBoost-FT did not provide a performance advantage under the present setting.


The quantitative metrics showed the same trend. Relative to the baseline model, LSTM-FT reduced RMSE from 0.63 to 0.50 kPa and MAE from 0.45 to 0.33 kPa, corresponding to decreases of 20.6% and 26.7%, respectively, while increasing R^2 from 0.82 to 0.89. By contrast, XGBoost-FT increased RMSE to 0.96 kPa and MAE to 0.81 kPa, and

reduced R^2 to 0.58. Taken together, these results indicate that LSTM-FT achieved the best predictive performance under limited target plant data, outperforming both the baseline model and XGBoost-FT. Therefore, the following sections focus on LSTM-FT to further interpret the observed transfer behavior using LOFO and SHAP analyses.

3.3.3. LOFO and SHAP interpretation of feature contributions during transfer

LOFO and SHAP analyses were used to identify the variables that supported transfer performance in LSTM-FT. LOFO analysis was first conducted to evaluate the effect of each input variable on LSTM-FT performance at FT = 40% (Fig. 5(e)). The reference model was the LSTM-FT model trained with all input variables, which achieved an MAE of 0.33 kPa. Each variable was then removed individually, and the resulting MAE was compared with that of the reference model using paired two-sided Wilcoxon signed-rank tests (Table S10). Removing EPSc caused the largest performance loss, increasing MAE to 0.37 kPa ($p \leq 0.001$), indicating that EPSc was the most important variable for maintaining LSTM-FT performance. Removing EPSp or SRT also increased MAE to 0.35 kPa (both $p \leq 0.001$), whereas removing FLUX caused a smaller but still significant increase ($p \leq 0.01$). Overall, the LOFO results confirmed that EPS-related variables, especially EPSc and EPSp, were important for LSTM-FT performance, while SRT and FLUX also showed smaller but statistically significant effects.

SHAP analysis was further used to examine how the feature-attribution pattern evolved with increasing FT. Under zero-shot transfer (FT = 0), EPSc was the top-ranked feature, contributing the largest share of the total attribution, well above MLVSS and EPSp (Fig. 6(b); Fig. S8(a)). This suggests that, under zero-shot transfer, the transferred model retained a strongly EPSc-centered attribution pattern, reflecting limited recalibration before fine-tuning. From FT = 10% to 30%, the attribution pattern became more distributed, with increased attribution to EPSp and more comparable contributions from EPSc, SRT, and MLVSS (Fig. S9–S10). At FT = 40%, EPSc and EPSp were the two top-ranked features and together accounted for more than half of the total attribution (Fig. 6(c); Fig. S8(b)), indicating a more balanced EPS-centered attribution structure after fine-tuning. The feature ranking and



Hình 6. Các mẫu phân bố SHAP và bản tóm tắt có hỗ trợ LLM cho LSTM-base và LSTM-FT: Biểu đồ tóm tắt SHAP của (a) LSTM-base, (b) LSTM-FT tại FT = 0, (c) LSTM-FT tại FT = 40%, (d) Bản tóm tắt được hỗ trợ bởi LLM về các quan sát SHAP tương ứng.

R^2 tăng từ 0,39 ở FT = 0 lên 0,58 ở FT = 40% và chỉ tăng nhẹ lên 0,61 ở FT = 50%. Nhìn chung, LSTM-FT đạt mức cải thiện hiệu suất lớn hơn ở các mức FT thấp so với XGBoost-FT, và việc tăng FT vượt quá 40% chỉ mang lại cải thiện bổ sung hạn chế. Vì cả hai mô hình chuyển giao đều được điều chỉnh từ các mô hình tiền huấn luyện trên bộ dữ liệu của nhà máy nguồn, nên những cải thiện hiệu suất này cần được hiểu là kết quả thích ứng với nhà máy đích thông qua học chuyển giao trong điều kiện thực tế bị hạn chế dữ liệu, chứ không phải là quá trình phát triển mô hình thông thường chỉ dựa trên 71 bản ghi của nhà máy đích. Ngoài ra, ở cả hai mô hình chuyển giao, độ lệch chuẩn giữa các phân đoạn tinh chỉnh và các lần chạy lặp lại đều lớn nhất tại FT = 10% và giảm ở các mức FT cao hơn, xuống mức thấp ở FT = 40%. Điều này cho thấy số lượng bản ghi mục tiêu quá ít làm giảm tính ổn định của quá trình thích ứng, trong khi một lượng dữ liệu mục tiêu vừa phải là đủ để duy trì hiệu suất ổn định. Do đó, FT = 40% được chọn làm điều kiện tinh chỉnh đại diện cho các phân tích tiếp theo.

3.3.2. Performance comparison of baseline model and transfer learning models

Để so sánh hiệu suất dự đoán trên nhà máy mục tiêu, mô hình cơ sở (được huấn luyện riêng dựa trên các bộ dữ liệu của nhà máy mục tiêu), cùng với LSTM-FT và XGBoost-FT, đã được đánh giá (Hình 5(d)).

Các mẫu kiểm tra chủ yếu tập trung trong khoảng TMP từ khoảng 19–21,5 kPa, với ít mẫu hơn ở các giá trị TMP thấp hơn, khoảng 15,5–18 kPa. Trong khoảng TMP chính, LSTM-FT có các điểm tập trung sát nhất quanh đường đồng nhất, cho thấy mức độ phù hợp cao nhất giữa giá trị TMP dự đoán và quan sát. Mô hình cơ sở có độ lệch vừa phải, trong khi XGBoost-FT có độ phân tán lớn nhất và lệch rõ rệt nhất khỏi đường đồng nhất. Các xu hướng này cho thấy học chuyển giao đã cải thiện khả năng dự đoán tại nhà máy mục tiêu khi được triển khai với LSTM, trong khi XGBoost-FT không mang lại lợi thế về hiệu suất trong thiết lập hiện tại.

Các chỉ số định lượng cho thấy xu hướng tương tự. So với mô hình cơ sở, LSTM-FT giảm RMSE từ 0,63 xuống 0,50 kPa và MAE từ 0,45 xuống 0,33 kPa, tương ứng giảm lần lượt 20,6% và 26,7%, đồng thời tăng R^2 từ 0,82 lên 0,89. Ngược lại, XGBoost-FT làm RMSE tăng lên 0,96 kPa và MAE tăng lên 0,81 kPa, và

giảm R^2 xuống 0,58. Nhìn chung, các kết quả này cho thấy LSTM-FT đạt hiệu suất dự đoán tốt nhất khi dữ liệu của nhà máy đích còn hạn chế, vượt trội hơn cả mô hình cơ sở và XGBoost-FT. Do đó, các phân tích tiếp theo tập trung vào LSTM-FT để diễn giải sâu hơn hành vi chuyển giao được quan sát bằng các phân tích LOFO và SHAP.

3.3.3. LOFO and SHAP interpretation of feature contributions during transfer

Phân tích LOFO và SHAP được sử dụng để xác định các biến hỗ trợ hiệu suất chuyển giao trong LSTM-FT. Trước tiên, phân tích LOFO được thực hiện để đánh giá ảnh hưởng của từng biến đầu vào đến hiệu suất của LSTM-FT tại FT = 40% (Hình 5(e)). Mô hình tham chiếu là mô hình LSTM-FT được huấn luyện với tất cả các biến đầu vào, đạt MAE 0,33 kPa. Sau đó, từng biến được loại bỏ riêng lẻ, và MAE thu được được so sánh với MAE của mô hình tham chiếu bằng kiểm định thứ hạng có dấu Wilcoxon hai phía cho các mẫu ghép cặp (Bảng S10). Việc loại bỏ EPSc gây ra mức suy giảm hiệu suất lớn nhất, làm MAE tăng lên 0,37 kPa ($p \leq 0.001$), cho thấy EPSc là biến quan trọng nhất để duy trì hiệu suất của LSTM-FT. Việc loại bỏ EPSp hoặc SRT cũng làm MAE tăng lên 0,35 kPa (cả hai đều có $p \leq 0.001$), trong khi loại bỏ FLUX gây ra mức tăng nhỏ hơn nhưng vẫn có ý nghĩa thống kê ($p \leq 0.01$). Nhìn chung, kết quả LOFO xác nhận rằng các biến liên quan đến EPS, đặc biệt là EPSc và EPSp, đóng vai trò quan trọng đối với hiệu suất của LSTM-FT, trong khi SRT và FLUX cũng cho thấy những ảnh hưởng nhỏ hơn nhưng có ý nghĩa thống kê.

Phân tích SHAP cũng được sử dụng để khảo sát cách mô hình phân bổ mức độ đóng góp cho các đặc trưng thay đổi khi FT tăng. Trong chuyển giao zero-shot (FT = 0), EPSc là đặc trưng được xếp hạng cao nhất, đóng góp tỷ trọng lớn nhất trong tổng mức độ đóng góp, vượt xa MLVSS và EPSp (Hình 6(b); Hình S8(a)). Điều này cho thấy, trong chuyển giao zero-shot, mô hình được chuyển giao vẫn giữ nguyên kiểu phân bổ mức độ đóng góp tập trung mạnh vào EPSc, phản ánh mức độ hiệu chỉnh hạn chế trước khi tinh chỉnh. Từ FT = 10% đến 30%, kiểu phân bổ mức độ đóng góp trở nên phân tán hơn, với mức đóng góp cho EPSp tăng lên và đóng góp của EPSc, SRT và MLVSS trở nên tương đương hơn (Hình S9–S10). Ở FT = 40%, EPSc và EPSp là hai đặc trưng được xếp hạng cao nhất và cùng chiếm hơn một nửa tổng mức độ đóng góp (Hình 6(c); Hình S8(b)), cho thấy cấu trúc phân bổ mức độ đóng góp tập trung vào EPS trở nên cân bằng hơn sau khi tinh chỉnh. Thứ hạng các đặc trưng và

attribution structure at FT = 50% remained largely similar to those at FT = 40% (Fig. S11), consistent with the limited additional performance improvement beyond FT = 40%. Together with the LOFO results, these findings indicate that LSTM-FT performance was mainly supported by EPS-related variables, with EPSc remaining top-ranked and EPSp becoming more prominent after fine-tuning.

3.3.4. Why did transfer learning enable accurate membrane fouling prediction in the target plant?

Because SHAP and LOFO identify model-relevant variables rather than causal mechanisms, the attribution changes were interpreted against independent physicochemical evidence from the target plant. At FT = 0, the attribution pattern remained dominated by EPSc, and the model retained moderate predictive performance ($R^2 = 0.41$), indicating that the EPSc-centered predictive structure learned by the base model was partially applicable to the target plant. The relatively high EPSc concentration in the target plant (49.6 mg/L) further suggests that polysaccharide-related fouling remained important. Elevated polysaccharide content can enhance water retention and reduce sludge dewaterability, thereby promoting the formation of a highly hydrated, compressible, and high-resistance fouling layer. This interpretation was consistent with the relatively high CST (49.45 s) and specific CST (4.36 s/(g/L)) observed in the target plant (Fig. 7(a)). Taken together, these results suggest that EPSc represented a shared membrane-fouling matrix characteristic across plants that remained stably informative during transfer prediction.

Performance improved when FT increased to 40% ($R^2 = 0.89$), and the most notable change in the SHAP results was the rise of EPSp to the second most important feature. This shift suggests that fine-tuning increased model sensitivity to protein-related EPS characteristics in the target plant. The EPS EEM spectrum of the target plant showed a dominant aromatic protein-like peak (Fig. 7(b)), consistent with the protein-related EPS signature observed in the source plants. Of note, it

was hypothesized that the increased importance of EPSp (aromatic proteins) could be due to the Fe-enriched influent in MBRs [54]. To further support this interpretation, two Fe-dosing stages in the target plant were compared (Table S11). Specifically, upstream Fe was dosed into the influent mixing tank before pretreatment at target dosages of 9 and 26 mg/L, allowing Fe accumulation and EPS compositional responses in the MBR system to be examined. As the Fe dosage increased, the sludge-associated Fe content increased from 45 to 101 mg/g-MLVSS, while EPSp increased from 47.96 to 62.30 mg/g-MLVSS. These observations suggest that Fe-enriched conditions were associated with a more protein-enriched EPS composition, which may explain the increased attribution of EPSp after fine-tuning. Higher EPS protein content is generally associated with stronger hydrophobicity and greater floc aggregation, which may favor membrane-surface adhesion and cake-layer densification [46,55]. This interpretation was consistent with the relatively high viscosity and specific viscosity of the target sludge (50.03 mPa s and 9.46 mPa s/(g/L), respectively; Fig. 7(d)). Taken together, the increased SHAP attribution of EPSp suggests that fine-tuning recalibrated the model toward the protein-related EPS characteristics that were more pronounced under the Fe-enriched conditions of the target plant.

The two-step CIP results further supported the association between the Fe-related EPS response and the composition of the retained fouling layer in the target plant. During the citric acid (CA) cleaning stage, total Fe increased sharply from 0.62 to 43.02 mg/L (Fig. 7(e)), indicating the release of substantial Fe-bearing components from the fouling layer. During the subsequent NaClO cleaning stage, TOC increased from 5.19 to 43.22 mg/L (Fig. 7(f)), while total Fe also increased from 1.85 to 11.16 mg/L, suggesting the release of oxidizable organic matter together with Fe-bearing components. Together with the lower SCOD than TCOD in the target plant (93 vs. 271 mg/L), these results suggest that the dominant fouling layer was not formed by dissolved organics alone, but was more closely associated with a sludge-bound organic matrix

Cấu trúc quy kết tại FT = 50% nhìn chung tương tự cấu trúc tại FT = 40% (Hình S11), phù hợp với mức cải thiện hiệu năng bổ sung hạn chế sau FT = 40%. Cùng với các kết quả LOFO, những phát hiện này cho thấy hiệu năng của LSTM-FT chủ yếu được hỗ trợ bởi các biến liên quan đến EPS, trong đó EPSc vẫn đứng đầu bảng xếp hạng còn EPSp trở nên nổi bật hơn sau khi tinh chỉnh.

3.3.4. Why did transfer learning enable accurate membrane fouling prediction in the target plant?

Vì SHAP và LOFO xác định các biến liên quan đến mô hình chứ không phải các cơ chế nhân quả, những thay đổi về mức độ quy kết được diễn giải dựa trên bằng chứng hóa lý độc lập thu được từ nhà máy đích. Tại FT = 0, mô hình quy kết vẫn chủ yếu bị chi phối bởi EPSc, và mô hình duy trì hiệu suất dự đoán ở mức trung bình ($R^2 = 0.41$), cho thấy cấu trúc dự đoán tập trung vào EPSc mà mô hình cơ sở học được có thể áp dụng một phần cho nhà máy đích. Nồng độ EPSc tương đối cao trong nhà máy đích (49.6 mg/L) cũng cho thấy hiện tượng fouling liên quan đến polysaccharide vẫn đóng vai trò quan trọng. Hàm lượng polysaccharide tăng cao có thể làm tăng khả năng giữ nước và giảm khả năng tách nước của bùn, từ đó thúc đẩy hình thành lớp fouling có độ ngậm nước cao, dễ nén và có sức cản lớn. Cách diễn giải này phù hợp với CST (49.45 s) và CST riêng (4.36 s/(g/L)) tương đối cao được quan sát tại nhà máy đích (Hình 7(a)). Nhìn chung, các kết quả này cho thấy EPSc là đặc tính nền của hiện tượng fouling màng được chia sẻ giữa các nhà máy, đồng thời vẫn mang giá trị thông tin ổn định trong quá trình dự đoán chuyển giao.

Hiệu suất được cải thiện khi FT tăng lên 40% ($R^2 = 0.89$), và thay đổi đáng chú ý nhất trong các kết quả SHAP là EPSp vươn lên thành đặc trưng quan trọng thứ hai. Sự chuyển dịch này cho thấy việc tinh chỉnh đã làm tăng độ nhạy của mô hình đối với các đặc tính EPS liên quan đến protein ở cây mục tiêu. Phổ EEM của EPS ở cây mục tiêu cho thấy một đỉnh giống protein thơm chiếm ưu thế (Hình 7(b)), phù hợp với dấu hiệu EPS liên quan đến protein được quan sát thấy ở các cây nguồn. Đáng chú ý, nó

Người ta giả thuyết rằng tầm quan trọng gia tăng của EPSp (protein thơm) có thể là do dòng nước đầu vào giàu Fe trong các MBR [54]. Để củng cố thêm cách diễn giải này, hai giai đoạn châm Fe tại nhà máy mục tiêu đã được so sánh (Bảng S11). Cụ thể, Fe được châm ở t hướng nguồn vào bể trộn dòng nước đầu vào trước khi xử lý sơ bộ, với liều lượng mục tiêu lần lượt là 9 và 26 mg/L, cho phép khảo sát sự tích tụ Fe và các phản ứng về thành phần EPS trong hệ thống MBR. Khi liều lượng Fe tăng, hàm lượng Fe gắn với bùn tăng từ 45 lên 101 mg/g-MLVSS, trong khi EPSp tăng từ 47.96 lên 62.30 mg/g-MLVSS. Những quan sát này cho thấy điều kiện giàu Fe đi kèm với thành phần EPS giàu protein hơn, điều này có thể giải thích mức độ đóng góp gia tăng của EPSp sau khi tinh chỉnh. Hàm lượng protein EPS cao hơn thường đi kèm với tính kỵ nước mạnh hơn và sự kết tụ bông lớn hơn, có thể thúc đẩy sự bám dính lên bề mặt màng và sự đặc chắc của lớp bánh bùn [46,55]. Cách diễn giải này phù hợp với độ nhớt và độ nhớt riêng tương đối cao của bùn tại nhà máy mục tiêu (lần lượt là 50.03 mPa s và 9.46 mPa s/(g/L); Hình 7(d)). Nhìn chung, mức độ đóng góp SHAP gia tăng của EPSp cho thấy quá trình tinh chỉnh đã hiệu chỉnh lại mô hình theo hướng các đặc tính EPS liên quan đến protein, vốn thể hiện rõ hơn trong điều kiện giàu Fe tại nhà máy mục tiêu.

Kết quả CIP hai bước càng củng cố mối liên hệ giữa phản ứng EPS liên quan đến Fe và thành phần của lớp cặn còn bám lại trong nhà máy mục tiêu. Trong giai đoạn làm sạch bằng axit citric (CA), tổng Fe tăng mạnh từ 0,62 lên 43,02 mg/L (Hình 7(e)), cho thấy các thành phần chứa Fe đáng kể được giải phóng khỏi lớp cặn. Trong giai đoạn làm sạch tiếp theo bằng NaClO, TOC tăng từ 5,19 lên 43,22 mg/L (Hình 7(f)), trong khi tổng Fe cũng tăng từ 1,85 lên 11,16 mg/L, cho thấy chất hữu cơ có thể oxy hóa được giải phóng cùng với các thành phần chứa Fe. Cùng với SCOD thấp hơn TCOD tại nhà máy mục tiêu (93 so với 271 mg/L), những kết quả này cho thấy lớp cặn chủ đạo không chỉ hình thành từ các chất hữu cơ hòa tan, mà có liên quan chặt chẽ hơn đến một nền hữu cơ gắn với bùn cặn.





Fig. 7. Physicochemical evidence supporting the EPS-centered attribution pattern learned by LSTM-FT in the target plant: Mixed-liquor properties, including (a) CST and specific CST and (d) viscosity and specific viscosity; EEM spectra of (b) EPS and (c) SMP; (e) total iron concentrations in cleaning solutions collected during the two-step clean-in-place (CIP) procedure, and (f) TOC concentrations in cleaning solutions collected during sodium hypochlorite cleaning. Before CIP, the membrane unit was drained and rinsed with filtrate. The two-step CIP consisted of citric-acid cleaning (15 g/L, pH = 2.5) followed by sodium hypochlorite cleaning (1 g/L, pH = 10), with samples collected immediately before and after each cleaning step. B-CA and A-CA denote samples collected before and after citric-acid cleaning, respectively, whereas B-NaClO and A-NaClO denote samples collected before and after sodium hypochlorite cleaning.



Hình 7. Bằng chứng lý hóa củng cố mô hình quy kết tập trung vào EPS do LSTM-FT học được tại nhà máy mục tiêu: Các đặc tính của hỗn hợp bùn, bao gồm (a) CST và CST riêng, và (d) độ nhớt và độ nhớt riêng; phổ EEM của (b) EPS và (c) SMP; (e) nồng độ sắt tổng trong các dung dịch vệ sinh được thu thập trong quy trình vệ sinh tại chỗ (CIP) hai bước, và (f) nồng độ TOC trong các dung dịch vệ sinh được thu thập trong quá trình vệ sinh bằng natri hypochlorit. Trước CIP, cụm màng được tháo hết nước và tráng bằng nước lọc. Quy trình CIP hai bước gồm vệ sinh bằng axit citric (15 g/L, pH = 2.5), sau đó vệ sinh bằng natri hypochlorit (1 g/L, pH = 10), với mẫu được thu thập ngay trước và sau mỗi bước vệ sinh. B-CA và A-CA lần lượt chỉ các mẫu được thu thập trước và sau khi vệ sinh bằng axit citric, còn B-NaClO và A-NaClO lần lượt chỉ các mẫu được thu thập trước và sau khi vệ sinh bằng natri hypochlorit.

containing Fe-related constituents.

Furthermore, the decline in SMPp attribution after fine-tuning suggests that LSTM-FT placed less emphasis on soluble protein-related information during target plant adaptation. Although the SMP EEM spectrum of the target plant showed a pronounced low-excitation aromatic protein-like feature (Fig. 7(c)), the effluent EEM exhibited broader fluorescence regions ($E_x/E_m \approx 220\text{--}250/300\text{--}460$ nm) that partially overlapped with the low-excitation protein-like region in SMP (Fig. S12). This overlap suggests that part of the low-excitation protein-like dissolved organic signal was not fully retained by the membrane system. Therefore, the reduced attribution of SMPp after fine-tuning does not exclude its contribution to fouling, but suggests that SMPp was less closely associated with the dominant retained foulant layer in the target plant than EPS-related variables.

Taken together, LSTM fine-tuning preserved the transferable EPSc-related fouling information in the target MBR plant, recalibrated the target-specific EPSc-related signal, and placed less emphasis on SMPp, which was less representative of the dominant fouling layer.

3.3.5. Cross-scenario adaptability to an MBR treating industrial wastewater

Because the preceding analysis focused mainly on the domestic MBR scenario, additional validation was conducted using a pilot-scale MBR treating mixed petrochemical and pharmaceutical industrial wastewater. This case provided a preliminary test of the established transfer learning workflow under a more distinct wastewater background. Compared with the domestic target plant, the industrial MBR presented a more challenging transfer scenario, with a more complex influent composition, higher organic loading, and disturbance-driven biomass dynamics. The TMP profile of the industrial MBR showed a clear long-term trend together with multiple abrupt perturbations associated with real operational events (Fig. 8(a)), reflecting complex membrane-fouling behavior under practical engineering conditions.

The industrial MBR differed substantially from the source plants in wastewater and sludge properties, with consistently higher TCOD, SCOD, MLSS, and MLVSS (Fig. 8(b)). Importantly, despite these background differences, EPSc (43.6 ± 20.2 mg/L) remained close to the source plant range ($32.3\text{--}43.5$ mg/L), suggesting that EPSc-related

fouling information was still shared across scenarios. EPSp (256.8 ± 126.7 mg/L) was also of the same order of magnitude as in the source plants ($184\text{--}229$ mg/L), and SMPc (6.9 ± 5.0 mg/L) fell within the source plant range ($5.2\text{--}11.5$ mg/L). These overlaps suggest that part of the fouling-related information learned from the source plants could still be transferred to the industrial MBR, even under a substantially different wastewater background.

Under zero-shot transfer (FT = 0), the base model achieved only moderate performance in the industrial MBR ($R^2 = 0.46$; Fig. 8(c)), suggesting that the fouling-related information learned from the source plants was partially applicable but insufficient to fully capture the TMP dynamics in the industrial MBR. Fine-tuning with industrial MBR data improved prediction performance. This validation used the same chronological fine-tuning/testing logic, pretrained model, preprocessing procedure, and model settings as the main target plant analysis. At FT = 40%, R^2 increased to 0.89, while MAE and RMSE decreased by 68.6% and 54.7%, respectively, relative to FT = 0. This improvement indicates that the established workflow could be adapted to the industrial wastewater background without additional model optimization.

SHAP analysis further showed that EPSc retained the highest attribution after fine-tuning, whereas SMPp increased to the second-highest attribution level (Fig. 8(d)). This pattern differed from that observed in the domestic target MBR plant, where fine-tuning mainly increased the attribution of EPSc. Thus, the two target cases shared stable EPSc-related fouling information, but differed in the feature requiring target-specific recalibration: EPSc in the Fe-enriched domestic MBR and SMPp in the industrial MBR. The increased attribution of SMPp suggests that fine-tuning recalibrated the model toward a more prominent soluble proteinaceous signal under the industrial wastewater background.

The increased attribution of SMPp after fine-tuning was mechanistically plausible in the industrial MBR. SMPp was higher in the industrial MBR (27.6 ± 17.4 mg/L) than in the source plants ($10.8\text{--}13.8$ mg/L), indicating a stronger background of dissolved proteinaceous organics. Previous characterization of this industrial MBR showed pronounced SMP protein peaks during operational disturbances, together with decreases in MLSS and MLVSS, consistent with biomass loss, cell decay, and proteinaceous SMP release into the mixed liquor [56]. Moreover,

chứa các thành phần liên quan đến Fe.

Hơn nữa, sự suy giảm mức độ đóng góp của SMPp sau khi tinh chỉnh cho thấy LSTM-FT ít chú trọng hơn đến thông tin liên quan đến protein hòa tan trong quá trình thích nghi với nhà máy xử lý nước thải mục tiêu. Mặc dù phổ EEM của SMP tại nhà máy mục tiêu cho thấy đặc trưng giống protein thơm có kích thích thấp nổi bật (Hình 7(c)), EEM của dòng nước thải đầu ra lại thể hiện các vùng huỳnh quang rộng hơn ($E_x/E_m \approx 220\text{--}250/300\text{--}460$ nm), chồng lấp một phần với vùng giống protein có kích thích thấp trong SMP (Hình S12). Sự chồng lấp này cho thấy một phần tín hiệu chất hữu cơ hòa tan giống protein có kích thích thấp không được hệ thống màng giữ lại hoàn toàn. Do đó, mức độ đóng góp thấp hơn của SMPp sau khi tinh chỉnh không loại trừ vai trò của nó trong quá trình fouling, mà cho thấy SMPp ít liên quan hơn đến lớp chất gây fouling chủ yếu được giữ lại tại nhà máy mục tiêu so với các biến liên quan đến EPS.

Nhìn chung, quá trình tinh chỉnh LSTM đã bảo toàn thông tin về hiện tượng bám bẩn liên quan đến EPSc có thể chuyển giao trong nhà máy MBR đích, hiệu chỉnh lại tín hiệu liên quan đến EPSc đặc thù của đối tượng đích và giảm mức độ chú trọng đến SMPp, vốn ít đại diện hơn cho lớp bám bẩn chủ đạo.

3.3.5. Cross-scenario adaptability to an MBR treating industrial wastewater

Do phân tích trước đó chủ yếu tập trung vào kịch bản MBR sinh hoạt, nên nghiên cứu đã tiến hành xác thực bổ sung bằng một hệ thống MBR quy mô thí điểm xử lý nước thải công nghiệp hỗn hợp từ ngành hóa dầu và dược phẩm. Trường hợp này cung cấp phép thử sơ bộ cho quy trình học chuyển giao đã thiết lập trong bối cảnh nước thải khác biệt rõ rệt hơn. So với nhà máy mục tiêu xử lý nước thải sinh hoạt, hệ thống MBR công nghiệp đặt ra kịch bản chuyển giao thách thức hơn, với thành phần nước đầu vào phức tạp hơn, tải lượng hữu cơ cao hơn và động thái sinh khối chịu ảnh hưởng của các nhiễu động. Diễn biến TMP của hệ thống MBR công nghiệp cho thấy xu hướng dài hạn rõ rệt cùng nhiều biến động đột ngột gắn với các sự kiện vận hành thực tế (Hình 8(a)), phản ánh hành vi fouling màng phức tạp trong điều kiện kỹ thuật thực tiễn.

MBR công nghiệp khác biệt đáng kể so với các nhà máy nguồn về đặc tính nước thải và bùn, với TCOD, SCOD, MLSS và MLVSS luôn cao hơn (Hình 8(b)). Đáng chú ý, bất chấp những khác biệt nền này, EPSc (43.6 ± 20.2 mg/L) vẫn gần với khoảng giá trị của các nhà máy nguồn ($32.3\text{--}43.5$ mg/L), cho thấy các yếu tố liên quan đến EPSc

Thông tin về tắc nghẽn màng vẫn được chia sẻ giữa các kịch bản. EPSc (256.8 ± 126.7 mg/L) cũng có cùng bậc độ lớn với các nhà máy nguồn ($184\text{--}229$ mg/L), còn SMPc (6.9 ± 5.0 mg/L) nằm trong phạm vi của các nhà máy nguồn ($5.2\text{--}11.5$ mg/L). Những mức chồng lấp này cho thấy một phần thông tin liên quan đến tắc nghẽn màng được học từ các nhà máy nguồn vẫn có thể được chuyển giao sang MBR công nghiệp, ngay cả khi nền nước thải khác biệt đáng kể.

Trong điều kiện chuyển giao zero-shot (FT = 0), mô hình nền chỉ đạt hiệu suất ở mức trung bình trong MBR công nghiệp ($R^2 = 0.46$; Hình 8(c)), cho thấy thông tin liên quan đến hiện tượng tắc nghẽn được học từ các nhà máy nguồn có thể áp dụng một phần nhưng chưa đủ để nắm bắt đầy đủ động lực học TMP trong MBR công nghiệp. Tinh chỉnh bằng dữ liệu MBR công nghiệp đã cải thiện hiệu suất dự đoán. Quá trình xác thực này sử dụng cùng logic tinh chỉnh/kiểm thử theo trình tự thời gian, mô hình tiền huấn luyện, quy trình xử lý và thiết lập mô hình như trong phân tích nhà máy đích chính. Ở mức FT = 40%, R^2 tăng lên 0.89, trong khi MAE và RMSE lần lượt giảm 68.6% và 54.7% so với FT = 0. Sự cải thiện này cho thấy quy trình đã thiết lập có thể được điều chỉnh cho phù hợp với bối cảnh nước thải công nghiệp mà không cần tối ưu hóa mô hình bổ sung.

Phân tích SHAP cho thấy EPSc vẫn có mức đóng góp cao nhất sau khi tinh chỉnh, trong khi SMPp tăng lên mức đóng góp cao thứ hai (Hình 8(d)). Mô hình này khác với mô hình quan sát được ở nhà máy MBR nội địa mục tiêu, nơi việc tinh chỉnh chủ yếu làm tăng mức đóng góp của EPSc. Như vậy, hai trường hợp mục tiêu có chung thông tin ổn định liên quan đến hiện tượng fouling của EPSc, nhưng khác nhau ở đặc trưng cần hiệu chỉnh lại riêng cho từng mục tiêu: EPSc ở hệ MBR nội địa giàu Fe và SMPp ở hệ MBR công nghiệp. Mức đóng góp tăng của SMPp cho thấy việc tinh chỉnh đã hiệu chỉnh mô hình theo hướng tín hiệu protein hòa tan nổi bật hơn trong nền nước thải công nghiệp.

Việc tăng mức quy kết cho SMPp sau khi tinh chỉnh là hợp lý về mặt cơ chế trong MBR công nghiệp. SMPp trong MBR công nghiệp cao hơn (27.6 ± 17.4 mg/L) so với ở các nhà máy nguồn ($10.8\text{--}13.8$ mg/L), cho thấy nền chất hữu cơ hòa tan có bản chất protein mạnh hơn. Các đặc tính trước đây của MBR công nghiệp này cho thấy các đỉnh protein SMP nổi bật trong những giai đoạn vận hành bị xáo trộn, đồng thời MLSS và MLVSS giảm, phù hợp với tình trạng sinh khối hao hụt, tế bào chết và SMP chứa protein được giải phóng vào hỗn dịch [56]. Hơn nữa,





Fig. 8. Additional validation of the proposed transfer learning framework in an industrial wastewater MBR: (a) TMP profile with major operational events, (b) summary statistics of the operational and physicochemical variables in the industrial MBR, (c) the pretrained LSTM model before and after fine-tuning, evaluated at FT = 0 and FT = 40% using R^2 , MAE, and RMSE, and (d) mean absolute SHAP values of LSTM-FT at FT = 40%.



Hình 8. Kiểm định bổ sung khung học chuyển giao được đề xuất trong hệ thống MBR xử lý nước thải công nghiệp: (a) đường biểu diễn TMP cùng các sự kiện vận hành chính, (b) thống kê tóm tắt các biến vận hành và hóa lý trong MBR công nghiệp, (c) mô hình LSTM được tiền huấn luyện trước và sau khi tinh chỉnh, được đánh giá tại FT = 0 và FT = 40% bằng R^2 , MAE và RMSE, và (d) giá trị SHAP tuyệt đối trung bình của LSTM-FT tại FT = 40%.

SMP in this MBR was dominated by proteins rather than carbohydrates. These observations suggest that the enhanced SMPp attribution in the transfer model was associated with disturbance-driven soluble protein release. Such proteinaceous SMP could contribute to fouling development, thereby explaining the increased attribution of SMPp after fine-tuning.

Overall, this additional validation suggests that the proposed transfer learning workflow remained applicable to the industrial MBR, not because fouling mechanisms were identical across scenarios, but because the model retained transferable EPSc-related fouling information while fine-tuning recalibrated the attribution structure toward the dominant target-specific signal. In the domestic target MBR plant, this recalibration was reflected by the increased attribution of EPSp under Fe-enriched conditions, whereas in the industrial MBR, it was reflected by the increased attribution of SMPp associated with disturbance-driven soluble protein release. These results further support the ability of the transfer learning framework to preserve transferable fouling-related information while adapting to plant-specific fouling signals across distinct wastewater backgrounds.

4. Implications and outlook

The significance of this study lies not only in improving fouling prediction for a single pilot-scale MBR, but also in providing a basis for more mechanism-informed prediction in data-limited plants. By transferring knowledge learned from data-rich source plants, the LSTM model achieved reliable prediction in a data-limited target plant, suggesting that data-limited plants may not need to build fouling prediction systems entirely from scratch.

More importantly, the present results suggest that indicator selection for fouling prediction should begin with identifying the dominant fouling processes, followed by extraction of representative fouling fingerprints for prediction. Within this framework, indicators such as EPSc and EPSp appear to contain transferable fouling information across MBR plants. However, these variables are expensive, labor-intensive, and difficult to monitor routinely, which limits their direct practical use. A more feasible direction may therefore be to translate key fouling characteristics into monitorable surrogate fingerprints; in this regard, online spectral signals such as UV–vis and fluorescence fingerprints may provide a practical basis for plant-adaptive prediction and proactive fouling control [57].

Nevertheless, several limitations remain and point to directions for future work. The present models were developed from a limited number of pilot-scale MBRs with relatively similar operational backgrounds. At full scale, membrane fouling is further shaped by scale-dependent hydrodynamics and aeration and by greater operational variability than in pilot systems [58], so the pretrained relationships may not directly capture full-scale fouling dynamics. For systems with substantially different influent or operating conditions, the sludge and EPS/SMP composition and the dominant foulants can change, weakening the transferable EPS-centered signal and possibly requiring additional plant-specific indicators for reliable adaptation. The framework should therefore be further validated on larger datasets and extended to full-scale, geographically diverse plants to establish its robustness and generalizability. In addition, the prediction accuracy did not approach unity, indicating that the current indicator set is still incomplete. Besides organic foulants, the target plant also showed evidence of inorganic contributions, particularly iron-associated fouling revealed by the CIP results, which may not yet be fully captured by the present model inputs. Identifying more comprehensive indicators that better capture the combined effects of organic and inorganic foulants may in turn help support earlier fouling warning, better timing of operational adjustment and membrane cleaning, reduced energy and chemical consumption, and improved process stability (Fig. S13).

5. Conclusions

- Reliable base models for MBR fouling prediction were developed by pretraining on the three data-rich source plants. SHAP analysis showed that LSTM-base learned physically meaningful fouling-related patterns mainly through EPSc, EPSp, and SMPp, rather than relying on a single dominant operational signal. This was supported by the shared source plant characteristics, including EPS aromatic protein-like fluorescence, flocculated sludge particle-size distributions, and preferential retention of SMP by the membrane. These results indicate that LSTM-base provided a mechanistically interpretable and reliable pretrained basis for subsequent cross-plant transfer.
- Fine-tuning improved TMP prediction for the target plant treating domestic wastewater, with LSTM-FT achieving $R^2 = 0.89$ at 40% FT. SHAP and LOFO analyses showed that EPSc remained dominant, while EPSp gained importance after fine-tuning. Under the Fe-enriched condition of the target MBR plant, the increased importance of EPSp was associated with a shift toward protein-enriched EPS characteristics. Together, these findings explain why fine-tuning improved prediction accuracy: it retained the transferable EPSc-centered fouling basis while recalibrating the model toward Fe-associated, protein-enriched EPS characteristics that were more closely associated with fouling in the target plant.
- Validation in the industrial MBR further demonstrated that the framework remained effective under a markedly different fouling background. Unlike the target plant treating domestic wastewater, SMPp became the second most important feature in the industrial MBR, reflecting a more prominent proteinaceous SMP signal linked to operational disturbances and biomass decay. The continued dominance of EPSc in the industrial MBR further supported the cross-scenario stability of this transferable fouling basis, while the increased attribution of SMPp showed that fine-tuning could adaptively reweight plant-specific fouling drivers.
- Overall, this study demonstrates that shared fouling-related information can be transferred across MBR plants and selectively recalibrated with limited target-plant data, while independent physicochemical evidence makes this adaptation scientifically interpretable. The framework therefore provides a practical foundation for reliable TMP prediction and plant-adaptive fouling decision support in data-limited MBRs.

CRedit authorship contribution statement

Xiaohang Han: Conceptualization, Data curation, Formal analysis, Investigation, Methodology, Software, Validation, Visualization, Writing – original draft. **Liu Yang:** Conceptualization, Data curation, Formal analysis, Investigation, Methodology, Software, Validation, Visualization, Writing – original draft. **Huan Qin:** Data curation, Investigation. **Shujuan Huang:** Data curation, Investigation. **Han Zhang:** Data curation, Investigation. **Boyan Xu:** Conceptualization, Funding acquisition, Project administration, Supervision, Writing – review & editing. **How Yong Ng:** Conceptualization, Funding acquisition, Supervision, Writing – review & editing.

Declaration of competing interests

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgement

The authors gratefully acknowledge financial support from the Taishan Scholar Foundation of Shandong Province under Grant No. tsqn202312222. The research was also supported by National Natural

SMP trong MBR này chủ yếu là protein chứ không phải carbohydrat e. Những quan sát này cho thấy mức độ quy kết SMPp tăng lên trong mô hình chuyển giao có liên quan đến việc giải phóng protein hòa tan do sự xáo trộn gây ra. SMP giàu protein này có thể góp phần là m phát sinh hiện tượng tắc nghẽn, qua đó lý giải mức độ quy kết S MPp tăng lên sau khi tinh chỉnh.

Nhìn chung, kết quả kiểm định bổ sung này cho thấy quy trình học chuyển giao được đề xuất vẫn phù hợp với MBR công nghiệp, khi ông phải vì các cơ chế gây tắc nghẽn giống hệt nhau trong các kịch bản, mà vì mô hình vẫn giữ được thông tin gây tắc nghẽn liên quan đến EPSc có khả năng chuyển giao, trong khi quá trình tinh chỉnh hiệu chỉnh lại cấu trúc quy kết theo tín hiệu chỉ phối đặc thù của đối tượng đích. Tại nhà máy MBR xử lý nước thải sinh hoạt làm đối tượng đích, sự hiệu chỉnh này thể hiện qua mức quy kết tăng lên của EPSp trong điều kiện giàu Fe; còn ở MBR công nghiệp, điều này thể hiện qua mức quy kết tăng lên của SMPp, gắn với sự giải phóng protein hòa tan do các tác động gây nhiễu. Những kết quả này tiếp tục củng cố khả năng của khuôn khổ học chuyển giao trong việc bảo toàn thông tin liên quan đến hiện tượng tắc nghẽn có khả năng chuyển giao, đồng thời thích ứng với các tín hiệu gây tắc nghẽn đặc thù của từng nhà máy trong các nền nước thải khác nhau.

4. Hàm ý và triển vọng

Ý nghĩa của nghiên cứu này không chỉ nằm ở việc cải thiện khả năng dự đoán sự đóng bám cho một hệ thống MBR quy mô thí điểm, mà còn ở việc tạo cơ sở cho các dự đoán dựa trên cơ chế tốt hơn từ những nhà máy có dữ liệu hạn chế. Bằng cách chuyển giao kiến thức học được từ các nhà máy nguồn có dữ liệu phong phú hơn, mô hình LSTM đã đưa ra dự đoán đáng tin cậy tại một nhà máy đích có dữ liệu hạn chế, cho thấy các nhà máy này có thể không cần xây dựng hệ thống dự đoán sự đóng bám hoàn toàn từ đầu.

Quan trọng hơn, các kết quả hiện tại cho thấy việc lựa chọn chỉ thị để dự đoán tắc nghẽn nên bắt đầu bằng việc xác định các quá trình tắc nghẽn chi phối, sau đó trích xuất các dấu vân tay tắc nghẽn đại diện để dự đoán. Trong khuôn khổ này, các chỉ thị như EPSc và EPSp dường như chứa thông tin về tắc nghẽn có thể chuyển giao giữa các nhà máy MBR. Tuy nhiên, các biến này tồn kém, đòi hỏi nhiều công sức và khó theo dõi thường xuyên, hạn chế khả năng ứng dụng trực tiếp trong thực tiễn. Do đó, một hướng khả thi hơn có thể là chuyển đổi các đặc tính tắc nghẽn then chốt thành những dấu vân tay thay thế có thể theo dõi; theo hướng này, các tín hiệu quang phổ trực tuyến như dấu vân tay UV–vis và huỳnh quang có thể tạo cơ sở thiết thực cho việc dự đoán thích ứng theo nhà máy và kiểm soát tắc nghẽn chủ động [57].

Tuy nhiên, vẫn còn một số hạn chế và hướng nghiên cứu trong tương lai. Các mô hình hiện tại được xây dựng từ một số lượng hạn chế các hệ thống MBR quy mô thí điểm có điều kiện vận hành tương đương đồng. Ở quy mô toàn diện, sự bám bẩn màng còn chịu ảnh hưởng của thủy động lực học và quá trình sục khí phụ thuộc vào quy mô, cũng như mức độ biến động vận hành lớn hơn so với các hệ thống thí điểm [58]; do đó, các mối quan hệ được huấn luyện có thể không phản ánh trực tiếp động thái bám bẩn ở quy mô toàn diện. Đối với các hệ thống có đặc tính nước đầu vào hoặc điều kiện vận hành khác biệt đáng kể, thành phần bùn và EPS/SMP cũng như các chất gây bám bẩn chủ yếu có thể thay đổi, làm suy yếu tín hiệu có khả năng chuyển giao tập trung vào EPS và có thể đòi hỏi bổ sung các chỉ thị riêng cho từng nhà máy để thích ứng một cách đáng tin cậy. Vì vậy, cần tiếp tục thẩm định khung này trên các bộ dữ liệu lớn hơn và mở rộng áp dụng cho các nhà máy quy mô toàn diện ở nhiều khu vực địa lý khác nhau để xác lập tính vững chắc và khả năng khái quát hóa. Ngoài ra, độ chính xác dự đoán chưa đạt mức hoàn hảo, cho thấy tập hợp chỉ thị hiện tại vẫn chưa đầy đủ. Bên cạnh các chất gây bám bẩn hữu cơ, nhà máy mục tiêu còn cho thấy dấu hiệu có sự đóng góp của các chất vô cơ, đặc biệt là hiện tượng bám bẩn liên quan đến sắt được phát hiện qua kết quả CIP, mà các biến đầu vào hiện tại của mô hình có thể chưa phản ánh đầy đủ. Việc xác định các chỉ thị toàn diện hơn, nắm bắt tốt hơn tác động tổng hợp của các chất gây bám bẩn hữu cơ và vô cơ, có thể góp phần hỗ trợ cả nh bảo bám bẩn sớm hơn, xác định thời điểm điều chỉnh vận hành và làm sạch màng phù hợp hơn, giảm tiêu thụ năng lượng và hóa chất, đồng thời cải thiện độ ổn định của quy trình (Hình S13).

5. Kết luận

Các mô hình nền đáng tin cậy để dự đoán hiện tượng bám bẩn màng MBR được phát triển bằng cách tiền huấn luyện trên ba nhà máy nguồn có dữ liệu phong phú hơn. Phân tích SHAP cho thấy LSTM-base đã học được các kiểu hình liên quan đến bám bẩn có ý nghĩa về mặt vật lý, chủ yếu thông qua EPSc, EPSp và SMPp, thay vì dựa vào một tín hiệu vận hành chi phối duy nhất. Điều này được củng cố bởi các đặc điểm chung của các nhà máy nguồn, bao gồm huỳnh quang giống protein thơm trong EPS, phân bố kích thước hạt bùn kết bông và khả năng màng ưu tiên giữ lại SMP. Các kết quả này cho thấy LSTM-base cung cấp một nền tảng tiền huấn luyện đáng tin cậy, có thể diễn giải theo cơ chế, cho việc chuyển giao liên nhà máy tiếp theo.

Tinh chỉnh đã cải thiện khả năng dự đoán TMP cho nhà máy mục tiêu xử lý nước thải sinh hoạt, trong đó LSTM-FT đạt $R^2 = 0.89$ ở mức tinh chỉnh 40%. Các phân tích SHAP và LOFO cho thấy EPSc vẫn giữ vai trò chủ đạo, trong khi EPSp trở nên quan trọng hơn sau khi tinh chỉnh. Trong điều kiện giàu Fe tại nhà máy MBR mục tiêu, tầm quan trọng gia tăng của EPSp gắn liền với sự chuyển dịch sang các đặc tính EPS giàu protein hơn. Nhìn chung, những phát hiện này giải thích vì sao tinh chỉnh cải thiện độ chính xác dự đoán: mô hình vẫn duy trì cơ sở gây tắc nghẽn dựa trên EPSc có khả năng chuyển giao, đồng thời được hiệu chỉnh lại theo các đặc tính EPS giàu protein liên quan đến Fe, vốn gắn chặt hơn với hiện tượng tắc nghẽn tại nhà máy mục tiêu.

Việc thẩm định trên MBR công nghiệp tiếp tục cho thấy khung này vẫn hiệu quả trong bối cảnh cấu trúc khác biệt rõ rệt. Không giống như nhà máy mục tiêu xử lý nước thải sinh hoạt, SMPp trở thành đặc trưng quan trọng thứ hai trong MBR công nghiệp, phản ánh tín hiệu SMP giàu protein nổi bật hơn, gắn với các sự cố vận hành và sự suy thoái sinh khối. Việc EPSc tiếp tục chiếm ưu thế trong MBR công nghiệp càng củng cố tính ổn định của cơ sở cấu trúc có khả năng chuyển giao này giữa các kịch bản, trong khi mức độ đóng góp tăng lên của SMPp cho thấy quá trình tinh chỉnh có thể điều chỉnh trọng số một cách thích ứng cho các yếu tố gây cấu trúc đặc thù của từng nhà máy.

Nhìn chung, nghiên cứu này cho thấy thông tin chung liên quan đến hiện tượng tắc nghẽn có thể được chuyển giao giữa các nhà máy MBR và hiệu chỉnh lại có chọn lọc bằng dữ liệu hạn chế từ nhà máy đích, trong khi bằng chứng hóa lý độc lập giúp diễn giải một số khía cạnh khoa học quá trình thích ứng này. Do đó, khung này tạo nền tảng thiết thực cho việc dự đoán TMP đáng tin cậy và hỗ trợ ra quyết định về tắc nghẽn thích ứng với từng nhà máy trong các hệ thống MBR hạn chế dữ liệu.

Tuyên bố về đóng góp của tác giả theo CRediT

Xiaohang Han: Ý tưởng, Quản lý dữ liệu, Phân tích hình thức, Khảo sát, Phương pháp luận, Phần mềm, Xác thực, Trực quan hóa, Viết thảo luận ban đầu. Liu Yang: Ý tưởng, Quản lý dữ liệu, Phân tích hình thức, Khảo sát, Phương pháp luận, Phần mềm, Xác thực, Trực quan hóa, Viết thảo luận ban đầu. Huan Qin: Quản lý dữ liệu, Khảo sát. Shujuan Huang: Quản lý dữ liệu, Khảo sát. Han Zhang: Quản lý dữ liệu, Khảo sát. Boyan Xu: Ý tưởng, Tìm kiếm nguồn tài trợ, Quản lý dự án, Giám sát, Viết – rà soát và biên tập. How Yong Ng: Ý tưởng, Tìm kiếm nguồn tài trợ, Giám sát, Viết – rà soát và biên tập.

Tuyên bố về các lợi ích cạnh tranh

Các tác giả tuyên bố rằng họ không có bất kỳ lợi ích tài chính cạnh tranh hoặc mối quan hệ cá nhân nào đã biết có thể ảnh hưởng đến công trình được trình bày trong bài báo này.

Lời cảm ơn

Các tác giả trân trọng cảm ơn sự hỗ trợ tài chính của Quỹ Học bổng Thái Sơn tỉnh Sơn Đông theo khoản tài trợ số tsqn202312222. Nghiên cứu cũng được hỗ trợ bởi Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc.

Science Foundation of China (42406133), and the Basic and Applied Basic Research Foundation of Guangdong Province (2023A1515110786). The authors also thank the members of Professor How Yong Ng's research group in Singapore (e.g., Wei Hao Loh, David Imanuel Tanaka, and etc.) for their valuable assistance in collecting operational data from the pilot-scale membrane bioreactor plants. The data were used exclusively for AI-based modeling and simulation in this study, and all sensitive, confidential, or identifying information was anonymized or masked prior to analysis.

Appendix A. Supplementary data

Supplementary data to this article can be found online at <https://doi.org/10.1016/j.memsci.2026.126065>.

Data availability

Data will be made available on request.

References

- [1] P.L. McCarty, J. Bae, J. Kim, Domestic wastewater treatment as a net energy producer—can this be achieved? *Environ. Sci. Technol.* 45 (17) (2011) 7100–7106, <https://doi.org/10.1021/es2014264>.
- [2] C. Niu, X. Li, R. Dai, Z. Wang, Artificial intelligence-incorporated membrane fouling prediction for membrane-based processes in the past 20 years: a critical review, *Water Res.* 216 (2022), <https://doi.org/10.1016/j.watres.2022.118299>.
- [3] F. Meng, S. Zhang, Y. Oh, Z. Zhou, H.S. Shin, S.R. Chae, Fouling in membrane bioreactors: an updated review, *Water Res.* 114 (2017) 151–180, <https://doi.org/10.1016/j.watres.2017.02.006>.
- [4] K. Xiao, S. Liang, X. Wang, C. Chen, X. Huang, Current state and challenges of full-scale membrane bioreactor applications: a critical review, *Bioreour. Technol.* 271 (2019) 473–481, <https://doi.org/10.1016/j.biortech.2018.09.061>.
- [5] K.B. Newhart, R.W. Holloway, A.S. Hering, T.Y. Cath, Data-driven performance analyses of wastewater treatment plants: a review, *Water Res.* 157 (2019) 498–513, <https://doi.org/10.1016/j.watres.2019.03.030>.
- [6] M. Faisal, K.M. Muttaqi, D. Sutanto, A.Q. Al-Shetwi, P.J. Ker, M.A. Hannan, Control technologies of wastewater treatment plants: the state-of-the-art, current challenges, and future directions, *Renew. Sustain. Energy Rev.* 181 (2023), <https://doi.org/10.1016/j.rser.2023.113324>.
- [7] Y. Zhu, Y. Wang, E. Zhu, Z. Ma, H. Wang, C. Chen, J. Guan, T.D. Waite, Predicting membrane fouling of submerged membrane bioreactor wastewater treatment plants using machine learning, *Environ. Sci. Technol.* 59 (20) (2025) 10010–10021, <https://doi.org/10.1021/acs.est.4c12835>.
- [8] D.J. Kovacs, Z. Li, B.W. Baetz, Y. Hong, S. Donnaz, X. Zhao, P. Zhou, H. Ding, Q. Dong, Membrane fouling prediction and uncertainty analysis using machine learning: a wastewater treatment plant case study, *J. Membr. Sci.* 660 (2022), <https://doi.org/10.1016/j.memsci.2022.120817>.
- [9] K. Nam, S. Heo, G. Rhee, M. Kim, C. Yoo, Dual-objective optimization for energy-saving and fouling mitigation in MBR plants using AI-based influent prediction and an integrated biological-physical model, *J. Membr. Sci.* 626 (2021), <https://doi.org/10.1016/j.memsci.2021.119208>.
- [10] M. Alvi, D. Batstone, C.K. Mbamba, P. Keymer, T. French, A. Ward, J. Dwyer, R. Cardell-Oliver, Deep learning in wastewater treatment: a critical review, *Water Res.* 245 (2023) 120518, <https://doi.org/10.1016/j.watres.2023.120518>.
- [11] R. Huang, C. Ma, J. Ma, X. Huangfu, Q. He, Machine learning in natural and engineered water systems, *Water Res.* 205 (2021) 117666, <https://doi.org/10.1016/j.watres.2021.117666>.
- [12] H. Pang, Y. Ben, Y. Cao, S. Qu, C. Hu, Time series-based machine learning for forecasting multivariate water quality in full-scale drinking water treatment with various reagent dosages, *Water Res.* 268 (2025), <https://doi.org/10.1016/j.watres.2024.122777>.
- [13] J.J. Zhu, A.B. Boehm, Z.J. Ren, Environmental machine learning, baseline reporting, and comprehensive evaluation: the EMBRACE checklist, *Environ. Sci. Technol.* 58 (45) (2024) 19909–19912, <https://doi.org/10.1021/acs.est.4c09611>.
- [14] Y. Lai, K. Xiao, Y. He, X. Liu, J. Tan, W. Xue, A. Zhang, X. Huang, Machine learning for membrane bioreactor research: principles, methods, applications, and a tutorial, *Front. Environ. Sci. Eng.* 19 (3) (2025), <https://doi.org/10.1007/s11783-025-1954-2>.
- [15] Y. Lai, K. Xiao, Y. Tian, M. Xing, H. Ding, J. Tan, J. Zhang, Z. Peng, Y. Fan, X. Lu, S. Liang, W. Xue, X. Huang, Intelligent fouling monitoring in membrane-based wastewater treatment, *Nat. Sustain.* (2026), <https://doi.org/10.1038/s41893-026-01766-2>.
- [16] H. Zhang, H. Jiang, J. Yin, T. Wang, W. Zeng, D. Lin, B. Xu, L. Bai, H. Liang, H. Y. Ng, Biofilm response in potential difference-enhanced membrane-aerated biofilm systems for accelerated antibiotic removal and ARG mitigation, *Water Res.* 285 (2025) 124154, <https://doi.org/10.1016/j.watres.2025.124154>.
- [17] G. Mannina, B.J. Ni, J. Makinia, J. Harmand, M. Alliet, C. Brepols, M.V. Ruano, A. Robles, M. Heran, H. Gulhan, I. Rodriguez-Roda, J. Comas, Biological processes modelling for MBR systems: a review of the state-of-the-art focusing on SMP and

EPS, *Water Res.* 242 (2023) 120275, <https://doi.org/10.1016/j.watres.2023.120275>.

- [18] S. Gharibian, H. Hazrati, Towards practical integration of MBR with electrochemical AOP: improved biodegradability of real pharmaceutical wastewater and fouling mitigation, *Water Res.* 218 (2022) 118478, <https://doi.org/10.1016/j.watres.2022.118478>.
- [19] F. Karamouz, H. Hazrati, A.B. khoshfetrat, Mitigation of fouling in membrane bioreactor using the integration of electrical field and nano chitosan adsorbent, *Environ. Technol. Innov.* 36 (2024), <https://doi.org/10.1016/j.eti.2024.103774>.
- [20] H. Hazrati, N. Jahanbakhshi, M. Rostamizadeh, Fouling reduction in the membrane bioreactor using synthesized zeolite nano-adsorbents, *J. Membr. Sci.* 555 (2018) 455–462, <https://doi.org/10.1016/j.memsci.2018.03.076>.
- [21] A.H. Ba-Alawi, J. Loy-Benitez, S. Kim, C. Yoo, Missing data imputation and sensor self-validation towards a sustainable operation of wastewater treatment plants via deep variational residual autoencoders, *Chemosphere* 288 (Pt 3) (2022) 132647, <https://doi.org/10.1016/j.chemosphere.2021.132647>.
- [22] H. Cheng, J. Wu, Y. Liu, D. Huang, A novel fault identification and root-causality analysis of incipient faults with applications to wastewater treatment processes, *Chemometr. Intell. Lab. Syst.* 188 (2019) 24–36, <https://doi.org/10.1016/j.chemolab.2019.03.004>.
- [23] H. Zhang, L. Shi, J. Cai, X. Wang, Z. Yan, DMGTNet: a graph-temporal deep learning model for membrane fouling prediction in dual-membrane wastewater treatment systems, *J. Membr. Sci.* 736 (2025), <https://doi.org/10.1016/j.memsci.2025.124648>.
- [24] J.-H. Wang, H.-C. Wang, Z.-W. Guo, X. Gao, F. Dong, M.S. Mahmoud, Y.-P. Chen, Y. Shen, Breaking data silos: a new modeling method based on knowledge transfer-enhanced between wastewater treatment plants, *Process Saf. Environ. Prot.* 206 (2026), <https://doi.org/10.1016/j.psep.2025.108309>.
- [25] A. Elahi, D. Shumway, M. Kowalczyk, A. Shrestha, D. Caragea, C. Caragea, S. Dorevitch, Machine learning, generalization, and transfer learning for predicting the exceedance of fecal indicator bacteria thresholds at beaches, *Environ. Sci. Technol.* 59 (42) (2025) 22386–22396, <https://doi.org/10.1021/acs.est.5c02835>.
- [26] G. Ignacz, L. Bader, A.K. Beke, Y. Ghunaim, T. Shastry, H. Vovusha, M.R. Carbone, B. Ghanem, G. Szekeley, Machine learning for the advancement of membrane science and technology: a critical review, *J. Membr. Sci.* 713 (2025), <https://doi.org/10.1016/j.memsci.2024.123256>.
- [27] Y. Takefujii, Limitations of SHAP-based interpretations in environmental and membrane filtration applications, *Water Res.* 288 (Pt B) (2026) 124766, <https://doi.org/10.1016/j.watres.2025.124766>.
- [28] A.D. Eaton, M.A.H. Franson, A.P.H. Association, A.W.W. Association, W. E. Federation, Standard Methods for the Examination of Water and Wastewater, *American Public Health Association*, 2005.
- [29] Z. Huang, S.L. Ong, H.Y. Ng, Submerged anaerobic membrane bioreactor for low-strength wastewater treatment: effect of HRT and SRT on treatment performance and membrane fouling, *Water Res.* 45 (2) (2011) 705–713, <https://doi.org/10.1016/j.watres.2010.08.035>.
- [30] B. Xu, T.C. Albert Ng, S. Huang, X. Shi, H.Y. Ng, Feasibility of isolated novel facultative quorum quenching consortiums for fouling control in an AnMBR, *Water Res.* 169 (2020), <https://doi.org/10.1016/j.watres.2019.115251>.
- [31] B. Xu, Q.A.C. Cho, T.C.A. Ng, S. Huang, H.Y. Ng, Enriched autoinducer-2 (AI-2)-based quorum quenching consortium in a ceramic anaerobic membrane bioreactor (AnMBR) for biofouling retardation, *Water Res.* 214 (2022), <https://doi.org/10.1016/j.watres.2022.118203>.
- [32] X. Yue, Y.K.K. Koh, H.Y. Ng, Effects of dissolved organic matters (DOMs) on membrane fouling in anaerobic ceramic membrane bioreactors (AnCMBRs) treating domestic wastewater, *Water Res.* 86 (2015) 96–107, <https://doi.org/10.1016/j.watres.2015.07.038>.
- [33] M. Ribeiro, K. Grolinger, H.F. ElYamany, W.A. Higashino, M.A.M. Capretz, Transfer learning with seasonal and trend adjustment for cross-building energy forecasting, *Energy Build.* 165 (2018) 352–363, <https://doi.org/10.1016/j.enbuild.2018.01.034>.
- [34] C. Niu, B. Li, Z. Wang, Using artificial intelligence-based algorithms to identify critical fouling factors and predict fouling behavior in anaerobic membrane bioreactors, *J. Membr. Sci.* 687 (2023), <https://doi.org/10.1016/j.memsci.2023.122076>.
- [35] J.J. Zhu, M. Yang, Z.J. Ren, Machine learning in environmental research: common pitfalls and best practices, *Environ. Sci. Technol.* 57 (46) (2023) 17671–17689, <https://doi.org/10.1021/acs.est.3c00026>.
- [36] X. Chen, Y. Zhang, A. Ye, J. Li, K. Hsu, S. Sorooshian, Fine-tuning long short-term memory models for seamless transition in hydrological modelling: from pre-training to post-application, *Environ. Model. Software* 186 (2025), <https://doi.org/10.1016/j.envsoft.2025.106350>.
- [37] J. Zhao, F. Chu, L. Xie, Y. Che, Y. Wu, A.F. Burke, A survey of transformer networks for time series forecasting, *Comput. Sci. Rev.* 60 (2026), <https://doi.org/10.1016/j.cosrev.2025.100883>.
- [38] P. Lara-Benitez, M. Carranza-Garcia, J.C. Riquelme, An experimental review on deep learning architectures for time series forecasting, *Int. J. Neural Syst.* 31 (3) (2021) 2130001, <https://doi.org/10.1142/S0129065721300011>.
- [39] Y. Ma, Y. Qiao, M. Chen, D. Rui, X. Zhang, W. Liu, L. Ye, How small is big enough? Big data-driven machine learning predictions for a full-scale wastewater treatment plant, *Water Res.* 274 (2025), <https://doi.org/10.1016/j.watres.2024.123041>.
- [40] Z. Jiang, Z. Xia, S. Liu, Q. Wei, H. Fan, L. Qi, G. Liu, H. Wang, The effect of fine grits and fine debris concentrations on the MLVSS/MLSS ratio of an activated sludge system, *J. Environ. Sci. (China)* 147 (2025) 607–616, <https://doi.org/10.1016/j.jes.2023.10.032>.

Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc (42406133) và Quỹ Ng hiện cứu Cơ bản và Ứng dụng Cơ bản tỉnh Quảng Đông (2023A1515 110786). Các tác giả cũng xin cảm ơn các thành viên trong nhóm ng hiện cứu của Giáo sư How Yong Ng tại Singapore (chẳng hạn như W ei Hao Loh, David Imanuel Tanaka, v.v.) vì đã hỗ trợ quý báu trong v iệc thu thập dữ liệu vận hành từ các nhà máy bể phản ứng sinh học màng quy mô thí điểm. Dữ liệu chỉ được sử dụng cho mô hình hóa và mô phỏng dựa trên AI trong nghiên cứu này; mọi thông tin nhạy cảm, bí mật hoặc có thể nhận dạng đều đã được ẩn danh hoặc che giấu trước khi phân tích.

Phụ lục A. Dữ liệu bổ sung

Dữ liệu bổ sung cho bài viết này có thể được tìm thấy trực tuyến tại <https://doi.org/10.1016/j.memsci.2026.126065>.

Tính khả dụng của dữ liệu

Dữ liệu sẽ được cung cấp khi có yêu cầu.

Tài liệu tham khảo

- [1] P.L. McCarty, J. Bae, J. Kim, Xử lý nước thải sinh hoạt như một nguồn sản xuất năng lượng ròng—liệu có thể đạt được điều này? *Environ. Sci. Technol.* 45 (17) (2011) 7100–7106, <https://doi.org/10.1021/es2014264>.
- [2] C. Niu, X. Li, R. Dai, Z. Wang, Dự đoán tắc nghẽn màng có tích hợp trí tuệ nhân tạo cho các quy trình dựa trên màng trong 20 năm qua: một bài tổng quan phê bình, *Water Res.* 216 (2022), <https://doi.org/10.1016/j.watres.2022.118299>.
- [3] F. Meng, S. Zhang, Y. Oh, Z. Zhou, H.S. Shin, S.R. Chae, Tắc nghẽn trong các bể phản ứng sinh học màng: bài tổng quan cập nhật, *Water Res.* 114 (2017) 151–180, <https://doi.org/10.1016/j.watres.2017.02.006>.
- [4] K. Xiao, S. Liang, X. Wang, C. Chen, X. Huang, Hiện trạng và thách thức của việc ứng dụng bể phản ứng sinh học màng quy mô toàn diện: một bài tổng quan phê bình, *Bioreour. Technol.* 271 (2019) 473–481, <https://doi.org/10.1016/j.biortech.2018.09.061>.
- [5] K.B. Newhart, R.W. Holloway, A.S. Hering, T.Y. Cath, Phân tích hiệu suất các nhà máy xử lý nước thải dựa trên dữ liệu: bài tổng quan, *Water Res.* 157 (2019) 498–513, <https://doi.org/10.1016/j.watres.2019.03.030>.
- [6] M. Faisal, K.M. Muttaqi, D. Sutanto, A.Q. Al-Shetwi, P.J. Ker, M.A. Hannan, Các công nghệ điều khiển nhà máy xử lý nước thải: hiện trạng, thách thức hiện nay và định hướng tương lai, *Renew. Sustain. Energy R. ev.* 181 (2023), <https://doi.org/10.1016/j.rser.2023.113324>.
- [7] Y. Zhu, Y. Wang, E. Zhu, Z. Ma, H. Wang, C. Chen, J. Guan, T.D. Waite, Dự đoán tắc nghẽn màng tại các nhà máy xử lý nước thải sử dụng bể phản ứng sinh học màng chìm bằng học máy, *Environ. Sci. Technol.* 59 (20) (2025) 10010–10021, <https://doi.org/10.1021/acs.est.4c12835>.
- [8] D.J. Kovacs, Z. Li, B.W. Baetz, Y. Hong, S. Donnaz, X. Zhao, P. Zhou, H. Ding, Q. Dong, Dự đoán tắc nghẽn màng và phân tích độ bất định bằng học máy: nghiên cứu trường hợp tại một nhà máy xử lý nước thải, *J. Membr. Sci.* 660 (2022), <https://doi.org/10.1016/j.memsci.2022.120817>.
- [9] K. Nam, S. Heo, G. Rhee, M. Kim, C. Yoo, Tối ưu hóa hai mục tiêu nhằm tiết kiệm năng lượng và giảm tắc nghẽn màng: từ thí nghiệm MBR bằng dự đoán nước đầu vào dựa trên AI và mô hình sinh học-vật lý tích hợp, *J. Membr. Sci.* 626 (2021), <https://doi.org/10.1016/j.memsci.2021.119208>.
- [10] M. Alvi, D. Batstone, C.K. Mbamba, P. Keymer, T. French, A. Ward, J. Dwyer, R. Cardell-Oliver, Học sâu trong xử lý nước thải: một bài tổng quan phê bình, *Water Res.* 245 (2023) 120518, <https://doi.org/10.1016/j.watres.2023.120518>.
- [11] R. Huang, C. Ma, J. Ma, X. Huangfu, Q. He, Học máy trong các hệ thống nước tự nhiên và nhân tạo, *Water Res.* 205 (2021) 117666, <https://doi.org/10.1016/j.watres.2021.117666>.
- [12] H. Pang, Y. Ben, Y. Cao, S. Qu, C. Hu, Sử dụng các thuật toán dựa trên trí tuệ nhân tạo để xác định các yếu tố tắc nghẽn then chốt và dự đoán hành vi tắc nghẽn trong các bể phản ứng sinh học màng kỵ khí, *J. Membr. Sci.* 687 (2023), <https://doi.org/10.1016/j.memsci.2023.122076>.
- [13] J.J. Zhu, M. Yang, Z.J. Ren, Học máy trong nghiên cứu bể phản ứng sinh học màng: nguyên lý, phương pháp, ứng dụng và hướng dẫn, *Front. Environ. Sci. Eng.* 19 (3) (2025), <https://doi.org/10.1007/s11783-025-1954-2>.
- [14] Y. Lai, K. Xiao, Y. He, X. Liu, J. Tan, W. Xue, A. Zhang, X. Huang, Giám sát tắc nghẽn thông minh trong xử lý nước thải dựa trên màng, *Nat. Sustain.* (2026), <https://doi.org/10.1038/s41893-026-01766-2>.
- [15] Y. Lai, K. Xiao, Y. Tian, M. Xing, H. Ding, J. Tan, J. Zhang, Z. Peng, Y. Fan, X. Lu, S. Liang, W. Xue, X. Huang, Ảnh hưởng của nồng độ cát hạt mịn và mảnh vụn nhỏ đến tỷ lệ MLVSS/MLSS của hệ thống bùn hoạt tính, *J. Environ. Sci. (China)* 147 (2025) 607–616, <https://doi.org/10.1016/j.jes.2023.10.032>.
- [16] H. Zhang, H. Jiang, J. Yin, T. Wang, W. Zeng, D. Lin, B. Xu, L. Bai, H. Liang, H. Y. Ng, Đáp ứng của màng sinh học trong các hệ thống màng xử lý sinh học được tăng cường chênh lệch điện thế nhằm tăng tốc loại bỏ kháng sinh và giảm thiểu ARG, *Water Res.* 285 (2025) 124154, <https://doi.org/10.1016/j.watres.2025.124154>.
- [17] G. Mannina, B.J. Ni, J. Makinia, J. Harmand, M. Alliet, C. Brepols, M.V. Ruano, A. Robles, M. Heran, H. Gulhan, I. Rodriguez-Roda, J. Comas, Mô hình hóa các quá trình sinh học cho hệ thống MBR: tổng quan về hiện trạng, tập trung vào SMP và

EPS, *Water Res.* 242 (2023) 120275, <https://doi.org/10.1016/j.watres.2023.120275>.

[18] S. Gharibian, H. Hazrati, Hướng tới tích hợp thực tiễn MBR với quy trình oxy hóa nâng cao điện hóa: cải thiện khả năng phân hủy sinh học của nước thải được phẩm thực tế và giảm thiểu tắc nghẽn màng, *Water Res.* 218 (2022) 118478, <https://doi.org/10.1016/j.watres.2022.118478>.

[19] F. Karamouz, H. Hazrati, A.B. khoshfetrat, Giảm thiểu tắc nghẽn màng trong bể phản ứng sinh học màng bằng cách kết hợp p điện trường và chất hấp phụ nano chitosan, *Environ. Technol. Innov.* 36 (2024), <https://doi.org/10.1016/j.eti.2024.103774>.

[20] H. Hazrati, N. Jahanbakhshi, M. Rostamizadeh, Giảm tắc nghẽn màng trong bể phản ứng sinh học màng bằng các chất hấp phụ nano zeolit tổng hợp, *J. Membr. Sci.* 555 (2018) 455–462, <https://doi.org/10.1016/j.memsci.2018.03.076>.

[21] A.H. Ba-Alawi, J. Loy-Benitez, S. Kim, C. Yoo, Bù đắp liệu t hiều và tự xác thực cảm biến hướng tới vận hành bền vững các nhà máy xử lý nước thải bằng bộ mã hóa tự hồi quy biến phân sâu, *Chemosphere* 288 (Pt 3) (2022) 132647, <https://doi.org/10.1016/j.chemosphere.2021.132647>.

[22] H. Cheng, J. Wu, Y. Liu, D. Huang, Phương pháp mới nhận diện lỗi và phân tích quan hệ nhân quả gốc của c ác lỗi mới phát sinh, ứng dụng cho các quy trình xử lý nước thải, *Chemometr. Intell. Lab. Syst.* 188 (2019) 24–36, <https://doi.org/10.1016/j.chemolab.2019.03.004>.

[23] H. Zhang, L. Shi, J. Cai, X. Wang, Z. Yan, DMGTNet: mô hình học sâu đô thị-thời gian d ự đoán tắc nghẽn màng trong các hệ thống xử lý nước thải hai màng, *J. Membr. Sci.* 736 (2025), <https://doi.org/10.1016/j.memsci.2025.124648>.

[24] J.-H. Wang, H.-C. Wang, Z.-W. Guo, X. Gao, F. Dong, M.S. Mahmoud, Y.-P. Chen, Y. Shen, Phá vỡ các ốc đ ảo dữ liệu: phương pháp mô hình hóa mới dựa trên chuyển giao tri thức tăng cường g giữa các nhà máy xử lý nước thải, *Process Saf. Environ. Prot.* 206 (2026), <https://doi.org/10.1016/j.psep.2025.108309>.

[25] A. Elahi, D. Shumway, M. Kowalczyk, A. Shrestha, H. Vovusha, M.R. Carbone, B. Ghanem, G. Szekeley, Học máy thúc đẩy khoa học và công nghệ quản lý: tổng qu an phân biên, *J. Membr. Sci.* 713 (2025), <https://doi.org/10.1016/j.memsci.2024.123256>.

[26] Y. Takefujii, Những hạn chế của diễn giải dựa trên SHAP trong các ứng dụ ng môi trường và lọc màng, *Water Res.* 288 (Pt B) (2026) 124766, <https://doi.org/10.1016/j.watres.2025.124766>.

[27] A.D. Eaton, M.A.H. Franson, A.P.H. Association, A.W.W. Association, W. E. Federation, Các phương pháp tiêu chuẩn để kiểm nghiệm nướ c và nước thải, Hiệp hội Y tế Công cộng Hoa Kỳ, 2005.

[28] Z. Huang, S.L. Ong, H.Y. Ng, Bể phản ứng sinh học màng kỵ khí ngập chìm xử lý nước thải có nồng độ thấp: ản h hưởng của HRT và SRT đến hiệu quả xử lý và tắc nghẽn màng, *Water Res.* 45 (2) (2011) 705–713, <https://doi.org/10.1016/j.watres.2010.08.035>.

[29] B. Xu, T.C. Albert N g, S. Huang, X. Shi, H.Y. Ng, Tính khả thi của các quần thể vi sinh vật mới phân lập có khả năng đập tắt quorum tùy nghi để kiểm soát tắc nghẽn trong AnMBR, *Water Res.* 169 (2020), <https://doi.org/10.1016/j.watres.2019.115251>.

[30] B. Xu, Q.A.C. Cho, T. C.A. Ng, S. Huang, H.Y. Ng, Quần thể vi sinh vật đập tắt quorum dựa trên autoinduc er-2 (AI-2) được làm giàu trong bể phản ứng sinh học màng kỵ khí gồm (AnMBR) nh ằm làm chậm tắc nghẽn sinh học, *Water Res.* 214 (2022), <https://doi.org/10.1016/j.watres.2022.118203>.

[31] X. Yue, Y.K.K. Koh, H.Y. Ng, Ảnh hưởng của các chất hữu cơ hòa tan (DOM) đến tắc nghẽn màng trong các bể phản ứng sinh học màng gồm kỵ khí (AnCMBR) xử lý nước thải sinh hoạt, *Water Res.* 86 (2015) 96–107, <https://doi.org/10.1016/j.watres.2015.07.038>.

[32] M. Ribeiro, K. Grolinger, H.F. ElYamany, W.A. Higashino, M.A.M. Capretz, Học chuyên giao có điều chỉnh mùa vụ và xu hướng để dự b ảo năng lượng giữa các tòa nhà, *Energy Build.* 165 (2018) 352–363, <https://doi.org/10.1016/j.enbuild.2018.01.034>.

[33] C. Niu, B. Li, Z. Wang, Sử dụng các thuật toán dựa trên trí tuệ nhân tạo để xác định các yếu tố tắc nghẽn then chốt và dự đoán hành vi tắc nghẽn trong các bể phản ứng sinh học màng kỵ khí, *J. Membr. Sci.* 687 (2023), <https://doi.org/10.1016/j.memsci.2023.122076>.

[34] J.J. Zhu, M. Yang, Z.J. Ren, Học máy trong nghiên cứu bể phản ứng sinh học màng: nghiên cứu trường hợp tại một nhà máy xử lý nước thải, *J. Membr. Sci.* 660 (2022), <https://doi.org/10.1016/j.memsci.2022.120817>.

[35] K. Nam, S. Heo, G. Rhee, M. Kim, C. Yoo, Tối ưu hóa hai mục tiêu nhằm tiết kiệm năng lượng và giảm tắc nghẽn màng: từ thí nghiệm MBR bằng dự đoán nước đầu vào dựa trên AI và mô hình sinh học-vật lý tích hợp, *J. Membr. Sci.* 626 (2021), <https://doi.org/10.1016/j.memsci.2021.119208>.

[36] M. Alvi, D. Batstone, C.K. Mbamba, P. Keymer, T. French, A. Ward, J. Dwyer, R. Cardell-Oliver, Học sâu trong xử lý nước thải: một bài tổng quan phê bình, *Water Res.* 245 (2023) 120518, <https://doi.org/10.1016/j.watres.2023.120518>.

[37] R. Huang, C. Ma, J. Ma, X. Huangfu, Q. He, Học máy trong các hệ thống nước tự nhiên và nhân tạo, *Water Res.* 205 (2021) 117666, <https://doi.org/10.1016/j.watres.2021.117666>.

[38] H. Pang, Y. Ben, Y. Cao, S. Qu, C. Hu, Sử dụng các thuật toán dựa trên trí tuệ nhân tạo để xác định các yếu tố tắc nghẽn then chốt và dự đoán hành vi tắc nghẽn trong các bể phản ứng sinh học màng kỵ khí, *J. Membr. Sci.</*

[41] E. Poorasgari, T. Vistisen Bugge, M. Lykkegaard Christensen, M. Koustrup Jørgensen, Compressibility of fouling layers in membrane bioreactors, J. Membr. Sci. 475 (2015) 65–70, <https://doi.org/10.1016/j.memsci.2014.09.056>.
[42] J. Pyo, Y. Pachepsky, S. Kim, A. Abbas, M. Kim, Y.S. Kwon, M. Ligaray, K.H. Cho, Long short-term memory models of water quality in inland water environments, Water Res. X 21 (2023) 100207, <https://doi.org/10.1016/j.wroa.2023.100207>.
[43] S. Wang, H. Peng, S. Liang, Prediction of estuarine water quality using interpretable machine learning approach, J. Hydrol. 605 (2022), <https://doi.org/10.1016/j.jhydrol.2021.127320>.
[44] A.J. Atkinson, M.D. Armstrong, J.T. Eskew, O. Coronell, 2-Aminoimidazole reduces fouling and improves membrane performance, J Memb Sci 629 (2021), <https://doi.org/10.1016/j.memsci.2021.119262>.
[45] R. Chen, Y. Nie, Y. Hu, R. Miao, T. Utashiro, Q. Li, M. Xu, Y.-Y. Li, Fouling behaviour of soluble microbial products and extracellular polymeric substances in a submerged anaerobic membrane bioreactor treating low-strength wastewater at room temperature, J. Membr. Sci. 531 (2017) 1–9, <https://doi.org/10.1016/j.memsci.2017.02.046>.
[46] H. Lin, M. Zhang, F. Wang, F. Meng, B.-Q. Liao, H. Hong, J. Chen, W. Gao, A critical review of extracellular polymeric substances (EPSs) in membrane bioreactors: characteristics, roles in membrane fouling and control strategies, J. Membr. Sci. 460 (2014) 110–125, <https://doi.org/10.1016/j.memsci.2014.02.034>.
[47] L.-g. Shen, Q. Lei, J.-R. Chen, H.-C. Hong, Y.-M. He, H.-J. Lin, Membrane fouling in a submerged membrane bioreactor: impacts of floc size, Chem. Eng. J. 269 (2015) 328–334, <https://doi.org/10.1016/j.cej.2015.02.002>.
[48] S. Wang, X. Lu, L. Zhang, J. Guo, H. Zhang, Characterization of the initial fouling layer on the membrane surface in a membrane bioreactor: effects of permeation drag, Membranes 9 (9) (2019), <https://doi.org/10.3390/membranes9090121>.
[49] D.W. Gao, Z.D. Wen, B. Li, H. Liang, Membrane fouling related to microbial community and extracellular polymeric substances at different temperatures, Bioresour. Technol. 143 (2013) 172–177, <https://doi.org/10.1016/j.biortech.2013.05.127>.
[50] Y. Tian, Z. Li, Y. Ding, Y. Lu, Identification of the change in fouling potential of soluble microbial products (SMP) in membrane bioreactor coupled with worm

reactor, Water Res. 47 (6) (2013) 2015–2024, <https://doi.org/10.1016/j.watres.2013.01.026>.
[51] Y. Ding, Z. Guo, Z. Liang, X. Hou, Z. Li, D. Mu, C. Ge, C. Zhang, C. Jin, Long-term investigation into the membrane fouling behavior in anaerobic membrane bioreactors for municipal wastewater treatment operated at two different temperatures, Membranes 10 (9) (2020), <https://doi.org/10.3390/membranes10090231>.
[52] T. Kakuda, R. Naito, A. Suzuki, A. Hafuka, K. Kimura, Quantitative and qualitative variations of biopolymers in a pilot-scale membrane bioreactor treating municipal wastewater throughout 3 years of operation, J. Environ. Manag. 328 (2023) 116863, <https://doi.org/10.1016/j.jenvman.2022.116863>.
[53] H. Cao, X. Xie, Z. Xiao, W. Liu, Transferability of machine learning models for geogenic contaminated groundwaters, Environ. Sci. Technol. 58 (20) (2024) 8783–8791, <https://doi.org/10.1021/acs.est.4c01327>.
[54] Y. Gao, Y. Mao, L. Kong, L. Sun, S. Fu, W. Zhan, W. Zuo, Elucidating the role of ferric chloride on carbon capture from low-strength municipal wastewater in high-rate activated sludge process: parameter optimization and crucial mechanism, J. Clean. Prod. 452 (2024), <https://doi.org/10.1016/j.jclepro.2024.142248>.
[55] T. Peng, Y. Wang, J. Wang, F. Fang, P. Yan, Z. Liu, Effect of different forms and components of EPS on sludge aggregation during granulation process of aerobic granular sludge, Chemosphere 303 (Pt 2) (2022) 135116, <https://doi.org/10.1016/j.chemosphere.2022.135116>.
[56] Q. Su, Y. Zhong, J.C.J. Rui, M. Ding, T.C.A. Ng, B. Xu, H.Y. Ng, Stability and durability of polymeric membranes in membrane bioreactors for industrial wastewater treatment, J. Environ. Chem. Eng. 13 (6) (2025), <https://doi.org/10.1016/j.jece.2025.120356>.
[57] Y. Lai, Y. Xu, X. Liu, K. Xiao, F. Qu, S. Liang, W. Xue, X. Huang, Feedforward fouling control guided by online UV and fluorescence spectral early warning for low-energy operation of membrane bioreactor, Water Res. 297 (2026), <https://doi.org/10.1016/j.watres.2026.125715>.
[58] F. Delrue, A.E. Stricker, M. Miettton-Peuchot, Y. Racault, Relationships between mixed liquor properties, operating conditions and fouling on two full-scale MBR plants, Desalination 272 (1–3) (2011) 9–19, <https://doi.org/10.1016/j.desal.2010.12.056>.

[41] E. Poorasgari, T. Vistisen Bugge, M. Lykkegaard Christensen, M. Koustrup Jørgensen, Tính nén được của các lớp cấu trúc trong bể phản ứng sinh học màng, J. Membr. Sci. 475 (2015) 65–70, <https://doi.org/10.1016/j.memsci.2014.09.056>. [42] J. Pyo, Y. Pachepsky, S. Kim, A. Abbas, M. Kim, Y.S. Kwon, M. Ligaray, K.H. Cho, Mô hình bộ n hớ ngắn hạn dài hạn về chất lượng nước trong môi trường thủy vực nội địa, Water Res. X 21 (2023) 100207, <https://doi.org/10.1016/j.wroa.2023.100207>. [43] S. Wang, H. Peng, S. Liang, Dự đoán chất lượng nước cửa sông bằng phương pháp học máy c ó khả năng diễn giải, J. Hydrol. 605 (2022), <https://doi.org/10.1016/j.jhydrol.2021.127320>. [44] A.J. Atkinson, M.D. Armstrong, J.T. Eskew, O. Coronell, 2-Aminoimidazole l ảm giảm cấu trúc và cải thiện hiệu suất màng, J Memb Sci 629 (2021), <https://doi.org/10.1016/j.memsci.2021.119262>. [45] R. Chen, Y. Nie, Y. Hu, R. Miao, T. Utashiro, Q. L i, M. Xu, Y.-Y. Li, Đặc tính cấu trúc của các sản phẩm vi sinh hòa tan và các chất poly mer ngoại bào trong bể phản ứng sinh học màng kỵ khí chìm xử lý nước thải nồng độ thấp ở nhiệt độ phòng, J. Membr. Sci. 531 (2017) 1–9, <https://doi.org/10.1016/j.memsci.2017.02.046>. [46] H. Lin, M. Zhang, F. Wang, F. Meng, B.-Q. Liao, H. Hong, J. Ch en, W. Gao, Tổng quan phản biến về các chất polymer ngoại bào (EPS) trong bể phả n ứng sinh học màng: đặc tính, vai trò trong cấu trúc màng và các chiến lược kiểm s oát, J. Membr. Sci. 460 (2014) 110–125, <https://doi.org/10.1016/j.memsci.2014.02.034>. [47] L.-g. Shen, Q. Lei, J.-R. Chen, H.-C. Hong, Y.-M. He, H.-J. Lin, Cấu trúc màng tro ng bể phản ứng sinh học màng chìm: tác động của kích thước bông bùn, Chem. Eng . J. 269 (2015) 328–334, <https://doi.org/10.1016/j.cej.2015.02.002>. [48] S. Wang, X. Lu, L. Zhang, J. Guo, H. Zhang, Đặc trưng lớp cấu trúc ban đầu trên bề mặt màng trong bể phản ứng sinh học màng: ảnh hưởng của lực cản thẩm, Membranes 9 (9) (2019), <https://doi.org/10.3390/membranes9090121>. [49] D.W. Gao, Z.D. Wen, B. Li, H. Lian g, Cấu trúc màng liên quan đến cộng đồng vi sinh vật và các chất polymer ngoại bào ở các nhiệt độ khác nhau, Bioresour. Technol. 143 (2013) 172–177, <https://doi.org/10.1016/j.biortech.2013.05.127>. [50] Y. Tian, Z. Li, Y. Ding, Y. Lu, Xác định sự thay đổi v ề tiềm năng gây cấu trúc của các sản phẩm vi sinh hòa tan (SMP) trong bể phản ứng sinh học màng kết hợp với giun

bể phản ứng, Water Res. 47 (6) (2013) 2015–2024, <https://doi.org/10.1016/j.watres.2013.01.026>. [51] Y. Ding, Z. Guo, Z. Liang, X. Hou, Z. Li, D. Mu, C. Ge, C. Zhang, C. Jin, Nghiên cứu dài hạn về hiện tượng bám bẩn màng trong các bể phản ứng sinh học màng kỵ khí xử lý nước thải đô thị ở hai nhiệt độ khác nhau, Membranes 10 (9) (2020), <https://doi.org/10.3390/membranes10090231>. [52] T. Kakuda, R. Naito, A. Suzuki, A. Hafuka, K. Kimura, Những biến đổi định lượng và định tính của các polyme s inh học trong hệ thống phản ứng sinh học màng quy mô thí điểm xử lý nước thải đ ô thị trong suốt 3 năm vận hành, J. Environ. Manag. 328 (2023) 116863, <https://doi.org/10.1016/j.jenvman.2022.116863>. [53] H. Cao, X. Xie, Z. Xiao, W. Liu, Khả năng ch uyển giao của các mô hình học máy đối với nước ngầm bị ô nhiễm do nguồn gốc địa sinh, Environ. Sci. Technol. 58 (20) (2024) 8783–8791, <https://doi.org/10.1021/acs.est.4c01327>. [54] Y. Gao, Y. Mao, L. Kong, L. Sun, S. Fu, W. Zhan, W. Zuo, Làm sáng tỏ v ai trò của sắt(III) clorua trong thu hồi cacbon từ nước thải đô thị có nồng độ chất ô nhiễm thấp bằng quy trình bùn hoạt tính tốc độ cao: tối ưu hóa thông số và cơ chế t hen chốt, J. Clean. Prod. 452 (2024), <https://doi.org/10.1016/j.jclepro.2024.142248>. [5 5] T. Peng, Y. Wang, J. Wang, F. Fang, P. Yan, Z. Liu, Ảnh hưởng của các dạng và thàn h phần EPS khác nhau đến sự kết tụ bùn trong quá trình tạo hạt bùn hạt hiếu khí, C hemosphere 303 (Pt 2) (2022) 135116, <https://doi.org/10.1016/j.chemosphere.2022.135116>. [56] Q. Su, Y. Zhong, J.C.J. Rui, M. Ding, T.C.A. Ng, B. Xu, H.Y. Ng, Độ ổn định và độ bền của màng polyme trong các bể phản ứng sinh học màng xử lý nước thải c ông nghiệp, J. Environ. Chem. Eng. 13 (6) (2025), <https://doi.org/10.1016/j.jece.2025.120356>. [57] Y. Lai, Y. Xu, X. Liu, K. Xiao, F. Qu, S. Liang, W. Xue, X. Huang, Kiểm soát bám bẩn theo cơ chế truyền tiếp, dựa trên cảnh báo sớm trực tuyến bằng phổ UV v à huỳnh quang, nhằm vận hành bể phản ứng sinh học màng với mức tiêu thụ năng lượng thấp, Water Res. 297 (2026), <https://doi.org/10.1016/j.watres.2026.125715>. [58] F. Delrue, A.E. Stricker, M. Miettton-Peuchot, Y. Racault, Mối quan hệ giữa các đặc tính của hỗn hợp bùn, điều kiện vận hành và hiện tượng bám bẩn tại hai nhà máy M BR quy mô toàn phần, Desalination 272 (1–3) (2011) 9–19, <https://doi.org/10.1016/j.desal.2010.12.056>.