




Contents lists available at ScienceDirect

Journal of Water Process Engineering

journal homepage: www.elsevier.com/locate/jwpe



Interpretable prediction of coagulant dosage in drinking water treatment plant based on automated machine learning and SHAP method

Liyan Feng ^a, Ying Zhang ^{a,*}, Xiaoting Wei ^d, Mengyuan Wang ^a, Zhiguang Niu ^a, Chenchen Wang ^{b,c,**}

^a School of Environmental Science & Engineering, Tianjin University, Tianjin 300350, China

^b School of Environmental and Municipal Engineering, Tianjin Chengjian University, Tianjin 300384, China

^c Tianjin Key Laboratory of Aquatic Science and Technology, Tianjin Chengjian University, Tianjin 300384, China

^d Tianjin Teda Jinlian Water Supply Co., Ltd., Tianjin 300457, China

ARTICLE INFO

Editor: Guangming Jiang

Keywords:

Automated machine learning
SHAP interpretability
Random Forest
Coagulant
Water treatment

ABSTRACT

Accurate prediction of coagulant dosing is critical to ensure the efficiency and cost-effectiveness of the water treatment process. This study developed an accurate prediction model for coagulant dosing in drinking water treatment plants using automated machine learning (AutoML) and enhanced its transparency with the SHAP (Shapley Additive explanation) method. Results showed that the Random Forest (RF) model developed by AutoML outperformed the best single Gradient Boosting Tree model, with a 37 % lower RMSE of 0.89, a 52 % lower MAE of 0.47, and a 5 % higher R² of 0.96. The RF model has the potential to save 10.25 % of coagulant dosage per year, specifically, 222 kg/d of PACl at a cost of 180.7 yuan/d for Yangtze River water, and 225 kg/d at a cost of 183.2 yuan/d for Luan River water, while ensuring a more stable water quality in the treated water. SHAP analysis identified conductivity, ammonia nitrogen, chemical oxygen demand, and temperature of raw water as key factors affecting PACl dosage, which significantly impacts treated water pH. The combination of AutoML and SHAP method applied to intelligent water management, can bolster water treatment efficiency and management practices, resulting in noteworthy environmental, economic, and social benefits.

1. Introduction

With the rapid development of water treatment technologies, the issues of energy consumption and carbon emissions are becoming increasingly prominent [1,2]. In order to achieve the goal of green and low-carbon, traditional processes have been continuously optimized, but they are still subject to technical and economic constraints: adsorption technology is difficult to regenerate; photocatalytic deep mineralization is limited by the efficiency; and microwave catalytic efficiency is high, but the cost of the equipment is high [3–6]. Meanwhile, the complexity of the water treatment process places higher demands on the chemical dosing accuracy, especially in coagulation, whose operating cost accounts for a high proportion of the total cost of water plants [7,8], and multivariate (water temperature, pH, etc.), nonlinear dynamic response, and real-time disturbances make it difficult for traditional empirical models to balance dosing accuracy and energy efficiency [9,10]. Therefore, determining the optimal coagulant dosage

based on raw water quality and established treated water quality criteria is critical to ensure water treatment effectiveness and to realize economic and environmental benefits [11].

Traditional manual dosing is highly subjective, resulting in high drug consumption and difficult to adapt to large-scale production, resulting in insufficient stability of water control and regulatory lag [12]. Mechanistic models, on the other hand, struggle to capture the complex reactions and nonlinear relationships within the coagulation process, thereby limiting their practical applicability [13]. Alternatively, data-driven models utilizing machine learning can construct black-box models for nonlinear, multivariate dynamic systems by learning from limited datasets [14]. However, current models have limitations in simulating and predicting anticoagulant dosing, particularly in terms of generalizability and convergence [15]. Among the existing methods for coagulation dosing prediction, DL-MV relies on parameter tuning for high-precision prediction [16]; PSO-SVR optimization requires manually preset parameters [17]; and GA-RF architectures are hardened and

* Corresponding author.

** Corresponding author at: School of Environmental and Municipal Engineering, Tianjin Chengjian University, Tianjin 300384, China.

E-mail addresses: yzhang_n@tju.edu.cn (Y. Zhang), wcc12122008@163.com (C. Wang).

<https://doi.org/10.1016/j.jwpe.2025.107925>

Received 25 January 2025; Received in revised form 1 May 2025; Accepted 9 May 2025

Available online 15 May 2025


2214-7144/© 2025 Elsevier Ltd. All rights are reserved, including those for text and data mining, AI training, and similar technologies.



Contents lists available at ScienceDirect

Journal of Water Process Engineering

journal homepage: www.elsevier.com/locate/jwpe



Dự đoán có thể diễn giải liều lượng chất keo tụ trong nhà máy xử lý nước uống dựa trên học máy tự động và phương pháp SHAP

Liyan Feng ^a, Ying Zhang ^{a,*}, Xiaoting Wei ^d, Mengyuan Wang ^a, Zhiguang Niu ^a, Chenchen Wang ^{b,c,**}

^a School of Environmental Science & Engineering, Tianjin University, Tianjin 300350, China^b

School of Environmental and Municipal Engineering, Tianjin Chengjian University, Tianjin 300384, China^c

Tianjin Key Laboratory of Aquatic Science and Technology, Tianjin Chengjian University, Tianjin 300384, China^d

Tianjin Teda Jinlian Water Supply Co., Ltd., Tianjin 300457, China

THÔNG TIN BÀI VIẾT

Biên tập: Guangming Jiang

Keywords:

Học máy tự động, khả năng diễn giải SHAP, rừng ngẫu nhiên, chất keo tụ, xử lý nước

TÓM TẮT

Dự đoán chính xác liều lượng chất keo tụ đóng vai trò thiết yếu trong việc đảm bảo hiệu quả và tính kinh tế của quy trình xử lý nước. Nghiên cứu này đã xây dựng mô hình dự đoán chính xác liều lượng chất keo tụ tại các nhà máy xử lý nước uống bằng học máy tự động (AutoML) và tăng cường tính minh bạch của mô hình bằng phương pháp SHAP (giải thích cộng tính Shapley). Kết quả cho thấy mô hình Rừng ngẫu nhiên (RF) do AutoML xây dựng vượt trội hơn mô hình Cây tăng cường Gradient đơn tốt nhất, với RMSE thấp hơn 37 % (0,89), MAE thấp hơn 52% (0,47) và R² cao hơn 5% (0,96). Mô hình RF có khả năng giúp tiết kiệm 10,25% liều lượng chất keo tụ sử dụng mỗi năm, cụ thể là 222 kg/ngày PACl với chi phí 180,7 nhân dân tệ/ngày đối với nước sông Dương Tử và 225 kg/ngày với chi phí 183,2 nhân dân tệ/ngày đối với nước sông Loạn, đồng thời đảm bảo chất lượng nước sau xử lý ổn định hơn. Phân tích SHAP xác định độ dẫn điện, nitơ amoniac, nhu cầu oxy hóa học và nhiệt độ của nước thô là những yếu tố chính ảnh hưởng đến liều lượng PACl, từ đó tác động đáng kể đến độ pH của nước sau xử lý. Việc kết hợp AutoML và phương pháp SHAP trong quản lý nước uống thông minh có thể nâng cao hiệu quả xử lý nước và hoạt động quản lý, mang lại những lợi ích đáng kể về môi trường, kinh tế và xã hội.

1. Giới thiệu

Với sự phát triển nhanh chóng của các công nghệ xử lý nước, vấn đề tiêu thụ năng lượng và phát thải carbon ngày càng trở nên nổi bật [1,2]. Để đạt được mục tiêu xanh và ít phát thải carbon, các quy trình truyền thống đã liên tục được tối ưu hóa, nhưng vẫn chịu những hạn chế về kỹ thuật và kinh tế: công nghệ hấp phụ khó tái sinh; quá trình khoáng hóa sâu bằng xúc tác quang bị giới hạn bởi hiệu suất; còn hiệu suất xúc tác vi sóng cao nhưng chi phí thiết bị lại lớn [3–6]. Trong khi đó, quy trình xử lý nước phức tạp đặt ra yêu cầu cao hơn về độ chính xác khi châm hóa chất, đặc biệt là trong quá trình keo tụ, vốn có chi phí vận hành chiếm tỷ trọng lớn trong tổng chi phí của các nhà máy nước [7,8]. Các yếu tố đa biến (nhiệt độ nước, pH, v.v.), phản ứng động phi tuyến và các nhiễu thời gian thực khiến các mô hình kinh nghiệm truyền thống khó cân bằng độ chính xác khi châm hóa chất với hiệu quả năng lượng [9,10]. Do đó, việc xác định liều lượng chất keo tụ tối ưu

dựa trên chất lượng nước thô và các chỉ số chất lượng nước sau xử lý đã được thiết lập là yếu tố then chốt để đảm bảo hiệu quả xử lý nước và đạt được các lợi ích kinh tế và môi trường [11].

Việc định lượng thủ công truyền thống mang tính chủ quan cao, dẫn đến mức tiêu thụ thuốc lớn và khó thích ứng với sản xuất quy mô lớn, khiến khả năng kiểm soát nước chưa ổn định và việc điều chỉnh bị chậm trễ [12]. Trong khi đó, các mô hình cơ chế gặp khó khăn trong việc nắm bắt các phản ứng phức tạp và mối quan hệ phi tuyến trong quá trình keo tụ, do đó hạn chế khả năng ứng dụng thực tiễn [13]. Một giải pháp khác là các mô hình dựa trên dữ liệu sử dụng học máy, có thể xây dựng các mô hình hộp đen cho các hệ thống động phi tuyến, đa biến bằng cách học từ các tập dữ liệu hạn chế [14]. Tuy nhiên, các mô hình hiện nay vẫn còn hạn chế trong việc mô phỏng và dự đoán liều lượng chất chống đông, đặc biệt là về khả năng khái quát hóa và hội tụ [15]. Trong số các phương pháp hiện có để dự đoán liều lượng chất keo tụ, DL-MV dựa vào việc tinh chỉnh tham số để đưa ra dự đoán có độ chính xác cao [16]; phương pháp tối ưu hóa PSO-SVR đòi hỏi phải thiết lập tham số thủ công [17]; còn các kiến trúc GA-RF thì cứng nhắc và

* Corresponding author.

** Corresponding author at: School of Environmental and Municipal Engineering, Tianjin Chengjian University, Tianjin 300384, China.

E-mail addresses: yzhang_n@tju.edu.cn (Y. Zhang), wcc12122008@163.com (C. Wang).

<https://doi.org/10.1016/j.jwpe.2025.107925>

Received 25 January 2025; Received in revised form 1 May 2025; Accepted 9 May 2025

Available online 15 May 2025

2214-7144/© 2025 Elsevier Ltd. All rights are reserved, including those for text and data mining, AI training, and similar technologies.

have high computational requirements [18]. These methods generally have two limitations: first, they rely on manual intervention, making it difficult to automate the adjustment of complex nonlinear water quality relationships; second, they adhere to a single optimization paradigm and lack dynamic synergistic mechanisms, resulting in limited predictive efficiency and generalizability.

Automated Machine Learning (AutoML) builds efficient ML pipelines by automating the entire process [19], and its distributed frameworks (e. g., TPOT) enable fully automated model filtering to reduce development costs and labor dependency [20]. Studies have shown that AutoML excels in hyperparameter optimization and complex constraint solving [21–24]. TPOT improves accuracy by 15–20 % without feature reduction for 50-dimensional water quality data [25]. The H2O framework accurately predicts biological nutrient removal in wastewater [26], and TPOT outperforms traditional ML by 1.4 % in the lake water quality classification task [27]. Nevertheless, its exploration and application in coagulation agent dosing prediction have not yet been extensively pursued.

While some studies have used advanced ML techniques, their black-box nature limits interpretability and hinders practical application in water treatment plants, where operational transparency is critical. The SHapley Additive exPlanations (SHAP) method proposed by Lundberg and Lee [28], which significantly improves model transparency, credibility, and decision making by quantifying the marginal contribution of features to model predictions and identifying key influences and their interaction effects through global and local analysis [29]. The SHAP method has been applied in many fields [30–34] and has been used with high accuracy for surface water quality prediction [35–37]. However, this method has not been applied to coagulant dosage prediction.

Based on existing research, this study applies the interpretable AutoML framework to coagulation dose prediction for the first time, constructs the prediction system through automated model selection and hyper-parameter optimization, and integrates the SHAP method to achieve the global feature importance and local decision interpretation of the black-box model. By using real-time data and historical information, it ensures that the coagulation process can be accurately controlled while maintaining treated water quality standards, facilitating future technological advances and upgrades in the water treatment industry.

2. Materials and methods

2.1. Data acquisition and preprocessing

The data utilized in this study were sourced from a water treatment plant located in Tianjin, China. This plant receives water from two primary sources: the Luanhe River (for December, January and February annually), diverted from Hebei Province, and the Yangtze River (from March to November annually), originating from the Danjiangkou Reservoir in Hubei Province. The water treatment process involves pre-treatment, enhanced conventional treatment, and a combination of ultraviolet and chlorine disinfection. The daily treatment capacity of the water plant is 17.5 wt/d, and the hydraulic retention time is relatively stable at 25.56 min. The plant uses two types of coagulants: ferric chloride and PACl, which are dosed during the pretreatment and blending stages, respectively. Water quality parameters and coagulant dosing data were collected daily from October 2022 to May 2024, totaling 1339 data points. These data were randomly divided into a training set (1071 entries) and a test set (268 entries) in an 8: 2 ratio. The feature variables consist of inflow rate (WTR) and water quality indicators such as temperature (T), pH, turbidity (NTU), and electrical conductivity (EC), and chemical oxygen demand determined by potassium permanganate (COD_{Mn}) for both raw water (RW) and treated water (TW), with ammonia nitrogen (NH₃–N) being considered only for raw water. Based on practical plant operations and professional evaluations, the dosing amounts of the two coagulants are comparable, with a

maximum discrepancy not exceeding 5 mg/L. Therefore, PACl was used as the only target variable for accurate simulation of coagulant dosing in this study.

During data collection, the occurrence of detection errors and dosing system malfunctions resulted in the raw data set containing problems such as missing values and noise. Therefore, preprocessing is essential to improve data reliability, model performance, and decision quality [38]. In this study, the K-nearest neighbor (KNN, k = 4) estimation model was used to deal with missing data, which balances interpolation stability and global representativeness, and provides better data retention for non-randomly missing key parameters (e.g., water temperature, ammonia nitrogen). The interpolation effect in the range of k = 1–10 was searched through the grid and the mean square error (MSE) was used as the evaluation criterion, and the results showed that the MSE was minimized on the test set at k = 4. In addition, noise and random errors were mitigated using a moving average filter with a window size of $n = 5$, determined based on an autocorrelation function (ACF) analysis, a value that effectively captures short-term fluctuations in water quality parameters while avoiding excessive smoothing that leads to peak attenuation [39].

To investigate the correlations between various features such as WTR, raw water quality indicators, treated water quality indicators, and coagulant dosage, we used the Spearman rank correlation coefficient (rs) method, which is known for its low sensitivity to nonlinear relationships and outliers. By excluding features with low correlations, we reduced redundant features to reduce the input dimensionality of the model, thereby improving both the operational efficiency and generalization capabilities of the model. A flowchart illustrating the modeling methodology is shown in Fig. 1.

2.2. Automated machine learning

AutoML is a technique for automating the machine learning process through algorithms, including feature engineering, algorithm selection, and hyperparameter optimization [40]. Its primary goal is to reduce the need for human intervention while improving model performance. In this study, the Tree-based Pipeline Optimization Tool (TPOT), an AutoML tool based on genetic programming, is used to automate model construction. TPOT is an open source Python-based AutoML library (version 0.11.7) with underlying dependencies on Scikit-Learn (version 1.0.2), DEAP (Distributed Evolutionary Algorithms Framework), and extensions such as XGBoost [27]. The model runs in a Python 3.8 environment, and the full configuration code for TPOT is open source.

In this study, the TPOT framework is adopted to automate the design of machine learning pipelines, whose core mechanisms are: iterative optimization based on tree-structured coding of genetic programming, integration of Scikit-Learn multi-algorithms with predefined hyperparameter space to balance the search efficiency; and screening of the Pareto-optimal pipeline by repeating the 10-fold cross-validation (run independently for 3 times) to ensure the model generalization performance [41].

2.3. SHAP interpretability method

The SHAP methodology encompasses Kernel SHAP, Deep SHAP, and Tree SHAP [42]. This study used the Tree SHAP package in Python 3.9 to analyze the importance, dependencies, and interactions of features. The modules and functions used in Python are listed in Table 1. The average absolute SHAP values were used to evaluate the importance of different factors in determining the dosage amount. By summing the average absolute SHAP values for all relevant environmental parameters, their combined impact on dosing strategies was quantified. Dependency plots of SHAP values revealed interactions between features and their collective contribution to the prediction of dosing strategies for the coagulation process [43]. Two typical samples were selected to generate local interpretability plots, waterfall plots, and decision plots in order to

có yêu cầu tính toán cao [18]. Các phương pháp này thường có hai hạn chế: thứ nhất, chúng phụ thuộc vào sự can thiệp thủ công, khiến việc tự động điều chỉnh các mối quan hệ chất lượng nước phi tuyến phức tạp trở nên khó khăn; thứ hai, chúng tuân theo một mô hình tối ưu hóa duy nhất và thiếu các cơ chế phối hợp động, dẫn đến hiệu quả dự đoán và khả năng khái quát hóa hạn chế.

Học máy tự động (AutoML) xây dựng các quy trình ML hiệu quả bằng cách tự động hóa toàn bộ quá trình [19], và các khung phân tích của nó (ví dụ: TPOT) cho phép lọc mô hình hoàn toàn tự động nhằm giảm chi phí phát triển và sự phụ thuộc vào lao động [20]. Các nghiên cứu cho thấy AutoML vượt trội trong tối ưu hóa siêu tham số và giải quyết các ràng buộc phức tạp [21–24]. TPOT cải thiện độ chính xác 15–20% mà không cần giảm số lượng đặc trưng đối với dữ liệu chất lượng nước có 50 chiều [25]. Khung H2O dự đoán chính xác quá trình loại bỏ chất dinh dưỡng sinh học trong nước thải [26], còn TPOT vượt trội hơn ML truyền thống 1,4% trong nhiệm vụ phân loại chất lượng nước hồ [27]. Tuy nhiên, AutoML vẫn chưa được nghiên cứu và ứng dụng rộng rãi trong dự đoán liều lượng hóa chất keo tụ.

Mặc dù một số nghiên cứu đã sử dụng các kỹ thuật ML tiên tiến, bản chất “hộp đen” của chúng hạn chế khả năng diễn giải và cản trở việc ứng dụng thực tiễn tại các nhà máy xử lý nước, nơi tính minh bạch trong vận hành có ý nghĩa then chốt. Phương pháp SHapley Additive exPlanations (SHAP) do Lundberg và Lee [28] đề xuất giúp cải thiện đáng kể tính minh bạch, độ tin cậy và khả năng ra quyết định của mô hình bằng cách định lượng đóng góp biên của các đặc trưng vào dự đoán của mô hình, đồng thời xác định các yếu tố ảnh hưởng chính và tác động tương tác của chúng thông qua phân tích toàn cục và cục bộ [29]. Phương pháp SHAP đã được áp dụng trong nhiều lĩnh vực [30–34] và cho kết quả có độ chính xác cao trong dự đoán chất lượng nước mặt [35–37]. Tuy nhiên, phương pháp này chưa được áp dụng để dự đoán liều lượng chất keo tụ.

Dựa trên các nghiên cứu hiện có, nghiên cứu này lần đầu tiên áp dụng khung AutoML có khả năng diễn giải vào việc dự đoán liều lượng chất keo tụ, xây dựng hệ thống dự đoán thông qua lựa chọn mô hình tự động và tối ưu hóa siêu tham số, đồng thời tích hợp phương pháp SHAP để xác định mức độ quan trọng của các đặc trưng trên toàn cục và diễn giải các quyết định cục bộ của mô hình hộp đen. Bằng cách sử dụng dữ liệu thời gian thực và thông tin lịch sử, nghiên cứu bảo đảm quá trình keo tụ được kiểm soát chính xác mà vẫn duy trì các tiêu chuẩn chất lượng nước sau xử lý, qua đó tạo điều kiện cho những tiến bộ và nâng cấp công nghệ trong tương lai của ngành xử lý nước.

2. Vật liệu và phương pháp

2.1. Data acquisition and preprocessing

Dữ liệu được sử dụng trong nghiên cứu này được thu thập từ một nhà máy xử lý nước ở Thiên Tân, Trung Quốc. Nhà máy tiếp nhận nước từ hai nguồn chính: sông Loan Hà (vào tháng 12, tháng 1 và tháng 2 hằng năm), được dẫn từ tỉnh Hà Bắc, và sông Dương Tử (từ tháng 3 đến tháng 11 hằng năm), bắt nguồn từ hồ chứa Đan Giang Khẩu ở tỉnh Hồ Bắc. Quy trình xử lý nước bao gồm tiền xử lý, xử lý thô thường tăng cường và khử trùng kết hợp bằng tia cực tím và clo. Công suất xử lý hằng ngày của nhà máy là 17,5 wt/d, thời gian lưu thủy lực tương đối ổn định ở mức 25,56 phút. Nhà máy sử dụng hai loại chất keo tụ: sắt clorua và PACl, lần lượt được châm trong các giai đoạn tiền xử lý và phối trộn. Các thông số chất lượng nước và dữ liệu liều lượng chất keo tụ được thu thập hằng ngày từ tháng 10 năm 2022 đến tháng 5 năm 2024, với tổng cộng 1339 điểm dữ liệu. Dữ liệu được chia ngẫu nhiên theo tỷ lệ 8:2 thành tập huấn luyện (1071 mẫu) và tập kiểm tra (268 mẫu). Các biến đặc trưng gồm lưu lượng nước đầu vào (WTR) và các chỉ tiêu chất lượng nước như nhiệt độ (T), pH, độ đục (NTU), độ dẫn điện (EC) và nhu cầu oxy hóa học xác định bằng kali pemanganat (COD_{Mn}) đối với cả nước thô (RW) và nước đã xử lý (TW); nitơ amoniac (NH₃–N) chỉ được xét đối với nước thô. Dựa trên hoạt động thực tế của nhà máy và đánh giá chuyên môn, liều lượng của hai chất keo tụ là tương đương, với một

độ sai lệch tối đa không vượt quá 5 mg/L. Do đó, PACl được sử dụng làm biến mục tiêu duy nhất để mô phỏng chính xác liều lượng chất keo tụ trong nghiên cứu này.

Trong quá trình thu thập dữ liệu, các lỗi phát hiện và sự cố hệ thống định lượng khiến tập dữ liệu thô chứa những vấn đề như giá trị bị thiếu và nhiễu. Do đó, tiền xử lý là cần thiết để cải thiện độ tin cậy của dữ liệu, hiệu suất mô hình và chất lượng quyết định [38]. Trong nghiên cứu này, mô hình ước lượng K láng giềng gần nhất (KNN, k = 4) được sử dụng để xử lý dữ liệu bị thiếu, giúp cân bằng độ ổn định của phép nội suy và tính đại diện toàn cục, đồng thời bảo toàn dữ liệu tốt hơn đối với các tham số then chốt bị thiếu không ngẫu nhiên (ví dụ: nhiệt độ nước, nitơ amoniac). Hiệu quả nội suy trong phạm vi k = 1–10 được khảo sát bằng phương pháp lưới; sai số bình phương trung bình (MSE) được dùng làm tiêu chí đánh giá. Kết quả cho thấy MSE đạt mức thấp nhất trên tập kiểm tra tại k = 4. Ngoài ra, nhiễu và sai số ngẫu nhiên được giảm thiểu bằng bộ lọc trung bình trượt có kích thước cửa sổ $n = 5$, được xác định dựa trên phân tích hàm tự tương quan (ACF). Giá trị này giúp nắm bắt hiệu quả các biến động ngắn hạn của các thông số chất lượng nước, đồng thời tránh làm trơn quá mức dẫn đến suy giảm đỉnh [39].

Để khảo sát mối tương quan giữa các đặc trưng khác nhau như WTR, các chỉ số chất lượng nước thô, các chỉ số chất lượng nước đã xử lý và liều lượng chất keo tụ, chúng tôi sử dụng phương pháp hệ số tương quan thứ hạng Spearman (rs), vốn ít nhạy với các mối quan hệ phi tuyến và giá trị ngoại lệ. Bằng cách loại bỏ các đặc trưng có tương quan thấp, chúng tôi giảm các đặc trưng dư thừa, qua đó giảm số chiều đầu vào của mô hình và cải thiện cả hiệu quả vận hành lẫn khả năng khái quát hóa của mô hình. Lưu đồ minh họa phương pháp xây dựng mô hình được trình bày trong Hình 1.

2.2. Automated machine learning

AutoML là một kỹ thuật tự động hóa quy trình học máy thông qua các thuật toán, bao gồm thiết kế đặc trưng, lựa chọn thuật toán và tối ưu hóa siêu tham số [40]. Mục tiêu chính của kỹ thuật này là giảm nhu cầu can thiệp của con người, đồng thời cải thiện hiệu suất mô hình. Trong nghiên cứu này, Tree-based Pipeline Optimization Tool (TPOT), một công cụ AutoML dựa trên lập trình di truyền, được sử dụng để tự động hóa việc xây dựng mô hình. TPOT là một thư viện AutoML mã nguồn mở dựa trên Python (phiên bản 0.11.7), phụ thuộc vào Scikit-Learn (phiên bản 1.0.2), DEAP (Distributed Evolutionary Algorithms Framework) và các tiện ích mở rộng như XGBoost [27]. Mô hình chạy trong môi trường Python 3.8 và toàn bộ mã cấu hình TPOT đều là mã nguồn mở.

Trong nghiên cứu này, khung TPOT được sử dụng để tự động hóa việc thiết kế các quy trình học máy. Các cơ chế cốt lõi gồm: tối ưu hóa lặp dựa trên mã hóa dạng cây của lập trình di truyền; tích hợp nhiều thuật toán của Scikit-Learn với không gian siêu tham số được xác định trước nhằm cân bằng hiệu quả tìm kiếm; và sàng lọc quy trình tối ưu Pareto bằng cách lặp lại kiểm định chéo 10 phần (thực hiện độc lập 3 lần) để đảm bảo khả năng khái quát hóa của mô hình [41].

2.3. SHAP interpretability method

Phương pháp SHAP bao gồm Kernel SHAP, Deep SHAP và Tree SHAP [42]. Nghiên cứu này sử dụng gói Tree SHAP trong Python 3.9 để phân tích mức độ quan trọng, sự phụ thuộc và tương tác giữa các đặc trưng. Các mô-đun và hàm được sử dụng trong Python được liệt kê trong Bảng 1. Giá trị SHAP tuyệt đối trung bình được dùng để đánh giá mức độ quan trọng của các yếu tố khác nhau trong việc xác định liều lượng. Bằng cách cộng các giá trị SHAP tuyệt đối trung bình của tất cả các thông số môi trường liên quan, tác động tổng hợp của chúng lên các chiến lược định lượng được xác định. Các biểu đồ phụ thuộc của giá trị SHAP cho thấy tương tác giữa các đặc trưng và đóng góp tổng hợp của chúng vào việc dự đoán các chiến lược định lượng trong quá trình keo tụ [43]. Hai mẫu điển hình được chọn để tạo biểu đồ diễn giải cục bộ, biểu đồ thác nước và biểu đồ quyết định nhằm




Fig. 1. A flowchart illustrates the modeling methodology.

Table 1
Python modules and their corresponding functions employed.

Module	Function
Sklearn 1.5.0	Data processing, data set division, model evaluation, cross validation
Scipy 1.13.1	Spearman analysis
Seaborn 0.13.2	Statistical data visualization
Tpot 0.12 2	TPOT Regressor model establishment
Shap 0.45.1	Model interpretation, data visualization
Matplotlib 3.9.0	Graphical drawing

illustrate feature importance and decision-making mechanisms within the samples.

2.4. Model evaluation

Root mean square error (RMSE), mean absolute error (MAE), and coefficient of determination (R^2) were used as evaluation metrics to assess the reliability and accuracy of the predictive models [44]. RMSE assesses the degree of discrepancy between predicted and actual values within a sample set [45]. It has an increased sensitivity to outliers and acts as a metric of model accuracy by calculating the average size of prediction errors. MAE reflects the average discrepancy between predicted and actual values, with values closer to zero indicating superior model performance [10]. R^2 quantifies the fit of model predictions to actual data, assessing the robustness and reliability of the model. A value of R^2 approaching one indicates a higher correlation between the dependent and independent variables, which indicates a better model fit and consequently smaller prediction errors [46].


3. Results and discussion

3.1. Analysis of water quality data and feature selection

Fig. 2 illustrates the histogram distributions and statistical indicators, including minimum (MIN), maximum (MAX), mean, standard deviation (SD), and coefficient of variation (CV) for each feature. CV serves as a metric to quantify the variability in datasets [47], with higher CV values indicating greater data variability. Notably, significant differences are observed in T (SD = 9.37, CV = 62 %), $\text{NH}_3\text{-N}$ (SD = 0.07, CV = 59 %), NTU (SD = 2.58, CV = 57 %) for raw water, and T for treated water (SD = 8.77, CV = 54 %). Most other features remain relatively stable, with the pH fluctuation was minimal throughout the entire water treatment process, with a CV of only 3 % for the raw water pH and a CV of merely 2 % for the treated water pH.

The quality of raw water has a direct impact on the safety and reliability of the final water supply, as well as coagulant requirements. Raw water quality indicators at this plant, such as COD_{Mn} and ammonia nitrogen, exhibit distinct seasonal trends. During summer, elevated temperatures and increased rainfall stimulate algae growth in water sources, which raises the COD_{Mn} in water bodies and subsequently affects raw water quality. Additionally, rising temperatures reduce water viscosity, promoting ion movement in solutions and leading to decreased coagulant requirements. In contrast, during winter, low temperatures decrease the solubility and diffusivity of coagulants, resulting in a deceleration of chemical reactions. Consequently, higher coagulant dosages become necessary to ensure the effectiveness of water treatment. Accurate calculation of coagulant dosage based on real-time raw water quality data and historical fluctuation information is crucial for maintaining process efficiency, stable water quality output, and prudent chemical use.

The Spearman rank correlation matrix in Fig. 3 illustrates the relationships between the input parameters and the outcome variable. Strong correlations with PACl coagulant dosage are observed for T-RW



Hình 1. Lưu đồ minh họa phương pháp mô hình hóa.

Bảng 1. Các mô-đun Python và các hàm tương ứng được sử dụng.

Module	Function
Sklearn 1.5.0	Data processing, data set division, model evaluation, cross validation
Scipy 1.13.1	Spearman analysis
Seaborn 0.13.2	Statistical data visualization
Tpot 0.12 2	TPOT Regressor model establishment
Shap 0.45.1	Model interpretation, data visualization
Matplotlib 3.9.0	Graphical drawing

minh họa tầm quan trọng của các đặc trưng và cơ chế ra quyết định trong các mẫu.

2.4. Model evaluation

Sai số bình phương trung bình căn bậc hai (RMSE), sai số tuyệt đối trung bình (MAE) và hệ số xác định (R^2) được sử dụng làm các thước đo đánh giá để xác định độ tin cậy và độ chính xác của các mô hình dự đoán [44]. RMSE đánh giá mức độ chênh lệch giữa giá trị dự đoán và giá trị thực tế trong một tập mẫu [45]. Chỉ số này nhạy hơn với các giá trị ngoại lai và được dùng làm thước đo độ chính xác của mô hình bằng cách tính độ lớn trung bình của các sai số dự đoán. MAE phản ánh độ chênh lệch trung bình giữa giá trị dự đoán và giá trị thực tế; giá trị càng gần 0 cho thấy hiệu suất mô hình càng tốt [10]. R^2 định lượng mức độ phù hợp giữa các dự đoán của mô hình và dữ liệu thực tế, qua đó đánh giá tính vững chắc và độ tin cậy của mô hình. Giá trị R^2 tiến gần đến 1 cho thấy mối tương quan cao hơn giữa các biến phụ thuộc và độc lập, đồng nghĩa với mức độ phù hợp của mô hình tốt hơn và do đó sai số dự đoán nhỏ hơn [46].

3. Kết quả và thảo luận

3.1. Analysis of water quality data and feature selection

Hình 2 minh họa các phân bố biểu đồ tần suất và các chỉ số thống kê, bao gồm giá trị nhỏ nhất (MIN), giá trị lớn nhất (MAX), giá trị trung bình, độ lệch chuẩn (SD) và hệ số biến thiên (CV) của từng đặc trưng. CV là thước đo định lượng mức độ biến thiên trong tập dữ liệu [47], với giá trị CV cao hơn cho thấy dữ liệu biến thiên nhiều hơn. Đáng chú ý, nước thô có sự khác biệt đáng kể ở các đặc trưng T (SD = 9.37, CV = 62 %), $\text{NH}_3\text{-N}$ (SD = 0.07, CV = 59 %) và NTU (SD = 2.58, CV = 57 %); còn nước đã xử lý có sự khác biệt đáng kể ở T (SD = 8.77, CV = 54 %). Hầu hết các đặc trưng khác tương đối ổn định; dao động pH là rất nhỏ trong suốt quá trình xử lý nước, với CV chỉ 3 % đối với pH của nước thô và chỉ 2 % đối với pH của nước đã xử lý.

Chất lượng nước thô ảnh hưởng trực tiếp đến độ an toàn và độ tin cậy của nguồn nước thành phẩm, cũng như lượng chất keo tụ cần sử dụng. Các chỉ tiêu chất lượng nước thô tại nhà máy này, như COD_{Mn} và nitơ amoni, có những xu hướng biến động theo mùa rõ rệt. Vào mùa hè, nhiệt độ tăng cao và lượng mưa gia tăng kích thích phát triển trong các nguồn nước, làm tăng COD_{Mn} trong thủy vực và từ đó ảnh hưởng đến chất lượng nước thô. Ngoài ra, nhiệt độ tăng làm giảm độ nhớt của nước, thúc đẩy sự dịch chuyển của các ion trong dung dịch và dẫn đến giảm lượng chất keo tụ cần dùng. Ngược lại, vào mùa đông, nhiệt độ thấp làm giảm độ hòa tan và khả năng khuếch tán của chất keo tụ, khiến các phản ứng hóa học diễn ra chậm hơn. Do đó, cần tăng liều lượng chất keo tụ để đảm bảo hiệu quả xử lý nước. Việc tính toán chính xác liều lượng chất keo tụ dựa trên dữ liệu chất lượng nước thô theo thời gian thực và thông tin về biến động trong quá khứ đóng vai trò then chốt trong việc duy trì hiệu quả của quy trình, bảo đảm chất lượng nước đầu ra ổn định và sử dụng hóa chất hợp lý.

Ma trận tương quan thứ hạng Spearman trong Hình 3 minh họa mối quan hệ giữa các thông số đầu vào và biến kết quả. Liều lượng chất keo tụ PACl có tương quan mạnh với T-RW




Fig. 2. Histogram distributions of various features and target variables (RW: raw water, TW: treated water, MIN: minimum, MAX: maximum, SD: standard deviation, CV: coefficient of variation). Each subplot represents the distribution of sample points within a specific variable. The vertical axis reveals the occurrence frequency of each feature within the dataset, while the horizontal axis depicts the sample intervals. The purple line represents the fitted frequency distribution curve, which indicates the range of variable utilization within the dataset). (For interpretation of the references to colour in this figure legend, the reader is referred to the web version of this article.)

($r_s = -0.71$), $\text{NH}_3\text{-N-RW}$ ($r_s = 0.87$), pH-RW ($r_s = -0.9$), T-RW ($r_s = -0.67$), and WTR ($r_s = -0.68$). Moderate correlations are found for NTU-RW ($r_s = 0.45$), EC-RW ($r_s = 0.56$), pH-RW ($r_s = -0.33$), and $\text{COD}_{\text{Mn-RW}}$ ($r_s = 0.56$), as well as for EC-TW ($r_s = 0.43$) and NTU-TW ($r_s = -0.23$). $\text{COD}_{\text{Mn-TW}}$ ($r_s = 0.011$) shows a weak correlation with PACl dosage. Notably, EC-RW and EC-TW are highly linearly correlated ($r_s = 0.98$), and $\text{COD}_{\text{Mn-RW}}$ and EC-RW are also highly linearly correlated with T-TW ($r_s = 0.91$ and -0.95 , respectively). Therefore, to avoid

redundancy, only one feature from each highly correlated pair is retained, in addition to EC-RW and $\text{COD}_{\text{Mn-RW}}$. The final feature set for model training includes T-RW , pH-RW , $\text{NH}_3\text{-N-RW}$, NTU-RW , EC-RW , $\text{COD}_{\text{Mn-RW}}$, pH-TW , NTU-TW , and WTR , with PACl dosage as the target variable. This model captures the complex interactions between raw water quality, dosage, and treated water quality.

Hình 2. Biểu đồ tần suất phân bố của các đặc trưng và biến mục tiêu khác nhau (RW: nước thô, TW: nước đã xử lý, MIN: giá trị nhỏ nhất, MAX: giá trị lớn nhất, SD: độ lệch chuẩn, CV: hệ số biến thiên). Mỗi biểu đồ con thể hiện phân bố các điểm mẫu trong một biến cụ thể. Trục tung cho biết tần suất xuất hiện của từng đặc trưng trong tập dữ liệu, còn trục hoành biểu thị các khoảng mẫu. Đường màu tím biểu thị đường cong phân bố tần suất khớp với dữ liệu, cho thấy phạm vi sử dụng biến trong tập dữ liệu. (Để diễn giải các tham chiếu đến màu sắc trong chú giải hình này, độc giả vui lòng xem phiên bản web của bài viết.)

($r_s = -0.71$), $\text{NH}_3\text{-N-RW}$ ($r_s = 0.87$), pH-RW ($r_s = -0.9$), T-RW ($r_s = -0.67$) và WTR ($r_s = -0.68$). Tương quan trung bình được ghi nhận đối với NTU-RW ($r_s = 0.45$), EC-RW ($r_s = 0.56$), pH-RW ($r_s = -0.33$) và $\text{COD}_{\text{Mn-RW}}$ ($r_s = 0.56$), cũng như EC-TW ($r_s = 0.43$) và NTU-TW ($r_s = -0.23$). $\text{COD}_{\text{Mn-TW}}$ ($r_s = 0.011$) cho thấy tương quan yếu với liều lượng PACl. Đáng chú ý, EC-RW và EC-TW có tương quan tuyến tính cao ($r_s = 0.98$), còn $\text{COD}_{\text{Mn-RW}}$ và EC-RW cũng có tương quan tuyến tính cao với T-TW (lần lượt là $r_s = 0.91$ và -0.95). Do đó, để tránh

tính dư thừa, chỉ giữ lại một đặc trưng trong mỗi cặp có tương quan cao, ngoài EC-RW và $\text{COD}_{\text{Mn-RW}}$. Tập đặc trưng cuối cùng dùng để huấn luyện mô hình gồm T-RW , pH-RW , $\text{NH}_3\text{-N-RW}$, NTU-RW , EC-RW , $\text{COD}_{\text{Mn-RW}}$, pH-TW , NTU-TW và WTR , trong đó liều lượng PACl là biến mục tiêu. Mô hình này nắm bắt các tương tác phức tạp giữa chất lượng nước thô, liều lượng và chất lượng nước sau xử lý.




Fig. 3. Spearman rank correlation coefficient matrix between all input parameters and the target variable. Symbols with the suffix “RW” represent raw water quality indicators, while those with “TW” are for treated water.

3.2. Model comparison and optimization


In this study, alongside TPOT AutoML, a range of typical algorithms were chosen to develop a prediction model of PACl dosage for comparison, including Decision Tree (DT), Support Vector Regression (SVR), K-Nearest Neighbors (KNN), Linear Regression (LR), and Gradient Boosting Tree (GBT). Table 2 lists the hyperparameters of the models and Table 3 lists the performance metrics for each model. The optimal algorithm selected by AutoML was Random Forest (RF), which provided more robust and accurate predictions compared to the other algorithms. The R^2 values of the RF model for the training and testing sets reached 1.00 and 0.96, respectively, with the corresponding lowest RMSE: 0.95 ± 0.11 mg/L and MAE: 0.47 ± 0.83 mg/L. Kim et al. [48] predicted PAC dose using a convolutional neural network and gated recurrent units, and the model R^2 exceeded 0.8 for both the training and test sets. This may be due to the fact that the model is typically used to extract spatiotemporal features, and the main drivers of PAC dose prediction are static water quality parameters (e.g., pH, turbidity, temperature, etc.) rather than time series or spatial patterns, which can introduce unnecessary complexity and lead to information redundancy. Lin et al. [39] used deep learning to predict PAC and its sulfate with a model RMSE of 3.55 and an R^2 of 0.94, while the error was even smaller when predicting

Table 2 Hyperparameter optimization results of the models.	
Type of model	Hyperparameter setting
DT	max_depth = 8, min_samples_split = 10, min_samples_leaf = 5, max_features = 0.5, random_state = 42
SVR	c = 1, epsilon = 10, gamma = scale
KNN	n_neighbors = 15, p = 1, metric = minkowski
LR	fit_intercept = True, normalize = True, positive = False
GBT	n_estimators = 150, learning_rate = 0.1, max_depth = 5, min_samples_split = 8, subsample = 0.8, max_features = sqrt

Table 3 Performance comparison of different machine learning models.						
Type of model	Training			Testing		
	RMSE	MAE	R^2	RMSE	MAE	R^2
AutoML: RF	0.07	0.02	1.00	0.89	0.47	0.96
GBT	1.06	0.74	0.96	1.41	0.97	0.91
LR	1.68	1.21	0.89	1.81	1.34	0.84
DT	0.00	0.00	1.00	2.07	0.66	0.80
KNN	2.90	1.91	0.68	3.46	2.55	0.43
SVR	4.81	2.85	0.13	4.45	2.89	0.06

coagulants using AutoML. Genetic programming for TPOT often favors integrated methods, which are inherently better for small- to medium-sized data with better bias-variance balance. The worst performance was observed for SVR, with R^2 values of only 0.13 and 0.06 for the training and test sets, respectively. This is likely due to the high sensitivity of SVR to hyperparameter selection and the lack of a precise solution in defining the configuration parameters [49]. DT achieved an R^2 of 1.00 on the training set, but performed poorly on the testing set because it tends to build complex models on the training data that capture noise and details rather than the true data distribution patterns, resulting in poor predictive performance on new data.

Fig. 4 shows the training and testing results of the RF model developed using AutoML for predicting coagulant dosage. As shown in Fig. 4a and b, the model exhibits robust performance and high accuracy on both the training and testing sets. The low concentrations of suspended solids, colloids, and other contaminants in the raw water result in high quality water, and the minimal influence of pH-RW and NTU-RW on the coagulation process means that the errors observed in the testing dataset are predominantly below 20 mg/L. From the scatter density plots in Fig. 4c and d, it can be observed that the actual and predicted PACl dosages on the training and testing set are mostly aligned along the diagonal, indicating a minimal potential bias in the model.



Hình 3. Ma trận hệ số tương quan thứ hạng Spearman giữa tất cả các tham số đầu vào và biến mục tiêu. Các ký hiệu có hậu tố “RW” biểu thị chất lượng nước thô chỉ rơ, trong khi những loại có ký hiệu “TW” dùng cho nước đã qua xử lý.

3.2. Model comparison and optimization

Trong nghiên cứu này, bên cạnh TPOT AutoML, một loạt thuật toán điển hình được lựa chọn để xây dựng mô hình dự đoán liều lượng PACl nhằm so sánh, bao gồm Cây quyết định (DT), Hồi quy vector hỗ trợ (SVR), K láng giềng gần nhất (KNN), Hồi quy tuyến tính (LR) và Cây tăng cường độ dốc (GBT). Bảng 2 liệt kê các siêu tham số của mô hình, còn Bảng 3 liệt kê các chỉ số hiệu suất của từng mô hình. Thuật toán tối ưu được AutoML lựa chọn là Rừng ngẫu nhiên (RF), cho dự đoán ổn định và chính xác hơn so với các thuật toán khác. Các giá trị R^2 của mô hình RF trên tập huấn luyện và tập kiểm tra lần lượt đạt 1.00 và 0.96, với RMSE tương ứng thấp nhất là 0.95 ± 0.11 mg/L và MAE là 0.47 ± 0.83 mg/L. Kim và cộng sự [48] dự đoán liều PAC bằng mạng nơ-ron tích chập và các đơn vị hồi quy có cổng; R^2 của mô hình đạt trên 0.8 ở cả tập huấn luyện lẫn tập kiểm tra. Điều này có thể là do mô hình thường được sử dụng để trích xuất các đặc trưng không-thời gian, trong khi các yếu tố chính chi phối việc dự đoán liều PAC là các thông số chất lượng nước tĩnh (ví dụ: pH, độ đục, nhiệt độ, v.v.) chứ không phải chuổi thời gian hay các mẫu không gian, vốn có thể làm tăng độ phức tạp không cần thiết và dẫn đến dư thừa thông tin. Lin và cộng sự [39] sử dụng học sâu để dự đoán PAC và sulfat của nó, với RMSE của mô hình là 3.55 và R^2 là 0.94, trong khi sai số còn nhỏ hơn khi dự đoán

Bảng 2. Kết quả tối ưu hóa siêu tham số của các mô hình.	
Type of model	Hyperparameter setting
DT	max_depth = 8, min_samples_split = 10, min_samples_leaf = 5, max_features = 0.5, random_state = 42
SVR	c = 1, epsilon = 10, gamma = scale
KNN	n_neighbors = 15, p = 1, metric = minkowski
LR	fit_intercept = True, normalize = True, positive = False
GBT	n_estimators = 150, learning_rate = 0.1, max_depth = 5, min_samples_split = 8, subsample = 0.8, max_features = sqrt

Bảng 3. So sánh hiệu suất của các mô hình học máy khác nhau.						
Type of model	Training			Testing		
	RMSE	MAE	R^2	RMSE	MAE	R^2
AutoML: RF	0.07	0.02	1.00	0.89	0.47	0.96
GBT	1.06	0.74	0.96	1.41	0.97	0.91
LR	1.68	1.21	0.89	1.81	1.34	0.84
DT	0.00	0.00	1.00	2.07	0.66	0.80
KNN	2.90	1.91	0.68	3.46	2.55	0.43
SVR	4.81	2.85	0.13	4.45	2.89	0.06

chất keo tụ bằng AutoML. Lập trình di truyền của TPOT thường ưu tiên các phương pháp tích hợp, vốn có khả năng xử lý tốt hơn dữ liệu quy mô nhỏ đến trung bình nhờ cân bằng độ chệch-phương sai tốt hơn. Hiệu suất kém nhất thuộc về SVR, với các giá trị R^2 lần lượt chỉ đạt 0.13 và 0.06 trên tập huấn luyện và tập kiểm tra. Điều này có thể là do SVR rất nhạy với việc lựa chọn siêu tham số và thiếu giải pháp chính xác để xác định các tham số cấu hình [49]. DT đạt R^2 bằng 1.00 trên tập huấn luyện, nhưng hoạt động kém trên tập kiểm tra vì có xu hướng xây dựng các mô hình phức tạp dựa trên dữ liệu huấn luyện, nắm bắt nhiễu và các chi tiết thay vì các quy luật phân bố thực sự của dữ liệu, dẫn đến khả năng dự đoán kém trên dữ liệu mới.

Hình 4 cho thấy kết quả huấn luyện và kiểm thử của mô hình RF được phát triển bằng AutoML để dự đoán liều lượng chất keo tụ. Như thể hiện trong Hình 4a và b, mô hình cho thấy hiệu suất ổn định và độ chính xác cao trên cả tập huấn luyện lẫn tập kiểm thử. Nồng độ chất rắn lơ lửng, chất keo và các chất ô nhiễm khác trong nước thô thấp, tạo ra nguồn nước có chất lượng cao; đồng thời, pH-RW và NTU-RW ảnh hưởng rất ít đến quá trình keo tụ, nên sai số quan sát được trong tập dữ liệu kiểm thử chủ yếu dưới 20 mg/L. Từ các biểu đồ mật độ phân tán trong Hình 4c và d, có thể thấy liều lượng PACl thực tế và dự đoán trên tập huấn luyện và tập kiểm thử phần lớn nằm dọc theo đường chéo, cho thấy mô hình có khả năng bị sai lệch rất thấp.




Fig. 4. Fitting results and scatter density plots for the AutoML: RF model on training and testing sets. The Fig includes model performance plot for samples on the training set (a) and the testing set (b), and scatter plot of samples on the training set (c) and the testing set (d).

Fig. 5 shows the optimized dosage of PACI for two different water sources: Yangtze River water and Luanhe River water. The gray areas in the Fig represent the reduction in PACI dosage before and after optimization, highlighting the savings achieved. The optimized PACI dosage was predicted using the optimal RF model, which uses actual raw water quality data with specific targets for treated water quality. For Yangtze River water, the targets were set at NTU-TW: 0.2 NTU, COD_{Mn}-TW: 1.2 mg/L, pH-TW: 8, and NH₃-N-TW: 0.01 mg/L. For Luanhe River water, the targets were: NTU-TW: 0.3 NTU, COD_{Mn}-TW: 1.5 mg/L, pH-TW: 8, and the NH₃-N-TW: 0.01 mg/L. In spring and summer, the temperature of Yangtze River water is high, PACI hydrolysis is fast, and algae in the water source are negatively charged and proliferate, so more PACI is needed for charge neutralization. By precisely adjusting the dosage, the empirical redundancy at high temperature can be avoided, the dosage of chemicals can be reduced by 222 kg/d, saving 180.7 RMB/day, and the consumption of PACI can be reduced by 11 % per year. Luanhe water

temperature in winter is low, Al³⁺ hydrolysis is incomplete, flocculation is slow, and the formation of virtual body of small particle size, low density, but also may be affected by the upstream agricultural pollution, these need to compensate for the additional amount of PACI, through the optimization of PACI dosage prediction, it can reduce the compensatory overdosage caused by the low temperature, saving the amount of dosing from 225 kg/d, into 183.2 RMB/day, the amount of medicine can be saved by 8 % per year. The plant uses Yangtze River water as the sole source between March and November each year, with manual PACI dosages ranging from 8 to 30 mg/L. During the low temperature months from December to February each year, the manual PACI dosages for Luanhe River water are higher, ranging from 10 to 35 mg/L, which potentially allows for higher savings dosages, but at a lower percentage. As a result, according to the weighted average, the model has the potential to save 10.25 % of the annual dosage for the plant.






Fig. 5. Optimization results of PACI dosage using the AutoML: RF model for the Yangtze River source (a) and the Luanhe River source (b).



Hình 4. Kết quả khớp mô hình và biểu đồ mật độ phân tán cho mô hình AutoML: RF trên tập huấn luyện và tập kiểm tra. Hình này bao gồm biểu đồ hiệu suất mô hình trên tập huấn luyện (a) và tập kiểm tra (b), cùng biểu đồ phân tán các mẫu trong tập huấn luyện (c) và tập kiểm tra (d).

Hình 5 cho thấy liều lượng PACI tối ưu cho hai nguồn nước khác nhau: nước sông Dương Tử và nước sông Loan Hà. Các vùng màu xám trong hình biểu thị mức giảm liều lượng PACI trước và sau khi tối ưu hóa, làm nổi bật khoản tiết kiệm đạt được. Liều lượng PACI tối ưu được dự đoán bằng mô hình RF tối ưu, sử dụng dữ liệu chất lượng nước thực tế cùng các mục tiêu cụ thể về chất lượng nước sau xử lý. Đối với nước sông Dương Tử, các mục tiêu được đặt ở mức: NTU-TW: 0.2 NTU, COD_{Mn}-TW: 1.2 mg/L, pH-TW: 8 và NH₃-N-TW: 0.01 mg/L. Đối với nước sông Loan Hà, các mục tiêu là: NTU-TW: 0.3 NTU, COD_{Mn}-TW: 1.5 mg/L, pH-TW: 8 và NH₃-N-TW: 0.01 mg/L. Vào mùa xuân và mùa hè, nhiệt độ nước sông Dương Tử cao, quá trình thủy phân PACI diễn ra nhanh, còn tảo trong nguồn nước mang điện tích âm và sinh sôi, vì vậy cần nhiều PACI hơn để trung hòa điện tích. Bằng cách điều chỉnh liều lượng chính xác, có thể tránh việc sử dụng dư thừa theo kinh nghiệm ở nhiệt độ cao, giảm liều lượng hóa chất 222 kg/d, tiết kiệm 180.7 RMB/ngày và giảm 11 % lượng PACI tiêu thụ mỗi năm. Nước sông Loan Hà

Vào mùa đông, nhiệt độ thấp khiến quá trình thủy phân Al³⁺ không hoàn toàn, bông cặn hình thành chậm và các bông cặn giả có kích thước nhỏ, mật độ thấp; hiện tượng này cũng có thể chịu ảnh hưởng của ô nhiễm nông nghiệp ở thượng nguồn. Vì vậy, cần bổ sung thêm PACI. Tối ưu hóa dự báo liều lượng PACI có thể giảm lượng dùng bù quá mức do nhiệt độ thấp, tiết kiệm lượng hóa chất từ 225 kg/n ngày xuống còn 183,2 RMB/ngày; lượng hóa chất sử dụng có thể giảm 8% mỗi năm. Nhà máy chỉ sử dụng nước sông Dương Tử làm nguồn nước từ tháng 3 đến tháng 11 hằng năm, với liều lượng PACI thủ công từ 8 đến 30 mg/L. Trong những tháng nhiệt độ thấp từ tháng 12 đến tháng 2 hằng năm, liều lượng PACI thủ công khi xử lý nước sông Loan Hà cao hơn, từ 10 đến 35 mg/L; do đó, lượng tiết kiệm tiềm năng có thể lớn hơn, nhưng tỷ lệ tiết kiệm thấp hơn. Vì vậy, tính theo mức trung bình có trọng số, mô hình có tiềm năng giúp nhà máy tiết kiệm 10,25% liều lượng hóa chất hằng năm.



Hình 5. Kết quả tối ưu hóa liều lượng PACI bằng mô hình AutoML: RF cho nguồn nước sông Dương Tử (a) và nguồn nước sông Loan Hà (b).

This method more accurately predicts the optimal dosage required to consistently meet treated water standards under varying raw water conditions than manual empirical judgment and saves 10.25 % of coagulant dosage per year. Manual judgment often results in overdosing when raw water quality exceeds a certain threshold. Conversely, model prediction enables accurate dosing while maintaining treated water standards, reducing reagent costs and ensuring more stable treated water quality.

3.3. SHAP interpretation

Fig. 6 presents the SHAP feature importance and summary plots for the model evaluated on the testing set. Feature importance ranking from highest to lowest is as follows: EC-RW, pH-TW, $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$, T-RW, NTU-RW, WTR, NTU-TW, and pH-RW, as shown in Fig. 6(a). Notably, the model in this study was constructed using monitoring data from the water treatment plant, adhering to the principle of continuously adjusting dosage based on raw water quality to ensure stable and compliant treated water quality. Therefore, the relationship between dosage and treated water quality exhibits a direct causal link, despite dosage exceeding a certain threshold may have minimal impact on treated water quality. On the other hand, the relationship between dosage and raw water quality reflects practical expertise, with water plant operators relying on their experience and raw water quality to set chemical dosages that meet treated water standards. Because of the wide variation in raw water quality and the stability of treated water quality, raw water indicators are generally more important than treated water indicators in the model.

Fig. 6 (b) displays the contribution of input features to the prediction results, with features arranged in descending order along the vertical axis. Consistent SHAP values aligned with characteristic values for EC-RW, $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$, and NTU-RW suggest a positive influence on coagulant dosing, while the opposite trend for pH-RW, T-RW, and WTR suggests a negative influence on dosing. For example, higher EC-RW corresponds to higher SHAP values, indicating an increase in dosing. Higher EC implies lower water purity, potentially containing higher concentrations of dissolved salts, organics, metal ions, and other contaminants. The cations in PACl can neutralize the surface charges of negatively charged suspended particles or colloidal substances in water, reducing the electrostatic repulsion between particles and promoting aggregation [50]. In contrast, higher WTR values correspond to lower SHAP values, indicating a decrease in dosage.

Fig. 7 illustrates the SHAP values for individual variables, which demonstrates the marginal effects of each feature on model predictions.

For the raw water indicator, conductivity reflects the total concentration of dissolved ions in the water and shows a nearly linear enhancement relationship with dosage when it is between 300 and 550 $\mu\text{S}/\text{cm}$, while below 300 $\mu\text{S}/\text{cm}$ or above 550 $\mu\text{S}/\text{cm}$ this relationship shows a trend of diminishing returns. High conductivity compresses the bilayer and promotes coagulation, but low pH inhibits $\text{Al}(\text{OH})_3$ formation when incremental compensation is required. Ammonia is nitrogen in the form of free ammonia (NH_3) and ammonium ions (NH_4^+) regulated by pH and temperature. $\text{NH}_3\text{-N-RW}$ in the range of 0–0.2 mg/L also exerts a positive influence on coagulant dosage, with the relationship becoming less significant beyond this range. High temperature accelerates the hydrolysis, but low $\text{NH}_3\text{-N}$ can reduce the interference, at this time the PACl dosage can be dosed according to professional judgment.

COD_{Mn} reflects the total amount of organic matter and reducing inorganic matter in the water body, there is no obvious correlation with the dosage, if it is less than 4 mg/L, and more than 4 mg/L threshold, it will compete for the active site with the PACl, and the SHAP value at this time shows a sharp upward trend. Furthermore, NTU-RW generally has a positive promoting effect on dosing, as an appropriate increase in coagulant to promote particle aggregation and settlement, which is in line with the findings of Vunain et al. [51]. However, when NTU-RW is less than 2 NTU, the SHAP value shows an upward trend, as sparse and dispersed colloidal particles in low-turbidity water limit the ability of colloids formed after PACl hydrolysis to capture solid impurity particles. Therefore, the dosage of PACl must be increased to compensate for diffusion limitations and to ensure electroneutralization [52–54]. In high COD_{Mn} and high turbidity water, organic matter can encapsulate colloidal particles and additional amounts of PACl are needed to enhance charge neutralization and break down the organic matter barrier.

In addition, the required coagulant dosage decreases as the pH-RW increases within the range of 8.0 to 8.4, which is attributed to the opposite charges of PACl and contaminant particles in a weakly alkaline environment [55], allowing PACl to exhibit superior coagulation properties [56]. It is likely that temperature typically has a negative effect on dosing. The hydrolysis of PACl is an endothermic reaction, but the increased viscosity at low temperatures impedes the thermal motion of suspended particles in water, which is detrimental to the stability of colloidal aggregation [57]. Therefore, the dosage of PACl should be increased to achieve optimal coagulation efficacy [58].

For treated water indicators, a distinct negative linear correlation is observed between pH-TW and the quantity of coagulant administered, primarily clustering within a narrow pH range of 7.6 to 7.8. This negative linear relationship is primarily due to the fact that the

Phương pháp này dự đoán chính xác hơn liều lượng tối ưu cần thiết để liên tục đáp ứng các tiêu chuẩn về nước đã xử lý trong những điều kiện nước thô khác nhau so với phán đoán thực nghiệm thủ công, đồng thời tiết kiệm 10,25 % lượng chất keo tụ sử dụng mỗi năm. Phán đoán thủ công thường dẫn đến việc dùng quá liều khi chất lượng nước thô vượt một ngưỡng nhất định. Ngược lại, dự đoán của mô hình cho phép định lượng chính xác mà vẫn duy trì các tiêu chuẩn về nước đã xử lý, giảm chi phí hóa chất và đảm bảo chất lượng nước sau xử lý ổn định hơn.

3.3. SHAP interpretation

Hình 6 trình bày các biểu đồ tóm tắt và mức độ quan trọng của đặc trưng SHAP cho mô hình được đánh giá trên tập kiểm thử. Thứ hạng mức độ quan trọng của các đặc trưng, từ cao xuống thấp, lần lượt là: EC-RW, pH-TW, $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$, T-RW, NTU-RW, WTR, NTU-TW và pH-RW, như thể hiện trong Hình 6(a). Đáng chú ý, mô hình trong nghiên cứu này được xây dựng bằng dữ liệu giám sát từ nhà máy xử lý nước, tuân theo nguyên tắc liên tục điều chỉnh liều lượng dựa trên chất lượng nước thô nhằm đảm bảo chất lượng nước sau xử lý ổn định và đạt quy chuẩn. Do đó, mối quan hệ giữa liều lượng và chất lượng nước sau xử lý có liên hệ nhân quả trực tiếp, dù liều lượng vượt quá một ngưỡng nhất định có thể chỉ ảnh hưởng rất ít đến chất lượng nước sau xử lý. Mặt khác, mối quan hệ giữa liều lượng và chất lượng nước thô phản ánh kinh nghiệm thực tiễn: người vận hành nhà máy nước dựa vào kinh nghiệm và chất lượng nước thô để xác định liều lượng hóa chất đáp ứng các tiêu chuẩn về nước sau xử lý. Do chất lượng nước thô biến động lớn trong khi chất lượng nước sau xử lý ổn định, các chỉ tiêu nước thô nhìn chung quan trọng hơn các chỉ tiêu nước sau xử lý trong mô hình.

Hình 6(b) thể hiện mức độ đóng góp của các đặc trưng đầu vào vào kết quả dự đoán, trong đó các đặc trưng được sắp xếp theo thứ tự giảm dần trên trục tung. Các giá trị SHAP biến thiên cùng chiều với giá trị đặc trưng đối với EC-RW, $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$ và NTU-RW, cho thấy chúng tác động tích cực đến liều lượng chất keo tụ; ngược lại, xu hướng của pH-RW, T-RW và WTR cho thấy chúng tác động tiêu cực đến liều lượng. Ví dụ, EC-RW cao hơn tương ứng với giá trị SHAP cao hơn, cho thấy liều lượng tăng. EC cao hàm ý độ tinh khiết của nước thấp hơn, có khả năng chứa nồng độ muối hòa tan, chất hữu cơ, ion kim loại và các chất ô nhiễm khác cao hơn. Các cation trong PACl có thể trung hòa điện tích bề mặt của các hạt lơ lửng hoặc chất keo mang điện tích âm trong nước, làm giảm lực đẩy tĩnh điện giữa các hạt và thúc đẩy quá trình kết tụ [50]. Ngược lại, giá trị WTR cao hơn tương ứng với giá trị SHAP thấp hơn, cho thấy liều lượng giảm.

Hình 7 minh họa các giá trị SHAP của từng biến riêng lẻ, qua đó thể hiện tác động cận biên của mỗi đặc trưng lên các dự đoán của mô hình.

Đối với chỉ tiêu nước thô, độ dẫn điện phản ánh tổng nồng độ các ion hòa tan trong nước và cho thấy mối quan hệ tăng gần tuyến tính với liều lượng khi nằm trong khoảng 300 đến 550 $\mu\text{S}/\text{cm}$, trong khi dưới 300 $\mu\text{S}/\text{cm}$ hoặc trên 550 $\mu\text{S}/\text{cm}$, mối quan hệ này có xu hướng giảm dần hiệu quả. Độ dẫn điện cao làm nén lớp kép và thúc đẩy quá trình keo tụ, nhưng pH thấp cản trở sự hình thành $\text{Al}(\text{OH})_3$ khi cần bù thêm. Amoniac tồn tại dưới dạng amoniac tự do (NH_3) và ion amoni (NH_4^+), chịu sự điều tiết của pH và nhiệt độ. $\text{NH}_3\text{-N-RW}$ trong khoảng 0–0,2 mg/L cũng có ảnh hưởng tích cực đến liều lượng chất keo tụ, nhưng mối quan hệ này trở nên kém đáng kể khi vượt quá khoảng này. Nhiệt độ cao thúc đẩy quá trình thủy phân, nhưng hàm lượng $\text{NH}_3\text{-N}$ thấp có thể làm giảm sự can nhiễu; trong trường hợp này, liều lượng PACl có thể được xác định theo đánh giá chuyên môn.

COD_{Mn} phản ánh tổng lượng chất hữu cơ và chất vô cơ có tính khử trong nguồn nước; nếu nồng độ dưới ngưỡng 4 mg/L hoặc vượt ngưỡng 4 mg/L thì không có mối tương quan rõ rệt với liều lượng. Khi vượt ngưỡng 4 mg/L, chất này sẽ cạnh tranh vị trí hoạt động với PACl, và giá trị SHAP lúc này cho thấy xu hướng tăng mạnh. Hơn nữa, NTU-RW nhìn chung có tác dụng thúc đẩy tích cực đối với liều lượng, vì việc tăng lượng chất keo tụ thích hợp giúp thúc đẩy sự kết tụ và lắng của các hạt, phù hợp với những phát hiện của Vunain và cộng sự [51]. Tuy nhiên, khi NTU-RW dưới 2 NTU, giá trị SHAP có xu hướng tăng, vì các hạt keo thừa và phân tán trong nước có độ đục thấp hạn chế khả năng bắt giữ các hạt tạp chất rắn của các hạt keo hình thành sau khi PACl thủy phân. Do đó, cần tăng liều lượng PACl để bù đắp cho những hạn chế về khuếch tán và đảm bảo trung hòa điện tích [52–54]. Trong nước có COD_{Mn} và độ đục cao, chất hữu cơ có thể bao bọc các hạt keo, do đó cần bổ sung PACl để tăng cường trung hòa điện tích và phá vỡ hàng rào chất hữu cơ.

Ngoài ra, liều lượng chất keo tụ cần thiết giảm khi pH-RW tăng trong khoảng từ 8,0 đến 8,4. Điều này được cho là do PACl và các hạt chất ô nhiễm mang điện tích trái dấu trong môi trường kiềm nhẹ [55], giúp PACl thể hiện khả năng keo tụ vượt trội [56]. Nhiệt độ thường có tác động tiêu cực đến liều lượng sử dụng. Quá trình thủy phân PACl là phản ứng thu nhiệt, nhưng độ nhớt tăng ở nhiệt độ thấp cản trở chuyển động nhiệt của các hạt lơ lửng trong nước, gây bất lợi cho độ ổn định của sự kết tụ keo [57]. Do đó, cần tăng liều lượng PACl để đạt hiệu quả keo tụ tối ưu [58].

Đối với các chỉ số của nước đã xử lý, có thể thấy mối tương quan tuyến tính âm rõ rệt giữa pH-TW và lượng chất keo tụ được sử dụng, chủ yếu tập trung trong khoảng pH hẹp từ 7.6 đến 7.8. Mối quan hệ tuyến tính âm này chủ yếu là do thực tế rằng



Fig. 6. SHAP feature importance (a) and summary plot (b) for the test set. The vertical axis of plot (a) represents the features in descending order of their average absolute SHAP value on the model output, with larger values indicating a higher contribution of the feature to the prediction, and the horizontal axis indicates the size of the SHAP value, reflecting the average degree of influence of the feature on the model output. Fig (b) each point represents the SHAP value of a sample, the position of the horizontal axis shows the size of the value, the colour shades reflect the original value of the feature is high or low (red is high value, blue is low value), the vertical axis represents the order by the importance of the feature, in line with Fig (a), the superimposed trend represents the relationship between the feature's value high or low and the direction of the SHAP value that can be observed from the distribution of points. (For interpretation of the references to colour in this figure legend, the reader is referred to the web version of this article.)





Fig. 7. Nonlinear relationships between individual water quality parameters and coagulant dosage for EC-RW (a), pH-TW (b), $\text{NH}_3\text{-N-RW}$ (c), $\text{COD}_{\text{Mn-RW}}$ (d), T-RW (e), NTU-RW (f), WTR (g), NTU-TW (h), and pH-RW (i). For each data point with a positive SHAP value, the dosage of coagulant increases with the SHAP value, exerting a positive impact. Conversely, for points with negative SHAP values, the opposite effect is observed. The units for these variables are consistent with those in Fig. 2.

hydrolysis reaction of PACl releases H^+ , resulting in a decrease in effluent pH [59]. However, over-dosing chemicals to meet the effluent pH standard will cause the colloids to re-stabilize, resulting in a decrease in flocculation efficiency. In addition, the increase in dissolved aluminum residue can affect the safety of the effluent [54]. In addition, no apparent linear relationship is observed between PACl dosage and NTU-TW after coagulation, contrary to the results reported by Chiavola [60]. NTU-TW is affected by both raw water quality and coagulant dosage. Specifically, elevated NTU-RW values require a manual increase in coagulant dosage to meet NTU-TW standards. Therefore, the NTU-TW values from an operating plant remain relatively low and stable with minimal variation, which has little impact on dosage prediction. In addition, the effectiveness of PACl in the coagulation process depends primarily on charge neutralization and adsorption bridging. An appropriate dosage of PACl hydrolyzes to produce positively charged ions that neutralize negatively charged colloids, thereby enhancing turbidity removal. However, excessive PACl triggers “colloidal protection,” where excess positively charged ions adsorb onto colloidal surfaces and

hydrophobic colloids become hydrophilic, reducing floc settling and ultimately decreasing turbidity removal efficiency [56,61,62].

Although AutoML (TPOT) and SHAP perform well in optimizing machine learning models and improving interpretability, they still have several limitations. AutoML may face the risk of overfitting during model selection and hyperparameter optimization, and in this study, despite the training set $R^2 = 1.00$, the high consistency of the repeated cross-validation and the independent test set ($R^2 = 0.96$) suggests that the model was not overfitted. The SHAP method reveals complex action laws that cannot be captured by traditional linear methods, identifies the threshold response behavior of key parameters, and breaks through the limitations of linear statistics.

Fig. 8 shows waterfall plots and decision plots for two specific local samples using the SHAP method. Fig. 8a and b show a sample with a coagulant dosage higher than the average value (14.5 mg/L). This sample was collected in February, with the raw water coming from the Luanhe River, and T-RW recorded at 3.8 °C. Fig. 8a shows that the predicted coagulant dosage for this sample (34.9 mg/L) is higher than



Hình 7. Mối quan hệ phi tuyến giữa từng thông số chất lượng nước và liều lượng chất keo tụ đối với EC-RW (a), pH-TW (b), $\text{NH}_3\text{-N-RW}$ (c), $\text{COD}_{\text{Mn-RW}}$ (d), T-RW (e), NTU-RW (f), WTR (g), NTU-TW (h) và pH-RW (i). Với mỗi điểm dữ liệu có giá trị SHAP dương, liều lượng chất keo tụ tăng theo giá trị SHAP, tạo ra tác động tích cực. Ngược lại, các điểm có giá trị SHAP âm cho thấy tác động trái ngược. Đơn vị của các biến này giống với đơn vị trong Hình 2.

Phản ứng thủy phân PACl giải phóng H^+ , làm giảm pH của nước sau xử lý [59]. Tuy nhiên, việc sử dụng quá liều hóa chất để đáp ứng tiêu chuẩn pH của nước sau xử lý sẽ khiến các hạt keo tái ổn định, làm giảm hiệu quả keo tụ. Ngoài ra, lượng nhôm dư hòa tan tăng lên có thể ảnh hưởng đến độ an toàn của nước sau xử lý [54]. Bên cạnh đó, không quan sát thấy mối quan hệ tuyến tính rõ rệt giữa liều lượng PACl và NTU-TW sau khi keo tụ, trái với kết quả do Chiavola báo cáo [60]. NTU-TW chịu ảnh hưởng của cả chất lượng nước thô và liều lượng chất keo tụ thủ công để đáp ứng tiêu chuẩn NTU-TW. Do đó, giá trị NTU-TW tại một nhà máy đang vận hành duy trì tương đối thấp và ổn định, ít biến động, nên ít ảnh hưởng đến việc dự đoán liều lượng. Ngoài ra, hiệu quả của PACl trong quá trình keo tụ chủ yếu phụ thuộc vào cơ chế trung hòa điện tích và bắc cầu hấp phụ. Liều lượng PACl phù hợp sẽ thủy phân tạo ra các ion mang điện tích dương, trung hòa các hạt keo mang điện tích âm, qua đó tăng cường loại bỏ độ đục. Tuy nhiên, PACl dư thừa gây ra hiện tượng “bảo vệ hạt keo”, trong đó các ion mang điện tích dương dư thừa hấp phụ lên bề mặt hạt keo và

các chất keo kỵ nước trở nên ưa nước, làm giảm khả năng lắng của bông cặn và cuối cùng giảm hiệu quả loại bỏ độ đục [56,61,62].

Mặc dù AutoML (TPOT) và SHAP hoạt động hiệu quả trong việc tối ưu hóa các mô hình học máy và cải thiện khả năng diễn giải, chúng vẫn có một số hạn chế. AutoML có thể đối mặt với nguy cơ quá khớp trong quá trình lựa chọn mô hình và tối ưu hóa siêu tham số; trong nghiên cứu này, mặc dù tập huấn luyện đạt $R^2 = 1.00$, tính nhất quán cao giữa kiểm định chéo lặp lại và tập kiểm tra độc lập ($R^2 = 0.96$) cho thấy mô hình không bị quá khớp. Phương pháp SHAP làm sáng tỏ các quy luật tác động phức tạp mà các phương pháp tuyến tính truyền thống không thể nắm bắt, xác định hành vi đáp ứng theo ngưỡng của các tham số then chốt và vượt qua những hạn chế của thống kê tuyến tính.

Hình 8 trình bày các biểu đồ thác nước và biểu đồ quyết định cho hai mẫu cục bộ cụ thể bằng phương pháp SHAP. Hình 8a và b cho thấy một mẫu có liều lượng chất keo tụ cao hơn giá trị trung bình (14.5 mg/L). Mẫu này được thu thập vào tháng 2, với nước thô lấy từ sông Luanhe và T-RW được ghi nhận ở mức 3.8 °C. Hình 8a cho thấy liều lượng chất keo tụ dự đoán cho mẫu này (34.9 mg/L) cao hơn




Fig. 8. Decision plots and waterfall plots for two local samples, featuring three key characteristics: 1) the output value, representing the prediction for an individual sample; 2) the base value, corresponding to the average expected value in the testing set; and 3) colour coding, where red variables push the prediction upwards and blue variables push it downwards) are presented. The Fig includes decision plot (a) and waterfall plot (b) for a sample with dosing amount above the average, and decision plot (c) and waterfall plot (d) for a sample with dosing amount below the average. (For interpretation of the references to colour in this figure legend, the reader is referred to the web version of this article.)

the average expected value in the test set (14.5 mg/L), mainly due to COD_{Mn}-RW, followed by EC-RW, NTU-RW, and NH₃-N-RW, while the contribution of pH-RW and WTR are negligible. Fig. 8b shows the contribution of each feature in exceeding the average prediction (14.5 mg/L), ultimately resulting in a final output of 34.9 mg/L for this sample. First, COD_{Mn}-RW reaches 5.46 mg/L, exceeding the threshold of 4 mg/L, the SHAP value increases significantly. In addition, with EC-RW at 600.6 μ S/cm, NH₃-N-RW at 0.36 mg/L and NTU-RW at 7.19 NTU, their SHAP values all remain above 0. Based on professional judgment of the overall impact of raw water quality, the dosage of PACl was subsequently increased from the average level.

Fig. 8c and d show a sample taken in May with the Yangtze River as the source water, showing a coagulant dosage below the average. Fig. 8c shows that the predicted coagulant dosage for this sample (8.57 mg/L) is significantly lower than the average expected value in the test set (14.5 mg/L). Among the factors, pH-TW (with a value of 7.906) has the most significant negative effect on the dosage prediction, indicating that a coagulant dosage at this level will significantly lower the pH of the treated water. This is followed by T-RW, EC-RW, and COD_{Mn}-RW, while the contribution of NH₃-N-RW and WTR is negligible. Fig. 8d further illustrates how each feature contributes to shifting the dosage towards a value below the average prediction (14.5 mg/L), ultimately resulting in a final output of 8.57 mg/L for this sample. For the raw water characterized by T at 22.34 °C, EC at 290.2 μ S/cm, COD_{Mn}-RW at 2.6 mg/L, and pH at 8.15, the corresponding SHAP values for these parameters are uniformly negative. Based on practical experience, it was decided to reduce the dosage of PACl to a level below the average.


In summary, the model developed in this study optimizes coagulant

dosing, not only enabling precise chemical addition in the coagulation process of water treatment plants—thereby significantly minimizing coagulant overuse—but also employing interpretable methods to reveal key factors and their impact relationships influencing coagulant consumption. This empowers plant operators to make more scientific and rational decisions, avoiding overdosing while ensuring effluent quality. However, in practical water treatment applications, further efforts are required to mitigate the environmental impacts of coagulant use. This can be achieved by integrating the model with processes such as pre-chlorination and activated carbon adsorption to reduce coagulant demand. Additionally, developing green and sustainable water treatment technologies, such as bio-based flocculants (e.g., chitosan, microbial flocculants), photocatalytic technologies[63,64], could reduce reliance on non-renewable resources and minimize environmental risks posed by chemical residues and byproducts (e.g., aluminum hydroxide sludge).

4. Conclusions

In this study, we developed a predictive model for coagulant dosing in a water treatment plant using AutoML and interpreted the model results to address the transparency issue associated with such predictive models. The conclusions are as follows:

- (1) The RF model developed using AutoML demonstrated superior performance with a test R^2 value of 0.96, RMSE of 0.89, and MAE of 0.47. This model offers a faster development cycle and higher prediction accuracy compared to manually selected models, and



Hình 8. Các biểu đồ quyết định và biểu đồ thác nước cho hai mẫu cục bộ, thể hiện ba đặc điểm chính: 1) giá trị đầu ra, biểu thị dự đoán cho một mẫu riêng lẻ; 2) giá trị cơ sở, tương ứng với giá trị kỳ vọng trung bình trong tập kiểm tra; và 3) mã màu, trong đó các biến màu đỏ đẩy giá trị dự đoán tăng lên, còn các biến màu xanh lam đẩy giá trị này giảm xuống. Hình này trình bày biểu đồ quyết định (a) và biểu đồ thác nước (b) cho một mẫu có liều lượng cao hơn mức trung bình, cùng biểu đồ quyết định (c) và biểu đồ thác nước (d) cho một mẫu có liều lượng thấp hơn mức trung bình. (Để diễn giải các nội dung tham chiếu đến màu sắc trong chú giải hình này, độc giả vui lòng xem phiên bản trực tuyến của bài viết.)

giá trị kỳ vọng trung bình trong tập kiểm tra (14.5 mg/L), chủ yếu do COD_{Mn}-RW, tiếp theo là EC-RW, NTU-RW và NH₃-N-RW, trong khi đóng góp của pH-RW và WTR không đáng kể. Hình 8b cho thấy mức đóng góp của từng đặc trưng vào việc vượt mức dự đoán trung bình (14.5 mg/L), cuối cùng dẫn đến đầu ra là 34.9 mg/L cho mẫu này. Trước tiên, COD_{Mn}-RW đạt 5.46 mg/L, vượt ngưỡng 4 mg/L, khiến giá trị SHAP tăng đáng kể. Ngoài ra, khi EC-RW ở mức 600.6 μ S/cm, NH₃-N-RW ở mức 0.36 mg/L và NTU-RW ở mức 7.19 NTU, các giá trị SHAP của chúng đều vẫn lớn hơn 0. Dựa trên đánh giá chuyên môn về tác động tổng thể của chất lượng nước thô, liều lượng PACl sau đó đã được tăng lên cao hơn mức trung bình.

Hình 8c và d trình bày một mẫu được lấy vào tháng 5, sử dụng nước sông Dương Tử làm nguồn nước, với liều lượng chất keo tụ thấp hơn mức trung bình. Hình 8c cho thấy liều lượng chất keo tụ dự đoán cho mẫu này (8.57 mg/L) thấp hơn đáng kể so với giá trị trung bình kỳ vọng trong tập kiểm tra (14.5 mg/L). Trong số các yếu tố, pH-TW (có giá trị 7.906) có tác động tiêu cực đáng kể nhất đến dự đoán liều lượng, cho thấy liều lượng chất keo tụ ở mức này sẽ làm giảm đáng kể pH của nước sau xử lý. Tiếp theo là T-RW, EC-RW và COD_{Mn}-RW, trong khi đóng góp của NH₃-N-RW và WTR không đáng kể. Hình 8d minh họa thêm cách từng đặc trưng góp phần dịch chuyển liều lượng về phía giá trị thấp hơn mức dự đoán trung bình (14.5 mg/L), cuối cùng cho kết quả đầu ra là 8.57 mg/L đối với mẫu này. Đối với nước thô có T là 22.34 °C, EC là 290.2 μ S/cm, COD_{Mn}-RW là 2.6 mg/L và pH là 8.15, các giá trị SHAP tương ứng của những thông số này đều âm. Dựa trên kinh nghiệm thực tế, quyết định được đưa ra là giảm liều lượng PACl xuống thấp hơn mức trung bình.

Tóm lại, mô hình được phát triển trong nghiên cứu này tối ưu hóa chất keo tụ##+##+##+

liều lượng, không chỉ cho phép bổ sung hóa chất chính xác trong quá trình keo tụ tại các nhà máy xử lý nước—qua đó giảm đáng kể tình trạng sử dụng quá mức chất keo tụ—mà còn sử dụng các phương pháp dễ diễn giải để làm rõ những yếu tố then chốt và mối quan hệ tác động của chúng đến lượng chất keo tụ tiêu thụ. Điều này giúp người vận hành nhà máy đưa ra quyết định khoa học và hợp lý hơn, tránh chần chừ quá liều mà vẫn bảo đảm chất lượng nước thải đầu ra. Tuy nhiên, trong các ứng dụng xử lý nước thực tế, cần có thêm nỗ lực để giảm thiểu tác động môi trường của việc sử dụng chất keo tụ. Có thể thực hiện điều này bằng cách tích hợp mô hình với các quy trình như clo hóa sơ bộ và hấp phụ bằng than hoạt tính nhằm giảm nhu cầu sử dụng chất keo tụ. Ngoài ra, việc phát triển các công nghệ xử lý nước xanh và bền vững, chẳng hạn như chất keo tụ có nguồn gốc sinh học (ví dụ: chitosan, chất keo tụ vi sinh) và công nghệ quang xúc tác[63,64], có thể giảm sự phụ thuộc vào các nguồn tài nguyên không tái tạo và hạn chế rủi ro môi trường do dư lượng hóa chất và sản phẩm phụ gây ra (ví dụ: bùn nhôm hydroxit).

4. Kết luận

Trong nghiên cứu này, chúng tôi đã xây dựng một mô hình dự đoán liều lượng chất keo tụ tại nhà máy xử lý nước bằng AutoML và diễn giải kết quả mô hình nhằm giải quyết vấn đề về tính minh bạch liên quan đến các mô hình dự đoán như vậy. Các kết luận như sau:

- (1) Mô hình RF được phát triển bằng AutoML cho thấy hiệu suất vượt trội, với giá trị R^2 là 0,96, RMSE là 0,89 và MAE là 0,47. Mô hình này có chu kỳ phát triển nhanh hơn và độ chính xác dự đoán cao hơn so với các mô hình được lựa chọn thủ công, và

serves as a valuable tool for predicting coagulant dosing in water treatment plants.

- (2) Model interpretation based on SHAP values revealed the influence of each water quality indicator on the prediction results. Specifically, when NTU-RW is low and relatively stable, raw water conductivity emerges as the most significant factor influencing coagulant dosing, followed by $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$, T-RW, and WTR.
- (3) The optimized model predicts daily PACl savings of 222 kg (11 %) for water from the Yangtze River and 225 kg (8 %) for water from the Luanhe River. This highlights the key role of the coagulant dosing model in improving water treatment efficiency and optimizing resource utilization.

CRedit authorship contribution statement

Liyan Feng: Writing – review & editing, Writing – original draft, Visualization, Validation, Supervision, Software, Resources, Project administration, Methodology, Investigation, Formal analysis, Data curation, Conceptualization. **Ying Zhang:** Resources, Project administration, Methodology, Investigation, Funding acquisition, Data curation. **Xiaoting Wei:** Writing – original draft, Visualization, Supervision, Software. **Mengyuan Wang:** Visualization, Validation, Software, Resources, Project administration. **Zhiguang Niu:** Resources, Project administration, Methodology, Investigation, Data curation. **Chenchen Wang:** Writing – review & editing, Visualization, Supervision, Software, Project administration.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgements

This study was supported by the National Key Research and Development Programme (2022YFC3203803) and the Department of Science and Technology of Fujian Province (2022J01522), and we also thank Tianjin TEDA Water Industry Co. for providing the raw data.

Data availability

Data will be made available on request.

References

- [1] G. Mannina, T.F. Rebouças, A. Cosenza, K. Chandran, A plant-wide wastewater treatment plant model for carbon and energy footprint: model application and scenario analysis, *J. Clean. Prod.* 217 (2019) 244–256.
- [2] Z. Wu, H. Duan, K. Li, L. Ye, A comprehensive carbon footprint analysis of different wastewater treatment plant configurations, *Environ. Res.* 214 (2022) 113818.
- [3] N. Liu, D. Wang, J. Xu, L. Liu, J. Xue, T. Han, J. Wang, J. Lei, H. Shao, X. Zhang, Novel 3D MIL-53(Fe)/graphene aerogel composites for boosted photocatalytic ibuprofen degradation under visible light: process and mechanism, *Surf. Interface Anal.* 46 (2024) 104192, <https://doi.org/10.1016/j.surfin.2024.104192>.
- [4] Y. Wang, G. Jiao, Y. Yang, J. Wang, J. Zhang, H. Jiang, N. Liu, X. Zhang, 3D structure of $\text{LaFe1-8Co03@carbon cloth}$ composite catalyst for promoting peroxymonosulfate activation: identification of catalytic mechanism towards multiple antibiotics, *Desalination* 602 (2025) 118643, <https://doi.org/10.1016/j.desal.2025.118643>.
- [5] J. Xu, G. Jiao, G. Sheng, N. Lin, B. Yang, J. Wang, H. Jiang, Y. Wang, X. Zhang, Microwave-assisted PMS activation $\text{Ti3C2/LaFe0.5Cu0.5O3-P}$ catalysts for efficient degradation of CIP: enhancement of catalytic performance by phosphoric acid etching, *Sep. Purif. Technol.* 354 (2025) 129357.
- [6] Y. Yang, J. Ye, Y. Zhai, B. Yang, M. Yin, Y. Xu, J. Wang, X. Zhang, ZIF-67-derived monolithic bimetallic sulfides as efficient persulfate activators for the degradation of ofloxacin, *Surfaces and Interfaces* 51 (2024) 104713.
- [7] S. Li, G. Zhu, X. Li, P. Wan, F. Yuan, S. Xu, A.S. Hursthouse, Ecosystem-inspired model and artificial intelligence predicts pollutant consumption capacity by coagulation in drinking water treatment, *Environ. Chem. Lett.* 21 (5) (2023) 2499–2508.

- [8] G. Zhu, J. Lin, H. Fang, F. Yuan, X. Li, C. Yuan, A.S. Hursthouse, A flocculation tensor to monitor water quality using a deep learning model, *Environ. Chem. Lett.* 20 (6) (2022) 3405–3414.
- [9] O. Bello, Y. Hamam, K. Djouani, Coagulation process control in water treatment plants using multiple model predictive control, *Alex. Eng. J.* 53 (4) (2014) 939–948.
- [10] S. Peng, Y. Guo, J. Wang, Y. Wang, W. Zhang, X. Zhou, L. Jiang, B. Lai, The coagulation-precipitation turbidity prediction model for precision drug delivery system based on deep learning and machine vision, *J. Environ. Chem. Eng.* 12 (2) (2024) 112211.
- [11] H. Boumezbeur, F. Laouacheria, S. Heddam, L. Djemili, Modelling coagulant dosage in drinking water treatment plant using advance machine learning model: hybrid extreme learning machine optimized by bat algorithm, *Environ. Sci. Pollut. Res.* 30 (28) (2023) 72463–72483.
- [12] X. Fang, J. Zang, Z. Zhai, L. Zhang, Z. Shu, Y. Liang, Exploring potential dual-stage attention based recurrent neural network machine learning application for dosage prediction in intelligent municipal management, *Environ. Sci. Water Res. Technol.* 9 (3) (2023) 890–899, <https://doi.org/10.1039/D2EW00560C>.
- [13] L. Li, S. Rong, R. Wang, S. Yu, Recent advances in artificial intelligence and machine learning for nonlinear relationship analysis and process control in drinking water treatment: a review, *Chem. Eng. J.* 405 (2021) 126673.
- [14] A. Jakovljevic, L. Charlin, B. Barbeau, Applying recurrent neural networks and blocked cross-validation to model conventional drinking water treatment processes, *Water* 16 (7) (2024) 1042.
- [15] M. Achite, S. Samadianfard, N. Elshaboury, M. Sharafi, Modeling and optimization of coagulant dosage in water treatment plants using hybridized random forest model with genetic algorithm optimization, *Environ. Dev. Sustain.* 25 (10) (2023) 11189–11207.
- [16] S. Peng, Y. Guo, J. Wang, Y. Wang, W. Zhang, X. Zhou, L. Jiang, B. Lai, The coagulation-precipitation turbidity prediction model for precision drug delivery system based on deep learning and machine vision, *J. Environ. Chem. Eng.* 12 (2) (2024) 112211, <https://doi.org/10.1016/j.jece.2024.112211>.
- [17] X. Fu, Q. Zheng, G. Jiang, K. Roy, L. Huang, C. Liu, K. Li, H. Chen, X. Song, J. Chen, Z. Wang, Water quality prediction of copper-molybdenum mining-beneficiation wastewater based on the PSO-SVR model, *Front. Environ. Sci. Eng.* 17 (8) (2023) 98, <https://doi.org/10.1007/s11783-023-1698-9>.
- [18] M. Achite, S. Samadianfard, N. Elshaboury, M. Sharafi, Modeling and optimization of coagulant dosage in water treatment plants using hybridized random forest model with genetic algorithm optimization, *Environ. Dev. Sustain.* 25 (10) (2022) 11189–11207, <https://doi.org/10.1007/s10668-022-02523-z>.
- [19] M. Baratchi, C. Wang, S. Limmer, J.N. van Rijn, H. Hoos, T. Bäck, M. Olhofer, Automated machine learning: past, present and future, *Artif. Intell. Rev.* 57 (5) (2024) 122.
- [20] H. Eldeeb, M. Maher, R. Elshawi, S. Sakr, AutoMLBench: a comprehensive experimental evaluation of automated machine learning frameworks, *Expert Syst. Appl.* 243 (2024) 122877.
- [21] A. Brown, M. Gupta, M. Abdelsalam, Automated machine learning for deep learning based malware detection, *Comput. Secur.* 137 (2024) 103582.
- [22] X. Chen, C.Y. Liu, R. Proietti, Z. Li, S.J.B. Yoo, Automating optical network fault management with machine learning, *IEEE Commun. Mag.* 60 (12) (2022) 88–94.
- [23] J. Tetteroo, M. Baratchi, H.H. Hoos, Automated machine learning for COVID-19 forecasting, *IEEE Access* 10 (2022) 94718–94737.
- [24] N.P. Wu, W. Wang, D. Gadiagellan, M. Counsell, N.K. Hamidi, Y. Koike, H. Q. Nguyen, An automated robotic Interface for assays: facilitating machine learning in drug discovery by the automation of physicochemical property assays, *ACS Omega* 9 (23) (2024) 24948–24958.
- [25] R.S. Olson, N. Bartley, R.J. Urbanowicz, J.H. Moore, Evaluation of a Tree-Based Pipeline Optimization Tool for Automating Data Science, *Proceedings of the Genetic and Evolutionary Computation Conference* 2016, Association for Computing Machinery, Denver, Colorado, USA, 2016, pp. 485–492.
- [26] J. Luo, Y. Luo, X. Cheng, X. Liu, F. Wang, F. Fang, J. Cao, W. Liu, R. Xu, Prediction of Biological Nutrients Removal in Full-Scale Wastewater Treatment Plants Using H2O Automated Machine Learning and Back Propagation Artificial Neural Network Model: Optimization and Comparison, *Bioresour. Technol.* 390 (2023) 129842, <https://doi.org/10.1016/j.biortech.2023.129842>.
- [27] D. Venkata Vara Prasad, P. Senthil Kumar, L.Y. Venkataramana, G. Prasannamedha, S. Harshana, S. Jahnavi Srividya, K. Harrinei, S. Indraganti, Automating water quality analysis using ML and auto ML techniques, *Environ. Res.* 202 (2021) 111720, <https://doi.org/10.1016/j.envres.2021.111720>.
- [28] S.M. Lundberg, S.I. Lee, A unified approach to interpreting model predictions, *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS* 30 (NIPS 2017), 2017.
- [29] J.T. Hancock, T.M. Khoshgoftaar, Q. Liang, A problem-agnostic approach to feature selection and analysis using SHAP, *J. Big Data* 12 (1) (2025) 12.
- [30] N. Bacanin, M. Perisic, G. Jovanovic, R. Damaševičius, S. Stanisic, V. Simic, M. Zivkovic, A. Stojic, The explainable potential of coupling hybridized metaheuristics, XGBoost, and SHAP in revealing toluene behavior in the atmosphere, *Sci. Total Environ.* 929 (2024) 172195.
- [31] W. Chu, C. Zhang, H. Li, L. Zhang, D. Shen, R. Li, SHAP-powered insights into spatiotemporal effects: unlocking explainable Bayesian-neural-network urban flood forecasting, *Int. J. Appl. Earth Obs. Geoinf.* 131 (2024) 103972.
- [32] K. Lin, Y. Gao, Model interpretability of financial fraud detection by group SHAP, *Expert Syst. Appl.* 210 (2022) 118354.
- [33] K. Miao, A. Houssou Hounye, L. Su, Q. Pan, J. Wang, M. Hou, L. Xiong, Exploring explainable machine learning and Shapley additive exPlanations (SHAP) technique

là một công cụ hữu ích để dự đoán liều lượng chất keo tụ tại các nhà máy xử lý nước. (2) Việc diễn giải mô hình dựa trên các giá trị SHAP cho thấy ảnh hưởng của từng chỉ số chất lượng nước đến kết quả dự đoán. Cụ thể, khi NTU-RW thấp và tương đối ổn định, độ dẫn điện của nước thô là yếu tố ảnh hưởng đáng kể nhất đến liều lượng chất keo tụ, tiếp theo là $\text{NH}_3\text{-N-RW}$, $\text{COD}_{\text{Mn-RW}}$, T-RW và WTR. (3) Mô hình tối ưu dự đoán mức tiết kiệm PACl hằng ngày là 222 kg (11 %) đối với nước sông Dương Tử và 225 kg (8 %) đối với nước sông Loan Hà. Điều này nhấn mạnh vai trò then chốt của mô hình định lượng chất keo tụ trong việc nâng cao hiệu quả xử lý nước và tối ưu hóa việc sử dụng tài nguyên.

Tuyên bố về đóng góp của tác giả theo CRediT

Liyan Feng: Viết – rà soát và biên tập, Viết – thảo thảo gốc, Trực quan hóa, Thẩm định, Giám sát, Phần mềm, Nguồn lực, Quản lý dự án, Phương pháp luận, Điều tra, Phân tích hình thức, Quản lý dữ liệu, Hình thành ý tưởng. Ying Zhang: Nguồn lực, Quản lý dự án, Phương pháp luận, Điều tra, Huy động kinh phí, Quản lý dữ liệu. Xiaoting Wei: Viết – thảo thảo gốc, Trực quan hóa, Giám sát, Phần mềm. Mengyuan Wang: Trực quan hóa, Thẩm định, Phần mềm, Nguồn lực, Quản lý dự án. Zhiguang Niu: Nguồn lực, Quản lý dự án, Phương pháp luận, Điều tra, Quản lý dữ liệu. Chenchen Wang: Viết – rà soát và biên tập, Trực quan hóa, Giám sát, Phần mềm, Quản lý dự án.

Tuyên bố về xung đột lợi ích

Các tác giả tuyên bố rằng họ không có bất kỳ lợi ích tài chính cạnh tranh hoặc mối quan hệ cá nhân nào đã biết có thể ảnh hưởng đến công trình được trình bày trong bài báo này.

Lời cảm ơn

Nghiên cứu này được hỗ trợ bởi Chương trình Nghiên cứu và Phát triển Trọng điểm Quốc gia (2022YFC3203803) và Sở Khoa học và Công nghệ tỉnh Phúc Kiến (2022J01522); chúng tôi cũng xin cảm ơn Công ty TNHH Công nghiệp Nước TEDA Thiên Tân đã cung cấp dữ liệu thô.

Tính khả dụng của dữ liệu

Dữ liệu sẽ được cung cấp khi có yêu cầu.

Tài liệu tham khảo

- [1] G. Mannina, T.F. Rebouças, A. Cosenza, K. Chandran, Mô hình nhà máy xử lý nước thải toàn diện về dấu chân carbon và năng lượng: ứng dụng mô hình và phân tích kịch bản, *J. Clean. Prod.* 217 (2019) 244–256. [2] Z. Wu, H. Duan, K. Li, L. Ye, Phân tích toàn diện dấu chân carbon của các cấu hình nhà máy xử lý nước thải khác nhau, *Environ. Res.* 214 (2022) 113818. [3] N. Liu, D. Wang, J. Xu, L. Liu, J. Xue, T. Han, J. Wang, J. Lei, H. Shao, X. Zhang, Các tổ hợp aerogel graphene/MIL-53(Fe) 3D mới giúp tăng cường phân hủy ibuprofen bằng quang xúc tác dưới ánh sáng khả kiến: quy trình và cơ chế, *Surf. Interface Anal.* 46 (2024) 104192, <https://doi.org/10.1016/j.surfin.2024.104192>. [4] Y. Wang, G. Jiao, Y. Yang, J. Wang, J. Zhang, H. Jiang, N. Liu, X. Zhang, Cấu trúc 3D của chất xúc tác composite $\text{LaFe1-8Co03@vải carbon}$ nhằm thúc đẩy hoạt hóa peroxymonosulfate: xác định cơ chế xúc tác đối với nhiều loại kháng sinh, *Desalination* 602 (2025) 118643, <https://doi.org/10.1016/j.desal.2025.118643>. [5] J. Xu, G. Jiao, G. Sheng, N. Lin, B. Yang, J. Wang, H. Jiang, Y. Wang, X. Zhang, Các chất xúc tác $\text{Ti3C2/LaFe0.5Cu0.5O3-P}$ hoạt hóa PMS nhờ vi sóng để phân hủy CIP hiệu quả: tăng cường hiệu suất xúc tác bằng phương pháp ăn mòn axit photphoric, *Sep. Purif. Technol.* 354 (2025) 129357. [6] Y. Yang, J. Ye, Y. Zhai, B. Yang, M. Yin, Y. Xu, J. Wang, X. Zhang, Các sulfide lưỡng kim dạng khối có nguồn gốc từ ZIF-67 là m chất hoạt hóa persulfate hiệu quả để phân hủy ofloxacin, *Surfaces and Interfaces* 51 (2024) 104713. [7] S. Li, G. Zhu, X. Li, P. Wan, F. Yuan, S. Xu, A.S. Hursthouse, Mô hình lấy cảm hứng từ hệ sinh thái và trí tuệ nhân tạo dự đoán khả năng loại bỏ chất ô nhiễm bằng keo tụ trong xử lý nước uống, *Environ. Chem. Lett.* 21 (5) (2023) 2499–2508.

- [8] G. Zhu, J. Lin, H. Fang, F. Yuan, X. Li, C. Yuan, A.S. Hursthouse, Tensor kết bông để giám sát chất lượng nước bằng mô hình học sâu, *Environ. Chem. Lett.* 20 (6) (2022) 3405–3414. [9] O. Bello, Y. Hamam, K. Djouani, Điều khiển quá trình keo tụ tại các nhà máy xử lý nước bằng điều khiển dự báo mô hình đa mô hình, *Alex. Eng. J.* 53 (4) (2014) 939–948. [10] S. Peng, Y. Guo, J. Wang, Y. Wang, W. Zhang, X. Zhou, L. Jiang, B. Lai, Mô hình dự đoán độ đục do keo tụ-kết tủa cho hệ thống phân phối thuốc chính xác dựa trên học sâu và thị giác máy, *J. Environ. Chem. Eng.* 12 (2) (2024) 112211. [11] H. Boumezbeur, F. Laouacheria, S. Heddam, L. Djemili, Mô hình hóa liều lượng chất keo tụ tại nhà máy xử lý nước uống bằng mô hình học máy tiên tiến: máy học cực hạn lai được tối ưu hóa bằng thuật toán dơi, *Environ. Sci. Pollut. Res.* 30 (28) (2023) 72463–72483. [12] X. Fang, J. Zang, Z. Zhai, L. Zhang, Z. Shu, Y. Liang, Khảo sát ứng dụng tiềm năng của mạng nơ-ron hồi quy dựa trên cơ chế chú ý hai giai đoạn trong học máy để dự đoán liều lượng trong quản lý đô thị thông minh, *Environ. Sci. Water Res. Technol.* 9 (3) (2023) 890–899, <https://doi.org/10.1039/D2EW00560C>. [13] L. Li, S. Rong, R. Wang, S. Yu, Những tiến bộ gần đây trong trí tuệ nhân tạo và học máy phục vụ phân tích quan hệ phi tuyến và điều khiển quy trình trong xử lý nước uống: tổng quan, *Chem. Eng. J.* 405 (2021) 126673. [14] A. Jakovljevic, L. Charlin, B. Barbeau, Ứng dụng mạng nơ-ron hồi quy và kiểm định chéo phân khối để mô hình hóa các quy trình xử lý nước uống thông thường, *Water* 16 (7) (2024) 1042. [15] M. Achite, S. Samadianfard, N. Elshaboury, M. Sharafi, Mô hình hóa và tối ưu hóa liều lượng chất keo tụ tại các nhà máy xử lý nước bằng mô hình rừng ngẫu nhiên lai kết hợp tối ưu hóa bằng thuật toán di truyền, *Environ. Dev. Sustain.* 25 (10) (2023) 11189–11207. [16] S. Peng, Y. Guo, J. Wang, Y. Wang, W. Zhang, X. Zhou, L. Jiang, B. Lai, Mô hình dự đoán độ đục do keo tụ-kết tủa cho hệ thống phân phối thuốc chính xác dựa trên học sâu và thị giác máy, *J. Environ. Chem. Eng.* 12 (2) (2024) 112211, <https://doi.org/10.1016/j.jece.2024.112211>. [17] X. Fu, Q. Zheng, G. Jiang, K. Roy, L. Huang, C. Liu, K. Li, H. Chen, X. Song, J. Chen, Z. Wang, Dự đoán chất lượng nước thải khai thác tuyến đồng-molybden dựa trên mô hình PSO-SVR, *Front. Environ. Sci. Eng.* 17 (8) (2023) 98, <https://doi.org/10.1007/s11783-023-1698-9>. [18] M. Achite, S. Samadianfard, N. Elshaboury, M. Sharafi, Mô hình hóa và tối ưu hóa liều lượng chất keo tụ tại các nhà máy xử lý nước bằng mô hình rừng ngẫu nhiên lai kết hợp tối ưu hóa bằng thuật toán di truyền, *Environ. Dev. Sustain.* 25 (10) (2022) 11189–11207, <https://doi.org/10.1007/s10668-022-02523-z>. [19] M. Baratchi, C. Wang, S. Limmer, J.N. van Rijn, H. Hoos, T. Bäck, M. Olhofer, Học máy tự động: quá khứ, hiện tại và tương lai, *Artif. Intell. Rev.* 57 (5) (2024) 122. [20] H. Eldeeb, M. Maher, R. Elshawi, S. Sakr, AutoMLBench: đánh giá thực nghiệm toàn diện các khung học máy tự động, *Expert Syst. Appl.* 243 (2024) 122877. [21] A. Brown, M. Gupta, M. Abdelsalam, Học máy tự động để phát hiện phần mềm độc hại dựa trên học sâu, *Comput. Secur.* 137 (2024) 103582. [22] X. Chen, C.Y. Liu, R. Proietti, Z. Li, S.J.B. Yoo, Tự động hóa quản lý sự cố mạng quang bằng máy, *IEEE Commun. Mag.* 60 (12) (2022) 88–94. [23] J. Tetteroo, M. Baratchi, H.H. Hoos, Học máy tự động để dự báo COVID-19, *IEEE Access* 10 (2022) 94718–94737. [24] N.P. Wu, W. Wang, D. Gadiagellan, M. Counsell, N.K. Hamidi, Y. Koike, H. Q. Nguyen, Giao diện robot tự động cho các phép thử: hỗ trợ học máy trong khám phá thuốc bằng cách tự động hóa các phép thử tính chất hóa lý, *ACS Omega* 9 (23) (2024) 24948–24958. [25] R.S. Olson, N. Bartley, R.J. Urbanowicz, J.H. Moore, Đánh giá công cụ tối ưu hóa quy trình dựa trên cây nhăm tự động hóa khoa học dữ liệu, *Proceedings of the Genetic and Evolutionary Computation Conference* 2016, Association for Computing Machinery, Denver, Colorado, Hoa Kỳ, 2016, tr. 485–492. [26] J. Luo, Y. Luo, X. Cheng, X. Liu, F. Wang, F. Fang, J. Cao, W. Liu, R. Xu, Dự đoán loại bỏ chất dinh dưỡng sinh học tại các nhà máy xử lý nước thải quy mô lớn bằng học máy tự động H2O và mô hình mạng nơ-ron nhân tạo lan truyền ngược: tối ưu hóa và so sánh, *Bioresour. Technol.* 390 (2023) 129842, <https://doi.org/10.1016/j.biortech.2023.129842>. [27] D. Venkata Vara Prasad, P. Senthil Kumar, L.Y. Venkataramana, G. Prasannamedha, S. Harshana, S. Jahnavi Srividya, K. Harrinei, S. Indraganti, Tự động hóa phân tích chất lượng nước bằng các kỹ thuật ML và AutoML, *Environ. Res.* 202 (2021) 111720, <https://doi.org/10.1016/j.envres.2021.111720>. [28] S.M. Lundberg, S.I. Lee, Một phương pháp thống nhất để diễn giải các dự đoán của mô hình, *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS* 30 (NIPS 2017), 2017. [29] J.T. Hancock, T.M. Khoshgoftaar, Q. Liang, Phương pháp chọn lọc và phân tích đặc trưng không phụ thuộc vào mô hình bằng SHAP, *J. Big Data* 12 (1) (2025) 12. [30] N. Bacanin, M. Perisic, G. Jovanovic, R. Damaševičius, S. Stanisic, V. Simic, M. Zivkovic, A. Stojic, Tiềm năng giải thích của việc kết hợp các thuật toán siêu kinh nghiệm lai, XGBoost và SHAP trong việc làm sáng tỏ hành vi của toluen trong khí quyển, *Sci. Total Environ.* 929 (2024) 172195. [31] W. Chu, C. Zhang, H. Li, L. Zhang, D. Shen, R. Li, Những hiểu biết từ SHAP về các tác động không-thời gian: khai mở khả năng dự báo lũ đô thị có thể giải thích bằng mạng nơ-ron Bayes, *Int. J. Appl. Earth Obs. Geoinf.* 131 (2024) 103972. [32] K. Lin, Y. Gao, Khả năng diễn giải mô hình trong phát hiện gian lận tài chính bằng Group SHAP, *Expert Syst. Appl.* 210 (2022) 118354. [33] K. Miao, A. Houssou Hounye, L. Su, Q. Pan, J. Wang, M. Hou, L. Xiong, Khảo sát học máy có thể giải thích và kỹ thuật Shapley additive explanations (SHAP)

- to uncover key factors of HNSC cancer: An analysis of the best practices, Biomedical Signal Processing and Control 89 (2024) 105752.
- [34] K. Wang, J. Tian, C. Zheng, H. Yang, J. Ren, Y. Liu, Q. Han, Y. Zhang, Interpretable prediction of 3-year all-cause mortality in patients with heart failure caused by coronary heart disease based on machine learning and SHAP, Comput. Biol. Med. 137 (2021) 104813.
- [35] R. Li, K. Feng, T. An, P. Cheng, L. Wei, Z. Zhao, X. Xu, L. Zhu, Enhanced Insights into Effluent Prediction in Wastewater Treatment Plants: Comprehensive Deep Learning Model Explanation Based on SHAP, ACS ES&T Water, 2024.
- [36] R.K. Makumbura, L. Mampitiya, N. Rathnayake, D.P.P. Meddage, S. Henna, T. L. Dang, Y. Hoshino, U. Rathnayake, Advancing water quality assessment and prediction using machine learning models, coupled with explainable artificial intelligence (XAI) techniques like shapley additive explanations (SHAP) for interpreting the black-box nature, Results in Engineering 23 (2024) 102831, <https://doi.org/10.1016/j.rineng.2024.102831>.
- [37] J. Park, W.H. Lee, K.T. Kim, C.Y. Park, S. Lee, T.-Y. Heo, Interpretation of ensemble learning to predict water quality using explainable artificial intelligence, Sci. Total Environ. 832 (2022) 155070.
- [38] S. Narges, A. Ghorban, K. Hassan, K. Mohammad, Prediction of the optimal dosage of coagulants in water treatment plants through developing models based on artificial neural network fuzzy inference system (ANFIS), J. Environ. Health Sci. Eng. 19 (2) (2021) 1543–1553.
- [39] S. Lin, J. Kim, C. Hua, M.-H. Park, S. Kang, Coagulant dosage determination using deep learning-based graph attention multivariate time series forecasting model, Water Res. 232 (2023) 119665.
- [40] B. Celik, J. Vanschoren, Adaptation strategies for automated machine learning on evolving data, IEEE Trans. Pattern Anal. Mach. Intell. 43 (9) (2021) 3067–3078.
- [41] A. Abdollahi, D. Li, J. Deng, A. Amini, An explainable artificial-intelligence-aided safety factor prediction of road embankments, Eng. Appl. Artif. Intell. 136 (2024) 108854.
- [42] A. Abdollahi, B. Pradhan, Explainable artificial intelligence (XAI) for interpreting the contributing factors feed into the wildfire susceptibility prediction model, Sci. Total Environ. 879 (2023) 163004.
- [43] X. Ma, Y. Tang, C. Wang, Y. Li, J. Zhang, Y. Luo, Z. Xu, F. Wu, S. Wang, Interpretable XGBoost-SHAP model predicts nanoparticles delivery efficiency based on tumor genomic mutations and nanoparticle properties, ACS Appl. Bio Mater. 6 (10) (2023) 4326–4335.
- [44] D. Wang, L. Chen, T. Li, X. Chang, K. Ma, W. You, C. Tan, Successful prediction for coagulant dosage and effluent turbidity of a coagulation process in a drinking water treatment plant based on the Elman neural network and random forest models, Environ. Sci.: Water Res. Technol. 9 (9) (2023) 2263–2274.
- [45] S. Tan, R. Wang, G. Song, S. Qi, K. Zhang, Z. Zhao, Q. Yin, Machine learning and Shapley additive explanation-based interpretable prediction of the electrocatalytic performance of N-doped carbon materials, Fuel 355 (2024) 129469.
- [46] S. Lin, J. Kim, C. Hua, S. Kang, M.-H. Park, Comparing artificial and deep neural network models for prediction of coagulant amount and settled water turbidity: lessons learned from big data in water treatment operations, Journal of Water Process Engineering 54 (2023) 103949.
- [47] D.S. Wang, L. Chen, T.Y. Li, X. Chang, K.W. Ma, W.H. You, C.Q. Tan, Successful prediction for coagulant dosage and effluent turbidity of a coagulation process in a drinking water treatment plant based on the elman neural network and random forest models, ENVIRONMENTAL SCIENCE-WATER RESEARCH & TECHNOLOGY 9 (9) (2023) 2263–2274.
- [48] J. Kim, C. Hua, K. Kim, S. Lin, G. Oh, M.-H. Park, S. Kang, Optimizing coagulant dosage using deep learning models with large-scale data, Chemosphere 350 (2024) 140989.
- [49] P. Tsirikoglou, S. Abraham, F. Contino, C. Lacor, G. Ghorbaniasl, A hyperparameters selection technique for support vector regression models, Appl. Soft Comput. 61 (2017) 139–148.
- [50] A.-A. El Foulani, O. Ounas, M. Tahiri, M. Chafi, A comparative study of the performance of Polyaluminum chloride-sodium alginate and Polyaluminum chloride-chitosan composite coagulants in dam water treatment, J. Polym. Environ. 31 (11) (2023) 4909–4918.
- [51] E. Vunain, E.F. Masoamphambe, P.M.G. Mpeketula, M. Monjerezi, A. Etale, Evaluation of coagulating efficiency and water borne pathogens reduction capacity of *Moringa oleifera* seed powder for treatment of domestic wastewater from Zomba, Malawi, J. Environ. Chem. Eng. 7 (3) (2019) 103118, <https://doi.org/10.1016/j.jece.2019.103118>.
- [52] Campinas, M. , Silva, C. , Viegas, R.M.C. , Coelho, R. , Lucas, H. , Rosa, M.J. . 2020. To what extent may pharmaceuticals and pesticides be removed by PAC conventional addition to low-turbidity surface waters and what are the potential bottlenecks?. Journal of water Process Engineering.
- [53] Z. Liu, H. Wei, A. Li, H. Yang, Enhanced coagulation of low-turbidity micro-polluted surface water: properties and optimization, J. Environ. Manag. 233 (2019) 739–747.
- [54] Z. Zhang, R. Jing, S. He, J. Qian, K. Zhang, G. Ma, X. Chang, M. Zhang, Y. Li, Coagulation of low temperature and low turbidity water: adjusting basicity of polyaluminum chloride (PAC) and using chitosan as coagulant aid, Sep. Purif. Technol. 206 (2018) 131–139.
- [55] P. Cañizares, C. Jiménez, F. Martínez, M.A. Rodrigo, C. Sáez, The pH as a key parameter in the choice between coagulation and electrocoagulation for the treatment of wastewaters, J. Hazard. Mater. 163 (1) (2009) 158–164.
- [56] X. Ji, Z. Li, M. Wang, Z. Yuan, L. Jin, Response surface methodology approach to optimize parameters for coagulation process using Polyaluminum chloride (PAC), Water 16 (11) (2024) 1470.
- [57] G. Kim, J. Ryu, T. Ryu, H.-i. Kim, J. Shin, D.-W. Cho, Effects of calcination temperature on the adsorption ability of polyaluminum chloride (PAC) sludge-derived granules for as(V), Journal of water Process. Eng. 57 (2023) 104688.
- [58] W.P. Cheng, F.H. Chi, C.C. Li, R.F. Yu, A study on the removal of organic substances from low-turbidity and low-alkalinity water with metal-polysilicate coagulants, Colloids Surf. A Physicochem. Eng. Asp. 312 (2–3) (2008) 238–244, <https://doi.org/10.1016/j.colsurfa.2007.06.060>.
- [59] J. Duan, J. Gregory, Coagulation by hydrolysing metal salts, Adv. Colloid Interf. Sci. 100–102 (2003) 475–502.
- [60] A. Chiavola, C. Di Marcantonio, M. D'Agostini, S. Leoni, M. Lazzazzara, A combined experimental-modeling approach for turbidity removal optimization in a coagulation–flocculation unit of a drinking water treatment plant, J. Process Control 130 (2023) 103068.
- [61] B. Ozbey-Unal, C. Balcik-Canbolat, N. Dizge, B. Keskinler, Treatability studies on optimizing coagulant type and dosage in combined coagulation/membrane processes for table olive processing wastewater, J. Water Process Eng. 26 (2018) 301–307, <https://doi.org/10.1016/j.jwpe.2018.10.023>.
- [62] K. Wu, H. Wang, R. Liu, X. Zhao, H. Liu, J. Qu, Arsenic removal from a high-arsenic wastewater using in situ formed Fe-Mn binary oxide combined with coagulation by poly-aluminum chloride, J. Hazard. Mater. 158 (2–3) (2010) 990–995.
- [63] L. Luo, L. Zhang, H. Ye, Y. Dai, Y. Xie, Y. Chen, Z. Wang, Y. Zhang, Synchronous promotion of ZnIn2S4 sacrificial agent-free photocatalytic hydrogen production by non-metallic doping and construction of heterojunction, Sep. Purif. Technol. 360 (2025) 131102.
- [64] H. Yang, Y. Duan, Y. Dai, Y. Chen, Y. Xie, G. Zhang, Y. Zhang, CeO2-x decorated CoFe-LDH on nickel foam with moderated oxygen vacancies for the oxygen evolution reaction, Colloids Surf. A Physicochem. Eng. Asp. 709 (2025) 136055.
- nhằm làm sáng tỏ các yếu tố chính của ung thư HNSC: Phân tích các phương pháp tốt nhất, Biomedical Signal Processing and Control 89 (2024) 105752. [34] K. Wang, J. Tian, C. Zheng, H. Yang, J. Ren, Y. Liu, Q. Han, Y. Zhang, Dự đoán có thể diễn gì ải về tỷ lệ tử vong do mọi nguyên nhân trong 3 năm ở bệnh nhân suy tim do bệnh mạch vành dựa trên học máy và SHAP, Comput. Biol. Med. 137 (2021) 104813. [35] R. Li, K. Feng, T. An, P. Cheng, L. Wei, Z. Zhao, X. Xu, L. Zhu, Những hiểu biết chuyên sâu hơn về dự đoán chất lượng nước thải tại các nhà máy xử lý nước thải: Giải thích mô hình học sâu toàn diện dựa trên SHAP, ACS ES&T Water, 2024. [36] R.K. Makumbura, L. Mampitiya, N. Rathnayake, D.P.P. Meddage, S. Henna, T. L. Dang, Y. Hoshino, U. Rathnayake, Nâng cao đánh giá và dự đoán chất lượng nước bằng các mô hình học máy kết hợp với những kỹ thuật trí tuệ nhân tạo có khả năng giải thích (XAI), như phương pháp giải thích cộng tính Shapley (SHAP), để diễn giải bản chất hộp đen, Results in Engineering 23 (2024) 102831, <https://doi.org/10.1016/j.rineng.2024.102831>. [37] J. Park, W.H. Lee, K.T. Kim, C.Y. Park, S. Lee, T.-Y. Heo, Diễn giải phương pháp học tổ hợp để dự đoán chất lượng nước bằng trí tuệ nhân tạo có khả năng giải thích, Sci. Total Environ. 832 (2022) 155070. [38] S. Narges, A. Ghorban, K. Hassan, K. Hassan, K. Moha mmad, Dự đoán liều lượng chất keo tụ tối ưu tại các nhà máy xử lý nước thông qua phát triển các mô hình dựa trên hệ thống suy luận mờ mạng nơ-ron nhân tạo (ANFI S), J. Environ. Health Sci. Eng. 19 (2) (2021) 1543–1553. [39] S. Lin, J. Kim, C. Hua, M.-H. Park, S. Kang, Coagulant dosage determination using deep learning-based graph attention multivariate time series forecasting model, Water Res. 232 (2023) 119665. [40] B. Celik, J. Vanschoren, Các chiến lược thích ứng cho học máy tự động trên dữ liệu biến đổi, IEEE Trans. Pattern Anal. Mach. Intell. 43 (9) (2021) 3067–3078. [41] A. Abdollahi, D. Li, J. Deng, A. Amini, Dự đoán hệ số an toàn của nền đường đắp với sự hỗ trợ của trí tuệ nhân tạo có khả năng giải thích, Eng. Appl. Artif. Intell. 136 (2024) 108854. [42] A. Abdollahi, B. Pradhan, Trí tuệ nhân tạo có khả năng giải thích (XAI) để diễn giải các yếu tố đóng góp được đưa vào mô hình dự đoán nguy cơ cháy rừng, Sci. Total Environ. 879 (2023) 163004. [43] X. Ma, Y. Tang, C. Wang, Y. Li, J. Zhang, Y. Luo, Z. Xu, F. Wu, S. Wang, Mô hình XGBoost-SHAP có khả năng diễn giải dự đoán hiệu quả phân phối hạt nano dựa trên đột biến hệ gen khối u và đặc tính hạt nano, ACS Appl. Bio Mater. 6 (10) (2023) 4326–4335. [44] D. Wang, L. Chen, T. Li, X. Chang, K. Ma, W. You, C. Tan, Dự đoán thành công liều lượng chất keo tụ và độ đục nước thải của quá trình keo tụ tại nhà máy xử lý nước uống dựa trên các mô hình mạng nơ-ron Elman và rừng ngẫu nhiên, Environ. Sci.: Water Res. Technol. 9 (9) (2023) 2263–2274. [45] S. Tan, R. Wang, G. Song, S. Qi, K. Zhang, Z. Zhao, Q. Yin, Dự đoán có khả năng diễn gì ải hiệu suất xúc tác điện hóa của vật liệu carbon pha tạp N bằng học máy và phương pháp giải thích cộng tính Shapley, Fuel 355 (2024) 129469. [46] S. Lin, J. Kim, C. Hu a, S. Kang, M.-H. Park, So sánh các mô hình mạng nơ-ron nhân tạo và mạng nơ-ron sâu để dự đoán lượng chất keo tụ và độ đục của nước sau lắng: bài học rút ra từ dữ liệu lớn trong vận hành xử lý nước, Journal of Water Process Engineering 54 (2023) 103949. [47] D.S. Wang, L. Chen, T.Y. Li, X. Chang, K.W. Ma, W.H. You, C.Q. Tan, Dự đ oán thành công liều lượng chất keo tụ và độ đục nước thải của quá trình keo tụ tại nhà máy xử lý nước uống dựa trên các mô hình mạng nơ-ron Elman và rừng ngẫu nhiên, ENVIRONMENTAL SCIENCE-WATER RESEARCH & TECHNOLOGY 9 (9) (2023) 2263–2274. [48] J. Kim, C. Hua, K. Kim, S. Lin, G. Oh, M.-H. Park, S. Kang, Tối ưu hóa liều lượng chất keo tụ bằng các mô hình học sâu với dữ liệu quy mô lớn, Chemosphere 350 (2024) 140989.
- [49] P. Tsirikoglou, S. Abraham, F. Contino, C. Lacor, G. Ghorbaniasl, Kỹ thuật lựa chọn siêu tham số cho các mô hình hồi quy vector hỗ trợ, Appl. Soft Comput. 61 (2017) 139–148. [50] A.-A. El Foulani, O. Ounas, M. Tahiri, M. Chafi, Nghiên cứu so sánh hiệu suất của các chất keo tụ composite polyaluminum chloride-natri alginate và polyaluminum chloride-chitosan trong xử lý nước hồ chứa, J. Polym. Environ. 31 (11) (2023) 4909–4918. [51] E. Vunain, E.F. Masoamphambe, P.M.G. Mpeketula, M. Monjerezi, A. Etale, Đánh giá hiệu quả keo tụ và khả năng giảm mầm bệnh lây truyền qua nước của bột hạt *Moringa oleifera* trong xử lý nước thải sinh hoạt tại Zomba, Malawi, J. Environ. Chem. Eng. 7 (3) (2019) 103118, <https://doi.org/10.1016/j.jece.2019.103118>. [52] Campinas, M., Silva, C., Viegas, R.M.C., Coelho, R., Lucas, H., Rosa, M.J. 2020. Dự a vào mức độ nào, việc bổ sung PAC theo phương pháp thông thường có thể loại bỏ được phẩm và thuốc trừ sâu khỏi nước mặt có độ đục thấp, và đây là những trở ngại tiềm tàng? Journal of Water Process Engineering. [53] Z. Liu, H. Wei, A. Li, H. Yang, Tăng cường keo tụ nước mặt ít đục bị ô nhiễm vi lượng: đặc tính và tối ưu hóa, J. Environ. Manag. 233 (2019) 739–747. [54] Z. Zhang, R. Jing, S. He, J. Qian, K. Zhang, G. Ma, X. Chang, M. Zhang, Y. Li, Keo tụ nước nhiệt độ thấp và độ đục thấp: điều chỉnh độ bazơ của polyaluminum chloride (PAC) và sử dụng chitosan làm chất trợ keo tụ, Sep. Purif. Technol. 206 (2018) 131–139. [55] P. Cañizares, C. Jiménez, F. Martínez, M. A. Rodrigo, C. Sáez, pH là thông số then chốt khi lựa chọn giữa keo tụ và điện keo tụ để xử lý nước thải, J. Hazard. Mater. 163 (1) (2009) 158–164. [56] X. Ji, Z. Li, M. Wang, Z. Yuan, L. Jin, Phương pháp bề mặt đáp ứng để tối ưu hóa các thông số của quá trình keo tụ sử dụng polyaluminum chloride (PAC), Water 16 (11) (2024) 1470. [57] G. Kim, J. Ryu, T. Ryu, H.-i. Kim, J. Shin, D.-W. Cho, Ảnh hưởng của nhiệt độ nung đến khả năng hấp phụ as(V) của các hạt tạo thành từ bùn polyaluminum chloride (PAC), Journal of Water Process Engineering 57 (2023) 104688. [58] W.P. Cheng, F.H. Chi, C.C. Li, R.F. Yu, Nghiên cứu loại bỏ các chất hữu cơ khỏi nước có độ đục và độ kiềm thấp bằng chất keo tụ kim loại-polysilicat, Colloids Surf. A Physicochem. Eng. Asp. 312 (2–3) (2008) 238–244, <https://doi.org/10.1016/j.colsurfa.2007.06.060>. [59] J. Duan, J. Gregory, Keo tụ bằng muối kim loại thủy phân, Adv. Colloid Interf. Sci. 100–102 (2003) 475–502. [60] A. Chiavola, C. Di Marcantonio, M. D'Agostini, S. Leoni, M. Lazzazzara, Phương pháp kết hợp thực nghiệm và mô hình hóa để tối ưu hóa việc loại bỏ độ đục trong công đoạn keo tụ-tạo bông của nhà máy xử lý nước uống, J. Process Control 130 (2023) 103068. [61] B. Ozbey-Unal, C. Balcik-Canbolat, N. Dizge, B. Keskinler, Nghiên cứu khả năng xử lý nhằm tối ưu hóa loại và liều lượng chất keo tụ trong các quy trình kết hợp keo tụ/màng để xử lý nước thải chế biến ô liu bản địa, J. Water Process Eng. 26 (2018) 301–307, <https://doi.org/10.1016/j.jwpe.2018.10.023>. [62] K. Wu, H. Wang, R. Liu, X. Zhao, H. Liu, J. Qu, Loại bỏ arsen khỏi nước thải có hàm lượng arsen cao bằng oxit kép Fe-Mn hình thành tại chỗ kết hợp với keo tụ bằng polyaluminum chloride, J. Hazard. Mater. 158 (2–3) (2010) 990–995. [63] L. Luo, L. Zhang, H. Ye, Y. Dai, Y. Xie, Y. Chen, Z. Wang, Y. Zhang, Tăng cường đồng thời quá trình sản xuất hydro qua ng xúc tác không dùng chất hy sinh bằng ZnIn2S4 thông qua pha tạp phi kim và tạo dị thể, Sep. Purif. Technol. 360 (2025) 131102. [64] H. Yang, Y. Duan, Y. Dai, Y. Chen, Y. Xie, G. Zhang, Y. Zhang, CeO2-x trang trí trên CoFe-LDH phủ bột niken với các khuyết oxy được điều tiết cho phản ứng thoát oxy, Colloids Surf. A Physicochem. Eng. Asp. 709 (2025) 136055.