

Knowledge-Based Feature Selection Substantially Enhances Data-Driven Wastewater Treatment Modeling

Senyuan Gu, Shuting Wang, Ruihong Qiu, Kaili Li, Jaswinder Manjeet Singh, Jue Zhang, Bing-Jie Ni, T. David Waite, Liu Ye, and Haoran Duan*

Cite This: *Environ. Sci. Technol.* 2026, 60, 19882–19894

Read Online

ACCESS | Metrics & More | Article Recommendations | Supporting Information

ABSTRACT: Data-driven modeling in wastewater treatment is increasingly constrained by the reality of small, high-dimensional data, where the abundant monitoring parameters in small-sized data sets obscure fundamental mechanistic understandings. This study proposes a knowledge-driven feature selection framework that integrates mechanistic insights with statistical correlations to identify the most informative predictive features. Using nitrous oxide (N₂O) emission prediction at a full-scale plant as a case study, we compared classic deep-learning feature selection algorithms using attention mechanisms against two new knowledge-based approaches: (i) expert-guided feature selection and (ii) large language model (LLM)-augmented feature selection. Expert-knowledge-guided feature selection substantially enhances predictive accuracy, achieving a mean R² of 0.723 and an MAE of 0.033, compared to R² = 0.712 and MAE = 0.033 for the best-performing attention-based architecture. More importantly, the proposed framework markedly improves model generalizability: under out-of-distribution high-flow conditions where the attention-based model fails to capture N₂O emission patterns, the expert-selected model continues to reproduce the dominant temporal dynamics of N₂O emissions. The LLM-assisted approach also delivers competitive accuracy (mean R² = 0.596, MAE = 0.041) and similarly preserves generalizability under an input distributional shift. By introducing mechanistic understanding into the feature selection process, this framework offers a generalizable pathway for addressing complex wastewater treatment challenges while maintaining a computational efficiency.

KEYWORDS: Feature selection, wastewater modeling, high-dimensionality data, expert knowledge, machine learning, data driven

1. INTRODUCTION

Wastewater treatment modeling has become increasingly crucial for operational optimization, regulatory compliance, and addressing environmental concerns. Traditional mechanistic models, however, face significant limitations due to incomplete understanding of complex reaction mechanisms and microbial interactions, particularly when characterizing emerging issues that attract growing public attention such as emerging contaminants and GHG emissions.^{1–4} In recent years, the role of wastewater treatment systems has expanded beyond pollution removal toward energy-neutral and carbon-negative infrastructure.⁵ Wastewater treatment plants (WWTPs) are increasingly recognized as resource recovery facilities capable of generating energy, recovering nutrients, and reducing net GHG emissions.^{6,7} This transition places higher demands on process monitoring and optimization, which in turn requires reliable predictive models capable of accurately capturing system dynamics under diverse operational conditions.⁸

While machine learning models demonstrate promise for modeling complex systems, they encounter the “curse of

dimensionality” challenge, where an abundance of features leads to overfitting and reduced generalizability, ultimately compromising real-world performance.^{9,10} In wastewater treatment systems, this challenge is exacerbated by small-sized data sets which are generated from extensive monitoring and analytical techniques performed on a limited number of samples. Paradoxically, this wealth of data often obscures rather than illuminates the fundamental mechanistic relationships governing system performance.^{11–13}


Recent research has attempted to address high-dimensionality challenges through sophisticated model architectures, including deep learning approaches with convolutional neural networks, graph-based representations, and attention mechanisms designed to capture complex spatiotemporal depend-

Received: April 2, 2026

Revised: June 22, 2026

Accepted: June 24, 2026

Published: July 12, 2026



Downloaded from pubs.acs.org/esthag/article-pdf/60/26/19882/6588436/acs.est.6c04963.pdf by guest on 05 October 2026

Lựa chọn đặc trưng dựa trên tri thức cải thiện đáng kể mô hình hóa xử lý nước thải dựa trên dữ liệu

Senyuan Gu, Shuting Wang, Ruihong Qiu, Kaili Li, Jaswinder Manjeet Singh, Jue Zhang, Bing-Jie Ni, T. David Waite, Liu Ye và Haoran Duan*

Trích dẫn bài này: *Environ. Sci. Technol.* 2026, 60, 19882–19894

Đọc trực tuyến

TRUY CẬP | Chỉ số & hơn thế nữa | Bài viết được đề xuất *s1 Supporting Information

TÓM TẮT: Việc mô hình hóa dựa trên dữ liệu trong xử lý nước thải ngày càng bị hạn chế bởi thực tế là dữ liệu thu được ít nhưng có số chiều cao, trong đó các thông số giám sát phong phú trong những tập dữ liệu nhỏ che khuất các hiểu biết cơ bản về cơ chế. Nghiên cứu này đề xuất một khuôn khổ lựa chọn đặc trưng dựa trên tri thức, kết hợp hiểu biết về cơ chế với các mối tương quan thống kê để xác định những đặc trưng dự báo giàu thông tin nhất. Lấy việc dự đoán phát thải nitơ oxit (N₂O) tại một nhà máy quy mô toàn phần làm trường hợp nghiên cứu, chúng tôi so sánh các thuật toán lựa chọn đặc trưng học sâu kinh điển sử dụng cơ chế chú ý với hai phương pháp mới dựa trên tri thức: (i) lựa chọn đặc trưng có chuyên gia hướng dẫn và (ii) lựa chọn đặc trưng được tăng cường bằng mô hình ngôn ngữ lớn (LLM). Với cùng một cấu trúc mô hình và cùng một bộ dữ liệu, mô hình dựa trên cơ chế được đề xuất cải thiện đáng kể khả năng tổng quát hóa của mô hình: trong các điều kiện lưu lượng cao ngoài phân phối, nơi mô hình dựa trên cơ chế chú ý không thể nắm bắt các mẫu phát thải N₂O, mô hình được lựa chọn bởi chuyên gia vẫn tái hiện được động lực học chi phối theo thời gian của lượng phát thải N₂O. Phương pháp có hỗ trợ của LLM cũng đạt độ chính xác cạnh tranh (R² = trung bình là 0.596, MAE = 0.041) và tương tự duy trì khả năng tổng quát hóa khi phân phối đầu vào thay đổi. Bằng cách đưa hiểu biết cơ chế vào quá trình lựa chọn đặc trưng, khuôn khổ này mở ra một hướng tiếp cận có khả năng tổng quát hóa để giải quyết các thách thức phức tạp trong xử lý nước thải. **ĐOẠN TRÍCH:** Feature selection, wastewater modeling, high-dimensionality data, expert knowledge, machine learning, data driven

1. GIỚI THIỆU

Mô hình hóa xử lý nước thải ngày càng trở nên quan trọng đối với việc tối ưu hóa vận hành, tuân thủ quy định và giải quyết các vấn đề môi trường. Tuy nhiên, các mô hình cơ chế truyền thống gặp phải những hạn chế đáng kể do hiểu biết chưa đầy đủ về các cơ chế phản ứng phức tạp và tương tác giữa vi sinh vật, đặc biệt khi mô tả những vấn đề mới nổi đang thu hút sự quan tâm ngày càng tăng của cộng chúng, chẳng hạn như các chất ô nhiễm mới nổi và phát thải khí nhà kính.^{1–4} Trong những năm gần đây, vai trò của các hệ thống xử lý nước thải đã vượt ra ngoài việc loại bỏ ô nhiễm, hướng tới cơ sở hạ tầng trung hòa năng lượng và âm carbon.⁵ Các nhà máy xử lý nước thải (WWTP) ngày càng được công nhận là cơ sở thu hồi tài nguyên, có khả năng tạo ra năng lượng, thu hồi chất dinh dưỡng và giảm phát thải khí nhà kính ròng.^{6,7} Quá trình chuyển đổi này đặt ra yêu cầu cao hơn đối với việc giám sát và tối ưu hóa quy trình, từ đó đòi hỏi các mô hình dự báo đáng tin cậy, có khả năng nắm bắt chính xác động lực học chi phối theo thời gian của lượng phát thải N₂O. Phương pháp có hỗ trợ của LLM cũng đạt độ chính xác cạnh tranh (R² = trung bình là 0.596, MAE = 0.041) và tương tự duy trì khả năng tổng quát hóa khi phân phối đầu vào thay đổi. Bằng cách đưa hiểu biết cơ chế vào quá trình lựa chọn đặc trưng, khuôn khổ này mở ra một hướng tiếp cận có khả năng tổng quát hóa để giải quyết các thách thức phức tạp trong xử lý nước thải.

thách thức về số chiều, trong đó số lượng đặc trưng quá lớn dẫn đến hiện tượng quá khớp và giảm khả năng khái quát hóa, cuối cùng làm suy giảm hiệu suất trong thực tế.^{9,10} Trong các hệ thống xử lý nước thải, thách thức này càng trầm trọng hơn do các tập dữ liệu nhỏ được tạo ra từ hoạt động giám sát và các kỹ thuật phân tích chuyên sâu trên một số lưu lượng mẫu hạn chế. Trớ trêu thay, nguồn dữ liệu phong phú này thường che khuất thay vì làm sáng tỏ các mối quan hệ cơ chế cơ bản chi phối hiệu suất của các công nghệ. Gần đây đã tìm cách giải quyết những thách thức về số chiều cao bằng các kiến trúc mô hình tinh vi, bao gồm các phương pháp học sâu sử dụng mạng nơ-ron tích chập, biểu diễn dựa trên đồ thị và các cơ chế chú ý được thiết kế để nắm bắt những mối phụ thuộc không-thời gian phức tạp.

Received: April 2, 2026

Revised: June 22, 2026

Accepted: June 24, 2026

Published: July 12, 2026




Table 1. Summary of Data Sets and Monitored Raw Readings

Data set	WWTP	Monitoring period	Raw readings (SCADA variables)
A1	WWTP-A	May 2024 – July 2024	N ₂ O concentration, RAS_CDE, RAS_F, Aeration Power2, WAS, InflowRate, DO, Aeration On/Off status, effluent ammonia, effluent nitrate
A2	WWTP-A	9–16 August 2024	
B1	WWTP-B	5–15 December 2024	Influent flow, WAS flow, RAS pump flows, internal recycle pump speeds, aeration airflow (cells 1–3 and reaeration cell), DO (cells 1–3), reaeration DO, temperature, ammonia, nitrate, N ₂ O concentration
		October 2025 – November 2025	

encies in wastewater treatment data.^{14,15} While these innovations theoretically enable more effective navigation of high-dimensionality spaces by automatically identifying relevant features without explicit selection, practical limitations remain. Most wastewater facilities typically generate temporally sparse data sets due to monitoring constraints. Consequently, despite their theoretical advantages, increased architectural complexity and additional input features often lead to deteriorating rather than improved predictive accuracy.¹⁶ Some investigators have attempted to overcome these limitations by utilizing models that learn from mathematical equations and mechanistic descriptions of known principles to approach supervised learning tasks, offering potential advantages in data-sparse conditions.^{11,17}

It is recognized that feature selection can provide a more effective pathway to enhanced model performance than architectural sophistication alone.^{18,19} Through use of rigorous methodologies for identification of priority input parameters, models can achieve superior predictive performance while maintaining reasonable complexity and computational efficiency. However, traditional statistical feature selection methods, such as principal component analysis, lack domain context in wastewater modeling, potentially leading to the selection of features with high statistical significance but limited practical relevance.²⁰ Therefore, in this study, we propose that knowledge-guided feature selection based on wastewater domain knowledge offers an effective approach for constraining the model hypothesis space, potentially improving both predictive accuracy and generalizability.

Furthermore, large language models (LLMs) combined with retrieval-augmented generation (RAG) present new opportunities for knowledge-based feature selection by enabling systematic synthesis of domain knowledge from scientific literature.^{21–23} These systems can identify feature relevance across a broad body of evidence, potentially capturing relationships that individual experts might overlook due to limited literature exposure.²⁴ Integrating LLM-RAG-based knowledge extraction with traditional expert knowledge allows feature selection to benefit from both human intuition and machine-enabled literature synthesis.

To address emerging wastewater treatment modeling challenges, we present in this study a novel knowledge-based feature selection framework. In this study, feature selection is treated as a key intermediate step in the modeling workflow, aimed at optimizing the input space and improving predictive performance and generalizability. The framework is demonstrated through a case study of nitrous oxide (N₂O) emissions prediction at two full-scale wastewater treatment plants. N₂O, a potent GHG, is generated in wastewater treatment simultaneously from multiple highly dynamic biological processes governed, in different ways, by numerous environmental factors.²⁵ It is precisely the high-dimensional challenge that confounds purely data-driven approaches and provides an ideal

test case for this new methodology. We systematically compare architecture-based strategies, including attention-enhanced deep learning models, with two knowledge-based approaches: (1) knowledge-based feature selection integrating mechanistic understanding with statistical correlation analysis and (2) LLM-RAG-augmented feature selection leveraging scientific literature synthesis. Model performance is evaluated not only in terms of predictive accuracy but also with respect to overfitting risk and robustness under distributional shift, including temporal transfer across seasonal conditions and external generalizability across data sets from different treatment plants. Through this design, we assess whether improving feature quality, rather than increasing model complexity alone, provides a more effective pathway toward robust wastewater treatment modeling.

2. MATERIALS AND METHODS

2.1. Data Acquisition and Preprocessing

2.1.1. Study Site Characteristics. Comprehensive monitoring was conducted at two full-scale wastewater treatment plants (WWTPs) located in Queensland, Australia, termed WWTP-A and WWTP-B.

WWTP-A has a design treatment capacity of 20 ML day^{−1} and employs a biological nutrient removal configuration consisting of sequential anoxic and aerobic zones followed by secondary clarification. The plant operates with mechanical surface aerators in the aeration basins. The facility includes six parallel biological treatment basins, each consisting of an anoxic zone (tank 1) followed by an aerobic zone divided into two compartments (tanks 2 and 3) equipped with surface aerators. Monitoring campaigns primarily focus on one representative basin.

WWTP-B has a design treatment capacity of 30 ML·d^{−1} and employs a five-stage Bardenpho process. It utilizes a multicompart- mental biological reactor consisting of 12 sequential tanks, including anaerobic, aerobic, postanoxic, and reaeration zones, arranged in parallel treatment trains. The reactor configuration allows staged biological nutrient removal through multiple redox environments. Monitoring campaigns focused on one representative treatment train.

2.1.2. Data Sets and Pretreatments. Different data pretreat- ment methods were implemented for the data sets used in this study. Three data sets were employed to evaluate the proposed modeling framework, including two data sets from WWTP-A and one data set from WWTP-B (Table 1).

Data set A1 was collected from WWTP-A during a monitoring campaign from 25 May 2024 to 16 August 2024. Data set A2 was obtained from the same treatment plant during a second monitoring campaign from 5 to 15 December 2024, representing a different seasonal period. Both data sets were acquired from the SCADA (supervisory control and data acquisition) system and included the same set of monitored variables (Table 1). The recorded parameters included dissolved N₂O concentrations, return activated sludge (RAS) parameters (RAS_CDE and RAS_F), nitrogen indicators (ammonium and nitrate concentrations), operational metrics (aeration power2, WAS, inflow rate, DO, and aeration on/off status), and effluent quality indicators (effluent ammonia and effluent nitrate concentrations).

Bảng 1. Tóm tắt các tập dữ liệu và chỉ số đọc thô được giám sát

Data set	WWTP	Monitoring period	Raw readings (SCADA variables)
A1	WWTP-A	May 2024 – July 2024	N ₂ O concentration, RAS_CDE, RAS_F, Aeration Power2, WAS, InflowRate, DO, Aeration On/Off status, effluent ammonia, effluent nitrate
A2	WWTP-A	9–16 August 2024	
B1	WWTP-B	5–15 December 2024	Influent flow, WAS flow, RAS pump flows, internal recycle pump speeds, aeration airflow (cells 1–3 and reaeration cell), DO (cells 1–3), reaeration DO, temperature, ammonia, nitrate, N ₂ O concentration
		October 2025 – November 2025	

... trong dữ liệu xử lý nước thải.^{14,15} Mặc dù về lý thuyết, những đổi mới này cho phép điều hướng hiệu quả hơn trong các không gian có số chiều cao bằng cách tự động xác định các đặc trưng liên quan mà không cần lựa chọn tường minh, nhưng vẫn còn những hạn chế trong thực tế. Hầu hết các cơ sở xử lý nước thải thường tạo ra các bộ dữ liệu thưa thớt theo thời gian do những hạn chế trong việc giám sát. Vì vậy, bắt chước các ưu điểm trên lý thuyết, kiến trúc phức tạp hơn và các đặc trưng đầu vào bổ sung thường khiến độ chính xác dự đoán suy giảm thay vì được cải thiện.¹⁶ Một số nhà nghiên cứu đã tìm cách khắc phục những hạn chế này bằng cách sử dụng các mô hình học từ phương trình toán học và mô tả cơ chế của những nguyên lý đã biết để giải quyết các tác vụ học có giám sát, qua đó đem lại những lợi thế tiềm năng trong điều kiện dữ liệu thưa thớt. Tuy nhiên, việc tạo ra bộ trình hiểu quả hơn để hàng cáo hiệu suất mô hình so với chỉ cải tiến kiến trúc.^{18,19} Thông qua việc áp dụng các phương pháp nghiêm ngặt để xác định những tham số đầu vào ưu tiên, mô hình có thể đạt được hiệu suất dự báo vượt trội mà vẫn duy trì độ phức tạp và hiệu quả tính toán ở mức hợp lý. Tuy nhiên, các phương pháp lựa chọn đặc trưng thông kê truyền thống, chẳng hạn như phân tích thành phần chính, thiếu bối cảnh chuyên ngành trong mô hình hóa nước thải, có khả năng dẫn đến việc lựa chọn những đặc trưng có ý nghĩa thống kê cao nhưng ít phù hợp trong thực tiễn.²⁰ Vì vậy, trong nghiên cứu này, chúng tôi đề xuất rằng lựa chọn đặc trưng dựa trên tri thức chuyên ngành về nước thải là một cách tiếp cận hiệu quả để giới hạn không gian giả thuyết của mô hình, qua đó có khả năng cải thiện các chỉ số chính xác dự đoán khả năng phát huy phương pháp tạo sinh tăng cường truy xuất (RAG) mở ra những cơ hội mới cho việc lựa chọn đặc trưng dựa trên tri thức, bằng cách cho phép tổng hợp có hệ thống tri thức chuyên ngành từ các tài liệu khoa học.^{21–23} Các hệ thống này có thể xác định mức độ liên quan của đặc trưng trên một khối lượng bằng chứng rộng lớn, qua đó có khả năng nắm bắt những mối quan hệ mà từng chuyên gia có thể bỏ sót do chỉ tiếp cận được một lượng tài liệu hạn chế.²⁴ Việc kết hợp trích xuất tri thức dựa trên LLM-RAG với tri thức chuyên môn truyền thống giúp quá trình lựa chọn đặc trưng tận dụng được trọng kiến của chuyên gia và khả năng khám phá mối liên hệ ẩn trong dữ liệu, từ đó đưa ra những lựa chọn đặc trưng mới dựa trên tri thức. Trong nghiên cứu này, lựa chọn đặc trưng được xem là một bước trung gian then chốt trong quy trình mô hình hóa, nhằm tối ưu hóa không gian đầu vào và cải thiện hiệu quả dự báo cũng như khả năng khái quát hóa. Khung này được minh họa thông qua một nghiên cứu tình huống về dự báo phát thải nitơ oxit (N₂O) tại hai nhà máy xử lý nước thải quy mô lớn. N₂O, một khí nhà kính mạnh, được tạo ra trong quá trình xử lý nước thải đồng thời từ nhiều quá trình sinh học có tính biến động cao, được chi phối theo những cách khác nhau bởi nhiều yếu tố môi trường.²⁵ Chính thách thức nhiều chiều này gây trở ngại cho các phương pháp thuần túy dựa trên dữ liệu và tạo nên một cơ hội lý tưởng

trường hợp kiểm thử cho phương pháp luận mới này. Chúng tôi so sánh một cách có hệ thống các chiến lược dựa trên kiến trúc, bao gồm các mô hình học sâu được tăng cường bằng cơ chế chú ý, với hai phương pháp dựa trên tri thức: (1) lựa chọn đặc trưng dựa trên tri thức, kết hợp hiểu biết cơ chế với phân tích tương quan thống kê và (2) lựa chọn đặc trưng được tăng cường bằng LLM-RAG, khai thác việc tổng hợp tài liệu khoa học. Hiệu suất mô hình được đánh giá không chỉ về độ chính xác dự đoán mà còn xét đến nguy cơ quá khớp và độ bền vững trước dịch chuyển phân phối, bao gồm khả năng chuyển giao theo thời gian giữa các điều kiện mùa vụ và khả năng khái quát hóa bên ngoài trên các tập dữ liệu từ những nhà máy xử lý khác nhau. Thông qua thiết kế này, chúng tôi đánh giá liệu việc cải thiện chất lượng đặc trưng, thay vì chỉ tăng độ phức tạp của mô hình, có mang lại hướng tiếp cận hiệu quả hơn để xây dựng các mô hình xử lý nước thải vững chắc hay không.

2.1. Thu thập và tiền xử lý dữ liệu

2.1.1. Đặc điểm địa điểm nghiên cứu. Hoạt động giám sát toàn diện được tiến hành tại hai nhà máy xử lý nước thải (WWTP) quy mô đầy đủ ở Queensland, Australia, được gọi là WWTP-A và WWTP-B.

WWTP-A có công suất xử lý theo thiết kế là 20 ML/ngày^{−1} và sử dụng cấu hình loại bỏ chất dinh dưỡng sinh học gồm các vùng thiếu khí và hiếu khí nối tiếp, sau đó là công đoạn lắng thứ cấp. Nhà máy vận hành bằng các thiết bị sục khí bề mặt cơ học trong các bể sục khí. Cơ sở này có sáu bể xử lý sinh học song song, mỗi bể gồm một vùng hiếu khí (bể 1), tiếp theo là một vùng hiếu khí được chia thành hai ngăn (bể 2 và bể 3) có trang bị thiết bị sục khí bề mặt. Các đợt quan trắc chủ yếu tập trung vào một bể đại diện.

WWTP-B có công suất xử lý thiết kế là 30 ML·d^{−1} và sử dụng quy trình Bardenpho năm giai đoạn. Công trình sử dụng một bể phản ứng sinh học nhiều ngăn gồm 12 bể nối tiếp, bao gồm các vùng kỵ khí, hiếu khí, thiếu khí sau xử lý và tái sục khí, được bố trí thành các tuyến xử lý song song. Cấu hình bể phản ứng cho phép loại bỏ chất dinh dưỡng sinh học theo từng giai đoạn thông qua nhiều môi trường oxy hóa-khử. Các đợt quan trắc tập trung vào một tuyến xử lý đại diện.

Các phương pháp tiền xử lý dữ liệu khác nhau đã được áp dụng cho các tập dữ liệu sử dụng trong nghiên cứu này. Ba tập dữ liệu được sử dụng để đánh giá khung mô hình hóa đề xuất, bao gồm hai tập dữ liệu từ WWTP-A và một tập dữ liệu từ WWTP-B (Bảng 1).

Tập dữ liệu A1 được thu thập tại WWTP-A trong một đợt giám sát từ ngày 25 tháng 5 năm 2024 đến ngày 16 tháng 8 năm 2024. Tập dữ liệu A2 được lấy từ cùng nhà máy xử lý trong đợt giám sát thứ hai, từ ngày 5 đến ngày 15 tháng 12 năm 2024, đại diện cho một giai đoạn mùa khác. Cả hai tập dữ liệu đều được thu thập từ hệ thống SCADA (điều khiển giám sát và thu thập dữ liệu) và bao gồm cùng một bộ biến được giám sát (Bảng 1). Các thông số được ghi nhận gồm nồng độ N₂O hòa tan, các thông số vận hành tính toán tuần hoàn (RAS) (RAS_CDE và RAS_F), các chỉ thị nitơ (nồng độ amoni và nitrat), các chỉ số vận hành (công suất sục khí², WAS, lưu lượng đầu vào, DO và trạng thái bật/tắt sục khí), cùng các chỉ thị chất lượng nước thải đầu ra (nồng độ amoni và nitrat trong nước thải đầu ra).

Downloaded from pubs.acs.org/esthag/article-pdf/60/28/19882/6588436/acs.est.6c04963.pdf by guest on 05 October 2026

Downloaded from pubs.acs.org/esthag/article-pdf/60/28/19882/6588436/acs.est.6c04963.pdf by guest on 05 October 2026

Data set B1 was obtained from WWTP-B during a monitoring campaign from October to November 2025. The SCADA system recorded a range of operational and process variables, including influent and sludge flow rates, RAS pump flows, internal recycle pump speeds (A-cycle flow rates), aeration airflow rates in different aeration cells 1–3, dissolved oxygen concentrations in aeration tanks 1–3, pH in the reactor effluent, temperature in aeration tank 1, nitrogen indicators (ammonia and nitrate), and N₂O concentrations measured by in situ probes.

The original SCADA data were recorded at varying time intervals. To reduce computational complexity and better capture relevant process dynamics, the SCADA data from all data sets were resampled to 15 min intervals by calculating the mean value of each parameter within each 15 min time window.

In addition, hourly precipitation data corresponding to the catchment areas of both wastewater treatment plants were obtained from the CHRS Data Portal (PERSIANN-CCS). Linear interpolation was applied to align the rainfall data with the 15 min timestamps of the aggregated SCADA data sets, enabling integrated analysis of precipitation effects on treatment performance and N₂O emissions.

2.1.3. Feature Engineering. To further investigate the intermediate reaction processes contributing to N₂O emissions, we implemented an Activated Sludge Model - N₂O (ASM-N₂O) that was calibrated specifically for our system using the first 2 weeks of data.²⁶ To prevent data leakage in the downstream deep learning models (section 2.2), the calibration period was confined to data that falls within the training set, ensuring that no information from the validation or test sets was used during model calibration. This model incorporates the bioconversion pathways and kinetics described by Pocquet et al. for AOB-mediated N₂O production via nitrifier nitrification (NN) and nitrifier denitrification (ND), integrated with the four-step heterotrophic denitrification model from Hiatt and Grady.^{27,28} The model was separately calibrated using operational data from WWTP-A and WWTP-B, with particular attention to dissolved oxygen concentration profiles and nitrogen species transformations. The calibrated model generated a comprehensive set of state variables describing the biological nitrogen transformation processes, including dissolved gas concentrations (N₂ and N₂O), dissolved nitrogen species (NH₄⁺, NH₂OH, NO, NO₂[−], and NO₃[−]), dissolved oxygen levels, readily biodegradable substrate concentrations, and biomass concentrations (X_AOB, X_H, X_I, and X_NOB). The simulated temporal dynamics of these variables are presented in SI section 2.

2.2. Deep Learning Model Development and Implementation

For baseline performance assessment, we initially implemented a standard long short-term memory (LSTM) neural network architecture, which has demonstrated effectiveness in capturing temporal dependencies in environmental time series data.²⁹ For baseline performance assessment, we implemented a two-layer LSTM architecture. The baseline model comprised two stacked LSTM layers (32 units each), with each layer followed by batch normalization and dropout regularization (rate = 0.2) and a final linear dense output layer.

Building upon this foundation, we progressively increased the model architecture complexity through two primary mechanisms:

1. Architectural Enhancement:

Building upon the two-layer baseline, we conducted systematic hyperparameter optimization to search across architectures of varying depth and configuration. The number of LSTM layers, unit counts per layer, and regularization parameters was jointly optimized using the Optuna framework,³⁰ allowing the search to identify the best-performing architecture without manual exploration.

2. Attention–LSTM Model:

To enhance model interpretability and performance, we evaluated an Attention–LSTM architecture designed to capture complex dependencies in the data. This model applies multihead self-attention across the feature dimension prior to

temporal modeling via LSTM layers. By prioritizing informative features early in the processing pipeline, this architecture enhances model flexibility and robustness, particularly when dealing with high-dimensionality data sets.

The attention mechanisms were implemented as multihead self-attention layers following the formulation

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

where Q , K , and V represent the query, key, and value matrices derived from the input representations. The matrices W_i^Q , W_i^K , W_i^V , and W^O are learnable projection matrices that transform the input representations into query, key, value, and output spaces, respectively.³¹

3. CNN–LSTM Model:

In addition, a one-dimensional Convolutional Neural Network–LSTM (CNN-LSTM) hybrid architecture was evaluated. The CNN component applies temporal convolutional filters to extract local short-range patterns from the input sequence, after which the LSTM layers capture long-range dependencies from these condensed representations. This hierarchical feature extraction strategy has been shown to improve predictive performance in multivariate time series tasks.³²

To ensure rigorous and reproducible model development, all architectures underwent systematic hyperparameter optimization using the Optuna framework with Tree-structured Parzen Estimator (TPE) sampling and Hyperband pruning.³⁰ For each architecture, 100 optimization trials were conducted, with an initial random sampling phase of 15 trials to establish a diverse starting population before TPE-guided search commenced. Hyperparameter optimization was performed for each model architecture, including both architectural and training-related parameters. The complete hyperparameter search space and the optimal configurations identified for each model are summarized in Tables S4 and S5 in the Supporting Information. Each trial was evaluated using the validation mean absolute error (MAE) computed on inverse-transformed predictions to reflect true physical units. The optimal hyperparameter configuration identified for each architecture was subsequently used for the final model training.

All models were implemented in TensorFlow using the Keras API and trained with the Huber loss and Adam optimization, together with adaptive learning rate reduction and early stopping to prevent overfitting. For Data Set A1, the 51-day in-distribution data set was split chronologically into 30 days for training, 10 days for validation, and 11 days for testing. For data set B1, the 39-day data set was split into 25 days for training, 5 days for validation, and 9 days for testing. In both cases, the chronological order was preserved to maintain temporal integrity. For robust comparison, each model configuration was trained 20 times with different random initializations, and performance metrics (MAE and R²) were averaged to account for the training stochasticity. The computational requirements of each component in the proposed framework are summarized in Table S6.

2.3. Knowledge-Based Feature Selection Framework

A knowledge-based feature selection framework was applied independently to optimize the input variable space before downstream model development and hyperparameter optimization. This procedure followed a structured workflow to identify the most relevant variables for predicting N₂O emissions while balancing mechanistic understanding with statistical correlation:

1. Mechanistic Importance-Weighting

We first categorized features based on their functional roles within the biokinetic equations. Subsequently, Mechanistic Importance scores (MI-scores) were assigned to each feature according to its theoretical relevance to established mechanistic pathways, including kinetic equations and mass balance considerations (detailed in SI Section 3). These scores range from near-zero (indicating minimal relevance) to 1.0

Bộ dữ liệu B1 được thu thập tại WWTP-B trong một đợt giám sát từ tháng 10 đến tháng 11 năm 2025. Hệ thống SCADA ghi nhận nhiều biến vận hành và quy trình, bao gồm lưu lượng nước đầu vào và bùn, lưu lượng bơm RAS, tốc độ bơm tuần hoàn nội bộ (lưu lượng chu trình A), lưu lượng khí sục ở các ngăn sục khí 1–3, nồng độ oxy hòa tan trong các bể sục khí 1–3, độ pH của dòng ra khỏi bể phản ứng, nhiệt độ trong bể sục khí 1, các chỉ số nitơ (amoniac và nitrat), cùng nồng độ N₂O được đo bằng các đầu dò tại chỗ.

Dữ liệu SCADA ban đầu được ghi nhận theo các khoảng thời gian khác nhau. Để giảm độ phức tạp tính toán và nắm bắt tốt hơn các động lực học quy trình liên quan, dữ liệu SCADA từ tất cả các tập dữ liệu được lấy mẫu lại theo khoảng thời gian 15 phút bằng cách tính giá trị trung bình của từng tham số trong mỗi khoảng thời gian 15 phút.

Ngoài ra, dữ liệu lượng mưa theo giờ tương ứng với lưu vực của cả hai nhà máy xử lý nước thải được lấy từ Cổng dữ liệu CHRS (PERSIANN-CCS). Phép nội suy tuyến tính được áp dụng để đồng bộ dữ liệu lượng mưa với các mốc thời gian 15 phút của bộ dữ liệu SCADA tổng hợp, cho phép phân tích tích hợp tác động của lượng mưa đến hiệu suất xử lý và phát thải N₂O.

2.1.3. Kỹ thuật đặc trưng. Để khảo sát sâu hơn các quá trình phản ứng trung gian góp phần tạo ra N₂O, chúng tôi đã triển khai Mô hình Bùn hoạt tính - N₂O (ASM-N₂O), được hiệu chỉnh riêng cho hệ thống của chúng tôi bằng dữ liệu của 2 tuần đầu tiên.²⁶ Để ngăn rò rỉ dữ liệu vào các mô hình học sâu ở bước tiếp theo (mục 2.2), giai đoạn hiệu chỉnh chỉ sử dụng dữ liệu thuộc tập huấn luyện, bảo đảm không có thông tin nào từ tập xác thực hoặc tập kiểm tra được dùng trong quá trình hiệu chỉnh mô hình. Mô hình này tích hợp các con đường chuyển hóa sinh học và động học do Pocquet et al. mô tả về quá trình tạo N₂O qua nitrat hóa bởi vi khuẩn oxy hóa amoni (NN) và phản nitrat hóa bởi vi khuẩn nitrat hóa (ND), kết hợp với mô hình phân nitrat hóa dị dưỡng bốn bước của Hiatt và Grady.^{27,28} Mô hình được hiệu chỉnh riêng biệt bằng dữ liệu vận hành từ WWTP-A và WWTP-B, đặc biệt chú trọng đến các hồ sơ nồng độ oxy hòa tan và sự chuyển hóa các dạng nitơ. Mô hình đã hiệu chỉnh tạo ra một tập hợp toàn diện các biến trạng thái mô tả quá trình chuyển hóa nitơ sinh học, bao gồm nồng độ khí hòa tan (N₂ và N₂O), các dạng nitơ hòa tan (NH₄⁺, NH₂OH, NO, NO₂[−] và NO₃[−]), nồng độ oxy hòa tan, nồng độ cơ chất dễ phân hủy sinh học và nồng độ sinh khối (X_AOB, X_H, X_I và X_NOB). Động thái theo thời gian được mô phỏng của các biến này được trình bày trong mục 2 của SI.

2.2. Phát triển và triển khai mô hình học sâu

Để đánh giá hiệu suất cơ sở, ban đầu chúng tôi triển khai kiến trúc mạng nơ-ron bộ nhớ dài-ngắn hạn (LSTM) tiêu chuẩn, vốn đã chứng minh hiệu quả trong việc nắm bắt các mối phụ thuộc theo thời gian trong dữ liệu chuỗi thời gian môi trường.²⁹ Để đánh giá hiệu suất cơ sở, chúng tôi triển khai kiến trúc LSTM hai lớp. Mô hình cơ sở gồm hai lớp LSTM xếp chồng (mỗi lớp có 32 đơn vị), mỗi lớp được nối tiếp bằng chuẩn hóa theo lô và điều chuẩn dropout (tỷ lệ = 0.2), cùng với một lớp đầu ra dense tuyến tính ở cuối.

Dựa trên nền tảng này, chúng tôi từng bước tăng độ phức tạp của kiến trúc mô hình thông qua hai cơ chế chính:

1. Cải tiến kiến trúc:

Dựa trên mô hình cơ sở hai lớp, chúng tôi tiến hành tối ưu hóa siêu tham số một cách có hệ thống để tìm kiếm các kiến trúc có độ sâu và cấu hình khác nhau. Số lớp LSTM, số lượng đơn vị ở mỗi lớp và các tham số chính quy hóa được tối ưu hóa đồng thời bằng khung Optuna,³⁰ giúp quá trình tìm kiếm xác định kiến trúc có hiệu suất tốt nhất mà không cần thử nghiệm quá mức.

2. Mô hình LSTM chú ý:

Để nâng cao khả năng diễn giải và hiệu suất của mô hình, chúng tôi đánh giá một kiến trúc Attention–LSTM được thiết kế để nắm bắt các mối phụ thuộc phức tạp trong dữ liệu. Mô hình này áp dụng cơ chế tự chú ý đa đầu trên chiều đặc trưng trước khi

mô hình hóa theo thời gian thông qua các lớp LSTM. Bằng cách ưu tiên các đặc trưng giàu thông tin ở giai đoạn đầu của quy trình xử lý, kiến trúc này tăng cường tính linh hoạt và độ bền vững của mô hình, đặc biệt khi xử lý các tập dữ liệu có số chiều cao và phức tạp. Cơ chế này được triển khai dưới dạng các lớp tự chú ý đa đầu theo công thức { V }

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

trong đó Q , K và V lần lượt biểu thị các ma trận truy vấn, khóa và giá trị được suy ra từ các biểu diễn đầu vào. Các ma trận W_i^Q , W_i^K , W_i^V và W^O là các ma trận chiếu có thể học được, lần lượt biến đổi các biểu diễn đầu vào sang không gian truy vấn, khóa, giá trị và đầu ra.³¹

3. Mô hình CNN–LSTM:

Ngoài ra, một kiến trúc lai Mạng nơ-ron tích chập một chiều–LSTM (CNN-LSTM) cũng đã được đánh giá. Thành phần CNN áp dụng các bộ lọc tích chập theo thời gian để trích xuất các mẫu cục bộ trong phạm vi ngắn từ chuỗi đầu vào, sau đó các lớp LSTM nắm bắt những mối phụ thuộc dài hạn từ các biểu diễn cô đọng này. Chiến lược trích xuất đặc trưng phạm vi ngắn này đã được chứng minh là cải thiện hiệu suất dự đoán trong các tác vụ chuỗi thời gian đa biến.³²

Để đảm bảo quá trình phát triển mô hình nghiêm ngặt và có thể tái lập, tất cả các kiến trúc đều trải qua quá trình tối ưu hóa siêu tham số một cách có hệ thống bằng khung Optuna, sử dụng phương pháp lấy mẫu Tree-structured Parzen Estimator (TPE) và cắt tỉa Hyperband.³⁰ Với mỗi kiến trúc, 100 lượt thử tối ưu hóa đã được thực hiện; trong đó, 15 lượt đầu tiên lấy mẫu ngẫu nhiên nhằm tạo ra một quần thể khởi đầu đa dạng trước khi bắt đầu quá trình tìm kiếm theo hướng dẫn của TPE. Việc tối ưu hóa siêu tham số được thực hiện cho từng kiến trúc mô hình, bao gồm cả các tham số liên quan đến kiến trúc và quá trình huấn luyện. Không gian tìm kiếm siêu tham số đầy đủ và các cấu hình tối ưu được xác định cho từng mô hình được tóm tắt trong Bảng S4 và S5 của Tài liệu bổ trợ. Mỗi lượt thử được đánh giá bằng sai số tuyệt đối trung bình (MAE) trên tập xác thực, tính từ các dự đoán đã được biến đổi ngược để phản ánh đơn vị vật lý thực. Cấu hình siêu tham số đã được chọn được trình bày trong SI. Tất cả các mô hình đều được triển khai bằng TensorFlow và Keras, sử dụng các thư viện và hàm vật lý nhất quán để mô phỏng quá trình chuyển hóa nitơ sinh học. Phương pháp tối ưu hóa Adam, kết hợp với cơ chế giảm tốc độ học thích ứng và dừng sớm để ngăn hiện tượng quá khớp. Đối với Tập dữ liệu A1, tập dữ liệu 51 ngày được phân phối thời gian theo trình tự thời gian thành 30 ngày huấn luyện, 10 ngày xác thực và 11 ngày kiểm thử. Đối với Tập dữ liệu B1, tập dữ liệu 39 ngày được chia thành 25 ngày huấn luyện, 5 ngày xác thực và 9 ngày kiểm thử. Trong cả hai trường hợp, thứ tự thời gian được giữ nguyên để đảm bảo tính toàn vẹn theo thời gian. Để so sánh đáng tin cậy, mỗi cấu hình mô hình được huấn luyện 20 lần với các khởi tạo ngẫu nhiên khác nhau; các chỉ số hiệu suất (MAE và R²) được tính trung bình để tính đến tính ngẫu nhiên trong quá trình huấn luyện. Yêu cầu tính toán của từng kiến trúc phản ánh mức độ phức tạp của mô hình. Bảng S6 cung cấp các chi tiết về cấu trúc và các tham số huấn luyện. Yêu cầu tính toán của từng kiến trúc phản ánh mức độ phức tạp của mô hình. Bảng S6 cung cấp các chi tiết về cấu trúc và các tham số huấn luyện.

1. Gán trọng số mức độ quan trọng theo cơ chế

Trước tiên, chúng tôi phân loại các đặc trưng dựa trên vai trò chức năng của chúng trong các phương trình động học sinh học. Sau đó, điểm Mức độ quan trọng về cơ chế (điểm MI) được gán cho từng đặc trưng theo mức độ liên quan về mặt lý thuyết với các con đường cơ chế đã được xác lập, bao gồm các phương trình động học và các cân nhắc về cân bằng khối lượng (trình bày chi tiết trong Mục 3 của SI). Các điểm này nằm trong khoảng từ gần bằng không (cho biết mức độ liên quan thấp) đến gần bằng 1.0 (cho biết mức độ liên quan cao).

(indicating maximum relevance) and reflect the theoretical contribution of each variable to N₂O production as informed by well-established biochemical reaction mechanisms.

2. Process Group Categorization

Features were grouped into functional categories corresponding to their biological roles in the nitrogen removal processes. The AOB pathway includes ammonia, hydroxylamine, nitrite, and relevant autotrophic biomass concentrations; the NOB pathway includes nitrite, nitrate, and NOB biomass concentrations; heterotrophic denitrification includes nitrogen oxides and heterotrophic biomass concentrations; and other parameters include operational controls, real-time sensors, and weather-related variables.

3. Temporal Correlation Analysis

A time-matching correlation analysis was conducted using the ccf (cross-correlation function) from the statsmodels.tsa.s-tattools python package, which computes Pearson correlation coefficients between two time series at multiple time lags. For each process variable (e.g., dissolved oxygen, influent ammonia concentrations), we calculated cross-correlations with N₂O emissions over a ± 4 -h window using 15 min resolution data. This enabled identification of leading or lagging relationships, indicating whether changes in a feature tend to precede or follow N₂O fluctuations. The maximum absolute correlation within this window was recorded as the Statistical Correlation score (SC-score), representing the temporal predictive strength of each variable.

4. Redundancy Elimination

A feature similarity matrix was constructed by calculating pairwise time-matching Pearson correlation coefficients between normalized feature time series. Features were also grouped by shared process roles (e.g., nitrogen transformation or aeration control), and intragroup pairs were assigned elevated similarity scores to account for functional redundancy.

5. Final Feature Selection

Features were ranked based on a weighted combination of their SC and MI scores. Prior to combination, both scores were linearly normalized to a common scale to ensure a comparability.

Combined Score = SC-score + MI-score

Redundant features (similarity > 0.85) were removed iteratively, retaining the feature with the higher combined score. The threshold of 0.85 was selected as a conservative cutoff to capture strong interfeature redundancy and may be adjusted depending on data characteristics.

For comparison, LASSO regularization and SHAP-based feature importance analyses were independently applied as benchmark feature selection methods. Detailed procedures and results are provided in section 7 of the [Supporting Information](#).

2.4. LLM-RAG Feature Selection Framework

To support feature evaluation and selection for the data-driven modeling, a RAG framework was implemented to integrate domain knowledge from scientific literature with the operational data set. The framework was built using the PaperQA library,^{33–35} which enables large language models to retrieve and reason over indexed research documents. Three LLMs were used as the question-answering models in the RAG framework, representing different architectures, training methodologies, and knowledge cutoff dates, as summarized in [Table 2](#).

A local corpus of wastewater treatment and N₂O emission studies, including 520 N₂O-related articles from leading journals, was compiled and indexed using vector embeddings generated with the OpenAI text-embedding-3-small model, enabling a semantic similarity search across the literature database. For reasoning and response generation, a multi-LLM framework incorporating GPT-5.2, Claude Sonnet 4.6, and Gemini 2.5 Flash models was employed to leverage complementary reasoning capabilities across different architectures.

Table 2. Summary of LLMs with Corresponding Developers and Knowledge Cutoffs

Model	Developer	Knowledge Cutoff
GPT-5.2	OpenAI	December 2025
Gemini 2.5 Flash	Google	June 2025
Claude 4.6 Sonnet	Anthropic	February 2026

When the feature selection query (provided in the [Supporting Information](#)) together with the anonymized data set was submitted to the framework, the system first interpreted the data set through structured summaries, including feature descriptions, statistical characteristics, missing-value analysis, and correlations between process variables and the target variable (N₂O concentration). Prior to submission, all plant-identifying information, site names, and operationally sensitive metadata were removed from the data set to ensure data confidentiality. Relevant passages were then retrieved from the indexed literature corpus to provide an additional domain knowledge.

On the basis of the combined data set context and retrieved literature information, the framework generated the final feature selection results, which were subsequently used as inputs to the trained predictive model.

3. RESULTS AND DISCUSSION

3.1. Deeper and Attention-Based Models Improve Accuracy but Show Limited Generalizability

To systematically evaluate modeling options under the “small-sample, high-dimensional” setting (sample-to-feature ratio $\approx$ 76:1), two widely adopted strategies were examined: (1) searching for deeper architectures capable of capturing temporal dynamics and (2) incorporating attention mechanisms.

In the initial experiments, a two-layer LSTM was employed for prediction, but its performance was limited, achieving a mean test MAE of 0.0665 (σ = 0.0110) and a mean R² of 0.119 across 20 runs. A CNN–LSTM hybrid was also evaluated but yielded only marginal improvement (MAE = 0.0599, R² = 0.206) and was not pursued further. To assess whether deeper architecture could better capture temporal patterns, we conducted a systematic hyperparameter search over key architectural and training parameters, with regularization applied to mitigate overfitting under limited samples. The resulting five-layer LSTM achieved a mean test MAE of 0.0567 (σ = 0.0065) and a mean R² of 0.2263 (σ = 0.1843), a modest improvement over the two-layer baseline (0.0665). Incorporating attention mechanisms led to further improvements. Two variants were examined: Attention-LSTM, which employs feature-wise attention to reweight input features before sequential processing, and LSTM-Attention, which applies temporal attention after LSTM-based temporal encoding. Attention-LSTM achieves a mean test MAE of 0.0326 (R² = 0.712), outperforming LSTM-Attention (MAE = 0.0478, R² = 0.465) by 31.8%.

These results show that all evaluated model variants, including deeper LSTM, LSTM-attention, and attention-LSTM, improve predictive performance relative to the baseline. The performance gain observed in the five-layer LSTM may be attributed to its enhanced capacity to capture longer-range temporal dependencies, which has been reported in prior studies on recurrent architectures.³⁶ In contrast, the two attention variants provide a controlled comparison that isolates the effect of the attention placement. The observed performance difference between Attention-LSTM and LSTM-

(chỉ mức độ liên quan tối đa) và phản ánh đóng góp về mặt lý thuyết của từng biến số vào quá trình sản sinh N₂O, dựa trên các cơ chế phản ứng sinh hóa của quá trình này.

2.

Các đặc trưng được nhóm thành các loại chức năng tương ứng với vai trò sinh học của chúng trong các quá trình loại bỏ nitơ. Con đường AOB bao gồm nồng độ amoniac, hydroxylamin, nitrit và sinh khối tự dưỡng có liên quan; con đường NOB bao gồm nồng độ nitrit, nitrat và sinh khối NOB; quá trình khử nitrat dị dưỡng bao gồm nồng độ các oxit nitơ và sinh khối dị dưỡng; các thông số khác bao gồm các yếu tố kiểm soát vận hành, cảm biến thời gian thực và các biến liên quan đến thời tiết.

3. Phân tích tương quan theo thời gian

Phân tích tương quan khớp thời gian được thực hiện bằng ccf (hàm tương quan chéo) từ gói Python statsmodels.tsa.stattools, dùng để tính hệ số tương quan Pearson giữa hai chuỗi thời gian tại nhiều độ trễ khác nhau. Với mỗi biến quy trình (ví dụ: oxy hòa tan, nồng độ amoni trong dòng vào), chúng tôi tính tương quan chéo với lượng phát thải N₂O trong cửa sổ ± 4 giờ, sử dụng dữ liệu có độ phân giải 15 phút. Phương pháp này giúp xác định các mối quan hệ đi trước hoặc trễ theo sau, cho biết liệu những thay đổi của một đặc trưng có xu hướng xảy ra trước hay sau các dao động của N₂O. Giá trị tương quan tuyệt đối lớn nhất trong cửa sổ này được ghi nhận là điểm Tương quan Thống kê (SC-score), đại diện cho sức mạnh dự báo theo thời gian của từng biến.

4.

Ma trận độ tương đồng đặc trưng được xây dựng bằng cách tính các hệ số tương quan Pearson ghép cặp theo thời gian giữa các chuỗi thời gian đặc trưng đã được chuẩn hóa. Các đặc trưng cũng được nhóm theo vai trò quy trình chung (ví dụ: chuyển hóa nitơ hoặc điều khiển sục khí), và các cặp trong cùng nhóm được gán điểm tương đồng cao hơn để phản ánh tính tương tự về chức năng.

Các đặc trưng được xếp hạng dựa trên tổ hợp có trọng số giữa điểm SC và MI. Trước khi kết hợp, cả hai điểm số đều được chuẩn hóa tuyến tính về cùng một thang đo để đảm bảo khả năng so sánh.

Điểm tổng hợp Điểm SC Điểm MI

Các đặc trưng dư thừa (độ tương đồng > 0.85) được loại bỏ theo từng vòng lặp, giữ lại đặc trưng có điểm tổng hợp cao hơn. Ngưỡng 0.85 được chọn làm mức cắt thận trọng để phát hiện sự dư thừa đáng kể giữa các đặc trưng và có thể được điều chỉnh tùy theo đặc điểm của dữ liệu.

Để so sánh, phương pháp điều chuẩn LASSO và các phân tích mức độ quan trọng của đặc trưng dựa trên SHAP được áp dụng độc lập làm các phương pháp lựa chọn đặc trưng đối chuẩn. Quy trình và kết quả chi tiết được trình bày trong mục 7 của Thông tin bổ trợ.

2.4. Khung lựa chọn đặc trưng LLM-RAG

Để hỗ trợ đánh giá và lựa chọn đặc trưng cho mô hình hóa dựa trên dữ liệu, một khung RAG đã được triển khai nhằm tích hợp kiến thức chuyên ngành từ các tài liệu khoa học với bộ dữ liệu vận hành. Khung này được xây dựng bằng thư viện PaperQA,^{33–35} cho phép các mô hình ngôn ngữ lớn truy xuất và suy luận trên các tài liệu nghiên cứu đã được lập chỉ mục. Ba LLM được sử dụng làm mô hình hỏi đáp trong khung RAG, đại diện cho các kiến trúc, phương pháp huấn luyện và mốc thời gian giới hạn kiến thức khác nhau, như được tóm tắt trong Bảng 2.

Một kho ngữ liệu nội bộ về xử lý nước thải và các nghiên cứu phát thải N₂O, bao gồm 520 bài báo liên quan đến N₂O đăng trên các tạp chí hàng đầu, đã được biên soạn và lập chỉ mục bằng các vector embedding được tạo bằng mô hình OpenAI text-embedding-3-small, cho phép tìm kiếm độ tương đồng ngữ nghĩa trong cơ sở dữ liệu tài liệu. Để suy luận và tạo phản hồi, một khuôn khổ đa LLM kết hợp các mô hình GPT-5.2, Claude Sonnet 4.6 và Gemini 2.5 Flash đã được sử dụng nhằm khai thác các năng lực suy luận bổ trợ lẫn nhau giữa những kiến trúc khác nhau.

Bảng 2. Tóm tắt các LLM cùng nhà phát triển tương ứng và mốc giới hạn kiến thức

Model	Developer	Knowledge Cutoff
GPT-5.2	OpenAI	December 2025
Gemini 2.5 Flash	Google	June 2025
Claude 4.6 Sonnet	Anthropic	February 2026

Khi truy vấn lựa chọn đặc trưng (được cung cấp trong Tài liệu bổ trợ) cùng với tập dữ liệu đã được ẩn danh được gửi đến khuôn khổ, hệ thống trước tiên diễn giải tập dữ liệu thông qua các bản tóm tắt có cấu trúc, bao gồm mô tả đặc trưng, đặc tính thống kê, phân tích giá trị khuyết và mối tương quan giữa các biến quy trình với biến mục tiêu (nồng độ N₂O). Trước khi gửi, mọi thông tin có thể nhận diện nhà máy, tên địa điểm và siêu dữ liệu nhạy cảm về vận hành đều được xóa khỏi tập dữ liệu để bảo mật tính bảo mật của dữ liệu. Sau đó, các đoạn nội dung liên quan được truy xuất từ kho tài liệu đã lập chỉ mục nhằm bổ sung kiến thức chuyên môn trong lĩnh vực.

Dựa trên ngữ cảnh của tập dữ liệu tổng hợp và thông tin tài liệu được truy xuất, khung này đã tạo ra kết quả lựa chọn đặc trưng cuối cùng, sau đó được sử dụng làm đầu vào cho mô hình dự đoán đã huấn luyện.

3. KẾT QUẢ VÀ THẢO LUẬN

3.1. Các mô hình sâu hơn và dựa trên cơ chế chú ý cải thiện độ chính xác nhưng cho thấy khả năng khai quá tải còn hạn chế. Để đánh giá một cách có hệ thống các lựa chọn mô hình trong bối cảnh “mẫu nhỏ, số chiều cao” (tỷ lệ mẫu trên đặc trưng $\approx$ 76:1), chúng tôi đã xem xét hai chiến lược được áp dụng rộng rãi: (1) tìm kiếm các kiến trúc sâu hơn có khả năng nắm bắt động lực học theo thời gian và (2) tích hợp các cơ chế chú ý.

Trong các thí nghiệm ban đầu, mô hình LSTM hai lớp được sử dụng để dự đoán, nhưng hiệu suất còn hạn chế, với MAE kiểm tra trung bình đạt 0.0665 (σ = 0.0110) và R² trung bình đạt 0.119 qua 20 lần chạy. Mô hình lai CNN–LSTM cũng được đánh giá nhưng chỉ cải thiện đôi chút (MAE = 0.0599, R² = 0.206) nên không được nghiên cứu thêm. Để đánh giá liệu kiến trúc sâu hơn có thể nắm bắt các mẫu theo thời gian tốt hơn hay không, chúng tôi tiến hành tìm kiếm siêu tham số có hệ thống trên các tham số kiến trúc và huấn luyện then chốt, đồng thời áp dụng điều chuẩn để giảm thiểu hiện tượng quá khớp khi số lượng mẫu còn hạn chế. Mô hình LSTM năm lớp đạt MAE kiểm tra trung bình 0.0567 (σ = 0.0065) và R² trung bình 0.2263 (σ = 0.1843), cải thiện đáng kể so với mô hình cơ sở hai lớp (0.0665). Việc tích hợp các cơ chế chú ý giúp cải thiện thêm. Hai biến thể đã được khảo sát: Attention-LSTM, sử dụng cơ chế chú ý theo từng đặc trưng để điều chỉnh trọng số của các đặc trưng đầu vào trước khi xử lý tuần tự, và LSTM-Attention, áp dụng cơ chế chú ý theo thời gian sau khi mã hóa chuỗi thời gian bằng LSTM. Attention-LSTM đạt MAE kiểm tra trung bình 0.0326 (R² = 0.712), vượt trội hơn LSTM-Attention (MAE = 0.0478, R² = 0.465) đến 31,8%, bao gồm LSTM sâu hơn, LSTM-attention và attention-LSTM, đều cải thiện hiệu suất dự đoán so với mô hình cơ sở. Mức tăng hiệu suất quan sát được ở LSTM năm lớp có thể là nhờ khả năng nắm bắt các phụ thuộc thời gian ở khoảng cách xa được nâng cao, như đã được bảo đảm trong các nghiên cứu trước đây về kiến trúc hồi quy.³⁶ Ngược lại, hai biến thể attention cung cấp một phép so sánh có kiểm soát, qua đó cô lập tác động của vị trí đặt cơ chế attention. Chênh lệch hiệu suất quan sát được giữa Attention-LSTM và LSTM-





Figure 1. Model performance comparison under small-sample, high-dimensional conditions. (a) Test MAE distributions show progressive improvement from the baseline LSTM to deeper and attention-based models, with Attention-LSTM achieving the lowest error and variance. (b) Training–validation comparison indicates reduced error but increased overfitting in higher-capacity models. (c) Under in-distribution conditions (July), Attention-LSTM best captures N_2O dynamics. (d) Under distributional shift (August high-flow), all models degrade markedly, failing to reproduce observed variability.

Attention suggests that the stage at which attention is applied influences how feature information is extracted and used. Reweighting inputs prior to sequential processing appears more effective than applying attention to already encoded representations, indicating that the quality and relevance of input features may play a particularly important role in this setting. This is consistent with findings in high-dimensional time series modeling, where input feature quality has been shown to substantially affect model performance, and where early stage feature weighting has been found to improve information utilization under limited sample conditions.^{31,37}

Despite these improvements in test performance, their robustness remains uncertain. As shown in Figure 1b, all architectures exhibit overfitting to varying degrees, with validation-to-training MAE ratios ranging from 1.26x (LSTM-5-Layers) to 1.66x (Attention-LSTM), indicating that the gap between training and validation performance persists across all evaluated configurations. To further assess generalization under distributional shift, models were evaluated on an out-of-distribution data set collected during a high-flow

period in August, one month after the training and validation period, when the influent flow rate (64.04 L/s) substantially exceeds the training mean (52.71 L/s). As shown in Figure 1d, all architectures fail markedly under these conditions, with R^2 values turning negative across all models (Baseline: -0.017 , LSTM-5-Layers: -0.084 , LSTM-Attention: -0.199 , Attention-LSTM: -0.087) and MAE values substantially exceeding those observed in July. This collapse in performance indicates that the high-flow event introduces feature combinations that are underrepresented in the training data, forcing the model to extrapolate beyond the learned feature distribution and disrupting the learned input–output relationships. Similar behavior has been reported in data-driven hydrological modeling and sequence learning tasks under distributional shift.^{38,39} The strong in-distribution performance of Attention-LSTM may therefore partly reflect overfitting to the statistical characteristics of the July period rather than robust generalization.⁴⁰

Taken together, these results indicate that while increasing model depth and incorporating attention mechanisms can



Hình 1. So sánh hiệu năng mô hình trong điều kiện mẫu nhỏ, số chiều cao. (a) Phân bố MAE trên tập kiểm tra cho thấy sự cải thiện dần từ LSTM cơ sở đến các mô hình sâu hơn và dựa trên cơ chế chú ý; Attention-LSTM đạt sai số và phương sai thấp nhất. (b) So sánh giữa huấn luyện–thăm định cho thấy sai số giảm nhưng hiện tượng quá khớp tăng ở các mô hình có năng lực cao hơn. (c) Trong điều kiện cùng phân phối (tháng 7), Attention-LSTM mô phỏng tốt nhất động thái N_2O . (d) Khi phân phối thay đổi (lưu lượng cao trong tháng 8), hiệu năng của tất cả mô hình đều suy giảm rõ rệt, không tái hiện được mức độ biến thiên quan sát được.

Cơ chế chú ý cho thấy giai đoạn áp dụng chú ý ảnh hưởng đến cách thông tin đặc trưng được trích xuất và sử dụng. Việc tái trọng số các đầu vào trước khi xử lý tuần tự có vẻ hiệu quả hơn so với áp dụng chú ý lên các biểu diễn đã được mã hóa, cho thấy chất lượng và mức độ liên quan của các đặc trưng đầu vào có thể đóng vai trò đặc biệt quan trọng trong bối cảnh này. Điều này phù hợp với các phát hiện trong mô hình hóa chuỗi thời gian nhiều chiều, nơi chất lượng đặc trưng đầu vào được chứng minh là ảnh hưởng đáng kể đến hiệu suất mô hình, và việc giảm trọng số cho đặc trưng ở giai đoạn sớm được nhận thấy là cải thiện khả năng khai thác thông tin từ các biểu diễn sâu hơn. Tuy nhiên, việc cải thiện này chỉ xảy ra trong các mô hình vẫn chưa chắc chắn. Như thể hiện trong Hình 1b, tất cả các kiến trúc đều có dấu hiệu quá khớp ở các mức độ khác nhau, với tỷ lệ MAE giữa tập kiểm tra và tập huấn luyện dao động từ 1.26x (LSTM-5-Layers) đến 1.66x (Attention-LSTM), cho thấy khoảng cách về hiệu suất giữa huấn luyện và xác thực vẫn tồn tại ở tất cả các cấu hình được đánh giá. Để đánh giá thêm khả năng khái quát hóa khi phân phối dữ liệu thay đổi, các mô hình được đánh giá trên một tập dữ liệu ngoài phân phối được thu thập trong giai đoạn lưu lượng cao.

giai đoạn tháng 8, một tháng sau giai đoạn huấn luyện và xác thực, khi lưu lượng dòng vào (64.04 L/s) vượt đáng kể mức trung bình của tập huấn luyện (52.71 L/s). Như thể hiện trong Hình 1d, tất cả các kiến trúc đều suy giảm rõ rệt trong những điều kiện này, với các giá trị R^2 chuyển sang âm ở tất cả các mô hình (Baseline: -0.017 , LSTM-5-Layers: -0.084 , LSTM-Attention: -0.199 , Attention-LSTM: -0.087) và các giá trị MAE cao hơn đáng kể so với tháng 7. Sự sụp đổ về hiệu suất này cho thấy sự kiện lưu lượng cao tạo ra các tổ hợp đặc trưng ít xuất hiện trong dữ liệu huấn luyện, buộc mô hình phải ngoại suy vượt ra ngoài phân phối đặc trưng đã học và làm giảm độ tin cậy của các dự đoán. Hành vi tương tự đã được ghi nhận trong các bài toán mô hình hóa thủy văn dựa trên dữ liệu và học có hướng khi có dịch chuyển phân phối.^{38,39} Do đó, hiệu suất cao của Attention-LSTM trên dữ liệu cùng phân phối có thể phản ánh ảnh hưởng quá khớp với các đặc tính thống kê của giai đoạn tháng 7, thay vì khả năng khái quát hóa vững chắc.⁴⁰

Nhìn chung, những kết quả này cho thấy rằng mặc dù việc tăng độ sâu của mô hình và tích hợp các cơ chế chú ý có thể




Figure 2. Knowledge-based feature selection framework for N₂O emissions prediction: (a) Schematic overview of the proposed framework, integrating mechanistic importance and statistical correlation to reduce 52 candidate features to a final selected subset for input to the pretrained LSTM model; (b) Similarity matrix of monitored parameters showing correlation patterns. (c) Statistical correlation vs mechanistic importance scores for different parameter categories; dashed line indicates equal contribution from both.


improve predictive accuracy, they also introduce challenges such as overfitting under limited data. A likely contributing factor is the high sample-to-feature ratio ($\approx 76:1$), under which it becomes difficult to reliably identify and prioritize informative features. As a result, the model may learn spurious patterns rather than stable relationships, leading to reduced robustness, particularly under distributional shift. These findings suggest that further gains are unlikely to be achieved through architectural modifications alone. Instead, improving the quality of the input space, by reducing feature redundancy and enhancing the signal-to-noise ratio, may be essential for achieving stable and generalizable performance across varying operating conditions.

3.2. Expert-Guided Feature Selection Improves Accuracy and Generalizability

To address the generalization limitations identified in section 3.1, we developed a knowledge-based feature selection approach that simultaneously incorporates statistical correlation and mechanistic importance to reduce the input feature space (Figure 2a). As shown in Figure 2c, our analysis revealed several features with a high statistical correlation to Tank 3 N₂O emissions. The top statistically correlated features

included NO-tank3 (1.0), N₂-tank1 (0.983), and NO-tank2 (0.982). These strong correlations can be partially explained by the fact that nitric oxide is a direct biochemical precursor of N₂O in both nitrifier and heterotrophic denitrification pathways, while N₂ levels often reflect the extent of denitrification and may covary with intermediate gases under transient conditions.

However, statistical correlation primarily reflects direct linear relationships among observable variables and is often susceptible to data-collection noise and sample-distribution biases. Therefore, we incorporated the mechanistic importance as a complementary selection criterion. Mechanistic importance, grounded in process knowledge, captures both causal and indirect relationships within the system. Interestingly, some features demonstrated high mechanistic importance, despite moderate statistical correlations. For instance, InflowRate, N₂O-Tank3 (simulated N₂O concentration), and Aeration Power2 all received maximum mechanistic importance scores (1.0), suggesting their significance in N₂O production pathways according to the process understanding. The high mechanistic importance of InflowRate can be attributed to its direct influence on the hydraulic retention



Hình 2. Khung lựa chọn đặc trưng dựa trên tri thức để dự đoán phát thải N₂O: (a) Tổng quan sơ đồ về khung đề xuất, kết hợp tầm quan trọng theo cơ chế và tương quan thống kê để rút gọn 52 đặc trưng ứng viên thành tập con được chọn cuối cùng làm đầu vào cho mô hình LSTM đã tiền huấn luyện; (b) Ma trận độ tương đồng của các thông số được giám sát, thể hiện các kiểu tương quan. (c) Điểm tương quan thống kê so với điểm tầm quan trọng theo cơ chế của các nhóm thông số khác nhau; đường nét đứt biểu thị mức đóng góp bằng nhau của cả hai.

cải thiện độ chính xác dự đoán, chúng cũng làm phát sinh những thách thức như quá khớp khi dữ liệu hạn chế. Một yếu tố có khả năng góp phần là tỷ lệ mẫu trên đặc trưng cao ($\approx 76:1$), khiến việc xác định và ưu tiên các đặc trưng giàu thông tin một cách đáng tin cậy trở nên khó khăn. Do đó, mô hình có thể học các quy luật giả thay vì các mối quan hệ ổn định, làm giảm độ bền vững, đặc biệt khi phân phối dữ liệu thay đổi. Những phát hiện này cho thấy khó có thể đạt được thêm cải thiện chỉ bằng cách điều chỉnh kiến trúc. Thay vào đó, nâng cao chất lượng không gian đầu vào bằng cách giảm sự dư thừa giữa các đặc trưng và cải thiện tỷ lệ tín hiệu trên nhiễu có thể là điều thiết yếu để đạt được hiệu năng ổn định và khả năng khái quát hóa trong các điều kiện vận hành khác nhau.

Để giải quyết những hạn chế về khả năng khái quát hóa được nêu trong mục 3.1, chúng tôi đã phát triển một phương pháp lựa chọn đặc trưng dựa trên tri thức, đồng thời kết hợp tương quan thống kê và mức độ quan trọng về mặt cơ chế nhằm thu hẹp không gian đặc trưng đầu vào (Hình 2a). Như thể hiện trong Hình 2c, phân tích của chúng tôi cho thấy một số đặc trưng có tương quan thống kê cao với lượng phát thải N₂O ở Bể 3. Các đặc trưng có tương quan thống kê cao nhất

bao gồm NO-tank3 (1.0), N₂-tank1 (0.983) và NO-tank2 (0.982). Những mối tương quan mạnh này có thể được giải thích một phần bởi việc oxy nitric là tiền chất sinh hóa trực tiếp của N₂O trong cả các con đường khử nitrat hóa do vi khuẩn nitrat hóa và dị dưỡng thực hiện, trong khi nồng độ N₂ thường phản ánh mức độ khử nitrat hóa và có thể biến thiên đồng thời với các khí trung gian trong điều kiện nhất định. Tuy nhiên, tương quan thống kê chủ yếu phản ánh các mối quan hệ tuyến tính trực tiếp giữa những biến quan sát được và thường dễ bị ảnh hưởng bởi nhiễu trong quá trình thu thập dữ liệu cũng như sai lệch trong phân bố mẫu. Do đó, chúng tôi đưa tầm quan trọng cơ chế vào làm tiêu chí lựa chọn bổ sung. Tầm quan trọng cơ chế, dựa trên kiến thức về quy trình, nắm bắt cả các mối quan hệ nhân quả lẫn gián tiếp trong hệ thống. Điều thú vị là một số đặc trưng thể hiện tầm quan trọng cơ chế cao dù chỉ có tương quan thống kê ở mức vừa phải. Chẳng hạn, InflowRate, N₂O-Tank3 (nồng độ N₂O mô phỏng) và Aeration Power2 đều đạt điểm tầm quan trọng cơ chế tối đa (1.0), cho thấy chúng có ý nghĩa trong các con đường tạo N₂O theo hiểu biết về quy trình. Tầm quan trọng cơ chế cao của InflowRate có thể được lý giải bởi ảnh hưởng trực tiếp của nó đến thời gian lưu thủy lực




Figure 3. Performance of feature-selected LSTM models for N_2O prediction: (a) measured vs predicted time series under in-distribution conditions (July) for baseline and tuned models; (b) same comparison for the SHAP-selected tuned model; (c) MAE distribution across 20 runs as a function of model size; (d) overfitting analysis based on training and validation MAE and their ratio; (e) performance under out-of-distribution conditions (August high-flow). FS-basic-LSTM: 2-layer basic LSTM model with selected features as input; FS-tuned-LSTM: hyperparameter-tuned 1-layer LSTM model with selected features as input.

time and substrate availability, while Aeration Power2 controls dissolved oxygen levels that significantly impact nitrification and denitrification rates.


To mitigate feature redundancy and avoid multicollinearity, parameter instability, and reduced generalizability, we performed a similarity analysis of the normalized feature time series (Figure 2b). Specifically, we observed that several features, such as NH_4^+ -Tank1 and NH_4^+ -Tank2, exhibited near-identical temporal patterns after normalization. This pattern similarity likely arises from their shared mechanistic roles in the nitrification process, where NH_4^+ concentrations are governed by similar operational conditions (e.g., inflow ammonia concentration, aeration intensity). This type of redundancy, if left unaddressed, can introduce instability in model training and reduce generalization performance.⁴¹ We defined a similarity threshold of 0.85 using Pearson's correlation. Features exceeding this threshold were considered redundant, and we retained the one with the higher combined statistical and mechanistic score. For example, NH_4^+ -Tank2 was removed due to high similarity (0.906) with NH_4^+ -Tank1, and NO_2^- -Tank3 was excluded due to overlap with N_2O -Tank3 (similarity score: 0.865).

After evaluating multiple sample-to-feature ratios and testing feature subsets of varying sizes, we ultimately selected seven features: inflow rate, N_2O -tank3, aeration power2, NH_4^+ -tank1, WAS flow, COD-tank2, and NO_2^- -tank2. These features collectively represent the core operational controls, nitrogen transformation indicators, and organic loading conditions relevant to N_2O dynamics. InflowRate, Aeration Power2, and WAS flow reflect key process operations; NH_4^+ -Tank1 and NO_2^- -Tank2 capture critical steps in nitrification and

denitrification; COD-Tank2 serves as a proxy for organic carbon availability governing denitrification; and N_2O -Tank3 acts as a direct proxy for the target variable in prediction. This selection balances mechanistic relevance and statistical efficiency while reducing redundancy.

To further evaluate the effectiveness of the proposed feature selection strategy, the reduced feature subset was first applied with the basic 2-layer LSTM model structure (FS-basic-LSTM) introduced in Section 3.1. The FS-basic-LSTM trained on the selected features achieves strong predictive performance under in-distribution conditions, with a mean test MAE of 0.0367 ($\sigma = 0.0032$) and a mean R^2 of 0.6919. This represents a significant improvement over the baseline model ($p < 0.001$), the five-layer LSTM model ($p < 0.001$), and the LSTM-Attention model ($p < 0.001$) (Table S7). The R^2 is comparable to that of the Attention-LSTM, with no statistic difference. In the best-performing run, the model achieves an R^2 of 0.77, exceeding the best result obtained by the Attention-LSTM.

Using the same hyperparameter search strategy as in Section 3.1, model architecture optimization was further conducted on the selected feature set. Notably, the optimal configuration corresponds to a relatively straightforward 1-layer architecture (FS-tuned-LSTM). After tuning, the model exhibits improved stability but only marginal gains in predictive accuracy (mean MAE = 0.0330, $\sigma = 0.0015$; mean $R^2 = 0.7225$). Both feature-selected models, as shown in Figure 3a, more effectively capture the diurnal patterns of N_2O emissions compared to their full-feature counterparts. This improvement can be attributed to the reduction of multicollinearity and noise in the input space.⁴² Besides, the selected feature subset retained stable predictive performance across LSTM architectures with



Hình 3. Hiệu suất của các mô hình LSTM lựa chọn đặc trưng trong dự báo N_2O : (a) chuỗi thời gian đo được so với dự báo ở trong điều kiện cùng phân phối (tháng 7) đối với các mô hình cơ sở và mô hình được tinh chỉnh; (b) so sánh tương tự đối với mô hình được tinh chỉnh và lựa chọn bằng SHAP; (c) phân phối MAE qua 20 lần chạy theo kích thước mô hình; (d) phân tích quá khớp dựa trên MAE của tập huấn luyện và tập xác thực cùng tỷ số giữa chúng; (e) hiệu suất trong điều kiện khác phân phối (lưu lượng cao tháng 8). FS-basic-LSTM: mô hình LSTM cơ bản 2 lớp, nhận các đặc trưng đã chọn làm đầu vào; FS-tuned-LSTM: mô hình LSTM 1 lớp được tinh chỉnh siêu tham số, nhận các đặc trưng đã chọn làm đầu vào.

thời gian và lượng giá thể sẵn có, trong khi Công suất sức khí² kiểm soát nồng độ oxy hòa tan, yếu tố ảnh hưởng đáng kể đến tốc độ nitrat hóa và khử nitrat.

Để giảm thiểu sự dư thừa đặc trưng và tránh hiện tượng đa cộng tuyến, tính bất ổn của tham số và khả năng khái quát hóa suy giảm, chúng tôi đã phân tích mức độ tương đồng của các chuỗi thời gian đặc trưng đã chuẩn hóa (Hình 2b). Cụ thể, chúng tôi nhận thấy một số đặc trưng, chẳng hạn như NH_4^+ -Tank1 và NH_4^+ -Tank2, có các dạng biến thiên theo thời gian gần như giống hệt nhau sau khi chuẩn hóa. Sự tương đồng về dạng biến thiên này có thể bắt nguồn từ vai trò cơ chế chung của chúng trong quá trình nitrat hóa, trong đó nồng độ NH_4^+ được chi phối bởi các điều kiện vận hành tương tự (ví dụ: nồng độ amoniac đầu vào, cường độ sức khí). Nếu không được xử lý, dạng dư thừa này có thể gây bất ổn trong quá trình huấn luyện mô hình và làm giảm hiệu suất khái quát hóa.⁴¹ Chúng tôi xác định ngưỡng tương đồng là 0.85 dựa trên hệ số tương quan Pearson. Các đặc trưng vượt ngưỡng này được xem là dư thừa, và chúng tôi giữ lại đặc trưng có điểm m tổng hợp thống kê và cơ chế cao hơn. Ví dụ, NH_4^+ -Tank2 bị loại bỏ do có mức tương đồng cao (0.906) với NH_4^+ -Tank1, còn NO_2^- -Tank3 bị loại trừ do trùng lặp với N_2O -Tank3 (điểm tương đồng: 0.865).

Sau khi loại bỏ các đặc trưng dư thừa dựa trên ngưỡng 0.85, chúng tôi đã tiến hành phân tích tương quan chéo để kiểm tra các tập con đặc trưng có kích thước khác nhau, cuối cùng chúng tôi chọn bảy đặc trưng: lưu lượng đầu vào, bể N_2O -3, công suất sức khí 2, bể NH_4^+ -1, lưu lượng WAS, bể COD-2 và bể NO_2^- -2. Các đặc trưng này thể hiện tổng thể những yếu tố kiểm soát vận hành cốt lõi, các chỉ báo chuyển hóa nitơ và điều kiện tải lượng hữu cơ có liên quan đến động lực học N_2O . Lưu lượng đầu vào, công suất sức khí 2 và lưu lượng WAS phản ánh các hoạt động chính của quy trình; bể NH_4^+ -1 và bể NO_2^- -2 ghi nhận các bước then chốt trong quá trình nitrat hóa và

khử nitrat; COD-Tank2 là biến đại diện cho lượng carbon hữu cơ sẵn có chi phối quá trình khử nitrat; và N_2O -Tank3 là biến đại diện trực tiếp cho biến mục tiêu trong dự đoán. Lựa chọn này cân bằng giữa tính phù hợp về cơ chế và hiệu quả thống kê, đồng thời giảm sự dư thừa.

Để đánh giá sâu hơn hiệu quả của chiến lược lựa chọn đặc trưng được đề xuất, trước tiên tập hợp đặc trưng rút gọn được áp dụng cho cấu trúc mô hình LSTM cơ bản 2 lớp (FS-basic-LSTM) được giới thiệu ở Mục 3.1. FS-basic-LSTM được huấn luyện trên các đặc trưng đã chọn đạt hiệu suất dự đoán cao trong điều kiện cùng phân phối, với MAE kiểm tra trung bình là 0.0367 ($\sigma = 0.0032$) và R^2 trung bình là 0.6919. Kết quả này cải thiện đáng kể so với mô hình cơ sở ($p < 0.001$), mô hình LSTM 5 lớp ($p < 0.001$) và mô hình LSTM-Attention ($p < 0.001$) (Bảng S7). R^2 tương đương với mô hình Attention-LSTM, không có khác biệt có ý nghĩa thống kê. Trong lần chạy đạt kết quả tốt nhất, mô hình đạt R^2 là 0.77, vượt kết quả tốt nhất của mô hình Attention-LSTM.

Sử dụng cùng chiến lược tìm kiếm siêu tham số như trong Mục 3.1, chúng tôi tiếp tục tối ưu hóa kiến trúc mô hình trên tập đặc trưng đã chọn. Đáng chú ý, cấu hình tối ưu tương ứng với kiến trúc 1 lớp tương đối đơn giản (FS-tuned-LSTM). Sau khi tinh chỉnh, mô hình cho thấy độ ổn định được cải thiện rõ rệt trong việc dự đoán chính xác dự tăng nhẹ (MAE trung bình = 0.0330, $\sigma = 0.0015$; R trung bình² = 0.7225). Như thể hiện trong Hình 3a, cả hai mô hình sử dụng các đặc trưng đã chọn đều nắm bắt hiệu quả hơn các kiểu biến thiên theo ngày của lượng phát thải N_2O so với các mô hình tương ứng sử dụng toàn bộ đặc trưng. Cải thiện này có thể là nhờ giảm hiện tượng đa cộng tuyến và nhiễu trong không gian đầu vào.⁴² Ngoài ra, tập con đặc trưng được chọn duy trì hiệu suất dự đoán ổn định trên các kiến trúc LSTM




Figure 4. LLM-assisted feature selection results and model performance: (a) feature selection matrix across 15 experimental rounds for three LLMs (Claude, GPT, and Gemini), showing selected and unselected features per round with total selection frequency indicated below; (b) time series comparison of predicted versus measured N_2O concentrations under in-distribution conditions (July) using the LLM-assisted selected feature set; (c) time series comparison under out-of-distribution conditions (August high-flow period).

varying depths (Tables S8 and S9), indicating that the selected feature subset remained robust under different model configurations.

To assess whether the performance gains arise from feature reduction alone or from the proposed framework, we first applied LASSO regularization to select features based on coefficient shrinkage and subsequently applied SHAP to select seven features from the tuned 5-layer LSTM for a controlled comparison. However, the resulting model still underperformed compared to the FS models (Figure 3b; Tables S11 and S13). In contrast, mechanistic feature selection retains the most informative predictors, enabling a simpler yet more informative feature space for stable and efficient learning of system dynamics.⁴³ These results indicate that model performance is primarily determined by feature quality rather than model architecture, leading to reduced sensitivity to hyperparameter settings and improved stability in practice.⁴⁴

In addition to predictive accuracy, model overfitting was evaluated using the validation-to-training MAE ratio. As shown in Figure 3d, the FS-basic-LSTM model exhibits an overfitting ratio of approximately 1.46 $\times$, while FS-tuned-LSTM shows a slightly higher ratio of 1.53 $\times$ (Figure 3d). Nevertheless, the overall magnitude of overfitting is reduced compared to the results obtained using the full feature set in Section 3.1.


Robustness under distributional shift was further evaluated using the out-of-distribution August data set. After feature selection, both the FS-basic-LSTM and FS-tuned-LSTM achieve positive R^2 values (0.2690 and 0.2964, respectively). Although this data set lies outside the range of the training data, both models are able to capture the majority of temporal fluctuations in N_2O emissions, including the timing and general shape of peak events, suggesting that the selected features effectively preserve the dominant system dynamics (Figure 3e). Importantly, prediction accuracy remains high across most of the August period and only begins to deteriorate when inflow conditions increase far beyond the

training range. Specifically, when the inflow rate reaches 82.62 L/s (August 14–16), representing a 56.74% increase relative to the mean influent flow in the training data set, model performance shows a noticeable decline. This indicates that predictive performance may be limited when extrapolating beyond the training domain and suggests that future applications could benefit from incorporating additional data or adaptive retraining strategies.⁴⁵

Overall, these results indicate that the main improvement in model performance arises from the knowledge-guided reduction of the input space. By removing redundant and less informative variables, the selected feature set enables the model to learn more stable relationships from limited data, resulting in improved predictive accuracy and better retention of predictive skill under a distributional shift. Compared with the deeper and attention-based full-feature models, the feature-selected models more effectively preserve the dominant temporal dynamics of N_2O emissions under the shifted conditions. This suggests that, in small-sample, high-dimensional wastewater treatment modeling, mechanistically informed feature selection may be more important than architectural complexity for achieving robust generalization.⁴⁶

3.3. LLM-Assisted Feature Selection Provides a Viable Alternative

To evaluate whether LLM-RAG-based feature selection can serve as a viable alternative to expert knowledge, we constructed a RAG framework that synthesizes domain knowledge from scientific literature to guide feature selection without direct expert involvement. A total of 15 experimental runs were conducted, with each of the three LLMs evaluated five times, and seven features were selected in each run. Across all runs, 14 unique features were selected in total (Figure 4a). DO and InflowRate were consistently chosen (100%), followed by N_2O -Tank3 (80%) and Aeration Power2 (67%), together accounting for 46% of all selections (Figure 4a). The repeated selection of these variables indicates that the



Hình 4. Kết quả lựa chọn đặc trưng có hỗ trợ LLM và hiệu suất mô hình: (a) ma trận lựa chọn đặc trưng qua 15 vòng thử nghiệm của ba LLM (Claude, GPT và Gemini), cho thấy các đặc trưng được chọn và không được chọn ở mỗi vòng, cùng tổng tần suất lựa chọn được biểu thị bên dưới; (b) so sánh chuỗi thời gian giữa nồng độ N_2O dự đoán và đo được trong điều kiện cùng phân phối (tháng 7), sử dụng tập đặc trưng được lựa chọn với hỗ trợ LLM; (c) so sánh chuỗi thời gian trong điều kiện khác phân phối (giai đoạn lưu lượng cao trong tháng 8).

ở các độ sâu khác nhau (Bảng S8 và S9), cho thấy tập hợp đặc trưng được chọn vẫn ổn định với các cấu hình mô hình khác nhau.

Để đánh giá liệu mức tăng hiệu suất chỉ đến từ việc giảm số lượng đặc trưng hay từ khuôn khổ đề xuất, trước tiên chúng tôi áp dụng phương pháp chỉ định quy hóa LASSO để chọn đặc trưng dựa trên mức độ thu nhỏ hệ số, sau đó dùng SHAP để chọn bảy đặc trưng từ mô hình LSTM 5 lớp đã tinh chỉnh nhằm so sánh có kiểm soát. Tuy nhiên, mô hình thu được vẫn có hiệu suất thấp hơn các mô hình FS (Hình 3b; Bảng S11 và S13). Ngược lại, phương pháp lựa chọn đặc trưng cơ học giữ lại các biến dự báo giàu thông tin nhất, tạo ra không gian đặc trưng đơn giản hơn nhưng giàu thông tin hơn, giúp học động lực học của hệ thống một cách ổn định và hiệu quả.⁴³ Những kết quả này cho thấy hiệu suất mô hình chủ yếu được quyết định bởi chất lượng đặc trưng chứ không phải kiến trúc mô hình, từ đó giảm độ nhạy với các thiết lập kiến trúc và các tham số huấn luyện.

Bên cạnh việc đánh giá hiệu suất, chúng tôi cũng phân tích các đặc trưng được chọn dựa trên tỷ lệ MAE trên tập xác thực so với tập huấn luyện. Như thể hiện trong Hình 3d, mô hình FS-basic-LSTM có tỷ lệ quá khớp xấp xỉ 1.46 $\times$, trong khi FS-tuned-LSTM cho tỷ lệ cao hơn đôi chút, ở mức 1.53 $\times$ (Hình 3d). Tuy nhiên, mức độ quá khớp nhìn chung đã giảm so với kết quả thu được khi sử dụng toàn bộ tập đặc trưng gốc. Đồng thời, sự thay đổi phân phối tiếp tục được đánh giá bằng bộ dữ liệu tháng 8 nằm ngoài phân phối. Sau khi lựa chọn đặc trưng, cả FS-basic-LSTM và FS-tuned-LSTM đều đạt giá trị R^2 dương (lần lượt là 0.2690 và 0.2964). Mặc dù bộ dữ liệu này nằm ngoài phạm vi dữ liệu huấn luyện, cả hai mô hình đều có thể nắm bắt phần lớn các biến động theo thời gian của lượng phát thải N_2O , bao gồm thời điểm và hình dạng tổng thể của các đợt đỉnh, cho thấy các đặc trưng được chọn bảo toàn hiệu quả động lực học chi phối của hệ thống (Hình 3e). Đáng chú ý, độ chính xác dự đoán vẫn cao trong phần lớn thời gian của tháng 8 và chỉ bắt đầu suy giảm khi điều kiện dòng vào tăng vượt xa mức

phạm vi huấn luyện. Cụ thể, khi lưu lượng đầu vào đạt 82.62 L/s (ngày 14 tháng 8–16), tăng 56.74% so với lưu lượng đầu vào trung bình trong tập dữ liệu huấn luyện, hiệu suất mô hình suy giảm rõ rệt. Điều này cho thấy hiệu suất dự đoán có thể bị hạn chế khi ngoại suy vượt ra ngoài miền huấn luyện và gợi ý rằng các ứng dụng trong tương lai có thể được cải thiện bằng cách bổ sung dữ liệu hoặc áp dụng các chiến lược huấn luyện lại thích ứng.⁴⁵

Nhìn chung, các kết quả này cho thấy cải thiện chính về hiệu suất mô hình đến từ việc giảm không gian đầu vào dựa trên tri thức. Bằng cách loại bỏ các biến dư thừa và ít thông tin hơn, tập đặc trưng được chọn giúp mô hình học các mối quan hệ ổn định hơn từ dữ liệu hạn chế, qua đó nâng cao độ chính xác dự báo và duy trì tốt hơn năng lực dự báo khi có sự dịch chuyển phân phối. So với các mô hình đầy đủ đặc trưng sâu hơn và dựa trên cơ chế chú ý, các mô hình được chọn đặc trưng bảo toàn hiệu quả hơn động lực học thời gian chủ đạo của phát thải N_2O trong điều kiện đã dịch chuyển. Điều này cho thấy rằng, trong mô hình hóa xử lý nước thải với cỡ mẫu nhỏ và số chiều cao, việc lựa chọn đặc trưng dựa trên cơ chế có thể quan trọng hơn độ phức tạp của kiến trúc để đạt được khả năng khái quát hóa và ổn định. Lựa chọn đặc trưng có sự hỗ trợ của LLM là một phương án thay thế khả thi.

Để đánh giá liệu việc lựa chọn đặc trưng dựa trên LLM-RAG có thể là một giải pháp thay thế khả thi cho kiến thức chuyên môn hay không, chúng tôi đã xây dựng một khuôn khổ RAG tổng hợp kiến thức chuyên ngành từ các tài liệu khoa học để định hướng việc lựa chọn đặc trưng mà không cần sự tham gia trực tiếp của chuyên gia. Tổng cộng 15 lượt thử nghiệm đã được tiến hành; mỗi mô hình trong số ba LLM được đánh giá năm lần và bảy đặc trưng được chọn trong mỗi lượt. Qua tất cả các lượt, tổng cộng 14 đặc trưng riêng biệt đã được chọn (Hình 4a). DO và InflowRate luôn được chọn (100%), tiếp theo là N_2O -Tank3 (80%) và Aeration Power2 (67%); tổng cộng, các đặc trưng này chiếm 46% số lần được chọn (Hình 4a). Việc các biến này liên tục được lựa chọn cho thấy rằng the




Figure 5. Generalizability assessment of the knowledge-based feature selection framework. (a) Cross-seasonal validation on Data set A2 (WWTP-A, summer period): time series comparison of predicted versus measured N₂O concentrations using the expert-selected feature set trained on Data set A1. (b) Statistical performance metrics (R², MAE) of LSTM models trained on expert-selected features for WWTP-B (Data set B1) across 20 independent runs. (c) Time series comparison of predicted versus measured N₂O concentrations for WWTP-B using the expert-selected feature set. (d) Overfitting analysis for WWTP-B showing the validation-to-training MAE ratio for full-feature and feature-selected LSTM models.

framework converges on a stable set of mechanistically relevant predictors rather than selecting features arbitrarily. In addition, a comparison across three LLMs revealed only minor differences in feature frequencies (Figure 4a). All models consistently selected DO and InflowRate in all rounds, with closely aligned frequencies for other core variables such as N₂O-tank3. Minor variations in less frequently selected features did not affect the overall composition or the interpretability of the feature set. This suggests that output stability is driven by the RAG retrieval mechanism rather than model-specific preferences. The complete feature selection reports generated by each LLM across all five runs are provided in section 9 of the Supporting Information.

Seven features including DO, InflowRate, N₂O-Tank3, Aeration Power2, NH₄⁺-Tank1, NO₂⁻-Tank3, and NO₃⁻-Tank3 are selected. This exact set was recovered in 2 of 15 rounds, and all seven features ranked among the eight most frequently selected across the 14 candidates. Those core features are directly linked to N₂O production pathways: DO regulates AOB-mediated nitrification, inflow rate reflects hydraulic and substrate dynamics, N₂O-Tank3 provides autoregressive temporal information, and aeration power2 captures aeration control effects. Additional features include ammonium, nitrite, and nitrate concentrations, representing nitrogen transformation states that are relevant to N₂O production.


In comparison with the expert-based feature set, three core features (InflowRate, N₂O-Tank3, and Aeration Power2) are consistently identified by LLM-RAG, while NH₄⁺-Tank1 appears to be less frequent. In contrast, NO₂⁻-Tank2, WAS, and COD-Tank2 are not selected under the RAG approach, marking the main divergence. This may be because WAS and COD-Tank2 are operational variables that are less explicitly discussed in N₂O modeling literature, limiting their visibility in RAG retrieval. This difference likely reflects a key limitation of

the LLM-RAG approach. While it can synthesize general mechanistic knowledge from the literature, it does not fully capture the plant-specific operational context, process interactions, and local conditions that shape the feature relevance in a particular treatment system. As a result, variables that are important under the specific conditions of this plant may be underprioritized, even if they are mechanistically meaningful as reflected in data sets.

The final LLM-selected features were used to train a single-layer LSTM model with optimized hyperparameters. The model achieved a mean test MAE of 0.0412 ($\sigma = 0.0025$) and a mean R² of 0.596 across 20 runs, with the best run reaching an MAE of 0.0366 and an R² of 0.666 (Figure 4b). This performance exceeds that of the five-layer LSTM and LSTM-Attention models and approaches that of the Attention-LSTM. Compared with the expert-guided feature selection models, the MAE from the LLM-feature model is higher (0.0302 vs 0.0412, 36% higher) and R² is lower by 0.096. The results indicate that the LLM-RAG framework realized a substantial portion of the performance gains from feature selection without direct expert input.

Under the distributional shift during the August high-flow period, the model retained an R² of 0.405 and a test MAE of 0.051. The predictive accuracy remains reasonable during most of the August evaluation window but deteriorates notably during the extreme inflow event of August 14–16. The performance under out-of-distribution conditions confirms that the LLM-RAG-selected features preserve sufficient mechanistic signal to generalize partially beyond the training domain, a meaningful result, given that the feature set was constructed without explicit operational knowledge.

Taken together, these findings suggest that LLM-RAG-based feature selection can provide a viable alternative to expert-guided approaches, particularly when direct domain expertise is unavailable. Its key limitation, however, is that it draws



Hình 5. Đánh giá khả năng khái quát hóa của khung lựa chọn đặc trưng dựa trên tri thức. (a) Xác thực chéo theo mùa tr ên Tập dữ liệu A2 (WWTP-A, giai đoạn mùa hè): so sánh chuỗi thời gian giữa nồng độ N₂O dự đoán và đo được, sử dụng tập đặc trưng do chuyên gia lựa chọn, được huấn luyện trên Tập dữ liệu A1. (b) Các chỉ số hiệu suất thống kê (R², MAE) của các mô hình LSTM được huấn luyện trên các đặc trưng do chuyên gia lựa chọn cho WWTP-B (Tập dữ liệu B1) qua 20 l ần chạy độc lập. (c) So sánh chuỗi thời gian giữa nồng độ N₂O dự đoán và đo được tại WWTP-B, sử dụng tập đặc trưng d o chuyên gia lựa chọn. (d) Phân tích quá khớp tại WWTP-B, thể hiện tỷ lệ MAE giữa tập xác thực và tập huấn luyện của c

ác mô hình LSTM sử dụng toàn bộ đặc trưng và các đặc trưng đã chọn. Khung này hội tụ về một tập hợp ổn định các biến dự đoán có liên quan về mặt cơ chế, thay vì lựa ch ọn đặc trưng một cách tùy tiện. Ngoài ra, so sánh gi ữa ba LLM cho thấy chỉ có khác biệt nhỏ về tần suất xuất hiện của các đặc trưng (Hình 4a). Tất cả các mô hình đều nhất quán lựa chọn DO và InflowRate trong mọi vòng, với tần suất gần như tương đồng ở các biến cốt lõi khác như bể N₂O số 3. Những khá c biệt nhỏ ở các đặc trưng ít được lựa chọn hơn kh ông ảnh hưởng đến thành phần tổng thể hay khả năng diễn giải của tập đặc trưng. Điều này cho thấ y độ ổn định của đầu ra bắt nguồn từ cơ chế truy x uất RAG chứ không phải từ sở thích riêng của từng mô hình. Các báo cáo lựa chọn đặc trưng đầy đủ d ể xây dựng mô hình LSTM cho năm lần chạy được cung cấp trong phần bổ sung B1 của Tập dữ liệu B1, bao gồm DO, InflowRate, N₂O-Tank3, Aeration Power2, NH₄⁺-Tank1, NO₂⁻-Tank3 và NO₃⁻-Tank3. Tập hợp chính xác này được khôi phục trong 2 trên 15 vòng, và cả bảy đặc trưng đều nằm trong nhóm tám đặc trưng được chọn thường xuyên nhất trong số 14 ứng viên. Các đặc trưng cốt lõi này liên quan trực tiếp đến các con đường sản s inh N₂O: DO điều tiết quá trình nitrat hóa qua trung gian AOB, lưu lượng đầu vào phản ánh động lực th ủy lực và cơ chất, N₂O-Tank3 cung cấp thông tin th ời gian tự hồi quy, còn công suất sục khí 2 thể hiện các tác động của việc điều khiển sục khí. Các đặc tr ưng bổ sung gồm nồng độ amoni, nitrit và nitrat, đ ại diện cho các trạng thái chuyển hóa nitơ có liên q uan đến quá trình sản sinh N₂O.

So với tập hợp đặc trưng dựa trên chuyên gia, ba đặc trưng cốt lõi (InflowRate, N₂O-Tank3 và Aeratio n Power2) được LLM-RAG xác định nhất quán, tron g khi NH₄⁺-Tank1 ít xuất hiện hơn. Ngược lại, NO₂⁻-Tank2, WAS và COD-Tank2 không được lựa chọn th eo phương pháp RAG, tạo nên điểm khác biệt chín h. Điều này có thể là do WAS và COD-Tank2 là các b iến vận hành ít được đề cập tường minh hơn trong tài liệu về mô hình hóa N₂O, khiến chúng khó xuất hiện trong kết quả truy xuất của RAG. Khác biệt nà y có thể phản ánh một hạn chế then chốt của

phương pháp LLM-RAG. Mặc dù có thể tổng hợp ki ến thức cơ chế tổng quát từ tài liệu, phương pháp này không nắm bắt đầy đủ bối cảnh vận hành đặc t hù của nhà máy, các tương tác giữa các quá trình v à điều kiện tại chỗ—những yếu tố định hình mức đ ộ liên quan của đặc trưng trong một hệ thống xử lý cụ thể. Do đó, các biến quan trọng trong những đi ều kiện cụ thể của nhà máy này có thể không được ưu tiên đúng mức, ngay cả khi chúng có ý nghĩa về m ặt cơ chế. Những hạn chế này được minh họa rõ ràng ở kết quả đánh giá mô hình LSTM một lớp với các siêu tham số được tối ưu hóa. Mô hình đạt MAE kiểm tra trung bình là 0.0412 ($\sigma = 0.0025$) và R² trun g bình là 0.596 qua 20 lần chạy; lần chạy tốt nhất đ ạt MAE 0.0366 và R² 0.666 (Hình 4b). Hiệu suất này vượt mô hình LSTM năm lớp và LSTM-Attention, đ ồng thời tiệm cận mô hình Attention-LSTM. So với cá c mô hình chọn đặc trưng có hướng dẫn của chuyê n gia, MAE của mô hình dùng đặc trưng do LLM ch ọn cao hơn (0.0302 so với 0.0412, cao hơn 36%) và R² thấp hơn 0.096. Kết quả cho thấy khung LLM-RA G đã đạt được phần đáng kể mức cải thiện hiệu su ất nhờ chọn đặc trưng mà không cần đầu vào trực tiếp từ chuyên gia.

Trong điều kiện dịch chuyển phân phối ở giai đoạ n lưu lượng cao tháng Tám, mô hình duy trì R² ở m ức 0.405 và MAE trên tập kiểm tra ở mức 0.051. Độ chính xác dự đoán vẫn ở mức hợp lý trong phần lớ n khoảng thời gian đánh giá tháng Tám, nhưng s ự giảm đáng kể trong sự kiện dòng chảy vào cực đ ạo ngày 14–16 tháng Tám. Hiệu năng trong các đi ều kiện nằm ngoài phân phối xác nhận rằng nhữn g đặc trưng được LLM-RAG lựa chọn giữ lại đủ tín h iệu cơ chế để khái quát hóa một phần vượt ra ngoà i miền huấn luyện. Đây là một kết quả có ý nghĩa, vì tập đặc trưng do LLM-RAG chọn dựa trên chuyên gia l ựa chọn dựa trên tài liệu về mô hình hóa N₂O, khiến chúng khó xuất hiện trong kết quả truy xuất của RAG. Khác biệt nà y có thể phản ánh một hạn chế then chốt của

primarily on general knowledge from the literature and, therefore, cannot fully account for the plant-specific operating context that shapes feature relevance in an individual treatment system. Consequently, variables that are important under the specific conditions of a given plant may be underprioritized even when they are mechanistically or operationally meaningful.

3.4. Generalizability across Seasons and Treatment Plants

To evaluate the broader applicability of the proposed knowledge-based feature selection framework, we conducted two complementary validation experiments. First, we assessed temporal generalizability using data set A2, which was collected from WWTP-A during a different operational period representing summer conditions (December 2024). In this test, the best-performing model configurations identified in sections 3.1 and 3.2 were directly applied without further retraining or fine-tuning. Second, we assessed cross-plant transferability of the framework using data set B1 from another full-scale WWTP (plant B) with a distinct process configuration. In this case, the feature selection framework was reapplied to the new plant prior to model development.

As shown in Figure 5a, all three models exhibited some degree of performance degradation when evaluated on data set A2, which was associated with a substantially higher influent flow rate (75 L/s) than the training data set. However, the extent of degradation differed markedly among the models. The FS-LSTM model showed a systematic scaling bias, with predictions consistently higher than the observed values. Nevertheless, after normalization (Figure S6), it remained able to capture the dominant temporal dynamic patterns of the N₂O emissions. In contrast, both the LSTM-attention and attention-LSTM models failed to accurately reproduce these peak events, showing reduced sensitivity to transient fluctuations and a tendency to smooth extreme values. These results suggest that the expert-selected feature set retains predictive relevance under seasonal and hydraulic shifts, more consistent with the underlying biochemical mechanisms governing N₂O dynamics rather than being overfitted to operational patterns specific to a single monitoring period.

The validation using data set B1 was designed to test whether the same feature selection strategy remained effective when transferred to a different treatment system. Plant B consisted of 12 biological tanks and a substantially larger monitoring space, yielding 180 candidate input features when the process variables and sensor measurements were combined. Applying the knowledge-based feature selection framework reduced this set to 7 features including the Airflow Rates Tank 6–8, XH-Tank 5, InflowRate, XH-Tank 6, and COD-Tank2. Compared with the features from plant A, the selected variables in plant B were more strongly associated with denitrification-related processes. This difference highlights the influence of plant-specific configuration and operating conditions on N₂O dynamics and suggests that feature selection should be re-evaluated when the framework is applied to a new wastewater treatment system.

The plant B feature set was then used as an input to the FS-LSTM, Attention-LSTM, and LSTM-Attention models. Each model was trained 20 times, and the best performing run for each is shown in Figure 5b. Consistent with the results from plant A, the FS-LSTM model more effectively captured the temporal dynamics of N₂O emissions, whereas both attention-based models showed a reduced ability to reproduce the

dynamic fluctuation patterns. The FS-LSTM model also achieved the lowest MAE (0.00260), outperforming the attention-LSTM (0.00568) and LSTM-attention (0.00309) models. Although the overfitting ratios were broadly comparable across models, FS-LSTM exhibited more consistent performance across validation settings (Figure Sd). Such high-dimensional input in Plant B increases the difficulty for the model to learn the true underlying trends, as it may be distracted by noise and spurious correlations, ultimately leading to poorer predictive performance.^{38,47,48} These results collectively demonstrate that the proposed feature selection framework improves practical model generalizability in small-sample, high-dimensional wastewater treatment modeling by reducing irrelevant variation and preserving mechanistically informative inputs.

3.5. Implications

This study presents a knowledge-based feature selection framework that integrates mechanistic importance and statistical correlation, augmented by LLM-RAG literature synthesis, for predicting N₂O emissions in wastewater treatment plants. By reducing 52 candidate variables to seven mechanistically and statistically significant inputs, the expert-guided model achieved a mean R² of 0.723 under small-sample constraints while markedly improving generalizability under out-of-distribution conditions where all full-feature models failed. The results confirm that (i) knowledge-based feature selection addresses the generalization limitations of purely architectural approaches, (ii) feature quality rather than model complexity is the dominant factor controlling performance under small-sample, high-dimensional conditions, and (iii) LLM-RAG-based selection represents a viable alternative to expert-guided approaches, achieving competitive performance without direct expert involvement.

Feature selection is pivotal across fields from genomic risk prediction in bioinformatics^{49,50} and sentiment/text classification in NLP^{51,52} to diagnostic imaging⁵³ and credit-risk modeling in finance.⁵⁴ This approach started with simple one-variable filters that tamed the “curse of dimensionality” in high-sensor data sets^{55,56} and evolved into wrapper-style searches that test many candidate subsets in the model loop.^{57,58} With deep learning, construction and selection blurred together: autoencoders, attention maps, and multi-modal schemes now sift through images, time-series, and lab results in real time.^{59,60} Despite these proven benefits, most machine learning studies in environmental engineering implement feature selection unsystematically and are not fully aware of its critical role in achieving optimal model performance.^{61–64} Across recent WWTP influent-forecasting and potable-water studies, targeted feature pruning cut input variables by two-thirds, lifted test-set R² by roughly 10–20%, and slashed training time by half, underscoring feature selection’s decisive value in operational water-quality models for researchers and operators.^{65–67}

Our approach fuses mechanistic process insight with empirical correlation analysis to construct a feature selection framework that preserves statistical validity and enhances process-aware robustness. The methodology addresses the fundamental challenge in wastewater treatment modeling of how to extract meaningful predictive signals from high-dimensional, sparse data sets where traditional machine learning approaches systematically fail. Incorporating LLM-assisted knowledge extraction into our pipeline represents one

chủ yếu dựa trên kiến thức tổng quát từ tài liệu, do đó không thể phản ánh đầy đủ bối cảnh vận hành đặc thù của nhà máy, vốn định hình mức độ liên quan của các đặc trưng trong từng hệ thống xử lý. Vì vậy, các biến quan trọng trong những điều kiện cụ thể của một nhà máy nhất định có thể không được ưu tiên đúng mức, ngay cả khi chúng có ý nghĩa về mặt cơ chế hoặc vận hành.

3.4. Khả năng khái quát hóa qua các mùa và nhà máy xử lý nước thải

Để đánh giá khả năng áp dụng rộng hơn của khung lựa chọn đặc trưng dựa trên tri thức được đề xuất, chúng tôi tiến hành hai thí nghiệm kiểm chứng bổ trợ cho nhau. Thứ nhất, chúng tôi đánh giá khả năng khái quát hóa theo thời gian bằng bộ dữ liệu A2, được thu thập tại WWTP-A trong một giai đoạn vận hành khác, đại diện cho điều kiện mùa hè (tháng 12 năm 2024). Trong phép thử này, các cấu hình mô hình hoạt động tốt nhất được xác định ở mục 3.1 và 3.2 được áp dụng trực tiếp mà không huấn luyện lại hoặc tinh chỉnh thêm. Thứ hai, chúng tôi đánh giá khả năng chuyển giao giữa các nhà máy của khung này bằng bộ dữ liệu B1 từ một WWTP quy mô toàn phần khác (nhà máy B), có cấu hình quy trình khác biệt. Trong trường hợp này, khung lựa chọn đặc trưng được áp dụng cho một mức độ nhất định khi được đánh giá trên tập dữ liệu A2, vốn có lưu lượng nước đầu vào cao hơn đáng kể (75 L/s) so với tập dữ liệu huấn luyện. Tuy nhiên, mức độ suy giảm khác nhau rõ rệt giữa các mô hình. Mô hình FS-LSTM thể hiện sai lệch tỷ lệ có tính hệ thống, với các giá trị dự đoán luôn cao hơn giá trị quan sát. Dẫu vậy, sau khi chuẩn hóa (Hình S6), mô hình vẫn có thể nắm bắt các dạng biến động theo thời gian chủ đạo của lượng phát thải N₂O. Ngược lại, cả hai mô hình LSTM-attention và attention-LSTM đều không tái hiện chính xác các sự kiện đạt đỉnh này, cho thấy độ nhạy giảm đối với các biến động nhất thời và xu hướng làm trơn các giá trị cực đoan. Những kết quả này cho thấy tập đặc trưng do chuyên gia lựa chọn vẫn giữ được giá trị dự báo khi có sự thay đổi theo mùa và thủy lực, phù hợp hơn với các cơ chế sinh hóa nền tảng chi phối động thái N₂O thay vì bị quá khớp với các kiểu vận hành đặc thù của một giai đoạn ngắn. **Quá trình đánh giá** bằng bộ dữ liệu B1 được thiết kế để kiểm tra xem cùng một chiến lược lựa chọn đặc trưng có còn hiệu quả khi được áp dụng cho một hệ thống xử lý khác hay không. Nhà máy B gồm 12 bể sinh học và có không gian giám sát lớn hơn đáng kể, tạo ra 180 đặc trưng đầu vào ứng viên khi kết hợp các biến quy trình với số liệu đo từ cảm biến. Áp dụng khuôn khổ lựa chọn đặc trưng dựa trên tri thức đã giảm tập này xuống còn 7 đặc trưng, bao gồm Airflow Rates Tank 6–8, XH-Tank 5, InflowRate, XH-Tank 6 và COD-Tank2. So với các đặc trưng của nhà máy A, các biến được chọn ở nhà máy B có liên hệ chặt chẽ hơn với các quá trình khử nitrat. Sự khác biệt này làm nổi bật ảnh hưởng của cấu hình và điều kiện vận hành riêng của từng nhà máy đối với động thái N₂O, đồng thời cho thấy cần đánh giá lại việc lựa chọn đặc trưng khi áp dụng khuôn khổ này cho một hệ thống xử lý nước thải mới. Sau đó, tập hợp đặc trưng của nhà máy B được dùng làm đầu vào cho các mô hình FS-LSTM, Attention-LSTM và LSTM-Attention. Mỗi mô hình được huấn luyện 20 lần, và lần chạy có hiệu suất tốt nhất của từng mô hình được trình bày trong Hình 5b. Nhất quán với kết quả từ nhà máy A, mô hình FS-LSTM nắm bắt hiệu quả hơn các động lực theo thời gian của lượng phát thải N₂O, trong khi cả hai mô hình dựa trên attention đều cho thấy khả năng tái hiện giảm sút đối với các động lực này.

các kiểu biến động động. Mô hình FS-LSTM cũng đạt MAE thấp nhất (0.00260), vượt trội hơn các mô hình attention-LSTM (0.00568) và LSTM-attention (0.00309). Mặc dù tỷ lệ quá khớp nhìn chung tương đương giữa các mô hình, FS-LSTM thể hiện hiệu suất nhất quán hơn trong các thiết lập xác thực (Hình 5d). Đầu vào có số chiều cao như vậy ở Nhà máy B làm tăng độ khó trong việc học các xu hướng thực sự tiềm ẩn, vì mô hình có thể bị nhiễu và các tương quan giả gây phân tâm, cuối cùng dẫn đến hiệu suất dự đoán kém hơn.^{38,47,48} Nhìn chung, các kết quả này chứng minh rằng khung lựa chọn đặc trưng được đề xuất cải thiện khả năng khái quát hóa thực tiễn của mô hình trong bài toán mô hình hóa xử lý nước thải với dữ liệu ít mẫu, số chiều cao, bằng cách giảm các biến thiên không liên quan và giữ lại các đầu vào giàu thông tin về cơ chế.

3.5. Các hệ quả

Nghiên cứu này trình bày một khung lựa chọn đặc trưng dựa trên tri thức, kết hợp tầm quan trọng về mặt cơ chế với tương quan thống kê, đồng thời bổ sung tổng hợp tài liệu bằng LLM-RAG, nhằm đo lường phát thải N₂O tại các nhà máy xử lý nước thải. Bằng cách rút gọn 52 biến ứng viên xuống còn bảy đầu vào có ý nghĩa về cả cơ chế lẫn thống kê, mô hình được chuyên gia định hướng đạt R² trung bình 0.723 trong điều kiện có mẫu nhỏ, đồng thời cải thiện đáng kể khả năng khái quát hóa trong các điều kiện nằm ngoài phân phối, nơi tất cả các mô hình sử dụng đầy đủ đặc trưng đều thất bại. Kết quả xác nhận rằng (i) lựa chọn đặc trưng dựa trên tri thức giúp khắc phục những hạn chế về khả năng khái quát hóa của các phương pháp thuần túy dựa trên kiến trúc, (ii) chất lượng đặc trưng — chứ không phải độ phức tạp của mô hình — là yếu tố chi phối hiệu năng trong điều kiện có mẫu nhỏ, số chiều cao, và (iii) lựa chọn dựa trên LLM-RAG là một phương pháp chọn đặc trưng đáng tin cậy trong bối cảnh thiếu chuyên gia. **Ý nghĩa môi trường và xã hội** của việc giảm thiểu phát thải N₂O trong NLP^{51,52} đến chẩn đoán hình ảnh⁵³ và mô hình hóa rủi ro tín dụng trong tài chính.⁵⁴ Phương pháp này khởi đầu với các bộ lọc đơn biến đơn giản giúp khắc phục “lời nguyền số chiều” trong các tập dữ liệu có nhiều cảm biến^{55,56}, rồi phát triển thành các phương pháp tìm kiếm kiểu bao bọc, kiểm tra nhiều tập con ứng viên ngay trong vòng lặp của mô hình.^{57,58} Với học sâu, việc tạo lập và lựa chọn đặc trưng trở nên đan xen: các bộ tự mã hóa, bản đồ chú ý và những phương pháp đa mô thức hiện sàng lọc hình ảnh, chuỗi thời gian và kết quả xét nghiệm theo thời gian thực.^{59,60} Dù đã chứng minh được những lợi ích này, phần lớn nghiên cứu học máy trong kỹ thuật môi trường vẫn triển khai lựa chọn đặc trưng một cách thiếu hệ thống và chưa nhận thức đầy đủ vai trò then chốt của phương pháp này trong việc đạt hiệu năng mô hình tối ưu.^{61–64} Qua các nghiên cứu gần đây về dự báo nước đầu vào nhà máy xử lý nước thải và nước uống, việc cắt giảm đặc trưng có mục tiêu đã giảm đáng kể thời gian huấn luyện và cải thiện hiệu suất mô hình.^{65–67} **Tầm nhìn và thách thức** trong tương lai bao gồm việc tích hợp các mô hình sinh học và cảm biến tiên tiến để xây dựng các kho dữ liệu đa chiều và đa quy mô, đồng thời tận dụng các công nghệ như học sâu để khám phá các mối quan hệ ẩn trong dữ liệu vận hành, từ đó tối ưu hóa việc lựa chọn đặc trưng và nâng cao hiệu suất của các mô hình dự báo. Việc tích hợp khai thác tri thức có lời trong mô hình hóa xử lý nước thải: làm thế nào để trích xuất các tín hiệu dự báo có ý nghĩa từ những tập dữ liệu thưa thớt, có số chiều cao, nơi các phương pháp học máy truyền thống thường xuyên thất bại một cách có hệ thống. Việc tích hợp khai thác tri thức có sự hỗ trợ của LLM vào quy trình của chúng tôi thể hiện một bước tiến đáng kể.

Downloaded from pubs.acs.org/est/article-pdf/60/26/19882/6588436/acs.est.6c04963.pdf by guest on 05 October 2026

of the first applications of LLM-RAG-based feature selection in wastewater engineering. This breakthrough both expands the methodological toolkit and empirically validates our central claim that knowledge-guided selection consistently outperforms purely statistical heuristics. Variables suggested by prompting the LLM with domain knowledge from environmental science and engineering literature delivered competitive predictive accuracy and demonstrated partial generalizability under distributional shift. Beyond N₂O prediction, the same framework could be extended to other environmental modeling tasks characterized by sparse, high-dimensional, and mechanistically structured data.

Several limitations also warrant future studies. First, the current feature selection process primarily considers the individual contribution of each feature to the target variable. However, in N₂O production pathways, interactions among features and between feature relevance and model configurations may be significant. Future work should therefore explore interaction-aware feature selection strategies that explicitly account for both feature–feature dependencies and feature–model configuration interactions. Second, the combined feature importance score was based on equal weighting of statistical correlation and mechanistic importance. This 1:1 weighting provides a pragmatic balance for the present system as a proof of concept, but the optimal weighting may vary with data quality, system complexity, and confidence in the underlying mechanistic understanding. For example, in data-scarce scenarios, placing greater emphasis on mechanistic importance may be more appropriate, whereas statistical correlation may play a more dominant role when large, high-quality data sets are available. Therefore, the proposed framework is inherently flexible, and the weighting scheme can be adjusted in future applications to better reflect context-specific conditions. Lastly, due to the discrete nature of the available real-world data, the safe extrapolation bounds of the proposed method could not be systematically defined. Further validation under broader and systematically sampled operating conditions is required to establish these bounds and define the reliable application range of the model.

■ ASSOCIATED CONTENT

Data Availability Statement

The code of this work can be found at <https://github.com/SenyuanGu/Water-Feature-Selection>.

Supporting Information

The Supporting Information is available free of charge at <https://pubs.acs.org/doi/10.1021/acs.est.6c04963>.

Wastewater treatment plant process scheme and bioreactor configuration (Section 1: Figures S1–S2); key biochemical and kinetic parameters of the ASM1–N₂O model (Section 2: Table S1); feature engineering including state variable classification and model simulation results (Section 2: Tables S2–S3 and Figures S3–S5); hyperparameter tuning search space and optimal configurations (Section 3: Tables S4–S5); computational performance summary (Section 3: Table S6); feature selection methodology including mechanistic sensitivity analysis and SC-score derivation (Section 4); LLM prompt design for RAG-based feature recommendation (Section 5); model performance comparisons of pure machine learning and attention-based LSTM models (Section 6: Table S7); LASSO and

SHAP analysis results (Section 7: Tables S8–S11); LLM-RAG feature selection reports from GPT, Claude, and Gemini (Section 8); and generalizability analysis (Section 9: Figure S6) (PDF)

■ AUTHOR INFORMATION

Corresponding Author

Haoran Duan – UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia; Australian Centre for Water and Environmental Biotechnology (ACWEB, formerly AWMC) and School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia; Department of Civil Engineering, The University of Hong Kong, Pokfulam, Hong Kong SAR 999077, China; orcid.org/0000-0001-6679-3240; Email: haoran.duan@hku.hk

Authors

Senyuan Gu – UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia; Australian Centre for Water and Environmental Biotechnology (ACWEB, formerly AWMC), The University of Queensland, Brisbane, Queensland 4072, Australia

Shuting Wang – School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia

Ruihong Qiu – School of Information Technology and Electrical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia

Kaili Li – School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia; orcid.org/0000-0002-1676-1475

Jaswinder Manjeet Singh – Gold Coast City Council, Southport, Queensland 4215, Australia

Jue Zhang – College of Geo-informatics, Zhejiang University of Technology, Hangzhou, Zhejiang Province 310000, P. R. China

Bing-Jie Ni – UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia

T. David Waite – UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia; UNSW Centre for Transformational Environmental Technologies, Yixing, Jiangsu Province 214206, P. R. China; orcid.org/0000-0002-5411-3233

Liu Ye – School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia; orcid.org/0000-0001-5478-0864

Complete contact information is available at: <https://pubs.acs.org/10.1021/acs.est.6c04963>

Notes

The authors declare no competing financial interest.

■ ACKNOWLEDGMENTS

This study was funded by the Australian Research Council (ARC) through the Industry Fellowship project (IE230100422). Senyuan Gu thanks the China Scholarship Council for Scholarship Support. Shuting Wang acknowledges

một trong những ứng dụng đầu tiên của phương pháp lựa chọn đặc trưng dựa trên LLM-RAG trong lĩnh vực kỹ thuật nước thải. Bước đột phá này vừa mở rộng bộ công cụ phương pháp luận, vừa kiểm chứng bằng thực nghiệm luận điểm cốt lõi của chúng tôi rằng lựa chọn được định hướng bởi tri thức luôn vượt trội hơn các phương pháp kinh nghiệm thuần thống kê. Các biến được đề xuất khi cung cấp cho LLM tri thức chuyên ngành từ tài liệu về khoa học và kỹ thuật môi trường đạt độ chính xác dự đoán cạnh tranh và cho thấy khả năng khái quát hóa một phần khi phân phối dữ liệu thay đổi. Ngoài việc dự đoán N₂O, cùng khuôn khổ này có thể được mở rộng sang các bài toán mô hình hóa môi trường khác, chẳng hạn như chất lượng nước và được cấu trúc thành các chủ yếu xem xét đóng góp riêng lẻ của từng đặc trưng đối với biến mục tiêu. Tuy nhiên, trong các lộ trình sản xuất N₂O, tương tác giữa các đặc trưng cũng như giữa mức độ liên quan của đặc trưng và cấu hình mô hình có thể rất đáng kể. Do đó, các nghiên cứu trong tương lai nên tìm hiểu các chiến lược lựa chọn đặc trưng có xét đến tương tác, trong đó tính đến rõ ràng cả sự phụ thuộc giữa các đặc trưng– và tương tác giữa đặc trưng với cấu hình mô hình–. Thứ hai, điểm số mức độ quan trọng kết hợp của các đặc trưng được tính bằng cách gán trọng số bằng nhau cho tương quan thống kê và mức độ quan trọng về mặt cơ chế. Tỷ lệ trọng số 1:1 này tạo nên sự cân bằng thực tiễn cho hệ thống hiện tại với tư cách là một minh chứng khái niệm, nhưng trọng số tối ưu có thể thay đổi tùy theo chất lượng dữ liệu, độ phức tạp của hệ thống và mức độ tin cậy vào hiểu biết cơ chế nền tảng. Chẳng hạn, trong các tình huống khan hiếm dữ liệu, việc chú trọng hơn đến mức độ quan trọng về mặt cơ chế có thể phù hợp hơn, trong khi tương quan thống kê có thể đóng vai trò chủ đạo hơn khi có sẵn các tập dữ liệu lớn, chất lượng cao. Vì vậy, khuôn khổ được đề xuất vốn có tính linh hoạt, và có thể điều chỉnh phương pháp gán trọng số trong các ứng dụng tương lai để phản ánh tốt hơn các điều kiện cụ thể theo bối cảnh. Cuối cùng, do dữ liệu thực tế hiện có mang tính rời rạc, không thể xác định một cách hệ thống các giới hạn ngoại suy an toàn của phương pháp được đề xuất. Cần tiến hành xác thực thêm trong các điều kiện vận hành thực địa mới để đảm bảo việc lấy mẫu có hệ thống để xác lập các giới hạn này cũng như xác định nguồn gốc của công trình này có thể tìm thấy tại <https://github.com/SenyuanGu/Water-Feature-Selection>.

■ Thông tin bổ sung

Tài liệu bổ trợ được cung cấp miễn phí tại <https://pubs.acs.org/doi/10.1021/acs.est.6c04963>.

Sơ đồ quy trình của nhà máy xử lý nước thải và cấu hình lò phản ứng sinh học (Mục 1: Hình S1–S2); các thông số sinh hóa và động học chính của mô hình ASM1–N₂O (Mục 2: Bảng S1); kỹ thuật thiết kế đặc trưng, bao gồm phân loại biến trạng thái và kết quả mô phỏng mô hình (Mục 2: Bảng S2–S3 và Hình S3–S5); không gian tìm kiếm tinh chỉnh siêu tham số và các cấu hình tối ưu (Mục 3: Bảng S4–S5); tóm tắt hiệu năng tính toán (Mục 3: Bảng S6); phương pháp luận lựa chọn đặc trưng, bao gồm phân tích độ nhạy cơ chế và cách xác định điểm SC (Mục 4); thiết kế câu lệnh LLM để đề xuất đặc trưng dựa trên RAG (Mục 5); so sánh hiệu năng mô hình giữa các mô hình học máy thuần túy và LSTM dựa trên cơ chế chú ý (Mục 6: Bảng S7); LASSO và

Kết quả phân tích SHAP (Mục 7: Bảng S8–S11); báo cáo lựa chọn đặc trưng LLM-RAG từ GPT, Claude và Gemini (Mục 8); và phân tích khả năng khái quát hóa (Mục 9: Hình S6) (PDF)

THÔNG TIN TÁC GIẢ

Tác giả liên hệ

Haoran Duan – UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia; Australian Centre for Water and Environmental Biotechnology (ACWEB, formerly AWMC) and School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia; Department of Civil Engineering, The University of Hong Kong, Pokfulam, Hong Kong SAR 999077, China; orcid.org/0000-0001-6679-3240; Email: haoran.duan@hku.hk

Tác giả

Senyuan Gu

– UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia; Australian Centre for Water and Environmental Biotechnology (ACWEB, formerly AWMC), The University of Queensland, Brisbane, Queensland 4072, Australia **Shuting Wang** – School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia **Ruihong Qiu** – School of Information Technology and Electrical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia **Kaili Li** – School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia; orcid.org/0000-0002-1676-1475 **Jaswinder Manjeet Singh** – Gold Coast City Council, Southport, Queensland 4215, Australia **Jue Zhang** – College of Geo-informatics, Zhejiang University of Technology, Hangzhou, Zhejiang Province 310000, P. R. China **Bing-Jie Ni** – UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia **T. David Waite** – UNSW Water Research Centre, School of Civil and Environmental Engineering, The University of New South Wales, Sydney, New South Wales 2052, Australia; UNSW Centre for Transformational Environmental Technologies, Yixing, Jiangsu Province 214206, P. R. China; orcid.org/0000-0002-5411-3233 **Liu Ye** – School of Chemical Engineering, The University of Queensland, Brisbane, Queensland 4072, Australia; orcid.org/0000-0001-5478-0864

Thông tin liên hệ đầy đủ có tại: <https://pubs.acs.org/10.1021/acs.est.6c04963>

Ghi chú

Các tác giả tuyên bố không có lợi ích tài chính cạnh tranh.

LỜI CẢM ƠN

Nghiên cứu này được Hội đồng Nghiên cứu Úc (ARC) tài trợ thông qua dự án Học bổng Công nghiệp (IE230100422). Senyuan Gu cảm ơn Hội đồng Học bổng Trung Quốc đã hỗ trợ học bổng. Shuting Wang ghi nhận

the scholarship support from the Chinese Scholarship Council and the top-up scholarship from Research Project (RM2021001190) by Melbourne Water. Ruihong Qiu acknowledges support from the ARC DECRA Fellowship (DE250100919). Bing-Jie Ni and Haoran Duan acknowledge support from ARC Linkage Project LP240200633. Experiments were performed on the UNSW Compute Cluster Katana (DOI: 10.26190/669X-A286).

REFERENCES

- (1) Wang, Z.; DeWitt, J. C.; Higgins, C. P.; Cousins, I. T. A Never-Ending Story of Per- and Polyfluoroalkyl Substances (PFASs)? *Environ. Sci. Technol.* **2017**, *51* (5), 2508–2518.
- (2) Lenka, S. P.; Kah, M.; Padhye, L. P. A Review of the Occurrence, Transformation, and Removal of Poly- and Perfluoroalkyl Substances (PFAS) in Wastewater Treatment Plants. *Water Res.* **2021**, *199*, No. 117187.
- (3) Gruber, W.; Villez, K.; Kipf, M.; Wunderlin, P.; Siegrist, H.; Vogt, L.; Joss, A. N₂O Emission in Full-Scale Wastewater Treatment: Proposing a Refined Monitoring Strategy. *Sci. Total Environ.* **2020**, *699*, No. 134157.
- (4) Daelman, M. R. J.; van Voorthuizen, E. M.; van Dongen, U. G. J. M.; Volcke, E. I. P.; van Loosdrecht, M. C. M. Seasonal and Diurnal Variability of N₂O Emissions from a Full-Scale Municipal Wastewater Treatment Plant. *Sci. Total Environ.* **2015**, *536*, 1–11.
- (5) McCarty, P. L.; Bae, J.; Kim, J. Domestic Wastewater Treatment as a Net Energy Producer—Can This Be Achieved? *Environ. Sci. Technol.* **2011**, *45* (17), 7100–7106.
- (6) Guest, J. S.; Skerlos, S. J.; Barnard, J. L.; Beck, M. B.; Daigger, G. T.; Hilger, H.; Jackson, S. J.; Karvazy, K.; Kelly, L.; Macpherson, L.; Mihelcic, J. R.; Pramanik, A.; Raskin, L.; Van Loosdrecht, M. C. M.; Yeh, D.; Love, N. G. A New Planning and Design Paradigm to Achieve Sustainable Resource Recovery from Wastewater. *Environ. Sci. Technol.* **2009**, *43* (16), 6126–6130.
- (7) Mo, W.; Zhang, Q. Energy–Nutrients–Water Nexus: Integrated Resource Recovery in Municipal Wastewater Treatment Plants. *J. Environ. Manage.* **2013**, *127*, 255–267.
- (8) Glover, G. C.; Printemps, C.; Essemiani, K.; Meinhold, J. Modelling of Wastewater Treatment Plants – How Far Shall We Go with Sophisticated Modelling Tools? *Water Sci. Technol.* **2006**, *53* (3), 79–89.
- (9) Zhu, J.-J.; Yang, M.; Ren, Z. J. Machine Learning in Environmental Research: Common Pitfalls and Best Practices. *Environ. Sci. Technol.* **2023**, *57* (46), 17671–17689.
- (10) Ma, Y.; Qiao, Y.; Chen, M.; Rui, D.; Zhang, X.; Liu, W.; Ye, L. How Small Is Big Enough? Big Data-Driven Machine Learning Predictions for a Full-Scale Wastewater Treatment Plant. *Water Res.* **2025**, *274*, No. 123041.
- (11) Li, K.; Duan, H.; Liu, L.; Qiu, R.; van den Akker, B.; Ni, B.-J.; Chen, T.; Yin, H.; Yuan, Z.; Ye, L. An Integrated First Principal and Deep Learning Approach for Modeling Nitrous Oxide Emissions from Wastewater Treatment Plants. *Environ. Sci. Technol.* **2022**, *56* (4), 2816–2826.
- (12) Li, H.; Spelman, D.; Sansalone, J. Unit Operation and Process Modeling with Physics-Informed Machine Learning. *J. Environ. Eng.* **2024**, *150* (4), No. 04024002.
- (13) Quaghebeur, W.; Torfs, E.; De Baets, B.; Nopens, I. Hybrid Differential Equations: Integrating Mechanistic and Data-Driven Techniques for Modelling of Water Systems. *Water Res.* **2022**, *213*, No. 118166.
- (14) Zhang, Y.; Wang, J.; Li, C.; Duan, H.; Wang, W. Attention-Based Deep Learning Models for Predicting Anomalous Shock of Wastewater Treatment Plants. *Water Res.* **2025**, *275*, No. 123192.
- (15) Yin, W.-X.; Chen, K.-H.; Lv, J.-Q.; Chen, J.-J.; Liu, S.; Song, Y.-P.; Zhao, Y.-W.; Huang, F.; Bao, H.-X.; Wang, H.-C.; Wang, A.-J.; Ren, N.-Q. Deciphering and Mitigating of Dynamic Greenhouse Gas Emission in Urban Drainage Systems with Knowledge-Infused Graph Neural Network. *Environ. Sci. Technol.* **2025**, *59* (7), 3592–3602.

- (16) Alvi, M.; Batstone, D.; Mbamba, C. K.; Keymer, P.; French, T.; Ward, A.; Dwyer, J.; Cardell-Oliver, R. Deep Learning in Wastewater Treatment: A Critical Review. *Water Res.* **2023**, *245*, No. 120518.
- (17) Koksal, E. S.; Asrav, T.; Esenboga, E. E.; Cosgun, A.; Kusoglu, G.; Aydin, E. Physics-Informed and Data-Driven Modeling of an Industrial Wastewater Treatment Plant with Actual Validation. *Comput. Chem. Eng.* **2024**, *189*, No. 108801.
- (18) Li, J.; Cheng, K.; Wang, S.; Morstatter, F.; Trevino, R. P.; Tang, J.; Liu, H. Feature Selection: A Data Perspective. *ACM Comput. Surv.* **2018**, *50* (6), 1–45.
- (19) Duan, H.; Li, J.; Yuan, Z. Making Waves: Knowledge and Data Fusion in Urban Water Modelling. *Water Res. X* **2024**, *24*, 100234.
- (20) Xu, B.; Zhuang, P.; Wang, Y.; He, W.; Wang, Z.; Liu, Z. Fault Diagnosis of Wastewater Treatment Processes Based on CPSO-DKPCA. *Int. J. Comput. Intell. Syst.* **2024**, *17* (1), 19.
- (21) Lindsey, J.; Gurnee, W.; Ameisen, E.; Chen, B.; Pearce, A.; Turner, N. L.; Citro, C.; Abrahams, D.; Carter, S.; Hosmer, B.; Marcus, J.; Sklar, M.; Templeton, A.; Bricken, T.; McDougall, C.; Cunningham, H.; Henighan, T.; Jermyn, A.; Jones, A.; Persic, A.; Qi, Z.; Thompson, T. B.; Zimmerman, S.; Rivoire, K.; Conerly, T.; Olah, C.; Batson, J. On the Biology of a Large Language Model. *Transform. Circuits Thread* **2025**, in press.
- (22) Radford, A.; Narasimhan, K.; Salimans, T.; Sutskever, I. Improving Language Understanding by Generative Pre-Training; OpenAI, 2018. https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf.
- (23) Gemini Team Google Anil, R.; Borgeaud, S.; Alayrac, J.-B.; Yu, J.; Vinyals, O. et al. Gemini: A Family of Highly Capable Multimodal Models. *arXiv*. 2024, <https://doi.org/10.48550/arXiv.2312.11805> June 17 (accessed 2026–06–19).
- (24) Jeong, D. P.; Lipton, Z. C.; Ravikumar, P. K. LLM-Select: Feature Selection with Large Language Models. *Trans. Mach. Learn. Res.*, 2025 <https://openreview.net/forum?id=16f7ea1N3p>.
- (25) Duan, H.; Zhao, Y.; Koch, K.; Wells, G. F.; Zheng, M.; Yuan, Z.; Ye, L. Insights into Nitrous Oxide Mitigation Strategies in Wastewater Treatment and Challenges for Wider Implementation. *Environ. Sci. Technol.* **2021**, *55* (11), 7208–7224.
- (26) Wan, X.; Baeten, J. E.; Volcke, E. I. P. Effect of Operating Conditions on N₂O Emissions from One-Stage Partial Nitrification-Anammox Reactors. *Biochem. Eng. J.* **2019**, *143*, 24–33.
- (27) Hiatt, W. C.; Grady, C. P. L. An Updated Process Model for Carbon Oxidation, Nitrification, and Denitrification. *Water Environ. Res.* **2008**, *80* (11), 2145–2156.
- (28) Pocquet, M.; Wu, Z.; Queinnec, I.; Spérandio, M. A Two Pathway Model for N₂O Emissions by Ammonium Oxidizing Bacteria Supported by the NO/N₂O Variation. *Water Res.* **2016**, *88*, 948–959.
- (29) Hochreiter, S.; Schmidhuber, J. Long Short-Term Memory. *Neural Comput.* **1997**, *9* (8), 1735–1780.
- (30) Akiba, T.; Sano, S.; Yanase, T.; Ohta, T.; Koyama, M. Optuna: A Next-Generation Hyperparameter Optimization Framework. *arXiv*. 2019, <https://doi.org/10.48550/arXiv.1907.10902> July 25 (accessed 2026–06–19).
- (31) Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A. N.; Kaiser, L.; Polosukhin, I. Attention Is All You Need. In *Advances in Neural Information Processing Systems*; Curran Associates, Inc., 2017; Vol. 30.
- (32) Wu, Y.; Tan, H. Short-Term Traffic Flow Forecasting with Spatial-Temporal Correlation in a Hybrid Deep Learning Framework. *arXiv*. 2016, <https://doi.org/10.48550/arXiv.1612.01022> December 3 (accessed 2026–06–19).
- (33) Narayanan, S.; Braza, J. D.; Griffiths, R.-R.; Ponnampati, M.; Bou, A.; Laurent, J.; Kabeli, O.; Wellawatte, G.; Cox, S.; Rodrigues, S. G.; White, A. D. Aviary: Training Language Agents on Challenging Scientific Tasks. *arXiv*. 2024, <https://doi.org/10.48550/arXiv.2412.21154> December 30 (accessed 2026–06–19).
- (34) Skarlinski, M. D.; Cox, S.; Laurent, J. M.; Braza, J. D.; Hinks, M.; Hammerling, M. J.; Ponnampati, M.; Rodrigues, S. G.; White, A. D. Language Agents Achieve Superhuman Synthesis of Scientific

học bổng hỗ trợ từ Hội đồng Học bổng Trung Quốc và học bổng bổ sung từ Dự án Nghiên cứu (RM2021001190) do Melbourne Water tài trợ. Ruihong Qiu ghi nhận sự hỗ trợ từ Học bổng ARC DECRA (DE250100919). Bing-Jie Ni và Haoran Duan ghi nhận sự hỗ trợ từ Dự án Liên kết ARC LP240200633. Các thí nghiệm được thực hiện trên Cụm máy tính Katana của UNSW (DOI: 10.26190/669X-A286).

TÀI LIỆU THAM KHẢO

- (1) Wang, Z.; DeWitt, J. C.; Higgins, C. P.; Cousins, I. T. Câu chuyện bất tận về các chất per- và polyfluoroalkyl (PFA S)? *Environ. Sci. Technol.* 2017, *51* (5), 2508–2518.
- (2) Lenka, S. P.; Kah, M.; Padhye, L. P. Tổng quan về sự hiện diện, chuyển hóa và loại bỏ các chất poly- và perfluoroalkyl (PFAS) trong các nhà máy xử lý nước thải. *Water Res.* 2021, *199*, Số 117187.
- (3) Gruber, W.; Villez, K.; Kipf, M.; Wunderlin, P.; Siegrist, H.; Vogt, L.; Joss, A. Phát thải N₂O trong xử lý nước thải quy mô toàn diện: Đề xuất chiến lược giảm sát được cải tiến. *Sci. Total Environ.* 2020, *699*, Số 134157.
- (4) Daelman, M. R. J.; van Voorthuizen, E. M.; van Dongen, U. G. J. M.; Volcke, E. I. P.; van Loosdrecht, M. C. M. Biến thiên theo mùa và trong ngày của lượng phát thải N₂O từ một nhà máy xử lý nước thải đô thị quy mô toàn diện. *Sci. Total Environ.* 2015, *536*, 1–11.
- (5) McCarty, P. L.; Bae, J.; Kim, J. Xử lý nước thải sinh hoạt như một nguồn sản xuất năng lượng ròng—Liệu có thể đạt được điều này? *Environ. Sci. Technol.* 2011, *45* (17), 7100–7106.
- (6) Guest, J. S.; Skerlos, S. J.; Barnard, J. L.; Beck, M. B.; Daigger, G. T.; Hilger, H.; Jackson, S. J.; Karvazy, K.; Kelly, L.; Macpherson, L.; Mihelcic, J. R.; Pramanik, A.; Raskin, L.; Van Loosdrecht, M. C. M.; Yeh, D.; Love, N. G. Một mô hình quy hoạch và thiết kế mới nhằm thu hồi tài nguyên bền vững từ nước thải. *Environ. Sci. Technol.* 2009, *43* (16), 6126–6130.
- (7) Mo, W.; Zhang, Q. Mỗi liên kết năng lượng–dinh dưỡng–nước: Thu hồi tài nguyên tích hợp tại các nhà máy xử lý nước thải đô thị. *J. Environ. Manage.* 2013, *127*, 255–267.
- (8) Glover, G. C.; Printemps, C.; Essemiani, K.; Meinhold, J. Mô hình hóa các nhà máy xử lý nước thải – Chúng ta nên tiến xa đến đâu với các công cụ mô hình hóa phức tạp? *Water Sci. Technol.* 2006, *53* (3), 79–89.
- (9) Zhu, J.-J.; Yang, M.; Ren, Z. J. Học máy trong nghiên cứu môi trường: Những sai lầm thường gặp và các thực hành tốt nhất. *Environ. Sci. Technol.* 2023, *57* (46), 17671–17689.
- (10) Ma, Y.; Qiao, Y.; Chen, M.; Rui, D.; Zhang, X.; Liu, W.; Ye, L. Quy mô nhỏ đến mức nào thì đủ lớn? Dự đoán bằng học máy dựa trên dữ liệu lớn cho một nhà máy xử lý nước thải quy mô toàn diện. *Water Res.* 2025, *274*, Số 123041.
- (11) Li, K.; Duan, H.; Liu, L.; Qiu, R.; van den Akker, B.; Ni, B.-J.; Chen, T.; Yin, H.; Yuan, Z.; Ye, L. Phương pháp tích hợp nguyên lý cơ bản và học sâu để mô hình hóa phát thải nitơ oxit từ các nhà máy xử lý nước thải. *Environ. Sci. Technol.* 2022, *56* (4), 2816–2826.
- (12) Li, H.; Spelman, D.; Sansalone, J. Mô hình hóa đơn vị công đoạn và quy trình bằng học máy có hướng dẫn bởi vật lý. *J. Environ. Eng.* 2024, *150* (4), Số 04024002.
- (13) Quaghebeur, W.; Torfs, E.; De Baets, B.; Nopens, I. Phương trình vi phân lai: Kết hợp các kỹ thuật cơ chế và dựa trên dữ liệu để mô hình hóa các hệ thống nước. *Water Res.* 2022, *213*, Số 118166.
- (14) Zhang, Y.; Wang, J.; Li, C.; Duan, H.; Wang, W. Các mô hình học sâu dựa trên cơ chế chú ý để dự đoán các cú sốc bất thường tại các nhà máy xử lý nước thải. *Water Res.* 2025, *275*, Số 123192.
- (15) Yin, W.-X.; Chen, K.-H.; Lv, J.-Q.; Chen, J.-J.; Liu, S.; Song, Y.-P.; Zhao, Y.-W.; Huang, F.; Bao, H.-X.; Wang, H.-C.; Wang, A.-J.; Ren, N.-Q. Giải mã và giảm thiểu phát thải khí nhà kính biến động trong hệ thống thoát nước đô thị bằng mạng nơ-ron đồ thị tích hợp tri thức. *Environ. Sci. Technol.* 2025, *59* (7), 3592–3602.

- (16) Alvi, M.; Batstone, D.; Mbamba, C. K.; Keymer, P.; French, T.; Ward, A.; Dwyer, J.; Cardell-Oliver, R. Học sâu trong xử lý nước thải: Đánh giá phê bình. *Water Res.* 2023, *245*, Số 120518.
- (17) Koksal, E. S.; Asrav, T.; Esenboga, E. E.; Cosgun, A.; Kusoglu, G.; Aydin, E. Mô hình hóa dựa trên vật lý và dữ liệu cho nhà máy xử lý nước thải công nghiệp với xác thực thực tế. *Comput. Chem. Eng.* 2024, *189*, Số 108801.
- (18) Li, J.; Cheng, K.; Wang, S.; Morstatter, F.; Trevino, R. P.; Tang, J.; Liu, H. Lựa chọn đặc trưng: Góc nhìn dữ liệu. *ACM Comput. Surv.* 2018, *50* (6), 1–45.
- (19) Duan, H.; Li, J.; Yuan, Z. Tạo làn sóng: Hợp nhất tri thức và dữ liệu trong mô hình hóa nước đô thị. *Water Res. X* 2024, *24*, 100234.
- (20) Xu, B.; Zhuang, P.; Wang, Y.; He, W.; Wang, Z.; Liu, Z. C. Hẩn đoán lỗi các quy trình xử lý nước thải dựa trên CPSO-DKPCA. *Int. J. Comput. Intell. Syst.* 2024, *17* (1), 19.
- (21) Lindsey, J.; Gurnee, W.; Ameisen, E.; Chen, B.; Pearce, A.; Turner, N. L.; Citro, C.; Abrahams, D.; Carter, S.; Hosmer, B.; Marcus, J.; Sklar, M.; Templeton, A.; Bricken, T.; McDougall, C.; Cunningham, H.; Henighan, T.; Jermyn, A.; Jones, A.; Persic, A.; Qi, Z.; Thompson, T. B.; Zimmerman, S.; Rivoire, K.; Conerly, T.; Olah, C.; Batson, J. Vẽ sinh học của một mô hình ngôn ngữ lớn. *Transform. Circuits Thread* 2025, sắp xuất bản.
- (22) Radford, A.; Narasimhan, K.; Salimans, T.; Sutskever, I. Cải thiện khả năng hiểu ngôn ngữ bằng tiền huấn luyện sinh; OpenAI, 2018. https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf.
- (23) Gemini Team Google Anil, R.; Borgeaud, S.; Alayrac, J.-B.; Yu, J.; Vinyals, O. et al. Gemini: Một dòng mô hình đa phương thức có năng lực cao. *arXiv*. 2024, <https://doi.org/10.48550/arXiv.2312.11805> ngày 17 tháng 6 (truy cập ngày 2026–06–19).
- (24) Jeong, D. P.; Lipton, Z. C.; Ravikumar, P. K. LLM-Select: Lựa chọn đặc trưng bằng mô hình ngôn ngữ lớn. *Trans. Mach. Learn. Res.*, 2025 <https://openreview.net/forum?id=16f7ea1N3p>.
- (25) Duan, H.; Zhao, Y.; Koch, K.; Wells, G. F.; Zheng, M.; Yuan, Z.; Ye, L. Những hiểu biết về các chiến lược giảm thiểu oxit nitơ trong xử lý nước thải và những thách thức đối với việc triển khai rộng rãi hơn. *Environ. Sci. Technol.* 2021, *55* (11), 7208–7224.
- (26) Wan, X.; Baeten, J. E.; Volcke, E. I. P. Ảnh hưởng của điều kiện vận hành đến phát thải N₂O từ các bể phản ứng nitrit hóa một giai đoạn-Anammox. *Biochem. Eng. J.* 2019, *143*, 24–33.
- (27) Hiatt, W. C.; Grady, C. P. L. Mô hình quy trình cập nhật cho quá trình oxy hóa carbon, nitrat hóa và khử nitrat. *Water Environ. Res.* 2008, *80* (11), 2145–2156.
- (28) Pocquet, M.; Wu, Z.; Queinnec, I.; Spérandio, M. Mô hình hai con đường phát thải N₂O bởi vi khuẩn oxy hóa amoni được hỗ trợ bởi sự biến thiên NO/N₂O. *Water Res.* 2016, *88*, 948–959.
- (29) Hochreiter, S.; Schmidhuber, J. Bộ nhớ ngắn hạn-dài hạn. *Neural Comput.* 1997, *9* (8), 1735–1780.
- (30) Akiba, T.; Sano, S.; Yanase, T.; Ohta, T.; Koyama, M. Optuna: Bộ nhớ ngắn hạn-dài hạn. *Neural Comput.* 1997, *9* (8), 1735–1780.
- (31) Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A. N.; Kaiser, L.; Polosukhin, I. Attention Is All You Need. In *Advances in Neural Information Processing Systems*; Curran Associates, Inc., 2017; Vol. 30.
- (32) Wu, Y.; Tan, H. Short-Term Traffic Flow Forecasting with Spatial-Temporal Correlation in a Hybrid Deep Learning Framework. *arXiv*. 2016, <https://doi.org/10.48550/arXiv.1612.01022> ngày 3 tháng 12 (truy cập ngày 2026–06–19).
- (33) Narayanan, S.; Braza, J. D.; Griffiths, R.-R.; Ponnampati, M.; Bou, A.; Laurent, J.; Kabeli, O.; Wellawatte, G.; Cox, S.; Rodrigues, S. G.; White, A. D. Aviary: Huấn luyện tác tử ngôn ngữ thực hiện các nhiệm vụ khoa học đầy thách thức. *arXiv*. 2024, <https://doi.org/10.48550/arXiv.2412.21154> ngày 30 tháng 12 (truy cập ngày 2026–06–19).
- (34) Skarlinski, M. D.; Cox, S.; Laurent, J. M.; Braza, J. D.; Hinks, M.; Hammerling, M. J.; Ponnampati, M.; Rodrigues, S. G.; White, A. D. Các tác tử ngôn ngữ đạt khả năng tổng hợp khoa học siêu phàm

Knowledge. *arXiv*. 2024, <https://doi.org/10.48550/arXiv.2409.13740> September 26 (accessed 2026–06–19).

(35) Lála, J.; O'Donoghue, O.; Shtedritski, A.; Cox, S.; Rodriques, S. G.; White, A. D. PaperQA: Retrieval-Augmented Generative Agent for Scientific Research. *arXiv*. 2023, <https://doi.org/10.48550/arXiv.2312.07559> December 14 (accessed 2026–06–19).

(36) Reimers, N.; Gurevych, I. Optimal Hyperparameters for Deep LSTM-Networks for Sequence Labeling Tasks. *arXiv*. 2017, <https://doi.org/10.48550/arXiv.1707.06799> August 16 (accessed 2026–06–19).

(37) Wen, X.; Li, W. Time Series Prediction Based on LSTM-Attention-LSTM Model. *IEEE Access* **2023**, *11*, 48322–48331.

(38) Song, J.; Xu, Z.; Zhong, Y. Out-of-Distribution Generalization via Composition: A Lens through Induction Heads in Transformers. *Proc. Natl. Acad. Sci. U. S. A.* **2025**, *122* (6), No. e2417182122.

(39) Cai, J.; Luo, J.; Wang, S.; Yang, S. Feature Selection in Machine Learning: A New Perspective. *Neurocomputing* **2018**, *300*, 70–79.

(40) LeCun, Y.; Bengio, Y.; Hinton, G. Deep Learning. *Nature* **2015**, *521* (7553), 436–444.

(41) Dormann, C. F.; Elith, J.; Bacher, S.; Buchmann, C.; Carl, G.; Carré, G.; Marquéz, J. R. G.; Gruber, B.; Lafourcade, B.; Leitão, P. J.; Münkemüller, T.; McClean, C.; Osborne, P. E.; Reineking, B.; Schröder, B.; Skidmore, A. K.; Zurell, D.; Lautenbach, S. Collinearity: A Review of Methods to Deal with It and a Simulation Study Evaluating Their Performance. *Ecography* **2013**, *36* (1), 27–46.

(42) Bolón-Canedo, V.; Sánchez-Marño, N.; Alonso-Betanzos, A. Feature Selection for High-Dimensional Data. *Prog. Artif. Intell.* **2016**, *5* (2), 65–75.

(43) Hastie, T.; Tibshirani, R.; Friedman, J. H.; Friedman, J. H.. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*; Springer, 2009; Vol. 2.

(44) Zhang, C.; Bengio, S.; Hardt, M.; Recht, B.; Vinyals, O. Understanding Deep Learning Requires Rethinking Generalization. In *Proceedings of the 5th International Conference on Learning Representations (ICLR 2017)*; Toulon, France, 2017 <https://openreview.net/pdf?id=Sy8gdB9xx>.

(45) Zanotti, M. On the Retraining Frequency of Global Models in Retail Demand Forecasting. *Mach. Learn. Appl.* **2025**, *22*, No. 100769.

(46) Domingos, P. A Few Useful Things to Know about Machine Learning. *Commun. ACM* **2012**, *55* (10), 78–87.

(47) Yao, H.; Li, Q.; Li, X. Trajectory Prediction Dimensionality Reduction for Low-Cost Connected Automated Vehicle Systems. *Transp. Res. Part Transp. Environ.* **2022**, *111*, No. 103439.

(48) Lim, B.; Arık, S. Ö.; Loeff, N.; Pfister, T. Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting. *Int. J. Forecast.* **2021**, *37* (4), 1748–1764.

(49) Wang, H.; Jing, X.; Niu, B. A Discrete Bacterial Algorithm for Feature Selection in Classification of Microarray Gene Expression Cancer Data. *Knowl.-Based Syst.* **2017**, *126*, 8–19.

(50) Jain, I.; Jain, V. K.; Jain, R. Correlation Feature Selection Based Improved-Binary Particle Swarm Optimization for Gene Selection and Cancer Classification. *Appl. Soft Comput.* **2018**, *62*, 203–215.

(51) Tang, X.; Dai, Y.; Xiang, Y. Feature Selection Based on Feature Interactions with Application to Text Categorization. *Expert Syst. Appl.* **2019**, *120*, 207–216.

(52) Kushwaha, N.; Pant, M. Link Based BPSO for Feature Selection in Big Data Text Clustering. *Future Gener. Comput. Syst.* **2018**, *82*, 190–199.

(53) Sharma, V.; Juglan, K. C. Automated Classification of Fatty and Normal Liver Ultrasound Images Based on Mutual Information Feature Selection. *IRBM* **2018**, *39* (5), 313–323.

(54) Arora, N.; Kaur, P. D. A Bolasso Based Consistent Feature Selection Enabled Random Forest Classification Algorithm: An Application to Credit Risk Assessment. *Appl. Soft Comput.* **2020**, *86*, No. 105936.

(55) Guyon, I.; Elisseeff, A. An Introduction to Variable and Feature Selection. *J. Mach. Learn. Res.* **2003**, *3* (Mar), 1157–1182.

(56) Battiti, R. Using Mutual Information for Selecting Features in Supervised Neural Net Learning. *IEEE Trans. Neural Netw.* **1994**, *5* (4), 537–550.

(57) Yang, J.; Honavar, V. Feature Subset Selection Using a Genetic Algorithm. *IEEE Intell. Syst. Their Appl.* **1998**, *13* (2), 44–49.

(58) Zini, L.; Noceti, N.; Fusco, G.; Odone, F. Structured Multi-Class Feature Selection with an Application to Face Recognition. *Pattern Recognit. Lett.* **2015**, *55*, 35–41.

(59) Gui, N.; Ge, D.; Hu, Z. AFS: An Attention-Based Mechanism for Supervised Feature Selection. *Proc. AAAI Conf. Artif. Intell.* **2019**, *33* (01), 3705–3713.

(60) Qin, R.; Zhang, Z.; Huang, J.; Su, Y.; Wen, G.; He, W.; Chen, X. Deformable Convolutional Autoencoder-Based Feature Selection and Recognition for Acoustic Emission Monitoring in Laser Shock Peening. *Weld. World* **2025**, *69* (5), 1241–1254.

(61) DeLuca, N. M.; Mullikin, A.; Brumm, P.; Rappold, A. G.; Cohen Hubal, E. Using Geospatial Data and Random Forest To Predict PFAS Contamination in Fish Tissue in the Columbia River Basin, United States. *Environ. Sci. Technol.* **2023**, *57* (37), 14024–14035.

(62) Zhu, Y.; Wang, Y.; Zhu, E.; Ma, Z.; Wang, H.; Chen, C.; Guan, J.; Waite, T. D. Predicting Membrane Fouling of Submerged Membrane Bioreactor Wastewater Treatment Plants Using Machine Learning. *Environ. Sci. Technol.* **2025**, *59* (20), 10010–10021.

(63) Wang, Y.; Dong, J.; Zhou, Y.; Cheng, Y.; Zhao, X.; Peijnenburg, W. J. G. M.; Vijver, M. G.; Leung, K. M. Y.; Fan, W.; Wu, F. Addressing the Data Scarcity Problem in Ecotoxicology via Small Data Machine Learning Methods. *Environ. Sci. Technol.* **2025**, *59* (12), 5867–5871.

(64) Song, M. J.; Choi, S.; Bae, W. B.; Lee, J.; Han, H.; Kim, D. D.; Kwon, M.; Myung, J.; Kim, Y. M.; Yoon, S. Identification of Primary Effecters of N2O Emissions from Full-Scale Biological Nitrogen Removal Systems Using Random Forest Approach. *Water Res.* **2020**, *184*, No. 116144.

(65) Chen, Y.; Zhang, H.; You, Y.; Zhang, J.; Tang, L. A Hybrid Deep Learning Model Based on Signal Decomposition and Dynamic Feature Selection for Forecasting the Influent Parameters of Wastewater Treatment Plants. *Environ. Res.* **2025**, *266*, No. 120615.

(66) Inbar, O.; Avisar, D. Enhancing Wastewater Treatment through Artificial Intelligence: A Comprehensive Study on Nutrient Removal and Effluent Quality Prediction. *J. Water Process Eng.* **2024**, *61*, No. 105212.

(67) Zhou, P.; Li, Z.; Snowling, S.; Goel, R.; Zhang, Q. Multi-Step Ahead Prediction of Hourly Influent Characteristics for Wastewater Treatment Plants: A Case Study from North America. *Environ. Monit. Assess.* **2022**, *194* (5), 389.

Downloaded from pubs.acs.org/est/hg/article-pdf/60/26/19882/6588436/acs.est.6c04963.pdf by guest on 05 October 2026

Knowledge. *arXiv*. 2024, <https://doi.org/10.48550/arXiv.2409.13740> ngày 26 tháng 9 (truy cập ngày 19 tháng 6 năm 2026–06–). (35) Lála, J.; O'Donoghue, O.; Shtedritski, A.; Cox, S.; Rodriques, S. G.; White, A. D. PaperQA: Tác tử tạo sinh tăng cường truy xuất dành cho nghiên cứu khoa học. *arXiv*. 2023, <https://doi.org/10.48550/arXiv.2312.07559> ngày 14 tháng 12 (truy cập ngày 19 tháng 6 năm 2026–06–). (36) Reimers, N.; Gurevych, I. Các siêu tham số tối ưu cho mạng LSTM sâu trong các tác vụ gán nhãn chuỗi. *arXiv*. 2017, <https://doi.org/10.48550/arXiv.1707.06799> ngày 16 tháng 8 (truy cập ngày 19 tháng 6 năm 2026–06–). (37) Wen, X.; Li, W. Dự đoán chuỗi thời gian dựa trên mô hình LSTM-Attention-LSTM. *IEEE Access* **2023**, *11*, 48322–48331. (38) Song, J.; Xu, Z.; Zhong, Y. Khả năng khái quát hóa ngoài phân phối thông tin học: Góc nhìn từ các đầu cảm ứng trong Transformer. *Proc. Natl. Acad. Sci. U. S. A.* **2025**, *122* (6), Số e2417182122. (39) Cai, J.; Luo, J.; Wang, S.; Yang, S. Lựa chọn đặc trưng trong học máy: Một góc nhìn mới. *Neurocomputing* **2018**, *300*, 70–79. (40) LeCun, Y.; Bengio, Y.; Hinton, G. Học sâu. *Nature* **2015**, *521* (7553), 436–444. (41) Dormann, C. F.; Elith, J.; Bacher, S.; Buchmann, C.; Carl, G.; Carré, G.; Marquéz, J. R. G.; Gruber, B.; Lafourcade, B.; Leitão, P. J.; Münkemüller, T.; McClean, C.; Osborne, P. E.; Reineking, B.; Schröder, B.; Skidmore, A. K.; Zurell, D.; Lautenbach, S. Đa cộng tuyến: Tổng quan các phương pháp xử lý và nghiên cứu mô phỏng đánh giá hiệu quả của chúng. *Ecography* **2013**, *36* (1), 27–46. (42) Bolón-Canedo, V.; Sánchez-Marño, N.; Alonso-Betanzos, A. Lựa chọn đặc trưng cho dữ liệu nhiều chiều. *Prog. Artif. Intell.* **2016**, *5* (2), 65–75. (43) Hastie, T.; Tibshirani, R.; Friedman, J. H.; Friedman, J. H.. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*; Springer, 2009; Tập 2. (44) Zhang, C.; Bengio, S.; Hardt, M.; Recht, B.; Vinyals, O. Để hiểu học sâu cần suy nghĩ lại về khả năng khái quát hóa. Trong *Proceedings of the 5th International Conference on Learning Representations (ICLR 2017)*; Toulon, France, 2017 <https://openreview.net/pdf?id=Sy8gdB9xx>. (45) Zanotti, M. Về tần suất huấn luyện lại các mô hình toàn cục trong dự báo nhu cầu bán lẻ. *Mach. Learn. Appl.* **2025**, *22*, Số 100769. (46) Domingos, P. Một vài điều hữu ích cần biết về học máy. *Commun. ACM* **2012**, *55* (10), 78–87. (47) Yao, H.; Li, Q.; Li, X. Giảm chiều dự đoán quỹ đạo cho các hệ thống xe tự hành kết nối chi phí thấp. *Transp. Res. Part Transp. Environ.* **2022**, *111*, Số 103439. (48) Lim, B.; Arık, S. Ö.; Loeff, N.; Pfister, T. Transformer hợp nhất theo thời gian cho dự báo chuỗi thời gian nhiều chân trời có thể diễn giải. *Int. J. Forecast.* **2021**, *37* (4), 1748–1764. (49) Wang, H.; Jing, X.; Niu, B. Thuật toán vi khuẩn rời rạc để lựa chọn đặc trưng trong phân loại dữ liệu biểu hiện gen ung thư từ vi mô ảnh. *Knowl.-Based Syst.* **2017**, *126*, 8–19. (50) Jain, I.; Jain, V. K.; Jain, R. Lựa chọn đặc trưng tương quan kết hợp tối ưu hóa bầy hạt nhị phân cải tiến để chọn gen và phân loại ung thư. *Appl. Soft Comput.* **2018**, *62*, 203–215. (51) Tang, X.; Dai, Y.; Xiang, Y. Lựa chọn đặc trưng dựa trên tương tác giữa các đặc trưng, ứng dụng vào phân loại văn bản. *Expert Syst. Appl.* **2019**, *120*, 207–216. (52) Kushwaha, N.; Pant, M. BPSO dựa trên liên kết để lựa chọn đặc trưng trong phân cụm văn bản dữ liệu lớn. *Future Gener. Comput. Syst.* **2018**, *82*, 190–199. (53) Sharma, V.; Juglan, K. C. Phân loại tự động ảnh siêu âm gan nhiễm mỡ và gan bình thường dựa trên lựa chọn đặc trưng bằng thông tin tương hỗ. *IRBM* **2018**, *39* (5), 313–323. (54) Arora, N.; Kaur, P. D. Thuật toán phân loại rừng ngẫu nhiên với lựa chọn đặc trưng nhất quán dựa trên Bolasso: Ứng dụng trong đánh giá rủi ro tín dụng. *Appl. Soft Comput.* **2020**, *86*, Số 105936. (55) Guyon, I.; Elisseeff, A. Giới thiệu về lựa chọn biến và đặc trưng. *J. Mach. Learn. Res.* **2003**, *3* (Tháng 3), 1157–1182.

(56) Battiti, R. Sử dụng thông tin tương hỗ để lựa chọn đặc trưng trong quá trình học mạng nơ-ron có giám sát. *IEEE Trans. Neural Netw.* **1994**, *5* (4), 537–550. (57) Yang, J.; Honavar, V. Lựa chọn tập con đặc trưng bằng thuật toán di truyền. *IEEE Intell. Syst. Their Appl.* **1998**, *13* (2), 44–49. (58) Zini, L.; Noceti, N.; Fusco, G.; Odone, F. Lựa chọn đặc trưng đa lớp có cấu trúc với ứng dụng nhận dạng khuôn mặt. *Pattern Recognit. Lett.* **2015**, *55*, 35–41. (59) Gui, N.; Ge, D.; Hu, Z. AFS: Cơ chế dựa trên sự chú ý để lựa chọn đặc trưng có giám sát. *Proc. AAAI Conf. Artif. Intell.* **2019**, *33* (01), 3705–3713. (60) Qin, R.; Zhang, Z.; Huang, J.; Su, Y.; Wen, G.; He, W.; Chen, X. Lựa chọn và nhận dạng đặc trưng dựa trên bộ mã hóa tự động tích chập biến dạng để giám sát phát xạ âm trong quá trình phun bi xung kích laser. *Weld. World* **2025**, *69* (5), 1241–1254. (61) DeLuca, N. M.; Mullikin, A.; Brumm, P.; Rappold, A. G.; Cohen Hubal, E. Sử dụng dữ liệu không gian địa lý và rừng ngẫu nhiên để dự đoán ô nhiễm PFAS trong mô cá tại lưu vực sông Columbia, Hoa Kỳ. *Environ. Sci. Technol.* **2023**, *57* (37), 14024–14035. (62) Zhu, Y.; Wang, Y.; Zhu, E.; Ma, Z.; Wang, H.; Chen, C.; Guan, J.; Waite, T. D. Dự đoán hiện tượng tắc nghẽn màng trong các nhà máy xử lý nước thải bằng bề mặt phản ứng sinh học màng chìm sử dụng học máy. *Environ. Sci. Technol.* **2025**, *59* (20), 10010–10021. (63) Wang, Y.; Dong, J.; Zhou, Y.; Cheng, Y.; Zhao, X.; Peijnenburg, W. J. G. M.; Vijver, M. G.; Leung, K. M. Y.; Fan, W.; Wu, F. Giải quyết vấn đề khan hiếm dữ liệu trong độc chất học sinh thái thông qua các phương pháp học máy với dữ liệu nhỏ. *Environ. Sci. Technol.* **2025**, *59* (12), 5867–5871. (64) Song, M. J.; Choi, S.; Bae, W. B.; Lee, J.; Han, H.; Kim, D. D.; Kwon, M.; Myung, J.; Kim, Y. M.; Yoon, S. Xác định các tác nhân hình gây phát thải N2O từ các hệ thống loại bỏ nitơ sinh học quy mô toàn phần bằng phương pháp rừng ngẫu nhiên. *Water Res.* **2020**, *184*, số 116144. (65) Chen, Y.; Zhang, H.; You, Y.; Zhang, J.; Tang, L. Mô hình học sâu lai dựa trên phân rã tín hiệu và lựa chọn đặc trưng động để dự báo các thông số nước thải đầu vào của nhà máy xử lý nước thải. *Environ. Res.* **2025**, *266*, số 120615. (66) Inbar, O.; Avisar, D. Nâng cao hiệu quả xử lý nước thải thông qua trí tuệ nhân tạo: Nghiên cứu toàn diện về loại bỏ chất dinh dưỡng và dự đoán chất lượng nước thải đầu ra. *J. Water Process Eng.* **2024**, *61*, số 105212. (67) Zhou, P.; Li, Z.; Snowling, S.; Goel, R.; Zhang, Q. Dự đoán trước nhiều bước các đặc tính nước thải đầu vào theo giờ tại các nhà máy xử lý nước thải: Nghiên cứu trường hợp ở Bắc Mỹ. *Environ. Monit. Assess.* **2022**, *194* (5), 389.

Downloaded from pubs.acs.org/est/hg/article-pdf/60/26/19882/6588436/acs.est.6c04963.pdf by guest on 05 October 2026