


Machine learning for membrane bioreactor research: principles, methods, applications, and a tutorial

Yizhe Lai¹, Kang Xiao ^{1,2,3}, Yifan He⁵, Xian Liu^{3,4}, Jihua Tan^{1,3}, Wenchao Xue⁵, Aiqian Zhang^{3,4}, Xia Huang⁶

1. Beijing Yanshan Earth Critical Zone National Research Station, College of Resources and Environment, University of Chinese Academy of Sciences, Beijing 101408, China
2. Key Laboratory of Earth System Numerical Modeling and Application, University of Chinese Academy of Sciences, Beijing 101408, China
3. Environmental Chemistry Faculty, College of Resources and Environment, University of Chinese Academy of Sciences, Beijing 101408, China
4. State Key Laboratory of Environmental Chemistry and Ecotoxicology, Research Center for Eco-Environmental Sciences, Chinese Academy of Sciences, Beijing 100085, China
5. Department of Energy, Environment, and Climate Change, School of Environment, Resources, and Development, Asian Institute of Technology, P.O. Box 4, Klong Luang, Pathumthani 12120, Thailand
6. State Key Joint Laboratory of Environment Simulation and Pollution Control, School of Environment, Tsinghua University, Beijing 100084, China

HIGHLIGHTS

- Principles and methods of machine learning for MBR application are summarized.
- Available models for MBR pollutant removal and membrane fouling are reviewed.
- A tutorial is given to illustrate machine learning models for fouling prediction.
- Limitations and future improvements for MBR intelligent operation are discussed.



ABSTRACT: Membrane fouling poses a significant challenge to the sustainable development of membrane bioreactor (MBR) technologies for wastewater treatment. The accurate prediction of the membrane filtration process is of great importance for identifying and controlling fouling. Machine learning methods address the limitations of traditional statistical approaches, such as low accuracy, poor generalization ability, and slow convergence, particularly in predicting complex filtration and fouling processes within the realm of big data. This article provides an in-depth exposition of machine learning theory. The study then reviews advances in MBRs that utilize machine learning methods, including artificial neural networks (ANN), support vector machines (SVM), decision trees, and ensemble learning. Based on current literature, this study summarizes and compares the model input and output characteristics (including foulant characteristics, solution environments, filtration conditions, operating

 Corresponding author. E-mail: kxiao@ucas.ac.cn

Article history: Received 26 August 2024, Revised 29 October 2024, Accepted 22 November 2024, Available online 20 December 2024

© Higher Education Press 2025

Học máy trong nghiên cứu thiết bị phản ứng sinh học màng: nguyên lý, phương pháp, ứng dụng và hướng dẫn thực hành


Yizhe Lai¹, Kang Xiao

^{1,2,3}, Yifan He⁵, Xian Liu^{3,4}, Jihua Tan^{1,3}, Wenchao Xue⁵, Aiqian Zhang^{3,4}, Xia Huang⁶

1. Trạm Nghiên cứu Quốc gia về Vùng tới hạn Trái Đất Yanshan, Bắc Kinh, Trường Tài nguyên và Môi trường, Đại học Viện Hàn lâm Khoa học Trung Quốc, Bắc Kinh 101408, Trung Quốc 2. Phòng thí nghiệm Trọng điểm về Mô hình hóa và Ứng dụng Số của Hệ thống Trái Đất, Đại học Viện Hàn lâm Khoa học Trung Quốc, Bắc Kinh 101408, Trung Quốc 3. Khoa Hóa học Môi trường, Trường Tài nguyên và Môi trường, Đại học Viện Hàn lâm Khoa học Trung Quốc, Bắc Kinh 101408, Trung Quốc 4. Phòng thí nghiệm Trọng điểm Nhà nước về Hóa học Môi trường và Độc chất Sinh thái, Trung tâm Nghiên cứu Khoa học Sinh thái và Môi trường, Viện Hàn lâm Khoa học Trung Quốc, Bắc Kinh 100085, Trung Quốc 5. Khoa Năng lượng, Môi trường và Biến đổi Khí hậu, Trường Môi trường, Tài nguyên và Phát triển, Viện Công nghệ châu Á, Hộp thư 4, Klong Luang, Pathumthani 12120, Thái Lan 6. Phòng thí nghiệm Trọng điểm Liên hợp Nhà nước về Mô phỏng Môi trường và Kiểm soát Ô nhiễm, Trường Môi trường, Đại học Thanh Hoa, Bắc Kinh 100084, Trung Quốc

ĐIỂM NỔI BẬT

- Các nguyên tắc và phương pháp học máy cho ứng dụng MBR được tóm tắt.
- Các mô hình hiện có về loại bỏ chất ô nhiễm bằng MBR và hiện tượng tắc màng được tổng quan.
- Một hướng dẫn được cung cấp để minh họa các mô hình học máy dự đoán sự bám bẩn.
- Các hạn chế và cải tiến trong tương lai đối với hoạt động thông minh của MBR được thảo luận.



TÓM TẮT: Sự tắc nghẽn màng đặt ra thách thức đáng kể đối với sự phát triển bền vững của công nghệ bể phản ứng sinh học màng (MBR) trong xử lý nước thải. Việc dự đoán chính xác quá trình lọc qua màng có ý nghĩa quan trọng trong việc xác định và kiểm soát hiện tượng tắc nghẽn. Các phương pháp học máy khắc phục những hạn chế của các phương pháp thống kê truyền thống, chẳng hạn như độ chính xác thấp, khả năng khái quát hóa kém và hội tụ chậm, đặc biệt là khi dự đoán các quá trình lọc và tắc nghẽn phức tạp trong lĩnh vực dữ liệu lớn. Bài viết này trình bày chuyên sâu về lý thuyết học máy. Sau đó, nghiên cứu tổng quan những tiến bộ trong các hệ thống MBR ứng dụng các phương pháp học máy, bao gồm mạng nơ-ron nhân tạo (ANN), máy véc-tơ hỗ trợ (SVM), cây quyết định và học tổ hợp. Dựa trên các tài liệu hiện có, nghiên cứu này tổng hợp và so sánh các đặc điểm đầu vào và đầu ra của mô hình, bao gồm đặc tính của chất gây tắc nghẽn, môi trường dung dịch, điều kiện lọc, điều kiện vận hành

 Corresponding author. E-mail: kxiao@ucas.ac.cn

Article history: Received 26 August 2024, Revised 29 October 2024, Accepted 22 November 2024, Available online 20 December 2024

© Higher Education Press 2025

conditions, and time factors), as well as the selection of models and optimization algorithms. The modeling procedures of SVM, random forest (RF), back propagation neural network (BPNN), long short-term memory (LSTM), and genetic algorithm-back propagation (GA-BP) methods are elucidated through a tutorial example. The simulation results demonstrated that all five methods yielded accurate predictions with $R^2 > 0.8$. Finally, the existing challenges in the implementation of machine learning models in MBRs were analyzed. It is notable that integration of deep learning, automated machine learning (AutoML) and explainable artificial intelligence (XAI) may facilitate the deployment of models in practical engineering applications. The insights presented here are expected to facilitate the establishment of an intelligent control framework for MBR processes in future endeavors.

KEYWORDS: Membrane bioreactor, Machine learning, Pollutant removal, Membrane fouling, Model prediction

các điều kiện, và yếu tố thời gian), cũng như việc lựa chọn mô hình và thuật toán tối ưu hóa. Các quy trình mô hình hóa của SVM, rừng ngẫu nhiên (RF), mạng nơ-ron lan truyền ngược BPNN), bộ nhớ dài-ngắn hạn (LSTM), và phương pháp thuật toán di truyền-lan truyền ngược (GA-BP) được minh họa thông qua một ví dụ hướng dẫn. Các kết quả mô phỏng cho thấy cả năm phương pháp đều đưa ra các dự đoán chính xác với $R^2 > 0.8$. Cuối cùng, các thách thức hiện tại trong việc triển khai các mô hình học máy trong MBR được phân tích. Đáng chú ý, việc tích hợp học sâu, học máy tự động (AutoML) và trí tuệ nhân tạo có thể giải thích (XAI) có thể tạo điều kiện thuận lợi cho việc triển khai các mô hình trong các ứng dụng kỹ thuật thực tiễn. Những góc nhìn được trình bày ở đây được kỳ vọng sẽ tạo điều kiện thuận lợi cho việc xây dựng một khuôn khổ điều khiển thông minh cho các quy trình MBR trong những nỗ lực tương lai.

TỪ KHÓA: Màng sinh học máy học, Loại bỏ chất ô nhiễm, Dự đoán mô hình

1 Introduction

Wastewater treatment and reclamation are essential strategies for alleviating water crisis caused by water scarcity and pollution. The membrane bioreactor (MBR) technology, a combination of membrane separation and biological treatment (Yamamoto et al., 1989), has been widely used in recent years owing to its advantages of excellent and stable effluent quality, small footprint, and low residual sludge production (Xiao et al., 2014; Krzeminski et al., 2017; Xiao et al., 2019; Qu et al., 2022). However, membrane fouling during MBR operation leads to decreased flux, deteriorated separation efficiency, increased energy consumption, and shortened membrane lifespan, limiting the techno-economic sustainability (Xiao et al., 2019; Qu et al., 2022).

Membrane fouling is closely related to membrane properties, mixed liquor properties, and operating conditions. The fouling behavior of membrane materials, such as polyvinylidene fluoride, polyethersulfone, polyethylene, and polyacrylonitrile, varies depending on their hydrophilicity/hydrophobicity, pore structure, and surface roughness, all of which influence the membrane-foulant interaction (Yamamoto et al., 2006; Zhang et al., 2008). Generally, a hydrophobic membrane is more prone to fouling than a hydrophilic one (Choi et al., 2002). Membrane pore and foulant size play interactive roles in fouling. Foulants of comparable size to pores can tightly clog pores owing to size exclusion (Meireles et al., 1991), whereas small-size foulants can cause adsorptive fouling within the pores (Kawakatsu et al., 1993). A narrower pore size distribution is favorable for maintaining a stable flux (Shimizu et al., 1990; Meireles et al., 1991). The membrane surface roughness influences the fluid dynamics for particle deposition at the micrometer scale

and the intermolecular contact for foulant adsorption at the nanometer scale (Xu et al., 2020). Empirically, a smoother membrane surface tends to impede the progress of cake layer formation (Vatanpour et al., 2011; Sadeghi et al., 2013; Panda et al., 2015). Mixed liquor suspended solids (MLSS), extracellular polymeric substances (EPS), and soluble microbial products (SMP) all contribute to membrane fouling in MBRs. MLSS is responsible for overall fouling, especially at concentrations above 10 mg/L. EPS and SMP, on the other hand, are critical contributors to physically irreversible fouling. MLSS, EPS, and SMP are closely related to the operating conditions of MBR such as hydraulic retention time (HRT), sludge retention time (SRT), and food-to-microorganism rate (Huang et al., 2011). For instance, an excessively short HRT or long SRT can lead to high concentrations of MLSS and SMP, which can exacerbate fouling. Nonetheless, unusually low MLSS concentrations can also exacerbate fouling, probably due to the excessive release of EPS (Yoon, 2015).

Fouling control strategies can be mainly categorized into three groups: mixed liquor conditioning, filtration conditions adjustment, and physical/chemical cleaning of the fouled membranes (Meng et al., 2017). Mixed liquor conditioning involves the addition of material such as suspended carriers, particles, coagulants, ozone, and other chemicals (Wu and Huang, 2008; Kurita et al., 2014,2015; Juntawang et al., 2017; Zhang et al., 2017; Zhang et al., 2022). These additives can tailor the properties of SMP and EPS and affect the floc structure (Wu et al., 2006; Wu and Huang, 2008; Juntawang et al., 2017; Zhang et al., 2017). The overall fouling rate and cake/gel layer reversibility are influenced by aeration intensity and filtration/relaxation intervals (Liu et al., 2020b). Aeration or air scouring removes foulants from the membrane surface by increasing the cross-flow shear. Physical cleaning (e.g. tap water rinsing,

1 Giới thiệu

Xử lý nước thải và thu hồi là những chiến lược thiết yếu để giảm nhẹ cuộc khủng hoảng nước do tình trạng khan hiếm nước và ô nhiễm gây ra. Công nghệ lò phản ứng sinh học màng (MBR) , là sự kết hợp giữa quá trình phân tách bằng màng và xử lý sinh học (Yamamoto et al., 1989)), đã được sử dụng rộng rãi trong những năm gần đây do có những ưu điểm như chất lượng nước thải đầu ra rất tốt và ổn định , diện tích chiếm dụng nhỏ , và lượng bùn dư thấp được tạo ra (Xiao et al., 2014; Krzeminski et al., 2017; Xiao et al., 2019; Qu et al., 2022). Tuy nhiên, hiện tượng bám bẩn màng trong quá trình vận hành MBR dẫn đến lưu lượng giảm , hiệu suất phân tách suy giảm , mức tiêu thụ năng lượng tăng và tuổi thọ màng bị rút ngắn , làm hạn chế tính bền vững về kinh tế - kỹ thuật của công nghệ (Xiao et al., 2019; Qu et al., 2022).

Hiện tượng bám bẩn màng, đặc tính của hỗn dịch và điều kiện vận hành. Đặc tính tắc nghẽn của các vật liệu màng, chẳng hạn như polyvinylidene fluoride, polyethersulfone, polyethylene và polyacrylonitrile, thay đổi tùy thuộc vào tính ưa nước/kỵ nước, cấu trúc lỗ rỗng, và độ nhám bề mặt, tất cả đều ảnh hưởng đến tương tác giữa màng và chất gây tắc nghẽn (Yamamoto và cộng sự, 2006; Zhang và cộng sự, 2008) . Nhìn chung, màng kỵ nước dễ bị tắc nghẽn hơn màng ưa nước (Choi và cộng sự, 2002) . (Kích thước lỗ rỗng của màng và kích thước chất gây tắc nghẽn có vai trò tương tác trong quá trình tắc nghẽn. Các chất gây tắc nghẽn có kích thước tương đương với kích thước lỗ rỗng có thể làm tắc nghẽn lỗ rỗng một cách chặt chẽ do cơ chế loại trừ theo kích thước (Meireles và cộng sự, 1991) , trong khi các chất gây tắc nghẽn có kích thước nhỏ có thể (gây tắc nghẽn do hấp phụ bên trong lỗ rỗng) (Kawakatsu và cộng sự, 1993)). Sự phân bố kích thước lỗ rỗng hẹp hơn có lợi cho việc (duy trì thông lượng ổn định (Shimizu và cộng sự, 1990; Meireles và cộng sự, 1991). Độ nhám bề mặt màng ảnh hưởng đến động lực học chất lỏng trong quá trình lắng đọng hạt ở quy mô microm

et và tiếp xúc liên phân tử đối với sự hấp phụ chất ô nhiễm ở quy mô nanomet (Xu và cộng sự, 2020). Theo thực nghiệm, bề mặt màng nhẵn hơn thường cản trở quá trình hình thành lớp bám Vatanpour (và cộng sự, 2011; Sadeghi và cộng sự, 2013; Panda và cộng sự, 2015). Chất rắn lơ lửng trong hỗn hợp bùn MLSS), các chất polymer ngoại bào (EPS), và các sản phẩm vi sinh hòa tan (SMP) đều góp phần gây hiện tượng fouling màng trong các MBR. MLSS là nguyên nhân gây ra hiện tượng fouling tổng thể, đặc biệt ở nồng độ trên 10 mg/L. EPS và SMP, mặt khác, là những yếu tố góp phần quan trọng gây ra hiện tượng fouling không thể đảo ngược về mặt vật lý. MLSS, EPS, và SMP có mối liên hệ chặt chẽ với các điều kiện vận hành của MBR, chẳng hạn như thời gian lưu thủy lực (HRT), thời gian lưu bùn (SRT), và tỷ lệ thức ăn trên vi sinh vật (Huang và cộng sự, 2011). Chẳng hạn, thời gian lưu HRT quá ngắn hoặc SRT dài có thể dẫn đến nồng độ MLSS và SMP cao, điều này có thể làm trầm trọng thêm hiện tượng fouling. Tuy nhiên, nồng độ MLSS thấp bất thường cũng có thể làm trầm trọng thêm hiện tượng fouling, có thể do sự giải phóng quá mức của EPS (Yoon, 2015).

Các chiến lược kiểm soát của EPS chủ yếu có thể được chia thành ba nhóm: điều hòa hỗn hợp lỏng, điều chỉnh điều kiện lọc, và làm sạch vật lý/hóa học các màng bị cấu bẩn (Meng et al., 2017)). Điều hòa hỗn hợp lỏng bao gồm việc bổ sung các vật liệu như hạt mang lơ lửng, hạt, chất keo tụ, ozon và các hóa chất khác ((Wu and Huang, 2008; Kurita et al., 2014,2015 ; Juntawang et al., 2017; Zhang et al., 2017; Zhang et al., 2022)). Các chất phụ gia này có thể điều chỉnh đặc tính của SMP và EPS đồng thời ảnh hưởng đến cấu trúc bông bùn (Wu et al., 2006; Wu and Huang, 2008; Juntawang et al., 2017; Zhang et al., 2017). Tốc độ cấu bông tốt và khả năng thuận nghịch của lớp bán bông/lớp gel chịu ảnh hưởng bởi cường độ sục khí và các khoảng thời gian lọc/thư giãn (Liu et al., 2020b)). Sục khí hoặc rửa bằng khí loại bỏ các chất gây cấu bẩn khỏi bề mặt màng bằng cách tăng lực cắt của dòng chảy ngang. Làm sạch vật lý, (ví dụ như rửa bằng nước máy,

membrane effluent rinsing, staggered flow rinsing, backwash, and ultrasonic cleaning) can mitigate reversible fouling, whereas chemical cleaning (using acid, alkali, oxidant, chelating agent, and surfactants) can further alleviate irreversible fouling. However, these fouling control measures are mainly taken a posteriori based on observation of fouling phenomena (such as the increase in transmembrane pressure, TMP) that have already occurred, resulting in a certain lag between the fouling and fouling control. Incorrect control measures can reduce effectiveness, waste energy and chemicals, and lead to membrane damage. Therefore, it is essential to apply suitable control measures with accurate timing and dosage. To achieve early warning and timely control of membrane fouling, it is crucial to develop a model to predict the fouling tendency in its infancy.

Data-driven prediction and regulation models provide a new approach for precise control of membrane fouling. Researchers have progressed in fouling prediction using conventional statistical models. For instance, Zhang et al. (2012) established a partial least squares model ($R^2 = 0.84$) to predict membrane flux from mixed liquor characteristics, including MLSS/EPS/SMP concentrations, relative hydrophobicity, average particle size, and osmotic pressure. Chen et al. (2022) developed a time series model taking temperature as a covariate and online cleaning events as switching variables to predict the trend of TMP in an anaerobic MBR (AnMBR) across seasons ($R^2 = 0.91$). Conventional statistical models can well reflect the relationships between input and output variables. However, these models rely on a priori knowledge of these relationships, which inevitably have the following shortcomings: (a) insufficient fitting accuracy, weak generalization ability, and poor adaptability to fresh samples due to underestimation of the complexity of the real relationships and (b) low computational efficiency for big data analysis and slow convergence when dealing with multiple variables with complex interactions because of the limitations of the model structure. The diversity and complexity of multiple interactive variables are inherent in actual membrane fouling system, making the use of conventional statistical models challenging.

Machine learning is a recent statistical development that complements conventional statistical models. Machine learning has gained increasing attention in environmental engineering as a general artificial intelligence technology (Zhong et al., 2021). Born out of but different from statistical models, machine learning focuses on accurately estimating complex functions using a computer, rather than providing

statistical confidence intervals for these functions. Machine learning algorithms automatically “learn” from experience (data) to improve the system performance (Bishop, 2006). As a black-box model, it has a strong fitting ability, good adaptability, and prediction accuracy in dealing with problems with unknown response functions, complex variable relationships, and large amount of data. These advantages provide good prospects for fouling prediction in MBR systems. In recent years, machine learning has been gradually applied to predicting membrane filtration performances, such as flux, resistance, and permeability, and lent new quantitative support to the analysis of fouling mechanisms (Niu et al., 2022).

This study first introduces four common machine learning models, then reviews the application of machine learning models in predicting pollutant removal and fouling performance, and finally analyzes the limitations of existing models to help future researchers develop new machine learning models for improved fouling prediction in MBRs.

2 Principles and methods of machine learning

Machine learning constructs a model using “training data” to make predictions or decisions without explicit a priori assumptions or programming. Figures 1(a) and 1(b) depict the general and detailed steps of machine learning, respectively. Popular machine learning models include supervised learning, unsupervised learning, and reinforcement learning (RL), as illustrated in Fig. 2. To select an appropriate model, it is necessary to consider several factors, including model principles, problem type (classification, regression, time series, etc.), data volume, feature dimensions, and interpretation requirements. When there are a variety of models to choose, the optimal model can be selected by comparing the model performance, computational costs, and interpretability. Stemming from artificial intelligence, machine learning has found extensive application in the field of environmental science and engineering, enabling the construction of predictive models using diverse data sets, the assessment of feature importance via model interpretation, anomaly detection through historical data comparison, and the advancement of new materials (Zhong et al., 2022).

2.1 Machine learning methods

This section mainly introduces three common machine

rửa bằng nước thải đầu ra của màng , rửa dòng chảy luân phiên , rửa ngược và làm sạch bằng sóng siêu âm) có thể giảm thiểu hiện tượng tắc nghẽn thuận nghịch , trong khi làm sạch hóa học (bằng axit, kiềm, chất oxy hóa, chất tạo phức và chất hoạt động bề mặt) có thể tiếp tục giảm bớt hiện tượng tắc nghẽn không thuận nghịch . Tuy nhiên, các biện pháp kiểm soát tắc nghẽn này chủ yếu được thực hiện sau khi sự việc đã xảy ra , dựa trên việc quan sát các hiện tượng tắc nghẽn (chẳng hạn như sự gia tăng áp suất xuyên màng, TMP) đã xảy ra , dẫn đến một độ trễ nhất định giữa quá trình tắc nghẽn và việc kiểm soát tắc nghẽn . Các biện pháp kiểm soát không phù hợp có thể làm giảm hiệu quả, lãng phí năng lượng và hóa chất, đồng thời dẫn đến hư hỏng màng . Vì vậy, việc áp dụng các biện pháp kiểm soát phù hợp vào đúng thời điểm với thời gian và liều lượng chính xác là điều cần thiết để giảm thiểu tắc nghẽn và kéo dài tuổi thọ của màng lọc. Việc nghiên cứu các mô hình dự đoán tắc nghẽn màng lọc nước thải dựa trên các đặc tính của hỗn hợp bùn, bao gồm nồng độ MLSS/EPS/SMP, tính kỵ nước tương đối, kích thước hạt trung bình và áp suất thẩm thấu. Chen và cộng sự (2022) đã phát triển mô hình chuỗi thời gian, sử dụng nhiệt độ làm biến hiệp biến và các sự kiện làm sạch trực tuyến làm biến chuyển trạng thái, để dự đoán xu hướng TMP trong một hệ thống lọc sinh học màng kỵ khí (AnMBR) qua các mùa, với hệ số 0,91. Các mô hình thống kê truyền thống có thể phản ánh tốt mối quan hệ giữa các biến đầu vào và đầu ra. Tuy nhiên, những mô hình này dựa vào kiến thức tiên nghiệm về các mối quan hệ đó, nên không tránh khỏi các hạn chế sau: a) độ chính xác khớp mô hình chưa đủ, khả năng khái quát hóa yếu và khả năng thích ứng kém với các mẫu mới do đánh giá thấp độ phức tạp của các mối quan hệ thực tế; và b) hiệu suất tính toán thấp khi phân tích dữ liệu lớn, đồng thời hội tụ chậm khi xử lý nhiều biến có tương tác phức tạp do những hạn chế trong cấu trúc mô hình. Sự đa dạng và phức tạp của nhiều biến tương tác là đặc tính vốn có của các hệ thống cấu trúc màng lọc trong thực tế, khiến việc sử dụng các mô hình thống kê truyền thống phát triển trở nên khó khăn. Học máy đã thu hút ngày càng nhiều sự chú ý trong lĩnh vực kỹ thuật môi trường, với tư cách là một công nghệ trí tuệ nhân tạo tổng quát (Zhong và cộng sự, 2021). Ra đời từ những khác biệt với các mô hình thống kê, học máy tập trung vào việc ước tính chính xác các hàm phức tạp bằng một máy tính, thay vì cung cấp

khoảng tin cậy thống kê cho các hàm này. Các thuật toán học máy tự động “học” từ dữ liệu kinh nghiệm () để cải thiện hiệu suất hệ thống (Bishop, 2006). Là một mô hình hộp đen , nó có khả năng khớp dữ liệu mạnh, khả năng thích ứng tốt và độ chính xác dự đoán cao khi xử lý các vấn đề có hàm đáp ứng chưa biết, mối quan hệ phức tạp giữa các biến và lượng dữ liệu lớn. Những ưu điểm này mang lại triển vọng tốt cho việc dự đoán cấu trúc trong các hệ thống MBR . Trong những năm gần đây , học máy đã dần được ứng dụng để dự đoán hiệu suất lọc màng , chẳng hạn như thông lượng , điện trở và độ thấm, đồng thời cung cấp cơ sở định lượng mới cho việc phân tích các cơ chế cấu trúc (Niu và cộng sự, 2022).

Nghiên cứu này trước tiên giới thiệu bốn mô hình học máy phổ biến, sau đó đánh giá việc ứng dụng các mô hình học máy trong dự đoán khả năng loại bỏ chất ô nhiễm và hiệu suất bám bẩn, và cuối cùng phân tích những hạn chế của các mô hình hiện có để giúp các nhà nghiên cứu trong tương lai phát triển các mô hình học máy mới nhằm cải thiện khả năng dự đoán bám bẩn trong MBR.

2 Nguyên lý và phương pháp học máy

Học máy xây dựng mô hình bằng “dữ liệu huấn luyện” để đưa ra dự đoán hoặc quyết định mà không cần các giả định tiên nghiệm hay lập trình rõ ràng. Hình 1(a) và 1(b) lần lượt minh họa các bước tổng quát và chi tiết của học máy. Các mô hình học máy phổ biến bao gồm học có giám sát, học không giám sát và học tăng cường (RL), như minh họa trong Hình 2. Để lựa chọn mô hình phù hợp, cần cân nhắc một số yếu tố, bao gồm nguyên lý của mô hình, loại bài toán (phân loại, hồi quy, chuỗi thời gian, v.v.), khối lượng dữ liệu, số chiều đặc trưng và yêu cầu về khả năng diễn giải. Khi có nhiều mô hình để lựa chọn, có thể chọn mô hình tối ưu bằng cách so sánh hiệu năng, chi phí tính toán và khả năng diễn giải của các mô hình. Bắt nguồn từ trí tuệ nhân tạo, học máy được ứng dụng rộng rãi trong lĩnh vực khoa học và kỹ thuật môi trường, cho phép xây dựng các mô hình dự đoán bằng nhiều bộ dữ liệu khác nhau, đánh giá mức độ quan trọng của đặc trưng thông qua diễn giải mô hình, phát hiện bất thường bằng cách so sánh dữ liệu lịch sử và thúc đẩy phát triển vật liệu mới (Zhong và cộng sự, 2022).

2.1 Các phương pháp học máy

Phần này chủ yếu giới thiệu ba máy móc phổ biến машин




Fig. 1 Machine learning process: (a) general procedure; (b) detailed steps.

Hình 1 Quy trình học máy: (a) quy trình tổng quát; (b) các bước chi tiết.

learning methods: support vector machine (SVM), artificial neural network (ANN), and decision tree. Additionally, a concise overview of the k -nearest neighbor (KNN) algorithm is provided. These four methods have demonstrated their efficacy in addressing classification problems with discrete variables and regression problems with continuous variables. Table 1 summarizes the four methods and their respective scopes of application.

2.1.1 Support vector machine

SVM is a binary classification method rooted in

statistical learning theory, implementing a structural risk minimization strategy. It accomplishes data transformation from a low-dimensional space to a high-dimensional space by constructing a kernel function. SVM can be utilized for solving both classification (support vector classification, SVC) and regression (support vector regression, SVR) problems by finding the optimal dividing hyperplane that classifies the sample data into different categories with the widest “margin” at the border. The sample points closest to the border determine the position of the hyperplane and are thus called support vectors.

SVM is a suitable method for solving nonlinear

các phương pháp học: máy véc-tơ hỗ trợ SVM, mạng nơ-ron nhân tạo ANN và cây quyết định. Ngoài ra, bài viết cung cấp tổng quan ngắn gọn về thuật toán láng giềng gần nhất KNN. Bốn phương pháp này đã chứng minh hiệu quả trong việc giải quyết các bài toán phân loại với biến rời rạc và các bài toán hồi quy với biến liên tục. Bảng 1 tóm tắt bốn phương pháp và phạm vi ứng dụng tương ứng của chúng.

2.1.1 Máy véc-tơ hỗ trợ

SVM là một phương pháp phân loại nhị phân dựa

lý thuyết học thống kê, thực hiện chiến lược tối thiểu hóa rủi ro cấu trúc. Phương pháp này chuyển đổi dữ liệu từ không gian chiều thấp sang không gian nhiều chiều bằng cách xây dựng một hàm kernel. SVM có thể được sử dụng để giải quyết cả bài toán phân loại (phân loại bằng vector hỗ trợ, SVC) lẫn hồi quy (hồi quy bằng vector hỗ trợ, SVR) bằng cách tìm siêu phẳng phân chia tối ưu, phân loại dữ liệu mẫu thành các nhóm khác nhau với “biên” rộng nhất tại ranh giới. Các điểm mẫu gần ranh giới nhất quyết định vị trí của siêu phẳng và do đó được gọi là các vector hỗ trợ.

SVM là một phương pháp phù hợp để giải quyết các b





Fig. 2 Classification of machine learning methods.

Table 1 Summary and comparison of machine learning methods

Method	Advantage	Disadvantage	Scope of environmental application	Potential application scenarios and examples in MBRs
SVM	- Supervised learning. - Clear mathematical basis. - Robust performance with limited sample size. - Rapid prediction capabilities. - Strong interpretability.	- Susceptibility to missing data. - High computational complexity. - Inappropriateness for large data set.	Classification or regression problems where the sample size is not particularly large.	Prediction of TMP and resistance (Liu et al., 2020a).
ANN	- Supervised learning. - Diversified variants and innovations. - Wide range of applicable sample sizes. - Appropriateness for a variety of input data forms. - Robust nonlinear mapping capability.	- Complexity parameter setting. - Challenge of determining the optimal network structure. - Gradient vanishing and exploding issues.	Classification, regression, time series, and feature self-extraction for various sample sizes.	Prediction of effluent quality and biogas yield (Li et al., 2022); prediction of flux and flux recovery rate (Zhao et al., 2020); identification of fouling type (Shi et al., 2022).
Tree-based model	- Supervised learning. - If-then logical basis. - Strong interpretability.	- Susceptibility to noise or missing data. - Challenge of dealing with exclusive OR logic. - Proneness to overfitting.	Interpretable classification or regression problems where the sample size is not particularly large.	Prediction of effluent quality (Zhuang et al., 2021); prediction of flux (Li et al., 2020).
KNN	- Unsupervised learning. - Insensitivity to outliers. - Appropriateness for multimodal and multi-label classification problems.	- High computational complexity. - Susceptibility to sample imbalance. - Low interpretability.	Primarily applicable to handle numerical and nominal data.	Outlier identification and screening.

mapping problems in high-dimensional space with limited samples, and has certain generalization ability. The input to SVM is typically comprised of a series of data points containing multiple features. The number of features is typically ≥ 2 , depending on the modeling problem. When dealing with a small sample size (e.g., a training sample size less than 125 (Qian et al., 2015)), the SVM model generally exhibits superior generalization performance and prediction accuracy. This advantage arises from its relatively low complexity and solid statistical theoretical foundation. However, the computational efficiency decreases when



Hình 2 Phân loại các phương pháp học máy .

Bảng 1 Tóm tắt và so sánh về máy học các phương pháp

Method	Advantage	Disadvantage	Scope of environmental application	Potential application scenarios and examples in MBRs
SVM	- Supervised learning. - Clear mathematical basis. - Robust performance with limited sample size. - Rapid prediction capabilities. - Strong interpretability.	- Susceptibility to missing data. - High computational complexity. - Inappropriateness for large data set.	Classification or regression problems where the sample size is not particularly large.	Prediction of TMP and resistance (Liu et al., 2020a).
ANN	- Supervised learning. - Diversified variants and innovations. - Wide range of applicable sample sizes. - Appropriateness for a variety of input data forms. - Robust nonlinear mapping capability.	- Complexity parameter setting. - Challenge of determining the optimal network structure. - Gradient vanishing and exploding issues.	Classification, regression, time series, and feature self-extraction for various sample sizes.	Prediction of effluent quality and biogas yield (Li et al., 2022); prediction of flux and flux recovery rate (Zhao et al., 2020); identification of fouling type (Shi et al., 2022).
Tree-based model	- Supervised learning. - If-then logical basis. - Strong interpretability.	- Susceptibility to noise or missing data. - Challenge of dealing with exclusive OR logic. - Proneness to overfitting.	Interpretable classification or regression problems where the sample size is not particularly large.	Prediction of effluent quality (Zhuang et al., 2021); prediction of flux (Li et al., 2020).
KNN	- Unsupervised learning. - Insensitivity to outliers. - Appropriateness for multimodal and multi-label classification problems.	- High computational complexity. - Susceptibility to sample imbalance. - Low interpretability.	Primarily applicable to handle numerical and nominal data.	Outlier identification and screening.

ánh xạ các bài toán trong không gian nhiều chiều với số lượng mẫu hạn chế, và có khả năng khái quát hóa nhất định. Đầu vào của SVM thường bao gồm một loạt điểm dữ liệu chứa nhiều đặc trưng. Số lượng đặc trưng thường là ≥ 2 , tùy thuộc vào bài toán mô hình hóa. Khi xử lý một kích thước mẫu nhỏ (ví dụ, một Với quy mô mẫu huấn luyện dưới 125 (Qian et al., 2015)), mô hình SVM thường thể hiện khả năng tổng quát hóa vượt trội, hiệu suất và độ chính xác dự đoán. Ưu thế này xuất phát từ độ phức tạp tương đối thấp và nền tảng lý thuyết thống kê vững chắc. Tuy nhiên, hiệu suất tính toán sẽ giảm khi

the sample size is large, which may require longer time for the calculation. SVM is susceptible to the presence of missing data. Therefore, it is imperative to screen the data set for outliers and to address the issue of missing values prior to SVM modeling. Furthermore, it is important to consider the interpretability of high-dimensional mapping.

SVM has a variety of applications in water engineering and water environments, including leakage detection in water supply system (McMillan et al., 2024), structural analysis or characterization of pollutants (Zhong and Guan, 2023), spectral analysis of water quality (Mallet et al., 2022), monitoring of reactor operation (Vasilaki et al., 2020), ecological monitoring and control in watersheds (Kim et al., 2021a), and the early warning of water quality pollution event (Oliker and Ostfeld, 2014). SVM has also been used to monitor and assess of air quality (Li et al., 2017) and rapidly estimate soil organic carbon (Li et al., 2015).

2.1.2 Artificial neural network

An ANN comprises of a multitude of fundamental neurons that mimic the learning process of the human brain for solving diverse practical issues. As a representative example of connectionist learning, the ANN is one of the most frequently used models in machine learning. An ANN typically contains input, hidden, and output layers. A layer can have a few to millions of neurons, and the number of neurons determines the complexity of the hidden relationships among the data to be learned. The input layer receives training data, which is nonlinearly varied by one or more hidden layers, and the output layer outputs the nonlinearly transformed valuable data, thereby realizing input-to-output mapping. ANN's ability to deal with complex nonlinear problems can be increased by increasing the "depth" (by adding more layers), increasing the "width" (by increasing the number of neurons in a single layer), and optimizing the activation function. The ANN can be employed to address classification, regression, and time-series problems. It is suitable for the resolving problems with varying sample sizes through the multiple variants. The input data are multivariate and can be continuous, discrete, or matrix/image data.

Multilayer perceptron (MLP, also known as back-propagation neural network (BPNN)) (Fig. 3(a)) and radial basis function neural network (RBFNN) (Fig. 3(b)) are the simplest neural networks, typically employed to address regression problems. They can also be employed to address classification problems and

time series puzzles. Compared to MLP and RBFNN, deep neural network (DNN) (e.g., convolutional neural network (CNN) (Fig. 3(c)), recurrent neural network (RNN) (Fig. 3(d)), and graph neural network (GNN)) possess more intricate network architectures and are capable of autonomously extracting features, which reduces the necessity for human intervention and enhances the quality of feature extraction (Zhang et al., 2018). CNNs frequently utilize spatial or image data as inputs to achieve image recognition or spatial feature extraction through convolutional computation (Zeiler and Fergus, 2014; Gao et al., 2019; Kiranyaz et al., 2021). There have been many innovations in CNN, such as GoogLeNet (Szegedy et al., 2015), depth-based CNNs (Szegedy et al., 2016), DenseNet (Huang et al., 2017), wide residual networks (Zagoruyko and Komodakis, 2016), and dual-channel CNN (Ma et al., 2023). RNNs, in particular long short-term memory (LSTM) (Greff et al., 2017), demonstrate certain advantages when input data exhibit temporal characteristics. It is important to note that DNNs present a challenge in terms of increased model complexity and reduced interpretability.

It should be noted that different neural networks may apply different hidden layer activation functions. The Table S1 in Appendix A provides a summary of the hidden layer activation functions that may be employed. In contrast to the conventional S-type activation function, wavelet neural network (WNN) employs a wavelet function as the hidden layer activation function (Alexandridis and Zaprani, 2013). Compared to the traditional MLP, WNN has several benefits such as faster network convergence, prevention of local optimization, and the ability to conduct local time-frequency analysis.

The application of ANN is pervasive in the environmental field, encompassing a multitude of domains. These include the operation or optimization of membrane process systems (Wang et al., 2024b), wastewater treatment (Al-Ghazawi and Alawneh, 2021), prediction of novel pollutants such as disinfection by-products (Kulkarni and Chellam, 2010), prediction of surface or groundwater quality, biogas production (Liu et al., 2021), and environmental adsorption.

2.1.3 Decision tree and ensemble learning

The decision tree is a machine learning method characterized by a tree-like structure. Three common decision tree algorithms (Table S2 in Appendix A), namely ID3, C4.5 (Quinlan, 1993), and categorical regression tree (CART) (Breiman et al., 1984), use

kích thước mẫu là lớn, điều này có thể đòi hỏi thời gian lâu hơn cho việc tính toán. SVM dễ bị ảnh hưởng bởi sự hiện diện của dữ liệu thiếu. Do đó, việc là thiết yếu để sàng lọc tập dữ liệu để tìm ngoại lệ và giải quyết vấn đề về giá trị thiếu trước khi mô hình hóa SVM. Hơn nữa, cần xem xét khả năng diễn giải của phép ánh xạ trong không gian đa chiều.

SVM có nhiều ứng dụng trong kỹ thuật thủy lợi và môi trường nước, bao gồm phát hiện rò rỉ trong hệ thống cấp nước McMillan (và cộng sự, 2024), phân tích cấu trúc hoặc đặc trưng hóa các chất ô nhiễm (Zhong và Guan, 2023), phân tích quang phổ chất lượng nước (Mallet và cộng sự, 2022), giám sát hoạt động của lò phản ứng Vasilaki (và cộng sự, 2020), giám sát sinh thái và kiểm soát tại các lưu vực sông Kim (và cộng sự, 2021a), và cảnh báo sớm về sự cố ô nhiễm chất lượng nước Oliker (và Ostfeld, 2014). SVM cũng được sử dụng để giám sát và đánh giá chất lượng không khí Li (và cộng sự, 2017) và ước tính nhanh hàm lượng carbon hữu cơ trong đất Li và (cộng sự, 2015).

2.1.2 Mạng nơ-ron nhân tạo

Một ANN bao gồm các một số lượng lớn các nơ-ron cơ bản mô phỏng quá trình học tập của bộ não con người để giải quyết nhiều vấn đề thực tiễn khác nhau. Là một ví dụ tiêu biểu về học tập theo kết nối, ANN là một trong những mô hình được sử dụng thường xuyên nhất trong học máy. Một ANN thường bao gồm các lớp đầu vào, lớp ẩn và lớp đầu ra. Một lớp có thể có từ một vài đến hàng triệu nơ-ron, và số lượng nơ-ron xác định độ phức tạp của các mối quan hệ ẩn giữa các dữ liệu cần được học. Lớp đầu vào nhận dữ liệu huấn luyện, được biến đổi phi tuyến qua một hoặc nhiều lớp ẩn, và lớp đầu ra xuất ra dữ liệu có giá trị đã được biến đổi phi tuyến, qua đó thực hiện ánh xạ từ đầu vào sang đầu ra. Khả năng xử lý các vấn đề phi tuyến phức tạp của ANN có thể được nâng cao bằng cách tăng "độ sâu" thông qua việc thêm nhiều lớp hơn, tăng "độ rộng" bằng cách tăng số lượng nơ-ron trong một lớp đơn, và tối ưu hóa hàm kích hoạt. ANN có thể được sử dụng để giải quyết các bài toán phân loại, hồi quy, và chuỗi thời gian. Mô hình này phù hợp để giải quyết (các bài toán với kích thước mẫu khác nhau) thông qua nhiều biến thể. (Dữ liệu đầu vào có nhiều biến và có thể là dữ liệu liên tục, rời rạc hoặc dạng ma trận/ảnh.

Perceptron đa lớp MLP, còn được gọi là mạng nơ-ron (truyền ngược) (BPNN Hình 3(a)) và mạng nơ-ron hàm cơ sở (bán kính) (RBFNN) Hình 3(b)) là những mạng nơ-ron đơn giản nhất, thường được sử dụng để giải quyết các vấn đề hồi quy. Chúng cũng có thể được sử dụng để giải quyết các vấn đề phân loại và

các bài toán chuỗi thời gian. So với MLP và RBFNN, các mạng nơ-ron sâu (DNN), chẳng hạn như mạng nơ-ron tích chập (CNN, Hình 3(c)), mạng nơ-ron hồi tiếp (RNN, Hình 3(d)) và mạng nơ-ron đồ thị (GNN), có kiến trúc mạng phức tạp hơn và có khả năng tự động trích xuất đặc trưng, nhờ đó giảm nhu cầu can thiệp của con người và nâng cao chất lượng trích xuất đặc trưng (Zhang và cộng sự, 2018). CNN thường sử dụng dữ liệu không gian hoặc hình ảnh làm đầu vào để nhận dạng hình ảnh hoặc trích xuất đặc trưng không gian thông qua phép tích chập (Zeiler và Fergus, 2014; Gao và cộng sự, 2019; Kiranyaz và cộng sự, 2021). CNN đã có nhiều cải tiến, chẳng hạn như GoogLeNet (Szegedy và cộng sự, 2015), CNN dựa trên độ sâu (Szegedy và cộng sự, 2016), DenseNet (Huang và cộng sự, 2017), mạng dư rộng (Zagoruyko và Komodakis, 2016) và CNN hai kênh (Ma và cộng sự, 2023). RNN, đặc biệt là bộ nhớ dài-ngắn hạn (LSTM) (Greff và cộng sự, 2017), cho thấy một số ưu điểm khi dữ liệu đầu vào có đặc tính thời gian. Cần lưu ý rằng DNN đặt ra thách thức do độ phức tạp của mô hình tăng lên và khả năng diễn giải giảm đi.

Cần lưu ý rằng các mạng nơ-ron khác nhau có thể áp dụng các hàm kích hoạt lớp ẩn khác nhau. Bảng S1 trong Phụ lục A tóm tắt các hàm kích hoạt lớp ẩn có thể được sử dụng. Khác với hàm kích hoạt kiểu truyền thống, mạng nơ-ron wavelet (WNN) sử dụng hàm wavelet làm hàm kích hoạt lớp ẩn (Alexandridis và Zaprani, 2013). So với MLP truyền thống, WNN có một số lợi ích như hội tụ mạng nhanh hơn, ngăn ngừa tối ưu hóa cục bộ và có khả năng thực hiện phân tích thời gian-tần số cục bộ.

Việc ứng dụng ANN rất phổ biến trong lĩnh vực môi trường, bao gồm nhiều lĩnh vực. Những lĩnh vực này bao gồm vận hành hoặc tối ưu hóa các hệ thống quy trình màng (Wang và cộng sự, 2024b), xử lý nước thải (Al-Ghazawi và Alawneh, 2021), dự đoán các chất ô nhiễm mới như các sản phẩm phụ của quá trình khử trùng (Kulkarni và Chellam, 2010), dự đoán chất lượng nước mặt hoặc nước ngầm, sản xuất khí sinh học (Liu và cộng sự, 2021), và hấp phụ môi trường.

2.1.3 Cây quyết định và học tập tổ hợp

Cây quyết định là một phương pháp học máy có cấu trúc dạng cây. Ba thuật toán cây quyết định phổ biến (Bảng S2 trong Phụ lục A), gồm ID3, C4.5 (Quinlan, 1993) và cây hồi quy phân loại (CART; Breiman và cộng sự, 1984), sử dụng





Fig. 3 Schematic diagrams of artificial neural networks: (a) MLP, (b) RBFNN, (c) CNN, (d) RNN.

different metrics to divide samples. The single decision tree algorithm is typically applied to solve classification problems, whereas the CART method is suited for solving regression problems. The decision tree

algorithm can be considered as a set of if-then rules or a conditional probability distribution defined in both the feature and class spaces. This results in a low model complexity and facilitates good interpretability.



Hình 3 Sơ đồ các mạng nơ-ron nhân tạo: (a) MLP, (b) RBFNN, (c) CNN, (d) RNN.

các thước đo khác nhau để phân chia mẫu. Thuật toán cây quyết định đơn lẻ thường được áp dụng để giải quyết các bài toán phân loại, trong khi phương pháp CART phù hợp để giải quyết các bài toán hồi quy. Cây quyết định

thuật toán có thể được xem là một tập các quy tắc nếu-then hoặc một phân phối xác suất có điều kiện được xác định trong cả không gian đặc trưng và không gian lớp. Điều này dẫn đến độ phức tạp mô hình thấp và giúp tăng khả năng diễn giải.

However, overfitting may occur, potentially leading to weak generalization. To mitigate this, techniques such as pruning, cross-validation (CV), and ensemble learning can be employed to prevent overfitting.

Ensemble learning is a machine learning algorithm that combines a group of base learners (e.g., decision trees, BPNN, etc.) according to a specific strategy to improve the generalization performance of these base learners. Bagging and boosting are two typical ensemble learning implementation algorithms. Random forest (RF) (Breiman, 2001) is an extension of the bagging method. Adaptive boosting, gradient boosting decision tree (GBDT), and eXtreme gradient boosting (Chen and Guestrin, 2016) are extensions of the boosting method. Ensemble learning offers several advantages over base learner approaches, including high accuracy, good generalization performance, fast training speed, good robustness, minimal feature engineering, and a wide range of application scenarios.

Similar to ANN and SVM, decision trees and their integrated learning methods are widely used. Such as, water quality monitoring or classification (Xu et al., 2021), nano-plastics identification (Xie et al., 2023), pollutant degradation (Zhang et al., 2023), air quality prediction (Chen et al., 2020), groundwater contamination prediction (Bindal and Singh, 2019), source of soil contamination (Zhou and Li, 2024), and ecological and environmental evaluation (Espel et al., 2020). With better interpretability, tree models are employed not only for environmental prediction but also for environmental management and decision-making (Jiang et al., 2021).

2.1.4 *k*-nearest neighbors

KNN is an unsupervised machine learning model that measures the distance between different feature values as a basis for classification or regression. KNN model is employed to address the classification problem. It involves finding the *k*-nearest neighbors of the sample to be predicted for regression problem. KNN has obvious advantages, such as high precision, insensitivity to outliers, and no input assumption for sample labels. However, it is important to note that KNN has certain drawbacks, including high computational and space complexity. Hence, KNN is primarily applicable for handling numerical and nominal data.

KNN has a more circumscribed range of applications in the environmental domain than SVM, ANN, and tree models. Nevertheless, it can still be employed to solve a wide range of complex environment problems, including water quality monitoring (Uddin et al., 2023),

wastewater treatment control (Xu et al., 2022), adsorption evaluation (Nguyen et al., 2022), air quality prediction (Tella et al., 2021), etc.

2.1.5 Other methods

In addition to supervised and unsupervised learning, RL is another class of machine learning that relies on the optimal policy for mapping states to behaviors based on the interaction between intelligence and environment, with the objective of maximizing the cumulative rewards (Byeon, 2023). The Markov decision process is a fundamental RL framework. RL is a commonly employed methodology for addressing decision-making and control issues. Several studies have employed RL to optimize wastewater treatment control, including the removal of phosphorus (Mohammadi et al., 2024) and the reduction of energy consumption.

The development of large models (also known as foundation models) represents a significant advancement in the field of artificial intelligence. These models are commonly employed in the domains of natural language processing, computer vision, and multimodal problems. Large models are distinguished by large parameter scale, complex computational structure, multitask learning, and emergence capability. ChatGPT is currently one of the hottest models (Ahmed et al., 2024). At present, large models are employed primarily for addressing large-scale or long-term environment problems, like weather forecasting (Bi et al., 2023) and global methane emissions (Rouet-Leduc and Hulbert, 2024), given the necessity for a substantial number of samples to serve as a foundation for training or learning.

Another rapidly evolving field is automated machine learning (AutoML), which aims to automate the process of building machine learning. A series of automated procedures, including data processing, feature engineering, model/algorithm selection, hypermeter optimization, and model evaluation, have been established to minimize the need for intervention by model developers and enhancing the quality of models (Salehin et al., 2024). AutoML is a valuable tool in computer vision and natural language processing and has been employed in the environmental sector to predict the potential energy surfaces (Abbott et al., 2019) and water quality (Senthil Kumar et al., 2024).

2.1.6 Related algorithms

Fuzzy logic and Monte Carlo methods are frequently utilized algorithms in machine learning. Fuzzy logic represents a multi-valued logic approach to address

Tuy nhiên, hiện tượng khớp quá mức có thể xảy ra, có khả năng dẫn đến khả năng tổng quát hóa kém. Để giảm thiểu điều này, các kỹ thuật như cắt tỉa, kiểm định chéo (CV) và học tổ hợp có thể được áp dụng để ngăn chặn hiện tượng khớp quá mức. Một thuật toán học máy kết hợp một nhóm các thuật toán học cơ sở (ví dụ: cây quyết định, BPNN, v.v.) theo một chiến lược cụ thể để cải thiện hiệu suất khái quát hóa của các thuật toán học cơ sở này. Bagging và boosting là hai thuật toán triển khai học tổ hợp điển hình. Rừng ngẫu nhiên (RF) (Breiman, 2001) là một phần mở rộng của phương pháp bagging. AdaBoost (boosting thích ứng), cây quyết định boosting gradient ((GBDT)) và eXtreme gradient boosting (Chen và Guestrin, 2016) là các phần mở rộng của phương pháp boosting. Học tập tổ hợp mang lại một số ưu điểm so với các phương pháp dựa trên thuật toán học cơ sở, bao gồm độ chính xác cao, hiệu suất khái quát hóa tốt, tốc độ huấn luyện nhanh, độ bền vững cao, ít cần kỹ thuật đặc trưng, nhúng và v.v. Ứng dụng quy hoạch nhúng các phương pháp học tích hợp của chúng được sử dụng rộng rãi, chẳng hạn như trong giám sát hoặc phân loại chất lượng nước (Xu và cộng sự, 2021), nhận diện vi nhựa (Xie và cộng sự, 2023), phân hủy chất ô nhiễm (Zhang và cộng sự, 2023), dự đoán chất lượng không khí (Chen và cộng sự, 2020), dự đoán ô nhiễm nước ngầm (Bindal và Singh, 2019), xác định nguồn ô nhiễm đất (Zhou và Li, 2024), cũng như đánh giá sinh thái và môi trường (Espel và cộng sự, 2020). Nhờ khả năng diễn giải tốt hơn, các mô hình cây không chỉ được sử dụng để dự đoán môi trường mà còn phục vụ quản lý môi trường và ra quyết định (Jiang và cộng sự, 2021).

2.1.4 *k*-láng giềng gần nhất

KNN là một mô hình học máy không giám sát đo khoảng cách giữa các giá trị đặc trưng khác nhau làm cơ sở cho việc phân loại hoặc hồi quy. Mô hình KNN được sử dụng để giải quyết bài toán phân loại. Đối với bài toán hồi quy, phương pháp này tìm các láng giềng gần nhất của mẫu cần được dự đoán. KNN có những ưu điểm rõ rệt, chẳng hạn như độ chính xác cao, ít nhạy cảm với các giá trị ngoại lai, và không đưa ra giả định về nhân của mẫu. Tuy nhiên, điều quan trọng cần lưu ý là KNN có một số nhược điểm, bao gồm độ phức tạp tính toán và không gian cao. Do đó, KNN chủ yếu phù hợp để xử lý dữ liệu số và dữ liệu danh nghĩa.

KNN có phạm vi ứng dụng hạn chế hơn trong lĩnh vực môi trường so với SVM, ANN và các mô hình cây. Tuy nhiên, nó vẫn có thể được sử dụng để giải quyết nhiều vấn đề môi trường phức tạp, bao gồm giám sát chất lượng nước Uddin và cộng sự, 2023),

nước thải xử lý kiểm soát (Xu và cộng sự, 2022), đánh giá hấp phụ (Nguyen và cộng sự, 2022), dự đoán chất lượng không khí (Tella và cộng sự, 2021), v.v.

2.1.5 Các phương pháp khác

Ngoài ra học có giám sát và không giám sát, học tăng cường (RL) là một loại học máy khác, dựa trên chính sách tối ưu để ảnh xạ các trạng thái thành hành vi dựa trên sự tương tác giữa tác nhân thông minh và môi trường, với mục tiêu là tối đa hóa tổng phần thưởng tích lũy (Byeon, 2023)). Quy trình quyết định Markov là một khuôn khổ cơ bản trong học tăng cường. Học tăng cường là một phương pháp luận thường được sử dụng để giải quyết các vấn đề ra quyết định và điều khiển. Một số nghiên cứu đã áp dụng học tăng cường để tối ưu hóa việc xử lý nước thải, bao gồm loại bỏ phốt pho (Mohammadi và cộng sự, 2024) và giảm (mức tiêu thụ năng lượng) các mô hình quy mô lớn, còn được gọi là mô hình nền tảng, đánh dấu một bước tiến đáng kể trong lĩnh vực trí tuệ nhân tạo. Những mô hình này thường được sử dụng trong các lĩnh vực xử lý ngôn ngữ tự nhiên, thị giác máy tính và các bài toán đa phương thức. Mô hình quy mô lớn nổi bật với số lượng tham số lớn, cấu trúc tính toán phức tạp, khả năng học đa nhiệm và năng lực nổi trội. ChatGPT hiện là một trong những mô hình phổ biến nhất (Ahmed và cộng sự, 2024). Hiện nay, mô hình quy mô lớn chủ yếu được sử dụng để giải quyết các bài toán quy mô lớn hoặc liên quan đến môi trường dài hạn, chẳng hạn như dự báo thời tiết (Bi và cộng sự, 2023) và phát thải mê-tan toàn cầu (Rouet-Leduc và Hulbert, 2024), do cần có số lượng mẫu đáng kể làm nền tảng cho quá trình huấn luyện hoặc học tập.

Một lĩnh vực đang phát triển nhanh chóng khác là học máy tự động ((AutoML)), nhằm tự động hóa quy trình xây dựng các mô hình học máy. Một loạt quy trình tự động, bao gồm xử lý dữ liệu, kỹ thuật đặc trưng, lựa chọn mô hình/ thuật toán, tối ưu hóa siêu tham số, và đánh giá mô hình, đã được thiết lập để giảm thiểu nhu cầu can thiệp của các nhà phát triển mô hình và nâng cao chất lượng mô hình (Salehin và cộng sự, 2024). AutoML là một công cụ hữu ích trong lĩnh vực thị giác máy tính và xử lý ngôn ngữ tự nhiên, đồng thời đã được ứng dụng trong lĩnh vực môi trường để dự đoán các bề mặt năng lượng tiềm năng (Abbott và cộng sự, 2019)) và chất lượng nước (Senthil Kumar và cộng sự, 2024).)

2.1.6 Các thuật toán liên quan

Logic mờ và các phương pháp Monte Carlo là những thuật toán được sử dụng phổ biến trong học máy. Logic mờ là một cách tiếp cận logic đa trị để giải quyết

such uncertainty and imprecise information through simulation of human thinking (Zadeh, 2023). Fuzzy logic finds extensive application in control systems (Castillo et al., 2008). The combination of fuzzy logic and neural networks gives rise to a fuzzy neural network, which leverages pre-existing data to generate an expert knowledge base and predict outcomes through fuzzy logic inference (de Campos Souza, 2020). The Monte Carlo method is a numerical calculation method grounded in probability statistics theory (Raychaudhuri, 2008). The method is based on the “large number theorem” to achieve random approximation by repeatedly sampling a data set and performing randomized tests. Monte Carlo methods have been employed in machine learning, particularly in reinforcement learning. For example, the famous AlphaGo applied Monte Carlo method in reinforcement learning to improve the decision-making ability of neural networks (Silver et al., 2016). The integration of these two algorithms with machine learning enables the resolution of complex and uncertain problems in the context of big data.

2.2 Model optimization

Machine learning involves the optimization of multiple parameters during the learning process. A straightforward method for model optimization is CV (including *k*-fold CV, where the check of *k* has no normal rule), where the training data are first split into *k* subsets, and then the subsets are assigned to two parts (Browne, 2000): the training part (*k*-1 subsets) to train the model, and the validation part (the remaining subset outside the training part) to check the error. These two parts of data are used to obtain the model with the least generalization error. CV requires a substantial amount of time throughout repeated re-training and re-verification.

Heuristic intelligent optimization algorithms in the learning process can significantly improve the model performance and convergence rate during the learning process. Intelligent optimization algorithms usually draw inspiration from natural, biological, or physical phenomena. Common intelligent optimization algorithms include genetic algorithms (GA) (Fig. 4(a)) (Katoch et al., 2021), particle swarm optimization (PSO) (Fig. 4(b)), simulated annealing (SA) (Fig. 4(c)) (Suman and Kumar, 2006), artificial bee colony (Karaboga and Basturk, 2007), ant colony optimization (Dorigo et al., 2006), firefly algorithm (FFA) (Yang, 2009), bat algorithm (BA) (Yang, 2010), and gray wolf optimizer (GWO) (Mirjalili et al., 2014). These algorithms have been widely used in various fields to

solve optimization problems with high efficiency and accuracy. It is important to note that each algorithm has its own strengths and weaknesses.

2.3 Assessment of model performance

A statistical model’s performance can usually be evaluated through indicators, such as the coefficient of determination (*R*²), mean square error (MSE), root mean square error (RMSE), and mean absolute percentage error (MAPE) (Niu et al., 2022). The receiver operating characteristic (ROC), area under curve (AUC), accuracy, precision, and recall are frequently employed to assess the efficacy of a binary classifier. *R*², MSE, RMSE, MAPE, ROC, AUC, accuracy, precision, and recall can evaluate the performance of a model, but they are not designed to consider the model complexity (related to the number of unknown parameters).

Information criterion, such as Akaike information criterion (AIC) (Akaike, 1974), Bayesian information criterion (BIC) (Gideon, 1978), and Hannan-Quinn criterion (HQC) (Hannan and Quinn, 1979), can be employed to achieve optimal model selection by balancing the model complexity and model performance. For a large sample size, the model parameter penalty exerted on the three criteria exhibits a gradient from weak to strong as follows: AIC < HQC < BIC (Tu and Xu, 2012). The stronger the penalty, the more inclined it is toward favoring a low-dimensional model. In general, smaller AIC, BIC, or HQC values indicate better model fitting and greater accuracy.

2.4 Assessment of model interpretation

Variable importance metrics aid researchers in better understanding the data generation process by evaluating the relative importance of independent variables with respect to a dependent variable (Kruskal, 1987).

Common tree model interpretation methods include the Shapley value (Samek, 2020) and TreeExplainer method (Lundberg et al., 2020). However, the interpretability of the model decreases when the decision-making involves multiple trees. Therefore, advanced tree models fall into the category of black boxes (Samek, 2020). The variable importance measure is based on changes in out-of-bag prediction accuracy (such as MSE, accuracy) or Gini index when using that variable (Grömping, 2015).

In models like ANN and SVM, the relative importance of input features can be assessed using the simple *R*² (Hosseinzadeh et al., 2020). Variable importance can be evaluated through sensitivity

những điều như sự không chắc chắn và thông tin thiếu chính xác thông qua mô phỏng tư duy của con người (Zadeh, 2023). Logic mờ được ứng dụng rộng rãi trong các hệ thống điều khiển (Castillo và cộng sự, 2008). Sự kết hợp giữa logic mờ và mạng nơ-ron tạo ra mạng nơ-ron mờ, tận dụng dữ liệu sẵn có để xây dựng cơ sở tri thức chuyên gia và dự đoán kết quả thông qua suy luận logic mờ (de Campos Souza, 2020). Phương pháp Monte Carlo là một phương pháp tính toán số dựa trên lý thuyết thống kê xác suất (Raychaudhuri, 2008). Phương pháp này dựa trên “định lý số lớn” để thực hiện phép xấp xỉ ngẫu nhiên bằng cách lấy mẫu lặp đi lặp lại từ một tập dữ liệu và tiến hành các phép thử ngẫu nhiên. Các phương pháp Monte Carlo đã được áp dụng trong học máy, đặc biệt là học tăng cường. Ví dụ, AlphaGo nổi tiếng đã áp dụng phương pháp Monte Carlo trong học tăng cường để cải thiện khả năng ra quyết định của mạng nơ-ron (Silver và cộng sự, 2016). Việc tích hợp hai thuật toán này vào học máy cho phép giải quyết các vấn đề phức tạp và không chắc chắn trong bối cảnh dữ liệu lớn.

2.2 Tối ưu hóa mô hình

Học máy bao gồm việc tối ưu hóa nhiều tham số trong quá trình học. Một phương pháp đơn giản để tối ưu hóa mô hình là CV (bao gồm CV gập lại, trong đó việc kiểm tra không có quy tắc thông thường), theo đó dữ liệu huấn luyện trước tiên được chia thành *g* tập con, rồi các tập con được phân thành hai phần (Browne, 2000): phần huấn luyện gồm *g*-1 tập con để huấn luyện mô hình, còn phần xác thực là tập con còn lại, nằm ngoài phần huấn luyện, để kiểm tra sai số. Hai phần dữ liệu này được dùng để thu được mô hình có sai số khái quát hóa thấp nhất. CV đòi hỏi nhiều thời gian do phải huấn luyện lại và xác minh lặp đi lặp lại.

Các thuật toán tối ưu hóa thông minh trong quá trình học có thể cải thiện đáng kể hiệu suất mô hình và tốc độ hội tụ trong quá trình học. Các thuật toán tối ưu hóa thông minh thường lấy cảm hứng từ các hiện tượng tự nhiên, sinh học hoặc vật lý. Những thuật toán tối ưu hóa thông minh phổ biến bao gồm thuật toán di truyền (GA) (Hình 4(a)) (Katoch và cộng sự, 2021), tối ưu hóa bầy đàn hạt (PSO) (Hình 4(b)), mô phỏng luyện kim (SA) (Hình 4(c)) (Suman và Kumar, 2006), thuật toán đàn ong nhân tạo (Karaboga và Basturk, 2007), tối ưu hóa đàn kiến (Dorigo và cộng sự, 2006), thuật toán đom đóm (FFA) (Yang, 2009), thuật toán dơi (BA) (Yang, 2010) và thuật toán sói xám (GWO) (Mirjalili và cộng sự, 2014). Những thuật toán này đã được sử dụng rộng rãi trong nhiều lĩnh vực để

giải quyết các bài toán tối ưu hóa với hiệu suất cao và độ chính xác. Điều quan trọng cần lưu ý là mỗi thuật toán đều có những điểm mạnh và điểm yếu riêng.

2.3 Đánh giá hiệu suất mô hình

Hiệu suất của một mô hình thống kê thường có thể được đánh giá thông qua các chỉ số như hệ số xác định, sai số bình phương trung bình (MSE), căn bậc hai của sai số bình phương trung bình (RMSE) và sai số phần trăm tuyệt đối trung bình (MAPE) (Niu và cộng sự, 2022). Đường cong đặc tính hoạt động của bộ thu (ROC), diện tích dưới đường cong (AUC), độ chính xác, độ chuẩn xác và độ thu hồi thường được dùng để đánh giá hiệu quả của bộ phân loại nhị phân. MSE, RMSE, MAPE, ROC, AUC, độ chính xác, độ chuẩn xác và độ thu hồi có thể đánh giá hiệu suất của mô hình, nhưng không được thiết kế để xem xét độ phức tạp của mô hình liên quan đến số lượng tham số chưa biết.

Tiêu chí thông tin, chẳng hạn như tiêu chí thông tin Akaike (AIC) (Akaike, 1974), tiêu chí thông tin Bayes (BIC) (Gideon, 1978) và tiêu chí Hannan-Quinn (HQC) (Hannan và Quinn, 1979), có thể được sử dụng để đạt được lựa chọn mô hình tối ưu bằng cách cân bằng độ phức tạp của mô hình và hiệu suất mô hình. Với cỡ mẫu lớn, mức phạt tham số mô hình áp dụng trong ba tiêu chí tăng dần từ thấp đến cao như sau: AIC, HQC, BIC (Tu và Xu, 2012). Mức phạt càng cao thì tiêu chí càng có xu hướng ưu tiên mô hình có số chiều thấp. Nhìn chung, giá trị AIC, BIC hoặc HQC thấp hơn cho thấy mô hình phù hợp tốt hơn và độ chính xác cao hơn.

2.4 Đánh giá khả năng diễn giải mô hình

Các chỉ số mức độ quan trọng giúp các nhà nghiên cứu hiểu rõ hơn quá trình tạo ra dữ liệu bằng cách đánh giá tầm quan trọng tương đối của các biến độc lập so với biến phụ thuộc (Kruskal, 1987).

Các phương pháp diễn giải mô hình cây phổ biến bao gồm giá trị Shapley (Samek, 2020) và phương pháp TreeExplainer (Lundberg et al., 2020). Tuy nhiên, khả năng diễn giải của mô hình giảm khi quá trình ra quyết định liên quan đến nhiều cây. Do đó, các mô hình cây năng cao thuộc nhóm mô hình hộp đen (Samek, 2020). Thước đo mức độ quan trọng của biến dựa trên những thay đổi về độ chính xác của dự đoán ngoài túi (chẳng hạn như MSE, độ chính xác) hoặc chỉ số Gini khi sử dụng biến đó (Grömping, 2015).

Trong các mô hình như ANN và SVM, mức độ quan trọng tương đối của các đặc trưng đầu vào có thể được đánh giá bằng phương pháp đơn giản của Hosseinzadeh et al., 2020. Mức độ quan trọng của biến có thể được đánh giá thông qua độ nhạy







Fig. 4 Intelligent optimization algorithms: (a) genetic algorithms (GA), (b) particle swarm optimization (PSO), (c) simulated annealing (SA).

analysis (Cortez and Embrechts, 2013). For a neural network, it is possible to calculate the variable importance of input variables to the output using methods based on the connection weights of neurons.

Several methods, such as those of Garson (1991), Goh (1995), Gedeon (1997) and Olden (Olden et al., 2004), allow for this assessment. Notably, Gedeon's and Olden's methods use the weights of all connections,



Hình 4 Các thuật toán tối ưu hóa thông minh : (a) thuật toán di truyền GA , (b) (tối ưu hóa bầy đàn) PSO , ủ mô phỏng (SA), (c) ủ mô phỏng (SA).

phân tích (Cortez và Embrechts, 2013). Đối với một mạng nơ-ron, có thể tính được mức độ quan trọng của biến đầu vào đối với đầu ra bằng cách sử dụng các phương pháp dựa trên trọng số kết nối của các nơ-ron.

Một số phương pháp, chẳng hạn như các phương pháp của Garson (1991), Goh (1995), Gedeon (1997) và Olden et al. (2004), cho phép thực hiện đánh giá này. Đáng chú ý, các phương pháp của Gedeon và Olden sử dụng trọng số của tất cả các kết nối,

with Gedeon's method being tailored specially for deep learning.

Recently, explainable artificial intelligence (XAI) has seen application in various scientific fields, including water quality prediction (Madni et al., 2023) and understanding MBR process (Chang et al., 2022). Partial dependence plot, individual conditional expectation, local interpretable model-agnostic explanations, and Shapley additive explanations (SHAP) are suitable for model interpretation (Molnar, 2019). In particular, SHAP has the desirable properties of local accuracy, missingness, and consistency, thus can be used to interpret the model from global, local, and feature interaction perspectives (Aldrees et al., 2024b). These methods can be used to interpret or explain all kinds of machine learning models, including deep learning models.

2.5 Model selection guide

The selection of an appropriate modeling method is of paramount importance. Unsupervised learning methods are employed when the data set lacks output labels, whereas supervised learning methods are used when the data set contains output labels. The first step is to determine the type of problem. For problems with numerical output labels (i.e., regression or time-series problems), models such as SVR, RF, and ANN can be selected, whereas for problems with discrete or nominal output data (i.e., classification problems), SVC, RF, and ANN are suitable. In cases involving multiple decision-making processes, reinforcement learning may prove an advantageous solution. Subsequently, the magnitude of the data set must be taken into consideration. When the sample size is limited, it has been demonstrated that SVM, RF, and MLP models with relatively simple structures can achieve adequately robust results. The performance of DNN can be optimized when the sample size is large. The characteristics of the input data are also of great importance. LSTM is appropriate for time-series data, CNN is suitable for matrix data with image characteristics, and GNN is suitable for directly processing graph-structured data.

3 Application of machine learning in MBRs

3.1 Overview of application

In recent years, machine learning, an artificial intelligence technology, has gained widespread usage

for predicting MBR performances. Since 2015, there has been a noticeable surge in the number of researchers publishing papers on machine learning model in MBR, with a sharp rise after 2018 (Fig. S1 in Appendix A). The statistical analysis of models, features, and optimization provides a more comprehensive reflection of the research progress in MBR performance prediction. Among the reviewed papers, 34.3% focused on predicting pollutant removal and 67.1% were dedicated to predicting membrane fouling.

The characteristics/parameters of the membrane process can be categorized into seven main groups: time parameter (*t*), conventional concentration indices (CCI) (including chemical oxygen demand (COD), total nitrogen (TN), and total phosphorus (TP) in the influent and effluent, total suspended solids (TSS) in the influent, MLSS in the mixed liquor, and other parameters), membrane filtration indices (MFI) (including TMP, membrane flux, filtration resistance, $\Delta\text{TMP}/\Delta t$, membrane permeability, and other parameters), environment indices (EI) (including temperature (*T*), dissolved oxygen (DO), pH, oxidation reduction potential (ORP), organic loading rate (OLR), and other parameters), operation indices (OI) (including SRT, HRT, filtration-relaxation ratio, aeration intensity, backwash strength/time, and other parameters), and characteristic foulant indices (CFI) (including concentrations of SMP, loosely-bound EPS, tightly-bound EPS, among others). These characteristics can be used as model inputs, as well as other parameters such as sludge particle size, viscosity, zeta potential, blocking coefficient, membrane pore size, etc. Spectroscopic measurement results, such as spectral data and spectral grayscale maps, may also be used as model inputs to facilitate automatic spectral features extraction. With the aforementioned model inputs, pollutant removal and membrane fouling performances are typically received as the model outputs.

Figure 5(a) shows the models for MBR fouling prediction. For this purpose, CCI (60.4%) and MFI (68.8%) were used as the majority of input characteristics, and membrane flux (52.7%) was selected as the primary indicator of membrane fouling performance. Of the established models, ANN models accounted for 72.9%, with a focus on relatively simple model structures, including MLP at 39.6% and RBFNN at 18.8%. Additionally, DNN and SVM models were utilized, accounting for 8.3% and 18.8%, respectively. For model tuning, over half (56.3%) of the models did not employ any optimization algorithms, 33.3% chose intelligent optimization algorithms, and 8.3% used simple CV to optimize the parameters. Among the

với phương pháp của Gedeon được điều chỉnh đặc biệt cho học sâu.

Gần đây, trí tuệ nhân tạo (có khả năng giải thích XAI) đã được ứng dụng trong nhiều lĩnh vực khoa học, bao gồm dự báo chất lượng nước (Madni et al., 2023) và tìm hiểu quy trình MBR (Chang et al., 2022). Biểu đồ phụ thuộc bộ phận, kỳ vọng có điều kiện cá nhân, các giải thích cục bộ để diễn giải và không phụ thuộc mô hình, và các giải thích cộng tính Shapley (SHAP) phù hợp để diễn giải mô hình (Molnar, 2019). Đặc biệt, SHAP có các thuộc tính mong muốn là độ chính xác cục bộ, tính thiếu vắng, và tính nhất quán, do đó có thể được dùng để diễn giải mô hình từ các góc nhìn toàn cục, cục bộ và tương tác đặc trưng (Aldrees et al., 2024b). Các phương pháp này có thể được dùng để diễn giải hoặc giải thích mọi loại mô hình học máy, bao gồm cả các mô hình học sâu.

2.5 Hướng dẫn lựa chọn mô hình

Việc lựa chọn một phương pháp mô hình hóa phù hợp có tầm quan trọng tối cao. Các phương pháp học không giám sát được sử dụng khi tập dữ liệu không có nhãn đầu ra, trong khi các phương pháp học có giám sát được sử dụng khi tập dữ liệu có nhãn đầu ra. Bước đầu tiên là xác định loại bài toán. Đối với các bài toán có nhãn đầu ra dạng số, tức là bài toán hồi quy hoặc chuỗi thời gian, có thể chọn các mô hình như SVR, RF và ANN; còn đối với các bài toán có dữ liệu đầu ra rời rạc hoặc định danh, tức là bài toán phân loại, thì SVC, RF và ANN là phù hợp. Trong các trường hợp liên quan đến nhiều quá trình ra quyết định, học tăng cường có thể là một giải pháp hữu ích. Tiếp theo, cần xem xét quy mô của tập dữ liệu. Khi kích thước mẫu hạn chế, các mô hình SVM, RF và MLP có cấu trúc tương đối đơn giản đã được chứng minh là có thể đạt được kết quả đủ vững chắc. Hiệu suất của DNN có thể được tối ưu hóa khi kích thước mẫu lớn. Đặc điểm của dữ liệu đầu vào cũng rất quan trọng. LSTM phù hợp với dữ liệu chuỗi thời gian, CNN phù hợp với dữ liệu ma trận có đặc điểm của hình ảnh, còn GNN phù hợp để xử lý trực tiếp dữ liệu có cấu trúc đồ thị.

3 Ứng dụng học máy trong các MBR

3.1 Tổng quan về ứng dụng

Trong những năm gần đây, học máy, một công nghệ trí tuệ nhân tạo, đã được ứng dụng rộng rãi.

nhằm dự đoán hiệu suất MBR. Kể từ năm 2015, số lượng nhà nghiên cứu công bố các bài báo về mô hình học máy trong MBR đã tăng đáng kể, với mức tăng mạnh sau năm 2018 (Hình S1, Phụ lục A). Phân tích thống kê về các mô hình, đặc trưng và phương pháp tối ưu hóa phản ánh toàn diện hơn tiến độ nghiên cứu trong dự đoán hiệu suất MBR. Trong số các bài báo được tổng quan, 34,3% tập trung vào dự đoán khả năng loại bỏ chất ô nhiễm và 67,1% tập trung vào dự đoán hiện tượng tắc nghẽn màng.

Các đặc tính/thông số của quá trình màng có thể được phân loại thành bảy nhóm chính: thông số thời gian, các chỉ số nồng độ thông thường (CCI) (bao gồm nhu cầu oxy hóa học (COD), tổng nitơ (TN), và tổng photpho (TP) trong nước đầu vào và đầu ra, tổng chất rắn lơ lửng (TSS) trong nước đầu vào, MLSS trong hỗn hợp bùn lỏng, và các thông số khác), các chỉ số lọc màng (MFI) (bao gồm TMP, thông lượng màng, điện trở lọc, $\Delta\text{TMP}/\Delta t$, độ thấm của màng, và các thông số khác), các chỉ số môi trường (EI) (bao gồm nhiệt độ (*T*), oxy hòa tan (DO), pH, thế oxy hóa khử (ORP), tốc độ tải lượng hữu cơ (OLR), và các thông số khác), các chỉ số vận hành (OI) (bao gồm SRT, HRT, tỷ lệ lọc-thư giãn, cường độ sục khí, cường độ/thời gian rửa ngược, và các thông số khác, cùng với các chỉ số chất gây bám bẩn đặc trưng (CFI) (bao gồm nồng độ của SMP, EPS liên kết lỏng lẻo, EPS liên kết chặt, cùng với các chất khác). Các đặc tính này có thể được sử dụng làm đầu vào của mô hình, cũng như các thông số khác như kích thước hạt bùn, độ nhớt, thế zeta, hệ số tắc nghẽn, kích thước lỗ màng, v.v. Các kết quả đo quang phổ, chẳng hạn như dữ liệu phổ và bản đồ mức xám phổ, cũng có thể được sử dụng làm đầu vào mô hình để hỗ trợ trích xuất tự động các đặc trưng phổ. Với các đầu vào mô hình đã nêu ở trên, hiệu suất loại bỏ chất ô nhiễm và bám bẩn màng thường được thu nhận làm đầu ra của mô hình.

Hình 5(a) cho thấy các mô hình dùng để dự đoán sự tắc nghẽn màng MBR. Với mục đích này, CCI (60,4%) và MFI (68,8%) được sử dụng làm phần lớn các đặc trưng đầu vào, và thông lượng màng (52,7%) được chọn làm chỉ số chính để đánh giá hiệu suất tắc nghẽn màng. Trong số các mô hình đã xây dựng, các mô hình ANN chiếm 72,9%, trong đó tập trung vào các cấu trúc mô hình tương đối đơn giản, bao gồm MLP chiếm 39,6% và RBFNN chiếm 18,8%. Ngoài ra, các mô hình DNN và SVM được sử dụng, lần lượt chiếm 8,3% và 18,8%. Để tìm kiếm mô hình, hơn một nửa, tức (56,3%) các mô hình không sử dụng bất kỳ thuật toán tối ưu hóa nào, 33,3% sử dụng các thuật toán tối ưu hóa thông minh, và 8,3% sử dụng phương pháp CV đơn giản để tối ưu hóa các tham số. Trong số các





Fig. 5 Distribution of different machine learning models used for MBR research: (a) membrane fouling prediction models, (b) pollutant removal prediction models.



Hình 5 Phân bố của các mô hình học máy khác nhau được sử dụng trong nghiên cứu MBR: ((a)) các mô hình dự đoán cấu bẩn màng, (b) các mô hình dự đoán loại bỏ chất ô nhiễm.

intelligent optimization algorithms, GA was predominant at 56.5%, followed by PSO at 18.9%.

The prediction models for MBR pollutant removal are illustrated in Fig. 5(b). None of the model inputs employed CFI. Instead, the majority of the models utilized CCI (75.2%), OI (62.5%), and EI (54.2%) as input characteristics. Only 20.8% of the models incorporated MFI into the input characteristics. Regarding the model outputs, 79.2% of the models aimed to predict the crucial carbon-related indices (such as effluent COD and COD removal rate). The nitrogen-related indices (such as the removal rates and effluent concentrations of TN, ammonium nitrogen (NH₃-N), and nitrate nitrogen (NO₃⁻-N)) followed at 58.3%, while a lower percentage of models (16.7%) were targeted at the prediction of trace organic pollutants. In terms of model structure, a significant proportion of the models employed ANN models, with MLP models being the most favored option at 66.7%. Compared with membrane fouling prediction models, pollutant removal prediction models are usually simpler, with fewer models using optimization algorithms.

Figure S2 in Appendix A shows the relationship between R^2 and the number of parameters of different ANN models, with model's capacity denoted by the number of parameters. As illustrated in Fig. S2, the stability of the MLP model is inferior, which is potentially influenced by the data set or model parameter settings. The introduction of optimization algorithms, such as GA, leads to overall improvement

in model's performance, potentially resulting from the algorithm optimization or the refinement of the model parameter training process. Conversely, the WNN model shows commendable results with a modest parameter count, which is likely attributed to the construction of a more complex activation function.

In general, machine learning is a prevalent tool in the MBRs with satisfactory performance. It is important to recognize the limitations of an incomplete indicator system, lack of full-scale engineering validation, difficulty of real-time prediction, and lack of process understanding contribution.

3.2 Machine learning models to predict pollutant removal performances

The application of machine learning models to predict MBRs' pollutant removal performance is summarized in Table S3 in Appendix A. These applications are mainly based on ANNs. MLP model serves as a foundation for statistical analysis of various models, with a focus on optimizing the hierarchical structure and activation functions. Based on MLP, Kim et al. (2021b) used near-infrared spectroscopy to predict the concentrations of effluent pollutant (COD, TN, NH₃-N, nitrite nitrogen, NO₃⁻-N, and phosphate) as well as SMP and EPS in the mixed liquor with $R^2 > 0.97$. The MLP topology for predicting these three types of pollutants/foulants were 5-11-6, 5-9-1, and 5-9-2, respectively.

các thuật toán tối ưu hóa thông minh, GA chiếm ưu thế với 56.5%, tiếp theo là PSO với 18.9%.

Các mô hình dự đoán loại bỏ chất ô nhiễm trong MBR được minh họa trong Hình 5(b). Không mô hình nào sử dụng CFI làm biến đầu vào. Thay vào đó, phần lớn các mô hình sử dụng CCI (75, 2%), OI (62,5%) và EI (54,2%) làm đặc trưng đầu vào. Chỉ 20,8% số mô hình đưa MFI vào các đặc trưng đầu vào. Về đầu ra của mô hình, 79,2% số mô hình hướng đến dự đoán các chỉ số quan trọng liên quan đến carbon, chẳng hạn như COD trong nước thải đầu ra và tỷ lệ loại bỏ COD. Tiếp theo là các chỉ số liên quan đến nitơ, chẳng hạn như tỷ lệ loại bỏ và nồng độ trong nước thải đầu ra của TN, nitơ amoni NH₃-N và nitơ nitrat NO₃-N, với tỷ lệ 58,3%; trong khi tỷ lệ mô hình thấp hơn (16,7%) hướng đến dự đoán các chất ô nhiễm hữu cơ vi lượng. Xét về cấu trúc mô hình, một tỷ lệ đáng kể các mô hình sử dụng mô hình ANN, trong đó mô hình MLP là lựa chọn được ưa chuộng nhất, chiếm 66,7%. So với các mô hình dự đoán tắc nghẽn màng, các mô hình dự đoán loại bỏ chất ô nhiễm thường đơn giản hơn, với ít mô hình sử dụng thuật toán tối ưu hóa hơn.

Hình S2 trong Phụ lục A cho thấy mối quan hệ giữa R^2 và số lượng tham số của các mô hình ANN khác nhau, trong đó dung lượng của mô hình được biểu thị bằng số lượng tham số. Như minh họa trong Hình S2, độ ổn định của mô hình MLP kém hơn, điều này có thể chịu ảnh hưởng của tập dữ liệu hoặc thiết lập tham số mô hình. Việc đưa vào các thuật toán tối ưu hóa, chẳng hạn như GA, dẫn đến sự cải thiện toàn diện.

cải thiện hiệu suất của mô hình, có thể xuất phát từ việc tối ưu hóa thuật toán hoặc tinh chỉnh quy trình huấn luyện tham số mô hình. Ngược lại, mô hình WNN cho thấy kết quả đáng ghi nhận với số lượng tham số khiêm tốn, điều này có khả năng là nhờ xây dựng một hàm kích hoạt phức tạp hơn.

Nhìn chung, học máy là một công cụ phổ biến trong các MBR với hiệu suất thỏa đáng. Điều quan trọng là nhận ra những hạn chế của hệ thống chỉ thị không đầy đủ, thiếu xác nhận kỹ thuật quy mô đầy đủ, khó dự đoán theo thời gian thực và thiếu đóng góp vào sự hiểu biết về quy trình.

3.2 Các mô hình học máy dự đoán hiệu suất loại bỏ chất ô nhiễm

Ứng dụng các mô hình học máy để dự đoán hiệu suất loại bỏ chất ô nhiễm của MBR được tóm tắt trong Bảng S3, Phụ lục A. Các ứng dụng này chủ yếu dựa trên ANN. Mô hình MLP là nền tảng cho phân tích thống kê các mô hình khác nhau, tập trung vào việc tối ưu hóa cấu trúc phân cấp và các hàm kích hoạt. Dựa trên MLP, Kim và cộng sự (2021b) đã sử dụng quang phổ cận hồng ngoại để dự đoán nồng độ các chất ô nhiễm trong nước thải gồm COD, TN, NH₃-N, nitơ nitrit, NO₃-N và phosphate, cũng như SMP và EPS trong hỗn hợp bùn với độ chính xác 0,97. Cấu trúc MLP dùng để dự đoán ba loại chất ô nhiễm/chất gây tắc nghẽn này lần lượt là 5-11-6, 5-9-1 và 5-9-2.

Some MLP models were specifically focused on predicting the removal of trace organic pollutants, in addition to the detection of routine water quality (Wolf et al., 2001; Wolf et al., 2003). Researchers have attempted to optimize the activation function of the hidden layer using radial basis function (RBF) and wavelet functions. Mirbagheri et al. (2015b) established an RBFNN model with a topology of 5-5-1 to evaluate the performance of a submerged MBR in the treatment of a combined urban and industrial wastewater, using the influent concentrations (biochemical oxygen demand (BOD), COD, NH₃-N, TP), influent total dissolved solids, HRT, volatile MLSS (MLVSS), and mixed liquor pH as input characteristics to predict the effluent concentrations (BOD, COD, NH₃-N, and TP) with $R^2 > 0.98$. Cai et al. (2019b) established a WNN model with a topology of 3-2-1 to predict the effluent quality (COD: $R^2 = 0.999$; NH₃-N: $R^2 = 0.997$) with the influent COD, NH₃-N, and salinity as input characteristics. They also found that the WNN model had better performance than the MLP model in predicting effluent COD and TN (Cai et al., 2019a).

Researchers have also optimized the model hierarchy with structures that are more complex than MLPs, such as CNN, DenseNet, and LSTM. Li et al. (2022) established three DNN models, including fully connected network (FCN), CNN, and DenseNet, to predict the effluent pH, effluent COD, COD removal rate, biogas (CH₄, N₂, and CO₂) yield, and redox potential of an AnMBR by considering the ambient temperature, influent water temperature, influent pH, influent COD, mixed liquor temperature, and membrane flux as input characteristics. The prediction accuracy of the DenseNet model reached 97.4%, whereas those of FCN and CNN were 92.6% and 91.8%, respectively. Yaqub et al. (2020) established an LSTM to predict the removal of TN, TP, and NH₃-N by an anaerobic/anoxic/aerobic-MBR process using the influent water quality (total organic carbon (TOC), TN, TP, COD, NH₃-N, and suspended solids) and operating parameters (DO, ORP, and MLSS) as input characteristics, and the results showed that the model performed the best in predicting NH₃-N removal rate with MSE = 0.0047.

Based on the above analysis, previous studies have predominantly used MLP models to predict the pollutant removal performances. More complex ANN models, such as WNN, CNN, and LSTM are occasionally utilized. In addition to the enhancement of the model structure, some researchers have optimized machine learning models by applying intelligent optimization algorithms (e.g., FFA, PSO, and GWO) to improve the model accuracy and achieve more effective

solutions to complex problems (Aldrees et al., 2024a). However, some models did not include MFI as input variable and thus may have underestimated the role of membranes in pollutant removal. Furthermore, with regard to output variables, previous research primarily concentrated on removing C, N, and P, with insufficient attention paid to trace pollutants. ANNs seemed to be less effective in predicting trace organic pollutants due to the diversified behavior of trace pollutants during their degradation process. Optimizing the activation function can improve the performance of ANNs, and tree models may have better performance than ANNs. It is worth noting that complicating the model structure may not straightforwardly improve the performance of ANNs, which may be due to an insufficient amount of data, errors in the measured data, or complex relationship between variables.

3.3 Machine learning models to predict membrane fouling

Membrane fouling often involves organic, inorganic, biological, and composite fouling. Organic compounds, such as polysaccharides, proteins, and humic substances, contribute to various stages of membrane fouling resulting in reversible or irreversible fouling (Lin et al., 2014; Xu et al., 2020). Pollutant removal in MBRs involves a combination of biological processes and membrane retention, implying that the formation of membrane fouling is inherently linked to pollutant removal. Compared to considering solely pollutant removal, membrane fouling is a complex process with higher nonlinearity between parameters. Such complexity offers enormous potential for the implementation of machine learning models.

3.3.1 ANN for membrane fouling prediction

ANN is a favorable machine learning model with strong nonlinear fitting capabilities. It demonstrated good performance in predicting membrane fouling. The prediction of membrane fouling can be classified into two categories: filtration state prediction (such as flux, TMP, and permeability) and membrane fouling analysis (such as fouling type, flux recovery rate, and membrane interfacial energy). Table 2 summarizes the ANN models used to predict MBR filtration state. To improve the prediction, some researchers have modified the MLP model by optimizing/training algorithms, changing the hidden layer activation function, and adjusting the model hierarchy. Sensitivity factor analysis was used to interpret the model or identify significant parameters.

Một số mô hình MLP được tập trung cụ thể vào việc dự đoán sự loại bỏ các chất ô nhiễm hữu cơ vi lượng, bên cạnh việc phát hiện các tổng hợp chất lượng nước thông thường Wolf et al., 2001; Wolf et al., 2003.) Các nhà nghiên cứu đã tìm cách tối ưu hóa hàm kích hoạt của lớp ẩn bằng cách sử dụng hàm cơ sở hướn g tâm RBF và các hàm wavelet. Mirbagheri (et al. 2015b) đã xây dựng một mô hình RBFNN với i (kiến trúc) 5-5-1 để đánh giá hiệu suất của một hệ thống MBR chìm trong quá trình xử lý nước thải đô thị và công nghiệp hỗn hợp, sử dụng cá c nồng độ đầu vào gồm nhu cầu oxy sinh hóa BOD, COD, NH₃-N, TP, tổng chất rắn hòa tan trong nước thải đầu vào, HRT, MLSS bay hơi M LVSS và pH của hỗn hợp để dự đoán (nồng độ BOD, (COD,)NH₃-N, và TP trong nước thải đầu ra với) 0.98. Cai et al. 2019b) đã xây dựng một (mô hình WNN) với kiến trúc 3-2-1 để dự đoá n chất lượng nước thải đầu ra COD: 0.999; NH₃-N: 0.997 (với COD, NH₃-N, và độ mặn của nước thải đầu vào làm các đặc trưng đầu vào.) Họ $R^2 >$ cũng nhận thấy rằng mô hình (WNN) c ó hiệu suất tốt hơn mô hình MLP khi dự đoán COD và TN trong nước thải đầu ra Cai et al., 2019a). Các nhà nghiên cứu cũng đã tối ưu hóa hệ ph ân cấp mô hình bằng các cấu trúc phức tạp hơn MLP, chẳng hạn như CNN, DenseNet và LSTM. Li và cộng sự (năm 2022) đã xây dựng ba mô hình DNN, bao gồm mạng kết nối đầy đủ FCN), CNN và DenseNet để dự đoán pH nước thải đầu ra, COD nước thải đầu ra, tỷ lệ loại bỏ CO D, (sản lượng khí sinh học CH₄, N₂ và CO₂), cũn g như thế oxy hóa khử của AnMBR bằng cách xem xét nhiệt độ môi trường, nhiệt độ nước đầ u vào, pH nước đầu vào, COD đầu vào, nhiệt độ bùn hoạt tính và thông lượng màng làm đặ c trưng đầu vào. Độ chính xác dự đoán của mô hình DenseNet đạt 97,4%, trong khi các giá trị t ương ứng của FCN và CNN là 92,6% và 91,8%, tương ứng. Yaqub và cộng sự (năm 2020) đã xâ y dựng một mô hình LSTM để dự đoán mức độ l oại bỏ TN, TP và NH₃-N bằng quy trình MBR kỵ khí/thiếu khí/hiếu khí, sử dụng chất lượng nướ c đầu vào gồm tổng (carbon hữu cơ (TOC), TN, T P, COD, NH₃-N và chất rắn lơ lửng), cùng các th ông số vận hành DO, (ORP và MLSS) làm đặc trưng đầu vào; kết quả cho thấy mô hình hoạt động tốt nhất trong việc dự đoán tỷ lệ loại bỏ N H₃-N, với MSE bằng = 0,0047.

Dựa trên phân tích ở trên, các nghiên cứu trước đây chủ yếu sử dụng các mô hình MLP để dự đoán hiệu suất loại bỏ chất ô nhiễm. C ác mô hình ANN phức tạp hơn, như WNN, C NN và LSTM, đôi khi được sử dụng. Ngoài việc cải thiện cấu trúc mô hình, một số nhà nghiên cứu đã tối ưu hóa các mô hình học máy bằng cách áp dụng các thuật toán tối ưu hóa thông minh, ví dụ như FFA, PSO (và GWO, để cải th iện độ chính xác) của mô hình và đạt được hiệu quả cao hơn.

giải pháp cho các vấn đề phức tạp (Aldrees v à cộng sự, 2024a). Tuy nhiên, một số mô hình không đưa MFI vào làm biến đầu vào và do đó có thể đã đánh giá thấp vai trò của màng trong việc loại bỏ chất ô nhiễm. Hơn nữa, xét về các biến đầu ra, nghiên cứu trước đây chủ yếu tập trung vào việc loại bỏ C, N, và P, trong k hi chưa chú ý đầy đủ đến các chất ô nhiễm vi l ượng. Các mạng nơ-ron nhân tạo (ANN) dường như ít hiệu quả hơn trong việc dự đoán các ch ất ô nhiễm hữu cơ vi lượng do đặc tính đạ dạn g của các chất ô nhiễm vi lượng trong quá trìn h phân hủy. Tối ưu hóa hàm kích hoạt có thể cải thiện hiệu suất của ANN, còn các mô hình cây có thể đạt hiệu suất tốt hơn ANN. Cần lưu ý rằng việc làm phức tạp cấu trúc mô hình có th ể không trực tiếp cải thiện hiệu suất của ANN, điều này có thể là do lượng dữ liệu không đủ, sai số trong dữ liệu đo đạc, hoặc mối quan hệ phức tạp giữa các biến.

3.3 Các mô hình học máy dự đoán hiện tượng bám bẩn màng

Hiện tượng nghẹt màng thường bao gồm ng het hữu cơ, vô cơ, sinh học, và hỗn hợp. Các hợp p chất hữu cơ, chẳng hạn như polysaccharide, protein, và các chất humic, góp phần vào nhi ều giai đoạn khác nhau của hiện tượng nghẹt màng, dẫn đến nghẹt thuận nghịch hoặc kh ông thuận nghịch (Lin và cộng sự, 2014; Xu và c ộng sự, 2020). Việc loại bỏ chất ô nhiễm trong c ác MBR liên quan đến sự kết hợp giữa các qu á trình sinh học và khả năng giữ lại của màng, c ho thấy rằng sự hình thành hiện tượng nghẹt m àng vốn dĩ gắn liền với quá trình loại bỏ chất ô nhiễm. So với việc chỉ xem xét quá trình loại bỏ chất ô nhiễm, hiện tượng nghẹt màng là một quá trình phức tạp, với mức độ phi tuyến tính cao hơn giữa các tham số. Sự phức tạp nà y mang lại tiềm năng rất lớn cho việc triển kh ải các mô hình học máy.

3.3.1 ANN để dự đoán hiện tượng bám bẩn màng

ANN là một mô hình học máy có triển vọng với khả năng khớp phi tuyến mạnh mẽ. Mô hình nà y đã cho thấy hiệu suất tốt trong việc dự đoán s ự tắc nghẽn màng. Việc dự đoán sự tắc nghẽn màng có thể được chia thành hai nhóm: dự đo án trạng thái lọc như (thông qua các chỉ số như thông lượng, TMP, và độ thấm) và phân tích sự t ắc nghẽn màng (như loại tắc nghẽn, tỷ lệ khôì p hục thông lượng, và năng lượng liên bề mặt củ a màng). Bảng 2 tóm tắt các mô hình ANN đượ c sử dụng để dự đoán trạng thái lọc của MBR. Để cải thiện khả năng dự đoán, một số nhà nghi ên cứu đã điều chỉnh mô hình MLP bằng cách tổ i ưu hóa/huấn luyện các thuật toán, thay đổi hà m kích hoạt của lớp ẩn và điều chỉnh cấu trúc p hân cấp của mô hình. Phân tích các yếu tố độ n hạy được sử dụng để diễn giải mô hình hoặc xá c định các tham số quan trọng.

Table 2 Examples of ANN models to predict membrane filtration state in MBRs

Model	Optimization	Hidden layer activation function	Structural features	Input parameter	Output parameter	Training algorithm	Fitting performance	Ref.
ENN			9-55-1	T , SRT, TSS, ODR, TMP, dTMP/d t , Filtration and backwash time	Flux		AD = 2.7%	Geissler et al., 2005
MLP			3-5-1	Backwash time, Operation time, Flux	Flux	LM	$R^2 = 0.99$	Aidan et al., 2008
MLP	GA	log-sigmoid		MLSS, TMP, Resistance	Flux	LM	MAPE = 0.0331	Li et al., 2014
MLP	GA	tan-sigmoid	5-10-1	Time, MLSS, COD, SRT, TSS	TMP, Permeability	LM	$R^2 = 0.98$ $R^2 = 0.98$	Mirbagheri et al., 2015b
RBFNN	GA	RBF	5-5-1	Time, MLSS, COD, SRT, TSS	TMP, Permeability	LM	$R^2 = 0.98$ $R^2 = 0.99$	Mirbagheri et al., 2015b
MLP	GA	tan-sigmoid	6-8-1	Flux, Aeration ratio, Concentration of SMP and EPS, initial TMP, Running time	TMP	Bayesian rule	Relative MSE = 0.024	Wang and Wu, 2015
RBFNN	CV	RBF	2-2-1	Aeration volume, TMP	Flux		$R^2 = 0.80$	2017
MLP		log-sigmoid	6-5-1	Influent (TN, NO ₃ ⁻ -N, TP), Effluent (TN, NO ₃ ⁻ -N, TP)	TMP	LM	$R^2 = 0.85$	Schmitt et al., 2018
Fuzzy-RBFNN	PSO	log-sigmoid	2-14-49-1	Flux, Membrane flux variation	Flux		MAPE = 0.0287	Tao and Li, 2018
MLP	PSO			Temperature, Flux, TMP, MLSS	Resistance	LM	$R^2 = 0.97$	Hamed i et al., 2019
MLP		tan-sigmoid	4-8-1	MLSS, EC, DO, Time	Flux	LM	$R^2 = 0.98$	Hosseinzadeh et al., 2020
RBFNN		RBF	1-3-1	Permeate pump pressure	Flux, TMP	LM	$R^2 > 0.90$	Abdul Wahab et al.,
MLP		tan-sigmoid	1-5(7)-1	Permeate pump pressure	Flux, TMP	LM	$R^2 > 0.88$	Abdul Wahab et al.,
RNN				EC, Flux	EC, Flux		RMSE = 18 mS/cm RMSE = 1.1 LMH	Viet et al., 2021
MLP		tan-sigmoid	4-30-30-1 4-5-5-5-5-5-1	pH, EC, influent TN and NH ₃ -N	Flux Resistance	LM	Flux: $R^2 = 0.88$ Resistance: $R^2 = 0.86$	Viet and Jang, 2021
WNN	BA	Bandelet function	5-12-2	MLSS, Sludge particle size, EPS, SMP, Sludge viscosity, RH, Zeta potential	Flux, Membrane flux recovery rate	Gradient descent method	MAPE = 0.032	Zhao et al., 2020
MLP			3-17-2	MLSS, HRT, Time	Flux, COD removal rate	LM	$R^2 = 0.9996$	Hazrati et al., 2017
ANFIS				OLR, Effluent pH, MLSS, MLVSS	TMP	LM	$R^2 = 0.98$	Taheri et al., 2021
MLP		log-sigmoid	6-9-1	Time, Flux, influent COD, pH, MLSS, TMP rate of change	Permeability		$R^2 = 0.9985$	Yao et al., 2022
MLP		tan-sigmoid	3-9-1	Disc rotational speed, Membrane to disc gap, OLR	Permeability	LM	$R^2 = 0.999$	Irfan et al., 2022
MLP	CV	tan-sigmoid	6-6-1	Sludge filterability, MLVSS, pH, influent COD, T , Cleaning cycle	Permeability	BFGS	$R^2 = 0.93$	Alkmim et al., 2020

Note: ENN = Elman neural network, ODR = oxygen decay rate; EC = Electrical conductivity, ANFIS = adaptive network-based fuzzy inference system, BFGS = Broyden-Fletcher-Goldfarb-Shanno, RH = relative hydrophobicity.

GA and fuzzy logic have been used in the modified MLP models. Levenberg-Marquardt (LM) is a widely used training algorithm, some researchers have also used the Bayesian rule, gradient descent algorithm, or Broyden-Fletcher-Goldfarb-Shanno (BFGS) algorithm for model training. Wang and Wu (2015) predicted

Bảng 2 Ví dụ về các mô hình ANN để dự đoán trạng thái lọc màng trong MBR

Model	Optimization	Hidden layer activation function	Structural features	Input parameter	Output parameter	Training algorithm	Fitting performance	Ref.
ENN			9-55-1	T , SRT, TSS, ODR, TMP, dTMP/d t , Filtration and backwash time	Flux		AD = 2.7%	Geissler et al., 2005
MLP			3-5-1	Backwash time, Operation time, Flux	Flux	LM	$R^2 = 0.99$	Aidan et al., 2008
MLP	GA	log-sigmoid		MLSS, TMP, Resistance	Flux	LM	MAPE = 0.0331	Li et al., 2014
MLP	GA	tan-sigmoid	5-10-1	Time, MLSS, COD, SRT, TSS	TMP, Permeability	LM	$R^2 = 0.98$ $R^2 = 0.98$	Mirbagheri et al., 2015b
RBFNN	GA	RBF	5-5-1	Time, MLSS, COD, SRT, TSS	TMP, Permeability	LM	$R^2 = 0.98$ $R^2 = 0.99$	Mirbagheri et al., 2015b
MLP	GA	tan-sigmoid	6-8-1	Flux, Aeration ratio, Concentration of SMP and EPS, initial TMP, Running time	TMP	Bayesian rule	Relative MSE = 0.024	Wang and Wu, 2015
RBFNN	CV	RBF	2-2-1	Aeration volume, TMP	Flux		$R^2 = 0.80$	2017
MLP		log-sigmoid	6-5-1	Influent (TN, NO ₃ ⁻ -N, TP), Effluent (TN, NO ₃ ⁻ -N, TP)	TMP	LM	$R^2 = 0.85$	Schmitt et al., 2018
Fuzzy-RBFNN	PSO	log-sigmoid	2-14-49-1	Flux, Membrane flux variation	Flux		MAPE = 0.0287	Tao and Li, 2018
MLP	PSO			Temperature, Flux, TMP, MLSS	Resistance	LM	$R^2 = 0.97$	Hamed i et al., 2019
MLP		tan-sigmoid	4-8-1	MLSS, EC, DO, Time	Flux	LM	$R^2 = 0.98$	Hosseinzadeh et al., 2020
RBFNN		RBF	1-3-1	Permeate pump pressure	Flux, TMP	LM	$R^2 > 0.90$	Abdul Wahab et al.,
MLP		tan-sigmoid	1-5(7)-1	Permeate pump pressure	Flux, TMP	LM	$R^2 > 0.88$	Abdul Wahab et al.,
RNN				EC, Flux	EC, Flux		RMSE = 18 mS/cm RMSE = 1.1 LMH	Viet et al., 2021
MLP		tan-sigmoid	4-30-30-1 4-5-5-5-5-5-1	pH, EC, influent TN and NH ₃ -N	Flux Resistance	LM	Flux: $R^2 = 0.88$ Resistance: $R^2 = 0.86$	Viet and Jang, 2021
WNN	BA	Bandelet function	5-12-2	MLSS, Sludge particle size, EPS, SMP, Sludge viscosity, RH, Zeta potential	Flux, Membrane flux recovery rate	Gradient descent method	MAPE = 0.032	Zhao et al., 2020
MLP			3-17-2	MLSS, HRT, Time	Flux, COD removal rate	LM	$R^2 = 0.9996$	Hazrati et al., 2017
ANFIS				OLR, Effluent pH, MLSS, MLVSS	TMP	LM	$R^2 = 0.98$	Taheri et al., 2021
MLP		log-sigmoid	6-9-1	Time, Flux, influent COD, pH, MLSS, TMP rate of change	Permeability		$R^2 = 0.9985$	Yao et al., 2022
MLP		tan-sigmoid	3-9-1	Disc rotational speed, Membrane to disc gap, OLR	Permeability	LM	$R^2 = 0.999$	Irfan et al., 2022
MLP	CV	tan-sigmoid	6-6-1	Sludge filterability, MLVSS, pH, influent COD, T , Cleaning cycle	Permeability	BFGS	$R^2 = 0.93$	Alkmim et al., 2020

Note: ENN = Mạng nơ-ron Elman, ODR = tốc độ phân hủy = oxy; EC Độ = dẫn điện, ANFIS suy luận = mờ dựa = trên mạngYizhe Lai et al., Front. Environ. Sci. Eng. 2025, 19(3): 34

GA và logic mờ đã được sử dụng trong các mô hình MLP cải tiến. Levenberg-Marquardt (LM) là một thuật toán huấn luyện được sử dụng rộng rãi, một số nhà nghiên cứu cũng đã đã sử dụng quy tắc Bayes, thuật toán giảm gradient hoặc thuật toán Broyden-Fletcher-Goldfarb-Shanno (BFGS) để huấn luyện mô hình. Wang và Wu (2015) đã dự đoán

TMP by inputting flow rate, aeration ratio, initial TMP, running time, and the concentration of characteristic foulants (SMP and EPS) to obtain the jump point of TMP with a relative MSE of 0.024. They established the MLP model with a topology of 6-8-1, optimized the weight and bias of the model by GA algorithm, and trained the model by the Bayesian rule. Additionally, they showed that the performance of MLP with small sample sizes was less stable than traditional mathematical models. Alkmim et al. (2020) established an MLP model with a topology of 6-6-1, trained with the BFGS algorithm, and optimized the parameters by CV. They considered sludge filterability, MLVSS, pH, influent COD, temperature, and cleaning cycle as input characteristics to predict membrane permeability with $R^2 = 0.93$. The optimizing/training algorithms seem useful to improve the model. In the meantime, the impact of sample size on machine learning performance in addressing membrane fouling remains a concern.

RBF and wavelet function were used to optimize the hidden layer activation function in the fouling prediction models. Mirbagheri et al. (2015a) used an RBFNN model optimized by GA algorithm to predict TMP and membrane permeability from five input indicators, including operating time, TSS, COD, SRT, and MLSS, with $R^2 > 0.98$. Sensitive analysis highlighted the importance of operating time and mixed liquid MLSS as influencing factors. Zhao et al. (2020) used the Bandelet function (approximate to the wavelet function) as the hidden layer activation function to establish the Bandelle neural network, trained the network using the gradient descent method, and introduced the BA to optimize the parameters. They realized the prediction of membrane flux and membrane flux recovery rate using mixed liquid properties such as MLSS, sludge particle size, EPS, SMP, sludge viscosity, relative hydrophobicity, and zeta potential with a relative error of 3.2% on the entire data set.

RNNs are suitable for predicting time-varying membrane fouling because of the advantage in processing sequential data. Elman neural network (ENN) is a rudimentary form of RNN with local memory cells and local feedback connections, and has been used for membrane fouling prediction in early years. Geissler et al. (2005) established an ENN model with a network topology of 9-55-1 to predict membrane flux with an average deviation of 2.7%. Through sensitivity analysis, they revealed that the best membrane backwash condition was high-pressure backwash with short intervals. More recently, Viet et al. (2021) established an RNN model to predict the mixed liquor conductivity and membrane flux of the osmosis

membrane bioreactor for 40 d, showing an acceptable RMSE of 18 mS/cm and 1.1 LMH, respectively. The above studies have shown that consideration of time-series development factors can help to better predict membrane fouling, while model interpretation can help to design more optimal operating conditions or process flow. These findings may contribute to refined operation of MBR.

Many researchers using ANN, such as MLP, RBFNN, RNN, and CNN, for membrane fouling analysis. Chen et al. (2012) developed an MLP model that used the bioprocess aeration capacity, membrane aeration capacity, mixed liquor recirculation flowrate, and membrane flux as input variables to predict the energy consumption per unit water production in a full-scale MBR with the R^2 exceeding 0.55. Zhao et al. (2019) established an RBFNN model to quantify the MBR membrane interfacial energy by considering the contact angles of water/glycerol/diiodomethane on sludge/membrane surface, the zeta potentials of sludge/membrane surface, and the distance between particulate sludge and membrane surface as input variables. The computation time required by RBFNN was only approximately 1/50 that of the analytically extended Derjaguin-Landau-Verwey-Overbeek method. Shi et al. (2022) established a CNN model based on the attention mechanism. The model utilized a processed grayscale image set as input to classify membrane fouling with a diagnostic accuracy of 98%. Beside supervised learning methods, unsupervised learning methods were also used to analyze membrane fouling for operational process optimization (Woo et al., 2022). Although online monitoring is not available for most model features in the above applications, these models still possess strong analytical capabilities. These applications offer new insights for researchers to analyze mechanisms of membrane fouling and provide a modeling basis for targeted control of membrane fouling.

3.3.2 Other model applications

Other models, such as SVM (including SVR), least squares SVM (LSSVM), RF, limit GBDT, and GBDT have also been applied for membrane fouling prediction in MBRs.

Table S4 in Appendix A presents examples of using SVM or tree-based models to predict membrane fouling. Although the application of these models is not as widespread as ANN, they still demonstrate good predictive abilities in various scenarios. Hamed et al. (2019) established an LSSVM to simplify the optimization of a linear equation system. MLSS, TMP,

TMP bằng cách đưa vào lưu lượng, tỷ lệ sục khí, TMP ban đầu, thời gian vận hành, và nồng độ của các chất gây bám bẩn đặc trưng SMP (và EPS để) xác định điểm nhảy của TMP với sai số bình phương trung bình tương đối (MSE) là 0,024. Họ thiết lập mô hình MLP với cấu trúc 6-8-1, tối ưu hóa trọng số và độ lệch của mô hình bằng thuật toán GA, và huấn luyện mô hình bằng quy tắc Bayesian. Ngoài ra, họ cho thấy hiệu năng của MLP với kích thước mẫu nhỏ kém ổn định hơn so với các mô hình toán học truyền thống. Alkmim và cộng sự (2020) đã xây dựng mô hình MLP với cấu trúc 6-6-1, huấn luyện bằng thuật toán BFGS, và tối ưu hóa các tham số bằng CV. Họ xem xét khả năng lọc của bùn, MLVSS, (pH, COD) đầu vào, nhiệt độ, và chu kỳ làm sạch là các đặc trưng đầu vào để dự đoán độ thấm của màng với giá trị 0,93. Các thuật toán tối ưu hóa/huấn luyện có vẻ hữu ích trong việc cải thiện mô hình. Đồng thời, ảnh hưởng của kích thước mẫu đến hiệu năng học máy khi giải quyết vấn đề bám bẩn màng và n là một quan ngại. Wavelet được sử dụng để tối ưu hóa hàm kích hoạt của lớp ẩn trong các mô hình dự đoán hiện tượng tắc nghẽn. Mirbagheri và cộng sự (năm 2015a) đã sử dụng mô hình RBFNN được tối ưu hóa bằng thuật toán GA để dự đoán TMP và độ thấm của màng từ năm chỉ số đầu vào, bao gồm thời gian vận hành, TSS, COD, SRT và MLSS, với $R^2 > 0,98$. Phân tích độ nhạy làm nổi bật tầm quan trọng của thời gian vận hành và MLSS trong hỗn hợp lỏng với vai trò là các yếu tố ảnh hưởng. Zhao và cộng sự (năm 2020) đã sử dụng hàm Bandelet để xấp xỉ hàm wavelet) làm hàm kích hoạt của lớp ẩn nhằm xây dựng mạng nơ-ron Bandelle, huấn luyện mạng bằng phương pháp gradient descent, đồng thời đưa vào thuật toán BA để tối ưu hóa các tham số. Họ đã thực hiện việc dự đoán thông lượng màng và tỷ lệ khôi phục thông lượng màng bằng cách sử dụng các đặc tính của hỗn hợp lỏng như MLSS, kích thước hạt bùn, EPS, SMP, độ nhớt của bùn, tính kỵ nước tương đối và thế zeta với sai số tương đối là 3,2% trên toàn bộ tập dữ liệu. RNN phù hợp để dự đoán hiện tượng đóng cặn màng biến thiên theo thời gian do có ưu thế trong việc xử lý dữ liệu tuần tự. Mạng nơ-ron Elman (ENN) là một dạng sơ khai của RNN, với các tế bào bộ nhớ cục bộ và các kết nối phản hồi cục bộ, đã được sử dụng để dự đoán hiện tượng đóng cặn màng trong những năm đầu. Geissler và cộng sự (2005) đã xây dựng một mô hình ENN với cấu trúc mạng gồm 9-55-1 để dự đoán thông lượng màng với độ lệch trung bình là 2,7%. Thông qua phân tích độ nhạy, họ cho thấy điều kiện rửa ngược màng tốt nhất là rửa ngược áp suất cao với khoảng cách giữa các lần rửa ngắn. Gần đây hơn, Viet và cộng sự (2021) đã xây dựng mô hình RNN để dự đoán độ dẫn điện của hỗn hợp bùn và thông lượng màng trong quá trình thẩm thấu

màng lọc sinh học trong suốt 40 ngày, cho thấy RMSE ở mức chấp nhận được là 18 mS/cm và 1,1 LMH, tương ứng. Các nghiên cứu trên đã chỉ ra rằng việc xem xét các yếu tố phát triển theo chuỗi thời gian có thể giúp dự đoán tốt hơn hiện tượng tắc nghẽn màng, trong khi việc diễn giải mô hình có thể giúp thiết kế các điều kiện vận hành tối ưu hơn hoặc quy trình công nghệ. Những phát hiện này có thể góp phần vào việc vận hành MBR được cá nhân hóa. Hạn như MLP, RBFNN, RNN, và CNN, để phân tích hiện tượng đóng bám màng. Chen và cộng sự (2012) đã phát triển một mô hình MLP sử dụng công suất sục khí của quá trình sinh học, công suất sục khí màng, lưu lượng tuần hoàn bùn hỗn hợp và thông lượng màng làm các biến đầu vào để dự đoán mức tiêu thụ năng lượng trên mỗi đơn vị nước được sản xuất trong một hệ thống MBR quy mô đầy đủ với giá trị vượt quá R^2 0.55. Zhao và cộng sự (2019) đã xây dựng một mô hình RBFNN để định lượng năng lượng liên bề mặt của MBR bằng cách xem xét góc tiếp xúc của nước/glycerol/diiodomethane trên bề mặt bùn/màng, điện thế zeta của bề mặt bùn/màng, và khoảng cách giữa các hạt bùn và bề mặt màng làm các biến đầu vào. Thời gian tính toán mà RBFNN cần là chỉ khoảng 1/50 thời gian của phương pháp Derjaguin-Landau-Verwey-Overbeek mở rộng theo hướng giải tích. Shi và cộng sự (2022) đã xây dựng một mô hình CNN dựa trên cơ chế chú ý. Mô hình sử dụng một tập ảnh mức xám đã xử lý là đầu vào để phân loại hiện tượng đóng bám màng với độ chính xác chẩn đoán đạt 98%. Bên cạnh các phương pháp học có giám sát, các phương pháp học không giám sát cũng được sử dụng để phân tích hiện tượng đóng bám màng nhằm tối ưu hóa quy trình vận hành (Woo và cộng sự, 2022). Mặc dù không thể giám sát trực tuyến hầu hết các đặc trưng mô hình trong những ứng dụng trên, các mô hình này vẫn có năng lực phân tích mạnh mẽ. Những ứng dụng này mang đến những hiểu biết mới cho các nhà nghiên cứu để phân tích các cơ chế đóng bám màng và cung cấp cơ sở mô hình hóa cho việc kiểm soát có mục tiêu hiện tượng đóng bám màng. Other model applications

Các mô hình khác, chẳng hạn như (SVM bao gồm)SVR, SVM (bình phương tối thiểu)LSSVM, RF, GBDT giới hạn, và GBDT cũng đã được áp dụng để dự đoán hiện tượng cấu bẩn màng trong các MBR. Bảng S4 trong Phụ lục A trình bày các ví dụ về việc sử dụng SVM hoặc các mô hình dựa trên cây để dự đoán sự tắc nghẽn màng. Mặc dù việc ứng dụng các mô hình này không phổ biến bằng ANN, chúng vẫn cho thấy khả năng dự đoán tốt trong nhiều tình huống. Hamed et al. (2019) đã xây dựng một mô hình LSSVM để đơn giản hóa việc tối ưu hóa của một hệ phương trình tuyến tính. MLSS, TMP,

flux, and temperature were selected as input parameters to predict the filtration resistance. LSSVM model outperformed both the PSO-MLP model ($R^2 = 0.96$) and the gene expression programming model ($R^2 = 0.98$), achieving an R^2 of 0.99. Li et al. (2020) developed an RF model with 300 trees and 2 node variables. MLSS, TMP, and membrane resistance were selected as the main input features, as pre-evaluated via principal component analysis (PCA), to predict the membrane flux. The results showed that the RF model ($R^2 = 0.95$) outperformed the SVM model ($R^2 = 0.92$) and the MLP model ($R^2 = 0.89$). As seen from this example, the RF models may be more suitable than SVM and MLP models for predicting membrane fouling. The use of PCA for feature selection in these applications indicates the possibility of multicollinearity between factors that affect membrane fouling. Although the factors contributing to membrane fouling are complex, a few representative indicators can be selected for online monitoring and prediction.

4 Tutorial example

4.1 Method

According to the above literature review, BPNN, SVM, and RF have emerged as prevalent machine learning models, among which the BP and SVM models have been most widely used in MBRs. The GA is the predominant algorithm used for model optimization. In addition, introducing of long short-term memory mechanism in LSTM (as a variant of RNN) has demonstrated significant promise in addressing time issues. Given the complex nature of fouling formation compared to pollutant removal, the real-time prediction of membrane fouling proved is crucial, particularly considering the dynamic and time-sensitive interactions between foulants and membranes.

This tutorial aims to apply five typical machine learning methods (SVM, RF, BPNN, LSTM, and GA-BP) to predict membrane fouling in MBR systems. A virtual data set (see S Appendix B for the datasheet) was created for the machine learning practice of this example which is conducted on the MATLAB platform.

4.1.1 Data preprocessing

One should first specify the independent variables (as input characteristics) and the dependent variables (as output characteristics) from the raw data set. In this example, TMP was selected as the target output to

characterize the fouling state. The possibly important influencing factors for fouling were selected as input characteristics, according to the common understanding and preliminary investigations. In this example, variables such as temperature, MLSS, pH, DO in aerobic zone, influent water quality (COD, TN, and TP), and membrane flux were selected as input characteristics. To eliminate the adverse effects caused by singular data and expedite convergence, “mapminmax” function in MATLAB was applied to normalize the input and output data within the range of [0,1]. Subsequently, 70% of the sample data was randomly selected as the training set, and the remaining 30% for the test set.

4.1.2 Selection of model and policy

The MATLAB software was used for the modeling and programming (see Appendix C for the exemplary codes). For the SVM modeling, the LibSVM toolkit was employed for regression prediction, with the RBF kernel chosen as the kernel function. The parameters C (penalty coefficient, representing the tolerance for error) and G (a parameter for the RBF kernel function, calculated as $G = 1/(2\sigma_{\text{RBF}}^2)$, which implicitly determines the distribution of the data mapped to the new feature space) are optimized through CV. To construct BPNN, LSTM, and RF models, the neural network toolbox and random forest toolbox were selected from the MATLAB packages. The backpropagation training algorithm was employed for neural network model development. For GA-BP, a hybrid model of GA and BPNN algorithm was established, which involves a three-step process of selection, crossover, and mutation to globally optimize the weight and bias of the neural network.

4.1.3 Model evaluation

The reliability and accuracy of each model were evaluated by three statistical parameters: R^2 , RMSE, and MAPE. In general, the MAPE and RMSE values being closer to 0 (or R^2 closer to 1) suggest a more accurate prediction and better model performance.

4.2 Results and discussion

4.2.1 Presentation of raw data

Table S5 displays the mean, standard deviation, and maximum and minimum values of the input and output data. The input variables consisted of T , MLSS, pH, aerobic-zone DO, influent COD, influent TN, influent

lưu lượng, và nhiệt độ được chọn làm các tham số đầu vào để dự đoán điện trở lọc. Mô hình LSSVM hoạt động tốt hơn cả mô hình PSO-MLP với ($R^2 = 0,96$) lẫn mô hình lập trình biểu hiện gen với ($R^2 = 0,98$), đạt giá trị R^2 là 0,99. Li và cộng sự ((2020)) đã phát triển một mô hình RF với 300 cây và 2 biến nút. MLSS, TMP, và điện trở màng được chọn làm các đặc trưng đầu vào chính, đã được đánh giá sơ bộ bằng phân tích thành phần chính ((PCA)), để dự đoán lưu lượng qua màng. Các kết quả cho thấy rằng mô hình RF ($R^2 = 0,95$) hoạt động tốt hơn mô hình SVM với ($R^2 = 0,92$) và mô hình MLP với ($R^2 = 0,89$). Như có thể thấy từ ví dụ này, các mô hình RF có thể phù hợp hơn so với các mô hình SVM và MLP để dự đoán hiện tượng bám bẩn màng. Việc sử dụng PCA để lựa chọn đặc trưng trong các ứng dụng này cho thấy khả năng tồn tại đa cộng tuyến giữa các yếu tố ảnh hưởng đến hiện tượng bám bẩn màng. Mặc dù các yếu tố góp phần gây ra hiện tượng bám bẩn màng rất phức tạp, vẫn có thể chọn một vài chỉ số đại diện để giám sát trực tuyến và dự đoán.

4 Ví dụ hướng dẫn

4.1 Phương pháp

Theo tài liệu tổng quan ở trên, BPNN, SVM và RF đã trở thành các mô hình học máy phổ biến, trong số đó các mô hình BP và SVM được sử dụng rộng rãi nhất trong MBR. GA là thuật toán chủ yếu được sử dụng để tối ưu hóa mô hình. Ngoài ra, việc đưa cơ chế bộ nhớ dài ngắn hạn vào LSTM —một biến thể của RNN— đã cho thấy nhiều triển vọng trong việc giải quyết các vấn đề về thời gian. Do hình thành màng bám bẩn có bản chất phức tạp hơn so với việc loại bỏ chất ô nhiễm, nên việc dự đoán theo thời gian thực hiện tượng màng bám bẩn đã được chứng minh là rất quan trọng, đặc biệt khi xét đến các tương tác ma ng tính động và nhạy cảm với thời gian giữa các thông số đầu vào và đầu ra. Trong bài báo này, năm phương pháp học máy điển hình SVM, (RF, BPNN, LSTM, và GA-BP) để dự đoán hiện tượng đóng bám màng trong các hệ thống MBR. Một bộ dữ liệu ảo (xem Phụ lục B để biết bảng dữ liệu)) đã được tạo để thực hành học máy trong ví dụ này, được thực hiện trên nền tảng MATLAB.

4.1.1 Tiền xử lý dữ liệu

Trước tiên, nên xác định các biến độc lập là đặc trưng đầu vào và các biến phụ thuộc là đặc trưng đầu ra từ tập dữ liệu thô. Trong ví dụ này, TMP được chọn làm đầu ra mục tiêu để

mô tả trạng thái cấu bẩn. Các yếu tố có thể ảnh hưởng quan trọng đến hiện tượng cấu bẩn được chọn làm đặc trưng đầu vào dựa trên hiểu biết chung và các khảo sát sơ bộ. Trong ví dụ này, các biến như nhiệt độ, MLSS, pH, DO trong vùng hiếu khí, chất lượng nước đầu vào gồm COD, T N và TP, cùng với thông lượng màng được chọn làm đặc trưng đầu vào. Để loại bỏ các ảnh hưởng bất lợi do dữ liệu dị thường gây ra và đẩy nhanh quá trình hội tụ, hàm “mapminmax” trong MATLAB được áp dụng để chuẩn hóa dữ liệu đầu vào và đầu ra về khoảng [0,1]. Sau đó, 70% dữ liệu mẫu được chọn ngẫu nhiên làm tập huấn luyện, 30% còn lại làm tập kiểm tra.

4.1.2 Lựa chọn mô hình và chính sách

Phần mềm MATLAB được sử dụng để mô hình hóa và lập trình (xem Phụ lục C để biết các mã ví dụ). Để mô hình hóa SVM, bộ công cụ LibSVM được sử dụng cho dự đoán hồi quy, với hàm nhân RBF được chọn làm hàm nhân. Các tham số C (hệ số phạt, biểu thị mức dung sai đối với sai số) và G (một tham số cho hàm nhân RBF, được tính bằng $G = 1/(2\sigma_{\text{RBF}}^2)$, qua đó xác định ngầm định phân bố của dữ liệu được ánh xạ sang không gian đặc trưng mới) được tối ưu hóa thông qua CV. Để xây dựng các mô hình BPNN, LSTM và RF, hộp công cụ mạng nơ-ron và hộp công cụ rừng ngẫu nhiên được chọn từ các gói MATLAB. Thuật toán huấn luyện lan truyền ngược được sử dụng để phát triển mô hình mạng nơ-ron. Đối với GA-BP, một mô hình lai kết hợp GA và thuật toán BPNN được xây dựng, bao gồm quy trình ba bước gồm chọn lọc, lai ghép, và đột biến để tối ưu hóa toàn cục trọng số và độ chệch của mạng nơ-ron.

4.1.3 Đánh giá mô hình

Độ tin cậy và độ chính xác của từng mô hình được đánh giá bằng ba tham số thống kê: R^2 , RMSE và MAPE. Nhìn chung, các giá trị MAPE và RMSE càng gần 0 hoặc càng gần 1 thì dự đoán càng chính xác và hiệu suất mô hình càng tốt.

4.2 Kết quả và thảo luận

4.2.1 Trình bày dữ liệu thô

Bảng S5 trình bày giá trị trung bình, độ lệch chuẩn và giá trị lớn nhất và nhỏ nhất của dữ liệu đầu vào và đầu ra. Các biến đầu vào bao gồm m , MLSS, pH, TDO vùng hiếu khí, COD nước thải đầu vào, TN nước thải đầu vào, nước thải đầu vào

TP, and flux. The output variable was TMP. Machine learning models establish a mapping relationship between input and output variables to predict fouling. The raw data set comprises 2000 samples, with 70% randomly selected for training and the remaining 30% for testing.

4.2.2 Model performance

The set of model parameters is presented in Section 1 of Appendix A. Table 3 compares the prediction results of the SVM, RF, BPNN, LSTM, and GA-BP methods. All five models demonstrated good fitting ability for the full data set. The SVM, BPNN, LSTM, and GA-BP performed similarly on the training and testing sets, whereas RF showing good fitting ability but weaker generalized predictability. Although RFs do not have the problem of overfitting (Peter et al., 1998), their lack of generalization ability may originate from the correlation and redundancy among the independent variables caused by randomly drawn features (Wu et al., 2012). The generalization ability of the model can be improved by increasing the number of trees, performing feature selection, and optimizing the pruning algorithm (Yang et al., 2012). The LSTM has a slightly better predictive ability than BPNN. The GA-BP improved the prediction compared with the BPNN.

5 Summary and prospect

Machine learning models, including ANNs, SVMs, and decision trees, have been used to predict membrane filtration performances in MBRs. Several models have been reported to exhibit fairly good fitting performance and generalization ability. The model parameters can be optimized using intelligent optimization algorithms such as GA and PSO to enhance predictability. The

application of SHAP to the interpretation of MBR predication models has developed rapidly (Aldrees et al., 2024a; Niu et al., 2024). However, the present models are facing challenges in terms of: (a) inadequate input features and monitoring indices, (b) limited interpretability and generalizability of model prediction, and (c) lacked utilization in automated process control. This calls for further advancements in the modeling techniques and deeper integration of modeling into the physical world (e.g., monitoring and control systems). Therefore, we recommend exploring the constraints and enhancements of machine learning in MBR engineering validation applications at four levels: constitution of model features, online monitoring of model features, application toward process control, and data sharing and generalization.

(1) The model input parameters can be extended to achieve a more accurate and comprehensive description of key features. Compared to the conventional rough indices to describe overall membrane fouling by current models, specific indicators can be refined to more accurately describe fouling behavior (e.g., fouling potential for specific fouling stages) and foulant properties (e.g., polysaccharide/protein/humus concentrations and molecular characteristics). Another requirement is to extend the current index system toward a more complete coverage of possible factors. Previous models for pollutant removal efficiency have paid less attention to the effects of membrane operating state (TMP, flux, permeability, MFI, etc.) and the resultant pollutant interception by the membrane. In fouling prediction models, MFI and CCI have been frequently utilized as input parameters, whereas OI, which is related to membrane backwash and scouring, has not been adequately included. Traditional concentration parameters can be integrated with membrane status and operating conditions in the ensuing models. The inclusion of these more accurate

TP, và thông lượng . Biến đầu ra là TMP. Các mô hình học máy thiết lập mối quan hệ ánh xạ giữa các biến đầu vào và đầu ra để dự đoán hiện tượng bám bẩn. Bộ dữ liệu thô gồm 2 000 mẫu, trong đó 70% được chọn ngẫu nhiên để huấn luyện, còn 30% còn lại dùng để kiểm tra.

4.2.2 Hiệu suất mô hình

Tập hợp các tham số của mô hình được trình bày trong Mục 1, Phụ lục A. Bảng 3 so sánh kết quả dự đoán của các phương pháp SVM, RF, BPNN, LSTM và GA-BP. Cả năm mô hình đều cho thấy khả năng khớp tốt với toàn bộ tập dữ liệu. SVM, BPNN, LSTM và GA-BP có hiệu suất tương tự trên tập huấn luyện và tập kiểm tra, trong khi RF cho thấy khả năng khớp tốt nhưng khả năng dự đoán tổng quát hóa yếu hơn. Mặc dù RF không gặp vấn đề quá khớp (Peter và cộng sự, 1998), khả năng tổng quát hóa hạn chế của phương pháp này có thể bắt nguồn từ sự tương quan và dư thừa giữa các biến độc lập do các đặc trưng được lấy mẫu ngẫu nhiên (Wu và cộng sự, 2012). Có thể cải thiện khả năng tổng quát hóa của mô hình bằng cách tăng số lượng cây, thực hiện lựa chọn đặc trưng và tối ưu hóa thuật toán cắt tỉa (Yang và cộng sự, 2012). LSTM có khả năng dự đoán nhỉnh hơn một chút so với BPNN. GA-BP cải thiện kết quả dự đoán so với BPNN.

5 Tổng kết và triển vọng

Các mô hình học máy, bao gồm mạng nơ-ron nhân tạo (ANN), máy vector hỗ trợ (SVM) và cây quyết định, đã được sử dụng để dự đoán hiệu suất lọc màng trong các hệ thống MBR. Một số mô hình đã được báo cáo là có hiệu quả khớp dữ liệu và khả năng khái quát hóa khá tốt. Các tham số của mô hình có thể được tối ưu hóa bằng các thuật toán tối ưu hóa thông minh như GA và PSO để nâng cao khả năng dự đoán. The

việc ứng dụng SHAP để diễn giải các mô hình dự đoán MBR đã phát triển nhanh chóng (Aldrees và cộng sự, 2024a; Niu và cộng sự, 2024). Tuy nhiên, các mô hình hiện tại đang đối mặt với những thách thức về các khía cạnh sau: (a) đặc trưng đầu vào không đầy đủ và các chỉ số giám sát, (b) khả năng diễn giải và khả năng khái quát hóa của các dự đoán của mô hình, và (c) chưa được ứng dụng trong điều khiển quy trình tự động. Điều này đòi hỏi phải có những tiến bộ hơn nữa trong các kỹ thuật mô hình hóa và tích hợp sâu hơn các mô hình vào thế giới vật lý (chẳng hạn như các hệ thống giám sát và điều khiển). Vì vậy, chúng tôi khuyến nghị nghiên cứu các hạn chế và những cải tiến của học máy trong các ứng dụng thực tiễn kỹ thuật MBR ở bốn cấp độ: cấu trúc ảnh hưởng các đặc trưng của mô hình, giám sát trực tiếp các đặc trưng của mô hình, ứng dụng và điều khiển quy trình, và chia sẻ dữ liệu và khả năng mô phỏng để đạt được mô tả chính xác và khái quát hóa hơn về các đặc điểm then chốt. So với các chỉ số thông thường dùng để mô tả tổng thể hiện tượng đóng bẩn màng, trong các mô hình hiện tại, các chỉ báo cụ thể có thể được tinh chỉnh để mô tả chính xác hơn hành vi đóng bẩn, ví dụ như (tiềm năng đóng bẩn ở các giai đoạn đóng bẩn cụ thể và đặc tính của chất gây bẩn,) chẳng hạn như nồng độ polysaccharide/protein/chất mùn (và đặc tính phân tử. Một yêu cầu khác là mở rộng hệ thống chỉ số hiện tại theo hướng bao quát đầy đủ hơn các yếu tố có thể có. Các mô hình trước đây về hiệu suất loại bỏ chất ô nhiễm ít chú ý đến ảnh hưởng của trạng thái vận hành màng, bao gồm TMP, thông lượng, độ thấm, MFI, v.v., và khả năng giữ lại chất ô nhiễm do màng tạo ra. Trong các mô hình dự đoán đóng bẩn, MFI (và CCI thường được sử dụng làm) tham số đầu vào, trong khi OI, có liên quan đến quá trình rửa ngược và rửa màng, chưa được đưa vào một cách đầy đủ. Các tham số nồng độ truyền thống có thể được tích hợp với trạng thái màng và điều kiện vận hành trong các mô hình tiếp theo. Việc đưa vào những tham số chính xác hơn này

Table 3 Performance of different machine learning models for the tutorial example

		SVM	RF	BPNN	LSTM	GA-BP
R^2	Training	0.8208	0.9017	0.8199	0.8206	0.8201
	Testing	0.8124	0.7344	0.8096	0.8175	0.8128
	All Data	0.8184	0.8537	0.8170	0.8197	0.8180
RMSE	Training	1.4075	1.0424	1.4107	1.4080	1.4100
	Testing	1.3955	1.6605	1.4058	1.3765	1.3940
	All Data	1.4039	1.2601	1.4092	1.3987	1.4052
MAPE	Training	0.0616	0.0463	0.0629	0.0630	0.0628
	Testing	0.0624	0.0737	0.0636	0.0619	0.0625
	All Data	0.0618	0.0545	0.0631	0.0626	0.0627

Bảng 3 Hiệu suất của các mô hình học máy khác nhau đối với ví dụ hướng dẫn

		SVM	RF	BPNN	LSTM	GA-BP
R^2	Training	0.8208	0.9017	0.8199	0.8206	0.8201
	Testing	0.8124	0.7344	0.8096	0.8175	0.8128
	All Data	0.8184	0.8537	0.8170	0.8197	0.8180
RMSE	Training	1.4075	1.0424	1.4107	1.4080	1.4100
	Testing	1.3955	1.6605	1.4058	1.3765	1.3940
	All Data	1.4039	1.2601	1.4092	1.3987	1.4052
MAPE	Training	0.0616	0.0463	0.0629	0.0630	0.0628
	Testing	0.0624	0.0737	0.0636	0.0619	0.0625
	All Data	0.0618	0.0545	0.0631	0.0626	0.0627

and complete monitoring indices as input features would thus facilitate the machine learning for MBR processes.

(2) Online monitoring of the key parameters is crucial in developing “smart” models that are timely responsive to real-time operating status of MBRs. The conventional online monitoring items include temperature, pH, DO, turbidity, and COD, etc., which are inadequate to provide accurate details of pollutants/foulants for the modeling. For instance, COD can only reflect the overall concentration of organic matter, without revealing details of chemical composition and molecular structure. Elaborate measurements of these properties are often laborious, time-consuming, and unsuitable for online monitoring. Alternatively, spectroscopic methods (such as ultraviolet, visible, and fluorescence spectroscopy) offer new possibilities for real-time reflection of molecular details. These techniques are fast, sensitive, and informative for exploration of molecular fingerprints, and are promising supplements to the online monitoring system. Combining online spectral indicators with membrane operating status and control conditions is beneficial for developing models that are really implementable for process control.

(3) Feedforward models are required to support the early warning and proactive control of MBR processes. For optimized operation of MBRs in terms of pollutant removal and fouling mitigation, preventive actions should be taken in advance rather than reacting to adverse events. However, current MBRs lack feedforward control. Although most models have demonstrated fairly good performance in simulating existing facts, their capability to predict future tendencies remains insufficient. Owing to incomplete input features and lack of prediction models, intelligent feedforward fouling control has not yet been realized. In the ensuing modeling, attention should be paid to the tendency indices (e.g., fouling potential) as the model output, or incorporate time series concepts to forecast future performances from current operation status. Moreover, the model results should be coupled with an automatic control system to make them practical.

(4) A widely shared database can be constructed to enhance the interpretability and generalizability of the models. The interpretability of “black box” models remains a longstanding issue, and the complexity of physical/chemical/biological processes in MBR systems poses new requirements and obstacles for the interpretability of the predictive models. Currently, the application of model interpretation and deep learning models in MBR prediction remains limited. Various methods, such as decision rule analysis, correlation

coefficient comparison, sensitivity factor analysis, and SHAP, can help explain the model, but have not been sufficiently used. The incompleteness of input features makes the interpretation of the model toward its real physical meaning even harder. To support a robust deep learning model with sufficient input features and widely generalizable, a large amount of representative data are critical, which requires a significant workload for data collection and preprocess. To address this challenge, an open database similar to ImageNet would make great sense, where different researchers can share data and develop predictive models with better generalization and broader application by using large and diverse experimental or engineering data.

In summary, the future trajectory of machine learning in MBRs encompasses a multitude of dimensions, including monitoring multidimensional features with online potential, extracting spectral-driven molecular details, integrating intelligent control system based on real-time warning models, and establishing open and shared data systems. Additionally, model innovation is also noteworthy. Cutting-edge AI methods, such as explainable reinforcement learning (Yu et al., 2023) and large models based on the Transformer framework or multimodality (Vasu et al., 2023), have demonstrated considerable potential in certain fields, including remote sensing (Sun et al., 2023), spatio-temporal early prediction (Wei et al., 2024), and 3D object detection (Li et al., 2024b). It is also important for researchers to consider simple cutting-edge models such as KAN (Kolmogorov-Arnold Network with learnable activation functions on weights rather than employing fixed activation functions on neurons) (Liu et al., 2024), xLSTM (extended LSTM with exponential gating and enhanced memory structures) (Beck et al., 2024). The incorporation of physics-informed, physics-aware, or data-knowledge driven methodologies can also improve the model performance and/or interpretability (Nguyen et al., 2023; Li et al., 2024a; Wang et al., 2024a). However, these new models or methods have not been significantly underutilized in the field of water management and wastewater engineering. It is recommended that MBR researchers direct their attention to these cutting-edge directions. Machine learning (including deep learning) has several applications in materials, biology, medicine, and remote sensing. The field of water treatment may benefit from the interdisciplinary or cross-disciplinary inspiration of machine learning techniques, which have the potential to enhance the existing approaches to water treatment. The profiling of data types, solution goals, and application requirements facilitates the selection and optimization of models. Further comprehensive

và do đó, việc sử dụng các chỉ số giám sát ho àn chỉnh làm đặc trưng đầu vào sẽ hỗ trợ qu á trình học máy cho các quy trình MBR.

(2) Việc giám sát trực tuyến các thông số then chốt có vai trò quan trọng trong việc phát triển các mô hình “thông minh” có khả năng phản ứ ng kịp thời với trạng thái vận hành theo thời gi an thực của MBR. Các hạng mục giám sát trực tuyến truyền thống bao gồm nhiệt độ, pH, D O, độ đục, và COD, v.v., nhưng không đủ để cung cấp thông tin chi tiết chính xác về các chấ t ô nhiễm/chất gây bám bẩn phục vụ cho việc x ây dựng mô hình. Chẳng hạn, COD chỉ có thể p hản ánh nồng độ tổng thể của chất hữu cơ, m à không cho biết chi tiết về thành phần hóa họ c và cấu trúc phân tử. Việc đo đạc tỉ mỉ các đặ c tính này thường tốn nhiều công sức, thời gia n và không phù hợp với giám sát trực tuyến. Ngoài ra, các phương pháp quang phổ như q uang phổ tử ngoại, khả kiến và huỳnh quang mang lại những khả năng mới để phản ánh c ác chi tiết phân tử theo thời gian thực. Những kỹ thuật này nhanh, (nhạy và giàu thông tin, giúp khảo sát các dấu vân tay phân tử, đồng t hời là những phương pháp hỗ trợ)đầy hứa hẹn cho hệ thống giám sát trực tuyến. Việc kết hợ p các chỉ thị phổ trực tuyến với trạng thái vận hành màng và các điều kiện kiểm soát có lợi cho việc phát triển các mô hình thành thạo có thể triển khai để điều khiển quy trình và kiểm soát chủ động các quy trình MBR. Để vận hành tối ưu các MBR xét về khả năng loại bỏ chất ô nh iễm và hạn chế bám bẩn, cần thực hiện các b iện pháp phòng ngừa từ trước thay vì chờ đế n khi các sự cố bất lợi xảy ra rồi mới ứng phó. Tuy nhiên, các hệ thống MBR hiện nay chưa có khả năng điều khiển truyền thẳng. Mặc dù hầ u hết các mô hình đã cho thấy hiệu suất khá t ốt trong việc mô phỏng các hiện tượng hiện c ó, khả năng dự đoán xu hướng trong tương la i của chúng vẫn chưa đủ. Do các đặc trưng đ ầu vào chưa đầy đủ và thiếu các mô hình dự đ oán, việc kiểm soát bám bẩn thông minh theo kiểu truyền thẳng vẫn chưa được hiện thực h óa. Trong các nghiên cứu mô hình hóa tiếp the o, cần chú ý đến các chỉ số xu hướng, ví dụ n hư tiềm năng bám bẩn, làm đầu ra của mô hì nh, hoặc tích hợp các khái niệm chuỗi thời gia n để dự báo hiệu suất trong tương lai dựa trê n (trạng thái vận hành hiện tại, các thông số đượ c k ết hợp để nâng cao khả năng diễn giải và k ết hợp các kết quả mô hình.) Với một hệ thống k hai quát hóa các mô hình, khả năng diễn g iải điều khiển từ động để có thể ứng dụng chung l ài của các mô hình “hộp đen” vẫn là một vấn đề tồn tại từ lâu, và độ phức tạp của các quá trình vật lý/hóa học/sinh học trong các hệ thống MBR đặt ra những yêu cầu và trở ngại mới đối với kh ả năng diễn giải của các mô hình dự báo. Hiện n ay, việc ứng dụng các phương pháp diễn giải m ô hình và mô hình học sâu trong dự báo MBR v ẫn còn hạn chế. Nhiều phương pháp, chẳng hạ n như phân tích quy tắc quyết định, tương quan

so sánh hệ số , phân tích độ nhạy hệ số , và S HAP có thể giúp giải thích mô hình , nhưng c hưa được sử dụng đầy đủ. Sự không đầy đủ của các đặc trưng đầu vào khiến việc diễn giải mô hình theo hướng ý nghĩa vật lý thực sự củ a nó càng khó khăn hơn. Để hỗ trợ một mô h ình học sâu vững chắc với đầy đủ các đặc trun g đầu vào và khả năng khái quát hóa rộng, m ột lượng lớn dữ liệu mang tính đại diện là rất quan trọng, điều này đòi hỏi một khối lượng c ông việc đáng kể để thu thập dữ liệu và tiền x ử lý. Để giải quyết thách thức này, một cơ sở dữ liệu mở tương tự như ImageNet sẽ rất hữ u ích, nơi các nhà nghiên cứu khác nhau có th ể chia sẻ dữ liệu và phát triển các mô hình dự đoán có khả năng khái quát hóa tốt hơn và ph ản ánh đại diện cho các điều kiện vận hành của MBR. Để đạt được điều này, cần có các đặc trưng đ a chi ều có tiềm năng trực tuyến, trích xuất chi tiết p hân tử dựa trên phổ, tích hợp hệ thống điều khi ển thông minh dựa trên các mô hình cảnh báo t heo thời gian thực, và xây dựng các hệ thống d ữ liệu mở, được chia sẻ. Bên cạnh đó, đổi mới m ô hình cũng đáng chú ý. Các phương pháp AI tiê n tiến, chẳng hạn như học tăng cường có thể g ải thích (Yu và cộng sự, 2023), các mô hình lớn d ựa trên kiến trúc Transformer hoặc mô hình đa phương thức (Vasu và cộng sự, 2023), đã cho th ấy tiềm năng đáng kể trong một số lĩnh vực, ba o gồm viễn thám (Sun và cộng sự, 2023), dự bá o sớm theo không gian-thời gian (Wei và cộng s ự, 2024) và phát hiện vật thể 3D (Li và cộng sự, 2024b). Các nhà nghiên cứu cũng cần cân nhắc những mô hình tiên tiến, đơn giản như KAN (m ạng Kolmogorov-Arnold, sử dụng các hàm kích hoạt có thể học trên trọng số thay vì các hàm kí ch hoạt cố định trên nơ-ron) (Liu và cộng sự, 20 24) và xLSTM (mở rộng LSTM với cơ chế cổng hà m mũ và cấu trúc bộ nhớ tăng cường) (Beck và c ộng sự, 2024). Việc tích hợp các phương pháp đ ựa trên vật lý, nhận thức vật lý hoặc dựa trên tri thức dữ liệu cũng có thể cải thiện hiệu năng và/ hoặc khả năng diễn giải của mô hình (Nguyen v à cộng sự, 2023; Li và cộng sự, 2024a; Wang và cộng sự, 2024a). Tuy nhiên, các mô hình hoặc p hương pháp mới này vẫn chưa được ứng dụng rộng rãi trong lĩnh vực quản lý nước và kỹ thuật xử lý nước thải. Các nhà nghiên cứu MBR được khuyến nghị chú ý đến những hướng nghiên cứ u tiên tiến này. Học máy, bao gồm học sâu, có n hiều ứng dụng trong khoa học vật liệu, sinh học , y học và viễn thám. Lĩnh vực xử lý nước có thể hưởng lợi từ nguồn cảm hứng liên ngành hoặc xuyên ngành từ các kỹ thuật học máy, vốn có tiê m năng nâng cao những phương pháp xử lý nư ớc hiện có. Việc lập hồ sơ các loại dữ liệu, mục ti êu giải pháp và yêu cầu ứng dụng tạo điều kiện thuận lợi cho việc lựa chọn và tối ưu hóa mô hìn h. Toàn diện hơn nữa

exploration of the prospective applications of intelligent optimization algorithms (also known as metaheuristic algorithms), AutoML, and XAI in MBR procedures may facilitate the advancement of effective models for process prediction and explanation.

6 Conclusions

This paper summarized recent advances in machine learning for predicting the performance of MBR pollutants removal and membrane fouling. Based on the literature review, a range of machine learning methods, including ANN, SVM, and decision trees, have been utilized in this scope. Ordinary ANNs have dominated the prediction models, and there are limitations in the study of deep learning models. This paper not only reviewed the basic principles related to machine learning but also presented a tutorial example for readers to practice five models for the prediction of TMP. Alongside the great potential of machine learning in MBR research, further development and application of the models in full-scale engineering are challenged by inadequacies in input features and monitoring metrics, insufficient model interpretability and generalizability, and lack of practicability in automated process control. A more complete input index system reinforced by online monitoring would be crucial for developing real-time responsive or feedforward models that bridge the gap between model prediction and practical control. An open and shared MBR operation database would largely benefit advancements in model generalizability and interpretability. The application of deep learning and intelligent optimization algorithms may enhance the model performance. In addition, the integration of AutoML and XAI may facilitate the deployment of models in practical engineering applications. The information presented in this paper is expected to provide implications for future researches toward machine learning-based intelligent operation and maintenance of MBR processes.

Acknowledgements This work was supported by the National Natural Science Foundation of China (No. 52370059), the Beijing Natural Science Foundation (No. JQ22027), and the Fundamental Research Funds for the Central Universities (No. E2EG0502X2).

Conflict of Interests Kang Xiao and Xia Huang are editorial board members of *Frontiers of Environmental Science & Engineering*. The authors declare that this research was conducted without any commercial or financial relationships that could be construed as a potential conflict of interest.

Electronic Supplementary Material Supplementary material is

available in the online version of this article at <https://doi.org/10.1007/s11783-025-1954-2> and is accessible for authorized users.

Abbreviations

Abbreviation	Description
AIC	Akaike information criterion
ANFIS	Adaptive network-based fuzzy inference system
AnMBR	Anaerobic membrane bioreactor
ANN	Artificial neural networks
AUC	Area under curve
AutoML	Automated machine learning
BA	Bat algorithm
BFGS	Broyden-Fletcher-Goldfarb-Shanno
BIC	Bayesian information criterion
BOD	Biochemical oxygen demand
BPNN	Back propagation neural network
CART	Classification and regression tree
CCI	Conventional concentration indices
CFI	Characteristic foulant indices
CNN	Convolutional neural network
COD	Chemical oxygen demand
CV	Cross-validation
DNN	Deep neural network
DO	Dissolved oxygen
EC	Electrical conductivity
EI	Environment indices
ENN	Elman neural network
EPS	Extracellular polymeric substances
FFA	Firefly algorithm
FCN	Fully connected network
GA	Genetic algorithms
GA-BP	Genetic algorithm-back propagation
GBDT	Gradient boosting decision tree
GNN	Graph neural network
GWO	Grey wolf optimizer
HQC	Hannan-Quinn criterion
HRT	Hydraulic retention time
KAN	Kolmogorov-Arnold network
KNN	K-nearest neighbors
LM	Levenberg-Marquardt
LSSVM	Least-squares support vector machine
LSTM	Long short-term memory

Việc khám phá các ứng dụng tiềm năng của các thuật toán tối ưu hóa thông minh (còn được gọi là các thuật toán metaheuristic)), AutoML và XAI trong các quy trình MBR có thể thúc đẩy sự phát triển của các mô hình hiệu quả để dự đoán và giải thích quy trình.

6 Kết luận

Bài báo này tóm tắt những tiến bộ gần đây trong việc ứng dụng học máy để dự đoán hiệu suất loại bỏ chất ô nhiễm và hiện tượng tắc nghẽn màng trong MBR. Dựa trên tổng quan tài liệu, nhiều phương pháp học máy, bao gồm ANN, SVM và cây quyết định, đã được sử dụng trong lĩnh vực này. Các ANN thông thường chiếm ưu thế trong các mô hình dự đoán, trong khi nghiên cứu về các mô hình học sâu còn nhiều hạn chế. Bài báo này không chỉ điểm lại các nguyên lý cơ bản liên quan đến học máy mà còn trình bày một ví dụ hướng dẫn để độc giả thực hành năm mô hình dự đoán TMP. Bên cạnh tiềm năng to lớn của học máy trong nghiên cứu MBR, việc tiếp tục phát triển và ứng dụng các mô hình vào kỹ thuật quy mô toàn diện còn gặp nhiều thách thức do sự thiếu đầy đủ của các đặc trưng đầu vào và chỉ số giám sát, khả năng diễn giải và khái quát hóa mô hình còn hạn chế, cũng như tính khả thi thấp trong điều khiển quy trình tự động. Một hệ thống chỉ số đầu vào toàn diện hơn, được củng cố bằng hoạt động giám sát trực tuyến, sẽ đóng vai trò then chốt trong việc phát triển các mô hình phản hồi theo thời gian thực hoặc mô hình truyền thẳng, giúp thu hẹp khoảng cách giữa dự đoán của mô hình và điều khiển thực tế. Một cơ sở dữ liệu vận hành MBR mở và được chia sẻ rộng rãi sẽ góp phần đáng kể thúc đẩy khả năng khái quát hóa và diễn giải của mô hình. Việc ứng dụng học sâu và các thuật toán tối ưu hóa thông minh có thể nâng cao hiệu suất mô hình. Ngoài ra, việc tích hợp AutoML và XAI có thể hỗ trợ triển khai mô hình trong các ứng dụng kỹ thuật thực tế. Thông tin được trình bày trong bài báo này được kỳ vọng sẽ gợi mở cho các nghiên cứu trong tương lai về vận hành và bảo trì thông minh dựa trên học máy đối với các quy trình MBR.

Lời cảm ơn Công trình này được hỗ trợ bởi Quỹ Khoa học Tự nhiên Quốc gia Trung Quốc mã số 52370059 (, Quỹ Khoa học Tự nhiên Bắc Kinh)mã số JQ22027 và Quỹ Nghiên cứu Cơ bản dành cho (các trường đại học)trực thuộc trung ương mã số E2EG0502X2.

Xung đột lợi ích Kang Xiao và Xia Huang là thành viên ban biên tập của *Frontiers of Environmental Science & Engineering*. Các tác giả tuyên bố rằng nghiên cứu này được thực hiện mà không có bất kỳ mối quan hệ thương mại hoặc tài chính nào có thể được diễn giải là một xung đột lợi ích tiềm ẩn.

Tài liệu bổ sung điện tử Tài liệu bổ sung là

có sẵn trong phiên bản trực tuyến của bài viết này tại <http://s://doi.org/10.1007/s11783-025-1954-2> và có thể truy cập đối với người dùng được cấp quyền.

Các chữ viết tắt

Abbreviation	Description
AIC	Akaike information criterion
ANFIS	Adaptive network-based fuzzy inference system
AnMBR	Anaerobic membrane bioreactor
ANN	Artificial neural networks
AUC	Area under curve
AutoML	Automated machine learning
BA	Bat algorithm
BFGS	Broyden-Fletcher-Goldfarb-Shanno
BIC	Bayesian information criterion
BOD	Biochemical oxygen demand
BPNN	Back propagation neural network
CART	Classification and regression tree
CCI	Conventional concentration indices
CFI	Characteristic foulant indices
CNN	Convolutional neural network
COD	Chemical oxygen demand
CV	Cross-validation
DNN	Deep neural network
DO	Dissolved oxygen
EC	Electrical conductivity
EI	Environment indices
ENN	Elman neural network
EPS	Extracellular polymeric substances
FFA	Firefly algorithm
FCN	Fully connected network
GA	Genetic algorithms
GA-BP	Genetic algorithm-back propagation
GBDT	Gradient boosting decision tree
GNN	Graph neural network
GWO	Grey wolf optimizer
HQC	Hannan-Quinn criterion
HRT	Hydraulic retention time
KAN	Kolmogorov-Arnold network
KNN	K-nearest neighbors
LM	Levenberg-Marquardt
LSSVM	Least-squares support vector machine
LSTM	Long short-term memory

MAPE	Mean absolute percentage error
MBR	Membrane bioreactor
MFI	Membrane filtration indices
MLP	Multilayer perceptron
MLSS	Mixed liquor suspended solids
MLVSS	Volatile MLSS
MSE	Mean square error
NH ₃ -N	Ammonium nitrogen
NO ₃ ⁻ -N	Nitrate nitrogen
ODR	Oxygen decay rate
OI	Operation indices
OLR	Organic loading rate
ORP	Oxidation reduction potential
PCA	Principal component analysis
PSO	Particle swarm optimization
RBF	Radial basis function
RBFNN	Radial basis function neural network
RF	Random forest
RH	Relative hydrophobicity
RL	Reinforcement learning
RMSE	Root mean square error
RNN	Recurrent neural network
ROC	Receiver operating characteristic
SA	Simulated annealing
SHAP	Shapley additive explanations
SMP	Soluble microbial products
SRT	Sludge retention time
SVC	Support vector classification
SVM	Support vector machines
SVR	Support vector regression
<i>t</i>	Time parameter
<i>T</i>	Temperature
TMP	Transmembrane pressure
TN	Total nitrogen
TOC	Total organic carbon
TP	Total phosphorus
TSS	Total suspended solids
WNN	Wavelet neural network
XAI	Explainable artificial intelligence

References

Abbott A S, Turney J M, Zhang B, Smith D G A, Altarawy D,

Schaefer H F III (2019). PES-learn: an open-source software package for the automated generation of machine learning models of molecular potential energy surfaces. *Journal of Chemical Theory and Computation*, 15(8): 4386–4398

Abdul Wahab N, Mahmod N, Vilanova R (2020). Permeate flux control in SMBR system by using neural network internal model control. *Processes*, 8(12): 1672

Ahmed I, Kajol M, Hasan U, Datta P P, Roy A, Reza M R (2024). ChatGPT versus Bard: a comparative study. *Engineering Reports*, 6(11): 12890

Aidan A, Abdel-Jabbar N, Ibrahim T H, Nenov V, Mjalli F (2008). Neural network modeling and optimization of scheduling backwash for membrane bioreactor. *Clean Technologies and Environmental Policy*, 10(4): 389–395

Akaike H (1974). New look at statistical-model identification. *IEEE Transactions on Automatic Control*, 19(6): 716–723

Al-Ghazawi Z, Alawneh R (2021). Use of artificial neural network for predicting effluent quality parameters and enabling wastewater reuse for climate change resilience: a case from Jordan. *Journal of Water Process Engineering*, 44: 102423

Aldrees A, Javed M F, Khan M, Siddiq B (2024a). Optimized prediction modeling of micropollutant removal efficiency in forward osmosis membrane systems using explainable machine learning algorithms. *Journal of Water Process Engineering*, 66: 105937

Aldrees A, Khan M, Taha A T B, Ali M (2024b). Evaluation of water quality indexes with novel machine learning and SHapley Additive ExPlanation (SHAP) approaches. *Journal of Water Process Engineering*, 58: 104789

Alexandridis A K, Zapranis A D (2013). Wavelet neural networks: a practical guide. *Neural Networks*, 42: 1–27

Alkmim A R, De Almeida G M, De Carvalho D M, Amaral M C S, Oliveira S (2020). Improving knowledge about permeability in membrane bioreactors through sensitivity analysis using artificial neural networks. *Environmental Technology*, 41(19): 2424–2438

Beck M, Poppel K, Spanring M, Auer A, Prudnikova O, Kopp M K, Klambauer G, Brandstetter J, Hochreiter S J A (2024). xLSTM: Extended long short-term memory. *ArVix*, abs/2405.04517

Bi K, Xie L, Zhang H, Chen X, Gu X, Tian Q (2023). Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 619(7970): 533–538

Bindal S, Singh C K (2019). Predicting groundwater arsenic contamination: regions at risk in highest populated state of India. *Water Research*, 159: 65–76

Bishop C M (2006). *Pattern recognition and machine learning*. Springer New York, NY

Breiman L (2001). Random forests. *Machine Learning*, 45(1): 5–32

Breiman L, Friedman J, Olshen R A, Stone C J (1984). *Classification and Regression Trees*. New York: Chapman and Hall/CRC

Browne M W (2000). Cross-validation methods. *Journal of Mathematical Psychology*, 44(1): 108–132

Byeon H (2023). Advances in value-based, policy-based, and deep learning-based reinforcement learning. *International Journal of*

MAPE	Mean absolute percentage error
MBR	Membrane bioreactor
MFI	Membrane filtration indices
MLP	Multilayer perceptron
MLSS	Mixed liquor suspended solids
MLVSS	Volatile MLSS
MSE	Mean square error
NH ₃ -N	Ammonium nitrogen
NO ₃ ⁻ -N	Nitrate nitrogen
ODR	Oxygen decay rate
OI	Operation indices
OLR	Organic loading rate
ORP	Oxidation reduction potential
PCA	Principal component analysis
PSO	Particle swarm optimization
RBF	Radial basis function
RBFNN	Radial basis function neural network
RF	Random forest
RH	Relative hydrophobicity
RL	Reinforcement learning
RMSE	Root mean square error
RNN	Recurrent neural network
ROC	Receiver operating characteristic
SA	Simulated annealing
SHAP	Shapley additive explanations
SMP	Soluble microbial products
SRT	Sludge retention time
SVC	Support vector classification
SVM	Support vector machines
SVR	Support vector regression
<i>t</i>	Time parameter
<i>T</i>	Temperature
TMP	Transmembrane pressure
TN	Total nitrogen
TOC	Total organic carbon
TP	Total phosphorus
TSS	Total suspended solids
WNN	Wavelet neural network
XAI	Explainable artificial intelligence

References

Abbott A S, Turney J M, Zhang B, Smith D G A, Altarawy D,

Schaefer H F III (2019). PES-learn: an open-source software package for the automated generation of machine learning models of molecular potential energy surfaces. *Journal of Chemical Theory and Computation*, 15(8): 4386–4398

Abdul Wahab N, Mahmod N, Vilanova R (2020). Permeate flux control in SMBR system by using neural network internal model control. *Processes*, 8(12): 1672

Ahmed I, Kajol M, Hasan U, Datta P P, Roy A, Reza M R (2024). ChatGPT versus Bard: a comparative study. *Engineering Reports*, 6(11): 12890

Aidan A, Abdel-Jabbar N, Ibrahim T H, Nenov V, Mjalli F (2008). Neural network modeling and optimization of scheduling backwash for membrane bioreactor. *Clean Technologies and Environmental Policy*, 10(4): 389–395

Akaike H (1974). New look at statistical-model identification. *IEEE Transactions on Automatic Control*, 19(6): 716–723

Al-Ghazawi Z, Alawneh R (2021). Use of artificial neural network for predicting effluent quality parameters and enabling wastewater reuse for climate change resilience: a case from Jordan. *Journal of Water Process Engineering*, 44: 102423

Aldrees A, Javed M F, Khan M, Siddiq B (2024a). Optimized prediction modeling of micropollutant removal efficiency in forward osmosis membrane systems using explainable machine learning algorithms. *Journal of Water Process Engineering*, 66: 105937

Aldrees A, Khan M, Taha A T B, Ali M (2024b). Evaluation of water quality indexes with novel machine learning and SHapley Additive ExPlanation (SHAP) approaches. *Journal of Water Process Engineering*, 58: 104789

Alexandridis A K, Zapranis A D (2013). Wavelet neural networks: a practical guide. *Neural Networks*, 42: 1–27

Alkmim A R, De Almeida G M, De Carvalho D M, Amaral M C S, Oliveira S (2020). Improving knowledge about permeability in membrane bioreactors through sensitivity analysis using artificial neural networks. *Environmental Technology*, 41(19): 2424–2438

Beck M, Poppel K, Spanring M, Auer A, Prudnikova O, Kopp M K, Klambauer G, Brandstetter J, Hochreiter S J A (2024). xLSTM: Extended long short-term memory. *ArVix*, abs/2405.04517

Bi K, Xie L, Zhang H, Chen X, Gu X, Tian Q (2023). Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 619(7970): 533–538

Bindal S, Singh C K (2019). Predicting groundwater arsenic contamination: regions at risk in highest populated state of India. *Water Research*, 159: 65–76

Bishop C M (2006). *Pattern recognition and machine learning*. Springer New York, NY

Breiman L (2001). Random forests. *Machine Learning*, 45(1): 5–32

Breiman L, Friedman J, Olshen R A, Stone C J (1984). *Classification and Regression Trees*. New York: Chapman and Hall/CRC

Browne M W (2000). Cross-validation methods. *Journal of Mathematical Psychology*, 44(1): 108–132

Byeon H (2023). Những tiến bộ trong học tăng cường dựa trên giá trị, dựa trên chính sách, và học sâu. *Tạp chí Quốc tế về*

Advanced Computer Science and Applications, 14(8): 348–354

Cai Y H, Ben T, Zaidi A A, Shi Y, Zhang K, Lin A Q, Liu C (2019a). Effect of pH on pollutants removal of ship sewage treatment in an innovative aerobic-anaerobic micro-sludge MBR system. *Water, Air, and Soil Pollution*, 230(7): 163

Cai Y H, Zaidi A A, Shi Y, Zhang K, Li X, Xiao S H, Lin A Q (2019b). Influence of salinity on the biological treatment of domestic ship sewage using an air-lift multilevel circulation membrane reactor. *Environmental Science and Pollution Research International*, 26(36): 37026–37036

Castillo O, Aguilar L, Cazarez N, Cardenas S (2008). Systematic design of a stable type-2 fuzzy logic controller. *Applied Soft Computing*, 8(3): 1274–1279

Chang H M, Xu Y, Chen S S, He Z (2022). Enhanced understanding of osmotic membrane bioreactors through machine learning modeling of water flux and salinity. *Science of the Total Environment*, 838: 156009

Chen C, Sun M Z, Chang J, Liu Z W, Zhu X Z, Xiao K, Song G Q, Wang H, Liu G L, Huang X (2022). Unravelling temperature-dependent fouling mechanism in a pilot-scale anaerobic membrane bioreactor via statistical modelling. *Journal of Membrane Science*, 644: 120145

Chen J C, Ng W J, Luo R, Mu S, Zhang Z, Andersen M, Jorgensen P E (2012). Membrane bioreactor process modeling and optimization: ULU Pandan water reclamation plant. *Journal of Environmental Engineering*, 138(12): 1218–1226

Chen T, Guestrin C (2016). XGBoost: A Scalable Tree Boosting System. San Francisco: Association for Computing Machinery, 785–794

Chen W, Ran H, Cao X, Wang J, Teng D, Chen J, Zheng X (2020). Estimating PM_{2.5} with high-resolution 1-km AOD data and an improved machine learning model over Shenzhen, China. *Science of the Total Environment*, 746: 141093

Choi J G, Bae T H, Kim J H, Tak T M, Randall A A (2002). The behavior of membrane fouling initiation on the crossflow membrane bioreactor system. *Journal of Membrane Science*, 203(1–2): 103–113

Cortez P, Embrechts M J (2013). Using sensitivity analysis and visualization techniques to open black box data mining models. *Information Sciences*, 225: 1–17

de Campos Souza P V (2020). Fuzzy neural networks and neuro-fuzzy networks: a review the main techniques and applications used in the literature. *Applied Soft Computing*, 92: 106275

Dorigo M, Birattari M, Stützle T (2006). Ant colony optimization. *IEEE Computational Intelligence Magazine*, 1(4): 28–39

Espel D, Courty S, Auda Y, Sheeren D, Elger A (2020). Submerged macrophyte assessment in rivers: an automatic mapping method using Pleiades imagery. *Water Research*, 186: 116353

Gao Q, Li Z, Pan J (2019). A convolutional neural network for airport security inspection of dangerous goods. *IOP Conference Series. Earth and Environmental Science*, December 27–29, 2019, Guangzhou, China, 252(4): 042042

Garson G D (1991). Interpreting neural-network connection weights.

AI Expert, 6(4): 46–51

Gedeon T D (1997). Data mining of inputs: analysing magnitude and functional measures. *International Journal of Neural Systems*, 8(2): 209–218

Geissler S, Wintgens T, Melin T, Vossenkaul K, Kullmann C (2005). Modelling approaches for filtration processes with novel submerged capillary modules in membrane bioreactors for wastewater treatment. *Desalination*, 178(1–3): 125–134

Gideon S (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2): 461–464

Goh A T C (1995). Backpropagation neural networks for modeling complex-systems. *Artificial Intelligence in Engineering*, 9(3): 143–151

Greff K, Srivastava R K, Koutník J, Steunebrink B R, Schmidhuber J (2017). LSTM: a search space odyssey. *IEEE Transactions on Neural Networks and Learning Systems*, 28(10): 2222–2232

Grömping U (2015). Variable importance in regression models. *Wiley Interdisciplinary Reviews: Computational Statistics*, 7(2): 137–152

Hamed H, Ehteshami M, Mirbagheri S A, Zendejboudi S (2019). New deterministic tools to systematically investigate fouling occurrence in membrane bioreactors. *Chemical Engineering Research & Design*, 144: 334–353

Hannan E J, Quinn B G (1979). The determination of the order of an autoregression. *Journal of the Royal Statistical Society. Series B, Statistical Methodology*, 41(2): 190–195

Hazrati H, Moghaddam A H, Rostamizadeh M (2017). The influence of hydraulic retention time on cake layer specifications in the membrane bioreactor: experimental and artificial neural network modeling. *Journal of Environmental Chemical Engineering*, 5(3): 3005–3013

Hosseinizadeh A, Zhou J L, Altaee A, Baziar M, Li X (2020). Modeling water flux in osmotic membrane bioreactor by adaptive network-based fuzzy inference system and artificial neural network. *Bioresource Technology*, 310: 123391

Huang G, Liu Z, Maaten L V D, Weinberger K Q (2017). Densely connected convolutional networks. Honolulu, HI, USA: IEEE, 2261–2269

Huang Z, Ong S L, Ng H Y (2011). Submerged anaerobic membrane bioreactor for low-strength wastewater treatment: effect of HRT and SRT on treatment performance and membrane fouling. *Water Research*, 45(2): 705–713

Irfan M, Waqas S, Arshad U, Khan J A, Legutko S, Kruszelnicka I, Ginter-Kramarczyk D, Rahman S, Skrzypczak A (2022). Response surface methodology and artificial neural network modelling of membrane rotating biological contactors for wastewater treatment. *Materials*, 15(5): 1932

Jiang M, He Y, Song C, Pan Y, Qiu T, Tian S (2021). Disaggregating climatic and anthropogenic influences on vegetation changes in Beijing-Tianjin-Hebei region of China. *Science of the Total Environment*, 786: 147574

Juntawang C, Rongsayamanont C, Khan E (2017). Entrapped cells-based-anaerobic membrane bioreactor treating domestic

Advanced Computer Science and Applications, 14(8): 348–354

Cai Y H, Ben T, Zaidi A A, Shi Y, Zhang K, Lin A Q, Liu C (2019a). Ảnh hưởng của pH đến việc loại bỏ chất ô nhiễm trong quá trình xử lý nước thải tàu thủy bằng hệ thống MBR bùn vi lượng hiếu khí-kỵ khí cải tiến. *Water, Air, and Soil Pollution*, 230(7): 163

Cai Y H, Zaidi A A, Shi Y, Zhang K, Li X, Xiao S H, Lin A Q (2019b). Ảnh hưởng của độ mặn đến quá trình xử lý sinh học nước thải sinh hoạt từ tàu thủy bằng thiết bị phản ứng màng tuần hoàn đa cấp kiểu nâng khí. *Environmental Science and Pollution Research International*, 26(36): 37026–37036

Castillo O, Aguilar L, Cazarez N, Cardenas S (2008). Thiết kế có hệ thống bộ điều khiển logic mờ loại-2 ổn định. *Applied Soft Computing*, 8(3): 1274–1279

Chang H M, Xu Y, Chen S S, He Z (2022). Nâng cao hiểu biết về thiết bị phản ứng sinh học màng thấm thấu thông qua mô hình hóa bằng học máy dòng thông lượng nước và độ mặn. *Science of the Total Environment*, 838: 156009

Chen C, Sun M Z, Chang J, Liu Z W, Zhu X Z, Xiao K, Song G Q, Wang H, Liu G L, Huang X (2022). Làm sáng tỏ cơ chế đóng bám phụ thuộc nhiệt độ trong thiết bị phản ứng sinh học màng kỵ khí quy mô thí nghiệm thông qua mô hình thống kê. *Journal of Membrane Science*, 644: 120145

Chen J C, Ng W J, Luo R, Mu S, Zhang Z, Andersen M, Jorgensen P E (2012). Membrane bioreactor process modeling and optimization: ULU Pandan water reclamation plant. *Journal of Environmental Engineering*, 138(12): 1218–1226

Chen T, Guestrin C (2016). XGBoost: Hệ thống tăng cường cây có khả năng mở rộng. San Francisco: Association for Computing Machinery, 785–794

Chen W, Ran H, Cao X, Wang J, Teng D, Chen J, Zheng X (2020). Ước tính PM_{2.5} bằng dữ liệu AOD độ phân giải cao 1 km và mô hình học máy được cải tiến trên toàn Thâm Quyển, Trung Quốc. *Science of the Total Environment*, 746: 141093

Choi J G, Bae T H, Kim J H, Tak T M, Randall A A (2002). Đặc tính khởi phát đóng bám màng trong hệ thống thiết bị phản ứng sinh học màng dòng chảy ngang. *Journal of Membrane Science*, 203(1–2): 103–113

Cortez P, Embrechts M J (2013). Sử dụng phân tích độ nhạy và kỹ thuật trực quan hóa để mở hộp đen của các mô hình khai phá dữ liệu. *Information Sciences*, 225: 1–17

de Campos Souza P V (2020). Mạng nơ-ron mờ và mạng nơ-ron mờ lai: đánh giá các kỹ thuật chính và ứng dụng được sử dụng trong tài liệu nghiên cứu. *Applied Soft Computing*, 92: 106275

Dorigo M, Birattari M, Stützle T (2006). Tối ưu hóa đàn kiến. *IEEE Computational Intelligence Magazine*, 1(4): 28–39

Espel D, Courty S, Auda Y, Sheeren D, Elger A (2020). Đánh giá thực vật thủy sinh ngập nước ở sông: phương pháp lập bản đồ tự động sử dụng ảnh vệ tinh Pleiades. *Water Research*, 186: 116353

Gao Q, Li Z, Pan J (2019). Mạng nơ-ron tích chập dùng cho kiểm tra an ninh sân bay đối với hàng hóa nguy hiểm. *IOP Conference Series. Earth and Environmental Science*, December 27–29, 2019, Guangzhou, China, 252(4): 042042

Garson G D (1991). Diễn giải trọng số kết nối trong mạng nơ-ron.

AI Expert, 6(4): 46–51

Gedeon T D 1997. Khai phá dữ liệu đầu vào: phân tích độ lớn và các thước đo chức năng. *International Journal of Neural Systems*, 8(2): 209–218

Geissler S, Wintgens T, Melin T, Vossenkaul K, Kullmann C 2005. Các phương pháp mô hình hóa cho quá trình lọc với các mô-đun mao dẫn chìm mới trong thiết bị phản ứng sinh học màng xử lý nước thải. *Desalination*, 178(13): 125–134

Gideon S 1978. Ước tính số chiều của một mô hình. *Annals of Statistics*, 6(2): 461–464

Goh A T C 1995. Mạng nơ-ron lan truyền ngược để mô hình hóa các hệ thống phức tạp. *Artificial Intelligence in Engineering*, 9(3): 143–151

Greff K, Srivastava R K, Koutník J, Steunebrink B R, Schmidhuber J (2017). LSTM: hành trình khám phá không gian tìm kiếm. *IEEE Transactions on Neural Networks and Learning Systems*, 28(10): 2222–2232

Grömping U 2015. Tầm quan trọng của biến trong các mô hình hồi quy. *Wiley Interdisciplinary Reviews: Computational Statistics*, 7(2): 137–152

Hamed H, Ehteshami M, Mirbagheri S A, Zendejboudi S 2019. Các công cụ tối định mới để khảo sát một cách hệ thống sự xuất hiện của hiện tượng bám bẩn trong thiết bị phản ứng sinh học màng. *Chemical Engineering Research & Design*, 144: 334–353

Hannan E J, Quinn B G 1979. Xác định bậc của mô hình tự hồi quy. *Journal of the Royal Statistical Society. Series B, Statistical Methodology*, 41(2): 190–195

Hazrati H, Moghaddam A H, Rostamizadeh M 2017. Ảnh hưởng của thời gian lưu thủy lực đến các đặc tính của lớp bánh trong thiết bị phản ứng sinh học màng: mô hình hóa thực nghiệm và bằng mạng nơ-ron nhân tạo. *Journal of Environmental Chemical Engineering*, 5(3): 3005–3013

Hosseinizadeh A, Zhou J L, Altaee A, Baziar M, Li X 2020. Mô hình hóa thông lượng nước trong thiết bị phản ứng sinh học màng thấm thấu bằng hệ suy luận mờ dựa trên mạng thích nghi và mạng nơ-ron nhân tạo. *Bioresource Technology*, 310: 123391

Huang G, Liu Z, Maaten L V D, Weinberger K Q 2017. Densely connected convolutional networks. Honolulu, HI, USA: IEEE, 2261–2269

Huang Z, Ong S L, Ng H Y 2011. Submerged anaerobic membrane bioreactor for low-strength wastewater treatment: effect of HRT and SRT on treatment performance and membrane fouling. *Water Research*, 45(2): 705–713

Irfan M, Waqas S, Arshad U, Khan J A, Legutko S, Kruszelnicka I, Ginter-Kramarczyk D, Rahman S, Skrzypczak A 2022. Phương pháp bề mặt đáp ứng và mô hình hóa bằng mạng nơ-ron nhân tạo đối với thiết bị tiếp xúc sinh học quay dạng màng xử lý nước thải. *Materials*, 15(5): 1932

Jiang M, He Y, Song C, Pan Y, Qiu T, Tian S 2021. Phân tách ảnh hưởng của khí hậu và hoạt động của con người đối với những thay đổi thảm thực vật tại vùng Bắc Kinh–Thiên Tân–Hà Bắc, Trung Quốc. *Science of the Total Environment*, 786: 147574

Juntawang C, Rongsayamanont C, Khan E 2017. Thiết bị phản ứng sinh học màng kỵ khí sử dụng tế bào được giữ cố định để xử lý nước thải sinh hoạt

wastewater: performances, fouling, and bacterial community structure. Chemosphere, 187: 147–155

Karaboga D, Basturk B (2007). A powerful and efficient algorithm for numerical function optimization: artificial bee colony (ABC) algorithm. Journal of Global Optimization, 39(3): 459–471

Katoch S, Chauhan S S, Kumar V (2021). A review on genetic algorithm: past, present, and future. Multimedia Tools and Applications, 80(5): 8091–8126

Kawakatsu T, Nakao S, Kimura S (1993). Effects of size and compressibility of suspended particles and surface pore-size of membrane on flux in cross-flow filtration. Journal of Membrane Science, 81(1–2): 173–190

Kim J H, Shin J K, Lee H, Lee D H, Kang J H, Cho K H, Lee Y G, Chon K, Baek S S, Park Y (2021a). Improving the performance of machine learning models for early warning of harmful algal blooms using an adaptive synthetic sampling method. Water Research, 207: 117821

Kim S Y, Ćurko J, Gajdoš Kljusurić J, Matošić M, Crnek V, López-Vázquez C M, Garcia H A, Brdjanović D, Valinger D (2021b). Use of near-infrared spectroscopy on predicting wastewater constituents to facilitate the operation of a membrane bioreactor. Chemosphere, 272: 129899

Kiranyaz S, Avci O, Abdeljaber O, Ince T, Gabbouj M, Inman D J (2021). 1D convolutional neural networks and applications: a survey. Mechanical Systems and Signal Processing, 151: 107398

Kruskal W (1987). Relative importance by averaging over orderings. American Statistician, 41(1): 6–10

Krzeminski P, Leverette L, Malamis S, Katsou E (2017). Membrane bioreactors: a review on recent developments in energy reduction, fouling control, novel configurations, LCA and market prospects. Journal of Membrane Science, 527: 207–227

Kulkarni P, Chellam S (2010). Disinfection by-product formation following chlorination of drinking water: artificial neural network models and changes in speciation with treatment. Science of the Total Environment, 408(19): 4202–4210

Kurita T, Kimura K, Watanabe Y (2014). The influence of granular materials on the operation and membrane fouling characteristics of submerged MBRs. Journal of Membrane Science, 469: 292–299

Kurita T, Kimura K, Watanabe Y (2015). Energy saving in the operation of submerged MBRs by the insertion of baffles and the introduction of granular materials. Separation and Purification Technology, 141: 207–213

Li C Q, Yang Z X, Yan H Y, Wang T (2014). The application and research of the GA-BP neural network algorithm in the MBR membrane fouling. Abstract and Applied Analysis, 2014(1): 673156

Li G Y, Ji J Y, Ni J L, Wang S R, Guo Y T, Hu Y S, Liu S W, Huang S F, Li Y Y (2022). Application of deep learning for predicting the treatment performance of real municipal wastewater based on one-year operation of two anaerobic membrane bioreactors. Science of the Total Environment, 813: 151920

Li H M, Wang J H, Wang Q G, Tian C H, Qian X, Leng X Z (2017). Magnetic properties as a proxy for predicting fine-particle-bound heavy metals in a support vector machine approach. Environmental Science & Technology, 51(12): 6927–6935

Li S, Shi Z, Chen S C, Ji W J, Zhou L Q, Yu W, Webster R (2015). *In situ* measurements of organic carbon in soil profiles using vis-NIR spectroscopy on the Qinghai-Tibet Plateau. Environmental Science & Technology, 49(8): 4980–4987

Li W W, Li C Q, Wang T (2020). Application of machine learning algorithms in MBR simulation under big data platform. Water Practice & Technology, 15(4): 1238–1247

Li X A, Wu J, Tai X, Xu J, Wang Y G (2024a). Solving a class of multi-scale elliptic PDEs by Fourier-based mixed physics informed neural networks. Journal of Computational Physics, 508: 113012

Li Y, Fan L, Liu Y, Huang Z, Chen Y, Wang N, Zhang Z (2024b). Fully sparse fusion for 3D object detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 46(11): 7217–7231

Lin H J, Zhang M J, Wang F Y, Meng F G, Liao B Q, Hong H C, Chen J R, Gao W J (2014). A critical review of extracellular polymeric substances (EPSs) in membrane bioreactors: characteristics, roles in membrane fouling and control strategies. Journal of Membrane Science, 460: 110–125

Liu C Q, Xiao J W, Li H Y, Chen Q, Sun D Z, Cheng X, Li P S, Dang Y, Smith J A, Holmes D E (2021). High efficiency *in-situ* biogas upgrading in a bioelectrochemical system with low energy input. Water Research, 197: 117055

Liu J, Kang X, Luan X, Gao L, Tian H, Liu X (2020a). Performance and membrane fouling behaviors analysis with SVR-LibSVM model in a submerged anaerobic membrane bioreactor treating low-strength domestic sewage. Environmental Technology & Innovation, 19: 100844

Liu Z, Wang Y, Vaidya S, Ruehle F, Halverson J, Soljacic M, Hou T Y, Tegmark M J A (2024). KAN: Kolmogorov-Arnold Networks. ArXiv,

Liu Z W, Yu J L, Xiao K, Chen C, Ma H, Liang P, Zhang X Y, Huang X (2020b). Quantitative relationships for the impact of gas sparging conditions on membrane fouling in anaerobic membrane bioreactor. Journal of Cleaner Production, 276: 123139

Lundberg S M, Erion G, Chen H, Degraeve A, Prutkin J M, Nair B, Katz R, Himmelfarb J, Bansal N, Lee S I (2020). From local explanations to global understanding with explainable AI for trees. Nature Machine Intelligence, 2(1): 56–67

Ma K, Tang C, Zhang W, Cui B, Ji K, Chen Z, Abraham A (2023). DC-CNN: Dual-channel Convolutional Neural Networks with attention-pooling for fake news detection. Applied Intelligence, 53(7): 8354–8369

Madni H A, Umer M, Ishaq A, Abuzinadah N, Saidani O, Alsubai S, Hamdi M, Ashraf I (2023). Water-quality prediction based on H2O autoML and explainable AI techniques, Water, 15(3): 475

Mallet A, Charnier C, Latrille E, Bendoula R, Roger J M, Steyer J P (2022). Fast and robust NIRS-based characterization of raw

nước thải: hiệu suất, hiện tượng bám bẩn, và cấu trúc quần xã vi khuẩn. Chemosphere, 187: 147–155

Karaboga D, Basturk B (2007). Một thuật toán mạnh mẽ và hiệu quả để tối ưu hóa hàm số : thuật toán đàn ong nhân tạo ABC (.)Journal of Global Optimization, 39(3): 459–471

Katoch S, Chauhan S S, Kumar V 2021 (.)Tổng quan về thuật toán di truyền: quá khứ, hiện tại và tương lai. Multimedia Tools and Applications, 80(5): 8091–8126

Kawakatsu T, Nakao S, Kimura S 1993 . (Ảnh hưởng)của kích thước và khả năng nén của các hạt lơ lửng và kích thước lỗ bề mặt màng đến thông lượng trong quá trình lọc dòng chảy ngang. Journal of Membrane Science, 81(1 2): 173–190

Kim J H,–Shin JK, Lee H, Lee D H, Kang J H, Cho K H, Lee Y G, Chon K, Baek S S, Park Y 2021a . Cải thiện hiệu suất của các mô hình (học máy)để cảnh báo sớm hiện tượng tảo nở hoa có hại bằng cách sử dụng phương pháp lấy mẫu tổng hợp thích ứng. Water Research, 207: 117821

Kim S Y, Ćurko J, Gajdoš Kljusurić J, Matošić M, Crnek V, López-Vázquez C M, Garcia H A, Brdjanović D, Valinger D 2021b . Ứng dụng phổ cập hồng ngoại để dự đoán các thành phần nước thải, nhằm hỗ trợ vận hành bể phản ứng sinh học màng. Chemosphere, 272: 129899

Kiranyaz (S,)Avci O, Abdeljaber O, Ince T, Gabbouj M, Inman D J (2021). Mạng nơ-ron tích chập 1D và các ứng dụng: tổng quan. Mechanical Systems and Signal Processing, 151: 107398

Kruskal W 1987 . Tầm quan trọng tương đối bằng cách lấy trung bình trên các thứ tự sắp xếp. American Statistician, 41(1): 6–10

Krzeminski P, Leverette L, Malamis S, Katsou E 2017 . Bể phản ứng sinh học màng: tổng quan về những phát triển gần đây trong (giảm tiêu thụ năng lượng,)kiểm soát bám bẩn, các cấu hình mới, đánh giá vòng đời (LCA) và triển vọng thị trường. Journal of Membrane Science, 527: 207–227

Kulkarni P, Chellam S 2010 . Sự hình thành sản phẩm phụ khử trùng sau khi (k khử trùng bằng clo)nước uống: mô hình mạng nơ-ron nhân tạo và những thay đổi về dạng tồn tại hóa học trong quá trình xử lý. Science of the Total Environment, 408(19): 4202–4210

Kurita T, Kimura K, Watanabe Y 2014 . Ảnh hưởng của vật liệu dạng hạt đến hoạt động và (đặc tính bám bẩn màng)của MBR chìm. Journal of Membrane Science, 469: 292–299

Kurita T, Kimura K, Watanabe Y 2015 . Tiết kiệm năng lượng trong quá trình vận hành MBR chìm bằng cách lắp đặt các tấm chắn và đưa vào vật liệu dạng hạt . Separation and Purification Technology, 141: 207–213

(L i)C Q, Yang Z X, Yan H Y, Wang T 2014 . Ứng dụng và nghiên cứu thuật toán mạng nơ-ron GA-BP trong hiện tượng bám bẩn màng MBR. Abstract and Applied Analysis, 2014(1) : 673156

Li G Y, (Ji)J Y, Ni J L, Wang S R, Guo Y T, Hu Y S, Liu S W, Huang S F, Li Y Y 2022. Ứng dụng học sâu để dự đoán hiệu suất xử lý nước thải đô thị thực tế dựa trên hoạt động vận hành một năm của hai bể phản ứng sinh học màng kỵ khí. (Science)of the Total Environment, 813: 151920

Li H M, Wang J H, Wang Q G, Tian C H, Qian X, Leng X Z (2017). Tính chất từ như một chỉ thị để dự đoán các kim loại nặng gắn với hạt mịn bằng cáchtiếp cận máy vectơ hỗ trợ. Environmental Science & Technology, 51(12): 6927–6935

Li S, Shi Z, Chen S (C,)JiIn situ W J, Zhou L Q, Yu W, Webster R 2015 . Đo lượng carbon hữu cơ trong các tầng đấtbằng phổ kế vi s-NIR trên cao nguyên Thanh-Tạng. (Environmental Science)& Technology, 49(8): 4980–4987

Li W W, Li C Q, Wang T 2020 . Ứng dụng các thuậttoán học máy trong mô phỏng MBR trên nền tảng dữ liệu (lớn.) Water Practice & Technology, 15(4): 1238–1247

Li X A, Wu J, Tai X, Xu J, Wang Y G 2024a . Giải một lớp phương trình đạo hàm riêng elliptic đa tỉ lệ bằng mạng (nơ-ron)hỗn hợp dựa trên Fourier và tích hợp tri thức vật lý. Journal of Computational Physics, 508:113012

Li Y, Fan L, Liu Y, Huang Z, Chen Y, Wang N, Zhang Z 2024b . Hợp nhất thừa hoàn toàn cho phát (hiện)đối tượng 3D. IEEE E Transactions on Pattern Analysis (and) Machine Intelligence, 46(11): 7217–7231

Lin H J, Zhang M J, Wang F Y, Meng F G, Liao B Q, Hong H C, Chen J R, Gao W J 2014 . Tổng quan phê bình về các chất polyme ngoại bào (EPS) trong bể (phản)ứng sinh học *in-situ*màng: đặc điểm, vai trò trong hiện tượng tắc màng và các chiếnlược kiểm soát. Journal of Membrane Science, 460: 110–125

Liu C Q, Xiao J W, Li H Y, Chen Q, Sun D Z, Cheng X, Li P S, Chen Q, Sun D Z, Cheng X, Li P S, Dang Y, Smith J A, Holmes D E 2021. Nâng cấp khí sinh học hiệu suất cao trong hệ thống điện hóa sinh học với mức tiêu (thụ)năng lượng thấp. WaterResearch, 197: 117055

Liu J, Kang X, Luan X, Gao L, Tian H, Liu X 2020a . Phân tích (hiệu)suất và diễn biến tắc màng bằng mô hình SVR-LibSVM trong bể phản ứng sinh học màng kỵ khí chìmxử lý nước thải sinh hoạt có nồng độ thấp. Environmental Technology & Innovation, 19: 100844

Liu Z , Wang Y, Vaidya S, Ruehle (F,)Halverson J, Soljacic M, Hou T Y, Tegmark M J A 2024 . KAN: Mạng Kolmogorov-Arnold. ArXiv, Liu Z W, Yu J L, Xiao K, Chen C, Ma H, Liang P, Zhang (X)Y, Huang X 2020b . Các mối quan hệ định lượng về tác động củadiều kiện sục khí đến hiện tượng tắc màng trong bể phản ứng sinh học màng (kỵ)khí. Journal of Cleaner Production, 276: 123139

Lundberg S M, Erion G, Chen H, Degraeve A, Prutkin J M, Nair B, Katz R, Himmelfarb J, Bansal N, Lee S I 2020 . Từ giải thích cục bộ đến hiểu biết

<https://journal.hep.com.cn/fese>

toàn cục bằng AI có thể giải thích cho các mô hình cây. Nature Machine Intelligence, 2(1): 56–67

Ma K, Tang C, Zhang W, Cui B, Ji K, Chen Z, Abraham A 2023. DC-CNN: Mạng nơ-ron tích chập hai kênh với cơ chế ghép có chú ý để phát hiện giả. Applied Intelligence, 53(7): 8354–8369

Madni H A, Umer M, Ishaq A, Abuzinadah N, Saidani O, Alsubai S, dani O, Alsubai S, Hamdi M, Ashraf I 2023. Dự đoán chất lượng nước dựa trên các kỹ thuật H2O autoML và AI có thể giải thích, Water, 15(3): 475

Mallet A, Charnier C, Latrille E, Bendoula R, Roger J M, Steyer J P (2022). Đặc trưng nhanh và vững chắc nguyên liệu thô dựa trên NIRS

organic waste: using non-linear methods to handle water effects. *Water Research*, 227: 119308

McMillan L, Fayaz J, Varga L (2024). Domain-informed variational neural networks and support vector machines based leakage detection framework to augment self-healing in water distribution networks. *Water Research*, 249: 120983

Meireles M, Aimar P, Sanchez V (1991). Effects of protein fouling on the apparent pore-size distribution of sieving membranes. *Journal of Membrane Science*, 56(1): 13–28

Meng F G, Zhang S Q, Oh Y, Zhou Z B, Shin H S, Chae S R (2017). Fouling in membrane bioreactors: an updated review. *Water Research*, 114: 151–180

Mirbagheri S A, Bagheri M, Bagheri Z, Kamarkhani A M (2015a). Evaluation and prediction of membrane fouling in a submerged membrane bioreactor with simultaneous upward and downward aeration using artificial neural network-genetic algorithm. *Process Safety and Environmental Protection*, 96: 111–124

Mirbagheri S A, Bagheri M, Boudaghpour S, Ehteshami M, Bagheri Z (2015b). Performance evaluation and modeling of a submerged membrane bioreactor treating combined municipal and industrial wastewater using radial basis function artificial neural networks. *Journal of Environmental Health Science & Engineering*, 13(1): 17

Mirjalili S, Mirjalili S M, Lewis A (2014). Grey Wolf Optimizer. *Advances in Engineering Software*, 69: 46–61

Mohammadi E, Stokholm-Bjerregaard M, Hansen A A, Nielsen P H, Ortiz-Arroyo D, Durdevic P (2024). Deep learning based simulators for the phosphorus removal process control in wastewater treatment via deep reinforcement learning algorithms. *Engineering Applications of Artificial Intelligence*, 133: 107992

Molnar C (2019). *Interpretable Machine Learning: a Guide for Making Black Box Models Explainable*. München: Digital Reserch Academy

Nguyen P C H, Nguyen Y T, Choi J B, Seshadri P K, Udaykumar H S, Baek S S (2023). PARC: physics-aware recurrent convolutional neural networks to assimilate meso scale reactive mechanics of energetic materials. *Science Advances*, 9(17): eadd6868

Nguyen X C, Ly Q V, Nguyen T T H, Ngo H T T, Hu Y X, Zhang Z H (2022). Potential application of machine learning for exploring adsorption mechanisms of pharmaceuticals onto biochars. *Chemosphere*, 287: 132203

Niu C, Zhang Z, Cai T, Pan Y, Lu X, Zhen G (2024). Sludge bound-EPS solubilization enhance CH₄ bioconversion and membrane fouling mitigation in electrochemical anaerobic membrane bioreactor: insights from continuous operation and interpretable machine learning algorithms. *Water Research*, 264: 122243

Niu C X, Li X S, Dai R B, Wang Z W (2022). Artificial intelligence-incorporated membrane fouling prediction for membrane-based processes in the past 20 years: a critical review. *Water Research*, 216: 118299

Olden J D, Joy M K, Death R G (2004). An accurate comparison of methods for quantifying variable importance in artificial neural

networks using simulated data. *Ecological Modelling*, 178(3–4): 389–397

Oliker N, Ostfeld A (2014). A coupled classification: evolutionary optimization model for contamination event detection in water distribution systems. *Water Research*, 51: 234–245

Panda S R, Bhandaru N, Mukherjee R, De S (2015). Ultrafiltration of oily waste water: contribution of surface roughness in membrane properties and fouling characteristics of polyacrylonitrile membranes. *Canadian Journal of Chemical Engineering*, 93(11): 2031–2042

Peter B, Yoav F, Wee Sun L, Robert E S (1998). Boosting the margin: a new explanation for the effectiveness of voting methods. *Annals of Statistics*, 26(5): 1651–1686

Qian Y G, Zhou W Q, Yan J L, Li W F, Han L J (2015). Comparing machine learning classifiers for object-based land cover classification using very high resolution imagery. *Remote Sensing (Basel)*, 7(1): 153–168

Qu J H, Dai X H, Hu H Y, Huang X, Chen Z, Li T, Cao Y S, Daigge G T (2022). Emerging trends and prospects for municipal wastewater management in China. *ACS ES&T Engineering*, 2(3): 323–336

Quinlan J R (1993). *C4.5: Programs for Machine Learning*. San Francisco: Morgan Kaufmann Publishers Inc.

Raychaudhuri S (2008). Introduction to Monte Carlo simulation, 2008 Winter Simulation Conference, 91–100, December 7–10, 2008, Miami, FL, USA,

Rouet-Leduc B, Hulbert C (2024). Automatic detection of methane emissions in multispectral satellite imagery using a vision transformer. *Nature Communications*, 15(1): 3801

Sadeghi I, Aroujalian A, Raisi A, Dabir B, Fathizadeh M (2013). Surface modification of polyethersulfone ultrafiltration membranes by corona air plasma for separation of oil/water emulsions. *Journal of Membrane Science*, 430: 24–36

Salehin I, Islam M S, Saha P, Noman S M, Tuni A, Hasan M M, Baten M A (2024). AutoML: a systematic review on automated machine learning with neural architecture search. *Journal of Information and Intelligence*, 2(1): 52–81

Samek W (2020). Learning with explainable trees. *Nature Machine Intelligence*, 2(1): 16–17

Schmitt F, Banu R, Yeom I T, Do K U (2018). Development of artificial neural networks to predict membrane fouling in an anoxic-aerobic membrane bioreactor treating domestic wastewater. *Biochemical Engineering Journal*, 133: 47–58

Senthil Kumar D, Arumugam S S, Lordwin Cecil Prabhaker M, Daisy Merina R (2024). Eamlm: Enhanced automated machine learning model for IoT based water quality analysis with real-time dataset. *Automatic Control and Computer Sciences*, 58(1): 66–77

Shi Y K, Wang Z W, Du X J, Ling G B, Jia W C, Lu Y R (2022). Research on the membrane fouling diagnosis of MBR membrane module based on ECA-CNN. *Journal of Environmental Chemical Engineering*, 10(3): 107649

Shimizu Y, Rokudai M, Tohya S, Kayawake E, Yazawa T, Tanaka

chất thải hữu cơ : sử dụng các phương pháp phi tuyến để xử lý tác động của nước . *Water Research*, 227: 119308

McMillan L, Fayaz J, Varga L (2024). Mạng nơ-ron biế n phân và máy véc-tơ hỗ trợ dựa trên tri thức miền , tạo th ành khuôn khổ phát hiện rò rỉ nhằm tăng cường khả năng tự phục hồi trong mạng lưới phân phối nước. *Water Rese arch*, 249: 120983

Meireles M, Aimar P, Sanchez V (199 1). Ảnh hưởng của hiện tượng bám bẩn protein lên phân bố kích thước lỗ biểu kiến của màng sàng lọc. *Journal of Membrane Science*, 56(1): 13–28

Meng F G, Zhang S Q, Oh Y, Zhou Z B, Shin H S, Chae S R (2017). Hiện tượn g bám bẩn trong các bể phản ứng sinh học màng : một b ài tổng quan cập nhật. *Water Research*, 114: 151–180

Mir bagheri S A, Bagheri M, Bagheri Z, Kamarkhani A M (2 015a). Đánh giá và dự đoán hiện tượng bám bẩn màng tr ong bể phản ứng sinh học màng chìm với sục khí đồng th ời theo chiều lên và chiều xuống , sử dụng thuật toán di tr uyền kết hợp mạng nơ-ron nhân tạo. *Process Safety and Environmental Protection*, 96: 111–124

Mirbagheri S A, Bagheri M, Boudaghpour S, Ehteshami M, Bagheri Z (2 015b). Đánh giá hiệu suất và mô hình hóa bể phản ứng si nh học màng chìm xử lý nước thải đô thị và công nghiệp kết hợp , sử dụng mạng nơ-ron nhân tạo hàm cơ sở xuyên tâm. *Journal of Environmental Health Science & Enginee ring*, 13(1): 17

Mirjalili S, Mirjalili S M, Lewis A (2014). Thuật toán Sói Xám . *Advances in Engineering Softwar e*, 69: 46–61

Mohammadi E, Stokholm-Bjerregaard M, H ansen A A, Nielsen P H, Ortiz-Arroyo D, Durdevic P (2024). Các bộ mô phỏng dựa trên học sâu cho việc điều k hiển quy trình loại bỏ phốt pho trong xử lý nước thải bằng các thuật toán học tăng cường sâu . *Engineering Applicati ons of Artificial Intelligence*, 133: 107992

Molnar C (20 19). Học máy có thể diễn giải: hướng dẫn giúp các mô hì nh hộp đen trở nên dễ giải thích. München: Digital Reserc h Academy

Nguyen P C H, Nguyen Y T, Choi J B, Seshadri P K, Udaykumar H S, Baek S S (2023). PARC: mặ n g nơ-ron tích chậ p hồi quy có nhận thức vật lý để đồng hó a cơ học phản ứng ở quy mô trung mô của vật liệu giàu n ăng lượng. *Science Advances*, 9(17): eadd6868

Nguyen X C, Ly Q V, Nguyen T T H, Ngo H T T, Hu Y X, Zhang Z H (2022). Tiềm năng ứng dụng của học máy để khám phá các cơ chế hấp phụ của dược phẩm lên than sinh học. *Chemosp here*, 287: 132203

Niu C, Zhang Z, Cai T, Pan Y, Lu X, Zhen G (2024). Hòa tan EPS liên kết với bùn giúp tăng cường qu á trình chuyển hóa sinh học CH₄ và giảm bám bẩn màng t rong bể phản ứng sinh học màng kỵ khí điện hóa: những hiểu biết từ vận hành liên tục và các thuật toán học máy có thể diễn giải . *Water Research*, 264: 122243

Niu C X, Li X S, Dai R B, Wang Z W (2022). Dự đoán hiện tượng bám b ả n màng bằng trí tuệ nhân tạo cho các quy trình sử dụng màng trong 20 năm qua: bài tổng quan phản biện . *Wate r Research*, 216: 118299

Olden J D, Joy M K, Death R G (200 4). So sánh chính xác các phương pháp để định lượng m ức độ quan trọng của biến trong mạng nơ-ron nhân tạo

mạng sử dụng dữ liệu mô phỏng. Mô hình hóa sinh thái , 178(3–4): 389–397

Oliker N, Ostfeld A (2014). Mô hình p hân loại kết hợp: mô hình tối ưu hóa tiến hóa để phát hiệ n sự cố ô nhiễm trong hệ thống phân phối nước

Water 5 1: 234–245

Panda S R, Bhandaru N, Mukherjee R, De S (201 5). Siêu lọc nước thải chứa dầu : đóng góp của độ nhám b ề mặt đối với các đặc tính màng và đặc tính bám bẩn của màng polyacrylonitrile. *Tạp chí Kỹ thuật Hóa học Canada*, 9 3(11): 2031–2042

Peter B, Yoav F, Wee Sun L, Robert E S (1998). Tăng cường biên: một giải thích mới về tính hi ệu quả của các phương pháp bỏ phiếu. *Biên niên sử Thốn g kê*, 26(5): 1651–1686

Qian Y G, Zhou W Q, Yan J L, Li W F, Han L J (2015). So sánh các bộ phân loại học máy để phân loại lớp phủ đất dựa trên đối tượng sử dụng ảnh có độ ph ân giải rất cao. *Viễn thám (Basel)*, 7(1): 153–168

Qu J H, Hu H Y, Huang X, Chen Z, Li T, Cao Y S, Daigge r G T (2022). Xu hướng biên nổi và triển vọng trong qu ản lý nước thải đô thị tại Trung Quốc. *ACS ES&T Engineerin g*, 2(3): 323–336

Quinlan J R (1993). *C4.5: Các chương trìn h học máy*. San Francisco: Morgan Kaufmann Publishers I nc.

Raychaudhuri S (2008). Giới thiệu về mô phỏng Mont e Carlo, 2008 Hội nghị Mô phỏng Mùa đông, 91–100, ngà y 7–10 tháng 12 năm 2008, Miami, FL, Hoa Kỳ,

Rouet-Leduc B, Hulbert C (2024). Tự động phát hiện phát thải methane trong ảnh vệ tinh đa phổ sử dụng một transformer thị giá c. *Nature Communications*, 15(1):3801

Sadeghi I, Aroujali an A, Raisi A, Dabir B, Fathizadeh (M)2013 . *Biến đổi bề mặt màng siêu lọc polyethersulfone bằng plasma không khí corona để tách nhũ tương dầu/nước*. *Tạp chí Khoa họ c Màng*, 430: 24–36

Salehin I, Islam M S, Saha P, Noman S M, Tuni A, Hasan M M, Baten M A (2024). AutoML: mộ t tổng quan hệ thống về học máy tự động với tìm kiếm kiế n trúc mạng nơ-ron. *Tạp chí Thông tin và Trí tuệ*, 2(1): 52–8 1

Samek W (2020). Học với cây có thể giải thích. *Nature Ma chine Intelligence*, 2(1): 16–17

Schmitt F, Banu R, Yeom I T, Do K U (2018). Phát triển mạng nơ-ron nhân tạo để d ự đoán sự bám bẩn màng trong một bể phản ứng sinh h ọc màng thiếu khí-hiếu khí xử lý nước thải sinh hoạt. *Tạp c hí Kỹ thuật Hóa sinh*, 133: 47–58

Senthil Kumar D, Arumu gam S S, Lordwin Cecil Prabhaker M, Daisy Merina R (2 024). Eamlm: mô hình học máy tự động nâng cao để phâ n tích chất lượng nước dựa trên IoT với bộ dữ liệu thời gia n thực. *Điều khiển Tự động và Khoa học Máy tính*, 58(1): 6 6–77

Shi Y K, Wang Z W, Du X J, Ling G B, Jia W C, Lu Y R (20 22). Nghiên cứu về chẩn đoán bám bẩn màng của mô-đun màng MBR dựa trên ECA-CNN. *Tạp chí Kỹ thuật Hóa học M ôi trường*, 10(3): 107649

Shimizu Y, Rokudai M, Tohya S, Kay awake E, Yazawa T, Tanaka

H, Eguchi K (1990). Effect of membrane resistance on filtration characteristics for methanogenic waste. *Kagaku Kogaku Ronbunshu*, 16(1): 145–151

Silver D, Huang A, Maddison C J, Guez A, Sifre L, Van Den Driessche G, Schrittwieser J, Antonoglou I, Panneershelvam V, Lanctot M, et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587): 484–489

Suman B, Kumar P (2006). A survey of simulated annealing as a tool for single and multiobjective optimization. *Journal of the Operational Research Society*, 57(10): 1143–1160

Sun X, Wang P, Lu W, Zhu Z, Lu X, He Q, Li J, Rong X, Yang Z, Chang H, et al. (2023). RingMo: a remote sensing foundation model with masked image modeling. *IEEE Transactions on Geoscience and Remote Sensing*, 61: 1–22

Szegedy C, Ioffe S, Vanhoucke V, Alemi A a J A (2016). Inception-v4, Inception-ResNet and the impact of residual connections on learning. *ArXiv*,

Szegedy C, Wei L, Yangqing J, Sermanet P, Reed S, Anguelov D, Erhan D, Vanhoucke V, Rabinovich A (2015). Going deeper with convolutions. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 1–9, June 7–12, 2015, Boston, MA, USA

Taheri E, Amin M M, Fatehizadeh A, Rezakazemi M, Aminabhavi T M (2021). Artificial intelligence modeling to predict transmembrane pressure in anaerobic membrane bioreactor-sequencing batch reactor during biohydrogen production. *Journal of Environmental Management*, 292: 112759

Tao Y, Li C (2018). Application of PSO-RBF neural network in MBR membrane pollution prediction. 2018 Eighth International Conference on Instrumentation & Measurement, Computer, Communication and Control (IMCCC), 873–877, July 19–21, 2018, Harbin, China

Tella A, Balogun A L, Adebisi N, Abdullah S (2021). Spatial assessment of PM₁₀ hotspots using random forest, *k*-nearest neighbour and Naive Bayes. *Atmospheric Pollution Research*, 12(10): 101202

Tu S, Xu L (2012). A theoretical investigation of several model selection criteria for dimensionality reduction. *Pattern Recognition Letters*, 33(9): 1117–1126

Uddin M G, Nash S, Rahman A, Olbert A I (2023). Performance analysis of the water quality index model for predicting water state using machine learning techniques. *Process Safety and Environmental Protection*, 169: 808–828

Vasilaki V, Conca V, Frison N, Eusebi A L, Fatone F, Katsou E (2020). A knowledge discovery framework to predict the N₂O emissions in the wastewater sector. *Water Research*, 178: 115799

Vasu P K A, Gabriel J, Zhu J, Tuzel O, Ranjan A (2023). FastViT: A fast hybrid vision Transformer using structural reparameterization. Paris, France: IEEE, 5762–5772

Vatanpour V, Madaeni S S, Moradian R, Zinadini S, Astinchap B (2011). Fabrication and characterization of novel antifouling nanofiltration membrane prepared from oxidized multiwalled carbon nanotube/polyethersulfone nanocomposite. *Journal of*

Membrane Science, 375(1–2): 284–294

Viet N D, Im S J, Kim C M, Jang A (2021). An osmotic membrane bioreactor-clarifier system with a deep learning model for simultaneous reduction of salt accumulation and membrane fouling. *Chemosphere*, 272: 129872

Viet N D, Jang A (2021). Development of artificial intelligence-based models for the prediction of filtration performance and membrane fouling in an osmotic membrane bioreactor. *Journal of Environmental Chemical Engineering*, 9(4): 105337

Wang H, Zeng J, Dai R, Wang Z (2024a). Understanding rejection mechanisms of trace organic contaminants by polyamide membranes via data-knowledge codriven machine learning. *Environmental Science & Technology*, 58(13): 5878–5888

Wang X T, Sun X, Wu Y B, Gao F, Yang Y (2024b). Optimizing reverse osmosis desalination from brackish waters: predictive approach employing response surface methodology and artificial neural network models. *Journal of Membrane Science*, 704: 122883

Wang Z W, Wu X H (2015). Mathematical and artificial neural network models to predict the membrane fouling behavior of an intermittently-aerated membrane bioreactor under sub-critical flux. *Clean*, 43(7): 1002–1009

Wei S, Kang Y, Peng Z, Xiao X, Wang L, Yang Y, Salim F D J A (2024). STEMO: early spatio-temporal forecasting with multi-objective reinforcement learning. *ArXiv*,

Wolf G, Almeida J S, Crespo J G, Reis M A M (2003). Monitoring of biofilm reactors using natural fluorescence fingerprints. *Water Science and Technology*, 47(5): 161–167

Wolf G, Almeida J S, Pinheiro C, Correia V, Rodrigues C, Reis M A M, Crespo J G (2001). Two-dimensional fluorometry coupled with artificial neural networks: a novel method for on-line monitoring of complex biological processes. *Biotechnology and Bioengineering*, 72(3): 297–306

Woo T, Nam K, Heo S, Lim J Y, Kim S, Yoo C (2022). Predictive maintenance system for membrane replacement time detection using AI-based functional profile monitoring: application to a full-scale MBR plant. *Journal of Membrane Science*, 649: 120400

Wu J L, Chen F T, Huang X, Geng W Y, Wen X H (2006). Using inorganic coagulants to control membrane fouling in a submerged membrane bioreactor. *Desalination*, 197(1–3): 124–136

Wu J L, Huang X (2008). Effect of dosing polymeric ferric sulfate on fouling characteristics, mixed liquor properties and performance in a long-term running membrane bioreactor. *Separation and Purification Technology*, 63(1): 45–52

Wu Q, Ye Y, Liu Y, Ng M K (2012). SNP selection and classification of genome-wide SNP data using stratified sampling random forests. *IEEE Transactions on Nanobioscience*, 11(3): 216–227

Xiao K, Liang S, Wang X M, Chen C S, Huang X (2019). Current state and challenges of full-scale membrane bioreactor applications: a critical review. *Bioresource Technology*, 271: 473–481

H, Eguchi K (1990). Ảnh hưởng của điện trở màng đến đặc tính lọc đối với chất thải sinh methan. *Kagaku Kogaku Ronbunshu*, 16(1): 145–151

Silver D, Huang A, Maddison C J, Guez A, Sifre L, Van Den Driessche G, Schrittwieser J, Antonoglou I, Panneershelvam V, Lanctot M, và cộng sự. (2016). Làm chủ trò chơi cờ vây bằng mạng nơ-ron sâu và tìm kiếm cây. *Nature*, 529(7587): 484–489

Suman B, Kumar P (2006). Tổng quan về ủ mô phỏng như một công cụ cho tối ưu hóa đơn mục tiêu và đa mục tiêu. *Journal of the Operational Research Society*, 57(10): 1143–1160

Sun X, Wang P, Lu W, Zhu Z, Lu X, He Q, Li J, Rong X, Yang Z, Chang H, và cộng sự. (2023). RingMo: một mô hình nền tảng viễn thám với kỹ thuật mô hình hóa ảnh che khuất. *IEEE Transactions on Geoscience and Remote Sensing*, 61: 1–22

Szegedy C, Ioffe S, Vanhoucke V, Alemi A a J A (2016). Inception-v4, Inception-ResNet và tác động của các kết nối dư đối với việc học. *ArXiv*, Szegedy C, Wei L, Yangqing J, Sermanet P, Reed S, Anguelov D, Erhan D, Vanhoucke V, Rabinovich A (2015). Đi sâu hơn với các phép tích chập. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 1–9, June 7–12, 2015, Boston, MA, Hoa Kỳ

Taheri E, Amin M M, Fatehizadeh A, Rezakazemi M, Aminabhavi T M (2021). Mô hình hóa trí tuệ nhân tạo để dự đoán áp suất xuyên màng trong bể phản ứng sinh học màng kỵ khí—bể phản ứng theo mẻ tuần tự trong quá trình sản xuất hydro sinh học. *Journal of Environmental Management*, 292: 112759

Tao Y, Li C (2018). Ứng dụng mạng nơ-ron PSO-RBF trong dự đoán ô nhiễm màng MBR. 2018 Hội nghị quốc tế lần thứ tám về thiết bị đo lường, máy tính, truyền thông và điều khiển (IMCCC), 873–877, July 19–21, 2018, Harbin, Trung Quốc

Tella A, Balogun A L, Adebisi N, Abdullah S (2021). Đánh giá không gian các điểm nóng PM₁₀ bằng cách sử dụng rừng ngẫu nhiên, *k* láng giềng gần nhất và Bayes ngây thơ. *Atmospheric Pollution Research*, 12(10): 101202

Tu S, Xu L (2012). Nghiên cứu lý thuyết về một số tiêu chí lựa chọn mô hình cho giảm chiều. *Pattern Recognition Letters*, 33(9): 1117–1126

Uddin M G, Nash S, Rahman A, Olbert A I (2023). Phân tích hiệu năng của mô hình chỉ số chất lượng nước nhằm dự đoán trạng thái nước bằng cách sử dụng các kỹ thuật học máy. *Process Safety and Environmental Protection*, 169: 808–828

Vasilaki V, Conca V, Frison N, Eusebi A L, Fatone F, Katsou E (2020). Khung khai phá tri thức để dự đoán lượng phát thải N₂O trong lĩnh vực nước thải. *Water Research*, 178: 115799

Vasu P K A, Gabriel J, Zhu J, Tuzel O, Ranjan A (2023). FastViT: một Transformer thị giác lai tốc độ cao sử dụng tái tham số hóa cấu trúc. Paris, Pháp: IEEE, 5762–5772

Vatanpour V, Madaeni S S, Moradian R, Zinadini S, Astinchap B (2011). Chế tạo và đặc trưng hóa màng lọc nano chống bám bẩn mới được chế tạo từ nanocomposite ống nano carbon đa thành oxy hóa/polyethersulfone. *Journal of*

Membrane Science, 375(1–2): 284–294

Viet N D, Im S J, Kim C M, Jang A (2021). Hệ thống thiết bị phản ứng sinh học màng thẩm thấu-bể lắng với mô hình học sâu nhằm đồng thời giảm tích tụ muối và tắc nghẽn màng. *Chemosphere*, 272: 129872

Viet N D, Jang A (2021). Phát triển các mô hình dựa trên trí tuệ nhân tạo để dự đoán hiệu suất lọc và hiện tượng tắc nghẽn màng trong thiết bị phản ứng sinh học màng thẩm thấu. *Journal of Environmental Chemical Engineering*, 9(4): 105337

Wang H, Zeng J, Dai R, Wang Z (2024a). Tìm hiểu cơ chế loại bỏ các chất ô nhiễm hữu cơ dạng vết của màng polyamit thông qua học máy đồng dẫn dắt bằng dữ liệu và tri thức. *Environmental Science & Technology*, 58(13): 5878–5888

Wang X T, Sun X, Wu Y B, Gao F, Yang Y (2024b). Tối ưu hóa khử muối bằng thẩm thấu ngược từ nước lợ: phương pháp dự đoán sử dụng phương pháp bề mặt đáp ứng và các mô hình mạng nơ-ron nhân tạo. *Journal of Membrane Science*, 704: 122883

Wang Z W, Wu X H (2015). Các mô hình toán học và mạng nơ-ron nhân tạo để dự đoán đặc tính tắc nghẽn màng của thiết bị phản ứng sinh học màng sạch khí gián đoạn ở thông lượng dưới tới hạn. *Clean*, 43(7): 1002–1009

Wei S, Kang Y, Peng Z, Xiao X, Wang L, Yang Y, Salim F D J A (2024). STEMO: dự báo không-thời gian sớm bằng học tăng cường đa mục tiêu. *ArXiv*

Wolf G, Almeida J S, Crespo J G, Reis M A M (2003). Giám sát các thiết bị phản ứng màng sinh học bằng dấu vân tay huỳnh quang tự nhiên. *Water Science and Technology*, 47(5): 161–167

Wolf G, Almeida J S, Pinheiro C, Correia V, Rodrigues C, Reis M A M, Crespo J G (2001). Phép đo huỳnh quang hai chiều kết hợp với mạng nơ-ron nhân tạo: phương pháp mới để giám sát trực tuyến các quá trình sinh học phức tạp. *Biotechnology and Bioengineering*, 72(3): 297–306

Woo T, Nam K, Heo S, Lim J Y, Kim S, Yoo C (2022). Hệ thống bảo trì dự đoán để xác định thời điểm thay thế màng bằng cách giám sát hồ sơ chức năng dựa trên AI: ứng dụng tại nhà máy MBR quy mô toàn phần. *Journal of Membrane Science*, 649: 120400

Wu J L, Chen F T, Huang X, Geng W Y, Wen X H (2006). Sử dụng chất keo tụ vô cơ để kiểm soát hiện tượng tắc nghẽn màng trong thiết bị phản ứng sinh học màng chìm. *Desalination*, 197(1–3): 124–136

Wu J L, Huang X (2008). Ảnh hưởng của việc bổ sung polyme sắt(III) sulfat đến đặc tính tắc nghẽn, tính chất của hỗn hợp bùn và hiệu suất trong thiết bị phản ứng sinh học màng vận hành dài hạn. *Separation and Purification Technology*, 63(1): 45–52

Wu Q, Ye Y, Liu Y, Ng M K (2012). Lựa chọn và phân loại SNP trong dữ liệu SNP toàn hệ gen bằng rừng ngẫu nhiên lấy mẫu phân tầng. *IEEE Transactions on Nanobioscience*, 11(3): 216–227

Xiao K, Liang S, Wang X M, Chen C S, Huang X (2019). Hiện trạng và thách thức của các ứng dụng thiết bị phản ứng sinh học màng quy mô toàn phần: một bài tổng quan phản biện. *Bioresource Technology*, 271: 473–481

Xiao K, Xu Y, Liang S, Lei T, Sun J Y, Wen X H, Zhang H X, Chen C S, Huang X (2014). Engineering application of membrane bioreactor for wastewater treatment in China: current state and future prospect. *Frontiers of Environmental Science & Engineering*, 8(6): 805–819

Xie L, Luo S, Liu Y, Ruan X, Gong K, Ge Q, Li K, Valev V K, Liu G, Zhang L (2023). Automatic identification of individual nanoplastics by Raman spectroscopy based on machine learning. *Environmental Science & Technology*, 57(46): 18203–18214

Xu H, Xiao K, Wang X M, Liang S, Wei C H, Wen X H, Huang X (2020). Outlining the roles of membrane-foulant and foulant-foulant interactions in organic fouling during microfiltration and ultrafiltration: a mini-review. *Frontiers in Chemistry*, 8: 417

Xu J, Xu Z, Kuang J, Lin C, Xiao L, Huang X, Zhang Y (2021). An alternative to laboratory testing: random forest-based water quality prediction framework for inland and nearshore water bodies. *Water*, 13(22): 3262

Xu Y R, Zeng X H, Bernard S, He Z (2022). Data-driven prediction of neutralizer pH and valve position towards precise control of chemical dosage in a wastewater treatment plant. *Journal of Cleaner Production*, 348: 131360

Yamamoto K, Hiasa M, Mahmood T, Matsuo T (1989). Direct solid-liquid separation using hollow fiber membrane in an activated-sludge aeration tank. *Water Science and Technology*, 21(4–5): 43–54

Yamato N, Kimura K, Miyoshi T, Watanabe Y (2006). Difference in membrane fouling in membrane bioreactors (MBRs) caused by membrane polymer materials. *Journal of Membrane Science*, 280(1–2): 911–919

Yang F, Lu W H, Luo L K, Li T (2012). Margin optimization based pruning for random forest. *Neurocomputing*, 94: 54–63

Yang X S (2009). Firefly algorithms for multimodal optimization. Watanabe O and Zeugmann T, eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 169–178

Yang X S (2010). Nature inspired cooperative strategies for optimization (NICSO 2010). González J R, Pelta D A, Cruz C, Terrazas G, Krasnogor N, eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 65–74

Yao J Q, Wu Z Y, Liu Y, Zheng X Y, Zhang H B, Dong R J, Qiao W (2022). Predicting membrane fouling in a high solid AnMBR treating OFMSW leachate through a genetic algorithm and the optimization of a BP neural network model. *Journal of Environmental Management*, 307: 114585

Yaqub M, Asif H, Kim S, Lee W (2020). Modeling of a full-scale sewage treatment plant to predict the nutrient removal efficiency using a long short-term memory (LSTM) neural network. *Journal of Water Process Engineering*, 37: 101388

Yasmin N S A, Wahab N A, Yusuf Z (2017). Modeling of membrane bioreactor of wastewater treatment using support vector machine. Melaka, MALAYSIA: Springer, Singapore, 485–495

Yoon S H (2015). Membrane Bioreactor Processes: Principles and applications. Boca Raton: Membrane Bioreactor Processes:

Principles and Applications

Yu Z, Ruan J, Xing D (2023). Explainable reinforcement learning via a causal world model. ArXiv,

Zadeh L A (2023). Granular, Fuzzy, And Soft Computing. Lin T Y, Liao C J, Kacprzyk J, eds. New York: Springer US, 19–49

Zagoruyko S, Komodakis N J A (2016). Wide residual networks. ArXiv,

Zeiler M D, Fergus R (2014). Visualizing and understanding convolutional networks. Fleet D, Pajdla T, Schiele B, Tuytelaars T, eds. Computer Vision – ECCV 2014. ECCV 2014. Lecture Notes in Computer Science, Cham: Springer, 8689: 818–833

Zhang B, Mao X, Tang X M, Tang H L, Zhang B, Shen Y, Shi W X (2022). Effect of modified microbial flocculant on membrane fouling alleviation in a hybrid aerobic granular sludge membrane system for wastewater reuse. *Separation and Purification Technology*, 290: 120819

Zhang G J, Ji S L, Gao X, Liu Z Z (2008). Adsorptive fouling of extracellular polymeric substances with polymeric ultrafiltration membranes. *Journal of Membrane Science*, 309(1–2): 28–35

Zhang H, Ma Y, Jiang T, Zhang G, Yang F (2012). Influence of activated sludge properties on flux behavior in osmosis membrane bioreactor (OMBR). *Journal of Membrane Science*, 390–391: 270–276

Zhang Q, Yang L T, Chen Z, Li P (2018). A survey on deep learning for big data. *Information Fusion*, 42: 146–157

Zhang Q Y, Singh S, Stuckey D C (2017). Fouling reduction using adsorbents/flocculants in a submerged anaerobic membrane bioreactor. *Bioresource Technology*, 239: 226–235

Zhang X, Long T, Deng S, Chen Q, Chen S, Luo M, Yu R, Zhu X (2023). Machine learning modeling based on microbial community for prediction of natural attenuation in groundwater. *Environmental Science & Technology*, 57(50): 21212–21223

Zhao B, Chen H, Gao D K, Xu L Z, Zhang Y Y (2020). Cleaning decision model of MBR membrane based on Bandelet neural network optimized by improved Bat algorithm. *Applied Soft Computing*, 91: 106211

Zhao Z, Lou Y, Chen Y, Lin H, Li R, Yu G (2019). Prediction of interfacial interactions related with membrane fouling in a membrane bioreactor based on radial basis function artificial neural network (ANN). *Bioresource Technology*, 282: 262–268

Zhong H, Yuan Y, Luo L, Ye J, Chen M, Zhong C (2022). Water quality prediction of MBR based on machine learning: a novel dataset contribution analysis method. *Journal of Water Process Engineering*, 50: 103296

Zhong S F, Guan X H (2023). Count-based Morgan fingerprint: a more efficient and interpretable molecular representation in developing machine learning-based predictive regression models for water contaminants: activities and properties. *Environmental Science & Technology*, 57(46): 18193–18202

Zhong S F, Zhang K, Bagheri M, Burken J G, Gu A, Li B K, Ma X M, Marrone B L, Ren Z J, Schrier J, et al. (2021). Machine learning: New ideas and tools in environmental science and engineering. *Environmental Science & Technology*, 55(19):

Xiao K, Xu Y, Liang S, Lei T, Sun J Y, Wen X H, Zhang H X, Chen C S, Huang X (2014). Ứng dụng kỹ thuật của bề phản ứng sinh học màng trong xử lý nước thải tại Trung Quốc : hiện trạng và triển vọng tương lai. *Frontiers of Environmental Science & Engineering*, 8(6): 805–819

Xie L, Luo S, Liu Y, Ruan X, Gong K, Ge Q, Li K, Valev V K, Liu G, Zhang L (2023). Tự động nhận dạng các hạt nano nhựa riêng lẻ bằng phương pháp quang phổ Raman dựa trên máy học. *Environmental Science & Technology*, 57(46): 18203–18214

Xu H, Xiao K, Wang X M, Liang S, Wei C H, Wen X H, Huang X (2020). Khái quát vai trò của các tương tác giữa màng và chất gây bám bẩn cũng như giữa các chất gây bám bẩn trong hiện tượng bám bẩn hữu cơ trong quá trình vi lọc và siêu lọc: một bài tổng quan ngắn. *Frontiers in Chemistry*, 8: 417

Xu J, Xu Z, Kuang J, Lin C, Xiao L, Huang X, Zhang Y (2021). Một giải pháp thay thế cho thử nghiệm trong phòng thí nghiệm: khung dự đoán chất lượng nước dựa trên rừng ngẫu nhiên cho các thủy vực nội địa và ven bờ. *Water*, 13(22): 3262

Xu Y R, Zeng X H, Bernard S, He Z (2022). Dự đoán dựa trên dữ liệu về pH của chất trung hòa và vị trí van nhằm kiểm soát chính xác lượng hóa chất sử dụng tại nhà máy xử lý nước thải. *Journal of Cleaner Production*, 348: 131360

Yamamoto K, Hiasa M, Mahmood T, Matsuo T (1989). Tách rắn-lông trực tiếp bằng cách sử dụng màng sợi rỗng trong bể sục khí bùn hoạt tính. *Water Science and Technology*, 21(4–5): 43–54

Yamato N, Kimura K, Miyoshi T, Watanabe Y (2006). Sự khác biệt về hiện tượng bám bẩn màng trong các bể phản ứng sinh học màng (MBR) do vật liệu polymer của màng gây ra. *Journal of Membrane Science*, 280(1–2): 911–919

Yang F, Lu W H, Luo L K, Li T (2012). Tỉa cây rừng ngẫu nhiên dựa trên tối ưu hóa biên. *Neurocomputing*, 94: 54–63

Yang X S (2009). Các thuật toán đom đóm cho bài toán tối ưu đa phương thức. Watanabe O and Zeugmann T, chủ biên. Berlin, Heidelberg: Springer Berlin Heidelberg, 169–178

Yang X S (2010). Các chiến lược hợp tác lấy cảm hứng từ tự nhiên cho tối ưu hóa NICSO 2010. González J R, Pelta D A, Cruz C, Terrazas G, Krasnogor N, chủ biên. Berlin, Heidelberg: Springer Berlin Heidelberg, 65–74

Yao J Q, Wu Z Y, Liu Y, Zheng X Y, Zhang H B, Dong R J, Qiao W (2022). Dự đoán hiện tượng bám bẩn màng trong một AnMBR có hàm lượng chất rắn cao xử lý nước rỉ rác OFMSW thông qua thuật toán di truyền và tối ưu hóa mô hình mạng nơ-ron BP. *Journal of Environmental Management*, 307: 114585

Yaqub M, Asif H, Kim S, Lee W (2020). Mô hình hóa một nhà máy xử lý nước thải quy mô toàn diện để dự đoán hiệu suất loại bỏ chất dinh dưỡng bằng cách sử dụng mạng nơ-ron bộ nhớ dài-ngắn hạn (LSTM). *Journal of Water Process Engineering*, 37: 101388

Yasmin N S A, Wahab N A, Yusuf Z (2017). Mô hình hóa bể phản ứng sinh học màng: nguyên lý và ứng dụng. Boca Raton: Các quy trình bể phản ứng sinh học màng:

Nguyên lý và Ứng dụng

Yu Z, Ruan J, Xing D (2023). Học tăng cường có thể giải thích thông qua mô hình thế giới nhân quả. ArXiv, Zadeh L A (2023). Tính toán hạt, mờ và mềm. Lin T Y, Liao C J, Kacprzyk J, biên tập. New York: Springer US, 19–49

Zagoruyko S, Komodakis N J A (2016). Mạng dư rộng. ArXiv, Zeiler M D, Fergus R (2014). Trực quan hóa và tìm hiểu các mạng tích chập. Fleet D, Pajdla T, Schiele B, Tuytelaars T, biên tập. Thị giác máy tính – ECCV 2014. ECCV 2014. Lecture Notes in Computer Science, Cham: Springer, 8689: 818–833

Zhang B, Mao X, Tang X M, Tang H L, Zhang B, Shen Y, Shi W X (2022). Tác động của chất tạo bông vi sinh đã biến đổi đến việc giảm tắc nghẽn màng trong hệ thống màng bùn hạt hiếu khí lại nhằm tái sử dụng nước thải. *Separation and Purification Technology*, 290: 120819

Zhang G J, Ji S L, Gao X, Liu Z Z (2008). Tắc nghẽn do hấp phụ của các chất polymer ngoại bào trên màng siêu lọc polymer. *Journal of Membrane Science*, 309(1–2): 28–35

Zhang H, Ma Y, Jiang T, Zhang G, Yang F (2012). Ảnh hưởng của các đặc tính bùn hoạt tính đến diễn biến thông lượng trong thiết bị phản ứng sinh học màng thấm thấu OMBR. *Journal of Membrane Science*, 390–391: 270–276

Zhang Q, Yang L T, Chen Z, Li P (2018). Khảo sát về học sâu cho dữ liệu lớn. *Information Fusion*, 42: 146–157

Zhang Q Y, Singh S, Stuckey D C (2017). Giảm tắc nghẽn bằng cách sử dụng chất hấp phụ/chất tạo bông trong thiết bị phản ứng sinh học màng kỵ khí ngập chìm. *Bioresource Technology*, 239: 226–235

Zhang X, Long T, Deng S, Chen Q, Chen S, Luo M, Yu R, Zhu X (2023). Mô hình hóa bằng học máy dựa trên quần xã vi sinh vật để dự đoán sự suy giảm tự nhiên trong nước ngầm. *Environmental Science & Technology*, 57(50): 21212–21223

Zhao B, Chen H, Gao D K, Xu L Z, Zhang Y Y (2020). Mô hình quyết định làm sạch màng MBR dựa trên mạng nơ-ron Bandelet được tối ưu hóa bằng thuật toán Dơi cải tiến. *Applied Soft Computing*, 91: 106211

Zhao Z, Lou Y, Chen Y, Lin H, Li R, Yu G (2019). Dự đoán các tương tác liên bề mặt liên quan đến tắc nghẽn màng trong thiết bị phản ứng sinh học màng dựa trên mạng nơ-ron nhân tạo hàm cơ sở xuyên tâm ANN. *Bioresource Technology*, 282: 262–268

Zhong H, Yuan Y, Luo L, Ye J, Chen M, Zhong C (2022). Dự đoán chất lượng nước của MBR dựa trên học máy: phương pháp phân tích đóng góp của tập dữ liệu mới. *Journal of Water Process Engineering*, 50: 103296

Zhong S F, Guan X H (2023). Dấu vân tay Morgan dựa trên số đếm: biểu diễn phân tử hiệu quả và dễ diễn giải hơn trong việc xây dựng các mô hình hồi quy dự đoán dựa trên học máy cho các chất ô nhiễm trong nước: hoạt tính và tính chất. *Environmental Science & Technology*, 57(46): 18193–18202

Zhong S F, Zhang K, Bagheri M, Burken J G, Gu A, Li B K, Ma X M, Marrone B L, Ren Z J, Schrier J, và cộng sự (2021). Học máy: ý tưởng và công cụ mới trong khoa học và kỹ thuật môi trường. *Environmental Science & Technology*, 55(19):

12741–12754	Zhuang L P, Tang B, Bin L Y, Li P, Huang S S, Fu F L (2021).
Zhou M, Li Y (2024). Spatial distribution and source identification of potentially toxic elements in Yellow River Delta soils, China: an interpretable machine-learning approach. Science of the Total Environment, 912: 169092	Performance prediction of an internal-circulation membrane bioreactor based on models comparison and data features analysis. Biochemical Engineering Journal, 166: 107850

12741–12754	Zhuang L P, Tang B, Bin L Y, Li P, Huang S S, Fu F L (2021).
Zhou M, Li Y (2024). Phân bố không gian và xác định nguồn gốc của các nguyên tố có khả năng gây độc trong đất tại đống bằng sông Hoàng Hà, Trung Quốc: phương pháp học máy có khả năng diễn giải. Science of the Total Environment, 912: 169092	Dự đoán hiệu suất của một bể phản ứng sinh học màng tuần hoàn nội bộ dựa trên việc so sánh các mô hình và phân tích đặc trưng dữ liệu. Tạp chí Kỹ thuật Sinh học, 166: 107850