

Predicting nitrification status in aerobic membrane bioreactors by interpretable machine learning models: Proof of concept for advancing greywater reuse through process monitoring with cross-scenario model validation

Siyuan Wang^{a,b}, Seow Wah How^{a,b}, Duc-Viet Nguyen^{a,b}, Di Wu^{a,b,c,*}

^a Department of Green Chemistry and Technology, Ghent University, Ghent, Belgium
^b Centre for Green Chemistry and Environmental Biotechnology (GREAT), Ghent University Global Campus, Incheon, Republic of Korea
^c Department of Civil and Environmental Engineering, Water Technology Center and Chinese National Engineering Research Center for Control and Treatment of Heavy Metal Pollution (Hong Kong Branch), The Hong Kong University of Science and Technology, Hong Kong, China

ARTICLE INFO

Keywords:
Greywater reuse
MBR
Interpretable machine learning
Data-driven
Process monitoring
Soft sensor
On-site water treatment

ABSTRACT

Membrane bioreactor (MBR) systems for on-site greywater treatment and reuse have been widely investigated, where robust nitrification monitoring is critical to prevent operational disruptions and maintain effluent standards. This research proposed an interpretable machine learning-based framework to predict nitrification efficacy (classified as "sufficient" or "insufficient") in MBR systems, involving model-based and post hoc interpretability. Three interpretable machine learning algorithms—logistic regression (LR), random forest (RF), and extreme gradient boosting (XGB)—were systematically evaluated, accounting for model bias-variance trade-offs during binary classification. Six input features were selected based on direct measurability, compatibility with commercial sensors, and operational relevance. Model optimization criteria focused on maximizing precision to prevent erroneous controls for insufficient nitrification, achieved by low false positive rate (FPR: misclassified insufficient nitrification) and high true positive rate (TPR: correctly identified sufficient nitrification). Results showed that both LR and XGB achieved identical precision scores > 0.85 under standard conditions. Cross-scenario validation demonstrated RF's superior generalizability (precision=0.87) when predicting nitrification in biocarrier-amended MBRs using training data from non-biocarrier systems, reflecting the potential transferability of the model. The post hoc interpretability and stability analysis further identified prediction sensitivity to data limitations and distributional biases, providing critical insights for improving and even properly deploying models in practice.

1. Introduction

Greywater, defined as domestic wastewater excluding toilet contributions, represents around 70 % of residential sewage, with daily yields ranging from 20 to 220 L per capita (Shaikh and Ahammed, 2020). Its on-site reuse offers a critical strategy for water conservation, urban water resilience improvement, and sustainable urban development (Liu et al., 2023; Maggiotto, 2022). Membrane

* Correspondence to: Ghent University Global Campus, Incheon Global Campus, 119-5 Songdomunhwa-ro, Incheon 21985, Republic of Korea.
E-mail address: di.wu@ghent.ac.kr (D. Wu).



Dự đoán trạng thái nitrat hóa trong các bể phản ứng sinh học màng hiếu khí bằng mô hình học máy có khả năng diễn giải: Bằng chứng về tính khả thi của việc thúc đẩy tái sử dụng nước xám thông qua giám sát quy trình với thẩm định mô hình trên n hiều kịch bản

Siyuan Wang^{a,b}, Seow Wah How^{a,b}, Duc-Viet Nguyen^{a,b}, Di Wu^{a,b,c,*}

^a Department of Green Chemistry and Technology, Ghent University, Ghent, Belgium^b
Centre for Green Chemistry and Environmental Biotechnology (GREAT), Ghent University Global Campus, Incheon, Republic of Korea^c
~~Department of Civil and Environmental Engineering, Water Technology Center and Chinese National Engineering Research Center for Control and Treatment of Heavy Metal Pollution (Hong Kong Branch), The Hong Kong University of Science and Technology, Hong Kong, China~~

THÔNG TIN BÀI VIẾT

Keywords:
Tái sử dụng nước xám MBR
Học máy có khả năng diễn giải
Dựa trên dữ liệu Giám sát quy trình Cảm biến mềm Xử lý nước tại chỗ

TÓM TẮT

Các hệ thống thiết bị phản ứng sinh học màng (MBR) xử lý và tái sử dụng nước xám tại chỗ đã được nghiên cứu rộng rãi, trong đó việc giám sát quá trình nitrat hóa một cách đáng tin cậy là yếu tố then chốt nhằm ngăn ngừa gián đoạn vận hành và duy trì các tiêu chuẩn nước đầu ra. Nghiên cứu này đề xuất một khung dự đoán hiệu quả nitrat hóa trong các hệ thống MBR dựa trên học máy có khả năng diễn giải (được phân loại là “đủ” hoặc “không đủ”), kết hợp khả năng diễn giải dựa trên mô hình và diễn giải hậu nghiệm. Ba thuật toán học máy có khả năng diễn giải—hồi quy logistic (LR), rừng ngẫu nhiên (RF) và tăng cường gradient cực đại (XGB)—được đánh giá có hệ thống, có xét đến sự đánh đổi giữa độ phức tạp và phương sai của mô hình trong quá trình phân loại nhị phân. Sáu đặc trưng đầu vào được lựa chọn dựa trên khả năng đo trực tiếp, mức độ tương thích với các cảm biến thương mại và tính phù hợp với vận hành. Các tiêu chí tối ưu hóa mô hình tập trung vào việc tối đa hóa độ chính xác nhằm ngăn ngừa các biện pháp điều khiển sai khi quá trình nitrat hóa không đủ; mục tiêu này đạt được nhờ tỷ lệ dương tính giả thấp (FPR: nitrat hóa không đủ bị phân loại sai) và tỷ lệ dương tính thật cao (TPR: xác định chính xác nitrat hóa đủ). Kết quả cho thấy LR và XGB đạt điểm độ chính xác giống nhau là {v*} 0.85 trong điều kiện tiêu chuẩn. Việc xác thực chéo theo kịch bản cho thấy RF có khả năng khái quát hóa vượt trội (độ chính xác {v*} 0.87) khi dự đoán quá trình nitrat hóa trong các hệ thống MBR có bổ sung chất mang sinh học, sử dụng dữ liệu huấn luyện từ các hệ thống không có chất mang sinh học; điều này cho thấy tiềm năng chuyển giao của mô hình. Phân tích khả năng diễn giải hậu nghiệm và độ ổn định cũng xác định được mức độ nhạy cảm của dự đoán trước những hạn chế của dữ liệu và độ phức tạp phân phối, cung cấp những hiểu biết quan trọng để cải thiện mô hình và triển khai chúng một cách phù hợp trong thực tế.

1. Giới thiệu

Nước xám, được định nghĩa là nước thải sinh hoạt không bao gồm nước thải từ nhà vệ sinh, chiếm khoảng 70 % lượng nước thải sinh hoạt, với lưu lượng phát sinh hằng ngày dao động từ 20 đến 220 L/người (Shaikh và Ahammed, 2020). Tái sử dụng nước xám tại chỗ là một chiến lược thiết yếu để bảo tồn nước, tăng cường khả năng chống chịu về nước ở đô thị và thúc đẩy phát triển đô thị bền vững (Liu và cộng sự, 2023; Maggiotto, 2022). Màng

* Correspondence to: Ghent University Global Campus, Incheon Global Campus, 119-5 Songdomunhwa-ro, Incheon 21985, Republic of Korea.
E-mail address: di.wu@ghent.ac.kr (D. Wu).

bioreactors (MBRs) have emerged as a leading technology for such decentralized treatment, owing to their compact footprint and consistent production of high-quality effluent suitable for reuse (Gao et al., 2025). MBR systems synergistically combine biological processes—including heterotrophic oxidation and autotrophic nitrification—with membrane filtration for effective solids separation (Boleydei and Vaneekhaute, 2024).

Nitrification—converting ammonium ($\text{NH}_4^+\text{-N}$) into nitrite ($\text{NO}_2^-\text{-N}$) and then nitrate ($\text{NO}_3^-\text{-N}$)—is critical in MBRs to meet water reuse standards. Centralized plants typically use the proportional integral differential (PID) control strategy to maintain fixed dissolved oxygen (DO) setpoints, yet this strategy adapts poorly to influent fluctuations and incurs high energy costs (Gu et al., 2023). On-site greywater systems face amplified load variability: daily/seasonal usage patterns cause sustained low loads punctuated by sharp peaks, while highly variable water quality challenges empirical control parameters (DelaPaz-Ruiz et al., 2024; Hassan et al., 2024). Although PID adjusts aeration valves, its static DO targets lack real-time responsiveness to dynamic $\text{NH}_4^+\text{-N}$ loads (e.g., dynamic adjustment based on the $\text{NH}_4^+\text{-N}$ load) (Li et al., 2022; Shi et al., 2024). Furthermore, PID relies on submerged DO probes, which are prone to fouling and drift in small-scale MBRs due to continuous aeration and sludge accumulation. This compromises measurement reliability, potentially masking sensor failure as load variation.

Reliable nitrification monitoring remains challenging for decentralized MBRs, where inconsistent efficiency risks process stability despite compliant effluent (observed in the current trial). Notably, real-time monitoring of nitrification processes within MBRs—particularly under decentralized operational scenarios—remains unaddressed in existing studies. Commercial $\text{NH}_4^+\text{-N}/\text{NO}_2^-\text{-N}/\text{NO}_3^-\text{-N}$ sensors are often impractical for installing in the reactor: high sludge concentrations cause rapid fouling and maintenance burdens, increasing operational costs (Huang et al., 2024). Organic matter, suspended solids, and ionic interference further distort readings, while sensor response lags fail to capture rapid nitrogen dynamics—hindering real-time control.

Machine learning (ML) offers promising data-driven solutions for monitoring MBR nitrification, using effluent water quality parameters to assess performance without intrusive sensors, avoiding sensor installation in the reactors with challenges mentioned above (Van de Walle et al., 2023). These methods enable rapid, low-cost, and real-time monitoring—facilitating prompt process interventions and enhancing safety (Bahramian et al., 2023). Compared to mechanistic models, ML requires simpler inputs and incurs minimal maintenance, ideal for on-site systems (Duarte et al., 2024). Given greywater treatment’s critical need for regulatory and public trust, prioritizing interpretable ML methods provides transparent prediction rationales for operator action and model refinement (Allen et al., 2024). Additionally, utilizing interpretable ML methods allows us to further understand the limitations of current training

Các bể phản ứng sinh học màng (MBR) đã trở thành công nghệ hàng đầu cho hình thức xử lý phi tập trung này nhờ diện tích chiếm dụng nhỏ gọn và khả năng tạo ra nước thải đầu ra chất lượng cao, ổn định, phù hợp để tái sử dụng (Gao et al., 2025). Hệ thống MBR kết hợp hiệu quả các quá trình sinh học—bao gồm oxy hóa dị dưỡng và nitrat hóa tự dưỡng—với lọc màng để tách chất rắn hiệu quả (Boleydei và Vaneekhaute, 2024).

Quá trình nitrat hóa—chuyển amoni ($\text{NH}_4^+\text{-N}$) thành nitrit ($\text{NO}_2^-\text{-N}$), rồi thành nitrat ($\text{NO}_3^-\text{-N}$)—giữ vai trò then chốt trong các hệ thống MBR nhằm đáp ứng tiêu chuẩn tái sử dụng nước. Các nhà máy tập trung thường sử dụng chiến lược điều khiển tỷ lệ tích phân-vi phân (PID) để duy trì các giá trị đặt oxy hòa tan (DO) cố định, nhưng chiến lược này thích ứng kém với những biến động của nước đầu vào và tiêu tốn nhiều năng lượng (Gu et al., 2023). Các hệ thống nước xám tại chỗ phải đối mặt với mức độ biến động tải lớn hơn: thói quen sử dụng theo ngày/mùa gây ra tình trạng tải thấp kéo dài, xen kẽ các đỉnh tải tăng đột ngột, trong khi chất lượng nước biến động mạnh gây khó khăn cho việc áp dụng các thông số điều khiển thực nghiệm (DelaPaz-Ruiz et al., 2024; Hassan et al., 2024). Mặc dù PID điều chỉnh các van sục khí, các giá trị DO mục tiêu tĩnh của phương pháp này không đáp ứng theo thời gian thực với tải $\text{NH}_4^+\text{-N}$ biến động (ví dụ: điều chỉnh linh hoạt dựa trên tải $\text{NH}_4^+\text{-N}$) (Li et al., 2022; Shi et al., 2024). Hơn nữa, PID dựa vào các đầu dò DO đặt chìm, vốn dễ bị bám bẩn và trôi tín hiệu trong các hệ thống MBR quy mô nhỏ do sục khí liên tục và tích tụ bùn. Điều này làm giảm độ tin cậy của phép đo, có khả năng khiến sự cố cảm biến bị nhầm lẫn với biến động tải.

Việc giám sát quá trình nitrat hóa đáng tin cậy vẫn là một thách thức đối với các hệ thống MBR phi tập trung, nơi hiệu suất không ổn định đe dọa tính ổn định của quy trình, dù nước thải đầu ra vẫn đạt quy chuẩn (được ghi nhận trong thử nghiệm hiện tại). Đáng chú ý, các nghiên cứu hiện có vẫn chưa giải quyết vấn đề giám sát theo thời gian thực quá trình nitrat hóa trong MBR, đặc biệt là trong các kịch bản vận hành phi tập trung. Các cảm biến $\text{NH}_4^+\text{-N}/\text{NO}_2^-\text{-N}/\text{NO}_3^-\text{-N}$ thương mại thường không phù hợp để lắp đặt trong bể phản ứng: nồng độ bùn cao khiến cảm biến nhanh bị bám bẩn và làm tăng gánh nặng bảo trì, từ đó đẩy chi phí vận hành lên cao (Huang et al., 2024). Chất hữu cơ, chất rắn lơ lửng và nhiều ion cặn làm sai lệch số đo, trong khi độ trễ phản hồi của cảm biến không thể ghi nhận các biến động nitơ nhanh, gây cản trở việc điều khiển theo thời gian thực.

Học máy (ML) mang đến những giải pháp dựa trên dữ liệu đầy hứa hẹn để giám sát quá trình nitrat hóa trong MBR, sử dụng các thông số chất lượng nước đầu ra để đánh giá hiệu suất mà không cần cảm biến xâm lấn, qua đó tránh lắp đặt cảm biến trong các bể phản ứng vốn gặp những thách thức nêu trên (Van de Walle et al., 2023). Những phương pháp này cho phép giám sát nhanh chóng, ít tốn kém và theo thời gian thực, tạo điều kiện can thiệp kịp thời vào quy trình và nâng cao độ an toàn (Bahramian et al., 2023). So với các mô hình cơ chế, ML đòi hỏi dữ liệu đầu vào đơn giản hơn và cần rất ít bảo trì, phù hợp với các hệ thống tại chỗ (Duarte et al., 2024). Do xử lý nước xám cần được cơ quan quản lý và công chúng tin tưởng, việc ưu tiên các phương pháp ML có khả năng diễn giải sẽ cung cấp cơ sở dự đoán minh bạch để hỗ trợ người vận hành hành động và tinh chỉnh mô hình (Allen et al., 2024). Ngoài ra, việc sử dụng các phương pháp ML có khả năng diễn giải giúp chúng ta hiểu rõ hơn những hạn chế của dữ liệu huấn luyện hiện tại.





Fig. 1. Experimental setup and operation phases of MBR.



Hình 1. Thiết lập thí nghiệm và các giai đoạn vận hành của MBR.

strategies and provide guidance for model improvement.

Previous studies on data-driven prediction in MBR-based wastewater treatment have primarily focused on effluent quality, targeted pollutant removal efficiency, and membrane fouling (Muniz de Queiroz et al., 2025; Shi et al., 2022; Zhong et al., 2022). However, relying solely on effluent monitoring provides limited process controllability and fails to enable timely interventions during abnormal operational events. This approach is also labor-intensive, time-consuming, and inadequate for tracing underlying process flaws before effluent quality violations occur (Moretti et al., 2024). In contrast, real-time process monitoring enables proactive control, enhances system resilience, and supports early fault detection—critical for ensuring consistent water quality across diverse reuse applications.

This work aims to develop an interpretable ML model to monitor the nitrification process in MBRs via effluent parameters, reducing the difficulty of input feature acquisition in practice. Features were selected based on direct measurability, sensor compatibility, and operational relevance. To mitigate overfitting and balance bias-variance tradeoffs, three interpretable algorithms—logistic regression (LR), random forest (RF), and extreme gradient boosting (XGB)—were evaluated, simultaneously considering the bias and variance of each algorithm. Model training prioritized operational stability by maximizing precision, depending on the higher true positive rate (TPR) and lower false positive rate (FPR), trained on data from a suspended-sludge MBR. Furthermore, SHapley Additive exPlanations (SHAP) analysis, feature importance, and pairwise assessments elucidated factor-prediction linkages and informed model refinement. The models were further validated on a hybrid system, integrating suspended sludge and polyvinylidene fluoride (PVDF) biocarriers, performing simultaneously nitrification-denitrification, demonstrating cross-scenario prediction applicability. Finally, an automated aeration control strategy is proposed to operationalize the monitoring framework.

2. Material and methods

2.1. Experiment method

Synthetic greywater was prepared following Ongena et al. (2023) using Korean commercial personal care products, detergents, and

các chiến lược và đưa ra hướng dẫn để cải thiện mô hình.

Các nghiên cứu trước đây về dự đoán dựa trên dữ liệu trong xử lý nước thải bằng MBR chủ yếu tập trung vào chất lượng nước đầu ra, hiệu suất loại bỏ các chất ô nhiễm mục tiêu và hiện tượng tắc nghẽn màng (Muniz de Queiroz et al., 2025; Shi et al., 2022; Zhong et al., 2022). Tuy nhiên, việc chỉ dựa vào giám sát nước đầu ra khiến khả năng kiểm soát quy trình bị hạn chế và không cho phép can thiệp kịp thời khi xảy ra các sự cố vận hành bất thường. Cách tiếp cận này cũng đòi hỏi nhiều nhân lực, tốn thời gian và không đủ hiệu quả để truy tìm các khiếm khuyết tiềm ẩn của quy trình trước khi chất lượng nước đầu ra không đạt yêu cầu (Moretti et al., 2024). Ngược lại, giám sát quy trình theo thời gian thực cho phép kiểm soát chủ động, tăng cường khả năng chống chịu của hệ thống và hỗ trợ phát hiện sớm sự cố—những yếu tố thiết yếu để đảm bảo chất lượng nước ổn định trong nhiều ứng dụng tái sử dụng khác nhau.

Nghiên cứu này nhằm phát triển một mô hình học máy (ML) có khả năng diễn giải để giám sát quá trình nitrat hóa trong các bể phản ứng sinh học màng (MBR) thông qua các thông số nước đầu ra, qua đó giảm khó khăn trong việc thu thập đặc trưng đầu vào trên thực tế. Các đặc trưng được lựa chọn dựa trên khả năng đo trực tiếp, mức độ tương thích với cảm biến và mức độ phù hợp với hoạt động vận hành. Để giảm thiểu hiện tượng quá khớp và cân bằng sự đánh đổi giữa độ chệch và phương sai, ba thuật toán có khả năng diễn giải—hồi quy logistic (LR), rừng ngẫu nhiên (RF) và tăng cường gradient cực đại (XGB)—đã được đánh giá, đồng thời xem xét độ chệch và phương sai của từng thuật toán. Quá trình huấn luyện mô hình ưu tiên sự ổn định vận hành bằng cách tối đa hóa độ chính xác, dựa trên tỷ lệ dương tính thật (TPR) cao hơn và tỷ lệ dương tính giả (FPR) thấp hơn, với dữ liệu từ một MBR bùn lơ lửng. Ngoài ra, phân tích SHapley Additive exPlanations (SHAP), mức độ quan trọng của đặc trưng và các đánh giá theo từng cặp đã làm sáng tỏ mối liên hệ giữa các yếu tố và dự đoán, đồng thời hỗ trợ tinh chỉnh mô hình. Các mô hình còn được kiểm định trên một hệ thống lai kết hợp bùn lơ lửng với giá thể sinh học polyvinylidene fluoride (PVDF), trong đó quá trình nitrat hóa và khử nitrat diễn ra đồng thời, qua đó chứng minh khả năng áp dụng dự đoán trong nhiều kịch bản. Cuối cùng, một chiến lược điều khiển sục khí tự động được đề xuất nhằm đưa khung giám sát vào vận hành.

2. Vật liệu và phương pháp

2.1. Experiment method

Nước xám tổng hợp được pha chế theo Ongena et al. (2023) bằng cách sử dụng các sản phẩm chăm sóc cá nhân và chất tẩy rửa thương





Fig. 2. Flowchart of data-driven model development and evaluation for nitrification process monitoring.



Hình 2. Lưu đồ phát triển và đánh giá mô hình dựa trên dữ liệu để giám sát quá trình nitrat hóa.

literature-derived compositions. The overall synthetic greywater contained $405 \pm 70 \text{ mg L}^{-1}$ of chemical oxygen demand (COD), $20 \pm 3 \text{ mg L}^{-1}$ of $\text{NH}_4^+ - \text{N}$ and $21 \pm 5 \text{ mg L}^{-1}$ of total nitrogen (TN). The remainder of the COD and TN not provided by the personal care products and detergents was approximated by adding acetate and ammonium chloride. Fresh batches were prepared daily with tap water.

Two parallel 10 L MBRs were inoculated with activated sludge sampled from an Anaerobic-Anoxic-Oxic wastewater treatment plant (Incheon, Korea) and operated for 235 days. Each contained two $0.56\text{-}\mu\text{m}$ SiC flat-sheet membranes (0.165 m^2 surface area; Fig. 1). Continuous aeration maintained DO at $5.1 \pm 2.2 \text{ mg L}^{-1}$. Greywater feeding and permeate extraction were conducted continuously, with timer-controlled relaxation (0.06 L min^{-1}). The operational strategy for the two parallel MBRs involved three phases of adjusted net flux and aeration to enhance greywater treatment, particularly ammonia removal (Fig. 1). Initially low ammonia removal under a flux of $2.9 \text{ L}/(\text{m}^2\cdot\text{h})$ and aeration of 2.0 L/min prompted an increase in aeration to 6.0 L/min in Phase 2 to improve nitrification efficiency. Phase 3 involved an increase in flux to $6.9 \text{ L}/(\text{m}^2\cdot\text{h})$ to further test hydraulic stability. Biocarriers (10 % packing ratio) were added to MBR-2 in phase 3 to try to reduce membrane fouling under high flux and promote anoxic zones for enhancing simultaneous nitrification-denitrification, enabling comparative performance evaluation with MBR-1. The 10 % packing ratio was selected to balance fouling control with operational safety, avoiding abrasion and energy issues associated with higher loads (Noor et al., 2023; Rahman et al., 2023). These intentional variations in flux, aeration, and biocarriers addition diversified operational conditions, enriching the dataset to enhance the machine learning model's generalizability across multiple scenarios.

Influent, effluent and reactor water quality were analyzed daily as described in supplementary information (SI) 1.

2.2. Data-driven modelling

Fig. 2 presents the comprehensive flow-chart adopted for developing data-driven models to monitor the nitrification process in the MBR. Additionally, result analysis and future perspectives are elaborated in Sections 3 and 4.

2.2.1. Binary classification: nitrification process evaluation

To effectively predict nitrification status, the relationship between the concentrations of $\text{NO}_3^- - \text{N}$, $\text{NO}_2^- - \text{N}$, and $\text{NH}_4^+ - \text{N}$ in the reactor must be understood. In the simultaneous nitrification and denitrification process within the MBR, the concentration of $\text{NO}_3^- - \text{N}$ typically exceeds that of $\text{NO}_2^- - \text{N}$ and $\text{NH}_4^+ - \text{N}$ under sufficient aeration, which is a key factor for effective nitrogen conversion and removal (Huang et al., 2022; Paetkau and Cicek, 2011). Therefore, sufficient nitrification was defined as the condition in which the concentration of $\text{NO}_3^- - \text{N}$ exceeds the combined concentrations of $\text{NO}_2^- - \text{N}$ and $\text{NH}_4^+ - \text{N}$, labeled as “Positive”; otherwise, the condition was labeled as “Negative”. The primary goal of the data-driven model for treatment process prediction was to classify whether nitrification was sufficient or insufficient.

2.2.2. Qualitative analysis of inputs selection

Three data categories were collected during the experiment: 1 > Hydraulic: hydraulic retention time (HRT) and sludge retention time (SRT); 2 > Operational: transmembrane pressure (TMP), air/influent/effluent flow rates, gross/net flux, flux recovery; 3 > Water quality: COD, TN, $\text{NH}_4^+ - \text{N}$, $\text{NO}_3^- - \text{N}$, $\text{NO}_2^- - \text{N}$ (in influent, effluent, and mixed liquor in the reactor), TSS (influent/effluent), and DO, MLSS, MLVSS in the reactor. Removal efficiency was also calculated for each parameter. Input features were selected from the perspective of practical deployment, including: 1> Direct measurability, 2> Commercial sensor compatibility, 3> Operational relevance (e.g., TMP).

Indirect variables (SRT, removal efficiencies) were excluded. Water quality parameters (DO, COD, TN, $\text{NH}_4^+ - \text{N}$, $\text{NO}_3^- - \text{N}$, $\text{NO}_2^- - \text{N}$) and operational factors (flow rates, air flow, TMP) were initially considered. However, > 50 % DO data absence led to its exclusion—simulating probe failure scenarios. Air flow rate was retained as an oxygen proxy. Online sensor compatibility was prioritized to enhance model applicability and robustness. Influent water quality was excluded due to sensor reliability concerns: complex matrices cause fouling on sensors and sensor degradation (e.g., Ag/AgCl electrodes dissolution) (Ching et al., 2022; Haimi et al., 2013). Effluent $\text{NO}_2^- - \text{N}$ was also excluded due to measurement instability versus stable $\text{NO}_3^- - \text{N}$. TMP was included to monitor membrane performance, contributing to long-term operation monitoring. Finally, the dataset was refined by removing inappropriate variables and simplifying the inputs to facilitate dataset splitting.

2.2.3. Data preprocessing

From 128 datasets collected over 235 days from dual MBRs, eight incomplete entries were excluded. Biocarriers were added to one reactor in Phase 3 to enable denitrification (Fig. 1), altering parameter relationships. To evaluate cross-scenario applicability, 23 data groups from Phase 3 were used as an independent test group for models trained exclusively on 97 no-biocarrier data groups (activated sludge only). The 97 data groups were utilized for training, validation, and testing of the model's performance in predicting nitrification with activated sludge only. This approach assessed performance under altered operational conditions. Given inherent influent variability in onsite greywater systems, outliers were intentionally retained to evaluate model robustness against operational fluctuations, reflecting real-world dynamics.

2.2.4. Dataset splitting strategy

The preprocessed dataset comprised 120 groups of data, daily measurements reflecting operational manipulations. The data exhibited an inherent imbalance in label distribution due to controlled changes in treatment conditions. For each reactor, the airflow

thành phần được tổng hợp từ tài liệu. Nước xám tổng hợp có hàm lượng nhu cầu oxy hóa học (COD) là $405 \pm 70 \text{ mg L}^{-1}$, $\text{NH}_4^+ - \text{N}$ là $20 \pm 3 \text{ mg L}^{-1}$ và tổng nitơ (TN) là $21 \pm 5 \text{ mg L}^{-1}$. Phần COD và TN còn lại không được cung cấp bởi các sản phẩm chăm sóc cá nhân và chất tẩy rửa được ước tính bằng cách bổ sung axetat và amoni clorua. Các mẻ mới được pha hàng ngày bằng nước máy.

Hai MBR song song, mỗi bể 10 L, được cấy bùn hoạt tính lấy từ một nhà máy xử lý nước thải Anaerobic-Anoxic-Oxic (Incheon, Hàn Quốc) và vận hành trong 235 ngày. Mỗi bể chứa hai màng tấm phẳng SiC dài $0.56\text{-}\mu\text{m}$ (diện tích bề mặt 0.165 m^2 ; Hình 1). Sục khí liên tục duy trì DO ở mức $5.1 \pm 2.2 \text{ mg L}^{-1}$. Nước xám được cấp và nước thẩm được thu liên tục, với thời gian thư giãn được điều khiển bằng bộ hẹn giờ (0.06 L min^{-1}). Chiến lược vận hành hai MBR song song gồm ba giai đoạn điều chỉnh thông lượng thực và mức sục khí nhằm tăng cường xử lý nước xám, đặc biệt là loại bỏ amoniac (Hình 1). Ban đầu, hiệu suất loại bỏ amoniac thấp ở thông lượng $2.9 \text{ L}/(\text{m}^2\cdot\text{h})$ và mức sục khí 2.0 L/min , nên ở Giai đoạn 2, mức sục khí được tăng lên 6.0 L/min để cải thiện hiệu quả nitrat hóa. Ở Giai đoạn 3, thông lượng được tăng lên $6.9 \text{ L}/(\text{m}^2\cdot\text{h})$ để kiểm tra thêm độ ổn định thủy lực. Các giá thể sinh học (tỷ lệ lấp đầy 10%) được bổ sung vào MBR-2 trong Giai đoạn 3 nhằm thử giảm hiện tượng bám bẩn màng ở thông lượng cao và tạo các vùng thiếu khí để tăng cường quá trình nitrat hóa-khử nitrat đồng thời, qua đó cho phép đánh giá hiệu suất so sánh với MBR-1. Tỷ lệ lấp đầy 10% được lựa chọn để cân bằng giữa kiểm soát bám bẩn và an toàn vận hành, tránh ảnh hưởng về mài mòn và năng lượng liên quan đến tải lượng cao hơn (Noor et al., 2023; Rahman et al., 2023). Những thay đổi có chủ đích về thông lượng, mức sục khí và việc bổ sung giá thể sinh học đã đa dạng hóa điều kiện vận hành, làm phong phú tập dữ liệu và tăng cường khả năng khái quát hóa của mô hình học máy trong nhiều kịch bản.

Nước đầu vào, nước đầu ra và chất rắn trong nước được phân tích hằng ngày như mô tả trong thông tin bổ sung (SI) 1.

2.2. Data-driven modelling

Hình 2 trình bày sơ đồ quy trình tổng thể được sử dụng để phát triển các mô hình dựa trên dữ liệu nhằm giám sát quá trình nitrat hóa trong MBR. Ngoài ra, phân phân tích kết quả và triển vọng trong tương lai được trình bày chi tiết trong Mục 3 và 4.

2.2.1. Binary classification: nitrification process evaluation

Để dự đoán hiệu quả tình trạng nitrat hóa, cần hiểu mối quan hệ giữa nồng độ $\text{NO}_3^- - \text{N}$, $\text{NO}_2^- - \text{N}$ và $\text{NH}_4^+ - \text{N}$ trong bể phản ứng. Trong quá trình nitrat hóa và khử nitrat đồng thời trong MBR, khi được sục khí đầy đủ, nồng độ $\text{NO}_3^- - \text{N}$ thường cao hơn nồng độ $\text{NO}_2^- - \text{N}$ và $\text{NH}_4^+ - \text{N}$, đây là yếu tố then chốt giúp chuyển hóa và loại bỏ nitơ hiệu quả (Huang et al., 2022; Paetkau and Cicek, 2011). Vì vậy, nitrat hóa đầy đủ được định nghĩa là trạng thái trong đó nồng độ $\text{NO}_3^- - \text{N}$ cao hơn tổng nồng độ $\text{NO}_2^- - \text{N}$ và $\text{NH}_4^+ - \text{N}$, được gán nhãn “Positive”; nếu không, trạng thái được gán nhãn “Negative”. Mục tiêu chính của mô hình dựa trên dữ liệu dùng để dự đoán quá trình xử lý là phân loại tình trạng nitrat hóa đầy đủ hay không đầy đủ.

2.2.2. Qualitative analysis of inputs selection

Ba loại dữ liệu được thu thập trong quá trình thí nghiệm: 1 > Thủy lực: thời gian lưu thủy lực (HRT) và thời gian lưu bùn (SRT); 2 > Vận hành: áp suất xuyên màng (TMP), lưu lượng khí/nước đầu vào/nước đầu ra, thông lượng tổng/thực, mức độ phụ thuộc thông lượng; 3 > Chất lượng nước: COD, TN, $\text{NH}_4^+ - \text{N}$, $\text{NO}_3^- - \text{N}$, $\text{NO}_2^- - \text{N}$ (trong nước đầu vào, nước đầu ra và hỗn hợp bùn trong bể phản ứng), TSS (nước đầu vào/nước đầu ra), cùng DO, MLSS, MLVSS trong bể phản ứng. Hiệu suất loại bỏ cũng được tính cho từng thông số. Các đặc trưng đầu vào được lựa chọn dựa trên khả năng triển khai thực tế, bao gồm: 1> Có thể đo trực tiếp, 2> Tương thích với cảm biến thương mại, 3> Có liên quan đến vận hành (ví dụ: TMP).

Các biến gián tiếp (SRT, hiệu suất loại bỏ) đã bị loại trừ. Các thông số chất lượng nước (DO, COD, TN, $\text{NH}_4^+ - \text{N}$, $\text{NO}_3^- - \text{N}$, $\text{NO}_2^- - \text{N}$) và các yếu tố vận hành (lưu lượng, lưu lượng khí, TMP) ban đầu được xem xét. Tuy nhiên, do thiếu 50 % dữ liệu DO tại >, biến này đã bị loại trừ — mô phỏng các tình huống đầu dò bị hỏng. Lưu lượng khí được giữ lại làm chỉ báo thay thế cho oxy. Tính tương thích với cảm biến trực tuyến được ưu tiên nhằm nâng cao khả năng ứng dụng và độ bền vững của mô hình. Chất lượng nước đầu vào bị loại trừ do lo ngại về độ tin cậy của cảm biến: các nền mẫu phức tạp gây bám bẩn cảm biến và làm suy giảm cảm biến (ví dụ: điện cực Ag/AgCl bị hòa tan) (Ching et al., 2022; Haimi et al., 2013). $\text{NO}_2^- - \text{N}$ đầu ra cũng bị loại trừ do phạm vi dao động không ổn định, so với $\text{NO}_3^- - \text{N}$ ổn định. TMP được đưa vào để theo dõi hiệu suất màng, góp phần giám sát hoạt động dài hạn. Cuối cùng, bộ dữ liệu được tinh chỉnh bằng cách loại bỏ các biến không phù hợp và đơn giản hóa dữ liệu đầu vào để thuận tiện cho việc chia tách bộ dữ liệu.

2.2.3. Data preprocessing

Trong số 128 bộ dữ liệu được thu thập trong 235 ngày từ các hệ MBR kép, tám mục dữ liệu không đầy đủ đã bị loại bỏ. Giá thể sinh học được bổ sung vào một bể phản ứng ở Pha 3 để thúc đẩy quá trình khử nitrat (Hình 1), làm thay đổi các mối quan hệ giữa các tham số. Để đánh giá khả năng áp dụng giữa các kịch bản, 23 nhóm dữ liệu từ Pha 3 được dùng làm nhóm kiểm tra độc lập cho các mô hình chỉ được huấn luyện bằng 97 nhóm dữ liệu không có giá thể sinh học (chỉ có bùn hoạt tính). 97 nhóm dữ liệu được sử dụng để huấn luyện, xác thực và kiểm thử hiệu suất của mô hình trong việc dự đoán quá trình nitrat hóa chỉ bằng bùn hoạt tính. Cách tiếp cận này đánh giá hiệu suất trong các điều kiện vận hành đã thay đổi. Do nước thải đầu vào trong các hệ thống nước xám tại chỗ vốn có tính biến thiên, các giá trị ngoại lai được cố ý giữ lại để đánh giá độ bền vững của mô hình trước những biến động trong vận hành, qua đó phản ánh động thái thực tế.

2.2.4. Dataset splitting strategy

Bộ dữ liệu đã tiền xử lý gồm 120 nhóm dữ liệu, với các phép đo hằng ngày phản ánh những thao tác vận hành. Dữ liệu vốn có sự mất cân bằng trong phân bố nhãn do các thay đổi có kiểm soát về điều kiện xử lý. Đối với mỗi lò phản ứng, lưu lượng khí

rate was maintained at 2.0 L/min until day 111 and increased to 6.0 L/min thereafter to enhance the nitrification treatment. Similarly, the influent flow rate was predominantly 11.7 ML/min before the 149th day and increased to 20.6 ML/min afterward. Given these temporal shifts, a simple chronological split of the data could not fairly evaluate model performance. To ensure a representative assessment, the training and test sets were constructed strategically to encompass these operational variations, as illustrated in Fig. 3.

Given the imbalanced air flow and influent flow rates, every fourth data point was selected to form the test set, constituting 20 % of the data (8 positive & 11 negative labels). The remaining 80 % (28 positive & 50 negative labels) were used for training and validation, maintaining distinct distributional characteristics to assess model generalization. Hyperparameter optimization employed stratified 5-fold cross-validation (Scikit-Learn's *StratifiedKFold*), ensuring balanced class representation in each fold for enhanced reliability with imbalanced dataset (Szeghalmy and Fazekas, 2023; Zeng and Martinez, 2000). Additionally, 23 datasets from the biocarrier-added condition (Section 2.2 ; 15 positive and 8 negative labels) were used to test cross-scenario robustness under divergent label distributions. Section 2.1

2.2.5. Statistical correlation analysis for inputs determination

Based on the preliminary input feature selections by qualitative analysis in Section 2.2.2, Spearman's rank correlation was used to assess statistical relationships between inputs and outputs. This nonparametric method quantifies the strength of monotonic associations between variables without assuming normal distribution, making it suitable for nonlinear yet monotonic classification contexts (Hastie et al., 2009). Statistical significance was determined using p-values. Specifically, the p-value indicates the probability of obtaining the observed Spearman correlation coefficient, or a more extreme value, under the null hypothesis that no monotonic relationship exists between the variables. A p-value < 0.05 was used to reject the null hypothesis and confirm a significant correlation. The "spearmanr" function (SciPy, Python) computed coefficients and p-values for all variable pairs. (Van Rossum and Drake, 2009).

2.2.6. Model-based interpretability: interpretable ML algorithms

To predict the nitrification status in the MBR and ensure stable operations, this study considered not only the statistical accuracy of ML methods but also integrated algorithm-specific characteristics. In ML, bias stems from simplifying assumptions, while variance reflects sensitivity to fluctuations in the training data (Reynaert et al., 2023). Minimizing one typically increases the other (Belkin et al., 2019).




Fig. 3. Splitting strategy for training, validation and test groups.

lưu lượng được duy trì ở mức 2.0 L/min cho đến ngày thứ 111 và tăng lên 6.0 L/min sau đó để tăng cường xử lý nitrat hóa. Từ ngày thứ 149, lưu lượng nước đầu vào chủ yếu ở mức 11.7 ML/min trước ngày thứ 149 và tăng lên 20.6 ML/min sau đó. Do những thay đổi theo thời gian này, việc chia dữ liệu theo trình tự thời gian đơn thuần không thể đánh giá công bằng hiệu suất mô hình. Để đảm bảo đánh giá mang tính đại diện, các tập huấn luyện và kiểm tra được xây dựng một cách chiến lược nhằm bao quát những biến động trong vận hành này, như minh họa ở Hình 3.


Với lưu lượng khí và lưu lượng dòng vào mất cân bằng, cứ mỗi điểm dữ liệu thứ tư được chọn để tạo thành tập kiểm tra, chiếm 20 % dữ liệu (8 nhãn dương và 11 nhãn âm). 80 % dữ liệu còn lại (28 nhãn dương và 50 nhãn âm) được dùng để huấn luyện và xác thực, đồng thời vẫn duy trì các đặc điểm phân bố riêng biệt nhằm đánh giá khả năng khái quát hóa của mô hình. Tối ưu hóa siêu tham số sử dụng kiểm định chéo phân tầng 5 lần (Scikit-Learn's *StratifiedKFold*), đảm bảo biểu diễn cân bằng các lớp trong mỗi phần chia để tăng độ tin cậy với tập dữ liệu mất cân bằng (Szeghalmy and Fazekas, 2023; Zeng and Martinez, 2000). Ngoài ra, 23 bộ dữ liệu từ điều kiện có bổ sung giá thể sinh học (Mục 2.2; 15 nhãn dương và 8 nhãn âm) được sử dụng để kiểm tra độ bền vững khi chuyển đổi kịch bản trong bối cảnh phân bố nhãn khác biệt. Mục 2.1

2.2.5. Statistical correlation analysis for inputs determination

Dựa trên các lựa chọn đặc trưng đầu vào sơ bộ bằng phương pháp phân tích định tính trong Mục 2.2.2, hệ số tương quan thứ hạng Spearman được dùng để đánh giá các mối quan hệ thống kê giữa đầu vào và đầu ra. Phương pháp phi tham số này định lượng mức độ mạnh của mối liên hệ đơn điệu giữa các biến mà không giả định phân phối chuẩn, nhờ đó phù hợp với các bối cảnh phân loại phi tuyến nhưng đơn điệu (Hastie et al., 2009). Mức ý nghĩa thống kê được xác định bằng giá trị p. Cụ thể, giá trị p cho biết xác suất thu được hệ số tương quan Spearman quan sát được, hoặc một giá trị cực đoan hơn, theo giả thuyết rằng không có mối liên hệ không tồn tại tại mỗi quan hệ đơn điệu. Giá trị p < 0.05 được dùng để bác bỏ giả thuyết không và xác nhận mối tương quan có ý nghĩa. Hàm "spearmanr" (SciPy, Python) tính các hệ số và giá trị p cho mọi cặp biến (Van Rossum and Drake, 2009).

2.2.6. Model-based interpretability: interpretable ML algorithms

Để dự đoán trạng thái nitrat hóa trong MBR và đảm bảo vận hành ổn định, nghiên cứu này không chỉ xem xét độ chính xác thống kê của các phương pháp ML mà còn tích hợp các đặc điểm riêng của từng thuật toán. Trong ML, độ chệch bắt nguồn từ các giả định đơn giản hóa, còn phương sai phản ánh mức độ nhạy cảm với những biến động trong dữ liệu huấn luyện (Reynaert et al., 2023). Việc giảm thiểu yếu tố này thường làm tăng yếu tố kia (Belkin et al., 2019).



Hình 3. Chiến lược chia tập huấn luyện, xác thực và kiểm tra.

Previous studies have indicated that simpler models generally offer advantages for small datasets, including reduced overfitting risk, improved interpretability, and lower computational demands (Reynaert et al., 2023; Wang et al., 2025). For small, non-temporal datasets, complex structures such as artificial neural networks can increase the risk of overfitting (Chiroma et al., 2019).

Therefore, three interpretable algorithms with distinct bias–variance properties were selected. The logistic regression and decision tree-based models are normally cited as simulatable, i.e., interpretable (Breiman et al., 2017; Murdoch et al., 2019).

- **Logistic regression (LR):** High bias, low variance. Applies logit transformation to linear regression for binary probability prediction, handling continuous/categorical variables with high interpretability and simple structure (Hosmer et al., 2013).
- **Random forest classification (RF):** Intermediate bias-variance tradeoff. An ensemble method aggregating multiple decision trees via voting, improving accuracy and noise resistance for high-dimensional data (Breiman, 2001).
- **Extreme gradient boosting classification (XGB):** Low bias, high variance. An optimized implementation of the gradient boosting algorithm with successive decision trees, each correcting the errors of its predecessor to minimize the loss function and improve predictive performance. Compared to traditional gradient boosting decision trees, XGB introduces enhancements such as regularization, parallel computing, and custom loss function definition (Chen and Guestrin, 2016).

All models were implemented using scikit-learn 1.0.2 (Python 3.9.13), with hyperparameters optimized via grid search.

2.2.7. Evaluation metrics and hyperparameter tuning criteria

The performance of the classification models was evaluated using a confusion matrix, contrasting predicted outcomes ("Sufficient"/"Insufficient") against actual conditions. The “Positive” label indicated sufficient nitrification, while the “Negative” label indicated insufficient nitrification, as defined in Section 2.1 Key metrics included true positives (TP: correctly classified sufficient nitrification), false positives (FP: erroneously classified sufficient under insufficient conditions), false negatives (FN: insufficient misclassifications despite actual sufficiency), and true negatives (TN: accurate classified as insufficient). Section 2.2.1

Minimizing the FPR was crucial for ensuring safe effluent water quality. For instance, in a control system integrated with this nitrification monitoring model, when insufficient nitrification occurs, more air should be supplied. However, if an FP occurs, the model incorrectly predicts sufficient nitrification, leading the control system to refrain from adding additional oxygen and unsafe effluent unsuitable for reuse. Meanwhile, a higher TPR was necessary to detect sufficient nitrification under conventional operation conditions, reducing operational costs by preventing unnecessary oxygen supply triggered by FN.

Besides, optimizing solely for low FPR could severely reduce TPR, as indicated in previous studies (Reynaert et al., 2023; Salvia et al., 2021; Yang et al., 2019). Therefore, a balanced approach considering both TPR (Eq. 1) and FPR (Eq. 2) was adopted, with precision (Eq. 3) serving as a key optimization metric. Precision reflects the proportion of TP predictions among all positive predictions The TRP, FPR, and precision were calculated using the following equations:

$$TPR = \frac{TP}{TP + FN} \tag{1}$$

$$FPR = \frac{FP}{FP + TN} \tag{2}$$

$$Precision = \frac{TP}{TP + FP} \tag{3}$$

Although precision was prioritized during hyperparameter tuning, accuracy, representing the proportion of correct predictions out of all cases, was also used for model evaluation in test groups:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{4}$$

Finally, the stability of model performance was evaluated on the test dataset by calculating 95 % confidence intervals for accuracy, precision, recall, and F1 score using 1000-times bootstrap resampling, following standard practices in machine learning validation.

2.2.8. Post hoc interpretability

Despite the inherent interpretability of decision tree-based methods, complex models necessitate post hoc interpretation (Murdoch et al., 2019).

Feature importance quantifies the contributions of input variables, aiding model’s interpretability improvement and guiding data collection strategies for enhanced performance. In LR, feature coefficients are derived by minimizing the loss function (negative log-likelihood) using optimization methods such as gradient descent (Hastie et al., 2009). They indicate the strength and direction of each feature’s linear relationship with the target variable (Murphy, 2012). For RF, feature importance is assessed by the reduction in impurity (e.g., Gini index) when a feature is used to split a node. Scores are averaged across all trees, capturing the overall contribution of each feature to the model (Liaw and Wiener, 2002). The feature importance in XGB is typically calculated using the Gain method. This method sums up and normalizes the gains from all splits involving a feature to compute its importance score (Chen and Guestrin, 2016).

SHAP analysis was implemented to leverage game theory to assign each feature an importance value for specific predictions. SHAP

Các nghiên cứu trước đây cho thấy những mô hình đơn giản hơn thường có lợi thế khi áp dụng cho các tập dữ liệu nhỏ, bao gồm giảm nguy cơ quá khớp, cải thiện khả năng diễn giải và giảm yêu cầu tính toán (Reynaert et al., 2023; Wang et al., 2025). Với các tập dữ liệu nhỏ, không có yếu tố thời gian, những cấu trúc phức tạp như mạng nơ-ron nhân tạo có thể làm tăng nguy cơ quá khớp (Chiroma et al., 2019).

Do đó, ba thuật toán có thể diễn giải với các đặc tính thiên lệch–phương sai khác nhau đã được lựa chọn. Các mô hình hồi quy logistic và dựa trên cây quyết định thường được xem là có thể mô phỏng, tức là có thể diễn giải (Breiman et al., 2017; Murdoch et al., 2019).

- **Hồi quy logistic (LR):** Độ chệch cao, phương sai thấp. Áp dụng phép biến đổi logit vào hồi quy tuyến tính để dự đoán xác suất nhị phân, xử lý các biến liên tục/phân loại với khả năng diễn giải cao và cấu trúc đơn giản (Hosmer et al., 2013).
- **Phân loại bằng rừng ngẫu nhiên (RF):** Sự cân bằng giữa độ chệch và phương sai ở mức trung bình. Phương pháp tổ hợp tổng hợp nhiều cây quyết định, thông qua bỏ phiếu, cải thiện độ chính xác và khả năng chống nhiễu đối với dữ liệu nhiều chiều (Breiman, 2001).
- **Phân loại bằng tăng cường độ dốc cực đại (XGB):** Độ chệch thấp, phương sai cao. Một triển khai được tối ưu hóa của thuật toán tăng cường độ dốc bằng các cây quyết định nối tiếp, trong đó mỗi cây sửa các lỗi của cây trước đó nhằm tối thiểu hóa hàm mất mát và cải thiện hiệu suất dự đoán. So với các cây quyết định tăng cường độ dốc truyền thống, XGB có những cải tiến như điều chuẩn, tính toán song song và định nghĩa hàm mất mát tùy chỉnh (Chen và Guestrin, 2016).

Tất cả các mô hình được triển khai bằng scikit-learn 1.0.2 (Python 3.9.13), với các siêu tham số được tối ưu hóa thông qua tìm kiếm lưới.

2.2.7. Evaluation metrics and hyperparameter tuning criteria

Hiệu suất của các mô hình phân loại được đánh giá bằng ma trận nhầm lẫn, đối chiếu kết quả dự đoán ("Đủ"/"Không đủ") với điều kiện thực tế. Nhân “Dương tính” biểu thị quá trình nitrat hóa đủ, trong khi nhân “Âm tính” biểu thị quá trình nitrat hóa không đủ, như được định nghĩa trong Mục 2.1. Các chỉ số chính bao gồm dương tính thật (TP: phân loại chính xác quá trình nitrat hóa đủ), dương tính giả (FP: phân loại nhầm là đủ trong điều kiện không đủ), âm tính thật (TN: phân loại chính xác là không đủ dù thực tế là đủ) và âm tính giả (FN: phân loại chính xác là không đủ). Mục 2.2.1

Việc giảm thiểu FPR là yếu tố then chốt để đảm bảo chất lượng nước thải đầu ra an toàn. Chẳng hạn, trong một hệ thống điều khiển tích hợp mô hình giám sát quá trình nitrat hóa này, khi quá trình nitrat hóa không diễn ra đầy đủ, cần cấp thêm khí. Tuy nhiên, nếu xảy ra FP, mô hình dự đoán sai rằng quá trình nitrat hóa đã đầy đủ, khiến hệ thống điều khiển không cấp thêm oxy và tạo ra nước thải đầu ra không an toàn, không phù hợp để tái sử dụng. Trong khi đó, TPR cao hơn là cần thiết để phát hiện quá trình nitrat hóa đầy đủ trong các điều kiện vận hành thông thường, nhờ đó giảm chi phí vận hành bằng cách tránh cấp oxy không cần thiết do FN gây ra.

Ngoài ra, như các nghiên cứu trước đây đã chỉ ra (Reynaert et al., 2023; Salvia et al., 2021; Yang et al., 2019), việc chỉ tối ưu hóa để giảm FPR có thể làm giảm đáng kể TPR. Vì vậy, chúng tôi áp dụng cách tiếp cận cân bằng, xem xét cả TPR (Phương trình 1) và FPR (Phương trình 2), trong đó precision (Phương trình 3) là một chỉ số tối ưu hóa quan trọng. Precision phản ánh tỷ lệ dự đoán TP trong tổng số dự đoán dương tính. TPR, FPR và precision được tính bằng các phương trình sau:

$$TPR = \frac{TP}{TP + FN} \tag{1}$$

$$FPR = \frac{FP}{FP + TN} \tag{2}$$

$$Precision = \frac{TP}{TP + FP} \tag{3}$$

Mặc dù độ chính xác được ưu tiên trong quá trình tinh chỉnh siêu tham số, độ chính xác biểu thị tỷ lệ dự đoán đúng trên tổng số trường hợp cũng được sử dụng để đánh giá mô hình trong các nhóm kiểm thử:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{4}$$

Cuối cùng, độ ổn định của hiệu suất mô hình được đánh giá trên tập dữ liệu kiểm thử bằng cách tính khoảng tin cậy 95 % cho độ chính xác, độ chuẩn xác, độ bao phủ và điểm F1 thông qua phương pháp lấy mẫu bootstrap 1000 lần, theo các thông lệ tiêu chuẩn trong kiểm định học máy.

2.2.8. Post hoc interpretability

Mặc dù các phương pháp dựa trên cây quyết định vốn có tính dễ diễn giải, các mô hình phức tạp vẫn cần được diễn giải hậu nghiệm (Murdoch et al., 2019).

Độ quan trọng của đặc trưng định lượng mức đóng góp của các biến đầu vào, giúp cải thiện khả năng diễn giải của mô hình và định hướng các chiến lược thu thập dữ liệu nhằm nâng cao hiệu suất. Trong LR, các hệ số đặc trưng được xác định bằng cách tối thiểu hóa hàm mất mát (log-hợp lý âm) thông qua các phương pháp tối ưu hóa như hạ gradient (Hastie et al., 2009). Chúng biểu thị độ mạnh và chiều hướng của mối quan hệ tuyến tính giữa từng đặc trưng với biến mục tiêu (Murphy, 2012). Đối với RF, độ quan trọng của đặc trưng được đánh giá dựa trên mức giảm độ hỗn tạp (chẳng hạn như chỉ số Gini) khi đặc trưng đó được dùng để chia một nút. Điểm số được tính trung bình trên tất cả các cây, thể hiện mức đóng góp tổng thể của từng đặc trưng vào mô hình (Liaw and Wiener, 2002). Độ quan trọng của đặc trưng trong XGB thường được tính bằng phương pháp Gain. Phương pháp này cộng và chuẩn hóa mức tăng thu được từ tất cả các phép chia có sử dụng một đặc trưng để tính điểm độ quan trọng của đặc trưng đó (Chen and Guestrin, 2016).

Phân tích SHAP được triển khai nhằm tận dụng lý thuyết trò chơi để gán giá trị mức độ quan trọng cho từng đặc trưng trong các dự

values satisfy efficiency (prediction = base value + sum of feature contributions), symmetry, and additivity axioms, providing consistent local and global interpretability (Lundberg and Lee, 2017).

Furthermore, pairwise feature relationships were visualized via kernel density estimation (KDE) and pairwise feature plot. KDE could nonparametrically approximate continuous probability density functions by smoothing observed data points via symmetric kernel functions and bandwidth parameters (Scott, 2015). Pairwise feature plots, implemented as scatterplot matrices, reveal correlation and clustering patterns between features (Pekalska et al., 2005). It can help understand model classification performance by visualizing the confusion matrix (Waskom, 2021).

All analyses were implemented in Python 3.9.13 (Van Rossum and Drake, 2009).

3. Results analysis: data-driven model prediction

3.1. MBR performance and data collection

Phases 1–2 (no biocarriers) showed consistent COD (>85 % removal), NH₄⁺-N, and TN trends. Phase 1 effluent contained high NH₄⁺-N (14 ± 5 mg/L; 28 % removal) and TN (14 ± 2 mg/L; 23 % removal) with minimal NO₃⁻-N, indicating insufficient nitrification. Increasing aeration in Phase 2 improved NH₄⁺-N removal to 95 ± 1 % (effluent: 0.9 ± 0.2 mg/L). Meanwhile, the MLSS/MLVSS ratio stabilized at 0.92 ± 0.07 during Phase 1 and remained around 0.9 in Phase 2, indicating that most of the sludge consisted of organic fractions—a sign of healthy sludge conditions. In Phase 3, adding PVDF biocarriers to MBR-2 improved denitrification performance: TN removal reached 58 ± 21 %, compared to 34 ± 15 % in MBR-1 without biocarrier addition, while COD removal (90 ± 4 %) and NH₄⁺-N removal (94 ± 5 %) were maintained. The MBR-2 also exhibited reduced membrane fouling (TMP < 10 kPa) and higher biomass concentrations (MLSS: 2832 ± 831 mg/L; MLVSS: 2655 ± 806 mg/L) compared to the MBR-1 (MLSS: 2439 ± 648 mg/L; MLVSS: 2191 ± 543 mg/L). Overall, effluent COD and TN met EU Directive 91/271/EEC standards, though TN removal in Phase 3 was inconsistent, likely due to biofilm acclimatization. More detailed results are described in SI 2.

3.2. Input features determination

Following qualitative feature selection as shown in Section 2.2.2, nine input variables remained and were statistically evaluated. SI 3 identifies variables with significant correlations labeled with circles (p-value < 0.05) among the remaining input features. To simplify the model structure, only the influent flow rate was retained due to its similarity to the effluent flow rate, which demonstrated over 97 % flux recovery. Despite TMP’s weak correlation with nitrification, its inclusion could enhance model transferability by accounting for acyclic membrane fouling in long-term operations. Meanwhile, while the membrane cleaning record correlated with TMP, reflecting membrane maintenance needs, it was excluded to avoid material-specific biases. In addition, TN was omitted due to its marginal predictive contribution and impracticality for real-time monitoring. Although TN has certain correlation with the target output, TN sensors are costly and feature long measurement intervals (30–60 min, based on commercially available TN sensors), compared with sensors monitoring NO₃⁻-N and NH₄⁺-N.

Finally, six input features were selected for nitrification status prediction, including three operational factors (air flow rate, influent flow rate, and TMP) and three water quality variables (effluent COD, NO₃⁻-N, and NH₄⁺-N concentrations). This streamlined feature set balances model simplicity, accuracy, and field feasibility for nitrification monitoring.

3.3. Nitrification status prediction without biocarriers addition

Three classification models (LR, RF, XGB) were trained on datasets excluding biocarriers, with precision prioritized during hyperparameter optimization via stratified 5-fold cross-validation (SI 4). Table 1a summarizes prediction results using six selected input features, reporting accuracy, precision, TPR, and FPR for the test group, along with averaged results from cross-validation folds, illustrating the model’s predictive ability for nitrification status. Evaluation metrics for individual folds are provided in SI 5. Based on the limited data in the training (78) and test group (19), three key insights can be drawn from Table 1a:

- 1) LR, RF, and XGB achieved comparable test group performance (accuracy: 0.79–0.84). The confusion matrices for the test group predictions by each algorithm are provided in SI 6. This good fit could be attributed to the mechanistic relationship between the inputs and the target output, involving nitrogen conversion in the nitrification process (Huang et al., 2022; Omar et al., 2024).
- 2) With considering the superior performance in validation groups (accuracy: 0.90–0.91), RF and XGB underperformed LR in the test group, indicating potential overfitting risks with limited data.
- 3) Additionally, the small data limited the ability to fully evaluate the performance difference among algorithms with different complexity, hard to assess the influence of model complexity on TPR and FPR.

These results preliminarily support the effectiveness of the ML algorithm in predicting the nitrification status through TMP, air flow rate, influent flow rate, and effluent COD, NO₃⁻-N, and NH₄⁺-N concentrations.

However, compared with the prediction accuracy on the validation group, the decline of TPR in the test group can be attributed to several factors. One primary reason is the issue of class imbalance. In the training set, negative label samples accounted for 64.10 %, whereas in the test set, this proportion decreased to 57.89 %. Although this indicated a slightly lower proportion of negative Label samples in the test set, the imbalance remained significant. Such an imbalance biases the model toward the dominant class (negative

các giá trị thỏa mãn các tiên đề về tính hiệu quả (giá trị cơ sở dự đoán =, tổng đóng góp của các đặc trưng +), tính đối xứng v à tính cộng, giúp cung cấp khả năng diễn giải nhất quán ở cả cấp độ cục bộ lẫn toàn cục (Lundberg và Lee, 2017).

Hơn nữa, các mối quan hệ giữa từng cặp đặc trưng được trực quan hóa bằng phương pháp ước lượng mật độ hạt nhân (KDE) và biểu đồ đặc trưng theo cặp. KDE có thể xấp xỉ phi tham số các hàm mật độ xác suất liên tục bằng cách làm trơn các điểm dữ liệu quan sát được thông qua các hàm hạt nhân đối xứng và tham số băng thông (Scott, 2015). Biểu đồ đặc trưng theo cặp, được triển khai dưới dạng ma trận biểu đồ phân tán, cho thấy các kiểu tương quan và phân cụm giữa các đặc trưng (Pekalska và cộng sự, 2005). Biểu đồ này có thể giúp hiểu hiệu suất phân loại của mô hình thông qua việc trực quan hóa ma trận nhầm lẫn (Waskom, 2021).

Tất cả các phân tích đều được triển khai bằng Python 3.9.13 (Van Rossum và Drake, 2009).

3. Phân tích kết quả: dự đoán bằng mô hình dựa trên dữ liệu

3.1. MBR performance and data collection

Các Giai đoạn 1–2 (không có giá thể sinh học) cho thấy các xu hướng COD (>85 % loại bỏ), NH₄⁺-N và TN nhất quán. Nước thải đầu ra ở Giai đoạn 1 có hàm lượng NH₄⁺-N cao (14 ± 5 mg/L; loại bỏ 28 %) và TN (14 ± 2 mg/L; loại bỏ 23 %), trong khi NO₃⁻-N ở mức tối thiểu, cho thấy quá trình nitrat hóa chưa đủ. Tăng cường sục khí ở Giai đoạn 2 giúp nâng hiệu suất loại bỏ NH₄⁺-N lên 95 ± 1 % (nồng độ trong nước thải đầu ra: 0.9 ± 0.2 mg/L). Trong khi đó, tỷ lệ MLSS/MLVSS ổn định ở mức 0.92 ± 0.07 trong Giai đoạn 1 và duy trì khoảng 0.9 trong Giai đoạn 2, cho thấy phần lớn bùn gồm các thành phần hữu cơ—dấu hiệu của tình trạng bùn khỏe mạnh. Ở Giai đoạn 3, việc bổ sung giá thể sinh học PVDF vào MBR-2 đã cải thiện hiệu suất khử nitơ: hiệu suất loại bỏ TN đạt 58 ± 21 %, so với 34 ± 15 % ở MBR-1 không bổ sung giá thể sinh học, trong khi hiệu suất loại bỏ COD (90 ± 4 %) và NH₄⁺-N (94 ± 5 %) vẫn được duy trì. MBR-2 cũng có hiện tượng tắc màng giảm (TMP < 10 kPa) và nồng độ sinh khối cao hơn (MLSS: 2832 ± 831 mg/L; MLVSS: 2655 ± 806 mg/L) so với MBR-1 (MLSS: 2439 ± 648 mg/L; MLVSS: 2191 ± 543 mg/L). Nhìn chung, COD và TN trong nước thải đầu ra đáp ứng các tiêu chuẩn của Chỉ thị EU 91/271/EEC, mặc dù hiệu suất loại bỏ TN ở Giai đoạn 3 không nhất quán, có khả năng do màng sinh học đang thích nghi. Kết quả chi tiết hơn được trình bày trong SI 2.

3.2. Input features determination

Sau khi lựa chọn đặc trưng định tính như trình bày trong Mục 2.2.2, còn lại chín biến đầu vào và chúng được đánh giá về mặt thống kê. SI 3 xác định các biến có tương quan đáng kể, được đánh dấu bằng vòng tròn (giá trị p < 0.05) trong số các đặc trưng đầu vào còn lại. Để đơn giản hóa cấu trúc mô hình, chỉ giữ lại lưu lượng dòng vào do tương đồng với lưu lượng dòng ra, vốn cho thấy mức thu hồi thông lượng trên 97%. Mặc dù TMP có tương quan yếu với quá trình nitrat hóa, việc đưa biến này vào có thể cải thiện khả năng chuyển giao của mô hình bằng cách tính đến hiện tượng bám bẩn màng không theo chu kỳ trong quá trình vận hành dài hạn. Trong khi đó, dù hồ sơ vệ sinh màng có tương quan với TMP, phản ánh nhu cầu bảo trì màng, biến này vẫn bị loại bỏ để tránh sai lệch đặc thù vật liệu. Ngoài ra, TN bị loại do đóng góp dự báo không đáng kể và không phù hợp để giám sát thời gian thực. Mặc dù TN có tương quan nhất định với đầu ra mục tiêu, các cảm biến TN có giá thành cao và khoảng thời gian đo dài (30–60 phút, dựa trên các cảm biến TN hiện có trên thị trường) so với các cảm biến giám sát NO₃⁻-N và NH₄⁺-N.

Cuối cùng, sáu đặc trưng đầu vào được lựa chọn để dự đoán trạng thái nitrat hóa, gồm ba yếu tố vận hành (lưu lượng khí, lưu lượng nước đầu vào và TMP) cùng ba biến chất lượng nước (nồng độ COD, NO₃⁻-N và NH₄⁺-N trong nước đầu ra). Bộ đặc trưng tinh gọn này cân bằng giữa tính đơn giản, độ chính xác của mô hình và tính khả thi khi triển khai thực tế để theo dõi quá trình nitrat hóa.

3.3. Nitrification status prediction without biocarriers addition


Ba mô hình phân loại (LR, RF, XGB) được huấn luyện trên các bộ dữ liệu không bao gồm giá thể sinh học, trong đó độ chính xác được ưu tiên khi tối ưu hóa siêu tham số thông qua kiểm định chéo phân tầng 5 lần (SI 4). Bảng 1a tóm tắt kết quả dự đoán sử dụng sáu đặc trưng đầu vào được chọn, báo cáo độ chính xác tổng thể, độ chính xác, TPR và FPR của nhóm kiểm tra, cùng với kết quả trung bình từ các phần kiểm định chéo, qua đó thể hiện khả năng dự đoán trạng thái nitrat hóa của mô hình. Các chỉ số đánh giá cho từng phần kiểm định được trình bày trong SI 5. Dựa trên dữ liệu hạn chế ở nhóm huấn luyện (78) và nhóm kiểm tra (19), có thể rút ra ba nhận định chính từ Bảng 1a:

- 1) LR, RF và XGB đạt hiệu suất tương đương trên nhóm kiểm tra (độ chính xác: 0.79–0.84). Ma trận nhầm lẫn của các dự đoán trên nhóm kiểm tra do từng thuật toán đưa ra được trình bày trong SI 6. Kết quả khớp tốt này có thể được lý giải bởi mối quan hệ cơ chế giữa các biến đầu vào và đầu ra mục tiêu, liên quan đến quá trình chuyển hóa nitơ trong quá trình nitrat hóa (Huang et al., 2022; Omar et al., 2024).
- 2) Xét đến hiệu suất vượt trội trên các nhóm xác thực (độ chính xác: 0.90–0.91), RF và XGB có hiệu suất kém hơn LR trên nhóm kiểm tra, cho thấy nguy cơ quá khớp tiềm ẩn khi dữ liệu còn hạn chế.
- 3) Ngoài ra, dữ liệu hạn chế khiến việc đánh giá đầy đủ sự khác biệt về hiệu suất giữa các thuật toán có độ phức tạp khác nhau trở nên khó khăn, cũng như khó đánh giá ảnh hưởng của độ phức tạp mô hình đến TPR và FPR.

Những kết quả này bước đầu cho thấy thuật toán ML có hiệu quả trong việc dự đoán trạng thái nitrat hóa thông qua TMP, lưu lượng khí, lưu lượng dòng vào và nồng độ COD, NO₃⁻-N và NH₄⁺-N trong dòng ra.


Tuy nhiên, so với độ chính xác dự đoán trên nhóm xác thực, sự suy giảm TPR ở nhóm kiểm tra có thể được quy cho một số yếu tố. Một nguyên nhân chính là tình trạng mất cân bằng lớp. Trong tập huấn luyện, các mẫu mang nhãn âm chiếm 64.10 %, trong khi ở tập kiểm tra, tỷ lệ này giảm xuống còn 57.89 %. Mặc dù điều này cho thấy tỷ lệ mẫu mang nhãn âm trong tập kiểm tra thấp hơn đôi chút, tình trạng mất cân bằng vẫn đáng kể. Sự mất cân bằng như vậy khiến mô hình thiên về lớp chiếm ưu thế (lớp âm)

Table 1
Statistical evaluation of predicting test group with/without adding biocarriers with feature importance analysis of trained model with kernel density estimates (KDE).



* “Validation (Ave)”: the average value of stratified 5-fold validation groups
** The feature coefficient of LR was calculated to represent the feature importance in logistics regression-based prediction.

Bảng 1 Đánh giá thống kê khả năng dự đoán nhóm thử nghiệm có/không bổ sung giá thể sinh học, kèm phân tích mức độ quan trọng của các đặc trưng của mô hình đã huấn luyện bằng phương pháp ước lượng mật độ hạt nhân (KDE).



* “Độ chính xác xác thực (trung bình)”: giá trị trung bình của các nhóm xác thực phân tầng 5-fold ** Hệ số đặc trưng của LR được tính để biểu thị mức độ quan trọng của đặc trưng trong dự đoán dựa trên hồi quy logistic.

label), reducing its ability to accurately predict positive samples and resulting in TPR reduction in the test group. The problem was evident in all algorithms, where validation accuracy was even over 0.1 higher than that of the test group (Table 1a), highlighting the model's susceptibility to overfitting to class proportions during the training phase due to the small dataset.

Moreover, feature distribution shifts exacerbated TPR declines and reflected underlying overfitting to training feature dependencies. In the training set, 58.67 % of the samples had an air flow rate of 2, and 41.33 % had an air flow rate of 6. In the test set, these proportions shifted to 52.63 % and 47.37 %, respectively. While this shift was relatively small, it could still influence the model's generalization ability, particularly as the air flow rate is critical for predicting nitrification status. KDE plots (Table 1b) demonstrated that air flow rate distributions between positive and negative classes were well separated, which magnified the effect of even subtle distribution shifts. This explains why the RF and XGB models, although exhibiting high validation accuracy (0.9114 and 0.9063, respectively), suffered noticeable reductions in TPR during testing (0.6250 for RF and 0.7500 for XGB). Such discrepancies suggest that the models captured training-specific patterns too rigidly, a hallmark of overfitting.

Additionally, the scarcity of positive samples in the test set exacerbated overfitting risks. Limited training data forced models to overfit the dominant negative class, compromising their ability to generalize to unseen positive cases. Consequently, TPR declined during testing, as models struggled to correctly classify underrepresented positive samples. This phenomenon was particularly evident in RF, where precision remained relatively high (0.8333) but TPR declined sharply to 0.6250 in the test set. The discrepancy between validation and test outcomes demonstrated that RF overfit to negative-class features during training, compromising its predictive balance across both classes.

In contrast, the FPR remained stable across training and test sets. Such stability stemmed from the relatively uniform distribution of negative samples. As explained before, the training set's high negative sample proportion enhanced model sensitivity to negative class





Fig. 4. SHAP analysis: beeswarm (a: LR; b: RF; c: XGB) and waterfall (d: LR; e: RF; f: XGB) plot.

nhấn), làm giảm khả năng dự đoán chính xác các mẫu dương tính và dẫn đến giảm TPR trong nhóm kiểm tra. Vấn đề này thể hiện rõ ở tất cả các thuật toán, trong đó độ chính xác trên tập xác thực thậm chí còn cao hơn tập kiểm tra hơn 0,1 (Bảng 1a), c ho thấy mô hình dễ bị quá khớp với tỷ lệ các lớp trong giai đoạn huấn luyện do tập dữ liệu nhỏ.

Hơn nữa, sự dịch chuyển trong phân phối đặc trưng làm mức suy giảm TPR trầm trọng hơn và phản ánh tình trạng khớp quá mức tiềm ẩn với các mối phụ thuộc giữa các đặc trưng trong tập huấn luyện. Trong tập huấn luyện, 58,67 % mẫu có lưu lượng khí là 2 và 41,33 % có lưu lượng khí là 6. Trong tập kiểm tra, các tỷ lệ này lần lượt chuyển thành 52,63 % và 47,37 %. Dù mức dịch chuyển tương đối nhỏ, nó vẫn có thể ảnh hưởng đến khả năng khái quát hóa của mô hình, đặc biệt vì lưu lượng khí là yếu tố then chốt để dự đoán trạng thái nitrat hóa. Các biểu đồ KDE (Bảng 1b) cho thấy phân phối lưu lượng khí giữa các lớp dương tính và âm tính được tách biệt rõ rệt, làm gia tăng tác động của ngay cả những dịch chuyển phân phối nhỏ. Điều này giải thích vì sao các mô hình RF và XGB, dù đạt độ chính xác xác thực cao (lần lượt là 0.9114 và 0.9063), vẫn bị giảm TPR đáng kể khi kiểm tra (0.6250 đối với RF và 0.7500 đối với XGB). Những chênh lệch này cho thấy các mô hình đã nắm bắt quá cứng nhắc những mẫu hình đặc thù của tập huấn luyện, một dấu hiệu điển hình của hiện tượng khớp quá mức.

Ngoài ra, sự khan hiếm mẫu dương tính trong tập kiểm thử làm gia tăng nguy cơ quá khớp. Dữ liệu huấn luyện hạn chế buộc các mô hình quá khớp với lớp âm tính chiếm ưu thế, làm suy giảm khả năng khái quát hóa cho các trường hợp dương tính chưa từng gặp. Do đó, TPR giảm trong quá trình kiểm thử, vì các mô hình gặp khó khăn trong việc phân loại chính xác những mẫu dương tính ít đại diện. Hiện tượng này đặc biệt rõ ở RF: độ chính xác vẫn tương đối cao (0.8333), nhưng TPR giảm mạnh xuống 0.6250 trong tập kiểm thử. Sự chênh lệch giữa kết quả xác thực và kiểm thử cho thấy RF đã quá khớp với các đặc trưng của lớp âm tính trong quá trình huấn luyện, làm suy giảm sự cân bằng dự đoán giữa cả hai lớp.

Ngược lại, FPR vẫn ổn định giữa tập huấn luyện và tập kiểm tra. Sự ổn định này bắt nguồn từ phân phối tương đối đồng đều của các mẫu âm tính. Như đã giải thích trước đó, tỷ lệ mẫu âm tính cao trong tập huấn luyện đã làm tăng độ nhạy của mô hình đối với lớp âm tính.



Hình 4. Phân tích SHAP: biểu đồ beeswarm (a: LR; b: RF; c: XGB) và biểu đồ thác nước (d: LR; e: RF; f: XGB).

detection. Therefore, the model maintained robust negative class identification when the test set’s negative sample ratio decreased slightly, sustaining low FPR levels. However, this apparent stability should not obscure the underlying problem: the divergence between high validation performance and degraded test performance across all three models (Table 1a) clearly demonstrated that overfitting was a systemic issue. The models effectively learned training-specific distributions rather than robust, generalizable patterns required for reliable deployment.

In summary, the decline in TPR in the test set was primarily due to class imbalance, feature distribution shifts, and the limited number of “positive” label samples, which increased the overfitting risk. Conversely, the stability of FPR could be attributed to the consistent distribution of negative samples across the training and test sets. These results underscore the challenges in ensuring model robustness under data distribution shifts — a critical consideration for deploying ML in dynamic wastewater treatment environments.

Feature importance analysis elucidated prediction mechanisms and guided data collection strategies. Table 1b shows importance scores with Kernel Density Estimates (KDE) for LR, RF, and XGB models. In LR, regression coefficients indicated feature-prediction directionality/magnitude. For RF and XGB, importance scores quantified feature contributions. KDE visualized probability density distributions for Predicted Positive (red) and Predicted Negative (blue) classes. Curve peaks revealed value concentration regions (e.g., Eff_COD peaked at ~30 for Positive class). Class discriminative ability was assessed through KDE overlap: minimal overlap indicated strong separability (e.g., Air Flow Rate showed moderate separation). Curve width reflected feature variance—narrow curves denoted consistent class values, while broader curves indicated higher variability.

Feature importance and KDE analysis confirmed effluent $\text{NH}_4^+\text{-N}$ and $\text{NO}_3^-\text{-N}$ as primary predictors of nitrification status. Although mechanistically relevant, influent flow rate (11.7–20.6 ML/min) and air flow rate (2–6 Lpm) showed limited contributions due to low operational variability. Effluent COD likewise had a minor impact, evidenced by its lower coefficient of variance (55.25 %) versus $\text{NH}_4^+\text{-N}$ (93.82 %) and $\text{NO}_3^-\text{-N}$ (101.72 %)—calculated as standard deviation relative to mean. This variability disparity explained differential feature importance.

SI 7 and 8 display pairwise plots across models and feature importance quantification across validation groups respectively, which confirmed effluent $\text{NO}_3^-\text{-N}/\text{NH}_4^+\text{-N}$ as primary predictors, aligning with their biochemical centrality in nitrification. However, XGB validation groups showed unexpected prominence of stable influent and airflow rates over N-species. This stemmed from XGB’s boosting mechanism: sequential trees prioritize features correcting predecessor errors, dynamically weighting features during incremental optimization (Bentéjac et al., 2021; Nguyen et al., 2024). Such adaptability could enhance model flexibility across data groups but may inflate transient feature importance and overfitting risks.

Fig. 4 illustrates the SHAP analysis results for three predictive models—LR, RF, and XGB—including global importance (beeswarm plots, Fig. 4a–c) and instance-level decomposition (waterfall plots, Fig. 4d–f). The beeswarm plots revealed consistent feature importance rankings across all models: Effluent $\text{NH}_4^+\text{-N}$ and Effluent $\text{NO}_3^-\text{-N}$ dominate, followed by Effluent COD and TMP, suggesting robust, model-agnostic relevance of nitrogen and organic matter indicators in treatment performance prediction, consistent with the results of feature importance analysis.

More nuanced insights arose from the waterfall plots. In the LR model (Fig. 4d), the output was strongly driven by a single high $\text{NH}_4^+\text{-N}$ value (+2.84), counteracted by negative contributions from $\text{NO}_3^-\text{-N}$ and COD, reflecting the additive nature of linear models. Such strong reliance on a single dominant feature highlighted an overfitting risk: when $\text{NH}_4^+\text{-N}$ deviates from training patterns, the model struggles to generalize, explaining the decline in test TPR. In contrast, the RF model (Fig. 4e) showed a more balanced contribution from multiple features, with lower-magnitude but distributed impacts, consistent with ensemble decision averaging. The XGB model (Fig. 4f) exhibited stronger nonlinearity and interaction effects. Here, COD and $\text{NO}_3^-\text{-N}$ jointly exerted dominant negative influence, while $\text{NH}_4^+\text{-N}$ contributed positively but was insufficient to overcome process stress signals, resulting in a negative prediction. Nevertheless, the complexity of these nonlinear feature interactions in XGB, combined with limited training samples, raised the likelihood of memorizing dataset-specific noise, another hallmark of overfitting. Notably, TMP and Air Flow Rate emerged as minor but non-negligible modulators, indicating sensitivity to operational states.

Furthermore, combined with the analysis of the effluent concentration of $\text{NH}_4^+\text{-N}$ and $\text{NO}_3^-\text{-N}$, which had the main influence on the prediction, and by tracing back the characteristics in the data set, it was found that false positives mainly occurred when the effluent $\text{NO}_3^-\text{-N}$ was 9 mg/L and $\text{NH}_4^+\text{-N}$ was 2 mg/L. That is, the effluent quality showed a relatively obvious sufficient nitrification potential, but the reactor was in an insufficient nitrification state simultaneously. Compared with the output labels in the training dataset, this was mainly because when the effluent $\text{NO}_3^-\text{-N}$ concentration was greater than 9 mg/L and the $\text{NH}_4^+\text{-N}$ concentration was less than 2 mg/L, the data labels were all positive, that is, sufficient nitrification, which in turn affected the prediction in the test set. This phenomenon indicated that the models overfitted the label distribution patterns in the training set and thus misclassified borderline cases in the test set, exposing a lack of generalization.

The SHAP analysis revealed that effluent $\text{NH}_4^+\text{-N}$ and $\text{NO}_3^-\text{-N}$ were the most influential predictors across all models, underscoring their critical role as indicators of nitrification performance in MBR systems. This suggested that real-time monitoring of these nitrogen species—rather than relying only on conventional parameters like TMP, DO in the reactor—could enhance operational control while monitoring essential effluent water quality parameters. Specifically, the identification of borderline cases (e.g., simultaneous $\text{NH}_4^+\text{-N} \approx 2$ mg/L and $\text{NO}_3^-\text{-N} \approx 9$ mg/L where false positives occur) highlighted process instability regions that were prone to misclassification. Such thresholds could inform early-warning systems: when nitrogen levels approach these critical values, the intelligent control system should proactively adjust aeration rates (the “Air Flow Rate” SHAP contributions support its modulating role) or check sludge retention time to prevent nitrification failure. Moreover, multi-parameter synergistic management is essential to maintain robust nitrification and avoid model overfitting to transient noise. These insights bridge data-driven predictions with actionable process strategies, promoting adaptive control in MBR operations.

Therefore, based on this proof of concept, further experiments should be designed to investigate more variable influent water

khả năng phát hiện. Do đó, mô hình duy trì khả năng nhận diện lớp âm tính vững chắc khi tỷ lệ mẫu âm tính trong tập kiểm tra giảm nhẹ, qua đó giữ cho FPR ở mức thấp. Tuy nhiên, không nên để sự ổn định bề ngoài này che khuất vấn đề cốt lõi: sự chênh lệch giữa hiệu suất cao trên tập xác thực và hiệu suất suy giảm trên tập kiểm tra ở cả ba mô hình (Bảng 1a) cho thấy rõ hiện tượng quá khớp là một vấn đề mang tính hệ thống. Các mô hình đã học hiệu quả những phân phối đặc thù của tập huấn luyện thay vì những mẫu hình vững chắc, có khả năng khái quát hóa cần thiết để triển khai đáng tin cậy.

Tóm lại, sự suy giảm TPR trong tập kiểm thử chủ yếu là do mất cân bằng lớp, sự dịch chuyển phân phối đặc trưng và số lượng mẫu được gán nhãn “dương tính” hạn chế, làm tăng nguy cơ quá khớp. Ngược lại, FPR ổn định có thể là nhờ phân phối nhất quán của các mẫu âm tính trong tập huấn luyện và tập kiểm thử. Những kết quả này nhấn mạnh các thách thức trong việc đảm bảo tính vững chắc của mô hình khi phân phối dữ liệu thay đổi — một yếu tố cần cân nhắc then chốt khi triển khai ML trong các môi trường xử lý nước thải biến động.

Phân tích tầm quan trọng của đặc trưng giúp làm sáng tỏ cơ chế dự đoán và định hướng chiến lược thu thập dữ liệu. Bảng 1b thể hiện điểm tầm quan trọng cùng với Ước lượng mật độ Kernel (KDE) cho các mô hình LR, RF và XGB. Trong LR, các hệ số hồi quy cho biết hướng và mức độ ảnh hưởng của đặc trưng đến dự đoán. Với RF và XGB, điểm tầm quan trọng định lượng mức đóng góp của các đặc trưng. KDE trực quan hóa phân bố mật độ xác suất của các lớp Dự đoán dương (đỏ) và Dự đoán âm (xanh lam). Các đỉnh đường cong cho thấy những vùng tập trung giá trị (ví dụ: Eff_COD đạt đỉnh tại ~30 ở lớp Dương). Khả năng phân biệt các lớp được đánh giá thông qua mức độ chồng lấp của KDE: chồng lấp tối thiểu cho thấy khả năng phân tách tốt (ví dụ: Lưu lượng khí cho thấy mức phân tách vừa phải). Độ rộng đường cong phản ánh phương sai của đặc trưng—đường cong hẹp biểu thị các giá trị nhất quán giữa các lớp, trong khi đường cong rộng hơn cho thấy mức biến thiên cao hơn.

Phân tích mức độ quan trọng của đặc trưng và KDE xác nhận $\text{NH}_4^+\text{-N}$ và $\text{NO}_3^-\text{-N}$ trong nước thải đầu ra là các yếu tố dự báo chính về trạng thái nitrat hóa. Mặc dù có ý nghĩa về mặt cơ chế, lưu lượng nước đầu vào (11.7–20.6 ML/min) và lưu lượng khí (2–6 Lpm) đóng góp hạn chế do mức độ biến động thấp trong vận hành. Tương tự, COD trong nước thải đầu ra có tác động nhỏ, thể hiện qua hệ số biến thiên thấp hơn (55.25 %) so với $\text{NH}_4^+\text{-N}$ (93.82 %) và $\text{NO}_3^-\text{-N}$ (101.72 %)—được tính bằng độ lệch chuẩn chia cho giá trị trung bình. Sự chênh lệch về mức độ biến động này giải thích sự khác biệt về mức độ quan trọng của các đặc trưng.

SI 7 và 8 lần lượt trình bày biểu đồ theo từng cặp giữa các mô hình và định lượng mức độ quan trọng của đặc trưng giữa các nhóm xác thực, qua đó xác nhận $\text{NO}_3^-\text{-N}/\text{NH}_4^+\text{-N}$ trong nước thải đầu ra là các biến dự đoán chính, phù hợp với vai trò trung tâm về mặt sinh hóa của chúng trong quá trình nitrat hóa. Tuy nhiên, ở các nhóm xác thực của XGB, lưu lượng nước đầu vào và lưu lượng khí ổn định lại nổi bật hơn các dạng nhiễu, trái với dự kiến. Điều này bắt nguồn từ cơ chế boosting của XGB: các cây tuần tự ưu tiên những đặc trưng giúp khắc phục lỗi của cây trước đó, đồng thời điều chỉnh đóng trọng số đặc trưng trong quá trình tối ưu hóa lặp tăng dần (Bentéjac et al., 2021; Nguyen et al., 2024). Khả năng thích ứng này có thể tăng tính linh hoạt của mô hình giữa các nhóm dữ liệu, nhưng cũng có thể làm phóng đại tầm quan trọng nhất thời của đặc trưng và tăng nguy cơ quá khớp.

Hình 4 minh họa kết quả phân tích SHAP cho ba mô hình dự đoán—LR, RF và XGB—bao gồm mức độ quan trọng tổng thể (biểu đồ beeswarm, Hình 4a–c) và phân rã ở cấp độ từng trường hợp (biểu đồ waterfall, Hình 4d–f). Các biểu đồ beeswarm cho thấy thứ hạng mức độ quan trọng của các đặc trưng nhất quán ở tất cả các mô hình: $\text{NH}_4^+\text{-N}$ trong nước thải đầu ra và $\text{NO}_3^-\text{-N}$ trong nước đầu ra chiếm ưu thế, tiếp theo là COD trong nước đầu ra và TMP, cho thấy các chỉ số nitơ và chất hữu cơ có mức độ liên quan vững chắc, không phụ thuộc vào mô hình, trong dự đoán hiệu suất xử lý; điều này phù hợp với kết quả phân tích mức độ quan trọng của đặc trưng.

Những hiểu biết sâu sắc hơn được rút ra từ các biểu đồ waterfall. Trong mô hình LR (Hình 4d), đầu ra chịu ảnh hưởng mạnh từ một giá trị $\text{NH}_4^+\text{-N}$ cao duy nhất (+2.84), bị đối trọng bởi các đóng góp âm từ $\text{NO}_3^-\text{-N}$ và COD, phản ánh tính chất cộng của các mô hình tuyến tính. Sự phụ thuộc quá lớn vào một đặc trưng chi phối duy nhất làm nổi bật nguy cơ quá khớp: khi $\text{NH}_4^+\text{-N}$ lệch khỏi các mẫu trong tập huấn luyện, mô hình gặp khó khăn trong việc khái quát hóa, qua đó giải thích sự suy giảm TPR trên tập kiểm tra. Ngược lại, mô hình RF (Hình 4e) cho thấy đóng góp cân bằng hơn từ nhiều đặc trưng, với tác động có độ lớn thấp hơn nhưng phân bố rộng hơn, phù hợp với cơ chế lấy trung bình các quyết định trong mô hình tổ hợp. Mô hình XGB (Hình 4f) thể hiện tính phi tuyến và các hiệu ứng tương tác mạnh hơn. Trong trường hợp này, COD và $\text{NO}_3^-\text{-N}$ cùng tạo ra ảnh hưởng âm chi phối, trong khi $\text{NH}_4^+\text{-N}$ đóng góp theo chiều dương nhưng không đủ để vượt qua các tín hiệu căng thẳng của quy trình, dẫn đến dự đoán âm. Tuy nhiên, sự phức tạp của các tương tác phi tuyến giữa các đặc trưng trong XGB, kết hợp với số lượng mẫu huấn luyện hạn chế, làm tăng khả năng mô hình ghi nhớ những đặc thù của tập dữ liệu — một dấu hiệu khác của hiện tượng quá khớp. Đáng chú ý, TMP và Lưu lượng khí nổi lên như những yếu tố điều biến nhỏ nhưng không thể bỏ qua, cho thấy mô hình nhạy cảm với các trạng thái vận hành.

Hơn nữa, kết hợp với phân tích nồng độ $\text{NH}_4^+\text{-N}$ và $\text{NO}_3^-\text{-N}$ trong nước đầu ra—những yếu tố có ảnh hưởng chính đến kết quả dự đoán—và truy xét các đặc điểm trong tập dữ liệu, chúng tôi nhận thấy các trường hợp dương tính giả chủ yếu xảy ra khi nồng độ $\text{NO}_3^-\text{-N}$ trong nước đầu ra là 9 mg/L và nồng độ $\text{NH}_4^+\text{-N}$ là 2 mg/L. Nói cách khác, chất lượng nước đầu ra cho thấy tiềm năng nitrat hóa đầy đủ tương đối rõ rệt, nhưng đồng thời là phản ứng lại ở trạng thái nitrat hóa không đầy đủ. So với các nhãn đầu ra trong tập dữ liệu huấn luyện, nguyên nhân chủ yếu là do khi nồng độ $\text{NO}_3^-\text{-N}$ trong nước đầu ra lớn hơn 9 mg/L và nồng độ $\text{NH}_4^+\text{-N}$ nhỏ hơn 2 mg/L, tất cả các nhãn dữ liệu đều là nhãn dương tính, tức là nitrat hóa đầy đủ; điều này đã ảnh hưởng đến kết quả dự đoán trên tập kiểm thử. Hiện tượng này cho thấy các mô hình đã quá khớp với các quy luật phân bố nhãn trong tập huấn luyện, dẫn đến phân loại sai các trường hợp ranh giới trong tập kiểm thử và bộc lộ khả năng khái quát hóa hạn chế.

Phân tích SHAP cho thấy $\text{NH}_4^+\text{-N}$ và $\text{NO}_3^-\text{-N}$ trong nước thải đầu ra là các biến dự báo có ảnh hưởng lớn nhất trong tất cả các mô hình, nhấn mạnh vai trò then chốt của chúng với tư cách là các chỉ báo về hiệu suất nitrat hóa trong hệ thống MBR. Điều này cho thấy việc giám sát theo thời gian thực các dạng nitơ này—thay vì chỉ dựa vào các thông số thông thường như TMP và DO trong bể phản ứng—có thể cải thiện khả năng kiểm soát vận hành, đồng thời theo dõi các thông số chất lượng nước đầu ra thiết yếu. Cụ thể, việc xác định các trường hợp cận biên (ví dụ: $\text{NH}_4^+\text{-N} \approx 2$ mg/L và $\text{NO}_3^-\text{-N} \approx 9$ mg/L đồng thời, khi xảy ra dương tính giả) làm nổi bật các vùng bất ổn của quá trình, nơi dễ xảy ra phân loại sai. Các ngưỡng này có thể hỗ trợ xây dựng hệ thống cảnh báo sớm: khi nồng độ nitơ tiến gần các giá trị tới hạn này, hệ thống điều khiển thông minh cần chủ động điều chỉnh lưu lượng khí sục (các đóng góp SHAP cho “Lưu lượng khí” cho thấy vai trò điều tiết của thông số này) hoặc kiểm tra thời gian lưu bùn để ngăn ngừa sự cố nitrat hóa. Hơn nữa, quản lý hiệp đồng nhiều thông số là thiết yếu để duy trì quá trình nitrat hóa ổn định và tránh hiện tượng mô hình quá khớp với nhiễu nhất thời. Những hiểu biết này kết nối các dự đoán dựa trên dữ liệu với các chiến lược vận hành khả thi, thúc đẩy điều khiển thích ứng trong hoạt động của hệ thống MBR.

Do đó, dựa trên bằng chứng về tính khả thi này, cần thiết kể thêm các thí nghiệm để nghiên cứu nguồn nước đầu vào có độ biến thiên

quality based on the range of gray water quality characteristics summarized in existing literature to simulate the highly variable characteristics of gray water quality. Meanwhile, collecting different influent flow rates, that is, the water quality variation under different HRTs, would allow further analysis of the lag relationship between the effluent ammonia nitrogen and nitrate nitrogen concentrations, and the reaction state in the reactor. Furthermore, designing time series data collection, such as collecting and measuring water samples every hour, could help determine the time series relationship between the effluent water quality changes and the reaction state in the reactor at the same time from a more dynamic perspective. In summary, broader datasets with more dynamics are necessary to further test the feasibility of using effluent quality to predict or even control the reaction state inside the reactor. Such expanded and diversified datasets are also critical to mitigate current overfitting risks and improve the models’ robustness for real-world applications. [Sections 4.1 and 4.2](#) further discuss the impact of data limitation and input feature on the existing model framework.

3.4. Cross-scenario test

Building upon the demonstrated efficacy of the model in conventional nitrification systems ([Section 3.3](#)), its cross-scenario prediction capability was further evaluated in MBRs incorporating biocarriers for enhanced simultaneous nitrification-denitrification. The base model trained on no-biocarrier operations was directly tested to predict nitrification status in biocarrier-augmented systems without retraining.

As shown in [Table 1a](#), the cross-condition testing yielded three principal observations:

- 1) Compared with prediction performance of the test group without biocarriers, the RF model exhibited improvement in both accuracy ($0.79 \rightarrow 0.83$) and precision ($0.83 \rightarrow 0.87$) under biocarrier-amended conditions, suggesting superior adaptability to simultaneous nitrification-denitrification system complexities.
- 2) TPRs of all these three algorithms were greater than or equal to 0.8, especially that of LR, which reached 1, showing a significant increase compared with the test group without adding biological carriers.
- 3) Corresponding FPR values rose significantly, particularly for LR (FPR=0.50), indicating only 50 % negative sample identification accuracy.

Full confusion matrices are provided in SI 9. While these results are theoretically not directly comparable to those from non-biocarriers data ([Table 1a](#)) due to differences in operating conditions and dataset characteristics, these findings provide operational insights into cross-condition model behavior.

The comparatively high TPR and FPR observed in the test group of the MBR with biocarrier addition can be explained by the following reasons. First, feature consistency in the test set played a significant role. In the training set, the input feature "air flow rate" included two values (2 and 6 Lpm), whereas all samples in the test set had an air flow rate of 6 Lpm. This consistency simplified the model’s decision rules, reducing the likelihood of misclassifying negative label samples (as shown in the KDEs in [Table 1b](#)). Second, the limitations of the decision boundary also contributed to the results. Despite effective positive classification at 6 Lpm, the model retained residual misclassification tendencies for negative samples. This effect was amplified by the test set’s limited negative sample size ($n = 8$), rendering FPR measurements particularly sensitive to individual misclassifications.

Finally, bootstrap sampling ($n = 1000$) revealed that models without biocarriers exhibited high precision/accuracy but wide 95 % confidence intervals (indicating instability), whereas biocarrier addition narrowed confidence intervals—particularly for RF, which achieved optimal stability and performance (detailed confidence interval analysis for both scenarios is provided in SI 10).

4. Discussion and future perspective of sustainable operation

4.1. Data limitation and data collection

Data scarcity remains a fundamental constraint in developing ML models for environmental applications, particularly when adapting pre-trained models to novel operational scenarios through transfer learning ([Dansawad et al., 2023](#); [Imen et al., 2023](#); [Lowe et al., 2022](#); [Zhang, 2022](#); [Zhu et al., 2022](#)). This dataset—collected from experimental operations instead of being designed for ML development—limited model evaluation despite > 0.8 test accuracy. Larger datasets spanning diverse operation conditions are essential for robust decision boundaries, particularly when distinguishing transient process states during simultaneous nitrification-denitrification.

In addition to the prediction overfitting due to this smaller dataset discussed in [Section 3.3](#), data constraints impact optimization criteria. Although precision maximization (high TPR/low FPR) was prioritized, limited data hindered boundary definition for TPR-FPR optimization curves. The optimization curve, as demonstrated by [Reynaert, et al. \(2023\)](#), is a useful tool for visualizing the model calibration process and guiding the selection of an appropriate FPR to evaluate performance across the trainings, validation, and test sets. Beyond mathematical FPR determination, water reuse contexts require quantitative risk assessment of FPs. Identifying reasonable operating points before cross-scenario testing would benefit model validation and set-point adjustments. Meanwhile, wide confidence intervals further underscore the need for larger datasets to evaluate model stability and feature contributions comprehensively. Current reliance on effluent $\text{NH}_4^+\text{-N}/\text{NO}_3\text{-N}$ should expand to include operational parameters, water quality dynamics, and temporal data for credible sensitivity analysis.

Online sensors are vital for consistent data collection. Sensor-compatible features ([Section 2.2.2](#)) were prioritized in this research to

chất lượng dựa trên phạm vi các đặc tính chất lượng nước xám được tổng hợp trong các tài liệu hiện có nhằm mô phỏng các đặc tính chất lượng nước xám biến động mạnh. Đồng thời, việc thu thập dữ liệu ở các lưu lượng nước đầu vào khác nhau, tức là sự biến thiên chất lượng nước tại các thời gian lưu thủy lực (HRT) khác nhau, sẽ cho phép phân tích sâu hơn mối quan hệ tr ễ giữa nồng độ nitơ amoni và nitơ nitrat trong nước đầu ra với trạng thái phản ứng trong bể phản ứng. Hơn nữa, việc thiết kế hoạt động thu thập dữ liệu chuỗi thời gian, chẳng hạn như lấy mẫu và đo nước mỗi giờ, có thể giúp xác định mối quan hệ the o chuỗi thời gian giữa những thay đổi về chất lượng nước đầu ra và trạng thái phản ứng trong bể phản ứng tại cùng thời điể m từ một góc nhìn động hơn. Tóm lại, cần có các bộ dữ liệu rộng hơn và giàu tính động hơn để tiếp tục kiểm chứng tính khả t hi của việc sử dụng chất lượng nước đầu ra nhằm dự đoán hoặc thậm chí kiểm soát trạng thái phản ứng bên trong bể phản ứ ng. Các bộ dữ liệu mở rộng và đa dạng hóa như vậy cũng rất quan trọng để giảm thiểu nguy cơ quá khớp hiện nay và cải thiệ n tính vững chắc của các mô hình trong ứng dụng thực tế. Mục 4.1 và 4.2 sẽ thảo luận thêm về tác động của những hạn chế d ữ liệu và đặc trưng đầu vào đối với khuôn khổ mô hình hiện có.

3.4. Cross-scenario test

Dựa trên hiệu quả đã được chứng minh của mô hình trong các hệ thống nitrat hóa thông thường (Mục 3.3), khả năng dự đoán xuyên kịch bản của mô hình được đánh giá thêm trong các bể phản ứng sinh học màng (MBR) tích hợp giá thể sinh học nhằm tăng cường quá trình nitrat hóa-khử nitrat đồng thời. Mô hình cơ sở được huấn luyện bằng dữ liệu vận hành không có giá thể sinh học được kiểm tra trực tiếp để dự đoán trạng thái nitrat hóa trong các hệ thống có bổ sung giá thể sinh học mà k hông cần huấn luyện lại.

Như thể hiện trong Bảng 1a, thử nghiệm giữa các điều kiện cho thấy ba nhận định chính:

- 1) So với hiệu suất dự đoán của nhóm thử nghiệm không có chất mang sinh học, mô hình RF cho thấy độ chính xác ($0.79 \rightarrow 0.83$) và độ chuẩn xác ($0.83 \rightarrow 0.87$) đều được cải thiện trong điều kiện bổ sung chất mang sinh học, cho thấy khả năng thích ứn g vượt trội với các mức độ phức tạp của hệ thống nitrat hóa-khử nitrat đồng thời. 2) TPR của cả ba thuật toán này đều lớn hơ n hoặc bằng 0.8, đặc biệt là LR, đạt 1, cho thấy mức tăng đáng kể so với nhóm thử nghiệm không bổ sung chất mang sinh họ c. 3) Các giá trị FPR tương ứng tăng đáng kể, đặc biệt là LR (FPR=0.50), cho thấy độ chính xác nhận diện mẫu âm tính chỉ đạt 50%.

Các ma trận nhầm lẫn đầy đủ được cung cấp trong SI 9. Mặc dù về mặt lý thuyết, các kết quả này không thể so sánh trực ti ếp với kết quả từ dữ liệu không sử dụng chất mang sinh học (Bảng 1a) do khác biệt về điều kiện vận hành và đặc điểm của tậ p dữ liệu, những phát hiện này cung cấp thông tin chi tiết về hoạt động của mô hình giữa các điều kiện.

TPR và FPR tương đối cao quan sát được ở nhóm thử nghiệm của MBR có bổ sung chất mang sinh học có thể được giải th ị ch bởi các lý do sau. Thứ nhất, tính nhất quán của đặc trưng trong tập kiểm tra đóng vai trò quan trọng. Trong tập huấn luyệ n, đặc trưng đầu vào "lưu lượng khí" có hai giá trị (2 và 6 Lpm), trong khi tất cả các mẫu trong tập kiểm tra đều có lưu lượng k hí là 6 Lpm. Sự nhất quán này giúp đơn giản hóa các quy tắc ra quyết định của mô hình, giảm khả năng phân loại nhầm các mẫu có nhãn âm tính (như thể hiện trong các biểu đồ KDE ở Bảng 1b). Thứ hai, những hạn chế của ranh giới quyết định cũng góp phần tạo nên các kết quả này. Dù phân loại mẫu dương tính hiệu quả ở mức 6 Lpm, mô hình vẫn có xu hướng phân loại nhầm các mẫu âm tính. Hiệu ứng này càng rõ hơn do số lượng mẫu âm tính hạn chế trong tập kiểm tra ($n = 8$), khiến các phé p đo FPR đặc biệt nhạy với từng trường hợp phân loại nhầm.

Cuối cùng, lấy mẫu bootstrap ($n = 1000$) cho thấy các mô hình không có chất mang sinh học đạt độ chính xác cao nhưng c ó khoảng tin cậy 95 % rộng (cho thấy sự thiếu ổn định), trong khi việc bổ sung chất mang sinh học giúp thu hẹp khoảng tin cậy y—đặc biệt là với RF, mô hình đạt được độ ổn định và hiệu suất tối ưu (phân tích chi tiết khoảng tin cậy cho cả hai kịch bản đư ợc trình bày trong SI 10).

4. Thảo luận và triển vọng tương lai về hoạt động bền vững

4.1. Data limitation and data collection

Sự khan hiếm dữ liệu vẫn là một hạn chế căn bản trong việc phát triển các mô hình ML cho ứng dụng môi trường, đặc biệt khi điều chỉnh các mô hình tiền huấn luyện cho những kịch bản vận hành mới thông qua học chuyển giao ([Dansawad et al., 2023](#); [Imen et al., 2023](#); [Lowe et al., 2022](#); [Zhang, 2022](#); [Zhu et al., 2022](#)). Bộ dữ liệu này—được thu thập từ các hoạt động thực nghiệm thay vì được thiết kế để phát triển ML—đã hạn chế việc đánh giá mô hình dù đạt độ chính xác trên tập kiểm tra là > 0.8 . Các bộ dữ liệu lớn hơn, bao quát nhiều điều kiện vận hành đa dạng, là thiết yếu để xây dựng ranh giới quyết định vững ch ắc, đặc biệt khi phân biệt các trạng thái quá trình chuyển tiếp trong quá trình nitrat hóa-khử nitrat đồng thời.

Ngoài hiện tượng quá khớp trong dự đoán do bộ dữ liệu nhỏ hơn được thảo luận ở Mục 3.3, các hạn chế về dữ liệu còn ả n h hưởng đến tiêu chí tối ưu hóa. Mặc dù ưu tiên tối đa hóa độ chính xác (TPR cao/FPR thấp), dữ liệu hạn chế đã cản trở việc xá c định ranh giới cho các đường cong tối ưu hóa TPR-FPR. Đường cong tối ưu hóa, như [Reynaert và cộng sự \(2023\)](#) đã minh họ a, là một công cụ hữu ích để trực quan hóa quá trình hiệu chuẩn mô hình và định hướng lựa chọn FPR phù hợp nhằm đánh gi á hiệu suất trên các tập huấn luyện, xác thực và kiểm tra. Ngoài việc xác định FPR về mặt toán học, các bối cảnh tái sử dụng n ước còn đòi hỏi đánh giá định lượng rủi ro của các trường hợp dương tính giả (FP). Việc xác định các điểm vận hành hợp lý trư ớc khi kiểm tra giữa các kịch bản sẽ giúp ích cho quá trình xác thực mô hình và điều chỉnh điểm đặt. Trong khi đó, các khoảng tin cậy rộng càng nhấn mạnh nhu cầu cần có bộ dữ liệu lớn hơn để đánh giá toàn diện độ ổn định của mô hình và mức độ đố ng góp của các đặc trưng. Việc hiện chỉ dựa vào $\text{NH}_4^+\text{-N}/\text{NO}_3\text{-N}$ trong nước thải đầu ra cần được mở rộng để bao gồm các thô ng số vận hành, diễn biến chất lượng nước và dữ liệu theo thời gian, nhằm thực hiện phân tích độ nhạy đáng tin cậy.

Các cảm biến trực tuyến đóng vai trò thiết yếu trong việc thu thập dữ liệu nhất quán. Các tính năng tương thích với cảm biến (Mục 2.

facilitate future large-scale validation. Meanwhile, optimizing measurement frequency must balance water reuse requirements and operational costs (Reynaert et al., 2024). Furthermore, identifying the input values linked to misclassification points, increasing measurement frequency, and evaluating the model prediction results in such conditions could contribute to elucidating failure mechanisms and underpinning early-warning systems investigation.

Current model validation using synthetic greywater provides proof-of-concept but requires extension to real wastewater matrices. To address this, future work should implement a phased framework:

- Phase I: Synthetic → Synthetic (Current study)
- Phase II: Synthetic → Real (Next validation step)
- Phase III: Hybrid training (e.g., 60 % real + 40 % synthetic)

Incorporating more challenging operational conditions, such as system failures (e.g., aeration malfunction or membrane damage), is essential for improving the model’s applicability in real-world treatment scenarios (Reynaert, et al., 2023). Though this study included suboptimal operations (e.g., low-aeration nitrification), systematic data collection across failure modes remains essential.

4.2. Trade-offs of input features for data-driven model structure

The model uses effluent quality to assess concurrent nitrification status, effectively employing historical data to predict current conditions. However, influent flow variations affecting hydraulic retention time (HRT) introduce input-output time lags that may compromise accuracy. Accounting for inflow dynamics is thus critical, especially with highly variable greywater generation (Pinto and Maheshwari, 2015). Future data collection should address flow variability to enhance predictions, potentially through flow-specific sub-models. Due to extensive DO data gaps, air flow rate served as the sole oxygen proxy. However, observed DO heterogeneity—driven by fluid dynamics, uneven oxygen transfer, microbial activity gradients, and reactor design (Gillot and Héduit, 2000)—necessitates distributed DO sensors for accurate future modeling.

These findings underscore the need for strategic input feature selection. Features must balance statistical correlations with practical relevance, as imbalanced datasets can distort input-output relationships. Systematic comparison of feature combinations is essential, noting that added inputs do not guarantee accuracy gains despite correlations (Linardatos et al., 2020; Reynaert et al., 2023). Besides, feature stability and reliability are equally critical: water-quality-only inputs risk long-term bias without rigorous sensor maintenance. Measurement errors and recalibration schedules must be integrated into robust model design. Finally, sensor costs should be factored into monitoring systems to enhance real-world applicability and shorten payback periods.

4.3. Model transferability improvement

Model transferability — the ability of a model to adapt to new tasks or domains with minimal retraining — can be systematically optimized through structured transfer learning frameworks (Tian and Yu, 2023). Transfer learning strategies include feature alignment, pre-training models, meta-learning architectures, self-supervised learning, data augmentation, and scalability of model structure (Yu et al., 2022).

Despite broad industrial investigations and applications of transfer learning, its potential for cross-scenario adaptation in water treatment systems remains underexplored. Current interdisciplinary advances demonstrate promising pathways: Li et al. (2021) improved the short-term traffic prediction accuracy via fine-tuning pre-trained models from data-rich areas; Zhou et al. (2025) enhanced battery performance transferability through condition-robust data augmentation; Nieves-Avendano et al. (2023) successfully adapted a pre-trained MobileNetV2 model for mechanical fault detection via targeted domain fine-tuning.

Building on the cross-scenario test (Section 3.4), three enhancement pathways are proposed for enhancing transferability of water treatment models:

- Data-centric optimization: systematic experimental designs should prioritize wide operational condition coverage and representative data distributions during collection. Data augmentation efficacy directly depends on baseline dataset diversity
- Pre-trained frameworks: development of domain-specific pre-trained models requires cross-institutional data sharing, particularly for systems handling varied water qualities or scale-dependent processes. Input features should explicitly incorporate treatment facility scale parameters due to their hydraulic and biochemical implications.
- Model structure innovation: Clustered sub-models using feature grouping and range-partitioned training data could further improve local accuracy while maintaining overall system adaptability. Further attempts can also be made in the innovative application of algorithms (e.g., meta learning).

This multipronged approach addresses current limitations in model generalization while aligning with water treatment’s inherent variability in operational scales, influent characteristics, and process configurations. Future work should prioritize establishing open benchmarking datasets to standardize transferability evaluation across diverse scenarios.

4.4. Data-driven sustainable control

After training the model with suitable input features and sufficient data collected systematically (as discussed in sections 5.1 and

tạo điều kiện thuận lợi cho việc xác thực quy mô lớn trong tương lai. Trong khi đó, việc tối ưu hóa tần suất đo lường cần cân b ằng giữa yêu cầu tái sử dụng nước và chi phí vận hành (Reynaert và cộng sự, 2024). Hơn nữa, việc xác định các giá trị đầu vào liên quan đến những điểm phân loại sai, tăng tần suất đo lường và đánh giá kết quả dự đoán của mô hình trong những điều kiện như vậy có thể góp phần làm sáng tỏ các cơ chế gây lỗi và hỗ trợ nghiên cứu các hệ thống cảnh báo sớm.

Việc xác thực mô hình hiện tại bằng nước xám tổng hợp đã chứng minh tính khả thi ban đầu, nhưng cần được mở rộng sa ng các nền mẫu nước thải thực tế. Để giải quyết vấn đề này, các nghiên cứu trong tương lai nên triển khai một khuôn khổ the o từng giai đoạn:

- Giai đoạn I: Dữ liệu tổng hợp → Dữ liệu tổng hợp (Nghiên cứu hiện tại)
- Giai đoạn II: Dữ liệu tổng hợp→ Dữ liệu thự c tế (Bước xác thực tiếp theo)
- Giai đoạn III: Huấn luyện k ết hợp (ví dụ: 60 % dữ liệu thực tế + 40 % dữ liệu tổng hợp)

Việc đưa vào các điều kiện vận hành khắc nghiệt hơn, chẳng hạn như sự cố hệ thống (ví dụ: trục trặc sục khí hoặc hư hỏng màng), là điều cần thiết để cải thiện khả năng áp dụng của mô hình trong các tình huống xử lý thực tế (Reynaert, et al., 2023). Mặc dù nghiên cứu này đã bao gồm các điều kiện vận hành chưa tối ưu (ví dụ: nitrat hóa với mức sục khí thấp), việc thu thập dữ liệu có hệ thống về các dạng sự cố vẫn là điều cần thiết.

4.2. Trade-offs of input features for data-driven model structure

Mô hình sử dụng chất lượng nước thải đầu ra để đánh giá trạng thái nitrat hóa đồng thời, qua đó tận dụng hiệu quả dữ liệ u lịch sử để dự đoán các điều kiện hiện tại. Tuy nhiên, những biến động về lưu lượng nước đầu vào ảnh hưởng đến thời gian l ưu thủy lực (HRT), gây ra độ trễ giữa đầu vào và đầu ra, có thể làm giảm độ chính xác. Vì vậy, việc tính đến động lực dòng vào là rất quan trọng, đặc biệt khi lượng nước xám phát sinh biến động mạnh (Pinto và Maheshwari, 2015). Các đợt thu thập dữ li ệu trong tương lai cần tính đến biến động lưu lượng để cải thiện khả năng dự đoán, có thể thông qua các mô hình phụ riêng cho từng mức lưu lượng. Do dữ liệu DO bị thiếu hụt đáng kể, lưu lượng khí được dùng làm chỉ báo duy nhất cho oxy. Tuy nhi ên, sự không đồng nhất của DO được quan sát thấy—do động lực học chất lỏng, sự truyền oxy không đồng đều, chênh lệch h oạt động của vi sinh vật và thiết kế bể phản ứng (Gillot và Héduit, 2000)—đòi hỏi phải bố trí các cảm biến DO phân tán để xây dựng mô hình chính xác hơn trong tương lai.

Những phát hiện này nhấn mạnh sự cần thiết của việc lựa chọn đặc trưng đầu vào một cách có chiến lược. Các đặc trưng c ần cân bằng giữa tương quan thống kê và mức độ phù hợp trong thực tiễn, vì các bộ dữ liệu mất cân bằng có thể làm sai lệch mối quan hệ giữa đầu vào và đầu ra. Việc so sánh có hệ thống các tổ hợp đặc trưng là thiết yếu, đồng thời cần lưu ý rằng việc bổ sung đầu vào không đảm bảo cải thiện độ chính xác dù có tương quan (Linardatos et al., 2020; Reynaert et al., 2023). Bên cạnh đó, tính ổn định và độ tin cậy của đặc trưng cũng quan trọng không kém: chỉ sử dụng các đầu vào về chất lượng nước c ó nguy cơ gây sai lệch dài hạn nếu không bảo trì cảm biến nghiêm ngặt. Cần tích hợp sai số đo lường và lịch hiệu chuẩn lại và o thiết kế mô hình vững chắc. Cuối cùng, cần tính đến chi phí cảm biến trong các hệ thống giám sát để tăng khả năng ứng dụ ng trong thực tế và rút ngắn thời gian hoàn vốn.

4.3. Model transferability improvement

Khả năng chuyển giao của mô hình — khả năng thích ứng với các tác vụ hoặc lĩnh vực mới mà không cần huấn luyện lại n hiều — có thể được tối ưu hóa một cách hệ thống thông qua các khuôn khổ học chuyển giao có cấu trúc (Tian và Yu, 2023). C ác chiến lược học chuyển giao bao gồm căn chỉnh đặc trưng, tiền huấn luyện mô hình, kiến trúc học meta, học tự giám sát, tă ng cường dữ liệu và khả năng mở rộng của cấu trúc mô hình (Yu và cộng sự, 2022).

Mặc dù đã có nhiều nghiên cứu và ứng dụng rộng rãi trong công nghiệp, tiềm năng thích ứng liên kịch bản của học chuyể n giao trong các hệ thống xử lý nước vẫn chưa được khai thác đầy đủ. Những tiến bộ liên ngành hiện nay cho thấy các hướng tiếp cận đầy hứa hẹn: Li et al. (2021) cải thiện độ chính xác dự báo giao thông ngắn hạn bằng cách tinh chỉnh các mô hình đ ợc tiền huấn luyện từ những khu vực giàu dữ liệu; Zhou et al. (2025) nâng cao khả năng chuyển giao hiệu năng pin thông qua tăng cường dữ liệu có tính vững trước các điều kiện; Nieves-Avendano et al. (2023) đã thích ứng thành công mô hình MobileN etV2 được tiền huấn luyện để phát hiện lỗi cơ học bằng cách tinh chỉnh miền có mục tiêu.

Dựa trên thử nghiệm liên kịch bản (Mục 3.4), ba hướng cải tiến được đề xuất nhằm nâng cao khả năng chuyển giao của cá c mô hình xử lý nước:

- Tối ưu hóa lấy dữ liệu làm trung tâm: thiết kế thí nghiệm có hệ thống cần ưu tiên bao quát nhiều điều kiện vận hành và th u thập các phân phối dữ liệu có tính đại diện. Hiệu quả của việc tăng cường dữ liệu phụ thuộc trực tiếp vào mức độ đa dạng của tập dữ liệu cơ sở.
- Các khuôn khổ tiền huấn luyện: việc phát triển các mô hình tiền huấn luyện chuyên biệt theo lĩnh vực đòi hỏi chia sẻ dữ liệu giữa các tổ chức, đặc biệt đối với các hệ thống xử lý chất lượng nước đa dạng hoặc các quy trình phụ t huộc vào quy mô. Các đặc trưng đầu vào cần đưa rõ ràng các tham số về quy mô cơ sở xử lý do những tác động của chúng đ ến thủy lực và các quá trình sinh hóa.
- Đổi mới cấu trúc mô hình: Các mô hình con được phân cụm bằng cách nhóm đặc trưng và phân vùng dữ liệu huấn luyện t heo khoảng có thể cải thiện hơn nữa độ chính xác cục bộ, đồng thời duy trì khả năng thích ứng tổng thể của hệ thống. Cũng có thể tiếp tục thử nghiệm việc ứng dụng sáng tạo các thuật toán (ví dụ: meta-learning).

Phương pháp tiếp cận đa hướng này khắc phục những hạn chế hiện tại trong khả năng khái quát hóa của mô hình, đồng t hời phù hợp với sự biến thiên vốn có trong xử lý nước về quy mô vận hành, đặc tính nước đầu vào và cấu hình quy trình. Nghi ên cứu trong tương lai nên ưu tiên xây dựng các bộ dữ liệu đánh giá chuẩn mở nhằm tiêu chuẩn hóa việc đánh giá khả năng chuyển giao trong nhiều kịch bản khác nhau.

4.4. Data-driven sustainable control

Sau khi huấn luyện mô hình bằng các đặc trưng đầu vào phù hợp và lượng dữ liệu đầy đủ được thu thập một cách có hệ thống (như





Fig. 5. Flow chart of MBR control based on classification prediction model. * The flow chart presents the control mechanism under a fixed influent flow rate. * The grey dashed rectangle represents one prediction and the corresponding control operation. * “ a_i ” is the baseline value of air flow rate, “ A ” is the unit of air flow rate increase. * The red rectangle means that the air flow rate is a_i L/min; the green rectangle means that the air flow rate is $(a_i + A)$ L/min; the blue rectangle means that the air flow rate is $(a_i + 2A)$ L/min; the purple rectangle means that the air flow rate is $(a_i + 3A)$ L/min; the brown rectangle means that the air flow rate is $(a_i + 4A)$ L/min (rectangles of the same color represent the same air flow rate).



Hình 5. Lưu đồ điều khiển MBR dựa trên mô hình dự đoán phân loại. * Lưu đồ thể hiện cơ chế điều khiển khi lưu lượng nước đầu vào không đổi. * Hình chữ nhật nét đứt màu xám biểu thị một lần dự đoán và thao tác điều khiển tương ứng. * “ a_i ” là giá trị cơ sở của lưu lượng khí, “ A ” là mức tăng đơn vị của lưu lượng khí. * Hình chữ nhật màu đỏ có nghĩa là lưu lượng khí là a_i L/min; hình chữ nhật màu xanh lá có nghĩa là lưu lượng khí là $(a_i + A)$ L/min; hình chữ nhật màu xanh lam có nghĩa là lưu lượng khí là $(a_i + 2A)$ L/min; hình chữ nhật màu tím có nghĩa là lưu lượng khí là $(a_i + 3A)$ L/min; hình chữ nhật màu nâu có nghĩa là lưu lượng khí là $(a_i + 4A)$ L/min (các hình chữ nhật cùng màu biểu thị cùng một lưu lượng khí).

5.2), an automatic control system could be further developed for intelligent operation of MBR system. Fig. 5 presents a control flowchart based on the data-driven model for automatically managing the MBR treatment process. To simplify the explanation, it assumes air flow rate adjustments under a fixed influent flow rate (i.e., constant HRT). Before implementing the data-driven control system, the baseline air flow rate (a_i), and the increment unit (A) should be determined by analyzing influent greywater characteristics over a specific period. The measurement frequency should be tailored to reuse options and corresponding effluent quality requirements. The criteria for selecting these operational factors require further investigation.

The air flow rate can be increased or decreased to maintain sustainable control without excessive energy use. Assumably, the system operates at a_i , and nitrification is predicted at time t_i (Fig. 5). If the model predicts complete nitrification ("True" label), the air flow rate remains at a_i ; otherwise, it is increased by A to $a_i + A$. Then, if operating the system through a measurement interval with air flow rate of $a_i + A$, At the next measurement interval t_{i+1} . The air flow rate returns to the baseline value a_i if complete nitrification is predicted; if incomplete, it increases to $a_i + 2A$. This process repeats at each subsequent interval (t_{i+2} , t_{i+3} , etc.), adjusting the air flow rate accordingly. As shown in Fig. 5, after determining whether the treatment system is fully nitrified, the air flow rate increases or decreases in units of A . The air flow rate can be reduced to the baseline a_i minimally, but if it exceeds the aerator's maximum capacity, an early warning system should trigger human intervention, such as discarding greywater or adding aeration equipment. Moreover, monitoring frequency can be increased during peak water usage to enhance treatment efficiency and reuse safety.

The binary classification framework demonstrates operational feasibility under data-constrained conditions. Extending the current framework to multiclass nitrification states—such as a four-level prediction scheme (25 %, 50 %, 75 %, and complete nitrification)—could enable proportional aeration control. This refinement would optimize energy use, reduce carbon footprint, and help ensure consistent effluent quality. Such models require expanded datasets from online sensors (Section 4.1) and specialized optimization techniques: multi-class threshold tuning addressing misclassification costs, and methods for imbalanced data (Davis and Goadrich, 2006; Haibo He and Garcia, 2009; Saito and Rehmsmeier, 2015). Threshold selection should account for the cost and risk of misclassification, beyond purely mathematical considerations. Additionally, class definitions should align with influent characteristics and reuse requirements.

Integrating the multiclassification model into the control system enables more precise adjustments, potentially eliminating the need for incremental changes (such as A in Fig. 5), but optimal aeration reduction strategies post-complete nitrification prediction—gradual vs. immediate—require lab/pilot validation. Gradual reduction may be better for maintaining efficiency for strict reuse standards, necessitating risk-cost evaluations.

5. Conclusions

This work demonstrates the viability of interpretable ML-based models (LR, RF, XGB) for monitoring MBR nitrification by using six sensor-compatible features: airflow, influent flow, TMP, and effluent concentrations of COD, NO_3^- -N, and NH_4^+ -N. Strategic feature selection enabled robust classification (precision >0.85 for LR/XGB). RF excelled in cross-scenario testing (precision=0.87) for predicting biocarrier operations using training data from non-biocarrier systems, despite a decline in FPR due to feature distribution shifts. All models maintained $\text{TPR} \geq 0.80$ and accuracy > 0.75 in cross-scenario testing, though limited data constrained stability. Results emphasized ML's potential to enhance MBR control by balancing precision (minimizing FPs) with transferability across configurations. Post hoc analysis (feature importance, KDE, pairwise plots, and SHAP analysis) confirmed effluent NO_3^- -N and NH_4^+ -N as dominant predictors. Wide 95 % confidence intervals reflected instability from small dataset scope.

Future research should prioritize systematic data acquisition and model training across diverse influent water quality and DO regimes. Concurrently, expanding boundary conditions—specifically targeted collection under high NO_3^- -N/low NH_4^+ -N conditions is essential to optimize model architecture. This work establishes a framework for deploying interpretable data-driven models in decentralized greywater reuse, advancing intelligent MBR control while addressing transferability barriers in real-world implementations.

CRedit authorship contribution statement

Siyan Wang: Writing – review & editing, Writing – original draft, Visualization, Software, Methodology, Investigation, Formal analysis, Conceptualization. **Duc-Viet Nguyen:** Writing – review & editing, Investigation. **How Seow-Wah:** Methodology, Investigation, Formal analysis, Data curation. **WU Di:** Writing – review & editing, Supervision, Investigation, Funding acquisition, Conceptualization.

Declaration of Generative AI and AI-assisted technologies in the writing process

During the preparation of this work the author(s) used DEEPSEEK™ in order to improve the readability and language of the manuscript. After using this tool/service, the authors reviewed and edited the content as needed and took full responsibility for the content of the published article.

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

5.2), có thể phát triển thêm một hệ thống điều khiển tự động để vận hành thông minh hệ thống MBR. Hình 5 trình bày lưu đồ điều khiển dựa trên mô hình dựa trên dữ liệu nhằm tự động quản lý quy trình xử lý MBR. Để đơn giản hóa phần giải thích, lưu đồ giả định điều chỉnh lưu lượng khí trong điều kiện lưu lượng nước đầu vào cố định (tức là HRT không đổi). Trước khi triển khai hệ thống điều khiển dựa trên dữ liệu, cần xác định lưu lượng khí cơ sở (a_i) và mức tăng đơn vị (A) bằng cách phân tích đặc tính của nước xám đầu vào trong một khoảng thời gian cụ thể. Tần suất đo cần được điều chỉnh phù hợp với các phương án tái sử dụng và yêu cầu chất lượng nước đầu ra tương ứng. Các tiêu chí lựa chọn những yếu tố vận hành này cần được nghiên cứu thêm.

Lưu lượng khí có thể được tăng hoặc giảm để duy trì khả năng kiểm soát bền vững mà không tiêu tốn quá nhiều năng lượng. Giả sử hệ thống hoạt động ở mức a_i , quá trình nitrat hóa được dự đoán tại thời điểm t_i (Hình 5). Nếu mô hình dự đoán quá trình nitrat hóa hoàn toàn (nhãn "True"), lưu lượng khí giữ nguyên ở mức a_i ; nếu không, lưu lượng được tăng thêm A lên $a_i + A$. Sau đó, nếu vận hành hệ thống trong một khoảng đo với lưu lượng khí $a_i + A$, thì tại khoảng đo tiếp theo t_{i+1} . Lưu lượng khí trở về giá trị cơ sở a_i nếu dự đoán quá trình nitrat hóa hoàn toàn; nếu chưa hoàn toàn, lưu lượng tăng lên $a_i + 2A$. Quá trình này lặp lại ở mỗi khoảng tiếp theo (t_{i+2} , t_{i+3} , v.v.), điều chỉnh lưu lượng khí tương ứng. Như thể hiện trong Hình 5, sau khi xác định hệ thống xử lý đã nitrat hóa hoàn toàn hay chưa, lưu lượng khí được tăng hoặc giảm theo từng mức A . Lưu lượng khí có thể giảm xuống mức cơ sở a_i ở mức tối thiểu, nhưng nếu vượt quá công suất tối đa của thiết bị sục khí, hệ thống cảnh báo sớm cần kích hoạt sự can thiệp của con người, chẳng hạn như thải bỏ nước xám hoặc bổ sung thiết bị sục khí. Ngoài ra, có thể tăng tần suất giám sát trong thời gian sử dụng nước cao điểm để nâng cao hiệu quả xử lý và độ an toàn khi tái sử dụng.

Khung phân loại nhị phân cho thấy tính khả thi trong vận hành khi dữ liệu bị hạn chế. Việc mở rộng khung hiện tại sang các trạng thái nitrat hóa đa lớp—chẳng hạn như sơ đồ dự đoán bốn mức (25 %, 50 %, 75 % và nitrat hóa hoàn toàn)—có thể cho phép kiểm soát sục khí theo tỷ lệ. Cải tiến này sẽ tối ưu hóa việc sử dụng năng lượng, giảm lượng khí thải carbon và giúp đảm bảo chất lượng nước thải đầu ra ổn định. Các mô hình như vậy đòi hỏi bộ dữ liệu mở rộng từ cảm biến trực tuyến (Mục 4.1) và các kỹ thuật tối ưu hóa chuyên biệt: hiệu chỉnh ngưỡng đa lớp có xét đến chi phí phân loại sai, cùng các phương pháp xử lý dữ liệu mất cân bằng (Davis and Goadrich, 2006; Haibo He and Garcia, 2009; Saito and Rehmsmeier, 2015). Việc lựa chọn ngưỡng cần tính đến chi phí và rủi ro của phân loại sai, thay vì chỉ dựa trên các cân nhắc thuần túy về mặt toán học. Ngoài ra, các định nghĩa lớp cần phù hợp với đặc tính nước đầu vào và yêu cầu tái sử dụng.

Việc tích hợp mô hình phân loại đa lớp vào hệ thống điều khiển cho phép điều chỉnh chính xác hơn, có khả năng loại bỏ nhu cầu thay đổi từng bước (chẳng hạn như A trong Hình 5). Tuy nhiên, các chiến lược giảm sục khí tối ưu sau khi dự đoán hoàn tất quá trình nitrat hóa—giảm dần hay giảm ngay lập tức—cần được kiểm chứng trong phòng thí nghiệm hoặc ở quy mô thực địa. Giảm dần có thể phù hợp hơn để duy trì hiệu suất khi phải đáp ứng các tiêu chuẩn tái sử dụng nghiêm ngặt, do đó cần đánh giá rủi ro và chi phí.

5. Kết luận

Nghiên cứu này chứng minh tính khả thi của các mô hình dựa trên ML có khả năng diễn giải (LR, RF, XGB) trong giám sát quá trình nitrat hóa MBR bằng sáu đặc trưng tương thích với cảm biến: lưu lượng khí, lưu lượng nước đầu vào, TMP và nồng độ COD, NO_3^- -N, NH_4^+ -N trong nước đầu ra. Việc lựa chọn đặc trưng có chủ đích giúp phân loại mạnh mẽ (độ chính xác >0.85 đối với LR/XGB). RF hoạt động vượt trội trong thử nghiệm liên kịch bản (độ chính xác=0.87) khi dự đoán hoạt động của giá thể sinh học bằng dữ liệu huấn luyện từ các hệ thống không có giá thể sinh học, dù FPR giảm do sự dịch chuyển phân bố đặc trưng. Tất cả mô hình đều duy trì $\text{TPR} \geq 0.80$ và độ chính xác > 0.75 trong thử nghiệm liên kịch bản, mặc dù dữ liệu hạn chế làm giảm tính ổn định. Kết quả nhấn mạnh tiềm năng của ML trong việc cải thiện khả năng điều khiển MBR bằng cách cân bằng độ chính xác (giảm thiểu FP) với khả năng chuyển giao giữa các cấu hình. Phân tích hậu nghiệm (tầm quan trọng của đặc trưng, KDE, biểu đồ từng cặp và phân tích SHAP) xác nhận NO_3^- -N và NH_4^+ -N trong nước đầu ra là các yếu tố dự đoán chủ đạo. Khoảng tin cậy 95 % rộng phản ánh sự thiếu ổn định do quy mô bộ dữ liệu nhỏ.

Nghiên cứu trong tương lai nên ưu tiên thu thập dữ liệu và huấn luyện mô hình một cách có hệ thống trên nhiều điều kiện chất lượng nước đầu vào và chế độ DO khác nhau. Đồng thời, cần mở rộng các điều kiện biên—cụ thể là thu thập dữ liệu có mục tiêu trong điều kiện NO_3^- -N cao/ NH_4^+ -N thấp—để tối ưu hóa kiến trúc mô hình. Công trình này thiết lập một khuôn khổ để triển khai các mô hình dựa trên dữ liệu có khả năng diễn giải trong hệ thống tái sử dụng nước xám phi tập trung, thúc đẩy điều khiển MBR thông minh, đồng thời giải quyết các rào cản về khả năng chuyển giao trong ứng dụng thực tế.

Tuyên bố về đóng góp của tác giả theo CRediT

Siyan Wang: Viết – rà soát và biên tập, viết bản thảo gốc, trực quan hóa, phần mềm, phương pháp luận, điều tra, phân tích hình thức, hình thành ý tưởng. Duc-Viet Nguyen: Viết – rà soát và biên tập, điều tra. How Seow-Wah: Phương pháp luận, điều tra, phân tích hình thức, quản lý dữ liệu. WU Di: Viết – rà soát và biên tập, giám sát, điều tra, huy động kinh phí, hình thành ý tưởng.

Khai báo về AI tạo sinh và các công nghệ hỗ trợ bằng AI trong quá trình viết

Trong quá trình chuẩn bị công trình này, (các) tác giả đã sử dụng DEEPSEEK™ để cải thiện khả năng đọc và ngôn ngữ của bản thảo. Sau khi sử dụng công cụ/dịch vụ này, các tác giả đã xem xét và chỉnh sửa nội dung khi cần thiết, đồng thời hoàn toàn chịu trách nhiệm về nội dung của bài báo đã xuất bản.

Tuyên bố về lợi ích cạnh tranh

Các tác giả tuyên bố rằng họ không có lợi ích tài chính cạnh tranh hoặc mối quan hệ cá nhân nào đã biết có thể ảnh hưởng đến công trình được báo cáo trong bài báo này.

Acknowledgments

We wish to express our gratitude to Emile van Holsbeke, Helena Deberdt, Yujin Kim, Joonhyung Bai, Ji Eun Kim, Siyoung Kim, Loïc Ruiz and Dongha Kim from Ghent University for assisting in the MBR system installation and operation. This work was supported by the special research fund of Ghent University, Belgium (BOF22/DOC/135). Di Wu acknowledged the funding support from the Hong Kong Research Grant Councils (T21–604/19-R) and the Hong Kong Innovation and Technology Commission (ITC-CNERC14EG03).

Appendix A. Supporting information

Supplementary data associated with this article can be found in the online version at [doi:10.1016/j.eti.2025.104541](https://doi.org/10.1016/j.eti.2025.104541).

Data availability

Data will be made available on request.

References

Allen, G.I., Gan, L., Zheng, L., 2024. Interpretable machine learning for discovery: statistical challenges and opportunities. *Annu. Rev. Stat. Appl.* 11 (1), 97–121. <https://doi.org/10.1146/annurev-statistics-040120-030919>.

Bahramian, M., Dereli, R.K., Zhao, W., Giberti, M., Casey, E., 2023. Data to intelligence: the role of data-driven models in wastewater treatment. *Expert Syst. Appl.* 217, 119453. <https://doi.org/10.1016/j.eswa.2022.119453>.

Belkin, M., Hsu, D., Ma, S., Mandal, S., 2019. Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proc. Natl. Acad. Sci.* 116 (32), 15849–15854. <https://doi.org/10.1073/pnas.1903070116>.

Bentéjac, C., Csörgő, A., Martínez-Muñoz, G., 2021. A comparative analysis of gradient boosting algorithms. *Artif. Intell. Rev.* 54 (3), 1937–1967. <https://doi.org/10.1007/s10462-020-09896-5>.

Boleydei, H., Vaneekhaute, C., 2024. Advancements and challenges in membrane bioreactor performance for decentralized and low-temperature applications: a comprehensive review. *J. Water Process Eng.* 63, 105523. <https://doi.org/10.1016/j.jwpe.2024.105523>.

Breiman, L., 2001. Random forests. *Mach. Learn.* 45 (1), 5–32. <https://doi.org/10.1023/A:1010933404324>.

Breiman, L., Friedman, J.H., Olshen, R.A., Stone, C.J., 2017. Classification and regression trees. Routledge. <https://doi.org/10.1201/9781315139470>.

Chen, T., Guestrin, C., 2016. XGBoost: a scalable tree boosting system. *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.* 785–794. <https://doi.org/10.1145/2939672.2939785>.

Ching, P.M.L., Zou, X., Wu, D., So, R.H.Y., Chen, G.H., 2022. Development of a wide-range soft sensor for predicting wastewater BOD5 using an extreme gradient boosting (XGBoost) machine. *Environ. Res.* 210. <https://doi.org/10.1016/j.envres.2022.112953>.

Chiroma, H., Abdullahi, U.A., Abdulhamid, S.M., Abdulsalam Alarood, A., Gabralla, L.A., Rana, N., Shuib, L., Targio Hashem, I.A., Gbenga, D.E., Abubakar, A.I., Zeki, A.M., Herawan, T., 2019. Progress on artificial neural networks for big data analytics: a survey. *IEEE Access* 7, 70535–70551. <https://doi.org/10.1109/ACCESS.2018.2880694>.

Dansawad, P., Li, Y., Li, Y., Zhang, J., You, S., Li, W., Yi, S., 2023. Machine learning toward improving the performance of membrane-based wastewater treatment: a review. *Adv. Membr.* 3, 100072. <https://doi.org/10.1016/j.advmem.2023.100072>.

Davis, J., Goadrich, M., 2006. The relationship between Precision-Recall and ROC curves. *Proc. 23rd Int. Conf. Mach. Learn.* 233–240. <https://doi.org/10.1145/1143844.1143874>.

DelaPaz-Ruiz, N., Augustijn, E.-W., Farnaghi, M., Zurita-Milla, R., 2024. Modeling spatiotemporal domestic wastewater variability: implications for measuring treatment efficiency. *J. Environ. Manag.* 351, 119680. <https://doi.org/10.1016/j.jenvman.2023.119680>.

Duarte, M.S., Martins, G., Oliveira, P., Fernandes, B., Ferreira, E.C., Alves, M.M., Lopes, F., Pereira, M.A., Novais, P., 2024. A review of computational modeling in wastewater treatment processes. *ACS EST Water* 4 (3), 784–804. <https://doi.org/10.1021/acsestwater.3c00117>.

Gao, T., Jin, Y., Xiao, K., 2025. Techno–Economic and environmental impact assessment of membrane bioreactors for wastewater treatment: a review. *Engineering*. <https://doi.org/10.1016/j.eng.2025.05.001>.

Gillot, S., Héduit, A., 2000. Effect of air flow rate on oxygen transfer in an oxidation ditch equipped with fine bubble diffusers and slow speed mixers. *Water Res.* 34 (5), 1756–1762. [https://doi.org/10.1016/S0043-1354\(99\)00323-1](https://doi.org/10.1016/S0043-1354(99)00323-1).

Gu, Y., Li, Y., Yuan, F., Yang, Q., 2023. Optimization and control strategies of aeration in WWTPs: a review. *J. Clean. Prod.* 418, 138008. <https://doi.org/10.1016/j.jclepro.2023.138008>.

Haibo He, Garcia, E.A., 2009. Learning from imbalanced data. *IEEE Trans. Knowl. Data Eng.* 21 (9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>.

Haimi, H., Mulas, M., Corona, F., Vahala, R., 2013. Data-derived soft-sensors for biological wastewater treatment plants: an overview. *Environ. Model. Softw.* 47, 88–107. <https://doi.org/10.1016/j.envsoft.2013.05.009>.

Hassan, K., Alzahrani, A., Alotaibi, N.M., Helmy, M., 2024. Performance of an integrated household greywater treatment system for water optimization and reuse. *Appl. Water Sci.* 14 (11), 242. <https://doi.org/10.1007/s13201-024-02303-2>.

Hastie, T., Tibshirani, R., Friedman, J., 2009. Linear methods for classification. In *The Elements of Statistical Learning*, 2nd ed. Springer New York, pp. 101–137. https://doi.org/10.1007/978-0-387-84858-7_4.

Hosmer, D.W., Lemeshow, S., Sturdivant, R.X., 2013. Applied logistic regression. Wiley. <https://doi.org/10.1002/9781118548387>.

Huang, R., Geng, M., Gao, S., Yin, X., Tian, J., 2024. In-depth insight into improvement of simultaneous nitrification and denitrification/biofouling control by increasing sludge concentration in membrane reactor: performance, microbial assembly and metagenomic analysis. *Bioresour. Technol.* 393, 130013. <https://doi.org/10.1016/j.biortech.2023.130013>.

Huang, R., Meng, T., Liu, G., Gao, S., Tian, J., 2022. Simultaneous nitrification and denitrification in membrane bioreactor: effect of dissolved oxygen. *J. Environ. Manag.* 323, 116183. <https://doi.org/10.1016/j.jenvman.2022.116183>.

Imen, S., Croll, H.C., McLellan, N.L., Bartlett, M., Lehman, G., Jacangelo, J.G., 2023. Application of machine learning at wastewater treatment facilities: a review of the science, challenges and barriers by level of implementation. *Environ. Technol. Rev.* 12 (1), 493–516. <https://doi.org/10.1080/21622515.2023.2242015>.

Li, J., Guo, F., Sivakumar, A., Dong, Y., Krishnan, R., 2021. Transferability improvement in short-term traffic prediction using stacked LSTM network. *Transp. Res. Part C Emerg. Technol.* 124, 102977. <https://doi.org/10.1016/j.trc.2021.102977>.

Li, D., Zou, M., Jiang, L., 2022. Dissolved oxygen control strategies for water treatment: a review. *Water Sci. Technol.* 86 (6), 1444–1466. <https://doi.org/10.2166/wst.2022.281>.

Liaw, A., Wiener, M., 2002. Classification and regression by randomforest. *R. N.* 2 (3), 18–22 (<http://www.stat.berkeley.edu/>).

Lời cảm ơn

Chúng tôi xin bày tỏ lòng biết ơn đến Emile van Holsbeke, Helena Deberdt, Yujin Kim, Joonhyung Bai, Ji Eun Kim, Siyoung Kim, Loïc Ruiz và Dongha Kim thuộc Đại học Ghent đã hỗ trợ lắp đặt và vận hành hệ thống MBR. Công trình này được Quỹ Nghiê n cứu Đặc biệt của Đại học Ghent, Bỉ (BOF22/DOC/135) tài trợ. Di Wu ghi nhận sự hỗ trợ tài chính từ Hội đồng Tài trợ Nghiên cứu Hồng Kông (T21–604/19-R) và Ủy ban Đổi mới và Công nghệ Hồng Kông (ITC-CNERC14EG03).

Phụ lục A. Thông tin bổ trợ

Dữ liệu bổ sung liên quan đến bài viết này có thể được tìm thấy trong phiên bản trực tuyến tại doi:10.1016/j.eti.2025.104541.

Tính khả dụng của dữ liệu

Dữ liệu sẽ được cung cấp khi có yêu cầu.

Tài liệu tham khảo

Allen, G.I., Gan, L., Zheng, L., 2024. Học máy có thể diễn giải phục vụ khám phá: những thách thức và cơ hội về thống kê. *Annu. Rev. Stat. Appl.* 11 (1), 97–121. <https://doi.org/10.1146/annurev-statistics-040120-030919>.

Bahramian, M., Dereli, R.K., Zhao, W., Giberti, M., Casey, E., 2023. Từ dữ liệu đến trí tuệ: vai trò của các mô hình dựa trên dữ liệu trong xử lý nước thải. *Expert Syst. Appl.* 217, 119453. <https://doi.org/10.1016/j.eswa.2022.119453>.

Belkin, M., Hsu, D., Ma, S., Mandal, S., 2019. Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proc. Natl. Acad. Sci.* 116 (32), 15849–15854. <https://doi.org/10.1073/pnas.1903070116>.

Bentéjac, C., Csörgő, A., Martínez-Muñoz, G., 2021. Phân tích so sánh các thuật toán tăng cường độ dốc. *Artif. Intell. Rev.* 54 (3), 1937–1967. <https://doi.org/10.1007/s10462-020-09896-5>.

Boleydei, H., Vaneekhaute, C., 2024. Những tiến bộ và thách thức trong hiệu suất của bể ph ản ứng sinh học màng cho các ứng dụng phi tập trung và nhiệt độ thấp: tổng quan toàn diện. *J. Water Process Eng.* 63, 105523. <https://doi.org/10.1016/j.jwpe.2024.105523>.

Breiman, L., 2001. Rừng ngẫu nhiên. *Mach. Learn.* 45 (1), 5–32. <https://doi.org/10.1023/A:1010933404324>.

Breiman, L., Friedman, J.H., Olshen, R.A., Stone, C.J., 2017. Cây phân loại và hồi quy. Routledge. <https://doi.org/10.1201/9781315139470>.

Chen, T., Guestrin, C., 2016. XGBoost: hệ thống tăng cường cây có khả năng mở rộng. *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.* 785–794. <https://doi.org/10.1145/2939672.2939785>.

Ching, P.M.L., Zou, X., Wu, D., So, R.H.Y., Chen, G.H., 2022. Phát triển cảm biến mềm có phạm vi rộng để dự đoán BOD5 trong nước thải bằng thuật toán tăng cường độ dốc cực đại (XGBoost). *Environ. Res.* 210. <https://doi.org/10.1016/j.envres.2022.112953>.

Chiroma, H., Abdullahi, U.A., Abdulhamid, S.M., Abdulsalam Alarood, A., Gabralla, L.A., Rana, N., Shuib, L., Targio Hashem, I.A., Gbenga, D.E., Abubakar, A.I., Zeki, A.M., Herawan, T., 2019. Tiến triển trong ứng dụng mạng nơ ron nhân tạo vào phân tích dữ liệu lớn: tổng quan. *IEEE Access* 7, 70535–70551. <https://doi.org/10.1109/ACCESS.2018.2880694>.

Dansawad, P., Li, Y., Li, Y., Zhang, J., You, S., Li, W., Yi, S., 2023. Đánh giá tác động kỹ thuật-kinh tế và môi trường của bể phản ứng sinh học màng trong xử lý nước thải: tổng quan. *Adv. Membr.* 3, 100072. <https://doi.org/10.1016/j.advmem.2023.100072>.

Davis, J., Goadrich, M., 2006. Mỗi quan hệ giữa các đường cong Precision-Recall và ROC. *Proc. 23rd Int. Conf. Mach. Learn.* 233–240. <https://doi.org/10.1145/1143844.1143874>.

DelaPaz-Ruiz, N., Augustijn, E.-W., Farnaghi, M., Zurita-Milla, R., 2024. Mô hình hóa sự biến thiên theo không gian và thời gian của nước thải sinh hoạt: ý nghĩa đối với việc đo lường hiệu quả xử lý. *J. Environ. Manag.* 351, 119680. <https://doi.org/10.1016/j.jenvman.2023.119680>.

Duarte, M.S., Martins, G., Oliveira, P., Fernandes, B., Ferreira, E.C., Alves, M.M., Lopes, F., Pereira, M.A., Novais, P., 2024. Tổng quan về mô hình hóa tính toán trong các quy trình xử lý nước thải. *ACS EST Water* 4 (3), 784–804. <https://doi.org/10.1021/acsestwater.3c00117>.

Gao, T., Jin, Y., Xiao, K., 2025. Ảnh hưởng của lưu lượng khí đến quá trình truyền oxy trong mương oxy hóa được trang bị bộ khuếch tá n bọt khí mịn và máy khuấy tốc độ thấp. *Water Res.* 34 (5), 1756–1762. [https://doi.org/10.1016/S0043-1354\(99\)00323-1](https://doi.org/10.1016/S0043-1354(99)00323-1).

Gu, Y., Li, Y., Yuan, F., Yang, Q., 2023. Các chiến lược tối ưu hóa và kiểm soát quá trình sục khí tại các nhà máy xử lý nước thải: tổng quan. *J. Clean. Prod.* 418, 138008. <https://doi.org/10.1016/j.jclepro.2023.138008>.

Haibo He, Garcia, E.A., 2009. Học từ dữ liệu mất cân bằng. *IEEE Trans. Knowl. Data Eng.* 21 (9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>.

Haimi, H., Mulas, M., Corona, F., Vahala, R., 2013. Cảm biến mềm dựa trên dữ liệu cho các nhà máy xử lý nước thải sinh học: tổng quan. *Environ. Model. Softw.* 47, 88–107. <https://doi.org/10.1016/j.envsoft.2013.05.009>.

Hassan, K., Alzahrani, A., Alotaibi, N.M., Helmy, M., 2024. Hiệu suất của hệ thống xử lý nước xám hộ gia đình tích hợp nhằm tối ưu hóa và tái sử dụng nước. *Appl. Water Sci.* 14 (11), 242. <https://doi.org/10.1007/s13201-024-02303-2>.

Hastie, T., Tibshirani, R., Friedman, J., 2009. Các phương pháp tuyến tính để phân loại. Trong *The Elements of Statistical Learning*, ấn bản thứ 2. Springer New York, tr. 101–137. https://doi.org/10.1007/978-0-387-84858-7_4.

Hosmer, D.W., Lemeshow, S., Sturdivant, R.X., 2013. Hồi quy logistic ứng dụng. Wiley. <https://doi.org/10.1002/9781118548387>.

Huang, R., Geng, M., Gao, S., Yin, X., Tian, J., 2024. Tìm hiểu chuyên sâu về cải thiện quá trình nitrat hóa và khử nitrat đồng thời/kiế m soát tắc nghẽn sinh học bằng cách tăng nồng độ bùn trong bể phản ứng màng: hiệu suất, cấu trúc quần xã vi sinh vật và phân tích hệ gen chức năng. *Bio resour. Technol.* 393, 130013. <https://doi.org/10.1016/j.biortech.2023.130013>.

Huang, R., Meng, T., Liu, G., Gao, S., Tian, J., 2022. Nitrat hóa và khử nitrat đồn g thời trong bể phản ứng sinh học màng: ảnh hưởng của oxy hòa tan. *J. Environ. Manag.* 323, 116183. <https://doi.org/10.1016/j.jenvman.2022.116183>.

Imen, S., Croll, H.C., McLellan, N.L., Bartlett, M., Lehman, G., Jacangelo, J.G., 2023. Ứng dụng học máy tại các cơ sở xử lý nước thải: tổng quan về cơ sở khoa học, t hách thức và rào cản theo mức độ triển khai. *Environ. Technol. Rev.* 12 (1), 493–516. <https://doi.org/10.1080/21622515.2023.2242015>.

Li, J., Guo, F., Sivakumar, A., Dong, Y., Krishnan, R., 2021. Cải thiện khả năng chuyển giao trong dự báo giao thông ngắn hạn bằng mạng LSTM xếp chồng. *Transp. Res. Part C Eme rg. Technol.* 124, 102977. <https://doi.org/10.1016/j.trc.2021.102977>.

Li, D., Zou, M., Jiang, L., 2022. Các chiến lược kiểm soát oxy hòa tan trong xử lý nước: tở n g quan. *Water Sci. Technol.* 86 (6), 1444–1466. <https://doi.org/10.2166/wst.2022.281>.

Liaw, A., Wiener, M., 2002. Phân loại và hồi quy bằng rừng ngẫu nhiên. *R. N.* 2 (3), 18–22 (<http://www.stat.berkeley.edu/>).

- Linardatos, P., Papastefanopoulos, V., Kotsiantis, S., 2020. Explainable AI: a review of machine learning interpretability methods. *Entropy* 23 (1), 18. <https://doi.org/10.3390/e23010018>.
- Liu, L., Zhou, X., Dueñas-Osorio, L., Stadler, L., Li, Q., 2023. Hybrid wastewater treatment and reuse enhances urban water system resilience to disruptive incidents. *Nat. Water* 1 (12), 1048–1058. <https://doi.org/10.1038/s44221-023-00166-6>.
- Lowe, M., Qin, R., Mao, X., 2022. A review on machine learning, artificial intelligence, and smart technology in water treatment and monitoring. *Water* 14 (9), 1384. <https://doi.org/10.3390/w14091384>.
- Lundberg, S., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. Maggiorotto, G., 2022. Reusing grey water to lower temperatures in the Mediterranean basin cities. *Earth* 3 (1), 72–75. <https://doi.org/10.3390/earth3010005>.
- Moretti, A., Ivan, H.L., Skvaril, J., 2024. A review of the state-of-the-art wastewater quality characterization and measurement technologies. Is the shift to real-time monitoring nowadays feasible? *J. Water Process Eng.* 60, 105061. <https://doi.org/10.1016/j.jwpe.2024.105061>.
- Muniz de Queiroz, M., Moreira, V.R., Amaral, M.C.S., Oliveira, S.M.A.C., 2025. Machine learning algorithms for predicting membrane bioreactors performance: a review. *J. Environ. Manag.* 380, 124978. <https://doi.org/10.1016/j.jenvman.2025.124978>.
- Murdoch, W.J., Singh, C., Kumbier, K., Abbasi-Asl, R., Yu, B., 2019. Definitions, methods, and applications in interpretable machine learning. *Proc. Natl. Acad. Sci.* 116 (44), 22071–22080. <https://doi.org/10.1073/pnas.1900654116>.
- Murphy, K.P., 2012. *Machine learning: a probabilistic perspective*. MIT Press.
- Nguyen, D.-V., Wang, S., Nguyen, D.-P., Ching, P.M.L., Shim, J.H., Jung, Y., Wu, D., So, R.H.Y., 2024. Current developments in machine learning models with boosting algorithms for the prediction of water quality. In *Water Security: Big Data-Driven Risk Identification, Assessment and Control of Emerging Contaminants*. Elsevier, pp. 575–591. <https://doi.org/10.1016/B978-0-443-14170-6.00015-9>.
- Nieves-Avendano, D., Deschrijver, D., Van Hoecke, S., 2023. Transfer learning for anomaly detection using Bearings’ vibration signals. *Int. J. Acoust. Vib.* 28 (4), 420–434. <https://doi.org/10.20855/ijav.2023.28.41993>.
- Noor, A., Mohamed Kutty, S.R., Baloo, L., Affam, A.C., Jagaba, A.H., Saeed Ghaleb, A.A., Yahya Almahbashi, N.M., Ahmad, T., Nawab, M.S., Birniwa, A.H., 2023. Parametric optimization of additive manufactured biocarrier submerged in sequencing batch reactor for domestic wastewater treatment. *Heliyon* 9 (4), e14840. <https://doi.org/10.1016/j.heliyon.2023.e14840>.
- Omar, A., Almomani, F., Qiblawey, H., Rasool, K., 2024. Advances in Nitrogen-Rich wastewater treatment: a comprehensive review of modern technologies. *Sustainability* 16 (5), 2112. <https://doi.org/10.3390/su16052112>.
- Ongena, S., de Walle, A.V., Mosquera-Romero, S., Driesen, N., Gutierrez, L., Rabaey, K., 2023. Comparison of MBR and MBBR followed by UV or electrochemical disinfection for decentralised greywater treatment. *Water Res* 235, 119818. <https://doi.org/10.1016/j.watres.2023.119818>.
- Paetkau, M., Cicek, N., 2011. Comparison of nitrogen removal and sludge characteristics between a conventional and a simultaneous nitrification–denitrification membrane bioreactor. *Desalination* 283, 165–168. <https://doi.org/10.1016/j.desal.2011.02.018>.
- Pekalska, E., Harol, A., Lai, C., Duin, R.P.W., 2005. Pairwise Selection of Features and Prototypes. *Computer Recognition Systems: Proceedings of the 4th International Conference on Computer Recognition Systems CORES’05*, 271–278. https://doi.org/10.1007/3-540-32390-2_31.
- Pinto, U., Maheshwari, B.L., 2015. Sustainable graywater reuse for residential landscape irrigation – a critical review. *Chin. J. Popul. Resour. Environ.* 13 (3), 250–264. <https://doi.org/10.1080/10042857.2015.1059790>.
- Rahman, T.U., Roy, H., Islam, Md.R., Tahmid, M., Fariha, A., Mazumder, A., Tasnim, N., Pervaz, Md.N., Cai, Y., Naddeo, V., Islam, Md.S., 2023. The advancement in membrane bioreactor (MBR) technology toward sustainable industrial wastewater management. *Membranes* 13 (2), 181. <https://doi.org/10.3390/membranes13020181>.
- Reynaert, E., Nagappa, D., Sigrist, J.A., Morgenroth, E., 2024. Ensuring microbial water quality for on-site water reuse: importance of online sensors for reliable operation. *Water Res.* X 22, 100215. <https://doi.org/10.1016/j.wroa.2024.100215>.
- Reynaert, E., Steiner, P., Yu, Q., D’Oliif, L., Joller, N., Schneider, M.Y., Morgenroth, E., 2023. Predicting microbial water quality in on-site water reuse systems with online sensors. *Water Res.* 240, 120075. <https://doi.org/10.1016/j.watres.2023.120075>.
- Saito, T., Rehmsmeier, M., 2015. The Precision-Recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE* 10 (3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>.
- Salvia, M., Sanchez, N., Piles, M., Ruscica, R., Gonzalez-Zamora, A., Roitberg, E., Martinez-Fernandez, J., 2021. The Added-Value of Remotely-Sensed soil moisture data for agricultural drought detection in Argentina. *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.* 14, 6487–6500. <https://doi.org/10.1109/JSTARS.2021.3084849>.
- Scott, D.W., 2015. Kernel Density Estimators. In *Multivariate Density Estimation: Theory, Practice, and Visualization*, Second Edition (2nd ed., pp. 137–216). <https://doi.org/10.1002/9781118575574.ch6>.
- Shaikh, I.N., Ahmed, M.M., 2020. Quantity and quality characteristics of greywater: a review. In: *In Journal of Environmental Management*, 261. Academic Press. <https://doi.org/10.1016/j.jenvman.2020.110266>.
- Shi, Y., Wang, Z., Du, X., Ling, G., Jia, W., Lu, Y., 2022. Research on the membrane fouling diagnosis of MBR membrane module based on ECA-CNN. *J. Environ. Chem. Eng.* 10 (3), 107649. <https://doi.org/10.1016/j.jece.2022.107649>.
- Shi, H., Wei, A., Zhu, Y., Tang, K., Hu, H., Li, N., 2024. Accurate and robust ammonia level forecasting of aeration tanks using long short-term memory ensembles: a comparative study of adaboost and bagging approaches. *J. Environ. Manag.* 371, 123173. <https://doi.org/10.1016/j.jenvman.2024.123173>.
- Szeghalmy, S., Fazekas, A., 2023. A comparative study of the use of stratified Cross-Validation and Distribution-Balanced stratified Cross-Validation in imbalanced learning. *Sensors* 23 (4), 2333. <https://doi.org/10.3390/s23042333>.
- Tian, P., Yu, H., 2023. Can we improve meta-learning model in few-shot learning by aligning data distributions? *Knowl. Based Syst.* 277, 110800. <https://doi.org/10.1016/j.knosys.2023.110800>.
- Van de Walle, A., Kim, M., Alam, M.K., Wang, X., Wu, D., Dash, S.R., Rabaey, K., Kim, J., 2023. Greywater reuse as a key enabler for improving urban wastewater management. *Environ. Sci. Ecotechnol.* 16, 100277. <https://doi.org/10.1016/j.ese.2023.100277>.
- Van Rossum, G., Drake, F.L., 2009. *Python/C api manual - python 3*. CreateSpace.
- Wang, S., Schneider, M.Y., Volcke, E.I.P., Wu, D., 2025. How useful are data-driven methods for building-level greywater treatment from a process engineering perspective? *Water Res.* X 28, 100343. <https://doi.org/10.1016/j.wroa.2025.100343>.
- Waskom, M., 2021. Seaborn: statistical data visualization. *J. Open Source Softw.* 6 (60), 3021. <https://doi.org/10.21105/joss.03021>.
- Yang, H., Lu, K., Lyu, X., Hu, F., 2019. Two-way partial AUC and its properties. *Stat. Methods Med. Res.* 28 (1), 184–195. <https://doi.org/10.1177/0962280217718866>.
- Yu, F., Xiu, X., Li, Y., 2022. A survey on deep transfer learning and beyond. *Mathematics* 10 (19), 3619. <https://doi.org/10.3390/math10193619>.
- Zeng, X., Martinez, T.R., 2000. Distribution-balanced stratified cross-validation for accuracy estimation. *J. Exp. Theor. Artif. Intell.* 12 (1), 1–12. <https://doi.org/10.1080/095281300146272>.
- Zhang, H., 2022. AI and big data in water environments. *ACS ES T Water Am. Chem. Soc.* <https://doi.org/10.1021/acsestwater.2c00203>.
- Zhong, H., Yuan, Y., Luo, L., Ye, J., Chen, M., Zhong, C., 2022. Water quality prediction of MBR based on machine learning: a novel dataset contribution analysis method. *J. Water Process Eng.* 50, 103296. <https://doi.org/10.1016/j.jwpe.2022.103296>.
- Zhou, X., Han, X., Shi, K., Chen, X., Guo, D., Zheng, Y., Lu, L., Ouyang, M., 2025. Intelligent battery life management through mechanism and machine learning under real vehicle working conditions. *J. Power Sources* 640, 236749. <https://doi.org/10.1016/j.jpowsour.2025.236749>.
- Zhu, M., Wang, J., Yang, X., Zhang, Y., Zhang, L., Ren, H., Wu, B., Ye, L., 2022. A review of the application of machine learning in water quality evaluation. *Eco Environ. Health* 1 (2), 107–116. <https://doi.org/10.1016/j.eehl.2022.06.001>.

- Linardatos, P., Papastefanopoulos, V., Kotsiantis, S., 2020. AI có thể giải thích: tổng quan về các phương pháp diễn giải tính khả diễn giải của học máy. *Entropy* 23 (1), 18. <https://doi.org/10.3390/e23010018>.
- Liu, L., Zhou, X., Dueñas-Osorio, L., Stadler, L., Li, Q., 2023. Xử lý và tái sử dụng nước thải kết hợp giúp tăng cường khả năng chống chịu của hệ thống nước đô thị trước các sự cố gây gián đoạn. *Nat. Water* 1 (12), 1048–1058. <https://doi.org/10.1038/s44221-023-00166-6>.
- Lowe, M., Qin, R., Mao, X., 2022. Tổng quan về học máy, trí tuệ nhân tạo và công nghệ thông minh trong xử lý và giám sát nước. *Water* 14 (9), 1384. <https://doi.org/10.3390/w14091384>.
- Lundberg, S., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. Maggiorotto, G., 2022. Tái sử dụng nước xấp xỉ để giảm nhiệt độ tại các thành phố thuộc lưu vực Địa Trung Hải. *Earth* 3 (1), 72–75. <https://doi.org/10.3390/earth3010005>.
- Moretti, A., Ivan, H.L., Skvaril, J., 2024. Tổng quan về các công nghệ tiên tiến nhất trong đặc trưng hóa và đo lường chất lượng nước thải. Việc chuyển sang giám sát thời gian thực hiện nay có khả thi không? *J. Water Process Eng.* 60, 105061. <https://doi.org/10.1016/j.jwpe.2024.105061>.
- Muniz de Queiroz, M., Moreira, V.R., Amaral, M.C.S., Oliveira, S.M.A.C., 2025. Các thuật toán học máy dự đoán hiệu suất của bể phản ứng sinh học màng: tổng quan. *J. Environ. Manag.* 380, 124978. <https://doi.org/10.1016/j.jenvman.2025.124978>.
- Murdoch, W.J., Singh, C., Kumbier, K., Abbasi-Asl, R., Yu, B., 2019. Định nghĩa, phương pháp và ứng dụng trong học máy có thể diễn giải. *Proc. Natl. Acad. Sci.* 116 (44), 22071–22080. <https://doi.org/10.1073/pnas.1900654116>.
- Nguyen, D.-V., Wang, S., Nguyen, D.-P., Ching, P.M.L., Shim, J.H., Jung, Y., Wu, D., So, R.H.Y., 2024. Những phát triển hiện nay của các mô hình học máy sử dụng thuật toán boosting để dự đoán chất lượng nước. Trong *Water Security: Big Data-Driven Risk Identification, Assessment and Control of Emerging Contaminants*. Elsevier, tr. 575–591. <https://doi.org/10.1016/B978-0-443-14170-6.00015-9>.
- Nieves-Avendano, D., Deschrijver, D., Van Hoecke, S., 2023. Học chuyển giao để phát hiện bất thường bằng cách sử dụng tín hiệu rung của ổ trục. *Int. J. Acoust. Vib.* 28 (4), 420–434. <https://doi.org/10.20855/ijav.2023.28.41993>.
- Noor, A., Mohamed Kutty, S.R., Baloo, L., Affam, A.C., Jagaba, A.H., Saeed Ghaleb, A.A., Yahya Almahbashi, N.M., Ahmad, T., Nawab, M.S., Birniwa, A.H., 2023. Tối ưu hóa tham số của giá thể sinh học được chế tạo bằng phương pháp bồi đắp, nhúng trong bể phản ứng theo mô tuần tự để xử lý nước thải sinh hoạt. *Heliyon* 9 (4), e14840. <https://doi.org/10.1016/j.heliyon.2023.e14840>.
- Omar, A., Almomani, F., Qiblawey, H., Rasool, K., 2024. Những tiến bộ trong xử lý nước thải giàu nitơ: tổng quan toàn diện về các công nghệ hiện đại. *Sustainability* 16 (5), 2112. <https://doi.org/10.3390/su16052112>.
- Ongena, S., de Walle, A.V., Mosquera-Romero, S., Driesen, N., Gutierrez, L., Rabaey, K., 2023. So sánh MBR và MBBR kết hợp khử trùng bằng tia UV hoặc điện hóa để xử lý nước xám phi tập trung. *Water Res* 235, 119818. <https://doi.org/10.1016/j.watres.2023.119818>.
- Paetkau, M., Cicek, N., 2011. So sánh hiệu quả loại bỏ nitơ và đặc tính bùn giữa bể phản ứng sinh học màng nitrat hóa–khử nitrat hóa đồng thời và bể phản ứng sinh học màng thông thường. *Desalination* 283, 165–168. <https://doi.org/10.1016/j.desal.2011.02.018>.
- Pekalska, E., Harol, A., Lai, C., Duin, R.P.W., 2005. Lựa chọn từng cặp đặc trưng và nguyên mẫu. *Computer Recognition Systems: Proceedings of the 4th International Conference on Computer Recognition Systems CORES’05*, 271–278. https://doi.org/10.1007/3-540-32390-2_31.
- Pinto, U., Maheshwari, B.L., 2015. Sustainable graywater reuse for residential landscape irrigation – a critical review. *Chin. J. Popul. Resour. Environ.* 13 (3), 250–264. <https://doi.org/10.1080/10042857.2015.1059790>.
- Rahman, T.U., Roy, H., Islam, Md.R., Tahmid, M., Fariha, A., Mazumder, A., Tasnim, N., Pervaz, Md.N., Cai, Y., Naddeo, V., Islam, Md.S., 2023. The advancement in membrane bioreactor (MBR) technology toward sustainable industrial wastewater management. *Membranes* 13 (2), 181. <https://doi.org/10.3390/membranes13020181>.
- Reynaert, E., Nagappa, D., Sigrist, J.A., Morgenroth, E., 2024. Dự đoán chất lượng vi sinh của nước trong các hệ thống tái sử dụng nước tại chỗ bằng cảm biến trực tuyến. *Water Res.* 240, 120075. <https://doi.org/10.1016/j.watres.2023.120075>.
- Saito, T., Rehmsmeier, M., 2015. Biểu đồ Precision-Recall cung cấp nhiều thông tin hơn biểu đồ ROC khi đánh giá bộ phân loại nhị phân trên các tập dữ liệu mất cân bằng. *PLOS ONE* 10 (3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>.
- Salvia, M., Sanchez, N., Piles, M., Ruscica, R., Gonzalez-Zamora, A., Roitberg, E., Martinez-Fernandez, J., 2021. Giá trị gia tăng của dữ liệu độ ẩm đất viễn thám trong phát hiện hạn hán nông nghiệp ở Argentina. *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.* 14, 6487–6500. <https://doi.org/10.1109/JSTARS.2021.3084849>.
- Scott, D.W., 2015. Ước lượng mật độ hạt nhân. Trong *Multivariate Density Estimation: Theory, Practice, and Visualization*, Ấn bản thứ 2, tr. 137–216. <https://doi.org/10.1002/9781118575574.ch6>.
- Shaikh, I.N., Ahmed, M.M., 2020. Đặc điểm về lượng và chất của nước xám: tổng quan. Trong: *Journal of Environmental Management*, 261. Academic Press. <https://doi.org/10.1016/j.jenvman.2020.110266>.
- Shi, Y., Wang, Z., Du, X., Ling, G., Jia, W., Lu, Y., 2022. Nghiên cứu chẩn đoán tắc nghẽn màng của mô-đun màng MBR dựa trên ECA-CNN. *J. Environ. Manag.* 371, 123173. <https://doi.org/10.1016/j.jenvman.2024.123173>.
- Szeghalmy, S., Fazekas, A., 2023. Kiểm định chéo phân tầng cân bằng phân phối để ước lượng độ chính xác. *J. Exp. Theor. Artif. Intell.* 12 (1), 1–12. <https://doi.org/10.1080/095281300146272>.
- Zhang, H., 2022. AI và dữ liệu lớn trong môi trường nước. *ACS ES T Water Am. Chem. Soc.* <https://doi.org/10.1021/acsestwater.2c00203>.
- Zhong, H., Yuan, Y., Luo, L., Ye, J., Chen, M., Zhong, C., 2022. Dự đoán chất lượng nước của MBR dựa trên học máy: phương pháp phân tích đóng góp của bộ dữ liệu mới. *J. Water Process Eng.* 50, 103296. <https://doi.org/10.1016/j.jwpe.2022.103296>.
- Zhou, X., Han, X., Shi, K., Chen, X., Guo, D., Zheng, Y., Lu, L., Ouyang, M., 2025. Quản lý tuổi thọ pin thông minh thông qua cơ chế và học máy trong điều kiện vận hành thực tế của phương tiện. *J. Power Sources* 640, 236749. <https://doi.org/10.1016/j.jpowsour.2025.236749>.
- Zhu, M., Wang, J., Yang, X., Zhang, Y., Zhang, L., Ren, H., Wu, B., Ye, L., 2022. Tổng quan về ứng dụng học máy trong đánh giá chất lượng nước. *Eco Environ. Health* 1 (2), 107–116. <https://doi.org/10.1016/j.eehl.2022.06.001>.