

Article

Predictive Framework for Membrane Fouling in Full-Scale Membrane Bioreactors (MBRs): Integrating AI-Driven Feature Engineering and Explainable AI (XAI)

Jie Liang ^{1,†}, Sangyoup Lee ^{2,†} , Xianghao Ren ^{1,*}, Yingjie Guo ¹, Jeonghyun Park ³ , Sung-Gwan Park ², Ji-Yeon Kim ² and Moon-Hyun Hwang ^{2,*}

- ¹ Key Laboratory of Urban Stormwater System and Water Environment, Ministry of Education, Beijing University of Civil Engineering and Architecture, Beijing 100044, China; liangjie1165690218@163.com (J.L.); 17861271581@163.com (Y.G.)
- ² Institute of Conversions Science, Korea University, 145, Anam-ro, Sungbuk-gu, Seoul 02841, Republic of Korea; sangyoup_lee@korea.ac.kr (S.L.); sunggwan2@korea.ac.kr (S.-G.P.); greentree84@korea.ac.kr (J.-Y.K.)
- ³ Graduate School of Engineering Practice, Seoul National University, 1, Gwanak-ro, Gwanak-gu, Seoul 08826, Republic of Korea; park.jeonghyun@snu.ac.kr
- * Correspondence: renxianghao@bucea.edu.cn (X.R.); h2sm2000@korea.ac.kr (M.-H.H.)
- † These authors contributed equally to this work.

Abstract

Membrane fouling remains a major challenge in full-scale membrane bioreactor (MBR) systems, reducing operational efficiency and increasing maintenance needs. This study introduces a predictive and analytic framework for membrane fouling by integrating artificial intelligence (AI)-driven feature engineering and explainable AI (XAI) using real-world data from an MBR treating food processing wastewater. The framework refines the target parameter to specific flux (flux/transmembrane pressure (TMP)), incorporates chemical oxygen demand (COD) removal efficiency to reflect biological performance, and applies a moving average function to capture temporal fouling dynamics. Among tested models, CatBoost achieved the highest predictive accuracy ($R^2 = 0.8374$), outperforming traditional statistical and other machine learning models. XAI analysis identified the food-to-microorganism (F/M) ratio and mixed liquor suspended solids (MLSSs) as the most influential variables affecting fouling. This robust and interpretable approach enables proactive fouling prediction and supports informed decision making in practical MBR operations, even with limited data. The methodology establishes a foundation for future integration with real-time monitoring and adaptive control, contributing to more sustainable and efficient membrane-based wastewater treatment operations. However, this study is based on data from a single full-scale MBR treating food processing wastewater and lacks severe fouling or cleaning events, so further validation with diverse datasets is needed to confirm broader applicability.

Keywords: membrane fouling; membrane bioreactor (MBR); predictive and analytic framework; AI-driven feature engineering; explainable AI (XAI)

1. Introduction

Membrane bioreactor (MBR) technology has emerged as a crucial innovation in the wastewater treatment industry, offering significant advantages over conventional activated sludge processes. MBRs combine biological treatment with membrane filtration, resulting

Article

Khung dự đoán hiện tượng tắc nghẽn màng trong các hệ thống bể phản ứng sinh học màng (MBR) quy mô toàn phần: Tích hợp kỹ thuật tạo đặc trưng dựa trên AI và AI có khả năng giải thích (XAI)

Jie Liang ^{1,†}, Sangyoup Lee ^{2,†} , Xianghao Ren ^{1,*}, Yingjie Guo ¹, Jeonghyun Park ³, Sung-Gwan Park ², Ji-Yeon Kim ² và Moon-Hyun Hwang ^{2,*}

- ¹ Phòng thí nghiệm trọng điểm về Hệ thống nước mưa đô thị và Môi trường nước, Bộ Giáo dục, Đại học Kiến trúc và Xây dựng Bắc Kinh, Bắc Kinh 100044, Trung Quốc; liangjie1165690218@163.com (J.L.); 17861271581@163.com (Y.G.) ² Viện Khoa học Chuyển đổi, Đại học Korea, 145, Anam-ro, Sungbuk-gu, Seoul 02841, Hàn Quốc; sangyoup_lee@korea.ac.kr (S.L.); sunggwan2@korea.ac.kr (S.-G.P.); greentree84@korea.ac.kr (J.-Y.K.) ³ Trường Sau đại học về Thực hành Kỹ thuật, Đại học Quốc gia Seoul, 1, Gwanak-ro, Gwanak-gu, Seoul 08826, Hàn Quốc; park.jeonghyun@snu.ac.kr * Tác giả liên hệ: renxianghao@bucea.edu.cn (X.R.); h2sm2000@korea.ac.kr (M.-H.H.) [†] Các tác giả này có đóng góp ngang nhau cho công trình nghiên cứu này.

Tóm tắt

Hiện tượng tắc nghẽn màng vẫn là một thách thức lớn trong các hệ thống thiết bị phản ứng sinh học màng (MBR) quy mô công nghiệp, làm giảm hiệu quả vận hành và gia tăng nhu cầu bảo trì. Nghiên cứu này giới thiệu một khuôn khổ dự đoán và phân tích hiện tượng tắc nghẽn màng bằng cách tích hợp kỹ thuật đặc trưng dựa trên trí tuệ nhân tạo (AI) và AI có khả năng giải thích (XAI), sử dụng dữ liệu thực tế từ một hệ thống MBR xử lý nước thải chế biến thực phẩm. Khuôn khổ này tinh chỉnh tham số mục tiêu thành thông lượng riêng (thông lượng/áp suất xuyên màng (TMP)), đưa hiệu suất loại bỏ nhu cầu oxy hóa học (COD) vào để phản ánh hiệu quả sinh học, đồng thời áp dụng hàm trung bình trượt để nắm bắt diễn biến tắc nghẽn theo thời gian. Trong số các mô hình được thử nghiệm, CatBoost đạt độ chính xác dự đoán cao nhất ($R^2 = 0.8374$), vượt trội so với các mô hình thống kê truyền thống và các mô hình học máy khác. Phân tích XAI xác định tỷ lệ thức ăn/vi sinh vật (F/M) và chất rắn lơ lửng trong hỗn hợp bùn (MLSS) là những biến có ảnh hưởng lớn nhất đến hiện tượng tắc nghẽn. Phương pháp vững chắc và dễ diễn giải này cho phép dự đoán tắc nghẽn chủ động, đồng thời hỗ trợ đưa ra quyết định dựa trên thông tin trong vận hành MBR thực tế, ngay cả khi dữ liệu hạn chế. Phương pháp luận này tạo nền tảng cho việc tích hợp trong tương lai với hệ thống giám sát thời gian thực và điều khiển thích ứng, góp phần nâng cao tính bền vững và hiệu quả của hoạt động xử lý nước thải bằng màng. Tuy nhiên, nghiên cứu này dựa trên dữ liệu từ một hệ thống MBR quy mô công nghiệp duy nhất xử lý nước thải chế biến thực phẩm và không có các sự kiện tắc nghẽn nghiêm trọng hoặc làm sạch màng; do đó, cần thẩm định thêm bằng các bộ dữ liệu đa dạng để xác nhận khả năng áp dụng rộng rãi hơn.

Từ khóa: cấu bẩn màng; bể phản ứng sinh học màng (MBR); khung dự báo và phân tích; kỹ thuật đặc trưng ứng dụng AI; trí tuệ nhân tạo có khả năng giải thích (XAI)

1. Giới thiệu

Công nghệ bể phản ứng sinh học màng (MBR) đã trở thành một đối mới quan trọng trong ngành xử lý nước thải, mang lại những ưu điểm đáng kể so với các quy trình bùn hoạt tính thông thường. MBR kết hợp xử lý sinh học với lọc màng, qua đó tạo ra



Academic Editor: Qiang Xue

Received: 27 June 2025

Revised: 17 July 2025

Accepted: 21 July 2025

Published: 24 July 2025

Citation: Liang, J.; Lee, S.; Ren, X.; Guo, Y.; Park, J.; Park, S.-G.; Kim, J.-Y.; Hwang, M.-H. Predictive Framework for Membrane Fouling in Full-Scale Membrane Bioreactors (MBRs): Integrating AI-Driven Feature Engineering and Explainable AI (XAI). *Processes* **2025**, *13*, 2352.

<https://doi.org/10.3390/pr13082352>

Copyright: © 2025 by the authors. Licensee MDPI, Basel, Switzerland. This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).



Biên tập viên học thuật: Qiang Xue

Ngày nhận: 27 tháng 6 năm 2025; Ngày sửa đổi: 17 tháng 7 năm 2025; Ngày chấp nhận: 21 tháng 7 năm 2025; Ngày xuất bản: 24 tháng 7 năm 2025
Trích dẫn: Liang, J.; Lee, S.; Ren, X.; Guo, Y.; Park, J.; Park, S.-G.; Kim, J.-Y.; Hwang, M.-H. Khung dự đoán hiện tượng tắc màng trong các bể phản ứng sinh học màng (MBR) quy mô lớn: Tích hợp kỹ thuật đặc trưng dựa trên AI và AI có khả năng giải thích (XAI). *Processes* **2025**, *13*, 2352. <https://doi.org/10.3390/pr13082352>

Bản quyền: © 2025 thuộc về các tác giả. Đơn vị cấp phép: MDPI, Basel, Thụy Sĩ. Đây là bài báo truy cập mở được phân phối theo các điều khoản và điều kiện của giấy phép Creative Commons Ghi công (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

in high-quality effluent suitable for various reuse applications [1,2]. The process is characterized by its compact footprint, reduced sludge production, and superior removal of contaminants, including micropollutants and pathogens [3]. These benefits have led to the widespread adoption of MBRs in both municipal and industrial wastewater treatment facilities worldwide. However, MBR technology faces a persistent challenge: membrane fouling [4,5]. Fouling results from the accumulation of particles, colloids, and dissolved substances on or within the membrane, causing decreased permeability, increased energy consumption, and more frequent cleaning or replacement. It is influenced by factors such as influent wastewater characteristics, operational conditions, and biomass properties [6–8], ultimately impacting operational efficiency and significantly increasing maintenance costs. As the industry evolves, innovative solutions and predictive tools are needed to address fouling and optimize MBR performance for long-term sustainability.

The prediction of membrane fouling in MBR processes has become increasingly crucial for optimizing operational efficiency and reducing maintenance costs. Accurate fouling prediction allows operators to implement proactive measures, such as adjusting operational parameters or scheduling cleaning interventions, to mitigate the negative impacts of fouling on system performance [9–14]. Effective treatment of diverse wastewaters requires optimizing process design and operational conditions to minimize membrane fouling. Given its flux-driven nature, operating at excessively high flux may reduce cleaning frequency temporarily but accelerate fouling, raising long-term costs and risks [9]. Accurate fouling prediction enables the selection of operating conditions that balance productivity, effluent quality, cleaning needs, and overall cost. This highlights the role of predictive tools in achieving sustainable and economical MBR operation. Traditional approaches to fouling prediction have relied on empirical models and laboratory-scale experiments, which often fail to capture the complex dynamics of full-scale MBR systems. In recent years, researchers have explored various advanced techniques to enhance fouling prediction accuracy [10,11]. Mechanistic models based on principles of fluid dynamics, mass transfer, and biofilm formation have been developed to simulate the intricate interactions between biomass, suspended solids, and membrane surfaces, providing insights into fouling mechanisms [12]. Statistical and data-driven approaches, including time-series analysis and multivariate techniques, have also been used to identify correlations and detect trends in membrane performance [13,14]. Additionally, researchers have investigated the use of online monitoring tools and sensors to provide real-time data on key fouling indicators, such as transmembrane pressure (TMP) and permeate flux [15,16]. While these methods have shown promise in specific applications, they often face limitations when applied to the diverse and dynamic conditions encountered in full-scale MBR operations. The complexity of the fouling process, influenced by numerous interrelated factors, poses a significant challenge to developing universally applicable prediction models. Moreover, the time-dependent nature of fouling and the potential for sudden changes in influent characteristics or operational conditions further complicate prediction [17,18]. As a result, there is a growing recognition of the need for more sophisticated and adaptable approaches to membrane fouling prediction in MBR systems.

Artificial intelligence (AI) has emerged as a powerful tool for predicting membrane fouling in MBR systems, offering several advantages over traditional methods [19–24]. AI-based approaches, particularly machine learning algorithms, can effectively handle complex non-linear relationships between multiple variables and capture hidden patterns in large datasets [25–28]. These techniques have demonstrated superior predictive performance compared to conventional statistical models, especially when dealing with the dynamic and multifaceted nature of MBR fouling. However, most previous applications have been validated primarily under controlled laboratory or pilot-scale conditions, with

tạo ra nước thải sau xử lý có chất lượng cao, phù hợp với nhiều mục đích tái sử dụng khác nhau [1,2]. Quá trình này có ưu điểm là diện tích lắp đặt nhỏ gọn, lượng bùn phát sinh giảm và khả năng loại bỏ vượt trội các chất ô nhiễm, bao gồm vi chất ô nhiễm và mầm bệnh [3]. Những lợi ích này đã thúc đẩy việc ứng dụng rộng rãi MBR tại các cơ sở xử lý nước thải đô thị và công nghiệp trên toàn thế giới. Tuy nhiên, công nghệ MBR vẫn phải đối mặt với một thách thức dai dẳng: hiện tượng cáu bẩn màng [4, 5]. Cáu bẩn hình thành do các hạt, chất keo và chất hòa tan tích tụ trên hoặc bên trong màng, làm giảm độ thấm, tăng mức tiêu thụ năng lượng và khiến việc vệ sinh hoặc thay thế màng diễn ra thường xuyên hơn. Hiện tượng này chịu ảnh hưởng của các yếu tố như đặc tính nước thải đầu vào, điều kiện vận hành và đặc tính sinh khối [6–8], cuối cùng làm giảm hiệu quả vận hành và tăng đáng kể chi phí bảo trì. Khi ngành công nghiệp không ngừng phát triển, cần có các giải pháp đổi mới và công cụ dự báo để xử lý tình trạng cáu bẩn, đồng thời tối ưu hóa hiệu suất MBR nhằm bảo đảm tính bền vững lâu dài.

Việc dự đoán hiện tượng tắc nghẽn màng trong các quy trình MBR ngày càng trở nên quan trọng đối với việc tối ưu hóa hiệu quả vận hành và giảm chi phí bảo trì. Dự đoán chính xác hiện tượng tắc nghẽn cho phép người vận hành chủ động áp dụng các biện pháp như điều chỉnh thông số vận hành hoặc lên lịch vệ sinh để giảm thiểu tác động tiêu cực của hiện tượng này đến hiệu suất hệ thống [9–14]. Để xử lý hiệu quả các loại nước thải đa dạng, cần tối ưu hóa thiết kế quy trình và điều kiện vận hành nhằm giảm thiểu tắc nghẽn màng. Do đặc tính phụ thuộc vào thông lượng, vận hành ở thông lượng quá cao có thể tạm thời giảm tần suất vệ sinh nhưng lại đẩy nhanh quá trình tắc nghẽn, làm tăng chi phí và rủi ro về lâu dài [9]. Dự đoán chính xác hiện tượng tắc nghẽn giúp lựa chọn điều kiện vận hành cân bằng giữa năng suất, chất lượng nước đầu ra, nhu cầu vệ sinh và tổng chi phí. Điều này nhấn mạnh vai trò của các công cụ dự báo trong việc bảo đảm vận hành MBR bền vững và tiết kiệm. Các phương pháp dự đoán tắc nghẽn truyền thống chủ yếu dựa vào mô hình thực nghiệm và các thử nghiệm ở quy mô phòng thí nghiệm, vốn thường không mô tả được động lực phức tạp của các hệ thống MBR quy mô thực tế. Trong những năm gần đây, các nhà nghiên cứu đã tìm hiểu nhiều kỹ thuật tiên tiến nhằm nâng cao độ chính xác của dự đoán tắc nghẽn [10,11]. Các mô hình cơ chế dựa trên nguyên lý động lực học chất lưu, truyền khối và hình thành màng sinh học đã được phát triển để mô phỏng các tương tác phức tạp giữa sinh khối, chất rắn lơ lửng và bề mặt màng, qua đó cung cấp hiểu biết về các cơ chế gây tắc nghẽn [12]. Các phương pháp thống kê và dựa trên dữ liệu, bao gồm phân tích chuỗi thời gian và kỹ thuật đa biến, cũng được sử dụng để xác định mối tương quan và phát hiện xu hướng trong hiệu suất màng [13,14]. Ngẫu nhiên, các nhà nghiên cứu đã khảo sát việc sử dụng công cụ giám sát trực tuyến và cảm biến để cung cấp dữ liệu theo thời gian thực về các chỉ số tắc nghẽn chính, chẳng hạn như áp suất xuyên màng (TMP) và thông lượng dịch thấm [15,16]. Dù cho thấy nhiều triển vọng trong một số ứng dụng cụ thể, các phương pháp này thường gặp hạn chế khi áp dụng trong những điều kiện đa dạng và biến động của hoạt động MBR quy mô thực tế. Tính phức tạp của quá trình tắc nghẽn, chịu ảnh hưởng của nhiều yếu tố liên quan lẫn nhau, là thách thức đáng kể đối với việc phát triển các mô hình dự đoán có khả năng áp dụng phổ quát. Hơn nữa, đặc tính biến đổi theo thời gian của hiện tượng tắc nghẽn cùng khả năng thay đổi đột ngột về đặc tính nước đầu vào hoặc điều kiện vận hành càng khiến việc dự đoán trở nên phức tạp [17,18]. Do đó, ngày càng có nhiều sự thừa nhận về nhu cầu phát triển các phương pháp tính vi và thích ứng hơn để dự đoán hiện tượng tắc nghẽn màng trong các hệ thống MBR.

Trí tuệ nhân tạo (AI) đã nổi lên như một công cụ mạnh mẽ để dự đoán hiện tượng tắc nghẽn màng trong các hệ thống MBR, mang lại một số ưu điểm so với các phương pháp truyền thống [19–24]. Các phương pháp dựa trên AI, đặc biệt là thuật toán học máy, có thể xử lý hiệu quả các mối quan hệ phi tuyến phức tạp giữa nhiều biến và phát hiện các quy luật ẩn trong những tập dữ liệu lớn [25–28]. Những kỹ thuật này đã cho thấy hiệu suất dự đoán vượt trội so với các mô hình thống kê thông thường, nhất là khi xử lý tính chất động và đa diện của hiện tượng tắc nghẽn màng trong MBR. Tuy nhiên, hầu hết các ứng dụng trước đây chủ yếu được thẩm định trong điều kiện phòng thí nghiệm được kiểm soát hoặc ở quy mô thí điểm, với

limited demonstration in the noisy and dynamic environments of full-scale MBRs. Various AI algorithms have been applied to MBR fouling prediction, including artificial neural networks (ANNs), support vector machines (SVMs), random forests, and, more recently, deep learning models [19–24]. These models typically utilize a range of input parameters to predict fouling indicators, such as TMP or permeate flux. Common input variables include operational parameters (e.g., aeration rate, flux, MLSS concentration), influent characteristics (e.g., chemical oxygen demand (COD), nutrients, temperature), and membrane properties. Some studies have also incorporated advanced feature engineering techniques to enhance model performance, such as principal component analysis (PCA) for dimensionality reduction or wavelet transforms for time-series analysis [25,26]. The selection of appropriate input parameters and target variables is crucial for developing accurate and robust AI models. Researchers have explored various combinations of parameters, with some focusing on easily measurable online data, while others incorporate more comprehensive sets of physicochemical and biological indicators [27,28].

Despite the promising results achieved by AI-based fouling prediction models, several limitations and challenges persist, particularly regarding their robustness and generalizability when transitioning from controlled experimental settings to real-world full-scale MBR operations. One significant drawback is the “black box” nature of many AI algorithms, particularly deep learning models, which can make it difficult for operators to understand and trust the predictions [29–31]. This lack of interpretability can hinder the adoption of AI models in practical MBR operations, where operators need to make informed decisions based on model outputs. Another challenge lies in the quality and representativeness of the data used to train AI models. Many studies rely on data collected from well-controlled laboratory experiments or pilot-scale systems, which, unlike real-world full-scale MBR operations, often lack the noise, missing values, and operational variability encountered in practice. As a result, AI models developed under such conditions may not perform reliably when applied to real-world data, highlighting the need for approaches validated in actual operational environments. The issue of data scaling and normalization is also critical, as different input parameters often have vastly different ranges and units, potentially leading to biased or inaccurate predictions if not properly addressed. This is especially true considering the significant variability in the characteristics of wastewater treatment plant data [32,33]. Membrane fouling exhibits a time-dependent nature not only in MBR processes, but also in most membrane processes [34–36]. To capture the time-dependent nature of fouling, AI models must use feature engineering that accounts for both current and historical operational data. Most existing methods overlook the cumulative effects of past conditions, underscoring the need for advanced techniques that incorporate temporal dependencies and long-term trends in MBR performance. Another consideration is the choice of target parameter for fouling prediction. To date, the most commonly used representative target parameters (i.e., outputs) for predicting membrane fouling based on AI are TMP and flux [37–40]. In the case of TMP, when the operation mode of the MBR process is constant flux mode, it increases as membrane fouling progresses; conversely, in the case of flux, when the operation mode is constant pressure mode, it decreases as membrane fouling progresses [41–43]. In most cases, MBR processes are operated in constant flux mode [44,45]. However, due to inflow variability and changing environmental conditions, both flux and TMP often fluctuate even under constant flux operation. Therefore, it is important to select target parameters that reflect these simultaneous variations. Further research should focus on identifying such parameters to provide more accurate and practical insights into membrane fouling and to improve prediction performance. Continued efforts to enhance model interpretability, data quality, and feature engineering are essential for advancing AI-based fouling prediction and its practical application in MBR operations.

khả năng áp dụng còn hạn chế trong các môi trường nhiễu và biến động của các hệ thống MBR quy mô đầy đủ. Nhiều thuật toán AI đã được áp dụng để dự đoán hiện tượng tắc nghẽn màng trong MBR, bao gồm mạng nơ-ron nhân tạo (ANN), máy véc-tơ hỗ trợ (SVM), rừng ngẫu nhiên và gần đây hơn là các mô hình học sâu [19–24]. Các mô hình này thường sử dụng nhiều thông số đầu vào để dự đoán các chỉ báo tắc nghẽn, chẳng hạn như TMP hoặc thông lượng dịch thấm. Các biến đầu vào phổ biến gồm thông số vận hành (ví dụ: tốc độ sục khí, thông lượng, nồng độ MLSS), đặc tính nước thải đầu vào (ví dụ: nhu cầu oxy hóa học (COD), chất dinh dưỡng, nhiệt độ) và đặc tính màng. Một số nghiên cứu cũng áp dụng các kỹ thuật xây dựng đặc trưng tiên tiến để nâng cao hiệu suất mô hình, chẳng hạn như phân tích thành phần chính (PCA) để giảm số chiều hoặc biến đổi wavelet để phân tích chuỗi thời gian [25,26]. Việc lựa chọn các thông số đầu vào và biến mục tiêu phù hợp đóng vai trò then chốt trong phát triển các mô hình AI chính xác và đáng tin cậy. Các nhà nghiên cứu đã khảo sát nhiều tổ hợp thông số khác nhau; một số tập trung vào dữ liệu trực tuyến để đo lường, trong khi những nghiên cứu khác sử dụng các bộ chỉ báo hóa lý và sinh học toàn diện hơn [27,28].

Mặc dù các mô hình dự đoán tắc nghẽn dựa trên AI đã đạt được những kết quả đầy hứa hẹn, vẫn còn tồn tại một số hạn chế và thách thức, đặc biệt là về độ tin cậy và khả năng khái quát hóa khi chuyển từ môi trường thí nghiệm được kiểm soát sang vận hành MBR quy mô toàn phần trong thực tế. Một nhược điểm đáng kể là tính chất “hộp đen” của nhiều thuật toán AI, đặc biệt là các mô hình học sâu, khiến người vận hành khó hiểu và tin tưởng vào các dự đoán [29–31]. Khả năng diễn giải hạn chế này có thể cản trở việc áp dụng các mô hình AI vào vận hành MBR thực tế, nơi người vận hành cần đưa ra quyết định sáng suốt dựa trên kết quả đầu ra của mô hình. Một thách thức khác nằm ở chất lượng và tính đại diện của dữ liệu dùng để huấn luyện các mô hình AI. Nhiều nghiên cứu dựa vào dữ liệu thu thập từ các thí nghiệm trong phòng thí nghiệm được kiểm soát chặt chẽ hoặc các hệ thống quy mô thí điểm; khác với hoạt động MBR quy mô toàn phần trong thực tế, các hệ thống này thường không có nhiễu, giá trị bị thiếu và biến động vận hành vốn thường gặp trong thực tiễn. Do đó, các mô hình AI được phát triển trong những điều kiện như vậy có thể không hoạt động đáng tin cậy khi áp dụng cho dữ liệu thực tế, cho thấy cần có những phương pháp được kiểm chứng trong môi trường vận hành thực. Việc mở rộng quy mô và chuẩn hóa dữ liệu cũng rất quan trọng, vì các tham số đầu vào khác nhau thường có đơn vị và giá trị rất khác biệt, có khả năng dẫn đến dự đoán thiên lệch hoặc thiếu chính xác nếu không được xử lý phù hợp. Điều này đặc biệt đúng khi xét đến sự biến động đáng kể trong các đặc tính của dữ liệu tại nhà máy xử lý nước thải [32,33]. Hiện tượng tắc nghẽn màng phụ thuộc vào thời gian không chỉ trong các quy trình MBR mà còn trong hầu hết các quy trình màng [34–36]. Để nắm bắt đặc tính phụ thuộc thời gian của hiện tượng tắc nghẽn, các mô hình AI phải sử dụng kỹ thuật tạo đặc trưng có tính đến cả dữ liệu vận hành hiện tại lẫn dữ liệu trong quá khứ. Hầu hết các phương pháp hiện có bỏ qua ảnh hưởng tích lũy của các điều kiện trước đó, cho thấy cần có những kỹ thuật tiên tiến hơn để tích hợp các yếu tố phụ thuộc thời gian và xu hướng dài hạn trong hiệu suất MBR. Một vấn đề khác cần cân nhắc là lựa chọn tham số mục tiêu để dự đoán tắc nghẽn. Cho đến nay, các tham số mục tiêu đại diện (tức đầu ra) thường được dùng nhất để dự đoán hiện tượng tắc nghẽn màng dựa trên AI là TMP và thông lượng [37–40]. Với TMP, khi quy trình MBR vận hành ở chế độ thông lượng không đổi, TMP tăng khi hiện tượng tắc nghẽn màng tiến triển; ngược lại, với thông lượng, khi quy trình vận hành ở chế độ áp suất không đổi, thông lượng giảm khi hiện tượng tắc nghẽn màng tiến triển [41–43]. Trong hầu hết các trường hợp, quy trình MBR vận hành ở chế độ thông lượng không đổi [44,45]. Tuy nhiên, do lưu lượng đầu vào biến động và điều kiện môi trường thay đổi, cả thông lượng lẫn TMP thường dao động ngay cả khi vận hành ở chế độ thông lượng không đổi. Vì vậy, cần lựa chọn các tham số mục tiêu phản ánh những biến động đồng thời này. Các nghiên cứu tiếp theo nên tập trung xác định những tham số như vậy để cung cấp thông tin chuyên sâu chính xác và thiết thực hơn về hiện tượng tắc nghẽn màng, đồng thời cải thiện hiệu suất dự đoán. Những nỗ lực liên tục nhằm nâng cao khả năng diễn giải của mô hình, chất lượng dữ liệu và kỹ thuật tạo đặc trưng là thiết yếu để thúc đẩy việc dự đoán tắc nghẽn dựa trên AI và ứng dụng thực tiễn của phương pháp này trong vận hành MBR.

The primary objective of this study is to develop a predictive framework for membrane fouling in full-scale MBRs by integrating AI-driven feature engineering and explainable AI (XAI). To achieve this, the research focuses on innovative modeling strategies that enhance both prediction accuracy and practical applicability under real-world operating conditions. This study prioritizes parameters measurable in resource-constrained field environments, avoiding reliance on idealized or synthetic data. The proposed AI-driven feature engineering techniques (e.g., moving averages) explicitly address challenges like sensor noise and infrequent sampling, ensuring relevance to real-world MBR operations. This approach is distinguished by several innovative elements. First, diverse feature engineering techniques are employed to extract meaningful information from raw data, effectively capturing the complex relationships between operational parameters and fouling behavior. Additionally, specific flux (flux/TMP), which is physically equivalent to membrane permeability, is introduced as the target parameter. This dynamic indicator comprehensively reflects membrane performance by simultaneously accounting for variations in both flux and transmembrane pressure. Furthermore, COD removal efficiency is incorporated as an input parameter, reflecting the biological performance of the MBR system and its potential impact on fouling. To account for the time-dependent effects of biological reactions on membrane fouling, a moving average concept is implemented in the selection of input–output data pairs. Moreover, explainable AI models are utilized to enhance operator decision support, thereby improving the interpretability and trustworthiness of fouling predictions. The applicability of the model is demonstrated using over six months of real-world data collected from an operational MBR process, rather than a designed MBR process for this study. This ensures the model’s relevance to the actual data conditions and the non-ideal circumstances present in the field. While physics-based models provide a fundamental understanding of fouling mechanisms and traditional sensing tools offer real-time monitoring, the proposed AI framework complements these approaches by translating complex operational data into actionable insights for proactive control. By integrating with existing sensor networks, the framework can enhance decision making without replacing established physical models, thereby creating a more robust MBR management system. For example, the AI model can receive real-time sensor data (e.g., TMP, DO) and dynamically adjust input parameters for physics-based simulations, enabling adaptive and responsive fouling prediction. By combining AI predictions with traditional fouling indicators, a hybrid alarm or decision support system can be established, leveraging the strengths of both data-driven and mechanistic approaches. Overall, this research makes a significant contribution to the field by presenting a robust and interpretable predictive framework for membrane fouling in full-scale MBRs, integrating AI-driven feature engineering and explainable AI. This approach lays the foundation for more effective membrane fouling management and supports sustainable improvements in MBR operations.

2. Materials and Methods

2.1. MBR Process (Data Collection)

A schematic diagram illustrating the full-scale food processing wastewater treatment process located in Beijing is presented in Figure 1. The treatment train comprises a settling tank, grate tank, equalization tank, two sequential micro-aerobic reactors, a membrane bioreactor (MBR) system, and an effluent tank. Figure 1 also delineates—in red text—the specific parameters and locations at which operational and water quality data were collected. These parameters represent the measurement points utilized for the development of the AI-driven fouling analytic and predictive framework in this study. In this study, the primary focus is placed on the membrane bioreactor (MBR) system, and the AI-driven fouling analytic and predictive framework was developed exclusively using data directly

Mục tiêu chính của nghiên cứu này là phát triển một khuôn khổ dự báo hiện tượng cáu bẩn màng trong các hệ thống MBR quy mô toàn phần bằng cách tích hợp kỹ thuật tạo đặc trưng dựa trên AI và AI có khả năng giải thích (XAI). Để đạt được mục tiêu này, nghiên cứu tập trung vào các chiến lược mô hình hóa đổi mới nhằm nâng cao cả độ chính xác dự báo lẫn khả năng ứng dụng thực tiễn trong điều kiện vận hành thực tế. Nghiên cứu ưu tiên các thông số có thể đo được tại hiện trường khi nguồn lực hạn chế, tránh phụ thuộc vào dữ liệu lý tưởng hóa hoặc dữ liệu tổng hợp. Các kỹ thuật tạo đặc trưng dựa trên AI được đề xuất (ví dụ: trung bình trượt) trực tiếp giải quyết những thách thức như nhiễu cảm biến và tần suất lấy mẫu thấp, bảo đảm tính phù hợp với hoạt động thực tế của hệ thống MBR. Phương pháp này có một số điểm đổi mới nổi bật. Thứ nhất, nhiều kỹ thuật tạo đặc trưng được sử dụng để trích xuất thông tin có ý nghĩa từ dữ liệu thô, qua đó nắm bắt hiệu quả các mối quan hệ phức tạp giữa thông số vận hành và hiện tượng cáu bẩn. Ngoài ra, thông lượng riêng (thông lượng/TMP), tương đương về mặt vật lý với độ thấm của màng, được đưa vào làm thông số mục tiêu. Chỉ số động này phản ánh toàn diện hiệu suất màng bằng cách đồng thời xét đến biến thiên của cả thông lượng lẫn áp suất xuyên màng. Bên cạnh đó, hiệu suất loại bỏ COD được đưa vào làm thông số đầu vào, phản ánh hiệu quả sinh học của hệ thống MBR và khả năng tác động của yếu tố này đến hiện tượng cáu bẩn. Để tính đến ảnh hưởng phụ thuộc thời gian của các phản ứng sinh học đối với hiện tượng cáu bẩn màng, khái niệm trung bình trượt được áp dụng khi lựa chọn các cặp dữ liệu đầu vào–đầu ra. Hơn nữa, các mô hình AI có khả năng giải thích được sử dụng để cải thiện khả năng hỗ trợ người vận hành ra quyết định, từ đó nâng cao tính dễ hiểu và độ tin cậy của các dự báo cáu bẩn. Khả năng ứng dụng của mô hình được chứng minh bằng hơn sáu tháng dữ liệu thực tế thu thập từ một quy trình MBR đang vận hành, thay vì từ một quy trình MBR được thiết kế riêng cho nghiên cứu này. Điều này bảo đảm mô hình phù hợp với điều kiện dữ liệu thực tế và những tình huống không lý tưởng tại hiện trường. Trong khi các mô hình dựa trên vật lý giúp hiểu nền tảng về cơ chế cáu bẩn và các công cụ cảm biến truyền thống cung cấp khả năng giám sát theo thời gian thực, khuôn khổ AI được đề xuất bổ trợ cho những phương pháp này bằng cách chuyển đổi dữ liệu vận hành phức tạp thành thông tin hữu ích để kiểm soát chủ động. Khi tích hợp với các mạng cảm biến hiện có, khuôn khổ này có thể cải thiện việc ra quyết định mà không cần thay thế các mô hình vật lý đã được thiết lập, qua đó tạo nên một hệ thống quản lý MBR vững chắc hơn. Chẳng hạn, mô hình AI có thể tiếp nhận dữ liệu cảm biến theo thời gian thực (ví dụ: TMP, DO) và điều chỉnh linh hoạt các thông số đầu vào cho mô phỏng dựa trên vật lý, giúp dự báo cáu bẩn thích ứng và kịp thời. Bằng cách kết hợp các dự báo của AI với các chỉ báo cáu bẩn truyền thống, có thể xây dựng hệ thống cảnh báo hoặc hỗ trợ ra quyết định lại, tận dụng ưu thế của cả phương pháp dựa trên dữ liệu lẫn phương pháp cơ chế. Nhìn chung, nghiên cứu này đóng góp đáng kể cho lĩnh vực bằng cách trình bày một khuôn khổ dự báo hiện tượng cáu bẩn màng vững chắc và có khả năng giải thích cho các hệ thống MBR quy mô toàn phần, tích hợp kỹ thuật tạo đặc trưng dựa trên AI và AI có khả năng giải thích. Phương pháp này đặt nền tảng cho việc quản lý hiện tượng cáu bẩn màng hiệu quả hơn và hỗ trợ cải thiện bền vững hoạt động của các hệ thống MBR.

2. Vật liệu và phương pháp

2.1. MBR Process (Data Collection)

Sơ đồ khái quát minh họa quy trình xử lý nước thải chế biến thực phẩm quy mô công nghiệp tại Bắc Kinh được trình bày trong Hình 1. Dây chuyền xử lý bao gồm bể lắng, bể chắn rác, bể điều hòa, hai bể phản ứng vi hiếu khí nối tiếp, hệ thống bể phản ứng sinh học màng (MBR) và bể nước sau xử lý. Hình 1 cũng chỉ rõ—bằng chữ màu đỏ—các thông số cụ thể và vị trí thu thập dữ liệu vận hành và chất lượng nước. Các thông số này là những điểm đo được sử dụng để phát triển khung phân tích và dự báo cáu bẩn ứng dụng AI trong nghiên cứu này. Nghiên cứu tập trung chủ yếu vào hệ thống bể phản ứng sinh học màng (MBR), và khung phân tích và dự báo cáu bẩn ứng dụng AI được phát triển hoàn toàn bằng dữ liệu thu thập trực tiếp

associated with the MBR process. Therefore, detailed descriptions of other unit processes depicted in Figure 1, apart from the MBR system, are not provided. It is noteworthy that all data were compiled from routine field operations under real-world conditions, rather than from laboratory or specially designed experimental scenarios. This approach ensures the practical relevance and applicability of the data for predictive modeling in full-scale MBR systems. The MBR system has a daily treatment capacity of 150 m³/d, which meets the processing requirements of the food processing plant. The main components of the MBR system include the membrane module, influent and effluent systems, aeration system, and recirculation system. Polyethylene-embedded hollow fiber membranes with a pore size smaller than 0.4 µm are used in the MBR module. These membranes have an inner and outer diameter of 0.41 mm and 0.65 mm, respectively, with an elongation rate (i.e., the maximum strain the hollow fiber membrane can withstand before failure) of less than 17%. The filtrable surface area of a single membrane group is 200.7 m², with a total of 9 membrane groups in operation. The average influent flow rate to the MBR system is 114 m³/d, with a hydraulic retention time (HRT) of approximately 0.75 days. The dissolved oxygen (DO) concentration is 5.43 mg/L, and the mixed liquor suspended solids (MLSSs) concentration ranges from 5000 to 9000 mg/L. During the monitoring period, no intentional sludge wasting was performed, and the system operated with a stable MLSS concentration. As a result, solid retention time (SRT) was not explicitly controlled or recorded. Intermittent filtration of the effluent is performed by pumps, with a pumping cycle of 10 min on and 5 min off. Membrane cleaning cycle is scheduled when the TMP increases by more than 30% from its baseline value, or when it exceeds 60 kPa, in line with most common submerged MBR operational practice [4,5]. However, no chemical cleaning events, such as chemical-enhanced backwash (CEB) or cleaning in place (CIP), occurred during the 194-day monitoring period because TMP did not exceed the established cleaning thresholds. Thus, the predictive modeling framework does not include data related to chemical cleaning events as input variables.

Samples obtained from the mixed liquor of the MBR reactor were filtered through a 0.45 µm mixed cellulose filter (Advantec, Tokyo, Japan) for COD analysis. The COD was measured according to the guidelines outlined in the Standard Methods for the Examination of Water and Wastewater [46] published by the American Public Health Association (APHA). The concentrations of the COD before and after treatment were measured using a COD meter (DR1010, HACH, Loveland, CO, USA). pH and temperature (Temp.) were quantitatively analyzed using a portable multifunctional electrode (Multi 3630, Munich, Germany) equipped with a meter-matching network. Dissolved oxygen (DO) concentrations were measured using a portable multimeter (PHB-4, Zsynet, Shanghai, China). The MLSS concentration was determined using the gravimetric method. The TMP and flow rate were monitored and recorded daily using pressure gauges and flow meters connected to the operational MBR system. The sludge volume (SV30), sludge volume index (SVI), food-to-microorganism ratio (F/M), and flux were analyzed according to standard methods.

All measurements were collected on a daily basis over a period of 194 days, ensuring a comprehensive dataset for model development. Parameters such as F/M, SV30, SVI, MLSSs, and COD were measured once per day and recorded as daily data points, while variables monitored continuously by online sensors—including DO, pH, temperature, TMP, and flowrate—were processed as daily average values to ensure consistency and comparability across the dataset. Data collection was conducted under actual field conditions typical of real-world MBR operations, where manual sampling and sensor limitations constrained the availability of high-frequency data. Accordingly, variables such as F/M, SV30, SVI, MLSSs, and COD were sampled once daily, and continuously monitored parameters were averaged to daily values to ensure data completeness and comparability. While this

liên quan đến quy trình MBR. Do đó, không cung cấp mô tả chi tiết về các quy trình đơn vị khác được thể hiện trong Hình 1, ngoài hệ thống MBR. Đáng chú ý là toàn bộ dữ liệu được tổng hợp từ hoạt động vận hành thực tế thường xuyên trong điều kiện thực tế, thay vì từ các kịch bản trong phòng thí nghiệm hoặc được thiết kế riêng cho thí nghiệm. Cách tiếp cận này đảm bảo dữ liệu có tính thực tiễn và khả năng áp dụng cho mô hình dự báo trong các hệ thống MBR quy mô toàn phần. Hệ thống MBR có công suất xử lý hằng ngày là 150 m³/d, đáp ứng yêu cầu xử lý của nhà máy chế biến thực phẩm. Các thành phần chính của hệ thống MBR gồm mô-đun màng, hệ thống nước đầu vào và đầu ra, hệ thống sục khí và hệ thống tuần hoàn. Mô-đun MBR sử dụng màng sợi rỗng được nhúng polyethylene, có kích thước lỗ nhỏ hơn 0.4 µm. Đường kính trong và đường kính ngoài của các màng này lần lượt là 0.41 mm và 0.65 mm, với độ giãn dài (tức biến dạng tối đa màng sợi rỗng có thể chịu được trước khi hỏng) dưới 17%. Diện tích bề mặt lọc của một cụm màng là 200.7 m², với tổng cộng 9 cụm màng đang vận hành. Lưu lượng nước đầu vào trung bình của hệ thống MBR là 114 m³/d, với thời gian lưu thủy lực (HRT) khoảng 0.75 ngày. Nồng độ oxy hòa tan (DO) là 5.43 mg/L, còn nồng độ chất rắn lơ lửng trong hỗn hợp bùn (MLSS) dao động từ 5000 đến 9000 mg/L. Trong thời gian giám sát, không chủ động xả bùn và hệ thống vận hành với nồng độ MLSS ổn định. Do đó, thời gian lưu bùn (SRT) không được kiểm soát hoặc ghi nhận cụ thể. Nước đầu ra được lọc gián đoạn bằng bơm, theo chu kỳ bơm 10 phút bật và 5 phút tắt. Chu kỳ làm sạch màng được lên lịch khi TMP tăng hơn 30% so với giá trị cơ sở hoặc vượt quá 60 kPa, phù hợp với thông lệ vận hành phổ biến của MBR chìm [4,5]. Tuy nhiên, trong thời gian giám sát 194 ngày không diễn ra sự kiện làm sạch bằng hóa chất nào, chẳng hạn như rửa ngược tăng cường bằng hóa chất (CEB) hoặc làm sạch tại chỗ (CIP), do TMP không vượt quá các ngưỡng làm sạch đã thiết lập. Vì vậy, khung mô hình dự báo không đưa dữ liệu liên quan đến các sự kiện làm sạch bằng hóa chất vào làm biến đầu vào.

Các mẫu thu được từ hỗn dịch của lò phản ứng MBR được lọc qua màng lọc cellulose hỗn hợp 0,45 µm (Advantec, Tokyo, Nhật Bản) để phân tích COD. COD được đo theo các hướng dẫn nêu trong Standard Methods for the Examination of Water and Wastewater [46] do Hiệp hội Y tế Công cộng Hoa Kỳ (APHA) xuất bản. Nồng độ COD trước và sau xử lý được đo bằng máy đo COD (DR1010, HACH, Loveland, CO, Hoa Kỳ). pH và nhiệt độ (Temp.) được phân tích định lượng bằng điện cực đa chức năng cầm tay (Multi 3630, Munich, Đức) có trang bị mạng kết nối tương thích với máy đo. Nồng độ oxy hòa tan (DO) được đo bằng máy đo đa năng cầm tay (PHB-4, Zsynet, Thượng Hải, Trung Quốc). Nồng độ MLSS được xác định bằng phương pháp khối lượng. TMP và lưu lượng được theo dõi và ghi lại hằng ngày bằng đồng hồ đo áp suất và lưu lượng kết nối với hệ thống MBR đang vận hành. Thể tích bùn (SV30), chỉ số thể tích bùn (SVI), tỷ lệ thức ăn trên vi sinh vật (F/M) và thông lượng được phân tích theo các phương pháp tiêu chuẩn.

Tất cả các phép đo được thu thập hằng ngày trong khoảng thời gian 194 ngày, đảm bảo bộ dữ liệu toàn diện phục vụ phát triển mô hình. Các thông số như F/M, SV30, SVI, MLSSs và COD được đo mỗi ngày một lần và ghi nhận thành các điểm dữ liệu hằng ngày, trong khi các biến được giám sát liên tục bằng cảm biến trực tuyến—bao gồm DO, pH, nhiệt độ, TMP và lưu lượng—được xử lý dưới dạng giá trị trung bình hằng ngày nhằm đảm bảo tính nhất quán và khả năng so sánh trong toàn bộ bộ dữ liệu. Việc thu thập dữ liệu được thực hiện trong điều kiện hiện trường thực tế, điển hình cho hoạt động của các hệ thống MBR, nơi việc lấy mẫu thủ công và những hạn chế của cảm biến khiến dữ liệu tần suất cao không sẵn có. Theo đó, các biến như F/M, SV30, SVI, MLSSs và COD được lấy mẫu mỗi ngày một lần, còn các thông số được giám sát liên tục được tính trung bình theo ngày để đảm bảo tính đầy đủ và khả năng so sánh của dữ liệu. Mặc dù điều này

approach may obscure short-term fluctuations relevant to fouling dynamics, a moving average transformation (see Section 2.3.2) was applied to key features to better capture temporal dependencies and mitigate the loss of meaningful trends associated with short-term variability. These limitations, along with their implications, are discussed earlier in this section (see also Section 2.1). If high-frequency data become available in future work, visualizing intra-day trends could further enhance the analysis and interpretation of fouling behavior. The target parameters were either TMP or specific flux (Spec. Flux). Spec. Flux ($=\text{flux}/\text{TMP}$) is used as a target variable because it directly represents membrane permeability, a key indicator of fouling severity. In actual MBR operations, even under constant flux mode, both flux and TMP are subject to variation due to operational and environmental fluctuations [37,38]. Thus, Spec. Flux captures these simultaneous changes more effectively than either parameter alone, making it a more practical and robust indicator for predictive modeling. As fouling progresses, TMP increases for a given flux, resulting in a decrease in Spec. Flux. This inverse relationship is well established in membrane science [38–40]. To systematically compare model performance, four different cases were defined based on the inclusion of COD removal efficiency (COD RM) as an additional feature and the choice of the target parameters (Table 1).





Figure 1. Schematic diagram of the full-scale food wastewater treatment processes. The MBR system is highlighted within the red box, and the data used for developing the AI-driven fouling analytic and predictive framework are indicated in red text along with the corresponding collection points.

Table 1. Cases for model comparison based on MBR process data and target parameters.

Cases	Factors	Target
Case I	F/M, SV30, SVI, MLSSs, DO, pH, Temp.	TMP
Case II	F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM	TMP
Case III	F/M, SV30, SVI, MLSSs, DO, pH, Temp.	Spec. Flux
Case IV	F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM	Spec. Flux

Cách tiếp cận này có thể che khuất các dao động ngắn hạn liên quan đến động lực học của quá trình đóng cặn; do đó, phép biến đổi trung bình trượt (xem Mục 2.3.2) được áp dụng cho các đặc trưng chính nhằm nắm bắt tốt hơn các mối phụ thuộc theo thời gian và giảm thiểu sự mất đi các xu hướng có ý nghĩa do biến thiên ngắn hạn. Những hạn chế này cùng các hệ quả của chúng đã được thảo luận ở phần trước của mục này (xem thêm Mục 2.1). Nếu dữ liệu tần suất cao được cung cấp trong các nghiên cứu tương lai, việc trực quan hóa các xu hướng trong ngày có thể giúp nâng cao hơn nữa khả năng phân tích và diễn giải hiện tượng đóng cặn. Các tham số mục tiêu là TMP hoặc thông lượng riêng (Spec. Flux). Spec. Flux ($=\text{flux}/\text{TMP}$) được dùng làm biến mục tiêu vì nó biểu thị trực tiếp độ thấm của màng, một chỉ báo quan trọng về mức độ đóng cặn. Trong vận hành MBR thực tế, ngay cả ở chế độ thông lượng không đổi, cả thông lượng và TMP đều biến thiên do các dao động trong vận hành và môi trường [37,38]. Vì vậy, Spec. Flux phản ánh những thay đổi đồng thời này hiệu quả hơn từng tham số riêng lẻ, khiến nó trở thành một chỉ báo thiết thực và đáng tin cậy hơn cho mô hình dự đoán. Khi quá trình đóng cặn tiến triển, TMP tăng ở cùng một mức thông lượng, dẫn đến Spec. Flux giảm. Mối quan hệ nghịch này đã được xác lập rõ trong lĩnh vực khoa học màng [38–40]. Để so sánh có hệ thống hiệu suất của các mô hình, bốn trường hợp khác nhau được xác định dựa trên việc đưa hiệu suất loại bỏ COD (COD RM) vào làm đặc trưng bổ sung và lựa chọn các tham số mục tiêu (Bảng 1).



Hình 1. Sơ đồ quy trình xử lý nước thải thực phẩm ở quy mô thực tế. Hệ thống MBR được khoanh trong khung đỏ; dữ liệu dùng để xây dựng khuôn khổ phân tích và dự đoán hiện tượng bám bẩn ứng dụng AI được đánh dấu bằng chữ màu đỏ, cùng với các điểm thu thập dữ liệu tương ứng.

Bảng 1. Các trường hợp so sánh mô hình dựa trên dữ liệu quy trình MBR và các thông số mục tiêu.

Cases	Factors	Target
Case I	F/M, SV30, SVI, MLSSs, DO, pH, Temp.	TMP
Case II	F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM	TMP
Case III	F/M, SV30, SVI, MLSSs, DO, pH, Temp.	Spec. Flux
Case IV	F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM	Spec. Flux

2.2. Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) was conducted to examine the distribution, relationships, and underlying patterns in the dataset. The analysis included descriptive statistics, visualization techniques, correlation analysis, and normality tests to assess the characteristics of the features and target parameters before model development.

2.2.1. Operational Feature Statistics

Descriptive statistical measures, including mean, median, standard deviation (std), minimum, and maximum values, were calculated for all features and target variables. This analysis provided an overview of the central tendency and variability of the data, ensuring that potential anomalies or outliers could be identified.

2.2.2. Pair Plot

To investigate the pairwise relationships between features and target parameters, a pair plot was generated. This visualization provides insights into potential linear or non-linear correlations, clustering patterns, and outliers, facilitating a deeper understanding of the dataset before model development. Pair plots were constructed using the Seaborn library (0.13.2) in Python (3.13.1), incorporating regression lines to observe possible linear trends and confidence intervals to assess variability.

2.2.3. Scatter Plot

Individual scatter plots were used to explore the relationship between specific input features and target parameters (TMP and Spec. Flux). These plots helped in detecting possible linear or non-linear trends, as well as outliers that might influence model performance.

2.2.4. Pearson Correlation

The Pearson correlation coefficient (r) was computed to quantify the linear relationship between each feature and the target parameters. A correlation matrix was constructed to visualize the strength and direction of the associations. The analysis helped in feature selection by identifying highly correlated variables that could impact model performance.

2.2.5. Normality Check

To assess the normality of the dataset, the Shapiro–Wilk test was conducted for all features and target variables. The test evaluates whether a given dataset follows a normal distribution, with the null hypothesis (H_0) assuming normality and the alternative hypothesis (H_1) suggesting deviation from normality. The Shapiro–Wilk test examines statistic ranges from 0 to 1, with values approaching 1 indicating a closer resemblance to a normal distribution. A p -value threshold of 0.05 was used to assess statistical significance. If the p -value exceeded 0.05, the null hypothesis was not rejected, confirming that the data followed a normal distribution.

2.3. Preprocessing and Feature Engineering

To enhance data consistency and improve model performance under non-ideal field conditions, robust scaling and moving average transformations were applied. Robust scaling and moving averages were applied to simulate realistic field conditions, where data quality is often compromised. These methods ensure model resilience to outliers and temporal gaps, critical for industrial deployment. The following subsections detail these techniques.

2.2. Exploratory Data Analysis (EDA)

Phân tích dữ liệu khám phá (EDA) được thực hiện nhằm khảo sát phân phối, mối quan hệ và các quy luật tiềm ẩn trong tập dữ liệu. Phân tích bao gồm thống kê mô tả, các kỹ thuật trực quan hóa, phân tích tương quan và kiểm định tính chuẩn để đánh giá đặc điểm của các đặc trưng và tham số mục tiêu trước khi phát triển mô hình.

2.2.1. Thống kê đặc trưng vận hành

Các thước đo thống kê mô tả, bao gồm giá trị trung bình, trung vị, độ lệch chuẩn (std), giá trị nhỏ nhất và lớn nhất, được tính toán cho tất cả các đặc trưng và biến mục tiêu. Phân tích này cung cấp cái nhìn tổng quan về xu hướng trung tâm và độ biến thiên của dữ liệu, giúp xác định các bất thường hoặc giá trị ngoại lai tiềm ẩn.

2.2.2. Biểu đồ cặp

Để khảo sát mối quan hệ từng cặp giữa các đặc trưng và tham số mục tiêu, biểu đồ cặp đã được tạo. Trực quan hóa này cung cấp thông tin chi tiết về các tương quan tuyến tính hoặc phi tuyến tiềm năng, các kiểu phân cụm và các giá trị ngoại lệ, giúp hiểu sâu hơn về tập dữ liệu trước khi phát triển mô hình. Các biểu đồ cặp được tạo bằng thư viện Seaborn (0.13.2) trong Python (3.13.1), có bổ sung các đường hồi quy để quan sát xu hướng tuyến tính có thể có và các khoảng tin cậy để đánh giá mức độ biến thiên.

2.2.3. Biểu đồ phân tán

Các biểu đồ phân tán riêng lẻ được sử dụng để khám phá mối quan hệ giữa các đặc trưng đầu vào cụ thể và các tham số mục tiêu (TMP và thông lượng riêng). Những biểu đồ này giúp phát hiện các xu hướng tuyến tính hoặc phi tuyến có thể có, cũng như các giá trị ngoại lệ có thể ảnh hưởng đến hiệu suất của mô hình.

2.2.4. Tương quan Pearson

Hệ số tương quan Pearson (r) được tính toán để định lượng mối quan hệ tuyến tính giữa từng đặc trưng và các tham số mục tiêu. Ma trận tương quan được xây dựng để trực quan hóa mức độ và chiều hướng của các mối liên hệ. Phân tích này hỗ trợ lựa chọn đặc trưng bằng cách xác định các biến có tương quan cao, có thể ảnh hưởng đến hiệu suất của mô hình.

2.2.5. Kiểm tra tính phân phối chuẩn

Để đánh giá tính chuẩn của bộ dữ liệu, kiểm định Shapiro–Wilk được thực hiện cho tất cả các đặc trưng và biến mục tiêu. Kiểm định này đánh giá liệu một bộ dữ liệu nhất định có tuân theo phân phối chuẩn hay không, trong đó giả thuyết không (H_0) giả định dữ liệu có phân phối chuẩn, còn giả thuyết đối (H_1) cho rằng dữ liệu lệch khỏi phân phối chuẩn. Kiểm định Shapiro–Wilk xem xét giá trị thống kê trong khoảng từ 0 đến 1; các giá trị tiến gần đến 1 cho thấy dữ liệu càng giống với phân phối chuẩn. Ngưỡng giá trị p là 0,05 được sử dụng để đánh giá ý nghĩa thống kê. Nếu giá trị p vượt quá 0,05, giả thuyết không không bị bác bỏ, xác nhận rằng dữ liệu tuân theo phân phối chuẩn.

2.3. Preprocessing and Feature Engineering

Để tăng cường tính nhất quán của dữ liệu và cải thiện hiệu suất mô hình trong điều kiện hiện trường không lý tưởng, các phép biến đổi chuẩn hóa robust và trung bình trượt đã được áp dụng. Các phương pháp này mô phỏng điều kiện hiện trường thực tế, nơi chất lượng dữ liệu thường bị suy giảm. Chúng giúp mô hình chống chịu tốt hơn trước các giá trị ngoại lệ và khoảng trống theo thời gian, điều thiết yếu đối với việc triển khai trong công nghiệp. Các tiểu mục sau đây trình bày chi tiết những kỹ thuật này.

2.3.1. Robust Scaling

Robust scaling was applied to normalize the dataset while reducing the influence of extreme values. Unlike standard normalization methods, which are sensitive to outliers, robust scaling centers the data around the median and scales it using the interquartile range (IQR, Q3–Q1). This method ensures that the distribution of variables with different scales remains comparable.

The transformation was performed using the following Equation (1).

$$x_{robust\ scaled} = \frac{x - Median}{Q3 - Q1} \tag{1}$$

2.3.2. Moving Average

In MBR processes, the removal of contaminants requires a specific processing time, leading to a time delay between influent and effluent characteristics. It should be noted that the time delay concept applied in this study is a data-driven feature engineering method designed to optimize input–output data pairing for model training, rather than a direct representation of HRT or physical process lag. This approach enables the identification of the most effective temporal alignment for fouling prediction under the given operational and data conditions. To incorporate this time-dependent behavior, a moving average transformation was applied to all features, improving the model’s ability to capture long-term trends while minimizing the effect of short-term fluctuations.

Additionally, the moving average reduces the influence of extreme values, making it particularly effective for datasets with high noise levels. The transformed value was computed as follows (Equation (2)).

$$MA_t = \frac{x_{n-t+1} + x_{n-t+2} + \cdots + x_n}{t} = \frac{1}{t} \sum_{n-t+1}^n x_i \tag{2}$$

2.4. Models

To develop predictive models for membrane fouling, both statistical regression models and machine learning models were employed. The statistical models aimed to capture linear relationships between input features and target parameters, while machine learning models leveraged non-linear patterns to enhance predictive accuracy.

2.4.1. Statistical Models

1. Linear Regression

Linear regression is a fundamental statistical approach used to model the relationship between a dependent variable Y and multiple independent variables Xi. The model is represented as follows (Equation (3)):

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon \tag{3}$$

where β_0 is the intercept, β_1 to β_p are the regression coefficients, and ϵ represents the error term. This model assumes a linear relationship between predictors and the target parameters.

2. Lasso Regression

Least Absolute Shrinkage and Selection Operator (Lasso) regression introduces an L1 regularization term to the linear regression model, effectively performing feature selection

2.3.1. Chuẩn hóa bền vững

Phương pháp co giãn bền vững được áp dụng để chuẩn hóa tập dữ liệu đồng thời giảm ảnh hưởng của các giá trị cực đoan. Khác với các phương pháp chuẩn hóa tiêu chuẩn vốn nhạy cảm với giá trị ngoại lai, phương pháp này định tâm dữ liệu quanh trung vị và co giãn dữ liệu bằng khoảng tứ phân vị (IQR, Q3–Q1). Phương pháp này đảm bảo rằng phân phối của các biến có thang đo khác nhau vẫn có thể so sánh được.

Phép biến đổi được thực hiện bằng phương trình sau (1).

$$x_{robust\ scaled} = \frac{x - Median}{Q3 - Q1} \tag{1}$$

2.3.2. Trung bình động

Trong các quy trình MBR, việc loại bỏ chất ô nhiễm cần một khoảng thời gian xử lý nhất định, dẫn đến độ trễ thời gian giữa đặc tính của dòng vào và dòng ra. Cần lưu ý rằng khái niệm độ trễ thời gian được áp dụng trong nghiên cứu này là một phương pháp kỹ thuật đặc trưng dựa trên dữ liệu, nhằm tối ưu hóa việc ghép cặp dữ liệu đầu vào–đầu ra để huấn luyện mô hình, chứ không phải là biểu diễn trực tiếp của HRT hay độ trễ vật lý của quy trình. Cách tiếp cận này giúp xác định sự căn chỉnh theo thời gian hiệu quả nhất để dự đoán hiện tượng bám bẩn trong các điều kiện vận hành và dữ liệu cụ thể. Để tính đến hành vi phụ thuộc thời gian này, phép biến đổi trung bình trượt được áp dụng cho tất cả các đặc trưng, giúp cải thiện khả năng nắm bắt xu hướng dài hạn của mô hình đồng thời giảm thiểu ảnh hưởng của các dao động ngắn hạn.

Ngoài ra, giá trị trung bình động làm giảm ảnh hưởng của các giá trị cực đoan, nhờ đó đặc biệt hiệu quả với các tập dữ liệu có mức độ nhiễu cao. Giá trị sau khi biến đổi được tính như sau (Phương trình (2)).

$$MA_t = \frac{x_{n-t+1} + x_{n-t+2} + \cdots + x_n}{t} = \frac{1}{t} \sum_{n-t+1}^n x_i \tag{2}$$

2.4. Models

Để phát triển các mô hình dự đoán hiện tượng tắc nghẽn màng, chúng tôi sử dụng cả mô hình hồi quy thống kê lẫn mô hình học máy. Các mô hình thống kê nhằm nắm bắt mối quan hệ tuyến tính giữa các đặc trưng đầu vào và các tham số mục tiêu, trong khi các mô hình học máy khai thác những quy luật phi tuyến để nâng cao độ chính xác dự đoán.

2.4.1. Mô hình thống kê

1. Hồi quy tuyến tính

Hồi quy tuyến tính là một phương pháp thống kê cơ bản được sử dụng để mô hình hóa mối quan hệ giữa biến phụ thuộc Y và nhiều biến độc lập Xi. Mô hình được biểu diễn như sau (Phương trình (3)):

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon \tag{3}$$

trong đó β_0 là hệ số chặn, β_1 đến β_p là các hệ số hồi quy và ϵ biểu thị sai số. Mô hình này giả định có mối quan hệ tuyến tính giữa các biến dự báo và các tham số mục tiêu.

2. Hồi quy Lasso

Hồi quy Least Absolute Shrinkage and Selection Operator (Lasso) đưa thêm một số hạng chính quy hóa L1 vào mô hình hồi quy tuyến tính, qua đó thực hiện lựa chọn đặc trưng.

by penalizing the absolute magnitude of regression coefficients. The objective function is defined as follows (Equation (4)):

$$\min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j \beta x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \tag{4}$$

where λ is the hyperparameter controlling the strength of regularization. Lasso regression helps mitigate overfitting by shrinking some coefficients to zero, thereby selecting only the most relevant features.

3. Ridge Regression

Ridge regression extends linear regression by incorporating an L2 regularization term, which penalizes large regression coefficients and reduces model variance. The objective function is given by (Equation (5)).

$$\min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j \beta x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \tag{5}$$

Ridge regression is particularly useful in addressing multicollinearity issues, ensuring model stability and improved generalization.

4. Elastic Net Regression

Elastic net regression combines L1 (Lasso) and L2 (Ridge) regularization techniques, leveraging the advantages of both. The objective function is formulated as follows (Equation (6)):

$$\min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j \beta x_{ij} \right)^2 + \lambda \left(\alpha \sum_{j=1}^p |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^p \beta_j^2 \right) \tag{6}$$

where α controls the balance between L1 and L2 penalties and λ determines the overall regularization strength. This model is particularly effective when dealing with high-dimensional datasets with correlated features.

2.4.2. Machine Learning Models

The machine learning (ML) model employed in this study follows a systematic multi-stage workflow designed to ensure both predictive accuracy and interpretability. The key procedural steps are outlined as follows:

- Input: Preprocessed features, including variables such as the F/M ratio, MLSSs, and moving averages of operational parameters, are fed into the algorithm.
- Training: The algorithm iteratively builds decision trees, optimizing for minimal prediction error while penalizing overfitting.
- Output: Predictions of specific flux (flux/TMP) are generated, directly quantifying fouling severity.
- Interpretation: Shapley Additive Explanation (SHAP) values quantify the contribution of each input variable to predictions, enabling operators to identify actionable levers (e.g., adjusting MLSS levels).

In addition, key strategies for preventing overfitting in the predictive modeling process are detailed as follows:

- Cross-validation: Five-fold cross-validation was used during hyperparameter tuning to ensure robust performance estimation, which is especially important for small datasets.
- Early stopping: For CatBoost and XGBoost, early stopping based on validation loss was applied to halt training when performance ceased improving.

bằng cách phạt độ lớn tuyệt đối của các hệ số hồi quy. Hàm mục tiêu được định nghĩa như sau (Phương trình (4)):

$$\min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j \beta x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \tag{4}$$

trong đó λ là siêu tham số kiểm soát mức độ điều chuẩn. Hồi quy Lasso giúp giảm thiểu hiện tượng quá khớp bằng cách thu nhỏ một số hệ số về 0, qua đó chỉ chọn những đặc trưng phù hợp nhất.

3. Hồi quy Ridge

Hồi quy Ridge mở rộng hồi quy tuyến tính bằng cách bổ sung một số hạng điều chuẩn L2, nhằm phạt các hệ số hồi quy lớn và giảm phương sai của mô hình. Hàm mục tiêu được cho bởi (Phương trình (5)).

$$\min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j \beta x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \tag{5}$$

Hồi quy Ridge đặc biệt hữu ích trong việc giải quyết các vấn đề đa cộng tuyến, đảm bảo mô hình ổn định và khả năng khái quát hóa tốt hơn.

4. Hồi quy Elastic Net

Hồi quy elastic net kết hợp các kỹ thuật chính quy hóa L1 (Lasso) và L2 (Ridge), tận dụng ưu điểm của cả hai. Hàm mục tiêu được biểu diễn như sau (Phương trình (6)):

$$\min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j \beta x_{ij} \right)^2 + \lambda \left(\alpha \sum_{j=1}^p |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^p \beta_j^2 \right) \tag{6}$$

trong đó α kiểm soát sự cân bằng giữa các mức phạt L1 và L2, còn λ xác định cường độ điều chuẩn tổng thể. Mô hình này đặc biệt hiệu quả khi xử lý các tập dữ liệu có nhiều chiều với các đặc trưng tương quan.

2.4.2. Các mô hình học máy

Mô hình học máy (ML) được sử dụng trong nghiên cứu này tuân theo quy trình nhiều giai đoạn có hệ thống, được thiết kế nhằm đảm bảo cả độ chính xác dự đoán lẫn khả năng diễn giải. Các bước thực hiện chính được trình bày như sau:

- Đầu vào: Các đặc trưng đã được tiền xử lý, bao gồm các biến như tỷ lệ F/M, MLSS và giá trị trung bình trượt của các thông số vận hành, được đưa vào thuật toán.
- Huấn luyện: Thuật toán xây dựng các cây quyết định theo từng vòng lặp, tối ưu hóa để giảm thiểu sai số dự đoán đồng thời phạt hiện tượng quá khớp.
- Đầu ra: Các dự đoán về thông lượng riêng (thông lượng/TMP) được tạo ra, định lượng trực tiếp mức độ nghiêm trọng của hiện tượng bám bẩn.
- Diễn giải: Giá trị Shapley Additive Explanation (SHAP) định lượng mức đóng góp của từng biến đầu vào vào các dự đoán, giúp người vận hành xác định các yếu tố có thể điều chỉnh (ví dụ: điều chỉnh mức MLSS).

Ngoài ra, các chiến lược then chốt để ngăn ngừa hiện tượng quá khớp trong quá trình xây dựng mô hình dự đoán được trình bày chi tiết như sau:

- Kiểm định chéo: Kiểm định chéo năm phần được sử dụng trong quá trình tinh chỉnh siêu tham số để đảm bảo ước tính hiệu suất đáng tin cậy, điều này đặc biệt quan trọng đối với các tập dữ liệu nhỏ.
- Dừng sớm: Đối với CatBoost và XGBoost, phương pháp dừng sớm dựa trên mức mất mát của tập xác thực được áp dụng để dừng quá trình huấn luyện khi hiệu suất không còn được cải thiện.

- Hyperparameter tuning: Grid search was used to optimize model parameters such as tree depth, learning rate, and regularization terms.
- Model complexity control: Maximum tree depth and minimum child weight were constrained to avoid overfitting complex patterns in limited data.

1. XGBoost

eXtreme gradient boosting (XGBoost) is an optimized tree-based boosting algorithm designed for parallel computation and enhanced model efficiency. The objective function is expressed as follows (Equation (7)):

$$\sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^K \left[\gamma T + \frac{1}{2} \lambda ||\omega||^2 \right] \tag{7}$$

where y_i represents the true values, $\hat{y}_i^{(t)}$ denotes the predicted values at iteration t , and T corresponds to the number of leaf nodes, while ω represents their weights. The hyperparameters γ and λ control model complexity and regularization.

2. CatBoost

Category boosting (CatBoost) is a gradient-boosting algorithm developed by Yandex and designed to efficiently handle categorical features and mitigate prediction shift through ordered boosting. The objective function is given by the following (Equation (8)):

$$\sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^K \left[\gamma T + \frac{1}{2} \lambda ||\omega||^2 \right] + R_{ordered}(D) \tag{8}$$

where $R_{ordered}(D)$ is an additional regularization term introduced through ordered boosting, addressing the issue of gradient estimation bias.

2.5. Explainable AI

To enhance the interpretability of machine learning models and improve trust in their predictions, explainable AI (XAI) techniques were employed. Feature importance analysis and Shapley Additive Explanations (SHAP) were utilized to assess the contribution of individual features to model predictions. These methods allow for a deeper understanding of how different variables influence membrane fouling predictions, thereby increasing the transparency of the predictive framework [31].

2.5.1. Feature Importance

Feature importance quantifies the contribution of each input variable to the model’s predictions. By identifying the most influential features, this analysis provides insights into which parameters play a crucial role in predicting TMP and Spec. Flux.

2.5.2. Shapley Additive Explanations

Shapley Additive Explanations (SHAP) is an XAI technique based on game theory, designed to fairly allocate contributions among features in a predictive model. SHAP values quantify the marginal contribution of each feature to the model’s output by computing the difference in prediction when a feature is included versus when it is omitted from all possible feature subsets.

The Shapley value ϕ_i for a feature i is computed as follows (Equation (9)):

$$\phi_i(f) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(n - |S| - 1)!}{n!} [f_x(S \cup \{i\}) - f_x(S)] \tag{9}$$

where ϕ_i represents the Shapley value for feature i , which quantifies its average contribution to the model’s predictions. N denotes the set of all features, while S refers to a subset of

- Tinh chỉnh siêu tham số: Tìm kiếm theo lưới được sử dụng để tối ưu hóa các tham số của mô hình như độ sâu của cây, tốc độ học và các thành phần điều chuẩn.
- Kiểm soát độ phức tạp của mô hình: Giới hạn độ sâu tối đa của cây và trọng số con tối thiểu để tránh hiện tượng quá khớp với các mẫu phức tạp trong dữ liệu hạn chế.

1. XGBoost

Tăng cường gradient cực hạn (XGBoost) là một thuật toán tăng cường dựa trên cây được tối ưu hóa, thiết kế để tính toán song song và nâng cao hiệu quả của mô hình. Hàm mục tiêu được biểu diễn như sau (Phương trình (7)):

$$\sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^K \left[\gamma T + \frac{1}{2} \lambda ||\omega||^2 \right] \tag{7}$$

trong đó y_i biểu thị các giá trị thực, $\hat{y}_i^{(t)}$ biểu thị các giá trị dự đoán tại vòng lặp t , và T tương ứng với số lượng nút lá, còn ω biểu thị trọng số của chúng. Các siêu tham số γ và λ kiểm soát độ phức tạp của mô hình và mức độ chính quy hóa.

2. CatBoost

Tăng cường theo danh mục (CatBoost) là một thuật toán tăng cường độ dốc do Yandex phát triển, được thiết kế để xử lý hiệu quả các đặc trưng phân loại và giảm thiểu sự dịch chuyển dự đoán thông qua phương pháp tăng cường có thứ tự. Hàm mục tiêu được xác định như sau (Phương trình (8)):

$$\sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^K \left[\gamma T + \frac{1}{2} \lambda ||\omega||^2 \right] + R_{ordered}(D) \tag{8}$$

trong đó $R_{ordered}(D)$ là một thành phần chính quy hóa bổ sung được đưa vào thông qua boosting có thứ tự, nhằm giải quyết vấn đề sai lệch trong ước lượng gradient.

2.5. Explainable AI

Để tăng cường khả năng diễn giải của các mô hình học máy và củng cố niềm tin vào dự đoán của chúng, các kỹ thuật AI có thể giải thích (XAI) đã được sử dụng. Phân tích mức độ quan trọng của đặc trưng và phương pháp giải thích cộng tính Shapley (SHAP) được dùng để đánh giá mức độ đóng góp của từng đặc trưng vào các dự đoán của mô hình. Những phương pháp này giúp hiểu sâu hơn cách các biến khác nhau ảnh hưởng đến dự đoán hiện tượng bám bẩn màng, qua đó tăng tính minh bạch của khung dự đoán [31].

2.5.1. Mức độ quan trọng của đặc trưng

Tầm quan trọng của đặc trưng định lượng mức độ đóng góp của từng biến đầu vào vào các dự đoán của mô hình. Bằng cách xác định những đặc trưng có ảnh hưởng lớn nhất, phân tích này cho biết những tham số nào đóng vai trò then chốt trong việc dự đoán TMP và Spec. Flux.

2.5.2. Giải thích cộng tính Shapley

Giải thích cộng tính Shapley (SHAP) là một kỹ thuật XAI dựa trên lý thuyết trò chơi, được thiết kế để phân bổ công bằng mức đóng góp giữa các đặc trưng trong một mô hình dự đoán. Các giá trị SHAP định lượng mức đóng góp biên của từng đặc trưng vào đầu ra của mô hình bằng cách tính chênh lệch giữa dự đoán khi đặc trưng đó được đưa vào và khi bị loại bỏ khỏi mọi tập con đặc trưng có thể.

Giá trị Shapley ϕ_i cho một đặc trưng i được tính như sau (Phương trình (9)):

$$\phi_i(f) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(n - |S| - 1)!}{n!} [f_x(S \cup \{i\}) - f_x(S)] \tag{9}$$

trong đó ϕ_i biểu thị giá trị Shapley của đặc trưng i , định lượng mức đóng góp trung bình của đặc trưng đó vào các dự đoán của mô hình. N biểu thị tập hợp tất cả các đặc trưng, còn S đề cập đến một tập con của

features that excludes feature iii. The function $f_x(S)$ represents the model’s prediction when only the subset S of features is used. The factorial terms account for all possible feature–subset combinations, ensuring a fair distribution of contributions across features.

3. Results

3.1. Data Distribution and Correlation Analysis

3.1.1. Descriptive Statistics

Descriptive statistical analysis was conducted to summarize the central tendency, dispersion, and overall distribution of the dataset from MBR process (Table 2). Among the input features, MLSS exhibited the highest variability, with a mean of 7813 mg/L and a standard deviation of 1361 mg/L. The minimum and maximum values were 3390 mg/L and 11,980 mg/L, respectively. These values indicate substantial fluctuations in MLSS within the MBR process, likely influenced by variations in influent characteristics and microbial activity, which could impact membrane fouling rates.

Table 2. Summary of descriptive statistics for MBR process parameters.

Features	Count	Mean	Std	Min	25%	50%	75%	Max
F/M (kgCOD/(kgMLSS·d))	194	0.012	0.004	0.003	0.009	0.011	0.014	0.024
SV30 (%)	194	95.8	8.9	30.0	96.0	98.0	99.0	99.0
SVI (mL/g)	194	125.1	18.9	82.6	112.5	122.4	135.0	182.7
MLSS (mg/L)	194	7813	1361	3390	7080	7900	8628	11,980
DO (mg/L)	194	5.43	0.79	3.62	4.90	5.30	5.98	7.55
pH	194	8.11	0.40	5.02	7.85	7.98	8.45	8.97
Temp (°C)	194	26.4	4.5	13.0	25.0	28.3	29.7	31.6
Flux (LMH)	194	2.65	0.52	0.60	2.45	2.73	2.92	3.87
COD RM (%)	194	64.7	16.9	18.7	56.4	70.8	76.6	87.6
TMP (kPa)	194	51.0	6.8	37.08	46.3	50.5	55.0	69.0
Spec. Flux (LMH/kPa)	194	0.053	0.013	0.012	0.046	0.055	0.062	0.099

The DO concentration ranged from 3.62 mg/L to 7.55 mg/L, with a mean of 5.43 mg/L and a standard deviation of 0.79 mg/L. The quartile values (25%, 50%, and 75%) were 4.90 mg/L, 5.30 mg/L, and 5.98 mg/L, respectively, indicating that most observations were concentrated within a relatively narrow range. This suggests stable aeration conditions, ensuring sufficient oxygen availability for biological processes within the MBR.

The pH levels remained relatively stable, with a mean of 8.11 and a standard deviation of 0.39, demonstrating minimal fluctuations. The recorded pH values ranged from 5.02 to 8.97, with the 25th, 50th (median), and 75th percentiles recorded at 7.85, 7.98, and 8.45, respectively. These results confirm that the system maintained a controlled pH environment, which is critical for microbial activity and membrane stability.

The Temp. of the MBR varied between 13.0 °C and 31.6 °C, with a mean of 26.4 °C and a standard deviation of 4.5 °C. The quartile values (25%, 50%, and 75%) were 25.0 °C, 28.3 °C, and 29.7 °C, respectively, indicating that temperature fluctuations occurred within a moderate range. Since biological processes in MBRs are temperature-sensitive, this variation may influence microbial activity and system efficiency.

The F/M exhibited relatively low variability, with a mean of 0.012 kgCOD/(kgMLSS·d) and a standard deviation of 0.004 kgCOD/(kgMLSS·d). The values ranged from 0.003 kgCOD/(kgMLSS·d) to 0.024 kgCOD/(kgMLSS·d), while the 25th, 50th (median), and 75th percentiles were 0.009 kgCOD/(kgMLSS·d), 0.011 kgCOD/(kgMLSS·d), and 0.014 kgCOD/(kgMLSS·d), respectively. This suggests that organic loading conditions remained relatively stable throughout the study period, ensuring a consistent microbial response in the system.

các đặc trưng loại trừ đặc trưng iii. Hàm $f_x(S)$ biểu thị dự đoán của mô hình khi chỉ s ử dụng tập con S gồm các đặc trưng. Các số hạng giai thừa tính đến mọi tổ hợp tập con đặc trưng có thể, đảm bảo phân bổ đóng góp công bằng giữa các đặc trưng.

3. Kết quả

3.1. Data Distribution and Correlation Analysis

3.1.1. Thống kê mô tả

Phân tích thống kê mô tả được thực hiện nhằm tóm tắt xu hướng trung tâm, m ức độ phân tán và phân bố tổng thể của bộ dữ liệu từ quy trình MBR (Bảng 2). Trong số các đặc trưng đầu vào, MLSS có mức độ biến thiên cao nhất, với giá trị trung bình là 7813 mg/L và độ lệch chuẩn là 1361 mg/L. Giá trị nhỏ nhất và lớn nhất lần lượt là 3390 mg/L và 11.980 mg/L. Những giá trị này cho thấy MLSS biến động đáng kể tron g quy trình MBR, có thể chịu ảnh hưởng của sự thay đổi về đặc tính nước đầu vào và hoạt động của vi sinh vật, từ đó có thể tác động đến tốc độ cáu bẩn màng.

Bảng 2. Tóm tắt các thống kê mô tả về các thông số của quy trình MBR.

Features	Count	Mean	Std	Min	25%	50%	75%	Max
F/M (kgCOD/(kgMLSS·d))	194	0.012	0.004	0.003	0.009	0.011	0.014	0.024
SV30 (%)	194	95.8	8.9	30.0	96.0	98.0	99.0	99.0
SVI (mL/g)	194	125.1	18.9	82.6	112.5	122.4	135.0	182.7
MLSS (mg/L)	194	7813	1361	3390	7080	7900	8628	11,980
DO (mg/L)	194	5.43	0.79	3.62	4.90	5.30	5.98	7.55
pH	194	8.11	0.40	5.02	7.85	7.98	8.45	8.97
Temp (°C)	194	26.4	4.5	13.0	25.0	28.3	29.7	31.6
Flux (LMH)	194	2.65	0.52	0.60	2.45	2.73	2.92	3.87
COD RM (%)	194	64.7	16.9	18.7	56.4	70.8	76.6	87.6
TMP (kPa)	194	51.0	6.8	37.08	46.3	50.5	55.0	69.0
Spec. Flux (LMH/kPa)	194	0.053	0.013	0.012	0.046	0.055	0.062	0.099

Nồng độ DO dao động từ 3.62 mg/L đến 7.55 mg/L, với giá trị trung bình là 5.43 mg/L và độ lệch chuẩn là 0.79 mg/L. Các giá trị tứ phân vị (25%, 50% và 75%) lần lượt là 4.90 mg/L, 5.30 mg/L và 5.98 mg/L, cho thấy phần lớn các quan sát tập trung tron g một khoảng tương đối hẹp. Điều này cho thấy điều kiện sục khí ổn định, đảm bảo có đủ oxy cho các quá trình sinh học bên trong MBR.

Mức pH duy trì tương đối ổn định, với giá trị trung bình là 8,11 và độ lệch chuẩn là 0,39, cho thấy mức biến động rất nhỏ. Các giá trị pH được ghi nhận dao động từ 5 ,02 đến 8,97; các phân vị thứ 25, 50 (trung vị) và 75 lần lượt là 7,85, 7,98 và 8,45. Nhữ ng kết quả này xác nhận rằng hệ thống duy trì môi trường pH được kiểm soát, yếu t ố then chốt đối với hoạt động của vi sinh vật và độ ổn định của màng.

Nhiệt độ của MBR dao động từ 13.0 °C đến 31.6 °C, với giá trị trung bình là 26.4 °C và độ lệch chuẩn là 4.5 °C. Các giá trị tứ phân vị (25%, 50% và 75%) lần lượt là 25.0 °C, 28.3 °C và 29.7 °C, cho thấy nhiệt độ biến động trong một phạm vi vừa phải. Do c ác quá trình sinh học trong MBR nhạy cảm với nhiệt độ, sự biến động này có thể ảnh hưởng đến hoạt động của vi sinh vật và hiệu suất hệ thống.

F/M có mức biến thiên tương đối thấp, với giá trị trung bình là 0.012 kgCOD/(kg MLSS·d) và độ lệch chuẩn là 0.004 kgCOD/(kgMLSS·d). Các giá trị dao động từ 0.003 kgCOD/(kgMLSS·d) đến 0.024 kgCOD/(kgMLSS·d), trong khi các phân vị thứ 25, thứ 5 0 (trung vị) và thứ 75 lần lượt là 0.009 kgCOD/(kgMLSS·d), 0.011 kgCOD/(kgMLSS·d) v à 0.014 kgCOD/(kgMLSS·d). Điều này cho thấy các điều kiện tải lượng hữu cơ tương đối ổn định trong suốt thời gian nghiên cứu, đảm bảo phản ứng vi sinh vật nhất quá n trong hệ thống.

The SVI varied from 82.6 mL/g to 182.7 mL/g, with a mean of 125.1 mL/g and a standard deviation of 18.9 mL/g. The quartiles were 112.5 mL/g, 122.4 mL/g, and 135.0 mL/g, respectively. Given that SVI is a key parameter in assessing sludge settling characteristics, these results suggest that the system experienced moderate variability in sludge settleability.

Regarding target parameters, the TMP, which is a critical fouling parameter, ranged from 37.0 KPa to 69.0 KPa, with a mean of 51.0 KPa and a standard deviation of 6.8 KPa. The 25th, 50th (median), and 75th percentiles were 46.3 KPa, 50.5 KPa, and 55.0 KPa, respectively. This suggests that the membrane system experienced moderate levels of fouling, with periodic variations likely due to changes in influent conditions or operational adjustments.

Similarly, flux, which represents the filtration rate, had a mean of 2.65 LMH (i.e., L/m²·h) and a standard deviation of 0.52 LMH, with values ranging from 0.60 LMH to 3.87 LMH. The quartile values were 2.45 LMH, 2.73 LMH, and 2.92 LMH, respectively, indicating moderate variations in filtration performance.

Lastly, the specific flux (Spec. Flux), which normalizes flux with respect to TMP, had a mean of 0.053 LMH/kPa and a standard deviation of 0.013 LMH/kPa, with a range from 0.012 LMH/kPa to 0.099 LMH/kPa. The quartile values were 0.046 LMH/kPa, 0.055 LMH/kPa, and 0.062 LMH/kPa, suggesting relatively stable filtration efficiency across different operating conditions.

The descriptive statistical analysis provided insights into the variability of key operational parameters within the MBR process, enabling an initial assessment of their potential impact on membrane fouling and filtration performance. These findings serve as a foundational basis for subsequent correlation analysis and predictive modeling aimed at identifying the primary factors contributing to membrane fouling. Furthermore, the results will inform the development of optimization strategies for process control and operational improvements, enhancing overall system efficiency and sustainability.

3.1.2. Pair Plot Analysis

To investigate the relationships between key operational parameters and membrane fouling indicators, a pair plot analysis was performed, as shown in Figure 2. The pair plot provides a comprehensive visualization of bivariate relationships among process variables, including influent characteristics, operational conditions, and performance indicators such as TMP and Spec. Flux.

The results reveal several notable trends. A negative correlation is observed between TMP and DO concentration, suggesting that higher oxygen availability is associated with lower TMP values. This trend may be attributed to the role of aeration in mitigating biofilm accumulation and reducing membrane clogging. Conversely, TMP exhibits a weak positive correlation with MLSS, indicating that elevated MLSS levels may contribute to increased TMP, potentially due to intensified membrane fouling caused by higher suspended solid concentrations. A strong negative relationship between TMP and Spec. Flux is evident, confirming that, as membrane fouling progresses, TMP increases while filtration performance declines.

Similarly, Spec. Flux demonstrates a moderate positive correlation with COD_{RM}, suggesting that higher organic matter removal may enhance filtration performance by minimizing membrane biofouling. However, Spec. Flux exhibits a weaker association with MLSSs, indicating that MLSS variations alone may not directly impact filtration efficiency under the given operational conditions.

SVI dao động từ 82,6 mL/g đến 182,7 mL/g, với giá trị trung bình là 125,1 mL/g và độ lệch chuẩn là 18,9 mL/g. Các tứ phân vị lần lượt là 112,5 mL/g, 122,4 mL/g và 135,0 mL/g. Vì SVI là một thông số quan trọng để đánh giá đặc tính lắng của bùn, các kết quả này cho thấy khả năng lắng của bùn trong hệ thống biến thiên ở mức vừa phải.

Về các thông số mục tiêu, TMP, một thông số quan trọng phản ánh tình trạng bám bẩn, dao động từ 37.0 KPa đến 69.0 KPa, với giá trị trung bình là 51.0 KPa và độ lệch chuẩn là 6.8 KPa. Các phân vị thứ 25, 50 (trung vị) và 75 lần lượt là 46.3 KPa, 50.5 KPa và 55.0 KPa. Điều này cho thấy hệ thống màng bị bám bẩn ở mức độ vừa phải, với những biến động định kỳ có thể do thay đổi điều kiện nước đầu vào hoặc điều chỉnh vận hành.

Tương tự, thông lượng, đại diện cho tốc độ lọc, có giá trị trung bình là 2.65 LMH (tức là L/m²·h) và độ lệch chuẩn là 0.52 LMH, với các giá trị dao động từ 0.60 LMH đến 3.87 LMH. Các giá trị tứ phân vị lần lượt là 2.45 LMH, 2.73 LMH và 2.92 LMH, cho thấy hiệu suất lọc biến động ở mức vừa phải.

Cuối cùng, thông lượng riêng (Spec. Flux), được chuẩn hóa theo TMP, có giá trị trung bình là 0,053 LMH/kPa và độ lệch chuẩn là 0,013 LMH/kPa, với phạm vi từ 0,012 LMH/kPa đến 0,099 LMH/kPa. Các giá trị tứ phân vị lần lượt là 0,046 LMH/kPa, 0,055 LMH/kPa và 0,062 LMH/kPa, cho thấy hiệu suất lọc tương đối ổn định trong các điều kiện vận hành khác nhau.

Phân tích thống kê mô tả cung cấp những hiểu biết về mức độ biến thiên của các thông số vận hành chính trong quy trình MBR, cho phép đánh giá sơ bộ tác động tiềm tàng của chúng đối với hiện tượng tắc màng và hiệu suất lọc. Những phát hiện này là cơ sở nền tảng cho các phân tích tương quan và mô hình dự đoán tiếp theo nhằm xác định các yếu tố chính góp phần gây tắc màng. Hơn nữa, kết quả sẽ định hướng việc xây dựng các chiến lược tối ưu hóa nhằm kiểm soát quy trình và cải thiện vận hành, qua đó nâng cao hiệu quả tổng thể và tính bền vững của hệ thống.

3.1.2. Phân tích biểu đồ cặp

Để khảo sát mối quan hệ giữa các thông số vận hành chính và các chỉ báo cấu trúc màng, phân tích biểu đồ cặp đã được thực hiện như minh họa trong Hình 2. Biểu đồ cặp cung cấp hình ảnh trực quan toàn diện về các mối quan hệ hai biến giữa các biến quy trình, bao gồm đặc tính nước đầu vào, điều kiện vận hành và các chỉ số hiệu suất như TMP và lưu lượng riêng.

Kết quả cho thấy một số xu hướng đáng chú ý. Mối tương quan âm giữa TMP và nồng độ DO cho thấy lượng oxy sẵn có cao hơn thường đi kèm với giá trị TMP thấp hơn. Xu hướng này có thể bắt nguồn từ vai trò của quá trình sục khí trong việc hạn chế sự tích tụ màng sinh học và giảm tắc nghẽn màng. Ngược lại, TMP có tương quan dương yếu với MLSS, cho thấy mức MLSS cao có thể góp phần làm tăng TMP, có khả năng do hiện tượng cấu trúc màng trở nên nghiêm trọng hơn khi nồng độ chất rắn lơ lửng cao. Mối quan hệ âm mạnh giữa TMP và thông lượng riêng (Spec. Flux) cho thấy rõ ràng khi hiện tượng cấu trúc màng tiến triển, TMP tăng trong khi hiệu suất lọc suy giảm.

Tương tự, Thông lượng riêng biểu hiện mối tương quan thuận ở mức vừa với COD_{RM}, cho thấy việc loại bỏ chất hữu cơ nhiều hơn có thể cải thiện hiệu suất lọc bằng cách hạn chế hiện tượng màng bị bám bẩn sinh học. Tuy nhiên, Thông lượng riêng có mối liên hệ yếu hơn với MLSSs, cho thấy riêng sự biến động của MLSS có thể không tác động trực tiếp đến hiệu quả lọc trong các điều kiện vận hành đã nêu.





Figure 2. Pair plot of operational and target parameters in the MBR system.

Further analysis of feature interdependencies highlights a strong positive correlation between MLSSs and SVI, which is consistent with expectations, as increased MLSSs typically leads to greater sludge settleability. Additionally, a weak positive association between DO and pH is detected, implying that pH fluctuations may be influenced by aeration levels and microbial activity. The relationship between COD RM and flux suggests that higher organic removal efficiency may contribute to improved membrane performance, likely due to reduced organic fouling.

These preliminary findings underscore the complex interactions between operational parameters and membrane fouling dynamics, necessitating further quantitative correlation analysis (e.g., Pearson correlation).

3.1.3. Pearson Correlation Analysis

To quantitatively assess the relationships between key operational parameters and membrane fouling indicators, Pearson correlation coefficients were computed, as summarized in Table 3.



Hình 2. Biểu đồ cặp các thông số vận hành và mục tiêu trong hệ thống MBR.

Phân tích sâu hơn về mối quan hệ phụ thuộc lẫn nhau giữa các đặc trưng cho thấy mối tương quan thuận mạnh giữa MLSSs và SVI, phù hợp với kỳ vọng, vì MLSSs tăng thường dẫn đến khả năng lắng của bùn tốt hơn. Ngoài ra, ghi nhận mối tương quan thuận yếu giữa DO và pH, cho thấy dao động pH có thể chịu ảnh hưởng của mức độ sục khí và hoạt động của vi sinh vật. Mối quan hệ giữa COD RM và thông lượng cho thấy hiệu suất loại bỏ chất hữu cơ cao hơn có thể góp phần cải thiện hiệu suất màng, có khả năng nhờ giảm cấu bẩn hữu cơ.

Những phát hiện sơ bộ này nhấn mạnh sự tương tác phức tạp giữa các thông số vận hành và diễn biến tắc nghẽn màng, đòi hỏi phải phân tích tương quan định lượng sâu hơn (ví dụ: tương quan Pearson).

3.1.3. Phân tích tương quan Pearson

Để đánh giá định lượng mối quan hệ giữa các thông số vận hành chính và các chỉ số tắc nghẽn màng, hệ số tương quan Pearson đã được tính toán, như tóm tắt trong Bảng 3.

Table 3. Pearson correlation coefficients between operational and target parameters in the MBR system.

	F/M	SV30	SVI	MLSS	DO	pH	Temp.	Flux	COD RM	TMP	Spec. Flux
F/M	1.00	0.09	0.01	0.03	−0.28	−0.13	0.11	0.45	0.46	−0.30	0.52
SV30	0.09	1.00	0.08	0.54	−0.31	−0.27	−0.04	0.15	0.23	−0.14	0.20
SVI	0.014	0.08	1.00	−0.77	0.01	0.25	0.26	−0.22	−0.21	0.34	−0.33
MLSS	0.03	0.54	−0.77	1.00	−0.19	−0.38	−0.25	0.26	0.32	−0.36	0.39
DO	−0.28	−0.31	0.01	−0.19	1.00	−0.06	−0.70	−0.33	−0.10	0.20	−0.36
pH	−0.13	−0.27	0.25	−0.38	−0.06	1.00	0.42	0.22	−0.54	0.42	−0.05
Temp.	0.11	−0.04	0.26	−0.25	−0.70	0.42	1.00	0.25	−0.18	0.07	0.16
Flux	0.45	0.15	−0.22	0.26	−0.33	0.22	0.25	1.00	−0.13	−0.18	0.85
COD RM	0.46	0.23	−0.21	0.32	−0.10	−0.54	−0.18	−0.13	1.00	−0.41	0.11
TMP	−0.30	−0.14	0.34	−0.36	0.20	0.42	0.07	−0.18	−0.41	1.00	−0.65
Spec. Flux	0.52	0.20	−0.34	0.39	−0.36	−0.05	0.16	0.85	0.11	−0.65	1.00

Among the operational parameters, TMP exhibited the strongest positive correlation with pH ($r = 0.42$), suggesting that higher pH levels may be associated with increased TMP. This relationship could be attributed to pH-induced changes in microbial activity or the solubility of inorganic scaling compounds, both of which can contribute to membrane fouling. Conversely, TMP demonstrated a strong negative correlation with Spec. Flux ($r = -0.65$), reinforcing the well-established inverse relationship between membrane fouling and filtration performance. As TMP increases due to progressive membrane fouling, Spec. Flux declines, indicating reduced permeability and increased hydraulic resistance.

Additionally, TMP showed moderate negative correlations with MLSS ($r = -0.36$) and COD RM ($r = -0.41$). These findings suggest that higher biomass concentrations and improved organic removal efficiency may contribute to lower TMP values, possibly by reducing the accumulation of fouling precursors on the membrane surface.

In contrast, Spec. Flux exhibited the strongest positive correlation with F/M ($r = 0.52$), indicating that higher organic loading rates may enhance filtration performance. This could be attributed to improved microbial metabolism and sludge settleability under optimal F/M conditions, reducing membrane clogging. Furthermore, Spec. Flux displayed a moderate positive correlation with MLSSs ($r = 0.39$), suggesting that microbial concentration plays a role in maintaining filtration efficiency. Moreover, Spec. Flux demonstrated a negative correlation with DO ($r = -0.36$), implying that higher oxygen availability may contribute to reduced filtration performance. This may be due to increased biofilm formation at elevated DO levels, leading to enhanced membrane fouling. Additionally, the inverse correlation between specific flux and TMP ($r = -0.65$) aligns with the expected trend, where increasing membrane fouling results in reduced filtration efficiency.

The observed correlation patterns provide a foundational understanding of the key parameters influencing membrane fouling and filtration performance in MBR systems. The strong correlations between TMP, Spec. Flux, and key operational parameters highlight the importance of multivariate analysis in predictive modeling. These findings emphasize the necessity of incorporating multiple interacting factors into membrane fouling prediction models to improve forecasting accuracy and guide operational strategies.

3.1.4. Application of Normality Check

To assess the distributional properties of the dataset, a Shapiro–Wilk normality test was conducted for each feature, and the results are presented in Figure 3. The test statistic ranges from 0 to 1, where values closer to 1 indicate a stronger resemblance to a normal distribution. A p -value threshold of 0.05 was used to determine statistical significance,

Bảng 3. Hệ số tương quan Pearson giữa các thông số vận hành và thông số mục tiêu trong hệ thống MBR.

	F/M	SV30	SVI	MLSS	DO	pH	Temp.	Flux	COD RM	TMP	Spec. Flux
F/M	1.00	0.09	0.01	0.03	−0.28	−0.13	0.11	0.45	0.46	−0.30	0.52
SV30	0.09	1.00	0.08	0.54	−0.31	−0.27	−0.04	0.15	0.23	−0.14	0.20
SVI	0.014	0.08	1.00	−0.77	0.01	0.25	0.26	−0.22	−0.21	0.34	−0.33
MLSS	0.03	0.54	−0.77	1.00	−0.19	−0.38	−0.25	0.26	0.32	−0.36	0.39
DO	−0.28	−0.31	0.01	−0.19	1.00	−0.06	−0.70	−0.33	−0.10	0.20	−0.36
pH	−0.13	−0.27	0.25	−0.38	−0.06	1.00	0.42	0.22	−0.54	0.42	−0.05
Temp.	0.11	−0.04	0.26	−0.25	−0.70	0.42	1.00	0.25	−0.18	0.07	0.16
Flux	0.45	0.15	−0.22	0.26	−0.33	0.22	0.25	1.00	−0.13	−0.18	0.85
COD RM	0.46	0.23	−0.21	0.32	−0.10	−0.54	−0.18	−0.13	1.00	−0.41	0.11
TMP	−0.30	−0.14	0.34	−0.36	0.20	0.42	0.07	−0.18	−0.41	1.00	−0.65
Spec. Flux	0.52	0.20	−0.34	0.39	−0.36	−0.05	0.16	0.85	0.11	−0.65	1.00

Trong số các thông số vận hành, TMP có tương quan thuận mạnh nhất với pH ($r = 0.42$), cho thấy pH cao hơn có thể liên quan đến TMP tăng. Mối quan hệ này có thể bắt nguồn từ những thay đổi do pH gây ra đối với hoạt động của vi sinh vật hoặc độ hòa tan của các hợp chất vô cơ gây đóng cặn; cả hai đều có thể góp phần gây bám bẩn màng. Ngược lại, TMP có tương quan nghịch mạnh với thông lượng riêng ($r = -0.65$), củng cố mối quan hệ nghịch đã được xác lập rõ giữa tình trạng bám bẩn màng và hiệu suất lọc. Khi TMP tăng do màng dần bị bám bẩn, thông lượng riêng giảm, cho thấy độ thấm giảm và lực cản thủy lực tăng.

Ngoài ra, TMP có tương quan âm ở mức vừa phải với MLSS ($r = -0.36$) và COD RM ($r = -0.41$). Những phát hiện này cho thấy nồng độ sinh khối cao hơn và hiệu suất loại bỏ chất hữu cơ được cải thiện có thể góp phần làm giảm giá trị TMP, có thể bằng cách hạn chế sự tích tụ các tiền chất gây bám bẩn trên bề mặt màng.

Ngược lại, Spec. Flux có tương quan dương mạnh nhất với F/M ($r = 0.52$), cho thấy tải lượng hữu cơ cao hơn có thể cải thiện hiệu suất lọc. Điều này có thể là do quá trình chuyển hóa của vi sinh vật và khả năng lắng của bùn được cải thiện trong điều kiện F/M tối ưu, giúp giảm tắc nghẽn màng. Hơn nữa, Spec. Flux có tương quan dương ở mức trung bình với MLSSs ($r = 0.39$), cho thấy nồng độ vi sinh vật góp phần duy trì hiệu suất lọc. Ngoài ra, Spec. Flux thể hiện tương quan âm với DO ($r = -0.36$), hàm ý rằng lượng oxy dồi dào hơn có thể làm giảm hiệu suất lọc. Nguyên nhân có thể là do màng sinh học hình thành nhiều hơn khi DO tăng cao, dẫn đến tình trạng màng bị bám bẩn nghiêm trọng hơn. Bên cạnh đó, tương quan nghịch giữa thông lượng riêng và TMP ($r = -0.65$) phù hợp với xu hướng dự kiến: màng ngày càng bị bám bẩn thì hiệu suất lọc càng giảm.

Các mô hình tương quan quan sát được cung cấp hiểu biết nền tảng về những tác động số chính ảnh hưởng đến hiện tượng tắc nghẽn màng và hiệu suất lọc trong các hệ thống MBR. Mối tương quan chặt chẽ giữa TMP, thông lượng riêng (Spec. Flux) và các thông số vận hành chủ chốt cho thấy tầm quan trọng của phân tích đa biến trong mô hình hóa dự đoán. Những phát hiện này nhấn mạnh sự cần thiết phải đưa nhiều yếu tố tương tác vào các mô hình dự đoán hiện tượng tắc nghẽn màng nhằm nâng cao độ chính xác dự báo và định hướng các chiến lược vận hành.

3.1.4. Áp dụng phép kiểm tra tính phân phối chuẩn

Để đánh giá các đặc tính phân phối của tập dữ liệu, kiểm định tính chuẩn Shapiro–Wilk được thực hiện cho từng đặc trưng, và kết quả được trình bày trong Hình 3. Thống kê kiểm định nằm trong khoảng từ 0 đến 1, trong đó các giá trị càng gần 1 càng cho thấy mức độ tương đồng với phân phối chuẩn càng cao. Ngưỡng giá trị p bằng 0,05 được sử dụng để xác định ý nghĩa thống kê,

with p -values greater than 0.05 indicating failure to reject the null hypothesis, thereby confirming normality.





Figure 3. Shapiro–Wilk normality test results for operational and target parameters in the MBR system.

The results indicate that F/M is the only variable that satisfies normality assumptions ($p = 0.0518$), as its p -value exceeds the 0.05 threshold. All other features, including SV30, SVI, MLSSs, DO, pH, temperature, flux, COD RM, TMP, and Spec. Flux, exhibit p -values below 0.05, indicating statistically significant deviations from normality. These findings suggest that most variables in the dataset do not conform to a normal distribution, necessitating appropriate data preprocessing techniques to account for skewness and non-normality.

với các giá trị p lớn hơn 0.05 cho thấy không bác bỏ giả thuyết không, qua đó xác nhận tính chuẩn.



Hình 3. Kết quả kiểm định tính chuẩn Shapiro–Wilk đối với các thông số vận hành và mục tiêu trong hệ thống MBR.

Kết quả cho thấy F/M là biến duy nhất thỏa mãn giả định phân phối chuẩn ($p = 0.0518$), vì giá trị p của biến này vượt ngưỡng 0.05. Tất cả các đặc trưng còn lại, bao gồm SV30, SVI, MLSSs, DO, pH, nhiệt độ, thông lượng, COD RM, TMP và thông lượng r iêng, đều có giá trị p dưới 0.05, cho thấy những sai lệch có ý nghĩa thống kê so với p hân phối chuẩn. Những phát hiện này cho thấy phần lớn các biến trong tập dữ liệu k hông tuân theo phân phối chuẩn, do đó cần áp dụng các kỹ thuật tiền xử lý dữ liệu p hù hợp để xử lý độ lệch và tính không chuẩn.

The results of the normality check highlight the importance of incorporating appropriate feature transformations and preprocessing techniques when developing predictive models.

3.2. Application of Robust Scaling and Moving Average

3.2.1. Application of Robust Scaling

Given the presence of non-normal distributions and extreme values, robust scaling was applied to standardize the dataset while minimizing the influence of outliers. Figure 4 illustrates the data distribution before and after robust scaling. The original dataset (Figure 4a) exhibits high variability among features, with some variables (e.g., MLSSs) having significantly larger magnitudes than others, potentially leading to disproportionate model weightings.




Figure 4. Comparison of feature distributions before (a) and after (b) robust scaling.

Robust scaling was employed to normalize feature distributions while preserving their relative structure. Unlike standard scaling (which standardizes based on the mean and standard deviation), robust scaling centers the data around the median and scales it based on the interquartile range (IQR: Q3–Q1). This transformation ensures that variables with heavy-tailed distributions and extreme outliers do not unduly affect model performance.

After robust scaling (Figure 4b), all features are transformed to a similar scale, with a median centered around zero. The distribution of each variable is more comparable, preventing dominant features from skewing model predictions. Additionally, while outliers remain detectable, their impact is substantially reduced, ensuring a more stable and generalizable modeling approach.

By implementing robust scaling, the dataset is better suited for machine learning applications, where scale-invariant transformations enhance model convergence and interpretability. This preprocessing step ensures that feature importance is derived from underlying patterns rather than numerical disparities, ultimately improving model robustness and predictive performance.

3.2.2. Application of Moving Average

Membrane fouling in MBR systems progresses gradually due to the accumulation of operational conditions and microbial activity rather than occurring instantaneously. Therefore, incorporating time-dependent features is essential to capture the underlying patterns in fouling dynamics. Water quality and operational data often exhibit short-term fluctuations due to measurement variability. Applying moving average helps reduce noise and highlight long-term trends, leading to a more stable and reliable dataset.


Furthermore, predictive models should account for the historical impact of operational conditions on current membrane fouling rather than relying solely on individual time-point measurements. This approach is particularly crucial in machine learning (GBM, XGBoost). Therefore, it will be applied to Section 3.3.2. to preprocess time-series data by smoothing

Kết quả kiểm định tính chuẩn nhấn mạnh tầm quan trọng của việc áp dụng các phép biến đổi đặc trưng và kỹ thuật tiền xử lý phù hợp khi xây dựng các mô hình dự đoán.

3.2. Application of Robust Scaling and Moving Average

3.2.1. Ứng dụng phương pháp chuẩn hóa bền vững

Do sự hiện diện của các phân phối không chuẩn và các giá trị cực đoan, phép chuẩn hóa bền vững được áp dụng để chuẩn hóa tập dữ liệu, đồng thời giảm thiểu ảnh hưởng của các giá trị ngoại lai. Hình 4 minh họa phân phối dữ liệu trước và sau khi chuẩn hóa bền vững. Tập dữ liệu ban đầu (Hình 4a) cho thấy mức độ biến thiên cao giữa các đặc trưng, trong đó một số biến (ví dụ: MLSSs) có giá trị lớn hơn đáng kể so với các biến khác, có khả năng dẫn đến trọng số mô hình mất cân đối.



Hình 4. So sánh phân phối đặc trưng trước (a) và sau (b) khi chuẩn hóa bền vững.

Phương pháp chuẩn hóa bền vững được sử dụng để chuẩn hóa phân phối đặc trưng mà vẫn giữ nguyên cấu trúc tương đối của chúng. Khác với chuẩn hóa tiêu chuẩn (dựa trên giá trị trung bình và độ lệch chuẩn), phương pháp này lấy trung vị làm tâm dữ liệu và chuẩn hóa dựa trên khoảng tứ phân vị (IQR: Q3–Q1). Phép biến đổi này đảm bảo các biến có phân phối đuôi nặng và giá trị ngoại lai cực đoan không ảnh hưởng quá mức đến hiệu suất của mô hình.

Sau khi chuẩn hóa bền vững (Hình 4b), tất cả các đặc trưng được biến đổi về cùng một thang đo, với trung vị tập trung quanh giá trị không. Phân phối của từng biến trở nên dễ so sánh hơn, ngăn các đặc trưng chi phối làm sai lệch dự đoán của mô hình. Ngoài ra, mặc dù các giá trị ngoại lai vẫn có thể được phát hiện, ảnh hưởng của chúng giảm đáng kể, đảm bảo phương pháp mô hình hóa ổn định và có khả năng khái quát hóa tốt hơn.

Bằng cách áp dụng phương pháp chuẩn hóa bền vững, tập dữ liệu phù hợp hơn với các ứng dụng học máy, trong đó các phép biến đổi bất biến theo tỷ lệ giúp cải thiện khả năng hội tụ và tính dễ diễn giải của mô hình. Bước tiền xử lý này đảm bảo rằng mức độ quan trọng của các đặc trưng được xác định dựa trên những quy luật tiềm ẩn thay vì chênh lệch số học, từ đó nâng cao độ bền vững và hiệu suất dự đoán của mô hình.

3.2.2. Ứng dụng phương pháp trung bình động

Sự cáu bẩn màng trong các hệ thống MBR tiến triển dần do các điều kiện vận hành tích tụ và hoạt động của vi sinh vật, chứ không xảy ra tức thời. Vì vậy, việc đưa các đặc trưng phụ thuộc thời gian vào là cần thiết để nắm bắt các quy luật tiềm ẩn trong động lực học cáu bẩn. Chất lượng nước và dữ liệu vận hành thường có những biến động ngắn hạn do sai số đo lường. Áp dụng phương pháp trung bình trượt giúp giảm nhiễu và làm nổi bật các xu hướng dài hạn, từ đó tạo ra bộ dữ liệu ổn định và đáng tin cậy hơn.

Hơn nữa, các mô hình dự đoán nên tính đến tác động trong quá khứ của các điều kiện vận hành đối với tình trạng cáu bẩn hiện tại của màng, thay vì chỉ dựa vào các phép đo tại từng thời điểm riêng lẻ. Cách tiếp cận này đặc biệt quan trọng trong học máy (GBM, XGBoost). Do đó, phương pháp này sẽ được áp dụng trong Mục 3.3.2 để tiền xử lý dữ liệu chuỗi thời gian bằng cách làm mượt

fluctuations and capturing long-term trends, enabling the model to learn cumulative effects of operational conditions on membrane fouling dynamics. The optimal moving average window was selected by systematically evaluating different day-shifting periods for each input feature within a one-week period and comparing model performance (R^2 and RMSE) for each; the most effective window was then applied for subsequent analysis.

3.3. Model Performance Evaluation

To assess the predictive accuracy of different models for TMP and Specific Flux, various machine learning and statistical models were trained and evaluated across four different cases.

3.3.1. Model Performance Based on Raw Data

In Case I (Table 4, the prediction of TMP without COD RM), traditional statistical models such as linear regression, Ridge, Lasso, and ElasticNet exhibited poor predictive performance with R^2 values below 0.35. XGBoost ($R^2 = 0.6769$) and CatBoost ($R^2 = 0.7088$) significantly outperformed the statistical models, with CatBoost achieving the lowest root mean square error (RMSE = 3.9785), demonstrating superior prediction accuracy. Other evaluation metrics such as mean absolute error (MAE), mean absolute percentage error (MAPE), and mean square error (MSE) are also listed in Table 4.

Table 4. Model performance (Case I: F/M, SV30, SVI, MLSSs, DO, pH, Temp. → TMP).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.3439	4.9834	0.1008	35.6655	5.9721
Ridge	0.3168	5.1590	0.1037	37.1352	6.0939
Lasso	0.3396	5.0665	0.1021	35.8953	5.9913
ElasticNet	0.3292	5.1052	0.1028	36.4606	6.0383
XGBoost	0.6769	3.0784	0.0602	17.5643	4.1910
CatBoost	0.7088	2.9686	0.0591	15.8281	3.9785

For Case II (Table 5, the prediction of TMP with COD RM), the inclusion of COD RM slightly improved model performance, with CatBoost ($R^2 = 0.7059$) and XGBoost ($R^2 = 0.6922$) remaining the top-performing models. However, the RMSE improvement was marginal (from 3.9785 to 3.9980), indicating that COD RM contributes to TMP prediction but does not drastically enhance overall accuracy.

Table 5. Model performance (Case II: F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM → TMP).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.3439	4.9834	0.1008	35.6655	5.9721
Ridge	0.3457	5.0564	0.1016	35.5654	5.9637
Lasso	0.3769	4.9247	0.0992	33.8710	5.8199
ElasticNet	0.3563	5.0050	0.1007	34.9865	5.9149
XGBoost	0.6922	3.1245	0.0610	16.7314	4.0904
CatBoost	0.7059	3.1014	0.0626	15.9842	3.9980

In Case III (Table 6, the prediction of Spec. Flux without COD RM), linear regression ($R^2 = 0.6117$) performed better than Ridge, Lasso, and ElasticNet, suggesting that Spec. Flux exhibits stronger linear relationships with input features. Among machine learning models, CatBoost ($R^2 = 0.7317$) and XGBoost ($R^2 = 0.5797$) demonstrated superior predictive performance, with CatBoost achieving the lowest RMSE (0.0069), making it the most reliable model.

các dao động và nắm bắt xu hướng dài hạn, giúp mô hình học được tác động tích lũy của các điều kiện vận hành đối với diễn biến bám bẩn màng. Cửa sổ trung bình trượt tối ưu được chọn bằng cách đánh giá có hệ thống các khoảng dịch chuyển theo ngày khác nhau cho từng đặc trưng đầu vào trong khoảng thời gian một tuần và so sánh hiệu suất mô hình (R^2 và RMSE) ở mỗi khoảng; sau đó, cửa sổ hiệu quả nhất được áp dụng cho các phân tích tiếp theo.

3.3. Model Performance Evaluation

Để đánh giá độ chính xác dự đoán của các mô hình khác nhau đối với TMP và Lưu lượng riêng, nhiều mô hình học máy và thống kê đã được huấn luyện và đánh giá trong bốn trường hợp khác nhau.

3.3.1. Hiệu suất mô hình dựa trên dữ liệu thô

Trong Trường hợp I (Bảng 4, dự đoán TMP không có RM COD), các mô hình thống kê truyền thống như hồi quy tuyến tính, Ridge, Lasso và ElasticNet cho hiệu suất dự đoán kém, với các giá trị R^2 dưới 0,35. XGBoost ($R^2 = 0,6769$) và CatBoost ($R^2 = 0,7088$) vượt trội đáng kể so với các mô hình thống kê, trong đó CatBoost đạt sai số bình phương trung bình gốc thấp nhất (RMSE = 3,9785), cho thấy độ chính xác dự đoán vượt trội. Các chỉ số đánh giá khác như sai số tuyệt đối trung bình (MAE), sai số phần trăm tuyệt đối trung bình (MAPE) và sai số bình phương trung bình (MSE) cũng được liệt kê trong Bảng 4.

Bảng 4. Hiệu suất mô hình (Trường hợp I: F/M, SV30, SVI, MLSSs, DO, pH, Nhiệt độ → TMP).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.3439	4.9834	0.1008	35.6655	5.9721
Ridge	0.3168	5.1590	0.1037	37.1352	6.0939
Lasso	0.3396	5.0665	0.1021	35.8953	5.9913
ElasticNet	0.3292	5.1052	0.1028	36.4606	6.0383
XGBoost	0.6769	3.0784	0.0602	17.5643	4.1910
CatBoost	0.7088	2.9686	0.0591	15.8281	3.9785

Đối với Trường hợp II (Bảng 5, dự đoán TMP bằng COD RM), việc đưa COD RM vào đã cải thiện đôi chút hiệu suất mô hình, trong đó CatBoost ($R^2 = 0.7059$) và XGBoost ($R^2 = 0.6922$) vẫn là các mô hình có hiệu suất tốt nhất. Tuy nhiên, mức cải thiện RMSE không đáng kể (từ 3.9785 lên 3.9980), cho thấy COD RM góp phần dự đoán TMP nhưng không cải thiện đáng kể độ chính xác tổng thể.

Bảng 5. Hiệu suất mô hình (Trường hợp II: F/M, SV30, SVI, MLSSs, DO, pH, nhiệt độ, COD RM → TMP).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.3439	4.9834	0.1008	35.6655	5.9721
Ridge	0.3457	5.0564	0.1016	35.5654	5.9637
Lasso	0.3769	4.9247	0.0992	33.8710	5.8199
ElasticNet	0.3563	5.0050	0.1007	34.9865	5.9149
XGBoost	0.6922	3.1245	0.0610	16.7314	4.0904
CatBoost	0.7059	3.1014	0.0626	15.9842	3.9980

Trong Trường hợp III (Bảng 6, dự đoán Spec. Flux không có COD RM), hồi quy tuyến tính ($R^2 = 0.6117$) hoạt động tốt hơn Ridge, Lasso và ElasticNet, cho thấy Spec. Flux có mối quan hệ tuyến tính chặt chẽ hơn với các đặc trưng đầu vào. Trong số các mô hình học máy, CatBoost ($R^2 = 0.7317$) và XGBoost ($R^2 = 0.5797$) thể hiện hiệu suất dự đoán vượt trội, trong đó CatBoost đạt RMSE thấp nhất (0.0069), khiến đây trở thành mô hình đáng tin cậy nhất.

Table 6. Model performance (Case III: F/M, SV30, SVI, MLSSs, DO, pH, Temp. → Spec. Flux).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6117	0.0068	0.1521	0.0001	0.0083
Ridge	0.3951	0.0084	0.1770	0.0001	0.0104
Lasso	0.2497	0.0094	0.1980	0.0001	0.0116
ElasticNet	0.3070	0.0090	0.1858	0.0001	0.0111
XGBoost	0.5797	0.0063	0.1347	0.0001	0.0087
CatBoost	0.7317	0.0058	0.1237	0.0000	0.0069

For Case IV (Table 7, the prediction of Spec. Flux with COD RM), the addition of COD RM improved model performance across all models, particularly for boosting models. CatBoost ($R^2 = 0.7710$) showed the highest accuracy with the lowest RMSE (0.0064), confirming that COD RM significantly enhances the prediction of Spec. Flux. This aligns with recent studies, where ensemble methods (e.g., gradient boosting) outperformed traditional models in fouling prediction due to their capability to capture non-linear interactions [20]. Notably, the framework developed in this study achieved comparable accuracy ($R^2 > 0.77$) using fewer input parameters than typical sensor-intensive approaches [27], demonstrating efficiency for resource-limited MBR plants. XGBoost ($R^2 = 0.6555$) also performed well, but CatBoost consistently outperformed all models across all cases.

Table 7. Model performance (Case IV: F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM → Spec. Flux).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6200	0.0068	0.1500	0.0001	0.0082
Ridge	0.4349	0.0079	0.1685	0.0001	0.0100
Lasso	0.2513	0.0094	0.1976	0.0001	0.0115
ElasticNet	0.3070	0.0090	0.1858	0.0001	0.0111
XGBoost	0.6555	0.0059	0.1304	0.0001	0.0078
CatBoost	0.7710	0.0054	0.1149	0.0000	0.0064

Overall, gradient-boosting models (XGBoost and CatBoost) consistently outperformed traditional statistical models, with CatBoost emerging as the best-performing model in all cases. The inclusion of COD RM improved prediction accuracy, particularly for Spec. Flux, highlighting its relevance in membrane fouling dynamics. These results highlight the effectiveness of the proposed predictive framework, which integrates advanced feature engineering and explainable AI, in capturing complex fouling mechanisms and prioritizing key operational parameters for the prediction of Spec. Flux in full-scale MBRs.

3.3.2. Enhanced Model Performance with Robust Scaling and Moving Average

To further refine the predictive accuracy of the models, robust scaling and moving average were applied to the dataset in Case IV (F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM → Spec. Flux). The impact of these preprocessing methods on model performance is summarized in Tables 8 and 9.

Bảng 6. Hiệu suất mô hình (Trường hợp III: F/M, SV30, SVI, MLSSs, DO, pH, Nhiệt độ → Lưu lượng riêng).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6117	0.0068	0.1521	0.0001	0.0083
Ridge	0.3951	0.0084	0.1770	0.0001	0.0104
Lasso	0.2497	0.0094	0.1980	0.0001	0.0116
ElasticNet	0.3070	0.0090	0.1858	0.0001	0.0111
XGBoost	0.5797	0.0063	0.1347	0.0001	0.0087
CatBoost	0.7317	0.0058	0.1237	0.0000	0.0069

Đối với Trường hợp IV (Bảng 7, dự đoán Spec. Flux bằng COD RM), việc bổ sung COD RM đã cải thiện hiệu suất mô hình ở tất cả các mô hình, đặc biệt là các mô hình boosting. CatBoost ($R^2 = 0.7710$) đạt độ chính xác cao nhất cùng RMSE thấp nhất (0.0064), xác nhận rằng COD RM cải thiện đáng kể khả năng dự đoán Spec. Flux. Kết quả này phù hợp với các nghiên cứu gần đây, trong đó các phương pháp tổ hợp (ví dụ: gradient boosting) vượt trội hơn các mô hình truyền thống trong dự đoán sự bám bẩn nhờ khả năng nắm bắt các tương tác phi tuyến [20]. Đáng chú ý, khung phương pháp được phát triển trong nghiên cứu này đạt độ chính xác tương đương ($R^2 > 0.77$) với ít tham số đầu vào hơn so với các phương pháp điển hình đòi hỏi nhiều cảm biến [27], cho thấy tính hiệu quả đối với các nhà máy MBR có nguồn lực hạn chế. XGBoost ($R^2 = 0.6555$) cũng hoạt động tốt, nhưng CatBoost luôn vượt trội hơn tất cả các mô hình trong mọi trường hợp.

Bảng 7. Hiệu suất mô hình (Trường hợp IV: F/M, SV30, SVI, MLSSs, DO, pH, Nhiệt độ, COD RM → Lưu lượng riêng).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6200	0.0068	0.1500	0.0001	0.0082
Ridge	0.4349	0.0079	0.1685	0.0001	0.0100
Lasso	0.2513	0.0094	0.1976	0.0001	0.0115
ElasticNet	0.3070	0.0090	0.1858	0.0001	0.0111
XGBoost	0.6555	0.0059	0.1304	0.0001	0.0078
CatBoost	0.7710	0.0054	0.1149	0.0000	0.0064

Nhìn chung, các mô hình tăng cường gradient (XGBoost và CatBoost) luôn cho kết quả tốt hơn các mô hình thống kê truyền thống, trong đó CatBoost là mô hình đạt hiệu suất cao nhất trong mọi trường hợp. Việc bổ sung COD RM đã cải thiện độ chính xác dự đoán, đặc biệt đối với Spec. Flux, cho thấy tầm quan trọng của thông số này trong động lực học bám bẩn màng. Các kết quả này cho thấy khung dự đoán được đề xuất, kết hợp kỹ thuật xây dựng đặc trưng tiên tiến với AI có khả năng giải thích, có hiệu quả trong việc nắm bắt các cơ chế bám bẩn phức tạp và xác định thứ tự ưu tiên của các thông số vận hành then chốt để dự đoán Spec. Flux trong các hệ thống MBR quy mô thực tế.

3.3.2. Nâng cao hiệu suất mô hình với phương pháp chuẩn hóa bền vững và trung bình động

Để cải thiện hơn nữa độ chính xác dự báo của các mô hình, phương pháp chuẩn hóa robust và trung bình động đã được áp dụng cho bộ dữ liệu trong Trường hợp IV (F/M, SV30, SVI, MLSSs, DO, pH, Temp., COD RM → Spec. Flux). Tác động của các phương pháp tiền xử lý này đến hiệu suất của mô hình được tóm tắt trong Bảng 8 và 9.

Table 8. Model performance for Case IV with robust scaling.

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6344	0.0066	0.1477	0.0001	0.0081
Ridge	0.6356	0.0066	0.1478	0.0001	0.0081
Lasso	−0.0048	0.0112	0.2392	0.0002	0.0134
ElasticNet	0.2953	0.0095	0.2077	0.0001	0.0112
XGBoost	0.6555	0.0059	0.1304	0.0001	0.0078
CatBoost	0.7969	0.0050	0.1074	0.0000	0.0060

Table 9. Model performance for Case IV with robust scaling and moving average (5 says).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6623	0.0065	0.1445	0.0001	0.0078
Ridge	0.6617	0.0065	0.1460	0.0001	0.0078
Lasso	−0.0048	0.0112	0.2392	0.0002	0.0134
ElasticNet	0.3145	0.0093	0.2022	0.0001	0.0110
XGBoost	0.7404	0.0055	0.1168	0.0000	0.0068
CatBoost	0.8374	0.0042	0.0863	0.0000	0.0054

Robust scaling was first applied to mitigate the influence of extreme values and improve model stability (Table 8). This transformation led to noticeable performance improvements, particularly for gradient-boosting models such as CatBoost and XGBoost. CatBoost exhibited the best predictive performance, achieving an R^2 value of 0.7969 and the lowest RMSE of 0.0060, demonstrating strong generalization capabilities. XGBoost also benefited from scaling, with an R^2 value of 0.6555, although it remained less accurate than CatBoost. Linear and Ridge regression models showed moderate improvements, with R^2 values around 0.63, whereas ElasticNet and Lasso regression continued to perform poorly, especially when dealing with complex relationships.

Recognizing that membrane fouling progresses cumulatively over time, a 5-day moving average was introduced to incorporate temporal dependencies into the predictive models (Table 9). As described in Section 3.2.2, the 5-day window was selected as optimal by systematically evaluating different day-shifting periods for each input feature within a one-week span and comparing model performance (R^2 and RMSE); the configuration yielding the best predictive accuracy was then applied for subsequent analysis. This adjustment led to further refinements in model performance. CatBoost improved further, reaching an R^2 value of 0.8374 and a reduced RMSE of 0.0054, highlighting the effectiveness of incorporating historical trends. This supports the findings of the previous study [12], which emphasized the cumulative impact of operational conditions on fouling. While prior statistical models struggled with temporal dependencies [14], the moving average approach in this study explicitly addresses time-delayed fouling dynamics, resulting in a $>10\%$ R^2 improvement over raw data models. XGBoost also demonstrated a significant increase in accuracy, with an R^2 value of 0.7404, benefiting from the smoothing effect of the moving average. Linear and Ridge regression models also showed slight but consistent improvements, with R^2 values around 0.66, suggesting that the moving average contributed to more stable feature representation even in simpler models.

The results confirm that applying robust scaling improved model performance by reducing the impact of extreme values, particularly for non-linear machine learning models. Additionally, incorporating a moving average further enhanced predictive accuracy, effectively capturing the time-dependent nature of membrane fouling. Because all models were evaluated on the same real-world time-series dataset from a single full-scale MBR, statistical tests such as *t*-tests or confidence intervals—which require independent repeated

Bảng 8. Hiệu năng mô hình cho Trường hợp IV với chuẩn hóa bền vững.

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6344	0.0066	0.1477	0.0001	0.0081
Ridge	0.6356	0.0066	0.1478	0.0001	0.0081
Lasso	−0.0048	0.0112	0.2392	0.0002	0.0134
ElasticNet	0.2953	0.0095	0.2077	0.0001	0.0112
XGBoost	0.6555	0.0059	0.1304	0.0001	0.0078
CatBoost	0.7969	0.0050	0.1074	0.0000	0.0060

Bảng 9. Hiệu suất mô hình cho Trường hợp IV với phép chuẩn hóa robust và trung bình trượt (5 ngày).

Model	R-Squared	MAE	MAPE	MSE	RMSE
Linear	0.6623	0.0065	0.1445	0.0001	0.0078
Ridge	0.6617	0.0065	0.1460	0.0001	0.0078
Lasso	−0.0048	0.0112	0.2392	0.0002	0.0134
ElasticNet	0.3145	0.0093	0.2022	0.0001	0.0110
XGBoost	0.7404	0.0055	0.1168	0.0000	0.0068
CatBoost	0.8374	0.0042	0.0863	0.0000	0.0054

Chuẩn hóa robust được áp dụng trước tiên nhằm giảm thiểu ảnh hưởng của các giá trị cực đoan và cải thiện độ ổn định của mô hình (Bảng 8). Phép biến đổi này giúp hiệu suất cải thiện đáng kể, đặc biệt là ở các mô hình tăng cường gradient như CatBoost và XGBoost. CatBoost cho hiệu suất dự đoán tốt nhất, đạt giá trị R^2 là 0.7969 và RMSE thấp nhất là 0.0060, cho thấy khả năng khái quát hóa mạnh mẽ. XGBoost cũng được hưởng lợi từ việc chuẩn hóa, với giá trị R^2 là 0.6555, dù vẫn kém chính xác hơn CatBoost. Các mô hình hồi quy tuyến tính và Ridge có mức cải thiện vừa phải, với giá trị R^2 khoảng 0.63, trong khi hồi quy ElasticNet và Lasso tiếp tục cho hiệu suất kém, đặc biệt khi xử lý các mối quan hệ phức tạp.

Nhận thấy hiện tượng bám bẩn màng tích lũy dần theo thời gian, đường trung bình trượt 5 ngày đã được đưa vào để tích hợp các phụ thuộc theo thời gian vào các mô hình dự đoán (Bảng 9). Như mô tả trong Mục 3.2.2, cửa sổ 5 ngày được chọn là tối ưu thông qua việc đánh giá có hệ thống các khoảng dịch chuyển ngày khác nhau cho từng đặc trưng đầu vào trong phạm vi một tuần và so sánh hiệu suất mô hình (R^2 và RMSE); sau đó, cấu hình cho độ chính xác dự đoán tốt nhất được áp dụng cho các phân tích tiếp theo. Điều chỉnh này giúp cải thiện thêm hiệu suất mô hình. CatBoost tiếp tục được cải thiện, đạt giá trị R^2 là 0.8374 và RMSE giảm xuống còn 0.0054, cho thấy hiệu quả của việc tích hợp các xu hướng trong quá khứ. Kết quả này củng cố những phát hiện của nghiên cứu trước đây [12], trong đó nhấn mạnh tác động tích lũy của các điều kiện vận hành đối với hiện tượng bám bẩn. Trong khi các mô hình thống kê trước đây gặp khó khăn với các phụ thuộc theo thời gian [14], phương pháp trung bình trượt trong nghiên cứu này xử lý trực tiếp động thái bám bẩn có độ trễ, giúp cải thiện $R^2 > 10\%$ so với các mô hình sử dụng dữ liệu thô. XGBoost cũng cho thấy độ chính xác tăng đáng kể, với giá trị R^2 là 0.7404, nhờ hiệu ứng làm trơn của đường trung bình trượt. Các mô hình hồi quy tuyến tính và Ridge cũng cho thấy mức cải thiện nhẹ nhưng nhất quán, với các giá trị R^2 xấp xỉ 0.66, cho thấy đường trung bình trượt góp phần tạo ra biểu diễn đặc trưng ổn định hơn, ngay cả trong các mô hình đơn giản hơn.

Kết quả xác nhận rằng việc áp dụng phép chuẩn hóa bền vững đã cải thiện hiệu suất mô hình bằng cách giảm tác động của các giá trị cực đoan, đặc biệt là đối với các mô hình học máy phi tuyến. Ngoài ra, việc kết hợp đường trung bình trượt còn nâng cao độ chính xác dự báo, giúp nắm bắt hiệu quả đặc tính phụ thuộc theo thời gian của hiện tượng tắc nghẽn màng. Vì tất cả các mô hình đều được đánh giá trên cùng một tập dữ liệu chuỗi thời gian thực tế từ một hệ thống MBR quy mô đầy đủ duy nhất, các phép kiểm định thống kê như kiểm định *t* hoặc khoảng tin cậy—vốn đòi hỏi các lần lặp độc lập

samples—are not applicable in this context. Therefore, model comparison in this study emphasizes consistent performance and interpretability under actual operational conditions, rather than statistical significance based on repeated random sampling. CatBoost consistently outperformed all other models, confirming its robustness in handling complex non-linear relationships in MBR systems. XGBoost also benefited significantly from these refinements, reinforcing the importance of feature engineering in fouling prediction.

3.4. Final Prediction Performance

To evaluate the final predictive capability of the developed model, CatBoost was applied to Case IV with robust scaling and moving average (5 days). The dataset was split chronologically, with the first 80% of records used for training and the remaining 20% for testing, to preserve temporal dependencies. The time-series plot in Figure 5 presents the actual and predicted values for Spec. Flux in the test dataset, illustrating the ability of the model to capture temporal variations in membrane fouling. In accordance with standard time-series modeling practices, the dataset was divided chronologically, with the first 80% (155 records) used as training data and the last 20% (39 records) as test data. For visualization, instead of displaying individual points for the training and test sets, predicted data points were connected with dashed lines. This approach was selected because the relatively small number of data points would make point-based plots less effective at conveying overall trends. Using dashed lines allows for a clearer comparison of the trends and characteristics between the training and test sets, providing a more intuitive assessment of model performance across the entire period. The time-series visualization highlights the strong predictive performance of the model, as the predicted values (dashed red line) closely follow the actual values (solid blue line).





Figure 5. Comparison of actual (solid blue line) and predicted (dashed red line) Spec. Flux.

The performance metrics indicate that CatBoost achieved an R^2 score of 0.7712, with a low RMSE of 0.0064 and a minimal MAE of 0.0054. These metrics are calculated exclusively on the test set (20% of the data), providing an unbiased assessment of model performance on unseen data. Additionally, the mean absolute percentage error (MAPE) was only 0.11%, demonstrating the high accuracy of the model in predicting Spec. Flux. These results confirm that CatBoost effectively captures the complex non-linear dependencies between operational parameters and membrane fouling behavior. Although the dataset comprises 194 daily records, the application of advanced feature engineering (e.g., moving averages) and robust models (e.g., CatBoost) enabled effective prediction. Larger datasets would

các mẫu—không áp dụng trong bối cảnh này. Do đó, việc so sánh mô hình trong ng hiện cứu này nhấn mạnh hiệu suất nhất quán và khả năng diễn giải trong điều kiện vận hành thực tế, thay vì ý nghĩa thống kê dựa trên việc lấy mẫu ngẫu nhiên lặp lại. CatBoost luôn vượt trội hơn tất cả các mô hình khác, khẳng định tính bền vững của mô hình này trong việc xử lý các mối quan hệ phi tuyến phức tạp trong các hệ thống MBR. XGBoost cũng được hưởng lợi đáng kể từ những cải tiến này, càng nhấn mạnh tầm quan trọng của kỹ thuật đặc trưng trong dự đoán hiện tượng bám bẩn.

3.4. Final Prediction Performance

Để đánh giá năng lực dự đoán cuối cùng của mô hình đã phát triển, CatBoost đ ược áp dụng cho Trường hợp IV với phép chuẩn hóa robust và đường trung bình trượt (5 ngày). Tập dữ liệu được chia theo trình tự thời gian, trong đó 80% số bản ghi đầ u tiên được dùng để huấn luyện và 20% còn lại dùng để kiểm thử, nhằm bảo toàn cá c phụ thuộc theo thời gian. Biểu đồ chuỗi thời gian trong Hình 5 thể hiện các giá trị t hực tế và dự đoán của Spec. Flux trong tập dữ liệu kiểm thử, qua đó minh họa khả n ăng của mô hình trong việc nắm bắt các biến thiên theo thời gian của hiện tượng đố ng bám màng. Theo các thông lệ chuẩn trong mô hình hóa chuỗi thời gian, tập dữ liệ u được chia theo trình tự thời gian, với 80% đầu tiên (155 bản ghi) dùng làm dữ liệu huấn luyện và 20% cuối cùng (39 bản ghi) làm dữ liệu kiểm thử. Để trực quan hóa, th ay vì hiển thị từng điểm riêng lẻ cho tập huấn luyện và tập kiểm thử, các điểm dữ liệ u dự đoán được nối bằng các đường nét đứt. Cách tiếp cận này được lựa chọn vì số l ượng điểm dữ liệu tương đối ít khiến biểu đồ dạng điểm khó thể hiện hiệu quả các x u hướng tổng thể. Việc sử dụng đường nét đứt giúp so sánh rõ hơn các xu hướng và đặc điểm giữa tập huấn luyện và tập kiểm thử, đồng thời cung cấp đánh giá trực qu an hơn về hiệu suất mô hình trong toàn bộ giai đoạn. Hình ảnh trực quan hóa chuỗi thời gian cho thấy hiệu suất dự đoán tốt của mô hình, khi các giá trị dự đoán (đường nét đứt màu đỏ) bám sát các giá trị thực tế (đường liền màu xanh lam).



Hình 5. So sánh thông lượng quang phổ thực tế (đường liền màu xanh lam) và dự đoán (đường đứt nét màu đỏ) Spec. Flux.

Các chỉ số hiệu suất cho thấy CatBoost đạt điểm R^2 là 0.7712, với RMSE thấp ở m ức 0.0064 và MAE tối thiểu là 0.0054. Các chỉ số này chỉ được tính trên tập kiểm tra (2 0% dữ liệu), qua đó đưa ra đánh giá khách quan về hiệu suất của mô hình trên dữ liệ u chưa từng thấy. Ngoài ra, sai số phần trăm tuyệt đối trung bình (MAPE) chỉ là 0.11 %, cho thấy mô hình có độ chính xác cao khi dự đoán Spec. Flux. Những kết quả này xác nhận rằng CatBoost nắm bắt hiệu quả các mối quan hệ phi tuyến phức tạp giữa các thông số vận hành và hiện tượng bám bẩn màng. Mặc dù bộ dữ liệu chỉ gồm 19 4 bản ghi theo ngày, việc áp dụng kỹ thuật trích xuất đặc trưng tiên tiến (ví dụ: trung bình trượt) và các mô hình mạnh mẽ (ví dụ: CatBoost) đã giúp dự đoán hiệu quả. Các bộ dữ liệu lớn hơn sẽ

further enhance model generalizability, and future work should validate the framework with extended datasets.

The model successfully tracks fluctuations in Spec. Flux, especially during peak variations, indicating its ability to generalize well under dynamic operational conditions. However, minor deviations are observed in certain regions, particularly during rapid fluctuations, suggesting that additional temporal dependencies or lagged features could further refine the model. While the dataset does not include severe fouling or cleaning events, it reflects typical operational variability and moderate fouling progression encountered in stable full-scale MBR operations. Should future datasets include more diverse event data, the proposed framework can readily incorporate these to further enhance its generalizability and event prediction capabilities.

3.5. Explainable AI (XAI) for Membrane Fouling Prediction

To enhance the interpretability of the machine learning model and understand the contribution of individual features to membrane fouling prediction, XAI techniques were applied. Specifically, feature importance was assessed using built-in feature importance, permutation importance, and SHAP values, as summarized in Table 10. Additionally, Figures 6 and 7 provide visual representations of feature importance from different perspectives, allowing for a more comprehensive analysis.

Table 10. Feature importance comparison using built-in, permutation, and SHAP values.

Feature	Built-In (%)	Permutation (%)	SHAP (%)
F/M	12.05	16.19	13.23
SV30	2.55	1.39	3.21
SVI	3.40	2.16	2.83
MLSS	9.22	12.18	10.03695
DO	4.26	0.82	7.06
pH	3.92	2.06	2.96
Temp.	5.18	3.70	6.19
COD RM	6.79	1.64	4.16
F/M_MA5	22.65	33.70	26.17
SV30_MA5	5.30	3.28	3.04
SVI_MA5	4.47	1.25	2.54
MLSS_MA5	3.56	2.37	3.05
DO_MA5	2.93	1.51	3.38
pH_MA5	9.16	11.03	7.19
Temp._MA5	4.55	6.71	4.95




Figure 6. Comparison of built-in and permutation feature importance.

nâng cao hơn nữa khả năng khái quát hóa của mô hình, và các nghiên cứu trong tương lai nên kiểm chứng khung này bằng các bộ dữ liệu mở rộng.


Mô hình theo dõi thành công các biến động của Spec. Flux, đặc biệt trong những giai đoạn biến động đạt đỉnh, cho thấy khả năng khái quát hóa tốt trong điều kiện vận hành biến đổi. Tuy nhiên, mô hình vẫn có sai lệch nhỏ ở một số khu vực, nhất là khi biến động diễn ra nhanh, cho thấy việc bổ sung các yếu tố phụ thuộc theo thời gian hoặc đặc trưng trễ có thể giúp tinh chỉnh mô hình hơn nữa. Mặc dù bộ dữ liệu không bao gồm các sự kiện đóng cặn nghiêm trọng hoặc làm sạch, nhưng dữ liệu phản ánh mức độ biến thiên vận hành điển hình và quá trình đóng cặn ở mức vừa phải thường gặp trong các hệ thống MBR quy mô lớn vận hành ổn định. Nếu các bộ dữ liệu trong tương lai bao gồm dữ liệu về nhiều loại sự kiện hơn, khung đề xuất có thể dễ dàng tích hợp những dữ liệu này để nâng cao hơn nữa khả năng khái quát hóa và dự đoán sự kiện.

3.5. Explainable AI (XAI) for Membrane Fouling Prediction

Để tăng cường khả năng diễn giải của mô hình học máy và hiểu rõ đóng góp của từng đặc trưng đối với dự đoán hiện tượng bám bẩn màng, các kỹ thuật XAI đã được áp dụng. Cụ thể, mức độ quan trọng của đặc trưng được đánh giá bằng độ quan trọng đặc trưng tích hợp sẵn, độ quan trọng hoán vị và các giá trị SHAP, như được tóm tắt trong Bảng 10. Ngoài ra, Hình 6 và 7 minh họa trực quan mức độ quan trọng của đặc trưng từ nhiều góc độ khác nhau, cho phép phân tích toàn diện hơn.

Bảng 10. So sánh mức độ quan trọng của đặc trưng bằng các giá trị tích hợp sẵn, hoán vị và SHAP.

Feature	Built-In (%)	Permutation (%)	SHAP (%)
F/M	12.05	16.19	13.23
SV30	2.55	1.39	3.21
SVI	3.40	2.16	2.83
MLSS	9.22	12.18	10.03695
DO	4.26	0.82	7.06
pH	3.92	2.06	2.96
Temp.	5.18	3.70	6.19
COD RM	6.79	1.64	4.16
F/M_MA5	22.65	33.70	26.17
SV30_MA5	5.30	3.28	3.04
SVI_MA5	4.47	1.25	2.54
MLSS_MA5	3.56	2.37	3.05
DO_MA5	2.93	1.51	3.38
pH_MA5	9.16	11.03	7.19
Temp._MA5	4.55	6.71	4.95



Hình 6. So sánh mức độ quan trọng của đặc trưng tích hợp sẵn và độ quan trọng hoán vị




Figure 7. SHAP summary plot illustrating the impact of individual feature values, with color gradients representing feature magnitudes.


3.5.1. Feature Importance Analysis

The feature importance values obtained from the CatBoost model (Table 10) highlight that F/M_MA5 (five-day moving average of F/M ratio) had the highest contribution across all three importance metrics, with 22.65% (built-in), 33.70% (permutation), and 26.17% (SHAP). This confirms that short-term variations in F/M ratio play a crucial role in membrane fouling behavior. Similarly, F/M, MLSSs, and pH_MA5 were also identified as key predictive factors, suggesting that both operational conditions and moving-average-based features significantly impact membrane performance.

The permutation importance method (Figure 6) further emphasizes the dominance of F/M_MA5, showing that removing this feature leads to the most significant drop in model performance. Other notable features include MLSSs, pH_MA5, and Temp., indicating their substantial influence on fouling dynamics.

3.5.2. SHAP Analysis

The SHAP summary plot in Figure 7 provides additional insights into the feature contributions by illustrating how individual feature values influence the model output. Higher F/M_MA5 values (shown in red) positively contributed to predicting membrane fouling severity, while lower values (shown in blue) had the opposite effect. This trend was also observed for F/M and MLSS, reinforcing the importance of biomass concentration and organic loading in fouling progression. The XAI techniques revealed critical insights into fouling mechanisms, identifying F/M ratio and MLSSs as dominant factors, consistent with conventional fouling studies [7,45]. Unlike purely empirical models [40], the framework



Hình 7. Biểu đồ tóm tắt SHAP minh họa tác động của các giá trị đặc trưng riêng lẻ, với dải màu biểu thị độ lớn của các đặc trưng.

3.5.1. Phân tích mức độ quan trọng của đặc trưng

Các giá trị mức độ quan trọng của đặc trưng thu được từ mô hình CatBoost (Bảng 10) cho thấy F/M_MA5 (trung bình động 5 ngày của tỷ lệ F/M) có mức đóng góp cao nhất theo cả ba chỉ số mức độ quan trọng, lần lượt là 22,65% (tích hợp sẵn), 33,70% (hoán vị) và 26,17% (SHAP). Điều này xác nhận rằng những biến động ngắn hạn của tỷ lệ F/M đóng vai trò then chốt trong hiện tượng bám bẩn màng. Tương tự, F/M, MLSSs và pH_MA5 cũng được xác định là các yếu tố dự báo quan trọng, cho thấy cả điều kiện vận hành lẫn các đặc trưng dựa trên trung bình động đều ảnh hưởng đáng kể đến hiệu suất màng.

Phương pháp độ quan trọng của hoán vị (Hình 6) càng nhấn mạnh vai trò vượt trội của F/M_MA5, cho thấy việc loại bỏ đặc trưng này dẫn đến mức suy giảm hiệu suất mô hình đáng kể nhất. Các đặc trưng đáng chú ý khác bao gồm MLSSs, pH_MA5 và Temp., cho thấy chúng ảnh hưởng đáng kể đến động lực học của hiện tượng cấu bẩn.

3.5.2. Phân tích SHAP

Biểu đồ tóm tắt SHAP trong Hình 7 cung cấp thêm thông tin chi tiết về mức độ đóng góp của các đặc trưng bằng cách minh họa cách các giá trị đặc trưng riêng lẻ ảnh hưởng đến đầu ra của mô hình. Các giá trị F/M_MA5 cao hơn (được hiển thị màu đỏ) góp phần tích cực vào việc dự đoán mức độ nghiêm trọng của hiện tượng tắc nghẽn màng, trong khi các giá trị thấp hơn (được hiển thị màu xanh lam) có tác động ngược lại. Xu hướng này cũng được ghi nhận ở F/M và MLSS, nhấn mạnh tầm quan trọng của nồng độ sinh khối và tải lượng hữu cơ đối với quá trình tắc nghẽn. Các kỹ thuật XAI đã làm sáng tỏ những cơ chế tắc nghẽn quan trọng, xác định tỷ lệ F/M và MLSS là các yếu tố chi phối, phù hợp với các nghiên cứu thông thường về tắc nghẽn [7,45]. Khác với các mô hình thuần túy thực nghiệm [40], khuôn khổ này

proposed in this study provides both high accuracy ($R^2 = 0.8374$) and interpretability, enabling operators to prioritize actionable parameters like F/M control.

Furthermore, the SHAP values for pH_MA5 and temperature reveal that lower pH values tend to increase membrane fouling risk, aligning with the previous study on microbial activity and biofilm formation [7]. Critically, the XAI analysis in this study quantitatively validated F/M ratio and MLSSs as dominant factors (contributing > 25% to predictions), corroborating mechanistic models in the previous study [1] that identified these parameters as primary drivers of sludge viscosity and cake layer formation. Similarly, higher temperatures correlated with increased flux stability, suggesting that thermal conditions impact filtration performance.

3.5.3. Implications for MBR Optimization

The integration of XAI techniques demonstrates that time-dependent features (moving averages) enhance the model’s predictive power, particularly for short-term fluctuations in fouling indicators. This suggests that incorporating temporal dependencies in real-time monitoring systems could improve predictive accuracy and operational decision making. Additionally, the identification of F/M_MA5 and MLSSs as key variables indicates that process control strategies should focus on optimizing these parameters to mitigate membrane fouling risk. The CatBoost model was identified as the most suitable approach for AI-based analysis of membrane fouling factors and the prediction of specific flux in this study. Its predictive performance was further enhanced when combined with advanced techniques such as robust scaling and moving averages. These methods are expected to enable the application of the CatBoost model across a wide range of MBR scenarios. Furthermore, the incorporation of such preprocessing and feature engineering techniques is expected to improve the performance of other AI-based analysis and predictive models as well. Therefore, as demonstrated in this study, the universality and scalability of analysis and predictive models for MBR fouling can be significantly improved by applying appropriate feature engineering, robust scaling, and moving average methods tailored to the characteristics of real-world field data.

These results confirm that CatBoost, combined with XAI methodologies, provides a reliable and interpretable approach for membrane fouling prediction in MBR systems. By leveraging feature importance insights, practitioners can refine operational strategies, prioritize sensor deployments, and enhance the sustainability of membrane-based wastewater treatment.

4. Conclusions

This study presents a predictive framework for membrane fouling in full-scale MBR systems by integrating AI-driven feature engineering and explainable AI (XAI). The developed predictive framework is intended for direct application in real MBR plants. By utilizing parameters routinely measured in operational settings and incorporating robust interpretable AI models, the framework supports proactive fouling management and operational decision making. By refining the target parameter to specific flux (Flux/TMP) and incorporating COD removal efficiency as a biological performance indicator, the model captures the dynamic interplay between operational parameters and fouling behavior. The application of moving average techniques further enhanced temporal feature representation, addressing the cumulative effects of fouling progression. Among tested models, CatBoost demonstrated superior predictive accuracy, outperforming traditional statistical and machine learning approaches.

XAI techniques revealed critical insights into fouling mechanisms, identifying F/M ratio and MLSSs as dominant factors influencing fouling dynamics. These findings un-

được đề xuất trong nghiên cứu này vừa có độ chính xác cao ($R^2 = 0.8374$) vừa có khả năng diễn giải, giúp người vận hành ưu tiên các thông số có thể điều chỉnh như kiểm soát F/M.

Hơn nữa, các giá trị SHAP của pH_MA5 và nhiệt độ cho thấy pH thấp hơn có xu hướng làm tăng nguy cơ tắc nghẽn màng, phù hợp với nghiên cứu trước đây về hoạt động của vi sinh vật và sự hình thành màng sinh học [7]. Đáng chú ý, phân tích XAI trong nghiên cứu này đã định lượng và xác nhận tỷ lệ F/M cùng MLSS là các yếu tố chi phối (đóng góp > 25% vào các dự đoán), qua đó củng cố các mô hình cơ chế trong nghiên cứu trước đây [1], vốn xác định những thông số này là động lực chính gây ra độ nhớt của bùn và sự hình thành lớp bánh lọc. Tương tự, nhiệt độ cao hơn có mối tương quan với độ ổn định thông lượng tăng, cho thấy các điều kiện nhiệt ảnh hưởng đến hiệu suất lọc.

3.5.3. Hàm ý đối với việc tối ưu hóa MBR

Việc tích hợp các kỹ thuật XAI cho thấy các đặc trưng phụ thuộc vào thời gian (đường trung bình trượt) giúp nâng cao năng lực dự đoán của mô hình, đặc biệt đối với những biến động ngắn hạn của các chỉ số cấu bẩn. Điều này cho thấy việc đưa các phụ thuộc theo thời gian vào hệ thống giám sát thời gian thực có thể cải thiện độ chính xác dự đoán và khả năng ra quyết định vận hành. Ngoài ra, việc xác định F/M_MA5 và MLSSs là các biến số chủ chốt cho thấy các chiến lược kiểm soát quy trình nên tập trung vào việc tối ưu hóa những tham số này để giảm thiểu nguy cơ cấu bẩn màng. Trong nghiên cứu này, mô hình CatBoost được xác định là phương pháp phù hợp nhất để phân tích các yếu tố gây cấu bẩn màng dựa trên AI và dự đoán thông lượng riêng. Hiệu suất dự đoán của mô hình còn được nâng cao khi kết hợp với các kỹ thuật tiên tiến như chuẩn hóa bền vững và đường trung bình trượt. Các phương pháp này được kỳ vọng sẽ cho phép áp dụng mô hình CatBoost trong nhiều kịch bản MBR. Hơn nữa, việc áp dụng các kỹ thuật tiền xử lý và kỹ thuật tạo đặc trưng như vậy cũng được kỳ vọng sẽ cải thiện hiệu suất của các mô hình phân tích và dự đoán dựa trên AI khác. Do đó, như nghiên cứu này đã chứng minh, có thể cải thiện đáng kể tính phổ quát và khả năng mở rộng của các mô hình phân tích và dự đoán hiện tượng cấu bẩn trong MBR bằng cách áp dụng các phương pháp tạo đặc trưng, chuẩn hóa bền vững và trung bình trượt phù hợp với đặc điểm của dữ liệu thực địa.

Những kết quả này xác nhận rằng CatBoost, khi kết hợp với các phương pháp XAI, cung cấp một cách tiếp cận đáng tin cậy và dễ diễn giải để dự đoán hiện tượng tắc nghẽn màng trong các hệ thống MBR. Bằng cách tận dụng những thông tin chuyên sâu về mức độ quan trọng của các đặc trưng, các chuyên gia có thể tinh chỉnh chiến lược vận hành, ưu tiên triển khai cảm biến và nâng cao tính bền vững của quy trình xử lý nước thải bằng màng.

4. Kết luận

Nghiên cứu này trình bày một khuôn khổ dự đoán hiện tượng tắc nghẽn màng trong các hệ thống MBR quy mô thực tế, bằng cách tích hợp kỹ thuật đặc trưng dựa trên AI và AI có khả năng giải thích (XAI). Khuôn khổ dự đoán được phát triển nhằm ứng dụng trực tiếp tại các nhà máy MBR thực tế. Bằng cách sử dụng các thông số thường xuyên được đo trong quá trình vận hành và tích hợp các mô hình AI có khả năng diễn giải mạnh mẽ, khuôn khổ này hỗ trợ quản lý tắc nghẽn chủ động và ra quyết định vận hành. Việc điều chỉnh tham số mục tiêu thành thông lượng riêng (Flux/TMP) và đưa hiệu suất loại bỏ COD vào làm chỉ báo hiệu quả sinh học giúp mô hình nắm bắt sự tương tác biến động giữa các thông số vận hành và diễn biến tắc nghẽn. Việc áp dụng các kỹ thuật trung bình trượt còn cải thiện khả năng biểu diễn đặc trưng theo thời gian, qua đó xử lý các tác động tích lũy của quá trình tắc nghẽn. Trong số các mô hình được thử nghiệm, CatBoost cho thấy độ chính xác dự đoán vượt trội, tốt hơn các phương pháp thống kê và học máy truyền thống.

Các kỹ thuật XAI đã cung cấp những hiểu biết then chốt về cơ chế bám bẩn, xác định tỷ lệ F/M và MLSS là các yếu tố chi phối ảnh hưởng đến động thái bám bẩn. Những phát hiện này không-

derscore the importance of real-time monitoring and adaptive control strategies, such as optimizing organic loading and biomass concentration, to mitigate fouling risks. While the proposed framework is not intended to replace physics-based control models, its predictive capability and interpretability provide critical decision support inputs for optimizing maintenance schedules and informing adaptive control strategies in full-scale MBR operations. The framework’s validation using real-world data from an operational MBR highlights its practical applicability under non-ideal conditions. The framework synergizes with physics-based models (e.g., biofilm dynamics simulations) by providing data-driven refinements to fouling predictions, while its compatibility with low-cost sensors bridges gaps in traditional monitoring tools. This integration enables adaptive control strategies that dynamically adjust operational parameters (e.g., aeration intensity, sludge retention) based on real-time fouling risk assessment. However, the relatively small dataset limits the generalizability of the model. Future studies should validate the framework using larger and more diverse datasets to enhance robustness and applicability across different MBR configurations.

This work demonstrates that prediction and interpretation of fouling behavior is achievable even under suboptimal data conditions, providing a critical bridge between academic research and industrial practice. In addition, this work bridges the gap between complex AI models and operational interpretability, offering a robust tool for proactive membrane management. Future research should prioritize the integration of these AI-based models with sensor networks and adaptive control systems, thereby enabling the dynamic optimization of operational parameters such as aeration, sludge retention, and filtration protocols in real time. Such efforts are expected to enhance the overall efficiency of MBR processes, reduce energy consumption, and contribute to the extension of membrane lifespan. The methodology’s adaptability also holds promise for broader applications in membrane-based processes, including desalination and industrial wastewater treatment, fostering sustainable advancements in water resource management. The core principles of this framework—dynamic target parameters (e.g., specific flux), temporal feature engineering, and XAI interpretability—are transferable to other membrane processes like reverse osmosis (RO). For instance, RO fouling is similarly time-dependent and influenced by operational fluctuations (e.g., pressure, flux variations). Adaptations would require domain-specific adjustments (e.g., incorporating scaling indices for mineral fouling), but the methodology’s foundation in handling noisy real-world data and capturing cumulative effects remains broadly applicable across membrane technologies. Future work will focus on integrating the model with online monitoring systems for real-time prediction and adaptive control in full-scale facilities.

Author Contributions: Conceptualization, J.L. and S.L.; methodology, J.P., S.-G.P. and J.-Y.K.; experiments, J.L. and J.-Y.K.; software, S.L. and J.P.; formal analysis, J.L., Y.G., J.P., S.-G.P. and J.-Y.K. data curation, J.L. Ren, X., Y.G. and J.P.; visualization, J.P. and S.L.; writing—original draft preparation; J.L. and S.L.; writing—review and editing, S.L., X.R. and M.-H.H.; supervision, X.R. and M.-H.H.; project administration, X.R. and M.-H.H.; funding acquisition; X.R. and M.-H.H. All authors have read and agreed to the published version of the manuscript.

Funding: This work was supported by the Korea Agency for Infrastructure Technology Advancement (KAIA) grant funded by the Ministry of Land, Infrastructure and Transport (Grant RS-2022-00144137).

Data Availability Statement: The original contributions presented in this study are included in the article. Further inquiries can be directed to the corresponding author.

Conflicts of Interest: All authors declare that the research was conducted in the absence of any commercial or financial relationships that could be construed as potential conflicts of interest.

Nhấn mạnh tầm quan trọng của việc giám sát theo thời gian thực và các chiến lược điều khiển thích ứng, chẳng hạn như tối ưu hóa tải lượng hữu cơ và nồng độ sinh khối, nhằm giảm thiểu nguy cơ tắc nghẽn. Mặc dù khuôn khổ được đề xuất không nhằm thay thế các mô hình điều khiển dựa trên vật lý, khả năng dự báo và tính dễ diễn giải của nó cung cấp những thông tin hỗ trợ ra quyết định thiết yếu để tối ưu hóa lịch bảo trì và định hướng các chiến lược điều khiển thích ứng trong vận hành MBR quy mô thực tế. Việc kiểm định khuôn khổ bằng dữ liệu thực tế từ một hệ thống MBR đang hoạt động cho thấy khả năng ứng dụng thực tiễn trong các điều kiện không lý tưởng. Khuôn khổ này hỗ trợ cho các mô hình dựa trên vật lý (ví dụ: mô phỏng động lực học màng sinh học) bằng cách đưa ra những hiệu chỉnh dựa trên dữ liệu cho các dự báo về hiện tượng tắc nghẽn, đồng thời khả năng tương thích với các cảm biến chi phí thấp giúp khắc phục những hạn chế của các công cụ giám sát truyền thống. Sự tích hợp này cho phép áp dụng các chiến lược điều khiển thích ứng, trong đó các thông số vận hành (ví dụ: cường độ sục khí, thời gian lưu bùn) được điều chỉnh linh hoạt dựa trên đánh giá nguy cơ tắc nghẽn theo thời gian thực. Tuy nhiên, tập dữ liệu tương đối nhỏ hạn chế khả năng khái quát hóa của mô hình. Các nghiên cứu trong tương lai nên kiểm định khuôn khổ bằng những tập dữ liệu lớn hơn và đa dạng hơn để tăng cường độ vững chắc và khả năng ứng dụng trên các cấu hình MBR khác nhau.

Công trình này chứng minh rằng có thể dự đoán và diễn giải hành vi bám bẩn ngay cả trong điều kiện dữ liệu chưa tối ưu, qua đó tạo cầu nối quan trọng giữa nghiên cứu học thuật và thực tiễn công nghiệp. Ngoài ra, công trình này thu hẹp khoảng cách giữa các mô hình AI phức tạp và khả năng diễn giải trong vận hành, cung cấp một công cụ hiệu quả để quản lý màng một cách chủ động. Nghiên cứu trong tương lai nên ưu tiên tích hợp các mô hình dựa trên AI này với mạng lưới cảm biến và hệ thống điều khiển thích ứng, từ đó cho phép tối ưu hóa linh hoạt các thông số vận hành như sục khí, thời gian lưu bùn và quy trình lọc theo thời gian thực. Những nỗ lực này được kỳ vọng sẽ nâng cao hiệu quả tổng thể của các quy trình MBR, giảm tiêu thụ năng lượng và góp phần kéo dài tuổi thọ màng. Khả năng thích ứng của phương pháp này cũng hứa hẹn ứng dụng rộng rãi hơn trong các quy trình sử dụng màng, bao gồm khử muối và xử lý nước thải công nghiệp, thúc đẩy những tiến bộ bền vững trong quản lý tài nguyên nước. Các nguyên lý cốt lõi của khuôn khổ này—các tham số mục tiêu động (ví dụ: thông lượng riêng), thiết kế đặc trưng theo thời gian và khả năng diễn giải XAI—có thể áp dụng cho các quy trình màng khác như thẩm thấu ngược (RO). Chẳng hạn, hiện tượng bám bẩn trong RO cũng phụ thuộc vào thời gian và chịu ảnh hưởng của những biến động vận hành (ví dụ: áp suất, biến thiên thông lượng). Việc điều chỉnh sẽ cần những thay đổi đặc thù theo từng lĩnh vực (ví dụ: bổ sung các chỉ số đóng cặn khoáng), nhưng nền tảng phương pháp luận về xử lý dữ liệu thực tế nhiều và nắm bắt các tác động tích lũy vẫn có khả năng áp dụng rộng rãi trên nhiều công nghệ màng. Nghiên cứu trong tương lai sẽ tập trung tích hợp mô hình với các hệ thống giám sát trực tuyến để dự đoán theo thời gian thực và điều khiển thích ứng tại các cơ sở quy mô công nghiệp.

Đóng góp của các tác giả: Xây dựng ý tưởng, J.L. và S.L.; phương pháp, J.P., S.-G.P. và J.-Y.K.; thực nghiệm, J.L. và J.-Y.K.; phần mềm, S.L. và J.P.; phân tích chính thức, J.L., Y.G., J.P., S.-G.P. và J.-Y.K.; quản lý dữ liệu, J.L. Ren, X., Y.G. và J.P.; trực quan hóa, J.P. và S.L.; viết bản thảo gốc, J.L. và S.L.; rà soát và biên tập, S.L., X.R. và M.-H.H.; giám sát, X.R. và M.-H.H.; quản lý dự án, X.R. và M.-H.H.; huy động kinh phí, X.R. và M.-H.H. Tất cả các tác giả đã đọc và đồng ý với phiên bản bản thảo được công bố.

Kinh phí: Nghiên cứu này được hỗ trợ bởi khoản tài trợ của Cơ quan Thúc đẩy Công nghệ Hàn Quốc (KAIA), do Bộ Đất đai, Cơ sở hạ tầng và Giao thông tài trợ (Mã tài trợ RS-2022-00144137).

Tuyên bố về tính sẵn có của dữ liệu: Những đóng góp ban đầu được trình bày trong nghiên cứu này được đưa vào bài viết. Các thắc mắc khác có thể được gửi đến tác giả liên hệ.

Xung đột lợi ích: Tất cả các tác giả tuyên bố rằng nghiên cứu được thực hiện mà không có bất kỳ mối quan hệ thương mại hoặc tài chính nào có thể bị xem là xung đột lợi ích tiềm ẩn.

References

1. Meng, F.; Chae, S.-R.; Drews, A.; Kraume, M.; Shin, H.-S.; Yang, F. Recent advances in membrane bioreactors (MBRs): Membrane fouling and membrane material. *Water Res.* **2009**, *43*, 1489–1512. [\[CrossRef\]](#)

2. Shi, Y.; Wang, Z.; Du, X.; Gong, B.; Jegatheesan, V.; Haq, I.U. Recent advances in the prediction of fouling in membrane bioreactors. *Membranes* **2021**, *11*, 381. [\[CrossRef\]](#) [\[PubMed\]](#)

3. Rahman, T.U.; Roy, H.; Islam, M.R.; Tahmid, M.; Fariha, A.; Mazumder, A.; Tasnim, N.; Pervez, M.N.; Cai, Y.; Naddeo, V. The advancement in membrane bioreactor (MBR) technology toward sustainable industrial wastewater management. *Membranes* **2023**, *13*, 181. [\[CrossRef\]](#) [\[PubMed\]](#)

4. Burman, I.; Sinha, A. A review on membrane fouling in membrane bioreactors: Control and mitigation. In *Environmental Contaminants: Measurement, Modelling and Control*; Springer: Singapore, 2018; pp. 281–315. [\[CrossRef\]](#)

5. Meng, F.; Zhang, S.; Oh, Y.; Zhou, Z.; Shin, H.-S.; Chae, S.-R. Fouling in membrane bioreactors: An updated review. *Water Res.* **2017**, *114*, 151–180. [\[CrossRef\]](#)

6. Kim, M.; Sankararao, B.; Yoo, C. Determination of MBR fouling and chemical cleaning interval using statistical methods applied on dynamic index data. *J. Membr. Sci.* **2011**, *375*, 345–353. [\[CrossRef\]](#)

7. Iorhemen, O.T.; Hamza, R.A.; Tay, J.H. Membrane bioreactor (MBR) technology for wastewater treatment and reclamation: Membrane fouling. *Membranes* **2016**, *6*, 33. [\[CrossRef\]](#)

8. Morales, N.; Mery-Araya, C.; Guerra, P.; Poblete, R.; Chacana-Olivares, J. Mitigation of Membrane Fouling in Membrane Bioreactors Using Granular and Powdered Activated Carbon: An Experimental Study. *Water* **2024**, *16*, 2556. [\[CrossRef\]](#)

9. Lim, Y.J.; Goh, K.; Nadzri, N.; Wang, R. Thin-film composite (TFC) membranes for sustainable desalination and water reuse: A perspective. *Desalination* **2025**, *599*, 118451. [\[CrossRef\]](#)

10. Mannina, G.; Ni, B.-J.; Makinia, J.; Harmand, J.; Alliet, M.; Brepols, C.; Ruano, M.V.; Robles, A.; Heran, M.; Gulhan, H. Biological processes modelling for MBR systems: A review of the state-of-the-art focusing on SMP and EPS. *Water Res.* **2023**, *242*, 120275. [\[CrossRef\]](#)

11. Benyahia, B.; Charfi, A.; Lesage, G.; Heran, M.; Cherki, B.; Harmand, J. Coupling a simple and generic membrane fouling model with biological dynamics: Application to the modeling of an Anaerobic Membrane BioReactor (AnMBR). *Membranes* **2024**, *14*, 69. [\[CrossRef\]](#)

12. Kim, M.; Sankararao, B.; Lee, S.; Yoo, C. Prediction and identification of membrane fouling mechanism in a membrane bioreactor using a combined mechanistic model. *Ind. Eng. Chem. Res.* **2013**, *52*, 17198–17205. [\[CrossRef\]](#)

13. Sandoval-García, V.; Ruano, M.; Alliet, M.; Brepols, C.; Comas, J.; Harmand, J.; Heran, M.; Mannina, G.; Rodriguez-Roda, I.; Smets, I. Modeling MBR fouling: A critical review analysis towards establishing a framework for good modeling practices. *Water Res.* **2025**, *268*, 122611. [\[CrossRef\]](#)

14. Paul, P. Investigation of a MBR membrane fouling model based on time series analysis system identification methods. *Desalination Water Treat.* **2011**, *35*, 92–100. [\[CrossRef\]](#)

15. Galinha, C.; Carvalho, G.; Portugal, C.; Guglielmi, G.; Oliveira, R.; Crespo, J.; Reis, M. Real-time monitoring of membrane bioreactors with 2D-fluorescence data and statistically based models. *Water Sci. Technol.* **2011**, *63*, 1381–1388. [\[CrossRef\]](#) [\[PubMed\]](#)

16. Fortunato, L.; Pathak, N.; Rehman, Z.U.; Shon, H.; Leiknes, T. Real-time monitoring of membrane fouling development during early stages of activated sludge membrane bioreactor operation. *Process Saf. Environ. Prot.* **2018**, *120*, 313–320. [\[CrossRef\]](#)

17. Niu, B.; Yang, L.; Meng, S.; Liang, D.; Liu, H.; Yang, L.; Shen, L.; Zhao, Q. Time-dependent analysis of polysaccharide fouling by Hermia models: Reveal the structure of fouling layer. *Sep. Purif. Technol.* **2022**, *302*, 122093. [\[CrossRef\]](#)

18. Wang, Y.; Zheng, X.; Xiao, K.; Xue, J.; Ulbricht, M.; Zhang, Y. How and why does time matter-A comparison of fouling caused by organic substances on membranes over adsorption durations. *Sci. Total Environ.* **2023**, *866*, 160655. [\[CrossRef\]](#)

19. Ahmad Yasmin, N.S.; Abdul Wahab, N.; Yusuf, Z. Modeling of membrane bioreactor of wastewater treatment using support vector machine. In *Modeling, Design and Simulation of Systems, Proceedings of the 17th Asia Simulation Conference (AsiaSim 2017), Melaka, Malaysia, 27–29 August 2017*; Proceedings, Part II 17; Springer: Singapore, 2017; pp. 485–495. [\[CrossRef\]](#)

20. Niu, C.; Li, X.; Dai, R.; Wang, Z. Artificial intelligence-incorporated membrane fouling prediction for membrane-based processes in the past 20 years: A critical review. *Water Res.* **2022**, *216*, 118299. [\[CrossRef\]](#)

21. Abuwatfa, W.H.; AlSawaftah, N.; Darwish, N.; Pitt, W.G.; Hussein, G.A. A review on membrane fouling prediction using artificial neural networks (ANNs). *Membranes* **2023**, *13*, 685. [\[CrossRef\]](#)

22. Niu, C.; Li, B.; Wang, Z. Using artificial intelligence-based algorithms to identify critical fouling factors and predict fouling behavior in anaerobic membrane bioreactors. *J. Membr. Sci.* **2023**, *687*, 122076. [\[CrossRef\]](#)

23. Frontistis, Z.; Lykogiannis, G.; Sarmpanis, A. Artificial Neural Networks in Membrane Bioreactors: A Comprehensive Review—Overcoming Challenges and Future Perspectives. *Sci* **2023**, *5*, 31. [\[CrossRef\]](#)

24. Frontistis, Z.; Lykogiannis, G.; Sarmpanis, A. Machine learning implementation in membrane bioreactor systems: Progress, challenges, and future perspectives: A review. *Environments* **2023**, *10*, 127. [\[CrossRef\]](#)

Tài liệu tham khảo

1. Meng, F.; Chae, S.-R.; Drews, A.; Kraume, M.; Shin, H.-S.; Yang, F. Những tiến bộ gần đây trong công nghệ lọc sinh học màng (MBR): Sự tắc nghẽn màng và vật liệu màng. *Water Res.* 2009, *43*, 1489–1512. [\[CrossRef\]](#)

2. Shi, Y.; Wang, Z.; Du, X.; Gong, B.; Jegatheesan, V.; Haq, I.U. Những tiến bộ gần đây trong dự đoán sự tắc nghẽn ở các hệ thống lọc sinh học màng. *Membranes* 2021, *11*, 381. [\[CrossRef\]](#) [\[PubMed\]](#)

3. Rahman, T.U.; Roy, H.; Islam, M.R.; Tahmid, M.; Fariha, A.; Mazumder, A.; Tasnim, N.; Pervez, M.N.; Cai, Y.; Naddeo, V. Những tiến bộ trong công nghệ lọc sinh học màng (MBR) hướng tới quản lý bền vững nước thải công nghiệp. *Membranes* 2023, *13*, 181. [\[CrossRef\]](#) [\[PubMed\]](#)

4. Burman, I.; Sinha, A. Tổng quan về sự tắc nghẽn màng trong các hệ thống lọc sinh học màng: Kiểm soát và giảm thiểu. Trong *Environmental Contaminants: Measurement, Modelling and Control*; Springer: Singapore, 2018; tr. 281–315. [\[CrossRef\]](#)

5. Meng, F.; Zhang, S.; Oh, Y.; Zhou, Z.; Shin, H.-S.; Chae, S.-R. Sự tắc nghẽn trong các hệ thống lọc sinh học màng: Bài tổng quan cập nhật. *Water Res.* 2017, *114*, 151–180. [\[CrossRef\]](#)

6. Kim, M.; Sankararao, B.; Yoo, C. Xác định mức độ tắc nghẽn màng MBR và khoảng thời gian làm sạch hóa học bằng các phương pháp thống kê áp dụng trên dữ liệu chỉ số động. *J. Membr. Sci.* 2011, *375*, 345–353. [\[CrossRef\]](#)

7. Iorhemen, O.T.; Hamza, R.A.; Tay, J.H. Công nghệ lọc sinh học màng (MBR) để xử lý và tái sử dụng nước thải: Sự tắc nghẽn màng. *Membranes* 2016, *6*, 33. [\[CrossRef\]](#)

8. Morales, N.; Mery-Araya, C.; Guerra, P.; Poblete, R.; Chacana-Olivares, J. Giảm thiểu sự tắc nghẽn màng trong các hệ thống lọc sinh học màng bằng than hoạt tính dạng hạt và dạng bột: Nghiên cứu thực nghiệm. *Water* 2024, *16*, 2556. [\[CrossRef\]](#)

9. Lim, Y.J.; Goh, K.; Nadzri, N.; Wang, R. Màng composite màng mỏng (TFC) phục vụ khử muối bền vững và tái sử dụng nước: Một góc nhìn. *Desalination* 2025, *599*, 118451. [\[CrossRef\]](#)

10. Mannina, G.; Ni, B.-J.; Makinia, J.; Harmand, J.; Alliet, M.; Brepols, C.; Ruano, M.V.; Robles, A.; Heran, M.; Gulhan, H. Mô hình hóa các quá trình sinh học cho hệ thống MBR: Tổng quan về hiện trạng, tập trung vào SMP và EPS. *Water Res.* 2023, *242*, 120275. [\[CrossRef\]](#)

11. Benyahia, B.; Charfi, A.; Lesage, G.; Heran, M.; Cherki, B.; Harmand, J. Kết hợp mô hình đơn giản, tổng quát về sự tắc nghẽn màng với động học sinh học: Ứng dụng vào mô hình hóa hệ thống lọc sinh học màng kỵ khí (AnMBR). *Membranes* 2024, *14*, 69. [\[CrossRef\]](#)

12. Kim, M.; Sankararao, B.; Lee, S.; Yoo, C. Dự đoán và nhận diện cơ chế tắc nghẽn màng trong hệ thống lọc sinh học màng bằng mô hình cơ chế kết hợp. *Ind. Eng. Chem. Res.* 2013, *52*, 17198–17205. [\[CrossRef\]](#)

13. Sandoval-García, V.; Ruano, M.; Alliet, M.; Brepols, C.; Comas, J.; Harmand, J.; Heran, M.; Mannina, G.; Rodriguez-Roda, I.; Smets, I. Mô hình hóa sự tắc nghẽn MBR: Phân tích tổng quan phê bình nhằm thiết lập khuôn khổ cho các thực hành mô hình hóa tốt. *Water Res.* 2025, *268*, 122611. [\[CrossRef\]](#)

14. Paul, P. Nghiên cứu mô hình tắc nghẽn màng MBR dựa trên các phương pháp nhận dạng hệ thống bằng phân tích chuỗi thời gian. *Desalination Water Treat.* 2011, *35*, 92–100. [\[CrossRef\]](#)

15. Galinha, C.; Carvalho, G.; Portugal, C.; Guglielmi, G.; Oliveira, R.; Crespo, J.; Reis, M. Giám sát thời gian thực các hệ thống lọc sinh học màng bằng dữ liệu huỳnh quang 2D và các mô hình dựa trên thống kê. *Water Sci. Technol.* 2011, *63*, 1381–1388. [\[CrossRef\]](#) [\[PubMed\]](#)

16. Fortunato, L.; Pathak, N.; Rehman, Z.U.; Shon, H.; Leiknes, T. Giám sát thời gian thực quá trình hình thành sự tắc nghẽn màng trong giai đoạn đầu vận hành hệ thống lọc sinh học màng bùn hoạt tính. *Process Saf. Environ. Prot.* 2018, *120*, 313–320. [\[CrossRef\]](#)

17. Niu, B.; Yang, L.; Meng, S.; Liang, D.; Liu, H.; Yang, L.; Shen, L.; Zhao, Q. Phân tích sự tắc nghẽn do polysaccharide phụ thuộc thời gian bằng các mô hình Hermia: Làm sáng tỏ cấu trúc lớp tắc nghẽn. *Sep. Purif. Technol.* 2022, *302*, 122093. [\[CrossRef\]](#)

18. Wang, Y.; Zheng, X.; Xiao, K.; Xue, J.; Ulbricht, M.; Zhang, Y. Thời gian có vai trò như thế nào và vì sao? So sánh sự tắc nghẽn do các chất hữu cơ gây ra trên màng ở các khoảng thời gian hấp phụ khác nhau. *Sci. Total Environ.* 2023, *866*, 160655. [\[CrossRef\]](#)

19. Ahmad Yasmin, N.S.; Abdul Wahab, N.; Yusuf, Z. Mô hình hóa hệ thống lọc sinh học màng xử lý nước thải bằng máy vectơ hỗ trợ. Trong *Modeling, Design and Simulation of Systems, Proceedings of the 17th Asia Simulation Conference (AsiaSim 2017), Melaka, Malaysia, 27–29 August 2017*; Kỷ yếu, Phần II 17; Springer: Singapore, 2017; tr. 485–495. [\[CrossRef\]](#)

20. Niu, C.; Li, X.; Dai, R.; Wang, Z. Dự đoán sự tắc nghẽn màng tích hợp trí tuệ nhân tạo cho các quy trình sử dụng màng trong 20 năm qua: Tổng quan phê bình. *Water Res.* 2022, *216*, 118299. [\[CrossRef\]](#)

21. Abuwatfa, W.H.; AlSawaftah, N.; Darwish, N.; Pitt, W.G.; Hussein, G.A. Tổng quan về dự đoán sự tắc nghẽn màng bằng mạng nơ-ron nhân tạo (ANN). *Membranes* 2023, *13*, 685. [\[CrossRef\]](#)

22. Niu, C.; Li, B.; Wang, Z. Sử dụng các thuật toán dựa trên trí tuệ nhân tạo để xác định các yếu tố gây tắc nghẽn quan trọng và dự đoán diễn biến tắc nghẽn trong các hệ thống lọc sinh học màng kỵ khí. *J. Membr. Sci.* 2023, *687*, 122076. [\[CrossRef\]](#)

23. Frontistis, Z.; Lykogiannis, G.; Sarmpanis, A. Mạng nơ-ron nhân tạo trong các hệ thống lọc sinh học màng: Tổng quan toàn diện—Khả năng thách thức và triển vọng tương lai. *Sci* 2023, *5*, 31. [\[CrossRef\]](#)

24. Frontistis, Z.; Lykogiannis, G.; Sarmpanis, A. Ứng dụng học máy trong các hệ thống lọc sinh học màng: Tiến bộ, thách thức và triển vọng tương lai—Tổng quan. *Environments* 2023, *10*, 127. [\[CrossRef\]](#)

25. Maere, T.; Villez, K.; Marsili-Libelli, S.; Naessens, W.; Nopens, I. Membrane bioreactor fouling behaviour assessment through principal component analysis and fuzzy clustering. *Water Res.* **2012**, *46*, 6132–6142. [\[CrossRef\]](#)

26. Wang, Z.; Zeng, J.; Shi, Y.; Ling, G. MBR membrane fouling diagnosis based on improved residual neural network. *J. Environ. Chem. Eng.* **2023**, *11*, 109742. [\[CrossRef\]](#)

27. Zhong, H.; Yuan, Y.; Luo, L.; Ye, J.; Chen, M.; Zhong, C. Water quality prediction of MBR based on machine learning: A novel dataset contribution analysis method. *J. Water Process Eng.* **2022**, *50*, 103296. [\[CrossRef\]](#)

28. Zhang, S.; Jin, Y.; Chen, W.; Wang, J.; Wang, Y.; Ren, H. Artificial intelligence in wastewater treatment: A data-driven analysis of status and trends. *Chemosphere* **2023**, *336*, 139163. [\[CrossRef\]](#)

29. Savage, N. Breaking into the black box of artificial intelligence. *Nature* **2022**. [\[CrossRef\]](#)

30. Rudin, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nat. Mach. Intell.* **2019**, *1*, 206–215. [\[CrossRef\]](#)

31. Mersha, M.; Lam, K.; Wood, J.; AlShami, A.K.; Kalita, J. Explainable artificial intelligence: A survey of needs, techniques, applications, and future direction. *Neurocomputing* **2024**, *599*, 128111. [\[CrossRef\]](#)

32. Bourget, G. Statistical analysis of wastewater treatment plant data. *SN Appl. Sci.* **2023**, *5*, 130. [\[CrossRef\]](#)

33. Baarimah, A.O.; Bazel, M.A.; Alaloul, W.S.; Alazaiza, M.Y.; Al-Zghoul, T.M.; Almuhaya, B.; Khan, A.; Mushtaha, A.W. Artificial intelligence in wastewater treatment: Research trends and future perspectives through bibliometric analysis. *Case Stud. Chem. Environ. Eng.* **2024**, *10*, 100926. [\[CrossRef\]](#)

34. Cirillo, A.I.; Tomaiuolo, G.; Guido, S. Membrane fouling phenomena in microfluidic systems: From technical challenges to scientific opportunities. *Micromachines* **2021**, *12*, 820. [\[CrossRef\]](#) [\[PubMed\]](#)

35. Dagher, G.; Martin, A.; Galharret, J.M.; Moulin, L.; Croué, J.P.; Teychene, B. Forecasting multicycle hollow fiber ultrafiltration fouling using time series analysis. *J. Water Process Eng.* **2023**, *56*, 104441. [\[CrossRef\]](#)

36. Goi, Y.; Liang, Y. A general modeling framework for FO spiral-wound membrane and its fouling impact on FO-RO desalination system. *Desalination* **2025**, *593*, 118236. [\[CrossRef\]](#)

37. Hazrati, H.; Moghaddam, A.H.; Rostamizadeh, M. The influence of hydraulic retention time on cake layer specifications in the membrane bioreactor: Experimental and artificial neural network modeling. *J. Environ. Chem. Eng.* **2017**, *5*, 3005–3013. [\[CrossRef\]](#)

38. Schmitt, F.; Banu, R.; Yeom, I.-T.; Do, K.-U. Development of artificial neural networks to predict membrane fouling in an anoxic-aerobic membrane bioreactor treating domestic wastewater. *Biochem. Eng. J.* **2018**, *133*, 47–58. [\[CrossRef\]](#)

39. Viet, N.D.; Jang, A. Development of artificial intelligence-based models for the prediction of filtration performance and membrane fouling in an osmotic membrane bioreactor. *J. Environ. Chem. Eng.* **2021**, *9*, 105337. [\[CrossRef\]](#)

40. Li, C.; Tao, Y. Application of support vector machine with simulated annealing algorithm in MBR membrane pollution prediction. In Proceedings of the 2017 IEEE 15th International Conference on Software Engineering Research, Management and Applications (SERA), London, UK, 7–9 June 2017; pp. 211–217. [\[CrossRef\]](#)

41. Miller, D.J.; Kasemset, S.; Paul, D.R.; Freeman, B.D. Comparison of membrane fouling at constant flux and constant transmembrane pressure conditions. *J. Membr. Sci.* **2014**, *454*, 505–515. [\[CrossRef\]](#)

42. Hong, P.-N.; Noguchi, M.; Matsuura, N.; Honda, R. Mechanism of biofouling enhancement in a membrane bioreactor under constant trans-membrane pressure operation. *J. Membr. Sci.* **2019**, *592*, 117391. [\[CrossRef\]](#)

43. Yi, X.; Zhang, M.; Song, W.; Wang, X. Effect of Initial Water Flux on the Performance of Anaerobic Membrane Bioreactor: Constant Flux Mode versus Varying Flux Mode. *Membranes* **2021**, *11*, 203. [\[CrossRef\]](#)

44. Du, X.; Shi, Y.; Jegatheesan, V.; Haq, I.U. A review on the mechanism, impacts and control methods of membrane fouling in MBR system. *Membranes* **2020**, *10*, 24. [\[CrossRef\]](#)

45. Al-Asheh, S.; Bagheri, M.; Aidan, A. Membrane bioreactor for wastewater treatment: A review. *Case Stud. Chem. Environ. Eng.* **2021**, *4*, 100109. [\[CrossRef\]](#)

46. 5220; Standard Methods for the Examination of Water and Wastewater, 23rd ed. American Public Health Association (APHA): Washington, DC, USA, 2017. [\[CrossRef\]](#)

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.

25. Maere, T.; Villez, K.; Marsili-Libelli, S.; Naessens, W.; Nopens, I. Đánh giá đặc tính cấu trúc của bể phản ứng sinh học màng thông qua phân tích thành phần chính và phân cụm mờ. *Water Res.* **2012**, *46*, 6132–6142. [\[CrossRef\]](#)

26. Wang, Z.; Zeng, J.; Shi, Y.; Ling, G. Chẩn đoán cấu trúc màng MBR dựa trên mạng nơ-ron phân dư cải tiến. *J. Environ. Chem. Eng.* **2023**, *11*, 109742. [\[CrossRef\]](#)

27. Zhong, H.; Yuan, Y.; Luo, L.; Ye, J.; Chen, M.; Zhong, C. Dự đoán chất lượng nước của MBR dựa trên học máy: Phương pháp phân tích đóng góp dữ liệu mới. *J. Water Process Eng.* **2022**, *50*, 103296. [\[CrossRef\]](#)

28. Zhang, S.; Jin, Y.; Chen, W.; Wang, J.; Wang, Y.; Ren, H. Trí tuệ nhân tạo trong xử lý nước thải: Phân tích dựa trên dữ liệu về hiện trạng và xu hướng. *Chemosphere* **2023**, *336*, 139163. [\[CrossRef\]](#)

29. Savage, N. Khám phá hộp đen của trí tuệ nhân tạo. *Nature* **2022**. [\[CrossRef\]](#)

30. Rudin, C. Ngừng giải thích các mô hình học máy hộp đen trong những quyết định có hệ quả lớn và thay vào đó hãy sử dụng các mô hình có thể diễn giải. *Nat. Mach. Intell.* **2019**, *1*, 206–215. [\[CrossRef\]](#)

31. Mersha, M.; Lam, K.; Wood, J.; AlShami, A.K.; Kalita, J. Trí tuệ nhân tạo có thể giải thích: Khảo sát về nhu cầu, kỹ thuật, ứng dụng và định hướng tương lai. *Neurocomputing* **2024**, *599*, 128111. [\[CrossRef\]](#)

32. Bourget, G. Phân tích thống kê dữ liệu nhà máy xử lý nước thải. *SN Appl. Sci.* **2023**, *5*, 130. [\[CrossRef\]](#)

33. Baarimah, A.O.; Bazel, M.A.; Alaloul, W.S.; Alazaiza, M.Y.; Al-Zghoul, T.M.; Almuhaya, B.; Khan, A.; Mushtaha, A.W. Trí tuệ nhân tạo trong xử lý nước thải: Xu hướng nghiên cứu và triển vọng tương lai thông qua phân tích thư mục khoa học. *Case Stud. Chem. Environ. Eng.* **2024**, *10*, 100926. [\[CrossRef\]](#)

34. Cirillo, A.I.; Tomaiuolo, G.; Guido, S. Hiện tượng cấu trúc màng trong các hệ vi lưu: Từ thách thức kỹ thuật đến cơ hội khoa học. *Micromachines* **2021**, *12*, 820. [\[CrossRef\]](#) [\[PubMed\]](#)

35. Dagher, G.; Martin, A.; Galharret, J.M.; Moulin, L.; Croué, J.P.; Teychene, B. Dự báo cấu trúc trong quá trình siêu lọc sợi rỗng nhiều chu kỳ bằng phân tích chuỗi thời gian. *J. Water Process Eng.* **2023**, *56*, 104441. [\[CrossRef\]](#)

36. Goi, Y.; Liang, Y. Khuôn khổ mô hình hóa tổng quát cho màng FO cuộn xoắn ốc và tác động của cấu trúc đến hệ thống khử mặn FO-RO. *Desalination* **2025**, *593*, 118236. [\[CrossRef\]](#)

37. Hazrati, H.; Moghaddam, A.H.; Rostamizadeh, M. Ảnh hưởng của thời gian lưu thủy lực đến các đặc tính lớp bám trong bể phản ứng sinh học màng: Mô hình hóa thực nghiệm và bằng mạng nơ-ron nhân tạo. *J. Environ. Chem. Eng.* **2017**, *5*, 3005–3013. [\[CrossRef\]](#)

38. Schmitt, F.; Banu, R.; Yeom, I.-T.; Do, K.-U. Phát triển mạng nơ-ron nhân tạo để dự đoán cấu trúc màng trong bể phản ứng sinh học màng thiếu khí-hiếu khí xử lý nước thải sinh hoạt. *Biochem. Eng. J.* **2018**, *133*, 47–58. [\[CrossRef\]](#)

39. Viet, N.D.; Jang, A. Phát triển các mô hình dựa trên trí tuệ nhân tạo để dự đoán hiệu suất lọc và cấu trúc màng trong bể phản ứng sinh học màng thẩm thấu. *J. Environ. Chem. Eng.* **2021**, *9*, 105337. [\[CrossRef\]](#)

40. Li, C.; Tao, Y. Ứng dụng máy vectơ hỗ trợ kết hợp thuật toán tối ưu mô phỏng trong dự đoán ô nhiễm màng MBR. Trong Kỷ yếu Hội nghị Quốc tế lần thứ 15 I EEE về Nghiên cứu, Quản lý và Ứng dụng Kỹ thuật Phần mềm (SERA) năm 2017, London, Vương quốc Anh, 7–9 tháng 6 năm 2017; tr. 211–217. [\[CrossRef\]](#)

41. Miller, D.J.; Kasemset, S.; Paul, D.R.; Freeman, B.D. So sánh cấu trúc màng trong điều kiện thông lượng không đổi và áp suất xuyên màng không đổi. *J. Membr. Sci.* **2014**, *454*, 505–515. [\[CrossRef\]](#)

42. Hong, P.-N.; Noguchi, M.; Matsuura, N.; Honda, R. Cơ chế tăng cường cấu trúc sinh học trong bể phản ứng sinh học màng vận hành ở áp suất xuyên màng không đổi. *J. Membr. Sci.* **2019**, *592*, 117391. [\[CrossRef\]](#)

43. Yi, X.; Zhang, M.; Song, W.; Wang, X. Ảnh hưởng của thông lượng nước ban đầu đến hiệu suất của bể phản ứng sinh học màng kỵ khí: Chế độ thông lượng không đổi so với chế độ thông lượng thay đổi. *Membranes* **2021**, *11*, 203. [\[CrossRef\]](#)

44. Du, X.; Shi, Y.; Jegatheesan, V.; Haq, I.U. Tổng quan về cơ chế, tác động và các phương pháp kiểm soát cấu trúc màng trong hệ thống MBR. *Membranes* **2020**, *10*, 24. [\[CrossRef\]](#)

45. Al-Asheh, S.; Bagheri, M.; Aidan, A. Bể phản ứng sinh học màng để xử lý nước thải: Tổng quan. *Case Stud. Chem. Environ. Eng.* **2021**, *4*, 100109. [\[CrossRef\]](#)

46. 5220; Các phương pháp tiêu chuẩn để kiểm tra nước và nước thải, ấn bản lần thứ 23. Hiệp hội Y tế Công cộng Hoa Kỳ (APHA): Washington, DC, Hoa Kỳ, 2017. [\[CrossRef\]](#)

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.