




Contents lists available at ScienceDirect

Journal of Environmental Management

journal homepage: www.elsevier.com/locate/jenvman



Research article

Recognizing the state of aerobic granular sludge over its life-cycle in a continuous-flow membrane bioreactor with an artificial intelligence approach

Yu Zeng¹, Chenguang Zhao¹, Danling Ma, Liying Bin, Weirui Chen, Ping Li, Bing Tang^{*,2}

School of Environmental Science and Engineering, Guangdong University of Technology, Guangzhou, 510006, PR China

ARTICLE INFO

Keywords:

Artificial intelligence
Machine learning
Aerobic granular sludge
Life-cycle
Object detection
Membrane bioreactor

ABSTRACT

The continuous-flow aerobic granular sludge-membrane bioreactor (AGS-MBR) system represents an efficient and sustainable technology for wastewater treatment. AGS, a spherical or ellipsoidal granular sludge formed through microbial self-aggregation under aerobic conditions, progresses through four distinct life-cycle stages in the AGS-MBR system: initial, growth, mature, and cleaved. Accurate identification and classification of these stages are crucial for optimizing AGS-MBR operations and maintaining system stability; however, traditional monitoring methods are labor-intensive and error-prone. This study utilized Artificial Intelligence (AI) to develop a machine learning model based on the You Only Look Once (YOLOv8) algorithm for automated AGS monitoring and classification. Trained on 862 annotated images, the model achieved average precision of 0.985 at an Intersection over Union (IoU) threshold of 0.5 (mAP50), and the mAP50-95 of 0.837, demonstrating high accuracy in AGS classification. The t-distributed Stochastic Neighbor Embedding (t-SNE) revealed distinct clusters of AGS features across life-cycle stages, while SHapley Additive exPlanations (SHAP) demonstrated that the model focused on global features of small-grained images and edge features of large-grained images, both confirming the robustness of classification. The model's statistical functionality, supported by global variables, enabled real-time AGS monitoring in MBR system. This study provides a powerful tool for detecting and classifying the AGS life-cycle, offering guidance for the operation and maintenance of AGS-MBR system and demonstrating the potential applications of AI in wastewater treatment.

1. Introduction

Aerobic granular sludge (AGS), characterized by its unique structure and high biomass density, offers significant advantages in the simultaneous removal of nutrients and organic pollutants within a single bioreactor, potentially surpassing the conventional activated sludge (CAS) process in terms of efficiency and cost-effectiveness (Bengtsson et al., 2019; Hu et al., 2024). The long-term stability of AGS is pivotal to sustaining these benefits, while the sequencing batch reactor (SBR) in batch mode has been the most successful method for AGS cultivation (Han et al., 2024), there is a burgeoning interest in continuous mode cultivation, especially when AGS is integrated with membrane bioreactors (MBRs). MBRs, which combine CAS with membrane filtration, are known for producing high-quality effluent and reducing wasted

activated sludge (WAS) (Rahman et al., 2023). However, conventional MBRs often face issues with membrane fouling due to the deposition of flocculated activated sludge particles on the membrane surface (Morales et al., 2024). In contrast, AGS, with its aggregate form, has demonstrated an effective mitigation of membrane fouling, which is crucial for enhancing the practicality of MBR applications (Campo et al., 2021). Therefore, the AGS-MBR system stands out as an efficient, economical, and sustainable wastewater treatment technology that not only minimizes membrane fouling but also ensures superior effluent quality and reduced WAS production.

In AGS-MBR system, the stability of AGS is paramount, with morphological integrity and structure being key to operational efficiency. The AGS life-cycle, encompassing initial, growth, mature, and cleaved stages, significantly influences bioreactor performance (Yang

* Corresponding author.

E-mail addresses: tang@gdut.edu.cn, renytang@163.com (B. Tang).

¹ The first two authors equally contributed.

² Permanent address: No. 100, Waihuan Xi Road, Guangzhou Higher Education Mega Center, Guangzhou, 510,006, P.R. China.

<https://doi.org/10.1016/j.jenvman.2025.125527>

Received 15 February 2025; Received in revised form 15 April 2025; Accepted 21 April 2025

Available online 1 May 2025


0301-4797/© 2025 Elsevier Ltd. All rights are reserved, including those for text and data mining, AI training, and similar technologies.



Contents lists available at ScienceDirect

Journal of Environmental Management

journal homepage: www.elsevier.com/locate/jenvman



Bài báo nghiên cứu

Nhận diện trạng thái của bùn hạt hiếu khí trong suốt vòng đời trong bể phản ứng sinh học màng vận hành liên tục bằng phương pháp trí tuệ nhân tạo

Yu Zeng¹, Chenguang Zhao¹, Danling Ma, Liying Bin, Weirui Chen, Ping Li, Bing Tang^{*,2}

School of Environmental Science and Engineering, Guangdong University of Technology, Guangzhou, 510006, PR China

THÔNG TIN BÀI VIẾT

Keywords:

Trí tuệ nhân tạo Học máy Bùn hạt hiếu khí Vòng đời Phát hiện đối tượng Bể phản ứng sinh học màng

TÓM TẮT

Hệ thống thiết bị phản ứng sinh học màng-bùn hạt hiếu khí (AGS-MBR) dòng chảy liên tục là một công nghệ hiệu quả và bền vững để xử lý nước thải. AGS, loại bùn hạt hình cầu hoặc hình elip được hình thành thông qua quá trình tự kết tụ của vi sinh vật trong điều kiện hiếu khí, trải qua bốn giai đoạn vòng đời riêng biệt trong hệ thống AGS-MBR: khởi đầu, tăng trưởng, trưởng thành và phân tách. Việc nhận diện và phân loại chính xác các giai đoạn này đóng vai trò then chốt trong việc tối ưu hóa hoạt động của AGS-MBR và duy trì sự ổn định của hệ thống; tuy nhiên, các phương pháp giám sát truyền thống đòi hỏi nhiều công sức và dễ mắc lỗi. Nghiên cứu này ứng dụng trí tuệ nhân tạo (AI) để phát triển một mô hình học máy dựa trên thuật toán You Only Look Once (YOLOv8), nhằm tự động giám sát và phân loại AGS. Được huấn luyện trên 862 ảnh đã gán nhãn, mô hình đạt độ chính xác trung bình 0,985 tại ngưỡng Intersection over Union (IoU) là 0,5 (mAP50) và mAP50-95 là 0,837, cho thấy độ chính xác cao trong phân loại AGS. Phương pháp nhúng láng giềng ngẫu nhiên phân phối t (t-SNE) cho thấy các cụm đặc trưng AGS riêng biệt ở từng giai đoạn vòng đời, trong khi phương pháp giải thích cộng tính Shapley (SHAP) cho thấy mô hình tập trung vào các đặc trưng tổng thể của ảnh hạt nhỏ và đặc trưng đường biên của ảnh hạt lớn; cả hai đều xác nhận tính vững chắc của việc phân loại. Chức năng thống kê của mô hình, được hỗ trợ bởi các biến toàn cục, cho phép giám sát AGS theo thời gian thực trong hệ thống MBR. Nghiên cứu này cung cấp một công cụ hữu hiệu để phát hiện và phân loại các giai đoạn vòng đời của AGS, đưa ra hướng dẫn cho việc vận hành và bảo trì hệ thống AGS-MBR, đồng thời chứng minh tiềm năng ứng dụng AI trong xử lý nước thải.

1. Giới thiệu

Bùn hạt hiếu khí (AGS), với cấu trúc đặc trưng và mật độ sinh học cao, mang lại nhiều ưu điểm đáng kể trong việc loại bỏ đồng thời chất dinh dưỡng và các chất ô nhiễm hữu cơ trong một bể phản ứng sinh học duy nhất, có khả năng vượt trội hơn quy trình bùn hoạt tính thông thường (CAS) về hiệu quả và tính kinh tế (Bengtsson et al., 2019; Hu et al., 2024). Tính ổn định lâu dài của AGS có vai trò then chốt trong việc duy trì những lợi ích này. Mặc dù bể phản ứng theo mẻ tuần tự (SBR) vận hành theo chế độ mẻ là phương pháp nuôi cấy AGS thành công nhất (Han et al., 2024), việc nuôi cấy theo chế độ liên tục đang ngày càng được quan tâm, đặc biệt khi AGS được tích hợp với các bể phản ứng sinh học màng (MBR). MBR, kết hợp CAS với quá trình lọc màng, nổi tiếng với khả năng tạo ra nước thải đầu ra có chất lượng cao và giảm lượng bùn thải.

bùn hoạt tính dư (WAS) (Rahman et al., 2023). Tuy nhiên, các hệ thống MBR thông thường thường gặp vấn đề tắc nghẽn màng do các hạt bùn hoạt tính kết bông lắng đọng trên bề mặt màng (Morales et al., 2024). Ngược lại, AGS với dạng kết tụ đã cho thấy khả năng giảm thiểu hiệu quả tình trạng tắc nghẽn màng, yếu tố then chốt giúp nâng cao tính khả thi của các ứng dụng MBR (Campo et al., 2021). Vì vậy, hệ thống AGS-MBR nổi bật như một công nghệ xử lý nước thải hiệu quả, kinh tế và bền vững, không chỉ giảm thiểu tình trạng tắc nghẽn màng mà còn đảm bảo chất lượng nước đầu ra vượt trội và giảm lượng bùn hoạt tính dư phát sinh.

Trong hệ thống AGS-MBR, độ ổn định của AGS là yếu tố tối quan trọng, trong đó tính toàn vẹn về hình thái và cấu trúc đóng vai trò then chốt đối với hiệu quả vận hành. Vòng đời của AGS, bao gồm các giai đoạn hình thành ban đầu, phát triển, trưởng thành và phân tách, ảnh hưởng đáng kể đến hiệu suất của bể phản ứng sinh học (Yang

* Corresponding author.

E-mail addresses: tang@gdut.edu.cn, renytang@163.com (B. Tang).

¹ The first two authors equally contributed.

² Permanent address: No. 100, Waihuan Xi Road, Guangzhou Higher Education Mega Center, Guangzhou, 510,006, P.R. China.

<https://doi.org/10.1016/j.jenvman.2025.125527>

Received 15 February 2025; Received in revised form 15 April 2025; Accepted 21 April 2025

Available online 1 May 2025

0301-4797/© 2025 Elsevier Ltd. All rights are reserved, including those for text and data mining, AI training, and similar technologies.

et al., 2023). Monitoring AGS attributes, such as morphology, structure, and size distribution, is essential for effective process control (de Sousa Rollemberg et al., 2018). Then, operational parameters like influent composition and temperature can induce variability in AGS, potentially leading to a transition from granular to flocculated sludge and system instability (Iorhemen and Liu, 2021). The self-cultivation of AGS in continuous flow MBR system has gained interest due to operational convenience and enhanced performance. However, the heterogeneity of AGS, with varying physicochemical, microbiological, and morphological properties, remains a challenge (Yang et al., 2023). In the initial stage, the sludge particles are small; in the growth stage, the sludge particles have rough edges; in the mature stage, the sludge particles have a stable structure and smooth surface; in the cleaved stage, the sludge particles age, with a decrease in large particles and an increase in small ones. The characteristics of each stage are interrelated, reflecting the dynamic changes of AGS from formation to aging. Understanding the differences and features of these life-cycles is of great significance for optimizing the operation and management of AGS-MBR system, which can help us better control and adjust operational conditions to maintain the stability of AGS and improve the efficiency of wastewater treatment. In addition, this information also provides an important reference for the design of new bioreactors or the improvement of existing technologies.

Accurate state identification of AGS is crucial, yet methods like frozen section analysis, dissolved oxygen (DO) micro-electrodes, and CLSM have limitations. Invasive techniques can disrupt the internal micro-environment, while CLSM requires laborious sample preparation. These approaches may also be sensitive to AGS properties, leading to inaccuracies and a lack of reproducibility (Kirkland et al., 2020; Li et al., 2014; Ranzinger et al., 2020). This underscores the uniqueness of AGS in MBR operations and the necessity for advanced diagnostic tools for its state assessment, which is vital for optimizing the performance of AGS-MBR system. The development of intelligent, non-invasive methods to analyze AGS states in real-time is therefore imperative, ensuring the long-term stability and efficiency of these system.

Artificial intelligence (AI) has demonstrated its prowess in wastewater treatment modeling by offering enhanced learning capabilities, automation, and adaptability beyond traditional methods (Alvi et al., 2023; Narayanan et al., 2024). AI-driven models can reveal complex data relationships and adapt to new data, enhancing understanding of wastewater treatment processes and aiding in prediction and control (Ignacz et al., 2025; Pérez-Beltrán et al., 2024). Within the context of AGS system, artificial neural networks (ANNs) have been effectively utilized to predict critical process outcomes (Zhong et al., 2021), such as the removal rates of chemical oxygen demand, ammonia nitrogen, total nitrogen, and total phosphorus (Zaghloul and Achari, 2022). They have also been employed to predict sludge properties and water quality based on historical reactor data, enhancing the predictive accuracy and control of AGS processes (Mahmod and Wahab, 2017; Zaghloul et al., 2021). Despite these advancements, there is a significant gap in the application of AI for the image recognition and classification of aerobic granular sludge (AGS). You Only Look Once (YOLO) is a highly influential AI technology that, based on a deep learning framework, can efficiently identify the positions and categories of objects in images, demonstrating strong real-time performance and accuracy (Redmon et al., 2016). The YOLO algorithm has not only been widely applied in multiple fields such as agricultural disease monitoring (Gao et al., 2024), medical image diagnosis (Xu et al., 2025), infrastructure inspection (Santos and Carvalho, 2025), and autonomous driving (Ul Islam et al., 2025), but also provides strong support for machine learning in target recognition tasks in complex scenarios due to its efficiency and adaptability. It is an indispensable excellent tool in the field of image recognition. Perhaps the YOLO algorithm could be a new approach to achieving the image recognition and classification of AGS.

Based on the aforementioned background, this study aimed to develop a machine learning approach for accurately identifying the

states of AGS in a continuous-flow MBR over its entire life-cycle using the YOLOv8 object detection model. The model was trained following dataset screening, classification, and labeling, and then underwent hyperparameter tuning after pre-processing. Various evaluation metrics were calculated on the test set to quantify the model's predictive effectiveness, guiding the optimization of model parameters based on key indices. Additionally, dimensionality reduction techniques were applied to the semantic features of all AGS images in the test set, projecting them into two-dimensional visualizations. Feature clustering analysis was conducted across different categories, and interpretability analysis was performed to identify key features within images, elucidating differences and connections among them. Lastly, to facilitate real-world applications and enhance detection efficiency, a batch counting function was developed for each AGS stage, aiming to provide intelligent methods for obtaining timely statistical data to aid in the management and optimization of AGS-MBR processes.

2. Materials and methods

2.1. Description of the used AGS-MBR system

The study employed a previously reported MBR system with internal circulation as the physical model (Dai et al., 2020), in which, a multi-habitat environment was created through accumulated biomass, facilitated by the hydrodynamic conditions of internal circulation. The activated sludge used for inoculation was obtained from the secondary sedimentation tank of a local municipal wastewater treatment plant located in Haizhu District, Guangzhou, China (Biological Island Sewage Treatment Plant). The initial concentration of mixed liquor suspended solids (MLSS) was maintained at approximately 3000 mg/L. Throughout the experiment, the hydraulic retention time (HRT) ranged between 8.0 and 10.0 h, while the aeration rate varied from 4.8 to 7.2 m³/h to ensure sufficient DO supply. The AGS-MBR system used simulated wastewater as influent and consists of: CH₃COONa (769.20 mg/L), NH₄Cl (152.67 mg/L), KH₂PO₄ (26.36 mg/L), CaCl₂ (35.00 mg/L), FeSO₄ (0.85–0.95 mg/L), MgSO₄ (20.25 mg/L), NaHCO₃ (267.00 mg/L), corresponding COD, NH₄⁺-N and TP concentrations of 600 mg/L, 40 mg/L and 6 mg/L. All other aspects related to system configuration and operational conditions remained consistent with the previously reported work (Dai et al., 2020).

2.2. Data collection and feature classification

In the 100-day operation process, the system transitioned from startup to stable operation. Sludge samples were collected daily at fixed locations and fixed times throughout this period. These samples were examined using bright field microscopy (Leica DM500, Wetzlar, Germany) at 40 × magnification. Timely images were taken with an attached digital camera, and some images were adjusted for depth of field to ensure clarity. To enhance model generalization ability and robustness, a total of 862 images were combined from this study and a previous work (Dai et al., 2020). For data acquisition, conforming data corresponding to each stage's characteristics in the experiment underwent initial pre-processing and classification into four distinct stages based on the morphological features and size variation of AGS, namely: initial stage (IS), growth stage (GS), maturity stage (MS), and cleavage stage (CS) (Yang et al., 2023). Specific classification rules and demonstrations were presented in Table 1 and Fig. 1.

In this study, the target detection annotation tool (Labelimg v1.8.6) was used to annotate the AGS image dataset across its life-cycle. The annotation included the location and centroid information of the targets, and the results were stored in TXT files. The dataset was divided into a training set (690 images) and a testing set (172 images) at a ratio of 80% and 20%. A random seed was set to ensure the reproducibility of the results.

The annotation process was as follows: First, a portion of the

và cộng sự, 2023). Việc theo dõi các đặc tính của AGS, chẳng hạn như hình thái, cấu trúc và phân bố kích thước, là thiết yếu để kiểm soát quy trình hiệu quả (de Sousa Rollemberg et al., 2018). Sau đó, các thông số vận hành như thành phần nước thải đầu vào và nhiệt độ có thể gây ra sự biến động trong AGS, có khả năng dẫn đến chuyển đổi từ bùn dạng hạt sang bùn dạng bông và làm hệ thống mất ổn định (Iorhemen and Liu, 2021). Việc tự nuôi cấy AGS trong hệ thống MBR dòng chảy liên tục ngày càng được quan tâm nhờ sự thuận tiện trong vận hành và hiệu suất được nâng cao. Tuy nhiên, tính không đồng nhất của AGS, với các đặc tính lý hóa, vi sinh và hình thái khác nhau, vẫn là một thách thức (Yang et al., 2023). Ở giai đoạn ban đầu, các hạt bùn có kích thước nhỏ; ở giai đoạn tăng trưởng, các hạt bùn có cạnh gồ ghề; ở giai đoạn trưởng thành, các hạt bùn có cấu trúc ổn định và bề mặt nhẵn; ở giai đoạn phân tách, các hạt bùn bị lão hóa, số lượng hạt lớn giảm và số lượng hạt nhỏ tăng. Các đặc điểm của từng giai đoạn có mối liên hệ với nhau, phản ánh những biến đổi động của AGS từ khi hình thành đến khi lão hóa. Việc hiểu rõ sự khác biệt và đặc trưng của các chu kỳ sống này có ý nghĩa rất lớn đối với việc tối ưu hóa vận hành và quản lý hệ thống AGS-MBR, giúp chúng ta kiểm soát và điều chỉnh tốt hơn các điều kiện vận hành nhằm duy trì độ ổn định của AGS và nâng cao hiệu quả xử lý nước thải. Ngoài ra, thông tin này còn cung cấp tài liệu tham khảo quan trọng cho việc thiết kế các thiết bị phản ứng sinh học mới hoặc cải tiến các công nghệ hiện có.

Việc xác định chính xác trạng thái của AGS là rất quan trọng, tuy nhiên các phương pháp như phân tích lát cắt đông lạnh, vi điện cực oxy hòa tan (DO) và CLSM đều có những hạn chế. Các kỹ thuật xâm lấn có thể làm xáo trộn vi môi trường bên trong, trong khi CLSM đòi hỏi quy trình chuẩn bị mẫu tốn nhiều công sức. Những phương pháp này cũng có thể nhạy với các đặc tính của AGS, dẫn đến kết quả thiếu chính xác và khó tái lập (Kirkland et al., 2020; Li et al., 2014; Ranzinger et al., 2020). Điều này nhấn mạnh tính đặc thù của AGS trong vận hành MBR và sự cần thiết của các công cụ chẩn đoán tiên tiến để đánh giá trạng thái của AGS, yếu tố thiết yếu nhằm tối ưu hóa hiệu suất của hệ thống AGS-MBR. Do đó, cần thiết phải phát triển các phương pháp thông minh, không xâm lấn để phân tích trạng thái AGS theo thời gian thực, qua đó bảo đảm tính ổn định và hiệu quả lâu dài của các hệ thống này.

Trí tuệ nhân tạo (AI) đã chứng tỏ năng lực vượt trội trong mô hình hóa xử lý nước thải nhờ khả năng học tập nâng cao, tự động hóa và thích ứng tốt hơn các phương pháp truyền thống (Alvi et al., 2023; Narayanan et al., 2024). Các mô hình ứng dụng AI có thể làm sáng tỏ những mối quan hệ phức tạp trong dữ liệu và thích ứng với dữ liệu mới, qua đó nâng cao hiểu biết về các quy trình xử lý nước thải, đồng thời hỗ trợ dự đoán và kiểm soát (Ignacz et al., 2025; Pérez-Beltrán et al., 2024). Trong bối cảnh hệ thống AGS, mạng nơ-ron nhân tạo (ANN) đã được sử dụng hiệu quả để dự đoán các kết quả quy trình quan trọng (Zhong et al., 2021), chẳng hạn như tỷ lệ loại bỏ nhu cầu oxy hóa học, nitơ amoniac, tổng nitơ và tổng photpho (Zaghloul and Achari, 2022). ANN cũng được sử dụng để dự đoán các đặc tính của bùn và chất lượng nước dựa trên dữ liệu lịch sử của bể phản ứng, qua đó nâng cao độ chính xác trong dự đoán và khả năng kiểm soát các quy trình AGS (Mahmod and Wahab, 2017; Zaghloul et al., 2021). Mặc dù đã đạt được những tiến bộ này, vẫn còn một khoảng trống đáng kể trong việc ứng dụng AI để nhận dạng và phân loại hình ảnh bùn hạt hiếu khí (AGS). You Only Look Once (YOLO) là một công nghệ AI có ảnh hưởng lớn, dựa trên khung học sâu và có thể xác định hiệu quả vị trí cũng như loại đối tượng trong ảnh, cho thấy hiệu suất thời gian thực và độ chính xác cao (Redmon et al., 2016). Thuật toán YOLO không chỉ được ứng dụng rộng rãi trong nhiều lĩnh vực như giám sát bên cây trồng (Gao et al., 2024), chẩn đoán hình ảnh y tế (Xu et al., 2025), kiểm tra cơ sở hạ tầng (Santos and Carvalho, 2025) và lái xe tự hành (Ul Islam et al., 2025), mà còn hỗ trợ đặc biệt cho học máy trong các nhiệm vụ nhận dạng đối tượng ở những tình huống phức tạp nhờ hiệu quả và khả năng thích ứng. Đây là một công cụ xuất sắc không thể thiếu trong lĩnh vực nhận dạng hình ảnh. Có thể thuật toán YOLO là một hướng tiếp cận mới để nhận dạng và phân loại hình ảnh AGS.

Dựa trên bối cảnh đã nêu ở trên, nghiên cứu này nhằm phát triển một phương pháp học máy để xác định chính xác thế

các trạng thái của AGS trong hệ MBR dòng chảy liên tục trong toàn bộ vòng đời bằng mô hình phát hiện đối tượng YOLOv8. Mô hình được huấn luyện sau khi sàng lọc, phân loại và gán nhãn dữ liệu, rồi được tinh chỉnh siêu tham số sau bước tiền xử lý. Nhiều chỉ số đánh giá được tính toán trên tập kiểm tra để định lượng hiệu quả dự đoán của mô hình, qua đó định hướng tối ưu hóa các tham số dựa trên những chỉ số then chốt. Ngoài ra, các kỹ thuật giảm chiều được áp dụng cho đặc trưng ngữ nghĩa của tất cả ảnh AGS trong tập kiểm tra, biểu diễn chúng dưới dạng trực quan hóa hai chiều. Phân tích phân cụm đặc trưng được thực hiện trên các nhóm khác nhau, đồng thời tiến hành phân tích khả năng diễn giải để xác định những đặc trưng chính trong ảnh, làm sáng tỏ sự khác biệt và mối liên hệ giữa chúng. Cuối cùng, nhằm hỗ trợ ứng dụng thực tế và nâng cao hiệu quả phát hiện, chức năng đếm hàng loạt được phát triển cho từng giai đoạn AGS, hướng đến cung cấp các phương pháp thông minh để thu thập kịp thời dữ liệu thống kê phục vụ quản lý và tối ưu hóa các quy trình AGS-MBR.

2. Vật liệu và phương pháp

2.1. Description of the used AGS-MBR system

Nghiên cứu sử dụng hệ thống MBR tuần hoàn nội được báo cáo trước đây làm mô hình vật lý (Dai et al., 2020), trong đó môi trường đa sinh cảnh được tạo ra nhờ sinh khối tích tụ, được thúc đẩy bởi các điều kiện thủy động lực học của quá trình tuần hoàn nội. Bùn hoạt tính dùng để cấy được lấy từ bể lắng thứ cấp của một nhà máy xử lý nước thải đô thị địa phương tại quận Haizhu, Quảng Châu, Trung Quốc (Nhà máy xử lý nước thải Biological Island). Nồng độ chất rắn lơ lửng trong hỗn hợp bùn ban đầu (MLSS) được duy trì ở mức khoảng 3000 mg/L. Trong suốt thí nghiệm, thời gian lưu thủy lực (HRT) dao động từ 8.0 đến 10.0 h, trong khi tốc độ sục khí thay đổi từ 4.8 đến 7.2 m³/h để đảm bảo cung cấp đủ DO. Hệ thống AGS-MBR sử dụng nước thải mô phỏng làm dòng vào, gồm: CH₃COONa (769.20 mg/L), NH₄Cl (152.67 mg/L), KH₂PO₄ (26.36 mg/L), CaCl₂ (35.00 mg/L), FeSO₄ (0.85–0.95 mg/L), MgSO₄ (20.25 mg/L), NaHCO₃ (267.00 mg/L), với nồng độ COD, NH₄⁺-N và TP tương ứng là 600 mg/L, 40 mg/L và 6 mg/L. Tất cả các khía cạnh khác liên quan đến cấu hình hệ thống và điều kiện vận hành đều được giữ nhất quán với nghiên cứu đã báo cáo trước đây (Dai et al., 2020).

2.2. Data collection and feature classification

Trong suốt quy trình vận hành kéo dài 100 ngày, hệ thống chuyển từ giai đoạn khởi động sang vận hành ổn định. Mẫu bùn được lấy hằng ngày tại các vị trí và thời điểm cố định trong suốt giai đoạn này. Các mẫu được kiểm tra bằng kính hiển vi trường sáng (Leica DM500, Wetzlar, Đức) ở độ phóng đại 40 ×. Hình ảnh được chụp kịp thời bằng máy ảnh kỹ thuật số gắn kèm; một số hình được điều chỉnh độ sâu trường ảnh để đảm bảo độ rõ nét. Để nâng cao khả năng khái quát hóa và độ bền vững của mô hình, tổng cộng 862 hình ảnh được tập hợp từ nghiên cứu này và một nghiên cứu trước đó (Dai và cộng sự, 2020). Trong quá trình thu thập dữ liệu, dữ liệu phù hợp với đặc điểm của từng giai đoạn trong thí nghiệm được tiền xử lý ban đầu và phân loại thành bốn giai đoạn riêng biệt dựa trên đặc điểm hình thái và sự thay đổi kích thước của AGS, gồm: giai đoạn ban đầu (IS), giai đoạn tăng trưởng (GS), giai đoạn trưởng thành (MS) và giai đoạn phân cắt (CS) (Yang và cộng sự, 2023). Các quy tắc phân loại cụ thể và minh họa được trình bày trong Bảng 1 và Hình 1.

Trong nghiên cứu này, công cụ chú giải phát hiện mục tiêu (Labelimg v1.8.6) được sử dụng để chú giải bộ dữ liệu ảnh AGS trong suốt vòng đời của nó. Việc chú giải bao gồm thông tin về vị trí và trọng tâm của các mục tiêu, và kết quả được lưu trong các tệp TXT. Bộ dữ liệu được chia thành tập huấn luyện (690 ảnh) và tập kiểm tra (172 ảnh) theo tỷ lệ 80% và 20%. Một giá trị seed ngẫu nhiên được thiết lập để đảm bảo khả năng tái lập kết quả.

Quy trình gán nhãn được thực hiện như sau: Trước tiên, một phần của thế

Table 1
Classification of AGS whole life-cycle images.

Labels	Equivalent Size (μm)	Shape	Roughness	Color
IS	200–800	Irregular shape	Rough	Yellow, brown
GS	800–1600	Rough Circles	Rough	Yellow, brown, dark brown
MS	800–3000	Circles and ovals	Smooth	Dark brown, black
CS	1600–3000	Cracked shape	Rough	Dark brown, black

microscopic images from the sample set was selected for the training and testing sets. The images were imported into Labelimg, and the target regions were selected using the mouse. The corresponding “YOLO” label categories were then chosen. When a single image contained multiple sludge particles, each particle was annotated according to its respective life-cycle stage. After the annotation was completed, the results were exported as TXT files. The images and their corresponding TXT files for the training and testing sets were then imported into their respective folders to complete the data preparation. Throughout the annotation process, manual annotation was strictly performed in accordance with the rules outlined in Table 1 to ensure annotation accuracy.

2.3. Machine learning model

In this study, YOLOv8 was utilized to extract supervised information from each image, including the precise location and category parameters of the detected objects. After all datasets were classified based on these criteria, an object detection dataset annotation tool (Labelimg

v1.8.6) was employed to set the center position, height, width, and class of each identified object to annotate the object position in each image. These results were then normalized, with the entire process illustrated in Fig. 2.

The Darknet-53 network is based on the use of residual and skip connections to effectively capture features at various scales and levels (Redmon and Farhadi, 2018), whose core idea can be described as the combination of a fundamental feature extraction framework and a residual module (Kaiming and Jian, 2014; Kaiming et al., 2015). In this study, it served as the foundation for extracting features from the input images (Redmon and Farhadi, 2017), where the network backbone employed a comprehensive gradient flow structure, with different channel numbers adjusted for diverse scale models. The neck section incorporated a bidirectional path network to introduce a bottom-up path that facilitated the transmission of low-level information to the top of the upper layers, while, in the head section, a contemporary decoupled head structure was adopted to distinguish between classification and detection heads. This approach enables direct prediction of the object centers instead of calculating offsets from predefined anchor frames. Additionally, for enhancing model precision and efficiency, this work integrated the Simple Attention Mechanism (SimAM) into the utilized network, enabling inference of three-dimensional attention weights within network layers without introducing additional parameters (Yang et al., 2021).

The image sizes were normalized in this study, followed by initialization of the model weights for training from scratch. Comprehensively considering both the results of model training and computational efficiency, the number of training iterations was set to 100 with a batch size of 16 images. The initial learning rate was set to 0.01 and gradually adjusted to achieve the minimum prediction error. To prevent overfitting, an early stop strategy was adopted (Hanwen et al., 2019), which




Fig. 1. Image of AGS over its whole life-cycle: (a) Initial stage; (b) Growth stage; (c) Maturity stage; (d) Cleavage stage.


Bảng 1 Phân loại hình ảnh toàn bộ vòng đời của AGS.

Labels	Equivalent Size (μm)	Shape	Roughness	Color
IS	200–800	Irregular shape	Rough	Yellow, brown
GS	800–1600	Rough Circles	Rough	Yellow, brown, dark brown
MS	800–3000	Circles and ovals	Smooth	Dark brown, black
CS	1600–3000	Cracked shape	Rough	Dark brown, black

Ảnh hiển vi từ tập mẫu được chọn làm tập huấn luyện và tập kiểm tra. Các ảnh được nhập vào Labelimg, sau đó dùng chuột chọn các vùng mục tiêu. Tiếp theo, các nhãn tương ứng trong nhóm “YOLO” được chọn. Khi một ảnh có nhiều hạt bùn, mỗi hạt được gán nhãn theo giai đoạn vòng đời tương ứng. Sau khi hoàn tất việc gán nhãn, kết quả được xuất thành các tệp TXT. Ảnh và các tệp TXT tương ứng của tập huấn luyện và tập kiểm tra được đưa vào các thư mục tương ứng để hoàn tất quá trình chuẩn bị dữ liệu. Trong suốt quá trình gán nhãn, việc gán nhãn thủ công được thực hiện nghiêm ngặt theo các quy tắc nêu trong Bảng 1 nhằm đảm bảo độ chính xác của nhãn.

2.3. Machine learning model

Trong nghiên cứu này, YOLOv8 được sử dụng để trích xuất thông tin có giám sát từ mỗi hình ảnh, bao gồm vị trí chính xác và các thông số phân loại của đối tượng được phát hiện. Sau khi tất cả các tập dữ liệu được phân loại dựa trên những tiêu chí này, một công cụ gán nhãn tập dữ liệu phát hiện đối tượng (Labelimg)



Hình 1. Hình ảnh AGS trong toàn bộ vòng đời: (a) Giai đoạn khởi đầu; (b) Giai đoạn phát triển; (c) Giai đoạn trưởng thành; (d) Giai đoạn phân cắt.




Fig. 2. The YOLO detection framework operates by: (1) adjusting the input image to a 640×640 resolution; (2) applying a convolutional network to the resized image; (3) filtering the detected results based on the confidence levels determined by the model.

terminated the training process if no improvement was observed during iteration. Additionally, in order to enhance prediction accuracy effectively, the Mosaic enhancement was turned off during the last 10 rounds of iteration in the data augmentation part of training (Alexey et al., 2020). During the forward propagation stage, the input samples were sequentially processed through each layer of the neural network until generating the predicted results. Once the neural network predictions were obtained, they were compared with the actual labels using a loss function to quantify their differences. By applying the chain rule, the gradients of the loss function were back-propagated from the output layer to input layer and further propagated back to the weights and biases at each layer. Once the back-propagation completed and the gradients for each parameter obtained, the network parameters could be updated using the gradient descent algorithm for the forward-backward propagation process in subsequent training iterations. Through continuous parameter adjustment and loss function minimization, the neural networks can gradually improve performance and accuracy. During the prediction stage, the Soft non-maximum suppression (soft-NMS) algorithm was employed to smoothly suppress the detection box results that exhibited higher overlap with the local maximum values (Navaneeth et al., 2017).

In order to enhance the efficiency of the experiment and practical application capabilities, this study utilized a cloud-based graphics processing unit (GPU) platform called Featurize. The hardware configuration included an RTX3060 graphics card with 12 GB of graphics memory and a Central Processing Unit (CPU) consisting of $6 \times E5$ 2680 v4, along with 28 GB of RAM and a 50 GB disk storage capacity. The runtime environment employed Python v3.10.12 and the PyTorch v2.0.1 machine learning library.

2.4. Model evaluation

For a more comprehensive understanding of the model's performance, it is crucial to load the test set in order to evaluate the effectiveness of the trained model. Hence, this study employed various evaluation indexes, including the confusion matrix, F1-score, precision and recall curve for analysis, in which, the confusion matrix, consisting of a 5×5 grid that included a background class, visually represented the relationship between actual and predicted values across different categories, together with the instances of mis-classification and false positives. Precision refers to the predictive accuracy in identifying the positive samples correctly, whereas recall measures how well positive samples are identified from the original dataset. The F1-score, ranging

from 0 to 1, serves as a balanced measure by combining both precision and recall into one metric, with the optimal performance indicated by 1, and the least effective by 0.

The procedures were implemented using selected dependencies from the scikit-learn library embedded in Python 3.10.12. Cross Entropy Loss (CE Loss), a key loss function in deep learning for classification tasks, quantified the discrepancy between the model's predicted probability distribution and the actual probability distribution of the label. In a multi-classification problem with C classes, the model predicted an input $P = \{p_1, p_2, \dots, p_C\}$, while the actual probability distribution was typically represented by a vector $Y = \{y_1, y_2, \dots, y_C\}$. When the model's predicted probability p_j for class j approached 1, the loss would be close to 0. Conversely, as p_j approached zero, the loss increased significantly according to Eq. (1) (Chicco et al., 2021).

$$CE\ Loss = - \sum_{i=1}^C y_i \log(p_i) \quad (1)$$

where, C represents the total number of categories, while p_i symbolizes the predicted probability for class i , while $y_i = 1$, if the true label corresponds to class i and 0 otherwise.


The Mean Squared Error (MSE) method is commonly employed to calculate the discrepancy between the predicted bounding boxes, characterized by coordinates (x, y) and dimensions (w, h) , and the actual bounding box (Chicco et al., 2021). This loss component evaluates the confidence error for each predicted bounding box with the aim of minimizing the mean square variance between the predicted and actual values (Eq. (2)).

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2)$$

where, y_i represents the value of the i th sample for the target variable, $\hat{y}$ denotes the predicted value, and $\bar{y}$ signifies the mean of the aggregated samples.

2.5. Model interpretability

In order to provide a more comprehensive explanation of the model features, it is necessary to utilize interpretability analysis tools. The t-distributed Stochastic Neighbor Embedding (t-SNE) is a well-established technique in machine learning for reducing dimensionality, which can effectively transform data from a high-dimensional space to a lower-dimensional one while preserving the inherent information and



Hình 2. Khung phát hiện YOLO hoạt động bằng cách: (1) điều chỉnh ảnh đầu vào về độ phân giải 640×640 ; (2) áp dụng mạng tích chập lên ảnh đã thay đổi kích thước; (3) lọc các kết quả được phát hiện dựa trên mức độ tin cậy do mô hình xác định.

kết thúc quá trình huấn luyện nếu không ghi nhận được sự cải thiện nào sau vòng lặp. Ngoài ra, để nâng cao hiệu quả độ chính xác dự đoán, kỹ thuật tăng cường Mosaic đã được tắt trong 10 vòng lặp cuối cùng ở phần tăng cường dữ liệu của quá trình huấn luyện (Alexey et al., 2020). Trong giai đoạn truyền xuôi, các mẫu đầu vào lần lượt được xử lý qua từng lớp của mạng nơ-ron cho đến khi tạo ra kết quả dự đoán. Sau khi có được các dự đoán của mạng nơ-ron, chúng được so sánh với nhãn thực tế bằng hàm mất mát để định lượng mức độ sai khác. Áp dụng quy tắc dây chuyền, các gradient của hàm mất mát được lan truyền ngược từ lớp đầu ra về lớp đầu vào, rồi tiếp tục lan truyền ngược đến trọng số và độ lệch tại mỗi lớp. Sau khi quá trình lan truyền ngược hoàn tất và thu được gradient của từng tham số, các tham số mạng có thể được cập nhật bằng thuật toán giảm gradient để thực hiện quá trình lan truyền xuôi-ngược trong các vòng huấn luyện tiếp theo. Thông qua việc liên tục điều chỉnh tham số và tối thiểu hóa hàm mất mát, mạng nơ-ron có thể dần cải thiện hiệu năng và độ chính xác. Trong giai đoạn dự đoán, thuật toán t-riệt tiêu phi cực đại mềm (soft-NMS) được sử dụng để làm giảm dần các kết quả hộp phát hiện có độ chồng lấp cao hơn với các giá trị cực đại cục bộ (Navaneeth et al., 2017).

Để nâng cao hiệu quả thí nghiệm và khả năng ứng dụng thực tiễn, nghiên cứu này sử dụng nền tảng GPU trên đám mây có tên Featurize. Cấu hình phần cứng bao gồm card đồ họa RTX3060 với 12 GB bộ nhớ đồ họa và CPU gồm $6 \times E5$ 2680 v4, cùng với 28 GB RAM và dung lượng lưu trữ đĩa 50 GB. Môi trường chạy sử dụng Python v3.10.12 và thư viện học máy PyTorch v2.0.1.

2.4. Model evaluation

Để hiểu toàn diện hơn về hiệu suất của mô hình, cần tải tập kiểm tra nhằm đánh giá hiệu quả của mô hình đã huấn luyện. Vì vậy, nghiên cứu này sử dụng nhiều chỉ số đánh giá để phân tích, bao gồm ma trận nhầm lẫn, điểm F1, đường cong độ chính xác và độ bao phủ. Trong đó, ma trận nhầm lẫn gồm một lưới 5×5 có chứa lớp nền, trực quan thể hiện mối quan hệ giữa giá trị thực tế và giá trị dự đoán ở các danh mục khác nhau, cùng với các trường hợp phân loại sai và dương tính giả. Độ chính xác đề cập đến mức độ chính xác của dự đoán khi xác định đúng các mẫu dương tính, trong khi độ bao phủ đo lường mức độ xác định được các mẫu dương tính từ tập dữ liệu ban đầu. Điểm F1, dao động

từ 0 đến 1, là thước đo cân bằng bằng cách kết hợp cả độ chính xác và độ bao phủ thành một chỉ số, trong đó hiệu suất tối ưu được biểu thị bằng 1 và kém hiệu quả nhất là 0.

Các quy trình được triển khai bằng cách sử dụng các phụ thuộc được chọn từ thư viện scikit-learn tích hợp trong Python 3.10.12. Hàm mất mát Entropy chéo (CE Loss), một hàm mất mát chủ chốt trong học sâu cho các tác vụ phân loại, định lượng sự sai lệch giữa phân phối xác suất dự đoán của mô hình và phân phối xác suất thực tế của nhãn. Trong bài toán phân loại nhiều lớp với C lớp, mô hình dự đoán đầu vào $P = \{p_1, p_2, \dots, p_C\}$, trong khi phân phối xác suất thực tế thường được biểu diễn bằng vector $Y = \{y_1, y_2, \dots, y_C\}$. Khi xác suất dự đoán p_j của lớp j tiến gần đến 1, giá trị mất mát sẽ gần bằng 0. Ngược lại, khi p_j tiến gần đến 0, giá trị mất mát tăng đáng kể theo Eq. (1) (Chicco et al., 2021).

$$CE\ Loss = - \sum_{i=1}^C y_i \log(p_i) \quad (1)$$

trong đó, C biểu thị tổng số danh mục, còn p_i biểu thị xác suất dự đoán cho lớp i , trong khi $y_i = 1$ nếu nhãn thực tế tương ứng với lớp i và bằng 0 trong các trường hợp khác.

Phương pháp sai số bình phương trung bình (MSE) thường được sử dụng để tính toán độ sai lệch giữa các hộp giới hạn được dự đoán, đặc trưng bởi tọa độ (x, y) và kích thước (w, h) , với hộp giới hạn thực tế (Chicco et al., 2021). Thành phần hàm mất mát này đánh giá sai số độ tin cậy của từng hộp giới hạn được dự đoán, nhằm giảm thiểu phương sai bình phương trung bình giữa các giá trị dự đoán và giá trị thực tế (Phương trình (2)).

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2)$$

trong đó, y_i biểu thị giá trị của mẫu thứ i đối với biến mục tiêu, $\hat{y}$ biểu thị giá trị dự đoán và $\bar{y}$ biểu thị giá trị trung bình của các mẫu đã tổng hợp.

2.5. Model interpretability

Để giải thích toàn diện hơn về các đặc điểm của mô hình, cần sử dụng các công cụ phân tích khả năng diễn giải. Phương pháp nhúng láng giềng ngẫu nhiên phân phối t (t-SNE) là một kỹ thuật giảm chiều đã được khẳng định trong lĩnh vực học máy, có thể chuyển đổi dữ liệu từ không gian nhiều chiều sang không gian ít chiều hơn, đồng thời bảo toàn thông tin vốn có và

precise distribution characteristics during transmission, then furthermore, preserving the local characteristics of the dataset (Husnain et al., 2019). To achieve this, an appropriate amount of low-dimensional data was randomly generated, and the loss function measuring the difference between probability distributions was calculated. The gradient descent method was then employed to update the data until obtaining low-dimensional representations that meet specific requirements.

The similarity between each pair of data points in a high-dimensional space was initially computed using a Gaussian distribution, while the similarity between data points in a lower-dimensional space was calculated using a t-distribution. Kullback-Leibler divergence (KLD) serves as a loss function for minimizing the dissimilarity between the similarity distributions in high- and low-dimensional spaces, typically achieved through gradient descent optimization. For two points x_i and x_j within a high-dimensional dataset, Eq. (3) presents its definition.

$$p_{ji} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)} \quad (3)$$

where, p_{ji} represents the probability that x_j is adjacent to x_i , with higher values indicating closer they are. σ_i denotes the variance of the N nearest points to x_i , where N is a hyperparameter defined as perplexity. For two points y_i and y_j in a low-dimensional dataset, two definitions are provided as shown in (Eqs. (4)-(5)).

$$q_{ji} = \frac{\exp(-\|y_i - y_j\|^2)}{\sum_{k \neq i} \exp(-\|y_i - y_k\|^2)} \quad (4)$$

$$C = \sum_i \sum_j p_{ji} \log \frac{p_{ji}}{q_{ji}} \quad (5)$$

where, the meaning of q_{ji} is equivalent to that of p_{ji} . The low-dimensional data are randomly generated at the beginning, followed by the definition of a loss function based on p_{ji} and q_{ji} . C represents the Kullback-Leibler Divergence (KLD), which serves as the loss function minimized by t-SNE.

After importing the training model, the output results of the middle layer were extracted as the semantic features, then, loaded the test set image classification results and calculated the semantic features for each image, set the dimension and maximum number of iterations, and applied t-SNE to reduce the dimensionality to two dimensions. This approach effectively visualized clustering patterns throughout the AGS life-cycle and quantified the impact of each test set data feature on the overall dataset diversity. Additionally, for better interpretability of statistical data, the clustering results were visualized and further analyzed the internal feature correlations using the sklearn manifold library embedded in Python 3.10.12.

The SHapley Additive exPlanations (SHAP) method belongs to a category of additive feature attribution methods that is grounded in the amalgamation of game theory with local interpretation (Scott and Su-In, 2017), and its fundamental principle is the Shapley value, which considers both positive and negative contributions. In this model context, SHAP enables the elucidation of the influence of specific samples and features on the predicted outcome, facilitating the quantification of the local interpretations of the model. To simplify the input to z , SHAP operates by mapping x to z through the function $x = h_x(z)$. By utilizing z , the original model $f(x)$ can be approximated as a linear function of a binary variable (Eqs. (6)-(7)).

$$f(x) = g(z) = \phi_0 + \sum_{i=1}^M \phi_i z_i \quad (6)$$

where $z = \{0, 1\}^M$, M represents the count of input features, $\phi_0 = f(h_x(0))$, and ϕ_i is the feature attribution value.

$$\phi_i = \sum_{S \in \mathcal{F} \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_x(S \cup \{i\}) - f_x(S)] \quad (7)$$

where F denotes the set of non-zero inputs in z , while S denotes a subset of F that excludes the i th feature. The term ϕ_i refers to the SHAP value, which is an aggregate metric for additive feature attributions. Currently, SHAP stands out due to its unique combination of properties including local accuracy, accounting for missing values, and consistency with its application (Scott et al., 2018).

The deep SHAP algorithm is utilized for interpreting the predictions made by deep learning models, in which, a baseline value, typically the average of input features or a zero-value matrix, is selected as a reference point to evaluate the relative contribution of each feature to the output, and assess how it impacts the output in relation to this baseline value. For deep neural networks, the interpretation proceeds layer by layer from input to output layers, enabling more precise quantification of the contribution of each node or feature. Ultimately, every input feature is assigned a SHAP value that quantifies its impact on the model's output (Wang et al., 2022).

After loading the categories of the classification dataset and organizing the tensor dimensions, the number of pixels and channels were obtained, which were then pre-processed to construct a model prediction function. The SHAP interpretability analysis algorithm was utilized to generate input images with distinct characteristics throughout the life-cycle of AGS. Considering both accuracy and computational efficiency, the batch size was set to 50, and the number of iterations was set at 8000, while a 64×64 px blur masking method was defined to mask the local area on the input image. By visualizing the heatmap, one could observe the contributions predicted by the model, where red indicated positive effects and blue represented negative effects. Moreover, darker colors indicated more significant effects. These procedures were also implemented using the SHAP library embedded in Python 3.10.12.

2.6. Prediction and statistics of AGS over its life-cycle

The prediction pattern was utilized to predict a new image using the trained model, which was loaded from a checkpoint file and provided with a fresh image for inference. To assess the actual predictive performance of this model and validate its generalization capability, the AGS images throughout their entire life-cycle were collected from another MBR and categorized into seven batches of more than 50 images each, resulting in 362 valid data points for analysis. Subsequently, the acquired microscopic images were predicted by setting an Intersection over Union (IoU) threshold of 0.7 to select the best detection outcome in the candidate boxes with considerable overlap, and these results were then saved in a designated directory. Additionally, global variables were defined to record the number of categories predicted for each input image, while batch statistics on the accumulated number of categories across iterations were used as functions. By implementing intelligent identification and automatic statistical functions, the role of this model in practical application scenarios has been significantly enriched, and the monitoring efficiency over the entire life-cycle of AGS can be greatly improved.

3. Results and discussion

3.1. Model training and testing

During the process of model training and testing, the box loss was used to monitor the regression of the detection box and predict the discrepancy between the detection and calibration boxes. In contrast, classification loss (cls loss) was employed to evaluate the classification accuracy and determine whether the anchor frame matched with its corresponding calibration classification. Additionally, distributional feature learning loss (dfl loss) was implemented to track the correlation

các đặc điểm phân phối chính xác trong quá trình truyền tải, đồng thời bảo toàn các đặc điểm cục bộ của tập dữ liệu (Husnain và cộng sự, 2019). Để đạt được điều này, một lượng dữ liệu chiều thấp phù hợp được tạo ngẫu nhiên, sau đó hàm mất mát đo lường sự khác biệt giữa các phân phối xác suất được tính toán. Tiếp theo, phương pháp giảm độ dốc được sử dụng để cập nhật dữ liệu cho đến khi thu được các biểu diễn chiều thấp đáp ứng những yêu cầu cụ thể.

Độ tương đồng giữa mỗi cặp điểm dữ liệu trong không gian nhiều chiều ban đầu được tính bằng phân phối Gauss, trong khi độ tương đồng giữa các điểm dữ liệu trong không gian ít chiều được tính bằng phân phối t. Độ phân kỳ Kullback-Leibler (KLD) đóng vai trò là hàm mất mát nhằm giảm thiểu sự khác biệt giữa các phân phối độ tương đồng trong không gian nhiều chiều và ít chiều, thường được thực hiện thông qua tối ưu hóa bằng phương pháp giảm độ dốc. Với hai điểm x_i và x_j trong một tập dữ liệu nhiều chiều, phương trình (3) trình bày định nghĩa của nó.

$$p_{ji} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)} \quad (3)$$

trong đó, p_{ji} biểu thị xác suất x_j liên kết với x_i , giá trị càng cao cho biết chúng càng gần nhau. σ_i biểu thị phương sai của N điểm gần nhất với x_i , trong đó N là một siêu tham số được xác định là độ phức tạp. Đối với hai điểm y_i và y_j trong một tập dữ liệu có số chiều thấp, hai định nghĩa được đưa ra như trong (Eqs. (4)-(5)).

$$q_{ji} = \frac{\exp(-\|y_i - y_j\|^2)}{\sum_{k \neq i} \exp(-\|y_i - y_k\|^2)} \quad (4)$$

$$C = \sum_i \sum_j p_{ji} \log \frac{p_{ji}}{q_{ji}} \quad (5)$$

trong đó, ý nghĩa của q_{ji} tương đương với ý nghĩa của p_{ji} . Dữ liệu có số chiều thấp được tạo ngẫu nhiên lúc ban đầu, sau đó là định nghĩa hàm mất mát dựa trên p_{ji} và q_{ji} . C biểu thị độ phân kỳ Kullback-Leibler (KLD), được dùng làm hàm mất mát mà t-SNE tối thiểu hóa.

Sau khi nhập mô hình huấn luyện, kết quả đầu ra của lớp trung gian được trích xuất làm đặc trưng ngữ nghĩa. Tiếp đó, các kết quả phân loại ảnh trên tập kiểm thử được tải vào và đặc trưng ngữ nghĩa của từng ảnh được tính toán; kích thước và số vòng lặp tối đa được thiết lập, rồi t-SNE được áp dụng để giảm số chiều xuống còn hai. Phương pháp này trực quan hóa hiệu quả các mô hình phân cụm trong suốt vòng đời AGS và định lượng tác động của từng đặc trưng dữ liệu trong tập kiểm thử đối với mức độ đa dạng của toàn bộ tập dữ liệu. Ngoài ra, để giúp diễn giải dữ liệu thống kê tốt hơn, các kết quả phân cụm được trực quan hóa và các mối tương quan giữa những đặc trưng nội tại được phân tích sâu hơn bằng thư viện manifold của sklearn, tích hợp trong Python 3.10.12.

Phương pháp Giải thích cộng gộp Shapley (SHAP) thuộc nhóm các phương pháp quy kết đặc trưng cộng gộp, được xây dựng trên sự kết hợp giữa lý thuyết trò chơi và diễn giải cục bộ (Scott và Su-In, 2017); nguyên lý nền tảng của phương pháp này là giá trị Shapley, xét đến cả những đóng góp tích cực lẫn tiêu cực. Trong ngữ cảnh mô hình này, SHAP giúp làm sáng tỏ ảnh hưởng của các mẫu và đặc trưng cụ thể đến kết quả dự đoán, qua đó định lượng các diễn giải cục bộ của mô hình. Để đơn giản hóa đầu vào cho z , SHAP ánh xạ x thành z thông qua hàm $x = h_x(z)$. Bằng cách sử dụng z , mô hình gốc $f(x)$ có thể được xấp xỉ bằng một hàm tuyến tính của một biến nhị phân (Phương trình (6)-(7)).

$$f(x) = g(z) = \phi_0 + \sum_{i=1}^M \phi_i z_i \quad (6)$$

trong đó $z = \{0, 1\}^M$, M biểu thị số lượng đặc trưng đầu vào, $\phi_0 = f(h_x(0))$, và ϕ_i là giá trị quy kết đặc trưng.

$$\phi_i = \sum_{S \in \mathcal{F} \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_x(S \cup \{i\}) - f_x(S)] \quad (7)$$

trong đó F biểu thị tập hợp các đầu vào khác không trong z , còn S biểu thị một tập con của F không bao gồm đặc trưng thứ i . Thuật ngữ ϕ_i đề cập đến giá trị SHAP, một thước đo tổng hợp cho các mức quy kết đặc trưng có tính cộng. Hiện nay, SHAP nổi bật nhờ sự kết hợp độc đáo giữa các thuộc tính, bao gồm độ chính xác cục bộ, khả năng tính đến các giá trị bị thiếu và tính nhất quán với ứng dụng của nó (Scott và cộng sự, 2018).

Thuật toán deep SHAP được sử dụng để diễn giải các dự đoán của mô hình học sâu đưa ra. Trong đó, một giá trị cơ sở, thường là giá trị trung bình của các đặc trưng đầu vào hoặc một ma trận toàn số 0, được chọn làm điểm tham chiếu để đánh giá mức đóng góp tương đối của từng đặc trưng vào đầu ra, đồng thời xác định ảnh hưởng của đặc trưng đó đến đầu ra so với giá trị cơ sở này. Đối với mạng nơ-ron sâu, quá trình diễn giải được thực hiện lần lượt qua từng lớp, từ lớp đầu vào đến lớp đầu ra, cho phép định lượng chính xác hơn mức đóng góp của từng nút hoặc đặc trưng. Cuối cùng, mỗi đặc trưng đầu vào được gán một giá trị SHAP để định lượng mức độ ảnh hưởng của nó đến đầu ra của mô hình (Wang và cộng sự, 2022).

Sau khi tải các danh mục của tập dữ liệu phân loại và sắp xếp các chiều của tensor, số lượng điểm ảnh và kênh đã được xác định, sau đó được tiền xử lý để xây dựng hàm dự đoán của mô hình. Thuật toán phân tích khả năng diễn giải SHAP được sử dụng để tạo ra các hình ảnh đầu vào có đặc điểm riêng biệt trong suốt vòng đời của AGS. Cần nhắc cả độ chính xác và hiệu quả tính toán, kích thước lô được đặt là 50 và số vòng lặp là 8000, đồng thời phương pháp che mờ 64×64 px được xác định để che vùng cục bộ trên ảnh đầu vào. Thông qua việc trực quan hóa bản đồ nhiệt, có thể quan sát các mức đóng góp do mô hình dự đoán, trong đó màu đỏ biểu thị tác động tích cực và màu xanh lam biểu thị tác động tiêu cực. Ngoài ra, màu càng đậm thì tác động càng đáng kể. Các quy trình này cũng được triển khai bằng thư viện SHAP tích hợp trong Python 3.10.12.

2.6. Prediction and statistics of AGS over its life-cycle

Mẫu dự đoán được sử dụng để dự đoán một hình ảnh mới bằng mô hình đã huấn luyện, được tải từ tệp checkpoint và nhận một hình ảnh mới để suy luận. Để đánh giá hiệu suất dự đoán thực tế của mô hình này và xác nhận khả năng khái quát hóa, hình ảnh AGS trong toàn bộ vòng đời được thu thập từ một MBR khác và chia thành bảy lô, mỗi lô có hơn 50 hình ảnh, thu được 362 điểm dữ liệu hợp lệ để phân tích. Sau đó, các hình ảnh hiển vi thu được được đưa vào dự đoán bằng cách đặt ngưỡng Intersection over Union (IoU) ở mức 0,7 để chọn kết quả phát hiện tốt nhất trong số các hộp ứng viên có độ chồng lấp đáng kể; các kết quả này sau đó được lưu vào một thư mục được chỉ định. Ngoài ra, các biến toàn cục được định nghĩa để ghi lại số lượng danh mục được dự đoán cho mỗi hình ảnh đầu vào, trong khi thống kê theo lô về số lượng danh mục tích lũy qua các lần lặp được sử dụng làm hàm. Việc triển khai các chức năng nhận dạng thông minh và thống kê tự động đã làm phong phú đáng kể vai trò của mô hình này trong các tình huống ứng dụng thực tế, đồng thời có thể cải thiện đáng kể hiệu quả giám sát AGS trong toàn bộ vòng đời.

3. Kết quả và thảo luận

3.1. Model training and testing

Trong quá trình huấn luyện và kiểm thử mô hình, hàm mất mát hộp được sử dụng để theo dõi quá trình hồi quy của hộp phát hiện và dự đoán độ sai lệch giữa hộp phát hiện với hộp hiệu chuẩn. Ngược lại, hàm mất mát phân loại (cls loss) được dùng để đánh giá độ chính xác phân loại và xác định liệu khung neo có khớp với nhãn phân loại hiệu chuẩn tương ứng hay không. Ngoài ra, hàm mất mát hợp c đặc trưng phân phối (dfl loss) được áp dụng để theo dõi mỗi tương quan

between different feature areas and probability distribution within the dataset. As the iteration count increased, these various loss metrics gradually decreased in value within the training set until they eventually converged to a single final curve. The results indicated that when Mosaic data enhancement was disabled during the last 10 epochs of training, there was a certain decrease in all types of losses, suggesting that this operation effectively improved model accuracy (Fig. 3(a–c)). The depicted results from model training demonstrated a comprehensive training stage with well-suited chosen model parameters (Fig. 3(d–f)).

The effectiveness of the detector is commonly assessed through the mean average precision (mAP) across various classes. In this study, the metric was derived from ranking detection scores specific to each class (Everingham et al., 2010), and the IoU measured the accuracy of object detection in a particular dataset, which was the ratio of the predicted frames to the actual frames in object detection. The mAP50 set IoU to 0.5, calculated AP for each class of images, and then averaged them across all classes, therefore, mAP50-95 could be understood as an average value calculated at the intervals of 0.05 from 0.5 to 0.95 at different IoUs. With an increase in iterations, there was a gradual improvement in precision, recall, mAP50, and mAP50-95 indicators, which initially fluctuated but eventually approached a plateau close to 1 (Fig. 3(g) and (h)). The final model achieved an mAP50 score of 0.985 (Fig. 3(i)), while the mAP50-95 reached 0.837 (Fig. 3(j)). In reality, Kong et al. utilized the YOLO model to identify microorganisms in microscopic images of activated sludge, bolstering its detection capabilities by incorporating deformable convolutional networks and attention mechanisms (Kong and Shen, 2023). Their model achieved an mAP50 score of 0.937. Notably, in this experiment, the mAP50 score reached an impressive 0.985, demonstrating that our model exhibits exceptionally high accuracy at an IoU threshold of 0.5. Overall, the evaluation results demonstrated that the model trained with the provided data exhibited effective performance leading to accurate prediction outcomes.

3.2. Confusion matrix

A confusion matrix primarily serves the purpose of juxtaposing the classification results with actual measurements, which can effectively illustrate the accuracy of the classification outcomes and is a widely used tool for visually evaluating the effectiveness of supervised learning algorithms. Moreover, the most commonly employed metric for assessing imbalanced classification performance is derived from the confusion matrix (Luque et al., 2019). In the resulting matrix shown in Fig. 4, the main diagonal line represents the proportion of correctly predicted values compared to their true counterparts, while other positions indicate different types of mis-classifications presented in a 5×5 format.

Background, as a category, refers to the background part of an image that is typically distinguished from the target or foreground. As illustrated in Fig. 4, both IS and CS images exhibited the highest correct prediction rate in the test set, reaching 0.97 each. However, approximately 0.03 images of IS and CS were misclassified as GS due to their similarity at the critical values since GS represents the subsequent stage of IS in its life-cycle. Additionally, when granule sizes were closely aligned, GS and CS displayed rough edges and appeared similar to each other. The correct prediction rate for GS images was 0.96 with around 0.04 GS images being mistakenly classified as CS for similar reasons mentioned earlier. On the other hand, MS images had the lowest correct prediction rate at 0.94, where approximately 0.02 MS images were wrongly identified as GS while another 0.04 MS images were misclassified as CS due to their resemblance with AGS before and after this particular stage of development, and smaller ones being predicted as GS while larger ones being labeled as CS. In all instances where the background was incorrectly predicted as the target, AGS accounted for the proportions of 0.38, 0.38, 0.15, and 0.08 across different stages of its life-cycle depending on granule size, indicating that larger granules occupied more image area, resulting in higher probability of being classified correctly. Research indicates that the improved YOLOv7 underwater object detection model achieves accuracy rates of 81% for conch species, 90% for sea urchin species, 89% for scallop species, and 89% for starfish species (Liu et al., 2023). Due to the particularities of

giữa các vùng đặc trưng khác nhau và phân phối xác suất trong tập dữ liệu. Khi số lần lặp tăng lên, các chỉ số tổn thất khác nhau này dần giảm trong tập huấn luyện cho đến khi cuối cùng hội tụ thành một đường cong duy nhất. Kết quả cho thấy khi tắt tăng cường dữ liệu Mosaic trong 10 epoch cuối của quá trình huấn luyện, tất cả các loại tổn thất đều giảm ở một mức độ nhất định, cho thấy thao tác này đã cải thiện hiệu quả độ chính xác của mô hình (Hình 3(a–c)). Các kết quả được trình bày từ quá trình huấn luyện mô hình cho thấy một giai đoạn huấn luyện toàn diện với các tham số mô hình được lựa chọn phù hợp (Hình 3(d–f)).

Hiệu quả của bộ phát hiện thường được đánh giá thông qua độ chính xác trung bình (mAP) trên nhiều lớp khác nhau. Trong nghiên cứu này, chỉ số này được tính từ việc xếp hạng các điểm số phát hiện riêng cho từng lớp (Everingham et al., 2010), còn IoU đo độ chính xác của việc phát hiện đối tượng trong một tập dữ liệu cụ thể bằng tỷ lệ giữa các khung hình dự đoán và các khung hình thực tế trong quá trình phát hiện đối tượng. mAP50 đặt IoU ở mức 0.5, tính AP cho từng lớp ảnh rồi lấy trung bình trên tất cả các lớp. Do đó, có thể hiểu mAP50-95 là giá trị trung bình được tính tại các mức IoU cách nhau 0.05, từ 0.5 đến 0.95. Khi số vòng lặp tăng, các chỉ số độ chính xác, độ bao phủ, mAP50 và mAP50-95 dần được cải thiện; ban đầu chúng dao động nhưng cuối cùng tiến gần đến mức bão hòa xấp xỉ 1 (Hình 3(g) và (h)). Mô hình cuối cùng đạt điểm mAP50 là 0.985 (Hình 3(i)), trong khi mAP50-95 đạt 0.837 (Hình 3(j)). Trên thực tế, Kong và cộng sự đã sử dụng mô hình YOLO để nhận diện vi sinh vật trong ảnh hiển vi của bùn hoạt tính, đồng thời tăng cường khả năng phát hiện bằng cách tích hợp mạng tích chập biến dạng và cơ chế chú ý (Kong và Shen, 2023). Mô hình của họ đạt điểm mAP50 là 0.937. Đáng chú ý, trong thí nghiệm này, điểm mAP50 đạt mức ấn tượng 0.985, cho thấy mô hình của chúng tôi có độ chính xác đặc biệt cao ở ngưỡng IoU 0.5. Nhìn chung, kết quả đánh giá cho thấy mô hình được huấn luyện bằng dữ liệu đã cung cấp hoạt động hiệu quả và đưa ra các dự đoán chính xác.

3.2. Confusion matrix

Ma trận nhầm lẫn chủ yếu được sử dụng để đối chiếu kết quả phân loại với các phép đo thực tế, qua đó minh họa hiệu quả độ chính xác của kết quả phân loại; đây cũng là công cụ được sử dụng rộng rãi để đánh giá trực quan hiệu quả của các thuật toán học có giám sát. Hơn nữa, chỉ số thường được sử dụng nhất để đánh giá hiệu suất phân loại trên dữ liệu mất cân bằng được tính từ ma trận nhầm lẫn (Luque và cộng sự, 2019). Trong ma trận kết quả được thể hiện ở Hình 4, đường chéo chính biểu thị tỷ lệ các giá trị được dự đoán chính xác so với giá trị thực tương ứng, trong khi các vị trí khác biểu thị những loại phân loại sai khác nhau trong ma trận 5×5 .

Hậu cảnh, với tư cách là một hạng mục, chỉ phần nền của ảnh, thường được phân biệt với đối tượng mục tiêu hoặc tiền cảnh. Như minh họa trong Hình 4, cả ảnh IS và CS đều có tỷ lệ dự đoán chính xác cao nhất trong tập kiểm tra, đạt 0.97. Tuy nhiên, khoảng 0,03 ảnh IS và CS bị phân loại nhầm thành GS do chúng tương đồng tại các giá trị tới hạn, bởi GS là giai đoạn tiếp theo của IS trong vòng đời. Ngoài ra, khi kích thước hạt gần tương đương nhau, GS và CS có các cạnh mờ nhòe và trông giống nhau. Tỷ lệ dự đoán chính xác đối với ảnh GS là 0,96, trong đó khoảng 0,04 ảnh GS bị phân loại nhầm thành CS vì những lý do tương tự đã đề cập trước đó. Mặt khác, ảnh MS có tỷ lệ dự đoán chính xác thấp nhất, ở mức 0,94; khoảng 0,02 ảnh MS bị nhận diện nhầm thành GS, trong khi 0,04 ảnh MS khác bị phân loại nhầm thành CS do chúng giống AGS ở các giai đoạn trước và sau giai đoạn phát triển cụ thể này: các hạt nhỏ hơn được dự đoán là GS, còn các hạt lớn hơn được gán nhãn là CS. Trong mọi trường hợp hậu cảnh bị dự đoán nhầm là đối tượng mục tiêu, AGS chiếm tỷ lệ lần lượt là 0,38, 0,38, 0,15 và 0,08 ở các giai đoạn khác nhau trong vòng đời, tùy thuộc vào kích thước hạt; điều này cho thấy các hạt lớn hơn chiếm nhiều diện tích ảnh hơn, dẫn đến xác suất được phân loại chính xác cao hơn. Nghiên cứu cho thấy mô hình phát hiện vật thể dưới nước YOLOv7 cải tiến đạt độ chính xác 81% đối với loài ốc biển, 90% đối với loài nhím biển, 89% đối với loài sò điệp và 89% đối với loài sao biển (Liu và cộng sự, 2023). Do những đặc thù của





Fig. 3. The results of various loss functions and evaluation indexes in the process of 100 rounds of model iteration: (a), (b) and (c) are the results of iterations of box loss, cls loss and dfl loss on the training set, respectively; (d), (e) and (f) are the results of iterations of box loss, cls loss and dfl loss on the test set, respectively; (g) and (h) are the results of precision and recall on the test set; (i) and (j) are the results of mAP 50 and mAP50-95 on the test set.



Hình 3. Kết quả của các hàm mất mát và chỉ số đánh giá khác nhau trong quá trình lặp mô hình 100 vòng: (a), (b) và (c) là kết quả của các vòng lặp hộp mất mát, tổn thất cls và tổn thất dfl trên tập huấn luyện; (d), (e) và (f) lần lượt là kết quả của các vòng lặp tổn thất hộp, tổn thất cls và tổn thất dfl trên tập kiểm tra; (g) và (h) là kết quả về độ chính xác và độ bao phủ trên tập kiểm tra; (i) và (j) là kết quả mAP 50 và mAP50-95 trên tập kiểm tra.




Fig. 4. Normalization results of all classes in the confusion matrix.

the underwater environment, such as poor lighting conditions, optical properties of water, and dynamically changing backgrounds, the distinction between targets and backgrounds becomes challenging. In this study, the interference from the background was minimal, hence the probability of AGS being correctly identified and classified was higher, which was also related to the standardized collection method of AGS micrographs.

3.3. Analysis of the model evaluation parameter

The precision rate measures the accuracy of a model's predictions for positive samples, that is, the proportion of true positives among the predicted positive samples. The recall rate reflects the model's ability to identify actual positive samples, which is the proportion of true positives among the actual positive samples. There is a trade-off between precision and recall; increasing precision may decrease recall, and vice versa. The confidence threshold is used to adjust this trade-off by setting a





Fig. 5. Precision, recall and F1-score curves of AGS with different life-cycle under different confidence thresholds: (a) and (b) show the changing trends of precision and recall of various classes at different confidence levels, respectively; (c) shows the changing trend of F1-score.




Hình 4. Kết quả chuẩn hóa của tất cả các lớp trong ma trận nhầm lẫn.

Trong môi trường dưới nước, các yếu tố như điều kiện ánh sáng yếu, đặc tính quang học của nước và phông nền thay đổi liên tục khiến việc phân biệt mục tiêu với phông nền trở nên khó khăn. Trong nghiên cứu này, ảnh hưởng của phông nền là rất nhỏ, do đó xác suất AGS được nhận diện và phân loại chính xác cao hơn; điều này cũng liên quan đến phương pháp thu thập ảnh hiển vi AGS được chuẩn hóa.

3.3. Analysis of the model evaluation parameter

Tỷ lệ chính xác đo lường độ chính xác của các dự đoán của mô hình đối với các mẫu dương tính, tức là tỷ lệ mẫu dương tính thật trong số các mẫu được dự đoán là dương tính. Tỷ lệ thu hồi phản ánh khả năng xác định các mẫu dương tính thực tế của mô hình, tức là tỷ lệ mẫu dương tính thật trong số các mẫu dương tính thực tế. Có sự đánh đổi giữa độ chính xác và tỷ lệ thu hồi; tăng độ chính xác có thể làm giảm tỷ lệ thu hồi và ngược lại. Ngưỡng tin cậy được dùng để điều chỉnh sự đánh đổi này bằng cách thiết lập một {v*}



Hình 5. Các đường cong độ chính xác, độ thu hồi và điểm F1 của AGS với các vòng đời khác nhau ở các ngưỡng độ tin cậy khác nhau: (a) và (b) thể hiện xu hướng thay đổi độ chính xác và độ thu hồi của các lớp khác nhau ở các mức độ tin cậy khác nhau; (c) thể hiện xu hướng thay đổi của điểm F1.

standard for accepting prediction results. A high threshold increases precision but may decrease recall, while a low threshold increases recall but may decrease precision. The F1 score, as the harmonic mean of precision and recall, comprehensively evaluates model performance. Its value ranges from 0 to 1, with higher values indicating a better balance between precision and recall, thus avoiding performance bias caused by solely pursuing one of these metrics. In practical applications, an appropriate confidence threshold should be set according to the task requirements to achieve the desired precision and recall, and the overall performance of the model should be measured using the F1 score (Reda et al., 2020). The results of analyzing the model evaluation parameters are shown in Fig. 5.

When the confidence interval of IS and MS was 0.4–0.6, the precision gradually reached 1, while, the corresponding precision for GS and CS also gradually reached 1 for confidence interval of 0.8–1.0. Among them, IS showed the fastest growth rate, which indicated lower false detection rates for IS and MS features, making them easier to be accurately recognized by the model. In the confidence interval of 0.8–1.0, compared to GS and CS, IS was found to be more distinguishable from other AGS stages, indicating a lower false detection rate. This observation aligns with the fact that IS and MS represent relatively smaller-grained AGS targets, which are more susceptible to background interference and partial occlusion in images (Qian et al., 2022). For IS and MS, a precision of 1 could be achieved even with a confidence level of 0.4–0.6, suggesting that under certain specific conditions, models can still yield accurate detection results even with lower confidence levels. This highlights the importance of not solely relying on confidence levels to assess detection performance in practical applications, but rather integrating other metrics and actual scenarios for a comprehensive evaluation. However, when the confidence threshold was set at 0.942, all classes achieved the maximum value of 1 (Fig. 5(a)). As recall is generally negatively correlated with confidence levels, setting a threshold of 0 resulted in the maximum average recall for all classes (Fig. 5(b)). The smaller granule size and dense distribution of IS in images led to a higher recall rate for detecting smaller AGS granules when using low confidence intervals. When the confidence interval was set between 0.8 and 1.0, MS and CS had higher recall rates than IS and GS, with IS showing a significant decline. MS and CS, with their larger size and distinct features, resisted background noise and occlusion better, leading to higher recall rates. Conversely, IS had higher recall rates at lower confidence levels due to less stringent detection criteria, allowing more potential targets to be identified. However, at high confidence levels, IS's recall rate dropped significantly, indicating the model's limitation in recognizing smaller-grained IS targets, which are more affected by background interference and occlusion. This highlighted the need to balance the confidence threshold. Setting it too high increases false negatives, especially for small targets, while setting it too low increases false positives (Thatikonda et al., 2024). Thus, finding a balance between recall and false positive rates is crucial to optimize the model's performance. In summary, the higher recall rates for MS and CS at high confidence levels revealed the different characteristics of targets with varying granularities, while the significant drop in IS's recall rate emphasized the importance of balancing the confidence threshold in practical applications.

In this study, we determined that the confidence threshold should be set at 0.671. Setting the confidence threshold at 0.671 means that only predictions with a confidence level of 67.1% or higher were considered as positive samples. This threshold was used to balance precision and recall, ensuring that the model's predictions were both reliable and capable of capturing a sufficient number of actual positive instances. The average F1 score of 0.95 indicated that the model performed well in minimizing false positives and false negatives (Fig. 5(c)), thereby achieving a high level of overall performance. Therefore, it is recommended to use a confidence threshold of 0.671 when making predictions on new images to ensure optimal prediction accuracy.

3.4. Cluster analysis

The t-SNE technique, a machine learning method for visualizing and reducing the dimensionality of data, excels in preserving the integrity of relationships and structures in high dimensional data when it is projected onto a lower dimensional space (Pouyet et al., 2018). This technique is commonly employed to visually explore complex datasets and uncover patterns or clusters that may not be immediately discernible in the original high-dimensional space (Silva and Melo-Pinto, 2023). In this section, it was used to analyze the clusters for all classes with the results shown in Fig. 6.

As shown in Fig. 6, the features of AGS in the test set across its four different life-cycle stages were simplified to two dimensions and presented as four clusters. Overall, all types exhibited independent spatial distributions with low levels of coupling, indicating that the experimental classification criteria for the AGS life-cycle were reasonable. Specifically, CS showed the tightest distribution and a high degree of cohesion, suggesting a consistent pattern of morphological features. In contrast, GS exhibited the most dispersed distribution and showed specific coupling relationships with the other three categories. This implied that AGS, at various stages of development, diversified in appearance due to a variety of external conditions and internal developmental laws, leading to changes from light to dark colors and from rough to smooth edges. The corresponding complexity results confirmed that each class in the confusion matrix was predicted as GS. On the other hand, IS and MS only showed certain coupling relationships with adjacent life-cycle categories while maintaining similar morphological features within their respective clusters. This distribution pattern indicated that, despite certain interactions between adjacent stages, each stage retained unique characteristics identifiable through cluster analysis. The spatial independence and specific coupling patterns provided valuable insights into the dynamics of AGS development and confirmed the robustness of the classification method used in this study.

3.5. SHapley additive exPlanations (SHAP)

In the context of machine learning models, SHAP elucidates the impact of each sample and feature on the respective predicted value (Wang et al., 2024). By utilizing the SHapley value, it can quantify the local interpretation of the model, providing insights into the rationale behind the decision-making for a specific sample (Qi et al., 2025). In this section, it was first loaded the test images from each life-cycle, their dimensions were sorted out, and then a model prediction function was constructed after preprocessing. Considering the computation time and pixel granularity, an appropriate number of iterations were set to initialize the explainer, and the corresponding Shapley values were calculated for each category, test image, and pixel, and finally the heat map was generated as shown in Fig. 7.

The model primarily focused on capturing global features of small-grained images and edge features of large-grained images. As shown in Fig. 7, the global features in the IS and GS test images significantly influenced the model's predictions for MS. Specifically, the global features in IS and GS images, such as color variations and rough edges, provided the model with key information to distinguish between these two stages. The presence of these features enabled the model to more accurately identify the MS stage, as images in the MS stage typically had different colors and smoother edges. Furthermore, the edge features contained in the MS test images also had an adverse effect on the model's predictions for IS and GS. This indicated that there were significant morphological differences between IS, GS, and MS. IS and GS could be distinguished by their color variations and rough edges, while MS was characterized mainly by dark brown or black colors and smooth edges. This finding further validated the rationality of the aforementioned classification criteria. The internal structure and detailed features in the CS test images had a significant impact on the predictions for IS, as AGS fragments from CS re-emerged as IS AGS, thereby initiating a new

ngưỡng tiêu chuẩn để chấp nhận các kết quả dự đoán. Ngưỡng cao làm tăng độ chính xác nhưng có thể làm giảm độ bao phủ, trong khi ngưỡng thấp làm tăng độ bao phủ nhưng có thể làm giảm độ chính xác. Điểm F1, là trung bình điều hòa của độ chính xác và độ bao phủ, đánh giá toàn diện hiệu suất của mô hình. Giá trị này nằm trong khoảng từ 0 đến 1; giá trị càng cao cho thấy sự cân bằng giữa độ chính xác và độ bao phủ càng tốt, nhờ đó tránh thiên lệch hiệu suất do chỉ tập trung theo đuổi một trong hai chỉ số này. Trong các ứng dụng thực tế, cần đặt ngưỡng độ tin cậy phù hợp với yêu cầu của nhiệm vụ để đạt được độ chính xác và độ bao phủ mong muốn, đồng thời dùng điểm F1 để đo lường hiệu suất tổng thể của mô hình (Reda và cộng sự, 2020). Kết quả phân tích các tham số đánh giá mô hình được trình bày trong Hình 5.

Khi khoảng tin cậy của IS và MS nằm trong khoảng 0,4–0,6, độ chính xác dần đạt 1; trong khi đó, độ chính xác tương ứng của GS và CS cũng dần đạt 1 khi khoảng tin cậy nằm trong khoảng 0,8–1,0. Trong số đó, IS có tốc độ tăng nhanh nhất, cho thấy tỷ lệ phát hiện sai đối với các đặc trưng IS và MS thấp hơn, nhờ đó mô hình dễ nhận dạng chính xác hơn. Trong khoảng tin cậy 0,8–1,0, so với GS và CS, IS dễ phân biệt hơn với các giai đoạn AGS khác, cho thấy tỷ lệ phát hiện sai thấp hơn. Quan sát này phù hợp với thực tế rằng IS và MS là các mục tiêu AGS có kích thước hạt tương đối nhỏ, dễ bị ảnh hưởng bởi nhiễu nền và che khuất một phần trong ảnh hơn (Qian và cộng sự, 2022). Đối với IS và MS, độ chính xác có thể đạt 1 ngay cả khi mức tin cậy chỉ ở khoảng 0,4–0,6, cho thấy trong một số điều kiện cụ thể, mô hình vẫn có thể đưa ra kết quả phát hiện chính xác dù mức tin cậy thấp hơn. Điều này nhấn mạnh tầm quan trọng của việc không chỉ dựa vào mức tin cậy để đánh giá hiệu suất phát hiện trong các ứng dụng thực tế, mà cần kết hợp các chỉ số khác và bối cảnh thực tế để đánh giá toàn diện. Tuy nhiên, khi ngưỡng tin cậy được đặt ở mức 0,942, tất cả các lớp đều đạt giá trị tối đa là 1 (Hình 5(a)). Do độ thu hồi thường tương quan nghịch với mức tin cậy, việc đặt ngưỡng bằng 0 giúp tất cả các lớp đạt độ thu hồi trung bình tối đa (Hình 5(b)). Kích thước hạt nhỏ hơn và phân bố dày đặc của IS trong ảnh giúp tăng độ thu hồi khi phát hiện các hạt AGS nhỏ hơn bằng cách sử dụng khoảng tin cậy thấp. Khi khoảng tin cậy nằm trong khoảng 0,8–1,0, MS và CS có độ thu hồi cao hơn IS và GS, trong đó IS giảm đáng kể. MS và CS có kích thước lớn hơn cùng các đặc điểm nổi bật nên chống chịu nhiễu nền và hiện tượng che khuất tốt hơn, dẫn đến độ thu hồi cao hơn. Ngược lại, IS có độ thu hồi cao hơn ở các mức tin cậy thấp do tiêu chí phát hiện ít nghiêm ngặt hơn, cho phép nhận diện nhiều mục tiêu tiềm năng hơn. Tuy nhiên, ở mức tin cậy cao, độ thu hồi của IS giảm đáng kể, cho thấy hạn chế của mô hình trong việc nhận diện các mục tiêu IS có kích thước hạt nhỏ hơn, vốn chịu ảnh hưởng nhiều hơn bởi nhiễu nền và hiện tượng che khuất. Điều này cho thấy cần cân bằng ngưỡng tin cậy. Đặt ngưỡng quá cao sẽ làm tăng âm tính giả, đặc biệt đối với các mục tiêu nhỏ, trong khi đặt ngưỡng quá thấp sẽ làm tăng dương tính giả (Thatikonda và cộng sự, 2024). Vì vậy, việc tìm được sự cân bằng giữa độ thu hồi và tỷ lệ dương tính giả là rất quan trọng để tối ưu hóa hiệu suất của mô hình. Tóm lại, độ thu hồi cao hơn của MS và CS ở các mức tin cậy cao cho thấy các mục tiêu có kích thước hạt khác nhau mang những đặc điểm khác nhau; trong khi đó, sự sụt giảm đáng kể về độ thu hồi của IS nhấn mạnh tầm quan trọng của việc cân bằng ngưỡng tin cậy trong các ứng dụng thực tế.

Trong nghiên cứu này, chúng tôi xác định ngưỡng độ tin cậy nên được đặt ở mức 0,671. Đặt ngưỡng độ tin cậy ở mức 0,671 có nghĩa là chỉ những dự đoán có độ tin cậy từ 67,1% trở lên mới được xem là mẫu dương tính. Ngưỡng này được sử dụng để cân bằng độ chính xác và độ bao phủ, đảm bảo rằng các dự đoán của mô hình vừa đáng tin cậy vừa có khả năng nhận diện đủ số trường hợp dương tính thực tế. Điểm F1 trung bình là 0,95 cho thấy mô hình hoạt động tốt trong việc giảm thiểu dương tính giả và âm tính giả (Hình 5(c)), qua đó đạt hiệu suất tổng thể cao. Vì vậy, nên sử dụng ngưỡng độ tin cậy 0,671 khi đưa ra dự đoán trên ảnh mới để đảm bảo độ chính xác dự đoán tối ưu.

3.4. Cluster analysis

Kỹ thuật t-SNE, một phương pháp học máy dùng để trực quan hóa và giảm chiều dữ liệu, nổi bật trong việc bảo toàn tính toàn vẹn của các mối quan hệ và cấu trúc trong dữ liệu nhiều chiều khi dữ liệu được chiếu lên không gian có số chiều thấp hơn (Pouyet và cộng sự, 2018). Kỹ thuật này thường được sử dụng để khám phá trực quan các tập dữ liệu phức tạp và phát hiện những mẫu hoặc cụm có thể không dễ nhận thấy ngay trong không gian nhiều chiều ban đầu (Silva và Melo-Pinto, 2023). Trong phần này, kỹ thuật được dùng để phân tích các cụm của tất cả các lớp; kết quả được trình bày trong Hình 6.

Như thể hiện trong Hình 6, các đặc trưng của AGS trong tập kiểm tra ở bốn giai đoạn vòng đời khác nhau được giản lược xuống hai chiều và biểu diễn thành bốn cụm. Nhìn chung, tất cả các loại đều có phân bố không gian độc lập với mức độ liên kết thấp, cho thấy các tiêu chí phân loại thực nghiệm cho vòng đời AGS là hợp lý. Cụ thể, CS có phân bố tập trung nhất và mức độ gắn kết cao, cho thấy các đặc điểm hình thái có tính nhất quán. Ngược lại, GS có phân bố phân tán nhất và thể hiện mối liên kết nhất định với ba nhóm còn lại. Điều này hàm ý rằng AGS ở các giai đoạn phát triển khác nhau có diện mạo đa dạng do nhiều điều kiện bên ngoài và quy luật phát triển nội tại, dẫn đến sự thay đổi từ màu nhạt sang màu đậm, từ các cạnh thô ráp sang nhẵn mịn. Các kết quả độ phức tạp tương ứng xác nhận rằng mỗi lớp trong ma trận nhầm lẫn đều được dự đoán là GS. Mặt khác, IS và MS chỉ có một số mối liên kết nhất định với các nhóm vòng đời liên kề, đồng thời vẫn duy trì các đặc điểm hình thái tương tự trong từng cụm tương ứng. Mô hình phân bố này cho thấy rằng, mặc dù có một số tương tác giữa các giai đoạn liên kề, mỗi giai đoạn vẫn giữ những đặc điểm riêng biệt có thể nhận diện thông qua phân tích cụm. Tính độc lập về không gian và các mô hình liên kết cụ thể cung cấp những hiểu biết có giá trị về động lực phát triển của AGS, đồng thời xác nhận tính vững chắc của phương pháp phân loại được sử dụng trong nghiên cứu này.

3.5. SHapley additive exPlanations (SHAP)

Trong bối cảnh các mô hình học máy, SHAP làm sáng tỏ tác động của từng mẫu và đặc trưng lên giá trị dự đoán tương ứng (Wang et al., 2024). Bằng cách sử dụng giá trị SHapley, phương pháp này có thể định lượng cách diễn giải cục bộ của mô hình, cung cấp thông tin chi tiết về cơ sở đưa ra quyết định đối với một mẫu cụ thể (Qi et al., 2025). Trong phần này, trước tiên, ảnh kiểm thử từ mỗi vòng đời được tải lên và kích thước của chúng được xác định; sau đó, hàm dự đoán của mô hình được xây dựng sau bước tiền xử lý. Xét đến độ gian tính toán và độ phân giải pixel, số vòng lặp phù hợp được thiết lập để khởi tạo bộ giải thích; các giá trị Shapley tương ứng được tính cho từng lớp, ảnh kiểm thử và pixel, cuối cùng tạo ra bản đồ nhiệt như minh họa trong Hình 7.

Mô hình chủ yếu tập trung nắm bắt các đặc trưng toàn cục của ảnh hạt nhỏ và các đặc trưng cạnh của ảnh hạt lớn. Như thể hiện trong Hình 7, các đặc trưng toàn cục trong ảnh kiểm tra IS và GS ảnh hưởng đáng kể đến dự đoán của mô hình đối với MS. Cụ thể, các đặc trưng toàn cục trong ảnh IS và GS, chẳng hạn như sự biến thiên màu sắc và các cạnh thô, cung cấp cho mô hình thông tin quan trọng để phân biệt hai giai đoạn này. Sự hiện diện của các đặc trưng đó giúp mô hình nhận diện giai đoạn MS chính xác hơn, vì ảnh ở giai đoạn MS thường có màu sắc khác biệt và các cạnh mượt hơn. Hơn nữa, các đặc trưng cạnh trong ảnh kiểm tra MS cũng gây ảnh hưởng bất lợi đến dự đoán của mô hình đối với IS và GS. Điều này cho thấy có sự khác biệt đáng kể về hình thái giữa IS, GS và MS. IS và GS có thể được phân biệt dựa trên sự biến thiên màu sắc và các cạnh thô, trong khi MS chủ yếu được đặc trưng bởi màu nâu sẫm hoặc đen và các cạnh mượt. Phát hiện này tiếp tục xác nhận tính hợp lý của các tiêu chí phân loại đã nêu ở trên. Cấu trúc bên trong và các đặc trưng chi tiết trong ảnh kiểm tra CS ảnh hưởng đáng kể đến dự đoán đối với IS, vì các mảnh AGS từ CS xuất hiện trở lại dưới dạng AGS IS, qua đó khởi đầu một quá trình mới.




Fig. 6. The t-SNE cluster analysis of all classes.




Fig. 7. Analysis of the SHAP feature interpretability of all classes.

life-cycle iteration. This process not only revealed the dynamic changes in the AGS life-cycle but also emphasized the model's capability in capturing key features of these changes.


In summary, the model captures key features of different stages, effectively distinguishing each life-cycle phase of AGS. These findings not only validate the rationality of the classification criteria but also provide a new perspective for understanding the life-cycle of AGS.

3.6. Model prediction and statistics


To validate the practical application of the model, images of AGS were collected from the AGS-MBR reactor over one week in the laboratory. Microscopic imaging was performed under consistent equipment and environmental conditions. The resulting images were then imported

into the model for prediction, as illustrated in Fig. 8.

The AGS with larger sizes, such as MS and CS, are more likely to be detected and less likely to be missed (Fig. 8(a)–(c)). Conversely, the AGS with smaller sizes, such as IS and GS, have a higher probability of being missed (Fig. 8(d)–(f)). When there is a certain degree of gap between the sludge granules, the prediction accuracy improves. However, if the gap is too small, instances of missed detection may occur. The prediction performance was enhanced under clean background conditions, but might be influenced by complex interference in the surrounding environment. The counting results were derived based on these predicted outcomes, and the various types could be counted in multiple batches, with the calculation time varying according to the computing power. In this model, preprocessing of each image required 2.6–3.4 ms, inference took 10.0–10.4 ms, and post-processing for statistical overlay consumed



Hình 6. Phân tích cụm t-SNE của tất cả các lớp.



Hình 7. Phân tích khả năng diễn giải đặc trưng SHAP của tất cả các lớp.

lập lại vòng đời. Quá trình này không chỉ làm rõ những thay đổi động g trong vòng đời AGS mà còn nhấn mạnh khả năng của mô hình trong việc nắm bắt các đặc điểm then chốt của những thay đổi này.

Tóm lại, mô hình nắm bắt được các đặc điểm chính của từng giai đoạn khác nhau, qua đó phân biệt hiệu quả từng pha trong vòng đời của AGS. Những phát hiện này không chỉ xác nhận tính hợp lý của các tiêu chí phân loại mà còn cung cấp một góc nhìn mới để hiểu về vòng đời của AGS.

3.6. Model prediction and statistics

Để xác thực khả năng ứng dụng thực tế của mô hình, hình ảnh AGS được thu thập từ thiết bị phản ứng AGS-MBR trong phòng thí nghiệm suốt một tuần. Việc chụp ảnh hiển vi được thực hiện trong cùng điều kiện thiết bị và môi trường. Sau đó, các hình ảnh thu được đã được nhập vào

vào mô hình để dự đoán, như minh họa trong Hình 8.

Các AGS có kích thước lớn hơn, chẳng hạn như MS và CS, có nhiều khả năng được phát hiện hơn và ít có khả năng bị bỏ sót hơn (Hình 8(a)–(c)). Ngược lại, các AGS có kích thước nhỏ hơn, chẳng hạn như IS và GS, có xác suất bị bỏ sót cao hơn (Hình 8(d)–(f)). Khi các hạt bùn có một khoảng cách nhất định, độ chính xác dự đoán được cải thiện. Tuy nhiên, nếu khoảng cách quá nhỏ, có thể xảy ra trường hợp bỏ sót phát hiện. Hiệu suất dự đoán được nâng cao trong điều kiện nền sạch, nhưng có thể bị ảnh hưởng bởi các yếu tố gây nhiễu phức tạp trong môi trường xung quanh. Kết quả đếm được xác định dựa trên các kết quả dự đoán này; có thể đếm nhiều loại khác nhau theo nhiều đợt, với thời gian tính toán thay đổi tùy theo năng lực tính toán. Trong mô hình này, quá trình tiền xử lý mỗi ảnh cần 2,6–3,4 ms, suy luận mất 10,0–10,4 ms, còn hậu xử lý để chồng phủ thống kê tiêu tốn




Fig. 8. The new AGS image import model was used to predict: (a), (b) and (c) are main predictions for some larger targets; (d), (e) and (f) are main predictions for some smaller targets and mixed-size targets.


1.6–1.8 ms, summing up to a total processing time of 14.2–15.6 ms. The model was used to develop statistical functions for performing analysis on AGS samples collected from the four previously mentioned stages, where each day's sample constituted a separate batch. The results are presented in Fig. 9.

As depicted in Fig. 9, the number of IS was the highest in each batch, with a total exceeding 700, followed by GS, while MS and CS exhibit the lowest number. This distribution suggested that the overall AGS was currently in a fragmentation phase, undergoing regeneration and gradual growth. Although IS had the highest count in the reactor, exceeding 700, the number alone could not serve as the sole criterion for determining the most dominant category, given that IS typically had a smaller granularity. In contrast, CS, being the category with the largest granularity, had a total count surpassing that of MS, indicating that the volume proportion of CS was certainly greater than that of MS. Therefore, it could be inferred that a significant portion of AGS in the reactor was currently in the CS state. The breakdown of CS into the IS state (Yang et al., 2023) likely accounted for the increased number of IS instances. At present, the number of MS in the MBR was not substantial, and it did

not represent a dominant state. Under these circumstances, managers should consider measures such as increasing the organic load and controlling hydraulic shear forces to promote AGS granulation, thereby increasing the proportion of MS AGS in the system (Lin et al., 2020). The statistical function of the model intuitively presents the quantity of each type of AGS in each batch and the total number of each type throughout the entire cycle, reflecting its real-time status in the MBR system. This provides valuable guidance for managers in selecting appropriate operating parameters and enhancing the maintenance efficiency of the MBR.

4. Conclusions

This study developed a YOLOv8-based machine learning model for identifying and classifying AGS life-cycle stages. Utilizing a standardized microscopy image acquisition method, the model achieved mAP50 of 0.985 and mAP50-95 of 0.837, indicating high precision and robustness. t-SNE analysis revealed distinct clustering of AGS features across stages, while SHAP analysis highlighted the model's proficiency in capturing



Hình 8. Mô hình nhập ảnh AGS mới được sử dụng để dự đoán: (a), (b) và (c) là các dự đoán chính cho một số mục tiêu lớn hơn; (d), (e) và (f) là các dự đoán chính cho một số mục tiêu nhỏ hơn và mục tiêu có kích thước hỗn hợp.

1,6–1,8 ms, cộng lại thành tổng thời gian xử lý 14,2–15,6 ms. Mô hình được sử dụng để phát triển các hàm thống kê nhằm phân tích các mẫu AGS được thu thập từ bốn giai đoạn đã đề cập trước đó, trong đó mẫu của mỗi ngày được xem là một lô riêng biệt. Kết quả được trình bày trong Hình 9.

Như được thể hiện trong Hình 9, số lượng IS cao nhất trong mỗi mẻ, với tổng số vượt quá 700, tiếp theo là GS, trong khi MS và CS có số lượng thấp nhất. Phân bố này cho thấy AGS tổng thể hiện đang trong giai đoạn phân mảnh, trải qua quá trình tái sinh và tăng trưởng dần. Mặc dù IS có số lượng cao nhất trong bể phản ứng, vượt quá 700, nhưng chỉ riêng số lượng không thể là tiêu chí duy nhất để xác định nhóm chiếm ưu thế nhất, vì IS thường có kích thước hạt nhỏ hơn. Ngược lại, CS là nhóm có kích thước hạt lớn nhất và có tổng số cao hơn MS, cho thấy tỷ lệ thể tích của CS chắc chắn lớn hơn MS. Do đó, có thể suy luận rằng một phần đáng kể AGS trong bể phản ứng hiện đang ở trạng thái CS. Quá trình phân rã CS thành trạng thái IS (Yang et al., 2023) có thể giải thích cho sự gia tăng số lượng IS. Hiện tại, số lượng MS trong MBR không đáng kể, và điều đó đã...

không đại diện cho trạng thái chiếm ưu thế. Trong những trường hợp này, nhà quản lý nên cân nhắc các biện pháp như tăng tải lượng hữu cơ và kiểm soát lực cắt thủy lực để thúc đẩy quá trình tạo hạt AGS, qua đó làm tăng tỷ lệ AGS MS trong hệ thống (Lin et al., 2020). Chức năng thống kê của mô hình trực quan thể hiện số lượng từng loại AGS trong mỗi mẻ và tổng số lượng từng loại trong toàn bộ chu kỳ, phản ánh trạng thái thời gian thực của chúng trong hệ thống MBR. Điều này cung cấp hướng dẫn hữu ích cho nhà quản lý trong việc lựa chọn các thông số vận hành phù hợp và nâng cao hiệu quả bảo trì MBR.

4. Kết luận

Nghiên cứu này đã phát triển một mô hình học máy dựa trên YOLOv8 để nhận diện và phân loại các giai đoạn vòng đời của AGS. Sử dụng phương pháp thu nhận ảnh hiển vi được chuẩn hóa, mô hình đạt mAP50 là 0.985 và mAP50-95 là 0.837, cho thấy độ chính xác và tính vững chắc cao. Phân tích t-SNE cho thấy các đặc trưng AGS phân cụm rõ rệt theo từng giai đoạn, trong khi phân tích SHAP làm nổi bật khả năng của mô hình trong việc nắm bắt




Fig. 9. The image statistics for each stage of the life-cycle of each AGS batch together with the aggregated total for all seven batches.

global features in fine-grained images and edge features in coarse-grained images, thereby validating the classification rationality. Enhanced with global variables and attention mechanisms, the model significantly improved detection efficiency and accuracy, enabling real-time AGS monitoring in MBR system and providing batch counting functionality for classification. The AGS in this study was cultured in a continuous-flow MBR system, whereas in SBR system, retraining the model and selecting appropriate YOLO modules for specific datasets are recommended for reliable detection. Additionally, while AI can effectively assess AGS status, translating these assessments into operational decisions requires extensive practical experience and consideration of multiple operational parameters. In summary, this study developed a YOLOv8-based machine learning model that provides an efficient and reliable solution for the automatic detection and classification of AGS life-cycles. These findings not only offer technical support for optimizing AGS-MBR system management but also pave new avenues for the application of artificial intelligence in wastewater treatment.

CRedit authorship contribution statement

Yu Zeng: Writing – original draft, Software, Methodology, Investigation, Formal analysis, Data curation. **Chenguang Zhao:** Writing – original draft, Software, Methodology, Investigation, Formal analysis, Data curation. **Danling Ma:** Investigation, Data curation. **Liying Bin:** Methodology, Formal analysis. **Weirui Chen:** Resources. **Ping Li:** Software, Project administration. **Bing Tang:** Writing – original draft, Validation, Supervision, Funding acquisition, Conceptualization.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgments


This work was financially supported by the Key Technologies Research and Development Program of Guangzhou [No. 2023B03J1284]. The author would also like to thank the Analysis and Test Center of Guangdong University of Technology for their skillful analysis of our samples.

Data availability

No data was used for the research described in the article.

References

- Alexey, B., Chien-Yao, W., Hong-Yuan Mark, L., 2020. YOLOv4: optimal speed and accuracy of object detection. *arXiv - CS - Computer Vision and Pattern Recognition*.
Alvi, M., Batstone, D., Mbamba, C.K., Keymer, P., French, T., Ward, A., Dwyer, J., Cardell-Oliver, R., 2023. Deep learning in wastewater treatment: a critical review. *Water Res.* 245, 120518. <https://doi.org/10.1016/j.watres.2023.120518>.
Bengtsson, S., de Blois, M., Wilén, B.M., Gustavsson, D., 2019. A comparison of aerobic granular sludge with conventional and compact biological treatment technologies. *Environ. Technol.* 40, 2769–2778. <https://doi.org/10.1080/09593330.2018.1452985>.
Campo, R., Lubello, C., Lotti, T., Di Bella, G., 2021. Aerobic granular sludge-membrane bioreactor (ags-mbr) as a novel configuration for wastewater treatment and fouling mitigation: a Mini-Review. *Membranes* 11. <https://doi.org/10.3390/membranes11040261>.
Chicco, D., Warrens, M.J., Jurman, G., 2021. The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Comput. Sci.* 7, e623. <https://doi.org/10.7717/peerj-cs.623>.
Dai, C.C., Bin, L.Y., Tang, B., Li, P., Huang, S.S., Fu, F.L., Yin, Q., 2020. Promoting the granulation process of aerobic granular sludge in an integrated moving bed biofilm-membrane bioreactor under a continuous-flowing mode. *Sci. Total Environ.* 703, 135482. <https://doi.org/10.1016/j.scitotenv.2019.135482>.
de Sousa Rollemberg, S.L., Mendes Barros, A.R., Milen Firmino, P.I., Bezerra dos Santos, A., 2018. Aerobic granular sludge: cultivation parameters and removal mechanisms. *Bioresour. Technol.* 270, 678–688. <https://doi.org/10.1016/j.biortech.2018.08.130>.
Everingham, M., Van Gool, L., Williams, C.K.I., Winn, J., Zisserman, A., 2010. The pascal visual object classes (VOC) challenge. *Int. J. Comput. Vis.* 88, 303–338. <https://doi.org/10.1007/s11263-009-0275-4>.
Gao, W., Zong, C., Wang, M., Zhang, H., Fang, Y., 2024. Intelligent identification of rice leaf disease based on YOLO V5-EFFICIENT. *Crop Prot.* 183, 106758. <https://doi.org/10.1016/j.cropro.2024.106758>.
Han, X., Niu, X., Jin, Y., Yu, J., 2024. Rapid cultivation of aerobic granular sludge for shale gas flowback water treatment by bioaugmentation with inoculating multifunctional fungal pellets. *J. Clean. Prod.* 457, 142483. <https://doi.org/10.1016/j.jclepro.2024.142483>.
Hanwen, L., Shifeng, Z., Jiacheng, S., Xingqiu, H., Weiran, H., Kechen, Z., Zhenguo, L., 2019. DARTS+: improved differentiable architecture search with early stopping. *arXiv - CS - Computer Vision and Pattern Recognition*. <https://arxiv.org/abs/1909.06035>.
Hu, Q., Cheng, L., Liu, J., Zhang, Z., Wei, M., Luo, C., Zhang, Y., Chen, H., Hu, Z., 2024. Emergence and spread patterns of antibiotic resistance genes during cultivating aerobic granular sludge under different feeding modes. *J. Clean. Prod.* 455. <https://doi.org/10.1016/j.jclepro.2024.142320>.
Husnain, M., Missen, M., Mumtaz, S., Luqman, M., Coustaty, M., Ogier, J.M., 2019. Visualization of high-dimensional data by pairwise fusion matrices using t-SNE. *Symmetry* 11 (1), 107. <https://doi.org/10.3390/sym11010107>.
Ignacz, G., Bader, L., Beke, A.K., Ghunaim, Y., Shastry, T., Vovusha, H., Carbone, M.R., Ghanem, B., Szekeley, G., 2025. Machine learning for the advancement of membrane science and technology: a critical review. *J. Membr. Sci.* 713, 123256. <https://doi.org/10.1016/j.memsci.2024.123256>.
Iorhemen, O.T., Liu, Y., 2021. Effect of feeding strategy and organic loading rate on the formation and stability of aerobic granular sludge. *J. Water Process Eng.* 39, 101709. <https://doi.org/10.1016/j.jwpe.2020.101709>.
Kaiming, H., Jian, S., 2014. Convolutional Neural Networks at Constrained Time Cost. *arXiv - CS - Computer Vision and Pattern Recognition*.
Kaiming, H., Xiangyu, Z., Shaoqing, R., Jian, S., 2015. Deep residual learning for image recognition. *arXiv - CS - Computer Vision and Pattern Recognition*.
Kirkland, C.M., Krug, J.R., Vergeldt, F.J., van den Berg, L., Velders, A.H., Seymour, J.D., Codd, S.L., Van As, H., de Kreuk, M.K., 2020. Characterizing the structure of aerobic granular sludge using ultra-high field magnetic resonance. *Water Sci. Technol.* 82, 627–639. <https://doi.org/10.2166/wst.2020.341>.
Kong, Y., Shen, Z., 2023. Microorganism detection in activated sludge microscopic images using improved YOLO. *Appl. Sci.* 13. <https://doi.org/10.3390/app132212406>.
Li, J., Cai, A., Wang, D., Chen, C., Ni, Y., 2014. Structure analysis of aerobic granule from a sequencing batch reactor for organic matter and ammonia nitrogen removal. *Int. J. Environ. Res. Publ. Health* 2427–2436. <https://doi.org/10.3390/ijerph110302427>.
Lin, H., Ma, R., Hu, Y., Lin, J., Sun, S., Jiang, J., Li, T., Liao, Q., Luo, J., 2020. Reviewing bottlenecks in aerobic granular sludge technology: slow granulation and low granular stability. *Environ. Pollut.* 263, 114638. <https://doi.org/10.1016/j.envpol.2020.114638>.
Liu, K., Sun, Q., Sun, D., Peng, L., Yang, M., Wang, N., 2023. Underwater target detection based on improved YOLOv7. *J. Mar. Sci. Eng.* 11. <https://doi.org/10.3390/jmse11030677>.
Luque, A., Carrasco, A., Martín, A., de Las Heras, A.J.P.R., 2019. The Impact of Class Imbalance in Classification Performance Metrics Based on the Binary Confusion Matrix, vol. 91, pp. 216–231. <https://doi.org/10.1016/j.patcog.2019.02.023>.



Hình 9. Thống kê hình ảnh cho từng giai đoạn trong vòng đời của mỗi lô AGS, cùng với tổng hợp của cả bảy lô.

các đặc trưng toàn cục trong ảnh có độ phân giải mịn và các đặc trưng biên trong ảnh có độ phân giải thô, qua đó xác nhận tính hợp lý của việc phân loại. Được tăng cường bằng các biến toàn cục và cơ chế chú ý, mô hình cải thiện đáng kể hiệu suất và độ chính xác phát hiện, cho phép giám sát AGS theo thời gian thực trong hệ thống MBR và cung cấp chức năng đếm số lượng theo từng nhóm phân loại. AGS trong nghiên cứu này được nuôi cấy trong hệ thống MBR dòng chảy liên tục; trong khi đó, đối với hệ thống SBR, để phát hiện đáng tin cậy, nên huấn luyện lại mô hình và lựa chọn các mô-đun YOLO phù hợp với từng bộ dữ liệu cụ thể. Ngoài ra, mặc dù AI có thể đánh giá hiệu quả trạng thái AGS, việc chuyển các đánh giá này thành quyết định vận hành đòi hỏi nhiều kinh nghiệm thực tiễn và phải cân nhắc nhiều thông số vận hành. Tóm lại, nghiên cứu này đã phát triển một mô hình học máy dựa trên YOLOv8, cung cấp giải pháp hiệu quả và đáng tin cậy để tự động phát hiện và phân loại các giai đoạn vòng đời của AGS. Những phát hiện này không chỉ hỗ trợ kỹ thuật cho việc tối ưu hóa quản lý hệ thống AGS-MBR mà còn mở ra hướng đi mới cho ứng dụng trí tuệ nhân tạo trong xử lý nước thải.

Tuyên bố về đóng góp của tác giả theo CRediT

Yu Zeng: Viết – bản thảo gốc, Phần mềm, Phương pháp luận, Điều tra, Phân tích hình thức, Quản lý dữ liệu. Chenguang Zhao: Viết – bản thảo gốc, Phần mềm, Phương pháp luận, Điều tra, Phân tích hình thức, Quản lý dữ liệu. Danling Ma: Điều tra, Quản lý dữ liệu. Liying Bin: Phương pháp luận, Phân tích hình thức. Weirui Chen: Nguồn lực. Ping Li: Phần mềm, Quản lý dự án. Bing Tang: Viết – bản thảo gốc, Thẩm định, Giám sát, Huy động kinh phí, Xây dựng ý tưởng.

Tuyên bố về xung đột lợi ích

Các tác giả tuyên bố rằng họ không có bất kỳ lợi ích tài chính cạnh tranh hoặc mối quan hệ cá nhân nào đã biết có thể ảnh hưởng đến công trình được trình bày trong bài báo này.

Lời cảm ơn

Công trình này được hỗ trợ về mặt tài chính bởi Chương trình Nghiên cứu và Phát triển Công nghệ Trọng điểm của thành phố Quảng Châu [Số 2023B03J1284]. Tác giả cũng xin cảm ơn Trung tâm Phân tích và Thử nghiệm của Đại học Công nghệ Quảng Đông đã phân tích các mẫu của chúng tôi một cách chuyên nghiệp.

Tính khả dụng của dữ liệu

Không có dữ liệu nào được sử dụng cho nghiên cứu được mô tả trong bài

Tài liệu tham khảo

- Alexey, B., Chien-Yao, W., Hong-Yuan Mark, L., 2020. YOLOv4: tốc độ tối ưu và độ chính xác trong phát hiện đối tượng. *arXiv - CS - Thị giác máy tính và Nhận dạng mẫu*.
Alvi, M., Batstone, D., Mbamba, C.K., Keymer, P., French, T., Ward, A., Dwyer, J., Cardell-Oliver, R., 2023. Học sâu trong xử lý nước thải: một tổng quan phê bình. *Water Res.* 245, 120518. <https://doi.org/10.1016/j.watres.2023.120518>.
Bengtsson, S., de Blois, M., Wilén, B.M., Gustavsson, D., 2019. So sánh bùn hạt hiếu khí với các công nghệ xử lý sinh học thông thường và nhỏ gọn. *Environ. Technol.* 40, 2769–2778. <https://doi.org/10.1080/09593330.2018.1452985>.
Campo, R., Lubello, C., Lotti, T., Di Bella, G., 2021. Bùn hạt hiếu khí–bể phản ứng sinh học màng (ags-mbr) như một cấu hình mới trong xử lý nước thải và giảm bám bẩn: tổng quan ngắn. *Membranes* 11. <https://doi.org/10.3390/membranes11040261>.
Chicco, D., Warrens, M.J., Jurman, G., 2021. Hệ số xác định R bình phương có giá trị cung cấp thông tin cao hơn SMAPE, MAE, MAPE, MSE và RMSE trong đánh giá phân tích hồi quy. *PeerJ Comput. Sci.* 7, e623. <https://doi.org/10.7717/peerj-cs.623>.
Dai, C.C., Bin, L.Y., Tang, B., Li, P., Huang, S.S., Fu, F.L., Yin, Q., 2020. Thúc đẩy quá trình tạo hạt bùn hạt hiếu khí trong bể phản ứng sinh học màng–màng sinh học tăng chuyển động tích hợp ở chế độ dòng chảy liên tục. *Sci. Total Environ.* 703, 135482. <https://doi.org/10.1016/j.scitotenv.2019.135482>.
de Sousa Rollemberg, S.L., Mendes Barros, A.R., Milen Firmino, P.I., Bezerra dos Santos, A., 2018. Bùn hạt hiếu khí: các thông số nuôi cấy và cơ chế loại bỏ. *Bioresour. Technol.* 270, 678–688. <https://doi.org/10.1016/j.biortech.2018.08.130>.
Everingham, M., Van Gool, L., Williams, C.K.I., Winn, J., Zisserman, A., 2010. Thử thách các lớp đối tượng thị giác Pascal (VOC). *Int. J. Comput. Vis.* 88, 303–338. <https://doi.org/10.1007/s11263-009-0275-4>.
Gao, W., Zong, C., Wang, M., Zhang, H., Fang, Y., 2024. Nhận dạng thông minh bệnh trên lá lúa dựa trên YOLO V5-EFFICIENT. *Crop Prot.* 183, 106758. <https://doi.org/10.1016/j.cropro.2024.106758>.
Han, X., Niu, X., Jin, Y., Yu, J., 2024. Nuôi cấy hành bùn hạt hiếu khí để xử lý nước hồi lưu khai thác khí đã phiên bản phương pháp tăng cường sinh học với các viên nấm đa chức năng làm giống. *J. Clean. Prod.* 457, 142483. <https://doi.org/10.1016/j.jclepro.2024.142483>.
Hanwen, L., Shifeng, Z., Jiacheng, S., Xingqiu, H., Weiran, H., Kechen, Z., Zhenguo, L., 2019. DARTS+: tìm kiếm kiến trúc khả vi được cải tiến với cơ chế dừng sớm. *arXiv - CS - Thị giác máy tính và Nhận dạng mẫu*. <https://arxiv.org/abs/1909.06035>.
Hu, Q., Cheng, L., Liu, J., Zhang, Z., Wei, M., Luo, C., Zhang, Y., Chen, H., Hu, Z., 2024. Sự xuất hiện và mô hình lan truyền của các gen kháng kháng sinh trong quá trình nuôi cấy bùn hạt hiếu khí theo các chế độ cấp liệu khác nhau. *J. Clean. Prod.* 455. <https://doi.org/10.1016/j.jclepro.2024.142320>.
Husnain, M., Missen, M., Mumtaz, S., Luqman, M., Coustaty, M., Ogier, J.M., 2019. Trục quan hóa dữ liệu nhiều chiều bằng ma trận hợp nhất từng cấp sử dụng t-SNE. *Symmetry* 11 (1), 107. <https://doi.org/10.3390/sym11010107>.
Ignacz, G., Bader, L., Beke, A.K., Ghunaim, Y., Shastry, T., Vovusha, H., Carbone, M.R., Ghanem, B., Szekeley, G., 2025. Học máy thúc đẩy khoa học và công nghệ màng: tổng quan phê bình. *J. Membr. Sci.* 713, 123256. <https://doi.org/10.1016/j.memsci.2024.123256>.
Iorhemen, O.T., Liu, Y., 2021. Ảnh hưởng của chiến lược cấp liệu và tải trọng hữu cơ đến sự hình thành và độ ổn định của bùn hạt hiếu khí. *J. Water Process Eng.* 39, 101709. <https://doi.org/10.1016/j.jwpe.2020.101709>.
Kaiming, H., Jian, S., 2014. Mạng nơ-ron tích chập với chi phí thời gian bị giới hạn. *arXiv - CS - Thị giác máy tính và Nhận dạng mẫu*.
Kaiming, H., Xiangyu, Z., Shaoqing, R., Jian, S., 2015. Học sâu dự cho nhận dạng hình ảnh. *arXiv - CS - Thị giác máy tính và Nhận dạng mẫu*.
Kirkland, C.M., Krug, J.R., Vergeldt, F.J., van den Berg, L., Velders, A.H., Seymour, J.D., Codd, S.L., Van As, H., de Kreuk, M.K., 2020. Đặc trưng cấu trúc của bùn hạt hiếu khí bằng cộng hưởng từ trực ứng siêu cao. *Water Sci. Technol.* 82, 627–639. <https://doi.org/10.2166/wst.2020.341>.
Kong, Y., Shen, Z., 2023. Phát hiện vi sinh vật trong ảnh hiển vi bùn hoạt tính bằng YOLO cải tiến. *Appl. Sci.* 13. <https://doi.org/10.3390/app132212406>.
Li, J., Cai, A., Wang, D., Chen, C., Ni, Y., 2014. Phân tích cấu trúc hạt hiếu khí từ bể phản ứng theo mô hình tự động loại bỏ chất hữu cơ và amoni nitơ. *Int. J. Environ. Res. Publ. Health* 2427–2436. <https://doi.org/10.3390/ijerph110302427>.
Lin, H., Ma, R., Hu, Y., Lin, J., Sun, S., Jiang, J., Li, T., Liao, Q., Luo, J., 2020. Tổng quan các điểm nghẽn trong công nghệ bùn hạt hiếu khí: quá trình tạo hạt chậm và độ ổn định hạt thấp. *Environ. Pollut.* 263, 114638. <https://doi.org/10.1016/j.envpol.2020.114638>.
Liu, K., Sun, Q., Sun, D., Peng, L., Yang, M., Wang, N., 2023. Phát hiện mục tiêu dưới nước dựa trên YOLOv7 cải tiến. *J. Mar. Sci. Eng.* 11. <https://doi.org/10.3390/jmse11030677>.
Luque, A., Carrasco, A., Martín, A., de Las Heras, A.J.P.R., 2019. Tác động của mất cân bằng lớp đối với các thước đo hiệu năng phân loại dựa trên ma trận nhầm lẫn nhị phân, tập 91, tr. 216–231. <https://doi.org/10.1016/j.patcog.2019.02.023>.

Mahmod, N., Wahab, N.A., 2017. Dynamic modelling of aerobic granular sludge artificial neural networks. *Int. J. Electr. Comput. Eng.* 7. <https://doi.org/10.11591/ijece.v7i3.pp1568-1573>.

Morales, N., Mery-Araya, C., Guerra, P., Poblete, R., Chacana-Olivares, J., 2024. Mitigation of membrane fouling in membrane bioreactors using granular and powdered activated carbon: an experimental study. *Water* 16, 2556. <https://doi.org/10.3390/w16172556>.

Navaneeth, B., Bharat, S., Rama, C., Larry, S.D., 2017. Soft-NMS – improving object detection with one line of code. *arXiv - CS - Computer Vision and Pattern Recognition*.

Narayanan, D., Bhat, M., Samuel Paul, N.R., Khatri, N., Saroliya, A., 2024. Artificial intelligence driven advances in wastewater treatment: evaluating techniques for sustainability and efficacy in global facilities. *Desalination Water Treat.* 320, 100618. <https://doi.org/10.1016/j.dwt.2024.100618>.

Pérez-Beltrán, C.H., Robles, A.D., Rodriguez, N.A., Ortega-Gavilán, F., Jiménez-Carvelo, A.M., 2024. Artificial intelligence and water quality: from drinking water to wastewater. *Trac. Trends Anal. Chem.* 172, 117597. <https://doi.org/10.1016/j.trac.2024.117597>.

Pouyet, E., Rohani, N., Katsaggelos, A.K., Cossairt, O., Walton, M., 2018. Innovative data reduction and visualization strategy for hyperspectral imaging datasets using t-SNE approach. *Pure Appl. Chem.* 90, 493–506. <https://doi.org/10.1515/pac-2017-0907>.

Qi, X., Wang, S., Fang, C., Jia, J., Lin, L., Yuan, T., 2025. Machine learning and SHAP value interpretation for predicting comorbidity of cardiovascular disease and cancer with dietary antioxidants. *Redox Biol.* 79, 103470. <https://doi.org/10.1016/j.redox.2024.103470>.

Qian, H., Wu, P., Sun, B., Su, S., 2022. AGS-SSD: attention-guided sampling for 3D single-stage detector. *Electronics* 11 (14), 2079–9292. <https://doi.org/10.3390/electronics11142268>.

Rahman, T.U., Roy, H., Islam, M.R., Tahmid, M., Fariha, A., Mazumder, A., Tasnim, N., Pervéz, M.N., Cai, Y., Naddeo, V., Islam, M.S., 2023. The advancement in membrane bioreactor (MBR) technology toward sustainable industrial wastewater management. *membranes* 13, 181. <https://ieeexplore.ieee.org/document/10670627>.

Ranzinger, F., Matern, M., Layer, M., Guthausen, G., Wagner, M., Derlon, N., Horn, H., 2020. Transport and retention of artificial and real wastewater particles inside a bed of settled aerobic granular sludge assessed applying magnetic resonance imaging. *Water Res.* X 7, 100050. <https://doi.org/10.1016/j.wroa.2020.100050>.

Reda, Y., Dustin, A., 2020. Probabilistic extension of precision, recall, and f1 score for more thorough evaluation of classification models. *Association for computational linguistics* 20, 79–91. <https://aclanthology.org/2020.eval4nlp-1.9/>.

Redmon, J., Divvala, S., Girshick, R., Farhadi, A., 2016. You only look once: unified, real-time object detection. *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 779–788.

Redmon, J., Farhadi, A., 2017. YOLO9000: better, faster, stronger. *IEEE conference on computer vision and pattern recognition* 29, 6517–6525. <https://doi.org/10.1109/CVPR.2017.690>.

Redmon, J., Farhadi, A., 2018. Yolov3: an incremental improvement. *IEEE Conference on computer vision and pattern recognition* 15, 1125–1131.

Santos, P.A.S., Carvalho, M.T.M., 2025. Multi-class segmentation of structural damage and pathological manifestations using YOLOv8 and Segment Anything. *Model. Autom. Constr.* 172, 106037. <https://doi.org/10.1016/j.autcon.2025.106037>.

Scott, L., Su-In, L., 2017. A unified approach to interpreting model predictions. *arXiv - CS - Artificial Intelligence*.

Scott, M.L., Gabriel, G.E., Su-In, L., 2018. Consistent individualized feature attribution for tree ensembles. *arXiv - CS - Machine learning*.

Silva, R., Melo-Pinto, P., 2023. t-SNE: a study on reducing the dimensionality of hyperspectral data for the regression problem of estimating oenological parameters. *Artif. Intell. Agric.* 7, 58–68. <https://doi.org/10.1016/j.aiia.2023.02.003>.

Thatikonda, M.M.K.P.K., Amsaad, F., 2024. A novel dynamic confidence threshold estimation ai algorithm for enhanced object detection. *NAECON 2024 - IEEE National Aerospace and Electronics Conference*, pp. 359–363.

Ul Islam, Q., Khozaei, F., Salah Al Barhoumi, E.M., Baig, I., Ignatyev, D., 2025. Advancing autonomous SLAM systems: integrating YOLO object detection and enhanced loop closure techniques for robust environment mapping. *Robot. Auton. Syst.* 185, 104871. <https://doi.org/10.1016/j.robot.2024.104871>.

Wang, D., Thunell, S., Lindberg, U., Jiang, L., Trygg, J., Tysklind, M., 2022. Towards better process management in wastewater treatment plants: process analytics based on SHAP values for tree-based machine learning methods. *J. Environ. Manag.* 301, 113941. <https://doi.org/10.1016/j.jenvman.2021.113941>.

Wang, H., Liang, Q., Hancock, J.T., Khoshgoftaar, T.M., 2024. Feature selection strategies: a comparative analysis of SHAP-value and importance-based methods. *J. Big Data* 11, 44. <https://doi.org/10.1186/s40537-024-00905-w>.

Xu, C., Fan, Z., Ma, Y., Huang, Y., Wang, J., Xu, Y., Wu, D., 2025. CE-YOLO: a channel-efficient YOLO algorithm for colorectal polyp detection. *Biomed. Signal Process Control* 104, 107529. <https://doi.org/10.1016/j.bspc.2025.107529>.

Yang, B., Liang, W.F., Bin, L.Y., Chen, W.R., Chen, X.Y., Li, P., Wen, S.L., Huang, S.S., Tang, B., 2023. Insights into the life-cycle of aerobic granular sludge in a continuous flow membrane bioreactor by tracing its heterogeneous properties at different stages. *Water Res.* 243, 120419. <https://doi.org/10.1016/j.watres.2023.120419>.

Yang, L., Zhang, R.Y., Li, L., Xie, X., 2021. SimAM: a Simple, parameter-free attention module for convolutional neural networks. In: Marina, M., Tong, Z. (Eds.), *Proceedings of the 38th International Conference on Machine Learning*. PMLR, *Proceedings of Machine Learning Research*, pp. 11863–11874. In: <https://proceedings.mlr.press/v139/yang21o.html>.

Zaghloul, M.S., Achari, G., 2022. A review of mechanistic and data-driven models of aerobic granular sludge. *J. Environ. Chem. Eng.* 10. <https://doi.org/10.1016/j.jece.2022.107500>.

Zaghloul, M.S., Iorhemen, O.T., Hamza, R.A., Tay, J.H., Achari, G., 2021. Development of an ensemble of machine learning algorithms to model aerobic granular sludge reactors. *Water Res.* 189, 116657. <https://doi.org/10.1016/j.watres.2020.116657>.

Zhong, S., Zhang, K., Bagheri, M., Burken, J.G., Gu, A., Li, B., Ma, X., Marrone, B.L., Ren, Z.J., Schrier, J., Shi, W., Tan, H., Wang, T., Wang, X., Wong, B.M., Xiao, X., Yu, X., Zhu, J.J., Zhang, H., 2021. Machine learning: new ideas and tools in environmental science and engineering. *Environ. Sci. Technol.* 55, 12741–12754. <https://doi.org/10.1021/acs.est.1c01339>.

Mahmod, N., Wahab, N.A., 2017. Mô hình hóa động lực học bùn hạt hiếu khí bằng mạng nơ-ron nhân tạo. *Int. J. Electr. Comput. Eng.* 7. <https://doi.org/10.11591/ijece.v7i3.pp1568-1573>.

Morales, N., Mery-Araya, C., Guerra, P., Poblete, R., Chacana-Olivares, J., 2024. Giảm thiểu hiện tượng tắc nghẽn màng trong các bể phản ứng sinh học màng bằng than hoạt tính dạng hạt và dạng bột: một nghiên cứu thực nghiệm. *Water* 16, 2556. <https://doi.org/10.3390/w16172556>.

Navaneeth, B., Bharat, S., Rama, C., Larry, S.D., 2017. Soft-NMS – cải thiện khả năng phát hiện đối tượng chỉ bằng một dòng mã. *arXiv - CS - Computer Vision and Pattern Recognition*. Narayanan, D., Bhat, M., Samuel Paul, N.R., Khatri, N., Saroliya, A., 2024. Những tiến bộ trong xử lý nước thải nhờ trí tuệ nhân tạo: đánh giá các kỹ thuật về tính bền vững và hiệu quả tại các cơ sở trên toàn cầu. *Desalination Water Treat.* 320, 100618. <https://doi.org/10.1016/j.dwt.2024.100618>.

Pérez-Beltrán, C.H., Robles, A.D., Rodriguez, N.A., Ortega-Gavilán, F., Jiménez-Carvelo, A.M., 2024. Trí tuệ nhân tạo và chất lượng nước: từ nước uống đến nước thải. *Trac. Trends Anal. Chem.* 172, 117597. <https://doi.org/10.1016/j.trac.2024.117597>.

Pouyet, E., Rohani, N., Katsaggelos, A.K., Cossairt, O., Walton, M., 2018. Chiến lược giảm dữ liệu và trực quan hóa sáng tạo cho các bộ dữ liệu ảnh siêu phổ bằng phương pháp t-SNE. *Pure Appl. Chem.* 90, 493–506. <https://doi.org/10.1515/pac-2017-0907>.

Qi, X., Wang, S., Fang, C., Jia, J., Lin, L., Yuan, T., 2025. Học máy và diễn giải giá trị SHAP để dự đoán bệnh động mạch tim mạch và ung thư dựa trên các chất chống oxy hóa trong chế độ ăn. *Redox Biol.* 79, 103470. <https://doi.org/10.1016/j.redox.2024.103470>.

Qian, H., Wu, P., Sun, B., Su, S., 2022. AGS-SSD: lấy mẫu có hướng dẫn bằng cơ chế chú ý cho bộ phát hiện một giai đoạn 3D. *Electronics* 11 (14), 2079–9292. <https://doi.org/10.3390/electronics11142268>.

Rahman, T.U., Roy, H., Islam, M.R., Tahmid, M., Fariha, A., Mazumder, A., Tasnim, M., Pervéz, M.N., Cai, Y., Naddeo, V., Islam, M.S., 2023. Những tiến bộ trong công nghệ bể phản ứng sinh học màng (MBR) hướng tới quản lý nước thải công nghiệp bền vững. *Membranes* 13, 181. <https://ieeexplore.ieee.org/document/10670627>.

Ranzinger, F., Matern, M., Layer, M., Guthausen, G., Wagner, M., Derlon, N., Horn, H., 2020. Sự vận chuyển và lưu giữ các hạt nước thải nhân tạo và thực tế bên trong lớp bùn hạt hiếu khí đã lắng, được đánh giá bằng phương pháp chụp cộng hưởng từ. *Water Res.* X 7, 100050. <https://doi.org/10.1016/j.wroa.2020.100050>.

Reda, Y., Dustin, A., 2020. Mở rộng xác suất của độ chính xác, độ bao phủ và điểm F1 để đánh giá toàn diện hơn các mô hình phân loại. *Association for Computational Linguistics* 20, 79–91. <https://aclanthology.org/2020.eval4nlp-1.9/>.

Redmon, J., Divvala, S., Girshick, R., Farhadi, A., 2016. Bạn chỉ nhìn một lần: phát hiện đối tượng thống nhất theo thời gian thực. *IEEE Conference on Computer Vision and Pattern Recognition*, tr. 779–788. Redmon, J., Farhadi, A., 2017. YOLO9000: tốt hơn, nhanh hơn, mạnh hơn. *IEEE Conference on Computer Vision and Pattern Recognition* 29, 6517–6525. <https://doi.org/10.1109/CVPR.2017.690>.

Redmon, J., Farhadi, A., 2018. Yolov3: một cải tiến từng bước. *IEEE Conference on Computer Vision and Pattern Recognition* 15, 1125–1131.

Santos, P.A.S., Carvalho, M.T.M., 2025. Phân đoạn đa lớp các hư hại kết cấu và biểu hiện bệnh lý bằng YOLOv8 và Segment Anything. *Model. Autom. Constr.* 172, 106037. <https://doi.org/10.1016/j.autcon.2025.106037>.

Scott, L., Su-In, L., 2017. Phương pháp thống nhất để diễn giải các dự đoán của mô hình. *arXiv - CS - Trí tuệ nhân tạo*. Scott, M.L., Gabriel, G.E., Su-In, L., 2018. Gán mức độ đóng góp của đặc trưng nhất quán cho từng cá thể trong các mô hình tổ hợp cây. *arXiv - CS - Học máy*. Silva, R., Melo-Pinto, P., 2023. t-SNE: nghiên cứu về giảm chiều dữ liệu siêu phổ cho bài toán hồi quy ước tính các thông số enological. *Artif. Intell. Agric.* 7, 58–68. <https://doi.org/10.1016/j.aiia.2023.02.003>.

Thatikonda, M.M.K.P.K., Amsaad, F., 2024. Thuật toán AI mới để ước tính ngưỡng tin cậy động nhằm cải thiện khả năng phát hiện đối tượng. *NAECON 2024 - Hội nghị Hàng không vũ trụ và Điện tử Quốc gia IEEE*, tr. 359–363. Ul Islam, Q., Khozaei, F., Salah Al Barhoumi, E.M., Baig, I., Ignatyev, D., 2025. Thúc đẩy các hệ thống SLAM tự hành: tích hợp phát hiện đối tượng YOLO và các kỹ thuật khép kín vòng lặp nâng cao để lập bản đồ môi trường vững chắc. *Robot. Auton. Syst.* 185, 104871. <https://doi.org/10.1016/j.robot.2024.104871>.

Wang, D., Thunell, S., Lindberg, U., Jiang, L., Trygg, J., Tysklind, M., 2022. Hướng tới quản lý quy trình tốt hơn tại các nhà máy xử lý nước thải: phân tích quy trình dựa trên giá trị SHAP cho các phương pháp học máy dựa trên cây. *J. Environ. Manag.* 301, 113941. <https://doi.org/10.1016/j.jenvman.2021.113941>.

Wang, H., Liang, Q., Hancock, J.T., Khoshgoftaar, T.M., 2024. Chiến lược lựa chọn đặc trưng: phân tích so sánh các phương pháp dựa trên giá trị SHAP và mức độ quan trọng. *J. Big Data* 11, 44. <https://doi.org/10.1186/s40537-024-00905-w>.

Xu, C., Fan, Z., Ma, Y., Huang, Y., Wang, J., Xu, Y., Wu, D., 2025. CE-YOLO: thuật toán YOLO tiết kiệm kênh để phát hiện polyp đại trực tràng. *Biomed. Signal Process Control* 104, 107529. <https://doi.org/10.1016/j.bspc.2025.107529>.

Yang, B., Liang, W.F., Bin, L.Y., Chen, W.R., Chen, X.Y., Li, P., Wen, S.L., Huang, S.S., Tang, B., 2023. Tìm hiểu vòng đời của bùn hạt hiếu khí trong bể phản ứng sinh học màng dòng chảy liên tục bằng cách truy vết các đặc tính không đồng nhất của nó ở những giai đoạn khác nhau. *Water Res.* 243, 120419. <https://doi.org/10.1016/j.watres.2023.120419>.

Yang, L., Zhang, R.Y., Li, L., Xie, X., 2021. SimAM: mô-đun chú ý đơn giản, không tham số cho mạng nơ-ron tích chập. Trong: Marina, M., Tong, Z. (Biên tập), *Kỷ yếu Hội nghị Quốc tế lần thứ 38 về Học máy*. PMLR, *Kỷ yếu Nghiên cứu Học máy*, tr. 11863–11874. Trong: <https://proceedings.mlr.press/v139/yang21o.html>.

Zaghloul, M.S., Achari, G., 2022. Tổng quan về các mô hình cơ chế và mô hình dựa trên dữ liệu của bùn hạt hiếu khí. *J. Environ. Chem. Eng.* 10. <https://doi.org/10.1016/j.jece.2022.107500>.

Zaghloul, M.S., Iorhemen, O.T., Hamza, R.A., Tay, J.H., Achari, G., 2021. Phát triển một tổ hợp các thuật toán học máy để mô hình hóa các thiết bị phản ứng bùn hạt hiếu khí. *Water Res.* 189, 116657. <https://doi.org/10.1016/j.watres.2020.116657>.

Zhong, S., Zhang, K., Bagheri, M., Burken, J.G., Gu, A., Li, B., Ma, X., Marrone, B.L., Ren, Z.J., Schrier, J., Shi, W., Tan, H., Wang, T., Wang, X., Wong, B.M., Xiao, X., Yu, X., Zhu, J.J., Zhang, H., 2021. Học máy: những ý tưởng và công cụ mới trong khoa học và kỹ thuật môi trường. *Environ. Sci. Technol.* 55, 12741–12754. <https://doi.org/10.1021/acs.est.1c01339>.