

Wastewater Membrane Bioreactors: A Comprehensive Review of Explainable Artificial Intelligence and Digital Twin Applications

Wael S. Al-Rashed

Department of Civil Engineering, Faculty of Engineering, University of Tabuk, P.O. Box 741, Tabuk 71491, Saudi Arabia; walrashed@ut.edu.sa

Abstract

Wastewater membrane bioreactors (MBRs) have become an important advanced treatment technology due to their ability to produce high-quality effluent suitable for discharge and water reuse. However, their broader and more sustainable application remains constrained by membrane fouling, elevated energy demand, and the operational complexity of coupled biological and membrane separation processes. This comprehensive review critically evaluates the growing application of machine learning (ML), explainable artificial intelligence (XAI), and digital twin (DT) technologies in MBR systems. Published studies on fouling prediction, energy optimization, effluent quality estimation, and intelligent operational support are critically evaluated, with explicit attention to model performance, dataset limitations, and generalizability. The reviewed literature shows that ML models, particularly ensemble methods, support vector machines, and deep learning approaches, have demonstrated strong potential for predicting major MBR performance indicators, including transmembrane pressure, permeate flux, fouling resistance, and selected effluent-quality variables. In parallel, XAI methods such as SHAP, LIME, and Anchors are increasingly being used to enhance model transparency and to reveal the dominant factors controlling process performance. Digital twin frameworks further extend this potential by enabling the integration of mechanistic understanding, online sensor data, data-driven prediction, and interpretable decision support within real-time operational platforms. Nevertheless, several barriers continue to hinder practical implementation, including the limited number of full-scale studies, the scarcity of openly accessible and standardized datasets, insufficient consideration of uncertainty and model drift, and the early-stage maturity of DT deployment in operational plants. The evidence reviewed suggests that integrating ML, XAI, and DT can substantially improve the reliability, interpretability, and operational efficiency of MBR systems. Future research should therefore focus on full-scale validation, the development of benchmark datasets, uncertainty-aware modeling, and practical deployment strategies for interpretable intelligent MBR management.

Keywords: membrane bioreactor; explainable artificial intelligence; digital twin; membrane fouling; SHAP; energy optimization; machine learning; wastewater treatment

1. Introduction

Global water scarcity and increasingly stringent effluent discharge regulations have elevated membrane bioreactor (MBR) technology from a niche research application to a mainstream wastewater treatment solution deployed on every inhabited continent [1,2]. MBRs couple activated sludge biological treatment with pressure-driven membrane filtration. Hollow-fiber or flat-sheet ultrafiltration membranes are submerged directly in the



Academic Editor: Davor Dolar

Received: 10 April 2026

Revised: 14 May 2026

Accepted: 18 May 2026

Published: 21 May 2026

Copyright: © 2026 by the author. Licensee MDPI, Basel, Switzerland. This article is an open access article distributed under the terms and conditions of the [Creative Commons Attribution \(CC BY\) license](#).

Bể phản ứng sinh học màng xử lý nước thải: Tổng quan toàn diện về các ứng dụng trí tuệ nhân tạo có thể giải thích và bản sao số

Wael S. Al-Rashed

Khoa Kỹ thuật Xây dựng, Khoa Kỹ thuật, Đại học Tabuk, Hộp thư bưu điện 741, Tabuk 71491, Ả Rập Xê Út; walrashed@ut.edu.sa

Tóm tắt

Các lò phản ứng sinh học màng xử lý nước thải (MBR) đã trở thành một công nghệ xử lý tiên tiến quan trọng nhờ khả năng tạo ra nước đầu ra chất lượng cao, phù hợp để xả thải và tái sử dụng. Tuy nhiên, việc ứng dụng rộng rãi và bền vững hơn vẫn bị hạn chế bởi hiện tượng tắc nghẽn màng, nhu cầu năng lượng cao và độ phức tạp trong vận hành các quá trình sinh học và phân tách bằng màng kết hợp. Bài tổng quan toàn diện này đánh giá một cách phản biện việc ứng dụng ngày càng tăng của các công nghệ học máy (ML), trí tuệ nhân tạo có khả năng giải thích (XAI) và bản sao số (DT) trong các hệ thống MBR. Các nghiên cứu đã công bố về dự đoán tắc nghẽn, tối ưu hóa năng lượng, ước tính chất lượng nước đầu ra và hỗ trợ vận hành thông minh được đánh giá phản biện, đặc biệt chú ý đến hiệu năng mô hình, những hạn chế của bộ dữ liệu và khả năng khái quát hóa. Tài liệu được tổng quan cho thấy các mô hình ML, đặc biệt là phương pháp tổ hợp, máy vectơ hỗ trợ và các phương pháp học sâu, có tiềm năng lớn trong dự đoán những chỉ số hiệu năng chính của MBR, bao gồm áp suất xuyên màng, thông lượng dịch thấm, sức cản do tắc nghẽn và một số biến số về chất lượng nước đầu ra. Song song đó, các phương pháp XAI như SHAP, LIME và Anchors ngày càng được sử dụng để tăng tính minh bạch của mô hình và làm rõ các yếu tố chi phối hiệu năng quá trình. Các khuôn khổ bản sao số còn mở rộng tiềm năng này bằng cách cho phép tích hợp hiểu biết cơ chế, dữ liệu cảm biến trực tuyến, dự đoán dựa trên dữ liệu và hỗ trợ ra quyết định có thể diễn giải trong các nền tảng vận hành thời gian thực. Tuy vậy, vẫn còn nhiều rào cản cản trở việc triển khai thực tế, bao gồm số lượng nghiên cứu quy mô toàn diện còn hạn chế, tình trạng khan hiếm bộ dữ liệu được chuẩn hóa và công khai, việc xem xét chưa đầy đủ các yếu tố bất định và sự trôi dạt của mô hình, cũng như mức độ trưởng thành còn thấp của việc triển khai DT tại các nhà máy đang vận hành. Bằng chứng được tổng quan cho thấy việc tích hợp ML, XAI và DT có thể cải thiện đáng kể độ tin cậy, khả năng diễn giải và hiệu quả vận hành của các hệ thống MBR. Vì vậy, nghiên cứu trong tương lai nên tập trung vào xác nhận ở quy mô toàn diện, phát triển các bộ dữ liệu chuẩn, mô hình hóa có xét đến độ bất định và xây dựng chiến lược triển khai thực tiễn nhằm quản lý MBR thông minh, có khả năng diễn giải.

Từ khóa: bể phản ứng sinh học màng; trí tuệ nhân tạo có thể giải thích; bản sao số; cấu bản màng; SHAP; tối ưu hóa năng lượng; học máy; xử lý nước thải

1. Giới thiệu

Tình trạng khan hiếm nước toàn cầu và các quy định về xả nước thải ngày càng nghiêm ngặt đã đưa công nghệ bể phản ứng sinh học màng (MBR) từ một ứng dụng nghiên cứu chuyên biệt trở thành giải pháp xử lý nước thải phổ biến, được triển khai trên mọi châu lục có người sinh sống [1,2]. MBR kết hợp xử lý sinh học bằng bùn hoạt tính với quá trình lọc màng nhờ áp lực. Các màng siêu lọc dạng sợi rỗng hoặc tấm phẳng được nhúng trực tiếp vào bể phản ứng sinh học.



Academic Editor: Davor Dolar

Đã nhận: 10 tháng 4 năm 2026 Sửa đổi: 14 tháng 5 năm 2026 Chấp nhận: 18 tháng 5 năm 2026 Xuất bản: 21 tháng 5 năm 2026

Bản quyền: © 2026 thuộc về tác giả. Đơn vị cấp phép: MDPI, Basel, Thụy Sĩ. Bài viết này là bài viết truy cập mở, được phân phối theo các điều khoản và điều kiện của giấy phép Creative Commons Ghi công (CC BY).

bioreactor. MBRs produce a consistently high-quality, pathogen-free, and nutrient-reduced permeate. This effluent meets standards for direct non-potable reuse in agricultural irrigation, industrial process water, and environmental discharge [3,4]. This combination of compact footprint, flexible operation, and superior effluent quality has driven widespread commercial adoption. MBR systems now operate at scales ranging from decentralized 10 m³/day units to large municipal installations treating over 100,000 m³/day [1,5].

Since the first commercially significant installations in the early 1990s, MBR technology has expanded rapidly. More than 5000 wastewater treatment plants worldwide now use MBRs across municipal, industrial, and water-reuse applications [6,7]. Industrial applications span food and beverage processing, pharmaceutical manufacturing, textile and dye production, and petrochemical wastewater treatment. Each sector presents distinct mixed-liquor compositions and fouling challenges that conventional treatment technologies cannot address within the same process footprint [3,4]. The regulatory landscape has also shifted in MBR's favor. Effluent standards for nitrogen, phosphorus, and emerging contaminants have become increasingly stringent. Requirements for treated water reuse have also expanded. In many markets, MBR technology is now the only technically feasible option [2].

Despite this commercial success, MBR technology carries two persistent structural liabilities that constrain further deployment. Membrane fouling is the progressive accumulation of organic foulants, colloidal particles, and microbial extracellular polymeric substances (EPS) onto membrane surfaces. Within pore structures, fouling also reduces permeate flux, elevates transmembrane pressure (TMP), triggers chemical cleaning events, and ultimately forces premature membrane replacement. This represents the dominant lifecycle cost driver for MBR installations [4,8,9]. The fundamental mechanisms governing fouling are complex, nonlinear, and highly sensitive to mixed-liquor composition, sludge age, operational flux history, and hydraulic conditions. Even small changes in influent characteristics can significantly shift fouling behavior within a single operating day [10–12]. The second liability is energy. Aeration for biological oxygen transfer and membrane scouring, combined with permeate pumping, collectively accounts for 0.4–1.5 kWh/m³ of treated water. This is roughly double the specific energy demand of conventional activated sludge processes. Membrane aeration alone represents 60–75% of that total [13–15]. At scale, this energy penalty translates to substantial operating costs and carbon footprints that undermine the environmental credentials of water reuse applications.

Fouling unpredictability and energy inefficiency are precisely where machine learning offers a decisive advantage. ML algorithms learn complex, non-linear relationships between operational variables and process outcomes directly from historical data. They do not require the full mechanistic parameterization that constrains physics-based models in operational settings [16,17]. Support vector machines [18], random forests, gradient-boosting frameworks [19], and deep recurrent networks [20,21] have been applied to MBR systems. These approaches have demonstrated substantially better predictive accuracy than linear regression and simplified mechanistic models, across diverse scales and wastewater types [22–26].

However, deploying ML in regulated water treatment environments faces a critical barrier: the opacity of black-box model predictions. Operators, process engineers, and regulators require evidence that model recommendations are physically meaningful and consistent with domain knowledge. They also need assurance that models will not produce catastrophically incorrect outputs under unusual conditions. XAI tools such as LIME and gradient-based attribution methods address this need [27,28]. These tools decompose model predictions into quantifiable feature contributions. Engineers can interrogate model behavior, validate predictions against domain knowledge, and build operator trust. They

bể phản ứng sinh học. MBR tạo ra dòng nước thẩm có chất lượng cao ổn định, không chứa mầm bệnh và giảm hàm lượng dinh dưỡng. Nước thải đầu ra này đáp ứng các tiêu chuẩn để tái sử dụng trực tiếp, không dùng cho mục đích ăn uống, trong tưới tiêu nông nghiệp, nước dùng cho quy trình công nghiệp và xả thải ra môi trường [3, 4]. Sự kết hợp giữa diện tích chiếm dụng nhỏ gọn, vận hành linh hoạt và chất lượng nước đầu ra vượt trội đã thúc đẩy việc ứng dụng rộng rãi trong thương mại. Hiện nay, các hệ thống MBR hoạt động ở quy mô từ các thiết bị phi tập trung công suất 10 m³/ngày đến các cơ sở đô thị lớn xử lý hơn 100.000 m³/ngày [1,5].

Kể từ những hệ thống lắp đặt đầu tiên có ý nghĩa thương mại vào đầu thập niên 1990, công nghệ MBR đã phát triển nhanh chóng. Hiện nay, hơn 5.000 nhà máy xử lý nước thải trên toàn thế giới sử dụng MBR trong các ứng dụng đô thị, công nghiệp và tái sử dụng nước [6,7]. Các ứng dụng công nghiệp bao gồm chế biến thực phẩm và đồ uống, sản xuất dược phẩm, sản xuất dệt may và thuốc nhuộm, cũng như xử lý nước thải hóa dầu. Mỗi lĩnh vực có thành phần hỗn hợp bùn hoạt tính và những thách thức về tắc nghẽn riêng mà các công nghệ xử lý truyền thống không thể giải quyết trong cùng một diện tích quy trình [3,4]. Bối cảnh pháp quy cũng ngày càng có lợi cho MBR. Các tiêu chuẩn nước thải về nitơ, photpho và những chất ô nhiễm mới nổi ngày càng nghiêm ngặt. Các yêu cầu về tái sử dụng nước đã qua xử lý cũng được mở rộng. Tại nhiều thị trường, công nghệ MBR hiện là lựa chọn khả thi duy nhất về mặt kỹ thuật [2].

Bất chấp thành công thương mại này, công nghệ MBR vẫn tồn tại hai hạn chế mang tính cấu trúc dai dẳng, cản trở việc triển khai rộng rãi hơn. Tắc nghẽn màng là quá trình tích tụ dần các chất gây tắc hữu cơ, hạt keo và các chất polymer ngoại bào của vi sinh vật (EPS) trên bề mặt màng. Bên trong cấu trúc lỗ rỗng, hiện tượng tắc nghẽn cũng làm giảm thông lượng nước thẩm, tăng áp suất xuyên màng (TMP), dẫn đến các đợt làm sạch bằng hóa chất và cuối cùng buộc phải thay màng sớm hơn dự kiến. Đây là yếu tố chi phối chi phí vòng đời của các hệ thống MBR [4,8,9]. Các cơ chế cơ bản chi phối hiện tượng tắc nghẽn rất phức tạp, phi tuyến và cực kỳ nhạy cảm với thành phần hỗn hợp bùn, tuổi bùn, lịch sử thông lượng vận hành và điều kiện thủy lực. Ngay cả những thay đổi nhỏ trong đặc tính nước đầu vào cũng có thể làm thay đổi đáng kể diễn biến tắc nghẽn chỉ trong một ngày vận hành [10–12]. Hạn chế thứ hai là năng lượng. Nhu cầu năng lượng tổng hợp cho sục khí nhằm chuyển oxy sinh học và rửa bề mặt màng, cùng với bơm nước thẩm, đạt 0,4–1,5 kWh/m³ nước đã xử lý. Mức này xấp xỉ gấp đôi nhu cầu năng lượng riêng của các quy trình bùn hoạt tính thông thường. Riêng sục khí màng chiếm 60–75% tổng mức tiêu thụ đó [13–15]. Ở quy mô lớn, khoản chi phí năng lượng phát sinh này dẫn đến chi phí vận hành và lượng phát thải carbon đáng kể, làm suy giảm lợi ích môi trường của các ứng dụng tái sử dụng nước.

Tính khó lường của hiện tượng bám bẩn và tình trạng kém hiệu quả năng lượng chính là những lĩnh vực mà học máy mang lại lợi thế quyết định. Các thuật toán học máy trực tiếp học các mối quan hệ phức tạp, phi tuyến giữa các biến vận hành và kết quả của quy trình từ dữ liệu lịch sử. Chúng không đòi hỏi phải xác định đầy đủ các tham số cơ chế như những mô hình dựa trên vật lý cần có trong điều kiện vận hành [16,17]. Máy vectơ hỗ trợ [18], rừng ngẫu nhiên, các khung tăng cường gradient [19] và mạng hồi quy sâu [20,21] đã được áp dụng cho các hệ thống MBR. Trên nhiều quy mô và loại nước thải khác nhau, những phương pháp này cho thấy độ chính xác dự báo cao hơn đáng kể so với hồi quy tuyến tính và các mô hình cơ chế đơn giản hóa [22–26].

Tuy nhiên, việc triển khai ML trong các môi trường xử lý nước chịu sự quản lý chặt chẽ vẫn phải vượt qua rào cản nghiêm trọng: tính thiếu minh bạch của các dự đoán từ mô hình hộp đen. Người vận hành, kỹ sư quy trình và cơ quan quản lý cần có bằng chứng cho thấy các khuyến nghị của mô hình có ý nghĩa về mặt vật lý và nhất quán với kiến thức chuyên ngành. Họ cũng cần được đảm bảo rằng mô hình sẽ không đưa ra kết quả sai lệch nghiêm trọng trong những điều kiện bất thường. Các công cụ XAI như LIME và phương pháp quy kết dựa trên gradient đáp ứng nhu cầu này [27,28]. Những công cụ này phân rã các dự đoán của mô hình thành các mức đóng góp có thể định lượng của từng đặc trưng. Các kỹ sư có thể khảo sát hành vi của mô hình, xác thực các dự đoán dựa trên kiến thức chuyên ngành và xây dựng niềm tin của người vận hành. Họ

also help satisfy the regulatory expectation for explainable automated decisions in critical infrastructure [29].

A third technological trajectory has emerged: the digital twin. Digital twins serve as an integration framework that combines ML prediction, XAI transparency, and mechanistic modelling within a real-time operational tool [30–32]. A digital twin is a continuously updated, bidirectionally coupled virtual replica of a physical system. It combines high-fidelity process models with real-time sensor data and data-driven corrections. This enables predictive simulation, scenario testing, and optimization without physical experimentation [33]. For MBR systems, a mature digital twin would integrate activated sludge models [34,35], membrane filtration sub-models [36], ML-based fouling predictors, XAI explanation modules, and energy optimization engines. Together, these form a unified platform that provides operators with both operational recommendations and the transparent reasoning behind them [37].

No prior review has thoroughly mapped the intersection of ML, XAI, and DT as an integrated analytical framework for MBR systems. Existing reviews address ML and data-driven approaches in MBR and membrane processes in isolation [24,38], or examine DT applications in wastewater treatment without incorporating XAI transparency [37]. The present work is the first to synthesize all three paradigms within a single critically evaluated framework, directly addressing the gap between predictive capability and interpretable, deployable intelligent MBR control. The three paradigms form a logical and sequential chain. ML provides the predictive engine: it learns complex non-linear relationships from operational data and forecasts fouling, energy demand, and effluent quality with an accuracy that deterministic models cannot match under dynamic real-world conditions. XAI provides the interpretability layer: it decomposes individual ML predictions into ranked feature contributions, making model outputs auditable by engineers and regulators. Without XAI, ML cannot be safely deployed in regulated infrastructure. DT provides the operational integration layer: it combines ML predictions, XAI explanations, and mechanistic process models within a continuously updated virtual replica of the physical plant, enabling predictive simulation and scenario testing without physical experimentation. Each layer depends on the one before it. A predictive ML model without an XAI layer cannot satisfy regulatory transparency requirements. An XAI layer without a DT framework provides only post-hoc explanations without closed-loop operational integration. Only the combination of all three creates a system capable of trustworthy, interpretable, and deployable autonomous MBR control. This interdependence is the central analytical argument of this review and defines the scope of the critical synthesis that follows.

This review addresses these gaps through four objectives. First, it critically evaluates ML model performance, dataset limitations, and generalizability across MBR fouling prediction, energy optimization, and effluent quality estimation. Second, it assesses XAI interpretation frameworks and their practical role in building trustworthy, operator-accessible decisions for MBR systems. Third, it characterizes emerging digital twin architectures, their deployment maturity, and the requirements for integrating XAI within operational DT platforms. Fourth, it identifies the critical research gaps that must be resolved before XAI-DT integration can achieve operational-scale deployment. Figure 1 presents a schematic overview of the main MBR operational challenges, analytical paradigms, application domains, and key research gaps identified in this review.

Following this framework, the subsequent sections describe the review methodology and then critically discuss ML, XAI, and DT applications in wastewater MBR systems.

It should be noted that the term ‘comprehensive’ in the title refers to the breadth of the paradigms reviewed, spanning ML, XAI, and DT within a single analytical framework, rather than implying that the field itself is mature at an operational scale. Indeed, the

cũng giúp đáp ứng kỳ vọng của cơ quan quản lý về khả năng giải thích các quyết định tự động trong cơ sở hạ tầng trọng yếu [29].

Một hướng phát triển công nghệ thứ ba đã xuất hiện: bản sao số. Bản sao số đóng vai trò là một khuôn khổ tích hợp, kết hợp dự đoán bằng ML, tính minh bạch của XAI và mô hình hóa cơ chế trong một công cụ vận hành theo thời gian thực [30–32]. Bản sao số là bản sao ảo của một hệ thống vật lý, được cập nhật liên tục và ghép nối hai chiều. Nó kết hợp các mô hình quy trình có độ trung thực cao với dữ liệu cảm biến thời gian thực và các hiệu chỉnh dựa trên dữ liệu. Nhờ đó, có thể mô phỏng dự báo, kiểm thử kịch bản và tối ưu hóa mà không cần thử nghiệm vật lý [33]. Đối với các hệ thống MBR, một bản sao số hoàn thiện sẽ tích hợp các mô hình bùn hoạt tính [34,35], các mô hình phụ về lọc màng [36], bộ dự báo đóng bám dựa trên ML, các mô-đun giải thích XAI và các công cụ tối ưu hóa năng lượng. Kết hợp lại, chúng tạo thành một nền tảng thống nhất cung cấp cho người vận hành cả khuyến nghị vận hành lẫn phân giải thích minh bạch làm cơ sở cho những khuyến nghị đó [37].

Chưa có nghiên cứu tổng quan nào lập bản đồ toàn diện về sự giao thoa giữa ML, XAI và DT như một khuôn khổ phân tích tích hợp cho các hệ thống MBR. Các nghiên cứu tổng quan hiện có xem xét riêng lẻ ML và các phương pháp dựa trên dữ liệu trong MBR, cũng như các quy trình màng [24,38], hoặc khảo sát ứng dụng DT trong xử lý nước thải mà không tích hợp tính minh bạch của XAI [37]. Công trình này là nghiên cứu đầu tiên tổng hợp cả ba mô hình trong một khuôn khổ được đánh giá phản biện, trực tiếp giải quyết khoảng cách giữa năng lực dự đoán với khả năng diễn giải và triển khai của hệ thống điều khiển MBR thông minh. Ba mô hình này tạo thành một chuỗi logic và tuần tự. ML cung cấp động cơ dự đoán: phương pháp này học các mối quan hệ phi tuyến phức tạp từ dữ liệu vận hành và dự báo hiện tượng tắc nghẽn, nhu cầu năng lượng cũng như chất lượng nước đầu ra với độ chính xác mà các mô hình tất định không thể đạt được trong điều kiện thực tế biến động. XAI cung cấp lớp diễn giải: phương pháp này phân rã từng dự đoán của ML thành các mức đóng góp của đặc trưng được xếp hạng, giúp kỹ sư và cơ quan quản lý có thể kiểm tra kết quả đầu ra của mô hình. Thiếu XAI, ML không thể được triển khai an toàn trong cơ sở hạ tầng chịu sự quản lý. DT cung cấp lớp tích hợp vận hành: phương pháp này kết hợp các dự đoán của ML, phần giải thích của XAI và các mô hình quy trình cơ chế trong một bản sao ảo của nhà máy vật lý được cập nhật liên tục, cho phép mô phỏng dự báo và thử nghiệm các kịch bản mà không cần thực nghiệm vật lý. Mỗi lớp phụ thuộc vào lớp đứng trước. Mô hình ML có khả năng dự đoán nhưng không có lớp XAI thì không thể đáp ứng các yêu cầu về tính minh bạch theo quy định. Lớp XAI không có khuôn khổ DT chỉ cung cấp các phần giải thích hậu nghiệm, thiếu sự tích hợp vận hành theo vòng kín. Chỉ khi kết hợp cả ba mới có thể tạo ra một hệ thống có khả năng điều khiển MBR tự động đáng tin cậy, dễ diễn giải và có thể triển khai. Sự phụ thuộc lẫn nhau này là lập luận phân tích trọng tâm của bài tổng quan và xác định phạm vi của phần tổng hợp phản biện tiếp theo.

Bài tổng quan này giải quyết những khoảng trống đó thông qua bốn mục tiêu. Thứ nhất, bài đánh giá một cách phản biện hiệu suất của các mô hình ML, những hạn chế của bộ dữ liệu và khả năng khái quát hóa trong dự đoán hiện tượng cấu bẩn MBR, tối ưu hóa năng lượng và ước tính chất lượng nước thải đầu ra. Thứ hai, bài đánh giá các khuôn khổ diễn giải XAI và vai trò thực tiễn của chúng trong việc xây dựng các quyết định đáng tin cậy, dễ tiếp cận với người vận hành cho các hệ thống MBR. Thứ ba, bài mô tả các kiến trúc bản sao số mới nổi, mức độ trưởng thành trong triển khai và các yêu cầu để tích hợp XAI vào các nền tảng DT vận hành. Thứ tư, bài xác định những khoảng trống nghiên cứu then chốt cần được giải quyết trước khi việc tích hợp XAI-DT có thể được triển khai ở quy mô vận hành. Hình 1 trình bày sơ đồ tổng quan về những thách thức chính trong vận hành MBR, các mô hình phân tích, lĩnh vực ứng dụng và những khoảng trống nghiên cứu then chốt được xác định trong bài tổng quan này.

Theo khuôn khổ này, các phần tiếp theo trình bày phương pháp luận tổng quan, sau đó thảo luận phản biện về các ứng dụng ML, XAI và DT trong các hệ thống MBR xử lý nước thải.

Cần lưu ý rằng thuật ngữ “toàn diện” trong tiêu đề đề cập đến phạm vi rộng của các mô hình được đánh giá, bao quát ML, XAI và DT trong một khuôn khổ phân tích duy nhất, chứ không hàm ý rằng lĩnh vực này đã trưởng thành ở quy mô vận hành. Tuy nhiên, việc

scarcity of full-scale DT deployments and the limited extent of XAI integration documented throughout this review are among the review’s central findings and define the research agenda articulated in Section 7.




Figure 1. Conceptual framework of the review, showing the main operational challenges in wastewater membrane bioreactors (MBRs), the analytical paradigms covered in this paper (machine learning, explainable artificial intelligence, and digital twins), their major application areas, and the key research gaps and future directions identified.

2. Methodology


Literature Search and Study Selection

A focused literature search was conducted across three major scientific databases: Scopus, Web of Science, and PubMed. The search covered the period January 2010 to December 2025. This lower bound was chosen because it coincides with the period of significant growth in both MBR commercial deployment and the application of ML to environmental engineering.

The search used free-text keywords combined with Boolean operators: (“membrane bioreactor” OR “MBR”) AND (“machine learning” OR “artificial neural network” OR “deep learning” OR “LSTM” OR “random forest” OR “support vector machine” OR “explainable AI” OR “XAI” OR “SHAP” OR “LIME” OR “digital twin”). The search was restricted to peer-reviewed journal articles in English. Reference lists of retrieved articles were checked manually for additional relevant sources. Studies were excluded if they lacked quantitative performance metrics or focused solely on membrane material fabrication.

The studies retained after this search form the evidence base of this review. This work is a narrative review focused on AI trends in MBR systems. It does not constitute a systematic review or meta-analysis, and accordingly a PRISMA flow diagram was not established. Studies were retained if they addressed ML, XAI, or DT applications in MBR systems and reported original modelling or empirical results. Study-level data for all reviewed primary

Sự khan hiếm các triển khai DT toàn diện và mức độ tích hợp XAI còn hạn chế được ghi nhận xuyên suốt bài tổng quan này là những phát hiện trọng tâm, đồng thời định hình chương trình nghiên cứu được trình bày trong Mục 7.



Hình 1. Khung khái niệm của bài tổng quan, thể hiện các thách thức vận hành chính trong các bể phản ứng sinh học màng xử lý nước thải (MBR), các mô hình phân tích được đề cập trong bài báo này (học máy, trí tuệ nhân tạo có thể giải thích và bản sao số), các lĩnh vực ứng dụng chính, cùng những khoảng trống nghiên cứu trọng yếu và định hướng trong tương lai được xác định.

2. Phương pháp luận

Literature Search and Study Selection

Một cuộc tìm kiếm tài liệu có trọng tâm đã được tiến hành trên ba cơ sở dữ liệu khoa học lớn: Scopus, Web of Science và PubMed. Tìm kiếm bao quát giai đoạn từ tháng 1 năm 2010 đến tháng 12 năm 2025. Mốc thời gian bắt đầu này được chọn vì trùng với giai đoạn triển khai thương mại MBR và ứng dụng ML trong kỹ thuật môi trường ngày càng tăng đáng kể.

Chiến lược tìm kiếm sử dụng các từ khóa dạng văn bản tự do kết hợp với toán tử Boolean: (“membrane bioreactor” OR “MBR”) AND (“machine learning” OR “artificial neural network” OR “deep learning” OR “LSTM” OR “random forest” OR “support vector machine” OR “explainable AI” OR “XAI” OR “SHAP” OR “LIME” OR “digital twin”). Phạm vi tìm kiếm được giới hạn ở các bài báo tạp chí tiếng Anh đã qua bình duyệt. Danh mục tài liệu tham khảo của các bài báo thu thập được đã được kiểm tra thủ công để tìm thêm các nguồn liên quan. Các nghiên cứu bị loại nếu không có các chỉ số hiệu suất định lượng hoặc chỉ tập trung vào chế tạo vật liệu màng.

Các nghiên cứu được giữ lại sau quá trình tìm kiếm này tạo thành cơ sở bằng chứng cho tổng quan này. Đây là tổng quan tường thuật tập trung vào các xu hướng AI trong hệ thống MBR. Công trình này không phải là tổng quan hệ thống hay phân tích tổng hợp; do đó, không lập sơ đồ luồng PRISMA. Các nghiên cứu được giữ lại nếu đề cập đến ứng dụng ML, XAI hoặc DT trong hệ thống MBR và báo cáo kết quả mô hình hóa hoặc thực nghiệm ban đầu. Dữ liệu ở cấp độ nghiên cứu của tất cả các nghiên cứu sơ cấp được tổng quan

studies, including target variable, unit, reported value range, performance metric, and external validation approach, is provided in Supplementary Table S1.

3. Machine Learning for Membrane Fouling Prediction

3.1. Fouling Mechanisms and Modelling Context

Membrane fouling in MBRs is a multi-scale, multi-mechanism phenomenon. Its overall resistance is partitioned using the resistance-in-series framework into three contributions: reversible cake layer formation (removable by relaxation or backwashing), irreversible pore blocking (requiring chemical cleaning), and adsorptive fouling within the membrane matrix [4]. The contribution of each mechanism depends on mixed-liquor composition and on the operating flux relative to the critical flux threshold. Key EPS components include soluble microbial products (SMP), bound EPS, and colloidal biopolymers [39]. Below the critical flux, fouling accumulation is gradual and largely reversible; above it, rapid and irreversible fouling occurs, dramatically shortening cleaning intervals and membrane lifetime [4,9].

Several operational parameters govern fouling kinetics. MLSS concentration determines the mass of material available for cake formation and influences mixed-liquor viscosity. SRT controls EPS production through its effect on biomass growth rate and substrate availability. HRT affects the dilution and residence time of colloidal foulant material. DO concentration governs the balance between aerobic and anoxic metabolic pathways, which shapes EPS composition. Membrane aeration intensity provides the shear stress required to limit cake layer growth on submerged membrane surfaces [11,12]. The interactions between these variables are non-linear and frequently antagonistic. For example, increasing MLSS improves biological treatment performance. However, it accelerates fouling, while increasing aeration reduces fouling but increases energy consumption, creating multi-objective trade-offs that are difficult to capture in simple mechanistic models [23].

These operational parameters, namely MLSS, SRT, HRT, DO, and aeration intensity, also constitute the primary candidate feature set for ML models targeting MBR fouling prediction. Their selection as model inputs is therefore grounded in mechanistic understanding rather than empirical convention. This linkage between process knowledge and feature engineering is a key strength of the hybrid modelling approaches discussed in Section 3.2.

Mechanistic models, including the ASM family [34,35] and the BSM-MBR benchmark [36], have substantially advanced understanding of biological kinetics and their coupling to membrane performance. However, their predictive accuracy under dynamic loading conditions is limited by several factors. These include the difficulty of characterizing mixed-liquor EPS fractions in real time, the strong sensitivity of model parameters to temperature and sludge history, and the high computational cost of full mechanistic simulation at operational timescales [23,40]. Osmotic MBR (OMBR) configurations introduce additional complexity by coupling the bioreactor to the forward osmosis (FO) membrane via an osmotic driving force, creating concentration polarization dynamics that further motivate data-driven approaches [22,41]. These limitations have motivated the ML approaches reviewed in the following subsections.

To provide a concrete operational reference for the parameters and data streams discussed in the following sections, Figure 2 presents a schematic of a typical submerged and side-stream MBR system. The diagram shows the key unit operations. These include the aerated bioreactor with activated sludge mixed liquor, the submerged hollow-fiber or flat-sheet ultrafiltration membrane module operating under negative permeate pressure, the permeate extraction pump and effluent outlet, the sludge recycle line maintaining the target MLSS concentration, and the waste sludge outlet controlling SRT. The coarse-bubble

Các nghiên cứu, bao gồm biến mục tiêu, đơn vị, phạm vi giá trị được báo cáo, thước đo hiệu suất và phương pháp xác thực bên ngoài, được trình bày trong Bảng bổ sung S1.

3. Học máy để dự đoán hiện tượng bám bẩn màng

3.1. Fouling Mechanisms and Modelling Context

Hiện tượng cấu bẩn màng trong MBR diễn ra ở nhiều quy mô và theo nhiều cơ chế. Theo mô hình điện trở nối tiếp, tổng điện trở được chia thành ba thành phần: lớp bánh bùn có thể đảo ngược (loại bỏ bằng thư giãn hoặc rửa ngược), tắc nghẽn lỗ màng không thể đảo ngược (cần làm sạch bằng hóa chất) và cấu bẩn do hấp phụ bên trong cấu trúc màng [4]. Mức độ đóng góp của mỗi cơ chế phụ thuộc vào thành phần hỗn hợp bùn và thông lượng vận hành so với ngưỡng thông lượng tới hạn. Các thành phần EPS chính gồm sản phẩm vi sinh vật hòa tan (SMP), EPS liên kết và các polymer sinh học dạng keo [39]. Dưới ngưỡng thông lượng tới hạn, cấu bẩn tích tụ từ từ và phần lớn có thể đảo ngược; trên ngưỡng này, cấu bẩn xảy ra nhanh chóng và không thể đảo ngược, làm rút ngắn đáng kể khoảng thời gian giữa các lần làm sạch và tuổi thọ màng [4,9].

Một số thông số vận hành chi phối động học quá trình bám bẩn. Nồng độ MLSS quyết định khối lượng vật chất có thể hình thành lớp bánh và ảnh hưởng đến độ nhớt của hỗn hợp bùn. SRT kiểm soát quá trình sản sinh EPS thông qua tác động đến tốc độ sinh trưởng sinh khối và lượng cơ chất sẵn có. HRT ảnh hưởng đến độ pha loãng và thời gian lưu của các chất gây bám bẩn dạng keo. Nồng độ DO chi phối sự cân bằng giữa các con đường chuyển hóa hiếu khí và thiếu khí, từ đó định hình thành phần EPS. Cường độ sục khí màng tạo ra ứng suất cắt cần thiết để hạn chế sự phát triển của lớp bánh trên bề mặt màng chìm [11,12]. Mỗi tương tác giữa các biến này là phi tuyến và thường đối kháng. Ví dụ, tăng MLSS giúp cải thiện hiệu quả xử lý sinh học. Tuy nhiên, việc này đẩy nhanh quá trình bám bẩn, trong khi tăng cường sục khí làm giảm bám bẩn nhưng lại tăng mức tiêu thụ năng lượng, tạo ra những đánh đổi đa mục tiêu khó nắm bắt bằng các mô hình cơ học đơn giản [23].

Các thông số vận hành này, cụ thể là MLSS, SRT, HRT, DO và cường độ sục khí, cũng tạo thành tập hợp đặc trưng ứng viên chính cho các mô hình ML nhằm dự đoán hiện tượng cấu bẩn trong MBR. Vì vậy, việc lựa chọn chúng làm đầu vào của mô hình dựa trên hiểu biết về cơ chế thay vì quy ước thực nghiệm. Mỗi liên kết giữa kiến thức về quy trình và kỹ thuật xây dựng đặc trưng này là một thế mạnh then chốt của các phương pháp mô hình hóa lai được thảo luận trong Mục 3.2.

Các mô hình cơ chế, bao gồm họ ASM [34,35] và bộ tiêu chuẩn BSM-MBR [36], đã giúp nâng cao đáng kể hiểu biết về động học sinh học và mối liên hệ của chúng với hiệu suất màng. Tuy nhiên, độ chính xác dự đoán của các mô hình này trong điều kiện tải động bị hạn chế bởi một số yếu tố. Trong đó có khó khăn khi đặc trưng hóa các phân đoạn EPS trong hỗn hợp bùn hoạt tính theo thời gian thực, độ nhạy cao của các tham số mô hình với nhiệt độ và lịch sử bùn, cũng như chi phí tính toán lớn khi mô phỏng cơ chế đầy đủ ở thang thời gian vận hành [23,40]. Các cấu hình MBR thẩm thấu (OMBR) làm tăng thêm độ phức tạp do kết nối lò phản ứng sinh học với màng thẩm thấu thuận (FO) thông qua lực dẫn động thẩm thấu, tạo ra các động thái phân cực nồng độ và càng thúc đẩy việc áp dụng các phương pháp dựa trên dữ liệu [22,41]. Những hạn chế này đã thúc đẩy các phương pháp ML được tổng quan trong các tiểu mục tiếp theo.

Để cung cấp tài liệu tham chiếu vận hành cụ thể cho các thông số và dòng dữ liệu được thảo luận trong những phần tiếp theo, Hình 2 trình bày sơ đồ của một hệ thống MBR chìm và dòng bên điển hình. Sơ đồ thể hiện các công đoạn xử lý chính, bao gồm bể phản ứng sinh học được sục khí với hỗn hợp bùn hoạt tính, mô-đun màng siêu lọc sợi rỗng hoặc tấm phẳng đặt chìm, vận hành dưới áp suất âm phía nước thẩm, bơm hút nước thẩm và xả nước sau xử lý, đường tuần hoàn bùn duy trì nồng độ MLSS mục tiêu, cùng cửa xả bùn thải kiểm soát SRT. Bọt khí thô

membrane aeration system provides shear stress for fouling control and for the backwash and chemical cleaning (CIP) circuits. The principal online sensor measurement points are also indicated: dissolved oxygen probes in the bioreactor, transmembrane pressure transducers on the permeate line, influent and permeate flow meters, online turbidity sensors, and temperature probes. The data pathway from these field sensors through the SCADA data acquisition system to the ML prediction and digital twin analytical layers is shown, establishing the physical and data context for the modelling work reviewed in Sections 3–6.




Figure 2. Schematic of a typical submerged and side-stream wastewater membrane bioreactor (MBR) system.


3.2. Shallow and Kernel-Based ML Models

The studies reviewed in this section were selected because they met all the inclusion criteria defined in Section Literature Search and Study Selection, including reporting at least one quantitative performance metric and applying original ML methodology to MBR operational or experimental data. Direct benchmarking across studies is constrained by heterogeneity in target variables, dataset sizes, and operating conditions; performance metrics should therefore be interpreted within each study rather than as absolute rankings.

Artificial neural networks were among the first ML architectures applied systematically to MBR fouling prediction. Mirbagheri et al. compared multi-layer perceptron (MLP) and radial basis function (RBF) neural networks for TMP and permeability prediction in a pilot-scale submerged MBR, using time, TSS, COD, SRT, and MLSS as input variables across a 60-day operating campaign [23]. Both architectures produced satisfactory predictions, with RBF networks demonstrating faster convergence and reduced sensitivity to initial weight conditions, an important practical consideration for online model deployment. The study highlighted the importance of selecting input variables and ensuring diversity in the training dataset for generalization beyond the training period. Schmitt et al. subsequently developed a backpropagation ANN for fouling prediction in an anoxic-aerobic MBR treating domestic wastewater. The model achieved $R^2 = 0.850$ on held-out test data, reflecting the inherent variability of pilot-scale operation and the challenge of capturing fouling dynamics with limited input variables [25].

Kernel-based methods, which map input data to higher-dimensional feature spaces to learn non-linear decision boundaries without deep architectures, have demonstrated

Hệ thống sục khí qua màng tạo ứng suất cắt để kiểm soát sự bám bẩn và phục vụ các mạch rửa ngược, vệ sinh bằng hóa chất (CIP). Các điểm đo của cảm biến trực tuyến chính cũng được chỉ ra: đầu dò oxy hòa tan trong bể phản ứng sinh học, bộ chuyển đổi áp suất xuyên màng trên đường ống nước thẩm, lưu lượng kế nước đầu vào và nước thẩm, cảm biến độ đục trực tuyến và đầu dò nhiệt độ. Luồng dữ liệu từ các cảm biến hiện trường này qua hệ thống thu thập dữ liệu SCADA đến các lớp phân tích dự đoán ML và bản sao số được thể hiện, qua đó xác lập bối cảnh vật lý và dữ liệu cho công trình mô hình hóa được xem xét trong các Mục 3–6.



Hình 2. Sơ đồ hệ thống thiết bị phản ứng sinh học màng (MBR) xử lý nước thải điển hình kiểu màng ngập và dòng bên.

3.2. Shallow and Kernel-Based ML Models

Các nghiên cứu được tổng quan trong phần này được lựa chọn vì đáp ứng tất cả các tiêu chí đưa vào đã xác định trong mục Tìm kiếm tài liệu và lựa chọn nghiên cứu, bao gồm việc báo cáo ít nhất một chỉ số hiệu suất định lượng và áp dụng phương pháp ML nguyên bản cho dữ liệu vận hành hoặc thực nghiệm MBR. Việc đối chiếu trực tiếp giữa các nghiên cứu bị hạn chế do sự khác biệt về biến mục tiêu, quy mô bộ dữ liệu và điều kiện vận hành; do đó, các chỉ số hiệu suất cần được diễn giải trong phạm vi từng nghiên cứu thay vì xem là các thứ hạng tuyệt đối.

Mạng nơ-ron nhân tạo là một trong những kiến trúc ML đầu tiên được áp dụng một cách có hệ thống để dự đoán hiện tượng cấu bẩn trong MBR. Mirbagheri và cộng sự đã so sánh mạng perceptron nhiều lớp (MLP) và mạng nơ-ron hàm cơ sở xuyên tâm (RBF) để dự đoán TMP và độ thẩm trong một hệ thống MBR chìm quy mô thí điểm, sử dụng thời gian, TSS, COD, SRT và MLSS làm các biến đầu vào trong suốt chiến dịch vận hành kéo dài 60 ngày [23]. Cả hai kiến trúc đều đưa ra dự đoán thỏa đáng; mạng RBF hội tụ nhanh hơn và ít nhạy hơn với điều kiện trọng số ban đầu, một yếu tố thực tiễn quan trọng khi triển khai mô hình trực tuyến. Nghiên cứu nhấn mạnh tầm quan trọng của việc lựa chọn các biến đầu vào và bảo đảm tính đa dạng của tập dữ liệu huấn luyện để khái quát hóa tốt ngoài giai đoạn huấn luyện. Sau đó, Schmitt và cộng sự đã phát triển một mạng nơ-ron nhân tạo sử dụng thuật toán lan truyền ngược để dự đoán hiện tượng cấu bẩn trong hệ thống MBR thiếu khí-hiếu khí xử lý nước thải sinh hoạt. Mô hình đạt $R^2 = 0.850$ trên dữ liệu kiểm tra chưa được sử dụng trong quá trình huấn luyện, phản ánh tính biến thiên vốn có của hoạt động ở quy mô thực địa và thách thức trong việc mô tả động lực học cấu bẩn khi số biến đầu vào còn hạn chế [25].

Các phương pháp dựa trên kernel, vốn ánh xạ dữ liệu đầu vào sang các không gian đặc trưng có số chiều cao hơn để học các ranh giới quyết định phi tuyến mà không cần kiến trúc sâu, đã cho thấy

competitive performance. Hamed et al. conducted a rigorous benchmarking study comparing ANN-MLP, ANN with particle swarm optimization (ANN-PSO), gene expression programming (GEP), and least-squares support vector machine (LSSVM) for fouling resistance prediction in a laboratory MBR [42]. LSSVM achieved the best performance with $R^2 = 0.990$ and $MSE = 0.0002$, substantially outperforming all ANN variants. Sensitivity analysis identified permeate flux and TMP as the dominant input variables, consistent with the resistance-in-series framework, demonstrating that ML feature importance analysis can recover mechanistically meaningful variable rankings. Giwa et al. applied ANN modelling to a submerged MBR treating mixed industrial and municipal wastewater in the UAE. They showed that feed water characteristics (conductivity, pH, suspended solids) are important predictors of effluent quality parameters, including COD, BOD, and turbidity. ANN performance depended critically on training data diversity across different loading conditions [43]. More recent work has confirmed and extended these findings. Nguyen et al. applied decision tree regression, support vector regression, and linear regression to predict TMP in a domestic wastewater MBR [44]. Decision tree regression achieved $R^2 = 0.99$. This result must be interpreted with caution. The dataset was small and single-facility. The high R^2 likely reflects fitting to that dataset's specific noise structure rather than a generalizable fouling model. A comprehensive review by Queiroz et al. analysed 57 ML studies on MBR performance prediction [45]. ANNs were used in 88% of cases. The review also identified a critical gap: no study had used ML to predict membrane lifespan or replacement timing. This gap has direct economic relevance for plant operators.

Survey studies have systematically evaluated the state of ML modelling in MBR research. Schmitt and Do reviewed ML approaches for MBR fouling modelling across 30+ studies, identified data availability and representativeness as the primary constraints on model generalizability, and recommended long-duration continuous monitoring campaigns as the minimum dataset requirement for reliable model development [24]. Shi et al. reviewed ML applications across membrane filtration processes more broadly and concluded that hybrid ML–mechanistic models, which use mechanistic equations to compute derived input features before ML prediction, consistently outperformed purely black-box approaches in cross-validation studies, particularly when extrapolating beyond the training operating range [38].

3.3. Ensemble Methods and Deep Learning

Ensemble methods, algorithms that combine predictions from multiple base learners to reduce variance and improve generalization, have produced the strongest overall performance in the MBR ML literature. The random forest (RF) algorithm [21] aggregates predictions from an ensemble of independently trained decision trees, each built on a random subset of training data and input features. RF is particularly well-suited to MBR fouling prediction because it handles mixed variable types, is robust to outliers in process data, and provides built-in feature importance estimates without requiring a separate XAI step. Random forests are not without limitations, however. Their memory footprint scales with ensemble size, which can restrict deployment on embedded or edge hardware in real-time MBR control systems. Feature importance rankings from RF are also global and may mask local non-linearities; SHAP-based attribution, discussed in Section 4, is therefore recommended alongside RF when interpretability is required.

Viet and Jang demonstrated the potential of AI-based models for predicting osmotic MBR performance, applying several architectures to an OMBR system treating municipal wastewater [22]. Using feed water quality parameters, pH, conductivity, NH_4-N , total nitrogen, and total organic carbon, as model inputs, their best-performing models achieved $R^2 = 0.92$ – 0.98 for water flux and fouling resistance prediction, capturing the complex

hiệu suất cạnh tranh. Hamed và cộng sự đã tiến hành một nghiên cứu chuẩn đối sánh nghiêm ngặt, so sánh ANN-MLP, ANN kết hợp tối ưu hóa bầy đàn hạt (ANN-PSO), lập trình biểu hiện gen (GEP) và máy véc-tơ hỗ trợ bình phương tối thiểu (LSSVM) trong dự đoán sức cản bám bẩn ở một MBR quy mô phòng thí nghiệm [42]. LSSVM đạt hiệu suất tốt nhất với $R^2 = 0.990$ và $MSE = 0.0002$, vượt trội đáng kể so với tất cả các biến thể ANN. Phân tích độ nhạy xác định thông lượng nước thẩm và TMP là các biến đầu vào chi phối, phù hợp với khuôn khổ sức cản nối tiếp, cho thấy phân tích mức độ quan trọng của đặc trưng bằng ML có thể khôi phục thứ hạng biến có ý nghĩa về mặt cơ chế. Giwa và cộng sự áp dụng mô hình ANN cho một MBR chìm xử lý nước thải công nghiệp và đô thị hỗn hợp tại UAE. Họ cho thấy các đặc tính của nước đầu vào (độ dẫn điện, pH, chất rắn lơ lửng) là những yếu tố dự báo quan trọng đối với các thông số chất lượng nước đầu ra, bao gồm COD, BOD và độ đục. Hiệu suất của ANN phụ thuộc đáng kể vào tính đa dạng của dữ liệu huấn luyện trong các điều kiện tải trọng khác nhau [43]. Các nghiên cứu gần đây hơn đã xác nhận và mở rộng những phát hiện này. Nguyen và cộng sự áp dụng hồi quy cây quyết định, hồi quy véc-tơ hỗ trợ và hồi quy tuyến tính để dự đoán TMP trong MBR xử lý nước thải sinh hoạt [44]. Hồi quy cây quyết định đạt $R^2 = 0.99$. Cần diễn giải kết quả này một cách thận trọng. Bộ dữ liệu nhỏ và chỉ đến từ một cơ sở. R^2 cao có thể phản ánh việc khớp với cấu trúc nhiễu đặc thù của bộ dữ liệu đó, thay vì một mô hình bám bẩn có khả năng khái quát hóa. Một bài tổng quan toàn diện của Queiroz và cộng sự đã phân tích 57 nghiên cứu ML về dự đoán hiệu suất MBR [45]. ANN được sử dụng trong 88% trường hợp. Bài tổng quan cũng xác định một khoảng trống quan trọng: chưa có nghiên cứu nào sử dụng ML để dự đoán tuổi thọ màng hoặc thời điểm thay thế. Khoảng trống này có ý nghĩa kinh tế trực tiếp đối với đơn vị vận hành nhà máy.

Các nghiên cứu tổng quan đã đánh giá một cách có hệ thống hiện trạng mô hình hóa bằng ML trong nghiên cứu MBR. Schmitt và Do đã xem xét các phương pháp ML dùng để mô hình hóa hiện tượng bám bẩn trong MBR qua 30+ nghiên cứu, xác định tính sẵn có và tính đại diện của dữ liệu là những hạn chế chính đối với khả năng khái quát hóa của mô hình, đồng thời khuyến nghị các chiến dịch giám sát liên tục dài hạn là yêu cầu tối thiểu về tập dữ liệu để phát triển mô hình đáng tin cậy [24]. Shi và cộng sự đã xem xét các ứng dụng ML trong những quy trình lọc màng nói chung và kết luận rằng các mô hình lai ML–cơ chế, sử dụng phương trình cơ chế để tính toán các đặc trưng đầu vào suy dẫn trước khi ML đưa ra dự đoán, luôn cho kết quả tốt hơn các phương pháp hộp đen thuần túy trong các nghiên cứu kiểm định chéo, đặc biệt khi ngoại suy ra ngoài phạm vi vận hành của tập huấn luyện [38].

3.3. Ensemble Methods and Deep Learning

Các phương pháp tập hợp, tức những thuật toán kết hợp dự đoán từ nhiều mô hình học cơ sở để giảm phương sai và cải thiện khả năng khái quát hóa, đã đạt hiệu suất tổng thể mạnh nhất trong các tài liệu nghiên cứu về học máy cho MBR. Thuật toán rừng ngẫu nhiên (RF) [21] tổng hợp dự đoán từ một tập hợp các cây quyết định được huấn luyện độc lập; mỗi cây được xây dựng dựa trên một tập con ngẫu nhiên của dữ liệu huấn luyện và các đặc trưng đầu vào. RF đặc biệt phù hợp để dự đoán hiện tượng cấu bẩn trong MBR vì có thể xử lý các kiểu biến hỗn hợp, có khả năng chống chịu tốt với các giá trị ngoại lệ trong dữ liệu quy trình và cung cấp sẵn các ước lượng mức độ quan trọng của đặc trưng mà không cần một bước XAI riêng. Tuy nhiên, rừng ngẫu nhiên vẫn có những hạn chế. Dung lượng bộ nhớ cần thiết tăng theo kích thước tập hợp, điều này có thể hạn chế việc triển khai trên phần cứng nhúng hoặc phần cứng biên trong các hệ thống điều khiển MBR thời gian thực. Thứ hạng mức độ quan trọng của đặc trưng do RF cung cấp cũng mang tính toàn cục và có thể che khuất các quan hệ phi tuyến cục bộ; do đó, khi cần khả năng diễn giải, nên sử dụng phương pháp quy kết dựa trên SHAP được thảo luận ở Mục 4 cùng với RF.

Viet và Jang đã chứng minh tiềm năng của các mô hình dựa trên AI trong việc dự đoán hiệu suất MBR thẩm thấu, áp dụng một số kiến trúc cho hệ thống OMBR xử lý nước thải đô thị [22]. Sử dụng các thông số chất lượng nước cấp, pH, độ dẫn điện, NH_4-N , tổng nitơ và tổng carbon hữu cơ làm đầu vào mô hình, các mô hình có hiệu suất tốt nhất của họ đạt $R^2 = 0.92$ – 0.98 trong việc dự đoán thông lượng nước và khả năng chống bám bẩn, nắm bắt được sự phức tạp

osmotic driving force dynamics that govern OMBR performance. The results demonstrated that data-driven approaches can navigate the OMBR system's additional degrees of freedom, account for solution concentration and dilution effects, and capture reverse salt flux, without requiring explicit mechanistic parameterization of FO transport equations.

Kovacs et al. conducted the most comprehensive full-scale ML validation yet published in the MBR domain, applying RF, ANN, and LSTM models to a dataset comprising more than 80,000 samples from a municipal wastewater treatment plant [26]. The RF model achieved $R^2 = 0.927\text{--}0.996$ and $\text{RMSE} = 0.264\text{--}0.904$ kPa across the different stages of the MBR filtration cycle (initial fouling, stable operation, late-stage compaction, and post-cleaning recovery). ANN and LSTM produced higher overall RMSE values than RF. However, the LSTM showed particular strength in the temporally structured late-stage fouling period, where the history of flux and TMP evolution carries significant predictive information for the current fouling trajectory. Importantly, this study was the first to validate ML TMP prediction at full municipal scale with this level of accuracy, providing one of the strongest full-scale demonstrations to date of ML-based TMP prediction. It is critical to note, however, that validation on historical SCADA data is not equivalent to closed-loop operational deployment. Historical validation confirms that a model can reproduce past patterns from a single facility. It does not confirm that the model will perform reliably under real conditions involving sensor drift, measurement noise, data latency, or equipment failures. Full operational deployment requires additional closed-loop testing under live conditions before model outputs can be relied upon for operational decision-making.

It should be noted, however, that this dataset originates from a single municipal plant operating under a specific membrane configuration, sludge regime, and local influent composition. Operational variability arising from seasonal temperature fluctuations, industrial discharge events, and membrane aging was not separately analyzed. The generalizability of these models to other MBR facilities, therefore, remains to be established through cross-site validation, as discussed in Section 3.4.

The practical feasibility of LSTM and Transformer architectures in operational MBR systems warrants careful consideration. LSTM networks require substantially larger training datasets than shallow models, typically thousands to tens of thousands of time steps, to learn meaningful temporal dependencies without overfitting. Their training and inference also impose greater computational demands than random forests or support vector machines, which may limit deployment on the embedded industrial controllers typically used in MBR plants. Transformer architectures present an even higher data and compute burden. Model compression techniques, including pruning, quantization, and knowledge distillation, offer pathways to lightweight deployment but have not yet been evaluated in the MBR context. These constraints should be explicitly reported in future deep learning studies to allow practitioners to assess deployment readiness.

The emergence of LSTM networks [20] is particularly significant for MBR fouling modelling because TMP evolution is inherently time-dependent: the current fouling state encodes the accumulated history of flux excursions, aeration cycles, and sludge condition over preceding hours and days. LSTM networks, with their gated memory cells that selectively retain long-range temporal dependencies, are well-suited to this problem. Gradient boosting frameworks, such as XGBoost and LightGBM, have achieved strong performance on broader water-quality prediction tasks, and extending them to MBR-specific fouling prediction with appropriate temporal feature engineering represents a natural next step. Transformer architectures [46], which use self-attention mechanisms to capture global dependencies across input sequences, have demonstrated state-of-the-art performance in environmental time-series forecasting and represent a frontier application for MBR fouling prediction that has not yet been systematically evaluated in peer-reviewed studies. Random

động lực học lực dẫn động thẩm thấu chi phối hiệu suất OMBR. Kết quả cho thấy các phương pháp dựa trên dữ liệu có thể xử lý các bậc tự do bổ sung của hệ thống OMBR, tính đến ảnh hưởng của nồng độ và sự pha loãng dung dịch, đồng thời nắm bắt dòng muối ngược mà không cần tham số hóa tường minh các phương trình vận chuyển FO theo cơ chế.

Kovacs và cộng sự đã thực hiện nghiên cứu xác thực ML quy mô toàn diện nhất từng được công bố trong lĩnh vực MBR, áp dụng các mô hình RF, ANN và LSTM trên bộ dữ liệu gồm hơn 80.000 mẫu từ một nhà máy xử lý nước thải đô thị [26]. Mô hình RF đạt $R^2 = 0.927\text{--}0.996$ và $\text{RMSE} = 0.264\text{--}0.904$ kPa ở các giai đoạn khác nhau của chu kỳ lọc MBR (bám bẩn ban đầu, vận hành ổn định, nén chặt ở giai đoạn cuối và phục hồi sau làm sạch). ANN và LSTM cho giá trị RMSE tổng thể cao hơn RF. Tuy nhiên, LSTM thể hiện ưu thế đặc biệt trong giai đoạn bám bẩn cuối kỳ có cấu trúc theo thời gian, khi lịch sử diễn biến của thông lượng và TMP mang thông tin dự báo đáng kể về quỹ đạo bám bẩn hiện tại. Đáng chú ý, đây là nghiên cứu đầu tiên xác thực khả năng dự đoán TMP bằng ML ở quy mô đô thị đầy đủ với độ chính xác như vậy, đồng thời đưa ra một trong những minh chứng mạnh nhất cho đến nay về khả năng dự đoán TMP bằng ML ở quy mô toàn diện. Tuy nhiên, cần lưu ý rằng việc xác thực trên dữ liệu SCADA lịch sử không tương đương với triển khai vận hành vòng kín. Xác thực lịch sử xác nhận rằng mô hình có thể tái tạo các mô hình trong quá khứ từ một cơ sở dữ liệu nhất. Điều đó không xác nhận rằng mô hình sẽ hoạt động đáng tin cậy trong điều kiện thực tế có độ trôi cảm biến, nhiễu đo lường, độ trễ dữ liệu hoặc sự cố thiết bị. Việc triển khai vận hành đầy đủ đòi hỏi phải thử nghiệm vòng kín bổ sung trong điều kiện thực tế trước khi có thể tin cậy sử dụng đầu ra của mô hình để ra quyết định vận hành.

Tuy nhiên, cần lưu ý rằng bộ dữ liệu này bắt nguồn từ một nhà máy xử lý nước thải đô thị duy nhất, vận hành với cấu hình màng, chế độ bùn và thành phần nước thải đầu vào tại địa phương cụ thể. Sự biến động trong vận hành do biến động nhiệt độ theo mùa, các sự cố xả thải công nghiệp và tình trạng lão hóa màng chưa được phân tích riêng. Do đó, tính khái quát của các mô hình này đối với những cơ sở MBR khác vẫn cần được xác lập thông qua kiểm định chéo giữa các địa điểm, như đã thảo luận ở Mục 3.4.

Tính khả thi trong thực tế của các kiến trúc LSTM và Transformer trong các hệ thống MBR đang vận hành cần được cân nhắc kỹ lưỡng. Mạng LSTM đòi hỏi tập dữ liệu huấn luyện lớn hơn đáng kể so với các mô hình nông, thường cần từ hàng nghìn đến hàng chục nghìn bước thời gian để học được các phụ thuộc theo thời gian có ý nghĩa mà không bị quá khớp. Việc huấn luyện và suy luận các mạng này cũng đòi hỏi nhiều tài nguyên tính toán hơn so với rừng ngẫu nhiên hoặc máy véc-tơ hỗ trợ, điều này có thể hạn chế khả năng triển khai trên các bộ điều khiển công nghiệp nhúng thường được sử dụng tại các nhà máy MBR. Các kiến trúc Transformer còn đòi hỏi dữ liệu và năng lực tính toán nhiều hơn nữa. Các kỹ thuật nén mô hình, bao gồm cắt tỉa, lượng tử hóa và chưng cất tri thức, mở ra hướng triển khai các mô hình gọn nhẹ, nhưng vẫn chưa được đánh giá trong bối cảnh MBR. Các nghiên cứu học sâu trong tương lai cần báo cáo rõ những hạn chế này để người thực hành có thể đánh giá mức độ sẵn sàng triển khai.

Sự xuất hiện của các mạng LSTM [20] có ý nghĩa đặc biệt quan trọng đối với việc mô hình hóa hiện tượng fouling trong MBR, vì diễn biến TMP vốn phụ thuộc vào thời gian: trạng thái fouling hiện tại mã hóa lịch sử tích lũy của các biến động thông lượng, chu kỳ sục khí và tình trạng bùn trong những giờ và ngày trước đó. Với các ô nhớ có cổng chọn lọc lưu giữ những phụ thuộc thời gian dài hạn, mạng LSTM rất phù hợp với bài toán này. Các khung tăng cường gradient, chẳng hạn như XGBoost và LightGBM, đã đạt hiệu suất cao trong các bài toán dự đoán chất lượng nước nói chung; việc mở rộng chúng sang dự đoán fouling chuyên biệt cho MBR bằng kỹ thuật thiết kế đặc trưng theo thời gian phù hợp là bước tiếp theo tự nhiên. Các kiến trúc Transformer [46], sử dụng cơ chế tự chú ý để nắm bắt các phụ thuộc toàn cục trong chuỗi đầu vào, đã cho thấy hiệu suất tiên tiến nhất trong dự báo chuỗi thời gian môi trường và là một hướng ứng dụng tiên phong cho dự đoán fouling trong MBR, nhưng vẫn chưa được đánh giá một cách có hệ thống trong các nghiên cứu bình duyệt. Ngẫu nhiên

forests are not without limitations, however. Their memory footprint scales with ensemble size, which can restrict deployment on embedded or edge hardware in real-time MBR control systems. Feature importance rankings from RF are also global and may mask local non-linearities; SHAP-based attribution, discussed in Section 4, is therefore recommended alongside RF when interpretability is required.

3.4. Dataset Limitations, Overfitting Risk, and Cross-Site Generalization

A critical appraisal of the performance metrics summarized in Table 1 must account for the substantial heterogeneity in dataset characteristics across reviewed studies. The majority of studies trained and validated models on single-facility datasets comprising hundreds to a few thousand samples. Only Kovacs et al. reported a dataset comprising more than 80,000 operational samples from a full municipal-scale plant. High reported R^2 values, including $R^2 = 0.990$ for LSSVM [42] and $R^2 = 0.92\text{--}0.98$ for OMBR prediction models [22], must therefore be interpreted with care. When a model is trained and tested on data from a single, homogeneous operating campaign, a high R^2 can reflect the model’s capacity to reproduce the specific noise structure and temporal autocorrelation of that dataset rather than a genuinely generalizable representation of fouling dynamics. This overfitting risk is compounded by the near-universal absence of external validation on data from a separate operating period or independent plant; most reviewed studies relied on random train–test splits that do not preserve temporal ordering and therefore cannot detect temporal data leakage. Future studies should report k-fold cross-validation with temporal blocking, learning curves as a function of training set size, and, where feasible, cross-site validation on at least one independent facility.

Table 1. Confirmed ML model performance for MBR fouling and TMP prediction.

ML Algorithm	Target Variable	Scale	Best R^2	Approx. Dataset Size	External Validation	RMSE/MSE	Reference
ANN (MLP + RBF)	TMP/permeability	Pilot	Satisfactory	N/R; 60-day campaign	None (train–test split)	N/R	[23]
ANN (backprop)	TMP, AO-MBR	Pilot	0.850	N/R; pilot-scale	None (train–test split)	N/R	[25]
LSSVM (best)	Fouling resistance	Lab	0.990	N/R; lab-scale	None (train–test split)	MSE = 0.0002	[42]
ANN-MLP	Fouling resistance	Lab	Lower than LSSVM	N/R; lab-scale	None (train–test split)	>LSSVM	[42]
AI models (OMBR)	Water flux + fouling	Lab	0.92–0.98	N/R; lab OMBR	None (train–test split)	Reported	[22]
RF (best)	TMP, full-scale WWTP	Full-scale	0.927–0.996	>80,000 samples	None (single plant)	0.264–0.904 kPa	[26]
LSTM	TMP, full-scale WWTP	Full-scale	Lower than RF (no exact value reported)	>80,000 samples	None (single plant)	Higher than RF	[26]
ANN	TMP, full-scale WWTP	Full-scale	Lower than RF (no exact value reported)	>80,000 samples	None (single plant)	Higher than RF	[26]

The ability of a model trained at one MBR installation to maintain predictive accuracy when applied to a second facility with different membrane module geometry, influent composition, or operating regime, referred to here as cross-site generalization, has rarely been evaluated in the reviewed literature. Dataset shift, arising from differences in sludge microbiology, local wastewater chemistry, and climate-driven seasonal patterns, is the primary mechanism driving cross-site performance degradation. Transfer learning, in which a model pre-trained on a data-rich source facility is fine-tuned with limited data from a

Tuy nhiên, các rừng không phải là không có hạn chế. Dung lượng bộ nhớ của chúng tăng theo kích thước tập hợp, điều này có thể hạn chế việc triển khai trên phần cứng nhúng hoặc biên trong các hệ thống điều khiển MBR thời gian thực. Thứ hạng mức độ quan trọng của đặc trưng từ RF cũng mang tính toàn cục và có thể che khuất các quan hệ phi tuyến cục bộ; do đó, khi cần khả năng diễn giải, nên sử dụng phương pháp quy kết dựa trên SHAP, được thảo luận ở Mục 4, kết hợp với RF.

3.4. Dataset Limitations, Overfitting Risk, and Cross-Site Generalization

Một đánh giá phản biện về các chỉ số hiệu năng được tóm tắt trong Bảng 1 cần tính đến sự khác biệt đáng kể về đặc điểm bộ dữ liệu giữa các nghiên cứu được xem xét. Phần lớn các nghiên cứu huấn luyện và xác thực mô hình trên bộ dữ liệu từ một cơ sở duy nhất, gồm vài trăm đến vài nghìn mẫu. Chỉ Kovacs và cộng sự báo cáo bộ dữ liệu gồm hơn 80.000 mẫu vận hành từ một nhà máy quy mô đô thị hoàn chỉnh. Vì vậy, cần diễn giải thận trọng các giá trị R^2 được báo cáo ở mức cao, bao gồm $R^2 = 0,990$ đối với LSSVM [42] và $R^2 = 0,92\text{--}0,98$ đối với các mô hình dự đoán OMBR [22]. Khi mô hình được huấn luyện và kiểm tra trên dữ liệu từ một chiến dịch vận hành đơn lẻ, đồng nhất, R^2 cao có thể phản ánh khả năng mô phỏng cấu trúc nhiễu cụ thể và tự tương quan theo thời gian của bộ dữ liệu đó, thay vì biểu diễn thực sự có khả năng khái quát hóa động lực học của hiện tượng cấu bẩn. Nguy cơ quá khớp này càng gia tăng do hầu như không có nghiên cứu nào xác thực bên ngoài bằng dữ liệu từ một giai đoạn vận hành riêng biệt hoặc một nhà máy độc lập; phần lớn nghiên cứu được xem xét dựa vào cách chia ngẫu nhiên tập huấn luyện–kiểm tra, vốn không giữ nguyên thứ tự thời gian và do đó không thể phát hiện rò rỉ dữ liệu theo thời gian. Các nghiên cứu trong tương lai nên báo cáo kết quả kiểm định chéo k-fold có phân khối theo thời gian, đường cong học tập theo kích thước tập huấn luyện và, nếu khả thi, kiểm định chéo giữa các cơ sở tại ít nhất một cơ sở độc lập.

Bảng 1. Hiệu suất đã xác nhận của mô hình ML trong dự đoán hiện tượng bám bẩn MBR và TMP.

ML Algorithm	Target Variable	Scale	Best R^2	Approx. Dataset Size	External Validation	RMSE/MSE	Reference
ANN (MLP + RBF)	TMP/permeability	Pilot	Satisfactory	N/R; 60-day campaign	None (train–test split)	N/R	[23]
ANN (backprop)	TMP, AO-MBR	Pilot	0.850	N/R; pilot-scale	None (train–test split)	N/R	[25]
LSSVM (best)	Fouling resistance	Lab	0.990	N/R; lab-scale	None (train–test split)	MSE = 0.0002	[42]
ANN-MLP	Fouling resistance	Lab	Lower than LSSVM	N/R; lab-scale	None (train–test split)	>LSSVM	[42]
AI models (OMBR)	Water flux + fouling	Lab	0.92–0.98	N/R; lab OMBR	None (train–test split)	Reported	[22]
RF (best)	TMP, full-scale WWTP	Full-scale	0.927–0.996	>80,000 samples	None (single plant)	0.264–0.904 kPa	[26]
LSTM	TMP, full-scale WWTP	Full-scale	Lower than RF (no exact value reported)	>80,000 samples	None (single plant)	Higher than RF	[26]
ANN	TMP, full-scale WWTP	Full-scale	Lower than RF (no exact value reported)	>80,000 samples	None (single plant)	Higher than RF	[26]

Khả năng duy trì độ chính xác dự báo của một mô hình được huấn luyện tại một cơ sở MBR khi áp dụng cho cơ sở thứ hai có hình học mô-đun màng, thành phần nước đầu vào hoặc chế độ vận hành khác biệt, được gọi ở đây là khả năng khái quát hóa xuyên cơ sở, hiếm khi được đánh giá trong các tài liệu đã được tổng quan. Sự dịch chuyển dữ liệu, phát sinh từ khác biệt về hệ vi sinh bùn, hóa học nước thải tại địa phương và các kiểu biến thiên theo mùa do khí hậu chi phối, là cơ chế chính gây suy giảm hiệu suất xuyên cơ sở. Học chuyển giao, trong đó một mô hình được tiền huấn luyện trên cơ sở nguồn có nhiều dữ liệu sẽ được tinh chỉnh bằng dữ liệu hạn chế từ một

target plant, and domain adaptation, which explicitly minimizes the distributional discrepancy between source and target feature spaces, offer technically feasible pathways toward generalizable MBR ML models. Both approaches have demonstrated success in related environmental engineering contexts [17,47] and represent a high-priority methodological direction for future MBR ML research.

The limitations and generalizability constraints identified in this section directly affect the adoption of ML in regulated MBR operations. Practitioners and regulators require not only accurate predictions but also transparent, auditable justification for model-driven recommendations. This requirement motivates the use of explainable AI methods, which are evaluated in the following section. Table 2 presents a critical comparison of the principal ML algorithms reviewed, based solely on verified data from the primary cited sources. The table highlights the key strength, the primary limitation, and the bias risk level of each algorithm. Bias risk is rated High where no external validation on an independent facility was reported and the dataset comprised fewer than 500 samples. It is rated Moderate where the dataset was large but validation remained within a single facility. It is rated Low where at least two independent test sets from operational plants were used. This assessment follows the framework proposed by Reviewer and by published guidance on ML validation standards in environmental engineering [28,48].

Table 2. Critical comparison of principal ML algorithms applied to MBR fouling and TMP prediction.

Algorithm	Category	Key Strength	Key Limitation	Best R ²	Bias Risk ¹	Reference
ANN-MLP + RBF	Shallow ANN	Fast convergence; handles non-linear input-output relationships	No quantitative R ² reported; generalizability unvalidated	Not reported	HIGH	[23]
ANN (backprop)	Shallow ANN	Established architecture; practical for pilot-scale use	R ² = 0.850 only; moderate accuracy; no uncertainty quantification	0.850	HIGH	[24]
LSSVM	Kernel-based	Highest R ² in lab setting (0.99); robust on small data; built-in sensitivity analysis	Does not scale to large datasets; no temporal modeling capability	0.990	HIGH ²	[42]
AI models (OMBR)	Various	Captures osmotic driving force dynamics; R ² = 0.92–0.98	Small lab dataset; single facility only; no external validation	0.92–0.98	HIGH	[22]
Random Forest	Ensemble	Best accuracy at full scale; robust to outliers; built-in feature importance; handles mixed data types	Memory-intensive; global feature importance only; single-plant validation	0.927–0.996	MODERATE ³	[26]
LSTM	Deep learning (RNN)	Captures long-range temporal fouling dependencies; suited to time-series TMP	Requires large datasets; high compute demand; less accurate than RF in same study	Lower than RF	MODERATE ³	[26]
CatBoost + XAI	Gradient boosting	Strong full-scale performance; XAI identifies dominant fouling drivers (F/M, MLSS)	Moderate R ² (0.8374) on noisy industrial data; single food-processing plant	0.8374	MODERATE ³	[49]
MBR-Net (custom DL)	Deep learning	Real-time IoT-integrated prediction; R ² > 0.87 on two independent test sets; one-day-ahead forecasting	Limited by data availability; single facility type validated	>0.87	LOW ⁴	[50]

¹ Bias risk rated per Reviewer 2 criteria: High = no external validation + dataset < 500 samples; Moderate = large dataset but single-facility validation only; Low = validated on ≥2 independent test sets. ² LSSVM trained on lab-scale data only; dataset size not reported but consistent with <500 samples given lab campaign. ³ Single municipal or industrial plant; no cross-site validation performed. ⁴ MBR-Net validated on two independent test sets from the same full-scale facility; cross-site generalization not yet demonstrated.

nhà máy đích và thích ứng miền, vốn trực tiếp giảm thiểu sự sai khác về phân phối g iữa không gian đặc trưng của nguồn và đích, mang lại những hướng đi khả thi về m ặt kỹ thuật để xây dựng các mô hình ML MBR có khả năng khái quát hóa. Cả hai phư ơng pháp đều đã chứng minh hiệu quả trong các bối cảnh kỹ thuật môi trường liên quan [17,47] và là hướng nghiên cứu phương pháp luận được ưu tiên hàng đầu cho các nghiên cứu ML MBR trong tương lai.

Các hạn chế và ràng buộc về khả năng khái quát hóa được nêu trong phần này ảnh hưởng trực tiếp đến việc ứng dụng ML trong các hoạt động MBR chịu sự quản l ý chặt chẽ. Các chuyên gia thực hành và cơ quan quản lý không chỉ cần dự đoán chí nh xác mà còn cần cơ sở minh bạch, có thể kiểm toán để biện minh cho các khuyến nghị do mô hình đưa ra. Yêu cầu này thúc đẩy việc sử dụng các phương pháp AI có t hể giải thích, sẽ được đánh giá trong phần tiếp theo. Bảng 2 trình bày sự so sánh ph ản biện các thuật toán ML chủ yếu được xem xét, chỉ dựa trên dữ liệu đã được xác m inh từ các nguồn trích dẫn chính. Bảng nêu bật ưu điểm chính, hạn chế chủ yếu và mức độ rủi ro sai lệch của từng thuật toán. Rủi ro sai lệch được đánh giá là Cao khi k hông có báo cáo về việc xác thực bên ngoài tại một cơ sở độc lập và bộ dữ liệu gồm í t hơn 500 mẫu. Mức rủi ro được đánh giá là Trung bình khi bộ dữ liệu lớn nhưng việ c xác thực chỉ diễn ra trong một cơ sở. Mức rủi ro được đánh giá là Thấp khi sử dụng ít nhất hai bộ dữ liệu kiểm thử độc lập từ các nhà máy đang vận hành. Đánh giá này tuân theo khuôn khổ do Reviewer đề xuất và hướng dẫn đã công bố về các tiêu chuẩ n xác thực ML trong kỹ thuật môi trường [28,48].

Bảng 2. So sánh quan trọng các thuật toán ML chính được áp dụng để dự đoán hiện tượng bám bẩn M

Algorithm	Category	Key Strength	Key Limitation	Best R ²	Bias Risk ¹	Reference
ANN-MLP + RBF	Shallow ANN	Fast convergence; handles non-linear input-output relationships	No quantitative R ² reported; generalizability unvalidated	Not reported	HIGH	[23]
ANN (backprop)	Shallow ANN	Established architecture; practical for pilot-scale use	R ² = 0.850 only; moderate accuracy; no uncertainty quantification	0.850	HIGH	[24]
LSSVM	Kernel-based	Highest R ² in lab setting (0.99); robust on small data; built-in sensitivity analysis	Does not scale to large datasets; no temporal modeling capability	0.990	HIGH ²	[42]
AI models (OMBR)	Various	Captures osmotic driving force dynamics; R ² = 0.92–0.98	Small lab dataset; single facility only; no external validation	0.92–0.98	HIGH	[22]
Random Forest	Ensemble	Best accuracy at full scale; robust to outliers; built-in feature importance; handles mixed data types	Memory-intensive; global feature importance only; single-plant validation	0.927–0.996	MODERATE ³	[26]
LSTM	Deep learning (RNN)	Captures long-range temporal fouling dependencies; suited to time-series TMP	Requires large datasets; high compute demand; less accurate than RF in same study	Lower than RF	MODERATE ³	[26]
CatBoost + XAI	Gradient boosting	Strong full-scale performance; XAI identifies dominant fouling drivers (F/M, MLSS)	Moderate R ² (0.8374) on noisy industrial data; single food-processing plant	0.8374	MODERATE ³	[49]
MBR-Net (custom DL)	Deep learning	Real-time IoT-integrated prediction; R ² > 0.87 on two independent test sets; one-day-ahead forecasting	Limited by data availability; single facility type validated	>0.87	LOW ⁴	[50]

¹ Nguy cơ sai lệch được đánh giá theo tiêu chí của Người đánh giá 2: Cao = không có thẩm định bên ngo ài + bộ dữ liệu < 500 mẫu; Trung bình = bộ dữ liệu lớn nhưng chỉ được thẩm định tại một cơ sở; Thấp = đ ược thẩm định trên ≥2 bộ dữ liệu kiểm thử độc lập. ² LSSVM chỉ được huấn luyện trên dữ liệu quy mô ph òng thí nghiệm; không báo cáo kích thước bộ dữ liệu nhưng được cho là nhất quán với <500 mẫu, dựa tr ên chiến dịch nghiên cứu trong phòng thí nghiệm. ³ Một nhà máy đô thị hoặc công nghiệp duy nhất; chư a thực hiện thẩm định chéo giữa các cơ sở. ⁴ MBR-Net được thẩm định trên hai bộ dữ liệu kiểm thử độc lậ p từ cùng một cơ sở quy mô toàn phần; khả năng khái quát hóa giữa các cơ sở vẫn chưa được chứng min h.

4. Explainable Artificial Intelligence in MBR Applications

4.1. The Explainability Imperative in Regulated Water Systems

The adoption of ML in regulated water treatment environments faces a challenge that does not arise in most commercial ML applications: operators and regulators require not only accurate predictions but also interpretable justification for model-driven recommendations. In a manufacturing setting, a black-box ML system that reduces costs can be adopted solely on performance grounds. In a water utility, the bar is higher. An ML system that recommends reducing membrane aeration must demonstrate that the recommendation is physically sound, that it will not cause irreversible fouling under current conditions, and that it will not result in permit violations. All of this must be verifiable within the timeframe of the operating shift [29,51]. In regulated water treatment environments, the practical adoption of ML recommendations depends not only on predictive performance but also on operator trust, engineering plausibility, and the ability to document decision rationale.

Rudin [51] argues, in a widely cited analysis, that in high-stakes sequential decision-making domains, inherently interpretable models should be preferred over post-hoc explanations of black-box models whenever the mapping is sufficiently complex. However, the non-linear, multi-variable, temporally dependent nature of MBR fouling dynamics generally exceeds the representational capacity of interpretable models (e.g., logistic regression, decision trees) to achieve adequate predictive accuracy for operational use, making post-hoc XAI explanations of high-performing black-box models the pragmatic choice for the field [48]. XAI methods bridge this gap by providing explanations in a form that domain experts can evaluate, validate against process knowledge, and act upon, enabling the combination of black-box predictive power with the interpretability required for regulated deployment [29].

4.2. SHAP: Dominant XAI Framework in MBR Studies

SHAP (SHapley Additive exPlanations) [52], grounded in cooperative game theory, has emerged as the dominant XAI framework applied to MBR studies. Across XAI-inclusive publications identified in this review, SHAP was the most frequently applied method by a considerable margin. SHAP assigns each feature a contribution value equal to its expected marginal contribution across all possible feature subsets. This provides three desirable properties for engineering applications: local accuracy (SHAP values sum to the model output), consistency (features with larger marginal effects receive larger SHAP values), and missingness (absent features contribute zero). These properties make SHAP values directly interpretable as feature-level contributions to each prediction, enabling both local (per-prediction) and global (dataset-wide) model explanations [53].

Across the limited MBR studies that have applied SHAP or related feature-attribution methods, operational variables such as MLSS, SRT, HRT, and aeration intensity frequently emerge among the most influential predictors. However, their relative rankings vary across datasets, plant configurations, and modelling objectives. A recent full-scale study by Liang et al. applied CatBoost combined with XAI to an MBR treating food processing wastewater [49]. CatBoost achieved $R^2 = 0.8374$. XAI analysis identified the food-to-microorganism (F/M) ratio and MLSS as the two most influential fouling predictors. This finding is consistent with mechanistic understanding. It also demonstrates that XAI-informed ML can provide actionable guidance for full-scale MBR operations, not only for controlled lab or pilot systems. To illustrate how SHAP outputs translate into operator actions, consider a hypothetical but physically realistic scenario at a municipal MBR plant. Note: the numerical values below are illustrative. They are not extracted from a specific published dataset. They are consistent with operational ranges and SHAP output structures reported in Liang et al. and Kovacs et al. A Random Forest model predicts a TMP exceedance within

4. Trí tuệ nhân tạo có khả năng giải thích trong các ứng dụng MBR

4.1. The Explainability Imperative in Regulated Water Systems

Việc ứng dụng ML trong các môi trường xử lý nước chịu sự quản lý đối mặt với một thách thức không xuất hiện trong hầu hết các ứng dụng ML thương mại: người vận hành và cơ quan quản lý không chỉ yêu cầu các dự đoán chính xác mà còn cần có cơ sở giải thích được cho các khuyến nghị do mô hình đưa ra. Trong môi trường sản xuất, một hệ thống ML dạng hộp đen giúp giảm chi phí có thể được áp dụng chỉ dựa trên hiệu quả hoạt động. Tại một đơn vị cấp nước, tiêu chuẩn cao hơn. Một hệ thống ML khuyến nghị giảm sức khí màng phải chứng minh rằng khuyến nghị đó hợp lý về mặt vật lý, không gây tắc nghẽn màng không thể khắc phục trong điều kiện hiện tại và không dẫn đến vi phạm giấy phép. Tất cả những điều này phải có thể được kiểm chứng trong khoảng thời gian của ca vận hành [29,51]. Trong các môi trường xử lý nước chịu sự quản lý, việc áp dụng các khuyến nghị ML trên thực tế không chỉ phụ thuộc vào hiệu quả dự đoán mà còn vào niềm tin của người vận hành, tính hợp lý về kỹ thuật và khả năng ghi chép căn cứ cho quyết định.

Trong một phân tích được trích dẫn rộng rãi, Rudin [51] lập luận rằng trong các lĩnh vực ra quyết định tuần tự có mức độ rủi ro cao, nên ưu tiên các mô hình vốn dĩ có thể diễn giải được hơn là các lời giải thích hậu nghiệm cho mô hình hộp đen, bất cứ khi nào ánh xạ đủ phức tạp. Tuy nhiên, bản chất phi tuyến, đa biến và phụ thuộc theo thời gian của động lực học cấu trúc MBR nhìn chung vượt quá khả năng biểu diễn của các mô hình có thể diễn giải được (ví dụ: hồi quy logistic, cây quyết định) để đạt độ chính xác dự đoán phù hợp cho việc vận hành, khiến các lời giải thích XAI hậu nghiệm cho những mô hình hộp đen có hiệu năng cao trở thành lựa chọn thực tiễn của lĩnh vực này [48]. Các phương pháp XAI thu hẹp khoảng cách này bằng cách đưa ra lời giải thích dưới dạng mà chuyên gia trong lĩnh vực có thể đánh giá, đối chiếu với kiến thức về quy trình và dựa vào đó hành động, qua đó kết hợp sức mạnh dự đoán của mô hình hộp đen với khả năng diễn giải cần thiết để triển khai trong môi trường chịu sự quản lý [29].

4.2. SHAP: Dominant XAI Framework in MBR Studies

SHAP (các giải thích cộng tính theo giá trị Shapley) [52], dựa trên lý thuyết trò chơi hợp tác, đã nổi lên như khuôn khổ XAI chủ đạo được áp dụng trong các nghiên cứu về MBR. Trong số các công trình có sử dụng XAI được xác định trong bài tổng quan này, SHAP là phương pháp được áp dụng thường xuyên nhất, với khoảng cách đáng kể so với các phương pháp khác. SHAP gán cho mỗi đặc trưng một giá trị đóng góp bằng với đóng góp biên kỳ vọng của đặc trưng đó trên con đặc trưng có thể. Cách này mang lại ba thuộc tính đáng mong muốn trong các ứng dụng kỹ thuật: độ chính xác cục bộ (các giá trị SHAP có tổng bằng đầu ra của mô hình), tính nhất quán (các đặc trưng có tác động biên lớn hơn nhận giá trị SHAP lớn hơn) và tính vắng mặt (các đặc trưng không hiện diện có đóng góp bằng không). Những thuộc tính này giúp diễn giải trực tiếp các giá trị SHAP như mức đóng góp của từng đặc trưng vào mỗi dự đoán, qua đó cho phép giải thích mô hình ở cả cấp độ cục bộ (cho từng dự đoán) và toàn cục (trên toàn bộ tập dữ liệu) [53].

Trong số các nghiên cứu MBR còn hạn chế đã áp dụng SHAP hoặc các phương pháp quy thuộc đặc trưng liên quan, các biến vận hành như MLSS, SRT, HRT và cường độ sức khí thường nằm trong nhóm các yếu tố dự báo có ảnh hưởng lớn nhất. Tuy nhiên, thứ hạng tương đối của chúng thay đổi tùy theo bộ dữ liệu, cấu hình nhà máy và mục tiêu mô hình hóa. Một nghiên cứu gần đây ở quy mô toàn nhà máy của Liang và cộng sự đã áp dụng CatBoost kết hợp với XAI cho MBR xử lý nước thải chế biến thực phẩm [49]. CatBoost đạt $R^2 = 0.8374$. Phân tích XAI xác định tỷ lệ thức ăn trên vi sinh vật (F/M) và MLSS là hai yếu tố dự báo quan trọng nhất về hiện tượng đóng bám. Phát hiện này phù hợp với hiểu biết về cơ chế. Đồng thời, nó cho thấy ML được hỗ trợ bởi XAI có thể đưa ra hướng dẫn thiết thực cho hoạt động MBR ở quy mô toàn nhà máy, chứ không chỉ cho các hệ thống phòng thí nghiệm hoặc thí điểm được kiểm soát. Để minh họa cách chuyển các kết quả SHAP thành hành động của người vận hành, hãy xem xét một tình huống giả định nhưng phù hợp với thực tế vật lý tại một nhà máy MBR đô thị. Lưu ý: các giá trị số dưới đây chỉ nhằm minh họa. Chúng không được trích từ một bộ dữ liệu cụ thể đã công bố. Chúng phù hợp với các phạm vi vận hành và cấu trúc đầu ra SHAP được báo cáo trong các nghiên cứu của Liang và cộng sự cũng như Kovacs và cộng sự. Một mô hình Random Forest dự đoán áp suất xuyên màng (TMP) sẽ vượt ngưỡng trong

four hours. The SHAP explanation for this prediction identifies four feature contributions. MLSS = +2.1 kPa: mixed liquor concentration near its upper operating limit is the dominant risk driver. HRT = +1.4 kPa: short retention time is increasing organic loading to the membrane. Aeration intensity = −0.8 kPa: the current scouring rate is partially mitigating fouling risk. Feed flow rate = +0.6 kPa: elevated influent flow is compressing the cake layer. The SHAP values sum to the model output, confirming local accuracy. An operator reading this explanation identifies immediately that MLSS is the dominant risk factor. The current aeration rate is providing partial protection. The actionable response is to increase membrane scouring aeration and prepare for a relaxation cycle. This explanation uses the same process variables that operators monitor routinely. No specialist ML knowledge is required to act on it. This is the practical value of XAI in MBR operations: it tells the operator which specific condition is driving the risk and by how much [17,25,42]. This consistency is not merely a validation of known process understanding; it provides quantitative evidence that the ML models have learned physically meaningful representations of fouling dynamics rather than spurious correlations. In studies where SHAP global rankings diverge from mechanistic expectations. For example, when a SCADA timestamp feature is of high importance, it serves as an early warning of overfitting or data leakage, which can be detected and corrected before deployment [17,53].

Local SHAP values, computed for individual predictions, enable per-event explanation at the operational level. When a predictive model forecasts an imminent TMP exceedance, the associated SHAP values identify which specific process conditions are driving the prediction for that time step. An example being a combination of elevated MLSS (positive SHAP contribution), reduced HRT (positive), and adequate aeration (negative, stabilizing) with magnitudes that allow the operator to evaluate whether the prediction is consistent with their knowledge of the current operating state. Without interpretable local explanations, operators may be less willing to rely on model recommendations in safety or compliance-sensitive contexts [29].

Newhart et al. demonstrated the value of data-driven monitoring frameworks for MBR operational management, establishing that ML models trained on routine SCADA sensor streams can detect process upsets and deviations that precede measurable performance degradation [17]. Their work provided foundational evidence for integrating ML-based process monitoring into the MBR control infrastructure and identified the sensor variables most informative for state estimation. Viet and Jang applied AI-based predictive models to an OMBR system, demonstrating that draw solution concentration, feed water pH, and conductivity were the primary determinants of water flux and fouling resistance, with model predictions achieving $R^2 = 0.92\text{--}0.98$ [22]. These feature-importance findings are consistent with the osmotic-driving-force principles governing OMBR performance, confirming that ML-derived variable rankings can recover a mechanistically correct process understanding even in complex coupled systems.

Progressive evolution of SHAP values across an MBR filtration cycle provides operational insights not accessible from static feature importance rankings. As fouling accumulates during a filtration cycle, SHAP attributions for flux setpoint and MLSS tend to increase monotonically, reflecting the growing cake resistance. In contrast, the SHAP contribution of membrane aeration may plateau or decrease as the cake layer transitions from a loose, shear-removable deposit to a compacted gel layer where scouring becomes less effective. Monitoring these temporal SHAP profiles in real time provides early warning indicators of the transition from manageable to critical fouling, enabling proactive intervention before TMP reaches cleaning thresholds [17,53].

bốn giờ. Phần giải thích SHAP cho dự đoán này xác định bốn đóng góp của các đặc trưng. MLSS = +2.1 kPa: nồng độ bùn hoạt tính lơ lửng gần giới hạn vận hành trên là yếu tố rủi ro chi phối. HRT = +1.4 kPa: thời gian lưu ngắn đang làm tăng tải lượng hữu cơ lên màng. Cường độ sục khí = −0.8 kPa: tốc độ rửa màng hiện tại đang phần nào giảm thiểu nguy cơ fouling. Lưu lượng dòng cấp = +0.6 kPa: lưu lượng nước đầu vào tăng cao đang làm lớp bánh bùn bị nén chặt. Các giá trị SHAP cộng lại bằng đầu ra của mô hình, xác nhận độ chính xác cục bộ. Đọc phần giải thích này, người vận hành nhận ra ngay MLSS là yếu tố rủi ro chi phối. Tốc độ sục khí hiện tại đang giúp bảo vệ hệ thống phần nào. Biện pháp có thể thực hiện là tăng cường sục khí rửa màng và chuẩn bị cho một chu kỳ thư giãn. Phần giải thích này sử dụng cùng các biến quy trình mà người vận hành thường xuyên theo dõi. Không cần kiến thức chuyên môn về ML để hành động dựa trên đó. Đây là giá trị thực tiễn của XAI trong vận hành MBR: cho người vận hành biết chính xác điều kiện nào đang gây ra rủi ro và mức độ ảnh hưởng [17,25,42]. Sự nhất quán này không chỉ xác nhận những hiểu biết sẵn có về quy trình; nó còn cung cấp bằng chứng định lượng cho thấy các mô hình ML đã học được những biểu diễn có ý nghĩa vật lý về động lực học fouling, thay vì các tương quan giả. Trong các nghiên cứu mà thứ hạng toàn cục theo SHAP khác với những dự đoán theo cơ chế. Chẳng hạn, khi đặc trưng dấu thời gian SCADA có tầm quan trọng cao, đó là cảnh báo sớm về hiện tượng quá khớp hoặc rò rỉ dữ liệu, có thể được phát hiện và khắc phục trước khi triển khai [17,53].

Các giá trị SHAP cục bộ, được tính toán cho từng dự đoán riêng lẻ, cho phép giải thích từng sự kiện ở cấp độ vận hành. Khi một mô hình dự báo dự đoán TMP sắp vượt ngưỡng, các giá trị SHAP tương ứng sẽ xác định những điều kiện quy trình cụ thể nào đang chi phối dự đoán tại bước thời gian đó. Ví dụ, sự kết hợp giữa MLSS tăng cao (đóng góp SHAP dương), HRT giảm (dương) và sục khí đầy đủ (âm, có tác dụng ổn định), với độ lớn của các đóng góp cho phép người vận hành đánh giá liệu dự đoán có phù hợp với hiểu biết của họ về trạng thái vận hành hiện tại hay không. Nếu thiếu các giải thích cục bộ để diễn giải, người vận hành có thể ít sẵn lòng dựa vào khuyến nghị của mô hình trong những bối cảnh nhạy cảm về an toàn hoặc tuân thủ [29].

Newhart và cộng sự đã chứng minh giá trị của các khuôn khổ giám sát dựa trên dữ liệu trong quản lý vận hành MBR, cho thấy các mô hình ML được huấn luyện trên luồng dữ liệu cảm biến SCADA thường quy có thể phát hiện những sự cố và sai lệch của quy trình xuất hiện trước khi hiệu suất suy giảm ở mức có thể đo lường [17]. Nghiên cứu của họ cung cấp bằng chứng nền tảng cho việc tích hợp hoạt động giám sát quy trình dựa trên ML vào hạ tầng điều khiển MBR, đồng thời xác định các biến cảm biến có giá trị thông tin cao nhất đối với việc ước tính trạng thái. Viet và Jang đã áp dụng các mô hình dự đoán dựa trên AI cho một hệ thống OMBR, cho thấy nồng độ dung dịch kéo, pH và độ dẫn điện của nước cấp là những yếu tố quyết định chính đối với thông lượng nước và khả năng chống bám bẩn, với các dự đoán của mô hình đạt $R^2 = 0.92\text{--}0.98$ [22]. Những phát hiện về tầm quan trọng của các đặc trưng này phù hợp với các nguyên lý về lực dẫn thẩm thấu chi phối hiệu suất OMBR, xác nhận rằng thứ hạng biến số do ML xác định có thể tái hiện hiểu biết đúng đắn về quy trình dựa trên cơ chế, ngay cả trong các hệ thống phức hợp có sự liên kết chặt chẽ.

Diễn biến tăng dần của các giá trị SHAP trong suốt một chu kỳ lọc MBR cung cấp những hiểu biết vận hành mà các bảng xếp hạng tầm quan trọng đặc trưng tĩnh không thể mang lại. Khi cặn bám tích tụ trong chu kỳ lọc, mức đóng góp SHAP của giá trị đặt trước thông lượng và MLSS có xu hướng tăng đều, phản ánh sức cản do lớp bám cặn ngày càng lớn. Ngược lại, mức đóng góp SHAP của quá trình sục khí màng có thể chứng lại hoặc giảm khi lớp bánh cặn chuyển từ lớp lỏng động tới xốp, có thể bị loại bỏ bằng lực cắt, sang lớp gel bị nén chặt, nơi hiệu quả rửa trôi giảm đi. Việc theo dõi các hồ sơ SHAP theo thời gian này trong thời gian thực cung cấp các chỉ báo cảnh báo sớm về quá trình chuyển từ cặn bẩn có thể kiểm soát sang cặn bẩn nghiêm trọng, cho phép can thiệp chủ động trước khi TMP chạm ngưỡng làm sạch [17,53].

4.3. LIME, Partial Dependence Plots, and Gradient-Based Methods

LIME (Local Interpretable Model-agnostic Explanations) generates locally linear surrogate models around individual predictions by perturbing input features and observing the effect on the model's output [27]. For each prediction to be explained, LIME samples a neighborhood around the input point, weights samples by their proximity to the original input, and fits a simple interpretable model (typically linear regression or a shallow decision tree) to the sampled outputs. The coefficients of this local surrogate model explain the black-box model's local behavior. LIME's key advantage is computational efficiency: explanations can be generated in milliseconds, making it suitable for real-time operational dashboards where explanation latency is a constraint. Its limitation is inconsistency: explanations for similar inputs can vary significantly due to random sampling, and the choice of neighborhood radius affects explanation stability. The application of LIME specifically to MBR fouling and process control models is an emerging area of the literature with limited peer-reviewed examples, and a systematic comparison of LIME and SHAP performance in MBR contexts is a gap for future research.

Partial dependence plots (PDP) and individual conditional expectation (ICE) curves provide a global visualization of the marginal relationship between individual input features and model predictions [48]. PDPs show the expected model output as a function of a target feature, marginalized over the distribution of all other features; ICE curves disaggregate this by showing the relationship for each sample, revealing heterogeneity in the feature effect that is hidden in the averaged PDP. In MBR applications, PDP analysis of MLSS concentration typically reveals a non-linear threshold pattern, with fouling rates remaining relatively stable at MLSS below 10–12 g/L before increasing steeply, consistent with the empirically observed transition from dilute suspension dynamics to viscous, non-Newtonian sludge behavior above this concentration. ICE analysis further reveals that this threshold shifts with temperature and SRT, reflecting seasonal and operational variations in sludge filterability that complicate fixed-setpoint control [48].

Gradient-based attribution methods, originally developed for deep learning in computer vision and natural language processing, quantify the sensitivity of model outputs to input perturbations by analytically differentiating the computational graph [28,54]. Methods including vanilla gradients, integrated gradients (which average gradients along a path from a reference baseline to the actual input), and guided backpropagation have been applied to temporal neural network architectures, such as LSTMs and convolutional-recurrent hybrids, in water system monitoring applications. For MBR TMP prediction with LSTM models, gradient attribution maps identify which time steps carry the highest predictive information for the current TMP state. This typically corresponds to the 2–8 h immediately preceding the prediction window. This provides insight into the characteristic timescales of cake layer formation and consolidation, which are relevant for maintenance scheduling [28]. The application of these methods in MBR-specific deep learning models represents a frontier research area with significant practical potential. Table 3 summarizes the five principal XAI methods identified across the reviewed literature, comparing their explanation scope, model compatibility, computational cost, and MBR applications.

While XAI methods address the interpretability barrier to ML adoption, a parallel operational challenge in MBR systems concerns energy efficiency. Aeration for membrane scouring and biological treatment represents the dominant energy expenditure, and its optimization depends on the same complex, non-linear process relationships that ML models are well-suited to capture. The following section examines the evidence base for ML-driven energy optimization and establishes clear benchmarks against which future progress can be measured.

4.3. LIME, Partial Dependence Plots, and Gradient-Based Methods

LIME (Các giải thích cục bộ, có thể diễn giải, không phụ thuộc mô hình) tạo ra các mô hình thay thế tuyến tính cục bộ xung quanh từng dự đoán bằng cách làm nhiễu các đặc trưng đầu vào và quan sát tác động đến đầu ra của mô hình [27]. Với mỗi dự đoán cần giải thích, LIME lấy mẫu một vùng lân cận quanh điểm đầu vào, gán trọng số cho các mẫu dựa trên mức độ gần với đầu vào ban đầu, rồi khớp một mô hình đơn giản, dễ diễn giải (thường là hồi quy tuyến tính hoặc cây quyết định nông) với các đầu ra được lấy mẫu. Các hệ số của mô hình thay thế cục bộ này giải thích hành vi cục bộ của mô hình hộp đen. Ưu điểm chính của LIME là hiệu quả tính toán: có thể tạo ra lời giải thích trong vài mili giây, nhờ đó phù hợp với các bảng điều khiển vận hành thời gian thực, nơi độ trễ giải thích là một ràng buộc. Hạn chế của phương pháp này là tính không nhất quán: lời giải thích cho các đầu vào tương tự có thể khác nhau đáng kể do lấy mẫu ngẫu nhiên, và việc lựa chọn bán kính vùng lân cận ảnh hưởng đến độ ổn định của lời giải thích. Việc áp dụng LIME chuyển biệt cho các mô hình điều khiển quy trình và cấu bản trong MBR là một hướng nghiên cứu mới nổi với số lượng ví dụ được bình duyệt còn hạn chế; việc so sánh có hệ thống hiệu năng của LIME và SHAP trong bối cảnh MBR vẫn là khoảng trống cần được nghiên cứu trong tương lai.

Các đồ thị phụ thuộc riêng phần (PDP) và đường cong kỳ vọng có điều kiện riêng lẻ (ICE) cung cấp hình ảnh trực quan toàn cục về mối quan hệ biên giữa từng đặc trưng đầu vào và dự đoán của mô hình [48]. PDP thể hiện đầu ra kỳ vọng của mô hình theo một đặc trưng mục tiêu, sau khi lấy trung bình theo phân phối của tất cả các đặc trưng khác; ICE phân tách mối quan hệ này bằng cách thể hiện mối quan hệ cho từng mẫu, qua đó cho thấy tính không đồng nhất trong ảnh hưởng của đặc trưng vốn bị che khuất trong PDP đã lấy trung bình. Trong các ứng dụng MBR, phân tích PDP về nồng độ MLSS thường cho thấy dạng ngưỡng phi tuyến: tốc độ đóng bám vẫn tương đối ổn định khi MLSS dưới 10–12 g/L, sau đó tăng mạnh, phù hợp với sự chuyển đổi được quan sát thực nghiệm từ động lực học của huyền phù loãng sang trạng thái bùn nhớt, phi Newton khi nồng độ vượt ngưỡng này. Phân tích ICE còn cho thấy ngưỡng này dịch chuyển theo nhiệt độ và SRT, phản ánh những biến đổi theo mùa và vận hành trong khả năng lọc của bùn, khiến việc kiểm soát bằng điểm đặt cố định trở nên phức tạp [48].

Các phương pháp quy kết dựa trên gradient, vốn được phát triển cho học sâu trong thị giác máy tính và xử lý ngôn ngữ tự nhiên, định lượng độ nhạy của đầu ra mô hình trước các nhiễu loạn đầu vào bằng cách lấy đạo hàm giải tích của đồ thị tính toán [28,54]. Các phương pháp như gradient thông thường, gradient tích phân (lấy trung bình gradient dọc theo một đường đi từ giá trị tham chiếu cơ sở đến đầu vào thực tế) và lan truyền ngược có hướng dẫn đã được áp dụng cho các kiến trúc mạng neuron theo thời gian, chẳng hạn như LSTM và các mô hình lai tích chập–hồi tiếp, trong các ứng dụng giám sát hệ thống nước. Với bài toán dự đoán TMP của MBR bằng mô hình LSTM, các bản đồ quy kết gradient xác định những bước thời gian chứa nhiều thông tin dự báo nhất về trạng thái TMP hiện tại. Thông thường, đó là khoảng thời gian 2–8 giờ ngay trước cửa sổ dự đoán. Điều này cung cấp thông tin về các thang thời gian đặc trưng của quá trình hình thành và cố kết lớp bánh bùn, vốn có ý nghĩa đối với việc lập lịch bảo trì [28]. Việc áp dụng các phương pháp này vào các mô hình học sâu chuyên biệt cho MBR là một hướng nghiên cứu tiên phong với tiềm năng ứng dụng thực tiễn đáng kể. Bảng 3 tóm tắt năm phương pháp XAI chủ yếu được xác định từ tổng quan các tài liệu đã tổng quan, đồng thời so sánh phạm vi giải thích, khả năng tương thích với mô hình, chi phí tính toán và các ứng dụng trong MBR.

Mặc dù các phương pháp XAI giải quyết rào cản về khả năng diễn giải đối với việc ứng dụng ML, các hệ thống MBR còn đối mặt với một thách thức vận hành song song liên quan đến hiệu quả năng lượng. Sục khí để làm sạch màng và xử lý sinh học là khoản tiêu thụ năng lượng lớn nhất; việc tối ưu hóa hoạt động này phụ thuộc vào những mối quan hệ quy trình phức tạp, phi tuyến mà các mô hình ML có ưu thế trong việc nắm bắt. Phần tiếp theo xem xét cơ sở bằng chứng về tối ưu hóa năng lượng dựa trên ML và xác lập các tiêu chuẩn rõ ràng để đo lường tiến bộ trong tương lai.

Table 3. XAI methods applied in MBR and related water treatment studies: characteristics and applications.

XAI Method	Explanation Scope	Model Compatibility	Comp. Cost	Applications in MBR/Water Treatment	References
SHAP	Local + Global	Model-agnostic	Medium–High	Fouling prediction, energy optimization, effluent quality	[17,53]
LIME	Local	Model-agnostic	Low–Medium	Anomaly detection, water quality classification	[27,55]
PDP/ICE	Global	Model-agnostic	Low	Feature threshold identification, operating curve analysis	[48]
Integrated Gradients	Local (temporal)	Neural networks	Low	LSTM fouling forecasting, temporal attribution	[28,54]
ANCHORS	Local (rule-based)	Model-agnostic	High	Conceptual: operational rule extraction	[27]

5. ML-Driven Energy Optimization in MBR Systems

5.1. Energy Consumption Structure and Optimization Targets

Energy cost is the primary operational expenditure for MBR systems beyond membrane replacement, and aeration is by far the dominant energy consumer. Verrecht et al. established, through mechanistic modelling benchmarked against two full-scale plants, that aeration for membrane scouring and biological treatment combined consumes 0.4–0.8 kWh/m³ [56]. Krzeminski et al. confirmed, through a broader empirical survey, that total specific energy consumption for MBR systems typically falls in the range 0.8–1.1 kWh/m³, with the distribution within this range primarily driven by aeration control strategy, membrane flux setpoint, and sludge settleability [15]. Germain et al. also demonstrated that specific energy demand varies substantially across MBR configurations and that benchmarking across plants requires careful normalization for influent strength and treatment objectives [57]. Conventional aeration control in MBR systems employs either fixed air flow rate setpoints (determined during commissioning trials) or simple proportional-integral (PI) feedback on dissolved oxygen concentration. Fixed setpoints are energy-inefficient because they maintain membrane scouring aeration at the maximum required rate regardless of actual fouling conditions, resulting in systematic over-aeration during clean membrane periods immediately after backwashing or chemical cleaning. DO-feedback control improves biological aeration efficiency but does not directly manage membrane-scouring aeration, leaving the dominant aeration energy component under open-loop control [36]. The fundamental challenge is that the optimal scouring aeration rate is not a fixed process parameter. It depends on the current fouling state (cake layer thickness and compressibility), mixed-liquor viscosity, flux setpoint, and membrane age. None of these variables are directly measurable in real time with standard SCADA instrumentation [58].

This gap creates the natural use case for ML-based aeration optimization: a model that predicts the minimum scouring aeration required to maintain TMP below the critical fouling threshold under the current process conditions, given a stream of SCADA sensor inputs. Such a model would enable dynamic aeration adjustment that reduces energy consumption during favorable conditions while automatically increasing aeration when fouling risk is elevated, precisely the control action that requires the kind of non-linear, multi-variable mapping that ML architectures excel at providing [17,38].

Bảng 3. Các phương pháp XAI được áp dụng trong các nghiên cứu về MBR và xử lý nước liên quan: đặc

XAI Method	Explanation Scope	Model Compatibility	Comp. Cost	Applications in MBR/Water Treatment	References
SHAP	Local + Global	Model-agnostic	Medium–High	Fouling prediction, energy optimization, effluent quality	[17,53]
LIME	Local	Model-agnostic	Low–Medium	Anomaly detection, water quality classification	[27,55]
PDP/ICE	Global	Model-agnostic	Low	Feature threshold identification, operating curve analysis	[48]
Integrated Gradients	Local (temporal)	Neural networks	Low	LSTM fouling forecasting, temporal attribution	[28,54]
ANCHORS	Local (rule-based)	Model-agnostic	High	Conceptual: operational rule extraction	[27]

5. Tối ưu hóa năng lượng dựa trên học máy trong các hệ thống MBR

5.1. Energy Consumption Structure and Optimization Targets

Chi phí năng lượng là khoản chi phí vận hành chủ yếu của các hệ thống MBR, ngoài việc thay thế màng; trong đó, sục khí là khâu tiêu thụ năng lượng lớn nhất. Thông qua mô hình hóa cơ chế được đối chiếu với dữ liệu của hai nhà máy quy mô toàn phần, Verrecht et al. xác định rằng tổng năng lượng tiêu thụ cho sục khí rửa màng và xử lý sinh học là 0.4–0.8 kWh/m³ [56]. Qua một khảo sát thực nghiệm rộng hơn, Krzeminski et al. xác nhận rằng mức tiêu thụ năng lượng riêng tổng thể của các hệ thống MBR thường nằm trong khoảng 0.8–1.1 kWh/m³; sự phân bố trong khoảng này chủ yếu phụ thuộc vào chiến lược kiểm soát sục khí, giá trị đặt thông lượng màng và khả năng lắng của bùn [15]. Germain et al. cũng chứng minh rằng nhu cầu năng lượng riêng thay đổi đáng kể giữa các cấu hình MBR, đồng thời việc so sánh chuẩn giữa các nhà máy đòi hỏi phải chuẩn hóa cẩn thận theo nồng độ nước đầu vào và mục tiêu xử lý [57]. Các hệ thống MBR thường kiểm soát sục khí bằng giá trị đặt lưu lượng khí cố định (được xác định trong các đợt chạy thử khi đưa hệ thống vào vận hành) hoặc bằng điều khiển hồi tiếp tỷ lệ–tích phân (PI) đơn giản dựa trên nồng độ oxy hòa tan. Giá trị đặt cố định gây lãng phí năng lượng vì duy trì sục khí rửa màng ở mức tối đa cần thiết bất kể tình trạng cấu bồn thực tế, dẫn đến sục khí quá mức có tính hệ thống khi màng sạch, ngay sau khi rửa ngược hoặc vệ sinh hóa chất. Điều khiển hồi tiếp theo DO giúp nâng cao hiệu quả sục khí sinh học nhưng không trực tiếp kiểm soát sục khí rửa màng, khiến thành phần tiêu thụ năng lượng lớn nhất vẫn được điều khiển vòng hở [36]. Thách thức cốt lõi là lưu lượng sục khí rửa màng tối ưu không phải là một thông số quy trình cố định. Giá trị này phụ thuộc vào trạng thái cấu bồn hiện tại (độ dày và khả năng nén của lớp bánh bùn), độ nhớt của hỗn hợp bùn, giá trị đặt thông lượng và tuổi màng. Không biến nào trong số này có thể được đo trực tiếp theo thời gian thực bằng thiết bị SCADA tiêu chuẩn [58].

Khoảng trống này tạo nên trường hợp ứng dụng tự nhiên cho việc tối ưu hóa sục khí dựa trên ML: một mô hình dự đoán mức sục khí rửa tối thiểu cần thiết để duy trì TMP dưới ngưỡng tắc nghẽn tới hạn trong các điều kiện quy trình hiện tại, dựa trên luồng dữ liệu đầu vào từ các cảm biến SCADA. Mô hình như vậy sẽ cho phép điều chỉnh sục khí linh hoạt, giảm tiêu thụ năng lượng khi điều kiện thuận lợi, đồng thời tự động tăng sục khí khi nguy cơ tắc nghẽn cao — chính xác là hành động điều khiển đòi hỏi khả năng ánh xạ phi tuyến, đa biến mà các kiến trúc ML có thể mạnh [17,38].

5.2. Confirmed Energy Reduction Evidence and Research Gap

A critical distinction must be made at the outset of this section. Energy savings reported in the MBR literature originate from two fundamentally different control approaches. The first is ASM-based mechanistic control, which uses process models such as ASM1 or ASM2d combined with PI feedback. The second is ML-based data-driven control, which uses trained algorithms to predict and minimise energy demand. These two approaches are not equivalent, and conflating them overstates the maturity of ML-driven energy optimisation. Before examining the available evidence, it is important to distinguish between these two categories of energy optimization outcomes reported in the MBR literature. The first comprises validated energy savings measured at full-scale operational plants using mechanistic or feedback control strategies. The second comprises projected savings reported in simulation studies or pilot-scale control experiments, where the specific control algorithm and boundary conditions vary across publications, and savings are not always directly attributable to ML. This distinction is critical for a fair assessment of what ML has demonstrably achieved in MBR energy management versus what remains to be validated at an operational scale.

The most directly comparable evidence of energy reduction in the current literature comes from Sun et al., who conducted activated sludge model (ASM) simulations combined with proportional-integral (PI) feedback control of aeration at a full-scale MBR installation [59]. This model-based control approach, which used ASM predictions of oxygen demand to dynamically adjust biological aeration setpoints, achieved a 20% reduction in aeration energy demand, lowering total specific energy consumption to 0.45 kWh/m³, compared with the 0.73 kWh/m³ pilot-scale baseline established by Verrecht et al. [14]. This result confirms that dynamic, model-informed aeration control can deliver meaningful energy savings at full scale. However, it is important to note that the control algorithm used by Sun et al. was ASM-based PI control rather than an ML approach per se. The 20% aeration reduction thus represents a validated benchmark for model-based control rather than a confirmed ML-specific outcome.

Dedicated ML-driven energy optimization studies specifically targeting MBR aeration demand remain limited in the current literature. The range of aeration savings sometimes referenced in broader MBR optimization literature (spanning from approximately 15% to more than 25%) derives primarily from simulation studies, design optimization analyses, and pilot-scale control experiments where the control algorithm varies across publications and the savings are not always attributable to ML specifically. The development, validation, and full-scale demonstration of ML-based aeration optimization for MBR systems using real-time SCADA data, closed-loop control, and rigorous energy accounting are identified as among the highest-priority research directions in this field. Table 4 consolidates the confirmed specific energy consumption benchmarks and optimization evidence from the primary studies identified in this review.

The 20% reduction in aeration energy reported by Sun et al. was achieved through an ASM-based PI feedback control strategy rather than a dedicated ML algorithm. This result constitutes a validated benchmark for model-informed control rather than a confirmed ML-specific outcome. No peer-reviewed full-scale study has yet demonstrated a quantified energy saving directly attributable to a deployed ML control algorithm in an MBR plant. The development, closed-loop validation, and full-scale demonstration of ML-based dynamic aeration control using real-time SCADA data and rigorous energy accounting, thus, remain the most immediately impactful open research priorities in the energy optimization domain.

Addressing both the fouling prediction and energy optimization challenges at operational scale requires a unified framework that integrates ML prediction, XAI transparency,

5.2. Confirmed Energy Reduction Evidence and Research Gap

Ngay từ đầu phần này, cần phân biệt rõ hai phương pháp điều khiển hoàn toàn khác nhau làm cơ sở cho các mức tiết kiệm năng lượng được báo cáo trong các tài liệu về MBR. Thứ nhất là điều khiển cơ chế dựa trên ASM, sử dụng các mô hình quy trình như ASM1 hoặc ASM2d kết hợp với phản hồi PI. Thứ hai là điều khiển dựa trên dữ liệu bằng ML, sử dụng các thuật toán đã được huấn luyện để dự đoán và giảm thiểu nhu cầu năng lượng. Hai phương pháp này không tương đương, và việc đánh đồng chúng sẽ phóng đại mức độ trưởng thành của tối ưu hóa năng lượng dựa trên ML. Trước khi xem xét các bằng chứng hiện có, cần phân biệt hai nhóm kết quả tối ưu hóa năng lượng được báo cáo trong các tài liệu về MBR. Nhóm thứ nhất gồm các mức tiết kiệm năng lượng đã được xác thực, đo lường tại các nhà máy đang vận hành ở quy mô toàn diện bằng các chiến lược điều khiển cơ chế hoặc điều khiển phản hồi. Nhóm thứ hai gồm các mức tiết kiệm dự kiến được báo cáo trong những nghiên cứu mô phỏng hoặc thí nghiệm điều khiển ở quy mô thí điểm, trong đó thuật toán điều khiển cụ thể và các điều kiện biên khác nhau giữa các công bố, còn mức tiết kiệm không phải lúc nào cũng có thể quy trực tiếp cho ML. Sự phân biệt này rất quan trọng để đánh giá công bằng những gì ML đã chứng minh được trong quản lý năng lượng MBR, so với những gì vẫn cần được kiểm chứng ở quy mô vận hành.

Bằng chứng có thể so sánh trực tiếp nhất về mức giảm năng lượng trong các nghiên cứu hiện có đến từ Sun và cộng sự, những người đã thực hiện các mô phỏng mô hình bùn hoạt tính (ASM) kết hợp với điều khiển phản hồi tỷ lệ-tích phân (PI) cho quá trình sục khí tại một hệ thống MBR quy mô toàn phần [59]. Phương pháp điều khiển dựa trên mô hình này sử dụng các dự báo nhu cầu oxy của ASM để điều chỉnh linh hoạt các giá trị đặt sục khí sinh học, giúp giảm 20% nhu cầu năng lượng sục khí và đưa mức tiêu thụ năng lượng riêng tổng thể xuống còn 0.45 kWh/m³, so với mức cơ sở 0.73 kWh/m³ ở quy mô thí điểm do Verrecht và cộng sự xác lập [14]. Kết quả này xác nhận rằng việc điều khiển sục khí linh hoạt, có xét đến thông tin từ mô hình, có thể giúp tiết kiệm năng lượng đáng kể ở quy mô toàn phần. Tuy nhiên, cần lưu ý rằng thuật toán điều khiển Sun và cộng sự sử dụng là điều khiển PI dựa trên ASM, chứ không phải bản thân một phương pháp ML. Do đó, mức giảm sục khí 20% là một mốc tham chiếu đã được xác thực cho điều khiển dựa trên mô hình, chứ không phải kết quả đã được xác nhận là đặc thù của ML.

Các nghiên cứu tối ưu hóa năng lượng dựa trên học máy, nhằm riêng vào nhu cầu sục khí của MBR, hiện vẫn còn hạn chế trong các tài liệu nghiên cứu. Mức tiết kiệm sục khí đôi khi được đề cập trong các tài liệu rộng hơn về tối ưu hóa MBR (dao động từ khoảng 15% đến hơn 25%) chủ yếu bắt nguồn từ các nghiên cứu mô phỏng, phân tích tối ưu hóa thiết kế và thí nghiệm điều khiển ở quy mô thí điểm, trong đó thuật toán điều khiển khác nhau giữa các công bố và mức tiết kiệm không phải lúc nào cũng có thể quy cho riêng học máy. Việc phát triển, xác thực và trình diễn ở quy mô toàn phần các phương pháp tối ưu hóa sục khí dựa trên học máy cho hệ thống MBR, sử dụng dữ liệu SCADA theo thời gian thực, điều khiển vòng kín và hạch toán năng lượng nghiêm ngặt, được xác định là một trong những hướng nghiên cứu ưu tiên hàng đầu trong lĩnh vực này. Bảng 4 tổng hợp các chỉ số tiêu thụ năng lượng riêng đã được xác nhận và bằng chứng về tối ưu hóa từ những nghiên cứu chính được xác định trong bài tổng quan này.

Mức giảm 20% năng lượng sục khí mà Sun và cộng sự báo cáo đạt được nhờ chỉ số điều khiển phản hồi PI dựa trên ASM, chứ không phải một thuật toán ML chuyên dụng. Kết quả này là một chuẩn đo lường đã được kiểm chứng cho điều khiển dựa trên mô hình, chứ không phải kết quả đã được xác nhận là đặc thù của ML. Chưa có nghiên cứu nào được bình duyệt ở quy mô toàn diện chứng minh mức tiết kiệm năng lượng định lượng có thể trực tiếp quy cho một thuật toán điều khiển ML được triển khai tại nhà máy MBR. Vì vậy, việc phát triển, kiểm chứng vòng kín và trình diễn ở quy mô toàn diện hệ thống điều khiển sục khí động dựa trên ML, sử dụng dữ liệu SCADA theo thời gian thực và hạch toán năng lượng nghiêm ngặt, vẫn là những ưu tiên nghiên cứu còn bỏ ngỏ có tác động tức thời lớn nhất trong lĩnh vực tối ưu hóa năng lượng.

Giải quyết đồng thời các thách thức về dự đoán cấu cặn và tối ưu hóa năng lượng ở quy mô vận hành đòi hỏi một khuôn khổ thống nhất tích hợp khả năng dự đoán của học máy (ML) và tính minh bạch của AI có thể giải thích (XAI),

and mechanistic process understanding into a continuously updated operational tool. Digital twin technology provides precisely this integration layer, and its application to MBR systems is examined in the following section.

Table 4. Confirmed energy benchmarks and optimization evidence for MBR systems.

Scale	Method	Key Finding	Confirmed Energy Metric	Reference
Full-scale	Mechanistic energy model	Model validated within 20% of all plant parameters	Aeration: 0.4–0.8 kWh/m ³	[56]
BSM-MBR simulation	ASM scenario optimization	Energy reduced by SRT/recirculation tuning	Pilot baseline: 0.73 kWh/m ³	[14]
Multiple full-scale	Empirical survey	Benchmarking across diverse MBR plants	Typical range: 0.8–1.1 kWh/m ³	[15]
Full-scale	ASM + PI feedback control	Dynamic aeration control reduced blower demand 20%	Total: 0.45 kWh/m ³ (−20% aeration)	[59]

6. Digital Twin Frameworks for MBR Systems

6.1. Architecture, Components, and Maturity Tiers

The digital twin concept was first formally articulated in manufacturing by Grieves [30] and has since been elaborated across diverse industrial domains, including aerospace, energy infrastructure, and smart manufacturing [32]. Fuller et al. identify three essential components shared across industrial DT implementations: a physical entity with instrumented sensing and actuation; a virtual entity that models the physical system across relevant timescales; and a data connection layer enabling continuous state synchronization between physical and virtual domains [31]. The virtual entity must be multi-fidelity. It combines high-accuracy physics-based models for slowly varying system states with faster data-driven models for dynamic operational variables. This balance maintains both computational feasibility and predictive accuracy [33].

For MBR systems, this DT framework has three layers. The first is the physical plant: its SCADA network, online sensors (DO, turbidity, pressure transducers, flow meters), and actuators (blowers, pumps, valves). The second is a hierarchical virtual model incorporating ASM mechanistic sub-models [34,35], resistance-in-series fouling models [36], ML-based dynamic TMP predictors trained on operational data [22,26], SHAP-based feature attribution modules [53], and energy balance sub-models [14,56]. The third is a real-time data pipeline, potentially cloud-hosted, that synchronizes sensor readings to the virtual model and feeds model outputs back to the control system [37]. Wang et al. review DT applications across the entire wastewater treatment lifecycle, identify MBR fouling management and aeration optimization as the highest-value integration targets, and demonstrate that DT approaches can generate plant-wide energy savings and effluent quality improvements through coordinated optimization of biological, filtration, and chemical dosing subprocesses.

In practice, MBR digital twin implementations can be stratified into three capability tiers, reflecting increasing integration depth and autonomous decision-making. Tier I (Descriptive) twins monitor and visualize real-time plant state through sensor dashboards, alarm management systems, and historical trend analysis, capabilities that are already commercially available and deployed at many full-scale MBR installations [5,15]. The rapid growth of DT research in the water sector supports this framing. A recent review of 147 studies spanning 2015 to May 2025 found that DT publications in the sector grew from one in 2015 to 41 in 2024 [60]. Of those 147 studies, 41 addressed wastewater treatment.

và hiểu biết về cơ chế quy trình thành một công cụ vận hành được cập nhật liên tục. Công nghệ bản sao số cung cấp chính xác lớp tích hợp này, và việc ứng dụng công nghệ này vào các hệ thống MBR sẽ được xem xét trong phần tiếp theo.

Bảng 4. Các chuẩn năng lượng đã được xác nhận và bằng chứng tối ưu hóa cho hệ thống MBR.

Scale	Method	Key Finding	Confirmed Energy Metric	Reference
Full-scale	Mechanistic energy model	Model validated within 20% of all plant parameters	Aeration: 0.4–0.8 kWh/m ³	[56]
BSM-MBR simulation	ASM scenario optimization	Energy reduced by SRT/recirculation tuning	Pilot baseline: 0.73 kWh/m ³	[14]
Multiple full-scale	Empirical survey	Benchmarking across diverse MBR plants	Typical range: 0.8–1.1 kWh/m ³	[15]
Full-scale	ASM + PI feedback control	Dynamic aeration control reduced blower demand 20%	Total: 0.45 kWh/m ³ (−20% aeration)	[59]

6. Các khung bản sao số cho hệ thống MBR

6.1. Architecture, Components, and Maturity Tiers

Khái niệm bản sao số lần đầu tiên được Grieves chính thức đề xuất trong lĩnh vực sản xuất [30] và kể từ đó đã được mở rộng sang nhiều lĩnh vực công nghiệp khác nhau, bao gồm hàng không vũ trụ, hạ tầng năng lượng và sản xuất thông minh [32]. Fuller và cộng sự xác định ba thành phần thiết yếu có mặt trong các triển khai bản sao số công nghiệp: một thực thể vật lý được trang bị thiết bị cảm biến và cơ cấu chấp hành; một thực thể ảo mô hình hóa hệ thống vật lý trên các thang thời gian liên quan; và một lớp kết nối dữ liệu cho phép đồng bộ hóa trạng thái liên tục giữa các miền vật lý và ảo [31]. Thực thể ảo phải có độ trung thực đa mức. Nó kết hợp các mô hình dựa trên vật lý có độ chính xác cao cho những trạng thái hệ thống biến đổi chậm với các mô hình dựa trên dữ liệu nhanh hơn cho các biến vận hành động. Sự cân bằng này vừa đảm bảo tính khả thi về mặt tính toán vừa duy trì độ chính xác dự báo [33].

Đối với các hệ thống MBR, khung DT này gồm ba lớp. Lớp thứ nhất là nhà máy vật lý: mạng SCADA, các cảm biến trực tuyến (DO, độ đục, bộ chuyển đổi áp suất, lưu lượng kế) và các cơ cấu chấp hành (máy thổi khí, máy bơm, van). Lớp thứ hai là mô hình ảo phân cấp, tích hợp các mô hình phụ cơ chế ASM [34,35], mô hình cấu bản điện trở nối tiếp [36], các bộ dự báo TMP động dựa trên ML được huấn luyện bằng dữ liệu vận hành [22,26], các mô-đun quy thuộc đặc trưng dựa trên SHAP [53] và các mô hình phụ cân bằng năng lượng [14,56]. Lớp thứ ba là quy trình dữ liệu thời gian thực, có thể được lưu trữ trên đám mây, đồng bộ hóa số liệu cảm biến với mô hình ảo và đưa đầu ra của mô hình trở lại hệ thống điều khiển [37]. Wang và cộng sự tổng quan các ứng dụng DT trong toàn bộ vòng đời xử lý nước thải, xác định quản lý cấu bản MBR và tối ưu hóa sục khí là những mục tiêu tích hợp có giá trị cao nhất, đồng thời chứng minh rằng các phương pháp DT có thể giúp tiết kiệm năng lượng trên toàn nhà máy và cải thiện chất lượng nước thải đầu ra thông qua tối ưu hóa phối hợp các quy trình phụ về sinh học, lọc và chặm hóa chất.

Trong thực tế, các hệ thống bản sao số MBR có thể được phân thành ba cấp độ năng lực, phản ánh mức độ tích hợp và khả năng ra quyết định tự chủ ngày càng cao. Bản sao cấp I (mô tả) giám sát và trực quan hóa trạng thái nhà máy theo thời gian thực thông qua bảng điều khiển cảm biến, hệ thống quản lý cảnh báo và phân tích xu hướng lịch sử; đây là những năng lực hiện đã có trên thị trường và được triển khai tại nhiều cơ sở MBR quy mô đầy đủ [5,15]. Sự phát triển nhanh chóng của nghiên cứu về bản sao số trong lĩnh vực nước củng cố cách phân loại này. Một tổng quan gần đây về 147 nghiên cứu trong giai đoạn từ năm 2015 đến tháng 5 năm 2025 cho thấy số công bố về bản sao số trong lĩnh vực này tăng từ một bài năm 2015 lên 41 bài năm 2024 [60]. Trong số 147 nghiên cứu đó, 41 nghiên cứu đề cập đến xử lý nước thải.

This growth confirms that DT technology is moving from conceptual proposals toward structured implementation frameworks. Rodríguez-Alonso et al. demonstrated a practical microservices-based DT platform for a full wastewater treatment plant. It provides a concrete Tier I/II deployment reference using edge computing architecture [61]. Tier II (Predictive) twins forecast future plant states using trained ML models, including TMP trajectory, effluent quality, and energy demand 12–72 h ahead. This enables proactive rather than reactive operational decisions. This tier has been demonstrated in BSM-MBR simulation studies [24,36] and validated in isolation with full-scale data [26]. Tier III (Prescriptive) twins autonomously generate, evaluate, and implement operational decisions. These include aeration setpoint adjustments, flux control, and cleaning schedule optimization. Closed-loop simulation evaluates predicted consequences before any physical action is taken. No full-scale MBR implementation of Tier III with XAI integration has been documented in the literature, representing the primary frontier for the field [33,37].

6.2. XAI Integration in Digital Twin Decision Architecture

One of the most important architectural advances in higher-maturity MBR digital twins is the integration of explainable AI (XAI) modules as decision-support and transparency layers between the prediction engine and downstream human or control actions, improving interpretability, trust, and operational usability [62,63]. This explanation can be presented to the operator in interpretable visual formats such as a SHAP waterfall chart or a local ranked bar plot. It may also be translated into user-oriented summary text, enabling the operator to assess whether the prediction is plausible given the current process state before deciding whether to act on it [64].

First, within future DT-enabled MBR control architectures, the XAI layer could provide a near-real-time audit trail by logging the explanatory context associated with model-informed recommendations, thereby improving traceability, accountability, and post hoc review during internal audits, compliance assessments, or regulatory inspections [65]. Second, it enables informed operator override. Rather than simply accepting or rejecting an ML recommendation, operators can use the SHAP attribution to identify which specific variables are driving the prediction. They can then assess whether those variables reflect the true process state or a measurement artefact, enabling informed human oversight rather than blind rejection [17,66]. Third, shifts in explanation patterns, such as marked changes in SHAP ranking distributions, may also serve as interpretable warning signals of concept drift or operation outside the model's familiar regime, thereby triggering human review before continued automated control [48,67].

The data and decision flow within a Tier II/III MBR digital twin with embedded XAI operates through five stages. In the first stage, raw sensor streams, including dissolved oxygen, transmembrane pressure, permeate flux, turbidity, temperature, and membrane aeration flow rate, are transmitted from the physical plant via SCADA at one-minute intervals to the DT data layer, where they are quality-checked, gap-filled by interpolation, and stored in a time-series database. In the second stage, a trained ML prediction engine, such as a random forest or LSTM model for TMP forecasting and a gradient boosting model for effluent quality estimation, generates predictions 12 to 72 h ahead from the current and recent sensor history. In the third stage, a SHAP-based explanation module computes per-feature attribution values for each prediction in real time, producing a ranked contribution plot that identifies which process variables are driving the current forecast and by how much. In the fourth stage, both the prediction and its SHAP explanation are presented on an interpretable operator dashboard, enabling informed human review before any control action is executed. In the fifth stage, accepted recommendations are passed to the control layer, which adjusts aeration setpoints, flux targets, or cleaning schedules

Sự phát triển này xác nhận rằng công nghệ DT đang chuyển từ các đề xuất mang tính khái niệm sang những khuôn khổ triển khai có cấu trúc. Rodríguez-Alonso và cộng sự đã giới thiệu một nền tảng DT thực tiễn dựa trên vi dịch vụ cho toàn bộ nhà máy xử lý nước thải. Nền tảng này cung cấp một tham chiếu triển khai Tier I/II cụ thể sử dụng kiến trúc điện toán biên [61]. Các bản sao Tier II (Dự đoán) dự báo trạng thái tương lai của nhà máy bằng các mô hình ML đã huấn luyện, bao gồm diễn biến TMP, chất lượng nước đầu ra và nhu cầu năng lượng trong khoảng thời gian trước 12–72 giờ. Nhờ đó, các quyết định vận hành mang tính chủ động thay vì phản ứng. Cấp độ này đã được chứng minh trong các nghiên cứu mô phỏng BSM-MBR [24,36] và được xác thực riêng biệt bằng dữ liệu toàn quy mô [26]. Các bản sao Tier III (Đề xuất) tự động tạo ra, đánh giá và thực hiện các quyết định vận hành. Những quyết định này bao gồm điều chỉnh điểm đặt sức khí, kiểm soát thông lượng và tối ưu hóa lịch làm sạch. Mô phỏng vòng kín đánh giá các hệ quả dự đoán trước khi thực hiện bất kỳ hành động thực tế nào. Trong các tài liệu hiện có, chưa ghi nhận triển khai MBR toàn quy mô nào thuộc Tier III có tích hợp XAI; đây là hướng tiên phong chính của lĩnh vực [33,37].

6.2. XAI Integration in Digital Twin Decision Architecture

Một trong những bước tiến quan trọng nhất về kiến trúc trong các bản sao số MBR có độ trưởng thành cao hơn là tích hợp các mô-đun AI có khả năng giải thích (XAI) làm lớp hỗ trợ ra quyết định và minh bạch giữa công cụ dự đoán với các hành động tiếp theo của con người hoặc hệ thống điều khiển, qua đó cải thiện khả năng diễn giải, độ tin cậy và tính hữu dụng trong vận hành [62,63]. Phần giải thích này có thể được trình bày cho người vận hành bằng các định dạng trực quan dễ diễn giải, chẳng hạn như biểu đồ thác nước SHAP hoặc biểu đồ thanh xếp hạng cục bộ. Nội dung này cũng có thể được chuyển thành văn bản tóm tắt hướng đến người dùng, giúp người vận hành đánh giá liệu dự đoán có hợp lý xét theo trạng thái hiện tại của quy trình hay không trước khi quyết định có hành động dựa trên dự đoán đó [64].

Thứ nhất, trong các kiến trúc điều khiển MBR tích hợp DT trong tương lai, lớp XAI có thể cung cấp nhật ký kiểm toán gần như theo thời gian thực bằng cách ghi lại bối cảnh giải thích liên quan đến các khuyến nghị dựa trên mô hình, qua đó cải thiện khả năng truy xuất nguồn gốc, trách nhiệm giải trình và rà soát hậu kiểm trong các cuộc kiểm toán nội bộ, đánh giá tuân thủ hoặc thanh tra theo quy định [65]. Thứ hai, lớp này cho phép người vận hành đưa ra quyết định ghi đề có căn cứ. Thay vì chỉ chấp nhận hoặc bác bỏ một khuyến nghị của ML, người vận hành có thể sử dụng phương pháp quy kết SHAP để xác định những biến cụ thể nào đang chi phối dự đoán. Sau đó, họ có thể đánh giá liệu các biến đó phản ánh trạng thái thực của quy trình hay chỉ là sai lệch đo lường, nhờ đó hỗ trợ giám sát của con người dựa trên thông tin thay vì bác bỏ một cách máy móc [17,66]. Thứ ba, những thay đổi trong các dạng thức giải thích, chẳng hạn như biến động rõ rệt trong phân bố thứ hạng SHAP, cũng có thể đóng vai trò là tín hiệu cảnh báo để diễn giải về hiện tượng trôi dạt khái niệm hoặc hoạt động ngoài phạm vi quen thuộc của mô hình, từ đó kích hoạt việc con người rà soát trước khi tiếp tục điều khiển tự động [48,67].

Luồng dữ liệu và ra quyết định bên trong bản sao số MBR Tier II/III có tích hợp XAI diễn ra qua năm giai đoạn. Ở giai đoạn đầu tiên, các luồng dữ liệu cảm biến thô, bao gồm oxy hòa tan, áp suất xuyên màng, thông lượng nước thẩm, độ đục, nhiệt độ và lưu lượng sức khí màng, được truyền từ nhà máy vật lý qua SCADA theo chu kỳ một phút đến lớp dữ liệu DT, nơi chúng được kiểm tra chất lượng, lấp đầy dữ liệu thiếu bằng nội suy và lưu trữ trong cơ sở dữ liệu chuỗi thời gian. Ở giai đoạn thứ hai, một công cụ dự đoán ML đã được huấn luyện, chẳng hạn như mô hình rừng ngẫu nhiên hoặc LSTM để dự báo TMP và mô hình tăng cường gradient để ước tính chất lượng nước đầu ra, tạo dự đoán trước từ 12 đến 72 giờ dựa trên dữ liệu cảm biến hiện tại và gần đây. Ở giai đoạn thứ ba, mô-đun giải thích dựa trên SHAP tính toán các giá trị quy kết cho từng đặc trưng của mỗi dự đoán theo thời gian thực, tạo ra biểu đồ đóng góp được xếp hạng, cho biết những biến quy trình nào đang chi phối dự báo hiện tại và mức độ ảnh hưởng của chúng. Ở giai đoạn thứ tư, cả dự đoán lẫn phần giải thích SHAP đều được hiển thị trên bảng điều khiển để diễn giải dành cho người vận hành, giúp con người xem xét có căn cứ trước khi thực thi bất kỳ hành động điều khiển nào. Ở giai đoạn thứ năm, các khuyến nghị được chấp thuận sẽ được chuyển đến lớp điều khiển, nơi điều chỉnh các điểm đặt sức khí, mục tiêu thông lượng hoặc lịch vệ sinh.

as required, and the prediction, together with its explanation, is automatically logged to an audit trail for regulatory traceability and post-event review. This architecture ensures that XAI is structurally embedded in the decision pipeline rather than functioning as an optional post-hoc module.

Tao et al. [32] and Barricelli et al. [33] both identify interpretability as a fundamental design requirement for trustworthy industrial digital twins. They note that unexplained model recommendations under novel process conditions, even if quantitatively correct, will be systematically overridden by conservative operators. This negates the operational value of the twin. The incorporation of XAI into DT architecture is therefore not merely a regulatory convenience but a functional requirement for achieving the operator trust necessary for the transition from Tier II advisory to Tier III prescriptive operation. The convergence of ML prediction, XAI transparency, and mechanistic model consistency checking within a unified DT architecture represents the most complete available framework for intelligent, trustworthy MBR operation at the current state of the art [37]. Table 5 presents a structured overview of the three DT maturity tiers applicable to MBR systems, from descriptive monitoring through to closed-loop prescriptive control.

Table 5. Digital twin maturity tiers for MBR systems with capability and implementation characteristics.

Tier	Capabilities	Data Requirements	Implementation Complexity	Status in MBR Literature	References
I—Descriptive	Real-time monitoring, dashboards, alarm management	SCADA, online sensors	Low	Commercially deployed	[5,15]
II—Predictive	TMP forecast, effluent quality prediction, fault detection, 12–72 h ahead	SCADA + lab analytics + trained ML	Medium	Validated in simulation and full-scale data	[24,26,36]
III—Prescriptive	Closed-loop autonomous optimization, what-if scenario testing, XAI decision justification	Full DT + actuators + XAI + safety validation	High	No full-scale MBR deployment documented	[33,37]

The three tiers can also be characterized by their evidence status. Tier I is commercially deployed at full municipal and industrial scale worldwide [5,15] and therefore represents validated operational technology. Tier II has been demonstrated in BSM-MBR simulation studies [36] and validated using full-scale SCADA datasets (Kovacs et al., 2022 [26]), but has not yet been deployed as a continuously operating closed-loop advisory system in a commissioned plant; its evidence status is therefore simulation-to-full-scale data validation. Tier III remains at the conceptual and architectural proposal stage: no full-scale MBR implementation combining Tier III prescriptive control with integrated XAI decision justification has been documented in the peer-reviewed literature as of December 2025. The transition from Tier II to Tier III represents the field’s primary frontier and is directly linked to the research gaps discussed in Section 7.

To synthesize the current state of the field across application domains and deployment dimensions, Figure 3 presents a qualitative heat map of research maturity for ML, XAI, and digital twin applications in wastewater MBR systems.

theo yêu cầu, và dự đoán cùng với phần giải thích được tự động ghi vào dấu vết kiểm m toán nhằm đảm bảo khả năng truy xuất nguồn gốc phục vụ tuân thủ quy định và rà soát sau sự kiện. Kiến trúc này đảm bảo XAI được tích hợp về mặt cấu trúc vào quy trình ra quyết định, thay vì hoạt động như một mô-đun hậu kiểm tùy chọn.

Tao và cộng sự [32] cùng Barricelli và cộng sự [33] đều xác định khả năng diễn g iải là một yêu cầu thiết kế cơ bản đối với bản sao số công nghiệp đáng tin cậy. Họ lư u ý rằng các khuyến nghị của mô hình không được giải thích trong những điều kiện quy trình mới, ngay cả khi đúng về mặt định lượng, sẽ luôn bị những người vận hàn h thận trọng bác bỏ. Điều này làm mất đi giá trị vận hành của bản sao số. Vì vậy, việc tích hợp XAI vào kiến trúc DT không chỉ là một biện pháp thuận tiện để đáp ứng quy định mà còn là yêu cầu chức năng nhằm xây dựng lòng tin cần thiết của người vận h ành để chuyển từ vận hành tư vấn Cấp II sang vận hành chỉ định Cấp III. Sự hội tụ củ a khả năng dự đoán bằng ML, tính minh bạch của XAI và việc kiểm tra tính nhất quá n của mô hình cơ chế trong một kiến trúc DT thống nhất là khuôn khổ toàn diện nhấ t hiện có để vận hành MBR thông minh và đáng tin cậy theo trình độ tiên tiến hiện n ay [37]. Bảng 5 trình bày tổng quan có cấu trúc về ba cấp độ trưởng thành của DT áp dụng cho các hệ thống MBR, từ giám sát mô tả đến điều khiển chỉ định vòng kín.

Bảng 5. Các cấp độ trưởng thành của bản sao số cho hệ thống MBR, cùng các đặc điểm về năng lực và

Tier	Capabilities	Data Requirements	Implementation Complexity	Status in MBR Literature	References
I—Descriptive	Real-time monitoring, dashboards, alarm management	SCADA, online sensors	Low	Commercially deployed	[5,15]
II—Predictive	TMP forecast, effluent quality prediction, fault detection, 12–72 h ahead	SCADA + lab analytics + trained ML	Medium	Validated in simulation and full-scale data	[24,26,36]
III—Prescriptive	Closed-loop autonomous optimization, what-if scenario testing, XAI decision justification	Full DT + actuators + XAI + safety validation	High	No full-scale MBR deployment documented	[33,37]

Ba cấp độ cũng có thể được phân loại theo tình trạng bằng chứng. Cấp I đã đượ c triển khai thương mại ở quy mô toàn diện tại các đô thị và cơ sở công nghiệp trên t oàn thế giới [5,15], do đó là công nghệ vận hành đã được kiểm chứng. Cấp II đã đượ c chứng minh trong các nghiên cứu mô phỏng BSM-MBR [36] và được xác thực bằng các bộ dữ liệu SCADA quy mô toàn diện (Kovacs và cộng sự, 2022 [26]), nhưng vẫn c hưa được triển khai như một hệ thống tư vấn vòng kín vận hành liên tục tại một nhà máy đã đi vào hoạt động; do đó, tình trạng bằng chứng của cấp này là xác thực dữ li ệu từ mô phỏng đến quy mô toàn diện. Cấp III vẫn ở giai đoạn đề xuất khái niệm và kiến trúc: tính đến tháng 12 năm 2025, chưa có tài liệu nào trong các ấn phẩm khoa học bình duyệt ghi nhận việc triển khai MBR quy mô toàn diện kết hợp điều khiển m ang tính chỉ định cấp III với cơ chế giải trình quyết định XAI tích hợp. Quá trình chuy ển đổi từ cấp II sang cấp III là ranh giới phát triển trọng yếu của lĩnh vực và gắn trực tiếp với các khoảng trống nghiên cứu được thảo luận tại Mục 7.

Để tổng hợp tình hình hiện tại của lĩnh vực này trên các miền ứng dụng và khía cạnh triển khai, Hình 3 trình bày bản đồ nhiệt định tính về mức độ trưởng thành của nghiên cứu đối với các ứng dụng ML, XAI và bản sao số trong các hệ thống MBR xử l ý nước thải.





Figure 3. Research maturity heat map for intelligent wastewater membrane bioreactor (MBR) studies. The figure provides a qualitative synthesis of the reviewed literature across major application domains and deployment dimensions, indicating that fouling prediction is the most mature area.

In the heat map, each cell represents a qualitative maturity rating based on three criteria: the volume of peer-reviewed evidence available, the availability of full-scale operational validation, and the extent of documented deployment in commissioned water treatment facilities. High-rated cells indicate substantial evidence base supported by multiple independent studies with consistent results. Moderate-rated cells indicate an emerging evidence base that includes at least some pilot or full-scale validation. Emerging cells indicate that the application area is recognized, but evidence is confined to conceptual proposals, simulation studies, or a small number of laboratory-scale demonstrations. Low-rated cells indicate that no peer-reviewed evidence for that combination was identified in the structured search.

Three patterns are immediately apparent. First, fouling prediction shows the strongest evidence base and predictive maturity, both rated High, reflecting the substantial body of ML literature reviewed in Section 3. Nevertheless, its interpretability integration, full-scale validation, and deployment readiness are all rated Emerging, indicating that predictive capability has substantially outpaced practical implementation. Second, XAI-supported interpretation shows a high-rating for interpretability integration, as expected for a technology whose primary function is interpretability, but Low full-scale validation and Emerging deployment readiness, confirming that XAI application in MBR systems remains largely an academic exercise. Third, digital twin deployment shows the lowest overall maturity profile, with Emerging or Low ratings across all five dimensions, reflecting the absence of full-scale operational deployments documented in the peer-reviewed literature. Each low-maturity cell in the figure maps directly to one or more of the nine research gaps identified in Section 7, providing a visual roadmap for prioritizing future research investment.

7. Research Gaps and Future Directions

This review reveals nine interconnected research gaps whose resolution is necessary before XAI-DT integration can achieve operational deployment at scale in MBR facilities. The first five gaps were identified in the original review. Four additional gaps were identified in response to reviewer comments and are presented as Gaps 6 through 9.



Hình 3. Bản đồ nhiệt về mức độ trưởng thành của nghiên cứu trong các nghiên cứu về bể phản ứng sinh học màng xử lý nước thải thông minh (MBR). Hình này tổng hợp định tính các tài liệu đã được rà soát theo những lĩnh vực ứng dụng chính và các khía cạnh triển khai, cho thấy dự đoán tắc nghẽn màng là lĩnh vực trưởng thành nhất.

Trong bản đồ nhiệt, mỗi ô thể hiện mức độ trưởng thành định tính dựa trên ba tiêu chí: khối lượng bằng chứng đã qua bình duyệt, mức độ sẵn có của hoạt động kiểm chứng vận hành quy mô toàn diện và phạm vi triển khai được ghi nhận tại các cơ sở xử lý nước đang hoạt động. Các ô được đánh giá cao cho thấy có nền tảng bằng chứng đáng kể, được củng cố bởi nhiều nghiên cứu độc lập với kết quả nhất quán. Các ô được đánh giá ở mức trung bình cho thấy nền tảng bằng chứng đang hình thành, bao gồm ít nhất một số hoạt động kiểm chứng ở quy mô thí điểm hoặc quy mô toàn diện. Các ô ở mức sơ khai cho thấy lĩnh vực ứng dụng đã được ghi nhận, nhưng bằng chứng chỉ giới hạn ở các đề xuất khái niệm, nghiên cứu mô phỏng hoặc một số ít thử nghiệm quy mô phòng thí nghiệm. Các ô được đánh giá thấp cho thấy không tìm thấy bằng chứng đã qua bình duyệt nào cho tổ hợp đó trong quá trình tìm kiếm có cấu trúc.

Ba xu hướng nổi bật ngay lập tức. Thứ nhất, dự đoán tắc nghẽn có nền tảng bằng chứng và mức độ hoàn thiện về dự báo vững chắc nhất, cả hai đều được đánh giá ở mức Cao, phản ánh khối lượng lớn tài liệu về học máy đã được tổng quan trong Mục 3. Tuy nhiên, mức độ tích hợp khả năng diễn giải, xác thực ở quy mô toàn diện và mức độ sẵn sàng triển khai đều được đánh giá là Đang phát triển, cho thấy năng lực dự báo đã tiến xa hơn đáng kể so với việc triển khai thực tiễn. Thứ hai, diễn giải có hỗ trợ XAI được đánh giá cao về mức độ tích hợp khả năng diễn giải, đúng như kỳ vọng đối với một công nghệ có chức năng chính là diễn giải; tuy nhiên, việc xác thực ở quy mô toàn diện ở mức Thấp và mức độ sẵn sàng triển khai ở mức Đang phát triển, xác nhận rằng ứng dụng XAI trong các hệ thống MBR phần lớn vẫn là hoạt động học thuật. Thứ ba, triển khai bản sao số có hồ sơ mức độ hoàn thiện tổng thể thấp nhất, với các đánh giá Đang phát triển hoặc Thấp trên cả năm phương diện, phản ánh việc chưa có triển khai vận hành quy mô toàn diện nào được ghi nhận trong tài liệu bình duyệt. Mỗi ô có mức độ hoàn thiện thấp trong hình tương ứng trực tiếp với một hoặc nhiều trong số chín khoảng trống nghiên cứu được xác định ở Mục 7, tạo nên lộ trình trực quan giúp ưu tiên đầu tư cho nghiên cứu trong tương lai.

7. Khoảng trống nghiên cứu và định hướng tương lai

Bài tổng quan này chỉ ra chín khoảng trống nghiên cứu có mối liên hệ với nhau, cần được giải quyết trước khi có thể triển khai vận hành tích hợp XAI-DT trên quy mô lớn tại các cơ sở MBR. Năm khoảng trống đầu tiên được xác định trong bài tổng quan ban đầu. Bốn khoảng trống bổ sung được xác định dựa trên ý kiến của người phản biện và được trình bày dưới dạng Khoảng trống 6 đến 9.

The first and most fundamental gap is the scarcity of benchmark datasets. The vast majority of reviewed studies trained and validated models on single-facility datasets, typically collected over weeks to months, precluding evaluation of cross-site generalization. When models trained on one MBR installation are applied to a second facility with a different membrane module configuration, influent composition, or operating regime, performance typically degrades significantly, a consequence of a dataset shift documented in the broader ML environmental engineering literature. The wastewater ML community currently lacks the equivalent of the standardized benchmark datasets that enabled rapid, systematic progress in computer vision, natural language processing, and genomics over the past decade. The development of openly accessible, multi-facility MBR operational datasets encompassing diverse scales, configurations, wastewater types, and climate zones is a key requirement for rigorously evaluating and improving ML model generalizability [17,24,47]. The BSM-MBR platform [36,50] provides a valuable simulation-based benchmark. However, simulation data remain valuable for benchmarking, but they do not fully reproduce the non-stationary, noisy, and operationally constrained conditions of real plant data.

Beyond dataset size, the capacity for cross-site generalization poses an equally fundamental challenge. When a model trained at one MBR installation is applied to a second facility operating under different conditions, predictive performance typically degrades because the statistical relationship between input features and fouling outcomes differs between plants in ways that single-site training data cannot capture. Dataset shift has several primary sources. These include differences in membrane module geometry between hollow-fiber and flat-sheet configurations, sludge microbiology shaped by local wastewater composition and temperature, and the specific SRT and HRT operating windows maintained at each facility. Industrial trade waste discharge events, which introduce rapid and large disturbances not captured in routine training data, are another key source. Transfer learning, in which a model pre-trained on a data-rich source facility is fine-tuned using a small amount of data from a target plant, and domain adaptation, which explicitly minimizes the distributional discrepancy between the source and target feature spaces, offer practical methodological pathways toward generalizable MBR ML models. Both approaches have demonstrated success in related environmental engineering and water quality monitoring applications [17,47]. They should be prioritized in future multi-facility MBR studies, ideally using openly accessible benchmark datasets as the shared testbed.

The second gap is the near-universal absence of uncertainty quantification in MBR ML predictions. Very few reviewed studies reported prediction intervals or confidence bounds alongside point estimates. This is a critical gap, since uncertainty is directly actionable in operational contexts. A control system with a TMP forecast uncertainty of ± 2 kPa will respond differently than one facing ± 12 kPa uncertainty. Yet the current literature overwhelmingly provides only deterministic point predictions. Bayesian neural networks, which maintain probability distributions over network weights rather than point estimates, provide principled uncertainty quantification but are computationally demanding; conformal prediction methods, which provide distribution-free coverage guarantees under exchangeability assumptions, offer a computationally efficient alternative increasingly used in safety-critical engineering applications [28,48]. Neither approach has been systematically evaluated in the MBR ML context. For Tier III prescriptive DT operation, where control decisions are executed, automatically calibrated uncertainty bounds are not merely desirable but operationally essential for safe autonomous control.

The third gap is the lack of full-scale DT deployments with integrated XAI. Of the DT-focused publications identified in this review, all described simulation-based or laboratory-scale frameworks; none documented a complete Tier II or Tier III DT implementation at full municipal scale with contemporaneous XAI explanation generation and operator

Khoảng trống đầu tiên và căn bản nhất là sự khan hiếm các bộ dữ liệu chuẩn. Đa số các nghiên cứu được rà soát đã huấn luyện và xác thực mô hình trên các bộ dữ liệu từ một cơ sở duy nhất, thường được thu thập trong vài tuần đến vài tháng, khiến việc đánh giá khả năng khái quát hóa giữa các cơ sở không thể thực hiện được. Khi các mô hình được huấn luyện trên một hệ thống MBR được áp dụng cho cơ sở thứ hai có cấu hình mô-đun màng, thành phần nước đầu vào hoặc chế độ vận hành khác biệt, hiệu năng thường suy giảm đáng kể; đây là hệ quả của sự dịch chuyển dữ liệu đã được ghi nhận trong các tài liệu rộng hơn về học máy trong kỹ thuật môi trường. Hiện nay, cộng đồng học máy trong lĩnh vực nước thải chưa có những bộ dữ liệu huấn luyện tương đương với các bộ dữ liệu đã thúc đẩy tiến bộ nhanh chóng và có hệ thống trong thị giác máy tính, xử lý ngôn ngữ tự nhiên và hệ gen trong thập kỷ qua. Việc phát triển các bộ dữ liệu vận hành MBR đa cơ sở, có thể truy cập công khai, bao quát nhiều quy mô, cấu hình, loại nước thải và vùng khí hậu khác nhau, là yêu cầu then chốt để đánh giá và cải thiện một cách nghiêm ngặt khả năng khái quát hóa của mô hình học máy [17,24,47]. Nền tảng BSM-MBR [36,50] cung cấp một bộ dữ liệu chuẩn có giá trị dựa trên mô phỏng. Tuy nhiên, dù dữ liệu mô phỏng vẫn có giá trị cho việc đánh giá chuẩn, chúng không thể tái hiện đầy đủ các điều kiện phi dừng, nhiễu và chịu nhiều ràng buộc vận hành của dữ liệu từ nhà máy thực tế.

Ngoài quy mô tập dữ liệu, khả năng khái quát hóa xuyên cơ sở đặt ra một thách thức cơ bản không kém. Khi một mô hình được huấn luyện tại một cơ sở MBR được áp dụng cho cơ sở thứ hai hoạt động trong các điều kiện khác biệt, hiệu suất dự đoán thường suy giảm vì mối quan hệ thống kê giữa các đặc trưng đầu vào và kết quả bám bẩn khác nhau giữa các nhà máy theo những cách mà dữ liệu huấn luyện tại một cơ sở không thể nắm bắt. Sự dịch chuyển dữ liệu có một số nguồn chính. Trong đó có sự khác biệt về hình học mô-đun màng giữa cấu hình sợi rỗng và màng tấm phẳng; hệ vi sinh bùn chịu ảnh hưởng của thành phần nước thải và nhiệt độ tại địa phương; cũng các khoảng vận hành SRT và HRT cụ thể được duy trì tại mỗi cơ sở. Các sự kiện xả thải công nghiệp, vốn gây ra những nhiễu động lớn và đột ngột mà dữ liệu huấn luyện thường quy không ghi nhận, cũng là một nguồn quan trọng khác. Học chuyển giao, trong đó mô hình được tiền huấn luyện trên một cơ sở nguồn giàu dữ liệu rồi tinh chỉnh bằng một lượng nhỏ dữ liệu từ nhà máy đích, và thích nghi miền, phương pháp chủ động giảm thiểu sai khác phân phối giữa không gian đặc trưng của miền nguồn và miền đích, mở ra những hướng tiếp cận thực tiễn để phát triển các mô hình ML cho MBR có khả năng khái quát hóa. Cả hai phương pháp đều đã cho thấy hiệu quả trong các ứng dụng liên quan về kỹ thuật môi trường và giám sát chất lượng nước [17,47]. Cần ưu tiên các phương pháp này trong những nghiên cứu MBR đa cơ sở trong tương lai, lý tưởng nhất là sử dụng các bộ dữ liệu chuẩn có thể truy cập công khai làm môi trường thử nghiệm chung.

Khoảng trống thứ hai là việc hầu như không có nghiên cứu nào định lượng độ bất định trong các dự đoán MBR bằng ML. Rất ít nghiên cứu được rà soát báo cáo khoảng dự đoán hoặc giới hạn tin cậy bên cạnh các ước lượng điểm. Đây là một khoảng trống nghiêm trọng, vì độ bất định có thể được xử lý trực tiếp trong các bối cảnh vận hành. Một hệ thống điều khiển đối mặt với độ bất định trong dự báo TMP là ± 2 kPa sẽ phản ứng khác với hệ thống đối mặt với độ bất định ± 12 kPa. Tuy nhiên, các tài liệu hiện có phần lớn chỉ đưa ra những dự đoán điểm mang tính tất định. Mạng nơ-ron Bayes, duy trì các phân phối xác suất trên trọng số của mạng thay vì các ước lượng điểm, cung cấp phương pháp định lượng độ bất định có cơ sở vững chắc nhưng đòi hỏi nhiều tài nguyên tính toán; các phương pháp dự đoán conformal, đưa ra bảo đảm độ bao phủ không phụ thuộc vào phân phối trong các giả định về tính trao đổi được, là một lựa chọn thay thế hiệu quả về tính toán và ngày càng được sử dụng trong các ứng dụng kỹ thuật trọng yếu về an toàn [28,48]. Chưa có phương pháp nào trong hai phương pháp này được đánh giá một cách có hệ thống trong bối cảnh MBR-ML. Đối với vận hành DT mang tính quy định ở Cấp III, nơi các quyết định điều khiển được thực thi, các giới hạn bất định được hiệu chuẩn tự động không chỉ đáng mong muốn mà còn thiết yếu về mặt vận hành để bảo đảm điều khiển tự chủ an toàn.

Khoảng trống thứ ba là thiếu các triển khai DT quy mô đầy đủ có tích hợp XAI. Trong số các ấn phẩm tập trung vào DT được xác định trong bài tổng quan này, tất cả đều mô tả các khuôn khổ dựa trên mô phỏng hoặc ở quy mô phòng thí nghiệm; không ấn phẩm nào ghi nhận việc triển khai DT Tier II hoặc Tier III hoàn chỉnh ở quy mô toàn đô thị, với khả năng tạo lời giải thích XAI đồng thời và sự tham gia của người vận hành.

integration. The infrastructure requirements for full-scale deployment are substantial and multidimensional. Technical requirements include sensor calibration, data pipeline reliability, computational infrastructure, and cybersecurity. Organizational requirements include operator training, change management, and contractual liability frameworks for automated control. These organizational factors have not been well documented in the academic literature [33,37]. Structured collaboration between water utilities, technology providers, and academic research groups of the kind that has produced the full-scale ML validation work of Kovacs et al. [26] is needed to generate the deployment evidence base that will underpin regulatory and commercial adoption.

The fourth gap concerns dynamic influent characterization. Standard SCADA instrumentation measures bulk wastewater quality parameters (COD, BOD, TSS, turbidity, DO, pH, and conductivity) that provide only an aggregate characterization of the mixed liquor entering the biological system. Industrial trade waste discharge events, stormwater infiltration during rainfall, and diurnal variation in domestic sewage composition all introduce rapid, large-magnitude changes in influent characteristics that are poorly represented by daily composite samples or slow-response online sensors [3,22]. These uncharacterized disturbances are a primary source of MBR fouling events that are difficult to predict from standard sensor arrays. Integration of high-frequency online spectroscopic sensors (UV-Vis, fluorescence spectrophotometry), emerging optical coherence tomography for real-time cake layer characterization, and even molecular tools for microbial community fingerprinting into the DT sensor layer would substantially improve dynamic influent characterization and ML model predictive coverage of these high-consequence disturbance events.

The fifth gap concerns the regulatory dimension of XAI adoption. The theoretical case for XAI as a tool for building regulatory trust in ML-based water system management is well-developed in the academic literature [29,51]. However, no published study has empirically documented a case where SHAP explanations or equivalent XAI outputs directly influenced a permit condition, regulatory inspection outcome, operational license amendment, or other formal regulatory action in the water sector. This represents a critical missing link between the technical capability demonstrated in academic research and the regulatory permission structures that govern operational water systems. Proactive engagement between the water engineering community and environmental regulators to develop agreed-upon evidence standards for XAI validation, define acceptable use cases for automated ML-based control, and establish audit-trail requirements is a prerequisite for the transition from research demonstration to licensed operational deployment that the field currently needs. A sixth gap concerns the economic cost of ML model development and retraining. Developing a production-grade ML model for an MBR plant requires data infrastructure, engineering expertise, and computational resources. Retraining costs recur whenever influent characteristics shift, membrane modules are replaced, or plant configuration changes. These costs are rarely reported in academic studies. Future work should document the full cost of model development, validation, and maintenance cycles. This information is essential for water utilities evaluating whether ML-based control is economically justified relative to simpler alternatives. To contextualise this gap, a realistic deployment cost structure for an ML-based fouling prediction system at a medium-sized MBR plant includes the following components. Initial development covers sensor audit and data infrastructure (typically several months of SCADA historian cleanup), model development and cross-validation, and regulatory documentation for process change approval. Ongoing costs include periodic model retraining, edge computing hardware, IT security, and operator training. No peer-reviewed study has yet reported a full cost–benefit analysis for a deployed ML system in an MBR plant. This absence of data is itself a finding. Future studies should report total development cost, validation cost, and annual

tích hợp. Các yêu cầu về cơ sở hạ tầng để triển khai trên quy mô toàn diện rất đáng kể và đa chiều. Các yêu cầu kỹ thuật bao gồm hiệu chuẩn cảm biến, độ tin cậy của quy trình dữ liệu, hạ tầng tính toán và an ninh mạng. Các yêu cầu về tổ chức bao gồm đào tạo người vận hành, quản lý thay đổi và khuôn khổ trách nhiệm pháp lý theo hợp đồng đối với hoạt động điều khiển tự động. Những yếu tố về tổ chức này chưa được ghi chép đầy đủ trong tài liệu học thuật [33,37]. Cần có sự hợp tác có cấu trúc giữa các đơn vị cấp nước, nhà cung cấp công nghệ và các nhóm nghiên cứu học thuật, tương tự như sự hợp tác đã tạo ra nghiên cứu xác thực ML trên quy mô toàn diện của Kovacs và cộng sự [26], nhằm xây dựng cơ sở bằng chứng về triển khai làm nền tảng cho việc áp dụng trong lĩnh vực quản lý và thương mại.

Khoảng trống thứ tư liên quan đến việc đặc trưng hóa động các dòng nước thải đầu vào. Thiết bị đo SCADA tiêu chuẩn đo các thông số chất lượng nước thải tổng thể (COD, BOD, TSS, độ đục, DO, pH và độ dẫn điện), chỉ cung cấp đặc trưng tổng quát của hỗn hợp bùn lỏng đi vào hệ thống sinh học. Các đợt xả thải công nghiệp, nước mưa xâm nhập trong thời gian mưa và biến động theo chu kỳ ngày đêm về thành phần nước thải sinh hoạt đều gây ra những thay đổi nhanh chóng, với biên độ lớn, trong đặc tính của dòng thải đầu vào; các thay đổi này không được phản ánh đầy đủ qua mẫu gộp hàng ngày hoặc cảm biến trực tuyến có thời gian đáp ứng chậm [3,22]. Nhiều hiện tượng động chưa được đặc trưng hóa này là nguyên nhân chính gây ra các sự cố tắc nghẽn màng trong MBR, vốn khó dự đoán bằng các dãy cảm biến tiêu chuẩn. Việc tích hợp các cảm biến quang phổ trực tuyến tần số cao (UV-Vis, quang phổ huỳnh quang), công nghệ chụp cắt lớp kết hợp quang học mới nổi để đặc trưng hóa lớp bùn theo thời gian thực, và thậm chí cả các công cụ phân tử để lập dấu vân tay quy mô vi sinh vật vào lớp cảm biến của DT sẽ cải thiện đáng kể việc đặc trưng hóa động dòng thải đầu vào và khả năng bao quát dự báo của mô hình ML đối với các sự kiện nhiễu động có hậu quả nghiêm trọng này.

Khoảng trống thứ năm liên quan đến khía cạnh pháp quy của việc ứng dụng XAI. Cơ sở lý thuyết cho việc sử dụng XAI như một công cụ xây dựng niềm tin của cơ quan quản lý đối với hoạt động quản lý hệ thống nước dựa trên ML đã được phát triển đầy đủ trong các tài liệu học thuật [29,51]. Tuy nhiên, chưa có nghiên cứu nào được công bố ghi nhận bằng thực nghiệm một trường hợp trong đó các giải thích SHAP hoặc đầu ra XAI tương đương trực tiếp tác động đến điều kiện cấp phép, kết quả thẩm tra của cơ quan quản lý, sửa đổi giấy phép vận hành hay hành động pháp quy chính thức khác trong lĩnh vực nước. Đây là mắt xích còn thiếu mang tính then chốt giữa năng lực kỹ thuật được chứng minh trong nghiên cứu học thuật và các cơ chế cấp phép pháp quy chi phối hoạt động của các hệ thống nước. Việc cộng đồng kỹ thuật nước chủ động phối hợp với các cơ quan quản lý môi trường để xây dựng các tiêu chuẩn bằng chứng được thống nhất cho việc xác thực XAI, xác định các trường hợp sử dụng chấp nhận được đối với hoạt động điều khiển tự động dựa trên ML, cũng như thiết lập yêu cầu về nhật ký kiểm toán, là điều kiện tiên quyết để chuyển từ trình diễn nghiên cứu sang triển khai vận hành được cấp phép, điều mà lĩnh vực này hiện đang cần. Khoảng trống thứ sáu liên quan đến chi phí kinh tế cho việc phát triển và huấn luyện lại mô hình ML. Việc phát triển một mô hình ML đạt chuẩn sản xuất cho nhà máy MBR đòi hỏi hạ tầng dữ liệu, chuyên môn kỹ thuật và tài nguyên tính toán. Chi phí huấn luyện lại phát sinh mỗi khi đặc tính nước đầu vào thay đổi, mô-đun màng được thay thế hoặc cấu hình nhà máy biến đổi. Những chi phí này hiếm khi được báo cáo trong các nghiên cứu học thuật. Các nghiên cứu trong tương lai cần ghi chép đầy đủ chi phí phát triển mô hình, xác thực và các chu kỳ bảo trì. Thông tin này thiết yếu đối với các đơn vị cấp nước khi đánh giá liệu việc điều khiển dựa trên ML có hiệu quả kinh tế so với những phương án đơn giản hơn hay không. Để đặt khoảng trống này vào bối cảnh cụ thể, cơ cấu chi phí triển khai thực tế cho một hệ thống dự đoán tắc nghẽn dựa trên ML tại một nhà máy MBR quy mô trung bình bao gồm các hạng mục sau. Chi phí phát triển ban đầu bao gồm kiểm tra cảm biến và hạ tầng dữ liệu (thường mất vài tháng để làm sạch dữ liệu lịch sử SCADA), phát triển mô hình và xác thực chéo, cùng tài liệu pháp quy phục vụ phê duyệt thay đổi quy trình. Chi phí thường xuyên bao gồm huấn luyện lại mô hình định kỳ, phần cứng điện toán biên, an ninh CNTT và đào tạo nhân viên vận hành. Cho đến nay, chưa có nghiên cứu bình duyệt nào công bố phân tích đầy đủ chi phí–lợi ích cho một hệ thống ML được triển khai tại nhà máy MBR. Bản thân sự thiếu vắng dữ liệu này cũng là một phát hiện. Các nghiên cứu trong tương lai cần báo cáo tổng chi phí phát triển, chi phí xác thực và chi phí hằng năm

maintenance cost alongside model performance metrics. Without this information, water utilities cannot assess whether ML-based control is economically justified relative to simpler alternatives such as PID controllers. Until such data are available, practitioners should commission site-specific feasibility assessments before committing to ML-based control deployment. A seventh gap concerns the human capital requirements for operating a DT and XAI system. A functioning Tier II or Tier III digital twin requires staff with expertise in data engineering, ML operations, and process control. Most water utilities lack this skill set in-house. The gap between research-grade demonstrations and practical utility deployment is partly a workforce gap, not only a technology gap. Studies should explicitly report the staffing and training requirements of proposed DT frameworks. An eighth gap concerns the limited comparison of ML-based control with established non-ML alternatives. Proportional–integral–derivative (PID) controllers and fuzzy logic controllers are well-understood, low-cost, and already deployed in most MBR facilities. Very few reviewed studies benchmarked ML models against these baselines under equivalent operating conditions. Without such comparisons, the incremental benefit of ML over conventional control cannot be quantified. Future studies should include PID and fuzzy logic as mandatory baselines when claiming performance improvements. A ninth gap concerns the carbon and energy footprint of ML model computation. Training deep learning models such as LSTM networks or Transformers on large SCADA datasets consumes substantial electrical energy. Inference on edge hardware adds ongoing energy demand. For MBR systems deployed specifically to reduce environmental impact, this computational footprint is a legitimate concern. Future studies should report training energy consumption and inference energy per prediction alongside model performance metrics.

8. Conclusions

This comprehensive review has synthesized evidence from peer-reviewed sources on machine learning, explainable artificial intelligence, and digital twin applications in membrane bioreactor wastewater treatment. The following principal conclusions address the four review objectives stated in Section 1:

- ML models for MBR fouling and TMP prediction have matured substantially over the review period. Ensemble methods (particularly RF) and kernel-based approaches (LSSVM) achieve $R^2 = 0.85\text{--}0.99$ across laboratory, pilot, and full-scale systems, consistently outperforming standard ANN architectures. Full-scale RF validation on 80,000+ operational samples ($R^2 = 0.927\text{--}0.996$, RMSE = 0.264–0.904 kPa) represents a strong historical validation result. It is important to clarify, however, that historical validation on archived SCADA data is not equivalent to operational deployment validation. Closed-loop performance under live conditions, including sensor drift, noise, and data latency, has not yet been demonstrated. Site-specific validation and governance safeguards remain prerequisites before deployment in operational MBR monitoring systems.
- SHAP-based analyses in MBR studies frequently identify MLSS, SRT, HRT, and aeration intensity as dominant predictors. These findings simultaneously validate mechanistic understanding and provide operator-actionable evidence of the variables most critical for fouling control [17,25,42]. SHAP's dominance across XAI-inclusive publications reflects both its theoretical grounding in cooperative game theory and its practical usability for engineering interpretation.
- Model-based and feedback-control approaches have confirmed up to 20% reductions in aeration energy demand at full-scale MBR installations [59], establishing a validated benchmark for model-informed control. Dedicated ML-specific energy optimization

chi phí bảo trì cùng với các chỉ số hiệu năng của mô hình. Nếu không có thông tin này, các đơn vị cấp thoát nước không thể đánh giá liệu việc điều khiển dựa trên ML có hợp lý về mặt kinh tế so với các phương án đơn giản hơn như bộ điều khiển PID hay không. Cho đến khi có dữ liệu như vậy, các đơn vị vận hành nên yêu cầu đánh giá tính khả thi riêng cho từng địa điểm trước khi cam kết triển khai điều khiển dựa trên ML. Khoảng trống thứ bảy liên quan đến yêu cầu về nhân lực để vận hành hệ thống DT và XAI. Một bản sao số cấp II hoặc cấp III hoạt động hiệu quả đòi hỏi nhân viên có chuyên môn về kỹ thuật dữ liệu, vận hành ML và điều khiển quy trình. Hầu hết các đơn vị cấp thoát nước đều thiếu những kỹ năng này ngay trong nội bộ. Khoảng cách giữa các minh chứng ở cấp độ nghiên cứu và việc triển khai thực tế tại các đơn vị vận hành một phần là khoảng cách về lực lượng lao động, chứ không chỉ là khoảng cách về công nghệ. Các nghiên cứu cần nêu rõ yêu cầu về nhân sự và đào tạo của những khung DT được đề xuất. Khoảng trống thứ tám liên quan đến việc thiếu so sánh giữa điều khiển dựa trên ML với các phương án phi ML đã được thiết lập. Bộ điều khiển tỷ lệ–tích phân–vi phân (PID) và bộ điều khiển logic mờ đã được hiểu rõ, có chi phí thấp và đang được triển khai tại hầu hết các cơ sở MBR. Rất ít nghiên cứu được xem xét để đánh giá mô hình ML so với các phương pháp cơ sở này trong những điều kiện vận hành tương đương. Nếu thiếu những so sánh như vậy, không thể định lượng lợi ích gia tăng của ML so với điều khiển truyền thống. Các nghiên cứu trong tương lai cần đưa PID và logic mờ vào làm các phương pháp cơ sở bắt buộc khi tuyên bố có cải thiện hiệu năng. Khoảng trống thứ chín liên quan đến dấu chân carbon và năng lượng của quá trình tính toán mô hình ML. Việc huấn luyện các mô hình học sâu như mạng LSTM hoặc Transformer trên các tập dữ liệu SCADA lớn tiêu thụ lượng điện năng đáng kể. Suy luận trên phần cứng biên làm phát sinh nhu cầu năng lượng liên tục. Đối với các hệ thống MBR được triển khai nhằm giảm tải động môi trường, dấu chân tính toán này là một mối quan ngại chính đáng. Các nghiên cứu trong tương lai cần báo cáo mức tiêu thụ năng lượng khi huấn luyện và năng lượng suy luận trên mỗi lần dự đoán, bên cạnh các chỉ số hiệu năng của mô hình.

8. Kết luận

Bài tổng quan toàn diện này đã tổng hợp bằng chứng từ các nguồn đã qua bình duyệt về học máy, trí tuệ nhân tạo có thể giải thích và các ứng dụng song sinh số trong xử lý nước thải bằng bể phản ứng sinh học màng. Các kết luận chính sau đây đề cập đến bốn mục tiêu tổng quan được nêu tại Mục 1:

- Các mô hình ML dự đoán hiện tượng bám bẩn trong MBR và TMP đã trưởng thành đáng kể trong giai đoạn được đánh giá. Các phương pháp tổ hợp (đặc biệt là RF) và phương pháp dựa trên kernel (LSSVM) đạt $R^2 = 0.85\text{--}0.99$ trên các hệ thống quy mô phòng thí nghiệm, thí điểm và toàn quy mô, nhất quán vượt trội so với các kiến trúc ANN tiêu chuẩn. Việc thẩm định RF toàn quy mô trên 80,000+ mẫu vận hành ($R^2 = 0.927\text{--}0.996$, RMSE = 0.264–0.904 kPa) là một kết quả thẩm định lịch sử đầy ấn tượng. Tuy nhiên, cần làm rõ rằng thẩm định lịch sử trên dữ liệu SCADA lưu trữ không tương đương với thẩm định triển khai vận hành. Hiệu suất vòng kín trong điều kiện thực tế, bao gồm độ trôi cảm biến, nhiễu và độ trễ dữ liệu, vẫn chưa được chứng minh. Việc thẩm định riêng cho từng địa điểm và các biện pháp bảo vệ quản trị vẫn là điều kiện tiên quyết trước khi triển khai trong các hệ thống giám sát MBR vận hành.
- Các phân tích dựa trên SHAP trong các nghiên cứu MBR thường xác định MLSS, SRT, HRT và cường độ sục khí là những yếu tố dự báo chi phối. Những phát hiện này vừa xác thực hiểu biết về cơ chế, vừa cung cấp bằng chứng hữu ích cho người vận hành về các biến số quan trọng nhất đối với việc kiểm soát tắc nghẽn [17, 25,42]. Mức độ phổ biến vượt trội của SHAP trong các công bố có sử dụng XAI phản ánh cả cơ sở lý thuyết của phương pháp này trong lý thuyết trò chơi hợp tác lẫn tính ứng dụng thực tiễn trong diễn giải kỹ thuật.
- Các phương pháp dựa trên mô hình và điều khiển phản hồi đã xác nhận mức giảm tới 20% nhu cầu năng lượng sục khí tại các công trình MBR quy mô thực tế [59], thiết lập một chuẩn đối sánh đã được kiểm chứng cho điều khiển có hỗ trợ mô hình. Tối ưu hóa năng lượng chuyên biệt cho ML

demonstrations remain limited and represent the most immediately impactful research gap for operational energy efficiency.

- Digital twin frameworks integrating mechanistic ASM sub-models with ML corrections provide the architecture for Tier II predictive and Tier III prescriptive MBR management. The embedding of XAI decision-transparency modules within the DT architecture is a functional requirement, not merely a desirable feature for achieving the operator trust necessary for autonomous prescriptive control. No full-scale MBR Tier III deployment with integrated XAI has yet been documented, which represents the field’s primary frontier.
- Nine critical research gaps require systematic investigation: standardized multi-facility benchmark datasets; calibrated uncertainty quantification in operational ML predictions; full-scale DT deployment evidence; dynamic integration of influent characterization technology; empirical evaluation of XAI within regulatory acceptance frameworks; transparent reporting of ML model development and retraining costs; workforce capacity building for DT and XAI operations at water utilities; systematic benchmarking of ML-based control against PID and fuzzy logic baselines; and reporting of computational energy footprints for deep learning models deployed in environmental systems.

The convergence of interpretable ML prediction, XAI transparency, and real-time digital twin simulation represents the most promising near-term pathway for intelligent, trustworthy MBR operation. Realizing this vision will require sustained, coordinated investment in open data infrastructure, uncertainty-aware model pipelines, full-scale deployment partnerships, and engagement with regulatory frameworks, contributions that must come from the water engineering, data science, and water governance communities acting in concert.

Supplementary Materials: The following supporting information can be downloaded at <https://www.mdpi.com/article/10.3390/membranes16050181/s1>. Table S1: Study-level data extraction for reviewed ML, XAI, and DT studies on MBR systems.

Funding: This research received no external funding.

Data Availability Statement: No new data were created or analyzed in this study.

Conflicts of Interest: The author declares no conflict of interest.

References

1. Judd, S. *The MBR Book: Principles and Applications of Membrane Bioreactors for Water and Wastewater Treatment*; Elsevier: Amsterdam, The Netherlands, 2010.
2. Kraume, M.; Drews, A. Membrane bioreactors in waste water treatment—status and trends. *Chem. Eng. Technol.* **2010**, *33*, 1251–1259.
3. Xiao, K.; Liang, S.; Wang, X.; Chen, C.; Huang, X. Current state and challenges of full-scale membrane bioreactor applications: A critical review. *Bioresour. Technol.* **2019**, *271*, 473–481. [\[CrossRef\]](#)
4. Le-Clech, P.; Chen, V.; Fane, T.A. Fouling in membrane bioreactors used in wastewater treatment. *J. Membr. Sci.* **2006**, *284*, 17–53. [\[CrossRef\]](#)
5. Judd, S. The status of membrane bioreactor technology. *Trends Biotechnol.* **2008**, *26*, 109–116. [\[CrossRef\]](#)
6. Yang, W.; Cicek, N.; Ilg, J. State-of-the-art of membrane bioreactors: Worldwide research and commercial applications in North America. *J. Membr. Sci.* **2006**, *270*, 201–211.
7. Rahman, T.U.; Roy, H.; Islam, M.R.; Tahmid, M.; Fariha, A.; Mazumder, A.; Tasnim, N.; Pervez, M.N.; Cai, Y.; Naddeo, V. The advancement in membrane bioreactor (MBR) technology toward sustainable industrial wastewater management. *Membranes* **2023**, *13*, 181. [\[CrossRef\]](#)
8. Meng, F.; Chae, S.-R.; Drews, A.; Kraume, M.; Shin, H.-S.; Yang, F. Recent advances in membrane bioreactors (MBRs): Membrane fouling and membrane material. *Water Res.* **2009**, *43*, 1489–1512. [\[CrossRef\]](#)
9. Drews, A. Membrane fouling in membrane bioreactors—Characterisation, contradictions, cause and cures. *J. Membr. Sci.* **2010**, *363*, 1–28. [\[CrossRef\]](#)

Các minh chứng vẫn còn hạn chế và là khoảng trống nghiên cứu có tác động từ c thời lớn nhất đối với hiệu quả năng lượng trong vận hành.

- Các khung bản sao số tích hợp các mô hình con ASM cơ chế với các hiệu chỉnh ML cung cấp kiến trúc cho hoạt động quản lý MBR dự báo cấp II và chỉ dẫn cấp I II. Việc tích hợp các mô-đun minh bạch quyết định XAI vào kiến trúc DT là một yêu cầu chức năng, chứ không đơn thuần là tính năng đáng mong muốn, để đạt được sự tin tưởng của người vận hành cần thiết cho việc kiểm soát chỉ dẫn tự động. Chưa có triển khai MBR quy mô toàn phần cấp III nào tích hợp XAI được ghi nhận, đây là hướng nghiên cứu tiên phong chủ yếu của lĩnh vực này.
- Chín khoảng trống nghiên cứu trọng yếu cần được khảo sát một cách hệ thống: các bộ dữ liệu chuẩn hóa dùng làm bộ chuẩn, bao quát nhiều cơ sở; định lượng bất định đã hiệu chuẩn trong các dự đoán ML vận hành; bằng chứng triển khai DT ở quy mô đầy đủ; tích hợp linh hoạt công nghệ đặc trưng hóa dòng nước đầu vào; đánh giá thực nghiệm XAI trong khuôn khổ chấp thuận của cơ quan quản lý; báo cáo minh bạch chi phí phát triển và huấn luyện lại mô hình ML; nâng cao năng lực lực lượng lao động để vận hành DT và XAI tại các đơn vị cấp thoát nước; đổi chuẩn có hệ thống phương pháp điều khiển dựa trên ML với các phương pháp cơ sở PID và logic mờ; và báo cáo mức tiêu thụ năng lượng tính toán của các mô hình học sâu được triển khai trong các hệ thống môi trường.

Sự hội tụ giữa khả năng dự đoán có thể diễn giải của học máy, tính minh bạch của XAI và mô phỏng bản sao số theo thời gian thực là lộ trình triển vọng nhất trong tương lai gần để vận hành MBR thông minh, đáng tin cậy. Hiện thực hóa tầm nhìn này sẽ đòi hỏi đầu tư bền bỉ, phối hợp chặt chẽ vào hạ tầng dữ liệu mở, các quy trình mô hình hóa có xét đến độ bất định, quan hệ đối tác triển khai ở quy mô toàn diện và sự tham gia vào các khuôn khổ pháp quy; những đóng góp này cần đến từ các cộng đồng kỹ thuật nước, khoa học dữ liệu và quản trị nước cùng chung sức.

Tài liệu bổ sung: Có thể tải xuống thông tin hỗ trợ sau tại <https://www.mdpi.com/article/10.3390/membranes16050181/s1>. Bảng S1: Trích xuất dữ liệu ở cấp độ nghiên cứu của các nghiên cứu ML, XAI và DT được tổng quan về hệ thống MBR.

Nguồn tài trợ: Nghiên cứu này không nhận được tài trợ bên ngoài.

Tuyên bố về tính khả dụng của dữ liệu: Không có dữ liệu mới nào được tạo ra hoặc phân tích trong nghiên cứu này.

Xung đột lợi ích: Tác giả tuyên bố không có xung đột lợi ích.

Tài liệu tham khảo

1. Judd, S. *The MBR Book: Principles and Applications of Membrane Bioreactors for Water and Wastewater Treatment*; Elsevier: Amsterdam, Hà Lan, 2010.
2. Kraume, M.; Drews, A. Thiết bị phản ứng sinh học màng trong xử lý nước thải—hiện trạng và xu hướng. *Chem. Eng. Technol.* 2010, *33*, 1251–1259.
3. Xiao, K.; Liang, S.; Wang, X.; Chen, C.; Huang, X. Hiện trạng và thách thức của việc ứng dụng thiết bị phản ứng sinh học màng quy mô toàn diện: Tổng quan phản biện. *Bioresour. Technol.* 2019, *271*, 473–481. [\[CrossRef\]](#)
4. Le-Clech, P.; Chen, V.; Fane, T.A. Sự fouling trong các thiết bị phản ứng sinh học màng dùng trong xử lý nước thải. *J. Membr. Sci.* 2006, *284*, 17–53. [\[CrossRef\]](#)
5. Judd, S. Tình trạng công nghệ thiết bị phản ứng sinh học màng. *Trends Biotechnol.* 2008, *26*, 109–116. [\[CrossRef\]](#)
6. Yang, W.; Cicek, N.; Ilg, J. Hiện trạng tiên tiến của thiết bị phản ứng sinh học màng: Nghiên cứu u trên toàn thế giới và ứng dụng thương mại tại Bắc Mỹ. *J. Membr. Sci.* 2006, *270*, 201–211.
7. Rahman, T.U.; Roy, H.; Islam, M.R.; Tahmid, M.; Fariha, A.; Mazumder, A.; Tasnim, N.; Pervez, M.N.; Cai, Y.; Naddeo, V. Những tiến bộ trong công nghệ thiết bị phản ứng sinh học màng (MBR) hướng tới quản lý nước thải công nghiệp bền vững. *Membranes* 2023, *13*, 181. [\[CrossRef\]](#)
8. Meng, F.; Chae, S.-R.; Drews, A.; Kraume, M.; Shin, H.-S.; Yang, F. Những tiến bộ gần đây trong thiết bị phản ứng sinh học màng (MBR): Sự fouling màng và vật liệu màng. *Water Res.* 2009, *43*, 1489–1512. [\[CrossRef\]](#)
9. Drews, A. Sự fouling màng trong thiết bị phản ứng sinh học màng—Đặc trưng, mẫu thuẫn, nguyên nhân và cách khắc phục. *J. Membr. Sci.* 2010, *363*, 1–28. [\[CrossRef\]](#)

10. Wang, Z.; Ma, J.; Tang, C.Y.; Kimura, K.; Wang, Q.; Han, X. Membrane cleaning in membrane bioreactors: A review. *J. Membr. Sci.* **2014**, *468*, 276–307. [\[CrossRef\]](#)

11. Meng, F.; Zhang, S.; Oh, Y.; Zhou, Z.; Shin, H.-S.; Chae, S.-R. Fouling in membrane bioreactors: An updated review. *Water Res.* **2017**, *114*, 151–180. [\[CrossRef\]](#)

12. Liao, B.-Q.; Kraemer, J.T.; Bagley, D.M. Anaerobic membrane bioreactors: Applications and research directions. *Crit. Rev. Environ. Sci. Technol.* **2006**, *36*, 489–530. [\[CrossRef\]](#)

13. Jha, S.; Mishra, B.K. An overview of deploying different treatment processes with membrane bioreactor for enhanced treatment of wastewaters: Synergistic performances and reduced fouling of membrane. *Environ. Sci. Pollut. Res.* **2024**, *31*, 63603–63634. [\[CrossRef\]](#)

14. Verrecht, B.; Maere, T.; Nopens, I.; Brepols, C.; Judd, S. The cost of a large-scale hollow fibre MBR. *Water Res.* **2010**, *44*, 5274–5283. [\[CrossRef\]](#)

15. Krzeminski, P.; Leverette, L.; Malamis, S.; Katsou, E. Membrane bioreactors—a review on recent developments in energy reduction, fouling control, novel configurations, LCA and market prospects. *J. Membr. Sci.* **2017**, *527*, 207–227. [\[CrossRef\]](#)

16. Kamali, M.; Appels, L.; Yu, X.; Aminabhavi, T.M.; Dewil, R. Artificial intelligence as a sustainable tool in wastewater treatment using membrane bioreactors. *Chem. Eng. J.* **2021**, *417*, 128070. [\[CrossRef\]](#)

17. Newhart, K.B.; Holloway, R.W.; Hering, A.S.; Cath, T.Y. Data-driven performance analyses of wastewater treatment plants: A review. *Water Res.* **2019**, *157*, 498–513. [\[CrossRef\]](#)

18. Cortes, C.; Vapnik, V. Support-vector networks. *Mach. Learn.* **1995**, *20*, 273–297. [\[CrossRef\]](#)

19. Chen, T.; He, T.; Benesty, M.; Khotilovich, V.; Tang, Y.; Cho, H.; Chen, K.; Mitchell, R.; Cano, I.; Zhou, T. *Xgboost: Extreme Gradient Boosting*, R Package Version 0.4-2; R Foundation: Vienna, Austria, 2015.

20. Hochreiter, S.; Schmidhuber, J. Long short-term memory. *Neural Comput.* **1997**, *9*, 1735–1780. [\[CrossRef\]](#)

21. Breiman, L. Random forests. *Mach. Learn.* **2001**, *45*, 5–32. [\[CrossRef\]](#)

22. Viet, N.D.; Jang, A. Development of artificial intelligence-based models for the prediction of filtration performance and membrane fouling in an osmotic membrane bioreactor. *J. Environ. Chem. Eng.* **2021**, *9*, 105337. [\[CrossRef\]](#)

23. Mirbagheri, S.A.; Bagheri, M.; Bagheri, Z.; Kamarkhani, A.M. Evaluation and prediction of membrane fouling in a submerged membrane bioreactor with simultaneous upward and downward aeration using artificial neural network-genetic algorithm. *Process Saf. Environ. Prot.* **2015**, *96*, 111–124. [\[CrossRef\]](#)

24. Schmitt, F.; Do, K.-U. Prediction of membrane fouling using artificial neural networks for wastewater treated by membrane bioreactor technologies: Bottlenecks and possibilities. *Environ. Sci. Pollut. Res.* **2017**, *24*, 22885–22913. [\[CrossRef\]](#)

25. Schmitt, F.; Banu, R.; Yeom, I.-T.; Do, K.-U. Development of artificial neural networks to predict membrane fouling in an anoxic-aerobic membrane bioreactor treating domestic wastewater. *Biochem. Eng. J.* **2018**, *133*, 47–58. [\[CrossRef\]](#)

26. Kovacs, D.J.; Li, Z.; Baetz, B.W.; Hong, Y.; Donnaz, S.; Zhao, X.; Zhou, P.; Ding, H.; Dong, Q. Membrane fouling prediction and uncertainty analysis using machine learning: A wastewater treatment plant case study. *J. Membr. Sci.* **2022**, *660*, 120817. [\[CrossRef\]](#)

27. Ribeiro, M.T.; Singh, S.; Guestrin, C. Anchors: High-precision model-agnostic explanations. In Proceedings of the AAAI Conference on Artificial Intelligence, New Orleans, LA, USA, 2–7 February 2018; Volume 32.

28. Barredo, A.A.; Del Ser, J.; Gil-Lopez, S.; Díaz-Rodríguez, N.; Bennetot, A.; Chatila, R.; Tabik, S.; Garcia, S.; Molina, D.; Herrera, F. Explainable Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Inf. Fusion* **2020**, *58*, 82–115. [\[CrossRef\]](#)

29. Adadi, A.; Berrada, M. Peeking inside the black-box: A survey on explainable artificial intelligence (XAI). *IEEE Access* **2018**, *6*, 52138–52160. [\[CrossRef\]](#)

30. Grieves, M. Digital twin: Manufacturing excellence through virtual factory replication. *White Pap.* **2014**, *1*, 1–7.

31. Fuller, A.; Fan, Z.; Day, C.; Barlow, C. Digital twin: Enabling technologies, challenges and open research. *IEEE Access* **2020**, *8*, 108952–108971. [\[CrossRef\]](#)

32. Tao, F.; Zhang, H.; Liu, A.; Nee, A.Y. Digital twin in industry: State-of-the-art. *IEEE Trans. Ind. Inform.* **2018**, *15*, 2405–2415. [\[CrossRef\]](#)

33. Barricelli, B.R.; Casiraghi, E.; Fogli, D. A survey on digital twin: Definitions, characteristics, applications, and design implications. *IEEE Access* **2019**, *7*, 167653–167671. [\[CrossRef\]](#)

34. Henze, M.; Gujer, W.; Mino, T.; Van Loosedrecht, M. *Activated Sludge Models ASM1, ASM2, ASM2d and ASM3*; IWA Publishing: London, UK, 2006.

35. Gujer, W.; Henze, M.; Mino, T.; Van Loosedrecht, M. Activated sludge model No. 3. *Water Sci. Technol.* **1999**, *39*, 183–193. [\[CrossRef\]](#)

36. Maere, T.; Verrecht, B.; Moerenhout, S.; Judd, S.; Nopens, I. BSM-MBR: A benchmark simulation model to compare control and operational strategies for membrane bioreactors. *Water Res.* **2011**, *45*, 2181–2190. [\[CrossRef\]](#)

37. Wang, A.-J.; Li, H.; He, Z.; Tao, Y.; Wang, H.; Yang, M.; Savic, D.; Daigger, G.T.; Ren, N. Digital twins for wastewater treatment: A technical review. *Engineering* **2024**, *36*, 21–35. [\[CrossRef\]](#)

10. Wang, Z.; Ma, J.; Tang, C.Y.; Kimura, K.; Wang, Q.; Han, X. Làm sạch màng trong các bể phản ứng sinh học màng: Tổng qu an. *J. Membr. Sci.* 2014, *468*, 276–307. [\[CrossRef\]](#)

11. Meng, F.; Zhang, S.; Oh, Y.; Zhou, Z.; Shin, H.-S.; Chae, S.-R. Hiện tượng bá m bẩn trong các bể phản ứng sinh học màng: Tổng quan cập nhật. *Water Res.* 2017, *114*, 151–180. [\[CrossRef\]](#)

12. Liao, B.-Q.; Kraemer, J.T.; Bagley, D.M. Bể phản ứng sinh học màng kỵ khí: Ứng dụng và định hướng nghiên cứu. *Crit. Rev. Environ. Sci. Technol.* 2006, *36*, 489–530. [\[CrossRef\]](#)

13. Jha, S.; Mishra, B.K. Tổng quan về việc triển khai các quy trình xử lý khác nhau kế t hợp với bể phản ứng sinh học màng nhằm nâng cao hiệu quả xử lý nước thải: Hiệu suất cộng hưởng và giảm bám bẩn màn g. *Environ. Sci. Pollut. Res.* 2024, *31*, 63603–63634. [\[CrossRef\]](#)

14. Verrecht, B.; Maere, T.; Nopens, I.; Brepols, C.; Judd, S. Chi ph í của hệ thống MBR sợi rỗng quy mô lớn. *Water Res.* 2010, *44*, 5274–5283. [\[CrossRef\]](#)

15. Krzeminski, P.; Leverette, L.; Malamis, S.; Katsou, E. Bể phản ứng sinh học màng–tổng quan về các phát triển gần đây trong giảm năng lượng, kiểm soát bám bẩn, c ấu hình mới, đánh giá vòng đời và triển vọng thị trường. *J. Membr. Sci.* 2017, *527*, 207–227. [\[CrossRef\]](#)

16. Kamali, M.; Appels, L.; Yu, X.; Aminabhavi, T.M.; Dewil, R. Trí tuệ nhân tạo như một công cụ bền vững trong xử lý nước thải bằng bể phản ứng sinh học màng. *Chem. Eng. J.* 2021, *417*, 128070. [\[CrossRef\]](#)

17. Newhart, K.B.; Holloway, R.W.; Hering, A.S.; Cath, T.Y. Phân tích hiệu suất dựa trên dữ liệu của các nhà máy xử lý nước thải: Tổng quan. *Water Res.* 2019, *157*, 498–513. [\[CrossRef\]](#)

18. Cortes, C.; Vapnik, V. Mạng véc-tơ hỗ trợ. *Mach. Learn.* 1995, *20*, 273–297. [\[CrossRef\]](#)

19. Chen, T.; He, T.; Benesty, M.; Khotilovich, V.; Tang, Y.; Cho, H.; Chen, K.; Mitchell, R.; Cano, I.; Zhou, T. *Xgboost: Extreme Gradient Boosting*, Phiên bản gói R 0.4-2; R Foundation: Vienna , Áo, 2015.

20. Hochreiter, S.; Schmidhuber, J. Bộ nhớ ngắn hạn dài. *Neural Comput.* 1997, *9*, 1735–1780. [\[CrossRef\]](#)

21. Breiman, L. Rừng ngẫu nhiên. *Mach. Learn.* 2001, *45*, 5–32. [\[CrossRef\]](#)

22. Viet, N.D.; Jang, A. Phát triển các mô hình dựa trên trí tuệ nhâ n tạo để dự đoán hiệu suất lọc và hiện tượng bám bẩn màng trong bể phản ứng sinh học màng thẩm thấu. *J. Environ. Chem. Eng.* 2021, *9*, 105337. [\[CrossRef\]](#)

23. Mirbagheri, S.A.; Bagheri, M.; Bagheri, Z.; Kamarkhani, A.M. Đánh giá và dự đoán hiện tượng bám bẩn màng trong bể phản ứng sinh học màng ngập với sục khí đồng thời theo hướng lên và xuống bằng thuật toán mạng nơ-ron nhân tạo–di truyền. *Process Saf. Environ. Prot.* 2015, *96*, 111–124. [\[CrossRef\]](#)

24. Schmitt, F.; Do, K.-U. Dự đoán hiện tượng bám bẩn màng bằng mạng nơ-ron nhân tạo đối với nước thải được xử lý bằng công nghệ bể phản ứ ng sinh học màng: Trở ngại và khả năng. *Environ. Sci. Pollut. Res.* 2017, *24*, 22885–22913. [\[CrossRef\]](#)

25. Schmitt, F.; Banu, R.; Yeom, I.-T.; Do, K.-U. Phát triển mạng nơ-ron nhân tạo để dự đoán hiện tượng bám bẩn màng trong bể phản ứng sinh học mà ng thiếu khí–hiếu khí xử lý nước thải sinh hoạt. *Biochem. Eng. J.* 2018, *133*, 47–58. [\[CrossRef\]](#)

26. Kovacs, D.J.; Li, Z.; Baetz, B.W.; Hong, Y.; Donnaz, S.; Zhao, X.; Zhou, P.; Ding, H.; Dong, Q. Dự đoán hiện tượng bám bẩn màng và phân tích độ bất định bằng học máy: Nghiên cứu tình huống tại một nhà máy xử lý nước thải. *J. Membr. Sci.* 2022, *660*, 120817. [\[CrossRef\]](#)

27. Ribeiro, M.T.; Singh, S.; Guestrin, C. Anchors: Giải thích mô hình không phụ thuộc thuật toán với độ chính xác cao. Trong Kỷ yếu Hội nghị A AAI về Trí tuệ nhân tạo, New Orleans, LA, Hoa Kỳ, 2–7 tháng 2 năm 2018; Tập 32. 28. Barredo, A.A.; Del Ser, J.; Gil-Lopez, S.; Dí az-Rodríguez, N.; Bennetot, A.; Chatila, R.; Tabik, S.; Garcia, S.; Molina, D.; Herrera, F. Trí tuệ nhân tạo có thể giải thích (XAI): K hái niệm, hệ phân loại, cơ hội và thách thức hướng tới AI có trách nhiệm. *Inf. Fusion* 2020, *58*, 82–115. [\[CrossRef\]](#)

29. Adadi, A.; Berrada, M. Nhìn vào bên trong hộp đen: Tổng quan về trí tuệ nhân tạo có thể giải thích (XAI). *IEEE Access* 2018, *6*, 52138–521 60. [\[CrossRef\]](#)

30. Grieves, M. Bản sao số: Nâng cao năng lực sản xuất thông qua việc tái tạo nhà máy ảo. *White Pap.* 2014, *1*, 1 –7. 31. Fuller, A.; Fan, Z.; Day, C.; Barlow, C. Bản sao số: Công nghệ nền tảng, thách thức và hướng nghiên cứu mở. *IEEE Access* 2020, *8*, 108952–108971. [\[CrossRef\]](#)

32. Tao, F.; Zhang, H.; Liu, A.; Nee, A.Y. Bản sao số trong công nghiệp: Tình hì nh hiện nay. *IEEE Trans. Ind. Inform.* 2018, *15*, 2405–2415. [\[CrossRef\]](#)

33. Barricelli, B.R.; Casiraghi, E.; Fogli, D. Tổng quan về b ản sao số: Định nghĩa, đặc điểm, ứng dụng và hàm ý thiết kế. *IEEE Access* 2019, *7*, 167653–167671. [\[CrossRef\]](#)

34. Henze, M.; Gujer, W.; Mino, T.; Van Loosedrecht, M. *Activated Sludge Models ASM1, ASM2, ASM2d and ASM3*; IWA Publishing: London, Vương quốc Anh, 2006.

35. Gujer, W.; Henze, M.; Mino, T.; Van Loosedrecht, M. Mô hình bùn hoạt tính số 3. *Water Sci. Technol.* 1999, *39*, 183–193. [\[CrossRef\]](#)

36. Maere, T.; Verrecht, B.; Moerenhout, S.; Judd, S.; Nopens, I. BSM-MBR: Mô hình mô phỏng chuẩn để s o sánh các chiến lược điều khiển và vận hành cho bể phản ứng sinh học màng. *Water Res.* 2011, *45*, 2181–2190. [\[CrossRef\]](#)

37. Wang, A.-J.; Li, H.; He, Z.; Tao, Y.; Wang, H.; Yang, M.; Savic, D.; Daigger, G.T.; Ren, N. Bản sao số cho xử lý nước thải: Tổng qua n kỹ thuật. *Engineering* 2024, *36*, 21–35. [\[CrossRef\]](#)

38. Shi, Y.; Wang, Z.; Du, X.; Gong, B.; Jegatheesan, V.; Haq, I.U. Recent advances in the prediction of fouling in membrane bioreactors. *Membranes* **2021**, *11*, 381. [\[CrossRef\]](#)

39. Ni, B.-J.; Rittmann, B.E.; Yu, H.-Q. Soluble microbial products and their implications in mixed culture biotechnology. *Trends Biotechnol.* **2011**, *29*, 454–463. [\[CrossRef\]](#)

40. Fenu, A.; Guglielmi, G.; Jimenez, J.; Spèrandio, M.; Saroj, D.; Lesjean, B.; Brepols, C.; Thoeys, C.; Nopens, I. Activated sludge model (ASM) based modelling of membrane bioreactor (MBR) processes: A critical review with special regard to MBR specificities. *Water Res.* **2010**, *44*, 4272–4294. [\[CrossRef\]](#)

41. Achilli, A.; Cath, T.Y.; Marchand, E.A.; Childress, A.E. The forward osmosis membrane bioreactor: A low fouling alternative to MBR processes. *Desalination* **2009**, *239*, 10–21. [\[CrossRef\]](#)

42. Hamed, H.; Ehteshami, M.; Mirbagheri, S.A.; Zendejboudi, S. New deterministic tools to systematically investigate fouling occurrence in membrane bioreactors. *Chem. Eng. Res. Des.* **2019**, *144*, 334–353. [\[CrossRef\]](#)

43. Giwa, A.; Daer, S.; Ahmed, I.; Marpu, P.; Hasan, S. Experimental investigation and artificial neural networks ANNs modeling of electrically-enhanced membrane bioreactor for wastewater treatment. *J. Water Process Eng.* **2016**, *11*, 88–97.

44. Nguyen, T.N.; Do, K.U.; Tran, T.P.N.; Van Nguyen, T.; Chu, Q.X. Predictive Modeling of Membrane Fouling in Domestic Wastewater Membrane Bioreactor Using Machine Learning. *Water Environ. Res.* **2025**, *97*, e70205. [\[CrossRef\]](#)

45. de Queiroz, M.M.; Moreira, V.R.; Amaral, M.C.S.; Oliveira, S.M.A.C. Machine learning algorithms for predicting membrane bioreactors performance: A review. *J. Environ. Manag.* **2025**, *380*, 124978. [\[CrossRef\]](#)

46. Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A.N.; Kaiser, Ł.; Polosukhin, I. Attention is all you need. *Adv. Neural Inf. Process. Syst.* **2017**, *30*, 6000–6010.

47. Frontistis, Z.; Lykogiannis, G.; Sarpanis, A. Machine learning implementation in membrane bioreactor systems: Progress, challenges, and future perspectives: A review. *Environments* **2023**, *10*, 127. [\[CrossRef\]](#)

48. Molnar, C. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 2nd ed.; Leanpub: Victoria, BC, Canada, 2022.

49. Liang, J.; Lee, S.; Ren, X.; Guo, Y.; Park, J.; Park, S.-G.; Kim, J.-Y.; Hwang, M.-H. Predictive Framework for Membrane Fouling in Full-Scale Membrane Bioreactors (MBRs): Integrating AI-Driven Feature Engineering and Explainable AI (XAI). *Processes* **2025**, *13*, 2352. [\[CrossRef\]](#)

50. Zhu, Y.; Wang, Y.; Zhu, E.; Ma, Z.; Wang, H.; Chen, C.; Guan, J.; Waite, T.D. Predicting membrane fouling of submerged membrane bioreactor wastewater treatment plants using machine learning. *Environ. Sci. Technol.* **2025**, *59*, 10010–10021. [\[CrossRef\]](#)

51. Rudin, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nat. Mach. Intell.* **2019**, *1*, 206–215. [\[CrossRef\]](#)

52. Lundberg, S.M.; Lee, S.-I. A unified approach to interpreting model predictions. *Adv. Neural Inf. Process. Syst.* **2017**, *30*, 4768–4777.

53. Lundberg, S.M.; Erion, G.; Chen, H.; DeGrave, A.; Prutkin, J.M.; Nair, B.; Katz, R.; Himmelfarb, J.; Bansal, N.; Lee, S.-I. From local explanations to global understanding with explainable AI for trees. *Nat. Mach. Intell.* **2020**, *2*, 56–67. [\[CrossRef\]](#)

54. LeCun, Y.; Bengio, Y.; Hinton, G. Deep learning. *Nature* **2015**, *521*, 436–444. [\[CrossRef\]](#)

55. Ribeiro, M.T.; Singh, S.; Guestrin, C. “Why should i trust you?” Explaining the predictions of any classifier. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, CA, USA, 13–17 August 2016; pp. 1135–1144. [\[CrossRef\]](#)

56. Verrecht, B.; Judd, S.; Guglielmi, G.; Brepols, C.; Mulder, J. An aeration energy model for an immersed membrane bioreactor. *Water Res.* **2008**, *42*, 4761–4770. [\[CrossRef\]](#)

57. Germain, E.; Nelles, F.; Drews, A.; Pearce, P.; Kraume, M.; Reid, E.; Judd, S.J.; Stephenson, T. Biomass effects on oxygen transfer in membrane bioreactors. *Water Res.* **2007**, *41*, 1038–1044. [\[CrossRef\]](#) [\[PubMed\]](#)

58. Diaz, O.; Gonzalez, E.; Vera, L. Influence of air scouring and residual fouling on cake build-up and compression in membrane bioreactors. *Ind. Eng. Chem. Res.* **2024**, *63*, 13740–13751. [\[CrossRef\]](#)

59. Sun, J.; Liang, P.; Yan, X.; Zuo, K.; Xiao, K.; Xia, J.; Qiu, Y.; Wu, Q.; Wu, S.; Huang, X. Reducing aeration energy consumption in a large-scale membrane bioreactor: Process simulation and engineering application. *Water Res.* **2016**, *93*, 205–213. [\[CrossRef\]](#)

60. Ghorbani Bam, P.; Rezaei, N.; Roubanis, A.; Austin, D.; Austin, E.; Tarroja, B.; Takacs, I.; Villez, K.; Rosso, D. Digital Twin Applications in the Water Sector: A Review. *Water* **2025**, *17*, 2957. [\[CrossRef\]](#)

61. Rodríguez-Alonso, C.; Pena-Regueiro, I.; García, Ó. Digital twin platform for water treatment plants using microservices architecture. *Sensors* **2024**, *24*, 1568. [\[CrossRef\]](#) [\[PubMed\]](#)

62. Xu, M.; Liu, D. AI-Enabled Membrane Bioreactors: A Review of Control Architectures and Operating-Parameter Optimization for Nitrogen and Phosphorus Removal. *Water* **2025**, *17*, 2899. [\[CrossRef\]](#)

63. Wei, Q.; Xu, Z.; Yin, H. Enhanced nitrogen prediction and mechanistic process analysis in high-salinity wastewater treatment using interpretable machine learning approach. *Bioresour. Technol.* **2025**, *426*, 132393. [\[CrossRef\]](#)

64. Leichtmann, B.; Humer, C.; Hinterreiter, A.; Streit, M.; Mara, M. Effects of explainable artificial intelligence on trust and human behavior in a high-risk decision task. *Comput. Hum. Behav.* **2023**, *139*, 107539.

38. Shi, Y.; Wang, Z.; Du, X.; Gong, B.; Jegatheesan, V.; Haq, I.U. Những tiến bộ gần đây trong dự đoán hiện tượng bám bẩn tr ong các bể phản ứng sinh học màng. *Membranes* 2021, *11*, 381. [\[CrossRef\]](#)

39. Ni, B.-J.; Rittmann, B.E.; Yu, H.-Q. Các sản phẩm v i sinh vật hòa tan và hàm ý của chúng trong công nghệ sinh học nuôi cấy hỗn hợp. *Trends Biotechnol.* 2011, *29*, 454–463. [\[Cross Ref\]](#)

40. Fenu, A.; Guglielmi, G.; Jimenez, J.; Spèrandio, M.; Saroj, D.; Lesjean, B.; Brepols, C.; Thoeys, C.; Nopens, I. Mô hình hó a các quy trình bể phản ứng sinh học màng (MBR) dựa trên mô hình bùn hoạt tính (ASM): Đánh giá phê bình, đặc biệt chú tro ng đến các đặc thù của MBR. *Water Res.* 2010, *44*, 4272–4294. [\[CrossRef\]](#)

41. Achilli, A.; Cath, T.Y.; Marchand, E.A.; Childress, A.E. Bể phản ứng sinh học màng thẩm thấu thuận: Một giải pháp thay thế ít bám bẩn cho các quy trình MBR. *Desalination* 2009, *239*, 10–21. [\[CrossRef\]](#)

42. Hamed, H.; Ehteshami, M.; Mirbagheri, S.A.; Zendejboudi, S. Các công cụ xác định mới để khảo sát có hệ thống sự xuất hiện hiện tượng bám bẩn trong các bể phản ứng sinh học màng. *Chem. Eng. Res. Des.* 2019, *144*, 334–353. [\[CrossRef\]](#)

43. Giwa, A.; Daer, S.; Ahmed, I.; Marpu, P.; Hasan, S. Khảo sát thực nghiệm và mô hình hóa bằng mạng nơ-ron nh ân tạo (ANN) đối với bể phản ứng sinh học màng tăng cường điện để xử lý nước thải. *J. Water Process Eng.* 2016, *11*, 88–97. 44. Nguyen, T.N.; Do, K.U.; Tran, T.P.N.; Van Nguyen, T.; Chu, Q.X. Mô hình dự đoán hiện tượng bám bẩn màng trong bể phản ứn g sinh học màng xử lý nước thải sinh hoạt bằng học máy. *Water Environ. Res.* 2025, *97*, e70205. [\[CrossRef\]](#)

45. de Queiroz, M.M.; Moreira, V.R.; Amaral, M.C.S.; Oliveira, S.M.A.C. Các thuật toán học máy dự đoán hiệu suất của bể phản ứng sinh học màng: Bài tổng quan. *J. Environ. Manag.* 2025, *380*, 124978. [\[CrossRef\]](#)

46. Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A.N.; Kaiser, Ł.; Polosukhin, I. Chỉ cần cơ chế chú ý. *Adv. Neural Inf. Process. Syst.* 2017, *30*, 6000–6010. 47. Frontistis, Z.; Lykogiannis, G.; Sarpanis, A. Ứng dụng học máy trong các hệ thống bể phản ứng sinh học màng: Tiến triển, thách thức và t riển vọng tương lai: Bài tổng quan. *Environments* 2023, *10*, 127. [\[CrossRef\]](#)

48. Molnar, C. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, ấn bản lần thứ 2; Leanpub: Victoria, BC, Canada , 2022. 49. Liang, J.; Lee, S.; Ren, X.; Guo, Y.; Park, J.; Park, S.-G.; Kim, J.-Y.; Hwang, M.-H. Khung dự đoán hiện tượng bám bẩn màng trong các bể phản ứng sinh học màng (MBR) quy mô toàn phần: Tích hợp kỹ thuật đặc trưng dựa trên AI và AI có thể g iải thích (XAI). *Processes* 2025, *13*, 2352. [\[CrossRef\]](#)

50. Zhu, Y.; Wang, Y.; Zhu, E.; Ma, Z.; Wang, H.; Chen, C.; Guan, J.; Waite, T.D. Dự đoán hiện tượng bám bẩn màng tại các nhà máy xử lý nước thải sử dụng bể phản ứng sinh học màng chìm bằng học má y. *Environ. Sci. Technol.* 2025, *59*, 10010–10021. [\[CrossRef\]](#)

51. Rudin, C. Hãy ngừng giải thích các mô hình học máy hộp đen cho những quyết định có hệ quả lớn và thay vào đó hãy sử dụng các mô hình có thể diễn giải. *Nat. Mach. Intell.* 2019, *1*, 206–215. [\[CrossRef\]](#)

52. Lundberg, S.M.; Lee, S.-I. Một phương pháp thống nhất để diễn giải các dự đoán của mô hình. *Adv. Neural Inf. Process. Syst.* 2017, *30*, 4768–4777. 53. Lundberg, S.M.; Erion, G.; Chen, H.; DeGrave, A.; Prutkin, J.M.; Nair, B.; Kat z, R.; Himmelfarb, J.; Bansal, N.; Lee, S.-I. Từ giải thích cục bộ đến hiểu biết toàn cục với AI có thể giải thích cho cây quyết định . *Nat. Mach. Intell.* 2020, *2*, 56–67. [\[CrossRef\]](#)

54. LeCun, Y.; Bengio, Y.; Hinton, G. Học sâu. *Nature* 2015, *521*, 436–444. [\[CrossRef\]](#)

55. Ribeiro, M.T.; Singh, S.; Guestrin, C. “Tại sao tôi nên tin bạn?” Giải thích các dự đoán của mọi bộ phân loại. Trong Kỷ yếu H ội nghị Quốc tế ACM SIGKDD lần thứ 22 về Khám phá Tri thức và Khai phá Dữ liệu, San Francisco, CA, Hoa Kỳ, ngày 13–17 thá ng 8 năm 2016; tr. 1135–1144. [\[CrossRef\]](#)

56. Verrecht, B.; Judd, S.; Guglielmi, G.; Brepols, C.; Mulder, J. Mô hình năng lượng s ục khí cho bể phản ứng sinh học màng ngập chìm. *Water Res.* 2008, *42*, 4761–4770. [\[CrossRef\]](#)

57. Germain, E.; Nelles, F.; Drew s, A.; Pearce, P.; Kraume, M.; Reid, E.; Judd, S.J.; Stephenson, T. Ảnh hưởng của sinh khối đến quá trình truyền oxy trong các b ể phản ứng sinh học màng. *Water Res.* 2007, *41*, 1038–1044. [\[CrossRef\]](#) [\[PubMed\]](#)

58. Diaz, O.; Gonzalez, E.; Vera, L. Ảnh hưởng của việc sục khí làm sạch và hiện tượng bám bẩn tồn dư đến sự hình thành và nén bánh bùn trong các bể phản ứng sinh học màng. *Ind. Eng. Chem. Res.* 2024, *63*, 13740–13751. [\[CrossRef\]](#)

59. Sun, J.; Liang, P.; Yan, X.; Zuo, K.; Xiao, K.; Xia, J.; Qiu, Y.; Wu, Q.; Wu, S.; Huang, X. Giảm tiêu thụ năng lượng sục khí trong bể phản ứng sinh học màng quy mô lớn: Mô phỏng quy trình và ứng dụng kỹ thuật. *Water Res.* 2016, *93*, 205–213. [\[CrossRef\]](#)

60. Ghorbani Bam, P.; Rezaei, N.; Roubanis, A.; Austin, D.; Austin, E.; Tarroja, B.; Takacs, I.; Villez, K.; Rosso, D. Ứng dụng bản sao số trong lĩnh vực nước: Bài tổng quan. *Water* 2025, *17*, 2957. [\[CrossRef\]](#)

61. Rodríguez-Alonso, C.; Pena-Regueiro, I.; García, Ó. Nền tảng bản sao số cho các nhà máy xử lý nước sử dụng kiế n trúc vi dịch vụ. *Sensors* 2024, *24*, 1568. [\[CrossRef\]](#) [\[PubMed\]](#)

62. Xu, M.; Liu, D. Bể phản ứng sinh học màng tích hợp AI: Tổng quan về kiến trúc điều khiển và tối ưu hóa thông số vận hành nhằm loại bỏ nitor và phốt pho. *Water* 2025, *17*, 2899. [\[CrossRef\]](#)

63. Wei, Q.; Xu, Z.; Yin, H. Nâng cao khả năng dự đoán nitor và phân tích quy trình cơ chế trong xử lý nước thải có độ mặn cao bằng phương pháp học máy có thể diễn giải. *Bioresour. Technol.* 2025, *426*, 132393. [\[CrossRef\]](#)

64. Hnterreiter, A.; Streit, M.; Mara, M. Ảnh hưởng của trí tuệ nhân tạo có thể giải thích đến niềm tin và hành vi con người trong m ột nhiệm vụ ra quyết định có rủi ro cao. *Comput. Hum. Behav.* 2023, *139*, 107539.

65. Goncalves, A.; Correia, A. Engineering Explainable AI Systems for GDPR-Aligned Decision Transparency: A Modular Framework for Continuous Compliance. *J. Cybersecur. Priv.* **2025**, *6*, 7. [\[CrossRef\]](#)

66. Sheik, A.G.; Kumar, A.; Srungavarapu, C.S.; Azari, M.; Ambati, S.R.; Bux, F.; Patan, A.K. Insights into the application of explainable artificial intelligence for biological wastewater treatment plants: Updates and perspectives. *Eng. Appl. Artif. Intell.* **2025**, *144*, 110132. [\[CrossRef\]](#)

67. Teixeira, B.; Pinto, T.; Vale, Z. Detecting Concept Drift with SHapley Additive ExPlanations for Intelligent Model Retraining in Energy Generation Forecasting. In *World Conference on Explainable Artificial Intelligence*; Springer: Berlin/Heidelberg, Germany, 2025; pp. 156–168.

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.

65. Goncalves, A.; Correia, A. Thiết kế các hệ thống AI có khả năng giải thích nhằm đảm bảo tính minh bạch trong ra quyết đị nh phù hợp với GDPR: Một khuôn khổ mô-đun cho việc tuân thủ liên tục. *J. Cybersecur. Priv.* 2025, 6, 7. [\[CrossRef\]](#)

66. Sheik, A. G.; Kumar, A.; Srungavarapu, C.S.; Azari, M.; Ambati, S.R.; Bux, F.; Patan, A.K. Những hiểu biết về ứng dụng trí tuệ nhân tạo có khả năng giải thích trong các nhà máy xử lý nước thải sinh học: Cập nhật và triển vọng. *Eng. Appl. Artif. Intell.* 2025, 144, 1101 32. [\[CrossRef\]](#)

67. Teixeira, B.; Pinto, T.; Vale, Z. Phát hiện độ lệch khái niệm bằng SHapley Additive ExPlanations để huấn luyệ n lại mô hình thông minh trong dự báo sản lượng năng lượng. Trong *World Conference on Explainable Artificial Intelligence*; Sprin ger: Berlin/Heidelberg, Đức, 2025; tr. 156–168.

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.